FADENA
FACULTAD DE DEFENSA NACIONAL

Universidad de la Defensa Nacional

Facultad de Defensa Nacional

Licenciatura en Ciberdefensa

Sistemas de tratamiento de Datos

Álgebra Relacional y Cálculo Relacional

Año: 2025

FADENA
FACULTAD DE DEFENSA NACIONAL

Universidad de la Defensa Nacional

Introducción

En este módulo se presentan el álgebra relacional y el cálculo relacional, definidos por E. F. Codd como la base de los lenguajes relacionales.

Un lenguaje de consulta es un lenguaje en el que los usuarios solicitan información de la base de datos, y pueden clasificarse como procedimentales o no procedimentales. En los lenguajes **procedimentales** el usuario indica al sistema que lleve a cabo una serie de operaciones en la base de datos para calcular el resultado deseado. En los lenguajes **no procedimentales** el usuario describe la información deseada sin dar un procedimiento concreto para obtener esa información. La mayor parte de los sistemas comerciales de bases de datos relacionales ofrecen un lenguaje de consultas que incluye elementos de los enfoques procedimental y no procedimental (como por ejemplo SQL). Se puede decir que el álgebra relacional es un lenguaje procedural de alto nivel, mientras que el cálculo relacional es un lenguaje no procedural. Sin embargo, ambos lenguajes son equivalentes: para cada expresión del álgebra, se puede encontrar una expresión equivalente en el cálculo, y viceversa.

Tanto el álgebra como el cálculo son lenguajes formales no muy amigables; sin embargo, es conveniente estudiarlos porque sirven para ilustrar las operaciones básicas que todo lenguaje de manejo de datos debe ofrecer. Además, han sido la base para otros lenguajes relacionales de manejo de datos de más alto nivel.

Álgebra relacional

El álgebra relacional es un lenguaje formal con una serie de operadores que trabajan sobre **una o varias relaciones** para obtener **otra relación resultado**, sin que cambien las relaciones originales. Tanto los operandos como los resultados son relaciones, por lo que la salida de una operación puede ser la entrada de otra operación. Esto permite anidar expresiones del álgebra, del mismo modo que se pueden anidar las expresiones aritméticas. A esta propiedad se le denomina clausura: las relaciones son cerradas bajo el álgebra, del mismo modo que los números son cerrados bajo las operaciones aritméticas.

Existen ocho operadores originalmente propuestos por Codd, y otros operadores adicionales que añaden potencia al lenguaje. De los ocho operadores, sólo hay cinco que son fundamentales: selección (o restricción), proyección, producto cartesiano, unión y diferencia. A esos se les puede sumar también la operación de renombramiento. Los operadores fundamentales permiten realizar la mayoría de las operaciones de obtención de datos. Los operadores no fundamentales son la concatenación (join), la intersección y la división, que se pueden expresar a partir de los cinco operadores fundamentales. La selección (restricción), la proyección, y el renombramiento son operaciones **unarias** porque operan sobre una sola relación. El resto de las operaciones son **binarias** porque trabajan sobre pares de relaciones.

Operaciones relacionales unarias: selección, proyección, renombramiento

Operación selección (restricción)

La selección opera sobre una sola relación R y da como resultado otra relación cuyas tuplas son las tuplas de R que satisfacen la condición especificada. Se emplea para seleccionar un **subconjunto** de las tuplas de una relación que satisfacen una **condición de selección** (se puede considerar como un filtro que mantiene sólo las tuplas que satisfacen la condición). Esta condición es una comparación en la que aparece al menos un atributo de R, o una combinación booleana de varias de estas comparaciones.

En general, la selección está designada como:

$\sigma_{<\text{condición de selección}>}(R)$

donde el símbolo σ (sigma) se utiliza para especificar el operador de selección, mientras que la condición de selección es una expresión lógica (o booleana) especificada sobre los atributos de la relación R. Observe que R es, generalmente, una expresión de álgebra relacional cuyo resultado es una relación: la más sencilla de estas expresiones es sólo el nombre de una relación de base de datos. El **resultado de selección tiene los mismos atributos que R**. La expresión lógica especificada en está constituida por un número de cláusulas de la forma:

<nombre de atributo><operador de comparación><valor constante>,

o bien:

<nombre de atributo><operador de comparación><nombre de atributo>,

donde es el nombre de un atributo de R, <operador de comparación> suele ser uno de los operadores {=, <, ≤, >, ≥, ≠}, y <valor constante> es un valor del dominio del atributo. En el segundo caso, la selección incluye comparaciones entre dos atributos. Las cláusulas pueden estar conectadas arbitrariamente por operadores lógicos and (∧), or (∨) y not (¬) para formar una condición de selección general combinando varios predicados.

Por ejemplo, para seleccionar las tuplas de todos los empleados que trabajan en el departamento 4 y ganan más de 25.000 dólares al año, o los que trabajan en el 5 y ganan más de 30.000 dólares al año, podemos especificar la siguiente operación de selección:

$\sigma_{(DptoNo=4\ AND\ Sueldo>25000)\ OR\ (DptoNo=5\ AND\ Sueldo>30000)}(EMPLEADO)$.

La <condición de selección> se aplica independientemente a cada tupla t de R. Esto se realiza sustituyendo cada ocurrencia de un atributo A_i en la condición de selección por su valor en la tupla $t[A_i]$. Si la condición se evalúa como verdadero, la tupla t se selecciona. Todas las tuplas seleccionadas aparecen en el resultado de selección. Las condiciones lógicas and, or y not tienen la siguiente interpretación:

- (condición1 **AND** condición2) es verdadero si las dos condiciones (condición1 y condición2) lo son; en cualquier otro caso, es falso.

- (condición1 **OR** condición2) es verdadero si (condición1) o (condición2) o ambas son verdaderas; en cualquier otro caso, es falso.
- (**NOT** condición) es verdadero si condición es falso; en cualquier otro caso es falso.

La operación selección es **unaria**, es decir, se aplica a una sola relación. Además, esta operación se aplica a cada tupla individualmente; por consiguiente, las condiciones de selección no pueden implicar a más de una tupla. El grado de la relación resultante de una operación selección (su número de atributos) es el mismo que el de R. El número de tuplas en la relación resultante es siempre menor que o igual que el número de tuplas en R.

Además, la operación selección es conmutativa, es decir:

$$\sigma_{<condición1>}(\sigma_{<condición2>}(R)) = \sigma_{<condición2>}(\sigma_{<condición1>}(R))$$

por lo que puede aplicarse una secuencia de selecciones en cualquier orden. Además, se puede combinar una cascada de operaciones de selección en una sola a través de conectores lógicos **AND**:

$$\sigma_{<condición1>}(\sigma_{<condición2>}(\ldots(\sigma_{<condición>}(R))\ldots)) = \sigma_{<condición1>AND<condición2>AND\ldots AND<condición>}(R)$$

Operación Proyección

La proyección opera sobre una sola relación R y da como resultado otra relación que contiene un **subconjunto vertical** de R, extrayendo los valores de los **atributos especificados** y **eliminando duplicados**. Si sólo

estamos interesados en unos atributos de una relación, se usa la proyección donde su resultado puede visualizarse como una partición vertical de la relación en otras dos: una contiene las columnas (atributos) necesarias y otra las descartadas.

La forma general de la operación proyección es:

$\pi_{<\text{lista de atributos}>}(R)$

donde π(pi) es el símbolo usado para representar la operación proyección, mientras que <lista de atributos> contiene la lista de campos de la relación R que queremos. De nuevo, observe que R es, en general, una expresión de álgebra relacional cuyo resultado es una relación, cuyo caso más simple es obtener sólo el nombre de una relación de base de datos. El resultado de la operación proyección sólo tiene los atributos especificados en <lista de atributos> en el mismo orden a como aparecen en la lista. Por tanto, su grado es igual al número de atributos contenidos en <lista de atributos>.

Si la lista de atributos sólo incluye atributos no clave de R, es posible que se dupliquen tuplas. La operación proyección **elimina cualquier tupla duplicada**, por lo que el resultado de la misma es un conjunto de tuplas y, por consiguiente, una **relación válida**. Por ejemplo, consideremos la siguiente operación proyección:

$\pi_{\text{sexo,sueldo}}(\text{EMPLEADO})$

Si en la relación EMPLEADO existieran varias tuplas donde una mujer cobra 25.000 dólares anuales, la tupla <'M', 25000> sólo aparecerá una

vez en la relación resultado, aun cuando su combinación de valores se repitiera en la relación original.

La operación proyección es **unaria**, es decir, se aplica a una sola relación. Además, el número de tuplas de una relación resultante de una operación proyección es siempre menor o igual que el de las contenidas en R. Si la lista de proyección es una superclave de R (esto es, incluye alguna clave de R) la relación resultante tiene el mismo número de tuplas que R.

Operación renombramiento (renombrar)

A diferencia de las relaciones de la base de datos, los resultados de las expresiones de álgebra relacional no tienen un nombre que se pueda usar para referirse a ellas. Resulta útil poder ponerles nombre; utilizando la operación renombramiento.

En general, podemos querer aplicar varias operaciones de álgebra relacional una tras otra. Podemos escribir las operaciones como una única expresión de álgebra relacional anidando dichas operaciones, o aplicar una sola expresión una única vez y crear relaciones intermedias. En el último caso, puede que queramos asignar nombres a dichas relaciones intermedias.

Con frecuencia, resulta más simple partir una secuencia compleja de operaciones en relaciones intermedias que escribir una única expresión de álgebra relacional. Podemos usar también esta técnica para renombrar los atributos en las relaciones intermedias y resultantes, lo

que puede resultar útil cuando se emplea junto con operaciones más complejas como unión y concatenación que se verán más adelante.

Si no se realiza un renombrado, los nombres de atributo de la relación resultante de una selección son los mismos que los de la relación original y aparecen en el mismo orden. Para el caso de una operación proyección, ocurre lo mismo con los indicados en la lista de proyección.

Podemos definir una operación renombrar como un operador **unario**. Una operación renombrar aplicada a una relación R de grado n aparece denotada de cualquiera de estas tres formas:

- $\rho_{S(B1, B2, ..., Bn)}(R)$: renombra tanto la relación como sus atributos.
- $\rho_{S}(R)$: sólo renombra la relación.
- $\rho_{(B1, B2, ..., Bn)}(R)$: sólo renombra los atributos.

donde el símbolo ρ(rho) se utiliza para especificar el operador renombrar, S es el nombre de la nueva relación y B_1, B_2, …, B_n son los nuevos atributos. Si los atributos de R son (A_1, A_2, …, A_n) por este orden, entonces cada A_i es renombrado como B_i.

También se puede denotar como:

- TEMP ← Expresión_Relacional (por ej. TEMP ← $\sigma_{Dno=5}$(Empelado))
- R(B1, B2, …, Bn) ← Expresión_Relacional

donde Expresión_Relacional puede ser una Relación original.

Operaciones de álgebra relacional de la teoría de conjuntos: unión, intersección, diferencia.

Para **combinar los elementos de dos conjuntos** se utilizan varias operaciones de la teoría de conjuntos, como la unión, la intersección y la diferencia de conjuntos (llamada también a veces menos). Todas ellas son operaciones **binarias**, es decir, se aplican a dos conjuntos (de tuplas). Cuando se refieren a las bases de datos relacionales, las relaciones sobre las que se aplican estas tres operaciones deben tener el **mismo tipo de tuplas**; esta condición recibe el nombre de **compatibilidad de unión**. Dos relaciones $R(A_1, A_2, \dots, A_n)$ y $S(B_1, B_2, \dots, B_n)$ se dice que son de unión compatible si tienen el mismo grado n y si el $dom(A_i) = dom(B_i)$ para $1 \leq i \leq n$. Esto significa que **ambas relaciones tienen el mismo número de atributos y que cada par correspondiente cuenta con el mismo dominio**. En muchos casos es necesario realizar proyecciones para hacer que dos relaciones sean compatibles.

Podemos definir las tres operaciones unión, intersección y diferencia de conjunto en dos relaciones de unión compatible R y S del siguiente modo:

- **Unión:** El resultado de esta operación, especificada como $R \cup S$, es una relación que incluye todas las tuplas que están tanto en R como en S o en ambas, R y S. Las tuplas duplicadas se eliminan.
- **Intersección:** El resultado de esta operación, especificada como $R \cap S$, es una relación que incluye todas las tuplas que están en R y en S.

- **Diferencia de conjunto (o menos):** El resultado de esta operación, especificada como R – S, es una relación que incluye todas las tuplas que están en R, pero no en S.

Los nombres de atributo de la relación resultante son los mismos que los de R. Siempre es posible cambiar el nombre de estos valores a través del operador renombrar.

Tanto la unión como la intersección son operaciones conmutativas, esto es,

$R \cup S = S \cup R$ y $R \cap S = S \cap R$

La operación menos no es conmutativa; por tanto, en general,

$R - S \neq S - R$

En particular la intersección puede expresarse en términos de unión y diferencia de conjuntos del siguiente modo:

$R \cap S = R \cup S - (R - S) - (S - R)$

Por tanto, la **intersección de conjuntos no es una operación fundamental** y no añade potencia al álgebra relacional. Sencillamente, es más conveniente escribir la intersección que la combinación de las otras.

Operación Producto cartesiano

El producto cartesiano multiplica dos relaciones, definiendo una nueva relación que tiene todos los pares posibles de tuplas de las dos relaciones. Si la relación R tiene p tuplas y n atributos, y la relación S

tiene q tuplas y m atributos, la relación resultado tendrá p ∗ q tuplas y n + m atributos. Obtiene una relación cuyas tuplas están formadas por la concatenación de todas las tuplas de R con todas las tuplas de S.

Esta operación se identifica por X. También de una **operación de conjuntos binarios**, aunque **no es necesario que las relaciones en las que se aplica sean una unión compatible**. Como se mencionó, en su forma binaria produce un nuevo elemento combinando cada tupla de una relación (conjunto) con los de la otra. En general, el resultado de $R(A_1, A_2, \ldots, A_n)$ X $S(B_1, B_2, \ldots, B_m)$ es una relación Q con un grado de n + m atributos $Q(A_1, A_2, \ldots, A_n, B_1, B_2, \ldots, B_m)$, en este orden. La relación resultante Q tiene una tupla por cada combinación de éstas.

Ya que es posible que haya atributos con el mismo nombre en las dos relaciones, **el nombre de la relación se antepondrá al del atributo** en este caso para que los nombres de los atributos sigan siendo **únicos** en la relación resultado. Para los atributos que sólo aparecen en uno de los dos esquemas se suele omitir el prefijo con el nombre de la relación. Así mismo se puede utilizar la operación renombramiento para mantener la unicidad de nombres de atributos en la relación resultado.

Esta operación produce nuevas tuplas concatenando todas las posibles combinaciones de tuplas desde n relaciones subyacentes. **La operación aplicada, por sí misma, no tiene sentido**. Es útil cuando va seguida por una selección que correlacione los valores de los atributos procedentes de las relaciones componentes. Una vez realizado el producto cartesiano

de dos relaciones, se puede realizar una restricción que elimine aquellas tuplas cuya información no esté relacionada.

Por ejemplo, consideremos la consulta "Hallar los nombres de todos los clientes que tienen concedido un préstamo en el banco y averiguar su número e importe". En primer lugar, se calcula el producto cartesiano de las relaciones prestatario y préstamo. Después se seleccionan las tuplas que sólo atañen al mismo número_préstamo, seguidas por la proyección de nombre_cliente, número_préstamo e importe resultantes:

$$\pi_{\text{nombre_cliente,préstamo.número_prestamo, importe}}$$

$$(\sigma_{\text{prestatario.número_préstamo = préstamo.número_préstamo}} (\text{prestatario X préstamo}))$$

La combinación del producto cartesiano y la restricción del modo en que se acaba de realizar se puede reducir a la operación de concatenación (JOIN) que se presenta más adelante.

Operación concatenación (join)

La concatenación de dos relaciones R y S obtiene como resultado una relación cuyas tuplas son todas las tuplas de R concatenadas con todas las tuplas de S que en los atributos comunes (aquellos que se llaman igual) tienen los mismos valores; o bien cumplen con una condición de conexión. En el caso de los atributos comunes que tienen el mismo valor, aparecen una sola vez en el resultado.

La concatenación es una operación binaria que permite combinar ciertas selecciones y un producto cartesiano en una sola operación. Se denota

por el símbolo ⋈. La operación concatenación forma un producto cartesiano de sus dos argumentos, realiza una selección forzando la igualdad de los atributos que aparecen en ambos esquemas de relación y, finalmente, elimina los atributos duplicados.

La **forma general de una concatenación** en dos relaciones $R(A_1, A_2, \ldots, A_n)$ y $S(B_1, B_2, \ldots, B_m)$ es:

$R \bowtie_{\text{<condición de conexión>}} S$

El resultado de la concatenación (join) es una relación Q de n + m atributos $Q(A_1, A_2, \ldots, A_n, B_1, B_2, \ldots, B_m)$ por este orden; Q tiene una tupla por cada combinación de éstas siempre que dicha combinación satisfaga la condición de conexión. Ésta es la principal diferencia existente entre el producto cartesiano y la concatenación. En la concatenación sólo aparecen en el resultado las combinaciones de tuplas que satisfacen la condición de conexión, mientras que en el producto cartesiano se incluyen todas las combinaciones de tuplas.

La **condición de conexión** está especificada sobre los atributos de las dos relaciones R y S, y es evaluada para cada combinación de tuplas, incluyéndose en la relación Q resultante en forma de **una única tupla combinada sólo aquéllas** cuya **condición** de conexión se evalúe como **verdadero**. Una condición general e conexión tiene la forma:

<condición> AND <condición> AND … AND <condición>

donde cada condición es de la forma $A_i \, \theta \, B_j$, A_i es un atributo de R, B_j lo es de S, A_i y B_j tienen el mismo dominio y θ(theta) es uno de los

operadores de comparación {=, <, ≤, >, ≥, ≠}. Una concatenación con una condición de conexión de este tipo recibe el nombre de **asociación (theta join)**. **Las tuplas cuyos atributos de conexión son NULL, o aquéllas cuya condición es falsa, no aparecen en el resultado.**

El uso más habitual de concatenación supone el uso de condiciones de conexión sólo con comparaciones de igualdad, recibiendo el nombre de **equijoin,** donde se aplica una condición de selección para que las tuplas se unan solo cuando los valores de los atributos comunes son iguales. Por ejemplo,

$$\text{ESUDIANTE} \bowtie_{(\text{estudiante.id}=\text{curso.estudianteid})} \text{CURSO}$$

La versión simplificada del equijoin, **natural join** o **concatenación natural**, automáticamente une las tuplas basándose en los atributos con el mismo nombre y elimina los atributos duplicados en el resultado. La definición estándar de esta operación precisa que los dos atributos de conexión tengan el mismo nombre en ambas relaciones. Si éste no es el caso, se aplica en primer lugar una operación de renombrado.

En general, una concatenación natural se lleva a cabo equiparando todos los pares de atributos que tengan el mismo nombre en las dos relaciones. Puede existir una lista de atributos de conexión para cada relación, y los pares correspondientes deben tener el mismo nombre. De forma general, aunque no estandarizada, ésta es una definición posible:

$$R *_{(\langle\text{lista1}\rangle),(\langle\text{lista2}\rangle)} S$$

En este caso, <lista1> especifica una lista de i atributos de R, mientras que <lista2> especifica una lista de i atributos de S. Estas listas se emplean para formar condiciones de comparación coherentes entre los atributos correspondientes para, a continuación, evaluarlas juntas mediante un operador AND. Sólo se mantiene en el resultado la lista de atributos correspondiente a la primera relación R (<lista1>).

Operación división

La división, especificada mediante ÷, resulta adecuada para las consultas que incluyen la expresión "para todos".

Supongamos que se tienen dos relaciones:

- R: Una relación con atributos (A_1, …, A_m, B_1, …, B_n).
- S: Una relación con atributos (B_1, …, B_n).

La operación R ÷ S devuelve una nueva relación con los atributos (A_1, …, A_m). Es decir, que el resultado es una relación T(Y), donde Y es el conjunto de atributos de R que no lo son de S (es decir, Y = A - B). Una tupla con los valores (a_1, …, a_m) estará en el resultado de R ÷ S si, y sólo si, por **cada tupla** (b_1, …, b_n) que existe en la relación S, la tupla (a_1, …, a_m, b_1, …, b_n) también existe en la relación R. Es decir, que la división obtiene una relación T con un conjunto de atributos Y y que contiene las tuplas de R que están acompañadas de todas las tuplas de S.

En términos sencillos, la división encuentra los valores del conjunto de atributos de R que están relacionados con **todos** los valores del conjunto de atributos de S.

Veámoslo con un ejemplo práctico. Pensemos en el siguiente escenario con dos relaciones (tablas):

- Inscripciones: Muestra qué estudiantes se han inscrito en qué cursos.
    - Atributos: (Estudiante, Curso)
    - Tuplas: (Ana, DB1), (Ana, DB2), (Juan, DB1), (Juan, Algoritmos), (Pedro, DB1), (Pedro, DB2)
- CursosObligatorios: Lista los cursos que son obligatorios.
    - Atributos: (Curso)
    - Tuplas: (DB1), (DB2)

Si queremos responder a la pregunta: "¿Qué estudiantes se han inscrito en **todos** los cursos obligatorios?", utilizamos la operación de división. La consulta sería: Inscripciones ÷ CursosObligatorios

1. **Analizamos las tuplas** de Inscripciones: **Ana** está inscripta en DB1 y DB2; **Juan** está inscripto en DB1 y Algoritmos; **Pedro** está inscripto en DB1 y DB2.
2. **Analizamos las tuplas** de CursosObligatorios: El conjunto de cursos obligatorios es (DB1, DB2).
3. **Aplicamos la lógica de la división**:

- Ana está relacionada con todas las tuplas de CursosObligatorios (es decir, con DB1 y DB2). Por lo tanto, (Ana) estará en el resultado.
- Juan no está relacionado con todas las tuplas de CursosObligatorios (le falta DB2). Por lo tanto, (Juan) no estará en el resultado.

- Pedro está relacionado con todas las tuplas de CursosObligatorios (con DB1 y DB2). Por lo tanto, (Pedro) estará en el resultado.

El resultado de la operación Inscripciones ÷ CursosObligatorios sería una **nueva relación** con el atributo Estudiante y las tuplas: (Ana), (Pedro).

Operaciones del álgebra relacional extendida (o adicionales)

Proyección generalizada

La proyección generalizada es una operación que extiende las posibilidades de la proyección original permitiendo la inclusión de funciones aritméticas con atributos en la lista de proyección. La forma generalizada puede expresarse del siguiente modo:

$\pi_{F1,F2,\ldots,FN}(R)$

donde F_1, F_2, …, F_N son funciones aritméticas sobre los atributos de la relación R y pueden involucrar constantes. Esta operación está ideada como una ayuda a la hora de desarrollar informes en los que los valores calculados deben generarse en columnas. Por ejemplo, supongamos que se dispone de una relación información_crédito, en la que se proporciona entre otra información el límite de crédito y el importe consumido actualmente (saldo_crédito); y se quisiera determinar el importe disponible para cada persona, se puede escribir la expresión siguiente:

$\pi_{\text{nombre_cliente, límite} - \text{saldo_crédito}}$ (información_crédito)

En este caso el atributo resultante de límite - saldo_crédito no tiene nombre asignado, y se podría aplicar la operación renombramiento al resultado de la proyección generalizada para darle nombre.

Funciones de agregación y agrupamiento

Otro tipo de peticiones que no pueden expresarse a través del álgebra relacional básico son las que se utilizan para calcular funciones **matemáticas de agregación.** Las funciones de agregación toman un conjunto de valores y devuelven como resultado un único valor. Esta versión extendida incorpora la funcionalidad de resumir datos, algo fundamental para la generación de informes.

Las operaciones de agregación no operan sobre tuplas individuales, sino sobre **conjuntos de tuplas**. Toman una columna de valores como entrada y producen un único valor como resultado. Los funciones de agregación más comunes son:

- **SUM:** Calcula la suma total de los valores de una columna numérica.
- **AVG:** Calcula el promedio de los valores de una columna numérica.
- **COUNT:** Cuenta el número de tuplas en una relación o el número de valores no nulos en una columna.
- **MAX:** Encuentra el valor máximo en una columna.
- **MIN:** Encuentra el valor mínimo en una columna.

Para representar estas operaciones en el álgebra relacional extendida, se utiliza una notación especial que combina el operador de agregación con la relación sobre la que se opera.

La forma general de la operación de agregación Ģ es:

$G_1,G_2,...,G_m$ Ģ $_{F1(A1),F2(A2),...}(R)$

- **$G_1,G_2,...,G_n$**: constituye una lista de atributos sobre los que se realiza la agrupación. Si no se especifica, la agregación se aplica a toda la relación.
- **Ģ**: Es el símbolo del operador de agregación.
- **$F_1(A_1),F_2(A_2),..,F_m(A_m)$.**: Son las funciones de agregación (F) aplicadas a los atributos (A) de la relación R.

El significado de la operación es el siguiente: las tuplas del resultado se dividen en grupos de manera que:

1. Todas las tuplas de cada grupo tienen los mismos valores para G_1, G_2, ..., G_n.
2. Las tuplas de grupos diferentes tienen valores diferentes para G_1, G_2, ..., G_n.

Por tanto, los grupos pueden identificarse por el valor de los atributos G_1, G_2, ..., G_n. Para cada grupo (g_1, g_2, ..., g_n) el resultado tiene una tupla (g_1, g_2, ..., g_n, a_1, a_2, ..., a_m) donde, para cada i, a_i es el resultado de aplicar la función de agregación F_i al multiconjunto de valores del atributo A_i en el grupo.

Por ejemplo, si se quisiera determinar el sueldo máximo de los empleados de cada sucursal, además de la suma de los sueldos, habría que escribir la expresión:

$$_{nombre_sucursal}\mathcal{G}_{sum(sueldo),max(sueldo)}(trabajo_por_horas)$$

Operaciones de concatenación externa (outer join)

Las operaciones concatenación descritas anteriormente emparejan tuplas que satisfacen la condición de conexión. Por ejemplo, para una concatenación natural, sólo aparecen en el resultado las tuplas de R que coinciden con las de S (y viceversa). Por consiguiente, aquellas tuplas sin coincidencia (o relacionadas) se eliminan del resultado. Las tuplas con valores NULL en los atributos de conexión también se eliminan. Esto equivale a una pérdida de información en el caso de que la concatenación se utilice para generar un informe basado en todos los datos de las relaciones.

Existe un conjunto de operaciones, llamadas concatenaciones externas, que pueden usarse cuando queremos mantener en el resultado todas las tuplas de R, o de S, o de ambas, independientemente de si tienen correspondencias o no en la otra relación. Esto permite ejecutar consultas en las que tuplas procedentes de dos tablas se combinan emparejando las filas correspondientes, pero sin perder aquéllas que no tienen ese “compañero”.

La operación **concatenación externa izquierda (left outer join)** $R =\bowtie S$ devuelve todas las tuplas de la **relación de la izquierda** y las tuplas

coincidentes de la relación de la derecha. Si una tupla de la tabla izquierda no tiene una tupla correspondiente en la tabla derecha, los atributos de la tabla derecha en el resultado se rellenan con valores **NULL**.

Una operación parecida, la **concatenación externa derecha (right outer join)** R ⋈= S es simétrico al left outer join. Devuelve todas las tuplas de la **relación de la derecha** y las tuplas coincidentes de la relación de la izquierda. Si una tupla de la tabla derecha no tiene una correspondencia en la tabla izquierda, los atributos de la tabla izquierda en el resultado se rellenan con valores **NULL**.

Una tercera operación, concatenación externa completa **(full outer join)** R =⋈= S , combina los resultados de los joins externos izquierdo y derecho. Devuelve **todas las tuplas** de ambas relaciones. Las tuplas se unen si hay una coincidencia en las tablas. Si una tupla de la izquierda no tiene una coincidencia en la derecha, o viceversa, la porción sin coincidencia se rellena con valores **NULL**. Este join es útil cuando se quiere ver la relación completa entre dos tablas, incluyendo tanto las coincidencias como las no-coincidencias de ambas partes.

Resumen de Operaciones del álgebra relacional básicas

Operación	**Objetivo**	**Notación**
SELECCIÓN (RESTRICCIÓN)	Selecciona todas las tuplas de una relación R que satisfacen la condición de selección.	$\sigma_{\text{<condición de selección>}}(R)$

PROYECCIÓN	Produce una nueva relación en la que sólo existen algunos de los atributos de R, y elimina las tuplas duplicadas.	$\pi_{<\text{lista de atributos}>}(R)$
ASOCIACIÓN (THETA JOIN)	Genera todas las combinaciones de tuplas de R y S que satisfacen la condición de conexión	$R \bowtie_{<\text{condición de conexión}>} S$
EQUIJOIN	Genera todas las combinaciones de tuplas de R y S que satisfacen una condición de conexión sólo con comparaciones de igualdad.	$R \bowtie_{<\text{condición de conexión}>} S$ $R \bowtie_{(<\text{atributos de conexión1}>), (<\text{atributos de selección2}>)} S$
CONCATENACIÓN NATURAL	Es lo mismo que EQUIJOIN excepto por el hecho de que los atributos de conexión de S no están incluidos en la relación resultante; si estos atributos tienen los mismos nombres, no tienen que especificarse.	$R \bowtie_{<\text{condición de conexión}>} S$ $R \bowtie_{(<\text{atributos de conexión1}>), (<\text{atributos de selección2}>)} S$ $R * S$
UNIÓN	Produce una relación que incluye todas las tuplas de R o S o de ambas; R y S deben ser de unión compatible.	$R \cup S$
INTERSECCIÓN	Produce una relación que incluye todas las tuplas que están en R y S; R y S deben ser compatibles con la unión.	$R \cap S$

DIFERENCIA (MENOS)	Produce una relación que incluye todas las tuplas de R que no están en S; R y S deben ser compatibles con la unión.	R – S
PRODUCTO CARTESIANO	Produce una relación que tiene los atributos de R y S e incluye tantas tuplas como posibles combinaciones de tuplas de R y S.	R X S
DIVISIÓN	Produce una relación T(Y) que incluye todas las tuplas t[Y] en R(A) que aparecen en S en combinación con cada tupla de S(B), donde A = Y B, o bien Y = A - B	R(A) ÷ S(B)

Cálculo relacional

Otro **lenguaje de consulta formal** para el modelo relacional es el **cálculo relacional**. En él escribimos una expresión **declarativa** para especificar una consulta de recuperación; por tanto, no hay una descripción del modo de evaluar una consulta. Una expresión de cálculo especifica **qué** se quiere recuperar en lugar de cómo hacerlo, por lo que se le considera un lenguaje **no procedural**. Esto le hace diferente del álgebra relacional, en donde debemos escribir una secuencia de operaciones para especificar la consulta de recuperación, razón por la que se le puede considerar como una forma procedural de declarar la misma, donde se indica al sistema **cómo** construir la relación deseada. Es posible anidar

operaciones de álgebra para formar una única expresión; sin embargo, siempre es necesario indicar explícitamente un cierto orden en una expresión de álgebra relacional. Este orden influye también en la estrategia de evaluación de la consulta. Una expresión de cálculo puede escribirse de diferentes formas, aunque esto no influye en el modo en que dicha consulta será evaluada.

Cualquier recuperación que pueda especificarse mediante el álgebra relacional básica puede hacerse del mismo modo a través de cálculos relacionales, y viceversa; en otras palabras, la potencia expresiva de ambos lenguajes es idéntica.

El cálculo relacional toma su nombre del cálculo de predicados, que es una rama de la lógica. Hay dos tipos de cálculo relacional, el orientado a **tuplas**, y el orientado a **dominios**. En el cálculo de predicados (lógica de primer orden), un predicado es una función con argumentos que se puede evaluar a verdadero o falso. Cuando los argumentos se sustituyen por valores, la función lleva a una expresión denominada proposición, que puede ser verdadera o falsa.

Los predicados se pueden conectar mediante AND, OR y NOT para formar predicados compuestos.

Cálculo orientado a tuplas

En el cálculo relacional orientado a tuplas, lo que interesa es encontrar tuplas para las que se cumple cierto predicado. El cálculo orientado a tuplas se basa en el uso de **variables tupla**. Una variable tupla es una

variable cuyo rango de valores son las tuplas de una relación, lo que significa que la variable podría tomar su valor de cualquier tupla individual de esa relación.

Una consulta de cálculo relacional sencilla tiene la siguiente forma:

{t | COND(t)}

donde t es una variable de tupla y COND(t) es una expresión condicional que implica a t. El resultado es el conjunto de todas las tuplas t que satisfacen COND(t).

Por ejemplo, para localizar todos los empleados cuyo salario es superior a 50.000 dólares podemos escribir la siguiente expresión:

{t | EMPLEADO(t) AND t.Sueldo>50000}

La condición EMPLEADO(t) especifica que la **relación de rango** de la variable de tupla t es EMPLEADO. Cada EMPLEADO t que satisface la condición t.Sueldo>50000 será recuperada. Observe que t.Sueldo hace referencia al atributo Sueldo de la variable de tupla t. Esta consulta recupera todos los valores de atributo de cada tupla t EMPLEADO seleccionada. Para obtener sólo algunos de los atributos (por ejemplo, el nombre y el primer apellido) escribimos:

{t.Nombre, t.Apellido1 | EMPLEADO(t) AND t.Sueldo>50000}

Informalmente, tenemos que especificar la siguiente información en una expresión de cálculo de tupla:

- Para cada variable de tupla t, la **relación de rango** R de t. Este valor se indica con una condición de la forma R(t).
- Una condición para seleccionar combinaciones de tuplas particulares. Como las variables de tupla alcanzan a sus respectivas relaciones de rango, la condición se evalúa por cada combinación posible de tuplas para identificar las **combinaciones seleccionadas** que la condición evalúa como VERDADERO.
- El conjunto de los atributos a recuperar, los **atributos solicitados**. Los valores de estos atributos se recuperan por cada combinación de tuplas seleccionada.

Una **expresión genérica de cálculo relacional de tupla** tiene esta forma:

$\{t_1.A_j , t_2.A_k, \dots , t_n.A_m \mid COND(t_1, t_2, \dots , t_n, t_{n+1}, t_{n+2}, \dots , t_{n+m})\}$

donde $t_1, t_2, \dots , t_n, t_{n+1}, \dots , t_{n+m}$ son variables de tupla y cada A_i es un atributo de la relación a la que t_i engloba. **COND es una condición o fórmula de cálculo relacional** de tupla. Una fórmula **está compuesta por** alguno de los siguientes elementos de cálculo más pequeños (llamados **átomos**):

1. Un átomo de la forma **$R(t_i)$**, donde R es un nombre de relación y t_i es una variable de tupla. Este átomo identifica el ámbito de la variable de tupla t_i como la relación cuyo nombre es R.
2. Un átomo de la forma **t_i.A op tj.B**, donde **op** es uno de los operadores de comparación del conjunto $\{=, <, \leq, >, \geq, \neq\}$, t_i y t_j son **variables de tupla y A y B son atributos** de las relaciones t_i y t_j.
3. Un átomo de la forma **t_i.A op c** ó **c op t_j.B**, donde **op** es uno de los operadores de comparación del conjunto $\{=, <, \leq, >, \geq, \neq\}$, t_i y t_j son

variables de tupla, A y B son atributos de las relaciones t_i y t_j, y **c** es una **constante**.

Cada uno de los **átomos** anteriores se evalúa como **VERDADERO o FALSO** para una combinación específica de tuplas; esto recibe el nombre de **valor de verdad** (o de veracidad) de un átomo. Para los átomos de la forma R(t), si t está asignada a una tupla que es miembro de la relación R especificada, ese átomo es VERDADERO; en cualquier otro caso es FALSO. En los átomos de tipo 2 y 3, si las variables de tupla están asignadas a tuplas en las que los valores de los atributos especificados de las mismas satisfacen la condición, entonces el átomo es VERDADERO.

Una **fórmula** (condición) está compuesta por **uno o varios átomos conectados** mediante los operadores lógicos **AND, OR y NOT.** Se puede dar una definición **recursiva** de las fórmulas por dos reglas:

- Regla 1: Cada átomo es una fórmula.
- Regla 2: Si F1 y F2 son fórmulas, entonces también lo son (F1 **AND** F2), (F1 **OR** F2), **NOT** (F1) y **NOT** (F2).

Además de los ya comentados, existen otros dos símbolos especiales llamados **cuantificadores** que pueden aparecer en las fórmulas: el **universal** (∀) y el **existencial** (∃). Estos cuantificadores se utilizan en las fórmulas para indicar a cuántas instancias se aplica el predicado. La distinción entre variables de tupla **libres** y **acotadas** en una fórmula es fundamental para entender cómo funcionan los cuantificadores (∀ y ∃).

De manera informal, una variable de tupla t es acotada si está cuantificada, lo que significa que aparece en una cláusula (∃t) o (∀t); en cualquier otro caso, es libre. Es decir, que si la variable de tupla no está dentro del alcance de un cuantificador es libre; mientras que si aparece dentro del alcance de un cuantificador es acotada.

Por ejemplo, consideremos las siguientes fórmulas:

- F1: d.NombreDpto='Investigación'
- F2: (∃t)(d.NúmeroDpto=t.Dno)
- F3: (∀d)(d.DniDirector='333445555')

La variable de tupla d es libre tanto en F1 como en F2, mientras que es acotada respecto al cuantificador (∀) en F3. t es acotada respecto al cuantificador (∃) en F2.

Con esto, se pueden agregar las reglas 3 y 4 para la definición de fórmulas:

- Regla 3: Si F es una fórmula, entonces (∃t)(F) también lo es, donde t es una variable de tupla. La fórmula (∃t)(F) es VERDADERO si F se evalúa como tal en alguna (al menos una) tupla asignada a las ocurrencias libres de t en F; en cualquier otro caso, (∃t)(F) es FALSO. Es decir, que verifica que **existe al menos una tupla** que cumple la condición.

- Regla 4: Si F es una fórmula, entonces (∀t)(F) lo es también, donde t es una variable de tupla. La fórmula (∀t)(F) es VERDADERO si F se evalúa como tal para cada tupla asignada a las ocurrencias

libres de t en F; en cualquier otro caso, (∀t)(F) es FALSO. Se utiliza para verificar que **todas las tuplas** de un conjunto cumplen una condición.

Veamos un ejemplo. Supongamos que tenemos las relaciones:

- EMPLEADO(Dni, Nombre, Apellido, FechaNac, Dirección, Sexo, Dno)
- DEPARTAMENTO(NumeroDpto, NombreDpto, DniDirector)

donde Dno de EMPLEADO es una clave foránea que referencia a la clave primaria NumeroDpto de DEPARTAMENTO, y se solicita que listar el nombre y la dirección de todos los empleados que trabajan en el departamento 'Investigación', la consulta quedaría:

{t.Nombre, t.Apellido1, t.Dirección | EMPLEADO(t) AND (∃d) (DEPARTAMENTO(d) AND d.NombreDpto='Investigación' AND d.NúmeroDpto=t.Dno)}

Cálculo orientado a dominios

Existe otro tipo de cálculo relacional llamado de dominio. Los cálculos de dominio difieren de los de tupla en el tipo de variables usadas en las fórmulas: en lugar de que éstas operen sobre tuplas, lo hacen sobre valores individuales de los dominios de atributos. Para componer una relación de grado n para el resultado de una consulta, debe disponer de n de estas **variables de dominio:** una por cada atributo. Una expresión de cálculo de dominio tiene la siguiente forma:

$\{x_1, x_2, \ldots, x_n \mid COND(x_1, x_2, \ldots, x_n, x_{n+1}, x_{n+2}, \ldots, x_{n+m})\}$

donde $x_1, x_2, \dots, x_n, x_{n+1}, x_{n+2}, \dots, x_{n+m}$ son variables de dominio que operan sobre los dominios (de atributos), y COND es una condición o fórmula del cálculo relacional de dominio. Una fórmula está compuesta por átomos, los cuales son algo diferentes de los del cálculo de tupla, y pueden ser uno de los siguientes:

1. Un átomo de la forma $R(x_1\ x_2\ \dots\ x_j)$, donde R es el nombre de una relación y cada x_i es una variable de dominio. Este átomo afirma que una lista de valores de debe ser una tupla en la relación cuyo nombre es R, donde x_i es el ienésimo valor de atributo de esa tupla.
2. Un átomo de la forma $\mathbf{x_i}$ **op** $\mathbf{x_j}$, donde **op** es uno de los operadores de comparación del conjunto $\{=, <, \leq, >, \geq, \neq\}$, x_i y x_j son **variables de dominio**.
3. Un átomo de la forma $\mathbf{x_i}$ **op c** ó **c op** $\mathbf{x_j}$ **,** donde **op** es uno de los operadores de comparación del conjunto $\{=, <, \leq, >, \geq, \neq\}$, x_i y x_j son **variables de dominio**, y **c** es una constante.

Como ocurre en los cálculos de tupla, los átomos se evalúan como VERDADERO o FALSO para un conjunto específico de valores, llamados valores de verdad de esos átomos.

Veámoslo con un ejemplo. Supongamos que tenemos una relación:

- Empleado(Nombre, Apellido1, Apellido2, Dni, FechaNac, Dirección, Sexo, Sueldo, Dno).

Usamos las letras minúsculas para especificar las variables de dominio (en este caso necesitamos 9: por ejemplo q, r, s, t, u, v, w, x, y).

Si nos pidieran “enumere la fecha de nacimiento y la dirección de los empleados cuyo nombre sea Juan Gómez”, la consulta sería:

{uv | (∃q) (∃r) (Empleado(qrstuvwxy) AND q=‘Juan’ AND r=‘Gómez’)}

O bien con una notación alternativa asignando las constantes ‘Juan’ y ‘Gómez’ directamente:

{uv | (Empleado(‘Juan’, ‘Gómez’,s,t,u,v,w,x,y)}