FADENA
FACULTAD DE DEFENSA NACIONAL

Otras tendencias y tecnologías actuales

FADENA
FACULTAD DE DEFENSA NACIONAL

CONTENIDO

01 ETL Moderno

02 Big Data

03 Ciencia de Datos

04 Tendencias 2025

FADENA
FACULTAD DE DEFENSA NACIONAL

01

ETL Moderno

Del dato bruto al insight

FADENA
FACULTAD DE DEFENSA NACIONAL

Fuentes de datos modernas

En 2025, las organizaciones obtienen datos de fuentes diversas como APIs, IoT y redes sociales. El ETL moderno debe adaptarse a estos flujos de datos heterogéneos para extraer valor.

01

ETL híbrido

El enfoque ETL/ELT se ha vuelto común, permitiendo la integración de Data Lakes y soluciones en la nube. Esto garantiza la calidad y trazabilidad de los datos antes de la analítica.

02

Importancia de la gobernanza

La gobernanza de datos es esencial para mantener la integridad y seguridad de la información. Sin ella, los análisis pueden ser frágiles e inconsistentes.

Extracción: orígenes y desafíos

FADENA
FACULTAD DE DEFENSA NACIONAL

Diversidad de fuentes

La extracción de datos abarca desde bases de datos SQL y NoSQL hasta flujos de streaming de Kafka y archivos Parquet. Las fuentes de datos son cada vez más variadas y complejas.

Desafíos técnicos

Se requieren conectores dinámicos, autenticación OAuth y gestión de rate-limits para mantener latencias bajas y evitar pérdidas de datos durante la ingesta continua.

Transformación: reglas y validación

FADENA
FACULTAD DE DEFENSA NACIONAL

Limpieza de datos

Se eliminan duplicados y se homologan monedas y unidades para garantizar la consistencia de los datos. La calidad de los datos es fundamental para análisis confiables.

Enriquecimiento de datos

Se enriquecen los datos con información adicional como geolocalización. Esto agrega valor y contexto a los datos originales.

Validación de integridad

Se validan las relaciones entre los datos para garantizar la integridad referencial. Esto es crucial para evitar errores en los análisis posteriores.

Versión de reglas de negocio

Las reglas de negocio se versionan en Git y se ejecutan en Spark o SQL para garantizar la reproducibilidad y trazabilidad de los procesos de transformación.

Carga: destinos y estrategias

FADENA
FACULTAD DE DEFENSA NACIONAL

Estrategias de carga

La carga puede ser completa, incremental o en streaming hacia Data Warehouses, Data Lakes o servicios cloud como Snowflake. La elección del formato y partición es crucial para optimizar el costo y rendimiento de las consultas.

FADENA
FACULTAD DE DEFENSA NACIONAL

02

Big Data

FADENA
FACULTAD DE DEFENSA NACIONAL

Las 5V que definen Big Data

01

Volumen y Velocidad

Big Data se caracteriza por volúmenes masivos de datos y velocidades de generación y actualización rápidas. Esto requiere soluciones escalables y de alta performance.

Variedad, Veracidad y Valor

Los datos pueden ser estructurados, semiestructurados o no estructurados. La veracidad y el valor de los datos son fundamentales para la toma de decisiones informadas.

02

Arquitectura distribuida típica

FADENA
FACULTAD DE DEFENSA NACIONAL

Capas de la arquitectura

Una arquitectura típica incluye capas de ingesta (Kafka, NiFi), almacenamiento (HDFS, S3), procesamiento (Spark, Flink), consulta (Presto, Hive) y visualización (Kibana, Superset).

Orquestación y seguridad

Herramientas como Airflow se utilizan para orquestar los flujos de datos. La seguridad y alta disponibilidad se garantizan mediante políticas de réplica y acceso controlado.

Importancia de la modularidad

La modularidad de la arquitectura permite adaptarse a cambios y escalar según las necesidades de la organización.

Arquitectura distribuida típica

FADENA
FACULTAD DE DEFENSA NACIONAL

Capas de la arquitectura

Una arquitectura típica incluye capas de ingesta (Kafka, NiFi), almacenamiento (HDFS, S3), procesamiento (Spark, Flink), consulta (Presto, Hive) y visualización (Kibana, Superset).

Orquestación y seguridad

Herramientas como Airflow se utilizan para orquestar los flujos de datos. La seguridad y alta disponibilidad se garantizan mediante políticas de réplica y acceso controlado.

Importancia de la modularidad

La modularidad de la arquitectura permite adaptarse a cambios y escalar según las necesidades de la organización.

MapReduce vs Spark

FADENA
FACULTAD DE DEFENSA NACIONAL

Ventajas de MapReduce

MapReduce ofrece tolerancia a fallos y es económico para procesamiento batch, pero tiene un overhead significativo debido a la escritura y lectura en disco.

Ventajas de Spark

Spark procesa datos en memoria, lo que lo hace hasta 100 veces más rápido que MapReduce. Soporta SQL, streaming y machine learning en un mismo framework.

Compatibilidad y escalabilidad

Spark es compatible con múltiples lenguajes y puede ejecutarse en clusters propios o en la nube, lo que facilita la escalabilidad y el despliegue.

Uso en cargas mixtas

Spark es ideal para cargas de trabajo mixtas, donde se requiere procesamiento tanto en batch como en tiempo real.

Bases distribuidas clave

FADENA
FACULTAD DE DEFENSA NACIONAL

Cassandra ofrece alta disponibilidad y escalabilidad horizontal, mientras que HBase proporciona consistencia fuerte sobre HDFS. Ambas son ideales para aplicaciones con alta demanda de lectura/escritura.

Cassandra y HBase

MongoDB es una base de datos NoSQL documental que se puede shardear para escalabilidad horizontal. Elasticsearch es ideal para indexar y buscar logs y datos textuales de manera eficiente.

MongoDB y Elasticsearch

FADENA
FACULTAD DE DEFENSA NACIONAL

03

Ciencia de Datos

Ciclo de vida completo

FADENA
FACULTAD DE DEFENSA NACIONAL

Recolección de datos

La recolección de datos abarca múltiples fuentes, desde bases de datos SQL hasta APIs y sensores IoT. La diversidad de fuentes es fundamental para obtener datos completos.

Análisis exploratorio

El análisis exploratorio (EDA) permite identificar patrones y correlaciones en los datos. Herramientas como matplotlib y seaborn son esenciales en esta etapa.

Limpieza y preparación

La limpieza de datos con herramientas como pandas y Airflow es crucial para garantizar la calidad y usabilidad de los datos antes del análisis.

Modelado y despliegue

El modelado predictivo con scikit-learn y TensorFlow, seguido de la evaluación de métricas y despliegue en producción, completa el ciclo de vida de la Ciencia de Datos.

Rol de los sistemas de datos

FADENA
FACULTAD DE DEFENSA NACIONAL

Fuentes confiables

Los sistemas de datos proporcionan fuentes confiables de información, desde bases de datos transaccionales hasta sensores IoT y APIs externas.

Integración y almacenamiento

La integración ETL/ELT y el almacenamiento seguro en Data Warehouses o Data Lakes son fundamentales para la integridad de los datos.

Procesamiento y exposición

El procesamiento tanto en batch como en streaming y la exposición analítica son esenciales para extraer valor de los datos.

Perfiles profesionales

FADENA
FACULTAD DE DEFENSA NACIONAL

Roles clave

Data Engineer, Data Analyst, Data Scientist y ML Engineer son roles clave en el ecosistema de Ciencia de Datos. Cada uno tiene responsabilidades específicas.

Colaboración

La colaboración entre estos roles es esencial para el éxito de los proyectos de Ciencia de Datos. Cada uno aporta habilidades únicas al proceso.

FADENA
FACULTAD DE DEFENSA NACIONAL

04

Tendencias 2025

Lakehouses y formatos abiertos

FADENA
FACULTAD DE DEFENSA NACIONAL

Unificación de lake y warehouse

Lakehouses como Delta Lake, Iceberg y Hudi unifican las ventajas de Data Lakes y Data Warehouses, ofreciendo transacciones ACID y control de versiones.

Beneficios de los formatos abiertos

Los formatos abiertos facilitan la interoperabilidad y reducen la dependencia de soluciones propietarias, lo que simplifica las arquitecturas híbridas on-premise y cloud.

Optimización de costos

Estas soluciones reducen la duplicación de datos y optimizan el costo y rendimiento de las consultas, lo que es crucial en entornos de gran escala.

Streaming en tiempo real

FADENA
FACULTAD DE DEFENSA NACIONAL

Procesamiento en tiempo real

Herramientas como Kafka Streams, Flink y Spark Structured Streaming permiten procesar millones de eventos por segundo en tiempo real.

Aplicaciones prácticas

Esto habilita alertas de ciberseguridad, recomendaciones personalizadas y dashboards en vivo con latencia subsegundo y garantía exactly-once.

IA generativa y embeddings

FADENA
FACULTAD DE DEFENSA NACIONAL

Modelos de lenguaje

Modelos de lenguaje fine-tunados generan resúmenes, clasifican tickets y crean embeddings para búsqueda semántica.

Beneficios de la integración

La integración de IA generativa permite automatizar tareas complejas y mejorar la eficiencia en el procesamiento de datos.

Integración sin reescribir ETL

Estos modelos se despliegan con FastAPI y ONNX, y se integran a pipelines existentes sin necesidad de reescribir procesos ETL.

Aplicaciones en Ciencia de Datos

Esto se aplica en áreas como la generación de insights, la clasificación de datos y la mejora de la interacción con los usuarios.

Privacidad y gobernanza

FADENA
FACULTAD DE DEFENSA NACIONAL

Normativas y estándares

Normativas como GDPR y CCPA, junto con estándares de ciberdefensa, exigen medidas de privacidad y gobernanza rigurosas en el manejo de datos.



Implementación de políticas

Se implementan políticas de acceso dinámico y auditoría continua con herramientas open-source para garantizar la seguridad y transparencia.

Edge y federated learning

FADENA
FACULTAD DE DEFENSA NACIONAL

Procesamiento en dispositivos

El procesamiento en dispositivos IoT y federated learning reducen el tráfico hacia la nube y preservan la privacidad de los datos.

Entrenamiento local

Los modelos se entrenan localmente y solo se comparten gradientes, lo que minimiza el riesgo de exposición de datos sensibles.

Aplicaciones en defensa y salud

Esto es especialmente útil en campos como la defensa y la salud, donde la privacidad y la seguridad son cruciales.

FADENA
FACULTAD DE DEFENSA NACIONAL

Sostenibilidad energética

Estrategias de eficiencia

Clusters con GPUs de bajo consumo, compresión de datos y scheduling dinámico reducen la huella de carbono de los sistemas de datos.



Hacia 2026 y más allá

FADENA
FACULTAD DE DEFENSA NACIONAL

Convergencia de tecnologías

Se anticipa una convergencia de lakehouse-serverless y la adopción de tecnologías cuánticas para optimización de procesos.

Modelos multimodales

Los modelos multimodales que combinan texto, imágenes y datos estructurados se volverán más comunes en la Ciencia de Datos.

Regulaciones globales

La implementación de regulaciones globales de privacidad y seguridad de datos influirá en la arquitectura y gestión de datos.

Preparación para el futuro

La preparación requiere arquitecturas modulares, una cultura data-driven y formación continua en ciberseguridad para adaptarse a estos cambios.

FADENA
FACULTAD DE DEFENSA NACIONAL

GRACIAS