UNA INTRODUCCIÓN A JAMOVI

José R. Berrendero[*]
Departamento de Matemáticas
Universidad Autónoma de Madrid

Índice

1. Introducción **2**

2. Descripción de datos y operaciones básicas **2**
2.1. Datos sobre ácidos grasos en aceitunas 2
2.2. Descripción de una variable cualitativa 3
2.3. Descripción de una variable cuantitativa 4
2.4. Relaciones entre variables: diagrama de dispersión y correlación 5
2.5. Seleccionar un subconjunto de los datos 6
2.6. Transformaciones de variables 7
2.7. Guardar los resultados 8

3. Intervalos de confianza y contrastes de hipótesis **9**
3.1. Contraste para la media de una población normal 9
3.2. Comparación de dos medias (muestras independientes, poblaciones normales) . 11
3.3. Comparación de dos medias (datos emparejados, poblaciones normales) 13
3.4. Contraste para una proporción 15
3.5. Comparación de dos proporciones y contrastes de homogeneidad 17

4. Regresión lineal simple y análisis de la varianza **21**
4.1. Regresión lineal simple 21
4.2. Análisis de la varianza unifactorial 24

[*] joser.berrendero@uam.es

1. Introducción

El programa *jamovi* tiene la apariencia de una hoja de cálculo, pero es una interfaz gráfica de R (en inglés, una GUI, *Graphical User Interface*). Cada vez que elegimos una opción del menú de análisis, en realidad se ejecuta código de R para llevar a cabo los cálculos, sin embargo R está encapsulado dentro del programa y el usuario no se entera de ello, si así lo desea. El programa se puede obtener en la dirección https://www.jamovi.org/ y se puede instalar fácilmente. En la misma dirección se pueden conseguir otros recursos útiles para aprender a usarlo.

Esta guía para comenzar a trabajar con *jamovi* tiene tres partes. En la primera se explica cómo describir un conjunto de datos y se detalla cómo llevar a cabo algunas de las operaciones con los datos más comunes en estadística (tomar logaritmos, estandarizar, etc.) La segunda parte está dedicada a ejemplos de cálculo de intervalos de confianza y contrastes en diferentes situaciones. Finalmente, la tercera parte corresponde a dos ejemplos de ajuste de modelos muy sencillos: el modelo de regresión lineal simple y el modelo de análisis de la varianza unifactorial.

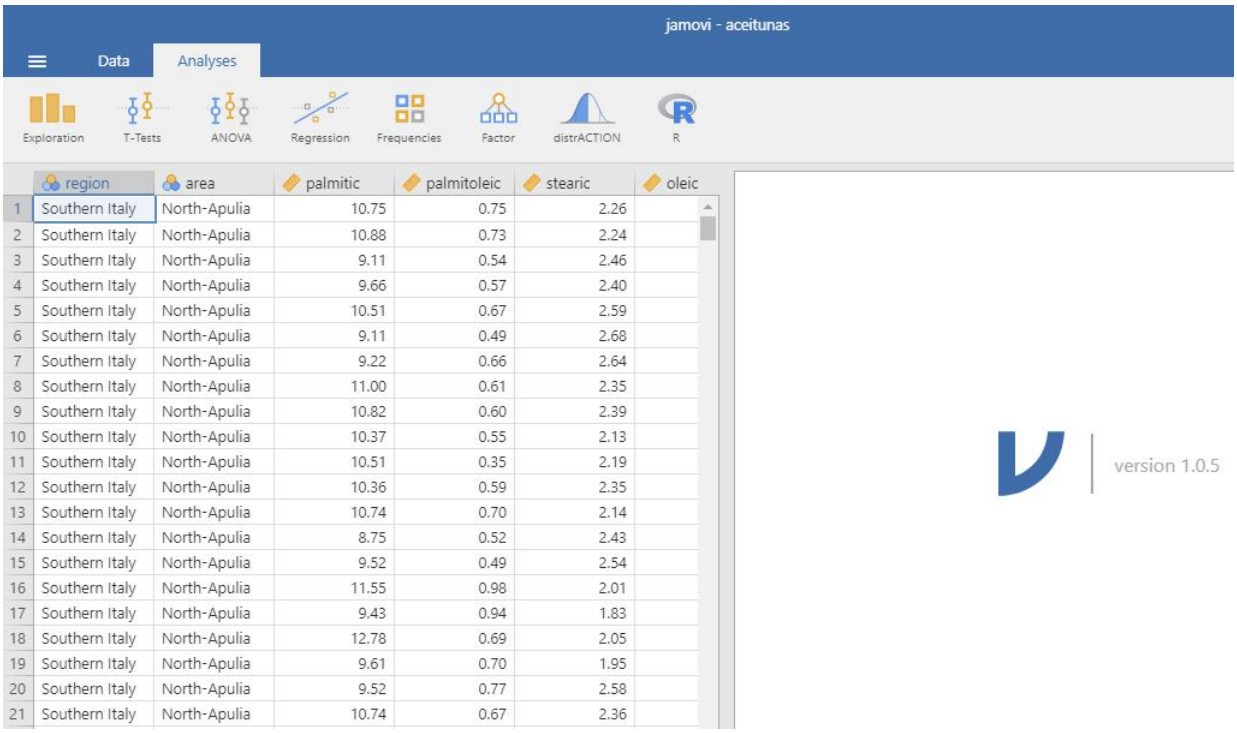
2. Descripción de datos y operaciones básicas

En esta sección se explica cómo obtener los principales gráficos y las principales medidas descriptivas de un conjunto de datos. Posteriormente, se detalla cómo llevar a cabo algunas de las operaciones más frecuentes: filtrar algunas observaciones, transformar las variables, estandarizarlas, etc.

2.1. Datos sobre ácidos grasos en aceitunas

Comenzamos presentando el conjunto de datos que vamos a usar en esta sección. El fichero aceitunas.omv contiene datos sobre el porcentaje de ocho ácidos grasos en la fracción lipídica de aceitunas procedentes de nueve áreas de Italia correspondientes a tres grandes regiones: norte de Italia, Cerdeña y sur de Italia.

Al abrir el fichero de datos con *jamovi* veremos una ventana con la apariencia de una hoja de cálculo. A la derecha veremos un espacio en el que irán apareciendo posteriormente los resultados de los cálculos.



	region	area	palmitic	palmitoleic	stearic	oleic
1	Southern Italy	North-Apulia	10.75	0.75	2.26	
2	Southern Italy	North-Apulia	10.88	0.73	2.24	
3	Southern Italy	North-Apulia	9.11	0.54	2.46	
4	Southern Italy	North-Apulia	9.66	0.57	2.40	
5	Southern Italy	North-Apulia	10.51	0.67	2.59	
6	Southern Italy	North-Apulia	9.11	0.49	2.68	
7	Southern Italy	North-Apulia	9.22	0.66	2.64	
8	Southern Italy	North-Apulia	11.00	0.61	2.35	
9	Southern Italy	North-Apulia	10.82	0.60	2.39	
10	Southern Italy	North-Apulia	10.37	0.55	2.13	
11	Southern Italy	North-Apulia	10.51	0.35	2.19	
12	Southern Italy	North-Apulia	10.36	0.59	2.35	
13	Southern Italy	North-Apulia	10.74	0.70	2.14	
14	Southern Italy	North-Apulia	8.75	0.52	2.43	
15	Southern Italy	North-Apulia	9.52	0.49	2.54	
16	Southern Italy	North-Apulia	11.55	0.98	2.01	
17	Southern Italy	North-Apulia	9.43	0.94	1.83	
18	Southern Italy	North-Apulia	12.78	0.69	2.05	
19	Southern Italy	North-Apulia	9.61	0.70	1.95	
20	Southern Italy	North-Apulia	9.52	0.77	2.58	
21	Southern Italy	North-Apulia	10.74	0.67	2.36	

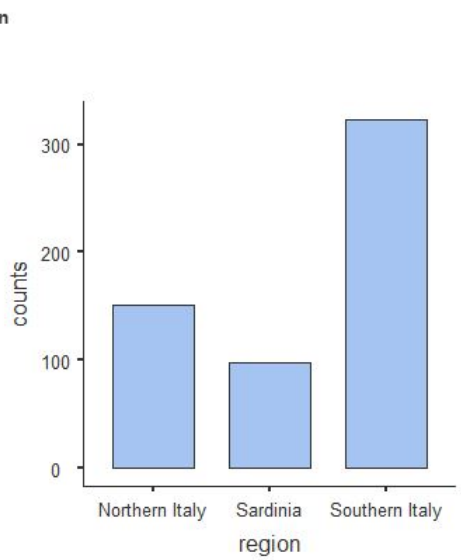
2.2. Descripción de una variable cualitativa

Consideramos la variable `region`, que corresponde a la región de procedencia de las aceitunas. Como es una variable cualitativa, para describirla lo que procede es calcular una tabla de frecuencias y representar un gráfico de barras.

Para ello, hay que seleccionar la opción `Analyses` ↪ `Exploration` ↪ `Descriptives`. A continuación seleccionamos la variable `region` y la pasamos (usando la flecha) al recuadro *variables*. En la parte inferior marcamos *Frequency tables* y, dentro del apartado *Plots*, marcamos *Bar plot*. Veremos a la derecha los resultados:

Frequencies of region

Levels	Counts	% of Total	Cumulative %
Northern Italy	151	26.4 %	26.4 %
Sardinia	98	17.1 %	43.5 %
Southern Italy	323	56.5 %	100.0 %



Si queremos saber el número de observaciones para cada región y cada área (lo que se llama habitualmente en los libros una tabla de contingencia), tenemos que ir a

`Analyses` ↪ `Frequencies` ↪ `Independent samples`

Podemos elegir la variable `region` para las columnas y `area` para las filas. ¿A qué caso corresponde el mayor número de observaciones? Debajo aparece un resultado relativo al contraste χ^2 que de momento podemos olvidar. En el apartado *Cells* podemos marcar las opciones que permiten calcular los porcentajes.

2.3. Descripción de una variable cuantitativa

De nuevo elegimos la opción:

`Analyses` ↪ `Exploration` ↪ `Descriptives`

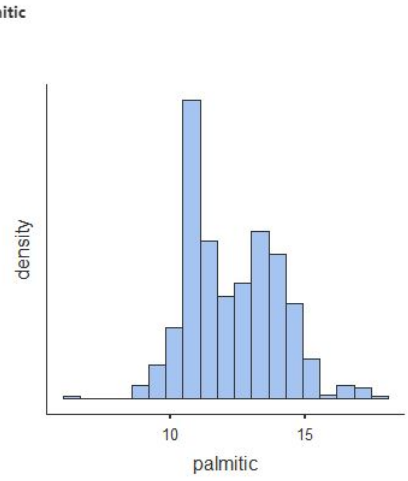
A continuación seleccionamos alguna de las variables cuantitativas, por ejemplo, `palmitic`. En la parte inferior marcamos:

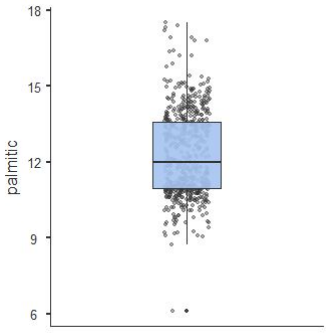
(a) En *Statistics*: las medidas numéricas que queramos calcular además de las que ya están marcadas por defecto. Por ejemplo: *quartiles, std. deviation, variance* y *s.e. mean.*

(b) En *Plots*: los gráficos que queramos representar. Por ejemplo: *histogram* y *box plot.* Puedes añadir los puntos que dan lugar a los gráficos eligiendo *Data.*

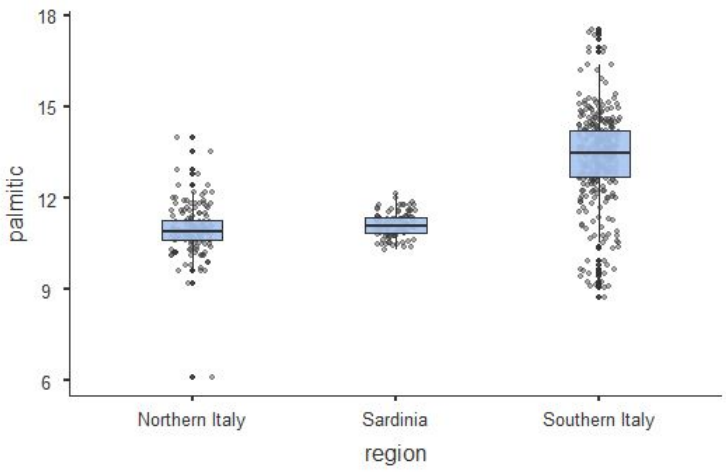
Descriptives

	palmitic
N	572
Missing	0
Mean	12.3
Std. error mean	0.0705
Median	12.0
Standard deviation	1.69
Variance	2.84
Minimum	6.10
Maximum	17.5
25th percentile	10.9
50th percentile	12.0
75th percentile	13.6





Claramente se observa que la distribucion es bimodal. Estamos considerando todas las observaciones a la vez, pero es conveniente separar el estudio por zonas. Para ello, tenemos que añadir al recuadro *Split by* la variable `region`. Vemos que ahora todos los resultados se dan por separado para cada una de las tres regiones. Por ejemplo, los diagramas de cajas resultan ser estos:

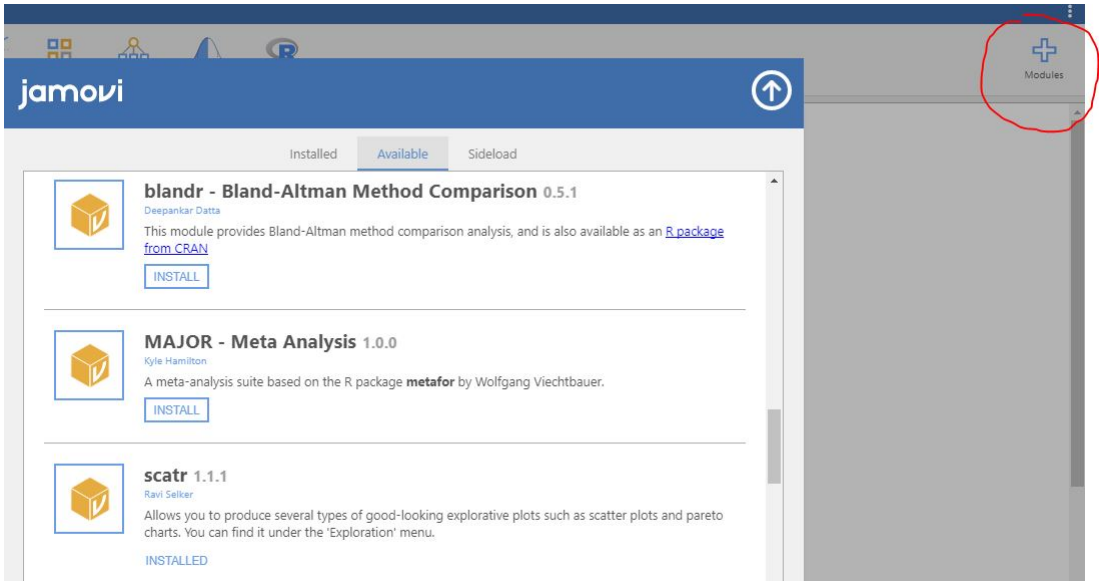


Una transformación habitual para una variable cualitativa consiste en recodificar los nombres de los valores de la variable. En el fichero que estamos manejando los nombres están en inglés pero tal vez preferiríamos que estuvieran en castellano. Para renombrar los niveles de la variable `region` hacemos doble clic en el nombre de la variable y dentro del recuadro *levels* nos situamos en los niveles que queremos modificar y hacemos los cambios. Cuando hayamos terminado salimos.

Con un procedimiento similar se pueden cambiar también el nombre y el tipo de cada variable.

2.4. Relaciones entre variables: diagrama de dispersión y correlación

Existe una lista creciente de módulos que permite incrementar la funcionalidad del programa. Para representar un diagrama de dispersión necesitamos cargar previamente el módulo `scatr` pulsando la cruz de la parte superior derecha de la pantalla:



Para estudiar gráficamente el grado de asociación existente entre dos variables elegimos la opción:

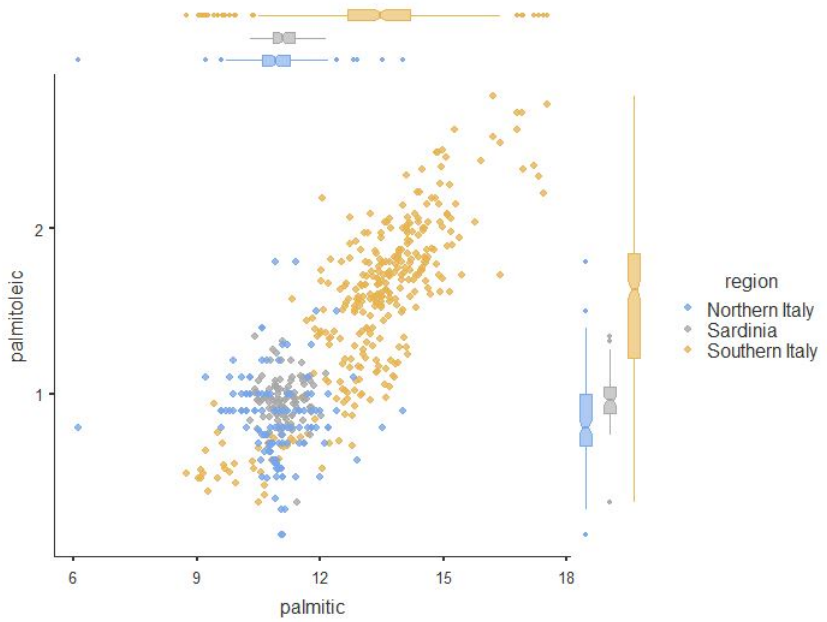
`Analyses ↪ Exploration ↪ Scatterplot`

Como variable Y debemos elegir la variable *dependiente*, la que queremos explicar. Por ejemplo, `palmitoleic`. Como variable X elegimos la variable *explicativa*. Por ejemplo, `palmitic`.

Si queremos que en el gráfico se utilice un color diferente según una variable cualitativa, la seleccionamos en el apartado *Group*. En nuestro ejemplo, podemos elegir `region`.

Finalmente es posible también marcar la opción *Boxplots* del apartado *Marginals*, con lo que se añade un diagrama de cajas de las dos variables involucradas.

El resultado es el siguiente:



Para calcular la correlación entre las dos variables, elegimos

`Analyses ↪ Regression ↪ Correlation Matrix`

A continuación pasamos al cuadro todas las variables entre las que queremos calcular correlaciones.

2.5. Seleccionar un subconjunto de los datos

Una operación que suele ser necesaria frecuentemente en la práctica es filtrar los datos, es decir, usar en el análisis solo un subconjunto de ellos que cumpla cierta condición. En nuestro caso, podríamos estar interesados en usar exclusivamente los datos de Cerdeña. Para filtrar los datos, elegimos la opción:

`Data` ↪ `Filters`

En el recuadro que se abre tenemos que escribir la condición lógica que queremos que cumplan los datos que queremos analizar. Para elegir los de Cerdeña, escribimos:



Obsérvese el uso del doble signo de igual y el de las comillas. En el conjunto de datos aparece una nueva columna que nos indica qué observaciones cumplen la condición y cuáles no.

Un segundo ejemplo: para seleccionar las observaciones que **no** sean de Cerdeña **y para las que además** la variable `palmitic` sea mayor que 10 escribimos:



Obsérvese el uso de `!=` para indicar que la variable *no es igual a...* y el de la palabra *and* para añadir una segunda condición.

Cuando un filtro se activa, todos los cálculos que hayamos hecho se rehacen automáticamente considerando únicamente el subconjunto de variables seleccionadas.

2.6. Transformaciones de variables

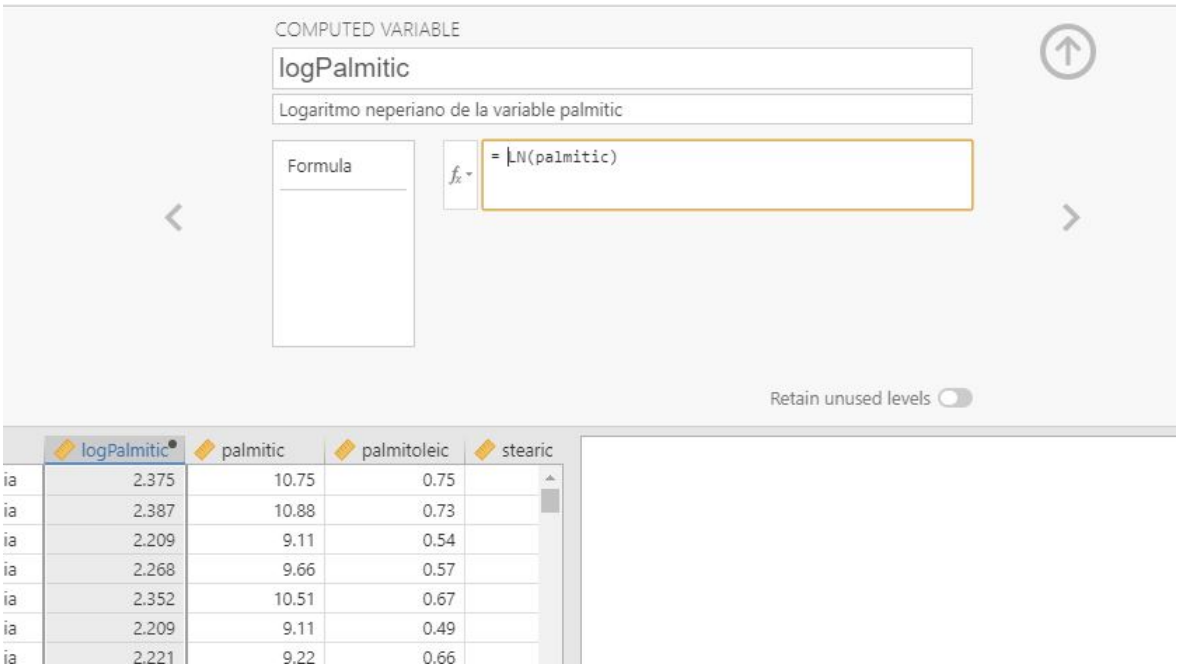
Para crear una nueva variable como resultado de aplicar una transformación a alguna de las ya existentes, se procede de la forma siguiente:

- Vamos a `Data` ↪ `Compute`.
- En *Computed variable* se escribe el nombre de la nueva variable que vamos a crear. Debajo se puede redactar una breve descripción que nos recuerde en qué consiste esa variable.

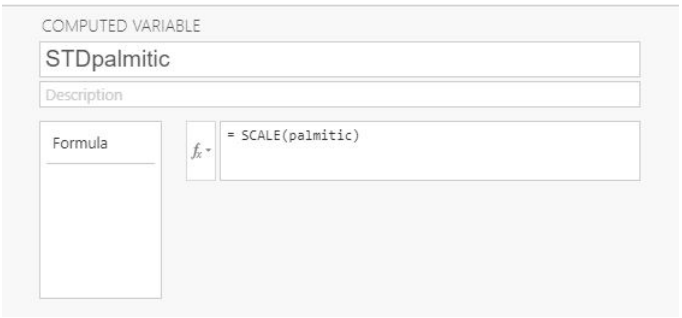
- Pulsando el botón f_x se despliegan los listados de funciones matemáticas y de variables ya existentes. Elegimos la función y la variable que queremos transformar (por este orden) haciendo doble clic en la opción deseada.

- Inmediatamente vemos que en el fichero aparece la nueva variable que hemos creado. A partir de ahora la podremos usar en cualquier tipo de cálculo.

Por ejemplo, si queremos crear una variable que sea el logaritmo neperiano de la variable `palmitic`, las opciones a elegir son las siguientes:



Si lo que queremos es estandarizar la variable, en lugar de la función `LN` se usa `SCALE`:



2.7. Guardar los resultados

Cada análisis individual (numérico o gráfico) se puede salvar usando el botón derecho del ratón. Se puede copiar al portapapeles para luego pegarlo en otro documento, o guardar en un fichero individual en diferentes formatos.

Es recomendable guardar los cambios y análisis que hemos llevado a cabo **en un nuevo fichero** de manera que siempre tengamos disponibles los datos originales. Para ello, en el menú de la parte superior izquierda (las tres rayas horizontales) elegimos *Save as...* y elegimos el nombre y la carpeta que queramos.

3. Intervalos de confianza y contrastes de hipótesis

En esta sección se proponen una serie de ejemplos que ilustran cómo se llevan a cabo con *jamovi* los principales contrastes de hipótesis. Veremos primero cómo hacer los cálculos para los contrastes relativos a una sola media y posteriormente cómo realizar contrastes para la diferencia de dos medias (tanto en el caso de muestras independientes como de datos emparejados). Finalmente, se describe cómo realizar contrastes relativos a proporciones y contrastes de homogeneidad.

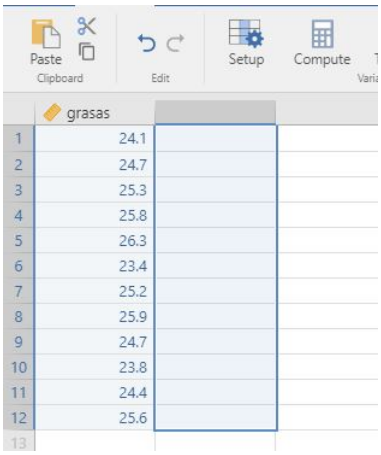
3.1. Contraste para la media de una población normal

Se desea estimar el contenido medio de grasas (en gramos por cada 100 gr.) de la carne de cerdo. Supongamos que se dispone de los siguientes resultados correspondientes a la carne de 12 animales elegidos al azar:

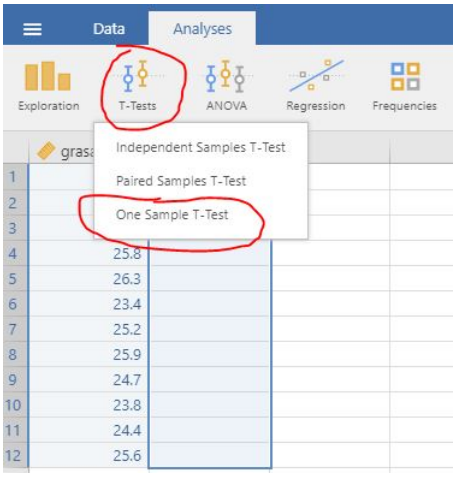
$$24.1,\ 24.7,\ 25.3,\ 25.8,\ 26.3,\ 23.4,\ 25.2,\ 25.9,\ 24.7,\ 23.8,\ 24.4,\ 25.6$$

¿Permiten los datos anteriores afirmar a nivel $\alpha = 0{,}01$ que el contenido medio en grasas es superior a 24 g? Si μ es el contenido medio en grasas de la carne de cerdo, queremos contrastar $H_0 : \mu \leq 24$ frente a $H_1 : \mu > 24$. Suponemos que los datos proceden de una población normal. Para realizar el contraste seguimos los siguientes pasos:

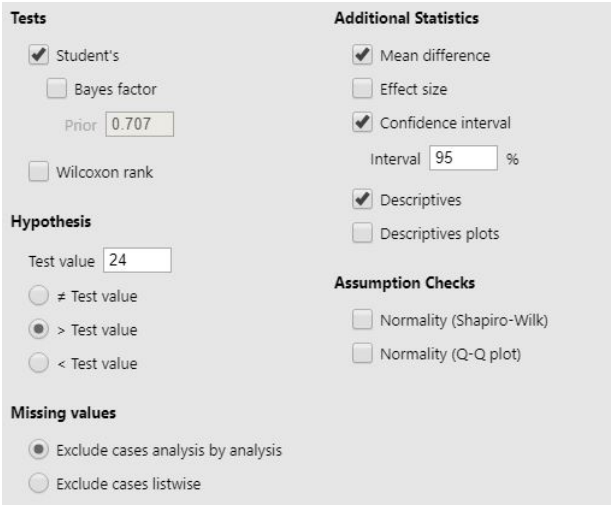
1. Creamos un fichero con una variable continua que contenga los datos (en la imagen siguiente, la variable *grasas*):



2. Elegimos la siguiente opción del menú *Analyses*:



3. Elegimos las opciones adecuadas para responder a la pregunta. Se indican también las opciones necesarias para calcular el intervalo de confianza y otras medidas descriptivas.



Se obtienen los siguientes resultados:

One Sample T-Test

						95% Confidence Interval	
		statistic	df	p	Mean difference	Lower	Upper
grasas	Student's t	3.59	11.0	0.002	0.933	0.466	Inf

Note. H_a population mean > 24

Descriptives

	N	Mean	Median	SD	SE
grasas	12	24.9	24.9	0.901	0.260

En este caso el p-valor es $0{,}002 < 0{,}01$ por lo que se rechaza la hipótesis nula a nivel $\alpha = 0{,}01$. Por otra parte $[0{,}466; \infty)$ es un intervalo de confianza de nivel 0,95 para $\mu - 24$.

3.2. Comparación de dos medias (muestras independientes, poblaciones normales)

El maíz es un alimento importante para los animales pero carece de algunos aminoácidos que son esenciales. Un grupo de científicos desarrolló una nueva variedad que sí contenía niveles apreciables de dichos aminoácidos. Para comprobar la utilidad de esta nueva variedad para la alimentación animal se llevó a cabo el siguiente experimento: a un grupo de 20 pollos se les suministró un pienso que contenía harina de maíz de la nueva variedad. A otro grupo de 20 pollos (grupo de control) se le alimentó con un pienso que solo se diferenciaba del anterior en que no contenía harina de la variedad mejorada de maíz. Los resultados que se obtuvieron sobre las ganancias de peso de los pollos (en gramos) al cabo de 21 días de alimentación fueron los siguientes:

- *Variedad común*

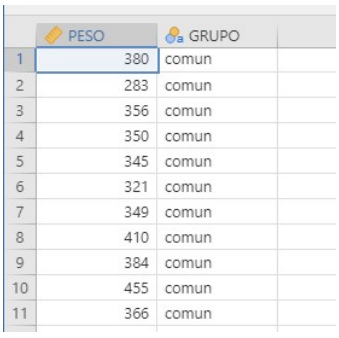
  380 321 366 356 283 349 402 462 356 410 329 399 350 384 316 272 345 455 360 431

- *Variedad transgénica*

  361 447 401 375 434 403 393 426 406 318 467 407 427 420 477 392 430 339 410 326

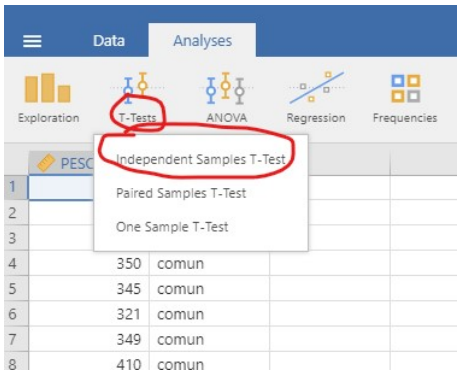
Suponemos que los datos de ambas muestras son independientes, ya que son pollos diferentes los que reciben los tipos de pienso. También suponemos que los datos proceden de dos distribuciones normales con varianzas iguales. ¿Es la diferencia entre las ganancias medias de peso en ambos grupos significativa a nivel $\alpha = 0{,}05$? Si μ_1 y μ_2 son las ganancias medias de peso en pollos alimentados con maíz normal y mejorado respectivamente, queremos contrastar $H_0 : \mu_1 = \mu_2$ frente a $H_1 : \mu_1 \neq \mu_2$. Para llevar a cabo el contraste seguimos los pasos siguientes:

1. Creamos un fichero con dos variables: una variable continua que contiene las ganancias de peso y otra cualitativa que informa de si la dieta fue con maíz común o transgénico:

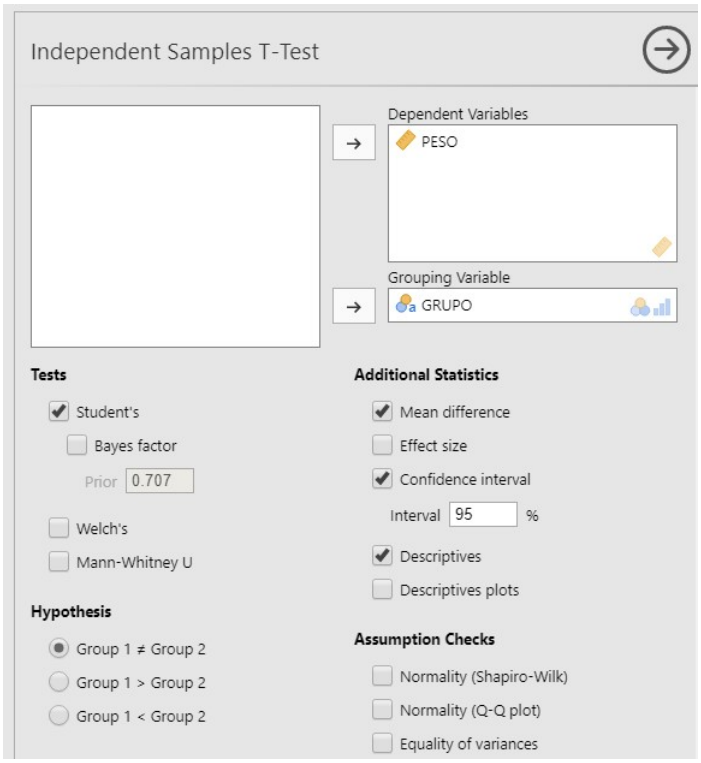


	PESO	GRUPO
1	380	comun
2	283	comun
3	356	comun
4	350	comun
5	345	comun
6	321	comun
7	349	comun
8	410	comun
9	384	comun
10	455	comun
11	366	comun

2. Elegimos la siguiente opción del menú *Analyses*:



3. Elegimos las opciones adecuadas para responder a la pregunta. Se indican también las opciones necesarias para calcular el intervalo de confianza y otras medidas descriptivas.



Se obtienen los siguientes resultados:

Independent Samples T-Test

		statistic	df	p	Mean difference	SE difference	95% Confidence Interval Lower	95% Confidence Interval Upper
PESO	Student's t	−2.47	38.0	0.018	−36.6	14.8	−66.7	−6.60

Group Descriptives

	Group	N	Mean	Median	SD	SE
PESO	comun	20	366	358	50.8	11.4
	trans	20	403	407	42.7	9.55

El p-valor del contraste es $0{,}018 < 0{,}05$, por lo que se rechaza la hipótesis nula a nivel $\alpha = 0{,}05$.

3.3. Comparación de dos medias (datos emparejados, poblaciones normales)

La existencia de trazas de metales en el agua afecta a su sabor y, si las concentraciones son altas, puede afectar a la salud. En un estudio se seleccionaron seis localizaciones en un río y, para cada localización, se determinó la concentración de zinc en el agua de la superficie y en el agua del fondo (en mg/l). Los resultados fueron los siguientes:

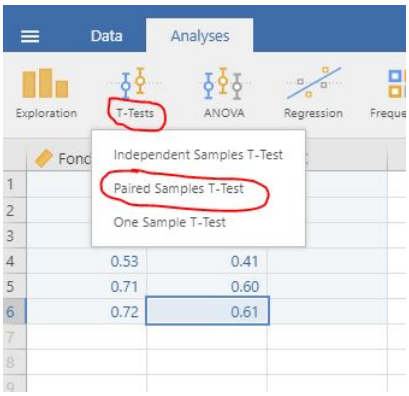
Localización	1	2	3	4	5	6
Fondo	0.43	0.57	0.57	0.53	0.71	0.72
Superficie	0.41	0.24	0.39	0.41	0.6	0.61

Claramente existe relación entre las medidas del fondo y de la superficie por lo que no podemos suponer que las muestras sean independientes para comparar las medias. Son datos emparejados. Asumiendo normalidad, ¿existe evidencia empírica para afirmar, con un nivel de significación $\alpha = 0,05$, que la concentración media de zinc en el fondo es diferente a la concentración media en la superficie? Si μ_1 y μ_2 son las concentraciones medias del fondo y la superficie respectivamente, queremos contrastar $H_0 : \mu_1 = \mu_2$ frente a $H_1 : \mu_1 \neq \mu_2$. Para llevar a cabo el contraste seguimos los pasos siguientes:

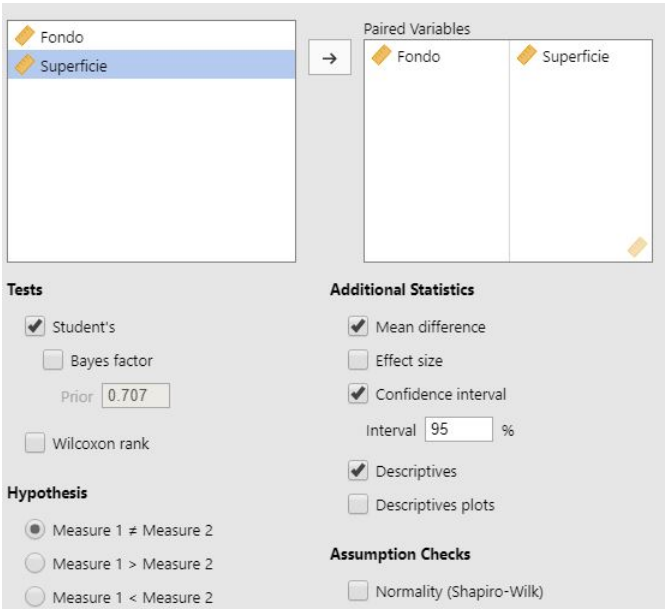
1. Creamos un fichero con dos variables continuas que contienen las concentraciones en el fondo y en la superficie para cada localización. Nótese la diferencia con el caso de muestras independientes. Para que un conjunto de datos esté ordenado cada fila debe corresponder a la misma unidad bajo estudio (en el ejemplo anterior, cada pollo; en este ejemplo, la localización):



2. Elegimos la siguiente opción del menú *Analyses*:



3. Elegimos las opciones adecuadas para responder a la pregunta, calcular el intervalo de confianza de la diferencia de medias y otros estadísticos descriptivos.



Se obtienen los siguientes resultados:

Paired Samples T-Test

								95% Confidence Interval	
			statistic	df	p	Mean difference	SE difference	Lower	Upper
Fondo	Superficie	Student's t	3.41	5.00	0.019	0.145	0.0425	0.0358	0.254

Descriptives

	N	Mean	Median	SD	SE
Fondo	6	0.588	0.570	0.111	0.0452
Superficie	6	0.443	0.410	0.141	0.0574

El p-valor del contraste es $0{,}019 < 0{,}05$ por lo que se rechaza la hipótesis nula a nivel $\alpha = 0{,}05$.

3.4. Contraste para una proporción

Consideramos dos posibilidades según el formato de los datos disponibles.

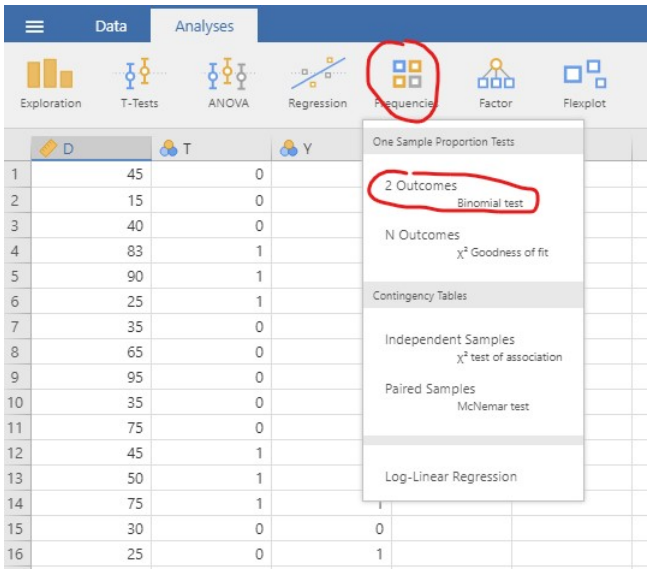
Los datos son variables dicotómicas

El fichero garganta.omv consta de tres variables correspondientes a 35 pacientes que han sido sometidos a cirugía: la variable `D` corresponde a la duración en minutos de la cirugía; la variable `T` corresponde al medio para garantizar la respiración (`T=0` máscara laríngea, `T=1` tubo traqueal) y la variable `Y` corresponde a si el paciente experimentó dolor de garganta al despertar (`Y=0` no, `Y=1` sí). A continuación vemos las primeras filas del fichero:

	D	T	Y
1	45	0	0
2	15	0	0
3	40	0	1
4	83	1	1
5	90	1	1
6	25	1	1
7	35	0	1
8	65	0	1
9	95	0	1
10	35	0	1

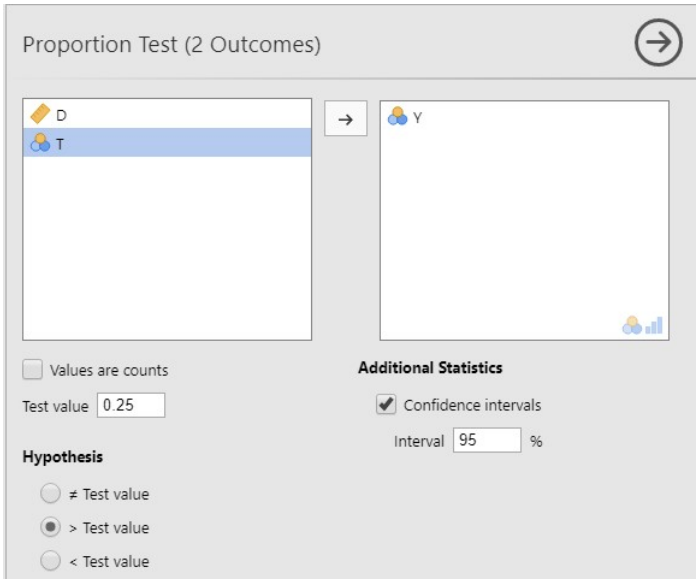
Supongamos que queremos encontrar evidencia a nivel $\alpha = 0{,}05$ de que el porcentaje de pacientes que experimenta dolor de garganta al despertar tras una cirugía supera el 25 %. Si p es la proporción de estos pacientes, queremos contrastar $H_0 : p \leq 0{,}25$ frente a $H_1 : p > 0{,}25$. Para ello seguimos los pasos siguientes:

1. Elegimos la siguiente opción del menú *Analyses*:



	D	T	Y
1	45	0	
2	15	0	
3	40	0	
4	83	1	
5	90	1	
6	25	1	
7	35	0	
8	65	0	
9	95	0	
10	35	0	
11	75	0	
12	45	1	
13	50	1	
14	75	1	
15	30	0	0
16	25	0	1

2. Elegimos las opciones adecuadas para responder a la pregunta:



Se obtienen los siguientes resultados:

Binomial Test

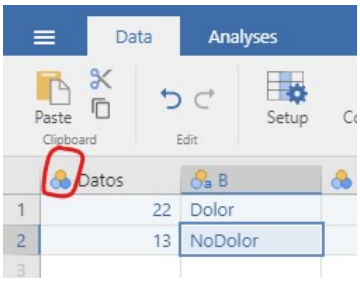
						95% Confidence Interval	
	Level	Count	Total	Proportion	p	Lower	Upper
Y	0	13	35	0.371	0.076	0.236	1.00
	1	22	35	0.629	< .001	0.476	1.00

Note. H_a is proportion > 0.25

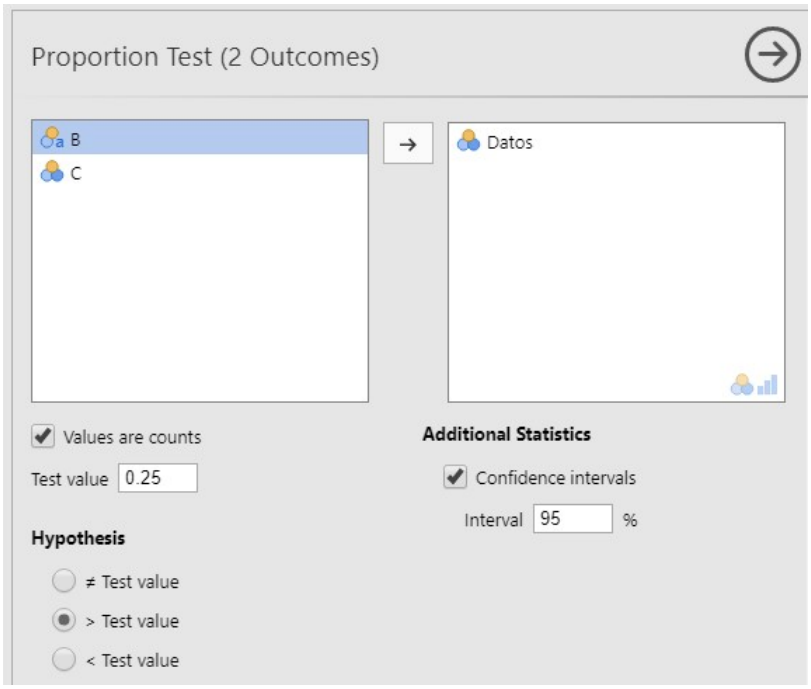
Nos fijamos en el p-valor de la línea `Y=1`, que es el que corresponde a los contrastes relativos a la proporción de individuos que han sufrido dolor. Vemos que el p-valor es menor que 0.001, por lo que rechazamos H_0 a nivel $\alpha = 0{,}05$.

Los datos son frecuencias

A veces disponemos directamente de las frecuencias de cada uno de los dos valores. Por ejemplo, en lugar de tener el fichero de los datos originales nos pueden decir que 22 entre 33 pacientes experimentaron dolor al despertar de la cirugía. En este caso, para introducir los datos se crea una columna que incluya la frecuencia de pacientes que experimentaron dolor (22) y de aquellos que no lo hicieron (13). Es importante que esta variable (por alguna razón) tiene que ser cualitativa tal y como se señala en el gráfico:



Ahora, para llevar a cabo el contraste, las opciones que hay que marcar son:



Obtendremos así los mismos resultados que en el caso de disponer del fichero completo.

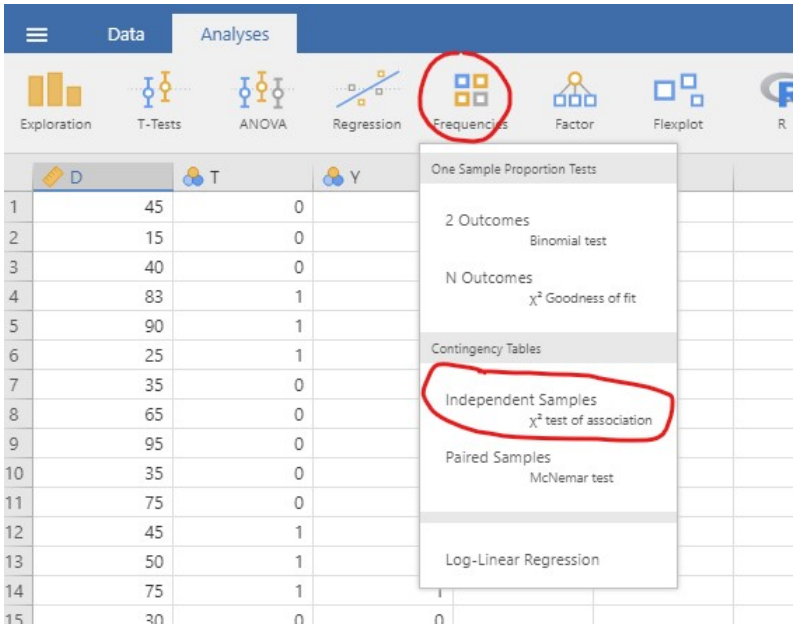
3.5. Comparación de dos proporciones y contrastes de homogeneidad

Veamos cómo se lleva a cabo un contraste de homogenidad (la comparación de dos proporciones es un caso particular). De nuevo distinguimos entre dos posibles casos, según los datos disponibles.

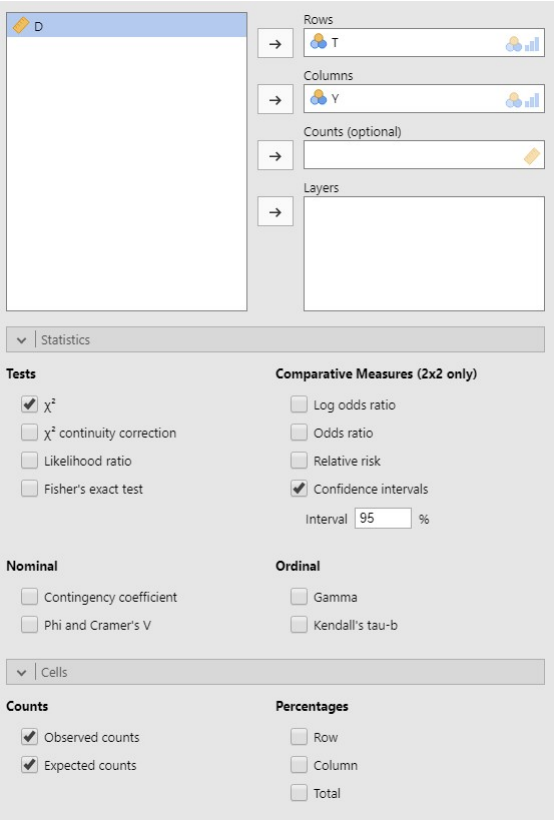
Los datos son variables dicotómicas

Con los datos de la sección anterior, supongamos que estamos interesados en saber si la distribución de individuos que experimentan dolor (equivalentemente, la proporción) es la misma en los casos de usar máscara laríngea o tubo traqueal. Si p_1 es la proporción de pacientes que sufren dolor entre los que usan máscara laríngea y p_2 es la proporción de pacientes que sufren dolor entre los que usan tubo traqueal, queremos contrastar $H_0 : p_1 = p_2$ frente a $H_1 : p_1 \neq p_2$. Seguimos los pasos siguientes:

1. Elegimos la siguiente opción del menú *Analyses*:



2. Elegimos las opciones adecuadas (véase figura) y obtenemos los resultados correspondientes. El p-valor resulta ser 0.06. Como consecuencia, no podemos rechazar la homogeneidad a nivel $\alpha = 0{,}05$, es decir, resulta aceptable la hipótesis de que la proporción de pacientes que sufren dolor no cambia con el método usado para garantizar la respiración del paciente.



Contingency Tables

T		Y = 0	Y = 1	Total
0	Observed	4	14	18
	Expected	6.69	11.3	
1	Observed	9	8	17
	Expected	6.31	10.7	
Total	Observed	13	22	35
	Expected	13.00	22.0	

χ^2 Tests

	Value	df	p
χ^2	3.53	1	0.060
N	35		

Los datos son una tabla de contingencia

En otras ocasiones se dispone únicamente de las frecuencias (de una tabla de contingencia) en lugar de tener todos los datos originales. Veamos con un ejemplo cómo se procede en este caso.

Se ha llevado a cabo un estudio para determinar si un medicamento dirigido a reducir el nivel de colesterol reduce también la probabilidad de sufrir un infarto. Para ello, a hombres de entre 45 y 55 años se les asignó aleatoriamente uno de los dos tratamientos siguientes: 2051 hombres tomaron un medicamento para reducir el nivel de colesterol, y 2030 hombres tomaron un placebo. Durante los cinco años que duró el estudio, 56 de los hombres que tomaron el medicamento, y 84 de los que tomaron el placebo, sufrieron infartos. ¿Podemos afirmar a nivel $\alpha = 0{,}05$ que la probabilidad de sufrir un infarto es diferente en ambos grupos?

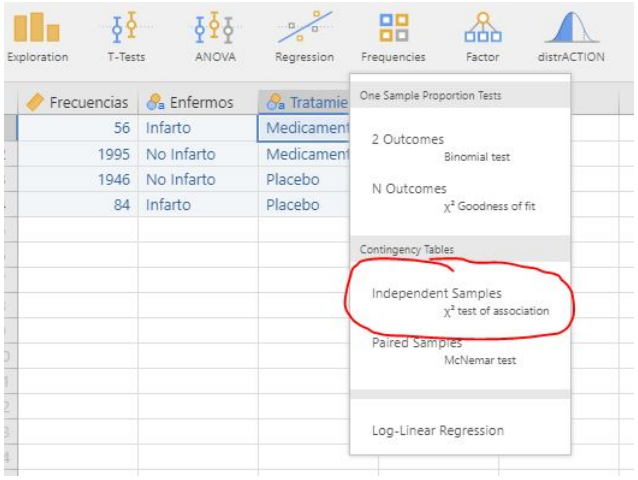
Tenemos que analizar esta tabla de contingencia:

	Medicamento	Placebo
Infarto	56	84
No infarto	1995	1946
Totales	2051	2030

La tabla de contingencia se introduce en *jamovi* de la forma siguiente:

	Frecuencias	Enfermos	Tratamien...
1	56	Infarto	Medicamento
2	1995	No Infarto	Medicamento
3	1946	No Infarto	Placebo
4	84	Infarto	Placebo
5			
6			
7			
8			
9			

Para llevar a cabo el contraste, hay que ir a la siguiente opción del menú, que es la misma del apartado anterior:



Finalmente, en el cuadro de diálogo las variables se eligen así:



Se obtiene el resultado siguiente:

Contingency Tables

	Tratamiento		
Enfermos	Medicamento	Placebo	Total
Infarto	56	84	140
No Infarto	1995	1946	3941
Total	2051	2030	4081

χ^2 Tests

	Value	df	p
χ^2	6.10	1	0.014
N	4081		

Como el p-valor vale 0,014 concluimos que hay evidencia a nivel $\alpha = 0{,}05$ para afirmar que la proporción de individuos que sufren infartos es diferente en el grupo de tratamiento y en el grupo de control.

4. Regresión lineal simple y análisis de la varianza

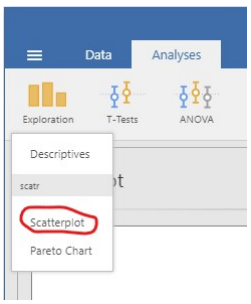
Terminamos la introducción detallando dos ejemplos sencillos de ajuste con *jamovi* de los dos modelos más utilizados en estadística: el modelo de regresión lineal y el modelo de análisis de la varianza. Por simplicidad, nos restringimos al caso de una única variable regresora en el primer caso y un solo factor en el segundo.

4.1. Regresión lineal simple

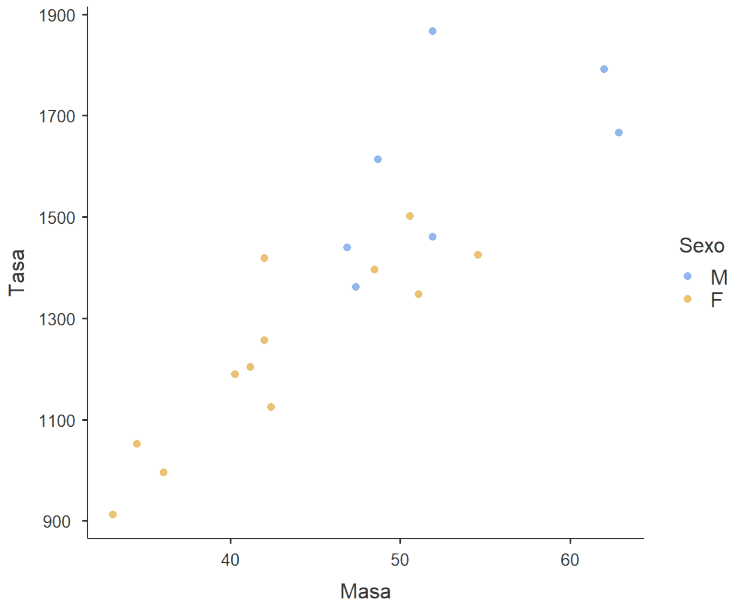
Utilizaremos los datos del fichero metabolismo.omv. Las variables corresponden a la tasa metabólica y la masa corporal magra de una muestra de 7 hombres y 12 mujeres. El objetivo en esta práctica es cuantificar la relación existente entre la masa corporal (que tomaremos como variable regresora) y la tasa metabólica (que tomaremos como variable respuesta). Por lo tanto, vamos a ajustar el modelo:

$$\texttt{Tasa} = \beta_0 + \beta_1 \texttt{Masa} + \epsilon.$$

Antes de obtener los resultados numéricos conviene representar el diagrama de dispersión de los datos para ver si podemos suponer que se cumplen algunas de las hipótesis habituales. Para confirmar otras hipótesis es necesario analizar los residuos del modelo. Recordemos que para representar los diagramas de dispersión es necesario instalar el módulo *scatr* y usar la opción



Representamos la masa en el eje de abscisas y la tasa en el de ordenadas. Parece que la relación es apropiadamente lineal aunque ligeramente heteroscedástica:



Para obtener los estimadores de mínimos cuadrados de la pendiente y el término independiente y otros resultados relacionados con el modelo, la opción que tenemos que seleccionar es:

`Analyses` ↪ `Regression` ↪ `Linear regression...`

1. Como variable dependiente se debe elegir la variable respuesta. En el ejemplo, la variable `Tasa`.

2. Como variable independiente (*covariate*) se selecciona la variable regresora que en nuestro caso es `Masa`.

Se debe obtener el siguiente resultado:

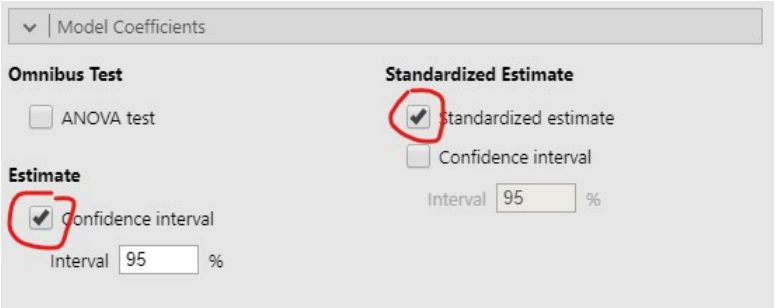
Model Fit Measures

Model	R	R^2
1	0.865	0.748

Model Coefficients

Predictor	Estimate	SE	t	p
Intercept	113.2	179.59	0.630	0.537
Masa	26.9	3.79	7.099	< .001

Para obtener más información sobre el ajuste del modelo, podemos marcar las opciones siguientes:



Con ello, se añadirán a la tabla anterior los intervalos de confianza para los coeficientes del modelo y los estimadores calculados a partir de las variables previamente estandarizadas:

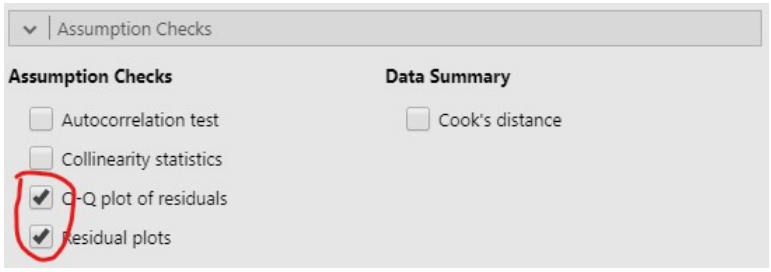
Model Fit Measures

Model	R	R^2
1	0.865	0.748

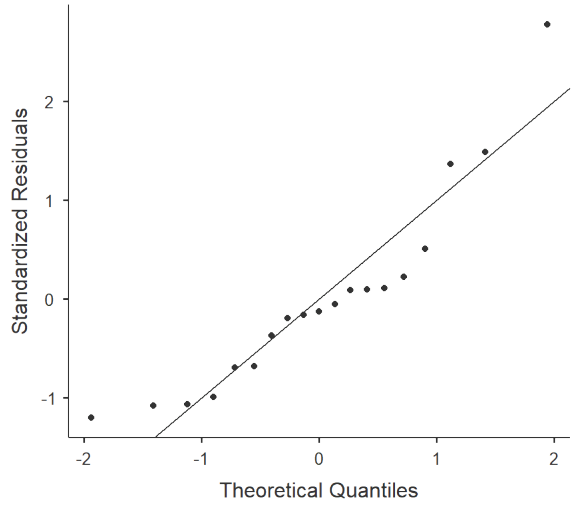
Model Coefficients

			95% Confidence Interval				
Predictor	Estimate	SE	Lower	Upper	t	p	Stand. Estimate
Intercept	113.2	179.59	−265.7	492.1	0.630	0.537	
Masa	26.9	3.79	18.9	34.9	7.099	< .001	0.865

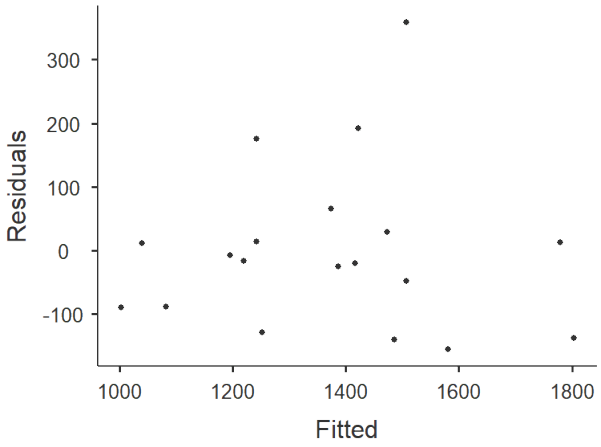
Finalmente, puede ser conveniente analizar algunos aspectos de los residuos para comprobar si las hipótesis habituales del modelo de regresión son aceptables. Para ello, marcamos las siguientes opciones



Este es el *QQ-plot* resultante en este caso. Corresponde a puntos razonablemente alineados con la excepción de algún dato ligeramente atípico. Parece aceptable la hipótesis de normalidad.



El siguiente gráfico corresponde a residuos frente a valores ajustados. No aparece ningún patrón claro, con la excepción de la ligera heteroscedasticidad que ya habíamos observado.



4.2. Análisis de la varianza unifactorial

En este apartado utilizaremos el fichero dientes.omv. Este fichero contiene 60 observaciones y 2 variables. La variable respuesta es la longitud de los dientes de varios conejos de indias (`longitud`) que han recibido tres dosis diferentes de vitamina C (`dosis`). El objetivo consiste en estudiar si la dosis de vitamina C tiene algún efecto sobre la longitud de los dientes.

Como paso previo a realizar los cálculos es necesario comprobar que la variable que va a hacer el papel de factor es de tipo ordinal o nominal. En este caso concreto hay que cambiar el tipo de la variable `dosis` puesto que en el fichero disponible aparece como variable continua.

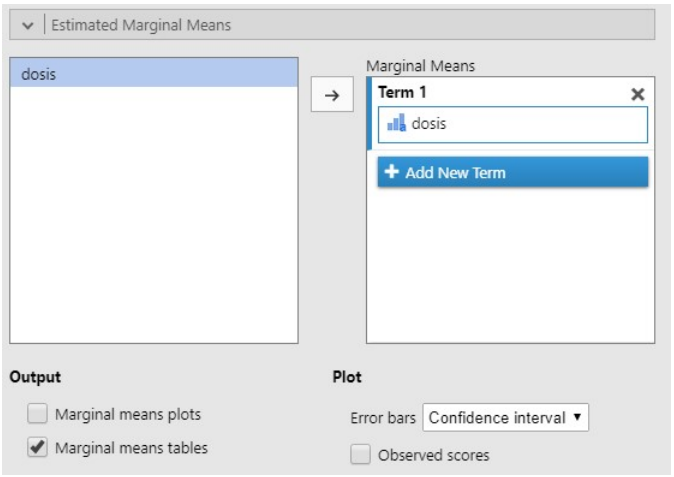
Para obtener la tabla ANOVA hay que elegir

`Analyses` ↪ `ANOVA` ↪ `ANOVA`

1. Como variable *dependiente* se debe elegir la variable respuesta. En el ejemplo, la variable `longitud`.

2. Se selecciona el factor que, en nuestro caso, es la variable `dosis`.

3. Para obtener las medias estimadas para cada grupo y los correspondientes intervalos de confianza se seleccionan las opciones siguientes:



Se debe obtener el siguiente resultado:

ANOVA

ANOVA

	Sum of Squares	df	Mean Square	F	p
dosis	2426	2	1213.2	67.4	< .001
Residuals	1026	57	18.0		

[3]

Estimated Marginal Means

dosis

Estimated Marginal Means - dosis

			95% Confidence Interval	
dosis	Mean	SE	Lower	Upper
0.5	10.6	0.949	8.71	12.5
1.0	19.7	0.949	17.84	21.6
2.0	26.1	0.949	24.20	28.0

[4]