Eduardo Bologna

Métodos Estadísticos de Investigación

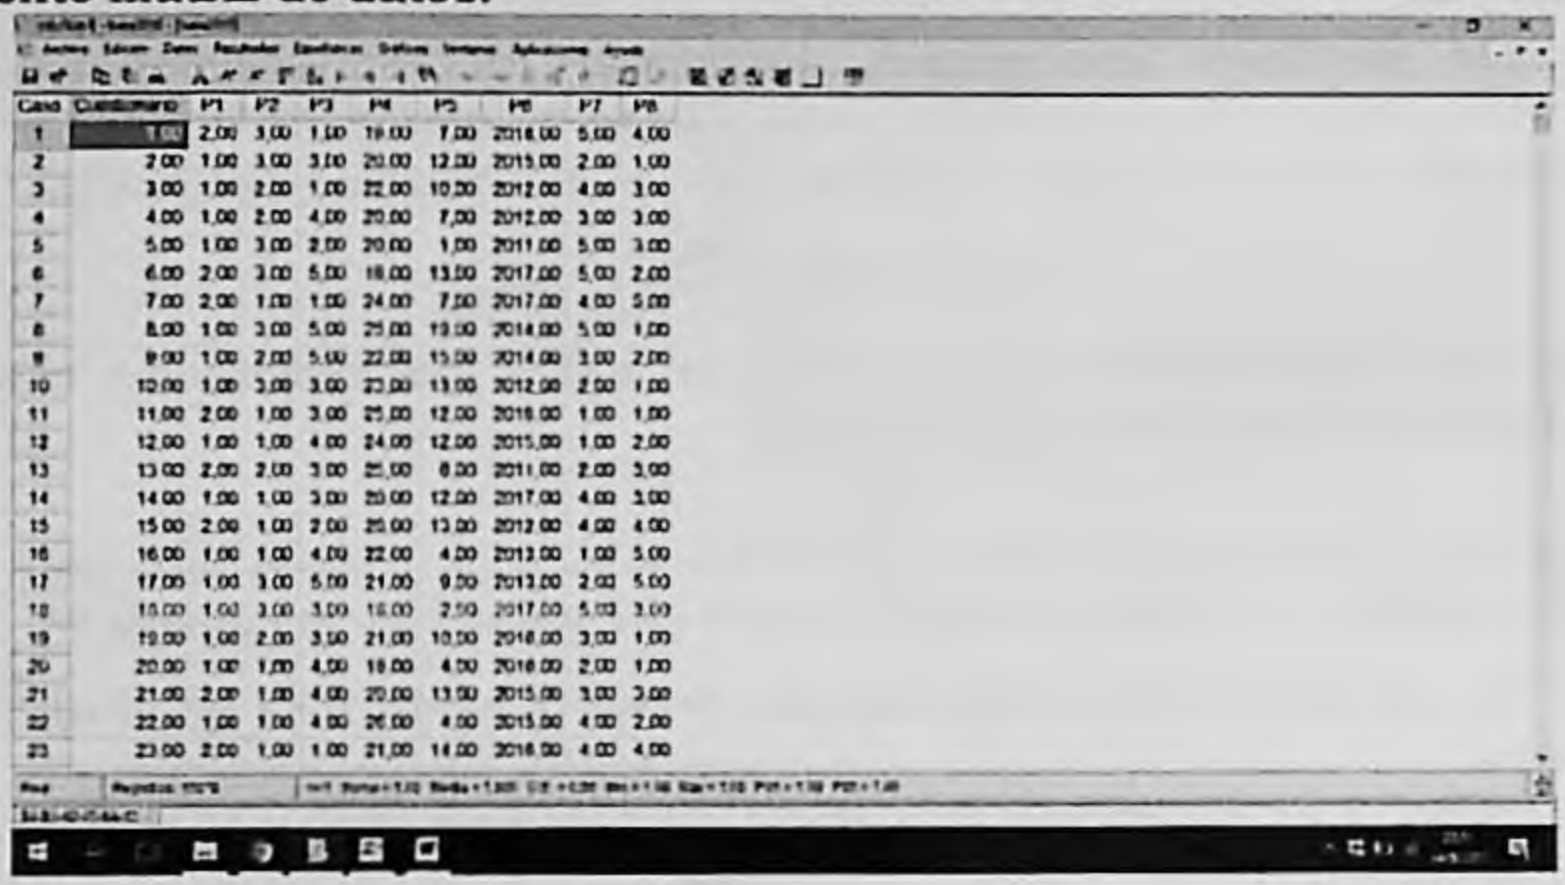


00026157

Editorial Brujas

Capítulo 2 Distribuciones de frecuencia

Una vez identificadas las variables y reconocido su nivel de medición, es necesario darle a la matriz de datos un formato que permita hacer lecturas de los resultados, ya que es imposible observar una tabla que tenga gran cantidad de filas (casos) y muchas columnas (variables).
La siguiente matriz de datos:



Caso	Cuestionario	P1	P2	P3	P4	P5	P6	P7	P8
1	1.00	2.00	3.00	1.00	19.00	7.00	2016.00	5.00	4.00
2	2.00	1.00	3.00	3.00	20.00	12.00	2015.00	2.00	1.00
3	3.00	1.00	2.00	1.00	22.00	10.00	2012.00	4.00	3.00
4	4.00	1.00	2.00	4.00	20.00	7.00	2012.00	3.00	3.00
5	5.00	1.00	3.00	2.00	20.00	1.00	2011.00	5.00	3.00
6	6.00	2.00	3.00	5.00	18.00	13.00	2017.00	5.00	2.00
7	7.00	2.00	1.00	1.00	24.00	7.00	2017.00	4.00	5.00
8	8.00	1.00	3.00	5.00	25.00	19.00	2014.00	5.00	1.00
9	9.00	1.00	2.00	5.00	22.00	15.00	2014.00	3.00	2.00
10	10.00	1.00	3.00	3.00	23.00	13.00	2012.00	2.00	1.00
11	11.00	2.00	1.00	3.00	25.00	12.00	2016.00	1.00	1.00
12	12.00	1.00	1.00	4.00	24.00	12.00	2015.00	1.00	2.00
13	13.00	2.00	2.00	3.00	25.00	8.00	2011.00	2.00	3.00
14	14.00	1.00	1.00	3.00	23.00	12.00	2017.00	4.00	3.00
15	15.00	2.00	1.00	2.00	25.00	13.00	2012.00	4.00	4.00
16	16.00	1.00	1.00	4.00	22.00	4.00	2013.00	1.00	5.00
17	17.00	1.00	3.00	5.00	21.00	9.00	2013.00	2.00	5.00
18	18.00	1.00	3.00	3.00	18.00	2.00	2017.00	5.00	3.00
19	19.00	1.00	2.00	3.00	21.00	10.00	2016.00	3.00	1.00
20	20.00	1.00	1.00	4.00	18.00	4.00	2016.00	2.00	1.00
21	21.00	2.00	1.00	4.00	20.00	13.00	2015.00	3.00	3.00
22	22.00	1.00	1.00	4.00	26.00	4.00	2015.00	4.00	2.00
23	23.00	2.00	1.00	1.00	21.00	14.00	2016.00	4.00	4.00

Corresponde a la aplicación del cuestionario mostrado antes.
Cada columna de la matriz de datos contiene los valores que se han observado en cada uno de los individuos (filas); si se observa verticalmente, cada columna es una secuencia de números, que algunos programas (como R) denominan vector. Para el caso de P4 (la edad), esta secuencia es la siguiente:

19 20 22 20 20 18 24 25 22 23 25 24 25 20 20 22 21 18 21 18 20 26 21 18 17 25
26 17 19 19 22 23 19 25 26 22 23 21 19 19 19 19 24 25 19 19 21 20 21 20 24 17
18 20 25 18 19 21 18 26 20 19 22 23 22 23 24 24 19 25 19 21 19 18 26 17 17 17
18 21 20 24 20 24 17 20 20 24 17 24 19 20 23 24 18 21 19 24 21 24 23 24 19 21
19 21 26 17 19 22 17 23 20 18 18 24 21 23 22 17 17 18 21 25 25 17 22 18 25 18
17 25 26 22 18 25 17 24 25 20 19 25 21 22 18 17 23 21 25 20

Así presentada, la secuencia se llama **serie simple** y solo puede analizarse cuando son muy pocos casos. El más elemental de los resúmenes consiste en contar, para una variable determinada, cuantas apariciones tiene cada categoria. En la columna encabezada P1 (sexo) pueden contarse cuántos unos (1s) y cuántos doses (2s) hay en total.

Tablas de distribución de frecuencia

Las tablas resumen los recuentos, que aquí indican que, de los 150 casos, hay 89 doses y 61 unos. Esto puede decirse brevemente así:

sexo	casos
1	89
2	61
n	150

O de manera más explícita:

sexo	casos
masculino	89
femenino	61
n	150

Que informan que hay 89 varones y 61 mujeres. A la cantidad de casos, que proviene del recuento del número de unos y doses en la columna de sexo, se lo llama técnicamente **frecuencia absoluta simple** y se la indica como **f**. La tabla resulta entonces:

Sexo	f
1	89
2	61
n	150

El total de 150 casos resulta de la suma de todas las frecuencias absolutas simples, de manera breve, esto se indica así:

$$\sum_{i=1}^{k} f_i = n$$

Que se lee "La sumatoria de las frecuencias desde *1* hasta *k* es igual al total de observaciones".
En esa expresión, Σ es el simbolo de suma o sumatoria e indica la realización de esa operación (sumar).
- Las f_i son las frecuencias absolutas simples. El subíndice *i* va cambiando entre categorías.
- La expresión *i=1* señala desde qué valor de *i* se inicia la suma, así como *k* señala la última categoría a sumar. En el ejemplo de las tablas, el valor de *k* es 2 (solo hay dos categorías), por lo que solo hay dos frecuencias a sumar: f_1 y f_2, correspondientes a las cantidades de varones y de mujeres.
-*n* es el total de casos (observaciones).

Lo mismo puede indicarse como:

$$f_1 + f_2 + \cdots + f_k = n$$

Que, en el caso de la tabla anterior resulta simplemente:

$$f_1 + f_2 = 89 + 61 = 150$$

La **frecuencia absoluta simple** de cada valor de la variable es el número de casos que asumen ese valor. Se indica *f*.

Si se quisieran comparar estas frecuencias con las de otra matriz de datos que tuviera un número total de casos diferente de 150, seria inadecuado usar los valores absolutos aquí presentados. Sea la comparación entre la tabla que acabamos de mostrar y otra de la que solo sabemos que contiene 120 varones. La información disponible solo nos diría que en una muestra hay 89 varones y en la otra 120. Sobre esos números no podemos hacer ningún juicio, ya que para saber si son muchos o pocos, o si hay más o menos varones en una muestra o en la otra, necesitamos el total. Si bien 120 es más que 89, la comparación depende de cuál sea el total *sobre* el que se los cuente. Sabemos que la primera muestra tiene

un total de 150 casos, si la otra tiene 200, podríamos afirmar que la cantidad de varones es parecida (poco más de la mitad en ambos casos). Pero para comparar con certeza nos hace falta indicar el peso *relativo* de los varones, no su número total, sino su contribución al total de casos.
Para calcularlo se divide el número de varones en el total general. En el ejemplo, 89/150 es 0,59 que también puede leerse como 59%. Es decir que los varones constituyen una proporción de 0,59 o bien que representan el 59% del total. Mientras que en la segunda tabla, la proporción de varones es 120/200 que es 60%. Estas proporciones se denominan **frecuencias relativas simples**, se simbolizan como *f'* (efe prima), y se calculan dividiendo la frecuencia absoluta por el total. Ahora puede completarse la tabla anterior agregando otra columna.

sexo	f	f'
1	89	0,59
2	61	0,41
n	150	1,00

El valor 1,00 que resulta de sumar las dos frecuencias relativas corresponde al 100% de los casos, es decir a las 150 observaciones. Usando la misma simbología que antes:

$$\sum_{i=1}^{k} f'_i = 1$$

Que afirma que la suma de las frecuencias relativas simples (*f'*) es igual a uno.
La salida Infostat[10] tiene la siguiente forma

P1	Total	Porcentaje
1,00	89	59,33
2,00	61	40,67
Total	150	100,00

Para la variable Carrera que cursa (P2)[11].

P2	Total	Porcentaje
1,00	48	32,00
2,00	44	29,33
3,00	58	38,67
Total	150	100,00

La tabla dice que hay 48 estudiantes de Psicología, que constituyen el 32% del total (*f'=0,32*), y del mismo modo con las demás categorías de la variable.
Al construir estas tablas de distribución de frecuencias se renuncia a una parte de la información que estaba en la matriz de datos. En ella se podía seguir por la fila a cada individuo y describirlo en cada uno de sus aspectos relevados (variables). Por el contrario, la tabla de distribución de frecuencias de *sexo* solo dice que hay 89 varones y 61 mujeres o, en la tabla de P2, que hay 48

[10] Que se obtiene en *Estadísticas — Datos categorizados — Tablas de contingencia*
[11] Con categorías: 1. Psicología; 2. Educación; 3. Psicopedagogía

estudiantes de Psicología y 44 de Educación pero no informa quiénes son. Esta pérdida de información es parte inevitable del proceso en el que se resumen datos, cuanto más sintética sea la presentación, tanta más información habremos perdido. Esto puede visualizarse como el proceso en el que se "toma distancia" de los datos originales: cada vez tenemos una mejor visión de conjunto, pero al mismo tiempo perdemos detalles.

La **frecuencia relativa simple** de cada valor de la variable es la proporción de casos que asumen ese valor. Se indica f.

Los dos ejemplos mostrados hasta aquí corresponden a variables medidas a nivel nominal, por lo que los números no son más que códigos, no representan orden ni puede considerarse la distancia entre ellos. ¿Qué cambia con un nivel de medición más elevado? Con el mismo principio usado para las variables nominales, la forma de la tabla de distribución de frecuencia para la edad (P4) sería:

P4	f	f
17	16	0,11
18	17	0,11
19	21	0,14
20	18	0,12
21	17	0,11
22	12	0,08
23	10	0,07
24	16	0,11
25	16	0,11
26	7	0,05
Total	150	1,00

Sobre esta tabla se pueden calcular otras frecuencias, que respondan a preguntas como ¿cuántos alumnos de menos de 20 años respondieron? Para saber eso, hay que contar cuántos casos hay con edades menores a 20: con 17, 18 o 19 años hay 54 casos, que provienen de sumar las frecuencias de esas categorías (16+17+21).

Así, además de indicar cuántos casos (o qué porcentaje de ellos) tiene determinados valores de la variable, resulta de interés mostrar cuantos (y también que porcentaje) tienen valores *iguales o menores* a uno determinado. Esto va a ser indicado por las **frecuencias acumuladas**, que responden a la pregunta por la cantidad de casos que hay por debajo de una categoría de la variable. Pero solo para variables medidas a escala ordinal o superior, porque con variables nominales no se pueden hacer juicios de orden, como decir que una categoría es mayor o menor que otra. El cálculo de las frecuencias acumuladas consiste en contar las frecuencias de la categoría que interesa y sumarla a las frecuencias de las categorías anteriores a ella. En el ejemplo de la distribución de P4 (edades):

P4	f	f´	F	F´
17	16	0,11	16	0,11
18	17	0,11	33	0,22
19	21	0,14	54	0,36
20	18	0,12	72	0,48
21	17	0,11	89	0,59
22	12	0,08	101	0,67
23	10	0,07	111	0,74
24	16	0,11	127	0,85
25	16	0,11	143	0,95
26	7	0,05	150	1,00
Total	150	1,00		

Se agregaron dos columnas más, las frecuencias acumuladas absolutas (F) y relativas (F´). Las primeras se obtuvieron sumando a la frecuencia absoluta de cada categoría, las frecuencias absolutas de las categorías anteriores a ella. Así, la primera categoría tiene frecuencia acumulada igual a la absoluta simple, porque no hay ningún caso por debajo de 17 años; la segunda es 33, que proviene de contar los 17 de la segunda categoría y sumarle los 16 de la anterior y del mismo modo se construyen las siguientes. La última categoría tiene por frecuencia absoluta acumulada al total de casos (en el ejemplo 150), porque todos (los 150) están en esa categoría o por debajo de ella, es decir, todos tienen de 26 años para abajo. La lectura que hacemos de estas frecuencias es que, por ejemplo, "hay 72 alumnos que tienen 18 años o menos."

La **frecuencia absoluta acumulada** de cada valor de la variable es la cantidad de casos que asumen ese valor y todos los valores menores a él. Se indica *F*.

La última columna de la tabla es la transformación en relativas de las frecuencias absolutas acumuladas y se logra con el mismo procedimiento que se usó para las relativas simples; el de dividir por el total de casos. Se denominan **frecuencias acumuladas relativas**. La lectura de una de estas frecuencias es, por ejemplo, que el 48% de los alumnos que respondieron tiene 20 años o menos. Notemos la diferencia con la frecuencia relativa simple: el 12% de los alumnos tiene exactamente 20 años. La frecuencia relativa simple es la fracción de casos que tienen una determinada categoría (o valor) de la variable, la frecuencia relativa acumulada es la fracción de casos que tiene un valor de la variable o cualquiera de los anteriores a ese valor. Por eso la lectura del ejemplo es "20 años" en la simple y "20 años o menos" en la acumulada.

La **frecuencia relativa acumulada** de cada valor de la variable es la proporción de casos que asumen ese valor y todos los valores menores a él. Se indica F´.

Recategorización

Como se señaló al final del capítulo 1, hay dos situaciones en que se apela a la presentación de los valores de la variable en forma agrupada, es decir que se

recategoriza la variable en intervalos: si se trata de una variable discreta con muchas categorías (como la edad) o si es una variable continua.

Variable discreta con muchas categorías

La construcción de intervalos es una elección; podríamos optar por mostrar todas las categorías, con lo que quedaría una tabla grande, pero muy detallada; o bien agrupar para ganar en sencillez de presentación. Es muy común optar por la construcción de intervalos, de manera de mantener la cantidad de categorías entre cinco y diez. En tablas en que se precisa mostrar mucho detalle, se opta por la enumeración de todas las categorías. La condición de exclusión mutua se logra terminando una categoría en un valor y comenzando la siguiente en el correlativo, como cuando se construyen grupos quinquenales de edad: 0-4, 5-9, 10-14, etc.

Variable continua

Si la variable es continua la recategorización es necesaria, porque no es posible mostrar "todas las categorías" de una variable continua, ya que éstas son, en teoría, infinitas[12]. Para resolver el problema de la exclusión mutua no es posible pasar de un valor al siguiente, por lo que se utiliza un criterio de intervalos abiertos o cerrados. Esto quiere decir que si una categoría es 1,75 – 1,85, se entiende que entran en el intervalo todos quienes tengan estatura superior a 1,75 (excluido este valor) hasta 1,85 (incluido). Se dice que este intervalo es abierto a la izquierda (excluye al valor inicial) y cerrado a la derecha (incluye al valor final). Una persona de 1,75 se contará en el intervalo anterior: 1,65 – 1,75, que si incluye al 1,75 y excluye al 1,65.

Se utilizan tres criterios para recategorizar variables: intervalos iguales, intervalos proporcionales e intervalos teóricos.

Intervalos iguales:

Se organizan los valores de la variable para lograr que el campo de variación quede dividido en tantos intervalos como se desee siendo ellos de igual amplitud. Si es una variable discreta y la cantidad de categorías originales no es múltiplo de número de intervalos que se desean, la cantidad de valores en cada uno no será idéntica, sino aproximadamente igual. La variable P4 del cuestionario, con cinco categorías queda, según este criterio, así:

Grupos de edades	f
17-18	33
19-20	39
21-22	29
23-24	26
25-26	23
n	150

Con dos valores de la variable en cada categoría. Pero si se solicitan tres intervalos, estos resultan:

[12] La cantidad de valores depende de la precisión con que se haga la medición

Grupos de edades	f
17-20	72
21-23	39
24-26	39
n	150

Con cuatro valores en el primer intervalo y tres en cada uno de los otros dos.

Criterio proporcional

Este criterio busca que los intervalos incluyan aproximadamente a la misma cantidad de casos, por lo que su amplitud puede ser diferente. En el capítulo siguiente se verá que los puntos para establecer los cortes de intervalos, se llaman percentiles. Por ahora interesa que con este criterio se logran grupos homogéneos en términos de cantidad de observaciones. P4 con tres intervalos resulta así categorizada:

Grupos de edades	f
17-19	54
20-22	47
23-26	49
n	150

El último intervalo es de mayor amplitud porque hay menos alumnos de esas edades, esto quedará más claro en el próximo capítulo.

Criterio teórico

Aquí la decisión por el lugar donde establecer los puntos de corte para definir los intervalos es del investigador y debe estar fundamentada. Si se considera que la edad esperada de los alumnos observados es entre 19 y 20 años, se pueden hacer tres intervalos con quienes tienen menos de esa edad, quienes tienen la edad esperada y quienes tienen más de esa edad. Los intervalos resultan así:

Grupos de edades	f
17-18	33
19-20	39
21-26	78
n	150

El modo en que se haga la recategorización de una variable depende de una elección del investigador, que debe estar adecuadamente fundamentada. El video *categorización* muestra el modo de hacerlo en este último caso con Infostat®.

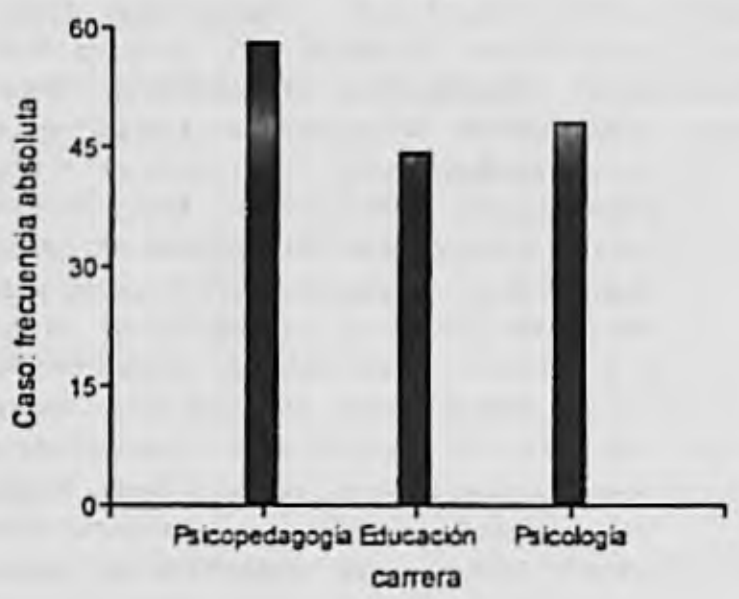
La presentación gráfica de los resultados

En la misma dirección de ofrecer una presentación de los datos recogidos que sea accesible para la interpretación, se muestran a continuación las representaciones gráficas que más se usan para describir información cuantitativa. Nuevamente

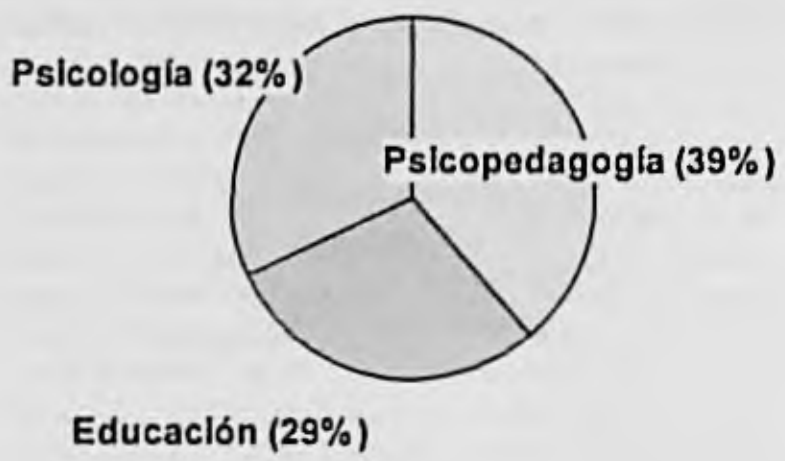
aquí se debe sacrificar la cantidad de información que se ofrece, en aras del impacto visual y facilidad de lectura que proveen los gráficos.
Cuando se trata de variables nominales, normalmente con pocas categorías, son adecuados los **gráficos de barras** o los **diagramas de sectores circulares** (o "de torta"). Veamos un ejemplo para la tabla de la "carrera que cursa" que reproducimos a continuación:

Carrera que cursa	f	f
Psicología	48	0,32
Educación	44	0,29
Psicopedagogía	58	0,38
Total	150	1,00

El paquete InfoStat® presenta el gráfico de barras así:



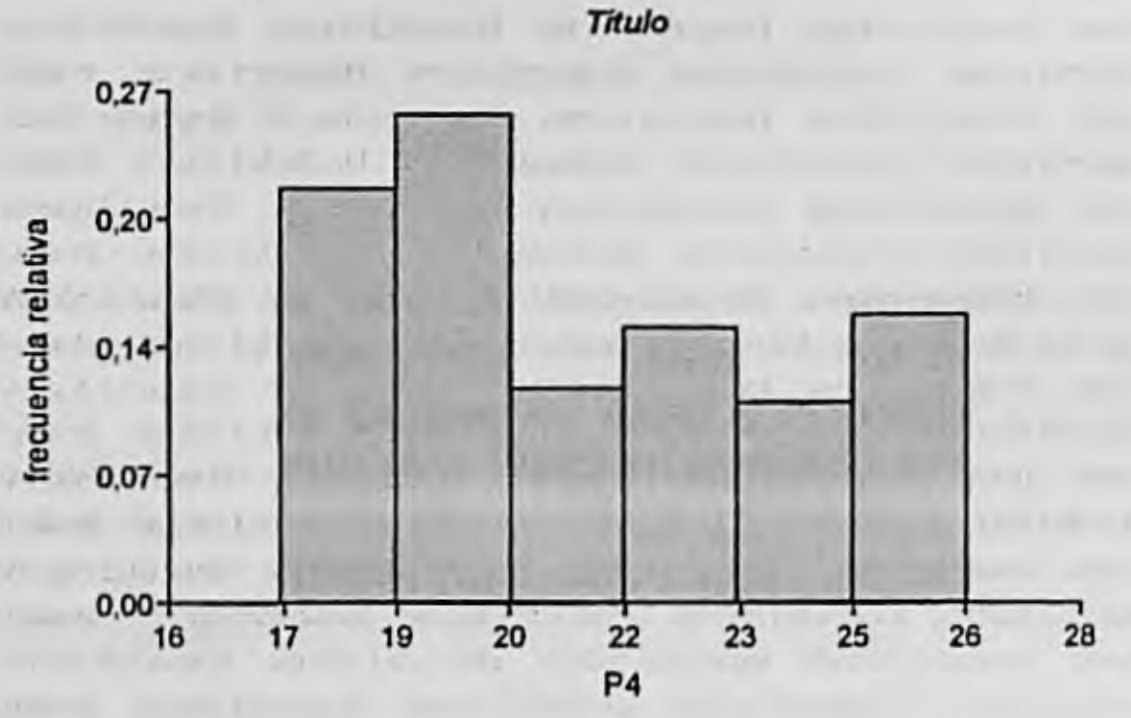
Y del siguiente modo los gráficos de sectores:



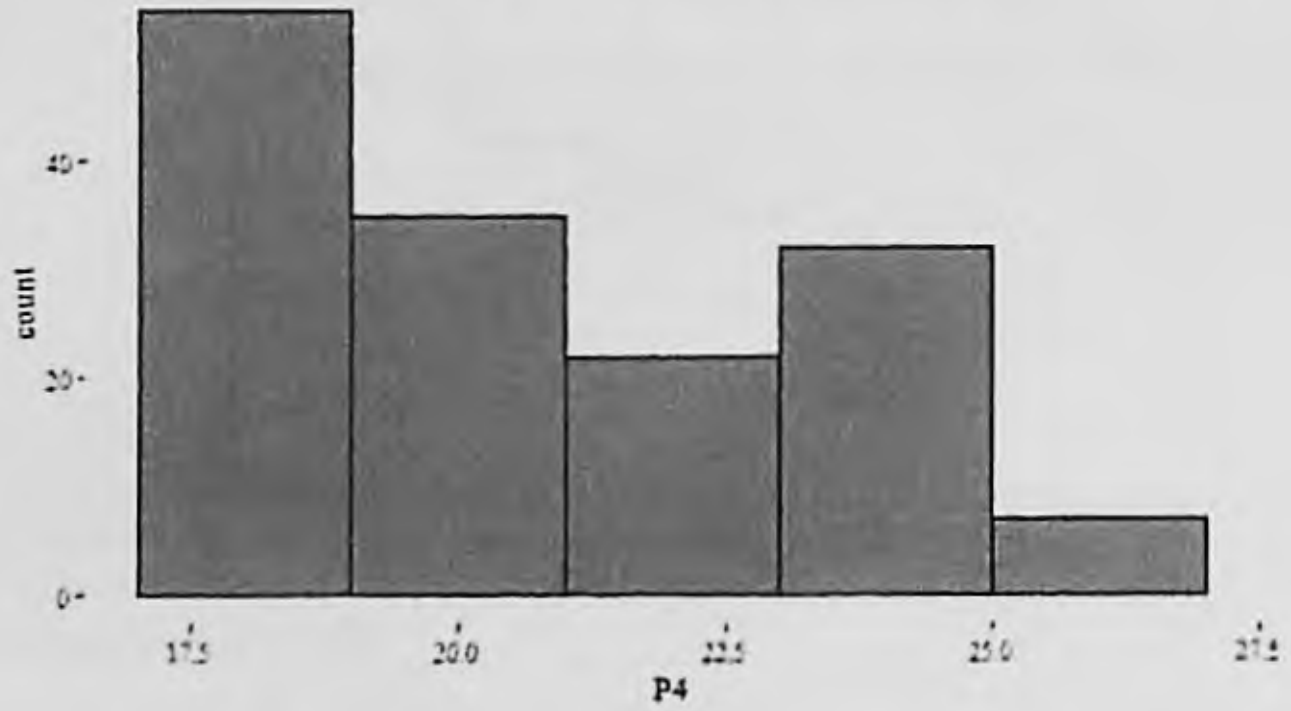
Este último gráfico solo es recomendable si la variable tiene pocas categorías (no más de tres) y las frecuencias son claramente diferentes. Esto es porque el ojo humano no es capaz de distinguir pequeñas diferencias de ángulos, como sí lo es para reconocer diferentes alturas de barras. En este ejemplo, si no estuviera el rótulo con el porcentaje, sería difícil ver la diferencia entre los sectores que

corresponden a Psicología y a Educación, mientras que en el gráfico de barras, eso se ve bien.

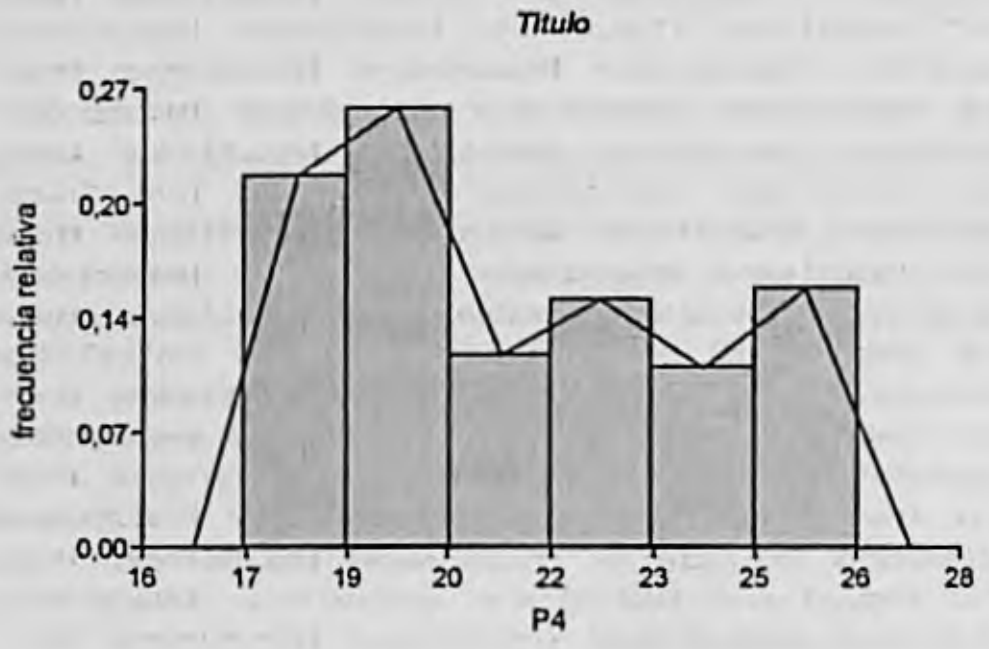
En los casos en que la variable tiene categorías cuantitativas (intervalar o proporcional) se utiliza un gráfico llamado **histograma**, que no es igual al de barras, que se usa con variables nominales.
La presentación de InfoStat® para las edades de la base2018 es:



El lugar donde dice "título" es un espacio editable, para escribir el título del gráfico que elijamos. Sin embargo, los gráficos no son un punto fuerte de Infostat®, con una hoja de cálculo se logran mejores presentaciones, otros programas son más adecuados para graficar, por ejemplo R, con el que se construyó este histograma para la misma variable:

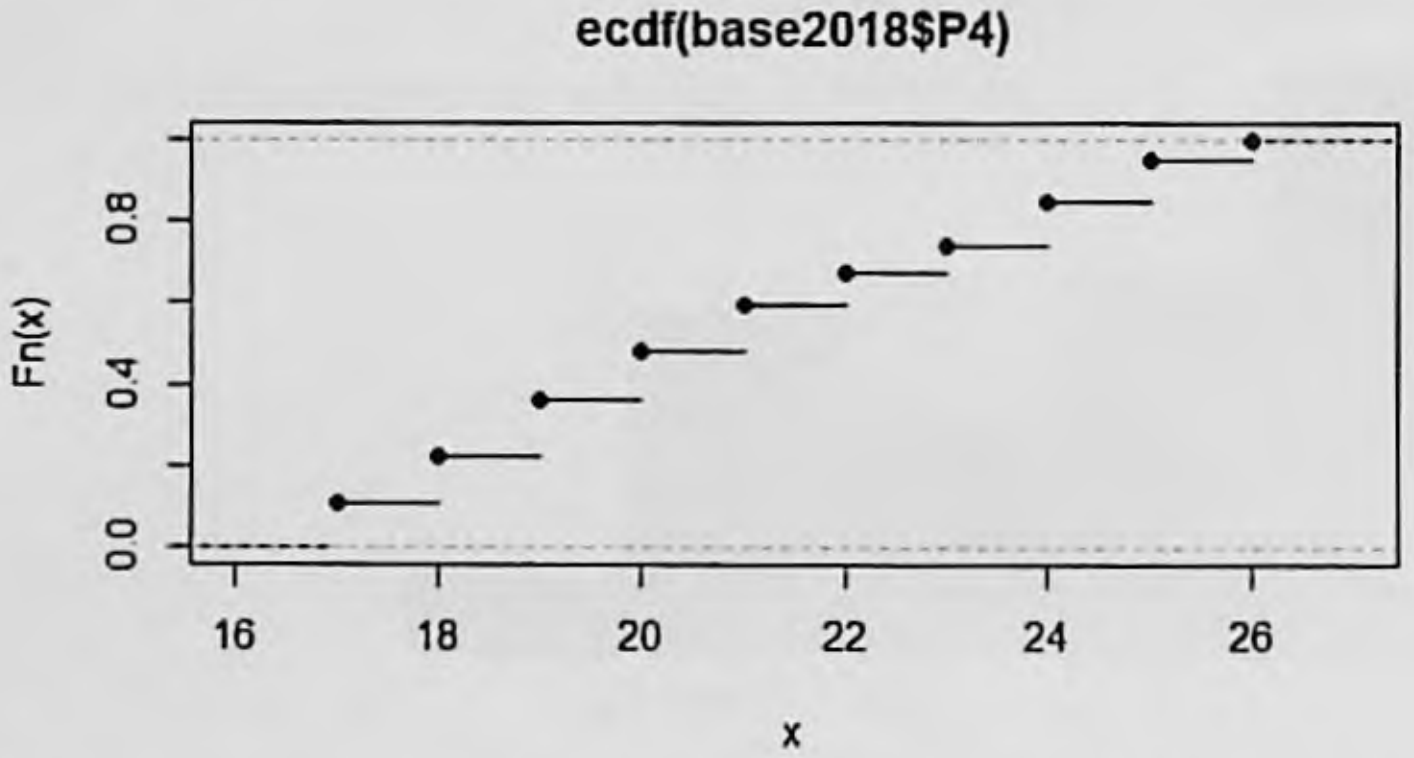


Los histogramas pueden transformarse en **polígonos de frecuencias** uniendo los puntos medios de cada intervalo como se muestra a continuación:

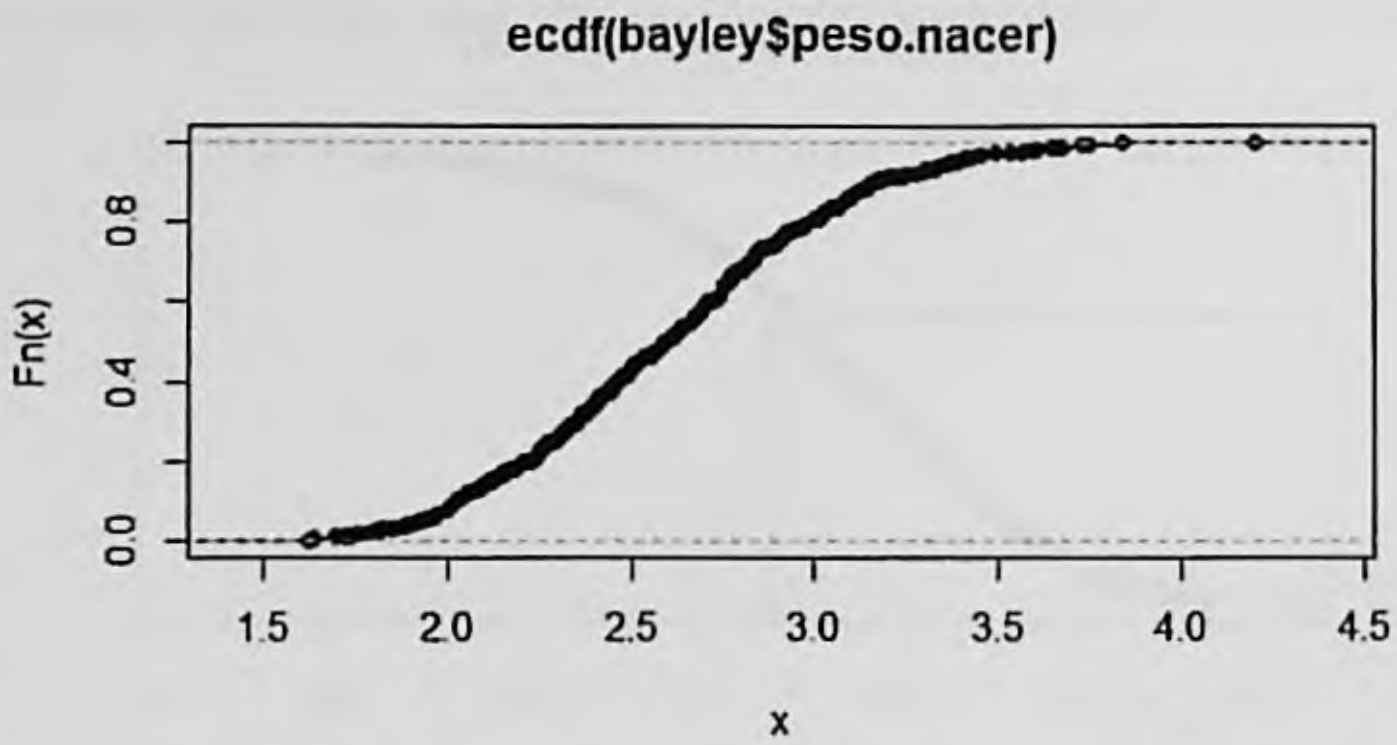


En este gráfico se agregaron dos intervalos, uno anterior al primero y uno posterior al último, cuyas frecuencias son cero, con el objetivo de "cerrar" el polígono sobre el eje horizontal.
El área que queda bajo este polígono es igual a la que encierran los rectángulos del histograma, y valdrá *n* si se grafican frecuencias absolutas ó *1* si son las relativas, como en este ejemplo y como más comúnmente se hace, ya que permite comparar distribuciones de frecuencia que tengan diferente número de casos.

En este tipo de variables (intervalares o proporcionales) es posible calcular frecuencias acumuladas, por lo que también ellas pueden representarse gráficamente. Si la variable es discreta, cada valor aporta su frecuencia, que "salta" en el valor siguiente, por eso el gráfico tiene forma escalonada. Para las edades de la base2018 es:



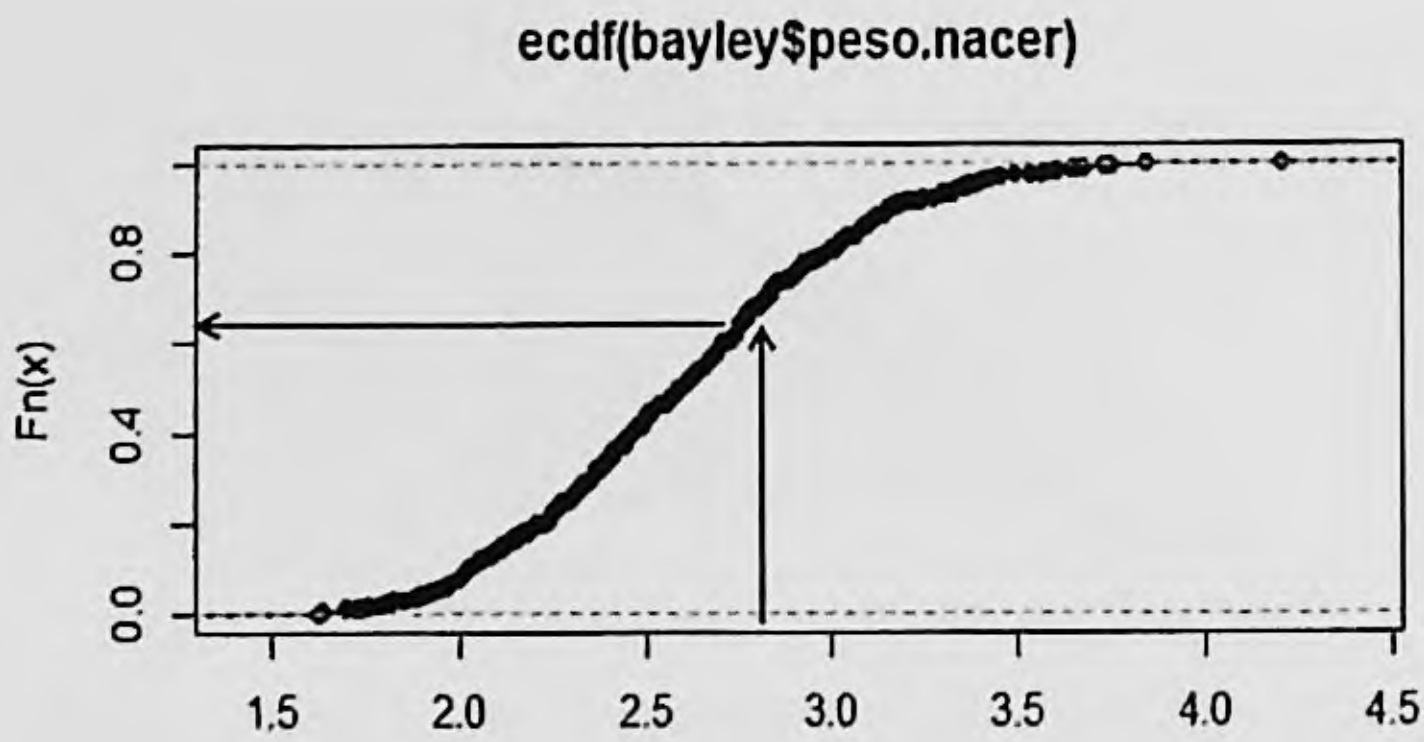
En el que el eje horizontal se indican los valores de la variable discreta edad y en el vertical las frecuencias acumuladas de cada categoría (de cada valor discreto).
Si la variable es continua, las frecuencias se van acumulando gradualmente a medida que aumenta el valor de la variable, el siguiente gráfico muestra las frecuencias acumuladas de los pesos al nacer de un conjunto grande de niños:



Este gráfico se llama **ojiva de Galton**[13] y tiene otra virtud además de la claridad visual, ya que permite **interpolar** valores no observados, o que no aparecen en la tabla. Asi, con el gráfico podemos responder a la pregunta ¿Qué proporción de niños nació con 2,8 kg o menos? La respuesta consiste en buscar el valor 2,8 kg e identificar la frecuencia acumulada que le corresponde.

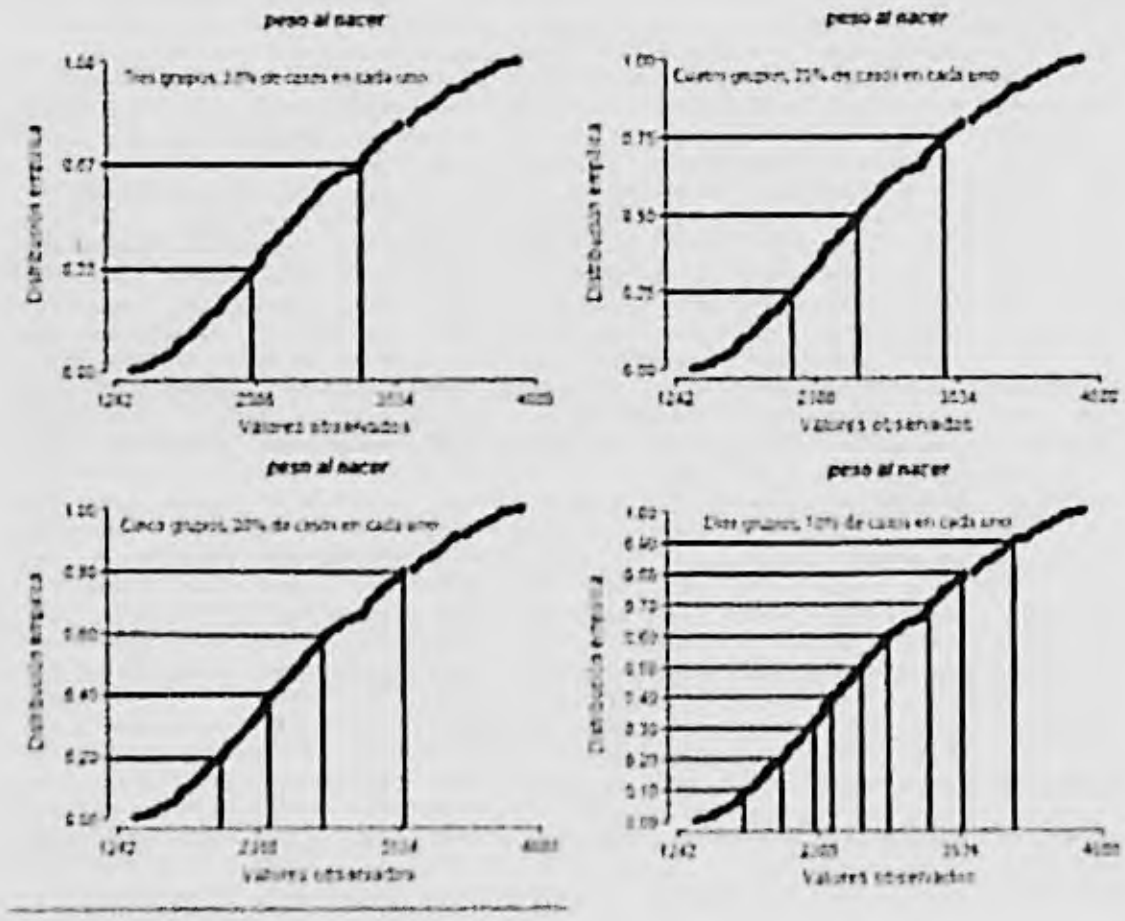
[13]El nombre proviene de la forma arquitectónica del arco ojival, y fue presentada por primera vez por Francis Galton en 1875. Se la denomina así a pesar que su forma recuerda más al arco conopial que al ojival:

Arco ojival	Arco conopial
	
Fuente: https://es.wikipedia.org/wiki/Arco_apuntado	Fuente: https://es.wikipedia.org/wiki/Arco_conopial



En este ejemplo, la ordenada (valor en el eje vertical) correspondiente a los 2,8 kg es aproximadamente 0,7, este resultado se lee diciendo que, de esta muestra, el 70% de los niños nació con 2,8 kg o menos. En los capítulos siguientes veremos otras aplicaciones útiles de este procedimiento.

Además, el establecimiento de los límites de los intervalos según el criterio proporcional, puede realizarse en base a este gráfico. Según cuántos intervalos se quiera construir, se ubican los puntos correspondientes a las frecuencias acumuladas en el eje vertical y se buscan los valores de la variable (eje horizontal), que delimitan los intervalos. Por ejemplo, para cuatro intervalos, cada uno debe contener aproximadamente el 25% de los casos. Se ubican las frecuencias acumuladas de 25, 50 y 75%. Los siguientes gráficos ilustran el uso de la ojiva de Galton para establecer 3, 4, 5 y 10 puntos de corte en una variable continua (pesos al nacer).



Obsérvese que la amplitud de los intervalos (en el eje horizontal) es diferente, pero la proporción de casos que cada uno contiene (eje horizontal), es la misma.

Resumen de definiciones

Frecuencia	Simbolo	Significado	Nivel en que tiene interpretación
Absoluta simple	f	Cantidad de observaciones en cada categoría de la variable	Todos
Relativa simple	f'	Proporción de observaciones en cada categoría de la variable	Todos
Absoluta acumulada	F	Cantidad de observaciones en cada categoría de la variable y en todas las anteriores a ella	Ordinal o superior
Relativa acumulada	F'	Proporción de observaciones en cada categoría de la variable y en todas las anteriores a ella	Ordinal o superior

O, de manera más compacta:

	Simples (en la categoría)	Acumuladas (en la categoría y las anteriores)
Absolutas (cantidad de casos)	f	F
Relativas (proporción de casos)	f'	F'