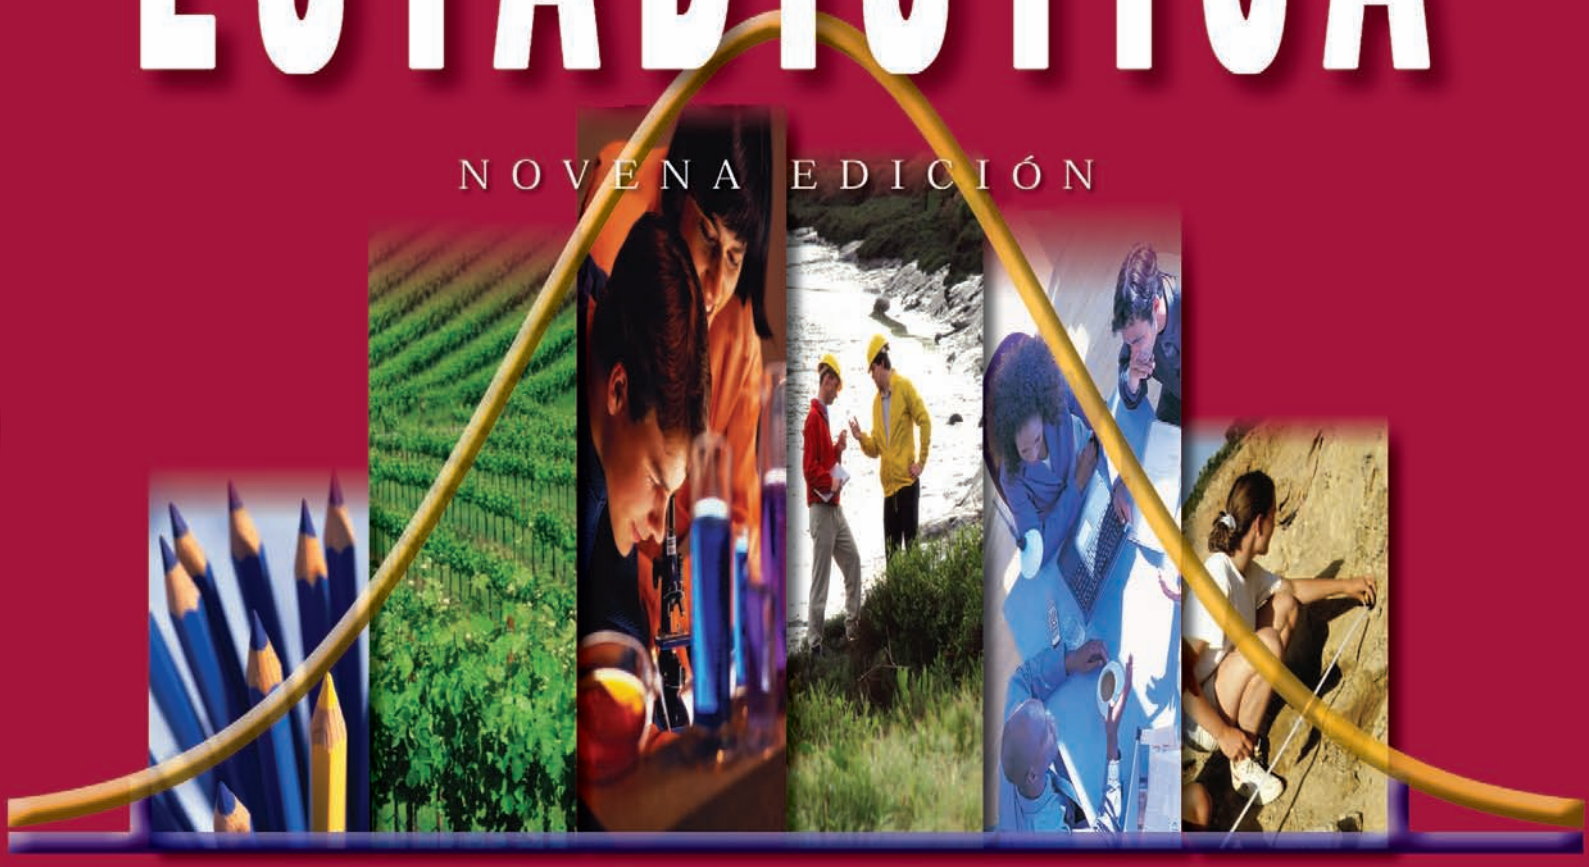
ESTADÍSTICA

NOVENA EDICIÓN

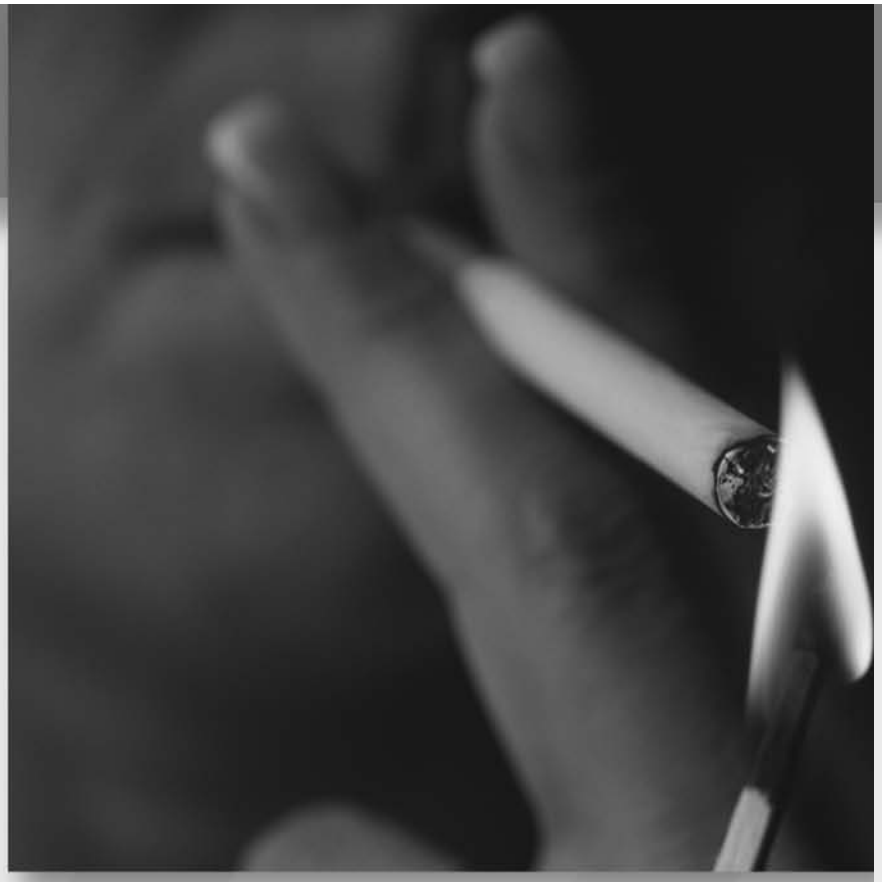


MARIO F. TRIOLA

PEARSON
Addison Wesley®

INCLUYE CD-ROM

2



Descripción, exploración y comparación de datos

2-1 Panorama general

2-2 Distribuciones de frecuencias

2-3 Visualización de los datos

2-4 Medidas de tendencia central

2-5 Medidas de variación

2-6 Medidas de posición relativa

2-7 Análisis exploratorio de datos (AED)

PROBLEMA DEL CAPÍTULO

¿Realmente son afectadas las personas que no fuman cuando otros sí lo hacen junto a ellas? ¿O es un mito el efecto del *fumador pasivo*?

El conjunto número 6 del Apéndice B incluye algunos de los datos disponibles más recientes del National Institute of Health de Estados Unidos. Los datos, que se reproducen en la tabla 2-1, se obtuvieron como parte del National Health and Nutrition Examination Survey. Los valores de los datos corresponden a los niveles medidos de cotinina sérica (en ng/ml) en personas seleccionadas como sujetos de estudio (los datos se redondearon hacia el entero más cercano, de tal modo que un valor de cero no necesariamente implica la ausencia total de cotinina. De hecho, todos los valores originales fueron mayores que cero). La cotinina es un metabolito de la nicotina, es decir, es una sustancia que se produce cuando el cuerpo absorbe la nicotina. Porque se sabe que la nicotina se absorbe cuando se consumen cigarrillos, hay una forma indirecta de medir la presencia efectiva del humo del tabaco; esto es, por medio de la cotinina.

Existen varios aspectos importantes al respecto: ¿deben preocuparse por su salud las personas que no fuman ante la presencia de fumadores activos? Para preverlo, en los últimos años las autoridades sanitarias han elaborado muchos reglamentos para restringir el tabaquismo en lugares públicos. ¿Son justificadas dichas regulaciones por razones de salud o sólo provocan dificultades innecesarias a los fumadores?

Pensamiento crítico: Una comparación visual de las cifras en los tres grupos de la tabla 2-1 proporciona cierta información. En este capítulo presentamos métodos para lograr una mayor comprensión. Seremos capaces de producir comparaciones productivas e inteligentes; aprenderemos técnicas para describir, explorar y comparar conjuntos de datos, tales como los tres grupos de la tabla 2-1.

Tabla 2-1 Niveles medidos de cotinina en tres grupos

Fumador: Los sujetos reportan su consumo de tabaco.

HTA: Humo de tabaco ambiental). Sujetos que no fuman, pero que están expuestos a humo de tabaco ambiental ("fumadores pasivos"), en su casa o trabajo.

SHTA: (Sin humo de tabaco ambiental): Sujetos que no fuman y que no se exponen a humo de tabaco ambiental en su casa o trabajo. Esto es, no fuman ni son fumadores pasivos.

Fumador:	1	0	131	173	265	210	44	277	32	3
	35	112	477	289	227	103	222	149	313	491
	130	234	164	198	17	253	87	121	266	290
	123	167	250	245	48	86	284	1	208	173
HTA:	384	0	69	19	1	0	178	2	13	1
	4	0	543	17	1	0	51	0	197	3
	0	3	1	45	13	3	1	1	1	0
	0	551	2	1	1	1	0	74	1	241
SHTA:	0	0	0	0	0	0	0	0	0	0
	0	9	0	0	0	0	0	0	244	0
	1	0	0	0	90	1	0	309	0	0
	0	0	0	0	0	0	0	0	0	0

2-1 Panorama general

Este capítulo es sumamente importante, ya que presenta las herramientas básicas para medir y describir diferentes características de un conjunto de datos. Cuando se describen, exploran y comparan conjuntos de datos, las siguientes características suelen ser de enorme importancia.

Características importantes de los datos

1. **Centro:** Valor representativo o promedio que indica la localización de la mitad del conjunto de los datos.
2. **Variación:** Medida de la cantidad en que los valores de los datos varían entre sí.
3. **Distribución:** Naturaleza o forma de la distribución de los datos (tales como normales, uniformes o sesgadas).
4. **Datos distantes:** Valores muestrales que están muy alejados de la vasta mayoría de los demás valores de la muestra.
5. **Tiempo:** Características cambiantes de los datos a través del tiempo.

Sugerencia: La memorización suele ser ineficaz para recordar información importante. Sin embargo, las cinco características anteriores son tan importantes que deben recordarse con el uso de una técnica mnemónica conocida por las iniciales CVDDT; por ejemplo, "**C**uidado con los **V**irus que **D**estruyen **D**atos y **T**rabajo". Se ha visto que dichas técnicas de memorización son muy efectivas para recordar importantes palabras clave que evocan conceptos básicos.

Pensamiento crítico e interpretación: más allá de las fórmulas

Los profesores de estadística, por lo general, piensan que no es tan importante memorizar fórmulas o realizar cálculos aritméticos complejos a mano. Por el contrario, suelen enfocarse en la obtención de resultados por medio del uso de algún tipo de herramienta tecnológica (calculadoras o programas de cómputo), para después entender, de forma práctica, los resultados a través del pensamiento crítico. Tenga esto en mente conforme avance en el estudio de este capítulo. Por ejemplo, cuando estudie la muy importante *desviación estándar*, en la sección 2-5, trate de observar por qué la fórmula clave funciona como una medida de variación, después aprenda a calcular los valores de las desviaciones estándar, pero trabaje realmente en la *comprensión* y la *interpretación* de los valores de la desviación estándar.

Aun cuando este capítulo incluye, de forma detallada, los casos para procedimientos importantes, no es necesario conocerlos a la perfección en todas las situaciones. No obstante, recomendamos que, en cada caso, realice algunos cálculos manuales antes de utilizar su calculadora o computadora. Lo anterior hará que su comprensión se incremente y podrá apreciar mejor los resultados obtenidos con las herramientas tecnológicas.

Los métodos de este capítulo suelen denominarse métodos de **estadística descriptiva**, porque su objetivo es resumir o *describir* las características importantes de un conjunto de datos. Más adelante, utilizaremos métodos de **estadística inferencial**; lo haremos cuando usemos datos muestrales para hacer inferencias (o generalizaciones) acerca de una población. Con la estadística inferencial realizamos una deducción que va más allá de los datos conocidos. La materia de estadística tiene dos divisiones generales: la descriptiva y la inferencial; este capítulo trata los conceptos básicos de la estadística descriptiva.

2-2 Distribuciones de frecuencias

Cuando se trabaja con conjuntos grandes de datos, con frecuencia es útil organizarlos y resumirlos por medio de la construcción de una tabla que liste los distintos valores posibles de los datos (ya sea de forma individual o por grupos), junto con las frecuencias correspondientes, es decir, el número de veces que ocurren dichos valores.

Definición

Distribución de frecuencias: lista valores de datos (ya sea de manera individual o por grupos de intervalos), junto con sus frecuencias (o conteos) correspondientes.

La tabla 2-2 es una distribución de frecuencias que resume los niveles medidos de cotinina de los 40 fumadores que se muetran en la tabla 2-1. La **frecuencia** de una clase particular es el número de valores originales que caen dentro de esa clase. Por ejemplo, la primera clase de la tabla 2-2 tiene una frecuencia de 11, lo que indica que 11 de los valores originales de los datos están entre 0 y 99, inclusive.

Para empezar, presentaremos algunos términos estándar utilizados al referirse a la distribución de frecuencia; después describiremos la forma en que se construyen e interpretan.

Tabla 2-2
Distribución de frecuencias de los niveles de cotinina de los fumadores

Cotinina	Frecuencia
0–99	11
100–199	12
200–299	14
300–399	1
400–499	2

Definiciones

Los **límites de clase inferiores** son las cifras más pequeñas que pueden pertenecer a las diferentes clases. (Los límites de clase inferiores de la tabla 2-2 son 0, 100, 200, 300 y 400).

Los **límites de clase superiores** son las cifras más grandes que pueden pertenecer a las diferentes clases. (Los límites de clase superiores de la tabla 2-2 son 99, 199, 299, 399 y 499).

Las **fronteras de clase** son las cifras utilizadas para separar las clases, aunque sin los espacios creados por los límites de clase. Se obtienen de la siguiente manera: se determina el tamaño del espacio entre el límite de clase superior de una clase y el límite de clase inferior de la siguiente. Se suma la mitad de esa cantidad a cada límite de clase superior, para obtener las fronteras de clase superiores; se resta la mitad de esa cantidad de cada límite de clase inferior, para obtener las fronteras de clase inferiores. (Los espacios de la tabla 2-2 son exactamente de una unidad, de modo que a los límites de clase superiores se les suma 0.5 y a los límites de clase inferiores se les resta 0.5. Las fronteras de la primera clase son −0.5 y 99.5, en tanto que las de la segunda clase son 99.5 y 199.5, y así

continúa



sucesivamente. La lista completa de fronteras utilizadas para todas las clases es la siguiente: −0.5, 99.5, 199.5, 299.5, 399.5 y 499.5.)

Las **marcas de clase** son los puntos medios de las clases. (Las marcas de clase de la tabla 2-2 son 49.5, 149.5, 249.5, 349.5 y 449.5). Cada marca de clase se calcula sumando el límite de clase inferior con el límite de clase superior y dividiendo la suma entre dos.

La **anchura de clase** es la diferencia entre dos límites de clase inferiores consecutivos o dos fronteras de clase inferiores consecutivas. (La anchura de clase que se utiliza en la tabla 2-2 es igual a 100).

Las definiciones de anchura de clase y frontera de clase son engañosas. Hay que tener cuidado para evitar el error común de considerar la amplitud de clase como la diferencia entre el límite de clase inferior y el límite de clase superior. Vea la tabla 2.2 y observe que la anchura de clase es de 100 y no de 99. El proceso para determinar las fronteras de clase se simplifica si se comprende que éstas básicamente llenan los espacios entre clases al dividir la diferencia entre el final de una clase y el inicio de la siguiente.

Procedimiento de construcción de una distribución de frecuencias

Las distribuciones de frecuencias se construyen por las siguientes razones: **1.** es posible resumir conjuntos grandes de datos, **2.** se logra cierta comprensión respecto de la naturaleza de los datos, y **3.** se llega a tener un avance para construir gráficas importantes (tales como *histogramas*, que se presentarán en la siguiente sección). Muchas de las herramientas tecnológicas permiten obtener de manera automática las distribuciones de frecuencias, sin necesidad de tenerlas que construir manualmente; no obstante, a continuación se presenta el procedimiento básico:

1. Decida el número de clases que desea tener. Debe ser de entre 5 y 20, y deben utilizarse números enteros o redondeados.
2. Calcule

$$\text{Anchura de clase} \approx \frac{(\text{valor más alto}) - (\text{valor más bajo})}{\text{número de clases}}$$

   Redondee el resultado para obtener un número más adecuado (generalmente se redondea hacia *arriba*). Es probable que necesite cambiar el número de clases, pero la prioridad debe ser utilizar valores que sean fáciles de comprender.
3. Punto de partida: comience por elegir un número para el límite inferior de la primera clase. Elija el valor del dato más bajo o un valor conveniente que sea un poco más pequeño.
4. Con el uso del límite más bajo de la primera clase y la anchura de clase, proceda a listar los demás límites de clase inferior. (Sume la anchura de clase al punto de partida para obtener el segundo límite de clase inferior. Después, sume la anchura de clase al segundo límite de clase inferior para obtener el tercero y así sucesivamente).
5. Anote los límites inferiores de clase en una columna vertical y luego proceda a anotar los límites superiores de clase, que pueden identificarse con facilidad.

Gráficas de crecimiento actualizadas

Los pediatras acostumbran utilizar gráficas de crecimiento estandarizadas para comparar el peso y la altura de sus pacientes con una muestra de otros niños. Se considera que los pequeños están dentro de un rango normal si su peso y su estatura caen dentro de los percentiles 5o y 95o. Si se encuentran fuera de este rango, les aplicarán pruebas para estar seguros de que no hay problemas médicos graves. Los pediatras se dan cuenta de la existencia de un problema importante gracias a las gráficas; debido a que se basan en niños que vivieron entre 1929 y 1975, se concluyó que las gráficas de crecimiento eran imprecisas. Para rectificar tal problema, las gráficas se actualizaron en el año 2000, con la finalidad de que reflejaran las mediciones actuales de millones de niños. Los pesos y las estaturas de los niños son buenos ejemplos de poblaciones que cambian con el paso del tiempo. Ésta es la razón que lleva a considerar las características cambiantes de los datos a lo largo del tiempo como un aspecto importante de una población.

6. Ponga una marca en la clase apropiada para cada dato. Utilice las marcas para obtener la frecuencia total de cada clase.

Cuando construya una distribución de frecuencias, asegúrese de que las clases no se traslapen, de modo que cada uno de los valores originales pertenezca exactamente a una de las clases. Incluya todos los casos, aun aquellos que tienen una frecuencia de cero. Trate de utilizar la misma anchura para todas las clases, aunque en ocasiones es imposible evitar los intervalos con finales abiertos, como "65 años o mayores".



EJEMPLO Niveles de cotinina de fumadores Utilice los 40 niveles de cotinina de los *fumadores* de la tabla 2-1 y siga el procedimiento anterior para crear la distribución de frecuencias que se muestra en la tabla 2-2. Suponga que desea incluir cinco clases.

SOLUCIÓN

Paso 1: Comience seleccionando cinco clases.

Paso 2: Calcule la anchura de clase. En el siguiente cálculo, 98.2 se redondea a 100, ya que es un número más conveniente.

$$\text{anchura de clase} \approx \frac{\text{(valor más alto)} - \text{(valor más bajo)}}{\text{número de clases}} = \frac{491 - 0}{5} = 98.2 \approx 100$$

Paso 3: Elija un punto de partida de 0, que es el valor más bajo en la lista y también porque es un número conveniente.

Paso 4: Sume la anchura de clase de 100 al punto de partida de 0 para determinar que el segundo límite inferior de clase es igual a 100. Continúe, y sume la anchura de clase de 100 para obtener los límites inferiores de clase restantes de 200, 300 y 400.

Paso 5: Liste los límites de clase inferiores de forma vertical, como se muestra al margen. Con esta lista se identifican con facilidad los límites de clases superiores correspondientes, tales como 99, 199, 299, 399 y 499.

0–
100–
200–
300–
400–

Paso 6: Una vez identificados los límites inferiores y superiores de cada clase, proceda a trabajar con el conjunto de datos asignando una marca a cada valor. Ya que completó las marcas, súmelas para obtener las frecuencias que se presentan en la tabla 2-2.

Distribución de frecuencias relativas

Una variante importante de la distribución básica de frecuencias utiliza las **frecuencias relativas**, que se obtienen fácilmente dividiendo cada frecuencia de clase entre el total de frecuencias. Una **distribución de frecuencias relativas** incluye los mismos límites de clase que una distribución de frecuencias, pero utiliza las frecuencias relativas en lugar de las frecuencias reales. Las frecuencias relativas, en ocasiones, se expresan como porcentajes.

$$\text{frecuencia relativa} = \frac{\text{frecuencia de clase}}{\text{suma de todas las frecuencias}}$$

En la tabla 2-3, las frecuencias reales de la tabla 2-2 se reemplazaron con las frecuencias relativas correspondientes, expresadas en porcentajes. La primera clase tiene una frecuencia relativa de $11/40 = 0.275$ o de 27.5%, que se redondea a 28%.

Tabla 2-3
Distribución de frecuencias relativas de los niveles de cotinina en fumadores

Cotinina	Frecuencias relativas
0–99	28%
100–199	30%
200–299	35%
300–399	3%
400–499	5%



Se identifican autores

Entre 1787 y 1788, Alexander Hamilton, John Jay y James Madison publicaron, de forma anónima, el famoso diario *Federalist*, en un intento por convencer a los neoyorquinos de que debían ratificar la Constitución. Se conoció la identidad de la mayoría de los autores de los artículos, pero el autor de 12 de éstos siguió siendo motivo de discusión. Mediante el análisis estadístico del análisis de frecuencias de diversas palabras, ahora concluimos que James Madison es el *probable* autor de esos dos artículos. En muchos de los artículos disputados, la evidencia en favor de la autoría de Madison es abrumadora, al grado de que casi con seguridad afirmamos que estamos en lo correcto.

La segunda clase tiene una frecuencia relativa de $12/40 = 0.3$ o 30%, y así sucesivamente. Si se construye de manera correcta, la suma de las frecuencias relativas debe totalizar 1 (o 100%), con algunas pequeñas discrepancias, que se permiten al redondear los errores. Puesto que 27.5% se redondeó a 28%, y 2.5% se redondeó a 3%, la suma de frecuencias relativas de la tabla 2-3 es de 101%, en lugar de 100%.

Ya que utilizan proporciones simples o porcentajes, las distribuciones de frecuencias nos facilitan la comprensión de la distribución de los datos y nos permiten comparar diferentes conjuntos de datos.

Distribución de frecuencias acumulativas

Otra variante de la distribución de frecuencias estándar se utiliza cuando se buscan totales acumulativos. La **frecuencia acumulativa** de una clase es la suma de las frecuencias para esa clase y todas las clases previas. La tabla 2-4 muestra la distribución de frecuencias acumulativas de la distribución de frecuencias de la tabla 2-2. Con el uso de las frecuencias originales de 11, 12, 14, 1 y 2, sumamos $11 + 12$ para obtener la segunda frecuencia acumulativa de 23; después, sumamos $11 + 12 + 14 = 37$, para obtener la tercera, y así sucesivamente. Vea la tabla 2-4 y observe que, además del uso de frecuencias acumulativas, los límites de clase fueron reemplazados por expresiones como “menor que”, las cuales describen el nuevo rango de valores.

Pensamiento crítico: interpretación de las distribuciones de frecuencias

La transformación de datos brutos en una distribución de frecuencias suele ser un medio para un gran fin. Los siguientes ejemplos ilustran la forma en que se utilizan las distribuciones de frecuencias para describir, explorar y comparar conjuntos de datos. (La siguiente sección muestra cómo la elaboración de una distribución de frecuencias suele ser el primer paso en la creación de una gráfica, que presenta la naturaleza de la distribución de forma visual).

EJEMPLO **Descripción de los datos** Remítase al conjunto de datos 1 en el Apéndice B, que se refieren al pulso de 40 adultos varones que se seleccionaron aleatoriamente. La tabla 2-5 presenta los *últimos dígitos* de tales datos. Si la tasa de pulsaciones se mide contando el número de latidos cardiacos en un minuto, esperamos que los últimos dígitos tengan frecuencias muy similares. Sin embargo, note que la distribución de frecuencias muestra que todos los últimos dígitos son números *pares*; *no* hay números impares. Lo anterior sugiere que las tasas de pulsaciones no se contaron durante un minuto. Tal vez se contaron durante 30 segundos y después se duplicaron los resultados. (Al examinar más las tasas de pulsaciones *originales*, vemos que cada valor original es un múltiplo de cuatro, lo que sugiere que el número de latidos por minuto se contó durante 15 segundos y que después el resultado se multiplicó por cuatro). Es fascinante aprender el método de recolección de datos con la simple descripción de algunas características de los mismos.

Tabla 2-4
Distribución de frecuencias acumulativas de los niveles de cotinina en fumadores

Cotinina	Frecuencia Relativa
Menos de 100	11
Menos de 200	23
Menos de 300	37
Menos de 400	38
Menos de 500	40

Tabla 2-5
Últimos dígitos de las tasas de pulsaciones de varones

Último dígito	Frecuencia
0	7
1	0
2	6
3	0
4	11
5	0
6	9
7	0
8	7
9	0

EJEMPLO Exploración de datos Para estudiar el comportamiento del géiser Old Faithful, ubicado en el Parque Nacional Yellowstone, los geólogos recolectan datos del tiempo (en minutos) que transcurre entre las erupciones. La tabla 2-6 muestra un resumen de los datos reales obtenidos. Un examen de la distribución de frecuencias reveló un comportamiento inesperado: la distribución del tiempo presenta dos picos distintos. Tal distribución condujo a los geólogos a considerar dos posibles explicaciones.

Tabla 2-6
Tiempo (en minutos) entre las erupciones del géiser Old Faithful

Tiempo	Frecuencia
40–49	8
50–59	44
60–69	23
70–79	6
80–89	107
90–99	11
100–109	1



EJEMPLO Comparación de conjuntos de datos El problema que abre este capítulo incluye conjuntos de datos que representan los niveles de cotinina que se midieron en fumadores, en no fumadores expuestos al humo del tabaco y en no fumadores sin exposición al

Tabla 2-7 Niveles de cotinina de los tres grupos

Cotinina	Fumadores	No fumadores expuestos al humo	No fumadores sin exposición al humo
0–99	28%	85%	95%
100–199	30%	5%	0%
200–299	35%	3%	3%
300–399	3%	3%	3%
400–499	5%	0%	0%
500–599	0%	5%	0%

continúa

humo del tabaco. La tabla 2-7 presenta las frecuencias relativas de los tres grupos. Al comparar dichas frecuencias relativas, es claro que la distribución de frecuencias de los fumadores es muy diferente de las de los otros dos grupos. Debido a que los dos grupos de no fumadores (expuestos y no expuestos) tienen una frecuencia tan alta de cantidades de la primera clase, sería útil comparar más esos conjuntos de datos examinando los valores con mayor detalle.

2-2 Destrezas y conceptos básicos

En los ejercicios 1 a 4, identifique la anchura de clase, las marcas de clase y las fronteras de clase para las distribuciones de frecuencias dadas, con base en el conjunto de datos 1 del Apéndice B.

1.

Presión sanguínea sistólica de varones	Frecuencia
90–99	1
100–109	4
110–119	17
120–129	12
130–139	5
140–149	0
150–159	1

2.

Presión sanguínea sistólica de mujeres	Frecuencia
80–99	9
100–119	24
120–139	5
140–159	1
160–179	0
180–199	1

3.

Colesterol en varones	Frecuencia
0–199	13
200–399	11
400–599	5
600–799	8
800–999	2
1000–1199	0
1200–1399	1

4.

Índice de masa corporal de mujeres	Frecuencia
15.0–20.9	10
21.0–26.9	15
27.0–32.9	11
33.0–38.9	2
39.0–44.9	2

En los ejercicios 5 a 8, elabore la distribución de frecuencias relativas que corresponda a la distribución de frecuencias del ejercicio indicado.

5. Ejercicio 1 **6.** Ejercicio 2 **7.** Ejercicio 3 **8.** Ejercicio 4

En los ejercicios 9 a 12, construya la distribución de frecuencias acumulativas que corresponda a la distribución de frecuencias del ejercicio indicado.

9. Ejercicio 1 **10.** Ejercicio 2 **11.** Ejercicio 3 **12.** Ejercicio 4

13. Dado cargado El autor taladró un hoyo en un dado, lo rellenó con plomo y lo lanzó 200 veces. (Sí, el autor tiene mucho tiempo libre). Los resultados se presentan en la distribución de frecuencias al margen. Construya la distribución de frecuencias relativas correspondiente y determine si el dado en cuestión difiere significativamente de un dado que no ha sido "cargado".

Tabla del ejercicio 13

Resultado	Frecuencia
1	27
2	31
3	42
4	40
5	28
6	32

Tabla del ejercicio14

Dígito	Frecuencia
0	18
1	12
2	14
3	9
4	17
5	20
6	21
7	26
8	7
9	16

14. Lotería La distribución de frecuencias al margen se basa en los números *Win 4* de la lotería del estado de Nueva York, incluidos en el conjunto de datos 26 del Apéndice B. Elabore la distribución de frecuencias relativas correspondiente y determine si los resultados se seleccionaron de tal forma que todos los dígitos sean igualmente probables.

15. Osos Remítase al conjunto de datos 9 del Apéndice B y construya una distribución de frecuencias con los pesos de los osos. Utilice 11 clases, iniciando con el límite de clase inferior de 0, con una anchura de clase de 50 lb.

16. Temperaturas corporales Remítase al conjunto de datos del Apéndice B; después, construya una distribución de frecuencias de las temperaturas corporales para la medianoche del segundo día. Utilice ocho clases, iniciando con el límite de clase inferior de 96.5, con una anchura de clase de 0.4°F. Describa dos características notables del resultado.

17. Circunferencias de cabezas Remítase al conjunto de datos 3 del Apéndice B. Elabore una distribución de frecuencias con las circunferencias de las cabezas de bebés hombres; luego, construya una distribución de frecuencias separada para las circunferencias de las cabezas de los bebés mujeres. En ambos casos, utilice las clases de 34.0–35.9, 36.0–37.9, etcétera. Después compare los resultados y determine si hay una diferencia significativa entre los dos géneros.

18. Películas de dibujos animados para niños Remítase al conjunto de datos 7 del Apéndice B. Construya una distribución de frecuencias con la duración de las escenas de consumo de tabaco que presentan las películas de dibujos animados para niños; luego, elabore una distribución de frecuencias separada con la duración de las escenas en donde se consume alcohol. En ambos casos, utilice las clases de 0–99, 100–199, etcétera. Compare los resultados y determine si hay una diferencia significativa.

19. Corredores del maratón Remítase al conjunto de datos 8 del Apéndice B. Construya una distribución de frecuencias relativas con las edades de la muestra de hombres que terminaron el maratón de la ciudad de Nueva York; después, elabore una distribución de frecuencias relativas separada con las edades de las mujeres. En ambos casos, inicie la primera clase con el límite de clase inferior de 19, con una anchura de clase de 10. Compare los resultados y determine si hay alguna diferencia notable entre los dos grupos.

20. Coca Cola regular/Coca Cola dietética Remítase al conjunto de datos 17 del Apéndice B. Construya una distribución de frecuencias relativas con los pesos de la Coca Cola regular; inicie la primera clase en 0.7900 lb, con una anchura de clase de 0.0050 lb. Después, construya otra distribución de frecuencias relativas con los pesos de la Coca Cola dietética, iniciando la primera clase en 0.7750 lb, con una anchura de clase de 0.0050 lb. Luego, compare los resultados y determine si hay una diferencia significativa. Si es así, dé una posible explicación.

2-2 Más allá de lo básico

21. Interpretación de los efectos de los datos distantes Remítase al conjunto de datos 20 del Apéndice B, de las cargas axiales de latas de aluminio de 0.0111 pulgadas de grosor. A la carga de 504 lb, se le denomina *dato distante*, ya que se encuentra muy lejos del resto de los valores. Construya una distribución de frecuencias que incluya el valor de 504 lb; después, elabore otra sin incluir este valor. En ambos casos, inicie la primera clase en 200 lb y utilice una anchura de clase de 20 lb. Interprete los resultados estableciendo una generalización acerca del efecto que tiene un dato distante en una distribución de frecuencias.

22. Número de clases Los lineamientos de Sturges para la construcción de una distribución de frecuencias sugieren que el número ideal de clases puede aproximarse por medio de $1 + (\log n)/(\log 2)$, donde n es el número de valores de datos. Utilice esta guía para completar la tabla y determine el número ideal de clases.

Tabla del ejercicio 22

Número de valores	Número ideal de clases
16–22	5
23–45	6
	7
	8
	9
	10
	11
	12

2-3 Visualización de los datos

Recuerde que el principal objetivo de este capítulo es aprender técnicas importantes para investigar las características "CVDDT" importantes de los conjuntos de datos: centro, variación, distribución, datos distantes y cambios a lo largo del tiempo. En la sección 2-2 se introdujo la distribución de frecuencias como una herramienta para describir, explorar o comparar *distribuciones* de conjuntos de datos. En esta sección continuaremos el estudio de las distribuciones por medio de la introducción de gráficas, que son dibujos de distribuciones. Conforme avance en esta sección, considere que el objetivo no es simplemente la construcción de gráficas, sino más bien aprender algo acerca de los conjuntos de datos, es decir, comprender la naturaleza de sus distribuciones.

Histogramas

Entre los distintos tipos de gráficas que se presentan en esta sección, el histograma es particularmente importante.

Definición

Histograma es una gráfica de barras en donde la escala horizontal representa clases de valores de datos y la escala vertical representa frecuencias. Las alturas de las barras corresponden a los valores de frecuencia, en tanto que las barras se dibujan de manera adyacente (sin espacios entre ellas).

Es posible construir un histograma tras completar una tabla de distribución de frecuencias para un conjunto de datos. En la figura 2-1 se presentan los niveles de cotinina de fumadores, los cuales corresponden, de forma directa, a la distribución de frecuencias de la tabla 2-2, que se presentó en la sección previa. Cada barra del histograma está marcada con su frontera de clase inferior a la izquierda y su frontera

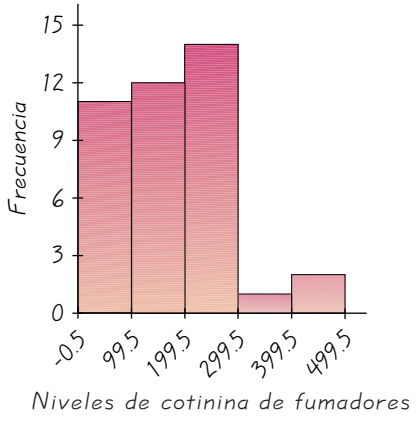


FIGURA 2-1 Histograma

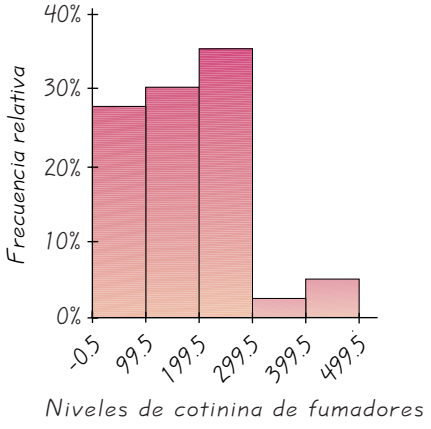


FIGURA 2-2 Histograma de frecuencias relativas

de clase superior a la derecha. En lugar de utilizar fronteras de clase a lo largo de la escala horizontal, suele ser más práctico utilizar los valores de las marcas de clase centradas por debajo de sus barras correspondientes. El uso de los valores de las marcas de clase es muy común en los programas de cómputo que generan histogramas de manera automática.

Antes de construir un histograma, a partir de una distribución de frecuencias completa, debemos mencionar algo acerca de las escalas que se utilizan en los ejes vertical y horizontal. La frecuencia máxima (o el siguiente número conveniente más alto) tiene que sugerir un valor para la parte superior de la escala vertical; el cero habrá de colocarse al inicio. En la figura 2-1 se diseñó una escala vertical que va de 0 a 15. La escala horizontal debe subdividirse de modo tal que permita que se ajusten bien todas las clases. De manera ideal, hay que tratar de seguir la regla práctica del intervalo, la cual establece que la altura vertical del histograma debe medir aproximadamente tres cuartas partes de la anchura total. Ambos ejes tienen que etiquetarse de forma clara.

Interpretación de un histograma Recuerde que el objetivo no es la simple construcción de un histograma, sino aprender algo acerca de los datos. Analice el histograma para ver qué es posible aprender acerca de "CVDDT": el centro de los datos, la variación (que se estudiará en la sección 2.5), la forma de la distribución y la existencia o ausencia de datos distantes (valores que se encuentran lejos de los demás). El histograma no es adecuado para determinar si hay cambios a lo largo del tiempo. Al examinar la figura 2-1, se verá que el histograma se centra alrededor del 175, que los valores varían aproximadamente desde 0 hasta 500 y que la distribución está más cargada hacia la izquierda.

Histograma de frecuencias relativas

Un **histograma de frecuencias relativas** tiene la misma forma y escala horizontal que un histograma, pero la escala vertical está marcada con las frecuencias relativas en lugar de las frecuencias reales, tal como sucede en la figura 2-2.

Polígono de frecuencias

Un **polígono de frecuencias** utiliza segmentos lineales conectados a puntos que se localizan directamente por encima de los valores de las marcas de clase. Véase la figura 2-3 en la página siguiente, que incluye el polígono de frecuencias correspondiente a la tabla 2-2. Las alturas de los puntos corresponden a las frecuencias de clase, en tanto que los segmentos lineales se extienden hacia la derecha y la izquierda, de manera que la gráfica inicia y termina sobre el eje horizontal.

Ojiva

Una ojiva es una gráfica lineal que representa frecuencias *acumulativas*, de la misma forma que la distribución de frecuencias acumulativas es una lista de éstas (véase la tabla 2-4 en la sección anterior). La figura 2-4 es la ojiva correspondiente a la tabla 2-4. Observe que la ojiva utiliza fronteras de clase, a lo largo de la escala horizontal, y que la gráfica empieza con la frontera inferior de la primera clase, en tanto que finaliza con la frontera superior de la última clase. Las ojivas son útiles para determinar el número de valores que se encuentran por debajo de un valor

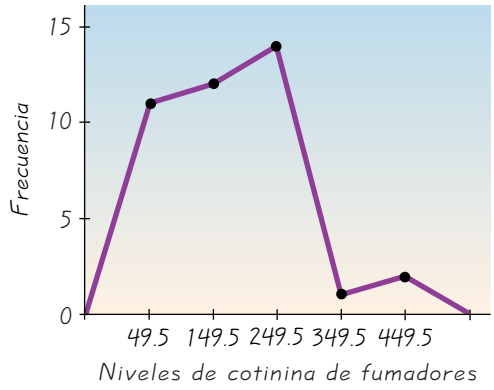


FIGURA 2-3 **Polígono de frecuencias**

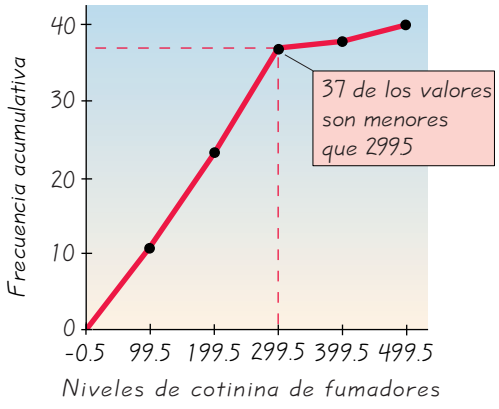


FIGURA 2-4 **Ojiva**

particular. Por ejemplo, la figura 2-4 muestra que 37 de los valores del nivel de cotinina son menores que 299.5.

Gráficas de puntos

Una **gráfica de puntos** consiste en una gráfica en donde se marca cada valor de un dato como un punto a lo largo de una escala de valores. Los puntos que representan valores iguales se amontonan. Observe la figura 2-5, que representa la duración de películas de dibujos animados para niños, que se listan en el conjunto de datos 7 del Apéndice B. Por ejemplo, los dos puntos que aparecen a la izquierda representan el valor de 64 minutos, que ocurre dos veces en el conjunto de datos 7. En esta gráfica de puntos vemos que la duración de 120 minutos difiere mucho de las demás.

Gráficas de tallo y hojas

Una **gráfica de tallo y hojas** representa datos que separan cada valor en dos partes: el tallo (el dígito ubicado en el extremo izquierdo) y la hoja (el dígito del extremo derecho). La ilustración de la siguiente página muestra una gráfica de tallo y hojas de las mismas duraciones de películas listadas en el conjunto de datos 7 del Apéndice B. Dichas duraciones (en minutos), si se acomodan en orden creciente, son 64, 64, 69, 70, 71, 71, 71, 72, 73, . . . , 120. Es fácil ver cómo el primer valor de 64 se separó en su tallo de 6 y su hoja de 4. Cada uno de los valores restantes, lo hace de una manera similar. Note que las hojas se ordenaron en forma creciente y no en el orden en que aparecen en la lista original.

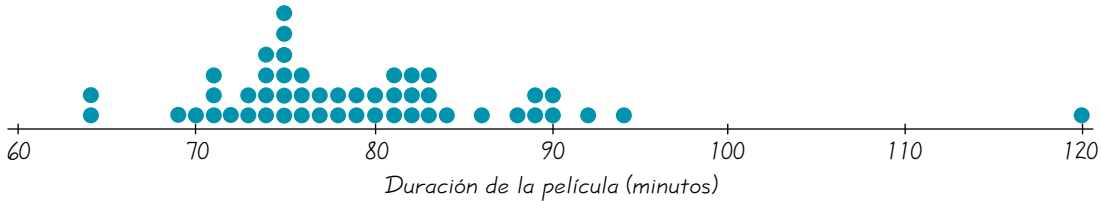


FIGURA 2-5 **Gráfica de puntos de la duración de películas para niños**

Gráfica de tallo y hojas

Tallo (decenas)	Hojas (unidades)	
6	449	←Los valores son 64, 64, 69.
7	01112334444555555666778899	
8	0011122233346899	
9	0024	
10		
11		
12	0	← El valor es 120.

Si colocamos la página de lado, veremos una distribución de tales datos. Una gran ventaja de la gráfica de tallo y hojas radica en que nos permite ver la distribución de los datos y, al mismo tiempo, retener toda la información de la lista original. En caso de ser necesario, reconstruiríamos la lista original de valores. Otra ventaja es que la construcción de una gráfica de tallo y hojas implica una forma fácil y rápida de *ordenar* datos, y algunos procedimientos estadísticos requieren de un ordenamiento (como el cálculo de una mediana o de los percentiles).

Los renglones de datos de una gráfica de tallo y hojas son similares en naturaleza a las barras de un histograma. Uno de los lineamientos para la construcción de histogramas es que se incluyan entre 5 y 20 clases, lo cual se aplica a la gráfica de tallo y hojas por las mismas razones. Por lo general, obtenemos mejores gráficas de tallo y hojas si redondeamos primero los valores de los datos originales. Además, este tipo de gráficas pueden *expandirse* para incluir más renglones y *condensarse* para disminuir el número de renglones. En nuestro ejemplo, la gráfica de tallo y hojas puede expandirse subdividiendo los renglones en otros con hojas que incluyan dígitos del 0 al 4, así como otros con dígitos del 5 al 9, tal como se muestra en el siguiente diagrama.

Gráfica expandida de tallo y hojas

Tallo	Hojas	
6	44	←Para hojas de 0 a 4
6	9	← Para hojas de 5 a 9
7	01112334444	
7	555555666778899	
8	001112223334	
8	6899	
9	0024	
9		
10		
10		
11		
11		
12	0	



El crecimiento de la estadística

El reportero Richard Rothstein escribió en el *New York Times* que el estudio del álgebra, la trigonometría y la geometría en la escuela preparatoria "deja muy poco espacio para el estudio de la estadística y la probabilidad. Sin embargo, los estudiantes necesitan fundamentos sobre el análisis de datos". El reportero observó que el cálculo tiene un papel prominente en los estudios universitarios, aun cuando "sólo algunos trabajos, principalmente en áreas técnicas, realmente lo utilizan". Rothstein citó un estudio realizado por el profesor Clifford Konold, de la Universidad de Massachusetts, quien contó el número de desplegados de datos que aparecen en el *New York Times*. En los ejemplares de 1972, el doctor Konold encontró cuatro gráficas o tablas en cada una de las 10 ediciones semanales (sin incluir las secciones de deportes y negocios), pero en 1982 había ocho, en 1992 fueron 44 y "el próximo año, él (el doctor Konold) podría encontrar más de 100". El crecimiento de la estadística como una disciplina se fomenta, en parte, por el uso creciente de dichos desplegados de datos en los medios de comunicación.

Cuando hay necesidad de *reducir* el número de renglones, es posible condensar una gráfica de tallo y hojas al combinar los renglones adyacentes, tal como se indica en la siguiente ilustración. Note que insertamos un asterisco para separar los dígitos en las hojas asociadas con los números en cada tallo. Cada renglón en la gráfica condensada debe incluir exactamente un asterisco, de modo que la forma de la gráfica no se distorsione.

Gráfica condensada de tallo y hojas

Tallo	Hojas	
6-7	449*01112334444555555666778899	← 64, 64, 69, 70, . . . , 79
8-9	0011122233346899*0024	
10-11	*	
12-13	0*	← El valor es 120.

Gráficas de Pareto

La Federal Communications Commission (FCC) verifica la calidad del servicio telefónico en Estados Unidos. Algunas de las quejas en contra de las compañías telefónicas incluyen los cambios, es decir, se cambia de compañía al cliente sin su consentimiento, y el cobro forzoso de cargos no autorizados. Datos recientes de la FCC mostraron que las quejas en contra de las compañías telefónicas estadounidenses eran las siguientes: 4473 por tarifas y servicios, 1007 por marketing, 766 por llamadas internacionales, 614 por cargos de acceso, 534 por servicios de operadora, 12,478 por cambios sin consentimiento y 1214 por forzamiento. Si usted fuese reportero de un medio impreso, ¿cómo presentaría dicha información? La simple escritura de oraciones con datos numéricos no llevaría a una verdadera comprensión. Un mejor método consiste en utilizar una gráfica conveniente; en este caso, la gráfica de Pareto se adecuaría muy bien.

Una **gráfica de Pareto** es una gráfica de barras para datos cualitativos, donde las barras se ordenan de acuerdo con las frecuencias. Al igual que en los histogramas, las escalas verticales de las gráficas de Pareto representan frecuencias o frecuencias relativas. La barra más alta se coloca a la izquierda y las más pequeñas hacia la derecha. Al ordenar las barras por frecuencias, la gráfica enfoca la atención en las categorías más importantes. La figura 2-6 es una gráfica de Pareto que muestra con claridad que el cambio sin consentimiento es, por mucho, el asunto más grave de las quejas de los clientes respecto de las empresas telefónicas.

Gráficas circulares

Las gráficas circulares también se utilizan para visualizar datos cualitativos. La figura 2-7 es un ejemplo de una **gráfica circular**, que presenta datos cualitativos como si fueran rebanadas de un pastel. La figura 2-7 representa los mismos datos de la figura 2-6. Para construir una gráfica circular, se separa el círculo en las proporciones que se adecuan mejor. La categoría de quejas por cambio sin consentimiento representan un 59% del total, de manera que la porción que representa el cambio sin consentimiento debe abarcar el 59% del total (con un ángulo central de $0.59 \times 360° = 212°$).

La gráfica de Pareto (figura 2-6) y la gráfica circular (figura 2-7) presentan los mismos datos en formas diferentes, pero una comparación probablemente demuestre que la gráfica de Pareto es mejor para resaltar los tamaños relativos de los distintos componentes, lo cual explica por qué muchas compañías, como Boeing Aircraft, a menudo utilizan las gráficas de Pareto.

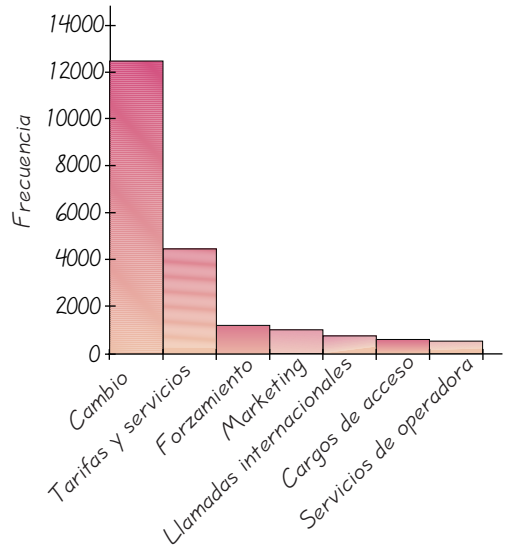


FIGURA 2-6 **Gráfica de Pareto de quejas en contra de las compañías telefónicas**

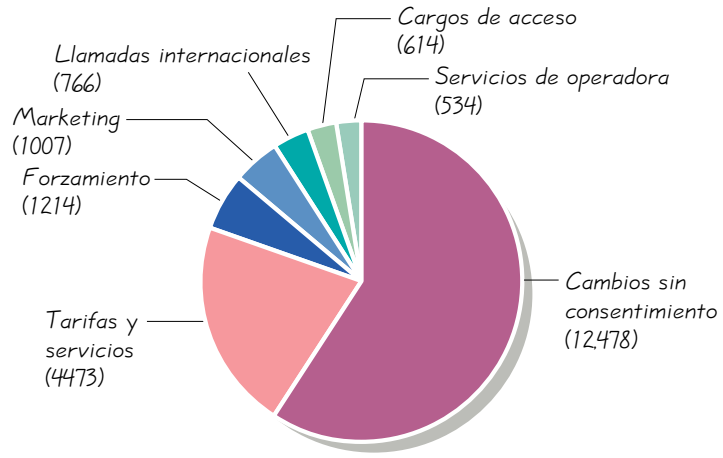
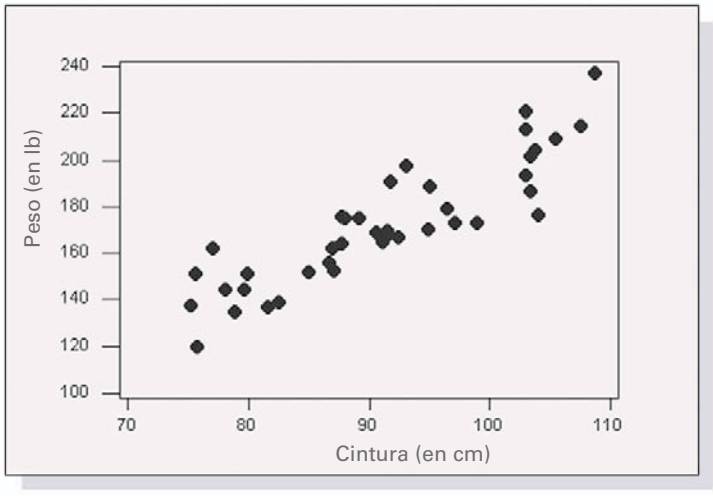


FIGURA 2-7 **Gráfica circular de quejas en contra de las compañías telefónicas**

Diagramas de dispersión

Un **diagrama de dispersión** es una gráfica de datos apareados (x, y), con un eje x horizontal y un eje y vertical. Los datos se aparean de tal forma que cada valor de un conjunto de datos corresponde a un valor de un segundo conjunto de datos. Para elaborar un diagrama de dispersión manualmente, construya un eje horizontal para los valores de la primera variable y un eje vertical para los valores de la segunda variable, y después grafique los puntos. El patrón de los puntos graficados suele ser útil para determinar si hay alguna relación entre las dos variables. (Este aspecto se estudia a profundidad en el tema de la correlación, en la sección 9-2). Con los datos del peso (en libras) y la circunferencia de la cintura (en cm) de los varones del conjunto de datos 1 del Apéndice B, utilizamos Minitab para generar el diagrama de dispersión que aparece a continuación. Con base en dicha gráfica, parece haber una relación entre el peso y la circunferencia de la cintura, tal como lo muestra el patrón de puntos.

Minitab





Florence Nightingale

A Florence Nightingale (1820-1910) se le reconoce como la fundadora de la profesión de enfermería, aunque también salvó miles de vidas usando la estadística. Cuando encontraba un hospital insalubre y con desabasto, mejoraba dichas condiciones y después utilizaba la estadística para convencer a otros de la necesidad de una reforma médica amplia. Ella diseñó gráficas originales para ilustrar que, durante la guerra de Crimea, murieron más soldados a consecuencia de las condiciones insalubres que en combate. Florence Nightingale fue pionera en el uso de la estadística social y de las técnicas gráficas.

Gráficas de series de tiempo

Los **datos de series de tiempo** son aquellos que se reúnen en diferentes momentos. Por ejemplo, la figura 2-8 muestra el número de pantallas de autocinemas existentes durante un periodo de 14 años (con base en datos de la National Association of Theater Owners). Vemos que durante este tiempo hay una clara tendencia de valores decrecientes. Lo que alguna vez fue parte importante de Estados Unidos, en especial para el autor, está en decadencia. Afortunadamente, la tasa de disminución parece ser menor que a finales de la década de 1980. Con frecuencia es sumamente importante conocer los cambios en los valores de una población a través del tiempo. Muchas compañías cayeron en la bancarrota porque no verificaban la calidad de sus bienes o servicios; además, de manera incorrecta, creían estar tratando con datos estables. No se dieron cuenta de que sus productos se volvían defectuosos conforme cambiaban importantes características de la población. El capítulo 13 introduce las *gráficas de control*, que son herramientas eficaces para verificar datos de series de tiempo.

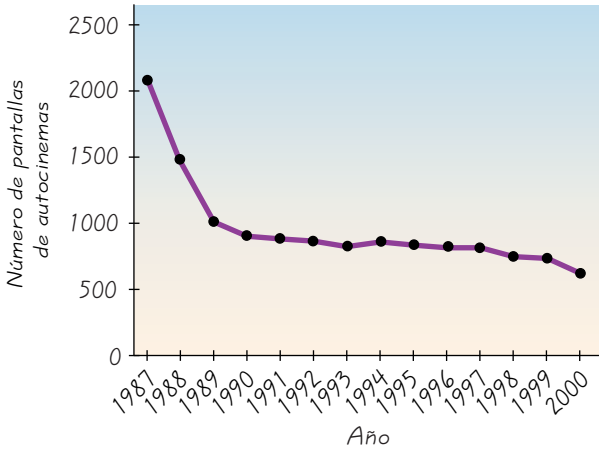
Otras gráficas

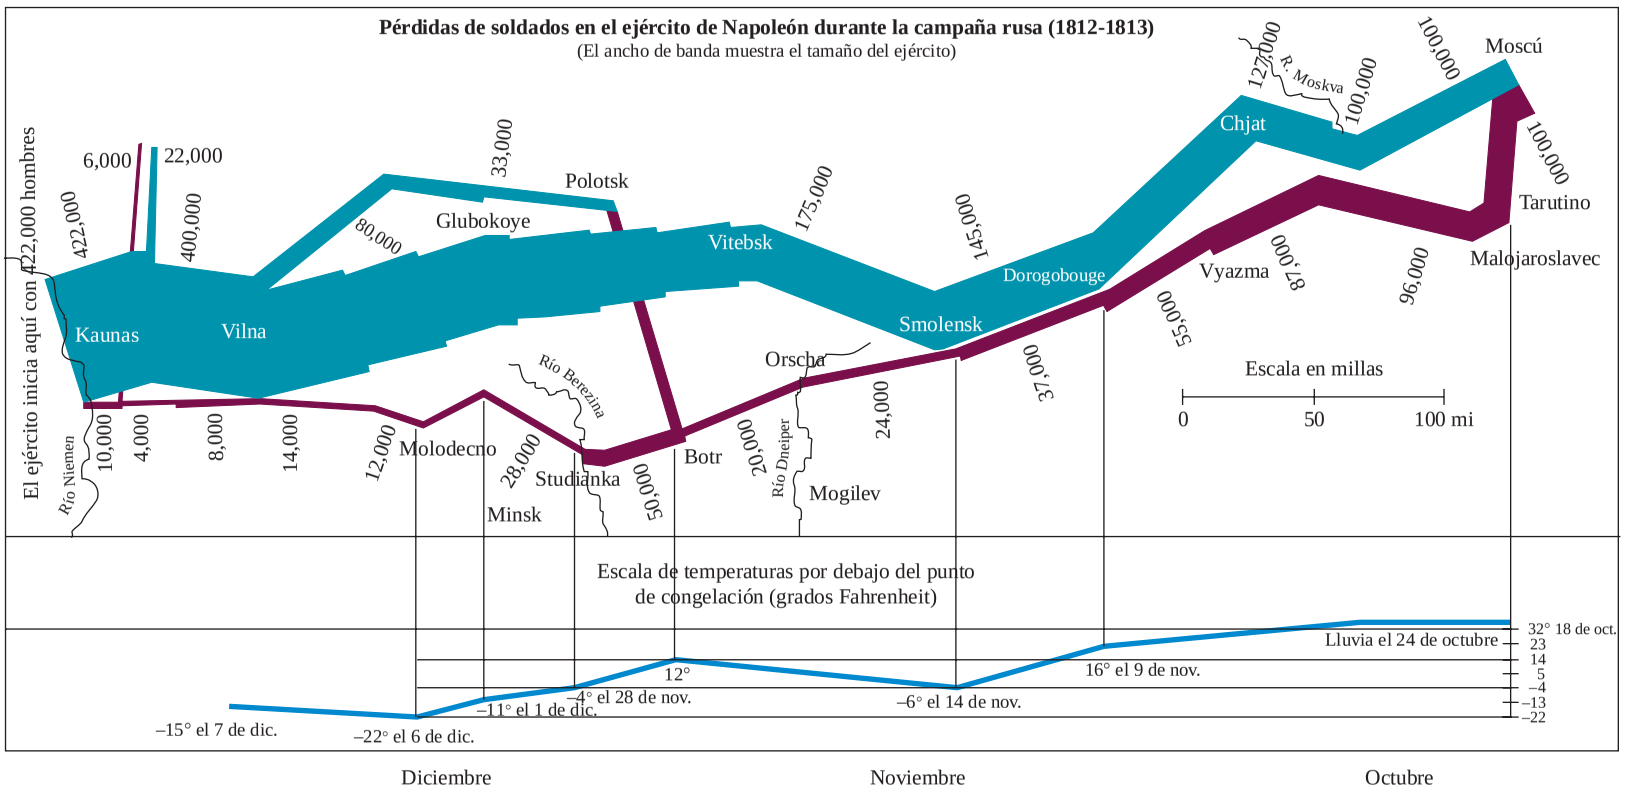
Además de las presentaciones gráficas descritas, hay muchas otras que pueden utilizarse para representar datos de manera llamativa y efectiva. En la sección 2-7 presentaremos las gráficas de cuadro, que son muy útiles para revelar la distribución de los datos. Los pictogramas representan datos con el uso de imágenes de objetos como soldados, tanques, aviones, monedas o bolsas de dinero.

La figura que aparece en la página 53 se ha descrito quizá como “la mejor gráfica estadística que se haya dibujado jamás”. Esta figura incluye seis variables diferentes con respecto a la marcha del ejército de Napoleón hacia Moscú en 1812-1813. La banda gruesa a la izquierda representa el tamaño del ejército cuando inició la invasión a Rusia, desde Polonia. La banda inferior muestra su tamaño durante la retirada, con las temperaturas y fechas correspondientes. Aunque Charles Joseph Minard la elaboró en 1861, esta gráfica es ingeniosa, incluso desde la perspectiva actual.

Otra gráfica notable, de importancia histórica, es la que elaboró la enfermera más famosa del mundo, Florence Nightingale. Esta gráfica, que aparece en la figura 2-9 de la página 54, es particularmente interesante porque salvó vidas cuando Nightingale la utilizó para convencer a los oficiales británicos de que los hospitales militares necesitaban mejorar sus condiciones sanitarias, sus tratamientos y su abastecimiento. Su dibujo se asemeja a una gráfica circular, pese a que todos los ángulos centrales

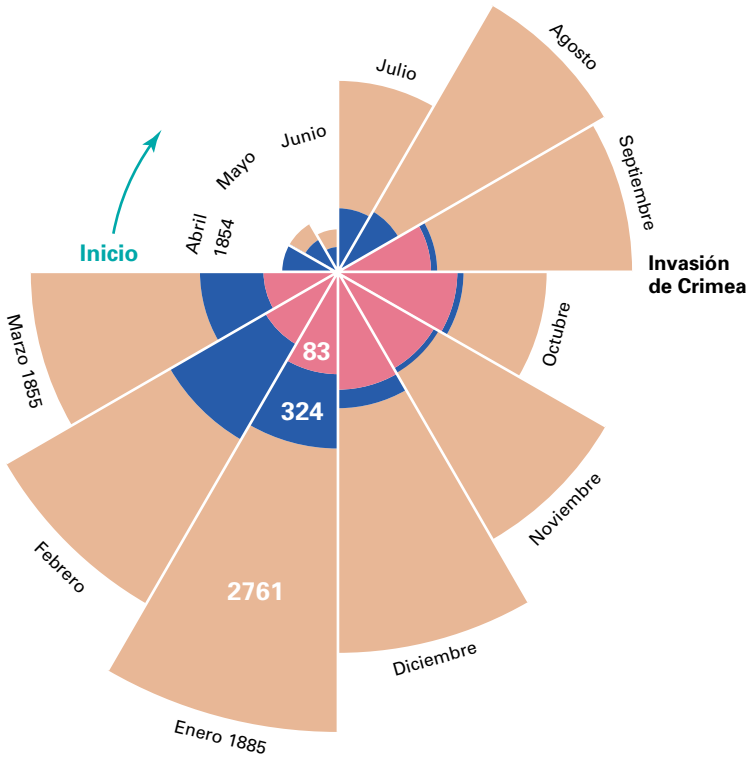
FIGURA 2-8 Datos de series de tiempo: número de pantallas de autocinemas





Créditos: Edward R. Tufte, *The Visual Display of Quantitative Information* (Cheshire, CT: Graphics Press, 1983). Se reproduce con autorización.

FIGURA 2-9 Muertes en los hospitales militares británicos durante la guerra de Crimea



son iguales y se usan radios diferentes para mostrar los cambios en el número de muertes mensuales. Las regiones externas de la figura 2-9 representan las muertes por enfermedades que pudieron prevenirse; las regiones internas representan muertes por heridas y las regiones centrales, muertes por otras causas.

Conclusión

La eficacia de la gráfica de Florence Nightingale ilustra muy bien el siguiente punto importante: una gráfica no es, en sí misma, un resultado final, es una herramienta para describir, explorar y comparar datos, que consideramos como sigue:

Descripción de datos: En un histograma, por ejemplo, se toman en cuenta el centro, la variación, la distribución y los datos distantes (CVDDT, sin el último elemento del tiempo). ¿Cuál es el valor aproximado del centro de la distribución y cuál es el rango aproximado de valores? Considere la forma completa de la distribución. ¿Están los valores distribuidos de manera uniforme? ¿La distribución está sesgada (ladeada) hacia la izquierda o hacia la derecha? ¿Tiene la distribución un pico a la mitad? Identifique cualquier valor extremo y cualquiera otra característica notable.

Exploración de datos: Buscamos características de la gráfica que revelen rasgos interesantes y/o útiles del conjunto de datos. Por ejemplo, en la figura 2-9 observamos que morían más soldados por cuidados hospitalarios inadecuados que por heridas de batalla.

Comparación de datos: Construya gráficas similares que faciliten la comparación de conjuntos de datos. Por ejemplo, si usted grafica un polígono de frecuencias con los pesos de hombres y otro polígono de frecuencias con pesos de mujeres, sobre el mismo conjunto de ejes, el polígono de los hombres debe aparecer a la derecha del polígono de mujeres, mostrando así que los hombres tienen pesos mayores.



Utilizando la tecnología

Ahora existen poderosos programas de computación que son bastante efectivos para generar gráficas impresionantes. Este libro hace referencia frecuente al STATDISK, Minitab, Excel y a la calculadora TI-83 Plus, por lo que listamos las gráficas (que ya comentamos en esta sección) que es posible elaborar. (Para información a detalle sobre los procedimientos, véanse los manuales que complementan este libro).

STATDISK Puede generar histogramas y diagramas de dispersión.

Minitab Puede generar todas las gráficas incluidas en esta sección.

Excel Puede generar histogramas, polígonos de frecuencias, gráficas circulares y diagramas de dispersión.

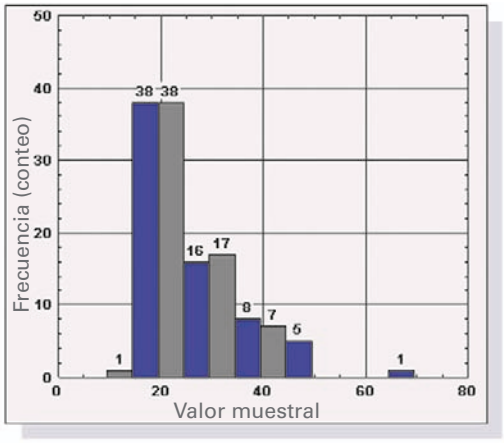
TI-83 Plus Puede generar histogramas y diagramas de dispersión.

2-3 Destrezas y conceptos básicos

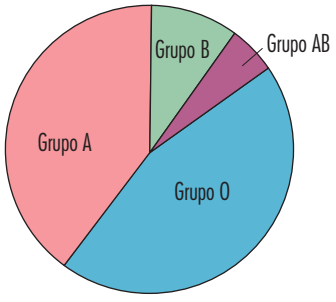
En los ejercicios 1 a 4, conteste las preguntas con respecto al histograma que se genera con STATDISK, el cual representa las edades de todos los polizontes del Queen Mary.

1. Centro ¿Cuál es el valor aproximado del centro? Es decir, ¿qué edad parece estar cerca del centro de todas las edades?
2. Variación ¿Cuáles son las edades más bajas y más altas posibles?
3. Porcentaje ¿Qué porcentaje de los 131 polizontes tenía menos de 30 años de edad?
4. Anchura de clase ¿Cuál es la anchura de clase?

STATDISK



En los ejercicios 5 y 6, remítase a la gráfica circular adjunta referente a los grupos sanguíneos de una muestra grande de personas (con base en datos del Greater New York Blood Program).



5. Interpretación de la gráfica circular ¿Cuál es el porcentaje aproximado de individuos con sangre tipo A? Suponiendo que la gráfica circular se base en una muestra de 500 personas, ¿aproximadamente cuántas de ellas tienen sangre tipo A?
6. Interpretación de la gráfica circular ¿Cuál es el porcentaje aproximado de personas con sangre tipo B? Suponiendo que la gráfica circular se base en una muestra de 500 personas, ¿aproximadamente cuántas de ellas tienen sangre tipo B?

Tabla del ejercicio 7

Edad	Estudiantes	Profesores
0–2	23	30
3–5	33	47
6–8	63	36
9–11	68	30
12–14	19	8
15–17	10	0
18–20	1	0
21–23	0	1

Tabla del ejercicio 8

Velocidad	Frecuencia
42–45	25
46–49	14
50–53	7
54–57	3
58–61	1

7. Automóviles de estudiantes/profesores Se obtuvieron muestras de automóviles de estudiantes y profesores en la universidad donde trabaja el autor. Sus edades (en años) se resumen en la distribución de frecuencias adyacente. Construya un histograma de frecuencias relativas para los automóviles de los estudiantes y otro histograma de frecuencias relativas para los automóviles de los profesores. Compare ambos. ¿Cuáles son las diferencias más notables?

8. Infracciones por exceso de velocidad La distribución de frecuencias adyacente describe las velocidades de conductores a quienes infraccionó la policía en la ciudad de Poughkeepsie. Estos conductores viajaban en una zona con límite de velocidad de 30 millas/hora en Creek Road, que atraviesa la universidad del autor. Construya un histograma correspondiente a la distribución de frecuencias. ¿Qué sugiere la distribución sobre el límite de velocidad establecido, comparándolo con el límite de velocidad señalado?

9. Osos El ejercicio 15, en la sección 2-2, se refiere al conjunto de datos 9 del Apéndice B. Use la distribución de frecuencias del peso de los osos (con 11 clases, iniciando con un límite de clase inferior de 0 y una anchura de clase de 50 lb), y construya el histograma correspondiente. ¿Cuál es el peso aproximado que se encuentra en el centro?

10. Temperaturas corporales El ejercicio 16, en la sección 2-2, se refiere al conjunto de datos 4 del Apéndice B. Con la distribución de frecuencias de las temperaturas corporales de medianoche del segundo día (con ocho clases, iniciando con el límite de clase inferior de 96.5 y una anchura de clase de 0.4°F), elabore el histograma correspondiente. ¿Qué sugiere la distribución sobre la creencia común de que la temperatura corporal promedio es de 98.6°F? Si se selecciona a los sujetos de forma aleatoria, las temperaturas deberían tener una distribución aproximadamente normal. ¿Es así?

En los ejercicios 11 a 14, realice las comparaciones construyendo las gráficas que se indican.

11. Circunferencia de cabezas El ejercicio 17, en la sección 2-2, se refiere al conjunto de datos 3 del Apéndice B. Utilice la distribución de frecuencias de la circunferencia de la cabeza de los niños y la distribución de frecuencias de la circunferencia de la cabeza de las niñas (con las clases de 34.0-35.9, 36.0-37.9, etcétera.), y construya los dos polígonos de frecuencias correspondientes, utilizando el mismo conjunto de ejes. Compare los resultados y determine si parece haber una diferencia significativa entre los dos géneros.

12. Películas de dibujos animados para niños El ejercicio 18, en la sección 2.2, se refiere al conjunto de datos 7 del Apéndice B. Utilice la distribución de frecuencias de la duración de las películas de dibujos animados para niños que incluyen consumo de tabaco y la distribución de frecuencias de la duración de aquéllas que presentan escenas de consumo de alcohol (con clases de 0-99, 100-199, etcétera.), y construya los dos polígonos de frecuencias correspondientes, usando el mismo conjunto de ejes. Compare los resultados y determine si parece haber una diferencia significativa.

13. Corredores del maratón El ejercicio 19, en la sección 2-2, se refiere al conjunto de datos 8 del Apéndice B. Utilice la distribución de frecuencias relativas de las edades de varones y la distribución de frecuencias relativas de las edades de mujeres (con un límite de clase inferior de 19 y una anchura de clase de 10), y construya los histogramas de frecuencias relativas correspondientes. Compare los resultados y determine si parece haber diferencias notables entre los dos grupos.

14. Coca Cola regular y Coca Cola dietética Remítase al conjunto de datos 17 del Apéndice B y utilice los pesos de la Coca Cola regular y de la Coca Cola dietética. Con las

clases de 0.7750-0.7799, 0.7800-0.7849, . . . , 0.8250-0.8299, construya los dos polígonos de frecuencias sobre los mismos ejes. Después, compare los resultados y determine si parece haber una diferencia significativa. ¿Cuál sería una posible explicación de la diferencia?

En los ejercicios 15 y 16, liste los datos originales que se representan con las gráficas de tallo y hojas.

15.

Tallo (decenas)	Hojas (unidades)
20	0005
21	69999
22	2233333
23	
24	1177

16.

Tallo (centenas)	Hojas (decenas y unidades)
50	12 12 12 55
51	
52	00 00 00 00
53	27 27 35
54	72

En los ejercicios 17 y 18, construya la gráfica de puntos con los datos que se representan en la gráfica de tallo y hojas del ejercicio dado.

17. Ejercicio 15

18. Ejercicio 16

En los ejercicios 19 y 20, elabore las gráficas de tallo y hojas para los conjuntos de datos que se indican, que se encuentran en el Apéndice B.

19. Osos La longitud (en pulgadas) de los osos en el conjunto de datos 9. (*Sugerencia*: Primero redondee las longitudes hacia el entero más cercano).

20. Plástico Los pesos (en libras) del plástico que desechan 62 amas de casa: remítase al conjunto de datos 23, e inicie redondeando los pesos hacia el decimal más cercano. (Utilice una gráfica expandida de tallo y hojas, con aproximadamente 11 renglones).

21. Empleos Se realiza un estudio para determinar la manera en que las personas obtienen empleo. La tabla incluye datos de 400 sujetos que se seleccionaron aleatoriamente. Los datos se basan en resultados del National Center for Carrer Strategies. Construya la gráfica de Pareto correspondiente a tales datos. Si alguien deseara obtener un empleo, ¿cuál parece ser el método más efectivo?

Fuentes de empleo de sujetos que se encuestaron	**Frecuencia**
Anuncios clasificados	56
Empresas que buscan ejecutivos	44
Contactos interpersonales	280
Envíos por correo	20

22. Empleos Remítase a los datos del ejercicio 21 y construya una gráfica circular. Compárela con la gráfica de Pareto. ¿Podría determinar cuál gráfica es más efectiva para mostrar la importancia relativa de las fuentes de empleo?

23. Descarrilamiento de trenes Un análisis del descarrilamiento de trenes mostró que 23 de éstos fueron causados por vías en mal estado, nueve por fallas en el equipo, 12 por errores humanos y seis por otras causas (con base en datos de la Federal Railroad Administration). Construya una gráfica circular que represente tales datos.

24. Descarrilamiento de trenes Remítase a los datos del ejercicio 23 y elabore una gráfica de Pareto. Compare dicha gráfica con la gráfica circular. ¿Podría determinar cuál de las gráficas es más efectiva para mostrar la importancia relativa de las causas de los descarrilamientos de trenes?

En los ejercicios 25 y 26, utilice los datos apareados del apéndice B para construir un diagrama de dispersión.

25. Alquitrán/ CO Para el conjunto de datos 5, ubique el alquitrán en la escala horizontal y el monóxido de carbono en la escala vertical. Determine si parece haber una relación entre el alquitrán y el monóxido de carbono. Si es así, describa dicha relación.

26. Cuello/peso de osos Para el conjunto de datos 9, ubique las medidas del cuello en la escala horizontal y los pesos de los osos en la escala vertical. Con base en los resultados, ¿cuál es la relación existente entre el tamaño del cuello y el peso de los osos?

En los ejercicios 27 y 28, use los datos del Apéndice B para construir una gráfica de series de tiempo.

27. Inversiones en acciones Para el conjunto de datos 25, utilice los valores altos del Dow Jones Industrial Average (DJIA) para construir una gráfica de series de tiempo; después, determine si parece haber alguna tendencia. ¿Cómo podría un inversionista beneficiarse de esta tendencia?

28. Muertes en vehículos automotores En el conjunto de datos 25, utilice los datos de las muertes en vehículos automotores en Estados Unidos para construir una gráfica de series de tiempo; después, determine si parece haber alguna tendencia. Si es así, ofrezca una posible explicación.

En los ejercicios 29 a 32, remítase a la figura de la página 53, que describe la campaña de Napoleón de 1812 hacia Moscú y su retirada. La banda gruesa a la izquierda representa el tamaño del ejército cuando comenzó a invadir Rusia desde Polonia; la banda inferior describe la retirada de Napoleón.

29. Calcule el porcentaje de hombres que sobrevivieron toda la campaña.

30. Calcule el número de hombres y el porcentaje de hombres que murieron durante el cruce del río Berezina.

31. ¿Cuántos hombres murieron durante la retirada de Moscú, en el tiempo cuando la temperatura bajó de 16°F hasta −6°F?

32. De los hombres que lograron llegar a Moscú, ¿cuántos murieron en el viaje de regreso entre Moscú y Botr? (Observe que 33,000 hombres no fueron a Moscú, pero se unieron a los hombres que regresaban).

2-3 Más allá de lo básico

33. **a.** Remítase al conjunto de datos 20 del Apéndice B y elabore un histograma con las cargas axiales de las latas que tienen un grosor de 0.0111 pulgadas. El conjunto de datos incluye un dato distante de 504 lb. (Un dato distante es un valor que aparece muy lejos de los demás valores).

b. Repita el inciso *a*) después de excluir el dato distante de 504 lb.

c. ¿Qué efecto produce un dato distante en la forma del histograma?

34. Los Óscares En el artículo "Ages of Oscar-winning Best Actors and Actresses" (revista *Mathematics Teachers*), escrito por Richard Brown y Gretchen Davis, se utilizan gráficas de tallo y hojas para comparar las edades de los actores y las actrices en el momento que ganaron un Óscar. A continuación, se presentan los resultados de ganadores recientes, para cada categoría.

Actores: 32 37 36 32 51 53 33 61 35 45 55 39
76 37 42 40 32 60 38 56 48 48 40 43
62 43 42 44 41 56 39 46 31 47 45 60
46 40 36

Actrices: 50 44 35 80 26 28 41 21 61 38 49 33
74 30 33 41 31 35 41 42 37 26 34 34
35 26 61 60 34 24 30 37 31 27 39 34
26 25 33

a. Construya una gráfica de tallo y hojas, espalda con espalda, con los datos. Las primeras dos edades de cada grupo se insertaron al margen.

b. Utilice los resultados del inciso *a*), compare los dos conjuntos de datos y explique cualquier diferencia.

Edades de los actores (unidades)	Tallo (decenas)	Edades de las actrices (unidades)
	2	
72	3	
	4	4
	5	0
	6	
	7	
	8	

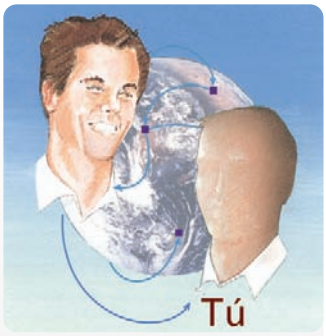
2-4 Medidas de tendencia central

Recuerde que el principal objetivo de este capítulo es lograr manejar las herramientas básicas para medir y describir diferentes características de un conjunto de datos. En la sección 2-1 observamos que, cuando describimos, exploramos y comparamos conjuntos de datos, las siguientes características suelen ser extremadamente importantes: centro, variación, distribución, datos distantes, cambios a través del tiempo. Las siglas CVDDT ("Cuidado con los Virus que Destruyen Datos y Trabajo") son útiles para recordar dichas características. En las secciones 2-2 y 2-3 señalamos que las distribuciones de frecuencias y las gráficas, así como los histogramas, sirven para investigar la distribución. En esta sección trataremos las características del *centro*.

Definición

Medida de tendencia central: valor que se encuentra en el centro o a la mitad de un conjunto de datos.

Hay muchas formas distintas de determinar el centro; por lo tanto, tenemos diferentes definiciones de las medidas de tendencia central, incluyendo media, mediana, moda y mitad del rango. Comenzaremos con la media.



Seis grados de separación

Los psicólogos sociales, historiadores, científicos políticos y especialistas en comunicaciones se interesan en el "problema del mundo pequeño": dadas dos personas cualesquiera en el mundo, ¿cuántos vínculos intermedios son necesarios para conectarlas? El psicólogo social Stanley Milgram realizó un experimento donde algunos sujetos intentaron ponerse en contacto con otras personas en específico, enviando por correo un archivo de información a un conocido que ellos pensaban estaba más cerca de la persona que buscaban. De las 160 cadenas de este tipo que se iniciaron, sólo 44 se completaron. El número de conocidos intermediarios varió de entre 2 y 10, con una mediana de 5 (o "seis grados de separación"). El experimento fue criticado por incluir sujetos muy sociales y por no hacer ajustes a las muchas conexiones perdidas de personas con ingresos más bajos. Otro estudio matemático mostró que si las cadenas perdidas se hubiesen completado, la mediana sería ligeramente mayor que 5.

Media

La media (aritmética) generalmente es la más importante de todas las medidas numéricas utilizadas para describir datos; constituye lo que la mayoría de la gente denomina *promedio*.

Definición

Media aritmética (de un conjunto de puntajes): medida de tendencia central que se obtiene sumando los puntajes y dividendo el total entre el número de puntajes. Tal medida de tendencia central se utilizará de manera frecuente a lo largo del libro; además, nos referiremos a ella simplemente como la **media**.

Esta definición se expresa como la fórmula 2-1, que utiliza la letra griega Σ (sigma mayúscula) para indicar que los valores de los datos deben sumarse. Esto es, Σx representa la sumatoria de todos los valores de los datos. El símbolo n denota el **tamaño de la muestra**, que es el número de puntajes en el conjunto de datos.

Fórmula 2-1

$$\text{media} = \frac{\Sigma x}{n}$$

La media se denota como $\bar{x}$ (se denomina "x barra"), si el conjunto de datos es una *muestra* de una población más grande; si se utilizan todos los puntajes de la población, entonces la media se simboliza con μ (mu minúscula). (Los estadísticos de una muestra generalmente se representan con letras inglesas, tales como $\bar{x}$, y los parámetros de la población con letras griegas, tales como μ).

Notación

Σ	denota la *sumatoria* de un conjunto de valores.
x	es la *variable* que suele utilizarse para representar los valores de datos individuales.
n	representa el *número de valores* de una *muestra*.
N	representa el *número de valores* de una *población*.
$\bar{x} = \frac{\Sigma x}{n}$	es la media de un conjunto de valores *muestrales*.
$\mu = \frac{\Sigma x}{N}$	es la media de todos los valores de una *población*.

EJEMPLO Verificación del plomo en el aire A continuación se presentan cantidades de plomo medidas (en microgramos por metro cúbico o $\mu g/m^3$) en el aire. La Environmental Protection Agency estableció un estándar de calidad del aire respecto del plomo: 1.5 $\mu g/m^3$. Las mediciones que se presentan más adelante se registraron en el edificio 5 del World Trade Center en distintos días, inmediatamente después de la destrucción causada por los ataques terroristas

del 11 de septiembre de 2001. Después del colapso de los dos edificios del World Trade Center, surgió una gran preocupación respecto de la calidad del aire. Calcule la media de esta muestra de niveles de plomo en el aire.

5.40 1.10 0.42 0.73 0.48 1.10

SOLUCIÓN La media se calcula empleando la fórmula 2-1. Primero se suman los puntajes y después se dividen entre el número de ellos:

$$\bar{x} = \frac{\Sigma x}{n} = \frac{5.40 + 1.10 + 0.42 + 0.73 + 0.48 + 1.10}{6} = \frac{9.23}{6} = 1.538$$

La media del nivel de plomo es 1.538 $\mu g/m^3$. Además del valor de la media, también es notable que el conjunto de datos incluye un valor (5.40), que está muy distante de los demás. Sería importante investigar un "dato distante" como éste. En tal caso, el nivel de plomo de 5.40 $\mu g/m^3$ se midió un día después del colapso de las torres del World Trade Center y los niveles de polvo y humo ofrecieron una explicación razonable para un valor tan extremo.

Una desventaja de la media es su sensibilidad a cada valor, de modo que un puntaje excepcional puede afectarla de manera drástica. La mediana resuelve, en gran parte, esa desventaja.

Mediana

Definición

Mediana (de un conjunto de datos): medida de tendencia central que implica el valor que está en medio, cuando los valores originales de los datos se presentan en orden de magnitud creciente (o decreciente). La mediana suele denotarse con $\tilde{x}$ (se pronuncia "x con tilde").

Para calcular la mediana, primero clasifique los valores (acomódelos en orden), luego siga uno de estos dos procedimientos:

1. Si el número de valores es impar, la mediana es el número que se localiza exactamente a la mitad de la lista.
2. Si el número de valores es par, la mediana se obtiene calculando la media de los dos números que están a la mitad.

La figura 2-10 demuestra este procedimiento para el cálculo de la mediana.

EJEMPLO Verificación del plomo en el aire A continuación se presentan cantidades de plomo medidas (en $\mu g/m^3$) en el aire. Calcule la mediana de esta muestra.

5.40 1.10 0.42 0.73 0.48 1.10

SOLUCIÓN Primero ordene los valores:

0.42 0.48 0.73 1.10 1.10 5.40

continúa



Paradoja del tamaño del grupo escolar

Hay al menos dos formas de obtener la media de un grupo escolar, y pueden dar resultados muy distintos. En una universidad, si consideramos las cantidades de estudiantes en 737 grupos, obtenemos una media de 40 estudiantes. Pero si compilamos una lista de los tamaños de grupo para cada estudiante y utilizamos dicha lista, obtendríamos una media de grupo de 147. Esta gran discrepancia es por el hecho de que hay muchos estudiantes en los grupos grandes, mientras que en los grupos pequeños hay muy pocos. Sin modificar el número de grupos ni de profesores, reduciríamos el tamaño medio del grupo escolar que los estudiantes experimentan, haciendo que todos los grupos tengan aproximadamente el mismo tamaño. Lo anterior también incrementaría la asistencia, que es mayor en los grupos escolares pequeños.

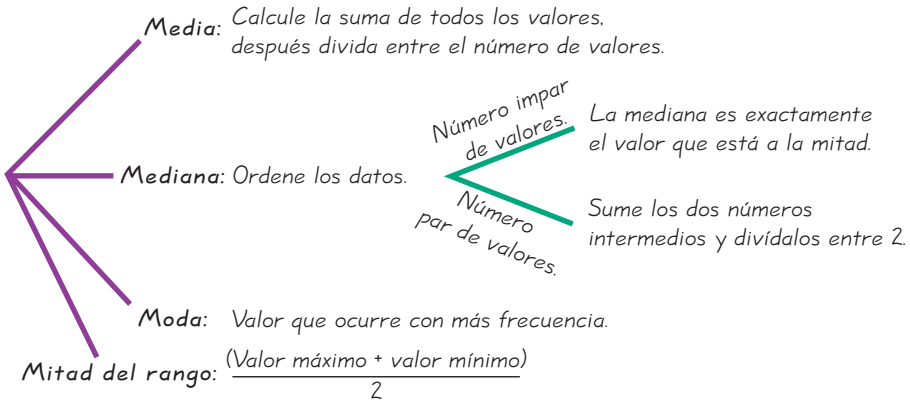


FIGURA 2-10 **Procedimientos para calcular las medidas de tendencia central**

Puesto que el número de valores es par (6), la mediana se obtiene calculando la media de los dos valores intermedios 0.73 y 1.10.

$$\text{Mediana} = \frac{0.73 + 1.10}{2} = \frac{1.83}{2} = 0.915$$

Como el número de valores es par (6), la mediana es el número que se encuentra exactamente a la mitad de la lista ordenada; por lo tanto, la mediana es 0.915 $\mu g/m^3$. Note que la mediana es muy diferente de la media de 1.538 $\mu g/m^3$, que se obtuvo del mismo conjunto de datos muestrales del ejemplo anterior. La razón de esa gran discrepancia es el efecto que el puntaje 5.40 tuvo en la media. Si este valor extremo se redujera a 1.20, la media caería de 1.538 $\mu g/m^3$ hasta 0.838 $\mu g/m^3$, pero la mediana no cambiaría.

EJEMPLO Verificación del plomo en el aire Repita el ejemplo anterior, después de incluir la medición de 0.66 $\mu g/m^3$, que se registró otro día. Es decir, calcule la mediana de estas mediciones del plomo:

5.40 1.10 0.42 0.73 0.48 1.10 0.66

SOLUCIÓN Primero ordene los valores

0.42 0.48 0.66 0.73 1.10 1.10 5.40

Puesto que el número de valores es impar (7), la mediana es exactamente el valor a la mitad de la lista ordenada: 0.73 $\mu g/m^3$.

Después de estudiar los ejemplos anteriores, debe quedar claro el procedimiento para obtener la mediana; además, que la media se ve afectada de manera drástica por valores extremos, mientras que la mediana no. Puesto que la mediana no es tan sensible a los valores extremos, con frecuencia se utiliza para conjuntos de datos que tienen un número relativamente pequeño de datos distantes. Por ejemplo, recientemente la oficina de censos de Estados Unidos reportó que la *mediana* del ingreso familiar es de 36,078 dólares anuales. Se usó la mediana ya que existen pocas familias con ingresos realmente altos.

Moda

Definiciones

Moda (de un conjunto de datos, que suele denotarse como *M*): valor que ocurre con mayor frecuencia.

- Cuando dos valores ocurren con la misma frecuencia y ésta es la más alta, ambos valores son modas, por lo que el conjunto de datos es **bimodal.**
- Cuando más de dos valores ocurren con la misma frecuencia y ésta es la más alta, todos los valores son modas, por lo que el conjunto de datos es **multimodal.**
- Cuando ningún valor se repite, se dice que no hay moda.

EJEMPLO Calcule las modas de los siguientes conjuntos de datos.

a. 5.40 1.10 0.42 0.73 0.48 1.10

b. 27 27 27 55 55 55 88 88 99

c. 1 2 3 6 7 8 9 10

SOLUCIÓN

a. El número 1.10 es la moda, ya que es el valor que ocurre con mayor frecuencia.

b. Los números 27 y 55 son modas, ya que ambos ocurren con la frecuencia más alta. Este conjunto de datos es bimodal, porque tiene dos modas.

c. No hay moda, ya que ningún valor se repite.

En realidad, la moda no se utiliza mucho con datos numéricos. Sin embargo, entre las distintas medidas de tendencia central que consideramos, la moda es la única que puede usarse con datos de nivel nominal de medición. (Recuerde que el nivel nominal de medición se aplica a datos que consisten únicamente en nombres, etiquetas o categorías). Por ejemplo, una encuesta que se aplicó a estudiantes universitarios mostró que el 84% tiene aparato de televisión; el 76%, videocasetera; el 60%, reproductor de discos compactos portátil; el 39%, sistema de videojuegos y el 35%, reproductor de DVD (con base en datos del National Center for Education Statistics). En tanto que el televisor es el aparato más frecuente, es posible afirmar que la moda es el televisor. No podemos calcular una media o mediana para datos como éstos, a nivel nominal.



Un hombre promedio

La revista *Men's Health* publicó estadísticas que describen al "hombre promedio", que tiene 34.4 años de edad, pesa 175 libras, mide cerca de 5 pies 10 pulgadas y se llama Mike Smith. La edad, el peso y la estatura son valores medios, pero el nombre de Mike Smith es la moda que corresponde al nombre y apellido más comunes. Otra estadística notable es la siguiente: el hombre promedio duerme aproximadamente 6.9 horas por noche, bebe cerca de 3.3 tasas de café al día y consume 1.2 bebidas alcohólicas diariamente; además, gana alrededor de 36,100 dólares anuales, debe 2,563 dólares en las tarjetas de crédito y tiene 3,100 dólares ahorrados en el banco.

Mitad del rango

Definición

Mitad del rango: medida de tendencia central que constituye el valor que está a medio camino, entre el puntaje más alto y el más bajo, en el conjunto original de datos. Se calcula sumando el valor máximo con el mínimo y luego dividiendo dicha suma entre 2, como en la siguiente fórmula.

$$\text{mitad del rango} = \frac{(\text{valor máximo} + \text{valor mínimo})}{2}$$



Maniquís ≠ realidad

La revista *Health* comparó las medidas de los maniquís con las medidas de las mujeres. Los siguientes resultados se reportaron como "promedios", que tal vez representan medias. Estatura de los maniquíes: 6 pies; estatura de las mujeres: 5 pies 4 pulgadas. Cintura de los maniquíes: 23 pulgadas; cintura de las mujeres: 29 pulgadas. Tamaño de la cadera de los maniquíes: 34 pulgadas; tamaño de la cadera de las mujeres: 40 pulgadas. Talla de vestido de los maniquíes: 6; talla de vestido de las mujeres: 11. Cuando se comparan las medias es evidente que los maniquíes y las mujeres reales son muy diferentes.

La mitad del rango se utiliza en pocas ocasiones. Puesto que sólo utiliza los valores máximo y mínimo es demasiado sensible a dichos extremos. Sin embargo, la mitad del rango posee tres características positivas: **1.** es fácil de calcular; **2.** ayuda a reforzar el hecho importante de que existen diferentes formas para definir el centro de un conjunto de datos; **3.** en ocasiones se utiliza de manera incorrecta como si fuese la mediana, de manera que es posible disminuir la confusión al definir con claridad la mitad del rango con respecto a la mediana.

EJEMPLO Verificación del plomo en el aire A continuación se presentan medidas de las cantidades de plomo ($\mu g/m^3$) en el aire, en el lugar donde estaba el World Trade Center, días después del 11 de septiembre del 2001. Calcule la mitad del rango para esta muestra:

5.40 1.10 0.42 0.73 0.48 1.10

SOLUCIÓN La mitad del rango se calcula de la siguiente manera:

$$\frac{(\text{valor máximo} + \text{valor mínimo})}{2} = \frac{(5.40 + 0.42)}{2} = 2.910$$

La mitad del rango es 2.910 $\mu g/m^3$.

Desafortunadamente, el término *promedio* en ocasiones se utiliza para cualquier medida de tendencia central y, en ocasiones, para implicar la media. Por esta ambigüedad, no debemos usar el término *promedio* cuando nos referimos a una medida de tendencia central en particular. En su lugar, habrá que aplicar el término específico, tal como media, mediana, moda o mitad del rango. Cuando nos encontremos un valor reportado como *promedio*, tendremos que saber que el valor puede ser el resultado de cualquiera de las distintas definiciones.

Con la idea de describir, explorar y comparar datos, incluimos la tabla 2-8, que resume las distintas medidas de tendencia central para los niveles de cotinina que se presentan en la tabla 2-1, en el problema del capítulo. Recuerde que la cotinina es un metabolito de la nicotina, de modo que cuando el cuerpo absorbe la nicotina se produce la cotinina. Una comparación de las medidas de tendencia central sugiere que los niveles de cotinina son más altos en los fumadores. Además, los niveles de cotinina de los individuos que no fuman, pero están expuestos al humo del tabaco, son más altos que los de personas que tampoco fuman y no están expuestas al humo. Lo anterior sugiere que "los fumadores pasivos" sí se ven afectados. Se

Tabla 2-8 Comparación de los niveles de cotinina de fumadores, de no fumadores expuestos al humo ambiental del tabaco (HAT) y de no fumadores no expuestos al humo ambiental del tabaco (SHAT).

	Fumadores	HAT	SHAT
Media	172.5	60.6	16.4
Mediana	170.0	1.5	0.0
Moda	1 y 173	1	0
Mitad del rango	245.5	275.5	154.5

dispone de métodos para determinar si estas aparentes diferencias son estadísticamente significativas. Más adelante, consideraremos algunos de estos métodos.

Regla de redondeo

Una regla sencilla para redondear respuestas es la siguiente:

Aumente una posición decimal más a las que están presentes en el conjunto original de datos.

Cuando aplique esta regla, redondee sólo la respuesta final y *no los valores intermedios que aparecen durante los cálculos*. Así, la media de 2, 3, 5, es 3.333333 . . . , que se redondea a 3.3. Como los valores originales son números enteros, redondeamos al décimo más cercano. Otro ejemplo sería la media de 80.4 y 80.6, que es igual a 80.50 (una posición decimal más de la que se empleó para los valores originales).

Media de una distribución de frecuencias

Cuando los datos se resumen en una distribución de frecuencias es probable que no conozcamos los valores exactos de una clase en particular. Para hacer que los cálculos sean posibles, pretendemos que todos los valores muestrales sean iguales a la marca de clase. Ya que cada marca de clase se repite un número de veces igual a la frecuencia de clase, la sumatoria de todos los valores muestrales es $\Sigma(f \cdot x)$, donde f denota la frecuencia y x representa la marca de clase. El número total de valores muestrales es la sumatoria de frecuencias Σf. La fórmula 2-2 se utiliza para calcular la media cuando los datos muestrales se resumen en una distribución de frecuencias. La fórmula 2-2 en realidad no es un concepto nuevo, sino una variación de la fórmula 2-1.

Primero multiplique cada frecuencia y marca de clase, después sume los productos

Fórmula 2-2

$$\bar{x} = \frac{\Sigma(f \cdot x)}{\Sigma f}$$

(media de la distribución de frecuencias)

sumatoria de las frecuencias

Por ejemplo, observe la tabla 2-9 en la siguiente página. Las primeras dos columnas son iguales a la distribución de frecuencias (tabla 2-2) de los niveles de cotinina de fumadores. La tabla 2-9 ilustra el procedimiento que se sigue para aplicar la fórmula 2-2 cuando se calcula la media de datos resumidos en una distribución de frecuencias. En realidad, por lo general se utilizan programas de cómputo o calculadoras, en lugar del cálculo manual. El resultado de la tabla 2-9 es $\bar{x} = 177.0$, aunque obtenemos $\bar{x} = 172.5$ si utilizamos la lista original con 40 valores. Recuerde, la distribución de frecuencias produce una aproximación de $\bar{x}$, ya que no se basa en la lista original exacta de valores muestrales.



Nadie en casa

Los encuestadores no pueden ignorar simplemente a quienes no estaban en casa cuando acudieron por primera vez. Una solución implica regresar varias veces hasta localizar a la persona. Alfred Politz y Willard Simmons describen una forma para compensar los resultados faltantes, sin tener que regresar varias veces. Sugieren ponderar los resultados con base en la frecuencia en que la gente no se encuentra en su casa. Por ejemplo, alguien que está en su casa sólo dos, de seis días a la semana, tendrá una probabilidad de 2/6 o 1/3 de estar allí en la primera visita. Cuando se localiza a dicha persona por primera vez, sus resultados se ponderan de modo que se cuenten tres veces, respecto de un sujeto que siempre está en su casa. Esta ponderación compensa a los demás individuos similares que permanecen en casa dos de seis días a la semana y que no respondieron cuando se les buscó por primera vez. Tan inteligente solución se presentó inicialmente en 1949.

Tabla 2-9 Cálculo de la media de una distribución de frecuencias

Nivel de cotinina	Frecuencia f	Marca de clase x	$f \cdot x$
0–99	11	49.5	544.5
100–199	12	149.5	1794.0
200–299	14	249.5	3493.0
300–399	1	349.5	349.5
400–499	2	449.5	899.0
Totales:	$\Sigma f = 40$		$\Sigma(f \cdot x) = 7080.0$

$$\bar{x} = \frac{\Sigma(f \cdot x)}{\Sigma f} = \frac{7080}{40} = 177.0$$

Media ponderada

En algunos casos los valores varían su grado de importancia, de modo que es posible que queramos acomodarlos de acuerdo con ello. Después, será posible proceder al cálculo de una **media ponderada**, que es una media que se obtiene asignando distintos pesos a los valores, tal como se muestra en la fórmula 2-3.

Fórmula 2-3 media ponderada: $\bar{x} = \dfrac{\Sigma(w \cdot x)}{\Sigma w}$

Por ejemplo, suponga que necesitamos una media de tres calificaciones de una prueba (85, 90, 75), donde la primera prueba cuenta el 20%, la segunda el 30% y la tercera el 50% de la calificación final. Podemos asignar pesos de 20, 30 y 50 a las calificaciones de la prueba y luego calcular la media aplicando la fórmula 2-3, como sigue:

$$\bar{x} = \frac{\Sigma(w \cdot x)}{\Sigma w}$$
$$= \frac{(20 \times 85) + (30 \times 90) + (50 \times 75)}{20 + 30 + 50} = \frac{8150}{100} = 81.5$$

Otro ejemplo son los promedios universitarios (que utilizan letras), que pueden calcularse si asignamos a cada calificación con letras el número adecuado de puntos (A = 4, B = 3, etcétera), y después asignamos a cada puntaje un peso igual al número de horas crédito. Nuevamente, se utiliza la fórmula 2-3 para calcular el promedio de calificaciones.

La mejor medida de tendencia central

Hasta ahora hemos considerado la media, mediana, moda y mitad del rango como medidas de tendencia central. ¿Cuál de ellas es la mejor? Desafortunadamente, no existe una respuesta única a esa pregunta, porque no hay criterios objetivos para determinar la medida más representativa para todos los conjuntos de datos. Las diferentes medidas de tendencia central ofrecen diversas ventajas y desventajas, algunas de las cuales se resumen en la tabla 2-10.

Tabla 2-10 Comparación de la media, mediana, moda y mitad del rango

Medida de tendencia central	Definición	¿Qué tan común es?	Existencia	¿Toma en cuenta cada valor?	¿Se ve afectada por valores extremos?	Ventajas y desventajas
Media	$\bar{x} = \frac{\Sigma x}{n}$	"promedio" más conocido	siempre existe	sí	sí	se usa a lo largo de este libro; funciona bien con muchos métodos estadísticos
Mediana	valor en medio	de uso común	siempre existe	no	no	suele ser una buena opción si hay algunos valores extremos
Moda	valor más frecuente	se usa en ocasiones	podría no existir; podría haber más de una	no	no	apropiada para datos en el nivel nominal
Mitad del rango	$\frac{(\text{máx} + \text{mín})}{2}$	poco usada	siempre existe	no	sí	muy sensible a los valores extremos

Comentarios generales:
- En el caso de una colección de datos que es aproximadamente simétrica con una moda, la media, la mediana, la moda y la mitad del rango tienden a ser iguales.
- En el caso de una colección de datos obviamente asimétrica, sería bueno reportar tanto la media como la mediana.
- La media es relativamente *confiable*. Es decir, cuando las muestras se extraen de la misma población, las medidas muestrales tienden a ser más consistentes que las demás medidas de tendencia central (consistentes en el sentido de que las medias muestrales, extraídas de la misma población, no varían tanto como las otras medidas de tendencia central).

Una ventaja importante de la media es que toma en cuenta cada valor; una desventaja notoria es que en ocasiones se ve afectada de manera drástica por unos cuantos valores extremos. Tal desventaja se supera usando una media recortada, como se describe en el ejercicio 21.

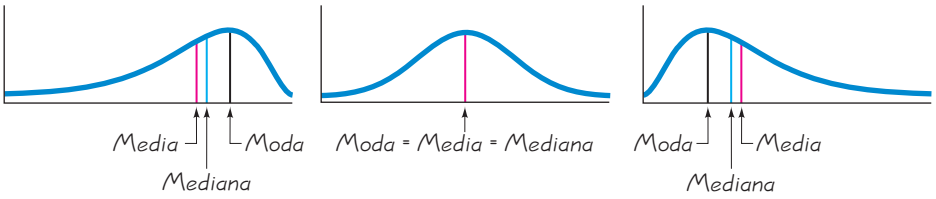
Sesgo

Una comparación de la media, la mediana y la moda puede revelar información acerca de la característica de sesgo, que se define a continuación y se ilustra en la figura 2-11.

Definición

Una distribución de datos está **sesgada** si no es simétrica y se extiende más hacia un lado que hacia el otro. (Una distribución de datos es **simétrica** si la mitad izquierda de su histograma es aproximadamente una imagen en espejo de su mitad derecha).

FIGURA 2-11 Sesgo



(a) Sesgada a la izquierda (sesgo negativo): la media y la mediana están a la izquierda de la moda.

(b) Simétrica (sesgo cero): la media, la mediana y la moda son iguales.

(c) Sesgada a la derecha (sesgo positivo): la media y la mediana están a la derecha de la moda.

Los datos **sesgados a la izquierda** (que también se denomina como *sesgo negativo*) poseen una cola izquierda más larga, en tanto que la media y la mediana se encuentran a la izquierda de la moda. Aunque no siempre es posible predecirlo, los datos sesgados a la izquierda suelen tener una media menor a la mediana, como sucede en la figura 2-11*a*). Los datos **sesgados a la derecha** (lo que también se denomina *sesgo positivo*) poseen una cola derecha más larga, mientras que la media y la mediana se encuentran a la derecha de la moda. Nuevamente, aunque no siempre es posible predecirlo, en los datos sesgados a la derecha, la media suele estar a la derecha de la mediana, como en la figura 2-11c).

Si examinamos el histograma de la figura 2-1, para los niveles de cotinina de fumadores, observaremos una gráfica sesgada hacia la derecha. En la práctica, muchas distribuciones de datos son simétricas y carecen de sesgo. Las distribuciones sesgadas hacia la derecha son más comunes que aquéllas sesgadas hacia la izquierda, porque con frecuencia es más fácil obtener valores excepcionalmente grandes que valores excepcionalmente pequeños. En el caso de los ingresos anuales, por ejemplo, es imposible obtener valores por debajo del límite inferior de cero, pero hay algunas personas que ganan millones de dólares en un año. Por lo tanto, los ingresos anuales tienden a estar sesgados hacia la derecha, como en la figura 2-11*c*).



Utilizando la tecnología

Los cálculos en esta sección son bastante sencillos, pero algunos de la siguiente sección requieren mayor esfuerzo. Muchos programas de cómputo le permiten introducir un conjunto de datos y utilizar una operación para obtener diversos estadísticos para muestras, que se engloban en la *estadística descriptiva*. (Véase la sección 2-6, donde se incluyen representaciones visuales de muestras que se obtienen con el STATDISK, Minitab, Excel y la calculadora TI-83 Plus.) A continuación, se incluyen algunos de los procedimientos para la obtención de dichas representaciones visuales.

STATDISK Elija **Data** del menú principal y utilice el **Sample Editor** para ingresar los datos. Presione **Copy** y luego presione **Data** nuevamente, pero ahora elija la opción **Descriptive Statistics**. Haga clic en **Paste,** para recuperar el conjunto de datos que usted alimentó. Ahora haga clic en **Evaluate** para obtener los estadísticos descriptivos, incluyendo la media, la mediana, la mitad del rango y otros que se discutirán en las próximas secciones.

Minitab Ingrese los datos en la columna que tiene el encabezado C1. Haga clic en **Stat**, seleccione **Basic Statistics** y luego **Descriptive Statistics.** Los resultados incluirán la media y la mediana, así como otros estadísticos.

Excel Ingrese los datos de la muestra en la columna A. Seleccione **Tools**, después **Data Analysis** y luego **Descriptive Statistics**; haga clic en **OK**. En el cuadro de diálogo, ingrese el rango de entrada de datos (tal como A1:A40 para 40 valores en la columna A), haga clic en **Summary Statistics** y después haga clic en **OK**. (Si Data Analysis no aparece en el menú Tools, deberá instalarlo haciendo clic en **Tools** y seleccionando **Add-Ins.**)

TI-83 Plus Primero ingrese los datos en la lista L1, presionando **STAT**, luego **Edit** y finalmente la tecla **ENTER**. Una vez que ingresó los datos, presione **STAT** y seleccione **CALC**, después **1-Var Stats** y finalmente **ENTER** dos veces. La representación visual incluirá la media, la mediana, el valor mínimo y el valor máximo. Utilice la flecha que va hacia abajo para ver los resultados que no aparecen en la primera representación visual.

2-4 Destrezas y conceptos básicos

En los ejercicios 1 a 8 calcule a) la media, b) la mediana, c) la moda y d) la mitad del rango, de los datos muestrales dados.

1. Consumo de tabaco en películas infantiles En el artículo "Tobacco and Alcohol Use in G-Rated Children's Animated Films", de Goldstein, Sobel y Newman (*Journal of the American Medical Association*, vol. 281, núm. 12), se registró la duración (en segundos) de escenas de películas animadas, de los Universal Studios, que muestran consumo de tabaco. A continuación se presentan los primeros seis valores, que están incluidos en el conjunto de datos 7 del Apéndice B. ¿Hay algún problema al incluir escenas de consumo de tabaco en películas infantiles de dibujos animados?

0 223 0 176 0 548

2. Harry Potter En un intento por medir el nivel de lectura de un libro, se obtuvieron los puntajes de la facilidad de lectura de Flesch Reading de 12 páginas, seleccionadas aleatoriamente, de la obra *Harry Potter y la piedra filosofal*, de J. K. Rowling. Dichos puntajes, que se incluyen en el conjunto de datos 14 del Apéndice B, se listan a continuación. En tanto que estos puntajes se basan en 12 páginas seleccionadas aleatoriamente, ¿será la media de esta muestra un estimado razonable del nivel medio de lectura de todo libro?

85.3 84.3 79.5 82.5 80.2 84.6
79.2 70.9 78.6 86.2 74.0 83.7

3. Cereal Un nutriólogo obtiene las cantidades de azúcar (en gramos) de un gramo de 16 cereales diferentes, incluyendo Cheerios, Corn Flakes, Fruit Loops, Trix y 12 más. Estos valores, que se incluyen en el conjunto de datos 16 del Apéndice B, se listan a continuación. ¿Será la media de estos valores un buen estimado de la cantidad media de azúcar que hay en cada gramo del cereal consumido por la población de todos los estadounidenses que lo comen? ¿Por qué?

0.03 0.24 0.30 0.47 0.43 0.07 0.47 0.13
0.44 0.39 0.48 0.17 0.13 0.09 0.45 0.43

4. Índice de masa corporal Como parte del examen nacional de salud (National Health Examination) en Estados Unidos, se mide el índice de masa corporal en una muestra aleatoria de mujeres. Algunos de los valores, que se incluyen en el conjunto de datos 1 del Apéndice B, se listan a continuación. ¿Estará la media de tal muestra razonablemente cerca de la media de 25.74, que es la media de las 40 mujeres incluidas en el conjunto de datos 1?

19.6 23.8 19.6 29.1 25.2 21.4 22.0 27.5
33.5 20.6 29.9 17.7 24.0 28.9 37.7

5. Conductores alcoholizados Más adelante se incluyen las concentraciones de alcohol en la sangre de conductores que se vieron envueltos en accidentes fatales y que después fueron sentenciados a prisión (con base en datos del Departamento de Justicia de Estados Unidos). Si las leyes estatales actuales prohíben conducir con niveles por encima de 0.08 o 0.10, ¿están estos niveles significativamente por arriba del máximo permitido?

0.27 0.17 0.17 0.16 0.13 0.24 0.29 0.24
0.14 0.16 0.12 0.16 0.21 0.17 0.18

6. Muertes en motocicletas A continuación se presentan las edades de motociclistas que se accidentaron mortalmente en accidentes de tránsito (con base en datos del Departamento del Transporte estadounidense). ¿Apoyan los resultados la creencia común de que una mayor proporción de conductores jóvenes se ven implicados en tales accidentes?

17 38 27 14 18 34 16 42 28
24 40 20 23 31 37 21 30 25

7. Tiempos de reacción El autor visitó el Museo de Ciencias Reuben H. Fleet en San Diego y repitió un experimento de tiempos de reacción. Se obtuvieron los siguientes tiempos (en centésimas de segundo). ¿Qué tan consistentes son estos resultados y de qué forma afecta la consistencia el uso de la media muestral, como un estimado de la media poblacional?

19	20	17	21	21	21	19	18	19	19
17	17	15	17	18	17	18	18	18	17

8. Tabletas de Bufferin A continuación se listan los pesos medidos (en miligramos) de una muestra de tabletas de aspirina Bufferin. ¿Cuál sería la consecuencia grave de tener pesos que varían tanto?

672.2	679.2	669.8	672.6	672.2	662.2
662.7	661.3	654.2	667.4	667.0	670.7

En los ejercicios 9 a 12 calcule media, mediana, moda y mitad del rango para cada una de las dos muestras; luego, compare los dos conjuntos de resultados.

9. Tiempos de espera de clientes A continuación se presentan los tiempos de espera (en minutos) de los clientes del Banco Jefferson Valley (donde todos los clientes forman una sola fila) y del Banco Providence (donde los clientes esperan en filas individuales, en tres ventanillas diferentes):

Jefferson Valley:	6.5	6.6	6.7	6.8	7.1	7.3	7.4	7.7	7.7	7.7
Providence:	4.2	5.4	5.8	6.2	6.7	7.7	7.7	8.5	9.3	10.0

Interprete los resultados y determine si hay una diferencia entre los dos conjuntos de datos, que no sea aparente cuando se comparen las medidas de tendencia central. Si es así, ¿cuál es?

10. Coca Cola regular/Coca Cola dietética Los siguientes son los pesos (en libras) de muestras del contenido de latas de Coca Cola regular y Coca Cola dietética:

Regular:	0.8192	0.8150	0.8163	0.8211	0.8181	0.8247
De dieta:	0.7773	0.7758	0.7896	0.7868	0.7844	0.7861

¿Parece haber una diferencia significativa entre los dos conjuntos de datos? ¿Cómo se explicaría una diferencia como ésa?

11. Mickey D *vs.* Jack Al investigar los tiempos que se requieren en el servicio en automóvil (en segundos), se obtuvieron los siguientes resultados (con base en datos del QSR Drive-Thru Time Study).

McDonald's:	287	128	92	267	176	240	192	118	153	254	193	136
Jack in the Box:	190	229	74	377	300	481	428	255	328	270	109	109

¿Cuál de los dos gigantes de comida rápida parece ser más veloz? ¿La diferencia parece ser significativa?

12. Anchura de cráneos Las anchuras máximas de muestras de cráneos egipcios de varones, que datan del 4000 a.C. y del 150 d.C. (de acuerdo con los datos de *Ancient Races of the Thebaid*, de Thomson y Randall-Maciver) se muestran a continuación:

4000 a.C.:	131	119	138	125	129	126	131	132	126	128	128	131
150 d.C.:	136	130	126	126	139	141	137	138	133	131	134	129

Los cambios del tamaño de las cabezas a través del tiempo sugieren la mezcla con personas de otras regiones. ¿Parece haber cambiado el tamaño de las cabezas del 4000 a.C. al 150 d.C.?

En los ejercicios 13 a 16, remítase a los conjuntos de datos del Apéndice B. Utilice un programa de cómputo o una calculadora para obtener las medias y las medianas, luego compare los resultados, tal como se indica.

13. Circunferencia de cabezas Para diagnosticar de forma correcta la hidrocefalia, un pediatra investiga la circunferencia de las cabezas de niños y niñas de dos años de edad. Utilice los resultados muestrales listados en el conjunto de datos 3. ¿Parece haber alguna diferencia entre los dos géneros?

14. Clancy, Rowling, Tolstoi Un psicólogo infantil investiga las diferencias en cuanto a la facilidad de la lectura; obtiene datos de *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones de la calificación de Flesch-Kincaid de las 12 páginas seleccionadas aleatoriamente, para cada uno de los tres libros. ¿Los datos parecen ser diferentes?

15. Lluvia en el fin de semana Utilice el conjunto de datos 11 del Apéndice B para calcular la media y la mediana de las cantidades de lluvia que caen en Boston los jueves; calcule también, la media y la mediana de las cantidades de lluvia que caen en Boston los domingos. Los reportes de los medios de comunicación afirmaron que llueve más durante los fines de semana que entre semana. ¿Estos resultados apoyan dicha afirmación?

16. Consumo de tabaco/alcohol en películas infantiles En el artículo "Tobacco and Alcohol Use in G-Rated Children's Animated Films", de Goldstein, Sobel y Newman (*Journal of the American Medical Association*, vol. 281, núm. 12), se registraron las duraciones (en segundos) de escenas que muestran consumo de tabaco y alcohol en películas infantiles de dibujos animados. Remítase al conjunto de datos del Apéndice B, luego calcule la media y la mediana de las duraciones de escenas con tabaco así como la media y la mediana de las escenas con alcohol. ¿Parece haber una diferencia entre tales duraciones? ¿Cuál parece ser el problema mayor: las escenas que presentan consumo de tabaco o aquellas que muestran consumo de alcohol?

En los ejercicios 17 a 20 calcule la media de los datos que se resumen en la distribución de frecuencias dada.

17. Old Faithful Los visitantes del Parque Nacional Yellowstone consideran que una erupción del géiser Old Faithful es una gran atracción que uno no debe perderse. La distribución de frecuencias dada resume una muestra de los tiempos (en minutos) entre las erupciones.

Tabla del ejercicio 17

Tiempo	Frecuencia
40–49	8
50–59	44
60–69	23
70–79	6
80–89	107
90–99	11
100–109	1

18. Dado cargado El autor taladró un hoyo en un dado y lo relleno con plomo, después procedió a lanzarlo 200 veces. Los resultados se presentan en la distribución de frecuencias al margen. ¿El resultado parece ser muy diferente del resultado esperado con un dado inalterado?

Tabla del ejercicio 18

Resultado	Frecuencia
1	27
2	31
3	42
4	40
5	28
6	32

19. Infracciones de tránsito La distribución de frecuencias describe las velocidades de conductores infraccionados por la policía en la ciudad de Poughkeepsie. Los conductores viajaban por una zona con límite de velocidad de 30 millas/hora en Creek Road, que pasa por la universidad del autor. ¿Cómo se compara la media con el límite de velocidad de 30 mi/h?

Tabla del ejercicio 19

Velocidad	Frecuencia
42–45	25
46–49	14
50–53	7
54–57	3
58–61	1

20. Temperaturas corporales La distribución de frecuencias al margen resume una muestra de temperaturas corporales humanas. (Véanse las temperaturas de medianoche del segundo día, listadas en el conjunto de datos 4 del Apéndice B.) ¿Cómo se compara la media con el valor de 98.6°F, que es el valor que la mayoría de la gente supone como la media?

Tabla del ejercicio 20

Temperatura	Frecuencia
96.5–96.8	1
96.9–97.2	8
97.3–97.6	14
97.7–98.0	22
98.1–98.4	19
98.5–98.8	32
98.9–99.2	6
99.3–99.6	4

2-4 Más allá de lo básico

21. Media recortada Ya que la media es muy sensible a los valores extremos, decimos que no es una medida de tendencia central *resistente*. La **media recortada** es más

resistente. Para calcular la media recortada del 10% de un conjunto de datos, primero se acomodan los datos en orden, después se elimina el 10% de los valores inferiores y el 10% de los valores superiores; finalmente, se calcula la media de los valores restantes. Para los pesos de los osos, en el conjunto de datos 9 del Apéndice B, calcule *a*) la media; *b*) la media recortada del 10%; *c*) la media recortada del 20%. ¿Cómo se comparan los resultados?

22. Media de medias Con el uso de un almanaque, un investigador obtiene la media del salario de maestros de cada estado de Estados Unidos. Suma los 50 valores y luego los divide entre 50 para obtener la media. ¿Será el resultado igual a la media nacional del salario de maestros? ¿Por qué?

23. Grados de libertad Diez valores tienen una media de 75.0. Nueve de los valores son 62, 78, 90, 87, 56, 92, 70, 70 y 93.

a. Calcule el décimo valor.

b. Necesitamos crear una lista de n valores que contenga una media específica conocida. Tenemos la libertad de seleccionar cualesquiera valores que deseemos para algunos de los n valores. ¿Cuántos de los n valores pueden asignarse libremente antes de determinar los valores restantes?

24. Datos censurados Se realizó un experimento para probar la vida de baterías de automóviles. El experimento se llevó a cabo durante un tiempo fijo de cinco años. (Se dice que la prueba se *censura* a los cinco años.) Los resultados muestrales (en años) son 2.5, 3.4, 1.2, 5+, 5+ (donde 5+ indica que la batería aún funcionaba al final del experimento). ¿Qué se concluye acerca de la vida media de las baterías?

25. Media ponderada Kelly Bell obtiene calificaciones parciales de 65, 83, 80 y 90. En el examen final recibe una calificación de 92. Calcule la media ponderada, si cada uno de los exámenes parciales cuenta el 15% y el examen final cuenta el 40% de la calificación total.

26. Datos transformados En cada uno de los siguientes casos, describa cómo se ven afectadas la media, la mediana, la moda y la mitad del rango.

a. La misma constante k se suma a cada valor del conjunto de datos.

b. Cada valor del conjunto de datos se multiplica por la misma constante k.

27. La **media armónica** se utiliza a menudo como una medida de tendencia central para conjuntos de datos que consisten en tasas de cambios, como la velocidad. Para calcularla, se divide el número de valores n entre la suma de los *recíprocos* de todos los valores, de la siguiente forma:

$$\frac{n}{\sum \frac{1}{x}}$$

(Ningún valor puede ser cero). Cuatro estudiantes conducen desde Nueva York hasta Florida (1,200 millas), a una velocidad de 40 mi/h (¡sí, como no!). Como necesitan llegar a su clase de estadística a tiempo, viajan de regreso a una velocidad de 60 mi/h. ¿Cuál es la velocidad promedio del viaje completo? (La media armónica se utiliza para promediar velocidades).

28. La **media geométrica** suele utilizarse en negocios y economía para calcular las tasas de cambio promedio, las tasas de crecimiento promedio o tasas promedio. Dados n valores (todos positivos), la media geométrica es la n-ésima raíz de su producto. El *factor de crecimiento promedio* de dinero compuesto con tasas de interés anual del 10%, el 8%, el 9%, el 12% y el 7% se obtiene determinando la media geométrica de 1.10, 1.08, 1.09, 1.12 y 1.07. Calcule el factor de crecimiento promedio.

29. La **media cuadrática** (o **cuadrado medio de raíz**, o **CMR**) suele utilizarse en aplicaciones físicas. Por ejemplo, en los sistemas de distribución de energía, los montajes y

las corrientes suelen referirse en términos de sus valores de CMR. La media cuadrática de un conjunto de valores se obtiene elevando al cuadrado cada valor, sumando los resultados, dividiendo el número de valores n y después sacando la raíz cuadrada del resultado, el cual se expresa como

$$\text{media cuadrática} = \sqrt{\frac{\Sigma x^2}{n}}$$

Calcule el CMR de estas fuentes de poder (en volts): 110, 0, −60, 12.

30. Mediana Cuando los datos se resumen en una distribución de frecuencias, la mediana puede calcularse si primero se identifica la *clase de la mediana* (la clase que contiene a la mediana). Entonces, suponemos que los valores en esa clase se distribuyen uniformemente y podemos interpolar. Este proceso se describe de la siguiente forma:

$$\begin{array}{c}\text{(límite inferior de clase de la mediana)} \\ + \text{ (anchura de clase)}\end{array}\left(\frac{\left(\frac{n+1}{2}\right) - (m+1)}{\text{frecuencia de clase de la mediana}}\right)$$

donde n es la suma de todas las frecuencias de clase y m es la suma de las frecuencias de clase que *preceden* la clase de la mediana. Utilice este procedimiento para calcular la mediana del conjunto de datos que se resume en la tabla 2.2. ¿Cómo se compara este resultado con la mediana de la lista original de datos, que es de 170? ¿Cuál valor de la mediana es mejor: el que se calculó para la tabla de frecuencias o el de 170?

2-5 Medidas de variación

Sugerencia: Ya que la sección introduce el concepto de variación, que es muy relevante en la estadística, es una de las más importantes de todo el libro. Primero lea esta sección en forma rápida y obtenga una comprensión general de las características de variación. Después, aprenda a calcular las medidas de variación, en especial la desviación estándar. Finalmente, trate de comprender el razonamiento que subyace a la fórmula de la desviación estándar, pero no gaste demasiado tiempo memorizando fórmulas o haciendo cálculos aritméticos. En lugar de ello, dé prioridad a aprender a *interpretar* los valores de la desviación estándar.

En la figura 2-12, de la página 74, se presenta un ejemplo visual de variación, el cual incluye muestras de tornillos de dos compañías diferentes. Puesto que dichos tornillos se utilizan para unir las alas al fuselaje, su calidad es muy importante. Si sólo tomamos en consideración la media, no reconoceríamos cualquier diferencia entre dos muestras, ya que ambas tienen una media de $\bar{x} = 2{,}000$ pulgadas. Sin embargo, debe ser evidente que las muestras difieren mucho con respecto a las *variaciones* de las longitudes de los tornillos. Los tornillos fabricados por Precision Bolt Co. parecen tener longitudes muy similares, mientras que las longitudes de los tornillos de Ruff Bolt Co. varían mucho. En muchos procesos de fabricación, este mismo aspecto tiene una gran importancia. Se logra una mejor calidad a través de una variación menor. En esta sección queremos que desarrolle la habilidad para medir y comprender la variación.

Otra situación ideal, que ilustra la importancia de la variación, se percibe en las filas de espera en los bancos. En el pasado, muchos bancos requerían que sus clientes esperaran en filas separadas, frente a cada una de las ventanillas; sin embargo, ahora la mayoría utiliza una sola fila de espera. ¿Por qué hicieron este cambio? El tiempo medio de espera no cambió, ya que la configuración de la fila de

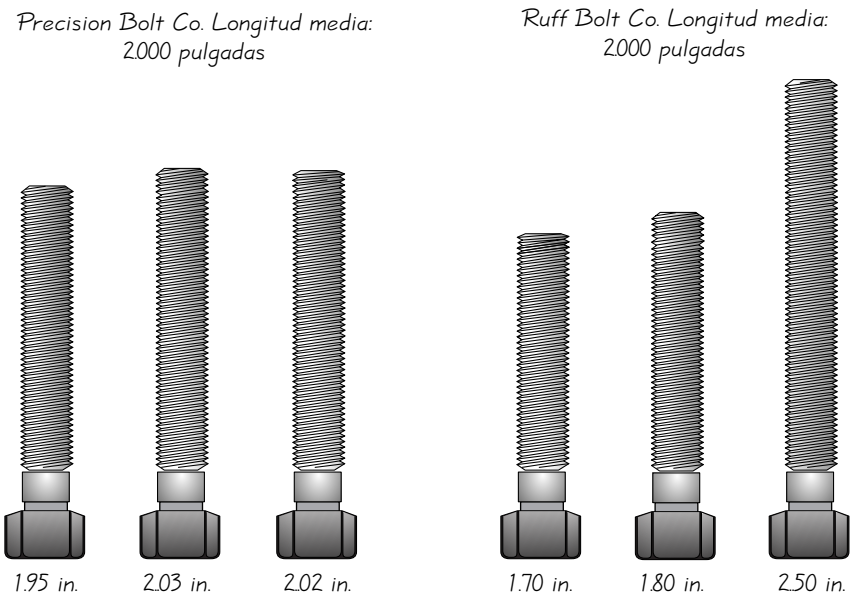


FIGURA 2-12 **Tornillos fabricados por dos compañías diferentes**

espera no afecta la eficiencia de los cajeros. El cambio a una sola fila se hizo porque los clientes prefieren esperar periodos que sean más *consistentes*, con menos variación. Miles de bancos hicieron un cambio que resultó en una menor variación (y clientes más contentos), aun cuando no se afectó la media. Consideremos algunos tiempos de espera específicos (en minutos) de clientes bancarios.

Banco Salem (una fila de espera)	4	7	7
Banco Mulberry (múltiples filas de espera)	1	3	14

Es fácil calcular que $\bar{x} = 6.0$ para ambos conjuntos de datos. También es fácil notar, mediante una inspección visual, que los tiempos de espera de 4, 7, 7 varían mucho menos que los tiempos de espera de 1, 3, 14. Procedamos ahora a desarrollar algunas formas específicas de medición real de la variación, de modo que sea posible utilizar números específicos en lugar de juicios subjetivos. Comencemos por el rango.

Rango

Definición

El **rango** de un conjunto de datos es la diferencia entre el valor máximo y el valor mínimo.

Rango = (valor máximo) − (valor mínimo)

Para calcular el rango, sólo se resta el valor mínimo del valor máximo. Para los clientes del Banco Salem, el rango es $7 - 4 = 3$ min. El Banco Mulberry tiene tiempos de espera con un rango de 13 min y este valor más grande sugiere una mayor variación.

Es muy fácil calcular el rango, pues depende únicamente de los valores máximo y mínimo, pero no es tan útil como otras medidas de variación que usan cada valor. (Véase el ejercicio 35 como un ejemplo en el que el rango causó confusión).

Desviación estándar de una muestra

La desviación estándar es, por lo general, la medida de variación más importante y útil. Definimos ahora la desviación estándar, pero para comprenderla por completo, es necesario estudiar el apartado "Interpretación y comprensión de la desviación estándar", que aparece posteriormente en esta sección (véase la página 81).

Definición

Desviación estándar (de un conjunto de valores muestrales): medida de variación de los valores con respecto a la media. Es un tipo de desviación promedio de los valores, con respecto a la media, que se calcula utilizando las fórmulas 2-4 o 2-5.

Fórmula 2-4

$$s = \sqrt{\frac{\Sigma(x - \bar{x})^2}{n - 1}}$$

desviación estándar de la muestra

Fórmula 2-5

$$s = \sqrt{\frac{n\Sigma(x^2) - (\Sigma x)^2}{n(n - 1)}}$$

fórmula abreviada de la desviación estándar de la muestra

Más adelante, en esta sección, analizaremos los fundamentos de estas fórmulas, aunque por ahora le recomendamos que utilice la fórmula 2-4, para resolver algunos ejemplos, y que después aprenda a calcular los valores de la desviación estándar por medio del uso de su calculadora y de un programa de cómputo. (La mayoría de las calculadoras científicas se diseñaron de tal modo que permiten que se introduzca una lista de valores y se obtenga de forma automática la desviación estándar). Mientras tanto, citamos propiedades importantes que son consecuencia de la forma en que se define la desviación estándar.

- La desviación estándar es una medida de variación de todos los valores con respecto a la *media*.
- El valor de la desviación estándar s suele ser positivo. Sólo es igual a cero cuando todos los valores de los datos son el mismo número. Además, valores grandes de s indican mayores cantidades de variación.
- El valor de la desviación estándar s se puede incrementar de manera drástica con la inclusión de uno o más datos distantes (valores de datos que se encuentran muy lejos de los demás).
- Las unidades de la desviación estándar s (como minutos, pies, libras, etcétera) son las mismas de los datos originales.



Más acciones, menos riesgo

En su libro *Investments*, Zvi Bodie, Alex Kane y Alan Marcus afirman que "la desviación estándar promedio de los rendimientos de carteras compuestas por un solo tipo de acciones fue de 0.554. El riesgo promedio de la cartera disminuye rápidamente cuando aumenta el número de acciones incluidas en la cartera". También señalan que con 32 acciones la desviación estándar es de 0.325, lo que indica mucho menos variación y riesgo. Los autores destacan que, con sólo unas cuantas acciones, una cartera tiene alto grado de riesgo "específico de una empresa", lo que significa que el riesgo puede atribuirse a la poca cantidad de acciones implicadas. Con más de 30 acciones, hay muy poco riesgo específico de una empresa; en su lugar, casi todo el riesgo es "riesgo de mercado", atribuible al mercado de acciones global. Además, señalan que estos principios son "sólo una aplicación de la bien conocida ley de promedios".

Procedimiento para calcular la desviación estándar con la fórmula 2-4

Paso 1: Calcule la media $\bar{x}$.

Paso 2: Reste la media de cada valor individual para tener una lista de desviaciones de la forma $(x - \bar{x})$.

Paso 3: Eleve al cuadrado cada una de las diferencias obtenidas en el paso 2. Esto produce números de la forma $(x - \bar{x})^2$.

Paso 4: Sume todos los cuadrados obtenidos en el paso 3. Éste es el valor de $\Sigma(x - \bar{x})^2$.

Paso 5: Divida el total del paso 4 entre el número $(n - 1)$, es decir, 1 menos que el total de valores presentes.

Paso 6: Calcule la raíz cuadrada del resultado del paso 5.

EJEMPLO Uso de la fórmula 2-4 Use la fórmula 2-4 para calcular la desviación estándar de los tiempos de espera de los clientes del Banco Mulberry. Dichos tiempos (en minutos) son 1, 3, 14.

SOLUCIÓN Utilizaremos los seis pasos en este proceso. Remítase a dichos pasos y a la tabla 2-11, que presenta los cálculos detallados.

Paso 1: Obtenga la media de 6.0 sumando los valores y después dividiendo entre el número de valores:

$$\bar{x} = \frac{\Sigma x}{n} = \frac{18}{3} = 6.0 \text{ min}$$

Paso 2: Reste la media de 6.0 de cada valor para obtener los valores de $(x - \bar{x})$: $-5, -3, 8$.

Paso 3: Eleve al cuadrado cada valor que se obtuvo en el paso 2 para lograr valores de $(x - \bar{x})^2$: 25, 9, 64.

Paso 4: Sume todos los valores anteriores para obtener el valor de

$$\Sigma(x - \bar{x})^2 = 98$$

Paso 5: Con $n = 3$ valores, divida entre 1 menos que 3:

$$\frac{98}{2} = 49.0$$

Paso 6: Calcule la raíz cuadrada de 49.0. La desviación estándar es

$$\sqrt{49.0} = 7.0 \text{ min}$$

De manera ideal, ahora interpretaríamos el significado de los resultados; dichas interpretaciones se analizarán más tarde en esta sección.

Tabla 2-11 Cálculo de la desviación estándar de los tiempos de espera de los clientes del Banco Mulberry

x	$x - \bar{x}$	$(x - \bar{x})^2$
1	−5	25
3	−3	9
14	8	64
Totales: 18		98

$$\bar{x} = \frac{18}{3} = 6.0 \text{ min} \qquad s = \sqrt{\frac{98}{3-1}} = \sqrt{49} = 7.0 \text{ min}$$

EJEMPLO Uso de la fórmula 2-5 En el ejemplo anterior se utilizó la fórmula 2-4 para calcular la desviación estándar de los tiempos de espera de los clientes del Banco Mulberry. Con el mismo conjunto de datos, calcule la desviación estándar con la fórmula 2-5.

SOLUCIÓN La fórmula 2-5 requiere que primero encontremos valores para n, Σx y Σx^2.

$n = 3$ (ya que existen tres valores en la muestra)

$\Sigma x = 18$ (se obtiene al sumar los tres valores muestrales)

$\Sigma x^2 = 206$ (se obtiene al sumar los cuadrados de los valores muestrales, $1^2 + 3^2 + 14^2$)

Si usamos la fórmula 2-5, obtendremos

$$s = \sqrt{\frac{n(\Sigma x^2) - (\Sigma x)^2}{n(n-1)}} = \sqrt{\frac{3(206) - (18)^2}{3(3-1)}} = \sqrt{\frac{294}{6}} = 7.0 \text{ min}$$

Una actividad adecuada es detenerse aquí y calcular la desviación estándar de los tiempos de espera del Banco Salem. Siga los mismos procedimientos de los dos ejemplos anteriores y verifique que, para el Banco Salem, $s = 1.7$ min. (También será importante desarrollar la habilidad para obtener valores de desviaciones estándar con el uso de calculadoras y de programas de cómputo). Aun cuando las interpretaciones de tales desviaciones estándar se analizarán posteriormente, ahora las compararemos para darnos cuenta de que la desviación estándar de los tiempos de espera del Banco Salem (1.7 min) es mucho menor que la desviación estándar del Banco Mulberry (7.0 min). Esto apoya nuestra conclusión subjetiva de que los tiempos de espera del Banco Salem tienen una variación mucho menor que los tiempos del Banco Mulberry.



¿Dónde están los bateadores de 0.400?

El último beisbolista que bateó más de 0.400 fue Ted Williams, quien promedió 0.406 en 1941. Hubo promedios por arriba de 0.400 en 1876, 1879, 1887, 1894, 1895, 1896, 1897, 1899, 1901, 1911, 1920, 1922, 1924, 1925 y 1930, pero ninguno desde 1941. ¿Ya no existen grandes bateadores? Stephen Jay Gould, de la Universidad de Harvard, señaló que el promedio de bateo medio se ha mantenido estable en 0.260 durante aproximadamente 100 años, pero la desviación estándar disminuyó de 0.049 en la década de 1870 hasta 0.031 en la actualidad. Él argumenta que las estrellas de hoy son tan buenas como las del pasado, pero que los mejores lanzadores actuales mantienen promedios por debajo de 0.400.

Desviación estándar de una población

En nuestra definición de la desviación estándar, nos referimos a datos *muestrales*. Para calcular la desviación estándar σ (sigma minúscula) de una *población*, se utiliza una fórmula ligeramente diferente: en lugar de dividir entre $n - 1$, se hace entre el tamaño N de la población, como en la siguiente expresión:

$$\sigma = \sqrt{\frac{\Sigma(x - \mu)^2}{N}}$$ desviación estándar de la población

Ya que generalmente usamos datos muestrales, a menudo utilizaremos la fórmula 2-4, en la cual dividimos entre $n - 1$. Muchas calculadoras dan tanto la desviación estándar muestral como la desviación estándar poblacional, pero con una gran variedad de notaciones diferentes. Asegúrese de identificar la notación de su calculadora, de modo que obtenga el resultado correcto. (La TI-83 Plus utiliza Sx para la desviación estándar muestral y σx para la desviación estándar poblacional).

Varianza de una muestra y una población

Usamos el término *variación* como una descripción general de la cantidad que varían los valores entre sí. (En ocasiones, se aplica el término *dispersión* en lugar de *variación*). El término *varianza* se refiere a una definición específica.

Definiciones

Varianza (de un conjunto de valores): medida de variación igual al cuadrado de la desviación estándar.

Varianza muestral: cuadrado de la desviación estándar s.

Varianza poblacional: cuadrado de la desviación estándar poblacional σ.

Se dice que la varianza muestral s^2 es un **estimador sin sesgo** de la varianza poblacional σ^2, lo que significa que los valores de s^2 tienden a igualar el valor de σ^2, en lugar de hacerlo de manera sistemática, a sobreestimar o subestimar σ^2. (Véase el ejercicio 41).

EJEMPLO Cálculo de la varianza En el ejemplo anterior, empleamos los tiempos de espera de los clientes del Banco Mulberry para descubrir que la desviación estándar está dada por $s = 7.0$ min. Calcule la varianza de esa misma muestra.

SOLUCIÓN Ya que la varianza es el cuadrado de la desviación estándar, obtenemos los resultados que se muestran abajo. Note que las unidades de los valores de los datos están dadas en minutos y que la desviación estándar es de 7.0 minutos; la varianza está dada en unidades de min^2.

$$\text{varianza muestral} = s^2 = 7.0^2 = 49.0\ \text{min}^2$$

La varianza es un estadístico importante que se utiliza en algunos métodos estadísticos relevantes, como el análisis de varianza, que se explica en el capítulo 11. Para nuestros propósitos presentes, la varianza tiene la siguiente gran desventaja:

las unidades de la varianza son diferentes a las unidades del conjunto original de datos. Por ejemplo, si los tiempos originales de espera de los clientes están dados en minutos, las unidades de varianza estarán dadas en minutos cuadrados (min^2). ¿Qué es un minuto cuadrado? (Diviértase elaborando una respuesta creativa a dicha pregunta). Ya que la varianza utiliza unidades distintas, es sumamente difícil comprender la varianza si la se relaciona con el conjunto original de datos. Por esta propiedad, nos enfocaremos en la desviación estándar, mientras tratamos de comprender la variación.

Ahora presentamos la notación y la regla de redondeo que utilizamos.

Notación

s = desviación estándar *muestral*
s^2 = varianza *muestral*

σ = desviación estándar *poblacional*
σ^2 = varianza *poblacional*

Nota: Los artículos de las revistas y los reportes científicos suelen usar DE (o bien, SD en inglés) para la desviación estándar y VAR para la varianza.

Regla del redondeo

Usamos la misma regla de redondeo que se empleó en la sección 2-4:

> **Aumentar una posición decimal a la que había en los datos originales**.

Redondee sólo la respuesta final, no los valores a la mitad de un cálculo. (Si se vuelve absolutamente necesario redondear a la mitad, deberemos llevar al menos el doble de posiciones decimales de las que se utilizarán en la respuesta final).

Comparación de la variación en diferentes poblaciones

Anteriormente afirmamos que, ya que las unidades de la desviación estándar son las mismas que las unidades de los datos originales, es más fácil comprender la desviación estándar que la varianza. Sin embargo, esta misma propiedad dificulta comparar la variación de valores que se tomaron de distintas poblaciones. El *coeficiente de variación* resuelve tal desventaja.

Definición

Coeficiente de variación o **CV** de un conjunto de datos muestrales o poblacionales, expresado como porcentaje, describe la desviación estándar relativa a la media, y está dada de la siguiente forma:

Muestra

$$CV = \frac{s}{\bar{x}} \cdot 100\%$$

Población

$$CV = \frac{\sigma}{\mu} \cdot 100\%$$

EJEMPLO Estatura y peso de hombres Si utilizamos los datos muestrales estatura y peso de 40 hombres, incluidos en el conjunto de datos 1 del Apéndice B, obtendremos los estadísticos que aparecen en la siguiente tabla. Calcule el coeficiente de variación de las estaturas, después el coeficiente de variación de los pesos; finalmente, compare los dos resultados.

	Media ($\bar{x}$)	Desviación estándar (s)
Estatura	68.34 in	3.02 in
Peso	172.55 lb	26.33 lb

SOLUCIÓN Debido a que tenemos estadísticos muestrales, los dos coeficientes de variación se obtienen de la siguiente manera:

Estaturas: $$CV = \frac{s}{\bar{x}} \cdot 100\% = \frac{3.02 \text{ in}}{68.34 \text{ in}} \cdot 100\% = 4.42\%$$

Pesos: $$CV = \frac{s}{\bar{x}} \cdot 100\% = \frac{26.33 \text{ lb}}{172.55 \text{ lb}} \cdot 100\% = 15.26\%$$

Aun cuando la diferencia en unidades imposibilita la comparación de la desviación estándar de 3.02 pulgadas, con la desviación estándar de 26.33 libras, es posible comparar los coeficientes de variación, que carecen de unidades. Se observa que las estaturas (con $CV = 4.42\%$) tienen una variación considerablemente menor que los pesos (con $CV = 15.26\%$). Lo anterior tiene sentido, ya que, por lo general, vemos que los pesos de los hombres varían mucho más que sus estaturas. Por ejemplo, es muy raro encontrar un adulto que mida el doble que otro, pero es mucho más común ver a uno que pese el doble que otro.

Cálculo de la desviación estándar a partir de una distribución de frecuencias

En ocasiones necesitamos calcular la desviación estándar de un conjunto de datos que se resume en una distribución de frecuencias, como en la tabla 2-2 de la sección 2-2. Si se dispone de la lista original de valores muestrales, se utiliza la fórmula 2-4 o la 2-5, de modo que el resultado es más exacto. Si los datos originales no están disponibles, se utiliza uno de los dos métodos siguientes:

1. Si el número total de valores no es demasiado grande, trabaje con su calculadora o programa de cómputo e introduzca cada marca de clase tantas veces como el número de la frecuencia de clase.
2. Calcule la desviación estándar con la fórmula 2-6.

Fórmula 2-6 $$s = \sqrt{\frac{n[\Sigma(f \cdot x^2)] - [\Sigma(f \cdot x)]^2}{n(n-1)}}$$ desviación estándar para una distribución de frecuencias

Tabla 2-12 Cálculo de la desviación estándar a partir de una distribución de frecuencias

Cotinina	Frecuencia f	Marca de clase, x	$f \cdot x$	$f \cdot x^2$
0–99	11	49.5	544.5	26952.75
100–199	12	149.5	1794.0	268203.00
200–299	14	249.5	3493.0	871503.50
300–399	1	349.5	349.5	122150.25
400–499	2	449.5	899.0	404100.50
Totales:	$\Sigma f = 40$		$\Sigma(f \cdot x) = 7080$	$\Sigma(f \cdot x^2) = 1692910$

EJEMPLO Niveles de cotinina de fumadores Calcule la desviación estándar de los 40 valores que se resumen en la distribución de frecuencias de la tabla 2.2, considerando que no se dispone del conjunto original de datos.

SOLUCIÓN

Método 1: La tabla 2-12 tiene marcas de clase de 49.5, 149.5, 249.5, 349.5 y 449.5. Con una calculadora o un programa de cómputo introduzca el valor de 49.5, 11 veces (ya que la frecuencia de la primera clase es 11); introduzca 149.5, 12 veces y así sucesivamente. Obtenga la desviación estándar de este conjunto de 40 marcas de clase. El resultado debe ser 106.2.

Método 2: Utilice la fórmula 2-6. La aplicación de la fórmula 2-6 requiere que primero obtengamos los valores de n, $\Sigma(f \cdot x)$ y $\Sigma(f \cdot x^2)$. Después de obtener estos valores de la tabla 2-12, apliquemos la fórmula 2-6 de la siguiente manera:

$$s = \sqrt{\frac{n[\Sigma(f \cdot x^2)] - [\Sigma(f \cdot x)]^2}{n(n-1)}} = \sqrt{\frac{40[1692910] - [7080]^2}{40(40-1)}}$$

$$= \sqrt{\frac{17{,}590{,}000}{1560}} = \sqrt{11275.64103} = 106.2$$

Calculadora TI-83 Plus A diferencia de la mayoría de las calculadoras, la TI-83 Plus calcula la desviación estándar de valores resumidos en una distribución de frecuencias. Primero, introduzca las marcas de clase en la lista L1, después introduzca las frecuencias en la lista L2. Ahora presione **STAT**, seleccione **CALC**, luego seleccione **1-VarStats** e introduzca L1, L2 para obtener resultados que incluyan la media y la desviación estándar. Nuevamente, la desviación estándar muestral se identifica con Sx y la desviación estándar poblacional con σx.

Interpretación y comprensión de la desviación estándar

Este apartado es sumamente importante, puesto que ahora trataremos de que la desviación estándar tenga sentido. Primero, debemos comprender con claridad que la

desviación estándar mide la variación entre los valores. Los valores cercanos producirán una desviación estándar pequeña, mientras que los valores muy dispersos producirán una desviación estándar más grande.

Ya que la variación es un concepto tan importante y que la desviación estándar es una herramienta tan útil para medir la variación, consideraremos tres formas diferentes para lograr una apreciación de los valores de las desviaciones estándar. La primera es la **regla práctica del intervalo**, que se basa en el principio de que para muchos conjuntos de datos, la vasta mayoría (tanto como el 95%) de los valores muestrales se ubican dentro de dos desviaciones estándar de la media. (Es posible mejorar la precisión de tal regla si tomamos en cuenta factores como el tamaño de la muestra y la naturaleza de la distribución, aunque preferimos sacrificar precisión en aras de la sencillez. Además, podríamos usar tres o, incluso, cuatro desviaciones estándar en lugar de 2, lo cual constituye una decisión un poco arbitraria. Sin embargo, deseamos una regla sencilla que nos ayude a interpretar los valores de las desviaciones estándar; métodos posteriores producirán resultados más precisos).

Regla práctica del intervalo

Para estimar el valor de la desviación estándar *s*: para obtener un estimado burdo de la desviación estándar, utilice

$$s \approx \frac{\text{rango}}{4}$$

donde el rango = (valor máximo) − (valor mínimo).

Para interpretar un valor conocido de la desviación estándar: si se conoce la desviación estándar *s*, utilícela para calcular estimados burdos de los valores muestrales mínimos y máximos "comunes" por medio de

$$\text{valor mínimo "común"} \approx (\text{media}) - 2 \times (\text{desviación estándar})$$

$$\text{valor máximo "común"} \approx (\text{media}) + 2 \times (\text{desviación estándar})$$

Cuando calcule una desviación estándar por medio de las fórmulas 2-4 o 2-5, la regla práctica del intervalo resulta útil para verificar el resultado, pero debe estar consciente de que, aun cuando la aproximación nos acerca a la respuesta, puede tener un error considerable.



EJEMPLO Niveles de cotinina de fumadores Utilice la regla práctica del intervalo para calcular un estimado burdo de la desviación estándar de la muestra de 40 niveles de cotinina de fumadores, como se observa en la tabla 2-1.

SOLUCIÓN Al emplear la regla práctica del intervalo para estimar la desviación estándar de datos muestrales, calculamos el rango y lo dividimos entre 4. Si observamos la lista de los niveles de cotinina, notaremos que el mínimo es 0 y el máximo 491; por lo tanto, el rango es de 491. La desviación estándar *s* se estima de la siguiente manera:

$$s \approx \frac{\text{rango}}{4} = \frac{491}{4} = 122.75 \approx 123$$

INTERPRETACIÓN Este resultado es muy cercano al valor correcto de 119.5, que se obtiene al calcular el valor exacto de la desviación estándar con las fórmulas 2-4 o 2-5. No espere que la regla práctica del intervalo funcione tan bien en otros casos.

El siguiente ejemplo es particularmente importante como ilustración de una forma de *interpretar* el valor de una desviación estándar.

EJEMPLO Circunferencias de la cabeza de niñas Resultados anteriores del National Health Survey sugieren que las circunferencias de las cabezas de niñas de dos meses de edad tienen una media de 40.05 cm y una desviación estándar de 1.64 cm. Utilice la regla práctica del intervalo para calcular el mínimo y el máximo "comunes" de las circunferencias de las cabezas. (Estos resultados serían prácticos para un médico al que le interese identificar circunferencias "infrecuentes", que serían el resultado de un trastorno como la hidrocefalia). Después, determine si una circunferencia de 42.6 cm sería considerada "infrecuente".

SOLUCIÓN Con una media de 40.05 cm y una desviación estándar de 1.64 cm, empleamos la regla práctica del intervalo para calcular las circunferencias mínima y máxima comunes, de la siguiente manera:

$$\text{mínimo} \approx (\text{media}) - 2 \times (\text{desviación estándar})$$
$$= 40.05 - 2(1.64) = 36.77 \text{ cm}$$

$$\text{máximo} \approx (\text{media}) + 2 \times (\text{desviación estándar})$$
$$= 40.05 + 2(1.64) = 43.33 \text{ cm}$$

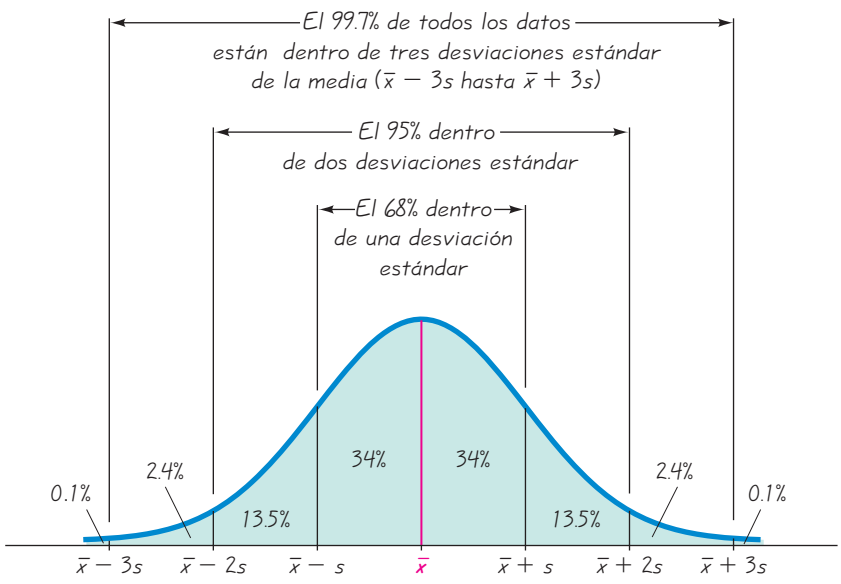
INTERPRETACIÓN Con base en estos resultados, esperamos que, generalmente, las niñas de dos meses de edad tengan una cabeza cuya circunferencia mida entre 36.77 cm y 43.33 cm. Como 42.6 cm está dentro de estos límites, se consideraría una niña normal.

Regla empírica para datos con distribución normal (o 68-95-99.7)

Otra regla útil para interpretar los valores de una desviación estándar es la **regla empírica**. Esta regla establece que las siguientes propiedades se aplican *a conjuntos de datos que tienen una distribución aproximadamente normal*. (Véase la figura 2-13).

- Aproximadamente el 68% de todos los valores están dentro de una desviación estándar de la media.
- Aproximadamente el 95% de todos los valores están dentro de dos desviaciones estándar de la media.
- Aproximadamente el 99.7% de todos los valores están dentro de tres desviaciones estándar de la media.

FIGURA 2-13 La regla empírica



EJEMPLO Puntuaciones de CI Las puntuaciones de adultos normales en la prueba Weschler tienen una distribución normal, con una media de 100 y una desviación estándar de 15. ¿Qué porcentaje de adultos tienen puntuaciones de CI entre 55 y 145?

SOLUCIÓN La clave para resolver el problema es reconocer que 55 y 145 están exactamente a tres desviaciones estándar de la media de 100, como se indica abajo.

$$3 \text{ desviaciones estándar} = 3s = 3(15) = 45$$

Por lo tanto, tres desviaciones estándar de la media son igual a

$$100 - 45 = 55$$

o

$$100 + 45 = 145$$

La regla empírica nos indica que aproximadamente el 99.7% de todos los valores están dentro de tres desviaciones estándar de la media; por lo tanto, el 99.7% de todas las puntuaciones de CI se encuentran entre 55 y 145.

Sugerencia: Las dificultades para aplicar la regla empírica suelen surgir de la confusión al interpretar frases tales como "dentro de 3 desviaciones estándar de la media". Deténgase aquí, revise el ejemplo anterior hasta que el significado de dicha frase esté claro. Además, observe las siguientes interpretaciones generales de esa frase.

Frase	Significado
Dentro de una desviación estándar de la media	Entre $(\bar{x} - s)$ y $(\bar{x} + s)$
Dentro de dos desviaciones estándar de la media	Entre $(\bar{x} - 2s)$ y $(\bar{x} + 2s)$
Dentro de tres desviaciones estándar de la media	Entre $(\bar{x} - 3s)$ y $(\bar{x} + 3s)$

Un tercer concepto útil para comprender el valor de una desviación estándar es el **teorema de Chebyshev**. La regla empírica anterior se aplica sólo a conjuntos de datos con una distribución normal. El teorema de Chebyshev, en lugar de limitarse a conjuntos de datos con distribuciones normales se aplica a cualquier conjunto de datos, pero sus resultados son muy aproximados.

Teorema de Chebyshev

La proporción (o fracción) de cualquier conjunto de datos que está dentro de K desviaciones estándar de la media es siempre *al menos* $1 - 1/K^2$, donde K es cualquier número positivo mayor que 1. Para $K = 2$ y $K = 3$, tenemos los siguientes enunciados:

- Al menos $3/4$ (o 75%) de todos los valores están dentro de dos desviaciones estándar de la media.
- Al menos $8/9$ (u 89%) de todos los valores están dentro de tres desviaciones estándar de la media.

EJEMPLO Puntuaciones de CI Las puntuaciones de CI de adultos normales tomadas de la prueba Weschler tienen una media de 100 y una desviación estándar de 15. ¿Qué podemos concluir a partir del teorema de Chebyshev?

SOLUCIÓN Al aplicar el teorema de Chebyshev, con una media de 100 y una desviación estándar de 15, llegamos a las siguientes conclusiones:

- Por lo menos $3/4$ (o 75%) de todos los adultos tienen puntuaciones de CI que están dentro de dos desviaciones estándar de la media (entre 70 y 130).
- Al menos $8/9$ (u 89%) de todos los adultos tienen puntuaciones de CI que están dentro de tres desviaciones estándar de la media (entre 55 y 145).

Cuando intentemos darle un significado a un valor de una desviación estándar, debemos usar uno o más de los tres conceptos anteriores. Para comprender aún mejor la naturaleza de la desviación estándar, consideraremos los fundamentos subyacentes que conducen a la fórmula 2-4, que es la base de su definición. (La fórmula 2-5 es sencillamente otra versión de la fórmula 2-4, derivada de modo que los cálculos aritméticos pueden simplificarse).

Fundamentos de la fórmula 2-4

La desviación estándar de un conjunto de datos muestrales se define con las fórmulas 2-4 y 2-5, las cuales son equivalentes en el sentido de que siempre producen el mismo resultado. La fórmula 2-4 tiene la ventaja de reforzar el concepto de que la desviación estándar es un tipo de desviación promedio. La fórmula 2-5, la de ser más fácil de usar cuando hay que calcular desviaciones estándar por nuestra cuenta. La fórmula 2-5 también elimina los errores de redondeo intermedios que se introducen en la fórmula 2-4 cuando no se utiliza el valor exacto de la media. La fórmula 2-5 se aplica en calculadoras y programas, ya que requiere sólo de tres lugares de memoria (para n, Σx y Σx^2), en vez de un lugar de memoria para cada valor del conjunto de datos.

¿Para qué definir una medida de variación en la forma descrita por la fórmula 2.4? Al medir la variación en un conjunto de datos muestrales, parece lógico iniciar con las cantidades individuales con las que los valores se desvían de la media. Para un valor particular x, la cantidad de **desviación** es $x - \bar{x}$, que es la diferencia entre el valor individual x y la media. Para los tiempos de espera del Banco Mulberry de 1, 3, 14, la media es 6.0, de modo que las desviaciones de la media son -5, -3 y 8. Sería bueno combinar, de alguna forma, dichas desviaciones en un solo valor colectivo. La simple suma de las desviaciones no funciona, ya que la suma siempre será cero. Para obtener un estadístico que mida la variación, necesitamos evitar la cancelación de números positivos y negativos. Un método consiste en sumar valores absolutos, como en $\Sigma|x - \bar{x}|$. Si calculamos la media de esta suma, obtendremos la **desviación media absoluta** (o **DMA**), que es la distancia media de los datos con respecto a la media.

$$\text{desviación media absoluta} = \frac{\Sigma|x - \bar{x}|}{n}$$

Ya que los tiempos de espera del Banco Mulberry de 1, 3, 14 tienen desviaciones de -5, -3 y 8, la desviación media absoluta es $(5 + 3 + 8)/3 = 6/3 = 5.3$.

¿Por qué no utilizar la desviación media absoluta? Como la desviación media absoluta requiere que usemos valores absolutos, emplea una operación que no es algebraica. (Las operaciones algebraicas incluyen la suma, la multiplicación, la raíz cuadrada y la elevación a potencias enteras o fraccionarias, pero el valor absoluto no está incluido). El uso de valores absolutos crea problemas algebraicos en los métodos inferenciales de la estadística. Por ejemplo, la sección 8.3 presentó un método para hacer inferencias acerca de las medias de dos poblaciones; dicho método se construye alrededor de una propiedad de adición de las varianzas, pero la desviación media absoluta no posee tal propiedad de adición. (He aquí una versión simplificada de la propiedad de adición de la varianza: si se tienen dos poblaciones independientes y se selecciona aleatoriamente un valor de cada población y se suman, dichas sumas tendrán una varianza que es igual a la suma de las varianzas de las dos poblaciones.) La misma propiedad de adición subyace en los fundamentos de la regresión, que se presentan en el capítulo 9, y el análisis de varianza que se introduce en el capítulo 11. Además, el ejercicio 42 demuestra que el valor de la media absoluta presenta un sesgo, lo cual significa que cuando se calculan valores de media absoluta de muestras, no se tiende a igualar el valor medio absoluto de la población. En contraste, la desviación estándar utiliza sólo operaciones algebraicas. Puesto que se basa en la raíz cuadrada de una suma de cuadrados, la desviación estándar se asemeja a las fórmulas de distancia que se usan en álgebra. Hay muchos ejemplos en los cuales un procedimiento estadístico se encuentra sesgado en una suma de cuadrados similar. Por lo tanto, en lugar de emplear valores absolutos, obtenemos una mejor medida de variación si logramos que todas las desviaciones $(x - \bar{x})$ no sean negativas, lo cual haremos elevándolas al cuadrado; este método conduce a la desviación estándar. Por tales razones, las calculadoras científicas suelen incluir una función para la desviación estándar, pero casi nunca la desviación media absoluta.

¿Por qué dividir entre $n - 1$? Después de obtener todos los valores individuales de $(x - \bar{x})^2$, los combinamos calculando su suma y luego obtenemos un promedio dividiéndola entre $n - 1$. Dividimos entre $n - 1$, porque hay solamente $n - 1$ valores independientes. Es decir, con una media dada, sólo a $n - 1$ valores se

le puede asignar un número con libertad, antes de que se determine el último valor. Véase el ejercicio 41, que proporciona números concretos que ilustran como tal división entre $n - 1$ es mejor que la división entre n. Este ejercicio muestra que si s^2 se definiera con la división entre n, de forma sistemática subestimaría el valor de σ^2, por lo que lo compensamos incrementando su valor general, haciendo que su denominador sea más pequeño (usando $n - 1$ en lugar de n). El ejercicio 41 demuestra cómo la división entre $n - 1$ provoca que la varianza muestral s^2 iguale el valor de la varianza poblacional σ^2; en tanto que la división entre n causa que la varianza muestral s^2 subestime el valor de la varianza poblacional σ^2.

El paso 6 de la fórmula 2-4, para el cálculo de una desviación estándar, implica sacar una raíz cuadrada. Esto se hace para compensar la elevación al cuadrado que se realizó en el paso 3. Una consecuencia importante de la obtención de la raíz cuadrada es que la desviación estándar tiene las mismas unidades de medición que los valores originales. Por ejemplo, si el tiempo de espera de los clientes se da en minutos, la desviación estándar de dichos tiempos también estará en minutos. Si nos detuviéramos en el paso 5, el resultado estaría dado en unidades de "minutos cuadrados", que es un concepto abstracto sin relación directa con la realidad.

Después de estudiar dicha sección, usted debe comprender que la desviación estándar es una medida de variación entre valores. Al tener datos muestrales, será capaz de calcular el valor de la desviación estándar y de interpretar los valores de las desviaciones estándar que obtuvo. Debe saber que, para un conjunto de datos común, es raro que un valor difiera de la media por más de 2 o 3 desviaciones estándar.

2-5 Destrezas y conceptos básicos

En los ejercicios 1 a 8 calcule el rango, la varianza y de desviación estándar para los datos muestrales dados. (En la sección 2-4 se utilizaron los mismos datos para calcular medidas de tendencia central. Aquí calculamos medidas de variación).

1. Consumo de tabaco en películas infantiles En el artículo "Tobbaco and Alcohol Use in G-Rated Children's Animated Films", de Goldstein, Sobel y Newman (*Journal of the American Medical Association*, vol. 281, núm. 12), se registró la duración (en segundos) de escenas de películas de dibujos animados, de los Universal Studios, que muestran consumo de tabaco. A continuación se presentan los primeros seis valores, que se incluyen en el conjunto de datos 7 del Apéndice B. ¿Parecen tales duraciones ser consistentes o varían ampliamente?

0 223 0 176 0 548

2. Harry Potter En un intento por medir el nivel de lectura de un libro, se obtuvieron los puntajes de la facilidad de lectura de Flesch de 12 páginas que se seleccionaron aleatoriamente, de la obra *Harry Potter y la piedra filosofal*, de J. K. Rowling. Dichos puntajes, que se encuentran en el conjunto de datos 14 del Apéndice B, se listan a continuación. Debido a que tales puntajes se basan en 12 páginas que se seleccionaron aleatoriamente, ¿es probable que la desviación estándar de esta muestra sea un estimado razonable de la desviación estándar de los niveles de lectura de todas las páginas del libro?

85.3 84.3 79.5 82.5 80.2 84.6
79.2 70.9 78.6 86.2 74.0 83.7

3. Cereal Un nutriólogo obtiene las cantidades de azúcar (en gramos) de un gramo de 16 cereales diferentes, incluyendo Cheerios, Corn Flakes, Fruit Loops, Trix y 12 más. Estos valores, que se incluyen en el conjunto de datos 16 del Apéndice B, se listan a continuación. ¿Será la desviación estándar de dichos valores un buen estimado de la

desviación estándar de la cantidad de azúcar en cada gramo del cereal consumido por la población de todos los estadounidenses? ¿Por qué?

0.03	0.24	0.30	0.47	0.43	0.07	0.47	0.13
0.44	0.39	0.48	0.17	0.13	0.09	0.45	0.43

4. Índice de masa corporal Como parte del National Health Examination se mide el índice de masa corporal en una muestra aleatoria de mujeres. Algunos de los valores, que se anexan en el conjunto de datos 1 del Apéndice B, se listan a continuación. ¿Estará la desviación estándar de la muestra razonablemente cerca de la desviación estándar de 6.17, que es la desviación estándar de las 40 mujeres que se incluyen en el conjunto de datos 1?

19.6	23.8	19.6	29.1	25.2	21.4	22.0	27.5
33.5	20.6	29.9	17.7	24.0	28.9	37.7	

5. Conductores alcoholizados Abajo se listan las concentraciones de alcohol en la sangre de conductores que se vieron envueltos en accidentes fatales y que después fueron sentenciados a prisión (de acuerdo con datos del Departamento de Justicia de Estados Unidos). Cuando un estado lanza una campaña para "reducir el número de conductores alcoholizados", ¿es la intención de la campaña disminuir la desviación estándar?

0.27	0.17	0.17	0.16	0.13	0.24	0.29	0.24
0.14	0.16	0.12	0.16	0.21	0.17	0.18	

6. Muertes en motocicleta A continuación se presentan las edades de motociclistas cuando se accidentaron fatalmente en accidentes de tránsito (de acuerdo con datos del Departamento del Transporte de Estados Unidos). ¿De qué manera se compara la variación de estas edades con la variación de las edades de conductores con licencia en la población general?

17	38	27	14	18	34	16	42	28
24	40	20	23	31	37	21	30	25

7. Tiempos de reacción El autor visitó el Museo de Ciencias Reuben H. Fleet, en San Diego, y repitió un experimento de tiempos de reacción. Se obtuvieron los siguientes tiempos (en centésimas de segundo). ¿De que manera las medidas de variación reflejan el hecho de que tales tiempos parezcan muy consistentes?

19	20	17	21	21	21	19	18	19	19
17	17	15	17	18	17	18	18	18	17

8. Tabletas de Bufferin A continuación se listan los pesos medidos (en miligramos) de una muestra de tabletas de aspirina Bufferin. Como este medicamento debe fabricarse de forma consistente para que las dosis se controlen, ¿las medidas de variación parecen indicar que la variación tiene un nivel aceptable?

672.2	679.2	669.8	672.6	672.2	662.2
662.7	661.3	654.2	667.4	667.0	670.7

En los ejercicios 9 a 12 calcule el rango, la varianza y la desviación estándar para cada una de las dos muestras; luego, compare los dos conjuntos de resultados. (En la sección 2.4 se utilizaron los mismos datos).

9. Tiempos de espera de clientes A continuación se presentan los tiempos de espera (en minutos) de los clientes del Banco Jefferson Valley (donde todos los clientes forman una sola fila) y del Banco Providence (donde los clientes esperan en filas individuales, en tres ventanillas diferentes):

Jefferson Valley:	6.5	6.6	6.7	6.8	7.1	7.3	7.4	7.7	7.7	7.7
Providence:	4.2	5.4	5.8	6.2	6.7	7.7	7.7	8.5	9.3	10.0

10. Coca Cola regular/Coca Cola dietética Los siguientes son los pesos (en libras) de muestras del contenido de latas de Coca Cola regular y Coca Cola dietética:

Regular:	0.8192	0.8150	0.8163	0.8211	0.8181	0.8247
Dietética:	0.7773	0.7758	0.7896	0.7868	0.7844	0.7861

11. Mickey D *vs.* Jack Al investigar los tiempos que se requieren en el servicio para automóvil (en segundos), se obtienen los siguientes resultados (con base en datos del QSR Drive-Thru Time Study).

McDonald's:	287	128	92	267	176	240	192	118	153	254	193	136
Jack in the Box:	190	229	74	377	300	481	428	255	328	270	109	109

12. Anchura de cráneos Las anchuras máximas de muestras de cráneos egipcios de varones que datan del 4000 a.C. y del 150 d.C (de acuerdo con datos de *Ancient Races of the Thebaid*, de Thomson y Randall-Maciver) se muestran a continuación:

4000 a.C.:	131	119	138	125	129	126	131	132	126	128	128	131
150 d.C.:	136	130	126	126	139	141	137	138	133	131	134	129

En los ejercicios 13 a 16 remítase a los conjuntos de datos del Apéndice B. Utilice un programa de cómputo o una calculadora para obtener las desviaciones estándar; luego, compare los resultados.

T **13.** Circunferencia de cabezas Para diagnosticar de forma correcta el trastorno de hidrocefalia, un pediatra investiga la circunferencia de las cabezas de niños y niñas de dos años de edad. Utilice los resultados muestrales listados en el conjunto de datos 3. ¿Hay alguna diferencia entre los dos géneros?

T **14.** Clancy, Rowling, Tolstoi Un psicólogo infantil investiga las diferencias en la facilidad de lectura; obtiene datos con *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones de la calificación de Flesch-Kincaid de las 12 páginas seleccionadas aleatoriamente para cada uno de los tres libros.

T **15.** Lluvia el fin de semana Utilice el conjunto de datos 11 del Apéndice B, sobre las cantidades de lluvia que caen en Boston los jueves y las que caen los domingos.

T **16.** Consumo de tabaco/alcohol en películas infantiles En el artículo "Tobacco and Alcohol Use in G-Rated Children's Animated Films", de Goldstein, Sobel y Newman (*Journal of the American Medical Association*, vol. 281, núm. 12), se registraron las duraciones (en segundos) de escenas que muestran consumo de tabaco y alcohol en películas infantiles de dibujos animados. En el conjunto de datos 7 del Apéndice B, utilice las duraciones de escenas con tabaco y después las escenas con alcohol.

En los ejercicios 17 a 20 calcule la desviación estándar de los datos que se resumen en la distribución de frecuencias dada. (En la sección 2.4 se utilizaron las mismas distribuciones de frecuencias.)

17. Old Faithful Los visitantes del Parque Nacional Yellowstone consideran que una erupción del géiser Old Faithful es una gran atracción que uno no debe perderse. La distribución de frecuencias dada resume una muestra de los tiempos (en minutos) entre las erupciones.

18. Dado cargado El autor taladró un hoyo en un dado y lo rellenó con plomo; después, procedió a lanzarlo 200 veces. Los resultados se presentan en la distribución de frecuencias al margen.

19. Infracciones de tránsito La distribución de frecuencias describe las velocidades de conductores infraccionados por la policía en la ciudad de Poughkeepsie. Los conductores viajaban a través de una zona con límite de velocidad de 30 millas/hora en Creek Road, que pasa por la universidad del autor.

Tabla del ejercicio 17

Tiempo	Frecuencia
40–49	8
50–59	44
60–69	23
70–79	6
80–89	107
90–99	11
100–109	1

Tabla del ejercicio 18

Resultado	Frecuencia
1	27
2	31
3	42
4	40
5	28
6	32

Tabla del ejercicio 19

Velocidad	Frecuencia
42–45	25
46–49	14
50–53	7
54–57	3
58–61	1

Tabla del ejercicio 20

Temperatura	Frecuencia
96.5–96.8	1
96.9–97.2	8
97.3–97.6	14
97.7–98.0	22
98.1–98.4	19
98.5–98.8	32
98.9–99.2	6
99.3–99.6	4

20. Temperaturas corporales La distribución de frecuencias al margen resume una muestra de temperaturas corporales humanas. (Véanse las temperaturas de medianoche del segundo día, listadas en el conjunto de datos 4 del Apéndice B).

21. Edades de profesores Utilice la regla práctica del intervalo para estimar la desviación estándar de las edades de todos los profesores de su universidad.

22. Calificaciones de prueba Con la regla práctica del intervalo estime la desviación estándar de las calificaciones del primer examen de estadística de su clase.

23. Longitudes de piernas En los datos muestrales del conjunto de datos 1 del Apéndice B, las longitudes del muslo de la muestra de 40 mujeres tienen una media de 38.86 centímetros y una desviación estándar de 3.78 centímetros. Use la regla práctica del intervalo para estimar las longitudes mínima y máxima "comunes" de los muslos de las mujeres. En dicho contexto, ¿una longitud de 47.0 centímetros sería considerada infrecuente?

24. Estaturas de mujeres La media de las estaturas de las mujeres es de 63.6 pulgadas, con una desviación estándar de 2.5 pulgadas (con base en datos del National Health Survey). Utilice la regla práctica del intervalo para estimar las estaturas mínima y máxima "comunes" de las mujeres. En tal contexto, ¿es poco común que una mujer mida seis pies?

25. Estaturas de mujeres Las estaturas de las mujeres tienen una distribución normal, con una media de 63.6 pulgadas y una desviación estándar de 2.5 pulgadas. Utilice la regla empírica para determinar el porcentaje aproximado de mujeres que están entre
a. 61.1 y 66.1 pulgadas
b. 56.1 y 71.1 pulgadas

26. Pesos de la Coca Cola regular Con los pesos de la Coca Cola regular listados en el conjunto de datos 17 del Apéndice B, encontramos que la media es de 0.81682 libras, la desviación estándar es de 0.00751 libras y la distribución es aproximadamente normal. Aplique la regla empírica y determine el porcentaje aproximado de latas de Coca Cola regular que tienen pesos entre
a. 0.80931 y 0.82433 libras
b. 0.80180 y 0.83184 libras

27. Estaturas de mujeres Si las estaturas de mujeres tienen una media de 63.6 pulgadas y una desviación estándar de 2.5 pulgadas, ¿qué se concluye a partir del teorema de Chebyshev acerca del porcentaje de mujeres que están entre 58.6 pulgadas y 68.6 pulgadas?

28. Pesos de la Coca Cola regular Utilizando los pesos de la Coca Cola regular listados en el conjunto de datos 17 del Apéndice B, encontramos que la media es de 0.81682 libras y la desviación estándar es de 0.00751 libras. ¿Qué concluye a partir del teorema de Chebyshev acerca del porcentaje de latas de Coca Cola regular con pesos que están entre 0.79429 y 0.83935 libras?

T 29. Coeficiente de variación del cereal Remítase al conjunto de datos 17 del Apéndice B. Calcule el coeficiente de variación de las calorías y el coeficiente de variación de los gramos de azúcar por gramo de cereal. Compare los resultados.

T 30. Coeficiente de variación de Coca Cola y de Pepsi Remítase al conjunto de datos 17 del Apéndice B. Calcule el coeficiente de variación de los pesos de la Coca Cola regular y después el coeficiente de variación de los pesos de la Pepsi regular. Compare los resultados. ¿Alguna de las dos compañías parece tener pesos significativamente más consistentes?

31. Igualdad para todos ¿Qué sabe usted acerca de los valores en un conjunto de datos con una desviación estándar $s = 0$?

32. Comprensión de las unidades de medición Si un conjunto de datos consiste en multas por exceso de velocidad (en dólares), ¿qué unidades se utilizan para la desviación estándar? ¿Qué unidades se utilizan para la varianza?

33. Comparación de baterías para automóviles Las marcas de baterías para automóviles Everlast y Endurance aseguran en su etiqueta una duración de 48 meses. En realidad, ambas tienen una vida media de 50 meses, pero las baterías Everlast tienen una desviación estándar de dos meses, mientras que la de las baterías Endurance es de seis meses. ¿Cuál de las marcas sería una mejor opción? ¿Por qué?

34. Interpretación de datos distantes Un conjunto de datos consta de 20 valores, bastante cercanos entre sí. Se incluye otro valor, pero éste es un dato distante (muy lejos de los demás). ¿De qué manera se ve afectada la desviación estándar por el dato distante? ¿No genera efecto alguno? ¿Tiene un efecto pequeño? ¿Un efecto grande?

2-5 Más allá de lo básico

35. Comparación de conjuntos de datos Dos secciones diferentes de un curso de estadística resuelven el mismo examen, cuyas calificaciones se muestran abajo. Calcule el rango y la desviación estándar de cada sección. ¿Qué se concluye acerca de la variación en las dos secciones, a partir de los valores del rango? ¿Por qué el rango causa confusión en este caso? ¿Qué se concluye acerca de la variación en las dos secciones con respecto a los valores de la desviación estándar?

Sección 1:	1	20	20	20	20	20	20	20	20	20	20
Sección 2:	2	3	4	5	6	14	15	16	17	18	19

36. Transformación de datos Describa de qué forma se afectan el rango y la desviación estándar de un conjunto de datos en los siguientes casos:

a. Se suma la misma constante K a cada valor del conjunto de datos.

b. Cada valor del conjunto de datos se multiplica por la misma constante K.

c. Para los datos de temperaturas corporales listados en el conjunto de datos 4 del Apéndice B (12 a. m. del día 2), $\bar{x} = 98.20°\text{F}$ y $s = 0.62°\text{F}$. Calcule los valores de y s después de convertir cada temperatura a grados Celsius.
[*Considere que* $C = 5\,(F - 32)/9$].

37. Genichi Taguchi creó un método para mejorar la calidad y reducir los costos de fabricación, por medio de una combinación de ingeniería y estadística. Una herramienta básica en el método de Taguchi es el **cociente señal-ruido**. La forma más simple para calcular tal cociente es dividir la media entre la desviación estándar. Calcule el cociente señal-ruido de los niveles de cotinina de fumadores listados en la tabla 2-1.

38. Sesgo En la sección 2-4, introdujimos el concepto general de sesgo. El sesgo puede medirse por medio del **índice de sesgo de Pearson**:

$$I = \frac{3(\bar{x} - \text{mediana})}{s}$$

Si $I \geq 1.00$ o $I \leq -1.00$, los datos se consideran *significativamente sesgados*. Calcule el índice de sesgo de Pearson de los niveles de cotinina de fumadores, listados en la tabla 2-1, y determine si hay un sesgo significativo.

39. Comprensión de la desviación estándar Una muestra consiste en 10 calificaciones de pruebas, que caen entre 70 y 100, inclusive. ¿Cuál es la desviación estándar más grande posible?

40. ¿Datos falsos? Para cualquier conjunto de datos de n valores, con desviación estándar $s\sqrt{n-1}$, cada valor debe estar dentro de la media. Una profesora de estadística reporta que las calificaciones de una prueba que se aplicó a 17 estudiantes de su clase tuvo una media de 75.0 y una desviación estándar de 5.0. Kelly, a quien se considera la mejor estudiante de la clase, afirma haber recibido una calificación de 97. ¿Podría Kelly estar diciendo la verdad?

41. ¿Por qué dividir entre $n-1$? Sea que una población consista en los valores 3, 6, 9. Suponga que muestras de los valores se seleccionan aleatoriamente *con reemplazo*.

- **a.** Calcule la varianza σ^2 de la población {3, 6, 9}.
- **b.** Liste las nueve muestras diferentes posibles de los valores seleccionados con reemplazo; luego, calcule la varianza muestral s^2 (que incluye la división entre $n-1$) de cada una de ellas. Si se seleccionan de forma repetida dos valores muestrales, ¿cuál es el valor medio de la varianza muestral s^2?
- **c.** Para cada una de las nueve muestras, calcule la varianza tratando cada muestra como si fuese una población. (Asegúrese de utilizar la fórmula de la varianza poblacional, que incluye la división entre n). Si selecciona de forma repetida dos valores muestrales, ¿cuál es el valor medio de las varianzas poblacionales?
- **d.** ¿Con qué método se obtienen mejores estimados de σ^2: el inciso *b*) o el inciso *c*)? ¿Por qué? Al calcular las varianzas muestrales, ¿debe utilizarse la división entre n o $n-1$?
- **e.** Los incisos anteriores muestran que s^2 es un estimador sin sesgo de σ^2. ¿Será s un estimador sin sesgo de σ?

42. ¿Por qué no utilizar la DMA? El ejercicio 41 demuestra que la varianza muestral s^2 es un estimador sin sesgo de σ^2. Haga lo que se le pide con la misma población de {3, 6, 9}, para demostrar que la desviación media absoluta de una muestra es un estimador sesgado de la desviación media absoluta de una población.

- **a.** Calcule la desviación media absoluta de la población {3, 6, 9}.
- **b.** Liste las nueve muestras diferentes posibles de dos valores seleccionadas con reemplazo, después calcule la desviación media absoluta de cada una de ellas. Si se seleccionan de forma repetida dos valores muestrales, ¿cuál es el valor medio de las desviaciones medias absolutas?
- **c.** Con base en los resultados de los incisos *a*) y *b*), ¿la desviación media absoluta de una muestra tiende a igualar la desviación media absoluta de una población? ¿La división entre $n-1$, en lugar de la división entre n, convierte a la desviación media absoluta en un estimado sin sesgo de la desviación media absoluta de la población?

2-6 Medidas de posición relativa

Esta sección incluye medidas que pueden utilizarse para comparar valores de diferentes conjuntos de datos o para comparar valores dentro del mismo conjunto de datos. Aquí introducimos las puntuaciones z (para comparar valores de distintos conjuntos de datos), así como los cuartiles y percentiles (para comparar valores dentro del mismo conjunto de datos).

Puntuaciones z

Una puntuación z (o puntuación estándar) se calcula convirtiendo un valor a una escala estandarizada, como se establece en la siguiente definición. Utilizaremos ampliamente las puntuaciones z en el capítulo 5 y en capítulos posteriores, ya que son muy importantes.

Definición

Puntuación estándar o **puntuación *z*:** número de desviaciones estándar que un valor *x* se encuentra por arriba o por debajo de la media. Se calcula utilizando las siguientes expresiones:

Muestra $z = \dfrac{x - \bar{x}}{s}$ o *Población* $z = \dfrac{x - \mu}{\sigma}$

(Redondear *z* a dos espacios decimales).

El siguiente ejemplo ilustra la forma en que se utilizan las puntuaciones *z* para comparar valores, aun cuando provengan de distintas poblaciones.

EJEMPLO Comparación de estaturas La superestrella de la NBA Michael Jordan mide 78 pulgadas, en tanto que la jugadora de basquetbol de la WNBA Rebecca Lobo mide 76 pulgadas. En efecto, Jordan es más alto por dos pulgadas, pero ¿cuál de los jugadores es *relativamente* más alto? ¿La estatura de Jordan, entre los hombres, excede la estatura de Lobo entre las mujeres? Los hombres tienen estaturas con una media de 69.0 pulgadas, con una desviación estándar de 2.8 pulgadas; las mujeres tienen estaturas con una media de 63.6 pulgadas, con una desviación estándar de 2.5 pulgadas (datos basados en el National Health Survey).

SOLUCIÓN Para comparar las estaturas de Michael Jordan y Rebecca Lobo, en relación con las poblaciones de hombres y mujeres, necesitamos estandarizar dichas estaturas convirtiéndolas en puntuaciones *z*.

Jordan: $z = \dfrac{x - \mu}{\sigma} = \dfrac{78 - 69.0}{2.8} = 3.21$

Lobo: $z = \dfrac{x - \mu}{\sigma} = \dfrac{76 - 63.6}{2.5} = 4.96$

INTERPRETACIÓN La estatura de Michael Jordan está a 3.21 desviaciones estándar por arriba de la media, pero la estatura de Rebecca Lobo está a 4.96 desviaciones estándar por arriba de la media. La estatura de Rebecca Lobo entre las mujeres es relativamente mayor que la estatura de Michael Jordan entre los hombres.

Puntuaciones *z* y valores infrecuentes

En la sección 2-5 utilizamos la regla práctica del intervalo para concluir que un valor es "infrecuente" o poco común si está a más de 2 desviaciones estándar de la media. Por lo tanto, los valores infrecuentes tienen puntuaciones *z* menores que -2 y mayores que 2. (Véase la figura 2-14 en la página 94). Si aplicamos este criterio, tanto Michael Jordan como Rebecca Lobo tienen estaturas infrecuentes, ya que ambos cuentan con estaturas con puntuaciones *z* mayores que 2.

Si consideramos a jugadores profesionales de basquetbol con estaturas excepcionales, tomemos en cuenta a otro jugador, Mugsy Bogues, que alcanzó el éxito aun cuando sólo mide 5 pies y 3 pulgadas. (Nuevamente usamos el hecho de que

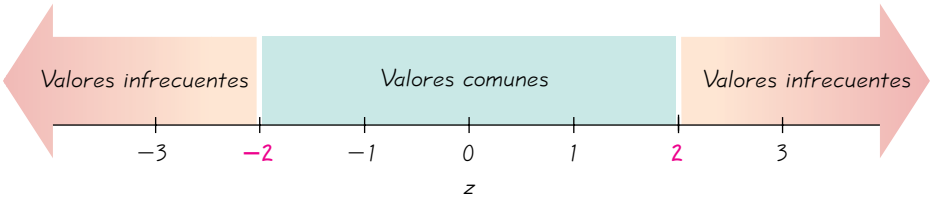


FIGURA 2-14
Interpretación de las puntuaciones *z*
Los valores infrecuentes son aquellos con puntuaciones *z* menores que −2.00 o mayores que 2.00.

los hombres tienen estaturas con una media de 69.0 pulgadas, con una desviación estándar de 2.8 pulgadas). Después de convertir 5 pies y 3 pulgadas a 63 pulgadas, convertimos su estatura en una puntuación *z* de la siguiente manera:

$$\text{Bogues: } z = \frac{x - \mu}{\sigma} = \frac{63 - 69.0}{2.8} = -2.14$$

Demos gracias a Mugsy Bogues por sus muchos años de juego inspirado y por ilustrar este principio:

Siempre que un valor sea menor que la media, su puntuación *z* correspondiente será negativa

Valores comunes: $-2 \leq z$ **puntuación** ≤ 2

Valores infrecuentes: z **puntuación** < -2 *o* z **puntuación** > 2

Las puntuaciones *z* son medidas de posición, en el sentido de que describen la localización de un valor (en términos de desviaciones estándar), en relación con la media. Una puntuación *z* de 2 indica que un valor está a dos desviaciones estándar *por encima* de la media, en tanto que una puntuación *z* de −3 indica que un valor está a tres desviaciones estándar *por debajo* de la media. Los cuartiles y los percentiles también son medidas de posición, pero se definen de forma distinta que las puntuaciones *z*; son útiles para comparar valores dentro del mismo conjunto de datos o entre distintos conjuntos de datos.

Cuartiles y percentiles

De la sección 2-4, recuerde que la mediana de un conjunto de datos es el valor que está a la mitad, de modo que 50% de los valores son iguales o menores a la mediana y el 50% de los valores son mayores o iguales a la mediana. Tal como la mediana divide los datos en dos partes iguales, los tres **cuartiles**, denotados por Q_1, Q_2 y Q_3, dividen los valores ordenados en cuatro partes iguales. (Los valores están *ordenados* cuando se acomodan en orden).

He aquí descripciones de los tres cuartiles:

Q_1 (Primer cuartil): Separa el 25% inferior de los valores ordenados, del 75% superior. (Para ser más precisos, al menos el 25% de los valores ordenados son menores o iguales que Q_1, y al menos el 75% de los valores son mayores o iguales que Q_1).

Q_2 (Segundo cuartil): Igual a la mediana; separa el 50% inferior de los valores ordenados, del 50% superior.

Q_3 (Tercer cuartil): Separa el 75% inferior de los valores ordenados, del 25% superior. (Para ser más precisos, al menos el 75% de los valores ordenados son menores o iguales que Q_3, y al menos el 25% de los valores son mayores o iguales que Q_3).

Describiremos un procedimiento para el cálculo de cuartiles después de analizar los percentiles. No existe un acuerdo universal respecto de un procedimiento

único para el cálculo de cuartiles, y con frecuencia los distintos programas de cómputo producen resultados diferentes. Por ejemplo, si usted utiliza un conjunto de datos 1, 3, 6, 10, 15, 21, 28 y 36, obtendrá los siguientes resultados:

	Q_1	Q_2	Q_3
STATDISK	4.5	12.5	24.5
Minitab	3.75	12.5	26.25
Excel	5.25	12.5	22.75
TI-83 Plus	4.5	12.5	24.5

Para este conjunto de datos, STATDISK y la calculadora TI-83 Plus coinciden, aunque esto no siempre sucede. Si utiliza una calculadora o un programa de cómputo para resolver ejercicios que comprenden cuartiles es posible que obtenga resultados que difieran ligeramente de las respuestas que vienen al final del libro.

Así como hay tres cuartiles que separan un conjunto de datos en cuatro partes, también se tienen 99 **percentiles**, que se denotan $P_1, P_2, \ldots, P_{99}$, los cuales separan los datos en 100 grupos, con aproximadamente el 1% de los valores en cada grupo. (Los cuartiles y percentiles son ejemplos de *cuantiles* o *fractiles*, que separan los datos en grupos con casi el mismo número de valores).

El proceso para calcular percentiles, que corresponde a un valor particular x, es bastante sencillo, tal como se indica en la siguiente expresión:

$$\text{percentil del valor } x = \frac{\text{número de valores menores que } x}{\text{número total de valores}} \cdot 100$$

EJEMPLO Niveles de cotinina de fumadores La tabla 2-13 lista los 40 niveles ordenados de cotinina de fumadores que se incluyen en la tabla 2-1. Calcule el percentil correspondiente al nivel de cotinina de 112.

SOLUCIÓN A partir de la tabla 2-13 se ve que hay dos valores menores que 112; por lo tanto,

$$\text{percentil de } 112 = \frac{12}{40} \cdot 100 = 30$$

INTERPRETACIÓN El nivel de cotinina de 112 es el percentil 30o.

El ejemplo anterior muestra cómo convertir un valor muestral dado a su percentil correspondiente. Existen diversos métodos para el procedimiento inverso de convertir un percentil en el valor correspondiente del conjunto de datos. El procedimiento que usaremos se resume en la figura 2-15, que emplea la notación que viene inmediatamente después.

Tabla 2-13 *Niveles ordenados de cotinina de 40 fumadores*

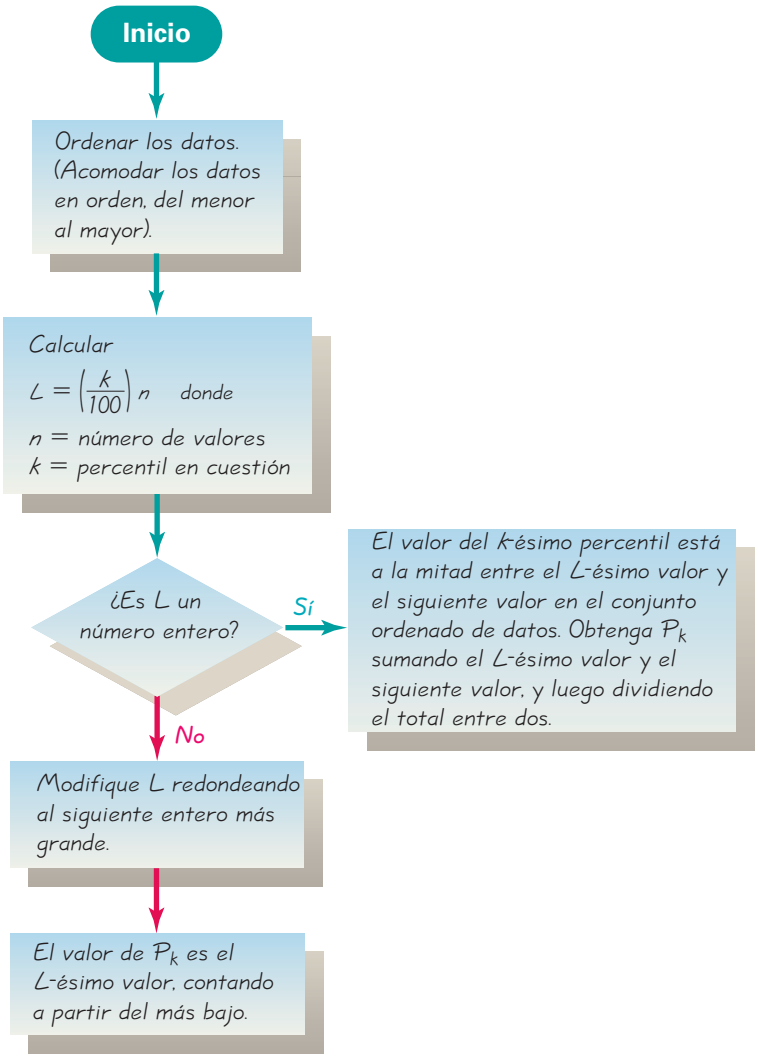
0	1	1	3	17	32	35	44	48	86
87	103	112	121	123	130	131	149	164	167
173	173	198	208	210	222	227	234	245	250
253	265	266	277	284	289	290	313	477	491



Índice del costo de la risa

En realidad hay un Índice del Costo de la Risa (ICR), que busca los costos de artículos como pollos de plástico, anteojos de Groucho Marx, entradas a clubes de comediantes y otros 13 indicadores principales del humor. Éste es el mismo método básico que se utiliza en la creación del Índice de Precios al Consumidor (IPC), que se basa en un promedio ponderado de bienes y servicios adquiridos por consumidores comunes. Mientras que las puntuaciones estándar y los percentiles nos permiten comparar valores diferentes, ignorando cualquier elemento del tiempo, los números índice, tales como el ICR y el IPC, nos permiten comparar el valor de alguna variable con su valor en un periodo base. El valor de un número índice es el valor real dividido entre el valor base, multiplicado por 100.

FIGURA 2-15 Conversión del *k*-ésimo percentil al valor del dato correspondiente



Notación

n = número total de valores en el conjunto de datos
k = percentil utilizado (ejemplo: para el percentil 25o, $k = 25$).
L = localizador que da la *posición* de un valor (ejemplo: para el valor 12o en la lista ordenada, $L = 12$).
P_k = percentil k-ésimo (ejemplo: P_{25} es el percentil 25o).



EJEMPLO Niveles de cotinina de fumadores Remítase a los niveles ordenados de cotinina de fumadores de la tabla 2-13, y utilice la figura 2-15 para calcular el valor del percentil 68o, P_{68}.

SOLUCIÓN Si nos referimos a la figura 2-15, veremos que los datos muestrales ya están ordenados, de modo que es posible proceder al cálculo del valor del localizador L. En el cálculo utilizamos $k = 68$, ya que estamos tratando de obtener el valor del percentil 68o. Usamos $n = 40$, porque tenemos 40 valores de datos.

$$L = \frac{k}{100} \cdot n = \frac{68}{100} \cdot 40 = 27.2$$

Después, nos preguntamos si L es un número entero; respondemos que no. Por lo tanto, procederemos al siguiente recuadro hacia abajo y modificamos L, redondeándola de 27.2 a 28. (En este libro solemos redondear de la forma común, pero es uno de los casos donde redondeamos hacia *arriba* y no hacia el entero *más cercano*). Por último, el recuadro final muestra que el valor de P_{68} es el valor 28o, contando hacia arriba, desde el mínimo. En la tabla 2-13, el valor 28o es 234. Es decir, $P_{68} = 234$.



EJEMPLO Niveles de cotinina de fumadores Remítase a la muestra de niveles de cotinina de fumadores que aparece en la tabla 2-13. Utilice la figura 2-15 para calcular el valor de Q_1, que es el primer cuartil.

SOLUCIÓN Primero observamos que Q_1 es igual que P_{25}, por lo que procedemos a calcular el valor del percentil 25o. Si nos referimos a la figura 2-15, veremos que los datos muestrales ya se ordenaron, de manera que procedemos a calcular el valor del localizador L. En este cálculo utilizamos $k = 25$, ya que tratamos de obtener el valor del percentil 25o y usamos $n = 40$, porque tenemos 40 valores de datos.

$$L = \frac{k}{100} \cdot n = \frac{25}{100} \cdot 40 = 10$$

Después, nos preguntamos si L es un número entero; respondemos que sí. Por lo tanto, vamos al recuadro que se ubica a la derecha. Vemos que el valor del percentil k-ésimo (25o) está a la mitad entre el valor L-ésimo (10o) y el siguiente valor en el conjunto original de datos. Es decir, el valor del percentil 25o se ubica a la mitad, entre el 10o valor y el 11o valor. El 10o valor es 86 y el 11o valor es 87; por lo tanto, el valor a la mitad de ellos es 86.5. Concluimos que el percentil 25o es $P_{25} = 86.5$. El valor del primer cuartil Q_1 es también 86.5.

El ejemplo anterior demuestra que al calcular un valor cuartilar (como Q_1), es posible utilizar el valor del percentil equivalente (como P_{25}) en su lugar. Al margen, se indican las relaciones equivalentes entre cuartiles y percentiles.

$Q_1 = P_{25}$
$Q_2 = P_{50}$
$Q_3 = P_{75}$

En secciones anteriores de este capítulo describimos diversos estadísticos, incluyendo media, mediana, moda, rango y desviación estándar. Algunos otros estadísticos se definen con el uso de cuartiles y percentiles, como los siguientes:

$$\text{rango intercuartilar (o RIC)} = Q_3 - Q_1$$

$$\text{rango semiintercuartilar} = \frac{Q_3 - Q_1}{2}$$

$$\text{cuartil medio} = \frac{Q_3 + Q_1}{2}$$

$$\text{rango de percentiles 10—90} = P_{90} - P_{10}$$

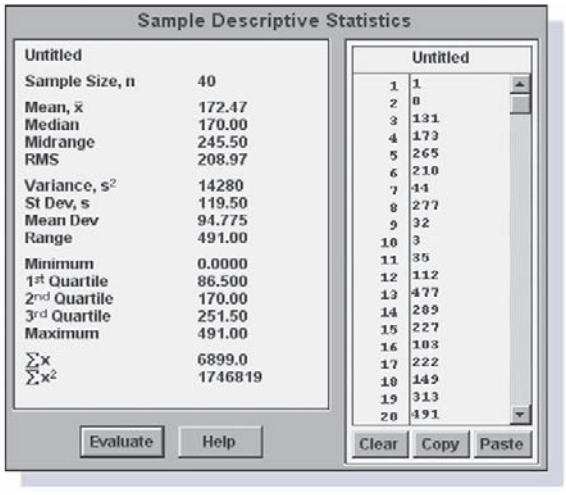
Después de completar esta sección, usted debe ser capaz de convertir un valor en su puntuación z (o puntuación estándar) correspondiente, de manera que sea posible compararlo con otros valores que provienen de diferentes conjuntos de datos. También tendrá que ser capaz de convertir un valor en su valor percentil correspondiente, de manera que pueda compararlo con otros valores en algún conjunto de datos. También sabrá convertir un percentil en su valor de dato correspondiente. Finalmente, comprenderá el significado de los cuartiles y podrá relacionarlos con sus valores percentiles correspondientes (como en $Q_3 = P_{75}$).



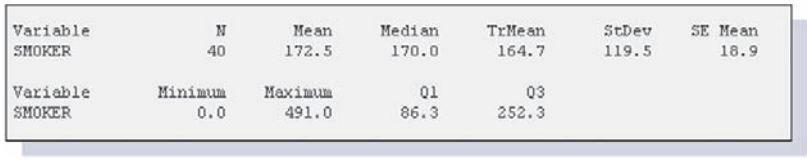
Utilizando la tecnología

Se puede utilizar una variedad de programas de cómputo y calculadoras diferentes para calcular muchos de los estadísticos estudiados hasta ahora en este capítulo. En la sección 2-4 dimos instrucciones específicas para el uso de STATDISK, Minitab, Excel y la calculadora TI-83 Plus. Señalamos que en ocasiones es posible introducir un conjunto de datos y utilizar una operación para obtener diversos estadísticos muestrales, frecuentemente llamados *estadísticos descriptivos*. En las siguientes representaciones visuales se mencionan ejemplos de tales resultados, los cuales provienen de los niveles de cotinina de *fumadores* que se presentaron en la tabla 2-1, en el problema del capítulo. Los resultados de la calculadora TI-83 Plus se muestran en dos pantallas, ya que no caben en una sola.

STATDISK



Minitab



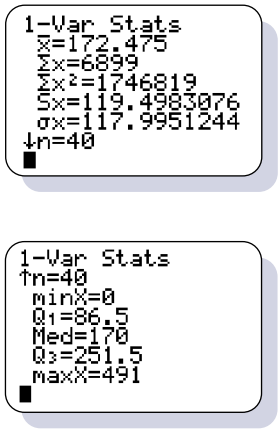
Variable	N	Mean	Median	TrMean	StDev	SE Mean
SMOKER	40	172.5	170.0	164.7	119.5	18.9

Variable	Minimum	Maximum	Q1	Q3
SMOKER	0.0	491.0	86.3	252.3

Excel

Column1	
Mean	172.475
Standard Error	18.89434
Median	170
Mode	1
Standard Deviation	119.4983
Sample Variance	14279.85
Kurtosis	0.519621
Skewness	0.587929
Range	491
Minimum	0
Maximum	491
Sum	6899
Count	40

TI-83 Plus



2-6 Destrezas y conceptos básicos

En los ejercicios 1 a 4 exprese todas las puntuaciones z con dos decimales.

1. Puntuaciones de CI Las puntuaciones de CI de la prueba Stanford Binet tienen una media de 100 y una desviación estándar de 16. Albert Einstein obtuvo un CI de 160.
- **a.** ¿Cuál es la diferencia entre el CI de Einstein y la media?
- **b.** ¿Cuántas desviaciones estándar implica esto [la diferencia obtenida en el inciso *a*)]?
- **c.** Convierta la puntuación de CI de Einstein a puntuación *z*.
- **d.** Si consideramos que las puntuaciones de CI "comunes" son aquellas que, convertidas en puntuaciones *z*, caen entre −2 y 2, ¿es el CI de Einstein común o infrecuente?

2. Pulso de adultos Suponga que los adultos tienen pulsos (latidos por minuto) con una media de 72.9 y una desviación estándar de 12.3 (con base en datos del National Health Examination). Cuando escribió este ejercicio, el autor tenía un pulso de 48.
- **a.** ¿Cuál es la diferencia entre el pulso del autor y la media?
- **b.** ¿Cuántas desviaciones estándar implica esto [la diferencia obtenida en el inciso *a*)]?
- **c.** Convierta el pulso de 48 a puntuación *z*.
- **d.** Si consideramos que los pulsos "comunes" son aquellos que, convertidos en puntuaciones *z*, caen entre −2 y 2, ¿es el pulso de 48 común o infrecuente? ¿Podría explicar por qué un pulso sería inusualmente bajo? (La razón de este pulso tan bajo *no* es que los autores de libros de estadística estén comúnmente en un estado que se describiría como comatoso).

3. Estaturas de hombres Las estaturas de hombres adultos tienen una media de 69.0 pulgadas y una desviación estándar de 2.8 pulgadas. Calcule las puntuaciones *z* que corresponden a los siguientes individuos:
- **a.** El actor Danny DeVito, que mide 5 pies.
- **b.** El jugador de basquetbol de la NBA, Shaquille O'Neal, que mide 7 pies 1 pulgada.
- **c.** El autor, quien es un "jugador" de golf y tenis, que mide 69.72 pulgadas.

4. Temperaturas corporales La temperatura corporal humana tiene una media de 98.20°F y una desviación estándar de 0.62°F. Convierta las temperaturas dadas a puntuaciones *z*.
a. 100° **b.** 96.96° **c.** 98.20°

En los ejercicios 5 a 8 exprese todas las puntuaciones z con dos decimales. Considere una puntuación como infrecuente si es menor que −2.00 o mayor que 2.00.

5. Estaturas de mujeres El Club Beanstalk es sólo para mujeres y hombres muy altos. La estatura mínima que se requiere en las mujeres es de 70 pulgadas. Las estaturas de las mujeres tienen una media de 63.6 pulgadas y una desviación estándar de 2.5 pulgadas. Calcule la puntuación *z* correspondiente a una mujer con una estatura de 70 pulgadas; después, determine si dicha estatura es infrecuente.

6. Duración del embarazo Una mujer, que escribió a *Dear Abby*, afirmó que dio a luz 308 días después de una visita de su esposo, que estaba en la marina. La duración del embarazo tiene una media de 268 días y una desviación estándar de 15 días. Calcule la puntuación *z* de 308 días. ¿Es infrecuente la duración? ¿Qué concluye?

7. Temperatura corporal La temperatura corporal humana tiene una media de 98.20°F y una desviación estándar de 0.62°F. Se descubre que un paciente de urgencias tiene una temperatura de 101°F. Convierta 101° en puntuación *z*. ¿Es la temperatura inusualmente alta? ¿Qué sugiere esto?

8. Niveles de colesterol Para hombres de entre 18 y 24 años de edad, los niveles séricos de colesterol (en mg/100ml) tienen una media de 178.1 y una desviación estándar de 40.7 (con base en datos del National Health Survey). Calcule la puntuación *z* correspondiente de un hombre de entre 18 y 24 años, quien presenta un nivel sérico de colesterol de 259.0 mg/100ml. ¿Es este nivel inusualmente alto?

9. Comparación de calificaciones de una prueba ¿Cuál es relativamente mejor: una calificación de 85 en una prueba de psicología o una calificación de 45 en una prueba de economía? Las calificaciones en la prueba de psicología tienen una media de 90 y una desviación estándar de 10. Las calificaciones en la prueba de economía tienen una media de 55 y una desviación estándar de 5.

10. Comparación de calificaciones Tres estudiantes resuelven pruebas equivalentes del sentido del humor; una vez que la risa disminuye, se calculan sus calificaciones. ¿Cuál es la calificación relativa más alta?
a. Una calificación de 144 en una prueba que tiene una media de 128 y una desviación estándar de 34.
b. Una calificación de 90 en una prueba que tiene una media de 86 y una desviación estándar de 18.
c. Una calificación de 18 en una prueba que tiene una media de 15 y una desviación estándar de 5.

T **11.** Peso de Coca Cola Remítase en el conjunto de datos 17 del Apéndice B, a la muestra de 36 pesos de Coca Cola regular. Convierta en peso de 0.7901 en puntuación *z*. ¿Es 0.7901 un peso inusual de la Coca Cola regular?

T **12.** M&M verdes Remítase en el conjunto de datos 19 del apéndice B, a la muestra de pesos de dulces M&M verdes. Convierta el peso del M&M verde más pesado en puntuación *z*. ¿Es infrecuente el peso del M&M verde más pesado en estos dulces?

2 *En los ejercicios 13 a 16 utilice los 40 niveles ordenados de cotinina de fumadores, listados en la tabla 2.13. Calcule el percentil correspondiente a los niveles de cotinina dados.*

13. 149 **14.** 210 **15.** 35 **16.** 250

2 *En los ejercicios 17 a 24 utilice los 40 niveles ordenados de cotinina de fumadores, listados en la tabla 2.13. Calcule el percentil o cuartil indicado.*

17. P_{20} **18.** Q_3 **19.** P_{75} **20.** Q_2
21. P_{33} **22.** P_{21} **23.** P_1 **24.** P_{85}

T *En los ejercicios 25 a 28 utilice los niveles de colesterol de mujeres listados en el conjunto de datos 1 del Apéndice B. Calcule el percentil correspondiente al nivel de colesterol dado.*

25. 123 **26.** 309 **27.** 271 **28.** 126

T *En los ejercicios 29 a 36 utilice los niveles de colesterol de mujeres listados en el conjunto de datos 1 del Apéndice B. Calcule el percentil o cuartil indicado.*

29. P_{85} **30.** P_{35} **31.** Q_1 **32.** Q_3

33. P_{18} **34.** P_{36} **35.** P_{58} **36.** P_{96}

2-6 Más allá de lo básico

37. Unidades de medición Cuando se calcula una puntuación z para la estatura de un jugador de basquetbol de la NBA, ¿de qué manera se afecta el resultado si, en lugar de utilizar pulgadas, todas las estaturas se expresan en centímetros? En general, ¿de qué manera se afectan las puntuaciones z por la unidad particular de medición que se utiliza?

38. Conversión de una puntuación z La estatura de las mujeres tiene una media de 63.6 pulgadas y una desviación estándar de 2.5 pulgadas.

a. Julia Roberts, que es una de las actrices más exitosas de los últimos años, tiene una estatura que, convertida a puntuación z, *es* de 2.16. ¿Qué tan alta es (en pulgadas)?

b. La cantante de rap Lil'Kim tiene una estatura que, convertida a puntuación z, *es* de -1.84. ¿Qué tan alta es (en pulgadas)?

39. Distribución de puntuaciones z

a. Un conjunto de datos tiene una distribución uniforme. Si todos los valores se convierten a puntuaciones z, ¿cuál es la forma de la distribución de las puntuaciones z?

b. Un conjunto de datos tiene una distribución normal. Si todos los valores se convierten a puntuaciones z, ¿cuál es la forma de la distribución de las puntuaciones z?

c. En general, ¿cómo se ve afectada la forma de una distribución si todos los valores se convierten en puntuaciones z?

40. Secuencia de Fibonacci Éstos son los primeros de muchos términos de la famosa secuencia de Fibonacci: 1, 1, 2, 3, 5, 8, 13.

a. Calcule la media $\bar{x}$ y la desviación estándar s; después, convierta cada valor a puntuación z. No redondee las puntuaciones z. Ocupe tantos datos como su calculadora pueda manejar.

b. Calcule la media y la desviación estándar de las puntuaciones z que se obtuvieron en el inciso *a*).

c. Si utilizara cualquier otro conjunto de datos, ¿obtendría los mismos resultados que en el inciso *b*)?

2 **41.** Niveles de cotinina de fumadores Utilice los niveles ordenados de cotinina de fumadores que se listan en la tabla 2-3.

a. Calcule el rango intercuartilar.

b. Calcule el cuartil medio.

c. Calcule el rango de percentiles 10-90.

d. ¿Es $P_{50} = Q_2$? Si es así, ¿es P_{50} *siempre* igual a Q_2?

e. ¿Es $Q_2 = (Q_1 + Q_3)/2$? Si es así, ¿es Q_2 *siempre* igual a $(Q_1 + Q_3)/2$?

T **42.** Interpolación Cuando se calculan percentiles con el uso de la figura 2-15, si el localizador L no es un número entero, lo redondeamos hacia el siguiente número entero mayor. Una alternativa para este procedimiento es interpolar, de modo que un localizador de 23.75 conduce a un valor que está a 0.75 (o 3/4) del camino entre los valores 23o y 24o. Utilice este método de interpolación para calcular P_{35} y Q_1 para los pesos de los osos que se listan en el conjunto de datos 9 del Apéndice B.

43. Deciles y cuartiles En un conjunto de datos hay nueve **deciles**, que se denotan con D_1, D_2, . . . ,D_9, que dividen los datos ordenados en 10 grupos, con aproximadamente 10% de los valores en cada grupo. También existen cuatro **quintiles**, que dividen los datos ordenados en cinco grupos, con aproximadamente 20% de los valores en cada grupo. (Note la diferencia entre los quintiles y los cuartiles, que ya describimos en esta sección).

a. ¿Qué percentil es equivalente a D_1? ¿A D_5? ¿A D_8?

b. Utilice los niveles ordenados de cotinina de fumadores de la tabla 2-13 y calcule los nueve deciles.

c. Utilice los niveles ordenados de cotinina de fumadores de la tabla 2-13 y calcule los cuatro quintiles.

2-7 Análisis exploratorio de datos (AED)

El presente capítulo presenta las herramientas básicas para describir, explorar y comparar datos; esta sección se enfoca en la exploración de datos. Iniciamos definiendo el análisis exploratorio de datos; después, introduciremos los datos distantes, el resumen de 5 números y las gráficas de cuadro.

Definición

Análisis exploratorio de datos: proceso para utilizar herramientas estadísticas (como gráficas, medidas de tendencia central y medidas de variación), con la finalidad de investigar conjuntos de datos para comprender sus características importantes.

Recuerde que en la sección 2-1 mencionamos cinco características importantes de los datos, y que iniciamos con **1.** *el centro*, **2.** *la variación*, y **3.** la naturaleza de la *distribución*. Tales características pueden investigarse calculando los valores de la media y la desviación estándar, así como por medio de la construcción de un histograma. Por lo general, es importante investigar más el conjunto de datos para identificar cualquier particularidad notable, en especial aquélla que llegue a afectar de forma importante los resultados y las conclusiones. Una de estas características es la presencia de datos distantes.

Datos distantes

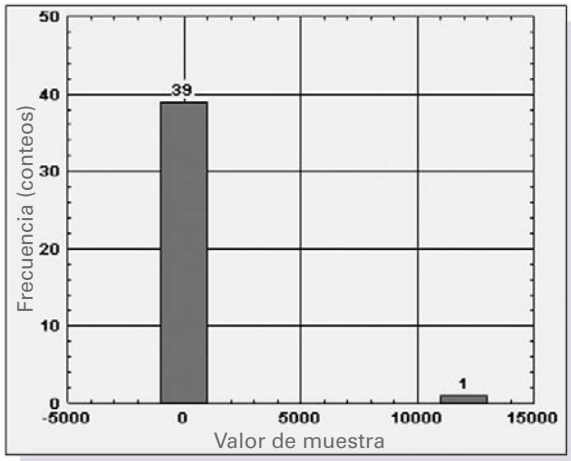
Dato distante: valor que está muy alejado de la mayoría de los demás valores. Un dato distante es un valor *extremo* en relación con los otros datos. Cuando se explora un conjunto de datos, se deben considerar los datos distantes, ya que pueden revelar información importante y afectar, en gran medida, el valor de la media y de la desviación estándar, así como distorsionar gravemente un histograma. El siguiente ejemplo utiliza un valor incorrecto para un dato distante; aunque no todos los datos distantes son errores, algunos de ellos son valores correctos.

EJEMPLO Niveles de cotinina de fumadores Cuando se utiliza un programa de cómputo o una calculadora, es muy fácil cometer errores con los dedos. Remítase a los niveles de cotinina de fumadores que se listan en la tabla 2-1, en el problema del capítulo; suponga que

el primer dato de 1 se introduce de manera incorrecta como 11111, porque usted estaba distraído viendo un meteorito que aterrizaba en su jardín. El dato incorrecto de 11111 es un dato distante, ya que se localiza muy lejos de los demás valores. ¿De qué manera afecta ese dato distante a la media, a la desviación estándar y al histograma?

SOLUCIÓN Cuando el dato 1 se reemplaza con el valor distante de 11111, la media cambia de 172.5 a 450.2, de modo que el efecto del dato distante es muy grande. El dato incorrecto de 11111 causa que la desviación estándar cambie de 119.5 a 1732.7, por lo que el efecto del dato distante también es muy grande. La figura 2-1, en la sección 2-3, muestra el histograma con los valores correctos de los niveles de cotinina de fumadores de la tabla 2-1, pero la representación visual del STATDISK que se muestra aquí, contiene el histograma que resulta del uso de los mismos datos con el valor de 1, reemplazado por el valor incorrecto de 11111. Compare el histograma del STATDISK con la figura 2-1 y verá fácilmente que la presencia del dato distante afecta de manera drástica la forma de la distribución.

STATDISK



El ejemplo anterior ilustra estos principios importantes:

1. **Un dato distante puede tener un efecto importante sobre la media.**
2. **Un dato distante puede tener un efecto importante sobre la desviación estándar.**
3. **Un dato distante puede tener un efecto importante sobre la escala del histograma, de modo que la verdadera naturaleza de la distribución se oculta totalmente.**

Un procedimiento sencillo para encontrar datos distantes es el examen de una lista *ordenada* de los datos. En particular, observe los valores mínimo y máximo muestrales; luego, determine si se alejan mucho de los demás valores. Algunos datos distantes son valores correctos y algunos son errores, como en el ejemplo anterior. Si estamos seguros de que un dato distante es un error, debemos corregirlo o eliminarlo. Si incluimos un dato distante, porque sabemos que es correcto, podríamos estudiar sus efectos por medio de la construcción de gráficas y el cálculo de estadísticos que incluyan y que no incluyan los datos distantes.



Una propina extrema

Es importante tomar en cuenta los datos distantes ya que, en muchos casos, un valor extremo puede tener un efecto muy importante en los estadísticos y en las conclusiones que se derivan de ellos. A veces un dato distante es un error que debe ser corregido o eliminado. En otros, un dato distante es un valor válido que debe investigarse para obtener información importante. Algunos alumnos del autor, al reunir datos consistentes de facturas y propinas de restaurantes, no encontraron datos distantes sobresalientes en esos valores muestrales. Sin embargo, un dato distante es la propina de 16,000 dólares que se dio por una cuenta de 8,899.78 dólares en un restaurante. Esta propina la dio un ejecutivo de Londres no identificado al mesero Lenny Lorando, en el restaurante Nello's, ubicado en la ciudad de Nueva York. Lorando dijo que ya antes había atendido al cliente y que "él siempre es generoso, pero nunca antes de esta forma. Tengo que hablarle a mi hermana acerca de él".



Buen consejo para los periodistas

El columnista Max Frankel escribió en el *New York Times* que "la mayoría de las escuelas de periodismo dan poca importancia a la estadística y algunas permiten que los estudiantes se gradúen sin entrenamiento alguno en números. ¿Cómo pueden estos reporteros escribir con sensibilidad sobre el comercio, la asistencia social y el crimen, o sobre tarifas aéreas, la atención a la salud y la nutrición? El uso sentimental que hacen los medios de comunicación de los números acerca de la incidencia de accidentes o muertes atemoriza a las personas y las deja vulnerables a las exageraciones periodísticas, la demagogia política y el fraude comercial". Este escritor cita varios casos, incluyendo el ejemplo de un artículo de página completa acerca del déficit de la ciudad de Nueva York con la promesa del alcalde de cubrir el déficit presupuestal de 2.7 mil millones de dólares; en el artículo nunca se menciona el tamaño *total* del presupuesto, de modo que la cifra de 2.7 mil millones de dólares está fuera de contexto.

Gráficas de cuadro

Además de las gráficas presentadas en la sección 2.3, una gráfica de cuadro es otro tipo de gráfica que se utiliza a menudo. Las gráficas de cuadro son útiles para revelar la tendencia central de los datos, su dispersión, su distribución y la presencia de datos distantes. La construcción de una gráfica de cuadro requiere que primero se obtenga el valor mínimo, el valor máximo y los cuartiles, tal como se define en el resumen de los cinco números.

Definiciones

Para un conjunto de datos, el **resumen de los cinco números** consiste en el valor mínimo; el primer cuartil, Q_1; la mediana (o segundo cuartil, Q_2); el tercer cuartil, Q_3; y el valor máximo.

Gráfica de cuadro (o **diagrama de cuadro y bigotes**): gráfica de un conjunto de datos que consiste en una línea que se extiende desde el valor mínimo hasta el valor máximo, así como una caja con líneas trazadas en el primer cuartil, Q_1; la mediana y el tercer cuartil, Q_3. (Véase la figura 2-16).

Procedimiento para construir una gráfica de cuadro

1. Elabore el resumen de los cinco números, consistente en el valor mínimo, Q_1, la mediana, Q_3, y el valor máximo.
2. Construya una escala con valores que incluyan el valor mínimo y el valor máximo.
3. Construya un cuadro (un rectángulo) que se extienda desde Q_1 hasta Q_3, y dibuje una línea en la caja, en el valor de la mediana.
4. Dibuje líneas que se extiendan hacia afuera del cuadro, hasta los valores mínimo y máximo.

Las gráficas de cuadro no muestran tanta información detallada como los histogramas o las gráficas de tallo y hojas, por lo que podría no ser la mejor elección cuando se maneja un solo conjunto de datos. Suelen ser muy útiles para comparar dos o más conjuntos de datos. Cuando se utilicen dos o más gráficas de cuadro para comparar distintos conjuntos de datos, es importante emplear la misma escala, de manera que sea posible realizar comparaciones correctas.



EJEMPLO Niveles de cotinina de fumadores Remítase a los 40 niveles de cotinina de fumadores en la tabla 2-1 (sin el error de 11111 utilizado en lugar del 1 en el ejemplo anterior).

a. Obtenga los valores que constituyen el resumen de los cinco números.

b. Construya una gráfica de cuadro.

SOLUCIÓN

a. El resumen de los cinco números consta del valor mínimo, Q_1, la mediana, Q_3, y el valor máximo. Para obtener dichos valores, primero ordene los datos (acomódelos en orden del más bajo al más alto). El mínimo de 0 y el máximo de 491 son fáciles de identificar en la lista ordenada. Ahora, proceda a calcular

los cuartiles. Si usamos el diagrama de flujo de la figura 2-15, obtendremos $Q_1 = P_{25} = 86.5$, que se sitúa al calcular el localizador $L = (25/100)40 = 10$, y al encontrar el valor que está a la mitad entre el 10o y el 11o valores en la lista ordenada. La mediana es 170, que es el valor que está a la mitad entre los valores 20o y 21o. También encontramos que $Q_3 = 251.5$, al utilizar la figura 2.15 para el percentil 75o. Por lo tanto, el resumen de los cinco números es 0, 86.5, 170, 251.5 y 491.

b. En la figura 2-16 creamos la gráfica de cuadro para los datos. Usamos el valor mínimo (0) y el valor máximo (491) para determinar la escala de valores; después, graficamos los valores del resumen de los cinco números, como se indica a continuación.

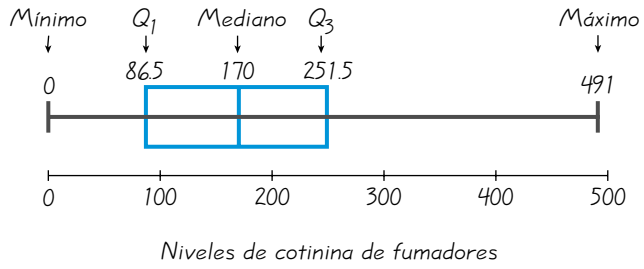


FIGURA 2-16
Gráfica de cuadro

En la figura 2-17, presentamos algunas gráficas de cuadro genéricas, junto con formas comunes de distribución. Parece ser que los niveles de cotinina de fumadores tienen una distribución sesgada.

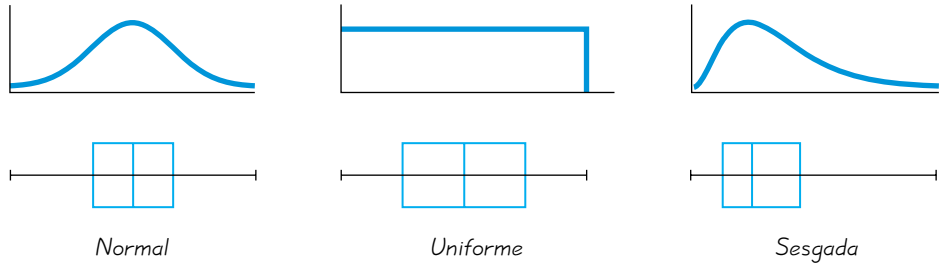
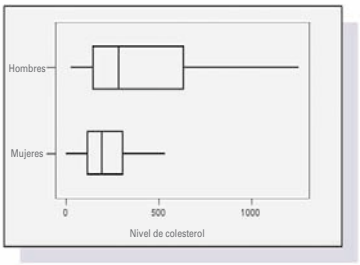


FIGURA 2-17 Gráficas de cuadro que corresponden a distribuciones normales, uniformes y sesgadas

Para ilustrar el uso de gráficas de cuadro que permiten comparar conjuntos de datos, véase la representación visual de Minitab de los niveles de colesterol para una muestra de hombres y una muestra de mujeres, con base en datos del National Health Examination, que se incluyen en el conjunto de datos 1 del Apéndice B. De acuerdo con el conjunto de datos, parece que los hombres tienen niveles de colesterol generalmente más altos que las mujeres, y que los niveles de colesterol de los hombres varían más que los de las mujeres.



LA ESTADÍSTICA EN LAS NOTICIAS

"Mejores" universidades

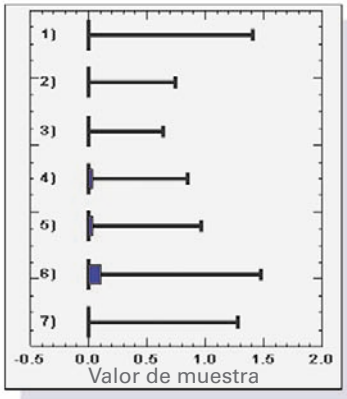
Cada año, el *U.S. News and World Report* publica un número con una lista de "las mejores universidades de Estados Unidos". Generalmente las ventas de ese ejemplar aumentan hasta un 40%. Existen críticos de la lista que argumentan en contra de los criterios y el método de recolección de datos. Las quejas más comunes son: que se da demasiada importancia a los criterios de riqueza, la reputación, las calificaciones del consejo universitario, las donaciones de los alumnos y las opiniones de los presidentes universitarios; que se da poca importancia a la satisfacción de los estudiantes y a las prácticas educativas efectivas. El *New York Times* entrevistó a Kenneth Auchincloss, que es editor de la obra *How to Get into College* (de Kaplan/Newsweek), quien respondió que "nunca nos hemos sentido cómodos tratando de cuantificar en términos numéricos los diversos criterios empleados al calificar a una universidad como buena o menos buena, y no queremos dedicar los recursos a realizar un análisis estadístico elaborado que, con franqueza, no pensamos que sea válido".

EJEMPLO ¿Llueve más durante los fines de semana? Remítase al conjunto de datos 11 del Apéndice B, que incluye una lista de las cantidades de lluvia (en pulgadas) que cayeron en Boston todos los días de un año reciente. La reunión de este conjunto de datos se inspiró con reportes de los medios de comunicación acerca de que llueve más durante los fines de semana (sábado y domingo) que entre semana. Más adelante, en este libro, describiremos métodos estadísticos importantes que permitan probar, de manera formal, dicha aseveración; por ahora, exploremos el conjunto de datos, para ver qué puede aprenderse. (Aun cuando sepamos aplicar estos métodos estadísticos formales, primero habrá que explorar los datos, antes de proceder con el análisis formal.)

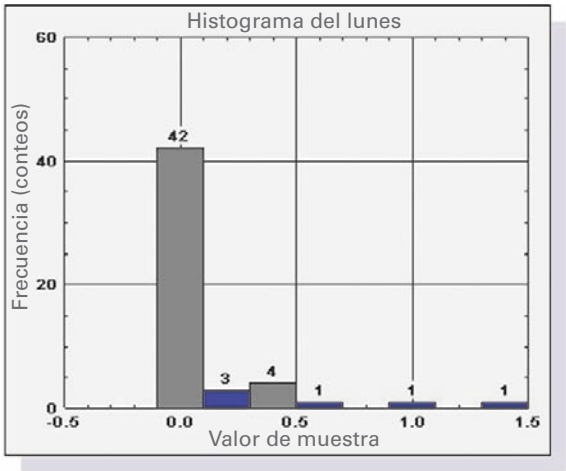
SOLUCIÓN Comencemos investigando los elementos clave del centro, la variación, la distribución, los datos distantes y las características en el tiempo (la misma lista "CVDDT" que se introdujo en la sección 2-1). Abajo se presentan medidas de tendencia central (media), medidas de variación (desviación estándar) y el resumen de los cinco números para las cantidades de lluvia que caen cada día de la semana. La representación visual del STATDISK muestra gráficas de cuadro de cada uno de los siete días de la semana, iniciando con el lunes en la parte superior. Debido a que los histogramas de los siete días son muy similares, únicamente mostramos el histograma de las cantidades de lluvia del lunes.

	Media	Desviación estándar	Mínimo	Q_1	Mediana	Q_3	Máximo
Lunes	0.100	0.263	0.000	0.000	0.000	0.010	1.410
Martes	0.058	0.157	0.000	0.000	0.000	0.015	0.740
Miércoles	0.051	0.135	0.000	0.000	0.000	0.010	0.640
Jueves	0.069	0.167	0.000	0.000	0.000	0.040	0.850
Viernes	0.095	0.228	0.000	0.000	0.000	0.040	0.960
Sábado	0.143	0.290	0.000	0.000	0.000	0.100	1.480
Domingo	0.068	0.200	0.000	0.000	0.000	0.010	1.280

STATDISK



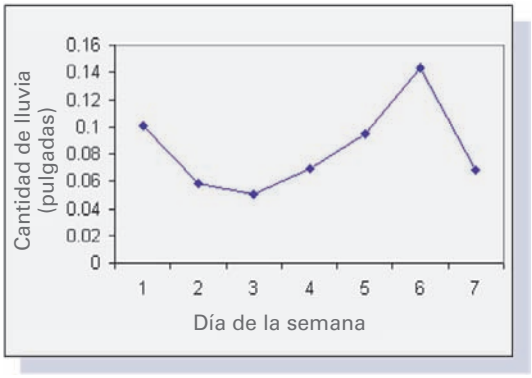
STATDISK



INTERPRETACIÓN Al examinar y comparar los estadísticos y las gráficas, hicimos las siguientes observaciones importantes:

- *Medias*: Las medias varían desde un mínimo de 0.051 pulgadas hasta un máximo de 0.143 pulgadas. Las siete medias varían en cantidades considerables. En capítulos siguientes presentaremos métodos para determinar si tales diferencias son *significativas*. (Métodos posteriores mostrarán que las medias no difieren en cantidades significativas). Si colocamos las medias en orden de menor a mayor, obtendremos la siguiente secuencia de días: miércoles, martes, domingo, jueves, viernes, lunes, sábado. No parece haber un patrón de mayor cantidad de lluvia durante los fines de semana (aunque la media más alta corresponde al sábado). Además, observe la gráfica de Excel de las siete medias, en donde la media del lunes se graficó primero. La gráfica de Excel no apoya la aseveración de mayor cantidad de lluvia durante los fines de semana (aunque podría argumentarse que llueve más los sábados).

Excel



- *Variación*: Las siete desviaciones estándar varían de 0.135 pulgadas a 0.290 pulgadas, pero estos valores no son muy diferentes. No parece haber algo infrecuente en las cantidades de variación.
- Los *mínimos*, *primeros cuartiles* y *medianas* son todos iguales a 0.00 para cada uno de los siete días. Lo anterior se explica por el hecho de que por cada día de la semana hay muchos días en los que no llueve. La abundancia de ceros también se observa en las gráficas de cuadro y en los histogramas, los cuales muestran que los datos tienen distribuciones cargadas hacia el extremo de los mínimos (sesgo derecho).
- *Datos distantes*: No aparecen datos distantes o valores inusuales. En el extremo de los mínimos hay muchas cantidades de lluvia iguales a cero. En el extremo de los máximos, la lista en que se ordenan las 365 cantidades de lluvia termina con los valores máximos de 0.92, 0.96, 1.28, 1.41 y 1.48.
- *Distribuciones*: Las distribuciones de las cantidades de lluvia están sesgadas hacia la derecha. No son normales, como esperaríamos. Si el uso de un método particular de estadística requiere poblaciones distribuidas normalmente (en forma de campana), este requisito no se satisface en las cantidades de lluvia.

Ahora comprendemos en gran medida la naturaleza de las cantidades de lluvia que caen en Boston durante distintos días de la semana. Con base en nuestra exploración, concluimos que en Boston no cae más lluvia durante los fines de semana que los demás días (aunque podríamos argumentar que llueve más los sábados).

Pensamiento crítico

Si nos armamos con una lista de herramientas para investigar el centro, la variación, la distribución, los datos distantes y las características de los datos a través del tiempo, tendríamos la tentación de desarrollar un procedimiento descuidado, por lo que el pensamiento crítico es sumamente importante. Además de utilizar las herramientas que se presentan en este capítulo, deberemos considerar cualesquiera otros factores que puedan ser cruciales para las conclusiones que elaboremos. En tal caso, plantearíamos preguntas como las siguientes: ¿Es posible que la muestra sea representativa de la población o está sesgada de alguna manera? ¿Cuál es la fuente de los datos? ¿Sería posible que la fuente fuera alguien con intereses que puedan afectar la calidad de los datos? Suponga, por ejemplo, que deseamos estimar el ingreso medio de estudiantes universitarios. También, suponga que enviamos por correo cuestionarios a 500 estudiantes y que recibimos 20 respuestas. Podríamos calcular la media y la desviación estándar, así como construir gráficas, identificar datos distantes, etcétera, pero los resultados serán lo que los estadísticos llaman desperdicios. La muestra es de respuesta voluntaria, por lo que no tiene posibilidades de ser representativa de la población de todos los estudiantes universitarios. Además de las herramientas estadísticas específicas presentadas en este capítulo, ¡también debemos *pensar*!



Utilizando la tecnología

Esta sección introdujo los datos distantes, los resúmenes de los cinco números y las gráficas de cuadro. Para encontrar datos distantes, se acomodan los datos en orden de menor a mayor; después, se examinan los valores máximo y mínimo para determinar si están muy lejos de los otros valores muestrales. El STATDISK, Minitab, Excel y la calculadora TI-83 Plus proporcionan valores de cuartiles, de modo que es fácil elaborar el resumen de los cinco números. El STATDISK, Minitab, Excel y la calculadora TI-83 Plus pueden utilizarse para crear gráficas de cuadro. Ahora describiremos los distintos procedimientos. (*Precaución*: Recuerde que los valores cuartilares calculados por medio de Minitab y la calculadora TI-83 Plus pueden diferir ligeramente de los calculados a partir de la figura 2-15, por lo que tal vez las gráficas de cuadro también difieran ligeramente).

STATDISK Elija el elemento **Data** del menú principal, y utilice el **Sample Editor** para introducir los datos; después, haga clic en **COPY**. Ahora seleccione **Data**, luego **Boxplot,** y haga clic en **PASTE** y en **Evaluate**.

Minitab Introduzca los datos en la columna C1; luego, seleccione **Graph** y **Boxplot**. Introduzca C1 en la primera celda, debajo de la columna Y; luego, haga clic en **OK**.

Excel Aunque Excel no se diseñó para generar gráficas de cuadro, éstas pueden crearse utilizando el Data Desk XL add-in, que complementa este libro. Primero introduzca los datos en la columna A. Haga clic en **DDXL** y seleccione **Charts y Plots.** Estando en la función Type, elija la opción de **Boxplot**. En el cuadro de diálogo, haga clic en el icono del lápiz e introduzca el rango de datos, como A1:A40, si usted tiene 40 valores listados en la columna A. Haga clic en **OK**. El resultado es una gráfica de cuadro modificada, tal como se describe en el ejercicio 13. También se muestran los valores del resumen de los cinco números.

TI-83 Plus Introduzca los datos muestrales en la lista L1. Ahora seleccione **STAT PLOT,** presionando la segunda tecla después de la tecla denominada Y =. Presione la tecla **ENTER**, después seleccione la opción **ON** y elija el tipo de gráfica de cuadro que se ubica a la mitad el segundo renglón. Xlist debe indicar L1 y el valor Freq tiene que ser 1. Ahora presione la tecla **ZOOM** y elija la opción 9 para **ZoomStat**. Presione la tecla **ENTER**; debe aparecer la gráfica de cuadro. Puede utilizar las teclas con flechas para moverse hacia la derecha o hacia la izquierda, de manera que le sea posible leer los valores desde la escala horizontal.

2-7 Destrezas y conceptos básicos

1. Lotería Remítase al conjunto de datos 26 y utilice sólo los 40 dígitos en la primera columna de los resultados *Win 4* de la lotería del estado de Nueva York (9, 7, 0, etcétera). Encuentre el resumen de los cinco números y construya una gráfica de cuadro. ¿Qué características de la gráfica de cuadro sugieren que los dígitos fueron seleccionados con un procedimiento aleatorio y justo?

2. Presupuestos de películas Remítase al conjunto de datos 21 del Apéndice B, con los montos de presupuesto de las 15 películas con clasificación R. Elabore el resumen de los cinco números y construya una gráfica de cuadro. Determine si los valores muestrales son representativos de las películas realizadas este año.

3. Calorías de cereales Remítase al conjunto de datos 16 del Apéndice B de los 16 valores de las calorías por gramo de cereales. Elabore el resumen de los cinco números y construya una gráfica de cuadro. Determine si los valores muestrales serían representativos de los cereales consumidos por la población en general.

4. Nicotina en cigarrillos Remítase al conjunto de datos 5 de las 29 cantidades de nicotina (en miligramos por cigarrillo). Elabore el resumen de los cinco números y construya una gráfica de cuadro. ¿Podrían los valores muestrales ser representativos de los cigarrillos fumados por un consumidor individual?

5. M&M rojos Remítase al conjunto de datos 9 de los 21 pesos (en gramos) de los dulces M&M rojos. Elabore el resumen de los cinco números y construya una gráfica de cuadro. ¿Podrían los valores muestrales ser representativos de los dulces M&M de todos los colores?

T 6. Longitudes de osos Remítase al conjunto de datos 9 de las longitudes (en pulgadas) de los 54 osos que anestesiamos y medimos. Elabore el resumen de los cinco números y construya una gráfica de cuadro. ¿Podría la distribución de longitudes ser simétrica? ¿O está sesgada?

T 7. Alcohol en películas infantiles Remítase al conjunto de datos 7 de las 50 duraciones (en segundos) de escenas que presentan consumo de alcohol en películas infantiles de dibujos animados. Elabore el resumen de los cinco números y construya una gráfica de cuadro. Con base en la gráfica de cuadro, ¿la distribución parece simétrica o está sesgada?

T 8. Temperaturas corporales Remítase al conjunto de datos 4 del Apéndice B de las 106 temperaturas corporales a las 12 a. m. del día 2. Elabore el resumen de los cinco números y construya una gráfica de cuadro; después, determine si los valores muestrales apoyan la creencia común de que la temperatura corporal media es de 98.6°F.

En los ejercicios 9 a 12 elabore los resúmenes de los cinco números, construya gráficas de cuadro y compare los conjuntos de datos.

9. Premios Óscar En el artículo "Ages of Oscar Winning Best Actors and Actresses" (revista *Mathematics Teacher*), de Richard Brown y Gretchen Davis, los autores comparan las edades de actores y actrices en el momento de ganar el Óscar. En la siguiente tabla se presentan los resultados de los ganadores de ambas categorías. Utilice gráficas de cuadro para comparar los dos conjuntos de datos.

Actores:	32	37	36	32	51	53	33	61	35	45	55
	39	76	37	42	40	32	60	38	56	48	48
	40	43	62	43	42	44	41	56	39	46	31
	47	45	60	46	40	36					
Actrices:	50	44	35	80	26	28	41	21	61	38	49
	33	74	30	33	41	31	35	41	42	37	26
	34	34	35	26	61	60	34	24	30	37	31
	27	39	34	26	25	33					

T 10. Coca Cola regular/Coca Cola dietética Remítase al conjunto de datos 17 del Apéndice B; utilice los pesos de la Coca Cola regular y los pesos de la Coca Cola dietética. ¿Parece haber una diferencia significativa? Si es así, ¿qué explicación le encuentra?

T **11.** Niveles de cotinina Remítase a la tabla 2-1 ubicada en el problema del capítulo. Ya calculamos que el resumen de los cinco números para los niveles de cotinina de fumadores es 0, 86.5, 170, 251.5 y 491. Elabore los resúmenes de los cinco números para los otros dos grupos; después, construya las tres gráficas de cuadro utilizando la misma escala. ¿Existe alguna diferencia aparente?

T **12.** Clancy, Rowling, Tolstoi Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones de la escala de facilidad de lectura de Flesch para las páginas muestra de las obras *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. (Las puntuaciones más altas indican una lectura más fácil). ¿Parece haber alguna diferencia en la facilidad de lectura? ¿Son los resultados consistentes con sus expectativas?

2-7 Más allá de lo básico

2 **13.** Las gráficas de cuadro introducidas en esta sección suelen denominarse gráficas de cuadro *de esqueleto* (o *regulares*). Las **gráficas de cuadro modificadas** se construyen de la siguiente forma:

a. Calcule el *RIC*, que denota el rango intercuartilar, definido por $RIC = Q_3 - Q_1$.

b. Dibuje el cuadro con la mediana y los cuartiles como siempre; pero, cuando trace las líneas a la derecha e izquierda del cuadro, dibújelas sólo hasta los puntos que corresponden a los valores máximo y mínimo, que están dentro de 1.5 *RIC* del cuadro.

c. Los **datos ligeramente distantes**, que se grafican como puntos *sólidos*, son valores que están por debajo de Q_1 o por arriba de Q_3, por una cantidad mayor que 1.5 *RIC*, pero no mayor que 3 *RIC*. Es decir, los datos ligeramente distantes son valores x, tales que

$$Q_1 - 3\ RIC \leq x < Q_1 - 1.5\ RIC$$

o

$$Q_3 + 1.5\ RIC < x \leq Q_3 + 3\ RIC$$

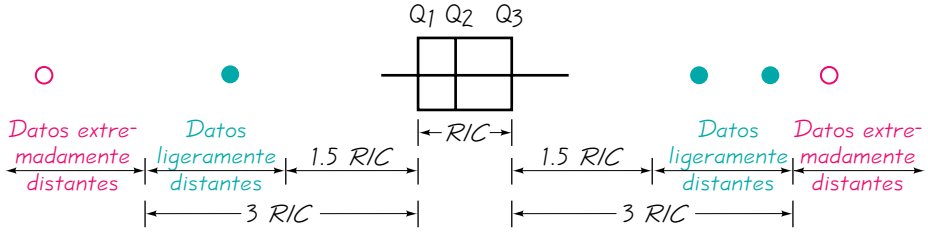
d. Los **datos extremadamente distantes**, que se grafican como pequeños círculos *vacíos*, son valores que están por debajo de Q_1 por más de 3 *RIC* o por encima de Q_3 por más de 3 *RIC*. Es decir, los datos extremadamente distantes son valores x, tales que

$$x < Q_1 - 3\ RIC$$

o

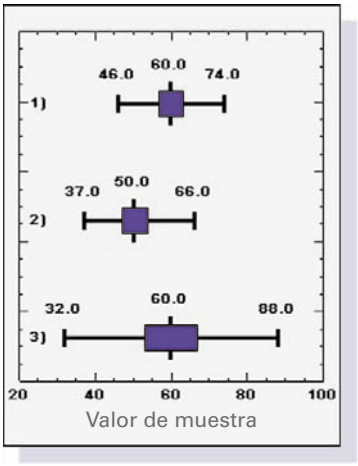
$$x > Q_3 + 3\ RIC$$

La figura anexa es un ejemplo de una gráfica de cuadro modificada. Remítase a los niveles de cotinina de fumadores de la tabla 2-1, incluida en el problema del capítulo. Ya sabemos que este conjunto de datos tiene un resumen de los cinco números de 0, 86.5, 170, 251.5 y 491. Identifique el valor de *RIC*, identifique los rangos de valores utilizados para localizar sus datos ligeramente distantes y extremadamente distantes; después, identifique cualesquiera datos ligeramente distantes y extremadamente distantes reales.



14. Remítase a la representación visual de STATDISK, de las tres gráficas de cuadro que representan la medida de longevidad (en meses) de muestras de tres distintas baterías para automóvil. Si usted es el encargado de una flotilla de automóviles y debe seleccionar una de las tres marcas, ¿cuál gráfica de cuadro representa la marca que debería elegir? ¿Por qué?

STATDISK



Repaso

En este capítulo consideramos métodos para describir, explorar y comparar conjuntos de datos. Cuando se investigan conjuntos de datos, las siguientes características son, por lo general, muy importantes:

1. *Centro*: Un valor representativo o promedio.
2. *Variación*: Una medida de la cantidad en que varían los valores.
3. *Distribución*: La naturaleza o forma de la distribución de los datos (como normal, uniforme o sesgada).
4. *Datos distantes*: Valores muestrales que se ubican muy lejos de la mayoría de valores muestrales.
5. *Tiempo*: Características cambiantes de los datos a través del tiempo.

Después de completar este capítulo, usted será capaz de hacer lo siguiente:

- Resumir datos por medio de la construcción de una distribución de frecuencias o de una distribución de frecuencias relativas (sección 2-2).
- Representar visualmente la naturaleza de la distribución por medio de la construcción de un histograma, una gráfica de puntos, una gráfica de tallo y hojas, una gráfica circular o una gráfica de Pareto (sección 2-3).
- Calcular medidas de tendencia central como la media, la mediana, la moda y la mitad del rango (sección 2-4).
- Calcular medidas de variación como la desviación estándar, la varianza y el rango (sección 2-5).
- Comparar valores individuales utilizando puntuaciones z, cuartiles o percentiles (sección 2-6).
- Investigar y explorar la dispersión de los datos, el centro de los datos y el rango de los valores por medio de la construcción de una gráfica de cuadro (sección 2-7).

Además de crear dichas tablas, gráficas y medidas, usted será capaz de comprender e interpretar los resultados. Por ejemplo, debe entender con claridad que la desviación estándar es una medida acerca de qué tanto varían los datos, y saber utilizar la desviación estándar para distinguir entre valores frecuentes e infrecuentes.

Ejercicios de repaso

1. Edades de presidentes La senadora Hayes está considerando competir por la presidencia de Estados Unidos, pero sólo tiene 35 años de edad, que es la edad mínima requerida. Al investigar este tema, descubre las edades de presidentes anteriores en el momento de tomar el cargo; dichas edades se listan abajo. Utilice las edades y calcule *a*) la media; *b*) la mediana; *c*) la moda; *d*) la mitad del rango; *e*) el rango; *f*) la desviación estándar; *g*) la varianza; *h*) Q_1; *i*) Q_3; y *j*) P_{10}.

57	61	57	57	58	57	61	54	68	51	49	64	50	48
65	52	56	46	54	49	51	47	55	55	54	42	51	56
55	51	54	51	60	62	43	55	56	61	52	69	64	46
54													

2. **a.** John F. Kennedy tenía 43 años de edad cuando tomó posesión. Utilice los resultados del ejercicio 1 y convierta esta edad a puntuación *z*.
b. ¿Será la edad de 43 años de Kennedy "infrecuente"? ¿Por qué?
c. Aplique la regla práctica del intervalo para identificar otras edades de la lista que sean infrecuentes.
d. Aun cuando la lista de edades no incluye la de 35 años, ¿sería esa edad infrecuente? ¿Es probable que un candidato a la presidencia, de 35 años de edad, descubra que su edad sea un tema importante de campaña?

3. Distribución de frecuencias Utilice la misma lista de edades del ejercicio 1 y construya una distribución de frecuencias. Use seis clases, con 40 como el límite inferior de la primera clase, y una anchura de clase de 5.

4. Histograma Utilice la distribución de frecuencias del ejercicio 3, construya un histograma e identifique la naturaleza general de la distribución (ya sea uniforme, normal, sesgada).

5. Gráfica de cuadro Utilice las mismas edades de la lista en el problema 1, construya una gráfica de cuadro e identifique los valores que constituyen el resumen de los cinco números.

6. Regla empírica Suponga que las edades de presidentes pasados, presentes y futuros tienen una distribución normal, con una media de 54.8 años y una desviación estándar de 6.2 años.
a. ¿Qué dice la regla empírica acerca del porcentaje de edades entre 48.6 años y 61.0 años (o dentro de una desviación estándar de la media)?
b. ¿Qué dice la regla empírica acerca del porcentaje de edades entre 42.4 y 67.2 años?

7. Comparación de puntuaciones Un psicólogo industrial de la Citation Corporation crea dos pruebas diferentes para medir la satisfacción laboral. ¿Cuál puntuación es mejor: una de 72 en la prueba de administración, la cual tiene una media de 80 y una desviación estándar de 12, o una de 19 en la prueba de producción de empleados, con una media de 20 y una desviación estándar de 5? Explique.

8. **a.** Estime la media de la edad de los automóviles que conducen los estudiantes de su universidad.
b. Utilice la regla práctica del intervalo para hacer un estimado de la desviación estándar de la edad de los automóviles que conducen los estudiantes de su universidad.

9. Transformación de datos Una profesora de estadística encontró que el tiempo que emplean los estudiantes para resolver su examen final tiene una media de 135 minutos y una desviación estándar de 15 minutos. Planea añadir una nueva pregunta, la cual requerirá cinco minutos adicionales de cada estudiante.
a. ¿Cuál es la media después de incluir la nueva pregunta?
b. ¿Cuál es la desviación estándar después de incluir la nueva pregunta?
c. ¿Cuál es la varianza después de incluir la nueva pregunta?

10. Quejas de pasajeros aéreos En un año reciente hubo 23,000 quejas por parte de pasajeros aéreos. Las categorías y frecuencias de las quejas, proporcionadas por el Departamento de Transporte de Estados Unidos, son las siguientes: atención al cliente (4370); problemas con el vuelo (9200); reservaciones, boletaje y abordaje (1610); equipaje (3450); obtención de reembolsos (1150), y otras razones (3220). Construya una gráfica de Pareto que resuma los datos.

Ejercicios de repaso acumulativos

1. Errores del reloj de pulso Como parte de un proyecto para la clase de estadística, un estudiante reúne datos sobre la precisión de relojes de pulso; obtiene los siguientes errores del tiempo (en segundos). (Los valores positivos representan relojes que se adelantan; los valores negativos representan relojes que se atrasan).

140 −125 105 −241 −85 41 186 −151 325 80 27 20 20 30 −65

a. Calcule la media, la mediana, la moda y la mitad del rango.
b. Calcule la desviación estándar, la varianza y el rango.
c. ¿Provendrán los tiempos dados de una población discreta o de una continua?
d. ¿Cuál es el nivel de medición de estos valores (nominal, ordinario, de intervalo, de razón)?

2. **a.** Un conjunto de datos tiene un nivel nominal de medición y usted desea obtener un dato representativo. ¿Cuál de los siguientes es el más apropiado: la media, la mediana, la moda o la mitad del rango? ¿Por qué?
b. Se obtiene una muestra al llamar por teléfono a las primeras 250 personas listadas en el directorio telefónico local. ¿Qué tipo de muestreo se utilizó (aleatorio, estratificado, sistemático, de racimo, de conveniencia)?
c. Se lleva a cabo una encuesta de salida, consistente en encuestar a cada persona que sale de la casilla electoral en 50 distritos seleccionados aleatoriamente. ¿Qué tipo de muestreo se utilizó (aleatorio, estratificado, sistemático, de racimo, de conveniencia)?
d. Un fabricante recarga cartuchos para impresoras de computadora. Un gerente descubre que la cantidad de tinta vertida en el recipiente no es muy consistente, de tal forma que algunos cartuchos duran más de lo esperado, en tanto que otros se agotan demasiado pronto. Él desea mejorar la calidad haciendo que la cantidad de tinta en los cartuchos tenga más consistencia. Cuando se analizan las cantidades de tinta, ¿cuál de los siguientes estadísticos es más importante: la media, la mediana, la moda, la mitad del rango, la desviación estándar, el primer cuartil, el tercer cuartil? ¿Debería elevarse, disminuirse o dejar sin cambio el valor de dicho estadístico?

3. Consumo de energía Cada año, el Departamento de Energía de Estados Unidos publica un *Annual Energy Review*, que incluye el consumo de energía *per capita* (en millones de BTU) de cada uno de sus 50 estados. Si se calcula la media de estos 50 valores, ¿el resultado será la media de consumo de energía *per capita* de la población de los 50 estados combinados? Si no es así, explique cómo calcularía la media del consumo de energía *per capita* de los 50 estados combinados.

Actividades de cooperación en equipo

1. Actividad fuera de clase ¿Influyen las cifras de anclaje en los estimados? En el artículo "Weighing Anchors", de la revista *Omni*, John Rubin observó que, cuando la gente estima un valor, su estimación suele estar "anclada a" (o influida por) un número anterior, aun cuando ese número no tenga ninguna relación con la cantidad que se estima. Para demostrar esto, pidió a varias personas que le dieran un estimado rápido del valor de $8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1$. La respuesta promedio fue 2250, pero cuando se invirtió el orden de los números el promedio fue 512. Rubin explicó que cuando iniciamos un cálculo con números grandes (como en $8 \times 7 \times 6$), nuestros estimados tienden a ser grandes. Señaló que tanto 2250 como 512 son mucho menores que el producto correcto, 40,320. El artículo sugiere que números irrelevantes pueden incluirse en los avalúos de bienes raíces, así como en las estimaciones del valor de un automóvil y en las de la posibilidad de una guerra nuclear.

Realice un experimento para probar dicha teoría. Seleccione a algunos sujetos y pídales que estimen rápidamente el valor de

$$8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1$$

Después, seleccione otros sujetos y pídales que estimen rápidamente el valor de

$$1 \times 2 \times 3 \times 4 \times 5 \times 6 \times 7 \times 8$$

Registre los estimados junto con el orden utilizado. Diseñe con cuidado el experimento, de modo que las condiciones sean uniformes y que los dos grupos muestrales se seleccionen de forma que se minimice cualquier sesgo. No describa la teoría a los sujetos hasta después de proporcionar sus estimaciones. Compare los dos conjuntos de resultados muestrales, a través del uso de los métodos de este capítulo. Prepare un reporte impreso, que incluya los datos reunidos, los métodos detallados utilizados, el método de análisis, las gráficas y/o los estadísticos relevantes, así como las conclusiones. Incluya una crítica dando razones por las que los resultados podrían ser incorrectos y describa formas para mejorar el experimento.

Una variante del experimento anterior consiste en encuestar personas acerca de su conocimiento sobre la población de Kenia. Primero pregúntele a la mitad de los sujetos si piensa que la población es mayor o menor que cinco millones; después, pídales que estimen la población dando un número real. Pregunte a la otra mitad de los sujetos si cree que la población es mayor o menor que 80 millones; después, pídales que estimen la población. (La población de Kenia es de 28 millones). Compare los dos conjuntos de resultados e identifique el efecto "de anclaje" en la cifra inicial que dieron los sujetos encuestados.

2. Actividad fuera de clase Cada equipo, formado por tres o cuatro estudiantes, debe reunir un conjunto original de datos que estén a un nivel de medición de intervalo o de razón. Proporcione lo siguiente: *a*) una lista de valores muestrales, *b*) resultados de computadora impresos con estadísticos descriptivos y gráficas, y *c*) una descripción por escrito de la naturaleza de los datos, el método de recolección y las características importantes.

3. Actividad en clase A continuación se indican las edades que un grupo de motociclistas tenía cuando se hirió fatalmente en accidentes de tránsito (según datos del Departamento del Transporte de Estados Unidos). Si su objetivo es dramatizar el peligro que constituyen las motocicletas para la gente joven, ¿cuál de los siguientes sería el más efectivo: el histograma, la gráfica de Pareto, la gráfica circular, la gráfica de puntos, la media, la mediana? Construya la gráfica y encuentre el estadístico que cumple mejor el objetivo. ¿Es correcto distorsionar los datos de manera deliberada si el objetivo es salvar la vida de los motociclistas?

17	38	27	14	18	34	16
42	28	24	40	20	23	31
37	21	30	25	17	28	33
25	23	19	51	18	29	

4. Actividad fuera de clase Pida a cada equipo, que se formó con tres o cuatro estudiantes, que seleccione uno de los siguientes reactivos y que construya una gráfica que sirva para poner énfasis en la pregunta:

a. ¿Habrá una diferencia entre los valores del índice de masa corporal (IMC) de los hombres y el de las mujeres? (Véase el conjunto de datos 1 del Apéndice B).

b. ¿Existirá alguna relación entre la estatura de los hijos (o hijas) y la estatura de sus padres (o madres)? (Véase el conjunto de datos 2 del Apéndice B).

c. ¿Parecen los dígitos generados por la lotería *Win 4* del estado de Nueva York haber sido seleccionados aleatoriamente? ¿O estarán sesgados? (Véase el conjunto de datos 26 del Apéndice B).

Proyecto tecnológico

Cuando se manejan conjuntos grandes de datos, la introducción manual de éstos suele ser tediosa y requerir de mucho tiempo. Hay mejores actividades que hacer con su tiempo, como aprender los principios aerodinámicos de un *frisbee*. Remítase al conjunto de datos 30 del Apéndice B, que incluye las distancias de los jonrones “”de tres jugadores de beisbol excepcionales: Barry Bonds (temporada 2001), Mark McGwire (temporada 1998) y Sammy Sosa (temporada 1998). En lugar de introducir manualmente las 209 distancias de los tres conjuntos de datos, utilice la calculadora TI-83 Plus, el STATDISK, el Minitab o Excel para cargar el conjunto de datos, los cuales están disponibles en el CD incluido en este libro. Proceda a generar histogramas, obtendrá estadísticos apropiados que le permitirán comparar los tres conjuntos de datos. ¿Hay algunas diferencias significativas? ¿Existen algunos datos distantes? ¿Parece que los jugadores que golpean más lejos hacen más jonrones””? ¿Por qué? Analice los últimos dígitos de las distancias y determine si los valores parecen ser estimaciones o mediciones. Escriba un reporte breve que contenga sus conclusiones y gráficas de apoyo.

Conjunto de datos 30: Distancias de jonrones

Las distancias de los jonrones de Mark McGwire (1998), Sammy Sosa (1998) y Barry Bonds (2001) están en pies.

Nombre de los archivos de STATDISK y de texto: MCGWR, SOSA, BONDS.
Minitab: el nombre de la hoja de cálculo es HOMERUNS.MTW.
Excel: el nombre del libro es HOMERUNS.XLS.
TI-83 Plus: el nombre es HOMERUNS, y los nombres de los archivos son los mismos de STATDISK y de los archivos de texto.

McGwire

360	370	370	430	420	340	460	410	440	410
380	360	350	527	380	550	478	420	390	420
425	370	480	390	430	388	423	410	360	410
450	350	450	430	461	430	470	440	400	390
510	430	450	452	420	380	470	398	409	385
369	460	390	510	500	450	470	430	458	380
430	341	385	410	420	380	400	440	377	370

Sosa

371	350	430	420	430	434	370	420	440	410
420	460	400	430	410	370	370	410	380	340
350	420	410	415	430	380	380	366	500	380
390	400	364	430	450	440	365	420	350	420
400	380	380	400	370	420	360	368	430	433
388	440	414	482	364	370	400	405	433	390
480	480	434	344	410	420				

Bonds

420	417	440	410	390	417	420	410	380	430
370	420	400	360	410	420	391	416	440	410
415	436	430	410	400	390	420	410	420	410
410	450	320	430	380	375	375	347	380	429
320	360	375	370	440	400	405	430	350	396
410	380	430	415	380	375	400	435	420	420
488	361	394	410	411	365	360	440	435	454
442	404	385							

de los DATOS a la DECISIÓN



Pensamiento crítico

Las muertes por choques de automóviles son devastadoras para las familias de las víctimas y con frecuencia implican procesos legales y pagos de seguro costosos. A continuación se presentan las edades de 100 conductores que murieron en choques de automóviles, seleccionados aleatoriamente. También se incluye una distribución de frecuencias, por edades, de conductores con licencia.

Edad (en años) de conductores muertos en choques de automóviles

37	76	18	81	28	29	18	18	27	20
18	17	70	87	45	32	88	20	18	28
17	51	24	37	24	21	18	18	17	40
25	16	45	31	74	38	16	30	17	34
34	27	87	24	45	24	44	73	18	44
16	16	73	17	16	51	24	16	31	38
86	19	52	35	18	18	69	17	28	38
69	65	57	45	23	18	56	16	20	22
77	18	73	26	58	24	21	21	29	51
17	30	16	17	36	42	18	76	53	27

Edad	Conductores con licencia (millones)
16–19	9.2
20–29	33.6
30–39	40.8
40–49	37.0
50–59	24.2
60–69	17.5
70–79	12.7
80–89	4.3

Análisis

Convierta la distribución de frecuencias a una distribución de frecuencias relativas; después, elabore una distribución de frecuencias relativas con las edades de los conductores que murieron en choques de automóviles. Compare las dos distribuciones de frecuencias relativas. ¿Cuáles categorías de edad parecen tener proporciones sustancialmente mayores de muertes que las proporciones de los conductores con licencia? Si usted fuese el responsable de establecer las tasas de seguros de automóviles, ¿a qué categorías de edad les asignaría las tasas más altas? Construya una gráfica que permita identificar las categorías de edad más propensas a accidentes automovilísticos fatales.

PROYECTO DE INTERNET

Datos en Internet



Internet posee una enorme cantidad de información, de la cual, gran parte, se presenta en forma de datos brutos que pueden estudiarse y resumirse con el uso de los estadísticos presentados en este capítulo. Por ejemplo, encontramos la siguiente información con tan sólo unos cuantos clics:

- El valor de la acción de Walt Disney Corporation tiende a subir durante los meses de invierno, pero varía el resto del año. En el 2001, los precios máximo y mínimo de la acción variaron más de 17 puntos.
- Ichiro Suzuki, jardinero lateral del equipo de beisbol de los Marineros de Seattle, tuvo un porcentaje de "hits" de 0.457 durante la temporada 2001.
- Las poblaciones de California, Nueva York y Texas representan más del 25% del total de la de Estados Unidos.

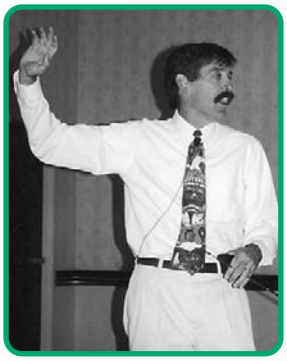
El proyecto de Internet para este capítulo, que se encuentra en el sitio de Internet de *Estadística elemental*, lo conducirá a conjuntos de datos en las áreas de deportes, finanzas y clima. Una vez que haya armado un conjunto de datos, aplicará los métodos de este capítulo para resumir y clasificar los datos.

El sitio Web para este capítulo se encuentra en

www.pearsoneducacion.net/triola

La estadística @ en el trabajo

"El periodista debe ser capaz de tener una visión crítica hacia la investigación, y comprender el verdadero contexto y el significado del trabajo".



Mark Fenton
Editor de la Revista Large Walking Magazine

Mark Fenton también es defensor de la marcha y campeón de este deporte. Perteneció al equipo nacional de marcha de Estados Unidos en cinco ocasiones, y ha representado a este país en numerosas competencias internacionales. Estudió biomecánica y fisiología del deporte en el Olympic Training Center's Sports Science Laboratory, ubicado en Colorado Springs, Colorado.

¿Cuáles conceptos de estadística utiliza?

Debo estar familiarizado con todas las herramientas comunes que se utilizan en los análisis estadísticos de las ciencias del deporte y de la investigación en salud pública; desde las medias y las desviaciones estándar, hasta la significancia o diferencias estadísticas, los intervalos de confianza y el análisis de varianza, entre otros.

¿De qué manera utiliza la estadística en su trabajo?

Suelo leer revistas de investigaciones médicas (*Medicine and Science in Sports and Exercise* y el *Journal of the American Medical Association* son los más relevantes) sobre fisiología del deporte, salud pública e investigación epidemiológica. Debo mantenerme informado sobre la manera en que se controlan y analizan los estudios, así como comprender la potencia o el valor relativo del resultado de un estudio. Esta información la utilizo en los artículos y conferencias que elaboro sobre los hallazgos de dicho trabajo.

Por favor, describa un ejemplo específico que ilustre la forma en que el uso de la estadística haya logrado mejorar un producto o servicio.

Por lo general, leo artículos de investigación y debo estar atento a los vacíos de la evidencia, tales como tamaños de muestra demasiado pequeños; significancia estadística con diferencias absolutas pequeñas entre grupos; desviaciones estándar extremadamente grandes; todo lo cual puede oscurecer la relevancia de un hallazgo para una persona promedio.

Un ejemplo simple es el problema que existe al afirmar que el pulso máximo **promedio** de una mujer de 36 años es de 190 latidos por minuto (226 menos la edad). Esto es útil para calcular el pulso que se busca, hasta que uno encuentra que la desviación es demasiado alta y la cifra resultante puede alejarse tanto como 10 latidos por minuto para casi 1/3 de la población, un error suficientemente grande para causar problemas al hacer ejercicio. El estudio que señaló esto alteró la forma en que recomiendo la intensidad del ejercicio.

¿Se estará incrementando o disminuyendo el uso de la probabilidad y la estadística, o permanece estable?

Debido a mi trabajo cada vez más intenso en salud pública y al incremento en la complejidad de las herramientas estadísticas que se utilizan en los análisis de poblaciones grandes, mis conocimientos en este campo **deben** seguir acrecentándose si quiero mantenerme al día.

¿Recomienda el uso de la estadística a los estudiantes universitarios de hoy?

Recomiendo al menos un curso de estadística, ya que es una herramienta útil para evaluar la información con que se nos bombardea cada día, mucha de la cual carece de contexto. Cualquier persona que se interesa en la ciencia del periodismo debe tomar al menos un curso introductorio extenso de estadística. El periodista debe ser capaz de tener una visión crítica hacia la investigación, y comprender el verdadero contexto y el significado del trabajo.