FADENA | Universidad de la Defensa Nacional

PROBALIDAD Y ESTADÍSTICA

Unidad 2

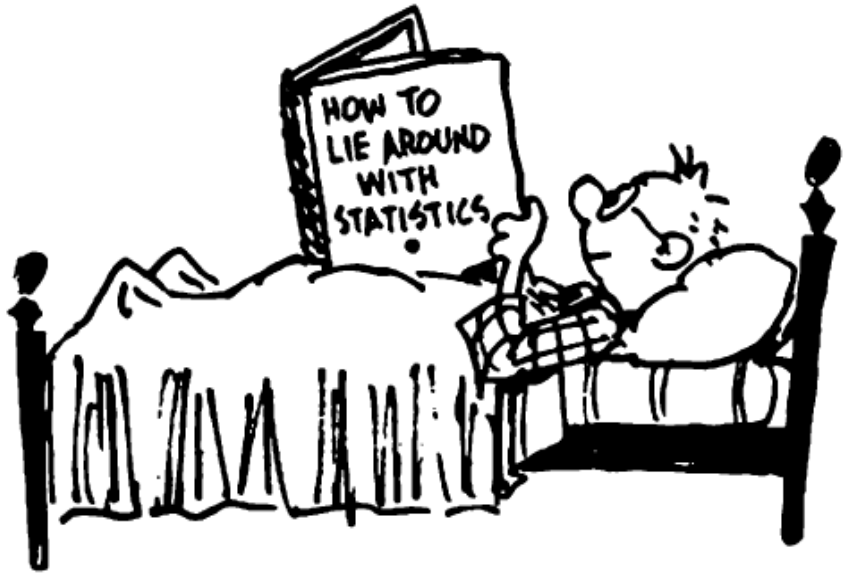
Prof. Tit.: Dra. Romina Caballero

Material de lectura: Unidad 2

Guía de lectura de material bibliográfico
Clase 3- Unidad II

Bibliografía

- Bologna, E. (2018). Métodos Estadísticos de Investigación (Cap.2, Distribuciones de frecuencias, pp. 37-50). Editorial Brujas.
- Triola, M. (2009). Estadística, 9.ª ed. (Cap. 2, Descripción, exploración y comparación de datos, pp. 38–102). Pearson.
- Chica de Galassi, et al. (2012). Nociones de estadística y de probabilidad (Cap.2, Organización de la información, pp.29-42). Ediciones de la Paz.



Objetivo

Comprender, organizar, representar e interpretar **información estadística** en distintos formatos (**tablas y gráficos**).

FADENA

2. UNIDAD 2

2.1. Presentación de datos. Clasificación y presentación de la información.

2.2.Textos estadísticos. Características los textos estadísticos. Tablas Estructura. Fuentes. Gráficos estadísticos. Tipos de gráficos.

2.3. Cantidades absolutas y porcentuales. Interpretación de la información.

Universidad de la Defensa Nacional

MATRIZ DE DATOS

Estadística Descriptiva

obtiene → DATOS → *Organizan* → TABLA DE DOBLE ENTRADA

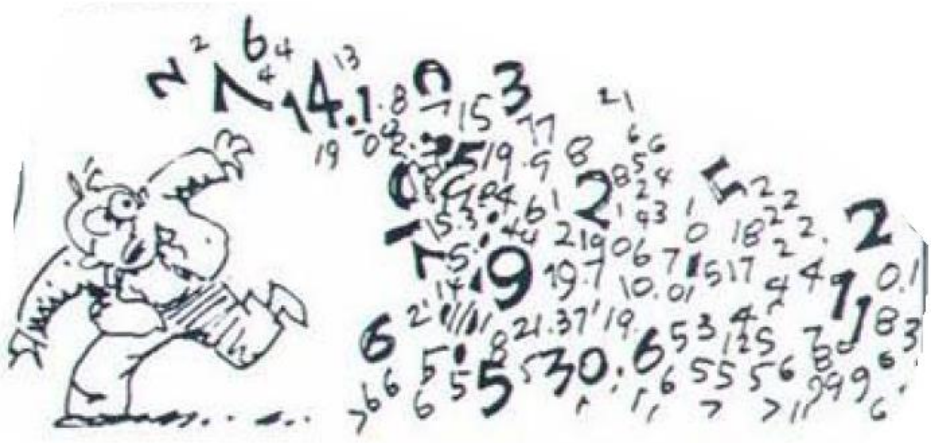
Registra cada observación

TABLA DE DOBLE ENTRADA → **COLUMNAS**

Aspecto de la UA=variable

TABLA DE DOBLE ENTRADA → **FILAS**

Unidades de Análisis



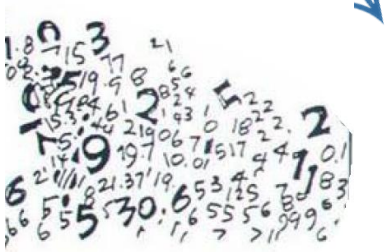
	Xi1	Xi2	Xi3	Xi4	Xin
id1	1	3	120	6	2025
id2	2	3	60	6	2024
id3	1	5	68	4	2024
id4	1	5	43	2	2024
...	2	4	65	6	2023
id1n	3	1	24	7	2025

MATRIZ DE DATOS

Source IP Address	Destination IP Addr...	Source Port	Destination Port	Protocol	Packet Length	Packet Type	Traffic Type
103.216.15.12	84.9.164.252	31225	17616	ICMP	503	Data	HTTP
78.199.217.198	66.191.137.154	17245	48166	ICMP	1174	Data	HTTP
63.79.210.48	198.219.82.17	16811	53600	UDP	306	Control	HTTP
163.42.196.10	101.228.192.255	20018	32534	UDP	385	Data	HTTP
71.166.185.76	189.243.174.238	6131	26646	TCP	1462	Data	DNS
198.102.5.160	147.190.155.133	17430	52805	UDP	1423	Data	HTTP
97.253.103.59	77.16.101.53	26562	17416	TCP	379	Data	DNS
11.48.99.245	178.157.14.116	34489	20396	ICMP	1022	Data	DNS
49.32.208.167	72.202.237.9	56296	20857	TCP	1281	Control	FTP
114.109.149.113	160.88.194.172	37918	50039	UDP	224	Data	HTTP
177.21.83.200	196.218.124.169	35538	35006	ICMP	661	Data	HTTP
92.4.25.171	112.43.185.24	10903	36817	TCP	281	Control	HTTP
57.91.207.84	98.96.110.38	53471	38048	ICMP	64	Control	DNS
80.28.21.123	111.204.103.106	43729	10845	ICMP	1341	Data	HTTP
54.163.130.178	62.112.149.214	47795	35243	UDP	913	Data	DNS
130.163.192.252	12.192.2.112	24912	21176	TCP	425	Data	DNS
4.255.187.165	136.159.186.239	39934	5259	TCP	838	Control	HTTP

La matriz de datos es un arreglo en el que **cada fila** (horizontal) representa un **individuo** del cual proviene la información, **cada columna** (vertical) es un **aspecto de los individuos**, que se ha seleccionado para observar, y cada **celda** es el **valor que tiene el individuo de la fila en el aspecto** de la columna correspondiente.

DATOS



MATRIZ de DATOS

	Xi1	Xi2	Xi3	Xi4	Xin
id1	1	3	120	6	2025
id2	2	3	60	6	2024
id3	1	5	68	4	2024
id4	1	5	43	2	2024
...	2	4	65	6	2023
idn	3	1	24	7	2025

VARIABLES

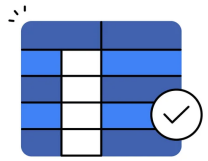
CUANTITATIVAS

- Datos se agrupan en intervalos numéricos de igual longitud (intervalos de clase).
- Se determina frecuencia de los intervalos de clase.

CUALITATIVAS

- Agrupar datos en clases o categorías
- Cada dato en una sola clase
- Determinar nº de datos que corresponde a la clase

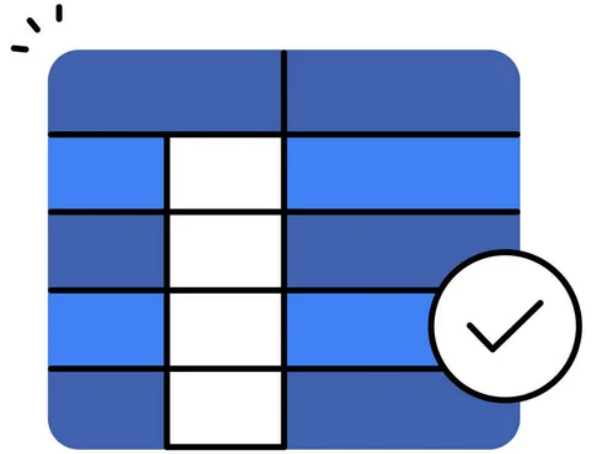
TABULACIÓN ESTADÍSTICA



Frequency Table

TABLAS en ESTADÍSTICA

1. Lo más simple posible
2. Título ¿Qué es? ¿Adónde? ¿Cuándo?
3. Título de filas y columnas. Concisos y claros
4. Fuente de los datos.

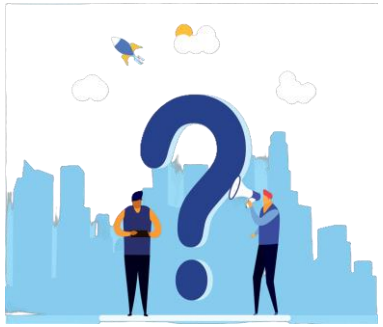


Frequency Table

DISTRIBUCIÓN DE FRECUENCIAS



Lista **valores de datos** (ya sea de manera individual o por grupos de intervalos), junto con sus frecuencias (o conteos) correspondientes.



1. Es posible resumir conjuntos grandes de datos
2. Se logra cierta comprensión respecto de la naturaleza de los datos
3. Avance para construir gráficas importantes

¿Cómo construyo? *Vídeos de prácticos*

DISTRIBUCIÓN DE FRECUENCIAS



ABSOLUTAS (*fi*)

Cantidad de veces que el valor de la variable está en el conjunto de datos.

RELATIVA (*fi'* = *f/n*)

Proporción de veces que el valor de la variable está en el conjunto de datos. **Cociente** entre la **frecuencia absoluta** y el **total de individuos** observados del conjunto de datos.

PORCENTUAL (*fi'%* = *fi'%*x100)

Porcentaje de veces que el valor de la variable está en el conjunto de datos. Expresa la frecuencia relativa en unidades de 100.

ACUMULADA (Fi, Fi', Fi'%)

Cuando el nivel de medida de la variable permite orden de sus valores, puede ser útil tener en cuenta la frecuencia de todos los valores menores o iguales a un valor dado xi (frecuencia acumulada (F) en xi)

DISTRIBUCIÓN DE FRECUENCIAS



LÍMITE DE CLASE INFERIOR (L_i)

Cifras más PEQUEÑAS que pueden pertenecer a las diferentes clases.

LÍMITE DE CLASE SUPERIOR (L_s)

Cifras más GRANDES que pueden pertenecer a las diferentes clases.

FRONTERAS DE CLASE (L_{ri}, L_{rs})

Cifras utilizadas para separar las clases, aunque sin los espacios creados por los límites de clase.

MARCA DE CLASE (X_i) $X1= (L_{s'} - L_i)/2$

Puntos medios de las clases que se calcula sumando el límite de clase inferior con el límite de clase superior y dividiendo la suma entre dos.

TAMAÑO o AMPLITUD (c) $c= L_{rs'} - L_{ri}$

Diferencia entre límite real superior e inferior

TABULACIÓN ESTADÍSTICA

VARIABLES CUANTITATIVAS

INTERVALOS DE CLASE

1. Calcular la diferencia entre el máximo valor observado y el mínimo valor observado menos media unidad.

2. Más media unidad (ej. 0,5 si las observaciones son enteras)

3. Se divide la amplitud por la cantidad de intervalos (depende de la cantidad de datos) requeridos (5 a 20).

Tabla 1. Intentos de intrusión que recibe un sistema diariamente

Intervalo (intentos de intrusión)	Marca de clase	*fi*
0 – 20	10	3
20 – 40	30	7
40 – 60	50	5
60 – 80	70	3
80 – 100	90	2
Total	—	**20**

FADENA

Universidad de la Defensa Nacional

FADENA

EJEMPLOS DE DISTRIBUCIÓN DE FRECUENCIAS

Universidad de la Defensa Nacional

Frecuencias: ejemplo para variable cuantitativa

Para agrupar en intervalos de clase

1) Calcular la diferencia entre el máximo valor observado y el mínimo valor observado menos media unidad.
2) Más media unidad (ej. 0,5 si las observaciones son enteras)
3) Se divide la amplitud por la cantidad de intervalos (depende de la cantidad de datos) requeridos (5 a 20).

Situación:

*Un SOC (Centro de Operaciones de Seguridad) registra el **tiempo de detección de incidentes de ciberseguridad (en minutos)** durante una semana.*

DATOS (minutos): 12, 15, 18, 20, 22, 25, 27, 30, 33, 35, 38, 40, 42, 45, 48, 50

Ejemplo:

1) Encontrar $x_{máx}$ y $x_{mín.}$ 12 y 50.
2) Correrse media unidad y calcular la amplitud:

   Amplitud =50,5 – 11,5 = 39

3) Dividir amplitud por el nro. de intervalos deseados; por ejemplo, 5: 39/ 5 ≈ 8

Tabla 2. Tiempo de detección de incidentes en min.

Intervalo (min)	*fi*	*fi'*	Fi	Fi'%
11,5 – 19,5	3	0,19	3	18,75%
19,5 – 27,5	3	0,19	6	37,50%
27,5 – 35,5	3	0,19	9	56,25%
35,5 – 43,5	4	0,25	13	81,25%
43,5 – 51,5	3	0,19	16	100%
Total	16	1,00	—	—

Frecuencias: ejemplo variable cualitativa – nominal

Situación:

Un equipo SOC registra los incidentes detectados en un sistema durante un día de monitoreo. Se registran 18 incidentes y clasifican según tipo de ataque (variable), cuyos valores son: Phishing **(P)**, Malware **(M)**, DDoS **(D)**, Ransomware **(R)** e Intrusión **(I)**.

Los datos son: R M D P P R M I P D M P R D I P M P



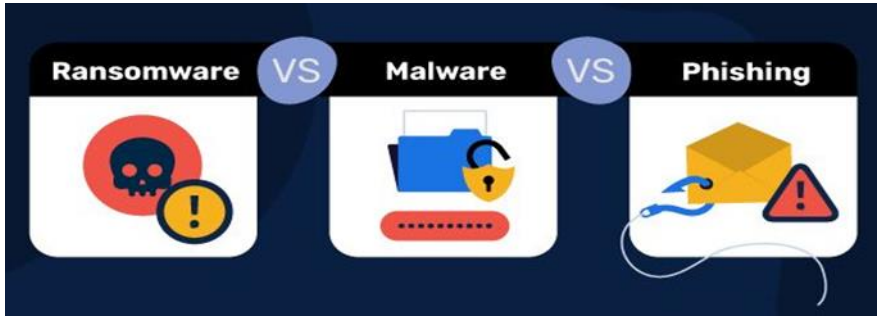
Frecuencias relativa y porcentual: ejemplo

Datos: R M D P P R M I P D M P R D I P M P

- El valor Phishing fue registrado 6 veces (frecuencia absoluta). Entonces, la frecuencia absoluta de Malware es 4, la de DDoS es 3, la de Ransomware es 3 y la de Intrusión es 2.

- La frecuencia relativa de “Phishing” es 6/18 = 0,33; la de “Malware” es 4/18 = 0,22; la de “DDoS” es 3/18 = 0,17; la de “Ransomware” es 3/18 = 0,17 y la de “Intrusión” es 2/18 = 0,11.

- El porcentaje de “Phishing” es 0,33 × 100 = 33%; el de “Malware” es 0,22 × 100 = 22%; el de “DDoS” es 0,17 × 100 = 17%; el de “Ransomware” es 0,17 × 100 = 17% y el de “Intrusión” es 0,11 × 100 = 11%.



Frecuencias relativa y porcentual: ejemplo

Tipo de ataque *Xi*	Frec. Abs. *fi*	Frec. Rel. *fi'*	Frec. Porc. *fi'%*
Phishing	6	0,33	33%
Malware	4	0,22	22%
DDoS	3	0,17	17%
Ransomware	3	0,17	17%
Intrusión	2	0,11	11%
Total	18	1,00	100%

¿Cómo calculo? *Vídeos de prácticos*

Frecuencias acumuladas: ejemplo para variable ordinal

Situación:

Una organización analiza los incidentes detectados durante un período determinado, clasificándolos según su nivel de severidad en las categorías: baja, media, alta y crítica. Sobre un total de 20 incidentes, se registran 4 de severidad baja, 6 media, 7 alta y 3 crítica.
Así, hasta el nivel medio se acumulan 10 incidentes (baja + media), mientras que hasta el nivel alto se alcanzan 17 incidentes.

Severidad Xi	*fi*	*fi'*	*fi'* %	Fi	Fi'%
Baja	4	0,20	20%	4	20%
Media	6	0,30	30%	10	50%
Alta	7	0,35	35%	17	85%
Crítica	3	0,15	15%	20	100%
Total	20	1,00	100%	—	—

FADENA

VISUALIZACIÓN DE LA INFORMACIÓN
Gráficos y Diagramas

Universidad de la Defensa Nacional

VISUALIZACIÓN DE LA INFORMACIÓN



VARIABLE

Según valores

- **Cualitativa**
  - *Según nivel de medición*
    - **Nominal**
      - Sectores (circular o de tortas)
    - **Ordinal**
      - Barras anchas o de rectángulos
      - Bastones o barras delgadas
- **Cuantitativa**
  - *Según nivel de medición*
    - **Discreta**
      - Escalonado/ de escalera
    - **Continua**
      - Tallo y hoja
      - Caja y bigotes
      - Histograma
      - Polígono de frecuencias
      - Ojiva de Galton

GRAFICOS y DIAGRAMAS

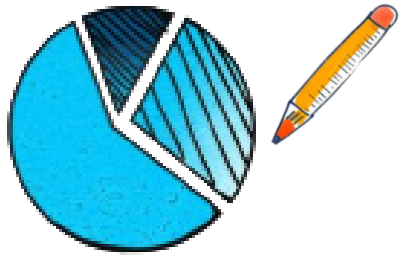


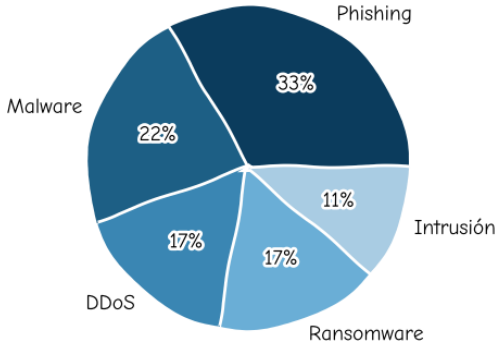
GRÁFICO DE SECTORES (CIRCULAR O DE TORTAS)

Tipo de ataque *Xi*	*fi*	*fi'*	*fi'%*	Ángulo (f'i x 360º)
Phishing	6	0,33	33%	118,8º
Malware	4	0,22	22%	79,2º
DDoS	3	0,17	17%	61,2º
Ransomware	3	0,17	17%	61,2º
Intrusión	2	0,11	11%	39,6º
Total	18	1,00	100%	360º

Asignar a cada valor de la variable un sector circular

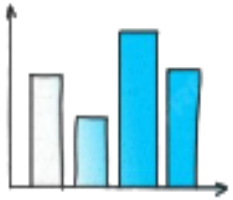
***f*i x 360º**

Variables cuantitativas



FADENA

Universidad de la Defensa Nacional

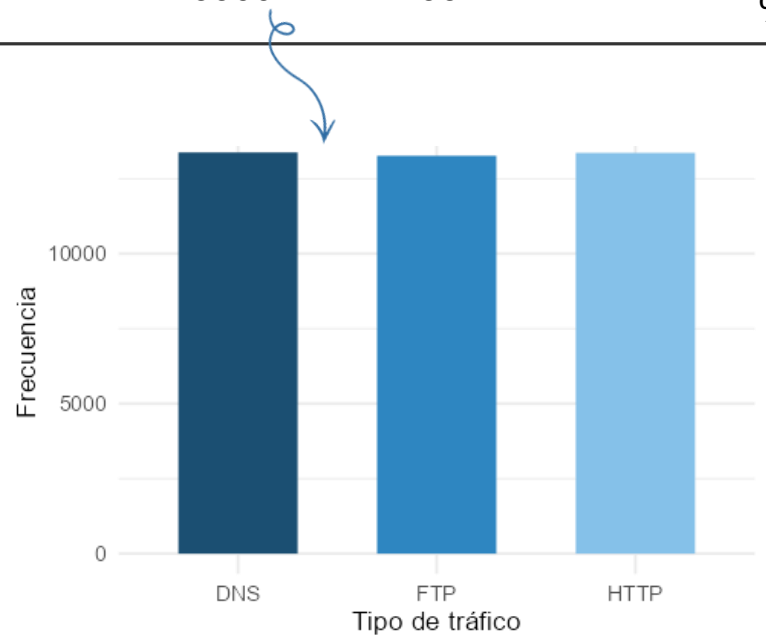


BARRAS ANCHAS O DE RECTÁNGULOS

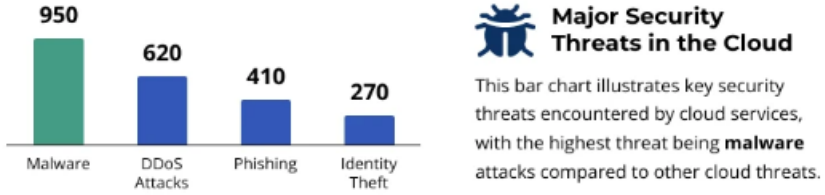
Variables cuantitativas

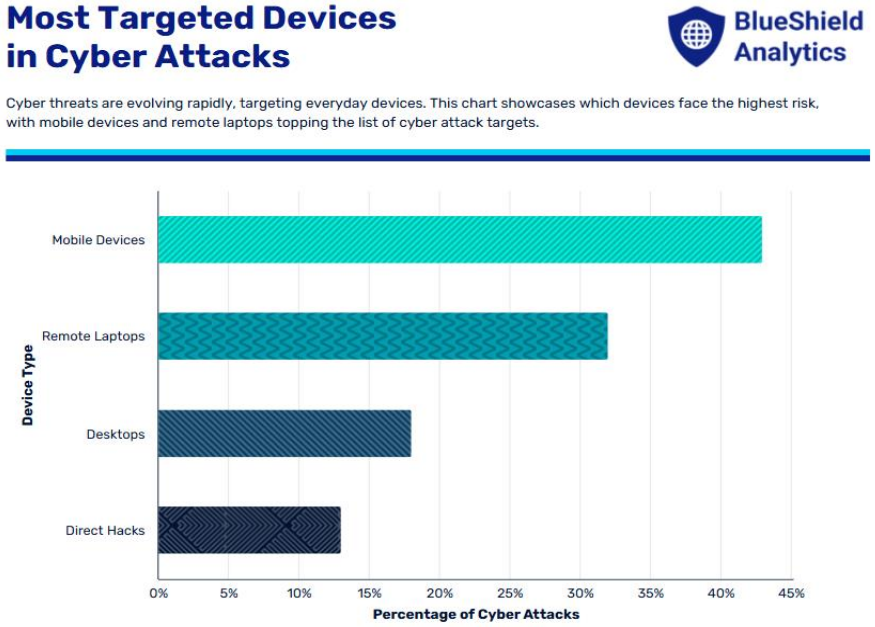
Frequencias de Traffic Type

Traffic Type	Frecuencias	% del Total	% Acumulado
DNS	13376	33.4 %	33.4 %
FTP	13264	33.2 %	66.6 %
HTTP	13360	33.4 %	100.0 %



Línea horizontal ⟶ Categorías





FADENA

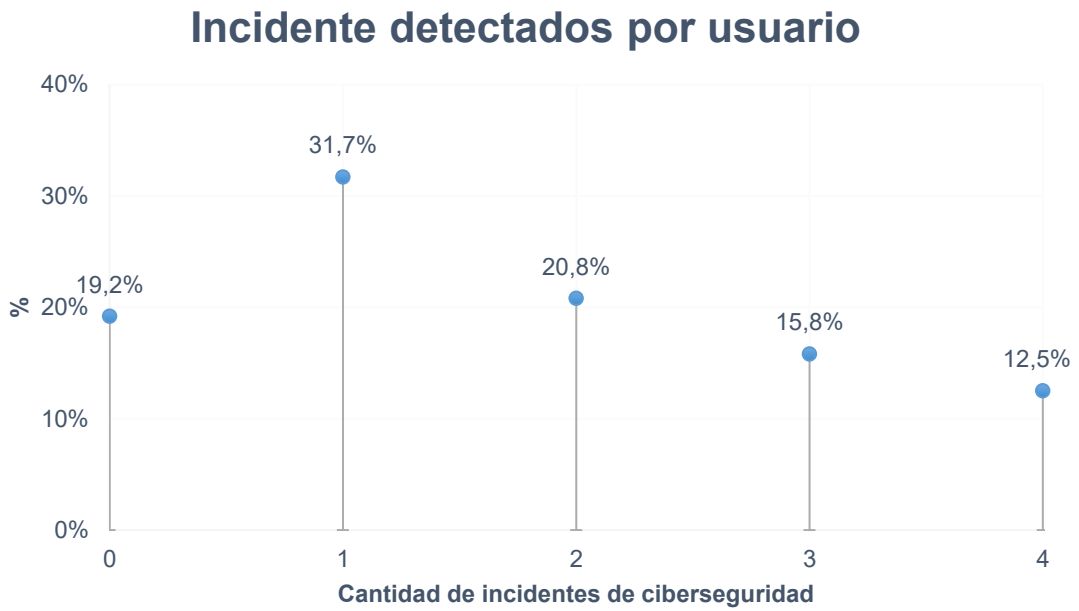
Universidad de la Defensa Nacional

BASTONES O BARRAS DELGADAS

Variables cuantitativas **discretas**

Incidentes detectados	*fi*	*fi* (%)	*fi'*	Fi	Fi (%)	*Fi'*
0	23	19,2%	0,192	23	19,2%	0,192
1	38	31,7%	0,317	61	50,8%	0,508
2	25	20,8%	0,208	86	71,7%	0,717
3	19	15,8%	0,158	105	87,5%	0,875
4	15	12,5%	0,125	120	100,0%	1,000
Total	120	100,0%	1,000			

y= frecuencias



x= valores de la variable

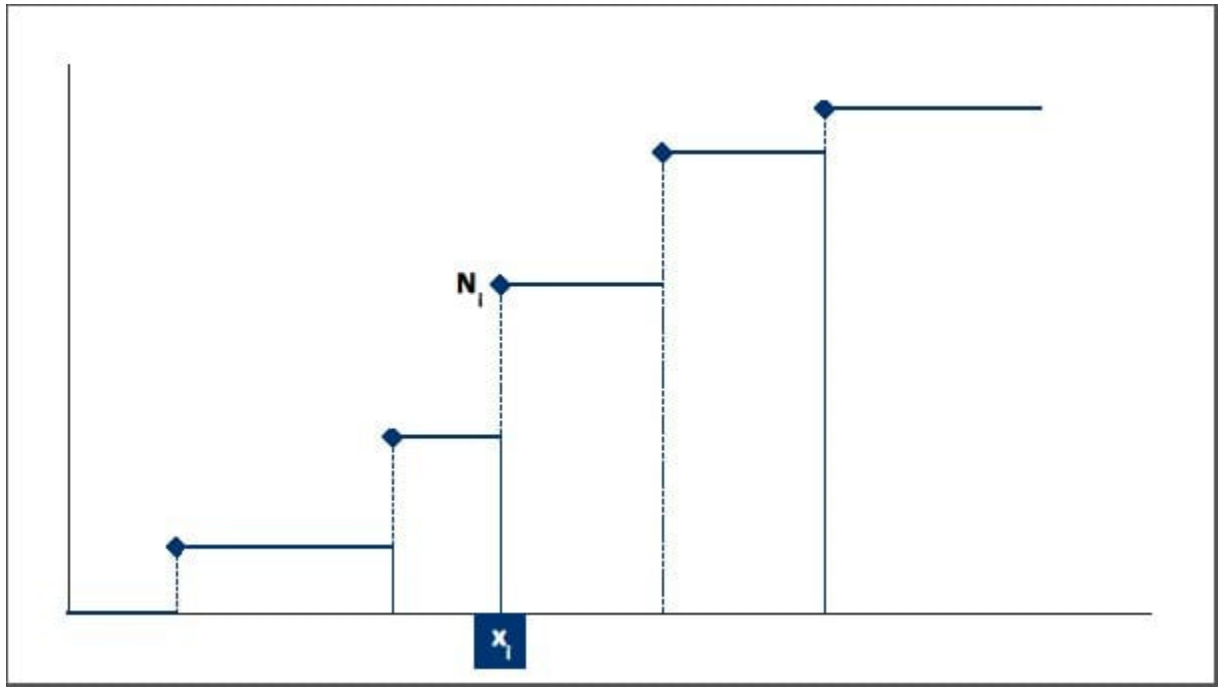
FADENA

Universidad de la Defensa Nacional

DIAGRAMA DE ESCALERA

Polígono de **frecuencias acumuladas** para una **variable discreta**

Eje **X** → valores de la variable
Eje **Y** → frecuencia acumulada (Fi)



FADENA

Universidad de la Defensa Nacional

HISTOGRAMA

Gráfica de barras en donde la escala horizontal representa clases de valores de datos y la escala vertical representa frecuencias. Las alturas de las barras corresponden a los valores de frecuencia, en tanto que las barras se dibujan de manera adyacente (sin espacios entre ellas).

Características

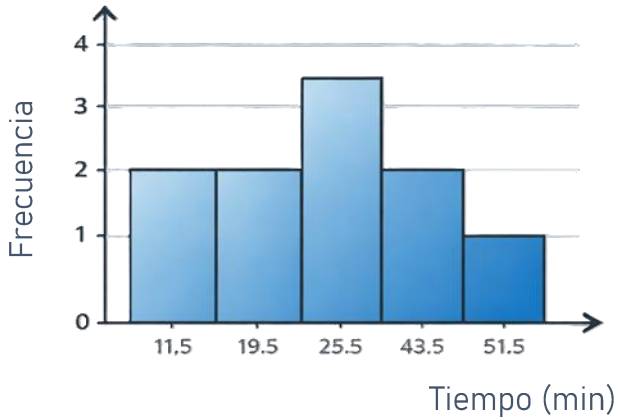
1. Las bases de los rectángulos están sobre el eje X y su longitud representa el tamaño del intervalo de clase

2. Los extremos de la base representan a los límites reales del intervalo

3. La superficie de los rectángulos es proporciona a las frecuencias de clase

Ej. Tiempo de detección de incidentes

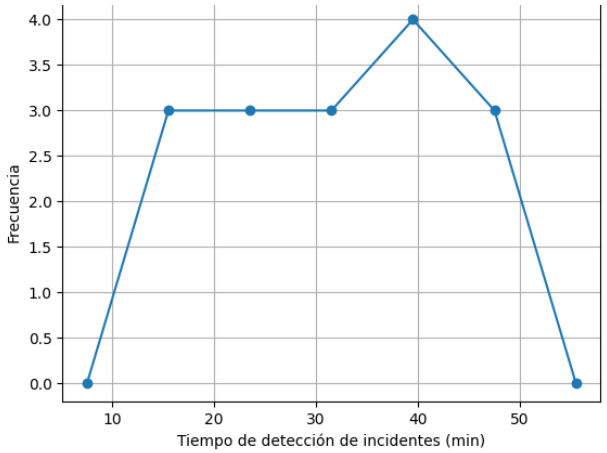
Intervalo (min)	fi
11,5 – 19,5	3
19,5 – 27,5	3
27.5 – 35,5	3
35,5 – 43,5	4
43,5 – 51,5	3
	Total: 16

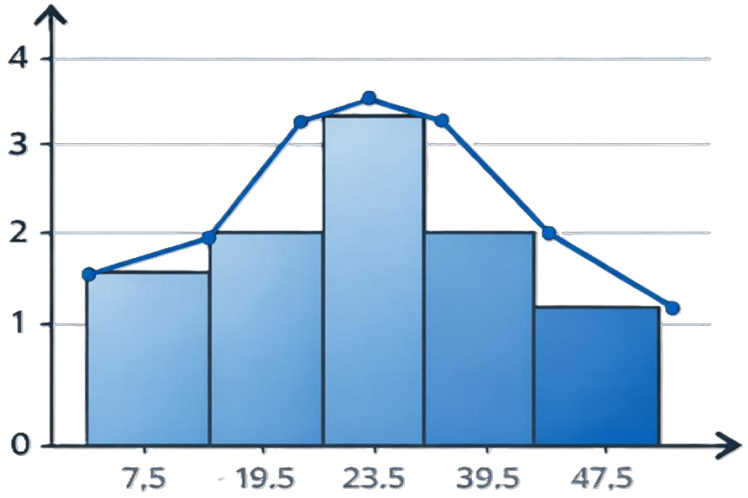


POLÍGONO DE FRECUENCIAS

Utiliza segmentos lineales conectados a puntos que se localizan directamente por encima de los valores de las marcas de clase.

Las alturas de los puntos corresponden a las frecuencias de clase, en tanto que los segmentos lineales se extienden hacia la derecha y la izquierda, de manera que la gráfica inicia y termina sobre el eje horizontal.





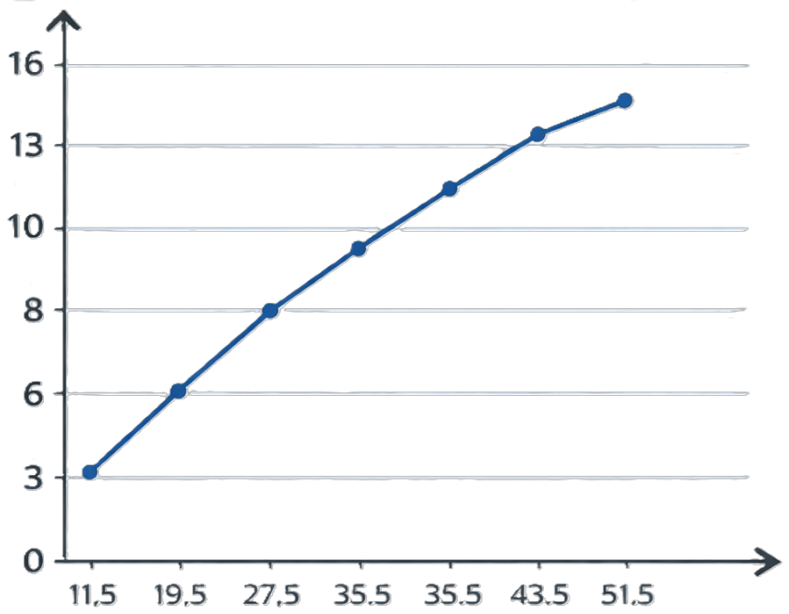
Tiempo de detección de incidentes

FADENA

Universidad de la Defensa Nacional

OJIVA

Gráfica lineal que representa **frecuencias acumuladas**
Utiliza fronteras de clase, a lo largo de la escala horizontal, y la gráfica empieza con la frontera inferior de la primera clase, en tanto que finaliza con la frontera superior de la última clase.
Son útiles para determinar el número de valores que se encuentran por debajo de un valor particular.

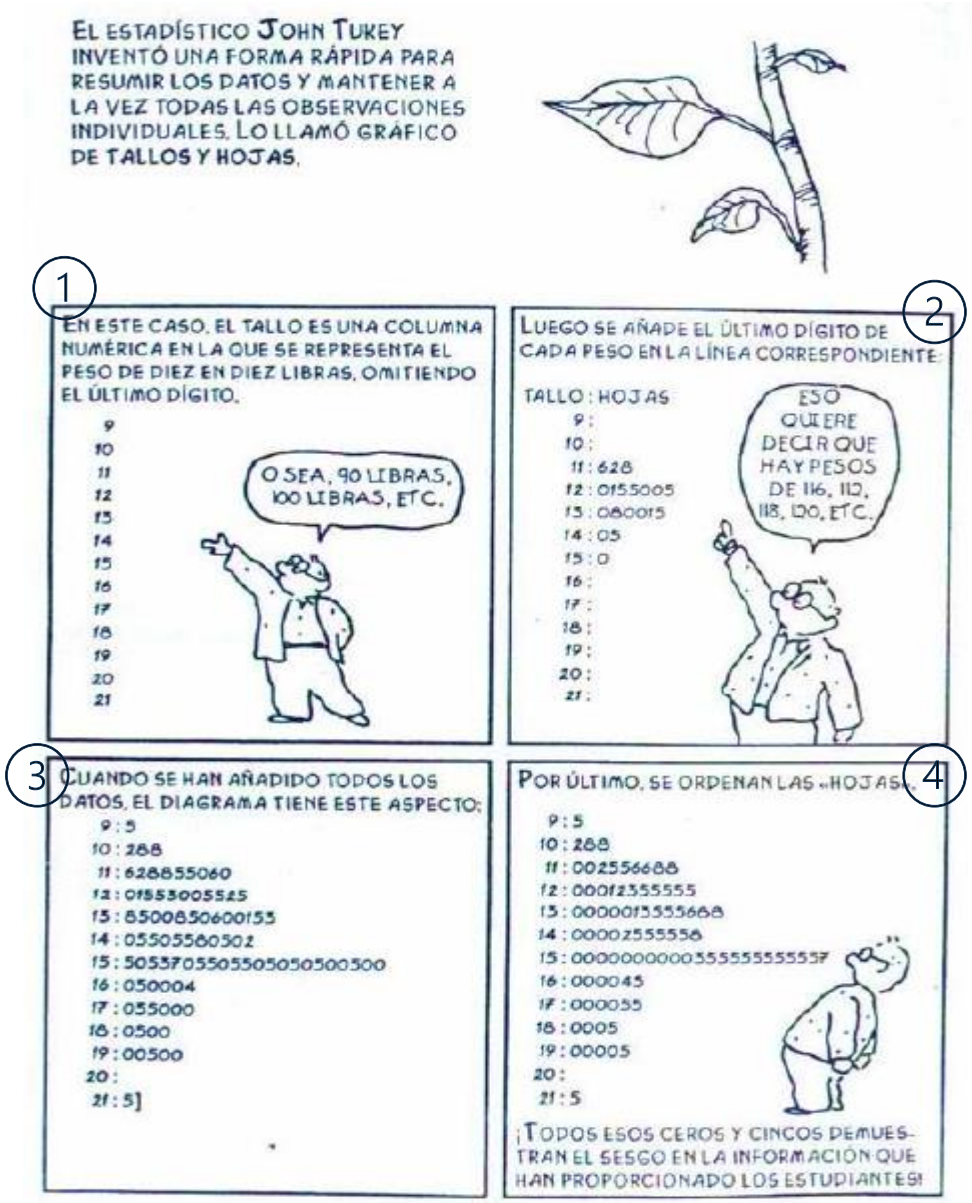


Tiempo de detección de incidentes

FADENA

Universidad de la Defensa Nacional

DIAGRAMA de TALLO-HOJA



Si el tipo de datos lo permite (por ej. una variable que se expresa en cifras de dos o tres dígitos), se los intenta agrupar tomando en cuenta las decenas (o centenas) que constituyen el "**tallo**", y contabilizando las unidades (o decenas), que corresponden a cada grupo (las que pasan a constituir las "**hojas**").

1. Construir el "**tallo**"
2. Agregar las "hojas" a medida que se observan
3. Completar todas las hojas
4. Ordenar las hojas

Continuará en Unidad 3

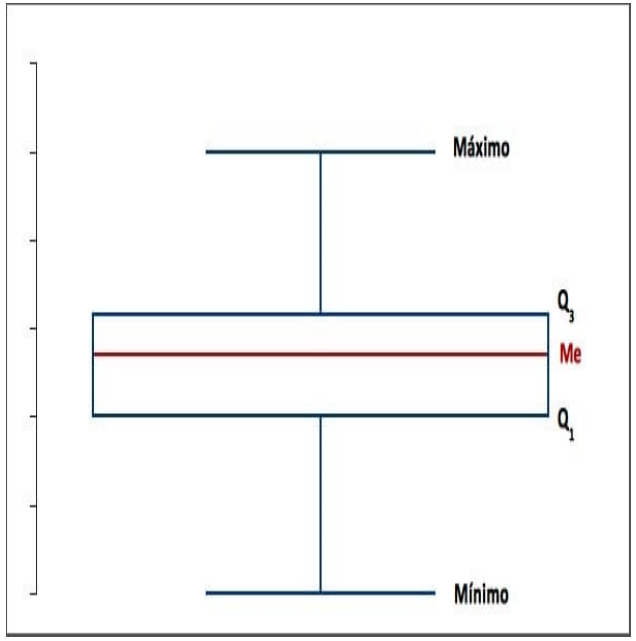
FADENA

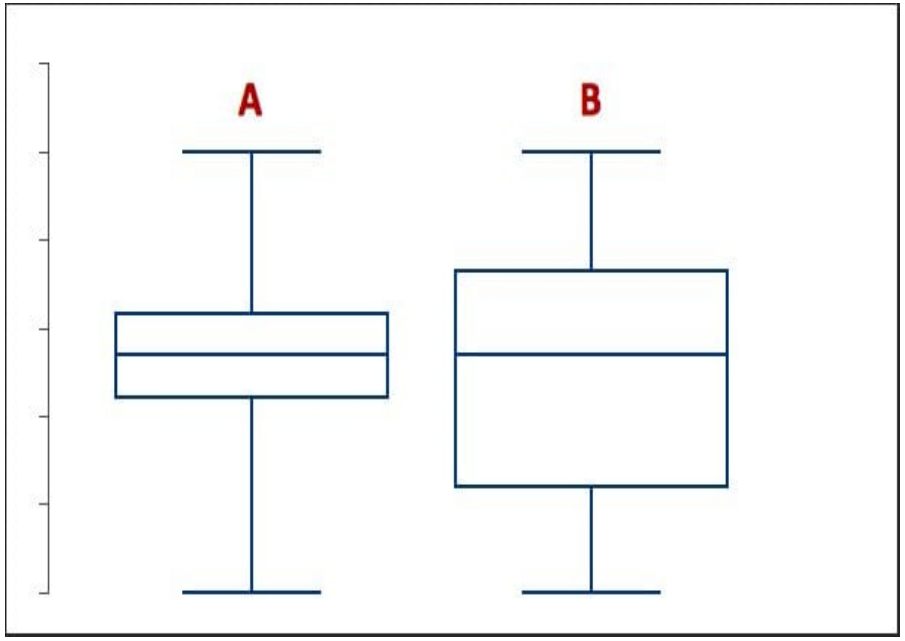
Universidad de la Defensa Nacional

CAJA , BIGOTES o BOX PLOT

Gráfica de un conjunto de datos que consiste en una línea que se extiende desde el valor mínimo hasta el valor máximo, así como una caja con líneas trazadas en el primer cuartil, Q1; la mediana y el tercer cuartil, Q3

Continuará en Unidad 3





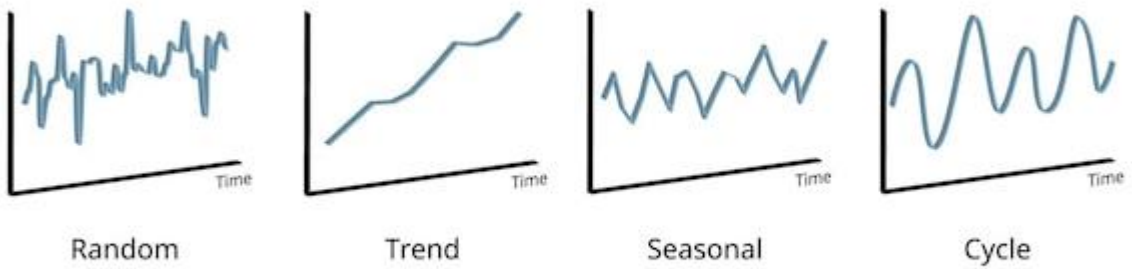
Son útiles para comparar dos o más conjuntos de datos.

FADENA

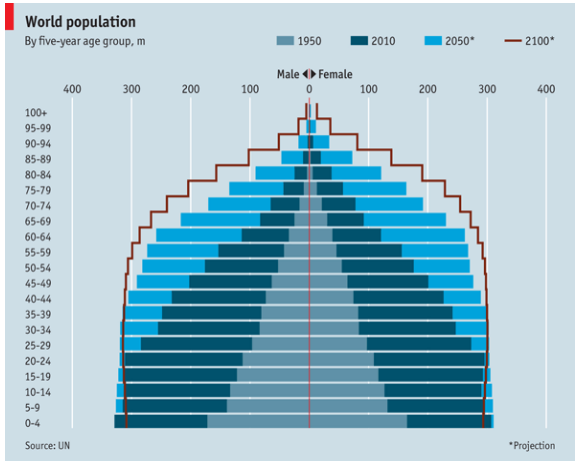
Universidad de la Defensa Nacional

OTROS GRÁFICOS

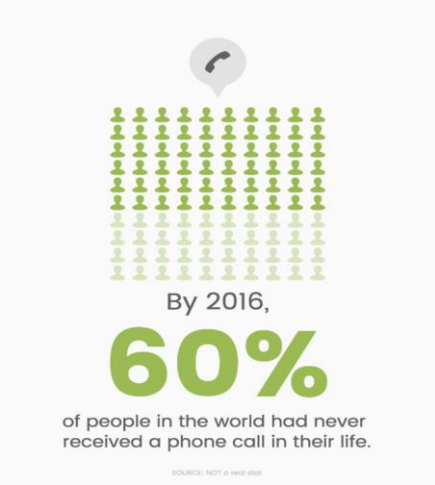
Gráficos de líneas



Pirámides de población

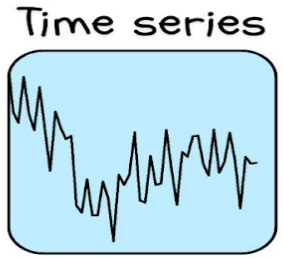


Pictogramas



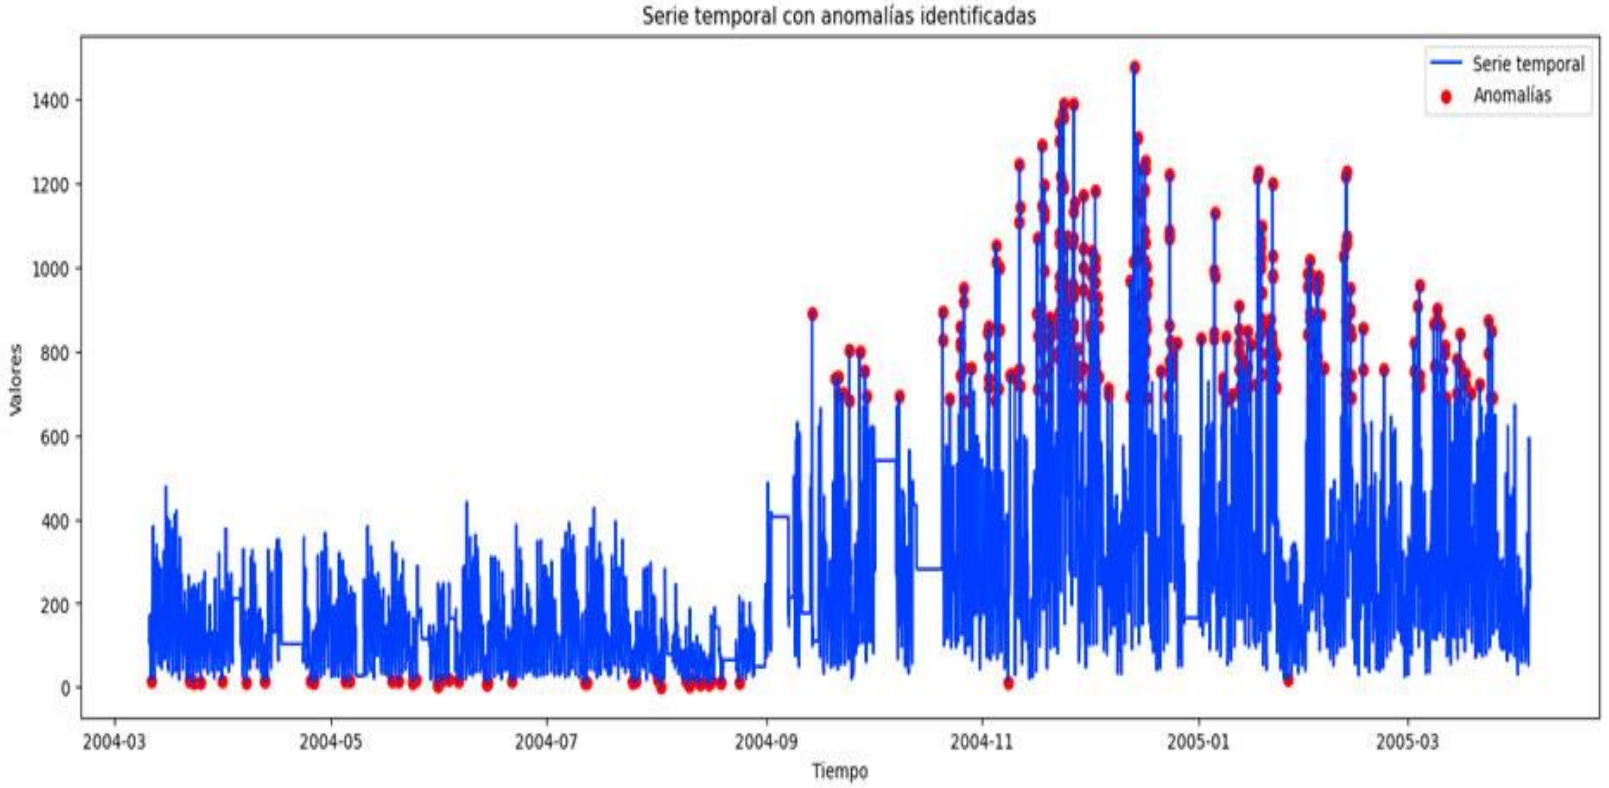
FADENA

Universidad de la Defensa Nacional



OTROS GRÁFICOS: De líneas. Series de tiempo

Eje X → Períodos
Eje Y → Variable



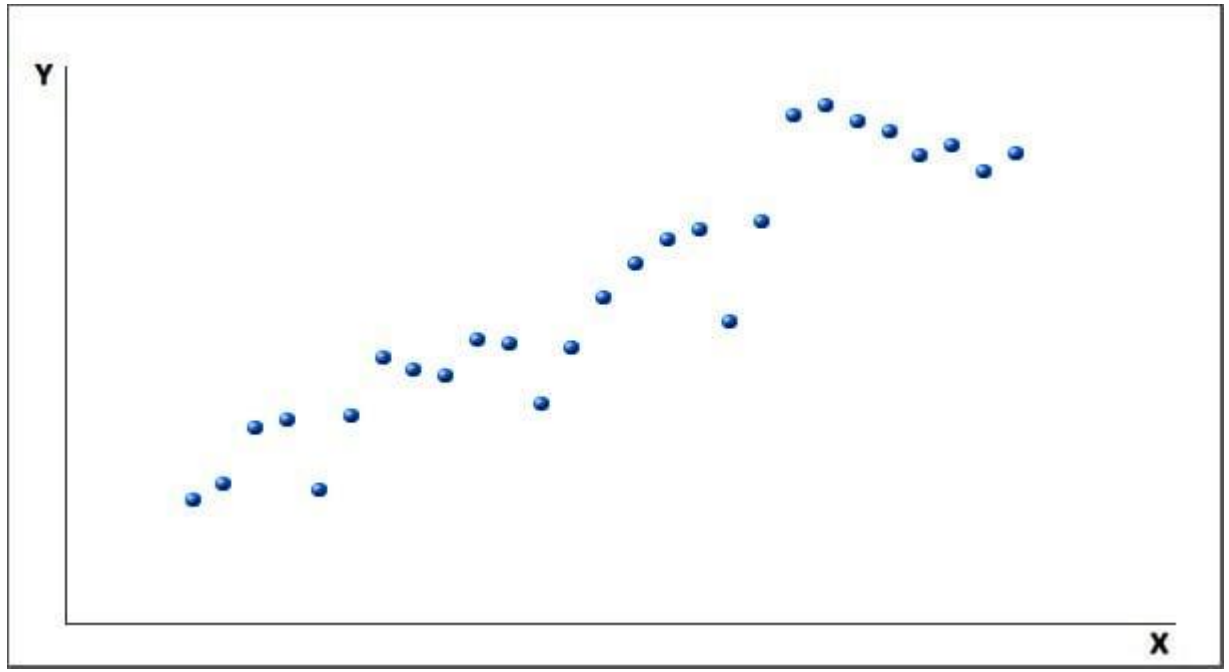
FADENA

Universidad de la Defensa Nacional

OTROS GRÁFICOS: Gráficos de Dispersión

Representación que permite analizar la **relación entre dos variables cuantitativas**

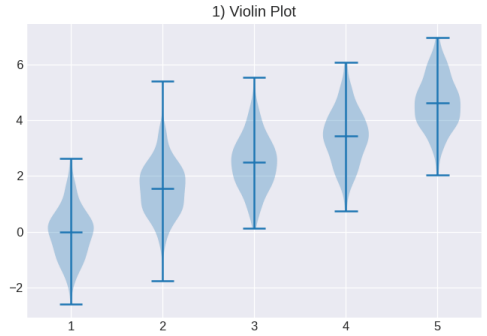
Ejemplo:
X: cantidad de intentos de acceso
Y: tiempo de respuesta del sistema

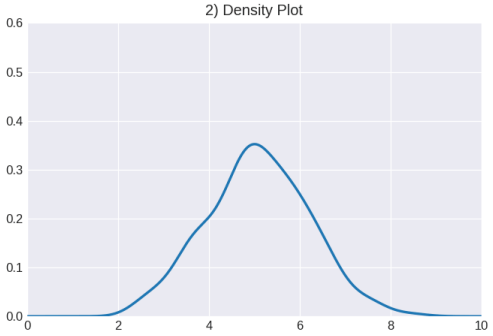


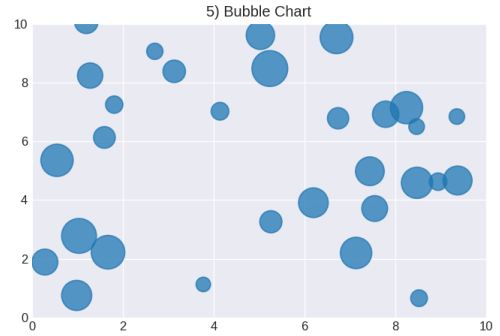
FADENA

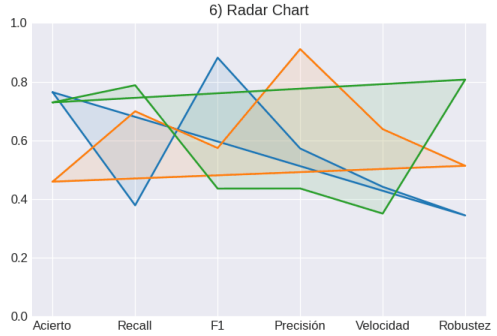
Universidad de la Defensa Nacional

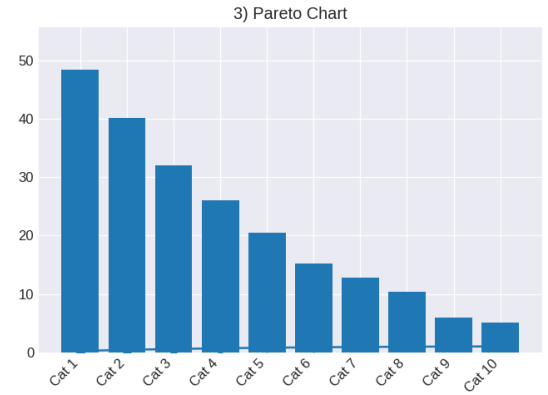
OTROS GRÁFICOS...más ejemplos

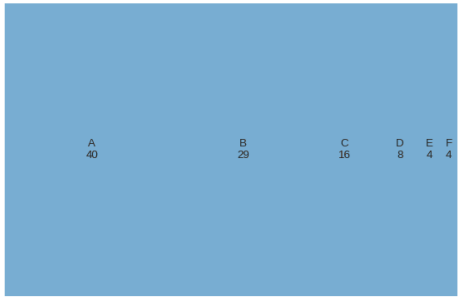


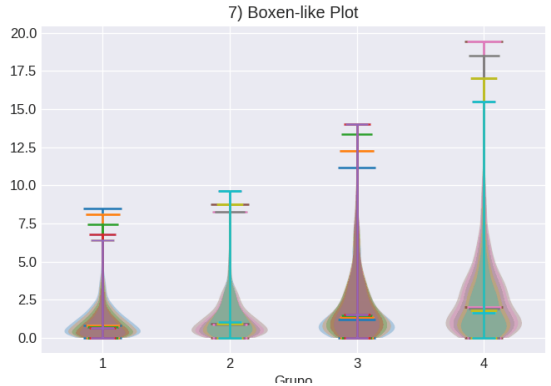


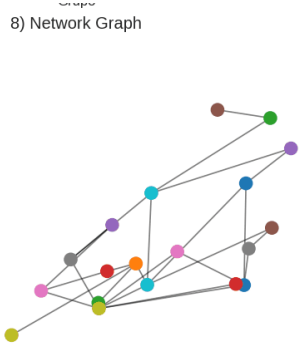












Clases de prácticas

- Vídeo 1: Matríz de datos en Excel
- Vídeo 2: Distribución de frecuencias
- Vídeo 2: Distribución de frecuencias (copia)
- Vídeo 3: Introducción a Jamovi (parte 1)
- Vídeo 5: Distribución de frecuencias- Jamovi

FADENA

Universidad de la Defensa Nacional

ACTIVIDADES COMPLEMENTARIAS

FADENA

ACTIVIDADES

PASO 1: Descargar Jamovi (software estadístico)

Para seguir la ejercitación de las actividades prácticas, solicitamos tener descargado el programa gratuito JAMOVI que se trata de es una interfaz gráfica de usuario de código abierto para el lenguaje de programación R.

Descargar carpeta

PASO 2: Utilizar estas matrices de datos

- Base 1 (video).xlsx
- Base 1.omv
- Base 1.xlsx

PASO 3: Guía de ejercicios (no obligatorios)

Universidad de la Defensa Nacional

MUCHAS GRACIAS

FADENA | Universidad de la Defensa Nacional