Eduardo Bologna

Métodos Estadísticos de Investigación



00026157

Editorial Brujas

Capítulo 3 La expresión resumida de la información

La segunda etapa en la descripción de datos consiste en calcular medidas que los resuman, que los expresen de manera sintética. Esta etapa implica un nuevo alejamiento de la información bruta, ya que se pierde de vista no solo a los individuos —presentes en la matriz de datos—, sino también a las distribuciones de frecuencia. La ventaja de resumir es la posibilidad de presentar la información de modo muy sintético; con unas pocas medidas descriptivas se ofrece bastante información sobre los datos que se han recogido.

Estas medidas requieren operaciones de diferente nivel de complejidad, por lo que apelan a diferentes propiedades de las escalas de medición, entonces no serán las mismas las medidas que se puedan calcular en una escala nominal que en una ordinal, intervalar o proporcional.

El objetivo de describir el conjunto de datos se logrará indicando tres tipos diferentes de medidas. En primer lugar, haremos referencia a las medidas de **posición**. Estas medidas indican en torno a qué valores se distribuyen las observaciones. Dentro de las medidas de posición, definiremos las medidas **centrales**, (también llamadas de **centralidad** o de **tendencia central**), y las **no centrales**. En segundo lugar, mencionaremos las medidas de **dispersión** (conocidas también como de **variabilidad**), que muestran si los datos están concentrados alrededor de las medidas de centralidad o si están alejados de esas medidas centrales. En tercer lugar, se describe la **forma** que toma la distribución, medida con dos indicadores: **simetría** y **curtosis**.

A los fines de la notación usada para referirse a cada una de estas medidas descriptivas, asumiremos que trabajamos sobre datos provenientes de una muestra, de la que *n* representa la cantidad de casos observados.

Medidas de posición

Como las operaciones que pueda hacerse entre las categorías dependen del nivel de medición de las variables, las medidas que se puedan calcular también dependerán del nivel de medición. Por eso las presentaremos separadamente para cada nivel, siempre recordando que las operaciones que son válidas a un determinado nivel de medición también son válidas para niveles más altos. Por ejemplo: lo que pueda hacerse con variables nominales, vale también para ordinales y métricas, con los ajustes de casa caso.

Medidas de centralidad

Son las que indican alrededor de qué valores de ubican las observaciones de una distribución de frecuencias.

Variables nominales: proporciones

Cuando se trabaja con una variable de nivel nominal, una manera sintética de presentar la información que ofrece la tabla de distribución de frecuencias es indicando la **proporción** de casos que se encuentran en una determinada categoría. Se trata de la frecuencia relativa simple (f) de una categoría particular. Sea la siguiente una clasificación de los diagnósticos dados por un psicólogo a un conjunto de pacientes:

Tabla 1

Diagnóstico	f	f'
Psicosis	10	0,125
Neurosis	50	0,625
Perversión	20	0,250
Total	80	1,000

Podemos indicar la proporción de casos diagnosticados como psicosis, como *p=0,125*, que puede también expresarse como 12,5%. La elección de cuál categoría se elige para indicar la proporción solo depende de los objetivos de la descripción. Al elegir una categoría se llama la atención sobre ella, se la destaca, ya que la proporción restante incluye a todas las demás categorías, los "otros". Esa proporción restante se obtiene restando de 1 (uno) la proporción indicada, o restando de 100 (cien) si ha expresado como porcentaje. En nuestro ejemplo, diremos que 0,875 (que proviene de hacer 1-0,125) es la proporción de *otros diagnósticos* o bien que éstos representan el 87,5% (100-12,5).

La **proporción** es la frecuencia relativa correspondiente a una categoría particular. Usualmente se expresa como porcentaje. Se indica como *p*.

Esta medida descriptiva se usa a menudo cuando la variable nominal tiene solo dos categorías (variable dicotómica), ya que se presenta la proporción de una de ellas e inmediatamente se sabe que el complemento es la proporción de la otra. Si se trata de pacientes que consultan a un servicio de admisión psicológica en un hospital, ellos pueden ser clasificados como sigue:

Tabla 2

Resultado de la entrevista de admisión	f	f'
Admitido como paciente	150	0,75
No admitido	50	0,25
Total	200	1,00

Eligiendo como categoría de referencia "Admitido como paciente", resulta ser *p=0,75*, que dice que la proporción de pacientes admitidos es de 0,75, o del 75%. Si se resume la tabla diciendo que "el 75% de las personas que consultan es admitido", se sabe de inmediato que el 25% restante no es admitido.

Esta medida ya apareció al definir la proporción como el cociente entre la frecuencia propia de la categoría y el total de casos. Esta proporción puede también indicarse en variables de nivel de medición superior al nominal, pero no resulta de interés cuando hay gran cantidad de categorías. Así, por ejemplo, si se trata de la distribución de las notas de un parcial, no se estila indicar cuál es la proporción de cada calificación e indicar algo como "el 20% sacó 8" (lo que se vería en una tabla de distribución de frecuencias de las notas). Por el contrario, es común construir variables nominales a partir de las notas y es de mucho interés indicar, por ejemplo, la proporción de *promocionados*, o la proporción de quienes *quedaron libres*.

Variables nominales: tasas

Se define habitualmente como **tasa** a la frecuencia relativa de un fenómeno en referencia a una población total, con la caracteristica de tener en cuenta un periodo de tiempo. También es común el uso del término cuando se trata de hechos de poca incidencia, es decir que su frecuencia es pequeña. En esos casos se la suele expresar cada 1.000, cada 10.000, o inclusive cada 100.000 casos. Por ejemplo, la tasa de mortalidad por accidentes de vehiculos de motor de personas entre 25 y 34 años de edad en México, en 1972[14], es de 12,6 por 100.000. La lectura de este dato debe hacerse considerando que el total sobre el que se calcula corresponde al total de personas de ese grupo de edad. Se obtienen dividiendo la cantidad de ocurrencias (muertes, nacimientos, casos nuevos de enfermedad, etc.) en una población dada en un momento especificado.

Variables nominales: razones

La palabra **razones** se usa a menudo para referirse a cocientes calculados entre conjuntos que no tienen elementos en común. Por ejemplo, se llama razón de masculinidad a la cantidad de hombres por cada 100 mujeres que hay en una población. Se obtiene dividiendo el total de varones por el total de mujeres (y luego multiplicando por 100), que son dos conjuntos que no se superponen. Esta medida se conoce también como índice de masculinidad.

Por ejemplo: el grupo de estudiantes que cursó Estadistica en Psicologia en 2010 estuvo compuesto por 1050 mujeres y 280 varones, por lo que la razón de masculinidad es de 27 (que resulta de 280/1050*100), al que leemos como 27 varones por cada 100 mujeres.

En la población general de la ciudad de Córdoba, según el censo de 2010, la razón (o índice) de masculinidad es de 91,9 varones cada 100 mujeres. La diferencia entre una razón y una tasa es que en la primera, el numerador no está incluido en el denominador. También se la indica como **ratio**.

Variables nominales: el modo

El **modo**, o **moda**, o **valor modal** es el valor de la variable (la categoria) que tiene la mayor frecuencia. Dicho de otra manera, el valor de la variable más frecuentemente observado[15]. Esta medida no requiere ningún cálculo, no exige ninguna propiedad de la escala de medición, por lo tanto se puede indicar en variables desde el nivel nominal, es decir en todos los niveles de medición.

La variable *carrera que cursa*, tiene la siguiente distribución:

carrera	f	f
Educación	44	0,29
Psicologia	48	0,32
Psicopedagogia	58	0,39
Total	150	1,00

El modo es Psicopedagogia, que es la categoria de mayor frecuencia. Debe cuidarse de no cometer el error de señalar la frecuencia 58 como el modo; el modo no es la

---

[14] Tomado de Guerrero et al (1986). Material bibliográfico de la Cátedra de Psicología Sanitaria.

[15] Esta es la idea que transmite el lenguaje coloquial: cuando algo es "la moda", es lo que más comúnmente (frecuentemente) se ve.

frecuencia más alta, sino la categoría de la variable que tiene mayor frecuencia. Para hallarlo, se identifica la más alta de las frecuencias y se señala la categoría que le corresponde.
Si se trata de una variable de mayor nivel de medición, no hay ninguna diferencia. La variable *concepto que los docentes asignan a los alumnos* tiene la distribución de frecuencias siguiente:

concepto	f
Excelente	150
Muy bueno	350
Bueno	200
Satisfactorio	120
No satisfactorio	50
Total	870

En este ejemplo, 350 es la frecuencia más alta, por lo tanto, la categoría que a ella corresponde es el modo: el modo de la distribución es "Muy bueno".

El **modo** es la categoría —o el valor— de la variable que tiene mayor frecuencia.
Se indica M_o

Cuando se trabaja sobre variables intervalares o proporcionales discretas no hay diferencia en la identificación del modo de la distribución. El *número de materias que tienen aprobadas alumnos que han terminado de cursar el primer año* de su carrera se distribuye así:

Cantidad de materias aprobadas	f
0	30
1	150
2	200
3	300
4	250
5	200
6	20
Total	1150

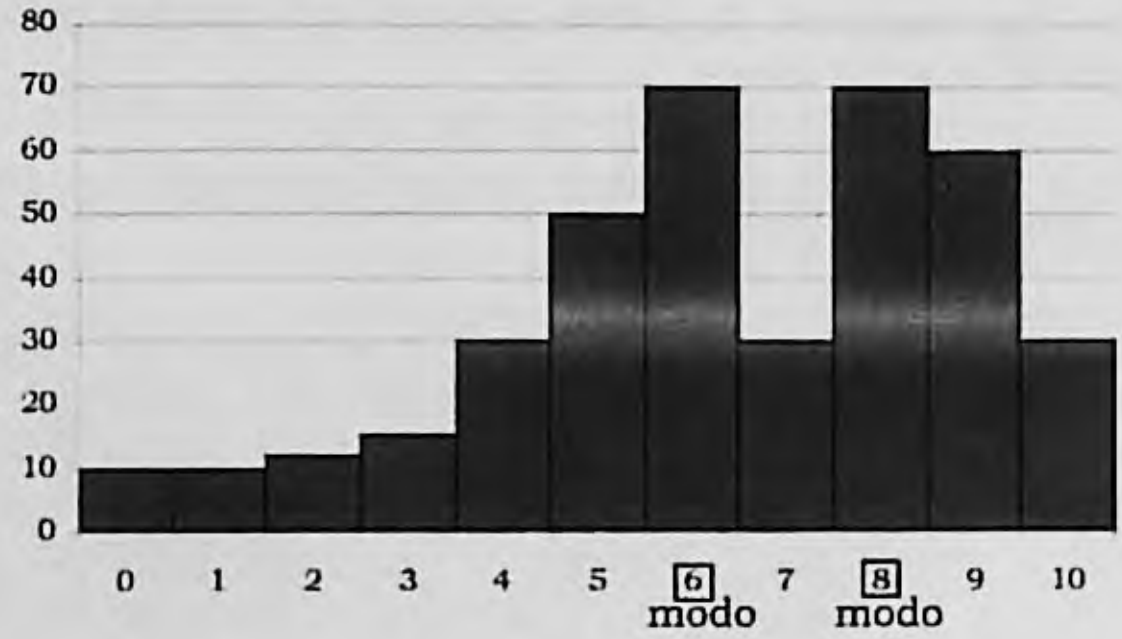
En esta distribución, el modo es 3 materias aprobadas ($M_o=3$), que es la categoría que tiene mayor frecuencia. Expresamos esto como "la mayor cantidad de alumnos que terminaron de cursar primer año han aprobado tres materias".
Puede suceder que en una distribución no haya una única categoría de mayor frecuencia, sino que dos o más compartan la mayor frecuencia. Para 160 alumnos clasificados según la facultad en que cursan su carrera, tenemos:

Facultad a la que pertenece	f
Arquitectura	50
Ingeniería	40
Psicología	50
Filosofía	20
Total	160

Vemos aquí que hay dos categorías que presentan la mayor frecuencia: Arquitectura y Psicología. Decimos en este caso que la distribución es **bimodal** que quiere decir que tiene dos modos.

Una distribución es **bimodal** cuando dos categorías tienen la mayor frecuencia. Si son más las categorías que comparten la mayor frecuencia, la distribución se denomina **multimodal**

Una representación gráfica de una distribución bimodal, para la variable *número de respuestas correctas en una prueba de opción múltiple*, la siguiente



La moda tiene el inconveniente de ser independiente de la mayor parte de los datos, por lo que es sensible a cambios en los valores de la distribución. En efecto, las siguientes dos muestras de 130 escuelas tienen la misma moda (M_o=*Pública*), aunque son muy dispares:

Gestión de la escuela	f
Pública	50
Privada laica	45
Privada confesional	35
total	130

Gestión de la escuela	f
Pública	100
Privada laica	20
Privada confesional	10
total	130

Variables ordinales: la mediana

Como ya hemos visto, cuando las categorías de la variable están ordenadas pueden hacerse juicios como "mayor que" (>) o "menor que" (<), y el nivel de medición es ordinal. En este tipo de variables puede calcularse otra medida de centralidad, que usa esa propiedad: la del orden entre categorías. Se trata de la **mediana**, que se podrá también calcular para escalas superiores (intervalar y proporcional) pero no para escalas nominales, en las que el orden entre categorías no está presente.

Esta medida se define como el valor de la variable que deja por debajo la mitad del total de observaciones. Se trata de la mitad de los casos y no la mitad de las categorías. La siguiente distribución presenta en serie simple ordenada el número de sesiones de psicoterapia que recibieron 9 pacientes internados en un hospital:

2, 2, 3, 5, 7, 10, 15, 19, 50

La mediana de estos datos es 7, porque es el valor que deja cuatro casos por debajo y también cuatro casos por encima. Atención a que la serie simple debe estar ordenada para poder identificar a la mediana.

Si la cantidad de observaciones fuera par como por ejemplo:

2, 2, 3, 5, 7, 10, 15, 19

El punto de corte correspondiente a la mitad de las observaciones se ubica entre 5 y 7, en este caso, la mediana es el promedio entre los dos valores centrales, que es 6.

Cuando hay valores repetidos en la parte central no resulta posible indicar la mediana, por ejemplo si la serie fuera:

2, 3, 7, 7, 7, 10, 15, 19

No puede señalarse a 7 como la mediana, porque es superado por tres valores (10, 15 y 19) pero supera solo a dos (2 y 3).

La mediana es una medida muy adecuada cuando se necesitan resumir datos que provienen de escalas ordinales o de nivel superior. Sin embargo, su cálculo no aporta nada en series simples con pocos casos (como los que acabamos de ver) ya que allí es más sencillo mostrar el conjunto completo de datos y no usar medidas resumen. Los ejemplos sirven para ilustrar el concepto, pero no es usual en la práctica. Las operaciones de resumen se justifican cuando se tiene un conjunto grande de datos.

Se denomina **mediana** al valor de la variable que deja por debajo a la mitad de las observaciones. La mediana deja la misma cantidad de casos por debajo y por encima de ella. Se indica Md_n.

Veamos la forma de reconocer a la mediana cuando los datos están presentados en una distribución de frecuencias. La siguiente es una clasificación de hogares por nivel socioeconómico:

Nivel socioeconómico	f (número de hogares)	F
Marginal	40	40
Bajo	100	140
Medio-bajo	120	260
Medio	150	410
Alto	30	440
Total	440	

La mitad del número total de casos es 220, que resulta de dividir por dos los 440 casos del total (440/2, equivalente a (1/2)*440). Entonces, para hallar la mediana, se debería identificar al caso (al hogar en el ejemplo) que ocupa el lugar 220. Según la tabla, hasta la categoría "medio-bajo" se acumulan 260 hogares y hasta la categoría anterior hay 140 acumulados. De manera que el hogar que ocupa el lugar 220 es uno de los que se encuentran en la categoría "medio-bajo". Diremos así que la mediana de esta distribución es "medio-bajo". Como puede verse, esta categoría no acumula exactamente la mitad de las observaciones, pero

es la que contiene a la observación que supera a la mitad y es superada por la otra mitad. Por esa razón la leemos como la mediana, diciendo que la mitad de los hogares tiene un nivel socioeconómico medio-bajo o inferior a ese.

La imprecisión señalada en este ejemplo también aparece si se trata de una variable cuantitativa discreta. Si la variable es el *número de síntomas* a partir de los cuales fueron diagnosticados de esquizofrenia un conjunto de pacientes[16]:

Cantidad de síntomas	f (número de pacientes	F
2	30	30
3	60	90
4	70	160
5	90	250
Total	250	

La mitad del número total de casos es de 125 (250/2 ó (1/2)*250), ¿cuál es el caso que ocupa ese lugar? Vemos que hasta 3 síntomas se acumulan 90 pacientes y 160 hasta los 4. El paciente que ocupa el puesto 125 en la serie simple ordenada es uno de los que fueron diagnosticados a partir de 4 síntomas. Por esa razón indicamos a la mediana con ese valor: 4, $M_{dn}=4$. Nuevamente encontramos que no es exactamente el valor que acumula la mitad, sino uno de los que están en la categoría dentro de la cual se acumula la mitad de los casos. La primera categoría que tenga una frecuencia acumulada superior al 50% será la que contenga a la mediana. Es así porque la clase anterior no alcanza a acumular la mitad de las observaciones. La lectura del resultado es que la mitad de los pacientes fue diagnosticada de esquizofrenia en presencia de cuatro síntomas o menos.

Sea la variable *número de materias aprobadas*:

Número de materias aprobadas	f	F
0	30	30
1	150	180
2	200	380
3	300	680
4	250	930
5	200	1130
6	20	1150
Total	1150	

La mitad de 1150 es 575, la primera frecuencia acumulada que supera a 575 es 680, que corresponde al valor 3. La mediana de esta distribución es entonces tres materias aprobadas y diremos que el 50% de los alumnos aprobó tres materias o menos.

---

[16] El manual DSM IV indica como síntomas característicos a dos (o más) de los siguientes, cada uno de ellos presente durante una parte significativa de un periodo de 1 mes: ideas delirantes, alucinaciones, lenguaje desorganizado (p. ej., descarrilamiento frecuente o incoherencia), comportamiento catatónico o gravemente desorganizado, síntomas negativos, por ejemplo, aplanamiento afectivo, alogia o abulia.

Cuando se trata de variables de nivel intervalar o proporcional y con categorías agrupadas, el cálculo anterior puede refinarse. Así, primero se identifica la categoría (el intervalo) en que se encuentra la mediana, igual que en los dos ejemplos anteriores y luego se interpola dentro del intervalo para encontrar su valor exacto.

Tiempo de reacción (en segundos)	f	F
1,0-1,5	5	5
1,5-2,0	7	12
2,0-2,5	6	18
2,5-3,0	3	21
3,0-3,5	8	29
3,5-4,0	5	34
Total	34	

La mitad de las 34 observaciones es 17, por lo que debe encontrarse una observación que tenga frecuencia acumulada de 17. Ese valor no aparece en la F, el primero que lo supera es 18, entonces la mediana estará en el intervalo 2,0-2,5. Esto es así porque hasta 2,0 se acumulan 12 casos (la F de la categoría anterior) y hasta 2,5 se acumulan 18. Nuestros 17 casos se acumulan para un valor de la variable que está entre 2,0 y 2,5.
Debemos ahora encontrar qué valor exactamente es la mediana, dentro del intervalo 2,0-2,5. La fórmula para este procedimiento es la siguiente:

$$M_{dn} = l_l + i * \left(\frac{\frac{n}{2} - F}{f_p}\right)$$

En la que:
l_l indica el límite inferior del intervalo en que se encuentra la mediana, en este caso es 80.
I es la amplitud del intervalo, es decir la diferencia entre los límites 2,0-2,5 = 0,5
$\frac{n}{2}$ es la mitad del número total de observaciones, es este caso, 17
F_d es la frecuencia acumulada por **d**ebajo de la categoría que contiene la mediana, en esta tabla es 12
f_p es la frecuencia **p**ropia del intervalo en que se encuentra la mediana. Es la frecuencia absoluta (no la acumulada), en este ejemplo es 6.

Reemplazando resulta:

$$M_{dn} = 2{,}0 + 0{,}5 * \left(\frac{17 - 12}{6}\right) = 2{,}0 + 0{,}5 * \left(\frac{5}{6}\right) = 2{,}42$$

Conviene detenerse en el orden en que se realizaron las operaciones. El signo más (+) separa términos, por lo que debe primero resolverse el segundo de ellos y luego recién sumar 2,0. Un error frecuente es el de sumar 2,0+0,5 y luego multiplicar por el resultado del paréntesis, eso es incorrecto.
Por cierto que debe verificarse que el valor encontrado se ubique dentro del intervalo; en este ejemplo, la mediana no podría ser menor que 2,0 ni mayor que 2,5. Observemos también que el número de categorías de la variable, que es de 6,

no participa en el cálculo de la mediana, de ningún modo se trata de una categoría que esté "al medio".

El resultado obtenido nos dice, según la definición de la mediana que "el 50% de los sujetos experimentales reaccionó en un tiempo de 2,42 segundos o inferior". Es muy importante la última parte de la lectura, porque cuando decimos "o inferior" incluimos los valores por debajo del indicado.
La mediana encontrada, de 2,42, es un valor razonable a partir de la observación de la tabla: la categoría de la mediana acumulaba 18 casos, que es apenas más que la mitad de las observaciones (17), por lo que era de esperar que la mediana apareciera cerca del límite superior del intervalo, que es lo que sucedió.
Este procedimiento para calcular la mediana es impreciso, porque supone que los valores están distribuidos de manera uniforme dentro de cada intervalo. Si los 6 valores que contiene el intervalo 2,0 – 2,5, fueran todos iguales a 2,01, por ejemplo, la mediana sería un número bastante menor al que se calculó con este método. El uso de la interpolación solo se justifica en situaciones en que la única información disponible es la tabla con los valores agrupados; por el contrario, si se cuenta con la matriz de datos, el cálculo debe hacerse usando todos los valores observados de la variable. Como esto es largo para hacer manualmente, se solicita a un software especializado.

Variables métricas: la media o promedio
Si se ha alcanzado un nivel de medición intervalar o proporcional, es posible hacer uso de las propiedades[17] que estas escalas tienen. Recordemos que además de designar y ordenar, las escalas intervalares conservan las distancias entre observaciones, y las proporcionales agregan la proporcionalidad de los valores absolutos y el carácter absoluto del cero. En este nivel los números que representan las categorías (o valores) pueden tratarse como tales y se puede operar con ellos. Antes de dar una definición de la media o promedio, veamos la idea intuitiva que tenemos, ya que se trata de una medida de mucho uso. Cuando queremos calcular un promedio "sumamos y dividimos por la cantidad de casos". Así, si tres personas cometen 5, 8 y 12 errores cada uno, el promedio de esa variable (número de errores) es $\frac{5+8+12}{3} = \frac{25}{3} = 8{,}33$. Usaremos la expresión $\bar{x}$ para referirnos a la media, con lo que el resultado se escribe: $\bar{x} = 8{,}33$ errores.

¿Cómo extenderemos esta forma de cálculo al caso en que la variable no está presentada en serie simple sino en distribución de frecuencias? Recordando que la frecuencia indica la cantidad de veces que cada valor se repite, por lo que habrá que considerar cada valor tantas veces como lo indique su frecuencia absoluta simple. Veamos un ejemplo en el que se cuenta el número de materias aprobadas:

[17]Propiedades que se agregan a las de las escalas de menor nivel, por lo que modo y mediana pueden calcularse e interpretarse también en las escalas métricas.

Número de materias aprobadas	f
0	30
1	150
2	200
3	300
4	250
5	200
6	20
Total	1150

El valor 0 (cero) está repetido 30 veces, lo que indica que hay 30 alumnos que no han aprobado aún ninguna materia. Del mismo modo, 150 alumnos aprobaron 1 materia, etc., por lo que si estuvieran presentados en serie simple, se sumarian los 1150 valores (30 veces el 0, 150 veces el 1, etc.) y esa suma se dividiría por 1150. Para hacerlo sobre la distribución de frecuencia, se multiplica cada valor de la variable por su frecuencia (que es equivalente a sumarlo tantas veces como aparece) y se divide por el total de casos. Resulta:

$$\bar{x} = \frac{0 * 30 + 1 * 150 + 2 * 200 + 3 * 300 + 4 * 250 + 5 * 200 + 6 * 20}{1150} = 3.10$$

La expresión formal de este cálculo es:

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i * f_i}{n}$$

En la que x_i es cada valor de la variable, f_i es su frecuencia absoluta simple, k es el número de categorias y n es el total de observaciones. La fórmula indica que cada valor de la variable (x_i) se multiplica por su frecuencia (f_i), se suman desde el primero ($i=1$) hasta el último (k) y el resultado se divide por el total de casos (n).

Veamos que no se trató como podríamos haber pensado rápidamente, de sumar desde el cero hasta el seis y dividir por siete. Haber hecho eso habria implicado dos errores: el primero es el de no considerar cuántas veces está repetido cada valor (su frecuencia absoluta simple), el segundo es el de confundir el número de casos (1150) con el número de categorias (7). Este último error puede provenir de una confusión entre la presentación en serie simple o en distribución de frecuencias. Cuando se observa una serie simple, los valores "sueltos" de la variable coinciden con sus categorias, pero cuando se agrupa, cada categoria incluye cierta cantidad de casos que tienen el mismo valor, lo cual está indicado en la frecuencia de cada categoria.

En el ejemplo anterior entonces, el número promedio de materias aprobadas es 3,10. Este número no es entero y no es un valor que se pueda observar; nadie tiene 3,10 materias aprobadas. Sin embargo, es valioso para caracterizar a la distribución completa y para hacer comparaciones. Por ejemplo, si en un grupo de alumnos la media es de 3,10 materias aprobadas y en otro de 3,90; puede decirse que en el segundo grupo los alumnos han aprobado —en promedio—, más materias; aunque ninguno haya aprobado 3,10 ni 3,90 materias.

Por el momento ofreceremos una definición operacional de la media, más adelante podrá darse una definición conceptual, basada en sus propiedades.

La **media** (o promedio) es un valor de la variable obtenido sumando todas las observaciones multiplicadas por su frecuencia absoluta y dividiendo el resultado en el número total de casos. Se indica como $\bar{x}$ (equis media).

Cuando la distribución de frecuencias presenta los datos agrupados, aparece el problema de no tener un único valor en cada categoría. Por ejemplo y nuevamente en el caso de los tiempos de reacción:

Tiempo de reacción (en segundos)	f
1,0-1,5	5
1,5-2,0	7
2,0-2,5	6
2,5-3,0	3
3,0-3,5	8
3,5-4,0	5
Total	34

Aquí no hay un valor único en cada categoría, sino un intervalo que incluye diferentes valores. Esto se resuelve considerando, para cada intervalo, su **marca de clase** (el punto medio), que es el promedio de los extremos de cada intervalo. La siguiente tabla agrega las marcas de clase de cada intervalo, indicadas como x':

Tiempo de reacción (en segundos)	x'	f
1,0-1,5	1,25	5
1,5-2,0	1,75	7
2,0-2,5	2,25	6
2,5-3,0	2,75	3
3,0-3,5	3,25	8
3,5-4,0	3,75	5
Total		34

Ahora puede usarse el método anterior para calcular la media, tomando las marcas de clase como los valores de la variable:

$$\bar{x} = \frac{1{,}25 * 5 + 1{,}75 * 7 + 2{,}25 * 6 + 2{,}75 * 3 + 3{,}25 * 8 + 3{,}75 * 5}{34} = 2{,}5$$

Resulta así que el tiempo promedio de reacción es de 2,5 segundos. Este procedimiento es impreciso, porque asigna a todos los casos que están dentro de cada categoría el mismo valor (el centro del intervalo) y se justifica en situaciones en que la única información disponible es la tabla con los valores agrupados; si se cuenta con la matriz de datos, el cálculo debe hacerse usando todos los valores observados de la variable, recurriendo a un software especializado cuando sean muchos datos.

Si bien la media es una medida muy valiosa para resumir un conjunto de datos, a veces se hace un uso abusivo de ella, al aplicarla a variables que no tienen el nivel de medición adecuado para autorizar su uso. Un ejemplo de esto es el caso

de las calificaciones escolares, que solo permiten ordenar a los alumnos según los resultados, pero que no implican la proporcionalidad de los valores (quien obtiene 10 no sabe el doble que quien obtiene 5). Aun asi, es habitual que se calcule incorrectamente el "promedio de las notas".

Medidas no centrales

Los cuartiles

Si la variable tiene un nivel de medición ordinal o superior, entonces podemos usar el mismo razonamiento con el que definimos la mediana para hacer cortes más finos en una distribución de frecuencia. Así, si la mediana nos indica el valor de la variable que deja por debajo la mitad de los casos, es lícito preguntar también por el valor que deja por debajo un cuarto de los casos, o también el que deja por debajo las tres cuartas partes de las observaciones. Estos puntos de corte se denominan respectivamente: primer cuartil y tercer cuartil.

El primer cuartil es el valor de la variable que deja por debajo un cuarto, o el 25% del total de observaciones.

El tercer cuartil es el valor que deja por debajo las tres cuartas partes o el 75% del total de observaciones. Como se ve, tanto el modo de cálculo como la interpretación son análogos a la mediana. Veamos su aplicación a los ejemplos anteriores:

Número de materias aprobadas	f	F
0	30	30
1	150	180
2	200	380
3	300	680
4	250	930
5	200	1130
6	20	1150
Total	1150	

Para encontrar el primer cuartil será ahora necesario buscar un cuarto del total de casos: 287,5 ((1/4)*1150). La pregunta ahora es ¿cuál es la primera frecuencia acumulada que supera a 287,5? se trata de 380, que corresponde al valor 2 y éste es entonces el primer cuartil. Leemos así que un cuarto del total de alumnos tiene dos materias aprobadas o menos. También puede decirse que el 25% de los alumnos aprobó dos materias o menos. Si se toma la cantidad de materias aprobadas como un indicador del ritmo más rápido o más lento de avance en la carrera, aquí se lee que el 25% que avanza con más lentitud no llegó a aprobar tres materias

El **primer cuartil** es el valor de la variable que deja un cuarto (25%) de los casos por debajo y tres cuartos (75%) por encima. Se indica Q_1.

Idéntico razonamiento seguimos para calcular el tercer cuartil: las tres cuartas partes del total es 862,5 ((3/4)*1150). Buscamos luego la primera frecuencia acumulada que supera a ese valor y hallamos que es 930 y que su categoria correspondiente es 4. Entonces el tercer cuartil es 4 materias aprobadas. La

lectura será: las tres cuartas partes (o el 75%) de los alumnos aprobó cuatro materias o menos. Esto último implica que el 25% restante aprobó más de cuatro materias. Así, el grupo que avanza más rápido en la carrera aprobó más de cuatro materias en su primer año.

El **tercer cuartil** es el valor de la variable que deja tres cuartos (75%) de los casos por debajo y un cuarto (25%) por encima. Se indica Q_3.

Cuando se trata de distribuciones con categorías agrupadas, procedemos como antes con una leve modificación en la fórmula:

Tiempo de reacción (en segundos)	f	F
1,0-1,5	5	5
1,5-2,0	7	12
2,0-2,5	6	18
2,5-3,0	3	21
3,0-3,5	8	29
3,5-4,0	5	34
Total	34	

Para el primer cuartil debe hallarse la primera frecuencia que supera a un cuarto de las observaciones, de las 34, un cuarto es 8,5 y la primera frecuencia mayor que ese número es 12, por lo que el primer cuartil se encuentra en la categoría 1,5-2,0. Para interpolar en valor exacto usamos una expresión equivalente a la de la mediana:

$$Q_1 = l_i + i * \left(\frac{\frac{n}{4} - f_d}{f_p} \right)$$

En la que se cambia $\frac{n}{2}$ por $\frac{n}{4}$ y lo demás mantiene el mismo significado. Aplicándola a estos datos resulta:

$$Q_1 = 1{,}5 + 0{,}5 * \left(\frac{8{,}5 - 5}{7} \right) = 1{,}5 + 0{,}5 * (0{,}5) = 1{,}75$$

Leemos en resultado como: el 25% de los sujetos reaccionó en un tiempo de 1,75s o menos.

Para el tercer cuartil la fórmula se transforma en:

$$Q_3 = l_i + i * \left(\frac{\frac{3 \cdot n}{4} - f_d}{f_p} \right)$$

Cuyo cambio consiste en que va $\frac{3 \cdot n}{4}$ en lugar de $\frac{n}{4}$ y manteniendo el resto de los símbolos con el mismo significado.
Usando esta expresión, verifique el lector que para la distribución de los tiempos de reacción, el tercer cuartil es 3,28.

No hemos hecho mención a un "segundo cuartil", que sería el valor de la variable que acumula las dos cuartas partes de los casos, pero como las dos cuartas partes es la mitad, se trata simplemente de la mediana $Q_2 = M_{dn}$.

Los percentiles

Por el mismo camino pueden definirse cortes en otros puntos de la distribución, los más frecuentemente usados, por su generalidad, se conocen como percentiles. Se trata de valores de la variable que dejan por debajo (acumulan) distintos porcentajes de casos.

El **percentil *r*** de una distribución es el valor de la variable que deja el r por ciento de los casos por debajo de él y (1-r) por ciento de los casos por encima. Se indica P_r.

Así por ejemplo, el percentil 10 (indicado como P_{10}) es el valor de la variable que acumula el 10% de las observaciones. Se representa de modo general un percentil dado como P_r en el que *r* indica el porcentaje del que se trata. La expresión para el cálculo de cualquier percentil es:

$$P_r = l_i + i * \left(\frac{\frac{r}{100} * n - f_d}{f_p} \right)$$

Son fáciles de observar las siguientes equivalencias:

$$Q_1 = P_{25}$$
$$M_{dn} = P_{50}$$
$$Q_3 = P_{75}$$

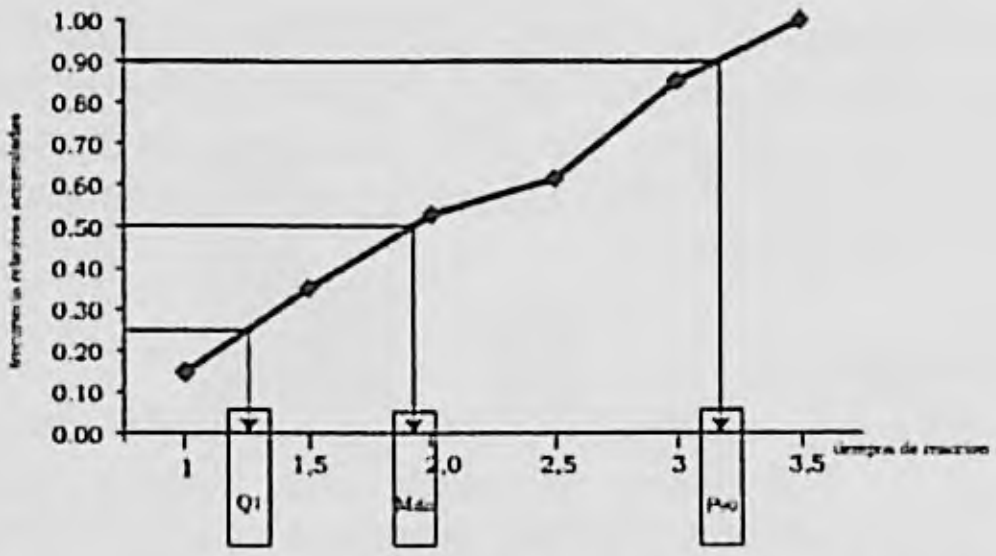
También suelen mencionarse, en algunas publicaciones, otros puntos de corte, como por ejemplo los quintiles. Esta medida representa valores que acumulan quintos (20%) de la distribución. La equivalencia es la siguiente:

Quintil:	Equivale a:
Primero	P_{20}
Segundo	P_{40}
Tercero	P_{60}
Cuarto	P_{80}

Para los cálculos con la fórmula de interpolación se reemplaza el $\frac{n}{2}$ de la mediana por $\frac{r}{100}$ para el percentil *r*. Esta manera de calcular los percentiles tiene la misma limitación mencionada para la mediana.

Obtención gráfica de los percentiles

Todas las medidas que hacen uso de las frecuencias acumuladas (mediana, cuartiles, percentiles) pueden obtenerse de manera aproximada a través del gráfico de frecuencias acumuladas, la ojiva de Galton. Veamos la forma de identificar el primer cuartil, la mediana y el percentil 90 en el ejemplo de los tiempos de reacción:



En el gráfico se ve que, si se ubica en el eje de las ordenadas la frecuencia relativa acumulada de 0,25 (un cuarto) y desde allí se llega hasta la ojiva, entonces en el eje horizontal (valores de la variable) se encuentra el primer cuartil. Para hallar la mediana se empieza ubicando en el eje vertical la frecuencia relativa acumulada de 0,50 (la mitad) y luego se la identifica en el eje horizontal. Del mismo modo con el percentil 90, ubicando ahora la frecuencia relativa acumulada de 0,90.

Obtención informática de las medidas de posición

Cuando se dispone de la matriz de datos, no se utilizan las fórmulas para interpolar, sino que se solicitan a un software que hace las operaciones sobre el conjunto completo de datos. El paquete estadístico InfoStat® obtiene estas medidas de tendencia central directamente desde los datos sin que sea necesario mostrar la distribuciones de frecuencia aunque se pueden pedir para mostrar más detalles sobre la variable que se observa. Los videos *descriptivos primera parte* y *descriptivos segunda parte* ilustran el modo de pedir estas medidas a Infostat®. Por ejemplo, para el número de errores cometidos por un conjunto de 1339 personas al responder a una prueba de diez preguntas, se obtiene la siguiente salida:

Medidas resumen

Resumen	numero de errores
n	1339
Media	3,18
Mín	0,00
Máx	8,00
Mediana	3,00
Q1	2,00
Q3	5,00
P(05)	0,00
P(10)	1,00
P(90)	6,00
P(95)	7,00
Percentil99	8,00

Esta descripción de los datos puede leerse del siguiente modo:
Cuando 1339 personas respondieron a una prueba de diez preguntas, el número promedio de preguntas respondidas de manera equivocada fue de 3,18. La cantidad de errores cometidos fue desde cero hasta ocho. La mitad de los

participantes cometió tres errores o menos, el 25% cometió dos o menos y el 75% hasta cinco. El 5% no cometió ningún error, el 10% cometió uno o ninguno. El 90% cometió seis errores o menos, el 95% cometió siete o menos. También decirse, usando el P_{90}, que solo el 10% cometió más de seis errores, o con el P_{95}, que solo el 5% cometió más de siete.

La forma de la distribución

La media es una medida muy completa como resumen de los datos, ya que los considera a todos con la frecuencia de cada uno. Opera como un punto de equilibrio en un conjunto de datos. Sin embargo esto puede ser una dificultad en algunos tipos de distribución. Consideremos el siguiente ejemplo simple:

x	f
3	16
4	7
6	6
10	3
total	32

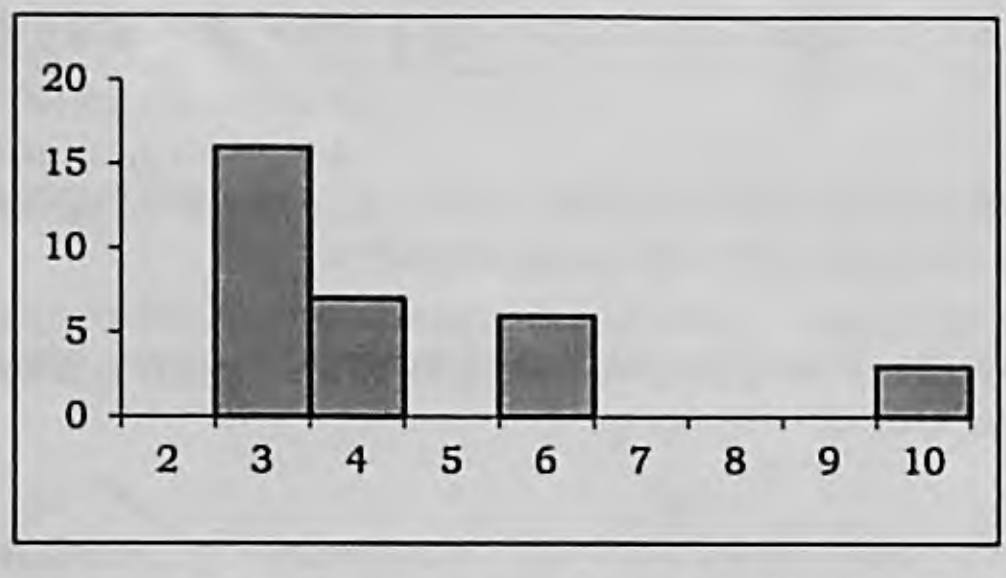
Estos datos muestran una marcada concentración en el valor 3, donde se encuentra la mitad de las observaciones. El resto de los valores son superiores y hay uno extremo, el 10, que tiene poca frecuencia: hay solo tres observaciones con ese valor. Veamos cuál es el efecto de esta forma de distribuirse de los datos. La media es:

$$\bar{x} = \frac{3 * 16 + 4 * 7 + 6 * 6 + 10 * 3}{32} = 4{,}44$$

A pesar de la concentración en 3 que se observa, la media es superior a 4, que es un resultado contrario a lo que intuitivamente esperaríamos, porque habríamos supuesto que se ubicaría más cerca de 3, ya que 3 parece ser un valor muy "representativo" de esta distribución, sin embargo, la media da un número bastante más grande. Esto se debe a la presencia de valores extremos, en este ejemplo el 10. Aunque este número tiene poca frecuencia, su efecto es de "tirar de la media" hacia valores más grandes. Esto sucede siempre con la media y proviene de su característica de tener en cuenta todos los valores de la distribución. Por esa razón, cuando la distribución se presenta como la anterior, la media no es una buena medida de centralidad.

Este inconveniente de la media aparece a menudo en las discusiones salariales por sectores. A menudo se escucha que no se justifica un aumento porque el salario promedio de todos los empleados del sector es de *X pesos*. Argumento al que se contrapone (expresado de diferentes maneras) que ese promedio incluye al personal que tiene salarios muy altos. Se trata de distribuciones asimétricas, que tienen la mayor parte de los casos con salarios bajos o intermedios y unos pocos casos con salarios muy superiores, por eso cuando se calcula la media se obtiene un resultado que representa mal al conjunto de datos.

El histograma siguiente muestra la forma de la distribución anterior:



En el gráfico se ve el carácter atípico del valor 10, que aparece muy alejado de la parte principal de la distribución. Decimos en este caso que la distribución es asimétrica.

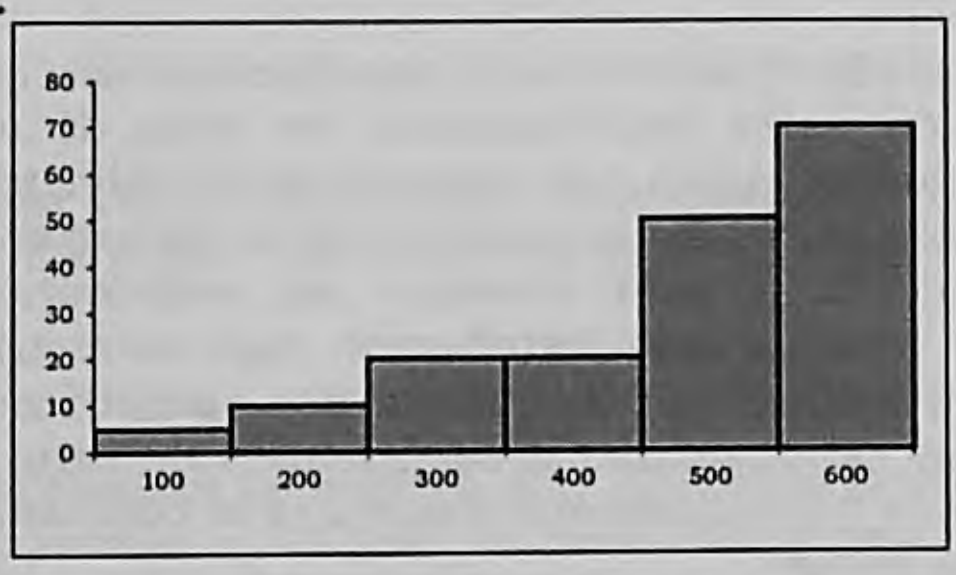
Asimetría

La **asimetría** de una distribución se indica señalando hacia dónde se sitúan los valores extremos. Si, como en este ejemplo, los valores extremos son mayores que la mayor parte de los datos, la asimetría es **hacia la derecha**.

La asimetría puede ser en sentido opuesto, si hay observaciones particularmente pequeñas y en ese caso se tratará de una distribución **asimétrica hacia la izquierda**. Como en el ejemplo siguiente:

X	F
100	5
200	10
300	20
400	20
500	50
600	70
Total	175

Cuyo histograma es:

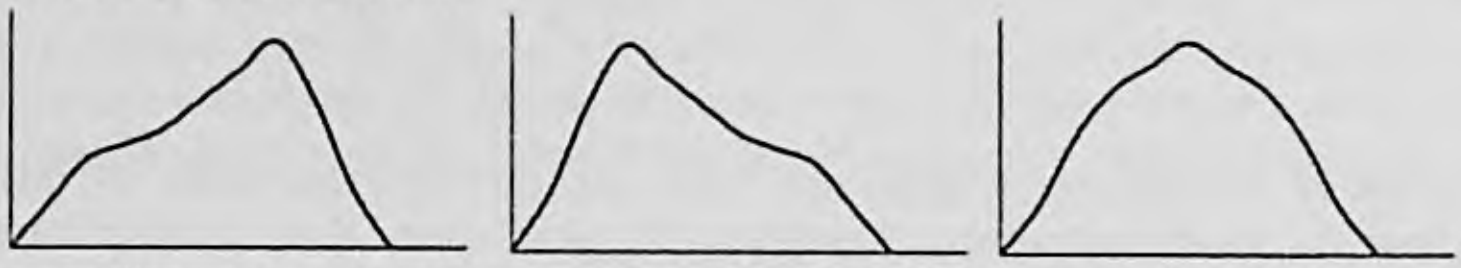


Aquí los valores extremos se encuentran por debajo del grupo principal de datos y la media se inclinará hacia los valores más pequeños. Así, aunque la mayoría de los casos se encuentra entre 500 y 600, la media es:

$$\bar{x} = \frac{100 * 5 + 200 * 10 + 300 * 20 + 400 * 20 + 500 * 50 + 600 * 70}{175} = 477{,}14$$

Un resultado que está por debajo de esos valores que concentran muchos casos. Decimos ahora que la asimetría es hacia la izquierda.

Las siguientes curvas de distribución de frecuencia, son ejemplos de formas posibles en cuanto a simetría:



El primer gráfico corresponde a una distribución asimétrica a la izquierda, el segundo derecha y el tercero muestra una distribución simétrica.

La asimetría puede evaluarse directamente a partir de las medidas de centralidad, ya que la posición relativa de la media y la mediana indican hacia dónde ésta sucede. Cuando la media y la mediana coinciden, la distribución es simétrica, es decir carece de asimetría. Si la media supera a la mediana, se trata de una distribución asimétrica a la derecha y si la media es menor que la mediana, la asimetría será hacia la izquierda.

Posición relativa de la media y la mediana:	Asimetría de la Distribución:
$\bar{x} = M_{dn}$	Simétrica
$\bar{x} > M_{dn}$	Asimétrica a la derecha
$\bar{x} < M_{dn}$	Asimétrica a la izquierda

Una distribución es **simétrica** si la media coincide con la mediana. La distribución se llama asimétrica a la derecha si la media es mayor que la mediana, y asimétrica a la izquierda si la media es menor que la mediana.

Hay otras maneras de medir la asimetría de una distribución, que la cuantifican y facilitan la comparación entre distribuciones, se trata de los *coeficientes de asimetría*. Estos coeficientes miden dos aspectos de la asimetría: hacia qué lado sucede y cuán acentuada es. Su signo positivo indica asimetría hacia la derecha y negativo hacia la izquierda. El valor absoluto del coeficiente indica si es muy asimétrica o poco. Por ejemplo, una distribución cuya asimetría vale 1,5 es más asimétrica que una con coeficiente 1,2, y ambas son asimétricas hacia la derecha. Cuando la distribución es simétrica, el coeficiente vale cero, no es positivo ni negativo. Uno de los más frecuentemente usados es el coeficiente de asimetría de Fisher[18], que se calcula como:

$$g_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^3 * f_i}{n * s^3}$$

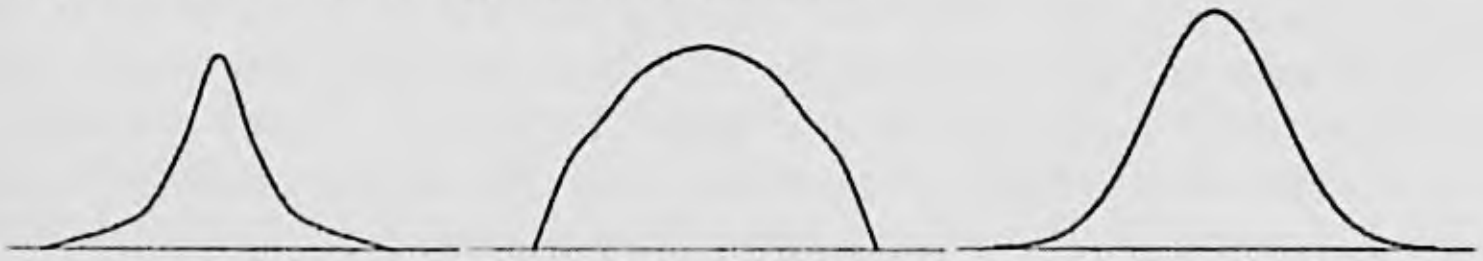
[18] Otros coeficientes de asimetría son: el de Pearson, que compara la ubicación de la media y del modo, y el de Bowley, que compara los cuartiles y la mediana.

Y cuya interpretación es:
$g_1 = 0$ La distribución es simétrica.
$g_1 > 0$ Asimétrica hacia la derecha.
$g_1 < 0$ Asimétrica hacia la izquierda.

En la práctica, es improbable que el coeficiente valga exactamente cero, por lo que se considera simétrica a una distribución cuyo coeficiente esté entre -0,5 y 0,5.

Curtosis

Además de la simetría, disponemos de otro indicador de la forma de la distribución, una medida de cuán "puntiaguda" es la curva, se denomina curtosis y distingue distribuciones con forma estrecha y elevada de que tienen forma amplia y baja. Como en los siguientes gráficos:



Las distribuciones con forma semejante a la primera se llaman leptocúrticas, las que se parecen al segundo gráfico, platicúrticas y las que tienen forma como la tercera, mesocúrticas.

Estos tres ejemplos corresponden a distribuciones simétricas, pero también pueden ser asimétricas.
La curtosis se mide con un coeficiente específico, que vale cero para distribuciones mesocúrticas, es negativo para las platicúrticas y positivo para las leptocúrticas. Su cálculo es:

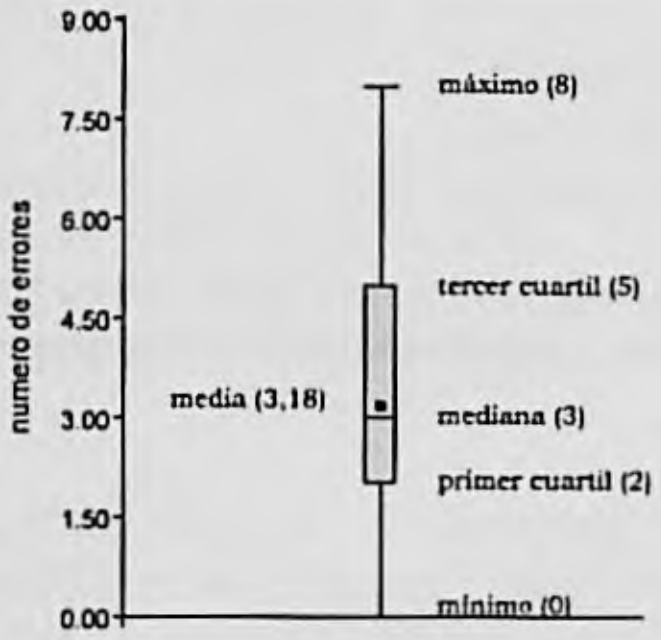
$$g_2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^4 * f_i}{n * s^4} - 3$$

Su interpretación es:
$g_2 = 0$ La distribución es mesocúrtica
$g_2 > 0$ Leptocúrtica
$g_2 < 0$ Platicúrtica

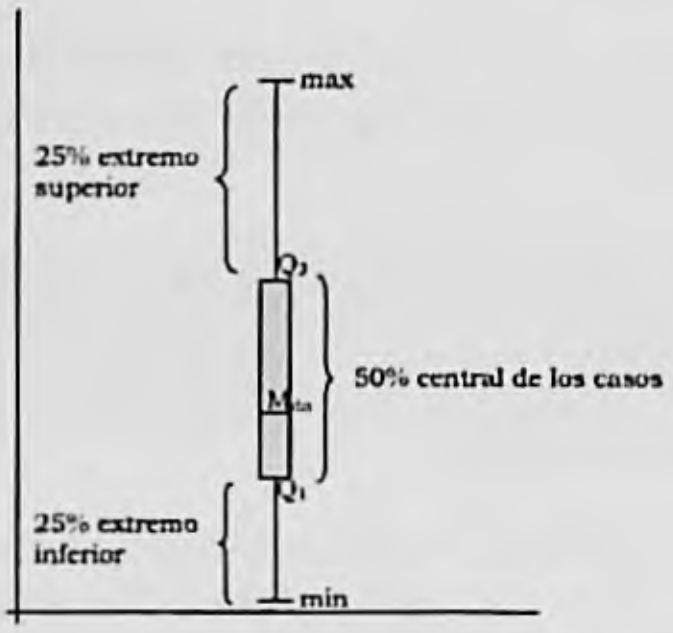
Con datos reales, muy raramente el valor será exactamente cero, por lo que se trata como mesocúrtica a una distribución cuyo coeficiente se encuentre entre -0,5 y 0,5.

Box-plots

Un gráfico que puede resumir de manera muy compacta la información sobre una distribución de frecuencias es el que se llama **diagrama de caja**, o también **diagrama de caja y bigotes** o **box-plot**, que fue propuesto por John Tukey en 1977. Aplicado al ejemplo de la variable *número de errores*, relevada sobre 1339 casos, que mostramos antes, ofrece.

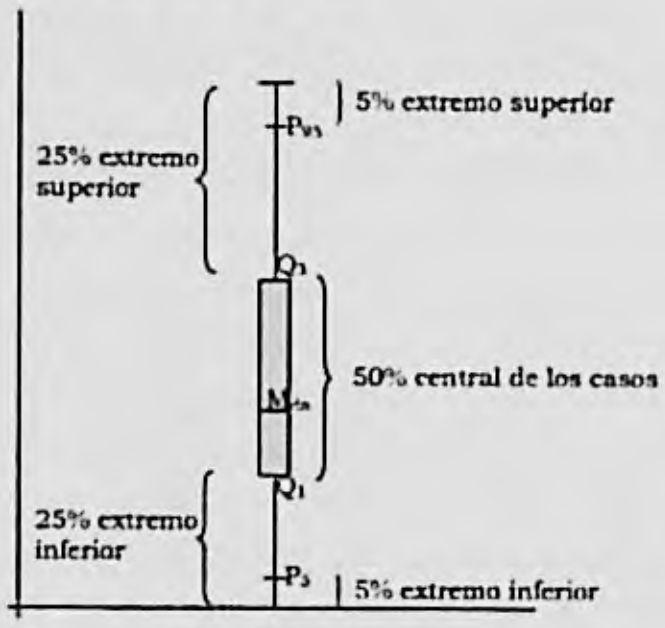


Este gráfico representa sobre el eje vertical los valores de la variable y muestra una "caja" delimitada por los cuartiles 1 y 3. Según la definición de los cuartiles, esa caja contiene al 50% central de los casos. Dentro de la caja se muestra la mediana en la línea horizontal y la media, con un punto; según la posición relativa de ellas, tendremos una idea gráfica de la asimetría de la distribución.
Además de la caja, se ven dos segmentos que se extienden hasta los valores máximo y mínimo de la distribución. Estos segmentos (llamados a veces "bigotes") muestran el campo completo de variación de la variable y completan la idea acerca de la asimetría de la distribución[19].
De manera general entonces, el box-plot permite apreciar gráficamente la distribución de los casos:



[19] Este gráfico tiene siempre la misma manera de definir la caja central; el extremo inferior es el percentil 25, el superior el percentil 75 y una línea dentro de la caja indica la posición de la mediana. Sin embargo, hay diferencias en la forma de construir los bigotes (McGill; Tukey y Larsen, 1978), aquí los hemos extendido desde el primer cuartil hasta el mínimo valor observado y desde el tercer cuartil hasta el máximo observado, para representar el campo completo de variación de los datos. Esta no es la única opción, más adelante veremos una versión más elaborada de este gráfico, que ayudará a identificar valores excepcionalmente altos o bajos.

En InfoStat®, también pueden pedirse los percentiles 5 y 95, con lo que la información que ofrece el gráfico es más rica:



La evaluación exploratoria de los datos puede usarse también de manera comparativa. Por ejemplo, las notas del primer parcial de Psicoestadística en 2009 y 2010 son descriptas en la siguiente salida InfoStat®:

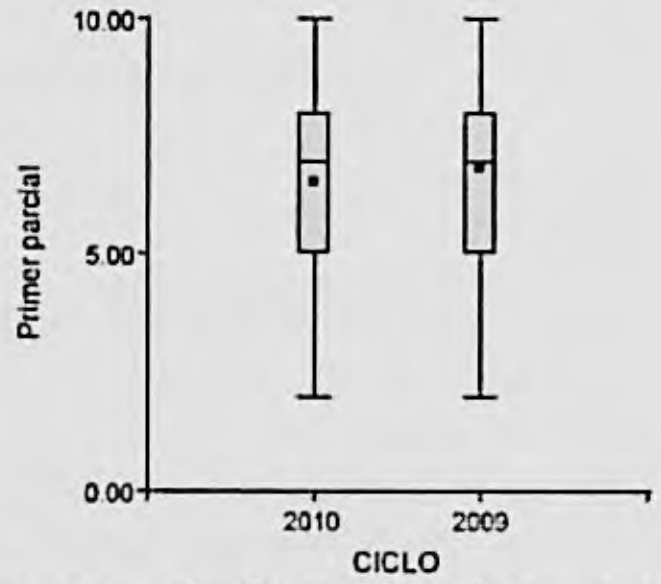
Medidas resumen

CICLO	Resumen	primero
2009	n	1345
2009	Media	6.82
2009	Mín	2
2009	Máx	10
2009	Mediana	7
2009	Q1	5
2009	Q3	8
2009	Asimetría	-0.42
2009	Kurtosis	-0.69
2010	n	1210
2010	Media	6.51
2010	Mín	1
2010	Máx	10
2010	Mediana	7
2010	Q1	5
2010	Q3	8
2010	Asimetría	-0.24
2010	Kurtosis	-0.68

Leemos esta descripción como: en 2009 rindieron el primer parcial 1345 alumnos, la nota promedio del grupo fue de 6.82. La mínima nota que alguien obtuvo fue un dos y la máxima un 10. La mitad de los alumnos sacó de 7 para abajo, el 25% que obtuvo los peores resultados estuvo de 5 para abajo y el 25% de notas más altas se concentra por encima de 8 (entre 8 y 10). Sobre la forma de la distribución, ésta tiene asimetría hacia la izquierda, pero es muy pequeña

(menos a 0.50) por lo que se la puede tratar como simétrica. Además, es platicúrtica. De manera equivalente se lee la descripción de las notas del 2010.

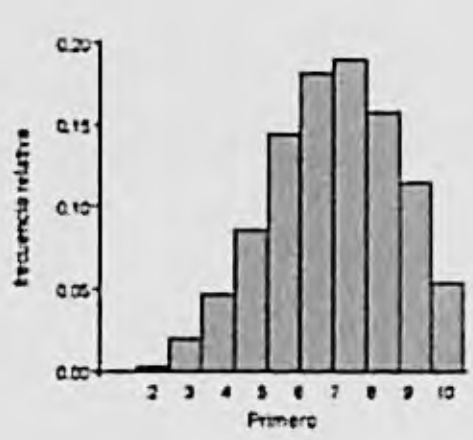
La variable *ciclo* es la que separa los dos grupos que se comparan y corresponde a quienes cursaron en 2009 y 2010.
La representación gráfica de esta descripción, a través de box-plots, es la siguiente:

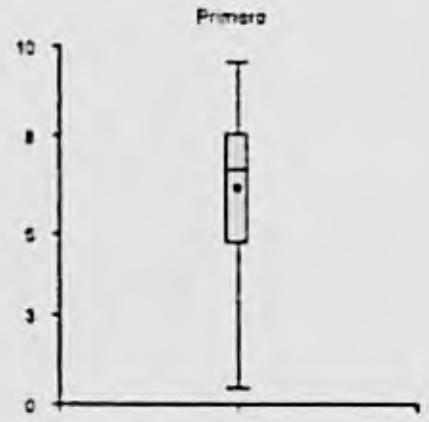


En el que se aprecia la gran similitud en los resultados obtenidos por los alumnos.

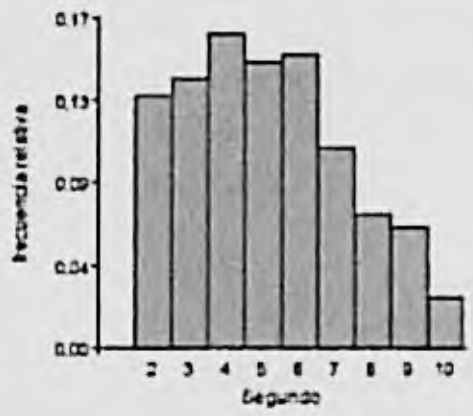
Para comparar las formas de representación de los resultados, a continuación vemos el histograma junto al box-plot de las notas de los dos primeros parciales del año 2010:

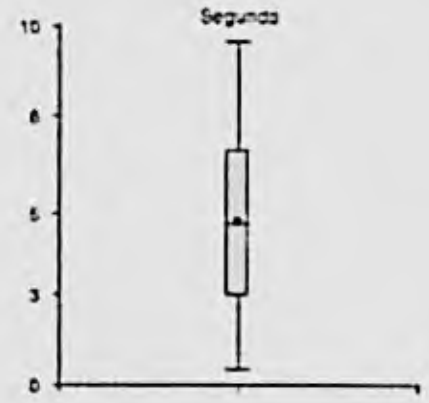
Resumen	Primero
n	1210
Media	6,52
Min	2
MÁX	10
Mediana	7
Q1	5
Q3	8





Resumen	Segundo
n	1231
Media	5,07
Min	2
MÁX	10
Mediana	5
Q1	3
Q3	7





Se puede observar la diferente asimetria de las dos distribuciones expresada en el sesgo de los histogramas y en la distinta longitud de los bigotes en los box-plot.

Medidas de dispersión

Además de indicar alrededor de qué valores se distribuyen los datos, también es necesario indicar si se encuentran concentrados alrededor de esos valores (si son cercanos a ellos) o dispersos (si están alejados). Por ejemplo, un promedio de 20 sesiones de psicoterapia puede provenir de cuatro casos que utilizaron 18, 19, 21 y 22 sesiones o de otros cuatro que hayan insumido 5, 10, 30 y 35 sesiones. En la primer situación las cuatro observaciones son cercanas a la media, están concentradas a su alrededor, mientras que en la segunda están lejos, dispersas. Diremos que en el primer caso la distribución es homogénea o que presenta poca dispersión y en el segundo que es heterogénea o que presenta mucha dispersión.
Conocer esto tiene importancia para poder evaluar la calidad de las medidas de centralidad, en particular de la media. Esto es así porque en una distribución muy dispersa, la media será un promedio de valores muy diferentes entre sí y no será tan fiel a los datos como si estos valores fueran similares. La media de 20 sesiones del primer ejemplo es una mejor medida resumen que la misma media de 20 del segundo, porque la primera representa mejor los datos de origen. Debido a esto, decimos que en la primera de las situaciones del ejemplo, la media es más *representativa* de los datos de los que proviene.
Nos ocuparemos ahora del modo en que puede medirse esa dispersión, cómo transformarla en una medida resumen que indique brevemente si los datos están dispersos o concentrados.

Recorrido

Una primera aproximación al problema es la de considerar la distancia que hay entre los valores extremos, entre el más pequeño y el más grande. Si usamos este procedimiento en el ejemplo anterior vemos que en la primera distribución hay 4 unidades entre la primera y la última observación (de 18 a 22) y en la segunda hay 30 unidades de extremo a extremo (de 5 a 35). Por lo que ésta sería una medida de la dispersión. Esta medida se llama recorrido, se indica con la letra R y la expresión formal de su cálculo es:

$$R = x_{max} - x_{min}$$

Donde x_{max} y x_{min} representan a los valores máximo y mínimo respectivamente. En las distribuciones del ejemplo, los recorridos son $R=4$ y $R=30$ respectivamente, que resumen la mayor dispersión de la segunda.

Se llama **recorrido** de una distribución a la diferencia entre los valores máximo y mínimo de la variable. Se indica R.

Cuando la distribución tiene más casos, el recorrido es insuficiente como medida de dispersión, ya que está determinado solo por los valores extremos. Por ejemplo, las dos siguientes series tienen la misma media, igual a 8:

2, 8, 8, 8, 8, 8, 14
7, 8, 8, 8, 8, 8, 9

El recorrido vale 12 para la primera ($R=14-2$) y 2 para la segunda (R=9–7) es una diferencia muy acentuada aunque las dos distribuciones solo difieren en los valores extremos. Dicho de otra manera, si sucede que hay un caso (o unos pocos) que tiene un valor excepcionalmente alto (o bajo), el recorrido dará un valor alto, indicando gran dispersión, lo que nos puede hacer pensar que todos

los datos están dispersos. Por esa razón se dice que es una medida "gruesa" de la variabilidad de los datos.

Amplitud intercuartílica

Un modo de afinar la calidad de esta medida es la de tomar la distancia que hay, no ya entre los valores extremos, sino entre los cuartiles primero y tercero. La medida que usa esta distancia se llama amplitud intercuartílica y es simplemente la diferencia entre el tercer cuartil y el primero:

$$AIQ = Q_3 - Q_1$$

Si bien tampoco es ésta una medida que considere todas las observaciones —ya que solo tiene en cuenta los dos cuartiles—, es mejor que el recorrido, porque deja de lado los valores extremos, aquellos que pertenecen al 25% más bajo y al 25% más alto de la distribución.

La **amplitud intercuartílica** es la diferencia entre los cuartiles tercero y primero. Se indica *AIQ*.

Gráficamente, esta medida es la altura de la caja del Box-plot. Algunos autores prefieren informar como medida de dispersión a la mitad de la distancia entre los cuartiles 1 y 3, a la que se denomina *semi recorrido intercuartilar*, y se abrevia SRIC.

El **semi recorrido intercuartilar** es la mitad de la amplitud intercuartílica. Se indica *SRIC*.

Que en el Box-plot representa al mitad de la altura de la caja.

$$SRIC = \frac{Q_3 - Q_1}{2}$$

Medidas de dispersión basadas en la media

Las medidas de variabilidad que más se usan son las que tienen en cuenta todas las observaciones, es decir aquellas que están basadas en la media. Una manera de ver si el conjunto de datos está concentrado o disperso, consiste en observar la distancia de la media a la que se encuentra cada observación, luego esas distancias individuales pueden promediarse y tener una idea global de qué tan lejos están los casos del promedio. Intentemos hacer eso y veamos qué limitación aparece.

Tomemos un conjunto pequeño de datos, presentado en serie simple:

5, 7, 9, 11

La media es 8, como lo es la mediana. Aunque no hay modo, ya que todos los valores tienen frecuencia igual a uno, la distribución es simétrica. Hemos elegido así el ejemplo solo para darle simplicidad, no es una condición necesaria para lo que sigue.

Consideremos las distancias desde cada observación hasta la media, restando a cada una de ellas el valor 8 (la media):

x_i	$x_i - \bar{x}$
5	-3
7	-1
9	1
11	3

Las distancias positivas corresponden a valores superiores a la media y las negativas a los inferiores, si un valor acertara en la media, su distancia sería cero. Si sumamos todas las diferencias $x_i - \bar{x}$, el resultado es cero (-3-1+1+3=0); además, éstas son simétricas, como efecto de la forma de la distribución original. Pero el hecho que la suma sea cero no depende de la forma de la distribución, sino que es una propiedad de la media. Por ser la media un punto de equilibrio entre las observaciones, las que se distancian por encima de ella están compensadas por las que lo hacen por debajo[20].

Los valores $x_i - \bar{x}$ se llaman desvíos, que indican cuánto se aleja cada observación de la media. Como vemos pueden ser positivos o negativos según se trate de observaciones que superen a la media o que estén por debajo de ella. Acabamos de ver también que su suma vale cero, es decir que $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$ y que esta es una cualidad de la media, que no depende de los datos[21]. Tan importante es esta propiedad que la usaremos para dar una definición más completa de la media:

> La **media** es el valor de la variable que anula la suma de los desvíos en torno suyo.

En el tema que nos ocupa en este momento, el de medición de la variabilidad del conjunto de casos, la consecuencia de esta propiedad es que no será posible usar la suma de los desvíos como indicador de dispersión, ya que da siempre cero, con datos homogéneos o heterogéneos. A fin de resolver este problema vamos a eliminar el signo, usando el hecho que todo número elevado a una potencia par es positivo, sin importar el signo que haya tenido el número. Elevaremos entonces al cuadrado cada una de los desvíos y así se perderá su signo y ya no será cero la suma de todos ellos.

Varianza

Usando ese recurso, definimos la varianza[22], a la que simbolizaremos como $V(x)$ o más frecuentemente como s^2 de la siguiente forma:

---

[20] Para ver esto, comparemos con el caso de la serie: 3, 4, 6, 7, 23, 45 con media 14,7. Las diferencias entre cada observación y la media son las siguientes:

x	3	4	6	7	23	45
$x_i - \bar{x}$	-11,7	-10,7	-8,7	-7,7	8,3	30,3

En este caso las diferencias no son simétricas, pero es igualmente cierto que su suma es igual a cero, es decir que están compensadas las diferencias por encima y por debajo de la media.

[21] Puede verse que es así haciendo: $\sum_{i=1}^{n}(x_i - \bar{x}) = \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \bar{x}$, como $\bar{x}$ es una constante, el segundo término es $n * \bar{x}$, igual que el primero, según la definición operativa de la media. Por lo tanto la diferencia es cero, cualquiera sea el conjunto de datos.

[22] En este punto aparece la primera diferencia entre cálculos hechos sobre datos de una muestra o de una población. Si estuviésemos trabajando sobre toda la población, la varianza (a la que indicaríamos con otra letra) tendría denominador *n*, en lugar de *n-1*. No

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Se llama **varianza** de una distribución a la suma de los cuadrados de los desvíos alrededor de la media, dividida por el total de observaciones menos uno. Se indica s^2.

Es una medida muy valiosa de la dispersión que tiene un conjunto de datos, cuanto mayor es, tanto más dispersos éstos se encuentran, es decir, son más heterogéneos. No puede ser negativa, porque es una suma de cuadrados y solo es cero si todos los desvíos son cero, es decir si todas las observaciones coinciden con la media[23].

Hay tres propiedades de la varianza que señalaremos porque serán necesarias más adelante:

-La varianza de una constante es cero. Esto resulta claro ya que la varianza mide la dispersión y si todas las observaciones son iguales no hay dispersión:

$$V(k) = 0$$

-La varianza de una constante que multiplica a una variable es la constante elevada al cuadrado multiplicada por la varianza de la variable:

$$V(k * x) = k^2 * V(x)$$

-La varianza de la suma de dos variables independientes es la suma de las varianzas de cada una de ellas:

$$V(x + y) = V(x) + V(y)$$

A los fines de la interpretación, la varianza presenta dos inconvenientes. Uno es que sus unidades están elevadas al cuadrado; por lo que, si medimos *número de errores*, la varianza quedará expresada en *número de errores al cuadrado* una entidad que no tiene significado, como tampoco lo tienen *hijos al cuadrado* o *segundos al cuadrado*, para los tiempos de reacción.

El otro inconveniente es que no tiene límite superior, puede ser muy grande y no tenemos con qué compararla para saber si indica una gran variabilidad o si es grande porque los valores de la variable lo son.

Desviación estándar

Para resolver el primer inconveniente, definiremos una medida derivada de la varianza, que se denomina desviación estándar (en algunos textos y programas de análisis de datos es llamada desviación típica). Esta medida, indicada con la letra *s* es la raíz cuadrada de la varianza:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

O más simplemente:

---

podemos explicar la razón de esto aún, habrá que esperar al capítulo de estimación. En algunos manuales, a la varianza calculada con denominador *n-1* se la llama *cuasivarianza* o también *seudovarianza*.

[23] En este caso no hay variabilidad, y en consecuencia, no hay variable, porque el valor asumido es siempre el mismo. Se trata de una constante.

$$s = \sqrt{s^2}$$

La **desviación estándar** es la raíz cuadrada de la varianza. Se indica *s*.

Ahora, por el sencillo trámite de introducir una raíz cuadrada, las unidades de *s* son las mismas que las de la variable original y no hay problemas con la interpretación del valor.

Coeficiente de variación

Para hacer frente al problema de la magnitud de la varianza —que sigue siéndolo para la desviación estándar—, definimos una medida relativa de la dispersión: el coeficiente de variación, indicado como CV como el cociente entre la desviación estándar y la media:

$$CV = \frac{s}{\bar{x}} * 100$$

Esta medida carece de unidades, porque la media tiene las mismas que las de la desviación estándar, por lo que se trata de una medida relativa de la dispersión. Indica la importancia relativa de la desviación estándar respecto de la media. El factor 100 que acompaña al cociente cumple la función de expresarlo como porcentaje, por comodidad para la lectura.

El **coeficiente de variación** expresa de manera relativa la dispersión, midiendo el peso de la desviación estándar comparado con la media. Se indica *CV*.

Conocer la dispersión de una distribución de frecuencias es muy necesario para poder decidir si la media es una medida adecuada para resumir los datos, y esto no sucede si hay mucha dispersión. Para aclarar esto veamos un ejemplo: sea un grupo de seis alumnos que hacen una prueba y que obtienen las siguientes notas: 2, 2, 2, 2, 10, 10. Si calculamos la media obtenemos 4,7. Este número no representa lo que sucede con los seis alumnos, quienes tuvieron resultados muy dispares: cuatro de ellos obtuvieron 2 y los otros dos, 10. Si calculamos el CV, resultado es 100%, un valor muy elevado, indicativo que la media no es una medida adecuada para sintetizar al conjunto de datos. Muchas de las críticas mal fundadas hacia la Estadística se equivocan por ignorancia, porque calculan la media cuando no corresponde usarla.

En la práctica se considera que si el coeficiente de variación es menor al 10% (algunas referencias ponen como límite al 15%), la distribución tiene poca dispersión y entonces podemos confiar en la media como medida de centralidad y tratarla como representativa de los datos que resume. Más allá de estos valores del CV, la media no alcanza para resumir los datos y es necesario acompañarla de otras medidas, como la mediana, los cuartiles, el mínimo y máximo.

Calcularemos por única vez las medidas de dispersión de manera manual para un pequeño conjunto de datos, a fin de seguir de cerca las operaciones que involucra. Se trata de seis pacientes diagnosticados de depresión a partir de cinco

o más de los síntomas que indica el manual DSM IV[24] y que para cada uno de ellos observamos (como variable) el número de síntomas que llevaron al diagnóstico:

Paciente	x_i (número de síntomas)	$x_i - \bar{x}$ (desvíos)	$(x_i - \bar{x})^2$ (cuadrados de los desvíos)
1	5	-2	4
2	6	-1	1
3	6	-1	1
4	8	1	1
5	8	1	1
6	9	2	4

$$\bar{x} = \frac{5+6+6+8+8+9}{6} = 7$$

$$\sum_{i=1}^{6}(x_i - \bar{x})^2 = 4+1+1+1+1+4 = 12$$

$$s^2 = \frac{\sum_{i=1}^{6}(x_i - \bar{x})^2}{n-1} = \frac{12}{6-1} = 2{,}4$$

$$s = \sqrt{s^2} = \sqrt{2{,}4} = 1{,}55$$

$$CV = \frac{s}{\bar{x}} * 100 = \frac{1{,}55}{7} * 100 = 22{,}13\%$$

---

[24] Presencia de cinco (o más) de los siguientes síntomas durante un período de 2 semanas, que representan un cambio respecto a la actividad previa; uno de los síntomas debe ser:
1. Estado de ánimo depresivo la mayor parte del día, casi cada día según lo indica el propio sujeto (p. ej., se siente triste o vacío) o la observación realizada por otros (p. ej., llanto). En los niños y adolescentes el estado de ánimo puede ser irritable
2. Disminución acusada del interés o de la capacidad para el placer en todas o casi todas las actividades, la mayor parte del día, casi cada día (según refiere el propio sujeto u observan los demás)
3. Pérdida importante de peso sin hacer régimen o aumento de peso (p. ej., un cambio de más del 5 % del peso corporal en 1 mes), o pérdida o aumento del apetito casi cada día. Nota: En niños hay que valorar el fracaso en lograr los aumentos de peso esperables
4. Insomnio o hipersomnia (sueño excesivo) casi cada día.
5. Agitación o enlentecimiento psicomotores casi cada día (observable por los demás, no meras sensaciones de inquietud o de estar enlentecido)
6. Fatiga o pérdida de energía casi cada día
7. Sentimientos de inutilidad o de culpa excesivos o inapropiados (que pueden ser delirantes) casi cada día (no los simples autorreproches o culpabilidad por el hecho de estar enfermo)
8. Disminución de la capacidad para pensar o concentrarse, o indecisión, casi cada día (ya sea una atribución subjetiva o una observación ajena)
9. Pensamientos recurrentes de muerte (no sólo temor a la muerte), ideación suicida recurrente sin un plan específico o una tentativa de suicidio o un plan específico para suicidarse

La lectura de este resultado es que para el conjunto de seis personas a las que se observa, el número promedio de síntomas a través de los cuales es diagnosticada la depresión es de siete. Sin embargo este número de síntomas es bastante variable según los pacientes y, seguramente también según los terapeutas.

Obtención informática de medidas de dispersión

Si la serie de datos del ejemplo anterior es cargada en InfoStat®, las medidas descriptivas se solicitan en el menú: Estadísticas, Medidas resumen. Luego de seleccionar la variable que se describirá, se eligen las medidas, el formato de la salida es el siguiente:

Estadística descriptiva

Variable	n	Media	D.E.	Var(n-1)	CV
NUMERO DE SINTOMAS	6	7,00	1,55	2,40	22,13

En la salida, *n* es la cantidad de casos, *D.E.* se refiere a la desviación estándar, *Var(n-1)* es la varianza, en la que la indicación *(n-1)* señala que se ha calculado con denominador *(n-1)*, por lo que se trata de la varianza muestral. *CV* el coeficiente de variación, expresado como porcentaje. Esta salida puede leerse "Sobre un total de seis pacientes diagnosticados como depresivos, el número promedio de síntomas presentes en que se basó el diagnóstico fue de 7. Las observaciones son levemente heterogéneas, ya que el coeficiente de variación es superior al 20%. De aquí puede concluirse que el número de síntomas que apoyan el diagnóstico de depresión es bastante variable entre los pacientes."

La medida relativa de la variabilidad es adecuada para comparar variables que tienen diferentes unidades, por ejemplo para responder ¿qué es más variable, el peso o la estatura de los niños? Es decir, ¿en cuál de esas dos medidas se diferencian más? Las siguientes son las salidas descriptivas

Variable	n	Media	D.E.	Var(n-1)	CV	Mín	Máx
peso	32	9,55	0,94	0,88	9,80	7,90	11,23
talla	32	73,43	2,89	8,36	3,94	65,80	80,00

Se trata de 32 niños de la misma edad, evaluados en dos aspectos; su peso y su talla, el primero en kilos y la segunda en centímetros. La comparación de las varianzas o de las desviaciones estándar no da información sobre la diferente variabilidad, porque dependen de esas unidades de medida. Por el contrario, los coeficientes de variación, (casi 10% para el peso y casi 4% para la talla) indican que hay más diferencias entre los pesos que entre las estaturas.

Box-plots y dispersión

La observación del diagrama de caja (box-plot) nos da también indicios acerca de la dispersión de la variable que se analiza. Cuando la caja es larga estamos en presencia de distribuciones muy dispersas en la parte central, los cuartiles están lejanos, hay mucha amplitud intercuartilar. Mientras que si la caja es corta, se trata de una concentración de datos en la parte central de la distribución. La longitud de los bigotes señala la mayor o menor concentración de los datos en las zonas extremas. Como dijimos antes, el box-plot es un gráfico que ayuda a explorar los datos, a hacerse una idea inicial de la distribución y esto puede ser

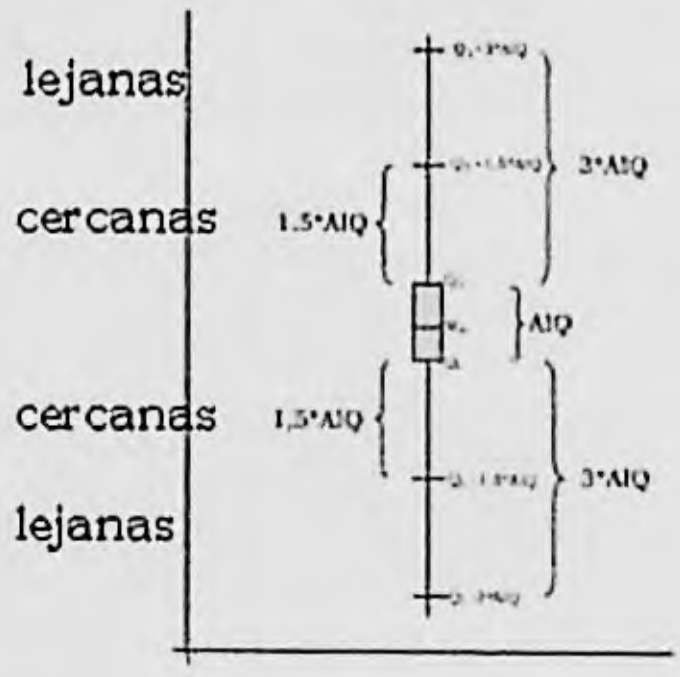
muy valioso cuando se trata de interpretarlos, porque permite sugerir hipótesis que expliquen la distribución que se observa.

Haciendo uso de la amplitud intercuartílica estableceremos criterios para detectar valores que destaquen por alejarse sustancialmente del grupo mayoritario. Se trata de mediciones atípicas o excepcionalmente extremas, ya porque sean excesivamente grandes o pequeñas. La identificación de estos valores es importante en la etapa exploratoria de los datos porque obliga a mirarlos en detalle. Puede tratarse de un error de medición o bien de un sujeto (o unos pocos) que se aparta de manera excepcional del grupo y que merece un análisis más detallado y particularizado.

Tukey (1977) analiza la distancia de los casos a los cuartiles y sugiere tratar como "lejanas" a las observaciones que se encuentren a más de una amplitud intercuartílica y media (1,5*AIQ) por debajo del primer cuartil o por encima del tercero, pero a menos de tres veces la amplitud intercuartílica (3*AIQ). Además, aquellas observaciones que estén más allá de tres AIQ por debajo del primer cuartil o por encima del tercero se denominan "muy lejanas". Este criterio determina entonces zonas en las que pueden hallarse las observaciones y según en cuál de ellas se encuentren, se las identifica como "cercanas", "lejanas" o "muy lejanas". Las zonas son las siguientes:

1. Cercanas: Entre Q_1 y Q_1-1,5*AIQ o entre Q_3 y Q_3+1,5*AIQ
2. Lejanas: Entre Q_1-1,5*AIQ y Q_1-3*AIQ o entre Q_3+1,5*AIQ y Q_3+3*AIQ
3. Muy lejanas: Menores que Q_1-3*AIQ o mayores que Q_3+3*AIQ

La división en zonas puede verse más claramente en un box-plot:



En este esquema hemos tomado la distancia entre los cuartiles tercero y primero (la amplitud intercuartílica) como unidad de medida, y consideramos una vez y media esa medida (1,5*AIQ) y tres veces esa medida (3*AIQ) como puntos de corte para decidir cuándo una observación se aleja excepcionalmente del grupo.

Medida de la dispersión cuando no hay distancias

Todo lo indicado hasta el momento acerca de la variabilidad ha necesitado de la medición de la distancia entre las observaciones: desde el comienzo hablamos de cercanía o lejanía entre los datos. Por lo tanto estas medidas, desde el recorrido

hasta el coeficiente de variación, solo tienen sentido si la variable es de nivel intervalar o proporcional. Si la variable tiene nivel nominal u ordinal habrá que medir su variabilidad de otra forma. En estos casos cambia un poco el significado de la variabilidad, ya que estaremos en presencia de una variable más dispersa cuanto más *equitativamente* se distribuya el total de observaciones entre las distintas categorías. Por ejemplo, si 100 individuos son clasificados según cómo sea su rendimiento en: muy bueno, bueno, regular, insatisfactorio; la distribución tendrá más dispersión si 25 de ellos se encuentran en cada categoría que si la gran mayoría está en una sola. La distribución:

Rendimiento	f	f'
Muy bueno	25	0,25
Bueno	25	0,25
Regular	25	0,25
Insatisfactorio	25	0,25
Total	100	1,00

Tiene más dispersión que esta otra:

Rendimiento	f	f'
Muy bueno	5	0,05
Bueno	80	0,80
Regular	5	0,05
Insatisfactorio	10	0,10
Total	100	1,00

¿Por qué? Porque en la segunda, los casos están muy concentrados en una categoría (bueno), mientras que en la primera se dispersan entre todas. Notemos que ahora habrá más dispersión cuanto más parecidas sean las frecuencias entre sí. Esto puede parecer contradictorio con lo indicado para variables cuantitativas, pero allí la mayor dispersión viene dada por la mayor disparidad entre los valores de las variables, que no puede evaluarse con variables nominales u ordinales.
Esta forma de considerar la dispersión equivale a la idea de incertidumbre. Supongamos que conocemos que la distribución del rendimiento es como lo muestra la primera tabla y que debemos "adivinar" cuál es el rendimiento de una persona elegida al azar. No tenemos ninguna razón para creer de manera preferencial que la persona sea de rendimiento muy bueno, bueno, regular o insatisfactorio; ya que todos son igualmente posibles. En esta situación, la incertidumbre es completa. Por el contrario, si supiéramos que la distribución es la que muestra la segunda tabla, tenderíamos con justa razón a creer que hay más chances que la persona elegida al azar tenga rendimiento bueno, ya que es bastante más probable que pertenezca a esa categoría que a otra. Diremos que aquí tenemos menos incertidumbre.
La medida para expresar de manera sintética esta dispersión es:

$$H(x) = -\sum_{i=1}^{k} f_i' * log f_i'$$

El cálculo consiste en multiplicar cada frecuencia relativa por su propio logaritmo y sumar para todas las categorías. El resultado de la sumatoria siempre es negativo, por lo que la fórmula incluye un signo menos para volverlo positivo.

Este coeficiente expresa en un solo número la magnitud de la dispersión. Cuanto más pequeña sea esta medida, tanto menos dispersa (o más concentrada) será la distribución de la variable que se analiza.
Aplicado a las dos tablas de más arriba resulta, para la primera:

$$H(x) = -(0{,}25 * log 0{,}25 + 0{,}25 * log 0{,}25 + 0{,}25 * log 0{,}25 + 0{,}25 * log 0{,}25) = -(-0{,}60) = 0{,}60$$

Y, para la segunda:

$$H(x) = -(0{,}05 * log 0{,}05 + 0{,}80 * log 0{,}80 + 0{,}05 * log 0{,}05 + 0{,}10 * log 0{,}10) = -(-0{,}31) = 0{,}31$$

Así, a la distribución en la que las frecuencias están más concentradas, es decir la que tiene menor dispersión, le corresponde un menor valor de *H(x)*.

El individuo en relación a su grupo

Un uso muy frecuente en evaluación psicológica y educativa de las medidas que acabamos de ver es que permiten decidir si un *valor particular* está cerca o lejos del promedio, o bien si se sitúa o no en los extremos de una distribución. Un valor particular en este caso se refiere al valor de la variable en un *caso*, en un *individuo*, por ejemplo, el puntaje que un sujeto obtiene en una prueba. Así formulado el problema puede parecer muy elemental, porque puede "verse" si un número está cerca o lejos de otro. Si sabemos que una persona tiene dos metros de estatura, no necesitamos hacer cuentas para saber que es alto, más alto que la mayoría de las personas. Sin embargo, en el caso de medidas menos familiares, y como veremos en los ejemplos siguientes, a veces resulta difícil hacer juicios de distancia sobre valores absolutos.
Si sabemos que en una prueba de memoria con un puntaje máximo de 100 puntos, una persona logró 80 puntos, ¿estamos autorizados para decir que obtuvo un puntaje alto? La respuesta es no, porque no sabemos qué puntajes obtuvieron las demás personas que hicieron la prueba. Si la media del grupo completo hubiese sido 60 puntos, entonces 80 sería un valor elevado, pero si la media hubiese sido de 85, entonces el caso que estamos considerando se encontraría por debajo del promedio. Más aún, si el promedio fuese 60 y la mayoría de los evaluados hubiese obtenido puntajes cercanos a 60 (poca variabilidad), entonces el valor 80 podría considerarse como muy elevado. Solo conocer su puntaje individual no nos dice nada acerca de la posición de un sujeto particular.
Otro ejemplo: nos informan que un niño obtuvo un puntaje bruto de 85 en la escala de desarrollo infantil de Bayley (2006), no tenemos, en principio ningún criterio para decidir si ese puntaje es alto o bajo.
Para situaciones como éstas, muy frecuentes en evaluaciones psicométricas, será necesario conocer cuál es la posición *relativa* que un puntaje ocupa respecto del conjunto completo de observaciones.
Supongamos que se aplica una prueba de ortografía a una muestra de alumnos de tercer grado y que el promedio de errores es 10 ($\bar{x} = 10$ errores) y que la desviación estándar es de 4 ($s = 4$ errores). Si un alumno comete 6 errores ($x = 6$ errores), podemos decir que cometió menos errores que el promedio del grupo. El cálculo de la

diferencia entre x y $\bar{x}$ da -4 errores ($x - \bar{x} = 6 - 10 = -4$), este resultado nos informa que este alumno se ubica a 4 errores por debajo del promedio (por debajo queda expresado en el signo menos el resultado). Ésta es una medida concreta, ya que expresa el número de errores que separan al alumno del comportamiento resumido del grupo (expresado en la media); dicho de otra manera, estamos considerando los valores absolutos. Si ahora a esta diferencia la dividimos por la desviación estándar obtenemos -1 (procedente de $\frac{-4}{4}$), que ya no tiene unidades, es un número abstracto. Como la desviación estándar es de 4 puntos y el alumno se encuentra a cuatro puntos de la media, esto equivale a decir que el alumno se encuentra "a una desviación estándar por debajo del promedio". La operación que hemos hecho ha sido la de restar al valor particular (de ese alumno) la media y dividir el resultado en la desviación estándar, hemos calculado lo siguiente:

$$\frac{x - \bar{x}}{s}$$

Este número, que como dijimos no tiene unidades, es diferente para cada valor de x, y mide la distancia a la que se encuentra una observación particular (x) de la media ($\bar{x}$), expresada como fracción de la desviación estándar (s). Decimos que se trata de una medida *estandarizada* del alejamiento que tiene una observación particular del promedio del conjunto de observaciones.
Hemos así expresado la posición del alumno respecto del grupo al que pertenece de manera relativa, en términos de desviaciones estándar.
La variable que resulta de esta operación se llama **desvío estándar**, ya que se trata de un desvío (calculado en la diferencia $x - \bar{x}$) expresado como cantidad de desviaciones estándar. Se utiliza la letra z para indicarla, así:

$$z = \frac{x - \bar{x}}{s}$$

Debido a que la letra z se utiliza de manera universal para indicar este valor, es también conocido como **puntaje z** o **puntuación z**. Esta nueva variable tiene media igual a cero y desviación estándar igual a uno[25].
Volvamos sobre el ejemplo del número de síntomas en que se basa el diagnóstico de depresión, cuya media fue de 7 y su desviación estándar de 1,55.

UNIVERSIDAD TÉCNICA DEL NORTE
BIBLIOTECA
Ibarra - Ecuador

---

[25] Dado que $\bar{x}$ y s son constantes, aplicando las propiedades de la media, resulta:
$\bar{z} = \overline{\left(\frac{x-\bar{x}}{s}\right)} = \frac{\bar{x}-\bar{x}}{s} = 0.$
También haciendo uso de las propiedades de la varianza, la de z es:
$V(z) = V\left(\frac{x-\bar{x}}{s}\right) = \frac{1}{s^2}\left(V(x) - V(\bar{x})\right) = \frac{1}{s^2}(V(x) - 0) = \frac{1}{s^2}V(x) = 1,$
ya que la media es constante por lo que tiene varianza nula, y $V(x) = s^2$

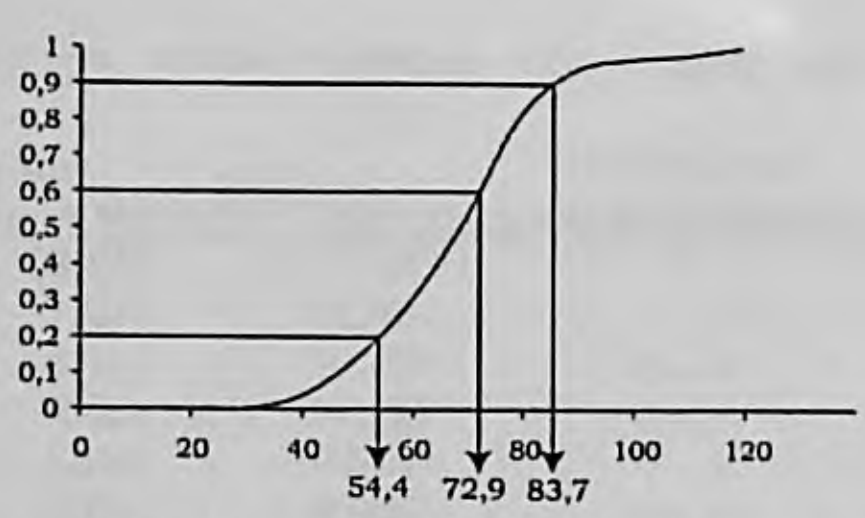
Paciente	x_i (número de síntomas)	$x_i - \bar{x}$ (desvíos)	z (desvíos estándar)
1	5	-2	-1,29
2	6	-1	-0,65
3	6	-1	-0,65
4	8	1	0,65
5	8	1	0,65
6	9	2	1,29

La última columna proviene de haber dividido cada desvío en la desviación estándar (1,55). Los desvíos indican a cuántas unidades de la variable (en este caso *número de síntomas*) se ubica cada caso del promedio. Los desvíos estándar indican a cuántas desviaciones estándar se encuentra cada caso del promedio. El primer paciente está a 1,29 desviaciones estándar por debajo del promedio, el tercero está a 0,65 desviaciones estándar por debajo del promedio, etc.

Cuando se trata de variables de nivel ordinal también es posible ubicar de manera relativa cada valor de la variable, aunque no puedan medirse distancias. Es así porque en esas variables podemos calcular percentiles e indicar a qué percentil corresponde cada valor. Antes vimos el modo de señalar gráficamente la ubicación de los percentiles, allí buscamos de identificar el valor de la variable que corresponde, por ejemplo, al percentil 90 ó a cualquier otro. Podemos hacer ahora el recorrido inverso: dado un valor de la variable ¿a qué percentil corresponde?
Consideremos los siguientes puntajes brutos obtenidos en una prueba psicológica administrada a una muestra de 310 personas:

x	f	F	F´
20-29	0	0	0,00
30-39	10	10	0,03
40-49	30	40	0,13
50-59	50	90	0,29
60-69	70	160	0,52
70-79	90	250	0,81
80-89	40	290	0,94
90-99	10	300	0,97
100-109	5	305	0,98
110-119	5	310	1,00
Total	310		

Los percentiles de esta distribución pueden obtenerse gráficamente usando la ojiva de Galton. Por ejemplo, hallamos los percentiles 20, 60 y 90:



Procediendo del mismo modo, hacemos la siguiente correspondencia de puntajes brutos a percentiles:

Percentil	X
10	47,0
20	54,4
30	60,4
40	64,9
50	69,3
60	72,9
70	76,3
80	79,8
90	87,3

La tabla nos informa sobre los valores de la variable donde se divide cada 10% del total de casos. Usando la definición de los percentiles diremos que:
- El 10% de los sujetos obtuvo 47 puntos o menos
- El 20% obtuvo 54,4 puntos o menos y así para el resto.

Con esta información sabemos que si una persona obtuvo 50 puntos, tiene un puntaje muy bajo, porque supera a menos del 20% del grupo. O dicho de otra manera, más del 80% de las personas alcanzaron puntajes más altos que él. Por el contrario si alguien obtuvo 88 puntos, tiene un puntaje muy alto, ya que supera al percentil 90, con lo que menos del 10% del grupo lo supera. O bien, él supera a más del 90%.

De este modo, la construcción de una tabla en la que se indica el valor de la variable (el puntaje en la prueba) correspondiente a cada percentil, permite conocer si un puntaje dado se ubica en algún extremo de la distribución (si es excepcionalmente elevado o bajo) o si es un valor intermedio.

Estas tablas de correspondencia entre valores absolutos (o puntajes brutos) y los correspondientes valores relativos pueden también construirse a partir de los desvíos estándar, para lo que se debe transformar cada valor observado en su puntuación *z*. Para el ejemplo anterior se debe calcular la media y la desviación estándar, que dan: $\bar{x} = 68{,}4$ y $s = 15{,}7$. Con esto se indican los puntajes z que corresponden a cada puntaje bruto, con la transformación $z = \frac{x-\bar{x}}{s}$.

Para la marca de clase del primer puntaje bruto (25), el puntaje z que le corresponde es:

$$z = \frac{25-68{,}4}{15{,}7} = -2{,}8.$$

Al repetir esta operación para cada puntaje bruto se obtiene la tabla de correspondencias:

Intervalo de puntajes brutos	Puntaje *z*
20-29	-2,8
30-39	-2,1
40-49	-1,5
50-59	-0,9
60-69	-0,2
70-79	0,4
80-89	1,1
90-99	1,7
100-109	2,3
110-119	3,0

Una tabla de ese tipo (ya sea construida a partir de los percentiles o bien de los puntajes *z*) se conoce como **baremo** y es absolutamente necesario para cualquier tipo de evaluación psicológica o educativa ya que posibilita decidir en qué lugar se encuentra un sujeto dado, respecto de su grupo de referencia, Esto se requiere porque, por ejemplo, para una prueba de inteligencia, un puntaje que es normal para la edad de 13 años, no lo es para los 16; los puntajes de alguien de 13 años se comparan con los puntajes de otras personas de 13 años. El baremo provee la transformación de puntajes absolutos en puntajes relativos.

Un **baremo** es una tabla de valores transformados que permiten ubicar a un sujeto en relación a su grupo de referencia.

Aplicación a un estudio local

Dentro de la materia Técnicas Psicométricas (segundo año de la Licenciatura en Psicología, UNC), los alumnos han realizado una toma de la escala general del Test de Raven[26] a una muestra de alumnos secundarios y universitarios de la ciudad de Córdoba. Con esos datos, un grupo de alumnos coordinado por un ayudante de la cátedra, se interesó en actualizar el baremo del test, puesto que no existían en ese momento baremos locales y actualizados. Se tomó muestra de 551 alumnos de nivel secundario y universitario, con edades entre 16 y 17 años, de ambos sexos.

A continuación, los protocolos fueron clasificados por rangos, para cada uno de los cuales se calcularon los percentiles y los puntajes *z* teniendo en cuenta el puntaje total y el de cada serie y se construyeron los baremos. A continuación se presentan en dos versiones, como rangos percentilados y como puntajes *z*:

[26]O test de matrices progresivas, es una prueba desarrollada por John Raven 1936 y dirigida a medir las dos componentes principales de la inteligencia general, que Spearman había definido años antes.

Puntaje Total (bruto)	Percentil	Intervalo de puntaje bruto	Puntaje *z*
28	5	0	-5,83
39	10	1 – 2	-5,64
43	25	3 – 4	-5,38
46	40	5 – 6	-5,13
48	50	7 – 8	-4,88
49	60	9 – 10	-4,63
50	70	11 – 12	-4,37
51	75	13 – 14	-4,12
52	80	15 – 16	-3,87
54	90	17 – 18	-3,61
55	95	19 – 20	-3,31
58	99	21 – 22	-3,10
		23 – 24	-2,86
		25 – 26	-2,61
		27 – 28	-2,35
		29 – 30	-2,10
		31 – 32	-1,85
		33 – 34	-1,59
		35 – 36	-1,35
		37 – 38	-1,09
		39 – 40	-0,84
		41 – 42	-0,59
		43 – 44	-0,36
		45 – 46	-0,06
		47 – 48	0,17
		49 – 50	0,42
		51 – 52	0,68
		53 – 54	0,93
		55 – 56	1,18
		57 – 58	1,43
		59 – 60	1,68

Resumen de medidas descriptivas

			Nivel de medición mínimo requerido
Medidas de posición	Centrales	Modo	Nominal
		Mediana	Ordinal
		Media	Intervalar
	No centrales	Cuartiles	Ordinal
		Quintiles	
		Percentiles	

			Nivel de medición mínimo requerido
Medidas de dispersión	Entre extremos	Recorrido	Intervalar
	Basada en el orden	Amplitud intercuartílica	Intervalar
	Basadas en la media	Varianza	Intervalar
		Desviación estándar	
		Coeficiente de variación	
	De incertidumbre	Coeficiente de incertidumbre	Nominal