¡¡APRUEBE SU EXAMEN CON SCHAUM!!

Estadística

Schaum

4ª EDICIÓN

Murray R. Spiegel • Larry J. Stephens

- 486 PROBLEMAS RESUELTOS PASO A PASO
- 660 PROBLEMAS DE PRÁCTICA
- INCLUYE SOLUCIONES A PROBLEMAS DE LOS PROGRAMAS DE CÓMPUTO ACTUALES

Utilícelo para las siguientes asignaturas:

☑ ESTADÍSTICA BÁSICA ☑ MÉTODOS ESTADÍSTICOS BÁSICOS ☑ INTRODUCCIÓN A LA ESTADÍSTICA
☑ INTRODUCCIÓN A LA PROBABILIDAD Y ESTADÍSTICA ☑ INTRODUCCIÓN AL ANÁLISIS EXPLORATORIO DE DAT

Mc Graw Hill

MEDIA, MEDIANA, MODA, Y OTRAS MEDIDAS DE TENDENCIA CENTRAL

3

ÍNDICES O SUBÍNDICES

El símbolo, X_j (que se lee "X subíndice j") representa cualquiera de los N *valores* $X_1, X_2, X_3, \ldots, X_N$ que puede tomar la variable X. A la letra j que aparece en X_j representando a cualquiera de los números 1, 2, 3, $\ldots$, N se le llama *subíndice* o *índice*. En lugar de j se puede usar, por supuesto, cualquier otra letra, i, k, p, q o s.

SUMATORIA

El símbolo $\sum_{j=1}^{N} X_j$ se emplea para denotar la suma de todas las X_j desde $j = 1$ hasta $j = N$; por definición,

$$\sum_{j=1}^{N} X_j = X_1 + X_2 + X_3 + \cdots + X_N$$

Cuando no puede haber confusión, esta suma se denota simplemente como $\sum X$, $\sum X_j$ o $\sum_j X_j$. El símbolo $\sum$ es la letra griega mayúscula *sigma* y denota suma.

EJEMPLO 1 $\displaystyle\sum_{j=1}^{N} X_j Y_j = X_1 Y_1 + X_2 Y_2 + X_3 Y_3 + \cdots + X_N Y_N$

EJEMPLO 2 $\displaystyle\sum_{j=1}^{N} aX_j = aX_1 + aX_2 + \cdots + aX_N = a(X_1 + X_2 + \cdots + X_N) = a\sum_{j=1}^{N} X_j$

donde a es una constante. O bien simplemente $\sum aX = a\sum X$.

EJEMPLO 3 Si a, b y c son cualesquiera constantes, entonces $\sum (aX + bY - cZ) = a\sum X + b\sum Y - c\sum Z$. Ver problema 3.3.

PROMEDIOS O MEDIDAS DE TENDENCIA CENTRAL

Un *promedio* es un valor típico o representativo de un conjunto de datos. Como estos valores típicos tienden a encontrarse en el centro de los conjuntos de datos, ordenados de acuerdo con su magnitud, a los promedios se les conoce también como *medidas de tendencia central.*

Se pueden definir varios tipos de promedios; los más usados son la *media aritmética*, la *mediana*, la *moda*, la *media geométrica* y la *media armónica.* Cada una de ellas tiene ventajas y desventajas de acuerdo con el tipo de datos y el propósito de su uso.

LA MEDIA ARITMÉTICA

La *media aritmética*, o brevemente la *media*, de un conjunto de N números $X_1, X_2, X_3, \ldots, X_N$ se denota así: $\bar{X}$ (que se lee "X barra") y está definida como

$$\bar{X} = \frac{X_1 + X_2 + X_3 + \cdots + X_N}{N} = \frac{\sum_{j=1}^{N} X_j}{N} = \frac{\sum X}{N} \tag{1}$$

EJEMPLO 4 La media aritmética de los números 8, 3, 5, 12 y 10 es

$$\bar{X} = \frac{8 + 3 + 5 + 12 + 10}{5} = \frac{38}{5} = 7.6$$

Si los números $X_1, X_2, \ldots, X_K$ se presentan $f_1, f_2, \ldots, f_K$ veces, respectivamente (es decir, se presentan con frecuencias $f_1, f_2, \ldots, f_K$), su media aritmética es

$$\bar{X} = \frac{f_1X_1 + f_2X_2 + \cdots + f_KX_K}{f_1 + f_2 + \cdots + f_K} = \frac{\sum_{j=1}^{K} f_jX_j}{\sum_{j=1}^{K} f_j} = \frac{\sum fX}{\sum f} = \frac{\sum fX}{N} \tag{2}$$

donde $N = \sum f$ es la *suma de las frecuencias* (es decir, la cantidad total de casos).

EJEMPLO 5 Si 5, 8, 6 y 2 se presentan con frecuencias 3, 2, 4 y 1, respectivamente, su media aritmética es

$$\bar{X} = \frac{(3)(5) + (2)(8) + (4)(6) + (1)(2)}{3 + 2 + 4 + 1} = \frac{15 + 16 + 24 + 2}{10} = 5.7$$

MEDIA ARITMÉTICA PONDERADA

Algunas veces, a los números $X_1, X_2, \ldots, X_K$ se les asignan ciertos *factores de ponderación* (o *pesos*) $w_1, w_2, \ldots, w_K$, que dependen del significado o importancia que se les asigne a estos números. En este caso, a

$$\bar{X} = \frac{w_1X_1 + w_2X_2 + \cdots + w_KX_k}{w_1 + w_2 + \cdots + w_K} = \frac{\sum wX}{\sum w} \tag{3}$$

se le llama *media aritmética ponderada.* Obsérvese la semejanza con la ecuación (*2*), la cual se puede considerar como una media aritmética ponderada con pesos $f_1, f_2, \ldots, f_K$.

EJEMPLO 6 Si en una clase, al examen final se le da el triple de valor que a los exámenes parciales y un estudiante obtiene 85 en el examen final, y 70 y 90 en los dos exámenes parciales, su puntuación media es

$$\bar{X} = \frac{(1)(70) + (1)(90) + (3)(85)}{1 + 1 + 3} = \frac{415}{5} = 83$$

PROPIEDADES DE LA MEDIA ARITMÉTICA

1. En un conjunto de números, la suma algebraica de las desviaciones de estos números respecto a su media aritmética es cero.

EJEMPLO 7 Las desviaciones de los números 8, 3, 5, 12 y 10 de su media aritmética, 7.6, son $8-7.6$, $3-7.6$, $5-7.6$, $12-7.6$ y $10-7.6$ o bien 0.4, -4.6, -2.6, 4.4 y 2.4, cuya suma algebraica es $0.4-4.6-2.6+4.4+2.4=0$.

2. En un conjunto de números X_j, la suma de los cuadrados de sus desviaciones respecto a un número a es un mínimo si y sólo si $a=\bar{X}$ (ver el problema 4.27).
3. Si la media de f_1 números es m_1, la media de f_2 números es $m_2,\ldots$, la media de f_k números es m_k, entonces la media de todos estos números es

$$\bar{X}=\frac{f_1m_1+f_2m_2+\cdots+f_Km_K}{f_1+f_2+\cdots+f_K} \tag{4}$$

es decir, una media aritmética ponderada de todas las medias (véase el problemas 3.12).

4. Si se *cree* o *se supone* que un número A (que puede ser cualquier número) es la *media aritmética* y si $d_j=X_j-A$ son las desviaciones de X_j de A, entonces las ecuaciones (*1*) y (*2*) se convierten, respectivamente, en

$$\bar{X}=A+\frac{\sum_{j=1}^{N} d_j}{N}=A+\frac{\sum d}{N} \tag{5}$$

$$\bar{X}=A+\frac{\sum_{j=1}^{K} f_jd_j}{\sum_{j=1}^{K} f_j}=A+\frac{\sum fd}{N} \tag{6}$$

donde $N=\sum_{j=1}^{N} f_j=\sum f$. Obsérvese que las fórmulas (*5*) y (*6*) se resumen en la ecuación $\bar{X}=A+\bar{d}$ (ver problema 3.18).

CÁLCULO DE LA MEDIA ARITMÉTICA PARA DATOS AGRUPADOS

Cuando se presentan los datos en una distribución de frecuencias, se considera que todos los datos que caen en un intervalo de clase dado coinciden con la marca o punto medio del intervalo. Para datos agrupados, interpretando a las X_j como las marcas de clase, a las f_j como las correspondientes frecuencias de clase, a A como cualquier marca de clase supuesta y $d_j=X_j-A$ como la desviación de X_j respecto de A, las fórmulas (*2*) y (*6*) son válidas.

A los cálculos empleando las fórmulas (*2*) y (*6*) se les suele conocer como *método largo* y *método abreviado*, respectivamente (ver los problemas 3.15 y 3.20).

Si todos los intervalos de clase son de una misma amplitud c, las desviaciones $d_j=X_j-A$ se pueden expresar como cu_j, donde u_j puede tener valores enteros positivos o negativos o cero (es decir, 0, ±1, ±2, $\pm3,\ldots$) con lo que la fórmula (*6*) se convierte en

$$\bar{X}=A+\left(\frac{\sum_{j=1}^{K} f_ju_j}{N}\right)=A+\left(\frac{\sum fu}{N}\right)c \tag{7}$$

lo que es equivalente a la ecuación $\bar{X}=A+c\bar{u}$ (ver problema 3.21). A esta ecuación se le conoce como *método codificado* para calcular la media. Es un método muy breve recomendado para datos agrupados cuando los intervalos de clase tienen todos la misma amplitud (ver problemas 3.22 y 3.23). Obsérvese que en el método codificado los valores de la variable X *se transforman* en valores de la variable u de acuerdo con $X=A+cu$.

LA MEDIANA

La *mediana* de un conjunto de números acomodados en orden de magnitud (es decir, en una ordenación) es el valor central o la media de los dos valores centrales.

EJEMPLO 8 La mediana del conjunto de números 3, 4, 5, 6, 8, 8, 8 y 10 es 6.

EJEMPLO 9 La mediana del conjunto de números 5, 5, 7, 9, 11, 12, 15 y 18 es $\frac{1}{2}(9 + 11) = 10$.

En datos agrupados, la mediana se obtiene por interpolación, como se expresa por la fórmula

$$\text{Mediana} = L_1 + \left(\frac{\frac{N}{2} - (\sum f)_1}{f_{\text{mediana}}} \right) c \tag{8}$$

donde $L_1 =$ frontera inferior de la clase mediana (es decir, de la clase que contiene la mediana)
$N =$ número de datos (es decir, la frecuencia total)
$(\sum f)_1 =$ suma de las frecuencias de todas las clases anteriores a la clase mediana
$f_{\text{mediana}} =$ frecuencia de la clase mediana
$c =$ amplitud del intervalo de la clase mediana

Geométricamente, la mediana es el valor de X (abscisa) que corresponde a una recta vertical que divide al histograma en dos partes que tienen la misma área. A este valor de X se le suele denotar $\tilde{X}$.

LA MODA

La *moda* de un conjunto de números es el valor que se presenta con más frecuencia; es decir, es el valor más frecuente. Puede no haber moda y cuando la hay, puede no ser única.

EJEMPLO 10 La moda del conjunto 2, 2, 5, 7, 9, 9, 9, 10, 10, 11, 12 y 18 es 9.

EJEMPLO 11 El conjunto 3, 5, 8, 10, 12, 15 y 16 no tiene moda.

EJEMPLO 12 El conjunto 2, 3, 4, 4, 4, 5, 5, 7, 7, 7 y 9 tiene dos modas, 4 y 7, por lo que se le llama *bimodal*.

A una distribución que sólo tiene una moda se le llama *unimodal*.

En el caso de datos agrupados, para los que se ha construido una curva de frecuencia que se ajuste a los datos, la moda es el valor (o los valores) de X que corresponden al punto (o puntos) máximos de la curva. A este valor de X se le suele denotar $\hat{X}$.

En una distribución de frecuencia o en un histograma la moda se puede obtener mediante la fórmula siguiente:

$$\text{Moda} = L_1 + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) c \tag{9}$$

donde $L_1 =$ frontera inferior de la clase modal (es decir, de la clase que contiene la moda)
$\Delta_1 =$ exceso de frecuencia modal sobre la frecuencia en la clase inferior inmediata
$\Delta_2 =$ exceso de frecuencia modal sobre la frecuencia en la clase superior inmediata
$c =$ amplitud del intervalo de la clase modal

RELACIÓN EMPÍRICA ENTRE LA MEDIA, LA MEDIANA Y LA MODA

En las curvas de frecuencias unimodales que son ligeramente sesgadas (asimétricas), se tiene la relación empírica siguiente:

$$\text{Media} - \text{moda} = 3(\text{media} - \text{mediana}) \tag{10}$$

En las figuras 3-1 y 3-2 se muestran las posiciones relativas de la media, la mediana y la moda en curvas de frecuencias sesgadas a la derecha o a la izquierda, respectivamente. En las curvas simétricas, la media, la mediana y la moda coinciden.

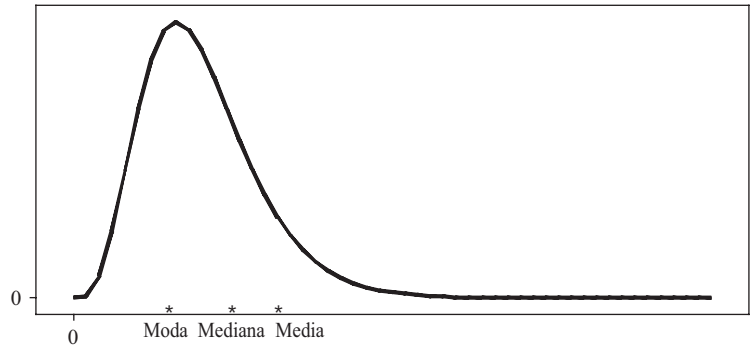


Figura 3-1 Posiciones relativas de la media, la mediana y la moda en curvas de frecuencias sesgadas a la derecha.

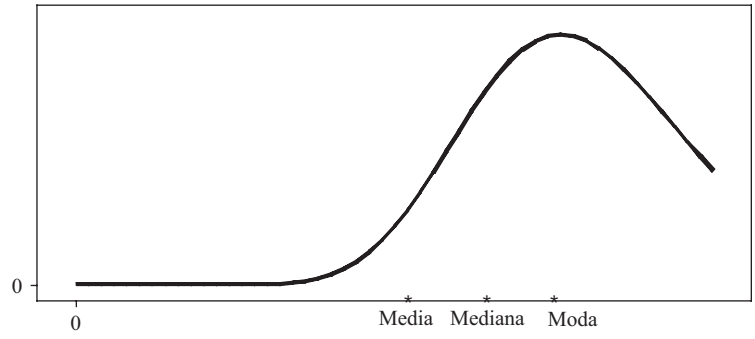


Figura. 3-2 Posiciones relativas de la media, la mediana y la moda en curvas de frecuencias sesgadas a la izquierda.

LA MEDIA GEOMÉTRICA *G*

La media geométrica G de N números positivos $X_1, X_2, X_3, \ldots, X_N$ es la raíz n-ésima del producto de los números:

$$G = \sqrt[N]{X_1 X_2 X_3 \cdots X_N} \tag{11}$$

EJEMPLO 13 La media geométrica de los números 2, 4 y 8 es $G = \sqrt[3]{(2)(4)(8)} = \sqrt[3]{64} = 4$.

G se puede calcular empleando logaritmos (ver problema 3.35) o usando una calculadora. Para la media geométrica de datos agrupados, ver los problemas 3.36 y 3.91.

LA MEDIA ARMÓNICA *H*

La media armónica H de un conjunto de N números $X_1, X_2, X_3, \ldots, X_N$ es el recíproco de la media aritmética de los recíprocos de los números:

$$H = \frac{1}{\dfrac{1}{N}\displaystyle\sum_{j=1}^{N}\frac{1}{X_j}} = \frac{N}{\sum \dfrac{1}{X}} \tag{12}$$

En la práctica es más fácil recordar que

$$\frac{1}{H} = \frac{\sum \frac{1}{X}}{N} = \frac{1}{N}\sum \frac{1}{X} \tag{13}$$

EJEMPLO 14 La media armónica de los números 2, 4 y 8 es

$$H = \frac{3}{\frac{1}{2}+\frac{1}{4}+\frac{1}{8}} = \frac{3}{\frac{7}{8}} = 3.43$$

Para la media armónica de datos agrupados ver los problemas 3.99 y 3.100.

RELACIÓN ENTRE LAS MEDIAS ARITMÉTICA, GEOMÉTRICA Y ARMÓNICA

La media geométrica de un conjunto de números positivos $X_1, X_2, \ldots, X_N$ es menor o igual que su media aritmética, pero mayor o igual que su media armónica. En símbolos,

$$H \leq G \leq \bar{X} \tag{14}$$

La igualdad es válida sólo cuando todos los números $X_1, X_2, \ldots, X_N$ son idénticos.

EJEMPLO 15 La media aritmética de los números 2, 4 y 8 es 4.67, su media geométrica es 4 y su media armónica es 3.43.

LA RAÍZ CUADRADA MEDIA

La raíz cuadrada media (RCM) o *media cuadrática* de un conjunto de números $X_1, X_2, \ldots, X_N$ suele denotarse $\sqrt{\overline{X^2}}$ y se define

$$\text{RCM} = = \sqrt{\overline{X^2}} = \sqrt{\frac{\sum_{j=1}^{N} X_j^2}{N}} = \sqrt{\frac{\sum X^2}{N}} \tag{15}$$

Este tipo de promedio suele usarse en aplicaciones físicas.

EJEMPLO 16 La raíz cuadrada media del conjunto 1, 3, 4, 5, y 7 es

$$\sqrt{\frac{1^2 + 3^2 + 4^2 + 5^2 + 7^2}{5}} = \sqrt{20} = 4.47$$

CUARTILES, DECILES Y PERCENTILES

En un conjunto de datos en el que éstos se hallan ordenados de acuerdo con su magnitud, el valor de en medio (o la media aritmética de los dos valores de en medio), que divide al conjunto en dos partes iguales, es la mediana. Continuando con esta idea se puede pensar en aquellos valores que dividen al conjunto de datos en cuatro partes iguales. Estos valores, denotados Q_1, Q_2 y Q_3 son el primero, segundo y tercer *cuartiles*, respectivamente; el valor Q_2 coincide con la mediana.

De igual manera, los valores que dividen al conjunto en diez partes iguales son los *deciles* y se denotan D_1, $D_2, \ldots, D_9$, y los valores que dividen al conjunto en 100 partes iguales son los percentiles y se les denota $P_1, P_2, \ldots, P_{99}$. El quinto decil y el percentil 50 coinciden con la mediana. Los percentiles 25 y 75 coinciden con el primero y tercer cuartiles, respectivamente.

A los cuartiles, deciles, percentiles y otros valores obtenidos dividiendo al conjunto de datos en partes iguales se les llama en conjunto *cuantiles*. Para el cálculo de estos valores cuando se tienen datos agrupados ver los problemas 3.44 a 3.46.

EJEMPLO 17 Utilizar EXCEL para hallar Q_1, Q_2, Q_3, D_9 y P_{95}, en la muestra siguiente de puntuaciones.

88	45	53	86	33	86	85	30	89	53	41	96	56	38	62
71	51	86	68	29	28	47	33	37	25	36	33	94	73	46
42	34	79	72	88	99	82	62	57	42	28	55	67	62	60
96	61	57	75	93	34	75	53	32	28	73	51	69	91	35

Para encontrar el primer cuartil, ingrese los datos en los primeros 60 renglones de la columna A de la hoja de cálculo de EXCEL. Después, dé el comando =PERCENTILE(A1:A60,0.25). EXCEL da el valor 37.75. Se encuentra que 15 de los 60 valores, o el 25%, son menores que 37.75. De igual manera =PERCENTILE(A1:A60,0.5) da 57, =PERCENTILE(A1:A60,0.75) da 76, =PERCENTILE(A1:A60,0.9) da 89.2, =PERCENTILE(A1:A60,0.95) da 94.1. EXCEL da los cuartiles, deciles y percentiles expresados como percentiles.

A continuación se describe un algoritmo que suele emplearse para hallar cuartiles, deciles y percentiles. Primero se ordenan los datos del ejemplo 17 de acuerdo con su magnitud; el resultado es:

Puntuaciones de examen

25	28	28	28	29	30	32	33	33	33	34	34	35	36	37
38	41	42	42	45	46	47	51	51	53	53	53	55	56	57
57	60	61	62	62	62	67	68	69	71	72	73	73	75	75
79	82	85	86	86	86	88	88	89	91	93	94	96	96	99

Supóngase que se quiere encontrar el primer cuartil (que es el percentil 25). Se calcula $i = np/100 = 60(25)/100 = 15$. Como 15 es un número entero, se saca el promedio de los datos en las posiciones 15 y 16 de los datos ordenados de menor a mayor. Es decir, se promedian 37 y 38 y se obtiene 37.5 como primer cuartil ($Q_1 = 37.5$). Para hallar el percentil 93, se calcula $np/100 = 60(93)/100$ y se obtiene 55.8. Como este número no es un entero, se redondea hacia arriba y se obtiene 56. El número que ocupa la posición 56 en los datos ordenados es 93 y $P_{93} = 93$. El comando de EXCEL =PERCENTILE(A1:A60,0.93) da 92.74. Obsérvese que con EXCEL no se obtienen los mismos valores para los percentiles, pero sí valores cercanos. A medida que los conjuntos de datos son mayores, tienden a obtenerse los mismos valores.

SOFTWARE Y MEDIDAS DE TENDENCIA CENTRAL

Todos los paquetes de software utilizados en este libro dan las estadísticas descriptivas vistas en esta sección. A continuación se presentan los resultados que se obtienen con estos cinco paquetes empleando las puntuaciones de examen del ejemplo 17.

EXCEL

Seleccionando la secuencia "Tools ⇒ Data Analysis ⇒ Descriptive Statistics", se obtienen las medidas de tendencia central mediana, media y moda, así como varias medidas de dispersión.

Media	59.16667
Error típico	2.867425
Mediana	57
Moda	28
Desviación estándar	22.21098
Varianza de la muestra	493.3277
Curtosis	–1.24413
Coeficiente de asimetría	0.167175
Rango	74
Mínimo	25
Máximo	99
Suma	3 550
Cuenta	60

MINITAB

Si se selecciona la secuencia "Stat ⇒ Basic Statistics ⇒ Display Descriptive Statistics", como resultado se obtiene:

Estadística descriptiva: calificación de examen

Variable	N	N*	Media	SE media	Desv est	Mínimo	Q1	Mediana	Q3	Máxima
Punt examen	60	0	59.17	2.87	22.21	25.00	37.25	57.00	78.00	99.00

SPSS

Si se selecciona la secuencia "Analyze ⇒ Descriptive Statistics ⇒ Descriptives", como resultado se obtiene:

Estadística descriptiva

	N	Mínimo	Máximo	Media	Desviación estándar
Puntuación de examen	60	25.00	99.00	59.1667	22.21098
N válida	60				

SAS

Si se selecciona la secuencia **"Solutions ⇒ Análisis ⇒ Analyst"** y los datos se leen como un archivo, seleccionando la secuencia **"Statistics ⇒ Descriptive ⇒ Summary Statistics"**, se obtiene como resultado:

The MEANS Procedure
Analysis Variable : Testscr

Mean	Std Dev	N	Minimum	Maximum
59.1666667	22.2109811	60	25.0000000	99.0000000

STATISTIX

Si se selecciona la secuencia "Statistics ⇒ Summary Statistics ⇒ Descriptive Statistics" del paquete STATISTIX, como resultado se obtiene:

Statistix 8.0
Descriptive Staistics

	Testscore
N	60
Mean	59.167
SD	22.211
Minimum	25.000
1st Quarti	37.250
3rd Quarti	78.000
Maximum	99.000

PROBLEMAS RESUELTOS

SUMATORIA

3.1 Escribir los términos de cada una de las sumas siguientes:

a) $\sum_{j=1}^{6} X_j$ *c*) $\sum_{j=1}^{N} a$ *e*) $\sum_{j=1}^{3} (X_j - a)$

b) $\sum_{j=1}^{4} (Y_j - 3)^2$ *d*) $\sum_{k=1}^{5} f_k X_k$

SOLUCIÓN

a) $X_1 + X_2 + X_3 + X_4 + X_5 + X_6$

b) $(Y_1 - 3)^2 + (Y_2 - 3)^2 + (Y_3 - 3)^2 + (Y_4 - 3)^2$

c) $a + a + a + \cdots + a = Na$

d) $f_1X_1 + f_2X_2 + f_3X_3 + f_4X_4 + f_5X_5$

e) $(X_1 - a) + (X_2 - a) + (X_3 - a) = X_1 + X_2 + X_3 - 3a$

3.2 Expresar cada una de las sumas siguientes empleado el símbolo de sumatoria.

a) $X_1^2 + X_2^2 + X_3^2 + \cdots + X_{10}^2$

b) $(X_1 + Y_1) + (X_2 + Y_2) + \cdots + (X_8 + Y_8)$

c) $f_1X_1^3 + f_2X_2^3 + \cdots + f_{20}X_{20}^3$

d) $a_1b_1 + a_2b_2 + a_3b_3 + \cdots + a_Nb_N$

e) $f_1X_1Y_1 + f_2X_2Y_2 + f_3X_3Y_3 + f_4X_4Y_4$

SOLUCIÓN

a) $\sum_{j=1}^{10} X_j^2$ *c*) $\sum_{j=1}^{20} f_j X_j^3$ *e*) $\sum_{j=1}^{4} f_j X_j Y_j$

b) $\sum_{j=1}^{8} (X_j + Y_j)$ *d*) $\sum_{j=1}^{N} a_j b_j$

3.3 Probar que $\sum_{j=1}^{N}(aX_j + bY_j - cZ_j) = a\sum_{j=1}^{N} X_j + b\sum_{j=1}^{N} Y_j - c\sum_{j=1}^{N} Z_j$, donde *a*, *b* y *c* son constantes.

SOLUCIÓN

$$\begin{aligned}\sum_{j=1}^{N}(aX_j + bY_j - cZ_j) &= (aX_1 + bY_1 - cZ_1) + (aX_2 + bY_2 - cZ_2) + \cdots + (aX_N + bY_N - cZ_N)\\ &= (aX_1 + aX_2 + \cdots + aX_N) + (bY_1 + bY_2 + \cdots + bY_N) - (cZ_1 + cZ_2 + \cdots + cZ_N)\\ &= a(X_1 + X_2 + \cdots + X_N) + b(Y_1 + Y_2 + \cdots + Y_N) - c(Z_1 + Z_2 + \cdots + Z_N)\\ &= a\sum_{j=1}^{N} X_j + b\sum_{j=1}^{N} Y_j - c\sum_{j=1}^{N} Z_j\end{aligned}$$

o brevemente, $\sum(aX + bY - cZ) = a\sum X + b\sum Y - c\sum Z$.

3.4 Dos variables, X y Y toman los valores $X_1 = 2$, $X_2 = -5$, $X_3 = 4$, $X_4 = -8$ y $Y_1 = -3$, $Y_2 = -8$, $Y_3 = 10$, $Y_4 = 6$, respectivamente. Calcular *a*) $\sum X$, *b*) $\sum Y$, *c*) $\sum XY$, *d*) $\sum X^2$, *e*) $\sum Y^2$, *f*) $(\sum X)(\sum Y)$, *g*) $\sum XY^2$ y *h*) $\sum(X + Y)(X - Y)$.

SOLUCIÓN

Obsérvese que en todos los casos se ha omitido en X y Y el subíndice j y que la $\sum$ se entiende como $\sum_{j=1}^{4}$. Por lo tanto, por ejemplo $\sum X$ es abreviación de $\sum_{j=1}^{4} X_j$.

a) $\sum X = (2) + (-5) + (4) + (-8) = 2 - 5 + 4 - 8 = -7$

b) $\sum Y = (-3) + (-8) + (10) + (6) = -3 - 8 + 10 + 6 = 5$

c) $\sum XY = (2)(-3) + (-5)(-8) + (4)(10) + (-8)(6) = -6 + 40 + 40 - 48 = 26$

d) $\sum X^2 = (2)^2 + (-5)^2 + (4)^2 + (-8)^2 = 4 + 25 + 16 + 64 = 109$

e) $\sum Y^2 = (-3)^2 + (-8)^2 + (10)^2 + (6)^2 = 9 + 64 + 100 + 36 = 209$

f) $(\sum X)(\sum Y) = (-7)(5) = -35$, de acuerdo con los incisos *a*) y *b*). Obsérvese que $(\sum X)(\sum Y) \neq \sum XY$.

g) $\sum XY^2 = (2)(-3)^2 + (-5)(-8)^2 + (4)(10)^2 + (-8)(6)^2 = -190$

h) $\sum (X + Y)(X - Y) = \sum (X^2 - Y^2) = \sum X^2 - \sum Y^2 = 109 - 209 = -100$, de acuerdo con los incisos *d*) y *e*).

3.5 En una nota de *USA Today* se informa que el promedio de impuestos, per cápita, recolectados en 2005, en todo Estados Unidos, fue de $2 189.84. Esta cantidad se desglosa así: ventas e ingresos, $1051.42; ingreso, $875.23; licencias, $144.33; otros, $80.49, y propiedades, $38.36. Usando EXCEL, demostrar que la suma es igual a $2 189.84.

SOLUCIÓN

Obsérvese que la expresión =sum(A1:A5) es equivalente a $\sum_{j=1}^{5} X_j$.

1 051.42	ventas e ingresos
875.23	ingreso
144.33	licencias
80.49	otros
38.36	propiedades
2 189.83	=sum(A1:A5)

LA MEDIA ARITMÉTICA

3.6 Las calificaciones de un estudiante en seis exámenes fueron 84, 91, 72, 68, 87 y 78. Hallar la media aritmética de estas calificaciones.

SOLUCIÓN

$$\bar{X} = \frac{\sum X}{N} = \frac{84 + 91 + 72 + 68 + 87 + 78}{6} = \frac{480}{6} = 80$$

El término *promedio* suele emplearse como sinónimo de *media aritmética*. Sin embargo, estrictamente hablando, esto no es correcto, ya que además de la media hay otros promedios.

3.7 Un científico mide diez veces el diámetro de un cilindro y obtiene los valores 3.88, 4.09, 3.92, 3.97, 4.02, 3.95, 4.03, 3.92, 3.98 y 4.06 centrímetros (cm). Hallar la media aritmética de estas mediciones.

SOLUCIÓN

$$\bar{X} = \frac{\sum X}{N} = \frac{3.88 + 4.09 + 3.92 + 3.97 + 4.02 + 3.95 + 4.03 + 3.92 + 3.98 + 4.06}{10} = \frac{39.82}{10} = 3.98\,\text{cm}$$

3.8 En el siguiente resultado obtenido con MINITAB se muestra la cantidad de tiempo por semana que 30 personas estuvieron empleando en Internet, así como la media de estas cantidades. ¿Podría decirse que este promedio es típico de las 30 cantidades?

```
MTB > print cl
```

Muestra de datos

```
tiempo
3   4   4   5   5   5   5   5   5   6
6   6   6   7   7   7   7   7   8   8
9  10  10  10  10  10  10  12  55  60
```

```
MTB > mean cl
```

Media de la columna

```
Mean of time = 10.400
```

SOLUCIÓN

Esta media de 10.4 horas no es típica de estas cantidades. Obsérvese que 21 de estas cantidades son de un solo dígito y que la media es 10.4 horas. Una gran desventaja de la media es que es fuertemente afectada por valores atípicos (o valores extremos.)

3.9 Encontrar la media aritmética de los números 5, 3, 6, 5, 4, 5, 2, 8, 6, 5, 4, 8, 3, 4, 5, 4, 8, 2, 5 y 4.

SOLUCIÓN

Primer método

$$\bar{X} = \frac{\sum X}{N} = \frac{5+3+6+5+4+5+2+8+6+5+4+8+3+4+5+4+8+2+5+4}{20} = \frac{96}{20} = 4.8$$

Segundo método

Hay las siguientes cantidades: seis 5, dos 3, dos 6, cinco 4, dos 2 y tres 8. Por lo tanto

$$\bar{X} = \frac{\sum fX}{\sum f} = \frac{\sum fX}{N} = \frac{(6)(5) + (2)(3) + (2)(6) + (5)(4) + (2)(2) + (3)(8)}{6+2+2+5+2+3} = \frac{96}{20} = 4.8$$

3.10 De 100 números, 20 fueron 4, 40 fueron 5, 30 fueron 6 y los restantes fueron 7. Encuéntrese la media aritmética de estos números.

SOLUCIÓN

$$\bar{X} = \frac{\sum fX}{\sum f} = \frac{\sum fX}{N} = \frac{(20)(4) + (40)(5) + (30)(6) + (10)(7)}{100} = \frac{530}{100} = 5.30$$

3.11 Las calificaciones finales de un estudiante en matemáticas, física, inglés e higiene son, respectivamente, 82, 86, 90 y 70. Si los créditos en cada uno de estos cursos son 3, 5, 3 y 1, determinar la correspondiente calificación promedio.

SOLUCIÓN

Se emplea la media aritmética ponderada, en donde los pesos que corresponden a cada puntuación son los créditos que les corresponden. Así,

$$\bar{X} = \frac{\sum wX}{\sum w} = \frac{(3)(82) + (5)(86) + (3)(90) + (1)(70)}{3 + 5 + 3 + 1} = 85$$

3.12 En una empresa en la que hay 80 empleados, 60 ganan \$10.00 por hora y 20 ganan \$13.00 por hora.

a) Determinar el sueldo medio por hora.
b) En el inciso *a*), ¿se obtiene la misma respuesta si los 60 empleados tienen un salario promedio de \$10.00 por hora? Probar la respuesta.
c) ¿Se considera que este salario medio por hora es representativo?

SOLUCIÓN

a)

$$\bar{X} = \frac{\sum fX}{N} = \frac{(60)(\$10.00) + (20)(\$13.00)}{60 + 20} = \$10.75$$

b) Sí, el resultado es el mismo. Para probar esto supóngase que la media de f_1 números es m_1 y que la media de f_2 números es m_2. Hay que demostrar que la media de todos estos números es

$$\bar{X} = \frac{f_1 m_1 + f_2 m_2}{f_1 + f_2}$$

Sea M_1 la suma de los f_1 números y M_2 la suma de los f_2 números. Entonces, por definición de media aritmética,

$$m_1 = \frac{M_1}{f_1} \qquad \text{y} \qquad m_2 = \frac{M_2}{f_2}$$

o $M_1 = f_1 m_1$ y $M_2 = f_2 m_2$. Como todos los $(f_1 + f_2)$ números suman $(M_1 + M_2)$, la media aritmética de todos estos números es

$$\bar{X} = \frac{M_1 + M_2}{f_1 + f_2} = \frac{f_1 m_1 + f_2 m_2}{f_1 + f_2}$$

como se deseaba. Este resultado se puede ampliar fácilmente.

c) Se puede decir que \$10.75 es un salario "representativo" por hora en el sentido de que la mayor parte de los empleados gana \$10.00 por hora, lo que no se aleja mucho de \$10.75 por hora. Se debe recordar que siempre que se resuman datos numéricos en un solo dato (como en un promedio) es posible que se cometa algún error. Sin embargo, el resultado desorienta tanto como en el problema 3.8

En realidad, para tener una mejor idea se debe dar una estimación de la "dispersión" o "variación" de los datos con respecto a la media. A esto se le llama *dispersión* de los datos. En el capítulo 4 se dan varias medidas de dispersión.

3.13 Los pesos medio de cuatro grupos de estudiantes que constan de 15, 20, 10 y 18 individuos son 162, 148, 153 y 140 libras, respectivamente. Encuentre el peso medio de todos los estudiantes.

SOLUCIÓN

$$\bar{X} = \frac{\sum fX}{\sum f} = \frac{(15)(162) + (20)(148) + (10)(153) + (18)(140)}{15 + 20 + 10 + 18} = 150\,\text{lb}$$

3.14 El ingreso medio anual de trabajadores agrícolas y no agrícolas es \$25 000 y \$35 000, respectivamente; ¿el ingreso medio anual de los dos grupos será \$30 000?

SOLUCIÓN

Sería \$30 000 únicamente si la cantidad de trabajadores agrícolas y no agrícolas fuese la misma. Para determinar el verdadero ingreso medio anual se necesita saber cuál es la cantidad relativa de trabajadores en cada grupo. Supóngase que 10% de los trabajadores son trabajadores agrícolas. En ese caso la media será $(0.10)(25\,000) + (0.90)(35\,000) = \$34\,000$. Si la cantidad de trabajadores de ambos tipos es la misma, la media será $(0.50)(25\,000) + (0.50)(35\,000) = \$30\,000$.

3.15 Usando la distribución de frecuencias de las estaturas que se presenta en la tabla 2.1, hallar la estatura media de los 100 estudiantes de la universidad XYZ.

SOLUCIÓN

En la tabla 3.1 se presentan los datos organizados para hacer los cálculos. Obsérvese que como estatura de los estudiantes que miden de 60 a 62 pulgadas (in), de 63 a 65 in, etc., se toman 61 in, 64 in, etc., respectivamente. Entonces, el problema se reduce a encontrar la estatura media de 100 estudiantes si 5 tienen una estatura de 61 in, 18 tienen una estatura de 64 in, etcétera.

Estos cálculos pueden resultar tediosos, en especial en los casos en que los números son grandes y se tienen muchas clases. Existen técnicas abreviadas para reducir el trabajo; ver los problemas 3.20 y 3.22.

Tabla 3.1

Estatura (in)	Marcas de clase (X)	Frecuencias (f)	fX
60-62	61	5	305
63-65	64	18	1 152
66-68	67	42	2 814
69-71	70	27	1 890
72-74	73	8	584
		$N = \sum f = 100$	$\sum fX = 6\,745$

$$\bar{X} = \frac{\sum fX}{\sum f} = \frac{\sum fX}{N} = \frac{6\,745}{100} = 67.45 \text{ in}$$

PROPIEDADES DE LA MEDIA ARITMÉTICA

3.16 Probar que la suma de las desviaciones de $X_1, X_2, \ldots, X_N$ respecto a su media $\bar{X}$ es igual a cero.

SOLUCIÓN

Sean $d_1 = X_1 - \bar{X}$, $d_2 = X_2 - \bar{X}, \ldots, d_N = X_N - \bar{X}$ las desviaciones de $X_1, X_2, \ldots, X_N$ de su media, $\bar{X}$. Entonces

$$\text{La suma de las desviaciones} = \sum d_j = \sum (X_j - \bar{X}) = \sum X_j - N\bar{X}$$
$$= \sum X_j - N\left(\frac{\sum X_j}{N}\right) = \sum X_j - \sum X_j = 0$$

donde se usa $\sum$ en vez de $\sum_{j=1}^{N}$. Si se desea, también se puede omitir el subíndice j de X_j siempre que éste se *sobreentienda*.

3.17 Si $Z_1 = X_1 + Y_1$, $Z_2 = X_2 + Y_2, \ldots, Z_N = X_N + Y_N$, probar que $\bar{Z} = \bar{X} + \bar{Y}$.

SOLUCIÓN

Por definición

$$\bar{X} = \frac{\sum X}{N} \qquad \bar{Y} = \frac{\sum Y}{N} \qquad \bar{Z} = \frac{\sum Z}{N}$$

Por lo tanto $\bar{Z} = \dfrac{\sum Z}{N} = \dfrac{\sum (X+Y)}{N} = \dfrac{\sum X + \sum Y}{N} = \dfrac{\sum X}{N} + \dfrac{\sum Y}{N} = \bar{X} + \bar{Y}$

en donde los subíndices de X, Y y Z se han omitido y donde $\sum$ significa $\sum_{j=1}^{N}$.

3.18 *a*) Si las desviaciones de N números $X_1, X_2, \ldots, X_N$ de un número cualquiera A están dadas por $d_1 = X_1 - A$, $d_2 = X_2 - A, \ldots, d_N = X_N - A$, respectivamente, probar que

$$\bar{X} = A + \frac{\sum_{j=1}^{N} d_j}{N} = A + \frac{\sum d}{N}$$

b) En caso de que $X_1, X_2, \ldots, X_K$ tengas frecuencias respectivas $f_1, f_2, \ldots, f_K$ y que $d_1 = X_1 - A, \ldots, d_K = X_K - A$ demostrar que en lugar del resultado del inciso *a*) se tiene

$$\bar{X} = A + \frac{\sum_{j=1}^{K} f_j d_j}{\sum_{j=1}^{K} f_j} = A + \frac{\sum fd}{N} \qquad \text{donde} \qquad \sum_{j=1}^{K} f_j = \sum f = N$$

SOLUCIÓN

a) **Primer método**

Ya que $d_j = X_j - A$ y que $X_j = A + d_j$, se tiene

$$\bar{X} = \frac{\sum X_j}{N} = \frac{\sum (A + d_j)}{N} = \frac{\sum A + \sum d_j}{N} = \frac{NA + \sum d_j}{N} = A + \frac{\sum d_j}{N}$$

donde se usa $\sum$ en lugar de $\sum_{j=1}^{N}$ para abreviar.

Segundo método

Se tiene $d = X - A$ o bien $X = A + d$, omitiendo los subíndices de d y X. Por lo tanto, de acuerdo con el problema 3.17,

$$\bar{X} = \bar{A} + \bar{d} = A + \frac{\sum d}{N}$$

ya que la media de cualquier cantidad de constantes todas iguales a A es A.

b)
$$\bar{X} = \frac{\sum_{j=1}^{K} f_j X_j}{\sum_{j=1}^{K} f_j} = \frac{\sum f_j X_j}{N} = \frac{\sum f_j (A + d_j)}{N} = \frac{\sum A f_j + \sum f_j d_j}{N} = \frac{A \sum f_j + \sum f_j d_j}{N}$$

$$= \frac{AN + \sum f_j d_j}{N} = A + \frac{\sum f_j d_j}{N} = A + \frac{\sum fd}{N}$$

Obsérvese que *formalmente* este resultado se obtiene del inciso *a*) sustituyendo d_j *por* $f_j d_j$ *y sumando desde* $j = 1$ hasta K en lugar de desde $j = 1$ hasta N. El resultado es equivalente a $\bar{X} = A + \bar{d}$, donde $\bar{d} = (\sum fd)/N$.

CÁLCULO DE LA MEDIA ARITMÉTICA A PARTIR DE DATOS AGRUPADOS

3.19 Emplee el método del problema 3.18*a*) para hallar la media aritmética de los números 5, 8, 11, 9, 12, 6, 14 y 10, eligiendo como "media supuesta" A los valores *a*) 9 y *b*) 20.

SOLUCIÓN

a) Las desviaciones de los números dados respecto al 9 son -4, -1, 2, 0, 3, -3, 5 y 1, y la suma de las desviaciones es $\sum d = -4 - 1 + 2 + 0 + 3 - 3 + 5 + 1 = 3$. Por lo tanto

$$\bar{X} = A + \frac{\sum d}{N} = 9 + \frac{3}{8} = 9.375$$

b) Las desviaciones de los números dados, respecto al 20, son -15, -12, -9, -11, -8, -14, -6 y -10 y $\sum d = -85$. Por lo tanto,

$$\bar{X} = A + \frac{\sum d}{N} = 20 + \frac{(-85)}{8} = 9.375$$

3.20 Emplee el método del problema 3.18*b*) para hallar la media aritmética de las estaturas de 100 estudiantes de la universidad XYZ (ver problema 3.15).

SOLUCIÓN

Para facilitar los cálculos pueden organizarse los datos como en la tabla 3.2. Como media supuesta *A* se toma la marca de clase 67 (que corresponde a la clase con mayor frecuencia), aunque para *A* se puede tomar cualquier marca de clase. Obsérvese que de esta manera los cálculos son más sencillos que en el problema 3.15. Para simplificar aún más el trabajo, se puede proceder como en el problema 3.22, donde se hace uso de que todas las desviaciones (columna 2 de la tabla 3.2) son múltiplos enteros de la amplitud del intervalo de clase.

Tabla 3.2

Marcas de clase (X)	Desviación $d = X - A$	Frecuencias (f)	fd
61	-6	5	-30
64	-3	18	-54
$A \rightarrow$ 67	0	42	0
70	3	27	81
73	6	8	48
		$N = \sum f = 100$	$\sum fd = 45$

$$\bar{X} = A + \frac{\sum fd}{N} = 67 + \frac{45}{100} = 67.45 \text{ in}$$

3.21 Con $d_j = X_j - A$ se denotan las desviaciones de las marcas de clase X_j, de una distribución de frecuencias, respecto a una marca de clase dada *A*. Mostrar que si todos los intervalos de clase son de una misma amplitud *c*, entonces: *a*) todas las desviaciones son múltiplos de *c* (es decir, $d_j = cu_j$ donde $u_j = 0, \pm 1, \pm 2, \ldots$) y *b*) que la media aritmética se puede calcular empleando la fórmula

$$\bar{X} = A + \left(\frac{\sum fu}{N}\right)c$$

SOLUCIÓN

a) Lo pedido queda ilustrado en la tabla 3.2 del problema 3.20, donde en la columna 2 se observa que todas las desviaciones son múltiplos de la amplitud del intervalo de clase $c = 3$ in.

Para ver que esto es válido en general, obsérvese que si $X_1, X_2, X_3, \ldots$ son marcas de clase sucesivas, la diferencia entre ellas será igual a *c*, de manera que $X_2 = X_1 + c$, $X_3 = X_1 + 2c$, y en general, $X_j = X_1 + (j - 1)c$. Entonces, la diferencia entre cualesquiera dos marcas de clase, por ejemplo, X_p y X_q, será

$$X_p - X_q = [X_1 + (p - 1)c] - [X_1 + (q - 1)c] = (p - q)c$$

que es un múltiplo de *c*.

b) De acuerdo con el inciso *a*), las desviaciones de todas las marcas de clase respecto a una marca de clase dada son múltiplos de c (es decir, $d_j = cu_j$). Entonces, usando el problema 3.18*b*), se tiene

$$\bar{X} = A + \frac{\sum f_j d_j}{N} = A + \frac{\sum f_j (cu_j)}{N} = A + c\,\frac{\sum f_j u_j}{N} = A + \left(\frac{\sum fu}{N}\right)c$$

Obsérvese que esto es equivalente a $\bar{X} = A + c\bar{u}$, lo que se obtiene de $\bar{X} = A + \bar{d}$ sustituyendo $d = cu$ y observando que $\bar{d} = c\bar{u}$ (ver problema 3.18).

3.22 Emplee los resultados del problema 3.21*b*) para hallar la estatura media de los 100 estudiantes de la universidad XYZ (ver problema 3.20).

SOLUCIÓN

Para facilitar los cálculos pueden organizarse los datos como en la tabla 3.3. A este método de le llama *método de compilación* y se recomienda usarlo siempre que sea posible.

Tabla 3.3

	X	u	f	fu
	61	−2	5	−10
	64	−2	18	−18
$A \longrightarrow$	67	0	42	0
	70	1	27	27
	73	2	8	16
			$N = 100$	$\sum fu = 15$

$$\bar{X} = A + \left(\frac{\sum fu}{N}\right)c = 67 + \left(\frac{15}{100}\right)(3) = 67.45\text{ in}$$

3.23 Calcule el salario medio semanal de los 65 empleados de la empresa P&R a partir de la distribución de frecuencias de la tabla 2.5, empleando: *a*) el método largo y *b*) el método codificado.

SOLUCIÓN

En las tablas 3.4 y 3.5 se dan las soluciones de *a*) y *b*), respectivamente.

Tabla 3.4

X	f	fX
\$255.00	8	\$2 040.00
265.00	10	2 650.00
275.00	16	4 400.00
285.00	14	3 990.00
295.00	10	2 950.00
305.00	5	1 525.00
315.00	2	630.00
	$N = 65$	$\sum fX = \$18\,185.00$

Tabla 3.5

	X	u	f	fX
	\$255.00	−2	8	−16
	265.00	−1	10	−10
$A \longrightarrow$	275.00	0	16	0
	285.00	1	14	14
	295.00	2	10	20
	305.00	3	5	15
	315.00	4	2	8
			$N = 65$	$\sum fu = 31$

Puede suponerse que estas tablas introducen un error, ya que en realidad las marcas de clase son \$254.995, \$264.995, etc., y no \$255.00, \$265.00, etc. Sin embargo, con las marcas de clase de la tabla 3.4, $\bar{X}$ resulta ser \$279.76 en lugar de \$279.77, lo que es una diferencia despreciable.

$$\bar{X} = \frac{\sum fX}{N} = \frac{\$18\ 185.00}{65} = \$279.77 \qquad \bar{X} = A + \left(\frac{\sum fu}{N}\right)c = \$275.00 + \frac{31}{65}(\$10.00) = \$279.77$$

3.24 Empleando la tabla 2.9*d*), hallar el salario medio de los 70 empleados de la empresa P&R.

SOLUCIÓN

En este caso, los intervalos de clase no son todos de la misma amplitud, por lo que se tiene que usar el método largo, como se muestra en la tabla 3.6

Tabla 3.6

X	u	fX
\$255.00	8	\$2 040.00
265.00	10	2 650.00
275.00	16	4 400.00
285.00	15	4 275.00
295.00	10	2 950.00
310.00	8	2 480.00
350.00	3	1 050.00
	$N = 70$	$\sum fX = \$19\ 845.00$

$$\bar{X} = \frac{\sum fX}{N} = \frac{\$19\ 845.00}{70} = \$283.50$$

LA MEDIANA

3.25 En los resultados de MINITAB, a continuación, se presenta el tiempo, por semana, que 30 usuarios de Internet pasaron haciendo búsquedas, así como la mediana de estos 30 tiempos. Verificar la mediana. ¿Se considera que este promedio es típico (representativo) de estos 30 tiempos? Compárense los resultados con los hallados en el problema 3.8.

```
MTB > print cl
```

Muestra de datos

```
tiempo
3   4   4   5   5   5   5   5   5   6
6   6   6   7   7   7   7   7   8   8
9  10  10  10  10  10  10  12  55  60
```

```
MTB > median cl
```

Mediana de columna

```
Median of time = 7.0000
```

SOLUCIÓN

Obsérvese que los dos valores de en medio son 7 y que la media de estos dos valores de en medio es 7. En el problema 3.8 se encontró que la media es 10.4 horas. La mediana es más típica (representativa) de estos tiempos que la media.

3.26 En los cajeros automáticos de cinco lugares de una ciudad grande, se registró la cantidad de transacciones por día. Los datos fueron 35, 49, 225, 50, 30, 65, 40, 55, 52, 76, 48, 325, 47, 32 y 60. Encontrar: *a*) la cantidad mediana de transacciones y *b*) la cantidad media de transacciones.

SOLUCIÓN

a) Los datos ordenados de menor a mayor son 30, 32, 35, 40, 47, 48, 49, 50, 52, 55, 60, 65, 76, 225 y 325. Como la cantidad de datos es un número non, sólo hay un valor de enmedio, 50, que es la mediana buscada.

b) La suma de los 15 valores es 1 189. La media es $1\,189/15 = 79.257$.

Obsérvese que a la mediana no le afectan los dos valores extremos 225 y 325, en tanto que a la media sí. En este caso, la mediana es un mejor indicador de la cantidad promedio de transacciones diarias en los cajeros automáticos.

3.27 Si en una ordenación se tienen: *a*) 85 y *b*) 150 números, ¿cómo se encuentra la mediana de estos números?

SOLUCIÓN

a) Como 85 es un número non, sólo hay un valor de en medio, habiendo 42 números mayores que él y 42 números menores que él. Por lo tanto, la mediana es el número que ocupa la posición 43 de la ordenación.

b) Como 150 es un número par, hay dos valores de en medio con 74 números menores que ellos y 74 números mayores que ellos. Los dos números de en medio son los números en las posiciones 75 y 76 de la ordenación; su media aritmética es la mediana buscada.

3.28 A partir de los datos del problema 2.8, encontrar el peso mediano de los 40 estudiantes de la universidad estatal empleando: *a*) la distribución de frecuencias dada en la tabla 2.7 (reproducida aquí como tabla 3.7) y *b*) los datos originales.

SOLUCIÓN

a) **Primer método** (empleando la interpolación)

Se supone que los pesos de la tabla 3.7 están distribuidos de manera continua. En ese caso, la mediana es un peso tal que la mitad del total de las frecuencias ($40/2 = 20$) quede por encima de él y la mitad del total de las frecuencias quede por debajo de él.

Tabla 3.7

Peso (lb)	Frecuencias
118-126	3
127-135	5
136-144	9
145-153	12
154-162	5
163-171	4
172-180	2
	Total 40

La suma de las tres primeras frecuencias de clase es 3 + 5 + 9 = 17. Por lo tanto, para dar la frecuencia 20, que es la buscada, se necesitan tres más de los 12 casos que pertenecen a la cuarta clase. Como el cuarto intervalo de clase, 145-153,

en realidad corresponde a los pesos desde 144.5 hasta 153.5, la mediana debe encontrarse a $3/12$ entre 144.5 y 153.5, es decir, la mediana es

$$144.5 + \frac{3}{12}(153.5 - 144.5) = 144.5 + \frac{3}{12}(9) = 146.8 \text{ lb}$$

Segundo método (empleando la fórmula)

Como las sumas de las primeras tres clases y de las primeras cuatro clases son, respectivamente, $3 + 5 + 9 = 17$ y $3 + 5 + 9 + 12 = 29$, la mediana se encuentra en la cuarta clase, que es, por lo tanto, la clase mediana. Entonces.

$L_1 =$ frontera inferior de clase de la clase mediana $= 144.5$
$N =$ número de datos $= 40$
$(\sum f)_1 =$ suma de las frecuencias de todas las clases anteriores a la clase mediana $= 3 + 5 + 9 = 17$
$f_{\text{mediana}} =$ frecuencia de la clase mediana $= 12$
$c =$ amplitud del intervalo de la clase mediana $= 9$

y por lo tanto

$$\text{Mediana} = L_1 + \left(\frac{N/2 - (\sum f)_1}{f_{\text{mediana}}}\right)c = 144.5 + \left(\frac{40/2 - 17}{12}\right)(9) = 146.8 \text{ lb}$$

b) Dispuestos en una ordenación, los pesos originales son
119, 125, 126, 128, 132, 135, 135, 135, 136, 138, 138, 140, 140, 142, 142, 144, 144, 145, 145, 146
146, 147, 147, 148, 149, 150, 150, 152, 153, 154, 156, 157, 158, 161, 163, 164, 165, 168, 173, 176
La mediana es la media aritmética de los pesos en las posiciones 20 y 21 de esta ordenación y es igual a 146 lb.

3.29 En la figura 3-3 se muestra una representación de tallo y hoja que proporciona el número de muertes en accidentes de tránsito en 2005 relacionados con el alcohol en los 50 estados y Washington, D.C.

Representación de tallo y hoja: Muertes

Representación de tallo y hoja: Muertes N = 51
Leaf Unit = 10

14	**0**	**22334556667889**
23	**1**	**122255778**
(7)	**2**	**0334689**
21	**3**	**124679**
15	**4**	**22669**
10	**5**	**012448**
4	**6**	**3**
3	**7**	
3	**8**	
3	**9**	
3	**10**	
3	**11**	
3	**12**	
3	**13**	
3	**14**	**7**
2	**15**	**6**
1	**16**	
1	**17**	**1**

Figura 3-3 MINITAB, representación de tallo y hoja de las muertes en accidentes de tránsito relacionados con el alcohol.

Encontrar la media, la mediana y la moda de las muertes relacionadas con el alcohol dadas en la figura 3-3.

SOLUCIÓN

La cantidad de muertes va de 20 a 1 710. La distribución es bimodal. Las dos modas son 60 y 120. Ambas se presentan tres veces.

La clase `(7) 2 0334689 es la clase mediana`. Es decir, la mediana se encuentra en esta clase. La mediana es el dato de en medio o el dato que ocupa la posición 26 en la ordenación. El dato en la posición 24 es 200, el dato en la posición 25 es 230 y el dato en la posición 26 es 230. Por lo tanto, la mediana es 230.

La suma de estos 51 datos es 16 660 y la media es $16\,660/51 = 326.67$.

3.30 Encontrar el salario mediano de los 65 empleados de la empresa P&R (ver el problema 2.3).

SOLUCIÓN

En este caso, $N = 65$ y $N/2 = 32.5$. Como la suma de las primeras dos y de las primeras tres frecuencias de clase son $8 + 10 = 18$ y $8 + 10 + 16 = 34$, respectivamente, la clase mediana es la tercera clase. Usando la fórmula,

$$\text{Mediana} = L_1 + \left(\frac{N/2 - (\sum f)_1}{f_{\text{mediana}}}\right)c = \$269.995 + \left(\frac{32.5 - 18}{16}\right)(\$10.00) = \$279.06$$

LA MODA

3.31 Encontrar la media, la mediana y la moda de los conjuntos: *a*) 3, 5, 2, 6, 5, 9, 5, 2, 8, 6 y *b*) 51.6, 48.7, 50.3, 49.5, 48.9.

SOLUCIÓN

a) En una ordenación, los números son 2, 2, 3, 5, 5, 5, 6, 6, 8 y 9.

$$\text{Media} = \tfrac{1}{10}(2 + 2 + 3 + 5 + 5 + 5 + 6 + 6 + 8 + 9) = 5.1$$

$$\text{Mediana} = \text{media aritmética de los dos valores de en medio} = \tfrac{1}{2}(5 + 5) = 5$$

$$\text{Moda} = \text{número que se presenta con mayor frecuencia} = 5$$

b) En una ordenación, los números son 48.7, 48.9, 49.5 50.3 y 51.6.

$$\text{Media} = \tfrac{1}{5}(48.7 + 48.9 + 49.5 + 50.3 + 51.6) = 49.8$$

$$\text{Mediana} = \text{número de en medio} = 49.5$$

$$\text{Moda} = \text{número que se presenta con mayor frecuencia (no existe uno aquí)}$$

3.32 Supóngase que se desea hallar la moda de los datos de la figura 3-29. Se puede usar el procedimiento "frequencies" de SAS para obtener el resultado siguiente. Observando el resultado dado por el procedimiento FREQ (figura 3-4), ¿cuáles son las modas de la cantidad de muertes relacionadas con el alcohol?

Procedimiento FREQ

Muertes

Muertes	Frecuencias	Porcentaje	Frecuencias acumuladas	Porcentajes acumulados
20	2	3.92	2	3.92
30	2	3.92	4	7.84
40	1	1.96	5	9.80
50	2	3.92	7	13.73
60	3	5.88	10	19.61
70	1	1.96	11	21.57
80	2	3.92	13	25.49
90	1	1.96	14	27.45
110	1	1.96	15	29.41
120	3	5.88	18	35.29
150	2	3.92	20	39.22
170	2	3.92	22	43.14
180	1	1.96	23	45.10
200	1	1.96	24	47.06
230	2	3.92	26	50.98
240	1	1.96	27	52.94
260	1	1.96	28	54.90
280	1	1.96	29	56.86
290	1	1.96	30	58.82
310	1	1.96	31	60.78
320	1	1.96	32	62.75
340	1	1.96	33	64.71
360	1	1.96	34	66.67
370	1	1.96	35	68.63
390	1	1.96	36	70.59
420	2	3.92	38	74.51
460	2	3.92	40	78.43
490	1	1.96	41	80.39
500	1	1.96	42	82.35
510	1	1.96	43	84.31
520	1	1.96	44	86.27
540	2	3.92	46	90.20
580	1	1.96	47	92.16
630	1	1.96	48	94.12
1470	1	1.96	49	96.08
1560	1	1.96	50	98.04
1710	1	1.96	51	100.00

Figura 3-4 SAS, resultados del procedimiento FREQ para la cantidad de decesos relacionados con el alcohol.

SOLUCIÓN

Estos datos son bimodales y las modas son 60 y 120. Esto se encuentra al observar los resultados de SAS, donde se nota que la frecuencia, tanto de 60 como de 120, es 3, que es mayor que todas las demás frecuencias.

3.33 Algunos paquetes de software para estadística tienen rutinas para encontrar la moda, pero en los casos en los que los datos son multimodales, no dan todas las modas. En la figura 3-5 considerar el resultado que se obtiene con SPSS.

¿Qué hace SPSS cuando se le pide que encuentre las modas?

Muertes

		Frecuencias	Porcentaje	Porcentajes válidos	Porcentajes acumulados
Válido	20.00	2	3.9	3.9	3.9
	30.00	2	3.9	3.9	7.8
	40.00	1	2.0	2.0	9.8
	50.00	2	3.9	3.9	13.7
	60.00	3	5.9	5.9	19.6
	70.00	1	2.0	2.0	21.6
	80.00	2	3.9	3.9	25.5
	90.00	1	2.0	2.0	27.5
	110.00	1	2.0	2.0	29.4
	120.00	3	5.9	5.9	35.3
	150.00	2	3.9	3.9	39.2
	170.00	2	3.9	3.9	43.1
	180.00	1	2.0	2.0	45.1
	200.00	1	2.0	2.0	47.1
	230.00	2	3.9	3.9	51.0
	240.00	1	2.0	2.0	52.9
	260.00	1	2.0	2.0	54.9
	280.00	1	2.0	2.0	56.9
	290.00	1	2.0	2.0	58.8
	310.00	1	2.0	2.0	60.8
	320.00	1	2.0	2.0	62.7
	340.00	1	2.0	2.0	64.7
	360.00	1	2.0	2.0	66.7
	370.00	1	2.0	2.0	68.6
	390.00	1	2.0	2.0	70.6
	420.00	2	3.9	3.9	74.5
	460.00	2	3.9	3.9	78.4
	490.00	1	2.0	2.0	80.4
	500.00	1	2.0	2.0	82.4
	510.00	1	2.0	2.0	84.3
	520.00	1	2.0	2.0	86.3
	540.00	2	3.9	3.9	90.2
	580.00	1	2.0	2.0	92.2
	630.00	1	2.0	2.0	94.1
	1 470.00	1	2.0	2.0	96.1
	1 560.00	1	2.0	2.0	98.0
	1 710.00	1	2.0	2.0	100.0
	Total	51	100.0	100.0	

Estadística

Muertes

N	Válido	51
	Equivocado	0
Moda		60.00[a]

[a]Hay múltiples modas. Se muestra el valor más pequeño.

Figura 3-5 SPSS, resultado para las muertes relacionadas con el alcohol.

SOLUCIÓN

SPSS da la moda más pequeña. Pero se puede inspeccionar la distribución de frecuencias y hallar las modas de la misma manera que con SAS (ver el resultado dado antes).

RELACIÓN EMPÍRICA ENTRE LA MEDIA, LA MEDIANA Y LA MODA

3.34 *a*) Emplear la fórmula empírica media − moda = 3(media − mediana) para hallar el salario modal de los 65 empleados de la empresa P&R.

b) Comparar el resultado con la moda obtenida en el problema 3.33.

SOLUCIÓN

a) De acuerdo con los problemas 3.23 y 3.30 se tiene media = \$279.77 y mediana = \$279.06. Por lo tanto,

$$\text{Moda} = \text{media} - 3(\text{media} - \text{mediana}) = \$279.77 - 3(\$279.77 - \$279.06) = \$277.64$$

b) De acuerdo con el problema 3.33, el salario modal es \$277.50, de manera que en este caso coincide con el resultado empírico.

LA MEDIA GEOMÉTRICA

3.35 Encontrar: *a*) la media geométrica y *b*) la media aritmética de los números 3, 5, 6, 6, 7, 10 y 12. Se supone que los números son exactos.

SOLUCIÓN

a) Media geométrica $= G = \sqrt[7]{(3)(5)(6)(6)(7)(10)(12)} = \sqrt[7]{453\,600}$. Empleando logaritmos comunes, $\log G = \frac{1}{7}\log 453\,600 = \frac{1}{7}(5.6567) = 0.8081$ y $G = 6.43$ (a la centésima más cercana). Otra posibilidad es usar una calculadora.

Otro método

$$\begin{aligned}\log G &= \tfrac{1}{7}(\log 3 + \log 5 + \log 6 + \log 6 + \log 7 + \log 10 + \log 12)\\ &= \tfrac{1}{7}(0.4771 + 0.6990 + 0.7782 + 0.7782 + 0.8451 + 1.0000 + 1.0792)\\ &= 0.8081\end{aligned}$$

y $G = 6.43$

b) Media aritmética $= \hat{X} = \frac{1}{7}(3 + 5 + 6 + 6 + 7 + 10 + 12) = 7$. Esto ilustra que la media geométrica de un conjunto de números positivos, no todos iguales, es menor que su media aritmética.

3.36 Los números $X_1, X_2, \ldots, X_K$ se presentan con frecuencias $f_1, f_2, \ldots, f_K$ donde $f_1 + f_2 + \ldots, + f_K = N$ es la frecuencia total.

a) Encontrar la media geométrica G de estos números.

b) Deducir una expresión para $\log G$.

c) ¿Cómo se pueden emplear los resultados para hallar la media geométrica de datos agrupados en una distribución de frecuencias?

SOLUCIÓN

a)
$$G = \sqrt[N]{\underbrace{X_1X_1\cdots X_1}_{f_1 \text{ veces}}\ \underbrace{X_2X_2\cdots X_2}_{f_2 \text{ veces}}\cdots\underbrace{X_KX_K\cdots X_K}_{f_K \text{ veces}}} = \sqrt[N]{X_1^{f_1}X_2^{f_2}\cdots X_K^{f_K}}$$

donde $N = \sum f$. A esta media suele llamársele *media geométrica ponderada.*

b) $$\log G = \frac{1}{N}\log\left(X_1^{f_1} X_2^{f_2} \cdots X_K^{f_K}\right) = \frac{1}{N}\left(f_1 \log X_1 + f_2 \log X_2 + \cdots + f_K \log X_K\right)$$
$$= \frac{1}{N}\sum_{j=1}^{K} f_j \log X_j = \frac{\sum f \log X}{N}$$

donde se supone que todos los números son positivos; de otra manera, los logaritmos no están definidos.

Obsérvese que el logaritmo de una media geométrica de un conjunto de números positivos es la media aritmética de los logaritmos de los números.

c) Al hallar la media geométrica de datos agrupados, este resultado puede emplearse tomando $X_1, X_2, \ldots, X_K$ como las marcas de clase y $f_1, f_2, \ldots, f_K$ como sus frecuencias correspondientes.

3.37 Durante un año la relación entre precios de un cuarto de galón de leche respecto a precios de una barra de pan fue 3.00, en tanto que al año siguiente la relación fue 2.00.

a) Encontrar la media aritmética de esta relación en estos dos años.
b) Encontrar la media aritmética de las relaciones ahora entre los precios de una barra de pan respecto a los precios de un cuarto de galón de leche en este periodo de 2 años.
c) Analizar la conveniencia de emplear la media aritmética para promediar relaciones.
d) Analizar la idoneidad de la media geométrica para promediar relaciones.

SOLUCIÓN

a) Media de las relaciones (cocientes) precio de leche respecto a precios de pan $= \frac{1}{2}(3.00 + 2.00) = 2.50$.

b) Como el primer año la relación entre precios de leche respecto a precios de pan es 3.00, la relación entre precios de pan respecto a precios de leche es $1/3 = 0.333$. De igual manera, la relación entre precios de pan y precios de leche el segundo año es $1/2.00 = 0.500$.

Por lo tanto,

Media de las relaciones (cocientes) precio de pan respecto a precios de leche $= \frac{1}{2}(0.333 + 0.500) = 0.417$

c) Si la media fuera un promedio adecuado, se esperaría que la media de las relaciones de precios de leche respecto a precios de pan fuera el recíproco de la media de las relaciones precios de pan respecto a precios de leche. Sin embargo, $1/0.417 = 2.40 \neq 2.50$. Esto demuestra que la media no es un promedio adecuado para (cocientes) relaciones.

d) La media geométrica de las relaciones entre precios de leche respecto a precios de pan $= \sqrt{(3.00)(2.00)} = \sqrt{6.00}$

La media geométrica de las relaciones entres precios de pan respecto a precios de leche $= \sqrt{(0.333)(0.500)} = \sqrt{0.0167} = 1/\sqrt{6.00}$

Dado que estos promedios son recíprocos, se concluye que la media geométrica es más adecuada que la media aritmética para promediar relaciones (cocientes).

3.38 La cuenta bacteriana en cierto medio de cultivo aumentó de 1 000 a 4 000 en 3 días. ¿Cuál es el incremento porcentual promedio por día?

SOLUCIÓN

Como un incremento de 1 000 a 4 000 es un incremento de 300%, uno está inclinado a concluir que el aumento porcentual promedio por día es $300\%/3 = 100\%$. Sin embargo, esto significaría que el primer día la cuenta aumentó de 1 000 a 2 000, el segundo día de 2 000 a 4 000 y el tercer día de 4 000 a 8 000, lo cual no es así.

Para determinar este incremento porcentual promedio se denotará r a este incremento porcentual promedio. Entonces

$$\text{Cuenta bacteriana total un día después} = 1\,000 + 1\,000r = 1\,000(1 + r)$$
$$\text{Cuenta bacteriana total dos días después} = 1\,000(1 + r) + 1\,000(1 + r)r = 1\,000(1 + r)^2$$
$$\text{Cuenta bacteriana total tres días después} = 1\,000(1 + r)^2 + 1\,000(1 + r)^2 r = 1\,000(1 + r)^3$$

Esta última expresión debe ser igual a 4 000. De manera que $1\,000(1 + r)^3 = 4\,000$, $(1 + r)^3 = 4$, $1 + r = \sqrt[3]{4}$, y $r = \sqrt[3]{4} - 1 = 1.587 - 1 = 0.587$, y así, $r = 58.7\%$.

En general, si se parte de una cantidad P y se incrementa esta cantidad a una tasa constante r por unidad de tiempo, la cantidad que se tendrá después de n unidades de tiempo será

$$A = P(1 + r)^n$$

A esta fórmula se le llama *fórmula del interés compuesto* (ver problemas 3.94 y 3.95).

LA MEDIA ARMÓNICA

3.39 Encontrar la media armónica H de los números 3, 5, 6, 6, 7, 10 y 12.

SOLUCIÓN

$$\frac{1}{H} = \frac{1}{N}\sum\frac{1}{X} = \frac{1}{7}\left(\frac{1}{3}+\frac{1}{5}+\frac{1}{6}+\frac{1}{6}+\frac{1}{7}+\frac{1}{10}+\frac{1}{12}\right) = \frac{1}{7}\left(\frac{140+84+70+70+60+42+35}{420}\right)$$

$$= \frac{501}{2\,940}$$

y $$H = \frac{2\,940}{501} = 5.87$$

Suele ser mejor expresar primero las fracciones en forma decimal. Así

$$\frac{1}{H} = \tfrac{1}{7}(0.3333 + 0.2000 + 0.1667 + 0.1667 + 0.1429 + 0.1000 + 0.0833)$$

$$= \frac{1.1929}{7}$$

y $$H = \frac{7}{1.1929} = 5.87$$

Comparando con los resultados del problema 3.35 se ilustra el hecho de que la media armónica de números positivos, no todos iguales, es menor que su media geométrica, la que a su vez es menor que su media aritmética.

3.40 Durante cuatro años consecutivos los precios del fuel para la calefacción son \$0.80, \$0.90, \$1.05 y \$1.25 por galón (gal). ¿Cuál es el precio promedio del fuel en estos cuatro años?

SOLUCIÓN

Caso 1

Supóngase que todos los años se compra la misma cantidad de fuel, digamos 1 000 gal. Entonces

$$\text{Precio promedio} = \frac{\text{precio total}}{\text{cantidad total comprada}} = \frac{\$800 + \$900 + \$1\,050 + \$1\,250}{4\,000\,\text{gal}} = \$1.00/\text{gal}$$

Esto es lo mismo que la media aritmética del costo por galón; es decir $\frac{1}{4}(\$0.80 + \$0.90 + \$1.05 + \$1.25) = 1.00/\text{gal}$. Este resultado sería el mismo aun cuando se usaran x galones por año.

Caso 2

Supóngase que en el fuel se gasta la misma cantidad de dinero todos los años, o sea \$1 000. Entonces

$$\text{Precio promedio} = \frac{\text{precio total}}{\text{cantidad total comprada}} = \frac{\$4\,000}{(1\,250 + 1\,111 + 952 + 800)\text{gal}} = \$0.975/\text{gal}$$

Esto es lo mismo que la media armónica de los precios por galón:

$$\frac{4}{\frac{1}{0.80}+\frac{1}{0.90}+\frac{1}{1.05}+\frac{1}{1.25}} = 0.975$$

El resultado será el mismo si se gastan *y* dólares por año.

Ambos promedios son correctos, pero se calculan para condiciones diferentes.

Debe notarse que si la cantidad de galones empleados varía de un año a otro, en vez de ser siempre la misma, en lugar de la media aritmética ordinaria usada en el caso 1, hay que usar la media aritmética ponderada. De manera similar, si la cantidad gastada varía de un año a otro, en lugar de la media armónica empleada en el caso 2 se debe usar la media armónica ponderada.

3.41 Un automóvil recorre 25 millas a 25 millas por hora (mph), 25 millas a 50 mph y 25 millas a 75 mph. Encontrar la media aritmética de las tres velocidades y la media armónica de las tres velocidades. ¿Cuál es correcta?

SOLUCIÓN

La velocidad promedio es igual a la distancia recorrida dividida entre el total del tiempo y es igual a lo siguiente:

$$\frac{75}{\left(1+\frac{1}{2}+\frac{1}{3}\right)} = 40.9 \text{ mi/h}$$

La media aritmética de las tres velocidades es:

$$\frac{25+50+75}{3} = 50 \text{ mi/h}$$

La media armónica se encuentra como sigue:

$$\frac{1}{H} = \frac{1}{N}\sum\frac{1}{X} = \frac{1}{3}\left(\frac{1}{25}+\frac{1}{50}+\frac{1}{75}\right) = \frac{11}{450} \qquad \text{y} \qquad H = \frac{450}{11} = 40.9$$

La media armónica es la medida correcta de la velocidad promedio.

LA RAÍZ CUADRADA MEDIA O MEDIA CUADRÁTICA

3.42 Encontrar la media cuadrática de los números 3, 5, 6, 6, 7, 10 y 12.

SOLUCIÓN

$$\text{Media cuadrática} = \text{RCM} = \sqrt{\frac{3^2+5^2+6^2+6^2+7^2+10^2+12^2}{7}} = \sqrt{57} = 7.55$$

3.43 Demostrar que la media cuadrática de dos números positivos distintos *a* y *b* es mayor que su media geométrica.

SOLUCIÓN

Se pide que se demuestre que $\sqrt{\frac{1}{2}(a^2+b^2)} > \sqrt{ab}$. Si esto es verdad, entonces elevando al cuadrado ambos miembros $\frac{1}{2}(a^2+b^2) > ab$, de manera que $a^2+b^2 > 2ab$, $a^2-2ab^2+b^2 > 0$ o bien $(a-b)^2 > 0$. Pero esta igualdad es cierta, ya que el cuadrado de cualquier número real distinto de cero es positivo.

La prueba consiste en demostrar el proceso inverso. Entonces, partiendo de $(a-b)^2 > 0$, que se sabe que es verdadero, se puede mostrar que $a^2 + b^2 > 2ab$, $\frac{1}{2}(a^2 + b^2) > ab$ y finalmente $\sqrt{\frac{1}{2}(a^2 + b^2)} > \sqrt{ab}$, que es lo pedido.

Obsérvese que $\sqrt{\frac{1}{2}(a^2 + b^2)} = \sqrt{ab}$ si y sólo si $a = b$.

CUARTILES, DECILES Y PERCENTILES

3.44 Para los salarios de los 65 empleados de la empresa P&R (ver problema 2.9), encontrar: *a*) los cuartiles Q_1, Q_2 y Q_3 y *b*) los deciles D_1, $D_2, \ldots, D_9$.

SOLUCIÓN

a) El primer cuartil Q_1 es el salario que se encuentra contando $N/4 = 65/4 = 16.25$ de los casos, comenzando con la primera clase (la más baja). Como la primera clase contiene 8 casos, hay que tomar 8.5 (16.25 − 8) casos de los 10 de la segunda clase. Usando el método de interpolación lineal, se tiene

$$Q_1 = \$259.995 + \frac{8.25}{10}(\$10.00) = \$268.25$$

El segundo cuartil Q_2 se encuentra contando los primeros $2N/4 = N/2 = 65/2 = 32.5$ de los casos. Como las primeras dos clases comprenden 18 casos, se deben tomar 32.5 – 18 = 14.5 casos de los 16 de la tercera clase, por lo tanto

$$Q_2 = \$269.995 + \frac{14.5}{16}(\$10.00) = \$279.06$$

Obsérvese que Q_2 es la mediana.

El tercer cuartil Q_3 se encuentra contando los primeros $3N/4 = \frac{3}{4}(65) = 48.75$ de los casos. Como las primeras cuatro clases comprenden 48 casos, se deben tomar 48.75 – 48 = 0.75 casos de los 10 de la quinta clase; por lo tanto

$$Q_3 = \$289.995 + \frac{0.75}{10}(\$10.00) = \$290.75$$

Así, 25% de los empleados ganan \$268.25 o menos, 50% gana \$279.06 o menos y 75% gana \$290.75 o menos.

b) Los deciles primero, segundo, …, y noveno se obtienen contando $N/10$, $2N/10, \ldots, 9N/10$ de los casos empezando por la primer clase (inferior). Por lo tanto

$$D_1 = \$249.995 + \frac{6.5}{8}(\$10.00) = \$258.12 \qquad D_6 = \$279.995 + \frac{5}{14}(\$10.00) = \$283.57$$

$$D_2 = \$259.995 + \frac{5}{10}(\$10.00) = \$265.00 \qquad D_7 = \$279.995 + \frac{11.5}{14}(\$10.00) = \$288.21$$

$$D_3 = \$269.995 + \frac{1.5}{16}(\$10.00) = \$270.94 \qquad D_8 = \$289.995 + \frac{4}{10}(\$10.00) = \$294.00$$

$$D_4 = \$269.995 + \frac{8}{16}(\$10.00) = \$275.00 \qquad D_9 = \$299.995 + \frac{0.5}{5}(\$10.00) = \$301.00$$

$$D_5 = \$269.995 + \frac{14.5}{16}(\$10.00) = \$279.06$$

De manera que 10% de los empleados gana \$258.12 o menos, 20% gana \$265.00 o menos, …, 90% gana \$301.00 o menos.

Obsérvese que el quinto decil es la mediana. Los deciles segundo, cuarto, sexto y octavo, que dividen la distribución en cinco partes iguales y a los que se les llama *quintiles*, también suelen usarse en la práctica.

3.45 En la distribución del problema 3.44, determinar *a*) el percentil 35o. y *b*) el percentil 60o.

SOLUCIÓN

a) El percentil 35o., que se denota P_{35}, se obtiene contando los primeros $35N/100 = 35(65)/100 = 22.75$ casos, empezando en la primera clase (la clase más baja). Entonces, como en el problema 3.44,

$$P_{35} = \$269.995 + \frac{4.75}{16}(\$10.00) = \$272.97$$

Esto significa que 35% de los empleados gana \$272.97 o menos.

b) El percentil 60o. es $P_{60} = \$279.995 + \frac{5}{14}(\$10.00) = \$283.57$. Obsérvese que éste coincide con el sexto decil o tercer quintil.

3.46 La siguiente hoja de cálculo de EXCEL está contenida en A1:D26. Esta hoja de cálculo contiene el ingreso per cápita en cada uno de los 50 estados de Estados Unidos. Dar los comandos de EXCEL para hallar Q_1, Q_2, Q_3 y P_{95}. Dar también los estados que están a ambos lados de estos cuartiles o percentiles.

Estado	Ingreso per cápita	Estado	Ingreso per cápita
Wyoming	36 778	Pennsylvania	34 897
Montana	29 387	Wisconsin	33 565
North Dakota	31 395	Massachusetts	44 289
New Mexico	27 664	Missouri	31 899
West Virginia	27 215	Idaho	28 158
Rhode Island	36 153	Kentucky	28 513
Virginia	38 390	Minnesota	37 373
South Dakota	31 614	Florida	33 219
Alabama	29 136	South Carolina	28 352
Arkansas	26 874	New York	40 507
Maryland	41 760	Indiana	31 276
Iowa	32 315	Connecticut	47 819
Nebraska	33 616	Ohio	32 478
Hawaii	34 539	New Hampshire	38 408
Mississippi	25 318	Texas	32 462
Vermont	33 327	Oregon	32 103
Maine	31 252	New Jersey	43 771
Oklahoma	29 330	California	37 036
Delaware	37 065	Colorado	37 946
Alaska	35 612	North Carolina	30 553
Tennessee	31 107	Illinois	36 120
Kansas	32 836	Michigan	33 116
Arizona	30 267	Washington	35 409
Nevada	35 883	Georgia	31 121
Utah	28 061	Louisiana	24 820

SOLUCIÓN

		Estados más cercanos
=PERCENTILE(A2:D26,0.25)	\$30 338.5	Arizona y NorthCarolina
=PERCENTILE(A2:D26,0.50)	\$32 657	Ohio y Kansas
=PERCENTILE(A2:D26,0.75)	\$36 144.75	Illinois y RhodeIsland
=PERCENTILE(A2:D26,0.95)	\$42 866.05	Maryland y NewJersey

PROBLEMAS SUPLEMENTARIOS

SUMATORIA

3.47 Escribir los términos de cada una de las sumas siguientes:

a) $\sum_{j=1}^{4}(X_j+2)$ *c*) $\sum_{j=1}^{3}U_j(U_j+6)$ *e*) $\sum_{j=1}^{4}4X_jY_j$

b) $\sum_{j=1}^{5}f_jX_j^2$ *d*) $\sum_{k=1}^{N}(Y_k^2-4)$

3.48 Escribir cada una de las sumas siguientes usando el signo de sumatoria:

a) $(X_1+3)^3+(X_2+3)^3+(X_3+3)^3$

b) $f_1(Y_1-a)^2+f_2(Y_2-a)^2+\cdots+f_{15}(Y_{15}-a)^2$

c) $(2X_1-3Y_1)+(2X_2-3Y_2)+\cdots+(2X_N-3Y_N)$

d) $(X_1/Y_1-1)^2+(X_2/Y_2-1)^2+\cdots+(X_8/Y_8-1)^2$

e) $\dfrac{f_1a_1^2+f_2a_2^2+\cdots+f_{12}a_{12}^2}{f_1+f_2+\cdots+f_{12}}$

3.49 Demostrar que $\sum_{j=1}^{N}(X_j-1)^2=\sum_{j=1}^{N}X_j^2-2\sum_{j=1}^{N}X_j+N$

3.50 Demostrar que $\sum(X+a)(Y+b)=\sum XY+a\sum Y+b\sum X+Nab$, donde a y b son constantes. ¿Cuáles son los subíndices implícitos?

3.51 Las variables U y V toman los valores $U_1=3$, $U_2=-2$, $U_3=5$ y $V_1=-4$, $V_2=-1$, $V_3=6$, respectivamente. Calcular *a*) $\sum UV$, *b*) $\sum(U+3)(V-4)$, *c*) $\sum V^2$, *d*) $(\sum U)(\sum V)^2$, *e*) $\sum UV^2$, *f*) $\sum(U^2-2V^2+2)$ y *g*) $\sum(U/V)$.

3.52 Dado que $\sum_{j=1}^{4}X_j=7$, $\sum_{j=1}^{4}Y_j=-3$ y $\sum_{j=1}^{4}X_jY_j=5$, encontrar *a*) $\sum_{j=1}^{4}(2X_j+5Y_j)$ y *b*) $\sum_{j=1}^{4}(X_j-3)(2Y_j+1)$.

LA MEDIA ARITMÉTICA

3.53 En cinco materias, un estudiante obtuvo las calificaciones siguientes: 85, 76, 93, 82 y 96. Determinar la media aritmética de estas calificaciones.

3.54 Un psicólogo mide los tiempos de reacción de un individuo a ciertos estímulos; éstos fueron 0.53, 0.46, 0.50, 0.49,0.52, 0.53, 0.44 y 0.55 segundos, respectivamente. Estimar el tiempo medio de reacción del individuo a estos estímulos.

3.55 Un conjunto de números consta de 6 seises, 7 sietes, 8 ochos, 9 nueves y 10 dieces. ¿Cuál es la media aritmética de estos números?

3.56 Un estudiante obtuvo las calificaciones siguientes en tres aspectos de un curso: 71, 78 y 89, respectivamente.

a) Si los pesos que se acuerda dar a estas calificaciones son 2, 4 y 5, respectivamente, ¿cuál es una calificación promedio apropiada?

b) ¿Cuál es la calificación promedio si se usan pesos iguales?

3.57 Los promedios de calificación en los cursos de tres maestros de economía son 79, 74 y 82, y sus grupos constan de 32, 25 y 17 alumnos, respectivamente. Determinar la calificación media de los tres cursos.

3.58 El salario anual medio pagado a los empleados de una empresa es \$36 000. Los salarios anuales medios pagados a hombres y mujeres de la empresa son \$34 000 y \$40 000, respectivamente. Determinar el porcentaje de hombres y mujeres empleados por la empresa.

3.59 En la tabla 3.8 se presenta la distribución de las cargas máximas, en toneladas cortas (1 tonelada corta = 2 000 lb) que soportan ciertos cables producidos por una empresa. Determinar la carga máxima media usando: *a*) el método largo y *b*) el método de compilación.

Tabla 3.8

Carga máxima (toneladas cortas)	Cantidad de cables
9.3-9.7	2
9.8-10.2	5
10.3-10.7	12
10.8-11.2	17
11.3-11.7	14
11.8-12.2	6
12.3-12.7	3
12.8-13.2	1
	Total 60

3.60 Encontrar $\bar{X}$ para los datos de la tabla 3.9 usando: *a*) el método largo y *b*) el método de compilación.

Tabla 3.9

X	462	480	498	516	534	552	570	588	606	624
f	98	75	56	42	30	21	15	11	6	2

3.61 En la tabla 3.10 se presenta la distribución de los diámetros de las cabezas de remaches producidos por una empresa. Calcular el diámetro medio.

3.62 Calcular la media de los datos de la tabla 3.11.

Tabla 3.10

Diámetro (cm)	Frecuencias
0.7247-0.7249	2
0.7250-0.7252	6
0.7253-0.7255	8
0.7256-0.7258	15
0.7259-0.7261	42
0.7262-0.7264	68
0.7265-0.7267	49
0.7268-0.7270	25
0.7271-0.7273	18
0.7274-0.7276	12
0.7277-0.7279	4
0.7280-0.7282	1
	Total 250

Tabla 3.11

Clase	Frecuencias
10 hasta menos de 15	3
15 hasta menos de 20	7
20 hasta menos de 25	16
25 hasta menos de 30	12
30 hasta menos de 35	9
35 hasta menos de 40	5
40 hasta menos de 45	2
	Total 54

3.63 Calcular la media de la cantidad de tiempo que ven televisión los 400 estudiantes del problema 2.20.

3.64 *a*) Emplear la distribución de frecuencias del problema 2.27 para calcular el diámetro medio de los balines.
b) Calcular la media directamente de los datos en bruto y compararla con el inciso *a*); explicar cualquier discrepancia.

LA MEDIANA

3.65 Encontrar la media y la mediana de estos conjuntos de números: *a*) 5, 4, 8, 3, 7, 2, 9 y *b*) 18.3, 20.6, 19.3, 22.4, 20.2, 18.8, 19.7, 20.0.

3.66 Encontrar la calificación mediana del problema 3.53.

3.67 Encontrar el tiempo mediano de reacción del problema 3.54.

3.68 Encontrar la mediana del conjunto de números del problema 3.55.

3.69 Encontrar la mediana de la carga máxima de los cables de la tabla 3.8 del problema 3.59.

3.70 Encontrar la mediana $\tilde{X}$ de la distribución presentada en la tabla 3.9 del problema 3.60.

3.71 Encontrar el diámetro mediano de las cabezas de los remaches de la tabla 3.10 del problema 3.61.

3.72 Encontrar la mediana de la distribución presentada en la tabla 3.11 del problema 3.62.

3.73 En la tabla 3.12 se da la cantidad, en miles, de muertes en Estados Unidos ocurridas en 1993 a causa de enfermedades cardiacas. Encontrar la edad mediana.

Tabla 3.12

Grupo de edad	Miles de muertes
Total	743.3
Menos de 1	0.7
1 a 4	0.3
5 a 14	0.3
15 a 24	1.0
25 a 34	3.5
35 a 34	13.1
45 a 54	32.7
55 a 64	72.0
65 a 74	158.1
75 a 84	234.0
85 y más	227.6

Fuente: U.S. National Center for Health Statistics, Vital Statistics of the U.S., annual.

3.74 Con los datos de la tabla del problema 2.31 encontrar la edad mediana.

3.75 Encontrar la mediana de la cantidad de tiempo que ven la televisión los 400 estudiantes del problema 2.20.

LA MODA

3.76 Encontrar la media, la mediana y la moda de cada uno de los conjuntos de números siguientes: *a*) 7, 4, 10, 9, 15, 12, 7, 9, 7 y *b*) 8, 11, 4, 3, 2, 5, 10, 6, 4, 1, 10, 8, 12, 6, 5, 7.

3.77 En el problema 3.53 encontrar la calificación modal.

3.78 En el problema 3.54 encontrar el tiempo de reacción modal.

3.79 En el problema 3.55 encontrar la moda del conjunto de números.

3.80 En el problema 3.59 encontrar la moda de la carga máxima de los cables.

3.81 En el problema 3.60 encontrar la moda $\hat{X}$ de la distribución dada en la tabla 3.9.

3.82 En el problema 3.61 encontrar el diámetro modal de las cabezas de los remaches de la tabla 3.10.

3.83 En el problema 3.62 encontrar la moda de la distribución dada.

3.84 En el problema 2.20 encontrar la moda de la cantidad de tiempo que ven televisión los 400 estudiantes.

3.85 *a*) ¿Cuál es el grupo de edad modal en la tabla 2.15?
b) ¿Cuál es el grupo de edad modal en la tabla 3.12?

3.86 Empleando las fórmulas (*9*) y (*10*) de este capítulo, hallar la moda de las distribuciones dadas en los problemas siguientes. Comparar las respuestas obtenidas con cada una de las dos fórmulas.
a) Problema 3.59 *b*) Problema 3.61 *c*) Problema 3.62 *d*) Problema 2.20.

3.87 La probabilidad de una variable aleatoria continua está descrita por la siguiente función de densidad de probabilidad. $f(x) = -0.75x^2 + 1.5x$ para $0 < x < 2$ y para todos los demás valores de x, $f(x) = 0$. La moda se presenta en el punto en el que la función alcanza su máximo. Empleando los conocimientos sobre funciones cuadráticas, mostrar que la moda se presenta en $x = 1$.

LA MEDIA GEOMÉTRICA

3.88 Hallar la media geométrica de los números: *a*) 4.2 y 16.8 y *b*) 3.00 y 6.00.

3.89 Hallar: *a*) la media geométrica G y *b*) la media aritmética $\bar{X}$ del conjunto 2, 4, 8, 16, 32.

3.90 Hallar la media geométrica de los conjuntos: *a*) 3, 5, 8, 3, 7, 2 y *b*) 28.5, 73.6, 47.2, 31.5, 64.8.

3.91 Hallar la media geométrica de las distribuciones de: *a*) el problema 3.59 y *b*) el problema 3.60. Verificar que en estos casos la media geométrica es menor o igual a la media aritmética.

3.92 Si en un periodo de 4 años se duplican los precios de un artículo, ¿cuál es el incremento porcentual anual promedio?

3.93 En 1980 y 1996 la población de Estados Unidos era de 226.5 millones y 266.0 millones, respectivamente. Empleando la fórmula dada en el problema 3.38, contestar lo siguiente.

a) ¿Cuál es el incremento porcentual anual promedio?

b) Estimar la población en 1985.

c) Si el incremento porcentual anual promedio de 1996 a 2000 es el mismo que en el inciso *a*), ¿a cuánto ascenderá la población en 2000?

3.94 Se invierten \$1 000 a una tasa de interés anual de 8%. ¿A cuánto ascenderá la cantidad total después de 6 años si no se retira el capital inicial?

3.95 Si en el problema 3.94 el interés es compuesto trimestralmente (es decir, el dinero gana 2% de interés cada 3 meses), ¿cuál será la cantidad total después de 6 años?

3.96 Encontrar dos números cuya media aritmética sea 9.00 y cuya media geométrica sea 7.2.

LA MEDIA ARMÓNICA

3.97 Encontrar la media armónica de los números: *a*) 2, 3 y 6 y *b*) 3.2, 5.2, 4.8, 6.1 y 4.2.

3.98 Encontrar: *a*) la media aritmética, *b*) la media geométrica y *c*) la media armónica de los números 0, 2, 4 y 6.

3.99 Si $X_1, X_2, X_3, \ldots$, son las marcas de clase de una distribución de frecuencias y $f_1, f_2, f_3, \ldots$, son sus frecuencias correspondientes, demostrar que su media armónica está dada por

$$\frac{1}{H} = \frac{1}{N}\left(\frac{f_1}{X_1} + \frac{f_2}{X_2} + \frac{f_3}{X_3} + \cdots\right) = \frac{1}{N}\sum \frac{f}{X}$$

donde $N = f_1 + f_2 + \cdots = \sum f$

3.100 Emplear el problema 3.99 para hallar la media armónica de la distribución: *a*) del problema 3.59 y *b*) del problema 3.60. Comparar con el problema 3.91.

3.101 Las ciudades *A*, *B* y *C* están equidistantes una de otra. Un conductor viaja de la ciudad *A* a la ciudad *B* a 30 mi/h, de la ciudad *B* a la ciudad *C* a 40 mi/h y de la ciudad *C* a la ciudad *A* a 50 mi/h. Determinar su velocidad promedio en este viaje.

3.102 *a*) Un aeroplano recorre las distancias d_1, d_2 y d_3 a las velocidades v_1, v_2 y v_3 mi/h, respectivamente. Mostrar que la velocidad promedio está dada por *V*, donde

$$\frac{d_1 + d_2 + d_3}{V} = \frac{d_1}{v_1} + \frac{d_2}{v_2} + \frac{d_3}{v_3}$$

Ésta es una media armónica ponderada.

b) Encontrar: *V* si $d_1 = 2\,500$, $d_2 = 1\,200$, $d_3 = 500$, $v_1 = 500$, $v_2 = 400$ y $v_3 = 250$.

3.103 Demostrar que la media geométrica de dos números *a* y *b* es: *a*) menor o igual que su media aritmética y *b*) mayor o igual que su media armónica. ¿Puede generalizar la prueba a más de dos números?

LA RAÍZ CUADRADA MEDIA O LA MEDIA CUADRÁTICA

3.104 Encontrar la RCM (o media cuadrática) de los números: *a*) 11, 23 y 35, y *b*) 2.7, 3.8, 3.2 y 4.3.

3.105 Probar que la RCM de dos números positivos, *a* y *b*, es: *a*) mayor o igual que la media aritmética y *b*) mayor o igual que la media armónica. Se puede extender la prueba a más de dos números.

3.106 Deducir una fórmula que pueda usarse para hallar la RCM de datos agrupados y aplicarla a una de las distribuciones de frecuencias ya consideradas.

CUARTILES, DECILES Y PERCENTILES

3.107 En la tabla 3.13 se presenta una distribución de frecuencias de las calificaciones en un examen final de álgebra. *a*) Encontrar los cuartiles de esta distribución y *b*) interpretar claramente cada uno de ellos.

Tabla 3.13

Calificación	Cantidad de estudiantes
90-100	9
80-89	32
70-79	43
60-69	21
50-59	11
40-49	3
30-39	1
	Total 120

3.108 Encontrar los cuartiles Q_1, Q_2 y Q_3 de las distribuciones: *a*) del problema 3.59 y *b*) del problema 3.60. Interpretar claramente cada uno de ellos.

3.109 Proporcionar seis términos estadísticos diferentes para el punto de equilibrio o valor central en una curva de frecuencias en forma de campana.

3.110 Encontrar: *a*) P_{10}, *b*) P_{90}, *c*) P_{25} y *d*) P_{75} en los datos del problema 3.59. Interpretar claramente cada uno de ellos.

3.111 *a*) ¿Se pueden expresar todos los deciles y cuartiles como percentiles? Explicar.

b) ¿Se pueden expresar los cuantiles como percentiles? Explicar.

3.112 Para los datos del problema 3.107, determinar: *a*) la calificación más baja obtenida por el 25% superior de los alumnos y *b*) la puntuación más alta alcanzada por el 20% inferior de los alumnos. Interpretar las respuestas en términos de percentiles.

3.113 Interpretar gráficamente los resultados del problema 3.107 empleando: *a*) un histograma porcentual, *b*) un polígono de frecuencia porcentual y *c*) una ojiva porcentual.

3.114 Repetir el problema 3.113 para los resultados del problema 3.108.

3.115 *a*) Desarrollar una fórmula similar a la de la ecuación (*8*) de este capítulo que permita calcular cualquier percentil de una distribución de frecuencias.

b) Ilustrar el uso de la fórmula empleándola para obtener los resultados del problema 3.110.

DESVIACIÓN ESTÁNDAR Y OTRAS MEDIDAS DE DISPERSIÓN

4

DISPERSIÓN O VARIACIÓN

El grado de dispersión de los datos numéricos respecto a un valor promedio se llama *dispersión* o *variación* de los datos. Existen varias medidas de dispersión (o variación); las más usadas son el rango, la desviación media, el rango semiintercuartil, el rango percentil 10-90 y la desviación estándar.

RANGO

El *rango* de un conjunto de números es la diferencia entre el número mayor y el número menor del conjunto.

EJEMPLO 1 El rango del conjunto 2, 3, 3, 5, 5, 5, 8, 10, 12 es $12 - 2 = 10$. Algunas veces el rango se da mediante el número menor y el número mayor; así, por ejemplo, en el caso del conjunto anterior, simplemente se indica de 2 a 12 o 2-12.

DESVIACIÓN MEDIA

La *desviación media*, o *desviación promedio*, de un conjunto de N números $X_1, X_2, \ldots, X_N$ se abrevia DM y está definida así:

$$\text{Desviación media (DM)} = \frac{\sum_{j=1}^{N} |X_j - \bar{X}|}{N} = \frac{\sum |X - \bar{X}|}{N} = \overline{|X - \bar{X}|} \qquad (1)$$

donde $\bar{X}$ es la media aritmética de los números y $|X_j - \bar{X}|$ es el valor absoluto de la desviación de X_j respecto de $\bar{X}$. (El valor absoluto de un número es el número sin signo; el valor absoluto de un número se indica por medio de dos barras verticales colocadas a los lados del número, así $|-4| = 4$, $|+3| = 3$, $|6| = 6$ y $|-0.84| = 0.84$|.)

EJEMPLO 2 Encuentre la desviación media del conjunto 2, 3, 6, 8, 11.

$$\text{Media aritmética } (\bar{X}) = \frac{2+3+6+8+11}{5} = 6$$

$$\text{DM} = \frac{|2-6|+|3-6|+|6-6|+|8-6|+|11-6|}{5} = \frac{|-4|+|-3|+|0|+|2|+|5|}{5} = \frac{4+3+0+2+5}{5} = 2.8$$

Si $X_1, X_2, \ldots, X_K$ se presentan con frecuencias $f_1, f_2, \ldots, f_K$, respectivamente, la desviación media puede expresarse como

$$\text{DM} = \frac{\sum_{j=1}^{K} f_j |X_j - \bar{X}|}{N} = \frac{\sum f\,|X - \bar{X}|}{N} = \overline{|X - \bar{X}|} \tag{2}$$

donde $N = \sum_{j=1}^{K} f_j = \sum f$. Esta fórmula es útil para datos agrupados, donde las X_j representan las marcas de clase y las f_j las correspondientes frecuencias de clase.

En ocasiones, la desviación media se define en términos de las desviaciones absolutas respecto de la mediana o de otro promedio, y no respecto de la media. Una propiedad interesante de la suma $\sum_{j=1}^{N} |X_j - a|$ es que es mínima cuando a es la mediana (es decir, la desviación media absoluta con respecto de la mediana es un mínimo).

Obsérvese que sería más apropiado emplear el término *desviación media absoluta* en vez de *desviación media.*

RANGO SEMIINTERCUARTIL

El *rango semiintercuartil*, o *desviación cuartil*, de un conjunto de datos se denota Q y está definido por

$$Q = \frac{Q_3 - Q_1}{2} \tag{3}$$

donde Q_1 y Q_3 son el primero y tercer cuartiles en los datos (ver problemas 4.6 y 4.7). Algunas veces se usa el rango intercuartil $Q_3 - Q_1$, sin embargo, el rango semiintercuartil es más usado como medida de dispersión.

RANGO PERCENTIL 10-90

El *rango percentil 10-90* de un conjunto de datos está definido por

$$\text{Rango percentil 10-90} = P_{90} - P_{10} \tag{4}$$

donde P_{10} y P_{90} son los percentiles 10o. y 90o. en los datos (ver problema 4.8). El rango semipercentil 10-90, $\frac{1}{2}(P_{90} - P_{10})$, también puede usarse, pero no es muy común.

DESVIACIÓN ESTÁNDAR

La *desviación estándar* de un conjunto de N números $X_1, X_2, \ldots, X_N$ se denota como s y está definida por

$$s = \sqrt{\frac{\sum_{j=1}^{N} (X_j - \bar{X})^2}{N}} = \sqrt{\frac{\sum (X - \bar{X})^2}{N}} = \sqrt{\frac{\sum x^2}{N}} = \sqrt{\overline{(X - \bar{X})^2}} \tag{5}$$

donde x representa la desviación de cada uno de los números X_j respecto a la media $\bar{X}$. Por lo tanto, s es la raíz cuadrada de la media (RCM) de las desviaciones respecto de la media, o, como suele llamársele algunas veces, la *desviación raíz-media-cuadrado.*

Si $X_1, X_2, \ldots, X_N$ se presentan con frecuencias $f_1, f_2, \ldots, f_K$, respectivamente, la desviación estándar se puede expresar como

$$s = \sqrt{\frac{\sum_{j=1}^{K} f_j (X_j - \bar{X})^2}{N}} = \sqrt{\frac{\sum f(X - \bar{X})^2}{N}} = \sqrt{\frac{\sum fx^2}{N}} = \sqrt{\overline{(X - \bar{X})^2}} \tag{6}$$

donde $N = \sum_{j=1}^{K} f_j = \sum f$. Esta fórmula es útil para datos agrupados.

Algunas veces la desviación estándar de una muestra de datos se define usando como el denominador, en las ecuaciones (*5*) y (*6*), $(N - 1)$ en lugar de *N*. Esto se debe a que el valor que así se obtiene es una mejor aproximación a la desviación estándar de la población de la que se ha tomado la muestra. Con valores grandes de *N* ($N > 30$), prácticamente no hay diferencia entre las dos definiciones. Y cuando se necesita una estimación mejor, ésta siempre se puede obtener multiplicando por $\sqrt{N/(N-1)}$ la desviación estándar obtenida de acuerdo con la primera definición. Por lo tanto, en este libro se emplearán las fórmulas (*5*) y (*6*).

VARIANZA

La *varianza* de un conjunto de datos se define como el cuadrado de la desviación estándar y, por lo tanto, corresponde al valor s^2 en las ecuaciones (*5*) y (*6*).

Cuando es necesario distinguir la desviación estándar de una población de la desviación estándar de una muestra obtenida de esa población, se suele emplear *s* para la última y σ (letra griega *sigma* minúscula) para la primera. De manera que s^2 y σ^2 representan la *varianza muestral* y *la varianza poblacional*, respectivamente.

MÉTODO ABREVIADO PARA EL CÁLCULO DE LA DESVIACIÓN ESTÁNDAR

Las ecuaciones (*5*) y (*6*) se pueden expresar, respectivamente, mediante las fórmulas siguientes

$$s = \sqrt{\frac{\sum_{j=1}^{N} X_j^2}{N} - \left(\frac{\sum_{j=1}^{N} X_j}{N}\right)^2} = \sqrt{\frac{\sum X^2}{N} - \left(\frac{\sum X}{N}\right)^2} = \sqrt{\overline{X^2} - \bar{X}^2} \tag{7}$$

$$s = \sqrt{\frac{\sum_{j=1}^{K} f_j X_j^2}{N} - \left(\frac{\sum_{j=1}^{K} f_j X_j}{N}\right)^2} = \sqrt{\frac{\sum fX^2}{N} - \left(\frac{\sum fX}{N}\right)^2} = \sqrt{\overline{X^2} - \bar{X}^2} \tag{8}$$

donde $\overline{X^2}$ representa la media de los cuadrados de los diversos valores de *X*, en tanto que $\bar{X}^2$ denota el cuadrado de la media de los diversos valores de *X* (ver problemas 4.12 a 4.14).

Si las $d_j = X_j - A$ son las desviaciones de X_j respecto a una constante arbitraria *A*, las fórmulas (*7*) y (*8*) se transforman, respectivamente, en

$$s = \sqrt{\frac{\sum_{j=1}^{N} d_j^2}{N} - \left(\frac{\sum_{j=1}^{N} d_j}{N}\right)^2} = \sqrt{\frac{\sum d^2}{N} - \left(\frac{\sum d}{N}\right)^2} = \sqrt{\overline{d^2} - \bar{d}^2} \tag{9}$$

$$s = \sqrt{\frac{\sum_{j=1}^{K} f_j d_j^2}{N} - \left(\frac{\sum_{j=1}^{K} f_j d_j}{N}\right)^2} = \sqrt{\frac{\sum fd^2}{N} - \left(\frac{\sum fd}{N}\right)^2} = \sqrt{\overline{d^2} - \bar{d}^2} \tag{10}$$

(Ver los problemas 4.15 y 4.17.)

Cuando en una distribución de frecuencia se tienen datos agrupados y los intervalos de clase son de un mismo tamaño c, se tiene $d_j = cu_j$, o $X_j = A + cu_j$ y la fórmula (*10*) se trasforma en

$$s = c\sqrt{\frac{\sum_{j=1}^{K} f_j u_j^2}{N} - \left(\frac{\sum_{j=1}^{K} f_j u_j}{N}\right)^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = c\sqrt{\overline{u^2} - \bar{u}^2} \tag{11}$$

Esta última fórmula proporciona un método muy sencillo para el cálculo de la desviación estándar y se recomienda su uso para datos agrupados, siempre que los intervalos de clase sean de un mismo tamaño. A este método se le llama *método de compilación* y es exactamente análogo al empleado en el capítulo 3 para calcular la media aritmética de datos agrupados. (Ver problemas 4.16 a 4.19.)

PROPIEDADES DE LA DESVIACIÓN ESTÁNDAR

1. La desviación estándar se puede definir como

$$s = \sqrt{\frac{\sum_{j=1}^{N} (X_j - a)^2}{N}}$$

donde a es un promedio cualquiera además de la media aritmética. De todas las desviaciones estándar, la mínima es aquella en la que $a = \bar{X}$, debido a la propiedad 2 del capítulo 3. Esta propiedad es una razón importante para definir la desviación estándar como se definió antes. En el problema 4.27 se presenta una demostración de esta propiedad.

2. En las distribuciones normales (ver capítulo 7) se encuentra que (como se muestra en la figura 4.1):

   a) 68.27% de los casos está comprendido entre $\bar{X} - s$ y $\bar{X} + s$ (es decir, una desviación estándar a cada lado de la media).
   b) 95.45% de los casos está comprendido entre $\bar{X} - 2s$ y $\bar{X} + 2s$ (es decir, dos desviaciones estándar a cada lado de la media).
   c) 99.73% de los casos está comprendido entre $\bar{X} - 3s$ y $\bar{X} + 3s$ (es decir, tres desviaciones estándar a cada lado de la media).

   En distribuciones moderadamente sesgadas, estos porcentajes se satisfacen de manera aproximada (ver problema 4.24).

3. Supóngase que dos conjuntos que constan de N_1 y N_2 números (o dos distribuciones de frecuencia con frecuencias totales N_1 y N_2) tienen varianzas s_1^2 y s_2^2, respectivamente, y una *misma* media $\bar{X}$. Entonces, la *varianza combinada* o *conjunta* de los dos conjuntos (o de las dos distribuciones de frecuencia) está dada por

$$s^2 = \frac{N_1 s_1^2 + N_2 s_2^2}{N_1 + N_2} \tag{12}$$

   Obsérvese que ésta es una media aritmética ponderada de las dos varianzas. Esta fórmula puede generalizarse a tres o más conjuntos.

4. El teorema de Chebyshev establece que para $k > 1$, por lo menos $(1 - (1/k^2)) \times 100\%$ de la distribución de probabilidad de cualquier variable está a no más de k desviaciones estándar de la media. En particular, para $k = 2$, por lo menos $(1 - (1/2^2)) \times 100\%$ o bien 75% de los datos está en el intervalo $(\bar{x} - 2S, \bar{x} + 2S)$; para $k = 3$, por lo menos $(1 - (1/3^2)) \times 100\%$ u 89% de los datos está en el intervalo $(\bar{x} - 3S, \bar{x} + 3S)$, y para $k = 4$, por lo menos $(1 - (1/4^2)) \times 100\%$ o bien 93.75% de los datos está en el intervalo $(\bar{x} - 4S, \bar{x} + 4S)$.

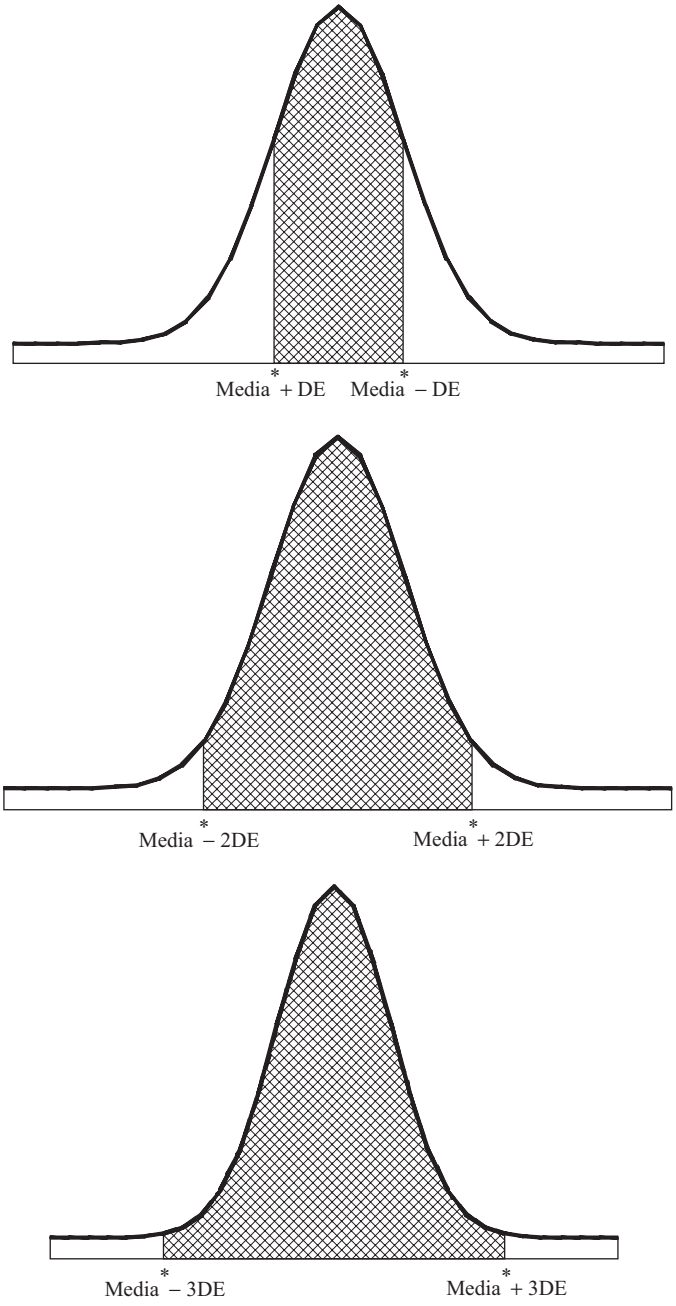


Figura 4-1 Ilustración de la regla empírica.

COMPROBACIÓN DE CHARLIER

La comprobación de Charlier, en el cálculo de la media y de la desviación estándar mediante el método de la compilación, hace uso de las identidades

$$\sum f(u+1) = \sum fu + \sum f = \sum fu + N$$

$$\sum f(u+1)^2 = \sum f(u^2+2u+1) = \sum fu^2 + 2\sum fu + \sum f = \sum fu^2 + 2\sum fu + N$$

(Ver el problema 4.20.)

CORRECCIÓN DE SHEPPARD PARA LA VARIANZA

El cálculo de la desviación estándar tiene cierto error debido a la agrupación de los datos en clases (error de agrupamiento). Para hacer un ajuste respecto al error de agrupamiento, se usa la fórmula

$$\text{Varianza corregida} = \text{Varianza de los datos agrupados} - \frac{c^2}{12} \tag{13}$$

donde c es el tamaño del intervalo de clase. A la corrección $c^2/12$ (que se resta) se le llama *corrección de Sheppard*. Esta corrección se usa para distribuciones de variables continuas, en las que las "colas", en ambas direcciones, se aproximan gradualmente a cero.

Hay discrepancia respecto a *cuándo* y *si* la corrección de Shepppard debe ser aplicada. Desde luego no debe aplicarse antes de que se examine la situación cuidadosamente, ya que se tiende a una *sobrecorrección*, con lo que sólo se sustituye un error por otro. En este libro, a menos que se indique otra cosa, no se usará la corrección de Sheppard.

RELACIONES EMPÍRICAS ENTRE LAS MEDIDAS DE DISPERSIÓN

Para las distribuciones moderadamente sesgadas, se tiene la relación empírica

$$\text{Desviación media} = \tfrac{4}{5}\,(\text{desviación estándar})$$

$$\text{Rango semiintercuartil} = \tfrac{2}{3}\,(\text{desviación estándar})$$

Esto es consecuencia de que en una distribución normal se encuentre que la desviación media y el rango semiintercuartil son iguales, respectivamente, a 0.7979 y 0.6745 veces la desviación estándar.

DISPERSIÓN ABSOLUTA Y RELATIVA; COEFICIENTE DE VARIACIÓN

La variación o dispersión real determinada mediante la desviación estándar u otra medida de dispersión se le conoce como *dispersión absoluta.* Sin embargo, una variación o dispersión de 10 pulgadas (in) en una distancia de 1 000 pies (ft) tiene un significado muy diferente a la misma variación de 10 in en una distancia de 20 ft. Este efecto se puede medir mediante la *dispersión relativa*, que se define como sigue:

$$\text{Dispersión relativa} = \frac{\text{dispersión absoluta}}{\text{promedio}} \tag{14}$$

Si la dispersión absoluta es la desviación estándar s y el promedio es la media $\bar{X}$, entonces a la dispersión relativa se le llama *coeficiente de variación* o *coeficiente de dispersión*; este coeficiente se denota por V y está dado por

$$\text{Coeficiente de variación } (V) = \frac{s}{\bar{X}} \tag{15}$$

y por lo general se expresa como porcentaje. También hay otras posibilidades (ver problema 4.30).

Obsérvese que el coeficiente de variación es independiente de las unidades que se empleen. Debido a esto, el coeficiente de variación es útil cuando se trata de comparar distribuciones en las que las unidades son diferentes. Una desventaja del coeficiente de variación es que no es útil cuando el valor de $\bar{X}$ es cercano a cero.

VARIABLE ESTANDARIZADA; PUNTUACIONES ESTÁNDAR

A la variable que mide la desviación respecto a la media en términos de unidades de desviaciones estándar se le llama *variable estandarizada* y es una cantidad adimensional (es decir, es independiente de las unidades empleadas) y está dada por

$$z = \frac{X - \bar{X}}{s} \tag{16}$$

Si las desviaciones respecto a la media se dan en términos de unidades de desviación estándar, se dice que las desviaciones se expresan en *unidades estándar* o en *puntuaciones estándar*. Las unidades estándar son de gran valor para comparar distribuciones (ver problema 4.31).

SOFTWARE Y MEDIDAS DE DISPERSIÓN

El software para estadística proporciona diversas medidas de dispersión. Estas medidas de dispersión suelen proporcionarse en estadística descriptiva. EXCEL permite el cálculo de todas las medidas estudiadas en este libro. Aquí se discuten MINITAB y EXCEL y en los problemas resueltos se muestran los resultados que proporcionan otros paquetes.

EJEMPLO 3

a) EXCEL proporciona cálculos para varias medidas de dipersión, y en el siguiente ejemplo se ilustran algunas de ellas. En una empresa se hace una encuesta; la pregunta es: ¿cuántos e-mails recibe una persona por semana? Las respuestas dadas por los 75 empleados se muestran en las celdas A1:E15 de la hoja de cálculo de EXCEL.

32	113	70	60	84
114	31	58	86	102
113	79	86	24	40
44	42	54	71	25
42	116	68	30	63
121	74	77	77	100
51	31	61	28	26
47	54	74	57	35
77	80	125	105	61
102	45	115	36	52
58	24	24	39	40
95	99	54	35	31
77	29	69	58	32
49	118	44	95	65
71	65	74	122	99

El rango se obtiene mediante =MAX(A1:E15)-MIN(A1:E15) o bien 125 − 24 = 101. La desviación media o desviación promedio se obtiene mediante = DESVPROM(A1:E15) o bien 24.42. El rango semiintercuartil se obtiene mediante la expresión =(PERCENTIL(A1:E15,0.75)-(PERCENTIL(A1:E15,0.25))/2 o bien 22. El rango percentil 10-90 se obtiene mediante PERCENTIL(A1:E15,0.9)-PERCENTIL(A1:E15,0.1) u 82.6.

La desviación estándar y la varianza se obtienen mediante =DESVEST(A1:E15), que es 29.2563 y =VAR(A1:E15), que es 855.932 para muestras, y =DESVESTP(A1:E15) que es 29.0606 y =VARP(A1:E15), que es 844.52 para poblaciones.

b)

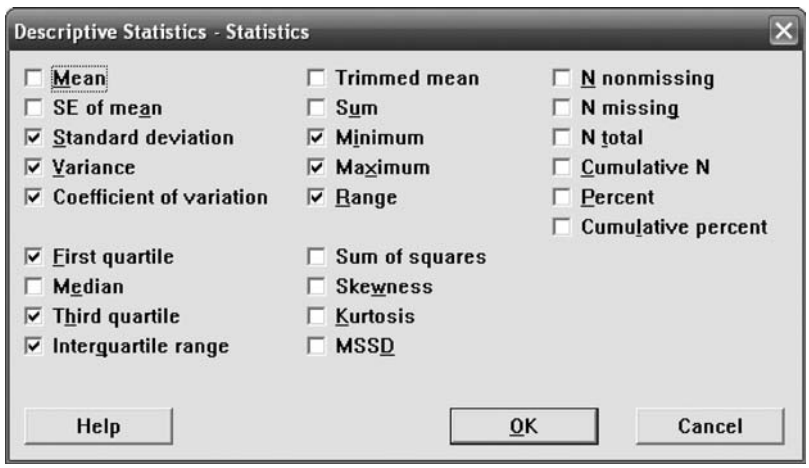


Figura 4-2 Ventana de diálogo de MINITAB.

En la ventana de diálogo de MINITAB, que se presenta en la figura 4-2, se han elegido las medidas de dispersión y de tendencia central. El resultado es el siguiente:

Estadística descriptiva: e-mails

Variable	StDev	Variance	CoefVar	Minimum	Q1	Q3	Maximum	Range	IQR
e-mails	29.26	855.93	44.56	24.00	40.00	86.00	125.00	101.00	46.00

PROBLEMAS RESUELTOS

EL RANGO

4.1 Encontrar el rango de los conjuntos: *a*) 12, 6, 7, 3, 15, 10, 18, 5 y *b*) 9, 3, 8, 8, 9, 8, 9, 18.

SOLUCIÓN

En ambos casos, rango = número mayor − número menor = 18 − 3 = 15. Sin embargo, como se puede ver en las ordenaciones de los conjuntos *a*) y *b*),

a) 3, 5, 6, 7, 10, 12, 15, 18 *b*) 3, 8, 8, 8, 9, 9, 9, 18

en el conjunto *a*) hay mucha más variación que en el conjunto *b*). En efecto, *b*) consta casi únicamente de ochos y nueves.

Dado que el rango no indica diferencia alguna entre estos conjuntos, en este caso no es una buena medida de dispersión. Cuando hay valores extremos, el rango no suele ser una buena medida de la dispersión.

Eliminando los valores extremos, 3 y 18, se logra una mejora. Entonces, el rango del conjunto *a*) es (15 − 5) = 10, en tanto que el rango del conjunto *b*) es (9 − 8) = 1, lo que muestra claramente que en *a*) hay mayor dispersión que en *b*). Sin embargo, el rango no ha sido definido de esta manera. El rango semiintercuartil y el rango percentil 10-90 están concebidos para obtener una medida mejor que el rango mediante la eliminación de los valores extremos.

4.2 Encontrar el rango de las estaturas de los estudiantes de la universidad XYZ dadas en la tabla 2.1.

SOLUCIÓN

Hay dos maneras para definir el rango de datos agrupados.

Primer método

$$\text{Rango} = \text{marca de clase de la clase más alta} - \text{marca de clase de la clase más baja}$$
$$= 73 - 61 = 12 \text{ in}$$

Segundo método

$$\text{Rango} = \text{frontera superior de la clase más alta} - \text{frontera inferior de la clase más baja}$$
$$= 74.5 - 59.5 = 15 \text{ in}$$

Empleando el primer método se tienden a eliminar, en cierta medida, los valores extremos.

LA DESVIACIÓN MEDIA

4.3 Encontrar la desviación media de los conjuntos de números del problema 4.1.

SOLUCIÓN

a) La media aritmética es

$$\bar{X} = \frac{12 + 6 + 7 + 3 + 15 + 10 + 18 + 5}{8} = \frac{76}{8} = 9.5$$

La desviación media es

$$\text{DM} = \frac{\sum |X - \bar{X}|}{N}$$
$$= \frac{|12 - 9.5| + |6 - 9.5| + |7 - 9.5| + |3 - 9.5| + |15 - 9.5| + |10 - 9.5| + |18 - 9.5| + |5 - 9.5|}{8}$$
$$= \frac{2.5 + 3.5 + 2.5 + 6.5 + 5.5 + 0.5 + 8.5 + 4.5}{8} = \frac{34}{8} = 4.25$$

b) $\bar{X} = \dfrac{9 + 3 + 8 + 8 + 9 + 8 + 9 + 18}{8} = \dfrac{72}{8} = 9$

$$\text{DM} = \frac{\sum |X - \bar{X}|}{N}$$
$$= \frac{|9 - 9| + |3 - 9| + |8 - 9| + |8 - 9| + |9 - 9| + |8 - 9| + |9 - 9| + |18 - 9|}{8}$$
$$= \frac{0 + 6 + 1 + 1 + 0 + 1 + 0 + 9}{8} = 2.25$$

La desviación media indica, como debe ser, que en el conjunto *b*) hay menos dispersión que en el conjunto *a*).

4.4 Encontrar la desviación media de las estaturas de 100 estudiantes de la universidad XYZ (ver tabla 3.2, problema 3.20).

SOLUCIÓN

De acuerdo con el problema 3.20, $\bar{X} = 67.45$ in. Para facilitar los cálculos, éstos pueden organizarse como en la tabla 4.1. También se puede idear un método de compilación para el cálculo de la desviación media (ver problema 4.47).

Tabla 4.1

Estaturas (in)	Marcas de clase (X)	$\lvert X - \bar{X}\rvert = \lvert X - 67.45\rvert$	Frecuencia (f)	$f\lvert X - \bar{X}\rvert$
60-62	61	6.45	5	32.25
63-65	64	3.45	18	62.10
66-68	67	0.45	42	18.90
69-71	70	2.55	27	68.85
72-74	73	5.55	8	44.40
			$N = \sum f = 100$	$\sum f\lvert X - \bar{X}\rvert = 226.50$

$$\text{DM} = \frac{\sum f|X - \bar{X}|}{N} = \frac{226.50}{100} = 2.26\,\text{in}$$

4.5 Determinar el porcentaje de las estaturas de los estudiantes del problema 4.4 que cae dentro de los rangos *a*) $\bar{X} \pm \text{DM}$, *b*) $\bar{X} \pm 2$ DM y *c*) $\bar{X} \pm 3$ DM.

SOLUCIÓN

a) El rango de 65.19 a 69.71 in es $\bar{X} \pm \text{DM} = 67.45 \pm 2.26$. Este rango comprende a todos los individuos de la tercera clase $+\frac{1}{3}(65.5 - 65.19)$ de los estudiantes de la segunda clase $+\frac{1}{3}(69.71 - 68.5)$ de los estudiantes de la cuarta clase (ya que el tamaño del intervalo de clase es 3 in, la frontera superior de clase de la segunda clase es 65.5 in y la frontera inferior de clase de la cuarta clase es 68.5 in). La cantidad de estudiantes en el rango $X \pm \text{DM}$ es

$$42 + \frac{0.31}{3}(18) + \frac{1.21}{3}(27) = 42 + 1.86 + 10.89 = 54.75 \qquad \text{o sea} \qquad 55$$

que es 55% del total.

b) El rango de 62.93 a 71.97 in es $\bar{X} \pm 2\,\text{DM} = 67.45 \pm 2(2.26) = 67.45 \pm 4.52$. El número de estudiantes en el rango $\bar{X} \pm 2$ DM es

$$18 - \left(\frac{62.93 - 62.5}{3}\right)(18) + 42 + 27 + \left(\frac{71.97 - 71.5}{3}\right)(8) = 85.67 \qquad \text{u} \qquad 86$$

que es 86% del total.

c) El rango de 60.67 a 74.23 in es $\bar{X} \pm 3\,\text{DM} = 67.45 \pm 3(2.26) = 67.45 \pm 6.78$. La cantidad de estudiantes en el rango $\bar{X} \pm 3$ DM es

$$5 - \left(\frac{60.67 - 59.5}{3}\right)(5) + 18 + 42 + 27 + \left(\frac{74.5 - 74.23}{3}\right)(8) = 97.33 \qquad \text{o sea} \qquad 97$$

que es 97% del total.

EL RANGO SEMIINTERCUARTIL

4.6 Encontrar el rango semiintercuartil en la distribución de las estaturas de los estudiantes de la universidad XYZ (ver tabla 4.1 del problema 4.4).

SOLUCIÓN

El cuartil inferior y el cuartil superior son $Q_1 = 65.5 + \frac{2}{42}(3) = 65.64$ in y $Q_3 = 68.5 + \frac{10}{27}(3) = 69.61$ in, respectivamente, y el rango semiintercuartil (o desviación cuartil) es $Q = \frac{1}{2}(Q_3 - Q_1) = \frac{1}{2}(69.61 - 65.64) = 1.98$ in. Obsérvese que el 50% de los casos se encuentra entre Q_1 y Q_3 (es decir, la estatura de 50 estudiantes está entre 65.64 y 69.61 in).

Se puede considerar que $\frac{1}{2}(Q_1 + Q_3) = 67.63$ in es una medida de tendencia central (es decir, una altura promedio). Por lo tanto, 50% de las estaturas se encuentra entre 67.63 ± 1.98 in.

4.7 Encontrar el rango semiintercuartil de los salarios de 65 empleados de la empresa P&R (ver la tabla 2.5 del problema 2.3).

SOLUCIÓN

De acuerdo con el problema 3.44, $Q_1 = \$268.25$ y $Q_3 = \$290.75$. Por lo tanto, el rango semiintercuartil es $Q = \frac{1}{2}(Q_3 - Q_1) = \frac{1}{2}(\$290.75 - \$268.25) = \$11.25$. Como $\frac{1}{2}(Q_1 + Q_3) = \$279.50$, se puede concluir que 50% de los empleados tienen salarios que se encuentran en el rango de $\$279.50 \pm \$11.25$.

EL RANGO PERCENTIL 10-90

4.8 Encontrar el rango percentil 10-90 de las estaturas de los estudiantes de la universidad XYZ (ver tabla 2.1).

SOLUCIÓN

Aquí, $P_{10} = 62.5 + \frac{5}{18}(3) = 63.33$ in y $P_{90} = 68.5 + \frac{25}{27}(3) = 71.27$ in. Por lo tanto, el rango percentil 10-90 es $P_{90} - P_{10} = 71.27 - 63.33 = 7.94$ in. Como $\frac{1}{2}(P_{10} + P_{90}) = 67.30$ in y $\frac{1}{2}(P_{90} - P_{10}) = 3.97$ in, se puede concluir que las estaturas de 80% de los estudiantes se encuentra en el rango de 67.30 ± 3.97 in.

LA DESVIACIÓN ESTÁNDAR

4.9 Encontrar la desviación estándar s de cada uno de los conjuntos de números del problema 4.1.

SOLUCIÓN

a)
$$\bar{X} = \frac{\sum X}{N} = \frac{12+6+7+3+15+10+18+5}{8} = \frac{76}{8} = 9.5$$

$$s = \sqrt{\frac{\sum (X-\bar{X})^2}{N}}$$

$$= \sqrt{\frac{(12-9.5)^2+(6-9.5)^2+(7-9.5)^2+(3-9.5)^2+(15-9.5)^2+(10-9.5)^2+(18-9.5)^2+(5-9.5)^2}{8}}$$

$$= \sqrt{23.75} = 4.87$$

b)
$$\bar{X} = \frac{9+3+8+8+9+8+9+18}{8} = \frac{72}{8} = 9$$

$$s = \sqrt{\frac{\sum (X-\bar{X})^2}{N}}$$

$$= \sqrt{\frac{(9-9)^2+(3-9)^2+(8-9)^2+(8-9)^2+(9-9)^2+(8-9)^2+(9-9)^2+(18-9)^2}{8}}$$

$$= \sqrt{15} = 3.87$$

Comparando los resultados anteriores con los del problema 4.3 se observa que la desviación estándar sí indica que el conjunto *b*) tiene menos dispersión que el conjunto *a*). Sin embargo, este efecto se enmascara por el hecho de que los valores extremos afectan a la desviación estándar mucho más que a la desviación media. Esto es de esperar, ya que para calcular la desviación estándar las desviaciones se elevan al cuadrado.

4.10 La desviación estándar de los dos conjuntos de datos dados en el problema 4.1 pueden encontrarse con MINITAB. Adelante se presentan los resultados. Comparlos con los obtenidos en el problema 4.9.

```
MTB > print cl
set1
      12     6     7     3     15     10     18      5
MTB > print c2
set2
       9     3     8     8      9      8      9     18
MTB > standard deviation cl
```

Columna de desviación estándar

```
   Standard deviation of set1 = 5.21
MTB > standard deviation c2
```

Columna de desviación estándar

```
   Standard deviation of set2 = 4.14
```

SOLUCIÓN

MINITAB emplea la fórmula

$$s = \sqrt{\frac{\sum (X - \bar{X})^2}{N - 1}}$$

y por lo tanto, en los problemas 4.9 y 4.10 no se obtiene la misma desviación estándar. Las respuestas del problema 4.10 se pueden obtener de las del problema 4.9 multiplicando éstas por $\sqrt{N/(N-1)}$. Como $N = 8$ para ambos conjuntos, $\sqrt{N/(N-1)} = 1.069045$. Entonces, para el conjunto 1 se tiene $(1.069045)(4.87) = 5.21$, que es la desviación estándar dada por MINITAB. De igual manera, $(1.069045)(3.87) = 4.14$, que es la desviación estándar dada por MINITAB para el problema 2.

4.11 Encuentre la desviación estándar de las estaturas de los 100 estudiantes de la universidad XYZ (ver tabla 2.1).

SOLUCIÓN

De acuerdo con los problemas 3.15, 3.20 o bien 3.22, $\bar{X} = 67.45$ in. Los cálculos pueden organizarse como en la tabla 4.2.

$$s = \sqrt{\frac{\sum f(X - \bar{X})^2}{N}} = \sqrt{\frac{852.7500}{100}} = \sqrt{8.5275} = 2.92 \text{ in}$$

Tabla 4.2

Estaturas (in)	Marcas de clase (X)	$X - \bar{X} = X - 67.45$	$(X - \bar{X})^2$	Frecuencias (f)	$f(X - \bar{X})^2$
60-62	61	−6.45	41.6025	5	208.0125
63-65	64	−3.45	11.9025	18	214.2450
66-68	67	−0.45	0.2025	42	8.5050
69-71	70	2.55	6.5025	27	175.5675
72-74	73	5.55	30.8025	8	246.4200
				$N = \sum f = 100$	$\sum f(X - \bar{X})^2 = 852.7500$

CÁLCULO DE LAS DESVIACIONES ESTÁNDAR DE DATOS AGRUPADOS

4.12 *a*) Demostrar que

$$s = \sqrt{\frac{\sum X^2}{N} - \left(\frac{\sum X}{N}\right)^2} = \sqrt{\overline{X^2} - \bar{X}^2}$$

b) Usar la fórmula del inciso *a*) para hallar la desviación estándar del conjunto 12, 6, 7, 3, 15, 10, 18, 5.

SOLUCIÓN

a) Por definición

$$s = \sqrt{\frac{\sum (X - \bar{X})^2}{N}}$$

Entonces
$$s^2 = \frac{\sum (X - \bar{X})^2}{N} = \frac{\sum (X^2 - 2\bar{X}X + \bar{X}^2)}{N} = \frac{\sum X^2 - 2\bar{X}\sum X + N\bar{X}^2}{N}$$
$$= \frac{\sum X^2}{N} - 2\bar{X}\,\frac{\sum X}{N} + \bar{X}^2 = \frac{\sum X^2}{N} - 2\bar{X}^2 + \bar{X}^2 = \frac{\sum X^2}{N} - \bar{X}^2$$
$$= \overline{X^2} - \bar{X}^2 = \frac{\sum X^2}{N} - \left(\frac{\sum X}{N}\right)^2$$

o bien
$$s = \sqrt{\frac{\sum X^2}{N} - \left(\frac{\sum X}{N}\right)^2} = \sqrt{\overline{X^2} - \bar{X}^2}$$

Obsérvese que en las sumatorias anteriores se ha usado la forma abreviada, empleando X en lugar de X_j y $\sum$ en lugar de $\sum_{j=1}^{N}$.

Otro método

$$s^2 = \overline{(X - \bar{X})^2} = \overline{X^2 - 2X\bar{X} + \bar{X}^2} = \overline{X^2} - \overline{2X\bar{X}} + \overline{\bar{X}^2} = \overline{X^2} - 2\bar{X}\bar{X} + \bar{X}^2 = \overline{X^2} - \bar{X}^2$$

b)
$$\overline{X^2} = \frac{\sum X^2}{N} = \frac{(12)^2 + (6)^2 + (7)^2 + (3)^2 + (15)^2 + (10)^2 + (18)^2 + (5)^2}{8} = \frac{912}{8} = 114$$
$$\bar{X} = \frac{\sum X}{N} = \frac{12 + 6 + 7 + 3 + 15 + 10 + 18 + 5}{8} = \frac{76}{8} = 9.5$$

Por lo tanto
$$s = \sqrt{\overline{X^2} - \bar{X}^2} = \sqrt{114 - 90.25} = \sqrt{23.75} = 4.87$$

Compárese este método con el del problema 4.9*a*).

4.13 Modificar la fórmula del problema 4.12*a*) para introducir las frecuencias que corresponden a los diversos valores de X.

SOLUCIÓN

La modificación apropiada es

$$s = \sqrt{\frac{\sum fX^2}{N} - \left(\frac{\sum fX}{N}\right)^2} = \sqrt{\overline{X^2} - \bar{X}^2}$$

Como en el problema 4.12*a*), a esta fórmula se puede llegar partiendo de

$$s = \sqrt{\frac{\sum f(X - \bar{X})^2}{N}}$$

Entonces
$$s^2 = \frac{\sum f(X-\bar{X})^2}{N} = \frac{\sum f(X^2 - 2\bar{X}X + \bar{X}^2)}{N} = \frac{\sum fX^2 - 2\bar{X}\sum fX + \bar{X}^2 \sum f}{N}$$
$$= \frac{\sum fX^2}{N} - 2\bar{X}\,\frac{\sum fX}{N} + \bar{X}^2 = \frac{\sum fX^2}{N} - 2\bar{X}^2 + \bar{X}^2 = \frac{\sum fX^2}{N} - \bar{X}^2$$
$$= \frac{\sum fX^2}{N} - \left(\frac{\sum fX}{N}\right)^2$$

o bien
$$s = \sqrt{\frac{\sum fX^2}{N} - \left(\frac{\sum fX}{N}\right)^2}$$

Obsérvese que la sumatoria anterior se ha usado en forma abreviada, empleando X y f en lugar de X_j y f_j, $\sum$ en lugar de $\sum_{j=1}^{K}$ y $\sum_{j=1}^{K} f_j = N$.

4.14 Empleando la fórmula del problema 4.13, encontrar la desviación estándar de los datos de la tabla 4.2, problema 4.11.

SOLUCIÓN

Los cálculos pueden organizarse como en la tabla 4.3, donde $\bar{X} = (\sum fX)/N = 67.45$ in, según se obtuvo en el problema 3.15. Observar que este método, como el del problema 4.11, conlleva cálculos muy tediosos. En el problema 4.17 se muestra cómo con el método de compilación se simplifican los cálculos enormemente.

Tabla 4.3

Estaturas (in)	Marcas de clase (X)	X^2	Frecuencias (f)	fX^2
60-62	61	3 721	5	18 605
63-65	64	4 096	18	73 728
66-68	67	4 489	42	188 538
69-71	70	4 900	27	132 300
72-74	73	5 329	8	42 632
			$N = \sum f = 100$	$\sum fX^2 = 455\,803$

$$s = \sqrt{\frac{\sum fX^2}{N} - \left(\frac{\sum fX}{N}\right)^2} = \sqrt{\frac{455\,803}{100} - (67.45)^2} = \sqrt{8.5275} = 2.92\,\text{in}$$

4.15 Si $d = X - A$ son las desviaciones de X respecto a una constante arbitraria A, probar que
$$s = \sqrt{\frac{\sum fd^2}{N} - \left(\frac{\sum fd}{N}\right)^2}$$

SOLUCIÓN

Como $d = X - A$, $X = A + d$ y $\bar{X} = A + \bar{d}$ (ver problema 3.18), entonces
$$X - \bar{X} = (A + d) - (A + \bar{d}) = d - \bar{d}$$

de manera que
$$s = \sqrt{\frac{\sum f(X-\bar{X})^2}{N}} = \sqrt{\frac{\sum f(d-\bar{d})^2}{N}} = \sqrt{\frac{\sum fd^2}{N} - \left(\frac{\sum fd}{N}\right)^2}$$

de acuerdo con los resultados del problema 4.13 y sustituyendo X y $\bar{X}$ en lugar de d y $\bar{d}$, respectivamente.

Otro método

$$s^2 = \overline{(X - \bar{X})^2} = \overline{(d - \bar{d})^2} = \overline{d^2 - 2\bar{d}d + \bar{d}^2}$$
$$= \overline{d^2} - 2\bar{d}^2 + \bar{d}^2 = \overline{d^2} - \bar{d}^2 = \frac{\sum fd^2}{N} - \left(\frac{\sum fd}{N}\right)^2$$

y la fórmula deseada se obtiene sacando la raíz cuadrada positiva.

4.16 Mostrar que si en una distribución de frecuencia en la que todos los intervalos de clase son del mismo tamaño c, se compila cada marca de clase X con su valor correspondiente u de acuerdo con la relación $X = A + cu$, donde A es una marca de clase dada, entonces la desviación estándar se puede expresar como

$$s = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = c\sqrt{\overline{u^2} - \bar{u}^2}$$

SOLUCIÓN

Esto se deduce inmediatamente del problema 4.15, ya que $d = X - A = cu$. Por lo tanto, como c es una constante,

$$s = \sqrt{\frac{\sum f(cu)^2}{N} - \left(\frac{\sum f(cu)}{N}\right)^2} = \sqrt{c^2\frac{\sum fu^2}{N} - c^2\left(\frac{\sum fu}{N}\right)^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2}$$

Otro método

Esta fórmula se puede probar también directamente sin usar el problema 4.15. Dado que $X = A + cu$, $\bar{X} = A + c\bar{u}$ y $X - \bar{X} = c(u - \bar{u})$, entonces

$$s^2 = \overline{(X - \bar{X})^2} = \overline{c^2(u - \bar{u})^2} = c^2\overline{(u^2 - 2\bar{u}u + \bar{u}^2)} = c^2(\overline{u^2} - 2\bar{u}^2 + \bar{u}^2) = c^2(\overline{u^2} - \bar{u}^2)$$

y

$$s = c\sqrt{\overline{u^2} - \bar{u}^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2}$$

4.17 Encontrar la desviación estándar de las estaturas de los estudiantes de la universidad XYZ (ver la tabla 2.1) empleando: *a*) la fórmula obtenida en el problema 4.15 y *b*) el método de codificación del problema 4.16.

SOLUCIÓN

En las tablas 4.4 y 4.5 arbitrariamente se ha elegido A igual a la marca de clase 67. Obsérvese que en la tabla 4.4 las desviaciones $d = X - A$ son múltiplos del tamaño del intervalo de clase $c = 3$. En la tabla 4.5 se ha eliminado este factor. Esto da como resultado que en la tabla 4.5 los cálculos se simplifican enormemente (en comparación con los de los problemas 4.11 y 4.14). Por esto se recomienda emplear el método de compilación siempre que sea posible.

a) Ver la tabla 4.4.

Tabla 4.4

Marcas de clase (X)	$d = X - A$	Frecuencias (f)	fd	fd^2
61	−6	5	−30	180
64	−3	18	−54	162
$A \rightarrow 67$	0	42	0	0
70	3	27	81	243
73	6	8	48	288
		$N = \sum f = 100$	$\sum fd = 45$	$\sum fX^2 = 873$

$$s = \sqrt{\frac{\sum fd^2}{N} - \left(\frac{\sum fd}{N}\right)^2} = \sqrt{\frac{873}{100} - \left(\frac{45}{100}\right)^2} = \sqrt{8.5275} = 2.92\,\text{in}$$

b) Ver la tabla 4.5

Tabla 4.5

Marcas de clase (X)	$u = \dfrac{X - A}{c}$	Frecuencias (f)	fu	fu^2
61	−2	5	−10	20
64	−2	18	−18	18
$A \rightarrow 67$	0	42	0	0
70	1	27	27	27
73	2	8	18	32
		$N = \sum f = 100$	$\sum fu = 15$	$\sum fu^2 = 97$

$$s = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = 3\sqrt{\frac{97}{100} - \left(\frac{15}{100}\right)^2} = 3\sqrt{0.9475} = 2.92\,\text{in}$$

4.18 Empleando el método de compilación, encontrar: *a*) la media y *b*) la desviación estándar de la distribución de los salarios de los 65 empleados de la empresa P&R (ver la tabla 2.5 del problema 2.3).

SOLUCIÓN

Los cálculos se pueden organizar como en la tabla 4.6.

a) $$\bar{X} = A + c\bar{u} = A + c\,\frac{\sum fu}{N} = \$275.00 + (\$10.00)\left(\frac{31}{65}\right) = \$279.77$$

b) $$s = c\sqrt{\bar{u^2} - \bar{u}^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = (\$10.00)\sqrt{\frac{173}{65} - \left(\frac{31}{65}\right)^2} = (\$10.00)\sqrt{2.4341} = \$15.60$$

Tabla 4.6

	X	u	f	fu	fu^2
	\$255.00	−2	8	−16	32
	265.00	−1	10	−10	10
$A \longrightarrow$	275.00	0	16	0	0
	285.00	1	14	14	14
	295.00	2	10	20	40
	305.00	3	5	15	45
	315.00	4	2	8	32
			$N = \sum f = 65$	$\sum fu = 31$	$\sum fu^2 = 173$

4.19 La tabla 4.7 muestra el CI de 480 niños de primaria. Empleando el método de compilación, encontrar: *a*) la media y *b*) la desviación estándar.

Tabla 4.7

Marca des clase (X)	70	74	78	82	86	90	94	98	102	106	110	114	118	122	126
Frecuencias (f)	4	9	16	28	45	66	85	72	54	38	27	18	11	5	2

SOLUCIÓN

El cociente intelectual es

$$\text{CI} = \frac{\text{edad mental}}{\text{edad cronológica}}$$

expresado como porcentaje. Por ejemplo, un niño de 8 años que (de acuerdo con ciertos procedimientos educativos) tiene una mentalidad de un niño de 10 años, tendrá un CI de $10/8 = 1.25 = 125\%$, o simplemente 125, el signo % se sobreentiende.

Para hallar la media y la desviación estándar de los cocientes intelectuales de la tabla 4.7, se pueden organizar los cálculos como en la tabla 4.8.

a) $$\bar{X} = A + c\bar{u} = A + c\,\frac{\sum fu}{N} = 94 + 4\left(\frac{236}{480}\right) = 95.97$$

b) $$s = c\sqrt{\bar{u^2} - \bar{u}^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = 4\sqrt{\frac{3\,404}{480} - \left(\frac{236}{480}\right)^2} = 4\sqrt{6.8499} = 10.47$$

COMPROBACIÓN DE CHARLIER

4.20 Emplear la comprobación de Charlier para verificar los cálculos de: *a*) la media y *b*) la desviación estándar realizados en el problema 4.19.

SOLUCIÓN

Para hacer la comprobación deseada, a las columnas de la tabla 4.8 se agregan las columnas de la tabla 4.9 (con excepción de la columna 2, que por comodidad se repite en la tabla 4.9).

a) De acuerdo con la tabla 4.9, $\sum f(u+1) = 716$; de acuerdo con la tabla 4.8, $\sum fu + N = 236 + 480 = 716$. Con esto se tiene la comprobación de la media.

Tabla 4.8

X	u	f	fu	fu^2
70	−6	4	−24	144
74	−5	9	−45	225
78	−4	16	−64	256
82	−3	28	−84	252
86	−2	45	−90	180
90	−1	66	−66	66
$A \longrightarrow$ 94	0	85	0	0
98	1	72	72	72
102	2	54	108	216
106	3	38	114	342
110	4	27	108	432
114	5	18	90	450
118	6	11	66	396
122	7	5	35	245
126	8	2	16	128
		$N = \sum f = 480$	$\sum fu = 236$	$\sum fu^2 = 3\,404$

Tabla 4.9

$u+1$	f	$f(u+1)$	$f(u+1)^2$
−5	4	−20	100
−4	9	−36	144
−3	16	−48	144
−2	28	−56	112
−1	45	−45	45
0	66	0	0
1	85	85	85
2	72	144	288
3	54	162	486
4	38	152	608
5	27	135	675
6	18	108	648
7	11	77	539
8	5	40	320
9	2	18	162
	$N = \sum f = 480$	$\sum f(u+1) = 716$	$\sum f(u+1)^2 = 4\,356$

b) De acuerdo con la tabla 4.9, $\sum f(u+1)^2 = 4\,356$; de acuerdo con la tabla 4.8, $\sum f^2 + 2\sum fu + N = 3\,404 + 2(236) + 480 = 4\,356$, con lo que se tiene la comprobación de la desviación estándar.

CORRECCIÓN DE SHEPPARD PARA LA VARIANZA

4.21 Emplee la corrección de Sheppard para determinar la desviación estándar de los datos en: *a*) el problema 4.17, *b*) el problema 4.18 y *c*) el problema 4.19.

SOLUCIÓN

a) $s^2 = 8.5275$ y $c = 3$. Varianza corregida $= s^2 - c^2/12 = 8.5275 - 3^2/12 = 7.7775$. Desviación estándar corregida $= \sqrt{\text{varianza corregida}} = \sqrt{7.7775} = 2.79$ in.

b) $s^2 = 243.41$ y $c = 10$. Varianza corregida $= s^2 - c^2/12 = 243.41 - 10^2/12 = 235.08$. Desviación estándar corregida $= \sqrt{235.08} = \$15.33$.

c) $s^2 = 109.60$ y $c = 4$. Varianza corregida $= s^2 - c^2/12 = 109.60 - 4^2/12 = 108.27$. Desviación estándar corregida $= \sqrt{108.27} = 10.41$.

4.22 Dada la segunda distribución de frecuencia del problema 2.8, encontrar: *a*) la media, *b*) la desviación estándar, *c*) la desviación estándar usando la corrección de Sheppard y *d*) la verdadera desviación estándar a partir de los datos no agrupados.

SOLUCIÓN

Los cálculos se pueden organizar como en la tabla 4.10.

a) $$\bar{X} = A + c\bar{u} = A + c\,\frac{\sum fu}{N} = 149 + 9\left(\frac{-9}{40}\right) = 147.0\,\text{lb}$$

b) $$s = c\sqrt{\overline{u^2} - \bar{u}^2} = c\sqrt{\frac{\sum fu^2}{N} - \left(\frac{\sum fu}{N}\right)^2} = 9\sqrt{\frac{95}{40} - \left(\frac{-9}{40}\right)^2} = 9\sqrt{2.324375} = 13.7\,\text{lb}$$

c) Varianza corregida $= s^2 - c^2/12 = 188.27 - 9^2/12 = 181.52$. Desviación estándar corregida $= 13.5$ lb.

Tabla 4.10

	X	u	f	fu	fu^2
	122	−3	3	−9	27
	131	−2	5	−10	20
	140	−1	9	−9	9
$A \longrightarrow$	149	0	12	0	0
	158	1	5	5	5
	167	2	4	8	16
	176	3	2	6	18
			$N = \sum f = 40$	$\sum fu = -9$	$\sum fu^2 = 95$

d) Para calcular la desviación estándar a partir de los verdaderos pesos de los estudiantes, dados en el problema, conviene primero restarle a cada peso un número adecuado, por ejemplo, $A = 150$ lb, y después usar el método del problema 4.15. Las desviaciones $d = X - A = X - 150$ se dan en la tabla siguiente:

−12	14	0	−18	−6	−25	−1	7
−4	8	−10	−3	−14	−2	2	−6
18	−24	−12	26	13	−31	4	15
−4	23	−8	−3	−15	3	−10	−15
11	−5	−15	−8	0	6	−5	−22

a partir de las cuales se encuentra que $\sum d = -128$ y $\sum d^2 = 7\,052$. Entonces

$$s = \sqrt{\overline{d^2} - \bar{d}^2} = \sqrt{\frac{\sum d^2}{N} - \left(\frac{\sum d}{N}\right)^2} = \sqrt{\frac{7\,052}{40} - \left(\frac{-128}{40}\right)^2} = \sqrt{166.06} = 12.9\,\text{lb}$$

Por lo tanto, con la corrección de Sheppard, en este caso, se obtiene cierta mejora.

RELACIONES EMPÍRICAS ENTRE LAS MEDIDAS DE DISPERSIÓN

4.23 Dada la distribución de las estaturas de los estudiantes de la universidad XYZ, comentar la validez de las fórmulas empíricas: *a*) desviación media $= \frac{4}{5}$(desviación estándar) y *b*) rango semiintercuartil $= \frac{2}{3}$(desviación estándar).

SOLUCIÓN

a) De acuerdo con los problemas 4.4 y 4.11, desviación media ÷ desviación estándar $= 2.26/2.92 = 0.77$, que es aproximadamente $\frac{4}{5}$.

b) De acuerdo con los problemas 4.6 y 4.11, rango semiintercuartil ÷ desviación estándar $= 1.98/2.92 = 0.68$, que es aproximadamente $\frac{2}{3}$.

Por lo tanto, en este caso las fórmulas empíricas son válidas.

Obsérvese que no se usó la desviación estándar con corrección de Sheppard para agrupamiento, ya que no se hicieron las correcciones correspondientes a la desviación media ni al rango semiintercuartílico.

PROPIEDADES DE LA DESVIACIÓN ESTÁNDAR

4.24 En el problema 4.19 determinar el porcentaje de estudiantes cuyo CI cae dentro de los rangos: *a*) $\bar{X} \pm s$, *b*) $\bar{X} \pm 2s$ y *c*) $\bar{X} \pm 3s$.

SOLUCIÓN

a) El rango para los CI de 85.5 a 106.4 es $\bar{X} \pm s = 95.97 \pm 10.47$. La cantidad de CI en el rango $\bar{X} \pm s$ es

$$\left(\frac{88 - 85.5}{4}\right)(45) + 66 + 85 + 72 + 54 + \left(\frac{106.4 - 104}{4}\right)(38) = 339$$

El porcentaje de CI en el rango $\bar{X} \pm s$ es $339/480 = 70.6\%$.

b) El rango de los CI de 75.0 a 116.9 es $\bar{X} \pm 2s = 95.97 \pm 2(10.47)$. La cantidad de CI en el rango $\bar{X} \pm 2s$ es

$$\left(\frac{76 - 75.0}{4}\right)(9) + 16 + 28 + 45 + 66 + 85 + 72 + 54 + 38 + 27 + 18 + \left(\frac{116.9 - 116}{4}\right)(11) = 451$$

El porcentaje de CI en el rango $\bar{X} \pm 2s$ es $451/480 = 94.0\%$.

c) El rango de los CI de 64.6 a 127.4 es $\bar{X} \pm 3s = 95.97 \pm 3(10.47)$. La cantidad de CI en el rango $\bar{X} \pm 3s$ es

$$480 - \left(\frac{128 - 127.4}{4}\right)(2) = 479.7 \qquad \text{o} \qquad 480$$

El porcentaje de CI en el rango $\bar{X} \pm 3s$ es $479.7/480 = 100\%$.

Los porcentajes de los incisos *a*), *b*) y *c*) coinciden con los esperados en una distribución normal: 68.27%, 95.45% y 99.73%, respectivamente.

Obsérvese que no se ha usado la corrección de Sheppard para la desviación estándar. Si se usa esta corrección, los resultados, en este caso, coinciden estrechamente con los anteriores. Obsérvese que los resultados anteriores también pueden obtenerse usando la tabla 4.11 del problema 4.32.

4.25 Dados los conjuntos 2, 5, 8, 11, 14 y 2, 8, 14, encontrar: *a*) la media de cada conjunto, *b*) la varianza de cada conjunto, *c*) la media de los conjuntos combinados (o conjuntados) y *d*) la varianza de los conjuntos combinados.

SOLUCIÓN

a) Media del primer conjunto $= \frac{1}{5}(2 + 5 + 8 + 11 + 14) = 8$. Media del segundo conjunto $= \frac{1}{3}(2 + 8 + 14) = 8$.

b) Varianza del primer conjunto $= s_1^2 = \frac{1}{5}[(2 - 8)^2 + (5 - 8)^2 + (8 - 8)^2 + (11 - 8)^2 + (14 - 8)^2] = 18$. Varianza del segundo conjunto $= s_2^2 = \frac{1}{3}[(2 - 8)^2 + (8 - 8)^2 + (14 - 8)^2] = 24$.

c) La media de los conjuntos combinados es

$$\frac{2 + 5 + 8 + 11 + 14 + 2 + 8 + 14}{5 + 3} = 8$$

d) La varianza de los conjuntos combinados es

$$s^2 = \frac{(2 - 8)^2 + (5 - 8)^2 + (8 - 8)^2 + (11 - 8)^2 + (14 - 8)^2 + (2 - 8)^2 + (8 - 8)^2 + (14 - 8)^2}{5 + 3} = 20.25$$

Otro método (mediante fórmula)

$$s^2 = \frac{N_1 s_1^2 + N_2 s_2^2}{N_1 + N_2} = \frac{(5)(18) + (3)(24)}{5 + 3} = 20.25$$

4.26 Resolver el problema 4.25 con los conjuntos 2, 5, 8, 11, 14 y 10, 16, 22.

SOLUCIÓN

Aquí las medias de los dos conjuntos son 8 y 16, respectivamente, en tanto que las varianzas son las *mismas* que las varianzas en el problema anterior, a saber: $s_1^2 = 18$ y $s_2^2 = 24$.

$$\text{Media de los conjuntos combinados} = \frac{2+5+8+11+14+10+16+22}{5+3} = 11$$

$$s^2 = \frac{(2-11)^2 + (5-11)^2 + (8-11)^2 + (11-11)^2 + (14-11)^2 + (10-11)^2 + (16-11)^2 + (22-11)^2}{5+3}$$

$$= 35.25$$

Obsérvese que la fórmula

$$s^2 = \frac{N_1 s_1^2 + N_2 s_2^2}{N_1 + N_2}$$

con la que se obtiene el valor 20.25, *no* es aplicable en este caso, ya que las medias de los dos conjuntos *no* son iguales.

4.27 *a*) Probar que $w^2 + pw + q$, donde p y q son constantes dadas, es mínimo si y sólo si $w = -\frac{1}{2}p$.

b) Empleando el inciso *a*), probar que

$$\frac{\sum_{j=1}^{N} (X_j - a)^2}{N} \qquad \text{o brevemente} \qquad \frac{\sum (X-a)^2}{N}$$

es mínimo si y sólo si $a = \bar{X}$.

SOLUCIÓN

a) Se tiene $w^2 + pw + q = (w + \frac{1}{2}p)^2 + q - \frac{1}{4}p^2$. Como $(q - \frac{1}{4}p^2)$ es constante, esta expresión tiene su mínimo valor si y sólo si $w + \frac{1}{2}p = 0$ (es decir, $w = -\frac{1}{2}p$).

b) $$\frac{\sum (X-a)^2}{N} = \frac{\sum (X^2 - 2aX + a^2)}{N} = \frac{\sum X^2 - 2a\sum X + Na^2}{N} = a^2 - 2a\frac{\sum X}{N} + \frac{\sum X^2}{N}$$

Comparando esta última expresión con $(w^2 + pw + q)$, se tiene

$$w = a \qquad p = -2\frac{\sum X}{N} \qquad q = \frac{\sum X^2}{N}$$

Por lo tanto, la expresión tiene un mínimo en $a = -\frac{1}{2}p = (\sum X)/N = \bar{X}$, empleando el resultado del inciso *a*).

DISPERSIÓN ABSOLUTA Y RELATIVA; COEFICIENTE DE VARIACIÓN

4.28 Un fabricante de cinescopios produce dos tipos de cinescopios, *A* y *B*. La vida media de los cinescopios es, respectivamente, $\bar{X}_A = 1\,495$ horas y $\bar{X}_B = 1\,875$ horas, y las desviaciones estándar son $s_A = 280$ horas y $s_B = 310$ horas. ¿Cuál de los cinescopios tiene: *a*) la mayor dispersión absoluta y *b*) la mayor dispersión relativa?

SOLUCIÓN

a) La dispersión absoluta de A es $s_A = 280$ horas y la de B es $s_B = 310$ horas. Por lo tanto, en los cinescopios B hay mayor dispersión absoluta.

b) Los coeficientes de variación son

$$A = \frac{s_A}{\bar{X}_A} = \frac{280}{1\,495} = 18.7\% \qquad B = \frac{s_B}{\bar{X}_B} = \frac{310}{1\,875} = 16.5\%$$

Por lo tanto, los cinescopios A tienen mayor variación relativa o dispersión.

4.29 Encontrar el coeficiente de variación, V, de los datos: *a*) del problema 4.14 y *b*) del problema 4.18, empleando la desviación estándar corregida y la desviación estándar no corregida.

SOLUCIÓN

a)
$$V(\text{no corregida}) = \frac{s(\text{no corregida})}{\bar{X}} = \frac{2.92}{67.45} = 0.0433 = 4.3\%$$

$$V(\text{corregida}) = \frac{s(\text{corregida})}{\bar{X}} = \frac{2.79}{67.45} = 0.0413 = 4.1\% \qquad \text{de acuerdo con el problema 4.21}a)$$

b)
$$V(\text{no corregida}) = \frac{s(\text{no corregida})}{\bar{X}} = \frac{15.60}{79.77} = 0.196 = 19.6\%$$

$$V(\text{corregida}) = \frac{s(\text{corregida})}{\bar{X}} = \frac{15.33}{79.77} = 0.192 = 19.2\% \qquad \text{de acuerdo con el problema 4.21}b)$$

4.30 *a*) Definir una medida de dispersión relativa que pueda emplearse para un conjunto de datos en el que se conocen los cuartiles.

b) Ilustrar el cálculo de la medida definida en el inciso *a*) aplicándolo a los datos del problema 4.6.

SOLUCIÓN

a) Si para un conjunto de datos, se dan los cuartiles Q_1 y Q_3, entonces $\frac{1}{2}(Q_1 + Q_3)$ es una medida de tendencia central de los datos o promedio, en tanto que $Q = \frac{1}{2}(Q_3 - Q_1)$, el rango semiintercuartil, es una medida de dispersión de los datos. De manera que una medida de dispersión relativa se puede definir de la siguiente manera.

$$V_Q = \frac{\frac{1}{2}(Q_3 - Q_1)}{\frac{1}{2}(Q_1 + Q_3)} = \frac{Q_3 - Q_1}{Q_3 + Q_1}$$

a la que se le llama *coeficiente de variación cuartil* o *coeficiente cuartil de dispersión relativa.*

b)
$$V_Q = \frac{Q_3 - Q_1}{Q_3 + Q_1} = \frac{69.61 - 65.64}{69.61 + 65.64} = \frac{3.97}{135.25} = 0.0293 = 2.9\%$$

VARIABLES ESTANDARIZADAS; PUNTUACIONES ESTÁNDAR

4.31 En el examen final de matemáticas en el que la media es 76 y la desviación estándar es 10, un alumno obtiene una calificación de 84. En el examen final de física, en el que la media es 82 y la desviación estándar es 16, el mismo alumno obtiene como puntuación 90. ¿En qué materia tiene una posición relativa más alta?

SOLUCIÓN

La variable estandarizada $z = (X - \bar{X})/s$ mide la desviación de X respecto a la media $\bar{X}$ en término de desviaciones estándar s. En matemáticas, $z = (84 - 76)/10 = 0.8$, y en física $z = (90 - 82)/16 = 0.5$. Por lo tanto, la calificación de este estudiante en matemáticas se encuentra a 0.8 de una desviación estándar sobre la media, en cambio la puntuación en física se encuentra a sólo 0.5 de una desviación estándar sobre la media. Por lo tanto, en matemáticas obtuvo una posición relativa más alta.

La variable $z = (X - \bar{X})/s$ suele emplearse para las calificaciones de los exámenes de conocimientos, en donde se denomina *calificación estándar.*

SOFTWARE Y MEDIDAS DE DISPERSIÓN

4.32 El análisis hecho con STATISTIX de los datos del ejemplo 3 de este capítulo da los resultados siguientes:

```
Statistix 8.0
Descriptive Statistics

Variable          SD      Variance        C.V.         MAD
e - mails     29.256        855.93      44.562     21.000
```

El valor MAD es la *desviación mediana absoluta.* Se trata del valor mediano de las diferencias absolutas entre cada uno de los valores y la mediana muestral. Verificar que el valor MAD de estos datos es 21.

SOLUCIÓN

Los datos ordenados de menor a mayor son:

24	24	24	25	26	28	29	30	31	31	31	32	32
35	35	36	39	40	40	42	42	44	44	45	47	49
51	52	54	54	54	57	58	58	58	60	61	61	63
65	65	68	69	70	71	71	74	74	74	77	77	77
77	79	80	84	86	86	95	95	99	99	100	102	102
105	113	113	114	115	116	118	121	122	125			

La mediana de los datos originales es 61.
Si a cada dato se le resta 61, se obtiene:

−37	−37	−37	−36	−35	−33	−32	−31	−30	−30	−30	−29	−29
−26	−26	−25	−22	−21	−21	−19	−19	−17	−17	−16	−14	−12
−10	−9	−7	−7	−7	−4	−3	−3	−3	−1	0	0	2
4	4	7	8	9	10	10	13	13	13	16	16	16
16	18	19	23	25	25	34	34	38	38	39	41	41
44	52	52	53	54	55	57	60	61	64			

Ahora se toma el valor absoluto de estos datos:

37	37	37	36	35	33	32	31	30	30	30	29	29	26	26
25	22	21	21	19	19	17	17	16	14	12	10	9	7	7
7	4	3	3	3	1	0	0	2	4	4	7	8	9	10
10	13	13	13	16	16	16	16	18	19	23	25	25	34	34
38	38	39	41	41	44	52	52	53	54	55	57	60	61	64

La mediana de este último conjunto es 21. Por lo tanto, MAD = 21.

PROBLEMAS SUPLEMENTARIOS

RANGO

4.33 Encontrar el rango de los conjuntos: *a*) 5, 3, 8, 4, 7, 6, 12, 4, 3 y *b*) 8.772, 6.453, 10.624, 8.628, 9.434, 6.351.

4.34 Encontrar el rango de las cargas máximas dadas en la tabla 3.8 del problema 3.59.

4.35 Encontrar el rango de los diámetros de remaches dados en la tabla 3.10 del problema 3.61.

4.36 En 50 medidas, la mayor es de 8.34 kilogramos (kg). Si el rango es 0.46 kg, encontrar la medida menor.

4.37 En la tabla siguiente se dan las semanas que necesitaron 25 trabajadores, que perdieron su trabajo por reducción de personal en sus empresas, para encontrar un nuevo empleo. Encontrar el rango de estos datos.

13	13	17	7	22
22	26	17	13	14
16	7	6	18	20
10	17	11	10	15
16	8	16	21	11

DESVIACIÓN MEDIA

4.38 Encontrar el valor absoluto de: *a*) -18.2, *b*) $+3.58$, *c*) 6.21, *d*) 0, *e*) $-\sqrt{2}$ y *f*) $4.00 - 2.36 - 3.52$.

4.39 Encontrar la desviación media de los conjuntos: *a*) 3, 7, 9, 5 y *b*) 2.4, 1.6, 3.8, 4.1, 3.4.

4.40 Encontrar a desviación media de los conjuntos de números del problema 4.33.

4.41 Encontrar la desviación media de las cargas máximas dadas en la tabla 3.8 del problema 3.59.

4.42 *a*) Encontrar la desviación media (DM) de los diámetros de los remaches de la tabla 3.10 del problema 3.61.

b) ¿Qué porcentaje de los diámetros de los remaches está entre ($\bar{X} \pm$ DM), ($\bar{X} \pm 2$ DM) y ($\bar{X} = 3$ DM)?

4.43 En el conjunto 8, 10, 9, 12, 4, 8, 2, encontrar la desviación media: *a*) respecto a la media y *b*) respecto a la mediana. Verificar que la desviación media respecto a la mediana no es mayor que la desviación media respecto a la media.

4.44 En la distribución dada en la tabla 3.9 del problema 3.60, encontrar la desviación media: *a*) respecto a la media y *b*) respecto a la mediana. Emplear los resultados de los problemas 3.60 y 3.70.

4.45 En la distribución dada en la tabla 3.11 del problema 3.62, encontrar la desviación media: *a*) respecto a la media y *b*) respecto a la mediana. Emplear los resultados de los problemas 3.62 y 3.72.

4.46 Encontrar la desviación media de los datos dados en el problema 4.37.

4.47 Deducir fórmulas de compilación para el cálculo de la desviación media: *a*) respecto a la media y *b*) respecto a la mediana a partir de una distribución de frecuencias. Emplear estas fórmulas para verificar los resultados obtenidos en los problemas 4.44 y 4.45.

EL RANGO SEMIINTERCUARTIL

4.48 Encontrar el rango semiintercuartil en las distribuciones: *a*) del problema 3.59, *b*) del problema 3.60 y *c*) del problema 3.107. En cada caso interpretar los resultados claramente.

4.49 Encontrar el rango semiintercuartil de los datos dados en el problema 4.37.

4.50 Probar que en cualquier distribución de frecuencias, el porcentaje de casos que cae en el intervalo $\frac{1}{2}(Q_1 + Q_3) \pm \frac{1}{2}(Q_3 - Q_1)$ es el 50%. ¿Ocurre lo mismo en el intervalo $Q_2 \pm \frac{1}{2}(Q_3 - Q_1)$? Explicar la respuesta.

4.51 *a*) ¿Cómo se graficaría el rango semiintercuartil correspondiente a una distribución de frecuencias dada?

b) ¿Qué relación hay entre el rango semiintercuartil y la ojiva de una distribución?

EL RANGO PERCENTIL 10-90

4.52 Encontrar el rango percentil 10-90 en las distribuciones: *a*) del problema 3.59 y *b*) del problema 3.107. En cada caso interpretar los resultados claramente.

4.53 El décimo percentil de los precios de venta de las casas en determinada ciudad es \$35 500 y el nonagésimo percentil de los precios de venta de las casas en la misma ciudad es \$225 000. Encontrar el rango percentil 10-90 y dar un rango en el que caiga el 80% de los precios de venta.

4.54 ¿Qué ventajas o desventajas tiene un rango percentil 20-80 en comparación con un rango percentil 10-90?

4.55 Contestar el problema 4.51 en relación: *a*) con el rango percentil 10-90, *b*) con el rango percentil 20-80 y *c*) el rango percentil 25-75. ¿Cuál es la relación entre *c*) y el rango semiintercuartil?

LA DESVIACIÓN ESTÁNDAR

4.56 Encontrar la desviación estándar de los conjuntos: *a*) 3, 6, 2, 1, 7, 5; *b*) 3.2, 4.6, 2.8, 5.2, 4.4, y *c*) 0, 0, 0, 0, 0, 1, 1, 1.

4.57 *a*) Sumando 5 a cada uno de los números del conjunto 3, 6, 2, 1, 7, 5 se obtiene el conjunto 8, 11, 7, 6, 12, 10. Mostrar que los dos conjuntos tienen la misma desviación estándar pero diferentes medias. ¿Qué relación hay entre las medias?

b) Si cada uno de los números del conjunto 3, 6, 2, 1, 7 y 5 se multiplica por 2 y después se le suma 5, se obtiene el conjunto 11, 17, 9, 7, 19, 15. ¿Qué relación existe entre las medias y las desviaciones estándar de estos dos conjuntos?

c) ¿Qué propiedades de la media y de la desviación estándar se ilustran mediante los conjuntos de números particulares de los incisos *a*) y *b*)?

4.58 Encontrar la desviación estándar del conjunto de números de la progresión aritmética 4, 10, 16, 22, . . . , 154.

4.59 Encontrar la desviación estándar en las distribuciones: *a*) del problema 3.59, *b*) del problema 3.60 y *c*) del problema 3.107,

4.60 Ilustrar el uso de la comprobación de Charlier en cada inciso del problema 4.59.

4.61 Encontrar: *a*) la media y *b*) la desviación estándar en la distribución del problema 2.17 y explicar el significado de los resultados obtenidos.

4.62 Cuando los datos tienen una distribución en forma de campana, la desviación estándar se puede obtener de manera aproximada dividiendo el rango entre 4. Con los datos dados en el problema 4.37, calcular la desviación estándar y compararla con el rango dividido entre 4.

4.63 *a*) Encontrar la desviación estándar s de los diámetros de los remaches dados en la tabla 3.10 del problema 3.61.

b) ¿Qué porcentaje de los diámetros de los remaches se encuentra entre $\bar{X} \pm s$, $\bar{X} \pm 2s$ y $\bar{X} \pm 3s$?

c) Comparar los porcentajes del inciso *b*) con los que teóricamente se esperan en una distribución normal y explicar cualquier diferencia observada.

4.64 Aplicar la corrección de Sheppard a las desviaciones estándar del problema 4.59. En cada caso, comentar si la aplicación de la corrección de Sheppard está o no justificada.

4.65 ¿Qué modificaciones ocurren en el problema 4.63 cuando se aplica la corrección de Sheppard?

4.66 *a*) Encontrar la media y la desviación estándar de los datos del problema 2.8.

b) Construir una distribución de frecuencia para los datos y encontrar la desviación estándar.

c) Comparar los resultados del inciso *b*) con los del inciso *a*). Determinar si la aplicación de la corrección de Sheppard produce mejores resultados.

4.67 Repetir el problema 4.66 con los datos del problema 2.27.

4.68 *a*) De un total de N números, la fracción p es de unos y la fracción $q = 1 - p$ es de ceros. Probar que la desviación estándar de este conjunto de números es $\sqrt{pq}$.

b) Aplicar el resultado del inciso *a*) al problema 4.56*c*).

4.69 *a*) Probar que la varianza del conjunto de números a, $a + d$, $a + 2d, \ldots, a + (n-1)d$ (es decir, de una progresión aritmética en la que el primer término es a y la diferencia común es d) es $\frac{1}{12}(n^2 - 1)d^2$.

b) Emplear el inciso *a*) para el problema 4.58. [*Sugerencia:* Usar $1 + 2 + 3 \cdots + (n-1) = \frac{1}{2}n(n-1)$, $1^2 + 2^2 + 3^2 + \cdots + (n-1)^2 = \frac{1}{6}n(n-1)(2n-1)$].

4.70 Generalizar y probar la propiedad 3 de este capítulo.

RELACIONES EMPÍRICAS ENTRE LAS MEDIDAS DE DISPERSIÓN

4.71 Comparando las desviaciones estándar obtenidas en el problema 4.59 con las desviaciones medias correspondientes de los problemas 4.41, 4.42 y 4.44, determinar si se cumple la siguiente relación empírica: desviación media $= \frac{4}{5}$(desviación estándar). Explicar cualquier diferencia que se presente.

4.72 Comparando las desviaciones estándar obtenidas en el problema 4.59 con los correspondientes rangos semiintercuartiles del problema 4.48, determinar si se cumple la siguiente relación empírica: rango semiintercuartil $= \frac{2}{3}$(desviación estándar). Explicar cualquier diferencia que se presente.

4.73 ¿Qué relación empírica se espera que exista entre el rango semiintercuartil y la desviación media en distribuciones en forma de campana ligeramente sesgadas?

4.74 Una distribución de frecuencias que es aproximadamente normal tiene un rango semiintercuartil igual a 10. ¿Qué valor se espera que tenga: *a*) la desviación estándar y *b*) la desviación media?

DISPERSIÓN ABSOLUTA Y RELATIVA; COEFICIENTE DE VARIACIÓN

4.75 En un examen final de estadística, la calificación media en un grupo de 150 alumnos es 78 y la desviación estándar 8.0. En álgebra, la puntuación media final del grupo es 73 y la desviación estándar 7.6. ¿En qué materia hay: *a*) mayor dispersión absoluta y *b*) mayor dispersión relativa?

4.76 Encontrar el coeficiente de variación de los datos: *a*) del problema 3.59 y *b*) del problema 3.107.

4.77 En las calificaciones obtenidas por los estudiantes en un examen de admisión, el primer cuartil es 825 y el segundo cuartil es 1 125. Calcular el coeficiente cuartil de variación en estas calificaciones del examen da admisión.

4.78 En el grupo de edad de 15 a 24 años, el primer cuartil de ingreso familiar es \$16 500 y el tercer cuartil de ingreso familiar, en este mismo grupo de edad, es \$25 000. Calcular el coeficiente cuartil de variación de la distribución de los ingresos en este grupo de edad.

VARIABLES ESTANDARIZADAS; PUNTUACIONES ESTÁNDAR

4.79 En el examen del problema 4.75 la calificación de un estudiante en estadística es 75 y en álgebra 71. ¿En qué examen tiene una puntuación relativa más alta?

4.80 Convertir el conjunto 6, 2, 8, 7, 5 en puntuaciones estándar.

4.81 Probar que la media y la desviación estándar en un conjunto de puntuaciones estándar son iguales a 0 y 1, respectivamente. Emplear el problema 4.80 para ilustrar esto.

4.82 *a*) Convertir las calificaciones del problema 3.107 en puntuaciones estándar y *b*) construir una gráfica de frecuencias relativas contra puntuaciones estándar.

SOFTWARE Y MEDIDAS DE DISPERSIÓN

4.83 En la tabla 4.11 se da el ingreso per cápita en los 50 estados de Estados Unidos, en 2005.

Tabla 4.11 Ingreso per cápita en los 50 estados de Estados Unidos

Estado	Ingreso per cápita	Estado	Ingreso per cápita
Wyoming	36 778	Pennsylvania	34 897
Montana	29 387	Wisconsin	33 565
North Dakota	31 395	Massachusetts	44 289
New Mexico	27 664	Missouri	31 899
West Virginia	27 215	Idaho	28 158
Rhode Island	36 153	Kentucky	28 513
Virginia	38 390	Minnesota	37 373
South Dakota	31 614	Florida	33 219
Alabama	29 136	South Carolina	28 352
Arkansas	26 874	New York	40 507
Maryland	41 760	Indiana	31 276
Iowa	32 315	Connecticut	47 819
Nebraska	33 616	Ohio	32 478
Hawaii	34 539	New Hampshire	38 408
Mississippi	25 318	Texas	32 462
Vermont	33 327	Oregon	32 103
Maine	31 252	New Jersey	43 771
Oklahoma	29 330	California	37 036
Delaware	37 065	Colorado	37 946
Alaska	35 612	North Carolina	30 553
Tennessee	31 107	Illinois	36 120
Kansas	32 836	Michigan	33 116
Arizona	30 267	Washington	35 409
Nevada	35 883	Georgia	31 121
Utah	28 061	Louisiana	24 820

El análisis de estos datos obtenido con SPSS es el siguiente:

Estadística descriptiva

	N	Rango	Desviación estándar	Varianza
Ingresos	50	22 999.00	4 893.54160	2E+007
N validado	50			

Verificar el rango, la desviación estándar y la varianza.

MOMENTOS, SESGO Y CURTOSIS

5

MOMENTOS

Dados N valores $X_1, X_2, \ldots, X_N$ que toma la variable X, se define la cantidad

$$\overline{X^r} = \frac{X_1^r + X_2^r + \cdots + X_N^r}{N} = \frac{\sum_{j=1}^{N} X_j^r}{N} = \frac{\sum X^r}{N} \tag{1}$$

a la que se le llama el r-ésimo *momento*. El primer momento, en el que $r = 1$ es la media aritmética $\bar{X}$.

El r-ésimo *momento respecto a la media* $\bar{X}$ se define como

$$m_r = \frac{\sum_{j=1}^{N} (X_j - \bar{X})^r}{N} = \frac{\sum (X - \bar{X})^r}{N} = \overline{(X - \bar{X})^r} \tag{2}$$

Si $r = 1$, entonces $m_1 = 0$ (ver el problema 3.16). Si $r = 2$, entonces m_2 es la varianza.

El r-ésimo *momento respecto a cualquier origen A* se define de la manera siguiente

$$m_r' = \frac{\sum_{j=1}^{N} (X_j - A)^r}{N} = \frac{\sum (X - A)^r}{N} = \frac{\sum d^r}{N} = \overline{(X - A)^r} \tag{3}$$

donde las $d = X - A$ son las desviaciones de las X respecto de A. Si $A = 0$, la ecuación (*3*) se reduce a la ecuación (*1*). Debido a esto, a la ecuación (*1*) suele llamársele el r-ésimo *momento respecto de cero.*

MOMENTOS PARA DATOS AGRUPADOS

Si $X_1, X_2, \ldots, X_K$ se presentan con frecuencias $f_1, f_2, \ldots, f_K$, respectivamente, los momentos anteriores están dados por

$$\overline{X^r} = \frac{f_1 X_1^r + f_2 X_2^r + \cdots + f_K X_K^r}{N} = \frac{\sum_{j=1}^{K} f_j X_j^r}{N} = \frac{\sum f X^r}{N} \tag{4}$$

$$m_r = \frac{\sum_{j=1}^{K} f_j (X_j - \bar{X})^r}{N} = \frac{\sum f(X - \bar{X})^r}{N} = \overline{(X - \bar{X})^r} \tag{5}$$

$$m'_r = \frac{\sum_{j=1}^{K} f_j (X_j - A)^r}{N} = \frac{\sum f\,(X - A)^r}{N} = \overline{(X - A)^r} \tag{6}$$

donde $N = \sum_{j=1}^{K} f_j = \sum f$. Estas fórmulas se emplean para el cálculo de momentos de datos agrupados.

RELACIONES ENTRE MOMENTOS

Entre los momentos respecto a la media m_r y los momentos respecto de un origen arbitrario m'_r existen las relaciones siguientes:

$$\begin{aligned} m_2 &= m'_2 - m'^2_1 \\ m_3 &= m'_3 - 3m'_1 m'_2 + 2m'^3_1 \\ m_4 &= m'_4 - 4m'_1 m'_3 + 6m'^2_1 m'_2 - 3m'^4_1 \end{aligned} \tag{7}$$

etcétera (ver problema 5.5). Obsérvese que $m'_1 = \bar{X} - A$.

CÁLCULO DE MOMENTOS PARA DATOS AGRUPADOS

El método de compilación dado en capítulos anteriores para el cálculo de la media y de la desviación estándar también puede usarse para obtener un método abreviado para el cálculo de los momentos. Este método aprovecha el hecho de que $X_j = A + cu_j$ (o brevemente, $X = A + cu$), de manera que de acuerdo con la ecuación (*6*) se tiene

$$m'_r = c^r \frac{\sum fu^r}{N} = c^r \overline{u^r} \tag{8}$$

que puede usarse para hallar m_r empleando las ecuaciones (*7*).

COMPROBACIÓN DE CHARLIER Y CORRECCIÓN DE SHEPPARD

La comprobación de Charlier al calcular momentos mediante el método de compilación emplea las identidades:

$$\begin{aligned} \sum f(u+1) &= \sum fu + N \\ \sum f(u+1)^2 &= \sum fu^2 + 2\sum fu + N \\ \sum f(u+1)^3 &= \sum fu^3 + 3\sum fu^2 + 3\sum fu + N \\ \sum f(u+1)^4 &= \sum fu^4 + 4\sum fu^3 + 6\sum fu^2 + 4\sum fu + N \end{aligned} \tag{9}$$

Las correcciones de Sheppard para momentos son las siguientes:

$$m_2 \text{ corregido} = m_2 - \tfrac{1}{12}c^2 \qquad m_4 \text{ corregido} = m_4 - \tfrac{1}{2}c^2 m_2 + \tfrac{7}{240}c^4$$

Los momentos m_1 y m_3 no necesitan corrección.

MOMENTOS EN FORMA ADIMENSIONAL

Para evitar usar unidades particulares, se definen *momentos adimensionales* respecto de la media:

$$a_r = \frac{m_r}{s^r} = \frac{m_r}{(\sqrt{m_2})^r} = \frac{m_r}{\sqrt{m_2^r}} \tag{10}$$

donde $s = \sqrt{m_2}$ es la desviación estándar. Como $m_1 = 0$ y $m_2 = s^2$, se tiene $a_1 = 0$ y $a_2 = 1$.

SESGO

El *sesgo* de una distribución es su grado de asimetría o el grado en el que se aleja de la simetría. Si una curva de frecuencias (polígono de frecuencias suavizado) de una distribución tiene una cola más larga hacia la derecha del máximo central que hacia la izquierda, se dice que la distribución es *sesgada a la derecha*, o que tiene un *sesgo positivo.* Si ocurre lo contrario, se dice que es *sesgada a la izquierda* o que tiene un *sesgo negativo.*

En las distribuciones sesgadas, la media tiende a encontrarse del mismo lado que la cola más larga opuesto al de la moda y que la cola más larga (ver figuras 3-1 y 3-2). Por lo tanto, una medida de la simetría (o sesgo) se obtiene mediante la diferencia: media – moda. Esta medida se puede hacer adimensional dividiendo entre una medida de dispersión, como la desviación estándar, lo que conduce a la definición:

$$\text{Sesgo} = \frac{\text{media} - \text{moda}}{\text{desviación estándar}} = \frac{\bar{X} - \text{moda}}{s} \tag{11}$$

Para evitar el uso de la moda se puede utilizar la fórmula empírica (*10*) del capítulo 3 y definir

$$\text{Sesgo} = \frac{3(\text{media} - \text{mediana})}{\text{desviación estándar}} = \frac{3(\bar{X} - \text{mediana})}{s} \tag{12}$$

A las ecuaciones (*11*) y (*12*) se les llama, respectivamente, *primer coeficiente de sesgo de Pearson* y *segundo coeficiente de sesgo de Pearson.*

Otras medidas del sesgo, que se definen en términos de cuartiles y percentiles, son las siguientes:

$$\text{Coeficiente cuartil de sesgo} = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1} = \frac{Q_3 - 2Q_2 + Q_1}{Q_3 - Q_1} \tag{13}$$

$$\text{Coeficiente de sesgo percentil 10–90} = \frac{(P_{90} - P_{50}) - (P_{50} - P_{10})}{P_{90} - P_{10}} = \frac{P_{90} - 2P_{50} + P_{10}}{P_{90} - P_{10}} \tag{14}$$

En una importante medida del sesgo se emplea el tercer momento respecto de la media, tal medida expresada en forma adimensional viene dada por:

$$\text{Coeficiente momento de sesgo} = a_3 = \frac{m_3}{s^3} = \frac{m_3}{(\sqrt{m_2})^3} = \frac{m_3}{\sqrt{m_2^3}} \tag{15}$$

Otra medida de sesgo suele darse mediante $b_1 = a_3^2$. En las curvas perfectamente simétricas, por ejemplo en la curva normal, a_3 y b_1 son cero.

CURTOSIS

La *curtosis* indica qué tan puntiaguda es una distribución; esto por lo regular es en relación con la distribución normal. A una distribución que tiene un pico relativamente alto se le llama *leptocúrtica*, en tanto que si es relativamente aplastada se dice *platicúrtica*. Una distribución normal, que no es ni puntiaguda ni muy aplastada se llama *mesocúrtica.*

En una medida de la curtosis se emplea el cuarto momento respecto de la media, expresada en forma adimensional, esta medida se encuentra dada por:

$$\text{Coeficiente momento de curtosis} = a_4 = \frac{m_4}{s^4} = \frac{m_4}{m_2^2} \tag{16}$$

el cual suele denotarse b_2. En las distribuciones normales $b_2 = a_4 = 3$. A esto se debe que la curtosis suela definirse mediante $(b_2 - 3)$, que tiene signo positivo en una distribución leptocúrtica, negativo en una distribución platicúrtica y cero en las distribuciones normales.

Otra medida de la curtosis se basa tanto en los cuartiles como en los percentiles y está dada por

$$\kappa = \frac{Q}{P_{90} - P_{10}} \tag{17}$$

donde $Q = \frac{1}{2}(Q_3 - Q_1)$ es el rango semiintercuartil. A κ (letra griega minúscula kappa) se le conoce como *coeficiente percentil de curtosis*; en las distribuciones normales, el valor de κ es 0.263.

MOMENTOS, SESGO Y CURTOSIS POBLACIONALES

Cuando es necesario distinguir los momentos muestrales, las medidas de sesgo muestrales o las medidas de curtosis muestrales, de las correspondientes medidas de la población de la que es parte la muestra, se acostumbra usar letras del alfabeto latino para las primeras y letras del alfabeto griego para las últimas. Así, si los momentos muestrales se denotan m_r y m_r', los correspondientes momentos poblacionales serán, μ_r y μ_r' (μ es la letra *mu* del alfabeto griego). Como subíndices se emplean siempre letras del alfabeto latino.

De igual manera, si las medidas muestrales de sesgo y curtosis se denotan a_3 y a_4, respectivamente, los sesgos y las curtosis poblacionales serán α_3 y α_4 (α es la letra *alfa* del alfabeto griego).

Como ya se dijo en el capítulo 4, la desviación estándar de una muestra y la desviación estándar de una población se denotan s y σ, respectivamente.

CÁLCULO DEL SESGO Y DE LA CURTOSIS EMPLEANDO SOFTWARE

El software visto en este libro puede usarse para calcular las medidas de curtosis y de sesgo de datos muestrales. Los datos que se presentan en la tabla 5.1 son muestras de 50 elementos (de tamaño 50) tomadas de distribuciones, una normal, otra sesgada a la derecha, otra sesgada a la izquierda y la última es una distribución uniforme.

Los datos normales son estaturas de mujeres, los datos sesgados a la derecha son edades de casamiento de mujeres, los datos sesgados a la izquierda son edades a las que fallecen las mujeres, y los datos uniformes son cantidades de

Tabla 5.1

Normal		Sesgada a la derecha		Sesgada a la izquierda		Uniforme	
67	69	31	40	102	87	12.1	11.6
70	62	43	24	55	104	12.1	11.6
63	67	30	29	70	75	12.4	12.0
65	59	30	24	95	80	12.1	11.6
68	66	38	27	73	66	12.1	11.6
60	65	26	35	79	93	12.2	11.7
70	63	29	33	60	90	12.2	12.3
64	65	55	75	73	84	12.2	11.7
69	60	46	38	89	73	11.9	11.7
61	67	26	34	85	98	12.2	11.7
66	64	29	85	72	79	12.3	11.8
65	68	57	29	92	35	12.3	12.5
71	61	34	40	76	71	11.7	11.8
62	69	34	41	93	90	12.3	11.8
66	65	36	35	76	71	12.3	11.8
68	62	40	26	97	63	12.4	11.9
64	67	28	34	10	58	12.4	11.9
67	70	26	19	70	82	12.1	11.9
62	64	66	23	85	72	12.4	12.2
66	63	63	28	25	93	12.4	11.9
65	68	30	26	83	44	12.5	12.0
63	64	33	31	58	65	11.8	11.9
66	65	24	25	10	77	12.5	12.0
65	61	35	22	92	81	12.5	12.0
63	66	34	28	82	77	12.5	12.0

refresco despachadas por una máquina en envases de 12 onzas. En la figura 5-1 se muestra la distribución de cada uno de estos conjuntos de datos muestrales. Las distribuciones de las cuatro muestras se ilustran mediante gráficas de puntos.

Gráficas de puntos de estaturas, edades de casamiento, edades de fallecimiento y llenado de refresco

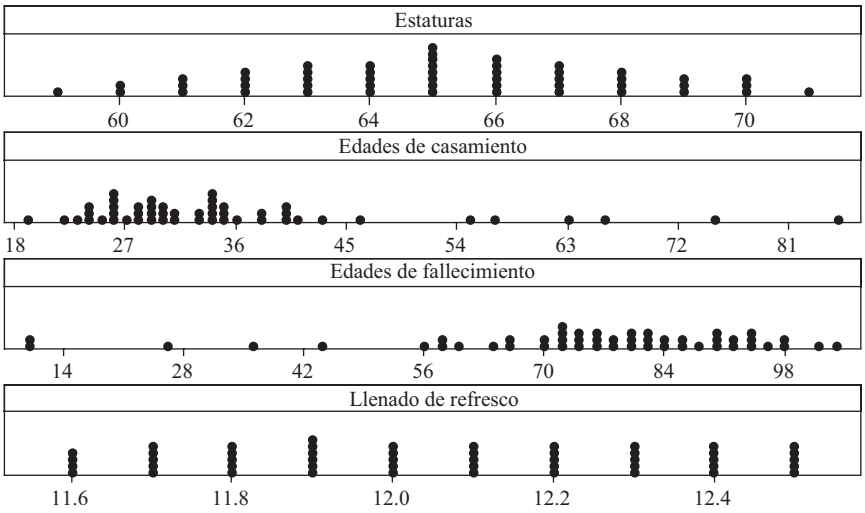


Figura 5-1 MINITAB, gráficas de cuatro distribuciones: normal, sesgada a la derecha, sesgada a la izquierda y uniforme.

En la variable estatura se da la estatura de 50 mujeres adultas, en la variable edad de casamiento se da la edad de casamiento de 50 mujeres, en la variable edad de fallecimiento se da la edad de fallecimiento de 50 mujeres y en la variable llenado de refresco se dan las cantidades de refresco despachadas en recipientes de 12 onzas. Cada muestra tiene 50 elementos (es de tamaño 50). Empleando la terminología aprendida en este capítulo: la distribución de las estaturas es mesocúrtica, la distribución del llenado de refresco es platicúrtica, la distribución de las edades de casamiento es sesgada a la derecha, y la distribución de las edades de fallecimiento es sesgada a la izquierda.

EJEMPLO 1 Para hallar los valores correspondientes al sesgo y a la curtosis de las cuatro variables puede emplearse MINITAB. Seleccionando la secuencia "**Stat ⇒ Basic statistics ⇒ Display descriptive statistics**", se obtiene el siguiente resultado:

Estadísticos descritivos: estatura, edades de casamiento, edades de fallecimiento y llenado de refresco

Variable	N	N*	Mean	StDev	Skewness	Kurtosis
Height	50	0	65.120	2.911	−0.02	−0.61
Wedage	50	0	35.48	13.51	1.98	4.10
Obitage	50	0	74.20	20.70	−1.50	2.64
Cola-fill	50	0	12.056	0.284	0.02	−1.19

Como se ve, los valores dados para el sesgo de las distribuciones normal y uniforme son cercanos a 0; el sesgo es positivo para la distribución sesgada a la derecha y negativo para la distribución sesgada a la izquierda.

EJEMPLO 2 Use EXCEL para hallar los valores de sesgo y curtosis correspondientes a los datos de la figura 5-1. Los nombres de las variables se ingresan en A1:D1, los datos muestrales se ingresan en A2:D51 y en cualquier celda vacía se ingresa =COEFICIENTE.ASIMETRIA(A2:A51) obteniéndose como resultado −0.0203. La función =COEFICIENTE.ASIMETRIA(B2:B51) da como resultado 1.9774, la función =COEFICIENTE.ASIMETRIA(C2:C51) da como resultado −1.4986 y la función =COEFICIENTE.ASIMETRIA(D2:D51) da como resultado 0.0156. Los valores de curtosis se obtienen mediante las funciones =CURTOSIS(A2:A51) que da como resultado −0.6083, =CURTOSIS(B2:B51) que da como resultado 4.0985, =CURTOSIS(C2:C51) que da como resultado 2.6368 y =CURTOSIS(D2:D51) que da como resultado −1.1889. Como puede observarse, EXCEL y MINITAB dan los mismos valores de curtosis y de sesgo.

EJEMPLO 3 También se puede emplear STATISTIX para analizar los datos de la figura 5-1. Se selecciona la secuencia "**Statistics ⇒ Summary Statistics ⇒ Descriptive Statistics**" y se obtiene la ventana de diálogo que se muestra en la figura 5-2.

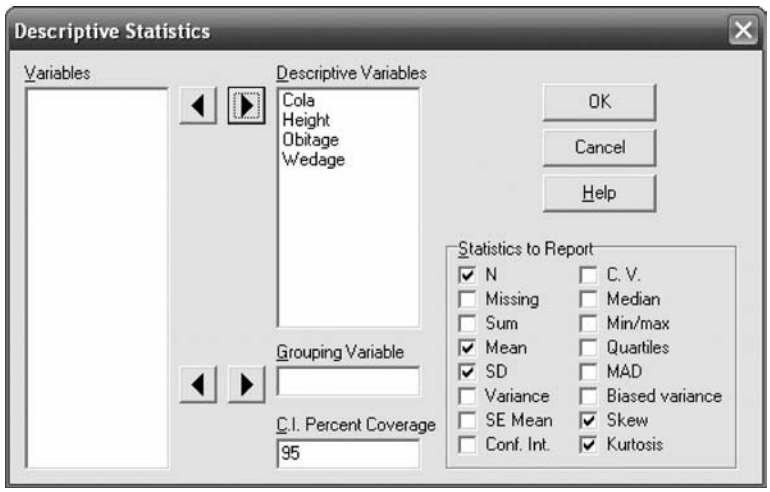


Figura 5-2 Ventana de diálogo de STATISTIX.

Obsérvese que N, Mean (media), SD (desviación estándar), Skew (sesgo) y Kurtosis (curtosis) fueron seleccionados como los estadísticos que se desean conocer. El resultado que se obtiene de STATISTIX es:

Estadísticos descriptivos

Variable	N	Mean	SD	Skew	Kurtosis
Cola	50	12.056	0.2837	0.0151	−1.1910
Height	50	65.120	2.9112	−0.0197	−0.6668
Obitage	50	74.200	20.696	−1.4533	2.2628
Wedage	50	35.480	13.511	1.9176	3.5823

Como los valores numéricos difieren ligeramente de los obtenidos con EXCEL y MINITAB, es claro que este software emplea métodos ligeramente diferentes para medir la curtosis y el sesgo.

EJEMPLO 4 En SPSS con la secuencia "**Analyze ⇒ Descriptive Statistics ⇒ Descriptives**" se obtiene la ventana de diálogo que se presenta en la figura 5-3, en la cual se selecciona Mean (media), Std. deviation (desviación estándar), Kurtosis (curtosis) y Skewness (sesgo). SPSS da las mismas medidas de sesgo y curtosis que EXCEL y MINITAB.

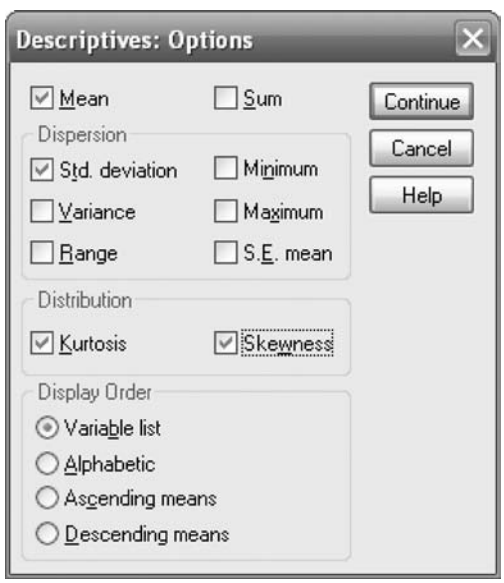


Figura 5-3 Ventana de diálogo de SPSS.

SPSS proporciona los siguientes resultados.

Estadísticos descriptivos

	N	Media	Desv. Estándar	Sesgo		Curtosis	
	Estadístico	Estadístico	Estadístico	Estadístico	Error estándar	Estadístico	Error estándar
Estatura	50	65.1200	2.91120	−.020	.337	−.608	.662
Casamientos	50	35.4800	13.51075	1.977	.337	4.098	.662
Defunciones	50	74.2000	20.69605	−1.499	.337	2.637	.662
Llenado	50	12.0560	.28368	.016	.337	−1.189	.662
N validada	50						

EJEMPLO 5 Si se usa SAS para calcular los valores del sesgo y de la curtosis, se obtienen los resultados que se muestran a continuación. Estos resultados son prácticamente los mismos que se obtienen con EXCEL, MINITAB y SPSS.

```
                        The MEANS Procedure
  Variable      Mean          Std Dev       N    Skewness      Kurtosis
ffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffff
  Height       65.1200000    2.9112029    50   −0.0203232   −0.6083437
  Wedage       35.4800000   13.5107516    50    1.9774237    4.0984607
  Obitage      74.2000000   20.6960511    50   −1.4986145    2.6368045
  Cola_fill    12.0560000    0.2836785    50    0.0156088   −1.1889600
ffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffffff
```

PROBLEMAS RESUELTOS

MOMENTOS

5.1 Encontrar: *a*) el primero, *b*) el segundo, *c*) el tercero y *d*) el cuarto momentos del conjunto 2, 3, 7, 8, 10.

SOLUCIÓN

a) El primer momento o media aritmética es

$$\bar{X} = \frac{\sum X}{N} = \frac{2+3+7+8+10}{5} = \frac{30}{5} = 6$$

b) El segundo momento es

$$\overline{X^2} = \frac{\sum X^2}{N} = \frac{2^2+3^2+7^2+8^2+10^2}{5} = \frac{226}{5} = 45.2$$

c) El tercer momento es

$$\overline{X^3} = \frac{\sum X^3}{N} = \frac{2^3+3^3+7^3+8^3+10^3}{5} = \frac{1\,890}{5} = 378$$

d) El cuarto momento es

$$\overline{X^4} = \frac{\sum X^4}{N} = \frac{2^4+3^4+7^4+8^4+10^4}{5} = \frac{16\,594}{5} = 3\,318.8$$

5.2 Dado el conjunto de números del problema 5.1, encontrar: *a*) el primero, *b*) el segundo, *c*) el tercero y *d*) el cuarto momentos respecto de la media.

SOLUCIÓN

a) $m_1 = \overline{(X - \bar{X})} = \dfrac{\sum (X - \bar{X})}{N} = \dfrac{(2-6) + (3-6) + (7-6) + (8-6) + (10-6)}{5} = \dfrac{0}{5} = 0$

m_1 siempre es igual a cero debido a que $\overline{X - \bar{X}} = \bar{X} - \bar{X} = 0$ (ver problema 3.16).

b) $m_2 = \overline{(X - \bar{X})^2} = \dfrac{\sum (X - \bar{X})^2}{N} = \dfrac{(2-6)^2 + (3-6)^2 + (7-6)^2 + (8-6)^2 + (10-6)^2}{6} = \dfrac{46}{5} = 9.2$

Obsérvese que m_2 es la varianza s^2.

c) $m_3 = \overline{(X - \bar{X})^3} = \dfrac{\sum (X - \bar{X})^3}{N} = \dfrac{(2-6)^3 + (3-6)^3 + (7-6)^3 + (8-6)^3 + (10-6)^3}{5} = \dfrac{-18}{5} = -3.6$

d) $m_4 = \overline{(X - \bar{X})^4} = \dfrac{\sum (X - \bar{X})^4}{N} = \dfrac{(2-6)^4 + (3-6)^4 + (7-6)^4 + (8-6)^4 + (10-6)^4}{5} = \dfrac{610}{5} = 122$

5.3 Para el conjunto de números del problema 5.1, encontrar: *a*) el primero, *b*) el segundo, *c*) el tercero y *d*) el cuarto momentos respecto del origen.

SOLUCIÓN

a) $m_1' = \overline{(X - 4)} = \dfrac{\sum (X - 4)}{N} = \dfrac{(2-4) + (3-4) + (7-4) + (8-4) + (10-4)}{5} = 2$

b) $m_2' = \overline{(X - 4)^2} = \dfrac{\sum (X - 4)^2}{N} = \dfrac{(2-4)^2 + (3-4)^2 + (7-4)^2 + (8-4)^2 + (10-4)^2}{5} = \dfrac{66}{5} = 13.2$

c) $m_3' = \overline{(X - 4)^3} = \dfrac{\sum (X - 4)^3}{N} = \dfrac{(2-4)^3 + (3-4)^3 + (7-4)^3 + (8-4)^3 + (10-4)^3}{5} = \dfrac{298}{5} = 59.6$

d) $m_4' = \overline{(X - 4)^4} = \dfrac{\sum (X - 4)^4}{N} = \dfrac{(2-4)^4 + (3-4)^4 + (7-4)^4 + (8-4)^4 + (10-4)^4}{5} = \dfrac{1\,650}{5} = 330$

5.4 Empleando los resultados de los problemas 5.2 y 5.3, verificar las siguientes relaciones entre los momentos: *a*) $m_2 = m_2' - m_1'^2$, *b*) $m_3 = m_3' - 3m_1'm_2' + 2m_1'^3$ y *c*) $m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4$.

SOLUCIÓN

De acuerdo con el problema 5.3 se tiene $m_1' = 2$, $m_2' = 13.2$, $m_3' = 59.6$ y $m_4' = 330$. Por lo tanto:

a) $m_2 = m_2' - m_1'^2 = 13.2 - (2)^2 = 13.2 - 4 = 9.2$

b) $m_3 = m_3' - 3m_1'm_2' + 2m_1'^3 = 59.6 - (3)(2)(13.2) + 2(2)^3 = 59.6 - 79.2 + 16 = -3.6$

c) $m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4 = 330 - 4(2)(59.6) + 6(2)^2(13.2) - 3(2)^4 = 122$

lo que coincide con el problema 5.2.

5.5 Probar que: *a*) $m_2 = m_2' - m_1'^2$, *b*) $m_3 = m_3' - 3m_1'm_2' + 2m_1'^3$ y *c*) $m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4$.

SOLUCIÓN

Si $d = X - A$, entonces $X = A + d$, $\bar{X} = A + \bar{d}$ y $X - \bar{X} = d - \bar{d}$, y por lo tanto:

a)
$$m_2 = \overline{(X - \bar{X})^2} = \overline{(d - \bar{d})^2} = \overline{d^2 - 2\bar{d}d + \bar{d}^2}$$
$$= \overline{d^2} - 2\bar{d}^2 + \bar{d}^2 = \overline{d^2} - \bar{d}^2 = m_2' - m_1'^2$$

b) $m_3 = \overline{(X-\bar{X})^3} = \overline{(d-\bar{d})^3} = \overline{(d^3 - 3d^2\bar{d} + 3d\bar{d}^2 - \bar{d}^3)}$
$= \overline{d^3} - 3\bar{d}\overline{d^2} + 3\bar{d}^3 - \bar{d}^3 = \overline{d^3} - 3\bar{d}\overline{d^2} + 2\bar{d}^3 = m_3' - 3m_1'm_2' + 2m_1'^3$

c) $m_4 = \overline{(X-\bar{X})^4} = \overline{(d-\bar{d})^4} = \overline{(d^4 - 4d^3\bar{d} + 6d^2\bar{d}^2 - 4d\bar{d}^3 + \bar{d}^4)}$
$= \overline{d^4} - 4\bar{d}\overline{d^3} + 6\bar{d}^2\overline{d^2} - 4\bar{d}^4 + \bar{d}^4 = \overline{d^4} - 4\bar{d}\overline{d^3} + 6\bar{d}^2\overline{d^2} - 3\bar{d}^4$
$= m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4$

Por extensión de este método se pueden deducir fórmulas semejantes para m_5, m_6, etcétera.

CÁLCULO DE MOMENTOS PARA DATOS AGRUPADOS

5.6 Encuentre los primeros cuatro momentos respecto de la media para la distribución de estaturas del problema 3.22.

SOLUCIÓN

Para facilitar los cálculos se pueden disponer como en la tabla 5.2, a partir de la cual se tiene

$$m_1' = c\frac{\sum fu}{N} = (3)\left(\frac{15}{100}\right) = 0.45 \qquad m_3' = c^3\frac{\sum fu^3}{N} = (3)^3\left(\frac{33}{100}\right) = 8.91$$

$$m_2' = c^2\frac{\sum fu^2}{N} = (3)^2\left(\frac{97}{100}\right) = 8.73 \qquad m_4' = c^4\frac{\sum fu^4}{N} = (3)^4\left(\frac{253}{100}\right) = 204.93$$

Por lo tanto
$$m_1 = 0$$
$$m_2 = m_2' - m_1'^2 = 8.73 - (0.45)^2 = 8.5275$$
$$m_3 = m_3' - 3m_1'm_2' + m_1'^3 = 8.91 - 3(0.45)(8.73) + 2(0.45)^3 = -2.6932$$
$$m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4$$
$$= 204.93 - 4(0.45)(8.91) + 6(0.45)^2(8.73) - 3(0.45)^4 = 199.3759$$

Tabla 5.2

X	u	f	fu	fu^2	fu^3	fu^4
61	−2	5	−10	20	−40	80
64	−1	18	−18	18	−18	18
67	0	42	0	0	0	0
70	1	27	27	27	27	27
73	2	8	16	32	64	128
		$N = \sum f = 10$	$\sum fu = 15$	$\sum fu^2 = 97$	$\sum fu^3 = 33$	$\sum fu^4 = 253$

5.7 Encontrar: *a*) m_1', *b*) m_2', *c*) m_3', *d*) m_4', *e*) m_1, *f*) m_2, *g*) m_3, *h*) m_4, *i*) $\bar{X}$, *j*) s, *k*) $\overline{X^2}$ y *l*) $\overline{X^3}$ para la distribución de la tabla 4.7 del problema 4.19.

SOLUCIÓN

Para facilitar los cálculos, disponerlos como en la tabla 5.3.

Tabla 5.3

X	u	f	fu	fu^2	fu^3	fu^4
70	−6	4	−24	144	−864	5 184
74	−5	9	−45	225	−1 125	5 625
78	−4	16	−64	256	−1 024	4 096
82	−3	28	−84	252	−756	2 268
86	−2	45	−90	180	−360	720
90	−1	66	−66	66	−66	66
$A \longrightarrow$ 94	0	85	0	0	0	0
98	1	72	72	72	72	72
102	2	54	108	216	432	864
106	3	38	114	342	1 026	3 078
110	4	27	108	432	1 728	6 912
114	5	18	90	450	2 250	11 250
118	6	11	66	396	2 376	14 256
122	7	5	34	245	1 715	12 005
126	8	2	16	128	1 024	8 192
		$N = \sum f = 480$	$\sum fu = 236$	$\sum fu^2 = 3\,404$	$\sum fu^3 = 6\,428$	$\sum fu^4 = 74\,588$

a) $m_1' = c\dfrac{\sum fu}{N} = (4)\left(\dfrac{236}{480}\right) = 1.9667$

b) $m_2' = c^2\dfrac{\sum fu^2}{N} = (4)^2\left(\dfrac{3\,404}{480}\right) = 113.4667$

c) $m_3' = c^3\dfrac{\sum fu^3}{N} = (4)^3\left(\dfrac{6\,428}{480}\right) = 857.0667$

d) $m_4' = c^4\dfrac{\sum fu^4}{N} = (4)^4\left(\dfrac{74\,588}{480}\right) = 39\,780.2667$

e) $m_1 = 0$

f) $m_2 = m_2' - m_1'^2 = 113.4667 - (1.9667)^2 = 109.5988$

g) $m_3 = m_3' - 3m_1'm_2' + 2m_1'^3 = 857.0667 - 3(1.9667)(113.4667) + 2(1.9667)^3 = 202.8158$

h) $m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4 = 35\,627.2853$

i) $\bar{X} = \overline{(A + d)} = A + m_1' = A + c\dfrac{\sum fu}{N} = 94 + 1.9667 = 95.97$

j) $s = \sqrt{m_2} = \sqrt{109.5988} = 10.47$

k) $\overline{X^2} = \overline{(A + d)^2} = \overline{(A^2 + 2Ad + d^2)} = A^2 + 2A\bar{d} + \overline{d^2} = A^2 + 2Am_1' + m_2'$
$= (94)^2 + 2(94)(1.9667) + 113.4667 = 9\,319.2063$ o 9 319 a cuatro cifras significativas.

l) $\overline{X^3} = \overline{(A + d)^3} = \overline{(A^3 + 3A^2d + 3Ad^2 + d^3)} = A^3 + 3A^2\overline{d} + 3A\overline{d^2} + \overline{d^3}$
$= A^3 + 3A^2m_1' + 3Am_2' + m_3' = 915\,571.9597$ o 915 600 a cuatro cifras significativas.

COMPROBACIÓN DE CHARLIER

5.8 Ilustrar el uso de la comprobación de Charlier en los cálculos del problema 5.7.

SOLUCIÓN

Para proporcionar la comprobación deseada, a la tabla 5.3 se agregan las columnas de la tabla 5.4 (con excepción de la columna 2, que por comodidad se repite en la tabla 5.3).

En cada uno de los siguientes pares de fórmulas, los datos para la primera se toman de la tabla 5.4 y los datos para la segunda se toman de la tabla 5.2. La igualdad de los resultados en cada par proporciona la comprobación deseada.

Tabla 5.4

$u+1$	f	$f(u+1)$	$f(u+1)^2$	$f(u+1)^3$	$f(u+1)^4$
−5	4	−20	100	−500	2 500
−4	9	−36	144	−576	2 304
−3	16	−48	144	−432	1 296
−2	28	−56	112	−224	448
−1	45	−45	45	−45	45
0	66	0	0	0	0
1	85	85	85	85	85
2	72	144	288	576	1 152
3	54	162	486	1 458	4 374
4	38	152	608	2 432	9 728
5	27	135	675	3 375	16 875
6	18	108	648	3 888	23 328
7	11	77	539	3 773	26 411
8	5	40	320	2 560	20 480
9	2	18	162	1 458	13 122
	$N = \sum f = 480$	$\sum f(u+1) = 716$	$\sum f(u+1)^2 = 4\,356$	$\sum f(u+1)^3 = 17\,828$	$\sum f(u+1)^4 = 122\,148$

$\sum f(u+1) = 716$

$\sum fu + N = 236 + 480 = 716$

$\sum f(u+1)^2 = 4\,356$

$\sum fu^2 + 2\sum fu + N = 3\,404 + 2\,(236) + 480 = 4\,356$

$\sum f(u+1)^3 = 17\,828$

$\sum fu^3 + 3\sum fu^2 + 3\sum fu + N = 6\,428 + 3(3\,404) + 3(236) + 480 = 17\,828$

$\sum f(u+1)^4 = 122\,148$

$\sum fu^4 + 4\sum fu^3 + 6\sum fu^2 + 4\sum fu + N = 74\,588 + 4(6\,428) + 6(3\,404) + 4(236) + 480 = 122\,148$

CORRECCIONES DE SHEPPARD PARA LOS MOMENTOS

5.9 Emplear las correcciones de Sheppard para determinar los momentos respecto de la media para los datos: *a*) del problema 5.6 y *b*) del problema 5.7.

SOLUCIÓN

a) m_2 corregido $= m_2 - c^2/12 = 8.5275 - 3^2/12 = 7.7775$

m_4 corregido $= m_4 - \frac{1}{2}c^2 m_2 + \frac{7}{240}c^4$

$= 199.3759 - \frac{1}{2}(3)^2(8.5275) + \frac{7}{240}(3)^4$

$= 163.3646$

m_1 y m_3 no necesitan correcciones.

b) m_2 corregido $= m_2 - c^2/12 = 109.5988 - 4^2/12 = 108.2655$

m_4 corregido $= m_4 - \frac{1}{2}c^2 m_2 + \frac{7}{240}c^4$

$= 35\,627.2853 - \frac{1}{2}(4)^2(109.5988) + \frac{7}{240}(4)^4$

$= 34\,757.9616$

SESGO

5.10 Encontrar: *a*) el primer coeficiente de sesgo de Pearson y *b*) el segundo coeficiente de sesgo de Pearson para la distribución de los salarios de los 65 empleados de la empresa P&R (ver los problemas 3.44 y 4.18).

SOLUCIÓN

Media = \$279.76, mediana = \$279.06, moda = \$277.50 y desviación estándar s = \$15.60. Por lo tanto:

a) Primer coeficiente de sesgo $= \dfrac{\text{media} - \text{moda}}{s} = \dfrac{\$279.76 - \$277.50}{\$15.60} = 0.1448;$ o bien 0.14

b) Segundo coeficiente de sesgo $= \dfrac{3(\text{media} - \text{mediana})}{s} = \dfrac{3(\$279.76 - \$279.06)}{\$15.60} = 0.1346;$ o bien 0.13

Si se emplea la desviación estándar corregida [ver problema 4.21*b*)], estos coeficientes se convierten, respectivamente, en:

a) $\dfrac{\text{Media} - \text{moda}}{s \text{ corregida}} = \dfrac{\$279.76 - \$277.50}{\$15.33} = 0.1474;$ o bien 0.15

b) $\dfrac{3(\text{media} - \text{mediana})}{s \text{ corregida}} = \dfrac{3(\$279.76 - \$279.06)}{\$15.33} = 0.1370;$ o bien 0.14

Como los coeficientes son positivos, la distribución tiene sesgo positivo (es decir, a la derecha).

5.11 Encontrar los coeficientes: *a*) cuartil y *b*) percentil de sesgo para la distribución del problema 5.10 (ver problema 3.44).

SOLUCIÓN

$Q_1 = \$268.25$, $Q_2 = P_{50} = \$279.06$, $Q_3 = \$290.75$, $P_{10} = D_1 = \$258.12$, y $P_{90} = D_9 = \$301.00$. Por lo tanto:

a) Coeficiente cuartil de sesgo $= \dfrac{Q_3 - 2Q_2 + Q_1}{Q_3 - Q_1} = \dfrac{\$290.75 - 2(\$279.06) + \$268.25}{\$290.75 - \$268.25} = 0.0391$

b) Coeficiente percentil de sesgo $= \dfrac{P_{90} - 2P_{50} + P_{10}}{P_{90} - P_{10}} = \dfrac{\$301.00 - 2(\$279.06) + \$258.12}{\$301.00 - \$258.12} = 0.0233$

5.12 Encontrar el coeficiente momento de sesgo, a_3, *a*) en la distribución de las estaturas de los estudiantes de la universidad XYZ (ver problema 5.6) y *b*) en los CI de los niños de primaria (ver problema 5.7).

SOLUCIÓN

a) $m_2 = s^2 = 8.5275$ y $m_3 = -2.6932$. Por lo tanto:

$$a_3 = \frac{m_3}{s^3} = \frac{m_3}{(\sqrt{m_2})^3} = \frac{-2.6932}{(\sqrt{8.5275})^3} = -0.1081 \qquad \text{o bien} \qquad -0.11$$

Si se emplea la corrección de Sheppard para datos agrupados [ver problema 5.9*a*)], se tiene

$$a_3 \text{ corregido} = \frac{m_3}{(\sqrt{m_2 \text{ corregido}})^3} = \frac{-2.6932}{(\sqrt{7.7775})^3} = -0.1242 \qquad \text{o bien} \qquad -0.12$$

b) $$a_3 = \frac{m_3}{s^3} = \frac{m_3}{(\sqrt{m_2})^3} = \frac{202.8158}{(\sqrt{109.5988})^3} = 0.1768 \qquad \text{o bien} \qquad 0.18$$

Si se emplea la corrección de Sheppard para datos agrupados [ver problema 5.9*b*)], se tiene

$$a_3 \text{ corregido} = \frac{m_3}{(\sqrt{m_2 \text{ corregido}})^3} = \frac{202.8158}{(\sqrt{108.2655})^3} = 0.1800 \qquad \text{o} \qquad 0.18$$

Obsérvese que ambas distribuciones son moderadamente sesgadas, la distribución *a*) a la izquierda (negativamente) y la distribución *b*) a la derecha (positivamente). La distribución *b*) es más sesgada que la distribución *a*); es decir, *a*) es más simétrica que *b*), lo que es evidente dado que el valor numérico (o el valor absoluto) del coeficiente de sesgo para *b*) es mayor que el valor del coeficiente de sesgo para *a*).

CURTOSIS

5.13 Encontrar el coeficiente momento de curtosis, a_4, de los datos: *a*) del problema 5.6 y *b*) del problema 5.7.

SOLUCIÓN

a) $$a_4 = \frac{m_4}{s^4} = \frac{m_4}{m_2^2} = \frac{199.3759}{(8.5275)^2} = 2.7418 \qquad \text{o bien} \qquad 2.74$$

Si se emplean las correcciones de Sheppard [ver problema 5.9*a*)], entonces

$$a_4 \text{ corregido} = \frac{m_4 \text{ corregido}}{(m_2 \text{ corregido})^2} = \frac{163.36346}{(7.7775)^5} = 2.7007 \qquad \text{o bien} \qquad 2.70$$

b) $$a_4 = \frac{m_4}{s^4} = \frac{m_4}{m_2^2} = \frac{35\,627.2853}{(109.5988)^2} = 2.9660 \qquad \text{o bien} \qquad 2.97$$

Si se emplean las correcciones de Sheppard [ver problema 5.9*b*)], entonces

$$a_4 \text{ corregido} = \frac{m_4 \text{ corregido}}{(m_2 \text{ corregido})^2} = \frac{34\,757.9616}{(108.2655)^2} = 2.9653 \qquad \text{o bien} \qquad 2.97$$

Como en una distribución normal $a_4 = 3$, se sigue que ambas distribuciones, *a*) y *b*), son *platicúrticas* con respecto a la distribución normal (es decir, menos puntiagudas que la distribución normal).

En lo que se refiere a qué tan puntiagudas son, la distribución *b*) se aproxima a la distribución normal más que la distribución *a*). Sin embargo, de acuerdo con el problema 5.12, la distribución *a*) es más simétrica que la distribución *b*), de manera que en lo que se refiere a la simetría, *a*) se aproxima más a una distribución normal que *b*).

CÁLCULO DEL SESGO Y DE LA CURTOSIS EMPLEANDO SOFTWARE

5.14 Algunas veces las puntuaciones de un examen no siguen una distribución normal, aunque generalmente lo hacen. Algunas veces se observa que los estudiantes obtienen puntuaciones altas o bajas y que hay pocas puntuaciones intermedias. La distribución que se muestra en la figura 5-4 es una de estas distribuciones. Este tipo de distribuciones se conocen como distribuciones en forma de U. Empleando EXCEL, encontrar la media, la desviación estándar, el sesgo y la curtosis de estos datos.

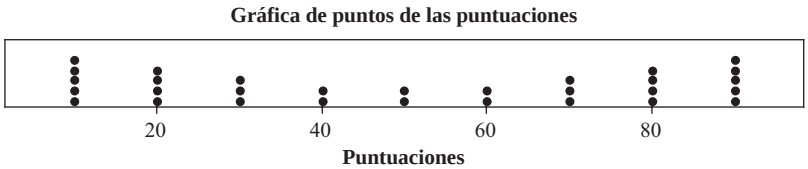


Figura 5-4 MINITAB, gráfica de puntos con datos que siguen una distribución en forma de U.

SOLUCIÓN

En una hoja de cálculo de EXCEL se ingresan los datos en A1:A30. El comando "=**AVERAGE(A1:A30)**" da como resultado 50. El comando "=**STDEV(A1:A30)**" da como resultado 29.94. El comando " =**SKEW(A1:A30)**" da como resultado 0. El comando " =**KURT(A1:A30)**" da como resultado –1.59.

PROBLEMAS SUPLEMENTARIOS

MOMENTOS

5.15 Encontrar el: *a*) primero, *b*) segundo, *c*) tercero y *d*) cuarto momentos del conjunto 4, 7, 5, 9, 8, 3, 6.

5.16 Encontrar el: *a*) primero, *b*) segundo, *c*) tercero y *d*) cuarto momentos respecto de la media para el conjunto de datos del problema 5.15.

5.17 Encontrar el: *a*) primero, *b*) segundo, *c*) tercero y *d*) cuarto momentos respecto del número 7 para el conjunto de datos del problema 5.15.

5.18 Empleando los resultados de los problemas 5.15 y 5.17, verificar las siguientes relaciones entre los momentos: *a*) $m_2 = m_2' - m_1'^2$, *b*) $m_3 = m_3' - 3m_1'm_2' + 2m_1'^3$ y *c*) $m_4 = m_4' - 4m_1'm_3' + 6m_1'^2m_2' - 3m_1'^4$.

5.19 En el conjunto de números de la progresión aritmética 2, 5, 8, 11, 14, 17, encontrar los primeros cuatro momentos respecto de la media.

5.20 Probar que: *a*) $m_2' = m_2 + h^2$, *b*) $m_3' = m_3 + 3hm_2 + h^3$ y *c*) $m_4' = m_4 + 4hm_3 + 6h^2m_2 + h^4$, donde $h = m_1'$.

5.21 Si el primer momento respecto del número 2 es igual a 5, ¿cuál es la media?

5.22 Si los primeros cuatro momentos respecto del número 3 son –2, 10, –25 y 50, determinar los momentos correspondientes: *a*) respecto de la media, *b*) respecto del número 5 y *c*) respecto del cero.

5.23 Para los números 0, 0, 0, 1, 1, 1, 1 y 1, encontrar los primeros cuatro momentos respecto de la media.

5.24 *a*) Probar que $m_5 = m_5' - 5m_1'm_4' + 10m_1'^2m_3' - 10m_1'^3m_2' + 4m_1'^5$.

b) Deducir una fórmula similar para m_6.

5.25 De un total de N números, la fracción p son unos y la fracción $q = 1 - p$ son ceros. Encontrar: *a*) m_1, *b*) m_2, *c*) m_3 y *d*) m_4 para este conjunto de números. Comparar con el problema 5.23.

5.26 Probar que los primeros cuatro momentos respecto de la media en la progresión geométrica a, $a + d$, $a + 2d, \ldots, a + (n-1)d$ son $m_1 = 0$, $m_2 = \frac{1}{12}(n^2 - 1)d^2$, $m_3 = 0$ y $m_4 = \frac{1}{240}(n^2 - 1)(3n^2 - 7)d^4$. Comparar con el problema 5.19 (ver también el problema 4.69). [*Sugerencia*: $1^4 + 2^4 + 3^4 + \cdots + (n-1)^4 = \frac{1}{30}n(n-1)(2n-1)(3n^2 - 3n - 1)$.]

MOMENTOS PARA DATOS AGRUPADOS

5.27 Dada la distribución de la tabla 5.5, calcular los cuatro momentos respecto de la media.

Tabla 5.5

X	f
12	1
14	4
16	6
18	10
20	7
22	2
	Total 30

5.28 Ilustrar el uso de la comprobación de Charlier para los cálculos del problema 5.27.

5.29 Aplicar las correcciones de Sheppard a los momentos obtenidos en el problema 5.27.

5.30 Dada la distribución del problema 3.59, calcular los primeros cuatro momentos respecto de la media: *a*) sin correcciones de Sheppard y *b*) con correcciones de Sheppard.

5.31 Dada la distribución del problema 3.62, encontrar *a*) m_1, *b*) m_2, *c*) m_3, *d*) m_4, *e*) $\bar{X}$, *f*) s, *g*) $\overline{X^2}$, *h*) $\overline{X^3}$, *i*) $\overline{X^4}$ y *j*) $\overline{(X+1)^3}$.

SESGO

5.32 Encontrar el coeficiente momento de sesgo, a_3, para la distribución del problema 5.27: *a*) sin correcciones y *b*) con correcciones de Sheppard.

5.33 Encontrar el coeficiente momento de sesgo, a_3, para la distribución del problema 3.59 (ver problema 5.30).

5.34 Los segundos momentos respecto de la media de dos distribuciones son 9 y 16, en tanto que los terceros momentos respecto de la media son –8.1 y –12.8, respectivamente. ¿Qué distribución es más sesgada a la izquierda?

5.35 Encontrar los coeficientes de Pearson: *a*) primero y *b*) segundo para la distribución del problema 3.59 y explicar cualquier diferencia que se encuentre.

5.36 Encontrar los coeficientes de sesgo: *a*) cuartil y *b*) percentil para la distribución del problema 3.59. Comparar sus resultados con los del problema 5.35 y explicar.

5.37 En la tabla 5.6 se dan tres distribuciones diferentes de la variable X. Las frecuencias de cada una de las tres distribuciones están dadas por f_1, f_2 y f_3. Encontrar el primero y el segundo coeficientes de sesgo de Pearson de las tres distribuciones. Para calcular los coeficientes, emplear la desviación estándar corregida.

Tabla 5.6

X	f_1	f_2	f_3
0	10	1	1
1	5	2	2
2	2	14	2
3	2	2	5
4	1	1	10

CURTOSIS

5.38 Encontrar el coeficiente momento de curtosis, a_4, para la distribución del problema 5.27: *a*) sin correcciones y *b*) con correcciones de Sheppard.

5.39 Encontrar el coeficiente momento de curtosis, a_4, de la distribución del problema 3.59: *a*) sin correcciones y *b*) con correcciones de Sheppard (ver problema 5.30).

5.40 Los cuartos momentos respecto de la media de las dos distribuciones del problema 5.34 son 230 y 780, respectivamente. ¿Qué distribución se aproxima más a una distribución normal desde el punto de vista: *a*) de aplastamiento y *b*) del sesgo?

5.41 ¿Cuál de las distribuciones del problema 5.40 es: *a*) leptocúrtica, *b*) mesocúrtica y *c*) platicúrtica?

5.42 La desviación estándar de una distribución simétrica es 5. ¿Cuál deberá ser el valor del cuarto momento respecto de la media para que la distribución sea: *a*) leptocúrtica, *b*) mesocúrtica y *c*) platicúrtica?

5.43 *a*) Calcular el coeficiente percentil de curtosis, κ, de la distribución del problema 3.59.
b) Comparar su resultado con el valor teórico 0.263 para una distribución normal, e interpretar.
c) ¿Cómo se puede reconciliar este resultado con el del problema 5.39?

CÁLCULO DEL SESGO Y DE LA CURTOSIS EMPLEANDO SOFTWARE

5.44 Los datos de la figura 5-5 muestran un pronunciado pico en 50. Esto debe mostrarse en la medida de la curtosis de los datos. Empleando EXCEL, mostrar que el sesgo es prácticamente cero y que la curtosis es 2.0134.

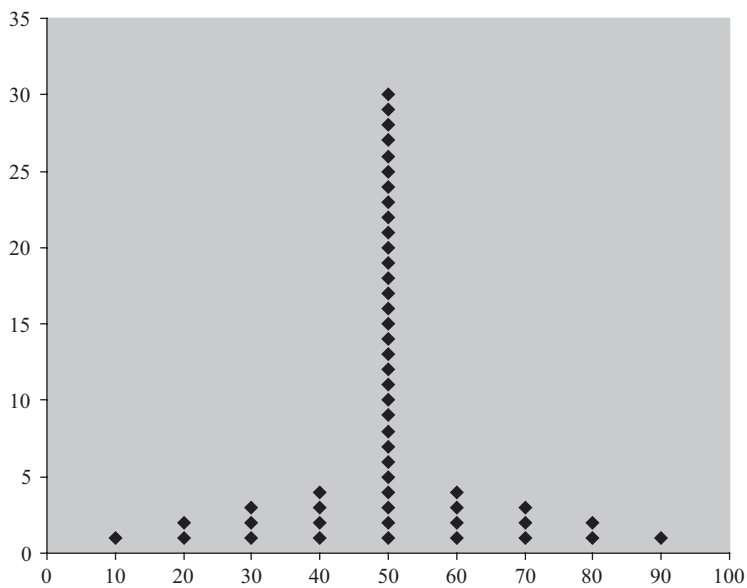


Figura 5-5 EXCEL, gráfica de los datos de puntuaciones de examen.