FADENA | Universidad de la Defensa Nacional

PROBALIDAD Y ESTADÍSTICA

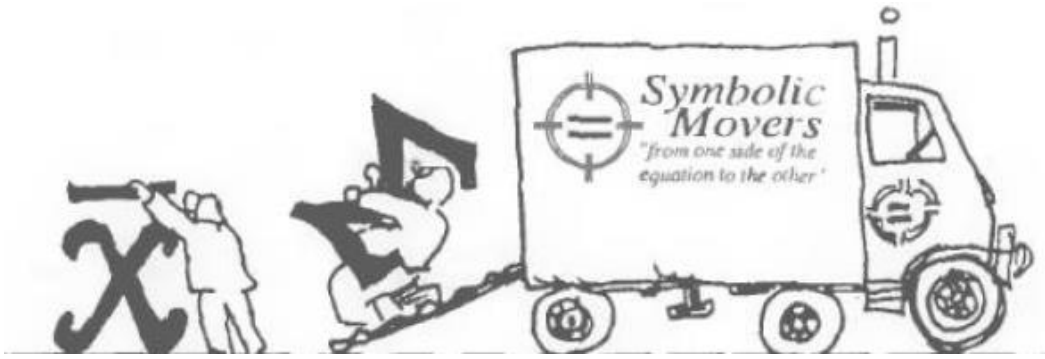
Unidad 3

Prof. Tit.: Dra. Romina Caballero

Objetivos

- Desarrollar habilidades para analizar e interpretar datos utilizando técnicas de **Estadística descriptiva**

- Conocer las propiedades y características de las **medidas de tendencia central**.
- Aprender a calcular e interpretar **medidas de posición no centrales**.
- Calcular y comprender las **medidas de dispersión**
- Entender **las medidas de forma**



Material de lectura: Unidad 3

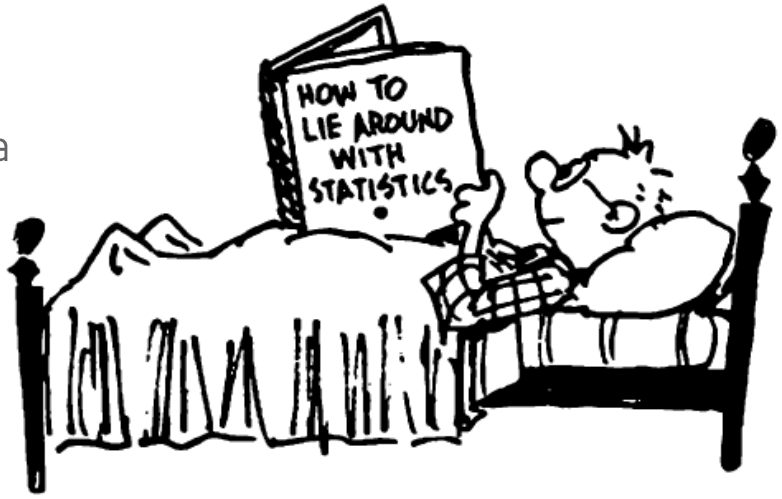
Guía de lectura de material bibliográfico
Clase 4- Unidad III

Bibliografía
Obligatoria

- Bologna, E. (2018). Métodos Estadísticos de Investigación (Cap.2, Distribuciones de frecuencias, pp. 37-50). Editorial Brujas.
- Bologna, E. (2018). Métodos Estadísticos de Investigación (Cap.3, La expresión resumida de la información, pp.51-88). Editorial Brujas.

Para ejercitación:

- Spiegel, M. R., & Stephens, L. J. (2009). Estadística (Cap. 3, Media, mediana, moda y otras medidas de tendencia central, pp. 61-67). Mc Graw-Hill.
- Spiegel, M. R., & Stephens, L. J. (2009). Estadística (Cap. 4, La desviación típica y otras medidas de dispersión, pp. 95-101). Mc Graw-Hill.
- Spiegel, M. R., & Stephens, L. J. (2009). Estadística (Cap. 5, Momentos, sesgos y curtosis, pp. 123-126). Mc Graw-Hill.



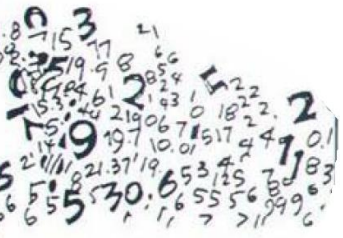
FADENA

4.1 REPASO: DISTRIBUCIÓN DE FRECUENCIAS.

4.1.1 Datos en agrupación simple
4.1.2. Datos en agrupación de intervalos
4.1.3. Frecuencias absolutas, relativas, porcentuales
4.1.4. Intervalos de clase
4.1.5. Marca de clase
4.1.6. Amplitud del intervalo

Universidad de la Defensa Nacional

DATOS



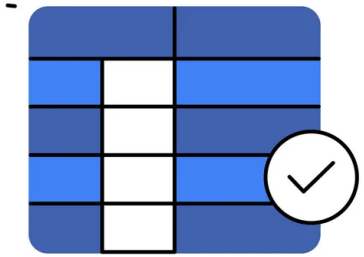
MATRIZ de DATOS

	X0	X2	X3	X4	Xn
id1	1	3	120	6	2025
id2	2	3	60	6	2024
id3	1	5	68	4	2024
id4	1	5	43	2	2024
...	2	4	65	6	2023
idn	3	1	24	7	2025

VARIABLES

Frecuencias

TABULACIÓN ESTADÍSTICA



Frequency Table

CUALITATIVAS → *Clases/categorías* → *nº de datos x clase*

- Nominales
- Ordinales

f_i $\sum_{i=1}^{k} f_i$ = n

fi'_i $\sum_{i=1}^{k} f_i' = 1$

$fi'_i\%$ $\sum_{i=1}^{k} f_i'\% = 100$

CUANTITATIVAS

- Discretas
- Continuas

Fi $\sum_{i=1}^{k} F_i$ = n

Fi' $\sum_{i=1}^{k} F_i'\% = 1$

$Fi'\%$ $\sum_{i=1}^{k} F_i' = 100$

≠criterios agrupamiento

Intervalos de clase

Variables discretas: resumen de símbolos, definiciones y fórmulas

Símbolo / Fórmula	*Significado / Descripción / Aclaración*
x	**Variable** que se analiza. Valor observado de una característica.
$i = \{1 - k\}$	Subíndice que expresa el **lugar u orden de cada valor diferente** de una variable. Determina el orden de ubicación de una característica agrupada desde 1 hasta k.
$xi = \{x_{Mín} - x_{Máx}\}$	**Valor i-ésimo de la variable** una vez ordenados e identificados los diferentes. Los valores mínimo y máximo son xMín y xMáx.
$x_{Mín} = x_1$	**Valor Mínimo** que toma la variable.
$x_{Máx} = x_k$	**Valor Máximo** que toma la variable
N	**Cantidad Total de Unidades** Estadísticas consideradas **en una Población**.
n	**Cantidad Total de Unidades consideradas en una Muestra**.
k	**Cantidad de resultados diferentes que toma la variable**
$f_i = f(x)$	**Frecuencia o frecuencia absoluta** de un valor observado. *Constituye la **cantidad de veces que se presenta o repite el valor xi de la variable**.*
$F_i = F(x)$ $(F_1 = f_1; F_k = n$	**Frecuencia absoluta acumulada** de un valor observado. *Constituye la **cantidad de casos que se tienen hasta el valor xi de la variable**.*
$fi' = fi'(x) = f_i / n$	**Frecuencia relativa** de un valor observado. *Constituye la **proporción de veces que se presenta** o repite **el valor xi de la variable**. Es la frecuencia en relación al total de unidades consideradas*
$Fi = F'(x) = F_i / n$ $(F_1 = f_1; F_k = 1)$	**Frecuencia relativa acumulada** de un valor observado. Constituye la proporción de casos que se tienen hasta el valor xi de la variable.

Variables Continuas: resumen de símbolos, definiciones y fórmulas

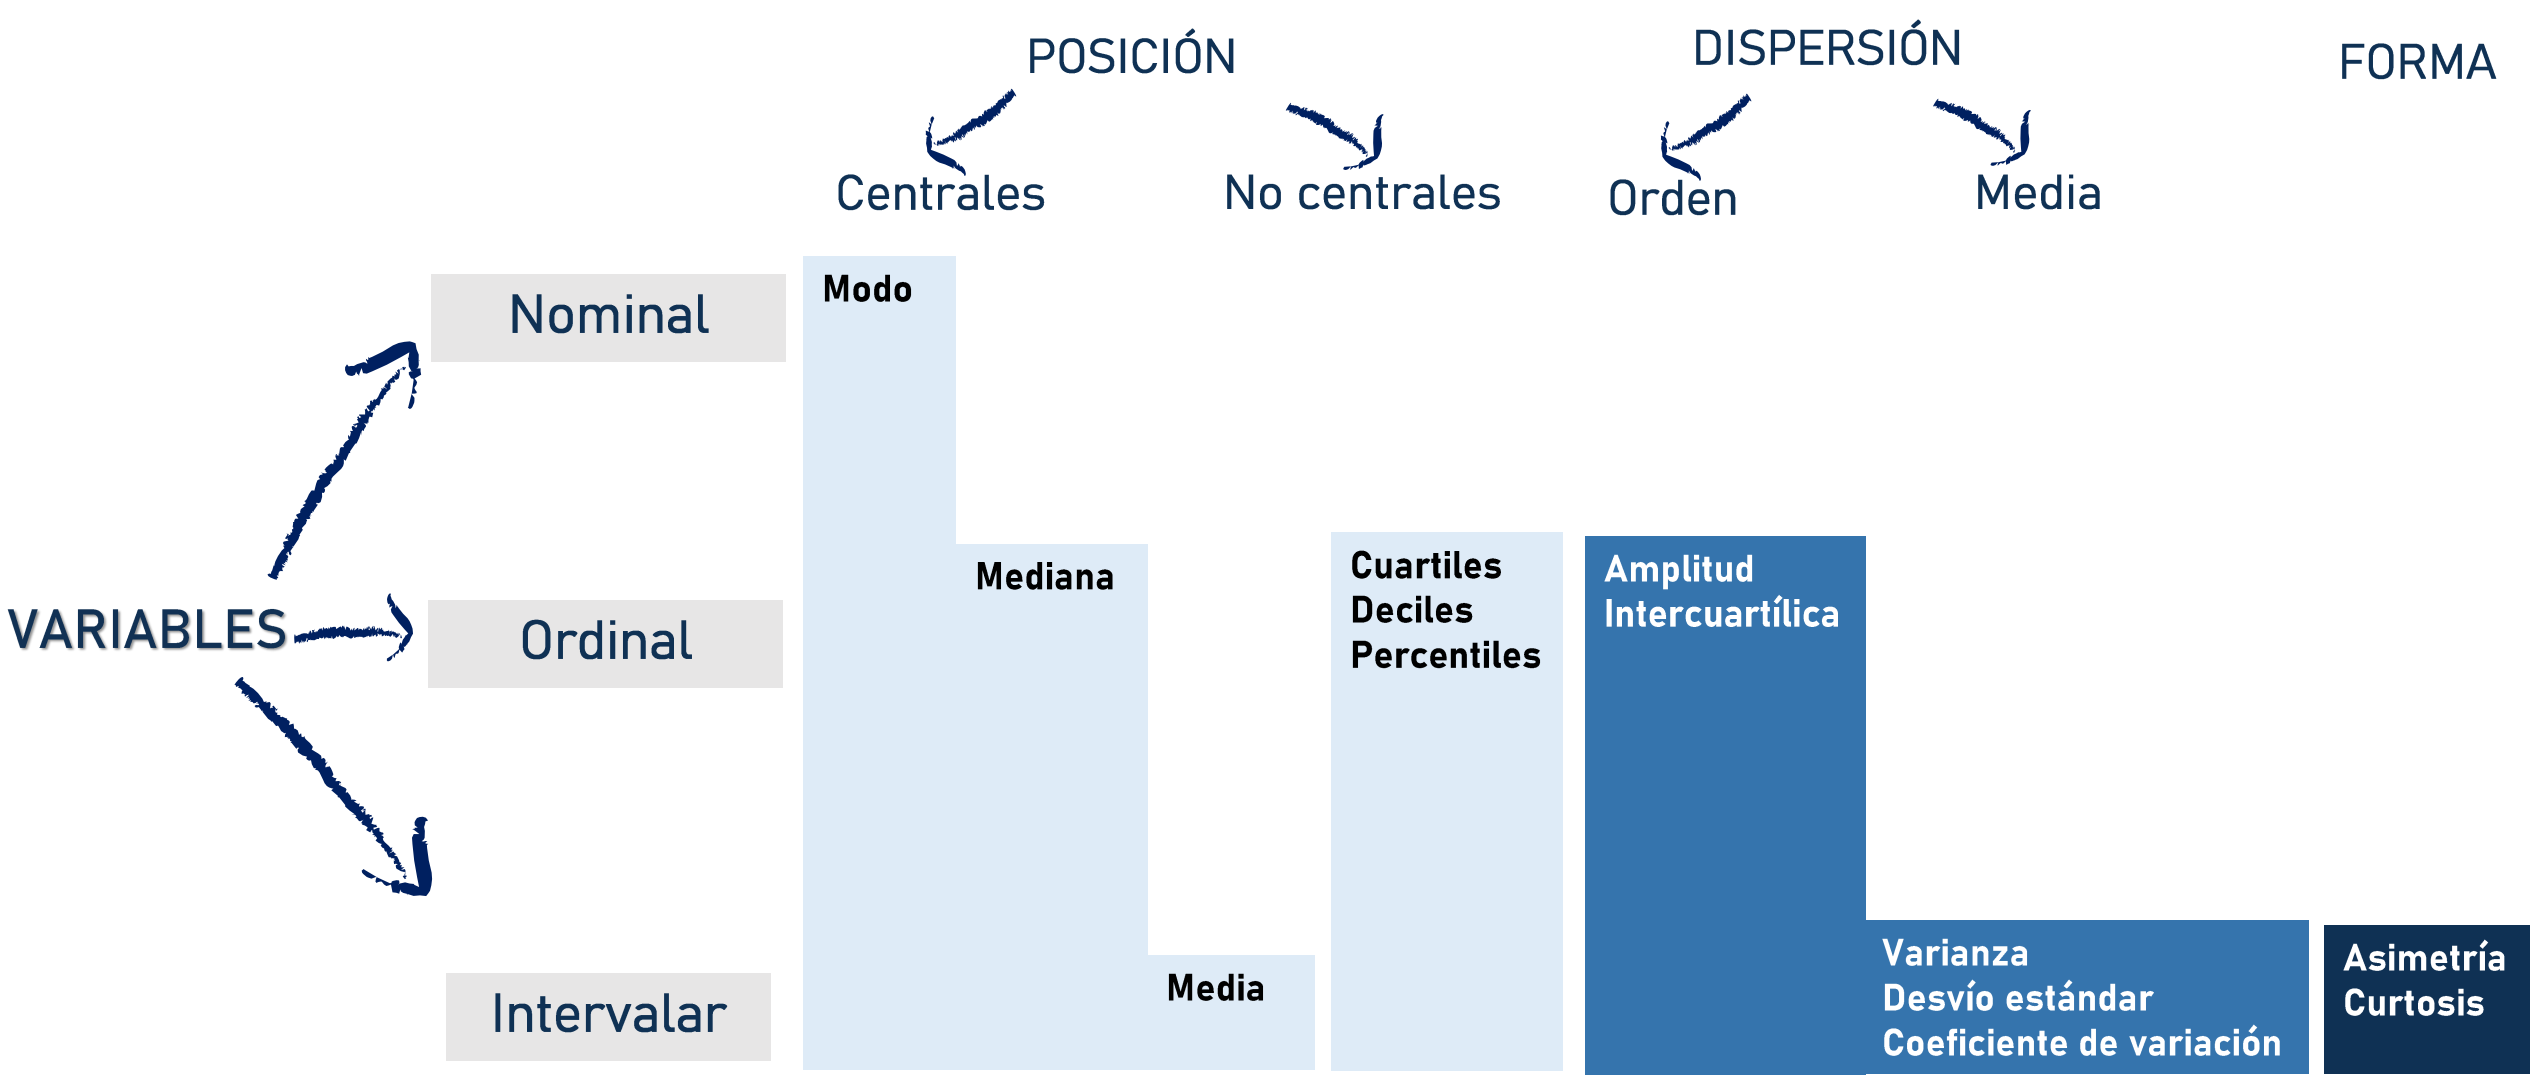
Símbolo / Fórmula	*Significado / Descripción / Aclaración*
$i = \{1 - k\}$	Subíndice que expresa **el lugar u orden de cada intervalo** en los que se agrupan los valores de la variable. Determina el orden de ubicación de cada intervalo desde 1 hasta k
x_i	**Punto medio del intervalo** i-ésimo en los que se agrupa la variable. Se lo adopta como el valor representativo del intervalo. En ciertas técnicas se lo adopta directamente como el valor de la variable.
K	**Cantidad de intervalos** en que se agrupa la variable
Li_i	**Límite inferior del intervalo** i-ésimo.
Ls_i	**Límite superior del intervalo** i-ésimo.
$a_i = Li_i - Ls_i$	**Amplitud del intervalo** i-ésimo. Diferencia entre el límite superior y el inferior. En muchos casos se simboliza con hi.
$f_i = f(x)$	**Frecuencia o frecuencia absoluta del intervalo i-ésimo.** *Constituye la cantidad de casos que caen en el intervalo iésimo construido*
$F_i = F(x)$ $(F_1 = f_1; F_k = n$	**Frecuencia absoluta acumulada hasta el límite superior del intervalo i-ésimo.** *Constituye la cantidad de casos que se tienen hasta el valor* Ls_i
$fi' = fi'(x) = f_i / n$	**Frecuencia relativa del intervalo i-ésimo.** *Constituye la proporción de casos que caen en el intervalo i-ésimo construido. Es la frecuencia en relación al total de unidades consideradas.*
$Fi = F'(x) = F_i / n$ $(F_1 = f_1; F_k = 1)$	**Frecuencia relativa acumulada hasta el valor** Ls_i (límite superior del intervalo i-ésimo). *Constituye la proporción de casos que se tienen hasta el valor* Ls_i

FADENA

MEDIDAS DESCRIPTIVAS

Universidad de la Defensa Nacional

MEDIDAS DESCRIPTIVAS



FADENA

4.2.MEDIDAS DE POSICIÓN: MEDIDAS DE CENTRALIZACIÓN

4.2.1 Moda

4.2.3 Mediana

4.2.3 Media

4.2.4 Otras

Universidad de la Defensa Nacional

MODO (M_0)



{Valor o categoría de la variable observado con más frecuencia}

Si los datos están agrupados en una distribución de frecuencias se aplica la Fórmula:

$$M_0 = L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2}\right) \cdot c$$

MODO (M_0)

17	21	42	35	21	16	17	36	21	25

Mo=21

26	41	35	28	34	27	32	29	21	40

No hay Mo. Distribución amodal

46	27	18	35	27	19	18	36	21	51

Hay dos Mo. Distribución bimodal:
Mo=18
Mo=27

MODO (M_o)

Tipo de ataque *Xi*	*fi*
Phishing	6
Malware	4
DDoS	3
Ransomware	3
Intrusión	2
Total	18

Mo= phishing

Severidad Xi	*fi*
Baja	4
Media	6
Alta	6
Crítica	3
Total	20

Mo= media y Mo= alta

MODO (M_0): ejemplo para datos agrupados

Consecuencias en gastos (USD) de tiempo sin operar por ciberataque en empresa de entretenimiento

Costo (USD) del tiempo sin operar	*fi*	*xi*	f.xi
300-499	5	399,5	1997,5
500-699	10	599,5	5995
700-899	17	799,5	13591,5
900-1099	9	999,5	8995,5
1100-1299	7	1199,5	8396,5
1300-1499	5	1399,5	6997,5
1500-1699	2	1599,5	3199
Total	55	---	—

$$M_0 = L_i + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2}\right) \cdot c$$

$$M_0 = 699{,}5 + \left(\frac{7}{7+8}\right) \cdot 200$$

$$M_0 = 699{,}5 + 93{,}33$$

$$M_0 = 792{,}83\ USD$$

El valor 792,83 USD es el valor que más se repite por no operar por un ciberataque

Mediana (M_e o M_{dn})



{Valor de la variable que deja por debajo a la mitad de las observaciones} = P_{50}

Si los datos están agrupados en una distribución de frecuencias se aplica la Fórmula:

$$M_e = L_i + \left(\frac{\frac{N}{2} \cdot (\Sigma f)_{na}}{f_{na}} \right) \cdot c$$

Mediana (M_e o M_{dn})

Ejemplo:

1. Impar

X_i	21	17	19	18	17	23	20	16	25

Ordenados

X_i	16	17	17	18	**19**	20	21	23	25

2. Par

Me=19

X_i	35	28	42	46	44	39	27	35	21	49

X_i	21	27	28	35	35	39	42	44	46	49

$$Me=\frac{35+39}{2}=37$$

FADENA

Universidad de la Defensa Nacional

MEDIANA (M_e): ejemplo para datos agrupados

Consecuencias en gastos (USD) de tiempo sin operar por ciberataque en empresa de entretenimiento

Costo (USD) del tiempo sin operar	*fi*
300-499	5
500-699	10
700-899	17
900-1099	9
1100-1299	7
1300-1499	5
1500-1699	2
Total	55

$$M_e = L_i + \left(\frac{\frac{N}{2} \cdot (\Sigma f)_{na}}{f_{na}} \right) \cdot c$$

$$M_e = 699{,}5_i + \left(\frac{\frac{55}{2} \cdot 15}{17} \right) \cdot 200$$

$$M_e = 699{,}5 + \left(\frac{12{,}5}{17} \right) \cdot 200$$

$$M_e = 699{,}5 + 147{,}06$$

$$M_e = 846{,}56\ USD$$

MEDIA ARITMETICA ($\bar{x}$)



{valor de la variable obtenido sumando todas las observaciones multiplicadas por su frecuencia absoluta y dividiendo el resultado en el número total de casos.}

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

x_i es la i-ésima observación
n es el número de observaciones.

Si los datos están agrupados en una distribución de frecuencias se aplica la Fórmula:

$$\bar{x} = \frac{\Sigma_{f_i} \cdot x_i}{\sum fi}$$

MEDIA O Promedio ($\bar{x}$)

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

x_i es la i-ésima observación
n es el número de observaciones.

Ejemplo:

21 17 19 18 17 23 20 16 25

Suma

$\bar{X}$=

21 + 17 + 19 + 18 + 17 + 23 + 20 + 16 + 25

$\bar{X}$= 176/9=19,55

FADENA

Universidad de la Defensa Nacional

MEDIA($\bar{x}$): ejemplo para datos agrupados

Consecuencias en gastos (USD) de tiempo sin operar por ciberataque en empresa de entretenimiento

Costo (USD) del tiempo sin operar	*fi*	*xi*	f.xi
300-499	5	399,5	1997,5
500-699	10	599,5	5995
700-899	17	799,5	13591,5
900-1099	9	999,5	8995,5
1100-1299	7	1199,5	8396,5
1300-1499	5	1399,5	6997,5
1500-1699	2	1599,5	3199
Total	55	---	—

$$\Sigma_{f_i} \cdot x_i = 49172{,}55$$

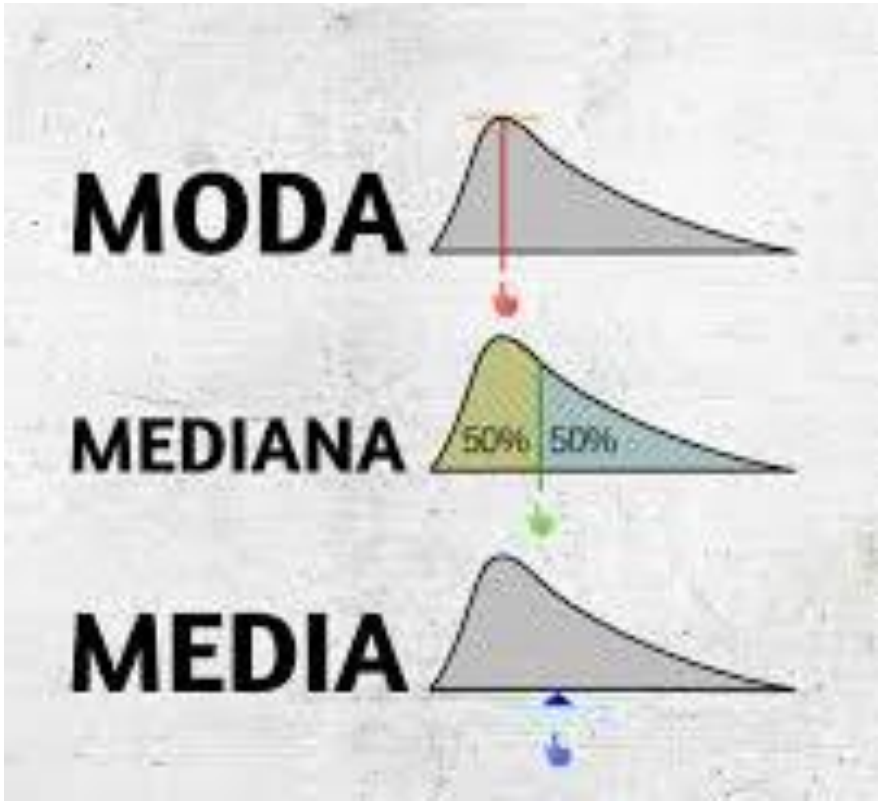
$$\bar{x} = \frac{\Sigma_{f_i} \cdot x_i}{\sum fi}$$

$$\bar{x} = \frac{49172{,}55}{55}$$

$$\bar{x} = 894{,}05$$

El costo promedio de no operar por un ciberataque es de 894,05 USD

Relación empírica entre Media, Mediana y Modo



Si una Distribución de frecuencias es UNIMODAL y aproximadamente normal, se puede aplicar la relación de Pearson para estimar una medida de tendencia central, conociendo a las otras.

$$M_0 = 3M_a - 2\bar{x}$$

FADENA

Universidad de la Defensa Nacional

Otras medidas

PROPORCIÓN (p)

{frecuencia relativa correspondiente a una categoría en particular.}

TASA

{frecuencia relativa de un fenómeno en referencia a una población total, en un periodo determinado}

RAZÓN

{cociente calculado entre dos conjuntos que no tienen elementos en común}

FADENA

4.3. MEDIDAS DE POSICIÓN: NO CENTRALES

4.3.1. Percentiles
4.3.2. Cuartiles
4.3.3. Deciles

Universidad de la Defensa Nacional

Medidas de posición no centrales: PERCENTILES

Pr

Es el valor de la variable que deja el r por ciento de los casos por debajo de él y (1-r) por ciento de los casos por encima

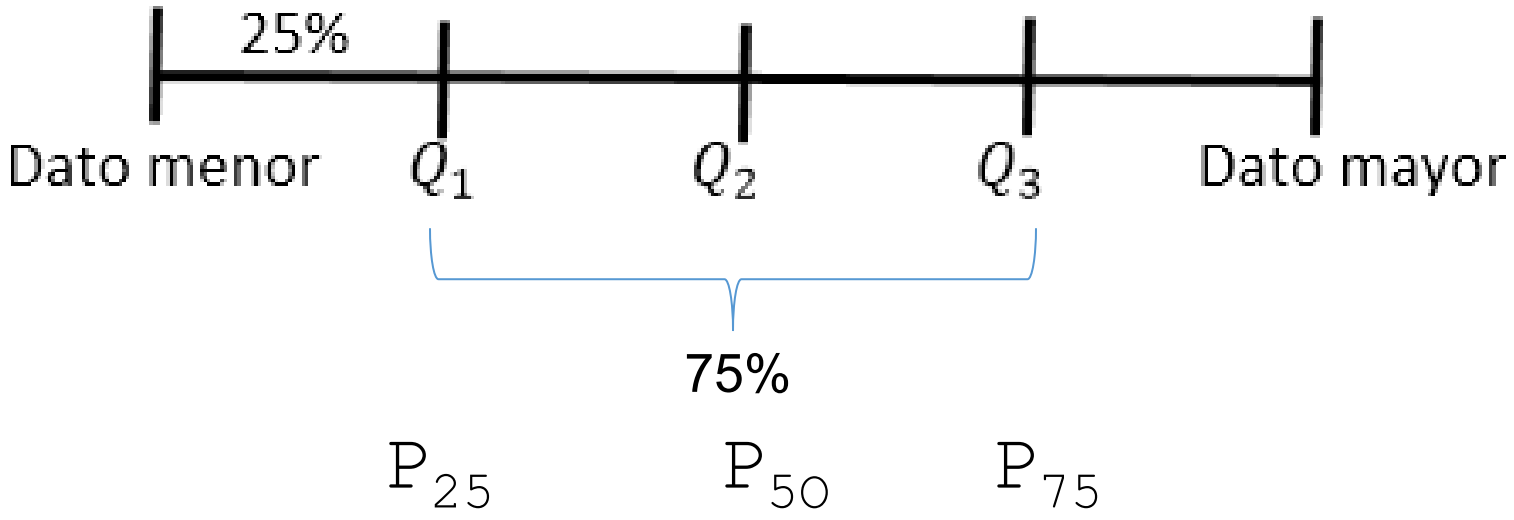
$$P_1,\ P_2,\ P_3 \ \ldots\ P_{99}$$

Ejemplos: centiles, deciles, cuartiles, quintiles, etc.

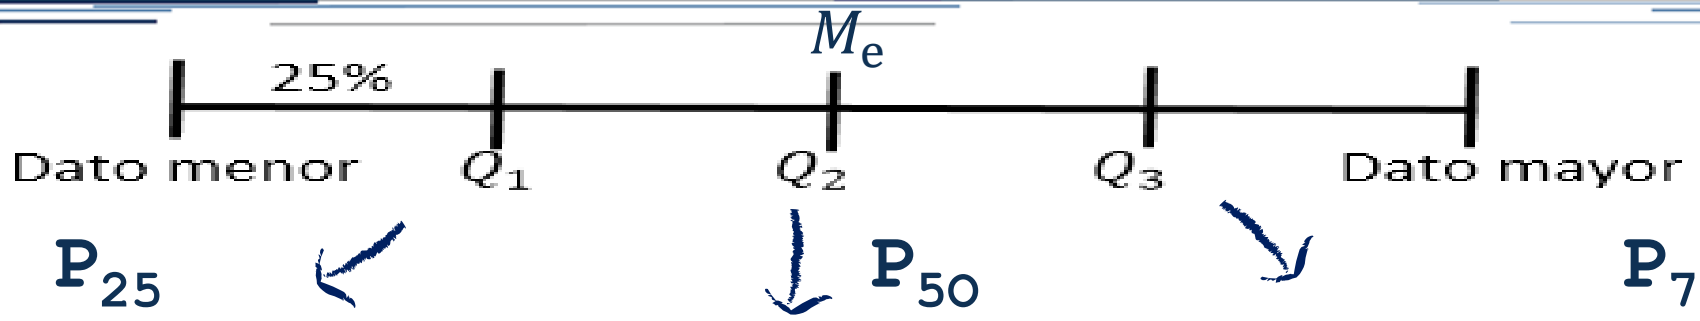
Los más utilizados son los CUARTILES

Medidas de posición no centrales: CUARTILES

Son tres valores de la variable que dividen al conjunto ordenado en cuatro partes de igual cantidad de datos



Medidas de posición no centrales: CUARTILES



P_{25}

Valor de la variable o promedio de valores de la variable que supera a lo sumo al 25% de las observaciones

$$Q_1 = L_i + \left(\frac{\frac{N}{4} \cdot (\Sigma f)_{Q1}}{f_{Q1}}\right) \cdot c$$

P_{50}

Valor de la variable o promedio de valores de la variable que supera a lo sumo al 50% de las observaciones

$$M_e = L_i + \left(\frac{\frac{N}{2} \cdot (\Sigma f)_{na}}{f_{na}}\right) \cdot c$$

P_{75}

Valor de la variable o promedio de valores de la variable que supera a lo sumo al 75% de las observaciones

$$Q_3 = L_i + \left(\frac{\frac{N}{4} \cdot 3 - (\Sigma f)_{Q3}}{f_{Q3}}\right) \cdot c$$

PERCENTILES: EJEMPLOS

Consecuencias en gastos (USD) de tiempo sin operar por ciberataque en empresa de entretenimiento

Costo (USD) del tiempo sin operar	*fi*
300-499	5
500-699	10
700-899	17
900-1099	9
1100-1299	7
1300-1499	5
1500-1699	2
Total	55

$$Q_1 = L_i + \left(\frac{\frac{N}{4} \cdot (\Sigma f)_{Q1}}{f_{Q1}} \right) \cdot c$$

$$Q1 = 674{,}5 USD$$

$$M_e = L_i + \left(\frac{\frac{N}{2} \cdot (\Sigma f)_{na}}{f_{na}} \right) \cdot c$$

$$M_e = 846{,}56\ USD$$

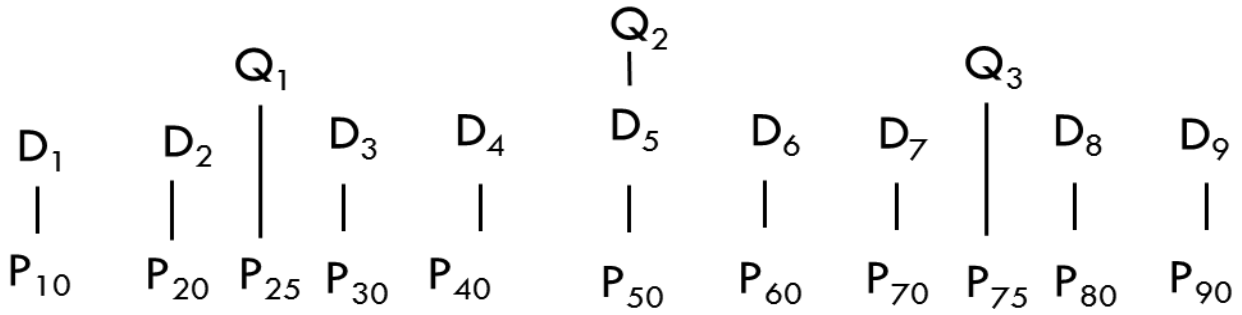
$$Q_3 = L_i + \left(\frac{\frac{N}{4} \cdot 3 - (\Sigma f)_{Q3}}{f_{Q3}} \right) \cdot c$$

$$Q3 = 1106{,}64 USD$$

Medidas de posición no centrales: DECILES

Dividen al conjunto ordenado en diez partes de igual cantidad de datos

Equivalencias



RANGO PERCENTILAR

*Indica la posición relativa de un sujeto según el **porcentaje de las puntuaciones** del grupo de pertenencia **que se encuentran debajo de su puntuación**.*

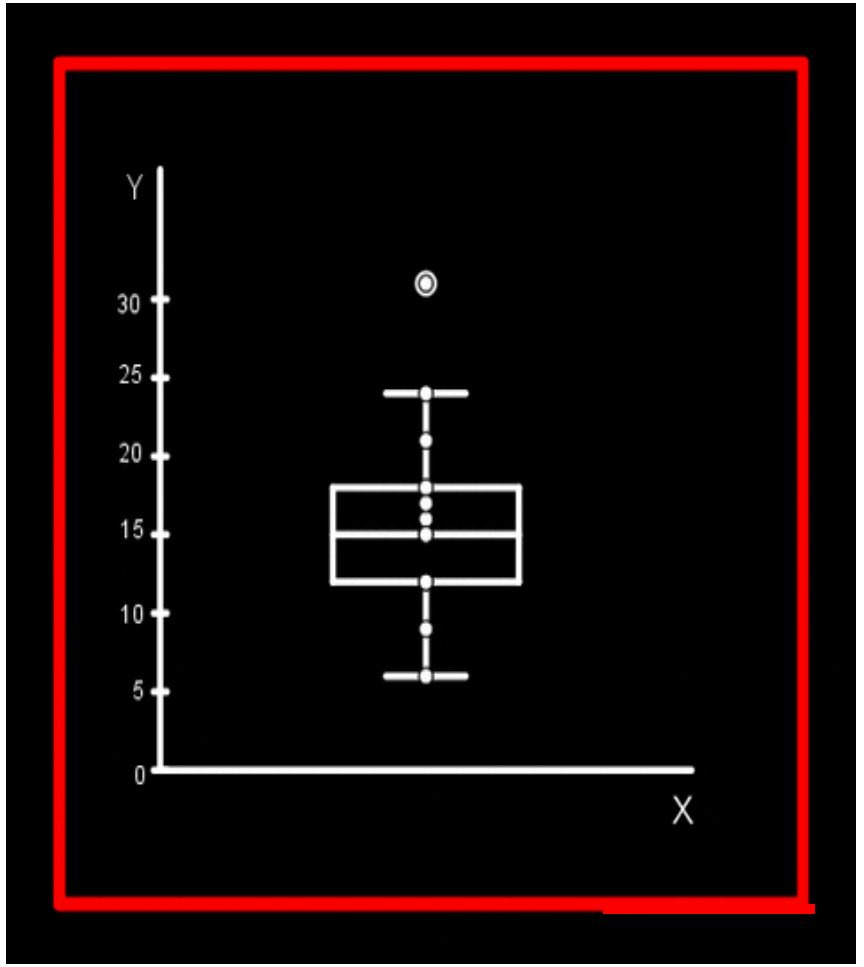
Ejemplo:

Un usuario con rango percentilar 95 es el que obtuvo una puntuación (intentos fallidos de login) que supera al 95% de las puntuaciones de otros usuarios y que es superado por el 5% de los mismos.

Comportamiento muy poco frecuente

BOX PLOT en Estadística Descriptiva

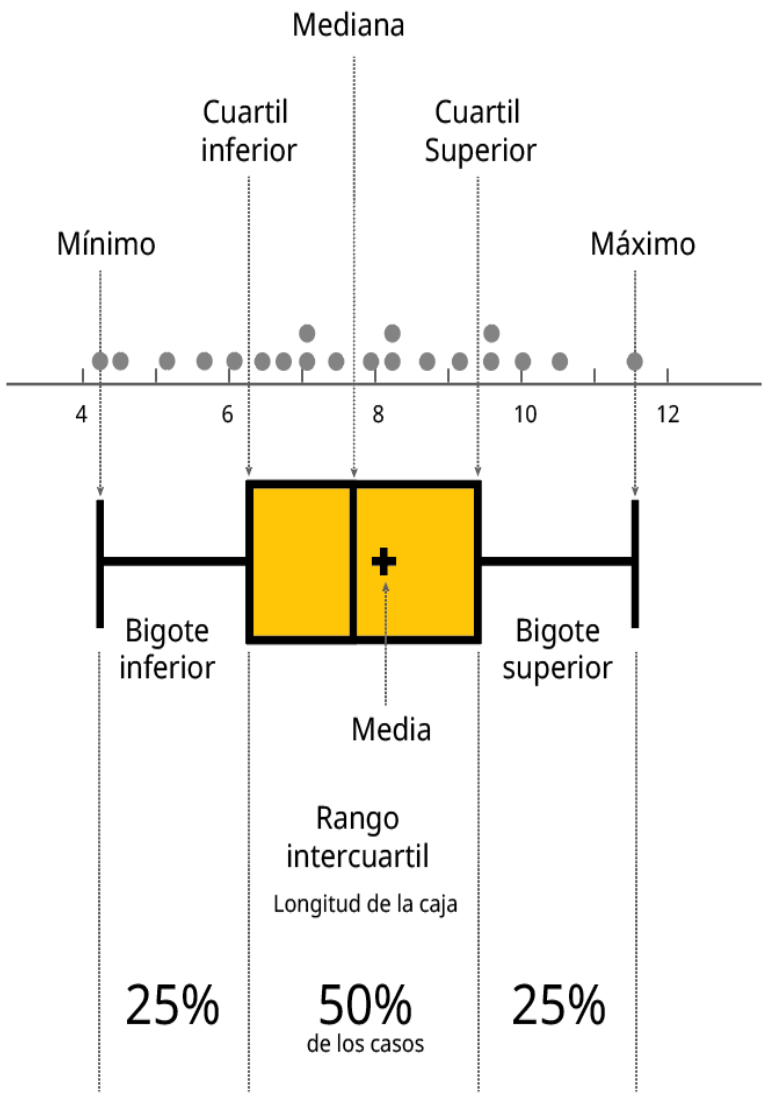




FADENA

Universidad de la Defensa Nacional

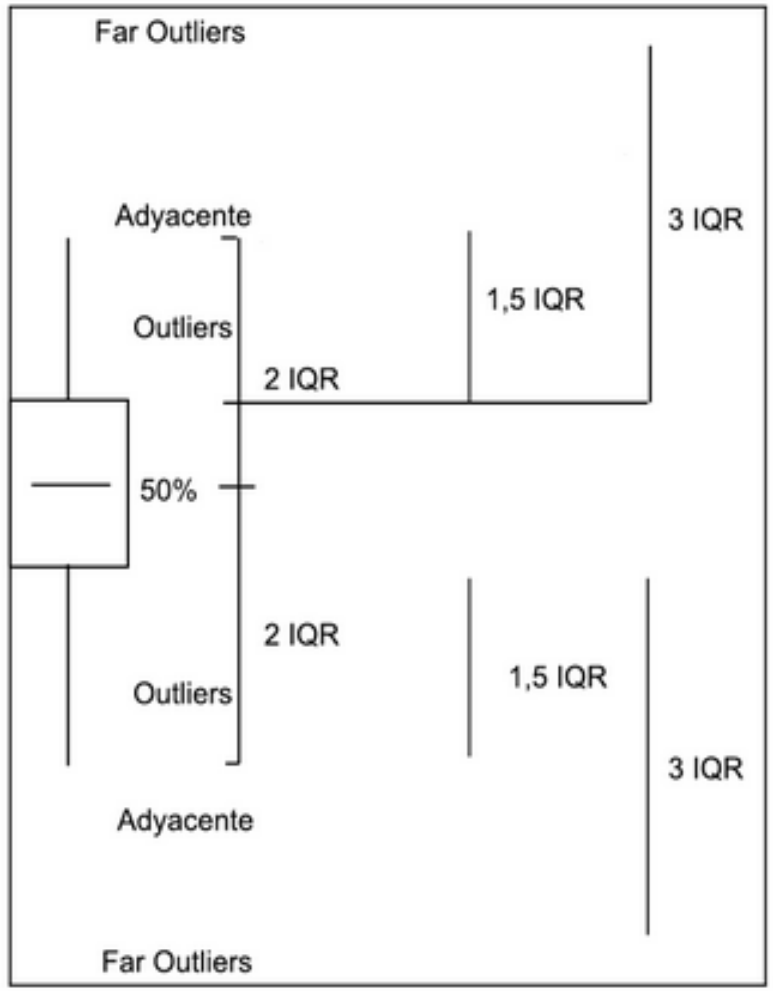
Diagrama de Caja (“Box Plot”)



se representa sobre el eje de la variable en análisis, construyéndose un rectángulo o “caja” con prolongaciones o “bigotes” teniendo en cuenta los siguientes valores:

Q1: el Cuartil de orden 1, inferior, marca el límite inferior del rectángulo.
Q3: el Cuartil de orden 3 o superior marca el límite superior del rectángulo.
Me: la Mediana se marca con una línea dentro del rectángulo.
Valor mínimo: que es el mayor entre el $x_{Mín}$ (menor valor de la variable) y 1,5 veces el Q (Desvío Semiintercuartílico), restado al Q1 . Desde el límite inferior del rectángulo, se extiende una línea o “bigote” hasta este valor mínimo.
Valor máximo: que es el menor entre el $x_{Máx}$ (mayor valor de la variable) y 1,5 veces el Q (Desvío Semiintercuartílico), sumado al Q3 . Desde el límite superior del rectángulo, se extiende una línea o “bigote” hasta este valor máximo.
El $x_{Mín}$ y/o el $x_{Máx}$ si es que no quedan comprendidos dentro del Diagrama del rectángulo con los bigotes, constituyen *valores anómalos*.

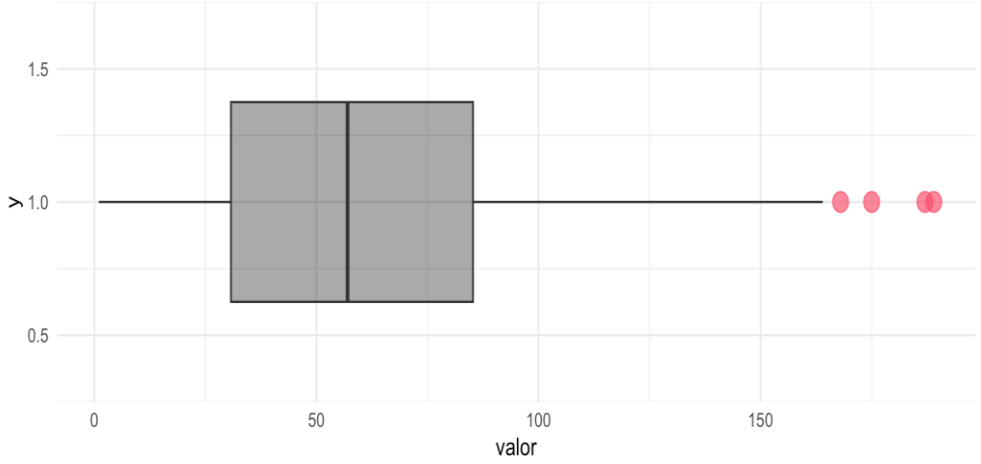
Diagrama de Caja ("Box Plot")



VALOR ATÍPICO
+ de 1,5 IQR (recorrido intercuartílico) desde el cuartil 3 (Q3 =P75) o 1,5 IQR desde el cuartil 1 (Q1 = P25)

ANOMALÍAS EXTREMAS
+ 3 IQR (recorrido intercuartílico) desde el cuartil 3 (Q3 =P75) o 3 IQR por debajo del cuartil 1 (Q1 = P25)





FADENA

4.4. MEDIDAS DE DISPERSIÓN o VARIABILIDAD

4.4.1 Rango o amplitud
4.4.2 Rango intercuartilíco
4.4.3 Desviación típica o estándar
4.4.4 Varianza
4.4.5 Coeficiente de variación

Universidad de la Defensa Nacional

AMPLITUD TOTAL o RECORDIDO



{diferencia entre el mayor y el menor de los valores observado}

$$R = X_{mÁx} - X_{min}$$

{Cuando la distribución tiene mas casos, el recorrido es insuficiente como medida de dispersión, ya que esta determinado solo por los valores extremos}

AMPLITUD (rango) INTERCUARTÍLICA (o)



{distancia entre los cuartiles tercero y primero}

$$AIQ = Q_3 - Q_1$$

AMPLITUD SEMI-INTERCUARTÍLICA



{**semi**-distancia entre los cuartiles tercero y primero}

$$SRIC = (Q_3 - Q_1)/2.$$

VARIANZA s_X^2



{Promedio del cuadrado de las distancias de los valores a la media}

$$s_X^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x})^2}{n-1}$$

La varianza es un valor no negativo.

{cuanto mayor es, tanto más dispersos éstos se encuentran, es decir, son más heterogéneos}

DESVIACIÓN ESTÁNDAR s_X



{raíz cuadrada de la varianza}

$$s_X = \sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \ /(n-1)}$$

es un valor no negativo.

{las unidades de s son las mismas que las de la variable original y no hay problemas con la interpretación del valor.}

COEFICIENTE DE VARIACIÓN CV_X



{expresa la desviación estándar relativa a la media en porcentaje}

$$CV_X = \frac{S_X}{|\overline{x}|}\ 100$$

{índice de representatividad de la media}

ENTROPÍA

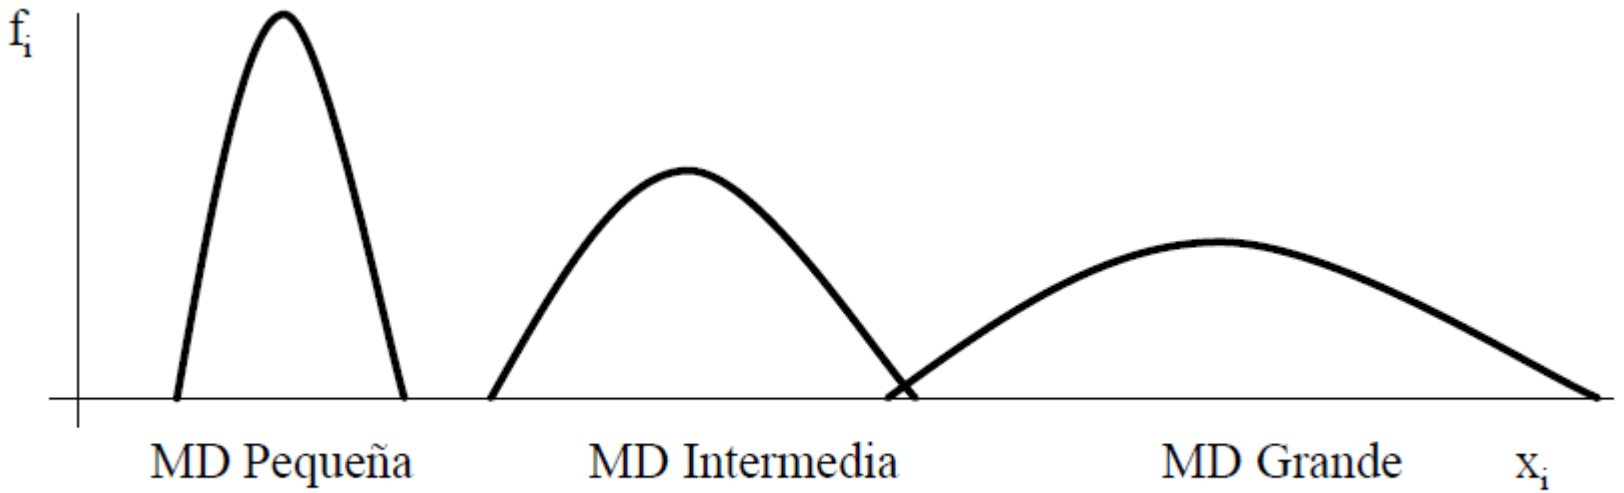


{cuantifica el nivel de incertidumbre acerca de la clase a la que pertenece el dato}

$$H = -\sum f'_i * log\, f'_i$$

{mayor entropía, mayor dispersión de los datos,mayor incertidumbre.}

{ MEDIDAS DE DISPERSIÓN}



En general: 0 (No hay Dispersión) $<$ **MD** $<$ $x_{Máx}$ (Dispersión Máxima)

FADENA
Universidad de la Defensa Nacional

FADENA

4.5. MEDIDAS DE FORMA

4.5.1 Asimetría

4.5.2 Curtosis

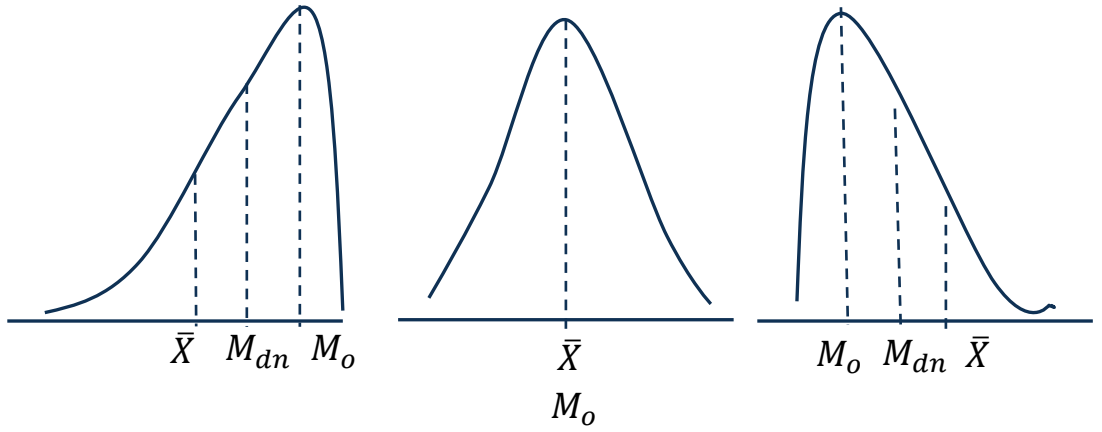
Universidad de la Defensa Nacional

ASIMETRÍA

{grado en que los datos se reparten equilibradamente por encima y por debajo de la tendencia central}

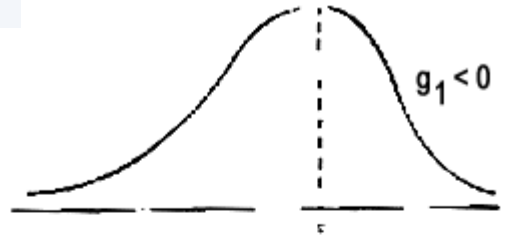
{puede evaluarse directamente a partir de las medidas de centralidad}

ASF
- = 0, Simétrica
- > 0, Asimétrica Positiva
- < 0, Asimétrica Negativa



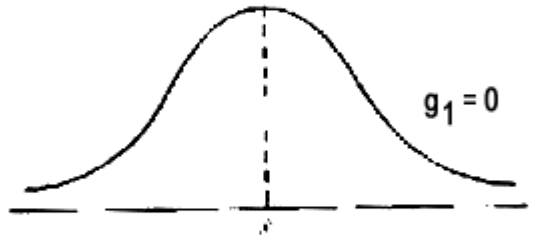
ASIMETRÍA

{Coeficientes de asimetría = cuantifican y facilitan la comparación entre distribuciones}



{coeficiente de asimetría de Fisher}

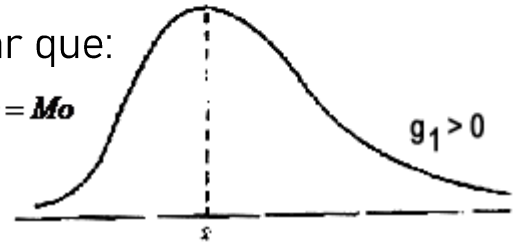
$$g_1 = \frac{\frac{\sum_{i=1}^{r}(x_i - \bar{x})^3 n_i}{N}}{S^3}$$



Si existe entonces $g_1 = 0$, y $\bar{X} = Me$; si además la distribución es unimodal, también podemos afirmar que:

- Si $g_1 > 0$, entonces : $\bar{X} > Me > Mo$
- Si $g_1 < 0$, entonces : $\bar{X} < Me < Mo$

$\bar{X} = Me = Mo$



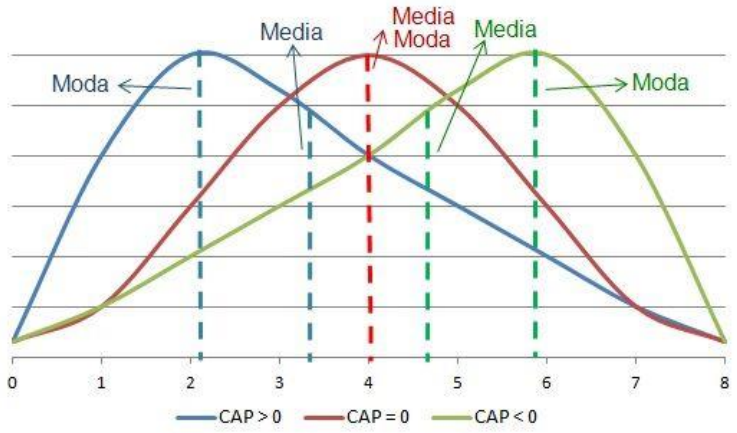
ASIMETRÍA

{coeficiente de asimetría de Pearson}

$$CA_P = \frac{\overline{x} - Mo(X)}{S_x}$$

{CAP mide la diferencia entre la media y la moda respecto a la dispersión del conjunto X=(x1, x2,…, xN}

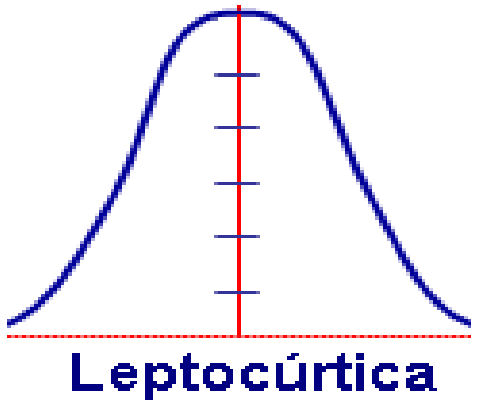
Si $CA_P<0$: la distribución tiene una **asimetría negativa**.
Si $CA_P=0$: la distribución es **simétrica**.
Si $CA_P>0$: la distribución tiene una **asimetría positiva**



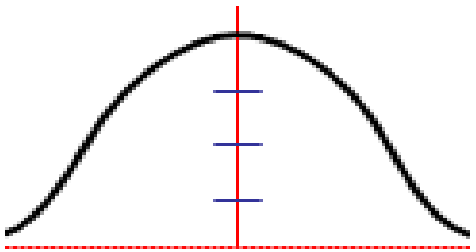
CURTOSIS

{grado de apuntamiento de la curva que representa a la distribución de frecuencias}

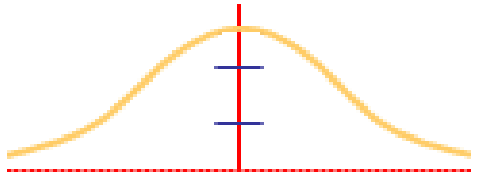
$$C_r = \sum_{i=1}^{n} \left[\frac{(x_i - \bar{x})^4 * f_i}{\text{n } s_X{}^4} \right] - 3 = \sum_{i=1}^{n} \frac{Z_i^4 * f_i}{\text{n}} - 3$$



Leptocúrtica



Mesocúrtica



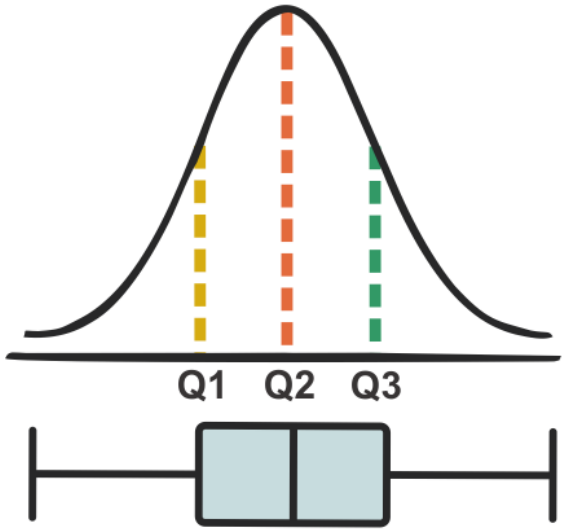
Platicúrtica

Interpretación:

Cr
- =0 Mesocúrtica
- >0 Leptocúrtica
- <0 Platicúrtica

Diagrama de Caja ("Box Plot")

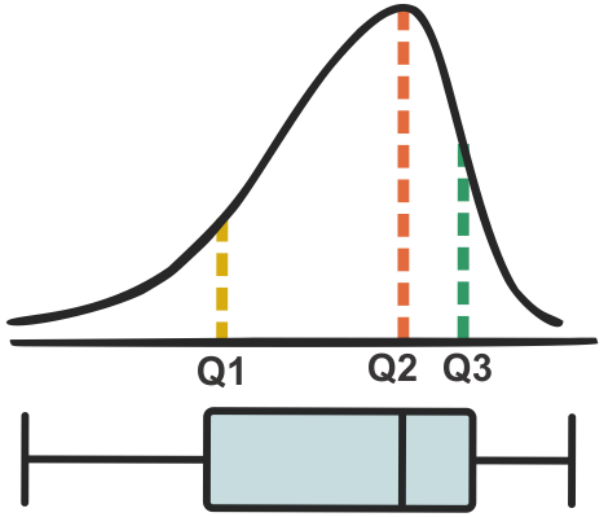
Distribución simétrica o en forma de campana (Normal)



Se cumple:

$$|X_{min} - Q_1| = |X_{max} - Q_3|$$
$$|Q_2 - Q_1| = |Q_2 - Q_3|$$
$$Q_2 = \bar{X}$$

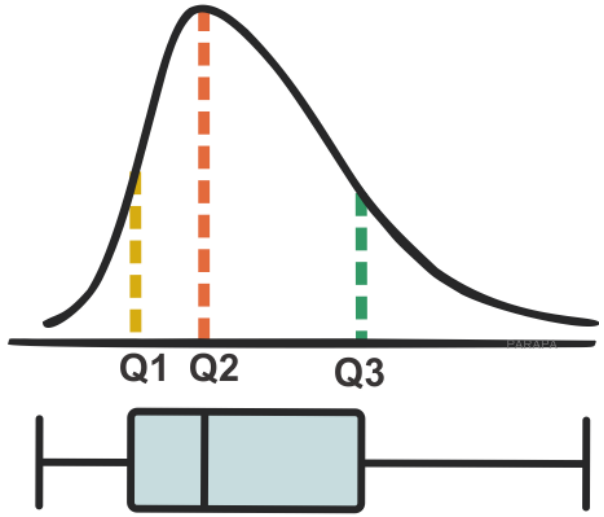
Distribución asimétrica negativa (cola hacia la izquierda)



Se cumple:

$$\bar{X} < Q_2 = M_e < M_o$$

Distribución asimétrica positiva (cola hacia la derecha)



Se cumple:

$$\bar{X} > Q_2 = M_e > M_o$$

Donde: $X_{min} \rightarrow$ *valor mínimo*, $X_{max} \rightarrow$ *valor máximo*, $Q_1, Q_2, Q_3 \rightarrow$ *Cuartiles*, $\bar{X} \rightarrow$ *media*, $M_e \rightarrow$ *mediana*, $M_o \rightarrow$ *moda*

FADENA

4.6. PUNTUACIONES

4.6.1 Típicas

4.6.2 Derivadas

Universidad de la Defensa Nacional

PUNTUACIONES TÍPICAS



{ubican la posición de un sujeto i en relación a un grupo de referencia}

$$z_i = \frac{x_i - \bar{x}}{s_x} \quad \textit{muestra}$$

$$z_i = \frac{x_i - \mu}{\sigma} \quad \textit{población}$$

{indica a cuántas desviaciones estándar por encima o por debajo de la media está el puntaje x_i}

PUNTAJES DERIVADOS



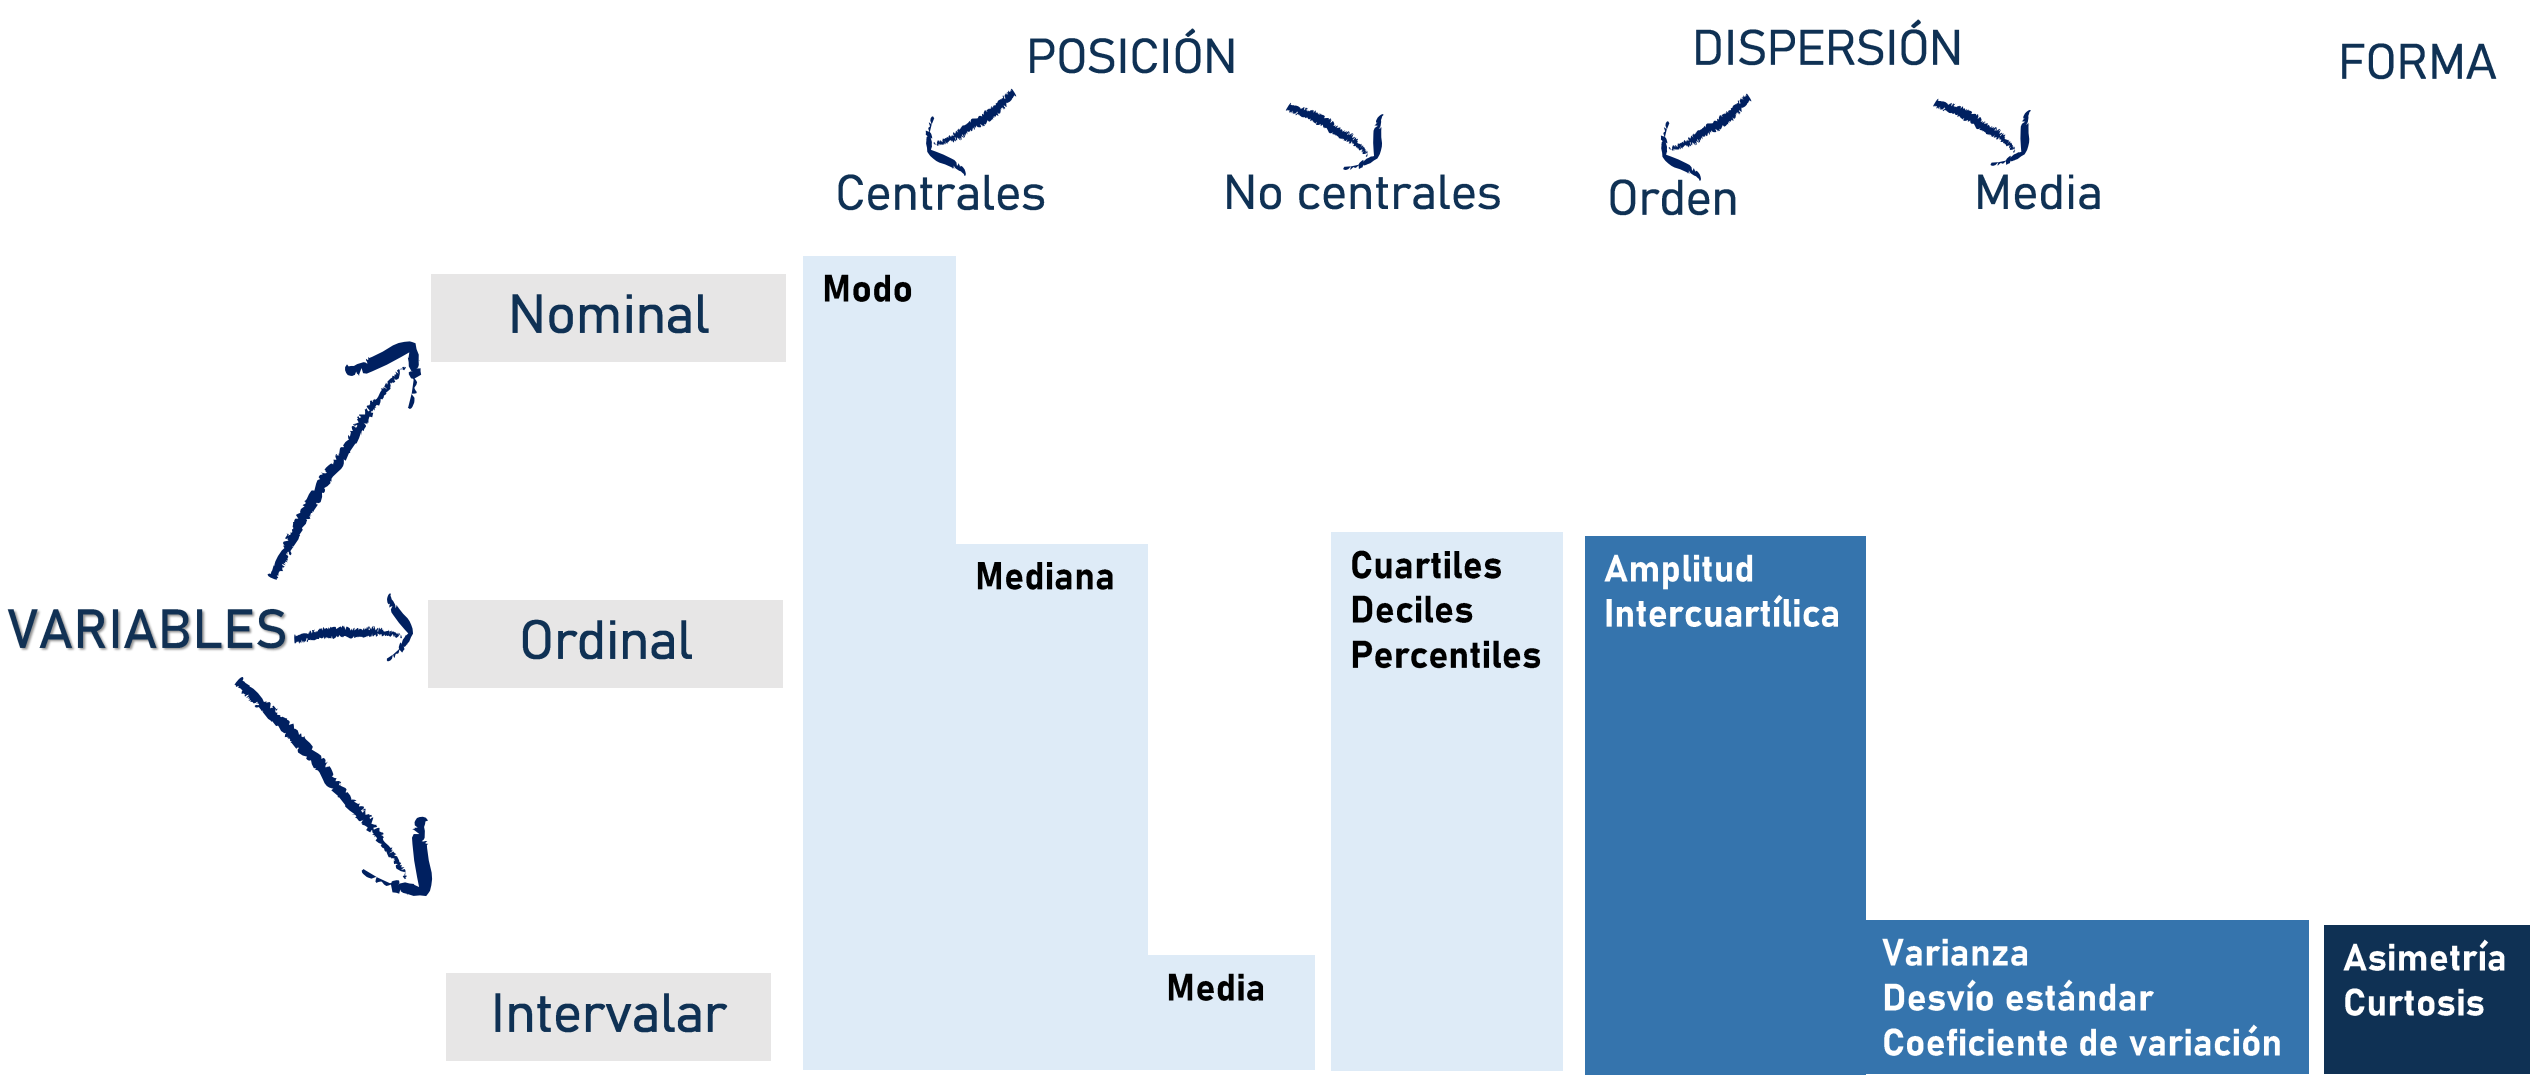
{Puntaje T = La media es 50 y la desviación típica es 10. }

$$T = 50 + 10.\ Z$$

Equivalencias

X	$\bar{x}$ -3*s*	$\bar{x}$ -2*s*	$\bar{x}$ - *s*	$\bar{x}$	$\bar{x}$ + *s*	$\bar{x}$ +2*s*	$\bar{x}$ +3*s*
Z	-3	-2	-1	0	1	2	3
T	20	30	40	50	60	70	80

MEDIDAS DESCRIPTIVAS





Actividades NO obligatorias
Sección ACTIVIDADES
Prácticas

ACTIVIDADES

FADENA

Universidad de la Defensa Nacional



Actividad obligatoria: Autoevaluación 3

AUTOEVALUACIÓN

Autoevaluación 3 U3 (obligatoria)

FADENA

Universidad de la Defensa Nacional

MUCHAS GRACIAS

FADENA | Universidad de la Defensa Nacional