¡¡APRUEBE SU EXAMEN CON SCHAUM!!

Estadística

Schaum

4ª EDICIÓN

Murray R. Spiegel • Larry J. Stephens

- 486 PROBLEMAS RESUELTOS PASO A PASO
- 660 PROBLEMAS DE PRÁCTICA
- INCLUYE SOLUCIONES A PROBLEMAS DE LOS PROGRAMAS DE CÓMPUTO ACTUALES

Utilícelo para las siguientes asignaturas:

☑ ESTADÍSTICA BÁSICA ☑ MÉTODOS ESTADÍSTICOS BÁSICOS ☑ INTRODUCCIÓN A LA ESTADÍSTICA
☑ INTRODUCCIÓN A LA PROBABILIDAD Y ESTADÍSTICA ☑ INTRODUCCIÓN AL ANÁLISIS EXPLORATORIO DE DAT

Mc Graw Hill

TEORÍA ELEMENTAL DEL MUESTREO

8

TEORÍA DEL MUESTREO

La *teoría del muestreo* es el estudio de la relación que existe entre una población y las muestras que se obtienen de esa población. La teoría del muestreo se emplea en muchos contextos. Por ejemplo, en la *estimación* de cantidades poblacionales desconocidas (como la media y la varianza poblacionales), a las que se les conoce como *parámetros poblacionales* o simplemente *parámetros*, a partir de las correspondientes cantidades muestrales (como la media y la varianza muestrales), a menudo conocidas como *estadísticos muestrales* o simplemente *estadísticos*. El problema de la estimación se estudia en el capítulo 9.

La teoría del muestreo también sirve para determinar si las diferencias que se observan entre dos muestras se deben a variaciones casuales o si son diferencias realmente significativas. Tales preguntas surgen, por ejemplo, al probar un nuevo suero para el tratamiento de una enfermedad o cuando se tiene que decidir si un proceso de producción es mejor que otro. Para responder a estas preguntas se usan las llamadas *pruebas de significancia o de hipótesis*, fundamentales en la *teoría de decisiones*. Estos temas se tratan en el capítulo 10.

En general, al estudio de las inferencias que se hacen acerca de una población, empleando muestras obtenidas de ella, y de las indicaciones de la exactitud de tales inferencias, mediante el uso de la teoría de la probabilidad, es a lo que se le llama *inferencia estadística*.

MUESTRAS ALEATORIAS Y NÚMEROS ALEATORIOS

Para que las conclusiones que se obtienen empleando la teoría del muestreo y la inferencia estadística sean válidas, las muestras deben elegirse de manera que sean *representativas* de la población. Al estudio de los métodos de muestreo y de los problemas relacionados con ellos se le conoce como *diseño de experimentos*.

Una manera de obtener una muestra representativa es mediante un proceso llamado *muestreo aleatorio*, mediante el cual cada uno de los miembros de la población tiene la misma posibilidad de ser incluido en la muestra. Una técnica para obtener una muestra aleatoria consiste en asignarle, a cada miembro de la población, un número, escribir estos números en pedazos pequeños de papel, colocarlos en una urna y después extraer los números de la urna, teniendo cuidado de mezclar muy bien antes de cada extracción. Una alternativa a este método es usar una tabla de *números aleatorios* (ver el apéndice IX), la cual se construye especialmente para este fin. Ver el problema 8.6.

MUESTREO CON REPOSICIÓN Y SIN ELLA

Si se extrae un número de una urna, antes de extraer otro, el número puede ser devuelto a la urna (ser repuesto) o no. En el primer caso, el número puede ser extraído varias veces, en tanto que en el segundo caso sólo puede ser extraído una vez. A un muestreo en el que cada miembro de la población puede ser elegido más de una vez se le llama *muestreo con reposición*; en cambio, si sólo puede ser elegido una vez se llama *muestreo sin reposición*.

Una población puede ser finita o infinita. Por ejemplo, si de una urna que contiene 100 canicas se extraen sucesivamente 10 canicas sin reposición, se está muestreando una población finita; en cambio, si se lanza una moneda 50 veces y se cuenta la cantidad de caras, se está muestreando de una población infinita.

Una población finita que se muestrea con reposición puede considerarse teóricamente infinita, ya que se puede extraer cualquier cantidad de muestras sin agotar la población. Para fines prácticos, cuando se muestrea de una población finita pero muy grande, se puede considerar que el muestreo se hace de una población infinita.

DISTRIBUCIONES MUESTRALES

Considérense todas las muestras de tamaño N que pueden extraerse de determinada población (ya sea con reposición o sin ella). Para cada muestra se pueden calcular diversos estadísticos (como media o desviación estándar), los cuales variarán de una muestra a otra. De esta manera se obtiene una distribución del estadístico de que se trate, a la que se le llama *distribución muestral*.

Por ejemplo, si el estadístico de que se trata es la media muestral, a la distribución que se obtiene se le llama *distribución muestral de las medias* o *distribución muestral de la media*. De igual manera se pueden obtener distribuciones muestrales de las desviaciones estándar, de las varianzas, de las medianas, de las proporciones, etcétera.

A cada distribución muestral se le puede calcular su media, su desviación estándar, etc. Así, se puede hablar de la media, de la desviación estándar, de la distribución muestral de las medias, etcétera.

DISTRIBUCIONES MUESTRALES DE MEDIAS

Supóngase que de una población finita de tamaño $N_p > N$ se extraen, sin reposición, todas las muestras posibles de tamaño N. Si se denota con $\mu_{\bar{X}}$ y $\sigma_{\bar{X}}$ respectivamente, a la media y a la desviación estándar de una distribución muestral de las medias, y con μ y σ, respectivamente, a la media y la desviación estándar poblacionales, entonces

$$\mu_{\bar{X}} = \mu \qquad \text{y} \qquad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{N}}\sqrt{\frac{N_p - N}{N_p - 1}} \tag{1}$$

Si la población es infinita, o si el muestreo se hace con reposición, las fórmulas anteriores se reducen a

$$\mu_{\bar{X}} = \mu \qquad \text{y} \qquad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{N}} \tag{2}$$

Si el valor de N es grande ($N \geq 30$), la distribución muestral de las medias es aproximadamente normal con media $\mu_{\bar{X}}$ y desviación estándar $\sigma_{\bar{X}}$, independientemente de la población (siempre y cuando la media y la varianza poblacionales sean finitas y el tamaño de la población sea por lo menos el doble del tamaño de la muestra). Si la población es infinita, este resultado es un caso especial del *teorema del límite central* de la teoría avanzada de la probabilidad, el cual muestra que la exactitud de la aproximación aumenta a medida que N aumenta. Esto suele indicarse diciendo que la distribución muestral es *asintóticamente normal*.

Si la población está distribuida normalmente, la distribución muestral de las medias también es normal aun cuando el valor de N sea pequeño (es decir, $N < 30$).

DISTRIBUCIONES MUESTRALES DE PROPORCIONES

Supóngase que una población sea infinita y que la probabilidad de ocurrencia de un evento (llamada éxito) es p, y que la probabilidad de no ocurrencia del evento es $q = 1 - p$. La población puede ser, por ejemplo, la de los lanzamientos de una moneda, en los que la probabilidad del evento "cara" es $p = \frac{1}{2}$. Considérense todas las posibles muestras de tamaño N extraídas de esta población, y para cada muestra determínese la proporción P de éxitos. En el caso de una moneda, P es la proporción de caras en N lanzamientos. De esta manera se obtiene una *distribución muestral de las proporciones* cuya media μ_P y cuya desviación estándar σ_P están dadas por

$$\mu_P = p \qquad \text{y} \qquad \sigma_P = \sqrt{\frac{pq}{N}} = \sqrt{\frac{p(1-p)}{N}} \tag{3}$$

que se pueden obtener de la ecuación (*2*) sustituyendo $\mu = p$ y $\sigma = \sqrt{pq}$. Si el valor de N es grande ($N \geq 30$), esta distribución muestral es aproximadamente normal. Obsérvese que la población está *distribuida en forma binomial*.

Las ecuaciones (*3*) también son válidas para poblaciones finitas si el muestreo se hace con reposición. En el caso de poblaciones finitas en las que el muestreo se hace sin reposición, las ecuaciones (*3*) se sustituyen por las ecuaciones (*1*) con $\mu = p$ y $\sigma = \sqrt{pq}$.

Obsérvese que las ecuaciones (*3*) pueden obtenerse más fácilmente dividiendo entre N, la media y la desviación estándar (Np y $\sqrt{Npq}$) de la distribución binomial (ver capítulo 7).

DISTRIBUCIONES MUESTRALES DE DIFERENCIAS Y SUMAS

Se supone que se tienen dos poblaciones. Para cada muestra de tamaño N_1 tomada de la primera población se calcula un estadístico S_1, con lo que se obtiene una distribución muestral de este estadístico S_1, cuya media y desviación estándar se denotan μ_{S1} y σ_{S1}, respectivamente. De igual manera, para cada muestra de tamaño N_2 tomada de la segunda población se calcula un estadístico S_2, con lo que se obtiene una distribución muestral de este estadístico S_2, cuya media y desviación estándar se denotan μ_{S2} y σ_{S2}, respectivamente. Con todas las posibles combinaciones de estas muestras de las dos poblaciones se obtiene una distribución de las diferencias, $S_1 - S_2$, a la que se le llama *distribución muestral de las diferencias de los estadísticos*. La media y la desviación estándar de esta distribución muestral se denotan, respectivamente, μ_{S1-S2} y σ_{S1-S2}, y están dadas por

$$\mu_{S1-S2} = \mu_{S1} - \mu_{S2} \qquad \text{y} \qquad \sigma_{S1-S2} = \sqrt{\sigma_{S1}^2 + \sigma_{S2}^2} \tag{4}$$

siempre y cuando las muestras elegidas no dependan, de manera alguna, una de la otra (es decir, las muestras sean *independientes*).

Si S_1 y S_2 son las medias muestrales de las dos poblaciones, a las que se les denota $\bar{X}_1$ y $\bar{X}_2$, respectivamente, entonces la distribución muestral de las diferencias de las medias está dada para poblaciones infinitas con media y desviación estándar (μ_1 y σ_1) y (μ_2 y σ_2), respectivamente, por

$$\mu_{\bar{X}1-\bar{X}2} = \mu_{\bar{X}1} - \mu_{\bar{X}2} = \mu_1 - \mu_2 \qquad \text{y} \qquad \sigma_{\bar{X}1-\bar{X}2} = \sqrt{\sigma_{\bar{X}1}^2 + \sigma_{\bar{X}2}^2} = \sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}} \tag{5}$$

usando las ecuaciones (*2*). Estas ecuaciones también son válidas para poblaciones finitas si el muestreo se hace con reposición. Para poblaciones finitas en las que el muestreo se haga sin reposición, se obtienen ecuaciones similares empleando las ecuaciones (*1*).

Tabla 8.1 Error estándar de distribuciones muestrales

Distribución muestral	Error estándar	Observaciones
Media	$\sigma_{\bar{X}} = \dfrac{\sigma}{\sqrt{N}}$	Esta fórmula es válida tanto para muestras grandes como para muestras pequeñas. La distribución muestral de las medias se aproxima a una distribución normal cuando $N \geq 30$, aun cuando la población no sea normal. $\mu_{\bar{X}} = \mu$, la media poblacional, en todos los casos.
Proporciones	$\sigma_P = \sqrt{\dfrac{p(1-p)}{N}} = \sqrt{\dfrac{pq}{N}}$	La observación hecha para las medias también es válida en este caso. $\mu_P = p$, en todos los casos.
Desviaciones estándar	(*1*) $\sigma_s = \dfrac{\sigma}{\sqrt{2N}}$ (*2*) $\sigma_s = \sqrt{\dfrac{\mu_4 - \mu_2^2}{4N\mu_2}}$	Cuando $N \geq 100$, la distribución muestral de s es casi normal. σ_s está dada por (*1*) sólo si la población es normal (o aproximadamente normal). Si la población no es normal, se puede usar (*2*). Obsérvese que (*2*) se reduce a (*1*) cuando $\mu_2 = \sigma^2$ y $\mu_4 = 3\sigma^4$, lo que ocurre en poblaciones normales. Cuando $N \geq 100$, $\mu_s = \sigma$ muy aproximadamente.
Medianas	$\sigma_{\text{med}} = \sigma\sqrt{\dfrac{\pi}{2N}} = \dfrac{1.2533\sigma}{\sqrt{N}}$	Cuando $N \geq 30$, la distribución muestral de la mediana es casi normal. La fórmula dada es válida sólo si la población es normal (o aproximadamente normal). $\mu_{\text{med}} = \mu$
Primero y tercer cuartiles	$\sigma_{Q1} = \sigma_{Q3} = \dfrac{1.3626\sigma}{\sqrt{N}}$	La observación hecha para las medianas también es válida aquí. μ_{Q1} y μ_{Q3} son casi iguales al primero y tercer cuartiles de la población. Obsérvese que $\sigma_{Q2} = \sigma_{\text{med}}$
Deciles	$\sigma_{D1} = \sigma_{D9} = \dfrac{1.7094\sigma}{\sqrt{N}}$ $\sigma_{D2} = \sigma_{D8} = \dfrac{1.4288\sigma}{\sqrt{N}}$ $\sigma_{D3} = \sigma_{D7} = \dfrac{1.3180\sigma}{\sqrt{N}}$ $\sigma_{D4} = \sigma_{D6} = \dfrac{1.2680\sigma}{\sqrt{N}}$	Las observaciones hechas para las medianas también son válidas aquí. μ_{D1}, μ_{D2}, ... son casi iguales al primero, segundo, ... deciles de la población. Obsérvese que $\sigma_{D5} = \sigma_{\text{med}}$.
Rangos semiinter-cuartílicos	$\sigma_Q = \dfrac{0.7867\sigma}{\sqrt{N}}$	Las observaciones hechas para las medianas también son válidas aquí. μ_Q es casi igual al rango semiintercuartil poblacional.
Varianzas	(*1*) $\sigma_{S^2} = \sigma^2\sqrt{\dfrac{2}{N}}$ (*2*) $\sigma_{S^2} = \sqrt{\dfrac{\mu_4 - \dfrac{N-3}{N-1}\mu_2^2}{N}}$	Las observaciones hechas para la desviación estándar también son válidas aquí. Obsérvese que si la población es normal (*2*) da (*1*). $\mu_{S^2} = \sigma^2(N-1)/N$, que es casi igual a σ^2 cuando N es grande.
Coeficiente de variación	$\sigma_V = \dfrac{v}{\sqrt{2N}}\sqrt{1+2v^2}$	Aquí $v = \sigma/\mu$ es el coeficiente de variación poblacional. La fórmula dada es válida para poblaciones normales (o casi normales) y $N \geq 100$.

Pueden obtenerse resultados semejantes para las distribuciones muestrales de las diferencias entre las proporciones de dos poblaciones distribuidas en forma binomial con parámetros (p_1, q_1) y (p_2, q_2), respectivamente. En este caso, S_1 y S_2 son proporción de éxitos, P_1 y P_2, y las ecuaciones (*4*) se transforman en

$$\mu_{P1-P2} = \mu_{P1} - \mu_{P2} = p_1 - p_2 \qquad \text{y} \qquad \sigma_{P1-P2} = \sqrt{\sigma_{P1}^2 + \sigma_{P2}^2} = \sqrt{\frac{p_1 q_1}{N_1} + \frac{p_2 q_2}{N_2}} \tag{6}$$

Si N_1 y N_2 son grandes ($N_1, N_2 \geq 30$), la distribución muestral de diferencias entre medias o proporciones se aproximan mucho a una distribución normal.

Algunas veces se necesita la *distribución muestral de la suma de estadísticos*. La media y la desviación estándar de estas distribuciones están dadas por

$$\mu_{S1+S2} = \mu_{S1} + \mu_{S2} \qquad \text{y} \qquad \sigma_{S1+S2} = \sqrt{\sigma_{S1}^2 + \sigma_{S2}^2} \tag{7}$$

suponiendo que las muestras sean *independientes*.

ERRORES ESTÁNDAR

A la desviación estándar de la distribución muestral de un estadístico suele conocérsele como su *error estándar*. En la tabla 8.1 se enumeran los errores estándar de distribuciones muestrales de varios estadísticos, suponiendo que el muestreo es un muestreo aleatorio de una población infinita (o muy grande) o de una población finita pero hecho el muestreo con reposición. Se presentan también algunas observaciones especiales en las que se dan las condiciones bajo las cuales son válidas las fórmulas, así como otras observaciones pertinentes.

Las cantidades μ, σ, p, μ_r y $\bar{X}$, s, P, m_r denotan media, desviación estándar, proporción y el r-ésimo momento respecto a la media, poblacionales y muestrales, respectivamente.

Se hace notar que si el tamaño N de la muestra es suficientemente grande, la distribución muestral es normal o casi normal. A esto se debe que estos métodos se conozcan como *métodos para muestras grandes*. Cuando $N < 30$, a las muestras se les llama *pequeñas*. La teoría de las muestras *pequeñas* o *teoría del muestreo exacto*, como se le llama algunas veces, se estudia en el capítulo 11.

Cuando los parámetros poblacionales, por ejemplo, σ, p o bien μ_r no se conocen, pueden estimarse con bastante exactitud a partir de sus estadísticos muestrales, s (o bien $\hat{s} = \sqrt{N/(N-1)}s$), P y m_r, siempre y cuando las muestras sean suficientemente grandes.

DEMOSTRACIONES DE LA TEORÍA ELEMENTAL DEL MUESTREO EMPLEANDO SOFTWARE

EJEMPLO 1

En una población grande se define la siguiente variable aleatoria. X es la cantidad de computadoras por hogar; X está distribuida de manera uniforme, es decir, $p(x) = 0.25$ para $x = 1, 2, 3$ y 4. En otras palabras, 25% de los hogares tiene 1 computadora; 25% tiene 2 computadoras; 25% tiene tres computadoras y 25% tiene 4 computadoras. La media de X es $\mu = \Sigma x p(x) = 0.25 + 0.5 + 0.75 + 1 = 2.5$. La varianza de X es $\sigma^2 = \Sigma x^2 p(x) - \mu^2 = 0.25 + 1 + 2.25 + 4 - 6.25 = 1.25$. Entonces, la cantidad media de computadoras por hogar es 2.5 y la varianza de la cantidad de computadoras por hogar es 1.25.

EJEMPLO 2

Para enumerar todas las muestras, tomadas con reposición, de dos hogares puede usarse MINITAB. La hoja de cálculo se verá como la que se presenta en la tabla 8.2. Las 16 muestras aparecen en C1 y C2, y la media de cada una de ellas en C3. Como la población está distribuida de manera uniforme, la probabilidad de cada media muestral es $1/16$. Resumiendo, en las columnas C4 y C5 se da la distribución de probabilidad.

Obsérvese que $\mu_{\bar{X}} = \Sigma \bar{x} p(\bar{x}) = 1(0.0625) + 1.5(0.1250) + \cdots + 4(0.0625) = 2.5$. Como se ve $\mu_{\bar{X}} = \mu$. Además, $\sigma_{\bar{X}}^2 = \Sigma \bar{x}^2 p(\bar{x}) - \mu_{\bar{X}}^2 = 1(0.0625) + 2.25(0.1250) + \cdots + 16(0.0625) - 6.25 = 0.625$ con lo que $\sigma_{\bar{X}}^2 = (\sigma^2/2)$. Empleando MINITAB para dibujar la gráfica de la distribución de probabilidad de x barra se obtiene el resultado que se muestra en la figura 8-1. (Obsérvese que $\bar{X}$ y x barra se usan indistintamente.)