FADENA | Universidad de la Defensa Nacional

PROBALIDAD Y ESTADÍSTICA

Unidad 4

Prof. Tit.: Dra. Romina Caballero

Material de lectura: Unidad 3

Guía de lectura de material bibliográfico

Clase 4- Unidad IV

Bibliografía

Obligatoria

Bologna, E. (2018). Métodos Estadísticos de Investigación (Cap.6, Obtención de la muestra). Editorial Brujas.

Spiegel, M. R., & Stephens, L. J. (2009). Estadística (Cap.8, Teoría elemental del muestreo). Mc Graw-Hill.

Triola, M. (2009). Estadística 9° Ed. (Cap.6, Estimados y tamaños de muestra). Pearson.

Complementaria

Lohr, S. L. (2000). Muestreo: diseño y análisis. Paraninfo.

Kish, L. (1972). Muestreo de Encuestas. Trillas.

Kelmansky, D. (2009). Estadística para todos. (Cap.6, Muestreo). Instituto Nacional de Educación Tecnológica- Ministerio de Educación de la Nación.

Contenidos

Muestra y población. Características de una muestra. Tamaño de una muestra. Representatividad. Muestreo. Conceptos básicos de muestreo. Diseño muestral. Marco muestral. Tipos de muestreo. Muestreo probabilístico. Muestreo no probabilístico. Errores de muestreo y no debidos a muestreo.

Objetivos

- Distinguir entre población y muestra.
- Comprender el diseño muestral
- Diferenciar entre los diferentes tipos de muestreo.



FADENA

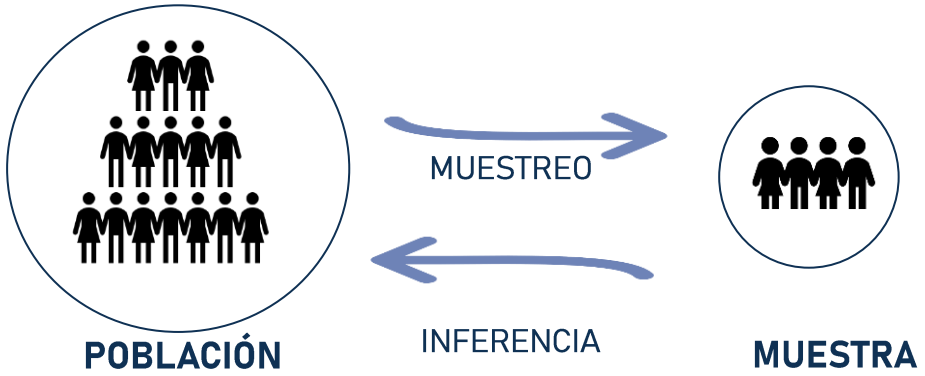
ESTADÍSTICA INFERENCIAL

Universidad de la Defensa Nacional

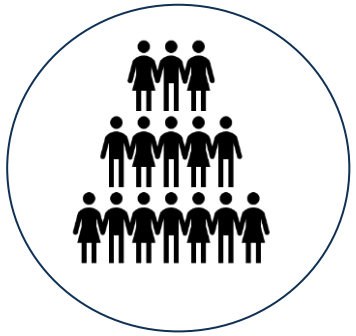
DATOS OBSERVADOS

Ej., eventos registrados por herramientas de monitoreo

INFERENCIA



INFERENCIA







Control error de muestreo

POBLACIÓN	MUESTRA
μ	$\overline{X}$
σ	S
p	f
ρ	r

PARÁMETROS Y ESTIMADORES



{Los parámetros poblacionales son desconocidos y para estimarlos, se calculan las características análogas a nivel muestral.}

Parámetro	*Estadístico*	*Estimador*
μ	$\bar{X}$	$\hat{\mu}$
σ	S	$\hat{\sigma}$
p	*f*	$\hat{p}$
ρ	r	$\hat{\rho}$

Error muestral

$$\varepsilon = |\theta - \hat{\theta}|$$

θ=parámetro

$\hat{\theta} = estimador$

FADENA

Universidad de la Defensa Nacional

PARÁMETRO



{característica fija, generalmente numérica de la población de valores de una variable.}

EJEMPLO: Promedio real de intentos de acceso fallidos por usuario en un sistema, calculado sobre todos los usuarios de la organización.

FADENA

Universidad de la Defensa Nacional

ESTADÍSTICO



{variable cuyos valores dependen de una muestra}

EJEMPLO: Promedio de intentos de acceso fallidos calculado a partir de 50 usuarios seleccionados de la organización.

FADENA

Universidad de la Defensa Nacional



ESTIMADOR

{estadístico cuyos valores se consideran próximos a un parámetro que, por ser generalmente desconocido, se desea estimar.}

Insesgado: $E(\hat{\theta}) = \theta$

FADENA

Universidad de la Defensa Nacional

MUESTREO



{conjunto de procedimientos mediante los cuales se selecciona, de un universo determinado, llamado población, un subconjunto que recibe el nombre de muestra}

FADENA

Universidad de la Defensa Nacional

MUESTREO

El muestreo no es una simple sustitución de una cobertura total por una parcial. Es la **ciencia** y **arte** de controlar y medir la confiabilidad de la información estadística útil a través de la Teoría de la Probabilidad (Deming, 1950, p.2).

Citado en: **Lohr**, Sharon, L.(2010). *Sampling: Design and Analysis*. Second Edition. Brooks/Cole, Advanced Cengage Learning.

FADENA

Universidad de la Defensa Nacional

INFERIR



{extraer conclusiones sobre una población a partir de una muestra controlando el error de muestreo }

FADENA

Universidad de la Defensa Nacional

POBLACIÓN



{conjunto de unidades de análisis que son objeto de un estudio particular}

{HIPÓTETICA: cuando no se tiene la posibilidad de delimitar a la población completa}

FADENA

Universidad de la Defensa Nacional

POBLACIÓN



{**FINITA**: Cuando el nº de elementos es limitado y se puede tener acceso a todos o casi todos los elementos}

{**INFINITA**: nº de elementos que integra la misma es elevado}

FADENA

Universidad de la Defensa Nacional

MARCO DE MUESTREO



{listado que comprende las unidades de la población}

Sub-enumeración

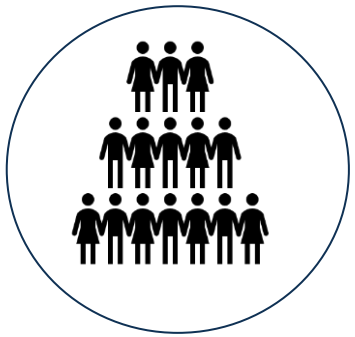
Sobre-enumeración

FADENA

Universidad de la Defensa Nacional

MUESTRA

{subconjunto de una población que comparte sus características en los aspectos de interés para la investigación.}



POBLACIÓN



MUESTRA

FADENA

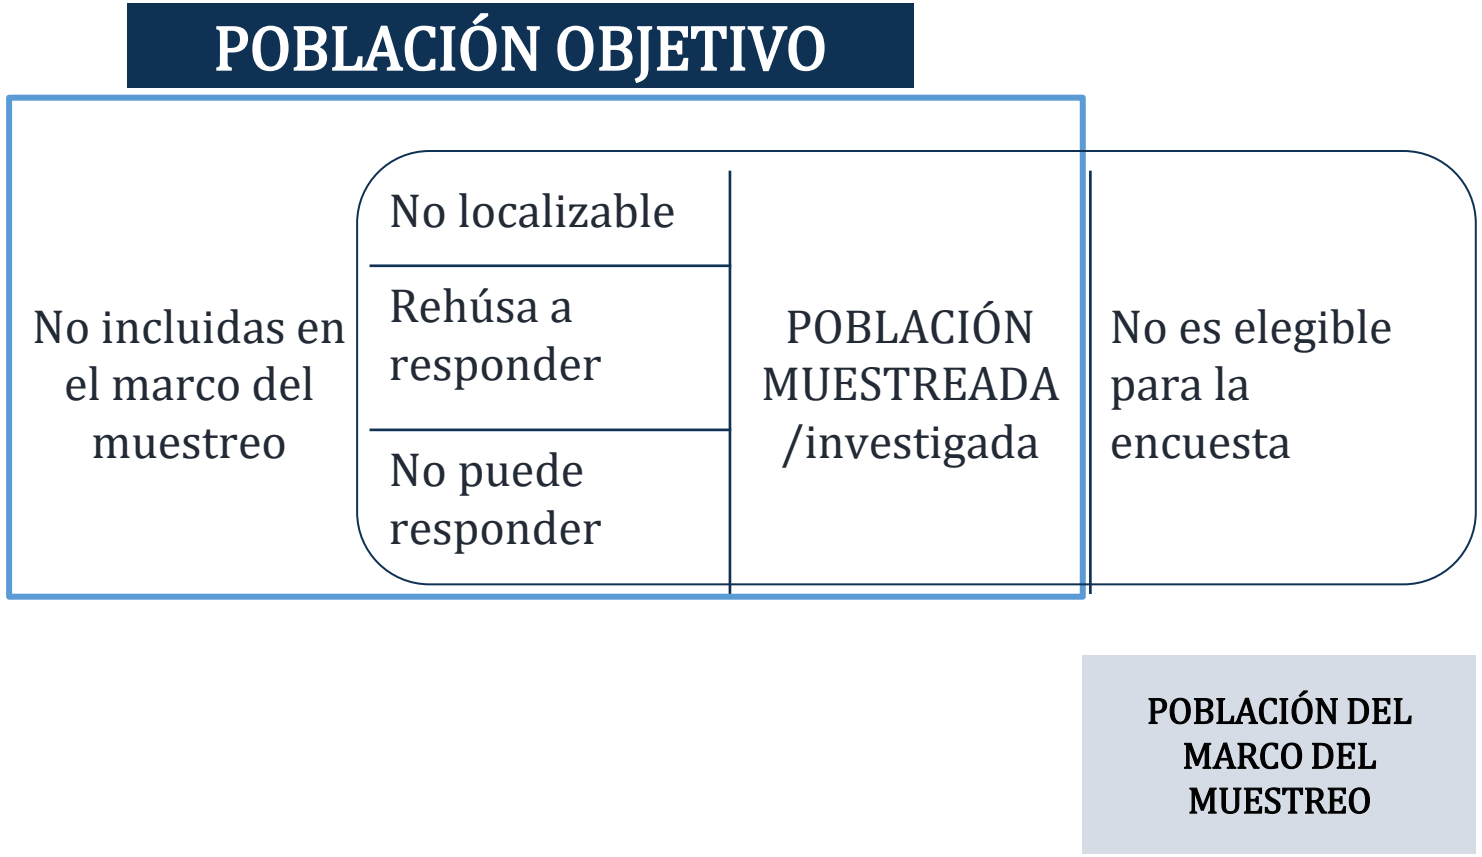
Universidad de la Defensa Nacional

Selección de una muestra apropiada

- Definir los casos sobre los cuales se habrán de recolectar los datos.
- Delimitar la **población (N)**.
- Elegir el **método de selección** de la muestra.
- Precisar el **tamaño de la muestra (n)** requerido.
- Aplicar el **procedimiento de selección**.
- Obtener la **muestra (n)** .

FADENA
Universidad de la Defensa Nacional

“Buena muestra”



Lohr, Sharon, L.(2010). *Sampling: Design and Analysis*. Second Edition. Brooks/Cole, Advanced Cengage Learning.

Para pensar

SITUACIÓN: Una organización desea evaluar el nivel de exposición a ataques de phishing entre sus empleados. Para ello, se envía una campaña simulada de correos electrónicos fraudulentos y se registra quiénes hacen clic en los enlaces.
El análisis se realiza sobre 800 empleados seleccionados de distintas áreas (administración, sistemas y ventas), utilizando la base de datos de usuarios activos de la empresa.

Identificar la población objetivo, población investigada, marco del muestreo, unidad de muestreo y/o análisis

FADENA
Universidad de la Defensa Nacional

Para pensar

SITUACIÓN: Una organización desea evaluar el nivel de exposición a ataques de phishing entre sus empleados. Para ello, se envía una campaña simulada de correos electrónicos fraudulentos y se registra quiénes hacen clic en los enlaces.
El análisis se realiza sobre 800 empleados seleccionados de distintas áreas (administración, sistemas y ventas), utilizando la base de datos de usuarios activos de la empresa.

Identificar la población objetivo, población investigada, marco del muestreo, unidad de muestreo y/o análisis

FADENA
Universidad de la Defensa Nacional

Muestreo

Tipos o Técnicas

Probabilística

No probabilística

ERROR DE MUESTREO

- Tamaño de la muestra
- Selección de unidad muestral
- Tipos



FADENA

Universidad de la Defensa Nacional

Muestreo Probabilístico

Aquel en el cual las unidades que integran la Muestra se eligen mediante **procedimientos aleatorios**, y por lo tanto es posible conocer y asignar a cada unidad de la Población una **probabilidad** de ser seleccionada.

Las muestras seleccionadas por métodos probabilísticos son **más representativas** que los métodos no probabilísticos.

Esenciales en los **diseños de investigación transeccionales**: descriptivos y correlacionales-causales

"LA SELECCIÓN ALEATORIA GARANTIZA IMPARCIALIDAD EN LA SELECCIÓN DE LAS UNIDADES DE MUESTREO"

FADENA

Universidad de la Defensa Nacional

Muestreo Probabilístico



Calcular un **tamaño de muestra** que sea representativo de la población.

Seleccionar los elementos muestrales de manera que al inicio todos tengan la **misma posibilidad** de ser elegidos.



FADENA

Universidad de la Defensa Nacional

Cálculo del tamaño de la muestra

Dado que una población es de **N** tamaño, ¿cuál es el menor número de unidades muestrales que necesito para conformar una muestra (**n**) que me asegure un determinado nivel de error estándar?

Muestra representativa



Error



Nivel de confianza

FADENA

Universidad de la Defensa Nacional

Fórmulas tamaño de muestra

Estimar proporción

Población finita

$$n = \frac{N * Z_\alpha^2 * p * q}{e^2 * (N-1) + Z_\alpha^2 * p * q}$$

Población infinita

$$n = \frac{Z_\alpha^2 * p * q}{e^2}$$

n	Tamaño de muestra buscado
N	Tamaño de la población
Z	Valor Z. Depende del Nivel de Confianza que establezca el investigador
e	Error estimado aceptado, el investigador lo establece
p	probabilidad de que ocurra el evento
q	(1-p) Probabilidad de que no ocurra el evento

FADENA

Universidad de la Defensa Nacional

Fórmulas tamaño de muestra

FADENA | Universidad de la Defensa Nacional

Calculadora de Tamaños de Muestras Cualitativa				
Población Infinita/Desconocida			**Población Finita/Conocida**	
Nivel de Confianza	99%		Nivel de Confianza	80%
Z	2,58		Z	1,28
p	15%		p	15%
q	85%		q	85%
E	5%		E	5%
			N	1000
n	**340**		**n**	**78**

FADENA

Universidad de la Defensa Nacional

Fórmulas tamaño de muestra

FADENA

Calculator.net FINANCIAL FITNESS & HEALTH

home / math / sample size calculator

Sample Size Calculator

Find Out The Sample Size

This calculator computes the minimum number of necessary samples to meet the desired statistical constraints.

Result save

Sample size: **278**

This means 278 or more measurements/surveys are needed to have a confidence level of 95% that the real value is within ±5% of the measured/surveyed value.

Confidence Level:	95%	
Margin of Error:	5 %	
Population Proportion:	50 %	Use 50% if not sure
Population Size:	1000	Leave blank if unlimited population size.

Calculate Clear

https://www.calculator.net/sample-size-calculator.html?type=1&cl=95&ci=5&pp=50&ps=1000&x=Calculate

Universidad de la Defensa Nacional

Muestreo Probabilístico: selección

Procedimientos que garantizan la incorporación aleatoria a la muestra

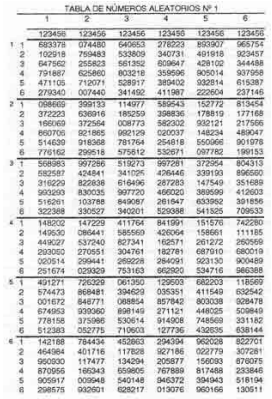


TABLA DE NÚMEROS ALEATORIOS Nº 1

	1	2	3	4	5	6
	123456	123456	123456	123456	123456	123456
1	1 683379	074480	640653	278223	853907	965754
	2 102918	759483	533809	340731	491918	923457
	3 647562	255823	561352	609647	428102	344488
	4 791667	625860	803218	358596	905014	937958
	5 471105	712071	528917	389402	932814	615387
	6 279340	007440	341492	411987	222604	237146
2	1 058669	399133	114977	589543	152772	613454
	2 372223	636916	892259	398836	178819	177168
	3 166069	372564	008773	582302	932121	217566
	4 860706	921865	992129	020037	148234	489047
	5 514639	918368	781764	254818	550966	901978
	6 776162	299518	575812	532671	097782	199153
3	1 568983	997286	519273	997281	372954	804313
	2 882587	424841	341026	426446	339193	896580
	3 316229	822838	616496	287283	147549	351689
	4 993293	830035	997720	466020	389599	412603
	5 516261	103788	949087	261947	653992	391856
	6 322388	330527	340201	529388	541326	709533
4	1 148202	147229	411764	841991	151576	742280
	2 149530	086441	585569	426064	158661	111185
	3 449027	537240	827341	162571	261272	260599
	4 293060	270551	304761	182781	687910	680019
	5 920514	209441	269228	284091	923130	900489
	6 251674	029329	753163	662900	534716	986388
5	1 491271	726329	061350	129503	682203	118569
	2 574473	868481	394629	035351	411549	632542
	3 001672	846771	068854	857842	803038	928478
	4 674953	930060	898149	271121	448025	509849
	5 778158	375986	530614	914908	748569	331182
	6 512383	052775	710603	127736	432635	638144
6	1 142188	784434	452803	294394	962028	922701
	2 464984	401716	117828	927186	022779	307281
	3 950330	117477	134294	205877	156093	876075
	4 870955	166343	659805	767889	817488	233846
	5 905917	009948	540148	946372	394943	518194
	6 298575	932601	628217	013076	960166	130511

Tablas de Números Aleatorios

Juego de azar (dados, bolilleros, ruletas, etc.)



Nº aleatorios generados por calculadoras o sistema de procesamiento electrónico (planillas de cálculo, “software” estadísticos, etc.).

FADENA

Universidad de la Defensa Nacional

MUESTREO ALEATORIO SIMPLE (MAS)



Todos los casos del universo tienen al inicio la **misma probabilidad** de ser seleccionados.

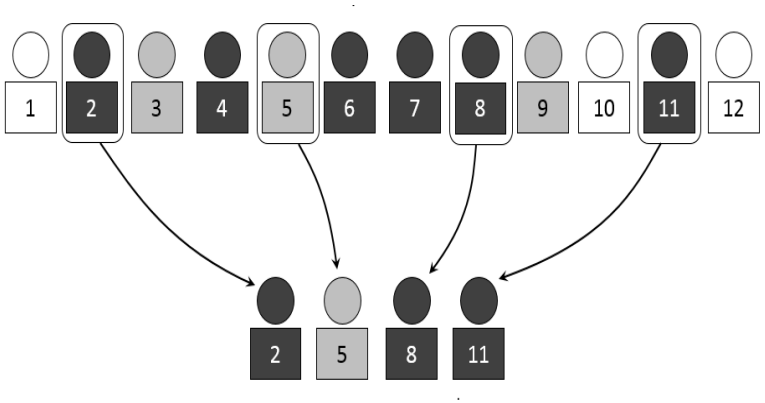
MUESTREO SISTEMÁTICO (MS)

- Derivación o forma particular del MAS, y se muestra más eficiente en el caso que, previo a la selección, las unidades se encuentran o son ordenadas en base a algún aspecto o variable que tiene que ver con la causa o variable del muestreo.
- La población no es estable o es dificultoso armar el marco de selección.

Ejemplo: *analizar el comportamiento de los eventos de seguridad en tiempo real en una red corporativa para estimar la proporción de eventos sospechosos..*

MUESTREO SISTEMÁTICO (MS)

- Procedimiento: se elige el tamaño de la muestra. Se selecciona el **factor K: N/n**, y se elige dentro del intervalo de la fracción K el **primer elemento al azar**. A este elemento se le va sumando la fracción K para ir eligiendo a los demás elementos de la muestra
- Es fundamental que los individuos estén totalmente mezclados



MUESTREO SISTEMÁTICO (MS)

Ejemplo: analizar el comportamiento de los eventos de seguridad en tiempo real en una red corporativa para estimar la proporción de eventos sospechosos. Durante una hora se registran aproximadamente: N ≈ 12.000 eventos de red

- *Se decide analizar n = 1.200 eventos*



k= N/n = 12000/1200 = 10

Inicio aleatorio: ej. 6

Evento 6 – evento 16 – evento 26 – evento 36 etc

MUESTREO ESTRATIFICADO

Considera segmentos o grupos de la población (estrato) empleando información disponible en el marco muestral.

La población se divide en segmentos y se selecciona una muestra para cada segmento (con MAS o MS).



Ejemplo: Se desea analizar eventos de seguridad según tipo de sistema en una red corporativa.

N = 1.420 eventos
n = 355 eventos
fh ≈ 0.25

$$fh = \frac{n}{N} \longrightarrow n_h = N_h \cdot fh$$

Cuántos elementos en cada estrato

Estrato	Tipo de sistema	Nh	nh
1	Servidores Web	120	30
2	Servidores de Base de Datos	200	50
3	Servidores de Correo	160	40
4	Estaciones de trabajo	300	75
5	Dispositivos móviles	220	55
6	Equipos de red	100	25
7	Sistemas en la nube	180	45
8	Aplicaciones internas	140	35

FADENA
Universidad de la Defensa Nacional

Muestreo Estratificado (ME)

Dificultades:

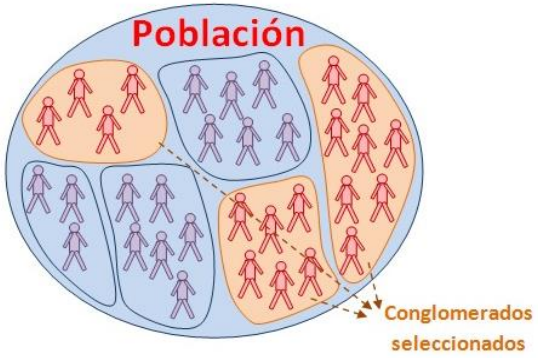
- La necesidad de contar con un marco que tenga información auxiliar.
- Dificultad para crear o formar los estratos.
- Determinar el número óptimo de estratos.
- Obliga a veces a emplear estimadores no tan simples.
- Determinar un tamaño de muestra ya que por lo general se precisa medidas de homogeneidad o de dispersión para cada estrato.

Muestreo por Conglomerados (MC)

C= Conjunto de unidades muestrales (o elementales)

Población	Unidad	Conglomerado
Habitantes de Argentina	Persona	Hogar
Viviendas de CABA	Viviendas	Manzana

Cada uno de los “Conglomerados” debe contener dentro de sí a todo tipo de unidades, y representar cada uno un fiel reflejo de la Población total; y en ese caso todos los Conglomerados deberían ser parecidos entre si en lo que concierne a su constitución o estructura interna.



MUESTREO NO PROBABILÍSTICO

- La elección de los elementos depende de causas relacionadas con las características de la investigación o de quien hace la muestra. De las decisiones del investigador: **“guiadas por uno o varios propósitos”**.
- En estos procedimientos no se puede determinar el error de muestreo y las muestras quedan libradas a errores sistemáticos incontrolados.
- La selección no aspira a que las unidades sean estadísticamente representativas de la población.
- No generalización.

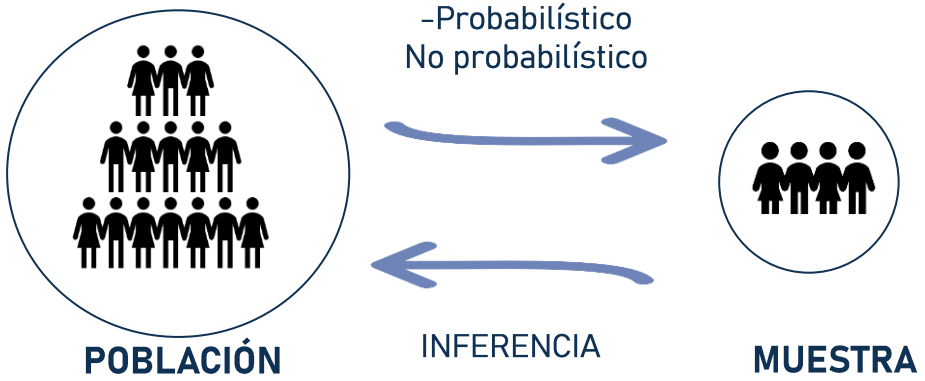
“LA SELECCIÓN ALEATORIA GARANTIZA IMPARCIALIDAD EN LA SELECCIÓN DE LAS UNIDADES DE MUESTREO”

MUESTREO NO PROBABILÍSTICO

- De participantes voluntarios o autoseleccionada.
- De expertos.
- De casos tipos o intencional .
- Por cuotas.
- Cuasi probabilístico.
- De captura y recaptura.
- Orientadas a la investigación cualitativa

DATOS OBSERVADOS

INFERENCIA



POBLACIÓN	MUESTRA
μ	$\overline{X}$
σ	S
p	f
ρ	r



Actividades NO obligatorias
Sección ACTIVIDADES
Prácticas

ACTIVIDADES

FADENA

Universidad de la Defensa Nacional



Actividad obligatoria: Autoevaluación 4

AUTOEVALUACIÓN

FADENA

Universidad de la Defensa Nacional

MUCHAS GRACIAS

FADENA | Universidad de la Defensa Nacional