Eduardo Bologna

Métodos Estadísticos de Investigación



00026157

Editorial Brujas

Capítulo 7 Probabilidad: los fundamentos

El rol de la probabilidad en Estadística

Para hacer inferencias se requiere de la probabilidad porque se trabaja con situaciones inciertas, que no se conocen y que son difíciles de prever. Por eso se comienza aquí haciendo la distinción entre las preguntas que pueden responderse con certeza y las que no. De las primeras, son ejemplos: ¿cuándo será el próximo eclipse de sol? ¿Cómo cambia la conducta de una persona si consume una sustancia alucinógena? Sobre estas preguntas tenemos, o bien un conocimiento profundo sobre el movimiento de los astros, o bien una gran cantidad de observaciones, que nos permiten dar una respuesta certera.

Por el contrario, si preguntamos ¿cuál es el efecto sobre la personalidad, de haber tenido figuras parentales autoritarias en la niñez? ¿Qué determina que algunos alumnos tengan éxito en la escuela y otros no? ¿Cómo afecta la estabilidad económica a la intención de voto?, solo podemos ofrecer respuestas parciales, tentativas, aproximadas. Se trata de hechos que dependen de muchos factores a los que no conocemos en su totalidad, por lo que el resultado es variable: algunas personas criadas en ambientes autoritarios desarrollan una personalidad autoritaria, otras no. En algunos alumnos, el hecho que sus padres tengan estudios elevados los ayuda a tener éxito en la escuela, pero también hay hijos de personas muy educadas que fracasan en la escuela. La estabilidad económica que favorecería una reelección, puede estar acompañada de mucha pobreza, o de corrupción; también eventos inesperados antes de las elecciones pueden cambiar decisiones a último momento. Hay razones más allá de nuestro alcance que inciden en la personalidad o en el resultado de la escuela, o la intención de voto. En estas situaciones, cuando no tenemos toda la información que hace falta para predecir el resultado, recurriremos a la probabilidad.

Ingresaremos al tema desde situaciones muy sencillas, desde el muy usado ejemplo de arrojar una moneda. Pero detengámonos un momento en él: si tuviéramos toda la información necesaria para predecir la trayectoria de la moneda en el aire (distancia desde donde se arroja, fuerza que se le aplica, el lugar de la moneda donde se aplica esa fuerza, eventuales corrientes de aire que puedan incidir en el desplazamiento de la moneda, etc.), podríamos predecir con certeza el resultado. Esa información no está disponible, el lado del que caiga la moneda está determinado por una multiplicidad de factores, por esa razón no podemos anticipar el resultado de la tirada. A esa ignorancia la resumimos diciendo que el resultado de la tirada de la moneda "depende del azar" y llamamos al experimento de tirar una moneda "experimento aleatorio".

Es un paso muy largo ir desde este ejemplo a decir que el modo en que se desarrolle la personalidad de alguien que ha sido criado en una familia autoritaria depende del azar. Sabemos que no depende del azar, depende de muchos factores que ignoramos, por eso usaremos probabilidades en nuestra disciplina. Podremos decir que un alumno cuyos padres valoran la educación tiene una probabilidad mayor de tener éxito en la escuela, pero no podremos asegurar que lo tendrá. Es razonable creer que si un gobierno logró estabilidad económica, tendrá más posibilidades de ser reelegido, pero no hay certeza sobre que lo será. Los tratamientos más exitosos encuentran casos en los que no logran resultados, por lo que su efectividad no puede garantizarse completamente, hay una componente impredecible en la evolución de la patología.

La probabilidad trata con la incertidumbre, con lo que hay entre la certeza en que algo ocurrirá y la certeza en que no ocurrirá.
Los eventos que no son azarosos no tienen que ver con probabilidades: no asignamos probabilidad a un eclipse porque hay conocimiento suficiente como para saber cuándo ocurrirá; pero sí se asigna probabilidad a una tormenta, porque no se conocen simultáneamente todos los factores que la determinan. Se asignan probabilidades a hechos de cuya ocurrencia no se tiene certeza. Con la probabilidad se cuantifica (se le asigna un número) a la expectativa sobre el fenómeno. Intuitivamente, cuando decimos que algo tiene "mucha probabilidad de suceder" es porque estamos bastante seguros que sucederá. Esta es la posición conocida como "azar epistemológico", que considera azarosos o aleatorios a los eventos cuya ocurrencia no puede anticiparse con certeza. Desde esta posición, que sea azaroso o no, depende el conocimiento que se tenga sobre los determinantes del evento.

La cuantificación de la probabilidad implica que ésta se expresa con un número que está comprendido entre cero y uno. Que un evento tenga probabilidad cero significa que es imposible que suceda. Si un evento tiene probabilidad igual a uno, se llama "evento seguro", y quiere decir que hay certeza en que sucederá.

Formas para asignar probabilidades

Asignación a priori

Podemos partir de esa idea intuitiva de probabilidad, ligada a procesos cuya ocurrencia no nos es conocida con certeza. Para evocar esta idea, el ejemplo que más a menudo se cita es el del lanzamiento de una moneda, ¿cuál es la probabilidad de obtener "cara" al arrojar una moneda? Si la respuesta es ½ (o 0,50 ó 50 y 50), debe tenerse en cuenta que eso solo será cierto si la moneda está equilibrada, es decir si tiene iguales chances de salir de un lado que del otro. Si esto es cierto, efectivamente la probabilidad de obtener cara es ½ (ó 0,50). Con idéntica condición, la probabilidad de obtener un 5 al arrojar un dado es 1/6 (ó 0,17). Esta asignación de probabilidad a los resultados de un experimento es previa a su realización, no es necesario tirar realmente la moneda: es suficiente con que tengamos razones para *suponer* que está equilibrada, para que afirmemos que la probabilidad de cara es ½. Diremos en este caso que asignamos la probabilidad *a priori*, es decir, antes de hacer el experimento.
De mismo modo sucede si el evento que nos interesa en un poco más complejo. Por ejemplo: ¿Cuál es la probabilidad de obtener un número mayor a cuatro si se tira un dado? Debido a que hay dos números mayores a cuatro (5 y 6), el evento tiene dos casos a su favor y hay seis resultados posibles, por lo que la probabilidad será: 2/6 (ó 1/3, si se simplifica la fracción).
La expresión formal de esta asignación de probabilidades es

$$P(A) = \frac{\#A}{\#\Omega}$$

En la que #A (que se lee "numeral de A") indica el número de maneras en que puede suceder el evento A, y #Ω (numeral de omega) es el número total de resultados que se pueden obtener al realizar el experimento. Ω es el conjunto de resultados posibles, es llamado *espacio muestral*. En el caso del ejemplo, el experimento es el de tirar el dado y buscar un número mayor que cuatro, #A es 2

porque son las formas en que puede obtenerse un número mayor que cuatro, y #Ω es 6, que es el número total de resultados posibles al tirar un dado.
Con este mismo razonamiento, la probabilidad de obtener un número par es 3/6 (1/2 después de simplificar), porque hay tres números pares (2, 4 y 6) en un dado.
Vamos a un caso más complejo: tiremos ahora dos dados y tomemos en cuenta la suma de los dos puntajes, a esa suma la llamaremos S. El mínimo número que puede resultar es dos (que ambos dados salgan uno) y el máximo es doce (ambos seis), entonces hay once resultados posibles de esta variable (que son: S = 2, S = 3, S = 4, S = 5, S = 6, S = 7, S = 8, S = 9, S = 10, S = 11 y S = 12), algunos de los cuales pueden suceder de varias formas. Estos resultados posibles y sus formas de obtención se ven de manera esquemática a continuación:

Esquema 1: Resultados posibles de la suma de los puntajes de dos dados

		Primer dado					
		1	**2**	**3**	**4**	**5**	**6**
Segundo dado	**1**	2	3	4	5	6	7
	2	3	4	5	6	7	8
	3	4	5	6	7	8	9
	4	5	6	7	8	9	10
	5	6	7	8	9	10	11
	6	7	8	9	10	11	12

Si bien los resultados posibles son 11, las formas en que estos pueden darse son 36; cada una de esas formas es un evento. El evento primer dado 5 y segundo dado 2 es diferente del evento primer dado 2 y segundo dado 5, aunque ambos conducen al mismo resultado: S=7. Más precisamente, si indicamos los eventos con pares ordenados, los eventos (1,6); (6,1); (2,5); (5,2); (3,4); (4,3) son diferentes pero todos corresponden a S=7.
Son entonces 36 los resultados posibles del experimento, por lo que #Ω = 36. Ahora podemos calcular probabilidades para diferentes resultados.
¿Cuál es la probabilidad que la suma sea 12?, lo que puede expresarse como: ¿cuál es P(S=12)? Como esta suma solo puede lograrse si ambos dados salen 6, hay una sola manera en que se produzca el evento que nos interesa (suma doce), por lo que el #A es 1 y la probabilidad es entonces 1/36.

$$\#A = 1,\ P(S = 12) = 1/36$$

		Primer dado					
		1	**2**	**3**	**4**	**5**	**6**
Segundo dado	**1**	2	3	4	5	6	7
	2	3	4	5	6	7	8
	3	4	5	6	7	8	9
	4	5	6	7	8	9	10
	5	6	7	8	9	10	11
	6	7	8	9	10	11	12

En cambio, si la pregunta es por la probabilidad de obtener un tres, hay más de una manera de llegar a ese resultado (que S = 3). La suma 3 puede resultar de 2+1 ó de 1+2, es decir que, o bien el primer dado sale 2 y el segundo 1 ó bien el

primero sale 1 y el segundo 2. Hay así dos formas posibles para el evento S = 3, y #A es 2, por lo que la probabilidad es P(S = 3) = 2/36.

#A = 2, P(S = 3)=2/36

		Primer dado					
		1	2	3	4	5	6
Segundo dado	1	2	3	4	5	6	7
	2	3	4	5	6	7	8
	3	4	5	6	7	8	9
	4	5	6	7	8	9	10
	5	6	7	8	9	10	11
	6	7	8	9	10	11	12

Otro ejemplo, sea P(S=7). La suma de siete puede obtenerse de muchas formas: 1+6, 2+5, 3+4, 4+3, 5+2 ó 6+1. Hay seis combinaciones que conducen a S=7, en consecuencia, la probabilidad es 6/36.

#A = 6, P(S = 7)=6/36

		Primer dado					
		1	2	3	4	5	6
Segundo dado	1	2	3	4	5	6	7
	2	3	4	5	6	7	8
	3	4	5	6	7	8	9
	4	5	6	7	8	9	10
	5	6	7	8	9	10	11
	6	7	8	9	10	11	12

Dos casos particulares

1. Jamás se obtendrá uno (1) al sumar los resultados de dos dados, por lo que el evento S = 1 es imposible y si preguntáramos por P(S = 1), la respuesta es cero, como lo es también si pedimos P(S>12). De manera general, diremos que la probabilidad de un evento imposible es cero, decir que un evento tiene probabilidad igual a cero, equivale a decir que no puede suceder.
2. Inversamente, al tirar dos dados siempre se obtendrá un número menor que 13, por lo tanto, el evento S<13 siempre sucede. Esto es así porque S<13 incluye todos los resultados posibles, lo mismo sería si se pidiera que S<14 o que S<75, o también S>1, cualesquiera de ellas coincide con Ω. Para indicar este tipo de evento, sobre el que hay certeza absoluta de su aparición, decimos que su probabilidad es uno. Así, P(Ω)= 1. Decir que un evento tiene probabilidad uno equivale a decir que hay completa seguridad que va a suceder.

Asignación a posteriori

Consideremos ahora una situación más cercana a la experiencia: supongamos que de un curso se selecciona un alumno al azar ¿Cuál es la probabilidad que sea mujer? Aquí el supuesto de equilibrio no es válido a priori, en gran medida depende de la carrera de que se trata, las hay con muchas mujeres y con pocas. Por lo tanto no podemos suponer que es igualmente probable que resulte un varón o una mujer y no podemos asignar probabilidad ½ a cada resultado. Aunque el experimento tenga dos resultados posibles, éstos no son igualmente probables.

En otro ejemplo, si al alumno aleatoriamente seleccionado se le pregunta por el tipo de colegio del que egresó, con los resultados posibles: "público", "privado laico", "privado religioso", el resultado que se obtenga también depende del azar, porque así fue elegido el alumno, la respuesta será una u otra según cuál sea el alumno elegido y esto depende del azar. Sin embargo, no podemos asignar una probabilidad igual a cada resultado, no es lícito decir que sea 1/3, ya que puede haber más estudiantes que provengan de colegios públicos que de privados y, en consecuencia, que sea más probable encontrar alumnos provenientes de esos colegios que de los otros. En este caso no podemos asignar de antemano probabilidades a los diferentes resultados, porque no tenemos suficientes razones para suponer *la forma en que se distribuyen* las probabilidades. Si supiéramos que hay el doble de alumnos que vienen de colegios públicos, podríamos decir que el alumno elegido al azar tiene el doble de probabilidad de provenir de un colegio público que de otro tipo.

Encontramos así una relación entre la frecuencia y la probabilidad: si conocemos la distribución de frecuencias, tenemos razones para usarlas para asignar probabilidades a los resultados del experimento. Así, si una muestra de alumnos ofrece la siguiente distribución de frecuencias para el tipo de colegio del que provienen.

Tabla 1: Distribución de frecuencias del tipo de colegio del que provienen alumnos que ingresan a la universidad

	f	f
Público	200	0,66
Privado laico	20	0,07
Privado religioso	80	0,27
Total	300	1,00

Fuente: datos ficticios para ejemplificación

Estamos autorizados a decir que la probabilidad que el alumno elegido al azar provenga de un colegio público es 0,66, que es su frecuencia relativa. Esto será válido en la medida que el número de casos sea elevado; no es posible transformar una frecuencia relativa en probabilidad si tenemos muy pocas observaciones. Más adelante volveremos sobre esta importante limitación.

Cuando atribuimos probabilidades de este modo se trata de probabilidades *a posteriori*, es decir con posterioridad a haber hecho la experiencia, luego de la observación de los resultados reales obtenidos. También se llama a estas probabilidades *empíricas*, para destacar que provienen de la experiencia.

¿Cuál es el significado del 1,00 que corresponde al total? Sin dudas, como frecuencia significa el 100% de los casos, pero como probabilidad indica que el conjunto completo de alternativas (público, privado laico, privado religioso) tiene

probabilidad 1,00; o bien que es un *evento seguro*. La expresión coloquial para este valor es que cuando se selecciona un alumno al azar, éste debe provenir de alguno de los tres tipos de colegio indicados, entonces el valor uno responde a la pregunta "¿cuál es la probabilidad de encontrar un alumno que provenga de un colegio público, privado laico o privado religioso?", la respuesta es que es seguro que de alguno de esos tipos de colegio provendrá el alumno, no hay otras alternativas, es decir que las categorías son exhaustivas, como debe ser. En este caso,

$$\Omega = \{público, privado\ laico, privado\ religioso\}$$

Como vimos más arriba, el evento seguro es el que tiene probabilidad 1, por lo que la expresión formal de este enunciado es:

$$P(\Omega) = 1$$

Donde Ω indica el conjunto de todos los resultados posibles de un experimento aleatorio, o el conjunto de todas las categorías de un variable, al que hemos llamado *espacio muestral*.

La relación entre asignación a priori y a posteriori

Volvamos al experimento simple de arrojar la moneda: si ésta se encuentra equilibrada será entonces correcto asignar probabilidad ½ (ó 0,50) a cada lado, lo que indica que esperamos que *a la larga* la moneda caiga la mitad de las veces cara y la mitad cruz. Destaquemos la expresión "a la larga", que quiere decir "si se arroja muchas veces". Hagamos el experimento realmente, busque usted una moneda y arrójela, digamos 10 veces. Yo lo hice y obtuve la siguiente secuencia de resultados: CXXXCCCXXC.

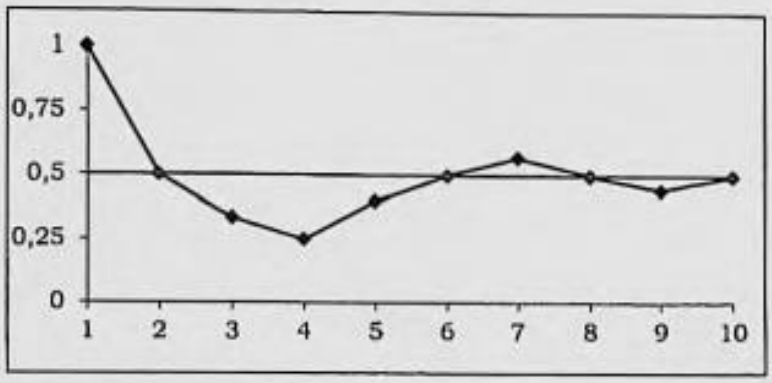
Elijamos nuestro lado favorito, que sea "cara" (C) y calculemos la frecuencia relativa de ese lado en cada tirada, presentamos los resultados resumidamente en la tabla 2. Cuando solo la he tirado una vez y como el primer resultado fue C, la frecuencia es 1 (una cara de un total de un resultado). A la segunda tirada, que es X, se obtiene ½ (una cara de dos tiradas). A la tercera, que otra vez sale X, la frecuencia de cara es 1/3 (una cara de tres tiradas) y así sigue:

Tabla 2: Frecuencias relativas correspondientes a una secuencia de diez lanzamientos de una moneda

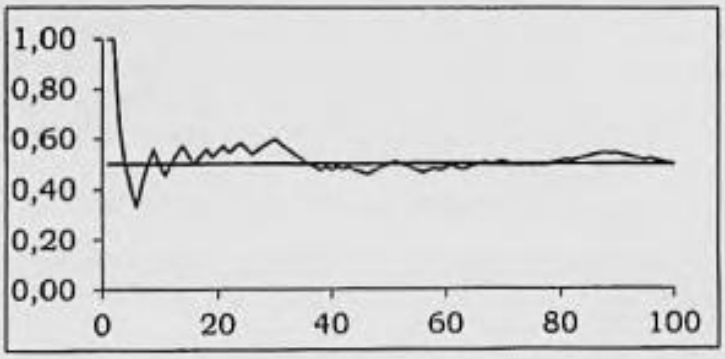
Tirada	Cantidad de tiradas	Resultado	Cantidad de caras acumuladas	Frecuencia relativa del evento "cara"
Primera	1	C	1	1/1 = 1,00
Segunda	2	X	1	1/2 = 0,50
Tercera	3	X	1	1/3 = 0,33
Cuarta	4	X	1	1/4 = 0,25
Quinta	5	C	2	2/5 = 0,40
Sexta	6	C	3	3/6 = 0,50
Séptima	7	C	4	4/7 = 0,57
Octava	8	X	4	4/8 = 0,50
Novena	9	X	4	4/9 = 0,44
Décima	10	C	5	5/10 = 0,50

En la distribución vemos que la frecuencia relativa de C toma valores alrededor de 0,50; al principio más lejos y luego "se va acercando" a ese número cuando

hemos hecho más tiradas. La representación gráfica de este proceso es la siguiente:



Donde hemos agregado una linea que muestra el valor 0,50 que es el que habiamos calculado antes de hacer el experimento. Se aprecia que la sucesión de frecuencias relativas es tal que éstas se van acercando a la probabilidad predicha. Si la moneda se hubiese tirado una cantidad mayor de veces (cien veces, por ejemplo), el gráfico tendria una forma como la siguiente:



Resulta entonces que, si se cumple que la moneda está equilibrada, entonces las frecuencias relativas de un resultado se irán acercando a la probabilidad asignada. Dicho de otra manera, la probabilidad a posteriori converge a la probabilidad a priori. Mucha atención a esto: solo en el caso que el supuesto inicial se cumpla, es decir que la moneda se comporte como esperamos (cayendo parejo de un lado y del otro).

Si por el contrario, la moneda estuviese desequilibrada —y que fuera más frecuente el lado X que el lado C—, podriamos obtener, en 500 tiradas, por ejemplo, 350 veces X y la probabilidad a posteriori será entonces P(C) = 350/500 = 0,70 y no 0,50 como seria si estuviera equilibrada. En ese caso el supuesto inicial de moneda equilibrada se muestra falso, decimos que "el modelo no se sostiene", en un momento veremos con más detalle el significado de esta expresión.

Hasta este punto
1. Si se sabe que los diferentes eventos tienen la misma probabilidad de ocurrir, entonces se puede asignar la probabilidad *a priori* que significa "antes de hacer ningún experimento".
2. Cuando no es posible conocer de antemano la probabilidad, entonces debe hacerse el experimento, que consiste en observar y contar las veces que sucede el evento que nos interesa. Con esta información podemos calcular de manera aproximada las probabilidades de cada evento, a través de las frecuencias relativas, a las que llamamos probabilidades *a posteriori*. A medida que sean más los casos observados, tanto más cerca estarán las frecuencias relativas de las probabilidades.
3. Si el supuesto inicial (que en este ejemplo es de iguales probabilidades) es verdadero, entonces las frecuencias relativas se acercarán a las probabilidades a priori.

Operando con probabilidades

Cualquiera sea el modo a través del que se hayan asignado probabilidades a eventos, las probabilidades cumplen con ciertas propiedades generales, que trataremos a continuación y que permiten hacer operaciones con ellas.
En primer lugar, y con carácter de axiomas, las siguientes características son condición para que un número P(A) pueda ser considerado una probabilidad:
-La probabilidad es un número comprendido entre cero y uno: $0 \leq P(A) \leq 1$
-La probabilidad del conjunto completo de resultados posibles (del espacio muestral) es uno: $P(\Omega) = 1$
-La probabilidad de la unión de dos eventos que se excluyen mutuamente es la suma de las probabilidades de cada uno de ellos: $P(A \cup B) = P(A) + P(B)$

La definición frecuencial (a posteriori), así como todos los modelos de asignación de probabilidad a priori que mencionamos cumplen con estas condiciones.

Con probabilidades frecuenciales

Sea una distribución conjunta de dos variables con asignación de probabilidades frecuenciales, es decir empíricas. Se trata de la relación entre la ciudad donde se vive y la intención de voto. Las categorías de la ciudad son: Córdoba, Rosario y Mendoza. Los partidos políticos son cuatro y los llamaremos Q, R, S y T. Supongamos que las siguientes son las frecuencias observadas luego de recoger los datos:

Tabla 2: Distribución del partido al que declara que va a votar y la ciudad de residencia.

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	650
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	260	320	1530

Calculemos algunas probabilidades a partir de las frecuencias relativas.

Probabilidades marginales

Cuando se consideran las categorías de una variable sin tener en cuenta a la otra, usamos las frecuencias de los márgenes de la tabla, esas son las llamadas **frecuencias marginales**. La probabilidad que una persona elegida al azar viva en Córdoba (sin importar a qué partido piense votar) es 650/1530. De manera equivalente, la probabilidad de encontrar por azar a alguien que piense votar al partido S (cualquiera sea su ciudad) es 260/1530. Las escribimos simplemente P(Córdoba) y P(S) respectivamente. En las tablas siguientes están destacadas las frecuencias que participan en el cálculo de estas probabilidades.

Tabla 3: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad marginal P(Córdoba)

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	**650**
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	260	320	**1530**

Tabla 4: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad marginal P(S)

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	650
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	**260**	320	**1530**

Probabilidades conjuntas o de la intersección de eventos

Las usamos para hallar la probabilidad de ocurrencia simultánea de una categoría de cada variable. Por ejemplo ¿Cuál es la probabilidad de encontrar por azar a alguien que viva en Rosario años **y** que piense votar al partido R? La cantidad de individuos que cumplen **simultáneamente** las dos condiciones es de 150, por lo que la probabilidad se calcula como 150/1530. Hemos destacado la

conjunción "y", junto al "simultáneamente" porque en este caso se piden dos condiciones juntas. Por eso estas son llamadas **probabilidades conjuntas**.
En teoría de conjuntos, corresponden a la intersección de dos conjuntos, que se indica con el signo∩, por lo que el evento "vivir en Rosario" y al mismo tiempo "decir que se va a votar a R", se escribe "$Rosario \cap R$".
Esa intersección puede verse gráficamente en el cruce de la fila con la columna correspondiente.

Tabla 5: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad conjunta P(Rosario y R)

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	650
Rosario	100	**150**	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	260	320	**1530**

¿Qué sucede si aplicamos esta operación a dos eventos que corresponden a dos categorías de la misma variable?, por ejemplo, ¿cuál es la probabilidad de encontrar a alguien que diga que votará a Q y a R? Esos eventos no pueden suceder juntos porque son incompatibles: solo uno de los dos puede suceder. La intersección entre ellos es imposible, por lo que la probabilidad es cero. Es el mismo caso de buscar a alguien que viva en Córdoba y también en Mendoza, es claro que no hay intersección entre estos conjuntos; dicho de otra forma, la intersección es el conjunto vacío. A estos eventos que no pueden suceder simultáneamente, los llamaremos mutuamente excluyentes. Como recordamos, esa es la condición que deben cumplir las categorías de cualquier variable.
Si dos eventos son mutuamente excluyentes entonces, su probabilidad conjunta es cero. En lenguaje de conjuntos:

$$si\ A \cap B = \emptyset\ entonces\ P(A \cap B) = 0$$

Probabilidad de la unión de eventos mutuamente excluyentes
Estas probabilidades sirven para analizar la ocurrencia de uno u otro de dos eventos, cuando éstos no pueden suceder simultáneamente. Por ejemplo: ¿qué probabilidad hay de encontrar a alguien que piense votar a Q **o** a R? Esto quiere decir "una cosa o la otra", se trata de una disyunción, es decir, la unión de los dos eventos. En el lenguaje de la teoría de conjuntos la unión de dos conjuntos se indica con el símbolo ∪, por lo que decir "A o B" equivale a decir "A∪ B".
El total de quienes cumplen con la condición de votar a Q o a R (sin tener en cuenta la ciudad) es de 950 (350 + 600), por lo que la probabilidad es de 950/1530.

Tabla 6: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad P(Q o R) (eventos disjuntos).

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	650
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	**350**	**600**	260	320	**1530**

De modo equivalente, la probabilidad de seleccionar al azar a alguien que viva en Córdoba o en Rosario es de 1030/1530, donde hemos sumado las dos primeras categorías (Córdoba y Rosario).

Tabla 7: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad P(Córdoba o Rosario) (eventos disjuntos).

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	**650**
Rosario	100	150	60	70	**380**
Mendoza	50	150	100	200	500
Total	350	600	260	320	**1530**

En estas probabilidades, admitimos que se cumpla cualquiera de las dos condiciones (Q **o** R en el primer caso, Córdoba **o** Rosario en el segundo). En los dos ejemplos se trata de eventos que no pueden suceder simultáneamente, por ser categorías de una de las variables, son mutuamente excluyentes, por lo que la probabilidad de su ocurrencia conjunta es cero. En estos casos, la probabilidad de la unión es simplemente la suma de las probabilidades de los dos eventos: $P(A \cup B) = P(A) + P(B)$

Aplicada a los ejemplos:
$P(Q \cup R) = P(Q) + P(R)$
$P(Córdoba \cup Rosario) = P(Córdoba) + P(Rosario)$

Probabilidad de la unión de eventos no mutuamente excluyentes
Vamos ahora a incluir en la operación de unión de eventos, aquellos que no se excluyan mutuamente. Para el ejemplo con el que venimos trabajando, cambiamos las condiciones de esta unión de eventos: Ahora preguntamos: ¿Cuál es la probabilidad de hallar por azar a alguien que viva en Córdoba **o** que piense votar al partido T? Otra vez es una disyunción, por lo que admitimos cualquiera de los dos eventos: que viva en Córdoba (sin importar a quién piense votar) **o** que piense votar a T (cualquiera sea su ciudad). Si intentamos el mismo procedimiento que en el caso anterior, deberíamos sumar las probabilidades: 650/1530 + 320/1530, con solo observar la Tabla 8, vemos que los 50 individuos que cumplen las dos condiciones (viven en Córdoba y votarán a T), han sido contados dos veces: en los 650 y en los 320, por lo que deben descontarse del resultado haciendo 650/1530 + 320/1530 – 50/1530.

¿Por qué sucedió esto?, porque los eventos cuya unión estamos considerando pueden ocurrir simultáneamente, tienen intersección y es esa intersección justamente la que aparece en el cálculo de las dos probabilidades que se suman. Esta última expresión tiene forma:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Y es la expresión más general para el cálculo de la probabilidad de la unión de conjuntos. Esta fórmula toma la forma simplificada que usamos antes $P(A \cup B) = P(A) + P(B)$ solo cuando A y B son disjuntos, es decir cuando se excluyen mutuamente como lo indica el tercer axioma.
Aplicada al ejemplo, el cálculo es:

$$P(Córdoba \cup T) = P(Córdoba) + P(T) - P(Córdoba \cap T) = \frac{650}{1530} + \frac{320}{1530} - \frac{50}{1350} = \frac{920}{1530}$$
$$= 0{,}60$$

Tabla 8: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad P(Córdoba o T) (eventos no disjuntos).

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	**50**	**650**
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	260	**320**	**1530**

Probabilidad condicional
Este es el caso en que necesitamos calcular una probabilidad bajo una condición, que restringe el conjunto de resultado posibles. Se aplica cuando se cuenta con información adicional antes de calcular una probabilidad, por ejemplo que se sepa que la persona seleccionada al azar vive en Córdoba. ¿Cuál es la probabilidad que piense votar al partido S? El planteo es tal que preguntamos cuál es la probabilidad de votar a S si se sabe que vive en Córdoba. Vivir en Córdoba es la condición y se escribe: S/Córdoba, y lo leemos "S, dado que vive en Córdoba".
En este caso, el dato "vive en Córdoba" es una restricción sobre el conjunto total, ya no debemos tener en cuenta a las 1530 personas del total, sino solo a los que cumplen con la condición de vivir en Córdoba. Entonces ahora, el nuevo total es de solo 650 personas, los que viven en Córdoba. De ellos, 100 piensan votar a S, por lo que la probabilidad que nos interesa es 100/650.
Entonces: $P\left({}^{S}/_{Córdoba}\right) = \frac{100}{650} = 0{,}15$.

Tabla 9: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad condicional P(*S/Córdoba*)

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	**100**	50	**650**
Rosario	100	150	60	70	380
Mendoza	50	150	100	200	500
Total	350	600	260	320	1530

Razonando del mismo modo, si se sabe que la persona elegida piensa votar a R, el total queda restringido a 600 casos (los que cumplen con esa condición). Si nos interesa la probabilidad que viva en Mendoza, bajo esa restricción resulta: 150/600.

Entonces: $P\left(Mendoza/_{R}\right) = \frac{150}{600} = 0{,}25$

Tabla 10: Distribución del partido al que declara que va a votar y la ciudad de residencia. Esquema para el cálculo de la probabilidad condicional P(*Mendoza/R*)

Ciudad	Partido al que dice que votará				Total
	Q	R	S	T	
Córdoba	200	300	100	50	650
Rosario	100	150	60	70	380
Mendoza	50	**150**	100	200	500
Total	350	**600**	260	320	1530

En estos dos últimos ejemplos, el cambio respecto de todos los anteriores es que el denominador de las probabilidades ya no es 1530 sino un número menor, que resulta de haber impuesto previamente una condición: que viva en Córdoba en el primer caso y que haya votado a R en el segundo. Como se ve, estas probabilidades condicionales no son conmutativas:

-Se selecciona una persona al azar entre quienes votarán a R, ¿Cuál es la probabilidad que viva en Mendoza? Se escribe P(*Mendoza/R*) y vale 150/600

-Se selecciona una persona al azar entre los que viven en Mendoza, ¿Cuál es la probabilidad que vaya a votar a R? Se escribe P(*R/Mendoza*) y vale150/500.

Relación entre probabilidades condicionales y conjuntas

Compararemos ahora la probabilidad de hallar alguien que vaya a votar a Q y que viva en Córdoba (P(*Q∩Córdoba*)) con la probabilidad que vaya a votarlo si se sabe que vive en Córdoba (P(*Q/Córdoba*)).

$$P(Q \cap Córdoba) = \frac{200}{1503}$$

$$P(Q/Córdoba) = \frac{200}{650}$$

Si dividimos entre si estas dos expresiones obtenemos:

UNIVERSIDAD TECNICA
BIBLIO
Ibarra

$$\frac{P(Q \cap Córdoba)}{P(Q/Córdoba)} = \frac{\frac{200}{1503}}{\frac{200}{650}} = \frac{650}{1503}$$

El último cociente es la probabilidad marginal correspondiente a Córdoba, por lo que:

$$\frac{P(Q \cap Córdoba)}{P(Q/Córdoba)} = P(Córdoba)$$

Esta expresión, que es general, nos ofrece una relación muy útil entre las probabilidades condicional y conjunta. Una forma más frecuente de escribir esta relación, para dos eventos cualesquiera A y B es:

$$P(A \cap B) = P(B) * P(A/B)$$

Si escribimos la intersección en orden inverso[46], tenemos:

$$P(B \cap A) = P(A) * P(B/A)$$

Como son iguales los primeros miembros de las dos expresiones anteriores, igualamos los segundos miembros, para obtener:

$$P(B) * P(A/B) = P(A) * P(B/A)$$

Esta igualdad relaciona las probabilidades condicionales en un orden o en el otro. Conociendo las probabilidades de A y B, esa igualdad nos permite pasar de P(A/B) a P(B/A), veremos más adelante que se trata de un resultado muy valioso.

Con probabilidades a priori

Veamos el uso de estas operaciones con probabilidades usando ahora un experimento en el que asignamos probabilidades a priori. Sea una caja que contiene 4 fichas rojas y 3 azules. ¿Cuál es la probabilidad de sacar una roja en la primera extracción? Como #Roja es 4 y #Ω es 7, la probabilidad vale 4/7. De mismo modo, la probabilidad de una azul es 3/7.

Hagamos ahora dos extracciones sucesivas de modo tal que no reponemos la primera ficha antes de sacar la segunda, este tipo de extracción se llama *sin reposición*. Saco la primera, veo su color y saco la segunda sin devolver la primera. ¿Cuál es la probabilidad que salga la segunda azul si la primera fue roja? En este caso, a la segunda extracción hay 3 azules sobre un total de 6 fichas (porque ya sacamos una), entonces #Azul = 3 y #Ω = 6 y la probabilidad es $P(A_2/R_1) = 3/6$ (ó 1/2).

Otro caso: ¿Cuál es la probabilidad que la segunda sea azul si la primera fue azul? Ahora quedan 2 azules, porque ya sacamos una, sobre un total de 6 fichas, por lo que la probabilidad es $P(A_2/A_1)=2/6$ (ó 1/3). Sucede entonces que la probabilidad de obtener una ficha azul a la segunda extracción *depende* de lo que haya resultado en la primera.

Otro problema: ¿cuál es la probabilidad de sacar dos rojas en dos extracciones sin reposición? Lo escribimos: $P(R_1 y R_2)=P(R_1 \cap R_2)$

Y aplicamos la relación que encontramos al final del apartado anterior:

---

[46]La intersección de dos eventos es conmutativa: $P(A \cap B)=P(B \cap A)$

$$P(R_1 \cap R_2)=P(R_1)*P(R_2/R_1)=(4/7)*(3/6)=2/7$$

Que es la probabilidad que salga roja la primera multiplicada por la probabilidad que salga roja la segunda condicionada a que ya haya salido roja la primera (es decir, con el espacio muestral restringido) .

Del mismo modo, la probabilidad de sacar dos azules es

$$P(A_1 \cap A_2)=P(A_1)*P(A_2/A_1)=(3/7)*(2/6)=1/7$$

Nuevamente, es la probabilidad de azul la primera por la probabilidad de azul la segunda condicionada a que ya haya salido azul la primera.
Ahora preguntamos por la probabilidad de obtener una azul y una roja, en cualquier orden. Esto equivale a pedir azul la primera y roja la segunda o bien roja la primera y azul la segunda, por lo que:

$$P((A_1 \cap R_2) \cup (R_1 \cap A_2)) = P(A_1 \cap R_2)+P(R_1 \cap A_2)=P(A_1)P(R_2/A_1)+P(R_1)*P(A_2/R_1)$$

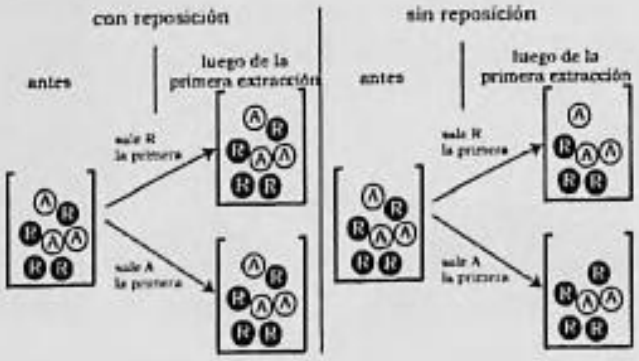
Si cambiamos el experimento reponiendo ahora la primera ficha antes de extraer la segunda, llamamos al experimento *extracción con reposición*. De este modo se restaura el espacio muestral al estado inicial. Por esta razón, la probabilidad de la segunda extracción será la misma que la de la primera para cualquier evento. Por ejemplo, $P(A_2/A_1)$ es 3/7, como lo es también $P(A_2/R_1)$. Que la primera haya sido azul o roja no afecta la probabilidad de la segunda extracción, ya que se la repone: la segunda extracción no depende de la primera. En el caso de extracciones con reposición —en que la segunda extracción no se ve afectada por el resultado que haya dado la primera—decimos que los eventos son **independientes** y resulta que, para dos eventos cualesquiera A y B:

$$P(A/B) = P(A)$$

Lo cual, dicho en lenguaje cotidiano nos indica que, para la ocurrencia del evento A, no importa que haya sucedido o no el evento B. Debido a esto, en nuestro ejemplo, la probabilidad de obtener dos rojas es:

$$P(R1 \cap R2)=P(R_1)*P(R_2)$$

Esquema 1: Efectos de extraer una ficha sin reponerla o reponiéndola, en las condiciones que quedan para la segunda extracción



Este concepto de independencia entre eventos en muy valioso para analizar uno de nuestros más importantes problemas: las relaciones entre variables. Veamos su aplicación a la Tabla 2. Si la intención de voto fuera independiente de la ciudad donde se vive (quiere decir si votaran del mismo modo personas de las diferentes ciudades) la probabilidad de encontrar una persona que vote a R si vive en Córdoba sería simplemente la probabilidad de votar a R, es decir $P(R/Córdoba)=P(R)$ y del mismo modo para los demás eventos. En nuestro ejemplo no se obtiene esa igualdad, ya que:

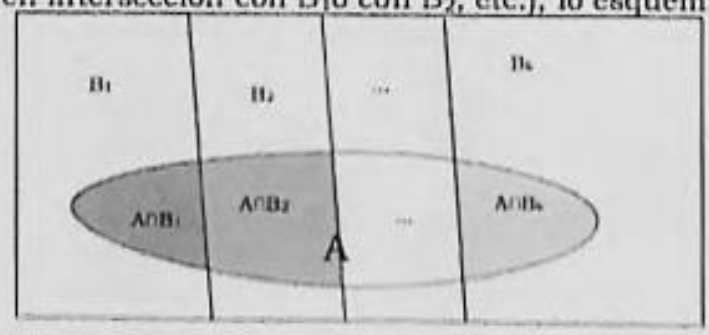
$P(R/Córdoba)=300/650=0,46$, mientras que: $P(R)=600/1530=0,39$

Por lo que estos eventos no son independientes en sentido estadístico. Cuando se trataron las relaciones entre variables, se discutió este problema, al calcular las frecuencias que se esperarían si las variables fueran independientes. Se concluyó que dos variables son independientes si la frecuencia relativa de cada celda resulta del producto de las frecuencias relativas marginales que le corresponden. En el lenguaje de las probabilidades, encontramos ahora el mismo resultado y lo expresamos diciendo que si los eventos A y B son independientes, entonces $P(A\cap B)=P(A)*P(B)$.

El teorema de Bayes

La aplicación que presentamos en este último apartado usa probabilidades condicionales para deducir la probabilidad que tiene un evento observado de provenir de diferentes eventos previos. Por esta razón se denomina también "teorema de las causas"[47]. Nos interesa porque es un resultado que permite "aprender de la experiencia", lo que quiere decir que da los medios para usar la información disponible para modificar las probabilidades de determinados eventos. Tiene mucho valor en Ciencias de la Salud, porque es frecuente conocer cuál es la probabilidad a priori que un paciente tenga determinada patología (la prevalencia de la enfermedad) pero, una vez que se dispone de indicadores clínicos, esa probabilidad cambia. De manera equivalente, si se conoce cuál es la probabilidad que un alumno termine una carrera universitaria, esa probabilidad puede modificarse, una vez que se cuenta con información adicional, como el número de materias que ya ha aprobado.

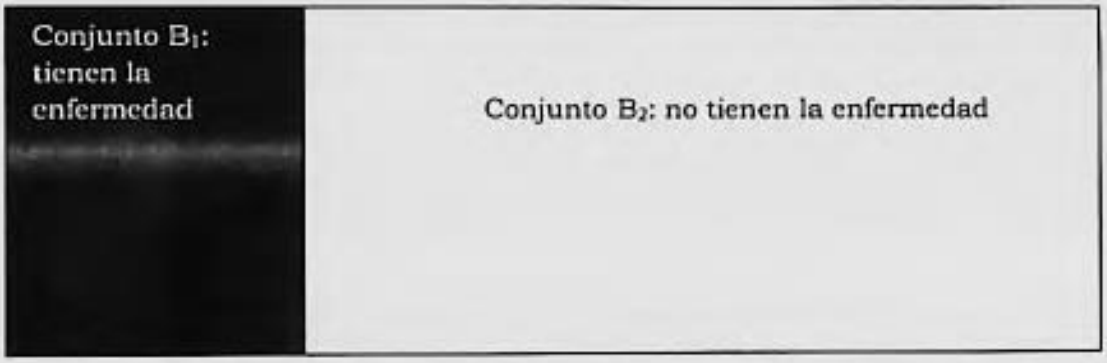
De manera general, si B_1, B_2...B_k son eventos mutuamente excluyentes que completan el espacio muestral (es decir que la unión de todos esos eventos es Ω), y un evento A puede suceder en intersección con cualquiera de ellos (es decir que A puede suceder en intersección con B_1 ó con B_2, etc.), lo esquematizaremos así:



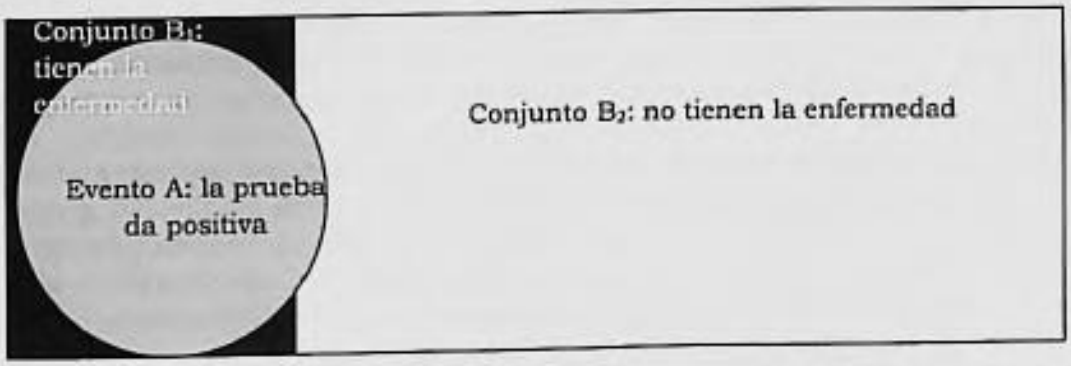
[47]Fue enunciado por Thomas Bayes (1702-1761), matemático inglés.

Por ejemplo, los eventos B pueden ser los diferentes tipos de escuela secundaria de la que provienen los alumnos y el evento A es "terminar la carrera". Hay quienes terminan la carrera (quienes están dentro de la elipse) y quienes no lo hacen (dentro del rectángulo pero fuera de la elipse), y tanto unos como otros pueden provenir de escuelas de cualquiera de los tipos B_1, B_2, etc. La primera de las intersecciones (la grisada más oscura) representa a alumnos que cumplen simultáneamente A (haber terminado la carrera) y B_1 (provenir de una escuela del tipo que ese grupo define).

Otro ejemplo es que los eventos B sean solo dos:
B_1: tener una determinada enfermedad
B_2: no tener esa enfermedad



Si el evento A es "una prueba diagnóstica dio positiva", aparecen intersecciones entre el resultado de la prueba y la condición de las personas a quienes se aplica. La primera es la zona dentro del círculo a la izquierda: ($A \cap B_1$), son los casos correctamente diagnosticados. Los que quedan fuera del círculo a la izquierda representa casos en los que la prueba no indicó la enfermedad aun cuando se trataba de personas enfermas, se llaman "falsos negativos". A la derecha, la pequeña parte de círculo es ($A \cap B_2$) e indica los casos en que la prueba dio positiva cuando fue aplicada a personas que no tenían la enfermedad, se llaman "falsos positivos". Por último, la parte blanca del rectángulo a la derecha son los casos en que dio correctamente negativa en personas que no tenían la enfermedad.



Con esta notación y esa relación entre los eventos B_1, $B_2 \ldots B_k$ y A, el teorema de Bayes se expresa de la siguiente manera:

$$P\left(B_j/A\right) = \frac{P(B_j)P\left(A/B_j\right)}{\sum_{i=1}^{k} P(B_i)P\left(A/B_i\right)}$$

El valor de este teorema es que permite pasar de la probabilidad simple de uno de los eventos B (en general, del que llamamos B_j), a la probabilidad "corregida", a partir de la información que aporta el evento A. Si se conoce inicialmente la probabilidad del evento B_j, el teorema permite calcular la probabilidad de B_j, luego de haber agregado la condición A.

Veamos un ejemplo sencillo: se dispone de dos frascos, el primero de ellos tiene 20 fichas azules y 10 rojas, el segundo contiene 20 azules y 20 rojas. Se elige un frasco al azar y luego se extrae de él una ficha, que resulta ser azul, nos preguntamos por la probabilidad que la ficha provenga del primer frasco. En ausencia de toda información, los dos frascos son igualmente probables, por lo que la probabilidad de cada uno es 0,50: P(F1)=0,50 y P(F2)=0,50. Si la ficha fue extraída del primer frasco, la probabilidad de que sea azul es: P(A/F1)=20/30=0,67, mientras que si proviene del segundo frasco es P(A/F2)=20/40=0,50. La pregunta es por P(F1/A), debemos invertir una probabilidad condicional, por lo que usaremos el teorema de Bayes:

$$P(F_1/A) = \frac{P(A/F_1) * P(F_1)}{P(A/F_1) * P(F_1) + P(A/F_2) * P(F_2)}$$

Reemplazando, tenemos:

$$P(F_1/A) = \frac{0{,}67 * 0{,}50}{0{,}67 * 0{,}50 + 0{,}50 * 0{,}50} = \frac{0{,}33}{0{,}58} = 0{,}57$$

Este resultado dice que, con el dato que la ficha extraída es azul, corregimos la probabilidad de provenir del primer frasco, que a priori era de 0,50; a 0,57. En este sentido la fórmula de Bayes nos permite usar la información para corregir probabilidades a priori.

En el ejemplo sobre la enfermedad y su diagnóstico, se dispone inicialmente de la probabilidad que tiene una persona cualquiera de padecer la enfermedad, esa es $P(B_1)$, luego esa probabilidad cambia cuando se agrega el dato que dice que a la persona la prueba le dio positiva.

Veamos un ejemplo que presentó Cohen (1994) en un artículo crítico hacia los procedimientos tradicionales de análisis estadístico. La aplicación ilustra el aporte del teorema a las interpretaciones de los resultados que arrojan las pruebas diagnósticas.

La prevalencia de esquizofrenia en adultos es de aproximadamente el 2%, que indica que aproximadamente 2 de cada 100 personas en la población general de adultos padece la enfermedad. Se dispone de un conjunto de pruebas diagnósticas del que se estima que tiene al menos un 95% de precisión al hacer diagnósticos positivos (sensibilidad) y aproximadamente 97% de precisión al declarar normalidad (especificidad).

Para expresar formalmente estos datos, tratamos por un lado, la situación real, la de ser esquizofrénico o no serlo. Llamamos E al evento "el paciente es esquizofrénico" y noE al evento "el paciente no es esquizofrénico". Por lo que,

elegida una persona al azar, su probabilidad de ser esquizofrénico es *P(E)=0,02*, la probabilidad que no lo sea es *P(noE)=0,98*.
Por otro lado tenemos el resultado del conjunto de pruebas, que pueden dar positivas o negativas. La sensibilidad se escribe así: *P(+/E)=0,95*, que quiere decir que, aplicada a sujetos esquizofrénicos, el 95% de las veces la prueba dará un resultado positivo, que conducirá al diagnóstico correcto de la enfermedad. El complemento de esa probabilidad, 5%, es la probabilidad de dar un resultado negativo ante un caso de alguien que sí es esquizofrénico, se denomina resultado "falso negativo" y solo puede identificarse ante pruebas posteriores más sensibles o por el desarrollo de otros síntomas, que dan más elementos para realizar el diagnóstico. Escribimos entonces que *P(-/E)=0,05*.
Ante personas que no son esquizofrénicas, la prueba da, en el 97% de los casos resultado negativo (correctamente), es decir: *P(-/noE)=0,97*. Su complemento, del 3%, es la probabilidad de hallar un resultado positivo en alguien que no es esquizofrénico[48], se denomina "falso positivo" y su probabilidad se escribe: *P(+/noE)=0,03*.

Dado un sujeto cuyas pruebas dan un resultado positivo, nos preguntamos por la probabilidad que efectivamente sea esquizofrénico. Antes de conocer la respuesta al problema piénselo un momento por su cuenta y ofrezca un valor aproximado para esa probabilidad.

Este es un problema que requiere que se invierta una probabilidad condicional, ya que conocemos la probabilidad de obtener un resultado positivo si el individuo es esquizofrénico *P(+/E)*, y queremos saber la probabilidad que sea esquizofrénico dado que la prueba dio positiva, que es *P(E/+)*.
En la aplicación del teorema de Bayes, el universo está compuesto por un 98% de no esquizofrénicos y un 2% de esquizofrénicos y la prueba puede dar positiva tratándose de alguien enfermo (muy frecuentemente) o estando sano (con poca probabilidad). Reemplazamos en la expresión del teorema de Bayes y tenemos:

$$P(E/+) = \frac{P(+/E) \cdot P(E)}{P(+/E) \cdot P(E) + P(+/noE) \cdot P(noE)} = \frac{0,95 \cdot 0,02}{0,95 \cdot 0,02 + 0,03 \cdot 0,98} = \frac{0,019}{0,019 + 0,029}$$
$$= 0,396$$

Entonces, si a una persona estas pruebas le han dado resultado positivo, la probabilidad que efectivamente sea esquizofrénico es menos del 40%, que es mucho mayor que la prevalencia en la población general, del 2%, pero que no resulta concluyente para el diagnóstico, el cual debe completarse con otros procedimientos. Es posible que este resultado no esté cerca de la estimación intuitiva que uno haría y nos pone muy en alerta sobre la interpretación de pruebas de este tipo. El razonamiento intuitivo quizás nos habría llevado a creer que alguien a quien la prueba da positiva tiene muchas posibilidades de tener la enfermedad, pero no debemos confundir la probabilidad que la prueba de positiva si se tiene la enfermedad (*P(+/E)*) con la probabilidad de tener la enfermedad si la prueba da positiva (*P(E/+)*). Si una persona es esquizofrénica, la prueba le da

[48]Nuevamente en este caso, esto puede conocerse a posteriori, luego de otras pruebas o del seguimiento del sujeto

positiva en el 95% de las veces; pero si da positiva, la probabilidad que sea esquizofrénica es menor al 40%.
Este resultado no debe conducir a creer que la prueba no sirva para el diagnóstico. Por el contrario, ante una persona de la que no se tiene ninguna información, la probabilidad que sea esquizofrénico es 0,02; cuando se agrega el dato que dice que el test dio positivo, la probabilidad que sea esquizofrénico asciende a 0,39. Nuevamente, se ve con claridad cómo este teorema permite usar los resultados de la experiencia para corregir probabilidades asignadas a priori.

En este ejemplo, la probabilidad de ser esquizofrénico para alguien que obtuvo resultado positivo en las pruebas es tan baja debido a la baja frecuencia de la esquizofrenia en la población general (prevalencia), pero demuestra lo equivocado que puede estarse si no se tienen en cuenta resultados falso positivo y falso negativo asociados a las pruebas diagnósticas.

Un abordaje alternativo a este problema es usando una tabla de contingencia. Suponiendo que aplicamos el conjunto de pruebas a un universo de un millón de personas y usando las probabilidades enunciadas antes:

Condición	Resultado de las pruebas		Total
	Positivo	Negativo	
Esquizofrénicos	19.000	1.000	20.000
No esquizofrénicos	29.400	950.600	980.000
Total	48.400	951.600	1.000.000

Queremos responder ¿cuál es la probabilidad que el sujeto sea esquizofrénico, si sabemos que la prueba le dio positiva? Para ello:

$$P(E/_{+}) = \frac{19.000}{48.400} = 0{,}39$$

Que es el mismo resultado que obtuvimos aplicando el teorema de Bayes.
La ventaja de la presentación a través de una tabla de doble entrada es que permite distinguir dos conjuntos de eventos sobre los que tenemos diferente conocimiento:
-Un *estado de realidad*, que es la condición de esquizofrénico o no esquizofrénico del sujeto. Este estado nos es desconocido.
-*La evidencia observable*, que está dada por el resultado de la prueba que aplicamos, que conocemos.
Como las pruebas nos son perfectas, los resultados deben leerse en términos probabilísticos y no determinísticos.

Cuando ingresemos a inferencia estadística veremos que ésta es la situación más frecuente: que dispongamos de cierta evidencia y debemos usarla para tomar una decisión acerca de un estado de realidad al que no conocemos.

El de Bayes es un teorema de gran importancia, por las consecuencias que tiene para muchas pruebas diagnósticas que se usan a menudo. Lo que hemos encontrado también implica el cuidado con que deben leerse los resultados de

pruebas de cualquier tipo: diagnósticos, dosaje de productos prohibidos en deportistas, pruebas genéticas, etc. Para una correcta interpretación de los resultados de esas pruebas se deben conocer cuáles son los errores de tipo "falso positivo" y "falso negativo" que las acompañan.

Variables aleatorias

Es necesario hacer más explícita una parte del vocabulario que hemos usado. Al tratar con eventos aleatorios (resultados de experimentos aleatorios), en algunos hemos usado una notación más textual, como "que la moneda salga cara" y en otros una más numérica, por ejemplo "S=4". De aquí en adelante trabajaremos con la segunda notación que tiene muchas ventajas. La razón es que pasamos a tratar a los experimentos como observación de variables, cuyas categorías (o valores) son los resultados del experimento. En la tirada de la moneda, no es difícil cuantificar los eventos, podemos elegir cara como lado preferido y definir la variable X = "número de caras que se obtienen al lanzar una moneda equilibrada", los valores posibles son 0 (si sale cruz) y 1 (si sale cara). En la suma de los puntos de los dos dados, S asume valores discretos del 2 al 12. La descripción como distribución de frecuencias que hacíamos antes, se transforma ahora en distribución de probabilidades y, para los dos ejemplos citados, toma la forma:

X

número de caras que se obtienen al lanzar una moneda equilibrada	P(X)
0	1/2
1	1/2
Total	1

S

suma de puntos obtenidos al lanzar dos dados equilibrados	P(S)
2	1/36
3	2/36
4	3/36
5	4/36
6	5/36
7	6/36
8	5/36
9	4/36
10	3/36
11	2/36
12	1/36
Total	1

Estas variables se denominan **variables aleatorias**, porque sus valores dependen del azar y serán muy necesarias en todo lo que sigue de la materia. El aspecto de estas tablas de distribución de probabilidades es en un todo equivalente al de las de distribución de frecuencias: el total igual a uno indica la probabilidad del espacio muestral ($P(\Omega) = 1$). Sobre ellas pueden hacerse operaciones similares a las descripciones de variables ya vistas.

Cuando la variable aleatoria puede asumir valores continuos, ya no es posible asignar probabilidades individualmente y debe hacerse a través de intervalos. Es el mismo problema que hallamos en las distribuciones de frecuencia, y lo resolvemos del mismo modo. Se usan probabilidades acumuladas, ya sea entre

valores de la variable o desde ciertos valores hacia los mayores o desde ciertos valores hacia los menores[49].

También es posible, sobre distribuciones de probabilidad, calcular algunas medidas descriptivas, veamos en qué se transforma la media. El procedimiento para calcularla que hemos visto consiste en multiplicar cada valor de la variable por su frecuencia y dividir por el total de casos; para las variables aleatorias eso se hace de una sola vez, multiplicando cada valor por la probabilidad y se obtiene:

$$E(x) = \sum_{i=1}^{n} x_i * P(x_i)$$

Que se llama **esperanza matemática**, la indicaremos E(x). Aunque esta expresión proviene del cálculo de la media[50], tiene una diferencia conceptual importante: la media es una medida resumen, por lo que describe hechos que han sido observados, puede decirse que hace referencia a algo que ya sucedió. Por el contrario la esperanza se refiere a eventos que pueden llegar a suceder, por eso tiene ese nombre, es la expectativa que tenemos sobre el devenir futuro de un experimento. Uno de los usos más difundidos de este concepto es la esperanza de vida, que mide el número promedio de años que viviría un conjunto de personas si a lo largo de toda su vida se mantuvieran las mismas tasas de mortalidad que en la actualidad (las tasas de mortalidad se usan para estimar las probabilidades de morir a cada edad). Un "promedio a futuro" es una descripción sobre algo que aún no sucedió, por eso se llama esperanza.

De manera análoga puede calcularse la varianza de una variable aleatoria, su fórmula es:

$$V(x) = \sum_{i=1}^{n} (x_i - E(x))^2 * P(x_i)$$

Al referirse a una variable aleatoria, la interpretación de la varianza difiere levemente de aquella que se usó como medida descriptiva de la dispersión. Aquí indica el modo en que se alcanzará el valor de la esperanza. Una varianza grande indica un proceso aleatorio muy variable, con valores dispares que convergen lentamente al valor de la esperanza. Por el contrario, un valor pequeño de la varianza indica un proceso más estable en el que los valores difieren poco de un paso al siguiente y rápidamente se aproximan a la esperanza.

---

[49] Sin embargo hay algo importante que cambia; porque en lugar de sumar un número finito de valores discretos, cuando se trata de variables continuas se debe sumar una cantidad infinita de valores infinitesimales, ese cambio se refleja en que la operación de suma se transforma en otra operación que se llama integral. No disponemos de los elementos matemáticos suficientes para ir más allá de esta mención imprecisa del concepto, pero tampoco es necesario a los fines de este curso.

[50] Puede deducirse esto a partir del cálculo de la media, si se reemplazan las frecuencias relativas por las probabilidades de cada valor de la variable, tenemos:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i * f_i}{n} = \sum_{i=1}^{n} x_i * \frac{f_i}{n} = \sum_{i=1}^{n} x_i * f_i' = \sum_{i=1}^{n} x_i * P(x_i) = E(x)$$

Un ejemplo común que ilustra el uso de estas medidas es el juego de la ruleta. En este juego, por cada ficha que se apuesta a un color se obtiene una de premio si sale ese color y, por cada ficha que se apuesta a un solo número, se obtienen 35 como premio. En ambos tipos de apuesta, la ganancia esperada[51] vale -0,027. Esto significa que, jugando indefinidamente, se espera perder (porque es negativa) 0,027 pesos por cada peso que se apueste; esa es la ganancia esperada del organizador del juego.

Sin embargo, las varianzas son diferentes; para las apuestas a color, vale poco menos de 1 y para la apuesta a número único es más de 34. Esto describe la dinámica del juego; mientras con la primera modalidad se gana y se pierde a menudo, con la segunda forma de apostar, se pierde muchas veces y cuando se gana es grande la recompensa. De todos modos en ambos tipos de apuesta, el balance entre ganancias y pérdidas es negativo, como lo indica la esperanza

[51] Para el caso de ruletas con un solo cero, existen algunas que tienen además del cero el doble cero, en esos casos la esperanza de pérdida es mayor.

Capítulo 8 Probabilidad: los modelos

Concepto de modelización

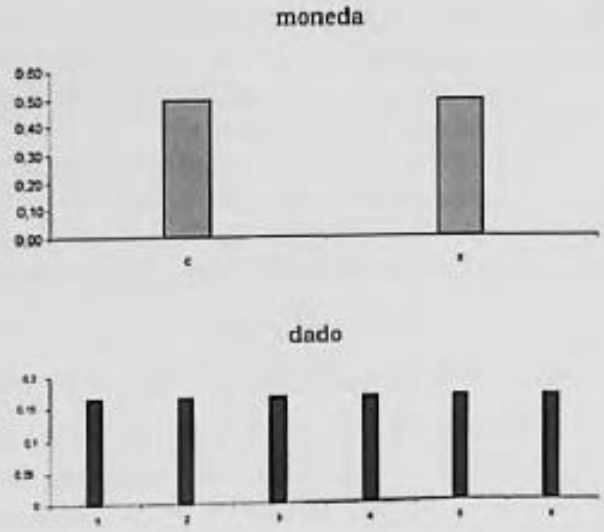
La asignación a priori de probabilidades, presentada con los ejemplos elementales de la moneda o el dado es parte de una forma muy general de tratar con los fenómenos que dependen del azar. El supuesto inicial de probabilidad ½ a cada lado, constituye un *modelo de probabilidad*, es una anticipación acerca de lo que se espera que suceda. No es arbitrario, ya que deben tenerse razones para suponer que el modelo se sostiene, pero en todos los casos es una aproximación a lo que sucede en la realidad. Tratamos de modelar (o modelizar) lo que observamos a fin de simplificarlo, pero un modelo puede ser más o menos adecuado a la realidad, por eso dijimos que cabe la posibilidad que "el modelo no se sostenga". La idea de simplificar está aquí utilizada en el sentido de elegir algunos aspectos de la realidad para construir un modelo que luego se usa para asignar probabilidades a los diferentes resultados posibles. La riqueza y complejidad de los fenómenos sociales no se menoscaba porque se usen modelos, salvo si se comete el error de confundir el modelo con la realidad. Disponer de un modelo de probabilidad permite calcular probabilidades de manera sencilla bajo ciertos supuestos, que deben explicitarse.

Para seguir con nuestra moneda, digamos que el modelo que resume el supuesto de iguales chances para todos los resultados, se llama *distribución uniforme*, es válido también para un dado, si está equilibrado, o para cualquier fenómeno aleatorio en el que se pueda suponer que los resultados son igualmente probables. La expresión formal de ese modelo es la siguiente:

"Si un experimento aleatorio tiene distribución uniforme y k resultados posibles, entonces $P(A_i) = \frac{1}{k}$, donde A_i es uno cualquiera de los k resultados"

Por lo tanto si se trata de una moneda (2 caras) la probabilidad de cualesquiera de sus caras será ½, si es un dado, cada lado tiene probabilidad 1/6, y si es un icosaedro regular (veinte caras iguales, parecido a un globo de espejos) cada cara tendrá probabilidad 1/20 de salir.

La representación gráfica de este modelo, es para cada uno de los ejemplos, la siguiente:





En estos gráficos, la idea de uniformidad (para todos los eventos la misma probabilidad) se transmite en la igual altura de todas las columnas.

Además de este modelo uniforme, en este capítulo presentaremos cinco modelos de probabilidad que serán necesarios para lo que sigue de nuestros contenidos; el primero para variables discretas y los demás para continuas. Hay una gran cantidad de modelos que permiten asignar probabilidades a priori a diferentes fenómenos observables. El tratamiento que haremos a continuación será de carácter utilitario, es decir estará centrado en el uso que podemos hacer de cada distribución teórica. Haremos las referencias matemáticas mínimas que sean necesarias para comprender las propiedades y condiciones de aplicación de los modelos.

Distribución binomial

Esta distribución se usa para modelar fenómenos aleatorios que pueden dar solo dos resultados, a los que se llama "éxito" y "fracaso". La elección de cuál es éxito es arbitraria y corresponde a la categoría que el investigador toma como de interés. La variable aleatoria que se considera es el número de veces que se obtienen éxitos, o simplemente el número de éxitos que resultan luego de una cierta cantidad de repeticiones de la experiencia. La condición para que este modelo sea válido es que cada repetición sea independiente de las anteriores, es decir, que cada realización del experimento no incida sobre la siguiente.

Nuevamente con la moneda equilibrada que hemos tratado, este modelo va a facilitar el cálculo de, por ejemplo, qué probabilidad hay de obtener 3 caras en 4 tiradas de la moneda. Resolvamos primero el problema de manera manual. En la tabla siguiente mostramos los resultados posibles de ese experimento (lanzar cuatro veces una moneda equilibrada) y el valor que corresponde a la variable aleatoria "número de caras", a la que llamaremos x[52].

[52]Con lo que hemos elegido tomar como éxito el resultado *cara*

Resultado del experimento	Valor de la variable "número de caras" x
XXXX	0
XXXC	1
XXCX	1
XXCC	2
XCXX	1
XCXC	2
XCCX	2
XCCC	3
CXXX	1
CXXC	2
CXCX	2
CXCC	3
CCXX	2
CCXC	3
CCCX	3
CCCC	4

Como estos 16 resultados son igualmente probables, le corresponde una probabilidad de 1/16 (0,0625) a cada uno, por lo que podemos calcular las probabilidades de cada valor sumando los que corresponden a las formas en que pueden lograrse. Por ejemplo, tres caras (x=3) puede ser consecuencia de cualquiera de los eventos XCCC, CXCC, CCXC, CCCX, por lo que hay cuatro eventos a su favor y su probabilidad es 4/16. Resumiendo entonces la tabla anterior, tenemos:

x	P(x)
0	1/16 (0,0625)
1	4/16 (0,25)
2	6/16 (0,375)
3	4/16 (0,25)
4	1/16 (0,0625)
Total	1

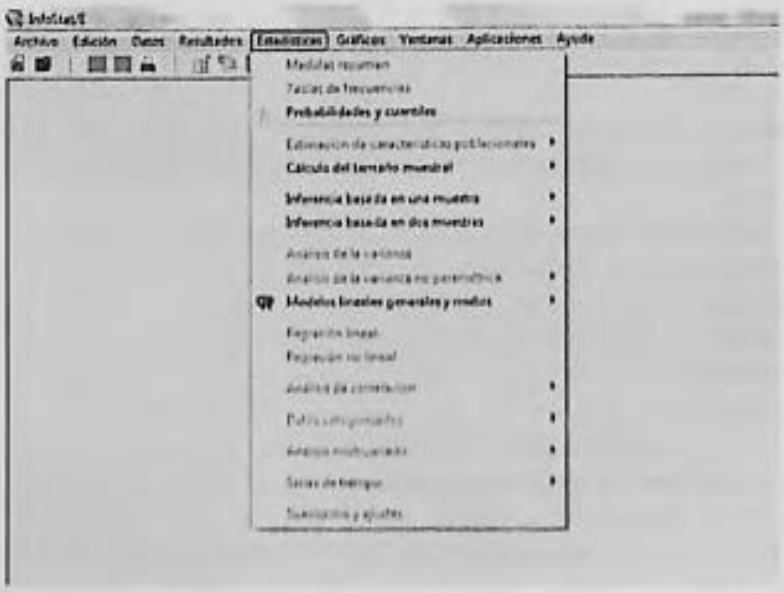
Como esperábamos, "lo más probable" es obtener dos caras, porque se espera que la moneda caiga cara la mitad de las veces, ahora sabemos también cuán probable es que caiga una cantidad diferente de veces cara. La respuesta a la pregunta que formulamos arriba es 0,25 y lo expresamos simplemente:

$$P(x = 3) = 0{,}25$$

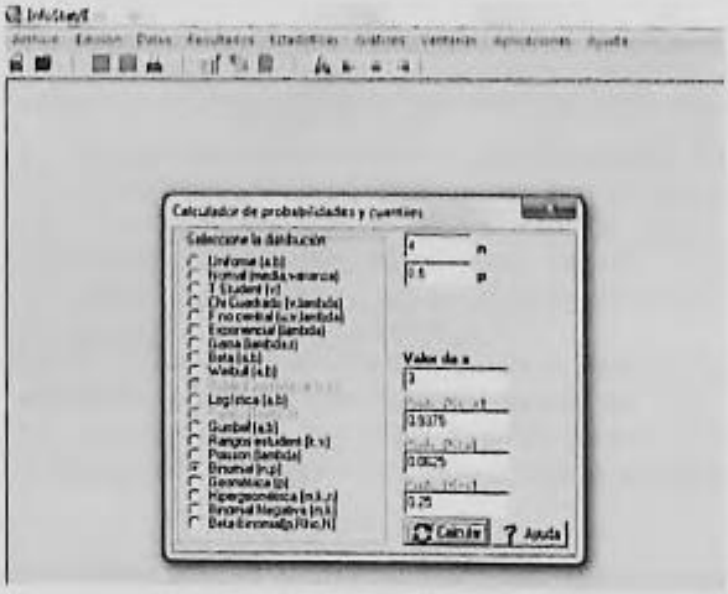
Para construir la tabla y responder a la pregunta hemos usado como información:

- la cantidad de repeticiones del experimento ($n=4$)
- la probabilidad del evento cada vez que se lo repite ($p=0{,}5$)
- el número de veces cuya probabilidad calculamos (el número de éxitos) ($x=3$)

Esta información es suficiente para aplicar el modelo binomial y solicitar[53] directamente la probabilidad a InfoStat®.
Sin necesidad de tener una base de datos abierta, en "Estadísticas" elegimos "Probabilidades y cuantiles":



La ventana siguiente, nos pregunta por la distribución de probabilidad que usaremos, elegimos "binomial (n, p)", en el valor de n indicamos 4 y p es 0,5. En "valor de x" ingresamos nuestra pregunta que corresponde a x=3, solicitamos "Calcular" y obtenemos:

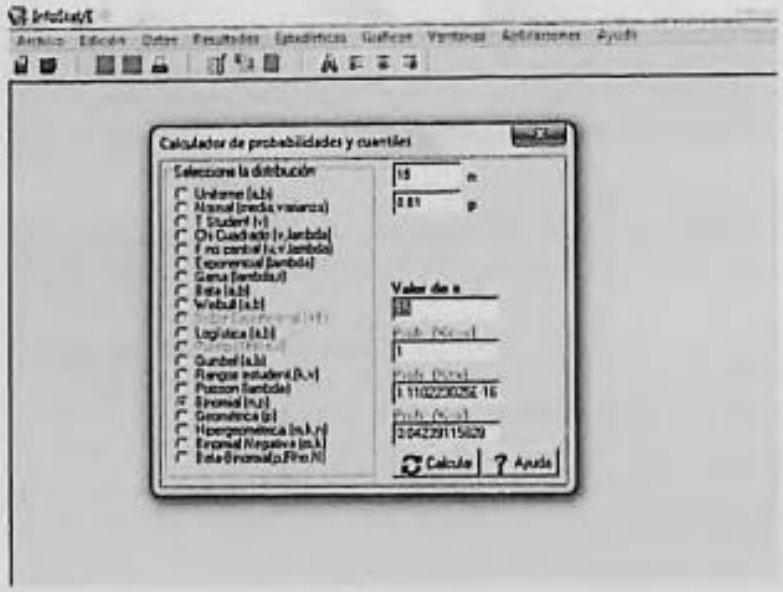


[53] La expresión formal del modelo es: $P(x,n,p) = \binom{n}{x} * p^x * (1-p)^{n-x}$, en la que x es el número de éxitos, n el número de repeticiones del experimento y p la probabilidad de éxito a cada repetición. Pero no la usaremos para el cálculo.

Esta operación nos ofrece tres resultados:
P(x≤3)=0,9375 Es la probabilidad de obtener tres caras *o menos*
P(x>3)=0,0625 Es la probabilidad de obtener *más* de tres caras
P(x=3)=0,25 Es la probabilidad de obtener *exactamente* tres caras, que es nuestra pregunta.
Escribimos entonces $B(X = 3; 4; 0{,}50) = 0{,}25$
Que leemos como "bajo un modelo binomial, la probabilidad de obtener 3 éxitos en 4 repeticiones de un experimento en el que cada éxito tiene probabilidad 0,50, es 0,25".
Cada vez que estemos ante un experimento en el que queramos calcular la probabilidad de una cierta cantidad de casos (x) de una categoría de una variable dicotómica (a la que llamamos éxito) que se presenta con una frecuencia relativa conocida y constante (p), luego de un determinado número de extracciones (n); usaremos este modelo y no serán necesarias las operaciones que realizamos antes manualmente. Esa es la utilidad de contar con un modelo de probabilidades.

Un ejemplo de más interés es el siguiente. Se elige una muestra al azar de 15 estudiantes de primer año de Psicología para un experimento, si no se establece ninguna restricción sobre la composición de la muestra y se sabe que la proporción de mujeres en primer año de Psicología es 0,81. ¿Cuál es la probabilidad que en la muestra resulten todas mujeres? Aquí el experimento que se repite es el de elegir al azar a un estudiante de primer año, y se repite 15 veces, por lo que $n=15$, la probabilidad que una persona elegida al azar sea mujer es la frecuencia relativa, $p=0,81$. La pregunta es que sean *todas* mujeres, es decir que sean 15 éxitos: $x=15$, por lo que se expresa $B(15; 15; 0{,}81)$. Usando InfoStat® para calcular la probabilidad binomial[54], obtenemos:

[54]El supuesto de independencia puede objetarse aquí, porque a cada extracción de una mujer, la proporción de mujeres en primer año se reduce, ya que no podemos seleccionar dos veces a la misma persona. Por ejemplo, si en primer año hay 1400 alumnos, de los cuales 1134 son mujeres, la proporción de mujeres es 1134/1400=0,81. Si la primera persona seleccionada es mujer, al momento de la segunda extracción, ya no hay 1134 mujeres, sino 1133, por lo que la proporción es ahora 1133/1399=0,8099. Si la primera extracción hubiese sido varón, la probabilidad de mujer para la segunda es 1134/1399=0,8106. Como estos números no son muy diferentes de 0,81, podemos usar el modelo binomial, que exige que esa probabilidad sea siempre la misma (independencia). Esta aproximación es válida si el universo del cual se extraen las muestras (que en este caso está formado por todos los alumnos de primer año) es mucho mayor que la cantidad de casos que constituyen la muestra; cuando así sucede, se dice, de manera breve, que es una "población infinita".



Donde:

P(x≤15)=1 Es la probabilidad de obtener *15 mujeres o menos*, vale 1 porque no pueden obtenerse más de 15 mujeres en 15 casos.

P(x>15)=1,11E-16 Esto es un número muy pequeño, que se interpreta como cero, es la probabilidad de obtener más de 15 mujeres en la muestra.

P(x=15)=0,0424 Es la probabilidad de obtener *exactamente* 15 mujeres en la muestra, que es nuestra pregunta.

La respuesta se expresa:

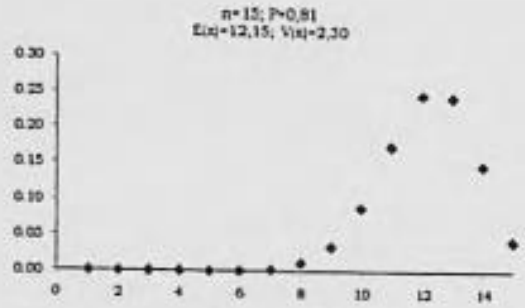
$$P(x = 15) = B(15; 15; 0{,}81) = 0{,}0424$$

Esperanza y varianza

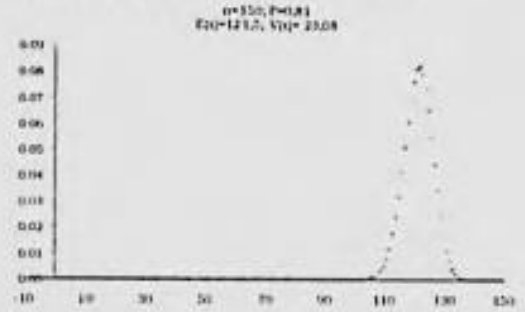
En este modelo de probabilidad, la esperanza es $n*p$, que representa el número esperado de casos favorables a obtener en n repeticiones. En el primer ejemplo, la esperanza es 4*0,50=2, que quiere decir que en 4 tiradas de la moneda equilibrada, esperaríamos obtener 2 caras, como sabemos, esto es lo que sucede luego de un gran número de repeticiones del experimento. En el segundo ejemplo, la esperanza es 0,81*15=12,15, aunque este número decimal no es una cantidad posible de casos favorables (mujeres) a obtener en la muestra, es el promedio a futuro, luego de la realización reiterada de este experimento muchas veces.

La varianza de la distribución binomial es $n*p*(1-p)$, que es una medida de la variabilidad del proceso. Más adelante volveremos sobre este tema.

El gráfico de esta distribución se construye calculando las probabilidades de los diferentes valores de x, que puede ir desde 0 hasta el número total de repeticiones del experimento. El siguiente es el correspondiente a los datos del ejemplo:



Veamos el cambio que sucede en el gráfico si el número de repeticiones es de 150 en lugar de 15 y mantenemos *P* en el mismo valor:



Observemos la forma en que aparece representada la diferencia entre las varianzas de las dos distribuciones[55].

Distribución normal

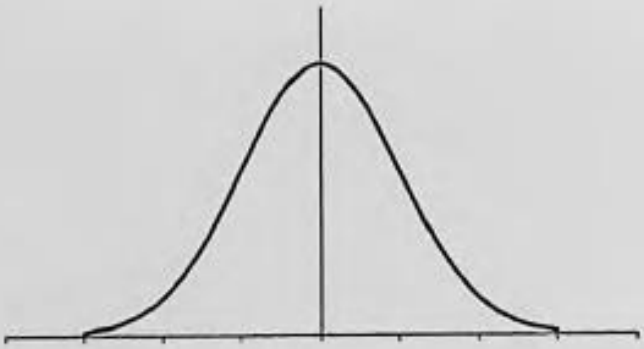
La mayoría de los fenómenos naturales, sociales, psicológicos no tienen distribución uniforme, es decir, no es igualmente probable que resulte cualquiera de los resultados. Por ejemplo, para una determinada población, el peso de los niños al nacer tiene un valor promedio y cuando un niño nace se espera que tenga un peso cercano a ese valor medio. No es igualmente probable que un niño nazca con 3500 gramos que con 5800. Son menos frecuentes los niños que nacen con pesos muy por encima o muy por debajo del promedio. De modo similar sucede con medidas psicológicas como el Cociente intelectual (CI); se hallan con mayor frecuencia valores cercanos al promedio y la probabilidad de encontrar personas muy por encima o muy por debajo de ese promedio es menor. Para este tipo de fenómeno, hay un modelo que suele ajustar bien las probabilidades, se llama distribución normal[56] y su representación gráfica, una curva unimodal, simétrica, de forma acampanada es llamada "campana de Gauss"[57] en referencia a Johann Carl Friedrich Gauss[58].

---

[55] Para explicar la diferencia, considere los coeficientes de variación de las dos distribuciones.

[56] El nombre "normal" de este modelo no hace referencia al sentido coloquial del término, como juico acerca de la salud o el comportamiento humano, sino a un modelo de distribución en el que es más frecuente hallar valores cercanos al promedio y resultan igualmente infrecuentes valores extremos mayores o menores.

[57] Este modelo tiene una expresión matemática más compleja que la primera que vimos, solo a título ilustrativo la mencionamos:



Un primer elemento a tener en cuenta es que, a diferencia de los gráficos anteriores, ahora se trata de una curva con trazado continuo. Esto se debe a que esta distribución es adecuada para modelar variables continuas. Recordemos que cuando se construyeron las distribuciones de frecuencia, resultaba imposible enumerar todas las categorías de una variable de este tipo, ya que son infinitas. Dijimos en ese momento que no es posible indicar la frecuencia de un valor único de una variable continua. Lo mismo vale ahora para las probabilidades: no calculamos probabilidades para valores simples de variables continuas, sí calculamos probabilidades acumuladas y, como sucedía con las frecuencias acumuladas, éstas están representadas gráficamente en el área bajo la curva, pero en lugar de sumar las frecuencias de valores discretos, se realiza una operación que se llama integración[59].
Dado que la curva que describe la distribución normal es unimodal y simétrica; el modo, la media y la mediana coinciden, el coeficiente de asimetría es cero (g_1=0) y la distribución es mesocúrtica (g_2=0).

El cálculo de las probabilidades bajo el modelo normal —o, lo que es lo mismo, de las áreas bajo la curva—, es muy complejo, por lo que se encuentra tabulado, es decir, precalculado para algunos valores de la variable. ¿De qué variable?, hemos mencionado el peso al nacer, el IQ, ¿con qué método calcularemos probabilidades para fenómenos tan disímiles? Antes que se difundiera el uso de la computadora personal, se usaban tablas, ahora usamos cualquier hoja de cálculo, donde se indica la probabilidad acumulada para diferentes valores de una variable abstracta, sin unidades, adaptable a una diversidad de fenómenos. Se trata de la variable z, que ya fue definida y que mide el número de desviaciones estándar —contadas desde la media—, a las que se encuentra un caso individual. Una de las aplicaciones prácticas de esta variable es que permite comparar variables que miden cualidades muy diferentes. Sabemos ya que la cantidad de desviaciones estándar (z) es una medida de lo cerca o lejos que un caso se encuentra del promedio. Si la variable en estudio es adecuadamente modelada con la

---

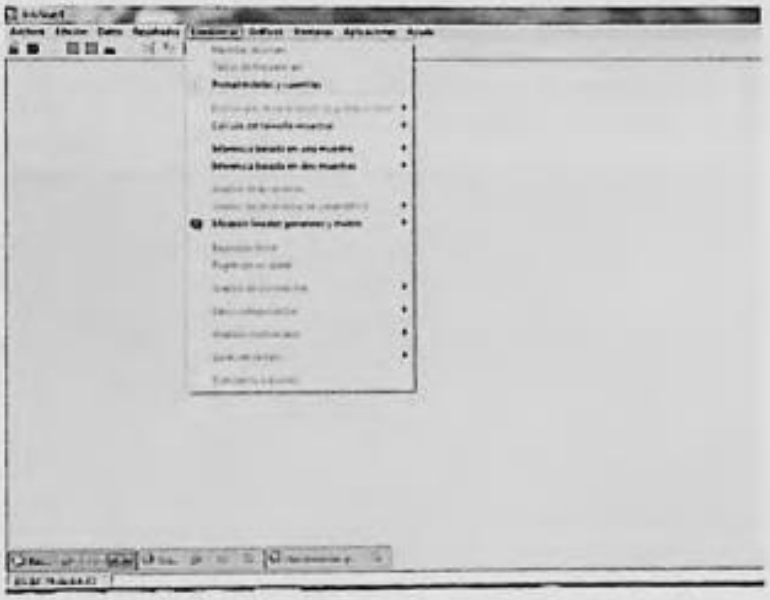
$$P(z < x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{z^2}{2}} dz$$

jamás la usaremos para calcular probabilidades.
[58]1777–1855, matemático, astrónomo y físico alemán. El primero en expresar la función y calcular áreas fue Abraham De Moivre matemático francés que trabajó en Inglaterra junto a Newton y Halley (Tankard, 1984).
[59]El símbolo de esta operación es $\int$, una S estilizada, que indica su origen en una suma.

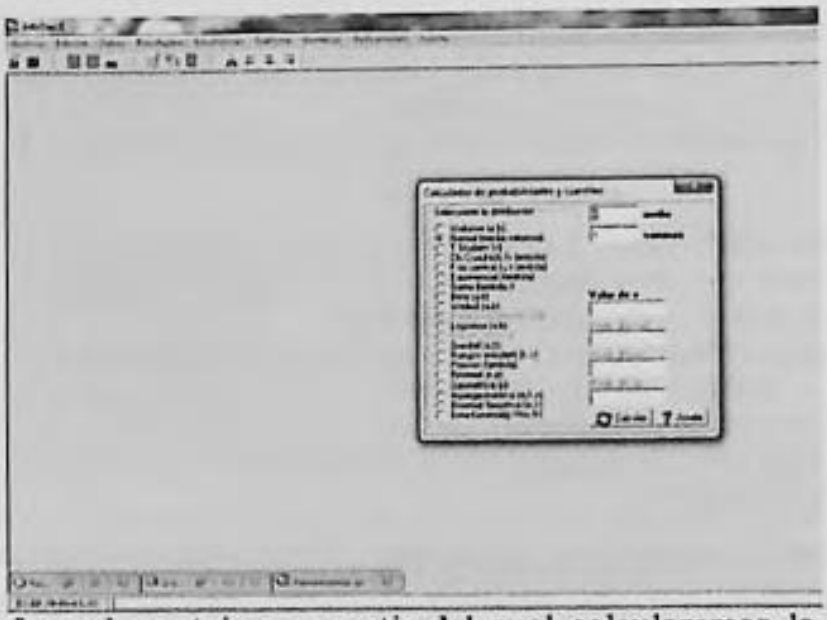
distribución normal, entonces podremos conocer la probabilidad de hallar casos, por ejemplo a *más de dos desviaciones estándar de la media* y eso tendrá una inmediata traducción a valores de la variable.
Recordemos que la variable z está definida, para un valor particular de x como:

$$z = \frac{x - \bar{x}}{s}$$

Y que tiene media igual a cero y desviación estándar igual a uno. Si x tiene una distribución normal con una media $\bar{x}$ y una desviación estándar s, entonces z tiene distribución que se llama **normal estándar**.
Dijimos que cualquier hoja de cálculo (como OpenOfficeCalc o Excel) calcula las probabilidades (o áreas) bajo la curva normal. Nos resulta más cómodo utilizar InfoStat®, que tiene estas operaciones incorporadas. Como con la binomial, no es necesario tener una base de datos abierta, nuevamente en "Estadisticas" elegimos "probabilidades y cuantiles":



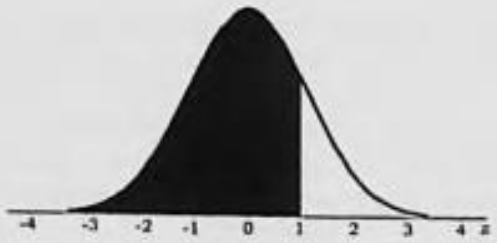
En la ventana siguiente ahora elegimos "Normal (media, varianza)" y por defecto, en el lugar de la media aparece un 0 y en el de la varianza un 1. Eso significa que, por defecto, trabajará con una normal estándar.



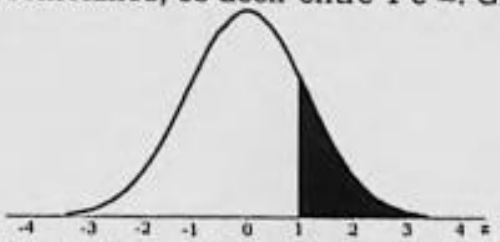
El "valor de x" es el puntaje z a partir del cual calcularemos la probabilidad. Vamos a introducir el valor 1 y solicitamos "calcular".



Obtenemos tres resultados expresados así (redondeados):
Prob (X<=x)=0,8413
Prob (X>x)=0,1587
Prob (X=x)=0
El primero es la probabilidad de hallar valores de z iguales o menores que 1. Eso significa, gráficamente, el área bajo la curva normal, desde 1 hacia la izquierda, hasta menos infinito ($-\infty$). La representación gráfica de esta área es la siguiente:



El segundo valor es el complemento del primero (lo que le falta para llegar a 1, que es el área completa) y representa ahora la probabilidad de hallar valores por encima del valor que especificamos, es decir entre 1 e ∞. Gráficamente es:



Esta probabilidad podría haberse obtenido restando de 1, la probabilidad anterior, ya que: $P(z \leq x) = 1 - P(z > x)$

El tercer valor dice que la probabilidad que tiene la variable de valer exactamente uno, es cero. Esto es así porque se trata de una variable continua, para la cual, como ya mencionamos, las probabilidades exactas son nulas. El equivalente gráfico de esta situación es que no hay área si se trata de un único valor de la variable. Al solicitar el resultado a InfoStat® para una variable continua, en ese recuadro siempre se obtiene un cero.

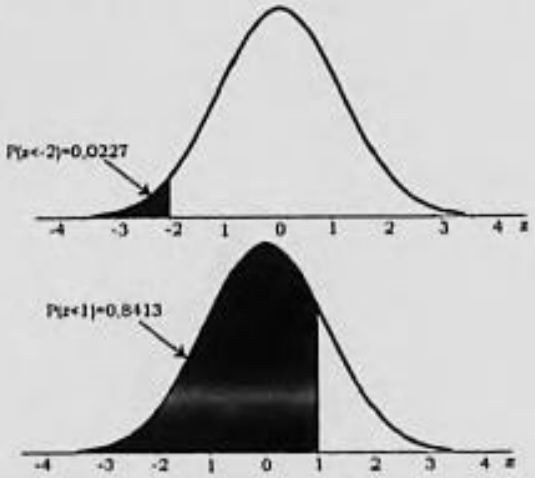
Por ahora usaremos el primero de los resultados, el que provee la probabilidad acumulada por debajo del valor que elegimos. Si solicitamos las probabilidades acumuladas por debajo de diferentes valores de *z*, empezando con los negativos, pasando por el cero y siguiendo por los positivos, obtenemos lo siguiente:

z	*P(<z)*	Ubicación
-3,0	0,00135	
-2,0	0,02275	
-1,0	0,15866	

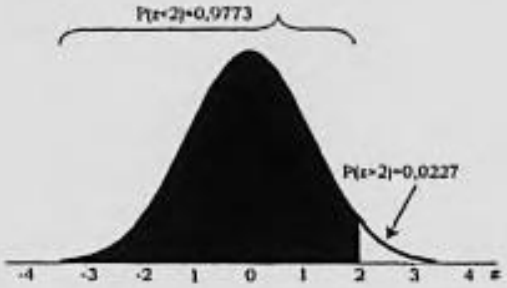
z	*P(<z)*	Ubicación
0,0	0,50000	
1,0	0,84134	
2,0	0,97725	
3,0	0,99865	

Las probabilidades acumuladas (es decir, las áreas a la izquierda) van creciendo desde casi cero en el valor más pequeño que pusimos (z = -3) y llegan hasta casi uno en el máximo valor (z = 3). En el modelo matemático, z tiene como campo de variación todos los valores, es decir, desde menos infinito hasta más infinito ($-\infty < z < \infty$), pero como vemos, en la realidad, los valores -4 y 4 son muy extremos, en

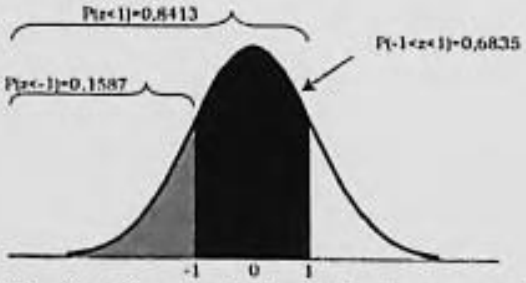
el sentido que las probabilidades acumuladas son **casi** cero y **casi** uno respectivamente. Aunque el modelo teórico tiene un comportamiento asintótico respecto del eje horizontal, en el gráfico, la curva se confunde con el eje para valores cercanos a 4. La notación para estos resultados es la siguiente (usando hasta cuatro decimales que es lo más frecuente), por ejemplo: P(z<-2) = 0,0227 ó también P(z<1) = 0,8413. Las representaciones gráficas de estas probabilidades son las siguientes:



A continuación vemos la representación gráfica de la relación entre las probabilidades "por encima" y "por debajo" de $z=2$.



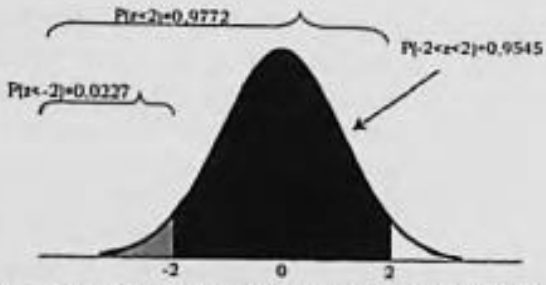
También se pueden identificar probabilidades **entre** valores de z, por ejemplo cuál es el área entre -1 y 1 (es decir cuál es la probabilidad de encontrar a z entre esos valores). Esto se escribe así: P(-1<z<1). Para calcularla solo usaremos la información sobre la probabilidad acumulada: el área por debajo de -1 vale 0,1587 y el área por debajo de 1 es 0,8413, si restamos esas dos áreas tendremos lo que queda entremedio: 0,8413 – 0,1578 = 0,6835, gráficamente:



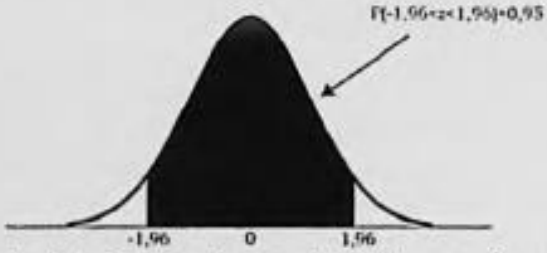
El área comprendida entre -2 y 2 se calcula del mismo modo, ya que

$$P(-2 < z < 2) = P(z < 2) - P(z < -2) = 0{,}9772 - 0{,}0227 = 0{,}9545$$

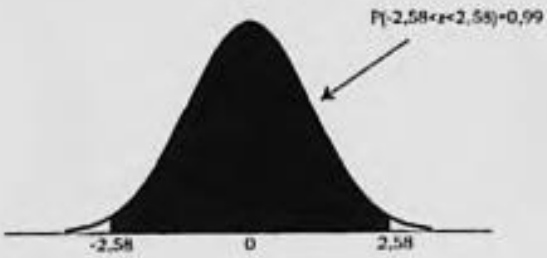
Verifique estos valores usando el procedimiento indicado con InfoStat®. La representación gráfica de esta área es:



Hay dos valores de z que conviene recordar, ya que delimitan áreas centrales que son de uso muy frecuente. El primero es el par de valores que dejan un 95% de los casos entre ellos. Según el cálculo del párrafo anterior, deben ser cercanos a -2 y 2 (±2), ya que entre ellos se ubica el 95,45% del área total. En efecto, los valores exactos son ±1,9599, que alcanza con tomarlo como ±1,96. Gráficamente, tenemos entonces:



El otro par de valores de interés es el que delimita un área central del 99%, es el valor ±2,5758, al que podemos recordar como ±2,58. El gráfico de esta relación entre valor z y área es:



Usos de la distribución normal

La distribución normal es muy valiosa, por muchas razones, de las cuales nos interesan dos.

La primera es que es adecuada para modelar muchos fenómenos observables, en especial variables biológicas como el *peso* de los niños al nacer, la *talla* para diferentes edades. Hay variables psicológicas como el *coeficiente intelectual*, para las que se elaboran instrumentos de medición cuyos puntajes se distribuyen de manera normal. Otras variables, como el *rendimiento en la escuela*, a menudo, pueden aproximarse de manera adecuada con un modelo normal.

La segunda razón es que cuando se extraen muestras aleatorias de una población, algunas medidas que se calculan sobre esas muestras tienen una distribución que se aproxima a la normal a medida que las muestras tienen

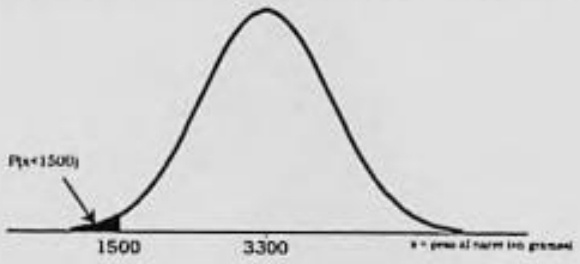
mayor tamaño. Eso será lo que nos permita realizar nuestras primeras estimaciones de valores poblacionales a partir de muestras.

Hasta este punto trabajamos con la distribución normal de una variable abstracta, sin unidades, a la que llamamos z, a cuyos valores pudimos asignar probabilidades. Es en términos de z que está expresada la función que describe la curva acampanada. Pero cuando vamos a trabajar con una variable real, como las que mencionamos, por ejemplo, el peso de los niños cuando nacen o el CI, es necesario disponer de una variable concreta, a la que llamamos x. ¿Qué relación tiene esa variable, cuya distribución podría modelarse bien con una curva normal, con la z, que nos permite hallar las probabilidades bajo el modelo normal? Es decir, ¿qué relación tiene x con z? Ya la conocemos, porque z es el desvío estándar que definimos en el capítulo 3, es:

$$z = \frac{x - \bar{x}}{s}$$

Que cuenta la cantidad de desviaciones estándar (s) a que se encuentra un valor (x) de la media ($\bar{x}$). Para encontrar probabilidades correspondientes a valores reales de una variable y no solo los z abstractos, debemos transformar esos valores en puntajes z, con la expresión de arriba.

Veamos esto en un ejemplo: a partir de las historias clínicas de varios años de un hospital materno infantil, conocemos que el peso medio en el momento de nacer (de niños varones, a término, con madre entre 20 y 29 años) son 3300 gramos y que la desviación estándar es de 800 gramos. Además sabemos que la distribución normal es adecuada para describir la variable *peso al nacer*. Entonces podemos calcular la probabilidad que un niño al nacer tenga un peso por debajo de los 1500 gramos. El problema es averiguar el área sombreada en el siguiente gráfico:



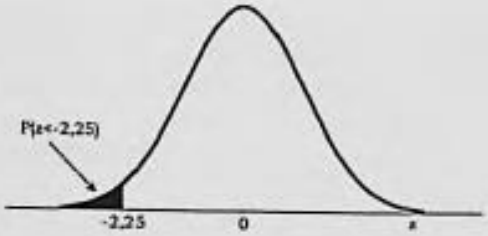
Para calcular el área marcada —que corresponde a la probabilidad solicitada—, vamos a transformar el valor de x (1500) a puntaje z, haciendo:

$$z = \frac{x - \bar{x}}{s} = \frac{1500 - 3300}{800} = -2{,}25$$

Ahora es equivalente solicitar la probabilidad de x menor que 1500 que la de z menor que -2,25, en símbolos:

$$P(x < 1500) = P(z < -2{,}25)$$

Y el gráfico anterior expresado en términos de z resulta:



A esta probabilidad sabemos cómo calcularla y obtenemos 0,0122.
Ésta es la probabilidad de hallar niños que al nacer tengan pesos inferiores a los 1500 gramos.

Del mismo modo podemos operar si nos interesa conocer la probabilidad de hallar niños que nazcan con peso comprendido entre 3500 y 4500 gramos. Transformando cada uno de los valores se obtiene:

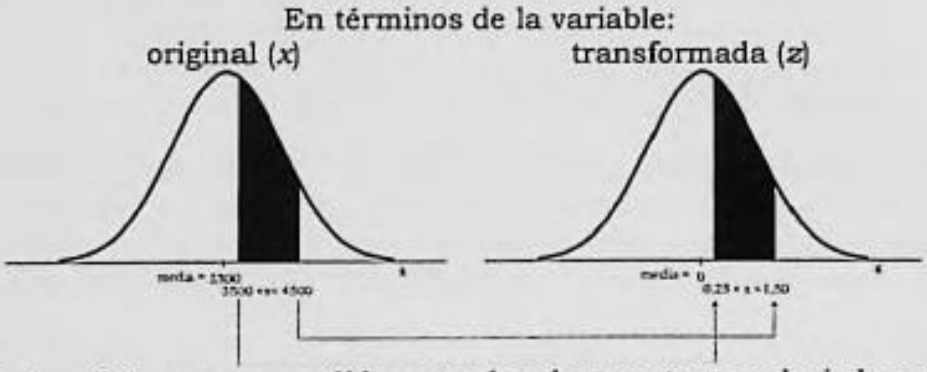
$$x = 3500 \rightarrow z = \frac{3500 - 3300}{800} = 0{,}25$$

$$x = 4500 \rightarrow z = \frac{4500 - 3300}{800} = 1{,}50$$

Entonces, que x (el peso de los niños al nacer) esté entre 3500 y 4500 gramos, equivale a que z (cantidad de desviaciones estándar) se encuentre entre 0,25 y 1,50. Esto se expresa simbólicamente así:

$$P(3500 < x < 4500) = P(0{,}25 < z < 1{,}50)$$

Y se representa gráficamente así:



Para calcular el área comprendida entre los dos puntos, es decir la probabilidad de hallar a x entre 3500 y 4500, restamos, a la probabilidad acumulada hasta *z=1,50*, la acumulada hasta *z=0,25*:

$$P(3500 < x < 4500) = P(0{,}25 < z < 1{,}50) = P(z < 1{,}50) - P(z < 0{,}25) = 0{,}9332 - 0{,}5987 = 0{,}3345$$

Leemos el resultado diciendo que la probabilidad de hallar a un niño que haya nacido con un peso comprendido entre los 3500 y los 4500 gramos es de 0,3345.

Toda variable que puede modelarse con una distribución normal puede transformarse a puntaje z y así hallar la probabilidad asociada a diferentes intervalos.
Las hojas de cálculo y, por cierto, los programas de análisis de datos incorporan esta operación, por lo que es posible ingresar directamente con los valores de la

variable e informar la media y la desviación estándar, para obtener las probabilidades correspondientes. Veamos el modo de obtener el resultado de manera directa, sin pasar por z. La probabilidad que nos interesa es, como antes:

$$P(3500 < x < 4500)$$

Que se calcula como la diferencia entre la probabilidad acumulada hasta 4500 menos la acumulada hasta 3500.

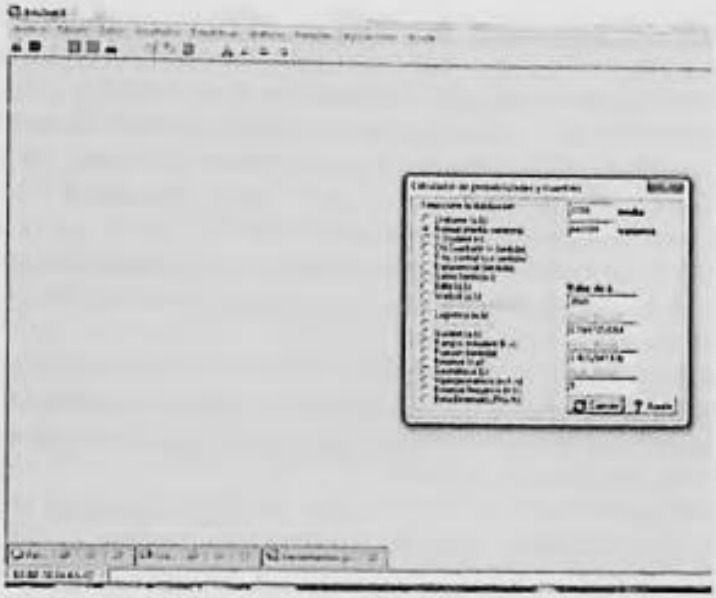
$$P(3500 < x < 4500) = P(x < 4500) - P(x < 3500)$$

Usando InfoStat®, solicitamos la distribución normal, pero ahora cambiamos la media y la varianza que aparece por defecto como cero y uno (para la variable z), por los valores de la media y la varianza que conocemos[60] e indicamos el primer valor de x:



La probabilidad acumulada hasta 4500 es 0,9332. Del mismo modo obtenemos la otra:

[60]Contábamos con el dato de desviación estándar igual a 800, por lo que la varianza es de 640000



Que es 0,5987, entonces

$$P(3500 < x < 4500) = P(x < 4500) - P(x < 3500) = 0{,}9332 - 0{,}5987 = 0{,}3345$$

Es el mismo resultado al que habíamos llegado a través de la transformación a puntaje z, pero ahora pidiéndola directamente desde x. Aunque éste sea el procedimiento más cómodo para calcular probabilidades, es necesario estar familiarizado con la distribución normal estándar (en z), por los usos que haremos en los próximos capítulos.

La distribución normal tiene un uso muy amplio y varios campos de aplicación. Más adelante veremos que para aplicar algunos procedimientos de análisis, es necesario que los datos provengan de una distribución normal, y existen pruebas para verificar que esto se cumpla. Una primera aproximación para ver si un conjunto de datos tiene distribución cercana a la normal es observar el histograma y evaluar si su forma se aproxima a la normalidad: si es unimodal y aproximadamente simétrica, es decir si la mediana es semejante a la media. Luego se calculan los coeficientes de curtosis y asimetría y, si éstos están entre -0,50 y +0,50, puede aceptarse, en primera instancia, la normalidad de los datos.

La idea de grados de libertad

Antes de avanzar hacia los otros modelos de probabilidad que presentaremos en este capítulo, es necesario tener una idea aproximada de un concepto que juega un papel de importancia en esas distribuciones, el de "grados de libertad", un número que, como veremos enseguida, determina la forma de algunas distribuciones. Se trata de un concepto matemático complejo, al que vamos a definir como el número de observaciones linealmente independientes que existen en una suma de cuadrados[61], pero del que haremos un uso exclusivamente instrumental. Su denominación es gl o bien df en inglés (degrees of freedom).

[61]Solo nos interesará contar con una idea intuitiva y ejemplos de aplicación.

Consideremos el caso del cálculo de la varianza, cuyo numerador es: $\sum_{i=1}^{n}(x_i - \bar{x})^2$. Que es la suma de n términos, cada uno de ellos elevado al cuadrado. Identificar los grados de libertad de esa expresión equivale a responder a ¿cuántos términos de esa suma no dependen del valor que asumen los demás? Supongamos que se conoce la media muestral; esto establece un número fijo para la suma de las n observaciones: x_1, x_2,...x_n, por lo que solo $n-1$ de ellas pueden elegirse "libremente", la última observación queda determinada.
Por ejemplo, si se trata de cuatro observaciones de las que sabemos que su media es cinco, entonces la suma de los cuatro números debe ser 20 ¿Cuáles son los valores posibles para las cuatro observaciones x_1, x_2, x_3, x_4? Hay infinitas combinaciones posibles que darian suma igual a 20, fijemos arbitrariamente algunos de los valores: $x_1=2$, $x_2=4$, $x_3=4$, estos tres números suman 11, por lo que el cuarto solo puede ser 9 (para lograr la suma de 20 y que entonces la media sea 5). Otra combinación posible de valores es $x_1=4$, $x_2=5$, $x_3=10$, con lo que $x_4=1$ necesariamente. Cualquiera sea la elección que se haga, siempre serán tres de los cuatro valores los que puedan elegirse libremente; decimos entonces que los grados de libertad son tres.
En general, para este problema, los grados de libertad se calcularán como $n-1$, donde n es el número de observaciones, diremos así que, de n observaciones, $n-1$ son independientes, si se fija el resultado de la suma.

Una situación diferente es cuando se trata con una tabla de doble entrada con frecuencias marginales fijas; allí los grados de libertad se interpretan de modo distinto. No están relacionados con el número de observaciones sino con la dimensión de la tabla. Veamos la siguiente tabla de dos por tres, con frecuencias marginales fijadas:

	A	B	C	Total
R				10
S				30
Total	5	10	25	40

En ella se relacionan dos variables cuyas categorías son A, B y C para la de las columnas y R y S para la de las filas. En la tabla, hemos fijado las frecuencias marginales. No hay dudas que hay infinitos valores posibles para las frecuencias conjuntas que podrían sumar lo que piden las marginales. Nos preguntamos ¿Cuántas de las frecuencias de las celdas (frecuencias conjuntas) pueden elegirse libremente? Si elegimos el valor 2 para la celda RA, queda determinado un 3 en la celda SA (para que cumpla con sumar 5 verticalmente). Si luego elegimos un 4 en la celda RB, la SB queda determinada a ser 6 (para sumar 10 en la segunda columna). Al mismo tiempo, la celda RC debe ser también 4 para sumar 10 en la primera fila y también se determina la celda SC, que no puede ser sino 21, para sumar 30 en la segunda fila y 25 en la tercera columna. La tabla queda así completada, solo las celdas RA y RB fueron elegidas, las demás quedaron determinadas por la exigencia de respetar las frecuencias marginales.

	A	B	C	Total
R	2	4	4	10
S	3	6	21	30
Total	5	10	25	40

¿Cuántos serán los grados de libertad en este ejemplo?, de las seis celdas que debían completarse con frecuencias, solo 2 pudieron elegirse libremente. Éstos últimos son los grados de libertad: 2.
De manera general, para una tabla de dimensión *f por c* (donde *f* es la cantidad de filas y *c* la de columnas, como antes), los grados de libertad se calculan multiplicando *(f-1)* por *(c-1)*. En la tabla que acabamos de usar como ejemplo, la dimensión es 2 por 3, por lo que los grados de libertad son *(2-1)*(3-1)= 1*2=2*, que son las dos celdas cuyas frecuencias pudimos fijar "libremente".

A los fines de nuestro curso, esta introducción a la idea de grados de libertad es suficiente, el concepto es amplio y su tratamiento más profundo exigiría algunos conocimientos de álgebra lineal, que no necesitamos desarrollar aquí.

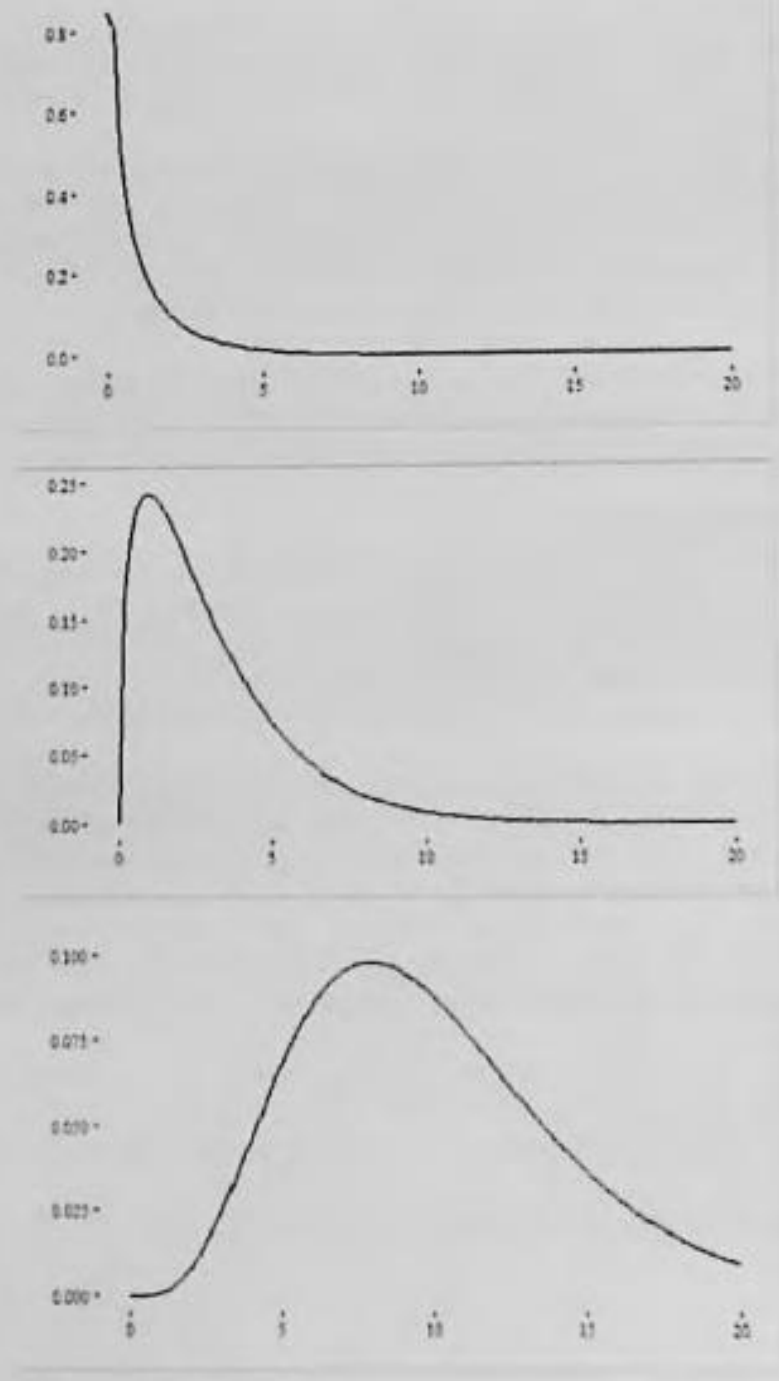
La distribución ji cuadrado (χ^2)

Esta distribución es el primer modelo que veremos con forma asimétrica[62]. Una de sus aplicaciones es la estimación de la varianza, nosotros la utilizaremos más adelante, cuando tratemos sobre estadística no paramétrica, en especial para probar si una variable puede modelarse con cierta distribución (pruebas de bondad de ajuste) y también para analizar la independencia entre variables nominales.
Del mismo modo en que tratamos a la distribución normal, no haremos uso de la fórmula para calcular probabilidades, sino que las buscaremos en una tabla disponible en cualquier hoja de cálculo. Además de la forma asimétrica, hay otra diferencia con la distribución normal, la χ^2 no es una distribución única: no es suficiente especificar un valor de la variable para conocer su probabilidad acumulada sino que la forma que tenga dependerá de los recientemente mencionados "grados de libertad", los cuales en una primera aproximación tomaremos como *n-1*.
Las siguientes son las formas diferentes que tiene la distribución χ^2 para diferentes valores de los *gl*, el eje horizontal indica los valores de la variable χ^2. Como en la normal, las probabilidades se representan como áreas bajo la curva:

Distribución χ^2 con uno, tres y diez grados de libertad:

UNIVERSIDAD TÉCNICA DEL NORTE
BIBLIOTECA
Ibarra - Ecuador

[62]La definición de la variable χ^2 con n grados de libertad es la suma de n variables aleatorias normales estándar elevadas al cuadrado: $\chi^2 = \sum_{i=1}^{n} z_i^2$, en la que cada z es una variable distribuida normalmente con media cero y desviación estándar igual a uno.

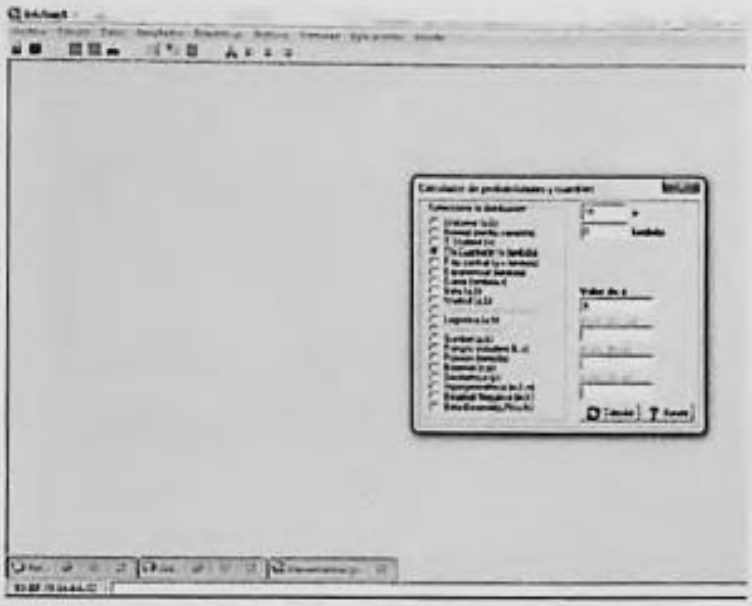


Los gráficos muestran que a medida que se incrementan los grados de libertad, la forma de la distribución gana en simetria y se asemeja a la distribución normal.

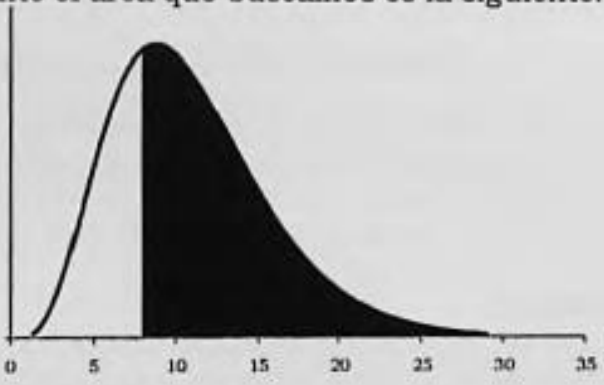
Para hallar las probabilidades correspondientes a valores de la variable, usaremos nuevamente InfoStat®. Vamos a calcular la probabilidad de hallar valores de una variable con distribución χ^2con diez grados de libertad, superiores a 8, a lo que expresamos como:

$$P(\chi^2_{10} > 8)$$

Donde hemos indicado los grados de libertad (10) como subindice.



La letra ν (nu) indica los grados de libertad, allí colocamos el 10. Dejaremos el otro valor (lambda) en cero que es el que está elegido por defecto. El espacio señalado como "valor de x", corresponde al valor de nuestra variable, que en este caso es 8. Gráficamente el área que buscamos es la siguiente:



Y la salida InfoStat® es:



Nuevamente obtenemos dos resultados válidos: el área por debajo (P(X<=x)) y el área por encima (P(X>x)) del valor que especificamos, las cuales son complementarias, es decir que su suma es igual a uno, que es el área completa bajo la curva. Nos interesa la segunda, por lo que:

$$P(\chi^2_{10} > 8) = 0{,}6288$$

Que es la superficie que está sombreada en el gráfico anterior.
La distribución χ^2 tiene muchas aplicaciones, una de las más frecuentes es para poner a prueba la independencia entre dos variables nominales. El vínculo entre esta distribución y el puntaje χ^2 que ya se mencionó, se verá más adelante.

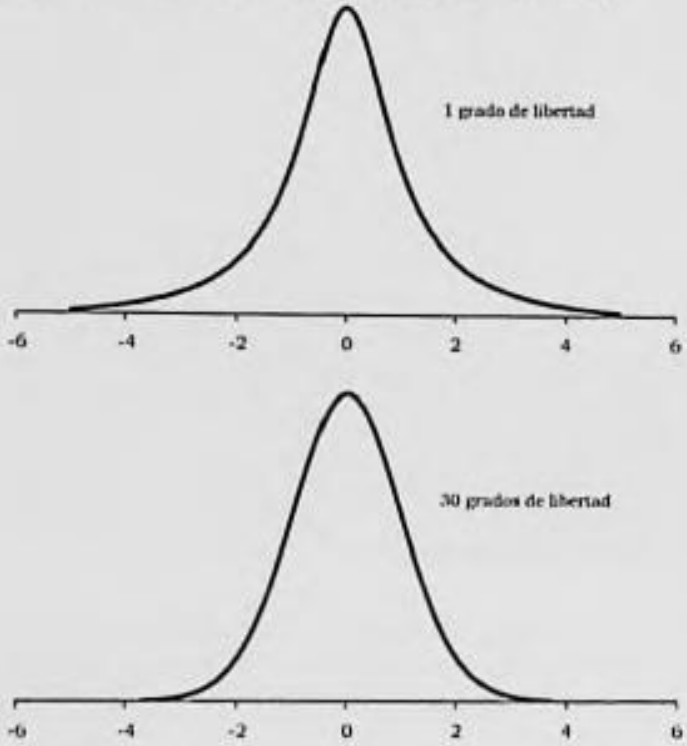
La distribución t de Student

El tercer modelo especial de probabilidades para variables continuas que nos interesa describir es la distribución t, conocida como "de Student", por el seudónimo que utilizaba quien la aplicó por primera vez, William Gosset[63].
Se trata de una distribución que, como la normal es simétrica y como la χ^2 depende de los grados de libertad[64]. Su forma es la siguiente, dependiendo de los grados de libertad:

[63] Químico y Estadístico inglés (1876-1937), era empleado de la cervecería Guiness y allí desarrolló procedimientos adecuados para trabajar con pequeñas muestras. Una de las versiones acerca de por qué publicó con el seudónimo Student es que la empresa temía que se revelaran secretos industriales.

[64] La definición de la variable con distribución t con n grados de libertad es el cociente entre una variable con distribución normal estándar y la raíz cuadrada de una χ^2 dividida por sus grados de libertad: $t = \frac{z}{\sqrt{\frac{\chi^2_n}{n}}}$

Distribución t de Student con diferentes grados de libertad:



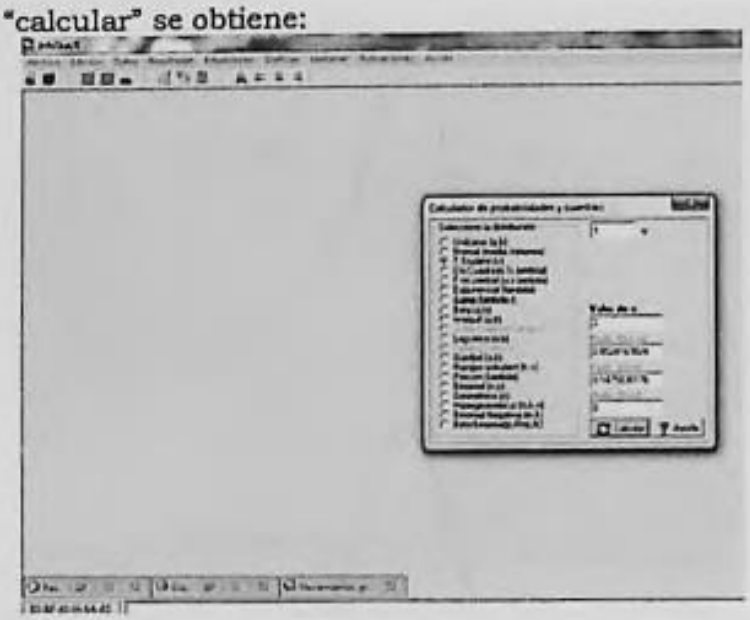
Con 30 grados de libertad, la distribución toma una forma que va haciéndose más similar a la normal. Las probabilidades acumuladas se buscan con InfoStat®, donde debe informarse los grados de libertad y el valor de la variable. La probabilidad que una variable con distribución t con un grado de libertad, supere a 2 se escribe:

$$P(t_1 > 2)$$

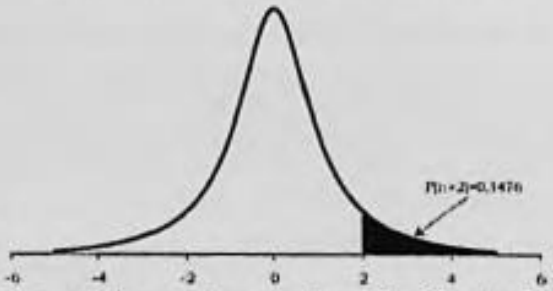
Y se solicita:



Luego de pedir "calcular" se obtiene:



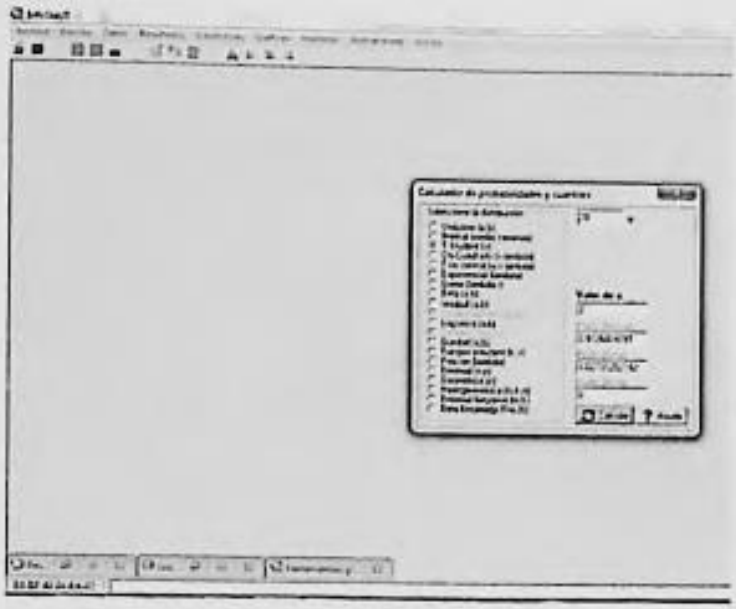
Como en las otras distribuciones, tenemos la probabilidad acumulada por debajo (Prob(X<=x)) y la probabilidad por encima (Prob(X>x)) que, cuando se suman, dan uno. El resultado que nos interesa para $P(t_1 > 2)$ es 0,1476 y se representa gráficamente así:



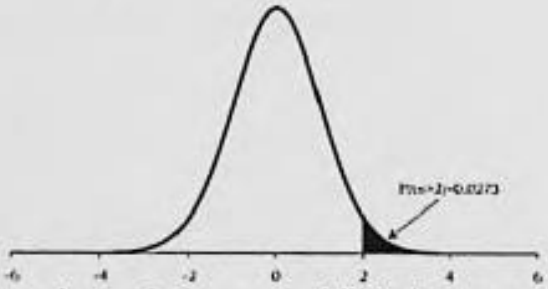
Para ver los efectos del cambio en los grados de libertad, vamos a comparar la probabilidad que una variable t con 30 grados de libertad supere a 2, es decir:

$$P(t_{30} > 2)$$

InfoStat® ofrece:



Por lo que $P(t_{30} > 2) = 0{,}0273$ que se representa:



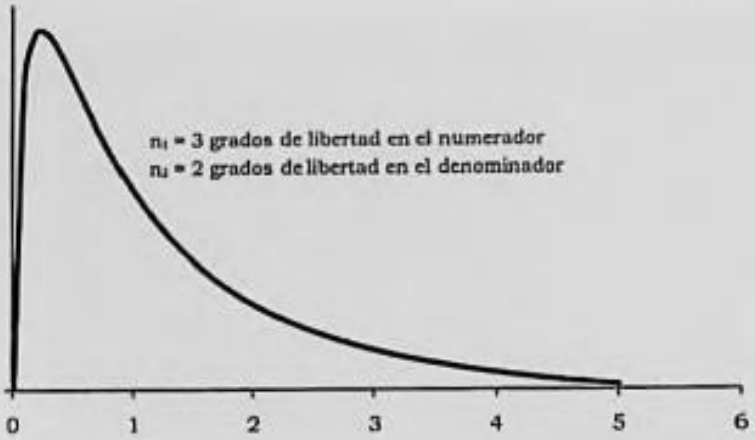
En los gráficos y en los valores de las probabilidades se ve que el aumento de los grados de libertad en la distribución t tiene el efecto de reducir la probabilidad de los valores extremos.
Cuando trabajemos con inferencia, veremos que la distribución t se aplica en reemplazo de la normal, cuando se trabaja con muestras pequeñas y que se va volviendo más equivalente a ella a medida que las muestras son de mayor tamaño.

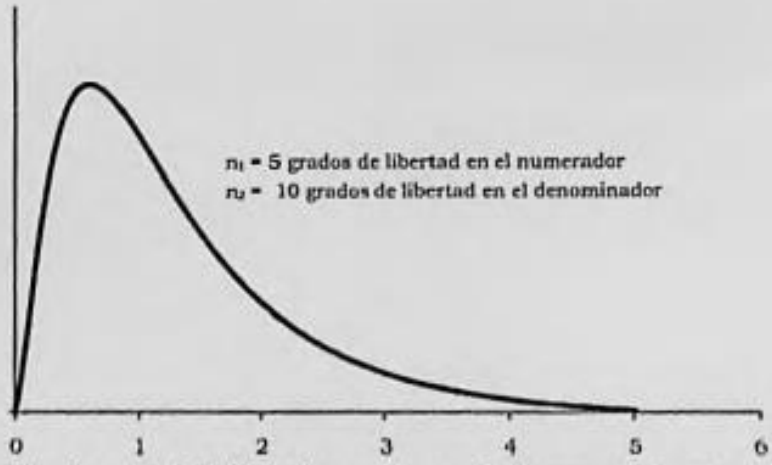
La distribución F

El último de los modelos de probabilidad que necesitamos para usar en los próximos capítulos en la realización de inferencias, es la distribución F de Fisher. Es una distribución asimétrica, no negativa y su forma depende de los valores de los grados de libertad del numerador y del denominador[65]. Es una curva muy asimétrica a la derecha cuando los grados de libertad son pocos y tiende a la normalidad a medida que aumentan los *gl*. Veamos dos casos de combinaciones de grados de libertad en el numerador y en el denominador:

---

[65]Estos nombres para los grados de libertad se originan en que la F se define como el cociente de dos distribuciones χ^2, cada una dividida por sus grados de libertad: $F_{n_1,n_2} = \frac{\chi_1^2/n_1}{\chi_2^2/n_2}$





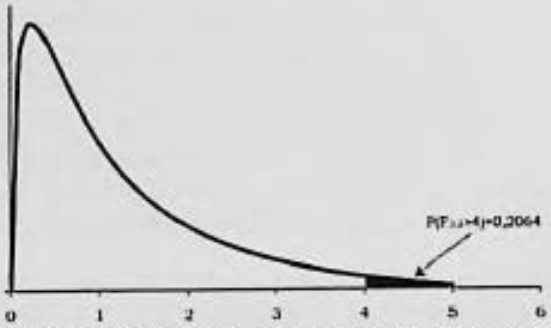
En el cálculo de las probabilidades, ahora debemos informar los grados de libertad del numerador y del denominador separadamente. Para solicitar, por ejemplo, la $P(F_{3,2} > 4)$, procedemos como antes, indicamos los *gl* en los dos espacios ofrecidos y dejamos lambda en cero:



Y obtenemos:



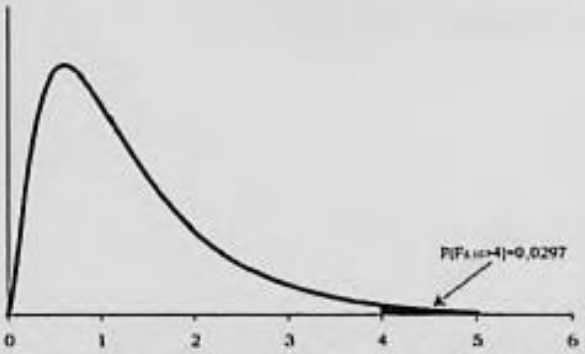
De modo que $P(F_{3,2} > 4) = 0{,}2064$. Cuyo gráfico es:



Cuando pedimos la comparación con otra variable que tenga distribución F con otros grados de libertad (5 y 10, por ejemplo), obtenemos lo siguiente:



Es decir: $P(F_{5,10} > 4) = 0{,}0297$. Esa probabilidad corresponde al área siguiente:



También en esta distribución vemos que el aumento de los *gl* tiene el efecto de reducir la probabilidad de los valores extremos. Con 3 y 2 *gl*, el valor 4 deja por encima al 20% del área total (0,2064), cuando aumentamos los *gl* a 5 y 10, ese mismo valor deja un poco menos del 3% (0,0297) por encima.

La distribución F es usada para comparar la dispersión de dos distribuciones, a través del cociente de las varianzas.

Capítulo 9 Distribuciones en el muestreo

Parámetros y estimadores

En este capítulo se ligan los conceptos de muestreo y de probabilidad para establecer las bases de los procedimientos de inferencia estadística. La parte III tratará con datos que provienen de muestras probabilísticas, es decir, unidades de análisis que habrán sido seleccionadas usando alguno de los procedimientos de muestreo probabilístico. En consecuencia, las medidas que se calculen a partir de esos datos dependerán del azar[66].

Por ejemplo, el conjunto completo de estudiantes de Psicología en 2014 tenía una edad promedio de 26,8 años (UNC, 2014), si ese año se hubiese extraído una muestra de 20 alumnos al azar, la edad promedio podría haber sido un número muy diferente de 26,8 años. Recordemos que las muestras tienen carácter aleatorio, no podemos asegurar que la variable que estamos estudiando se asemeje en la muestra al valor que tiene en la población. Por eso, el resultado que obtengamos en la muestra depende del azar: se trata de una variable aleatoria. La media muestral, por ser una medida calculada sobre los valores obtenidos en una muestra aleatoria, es una variable aleatoria, su valor depende de cuáles sean los casos que constituyen la muestra y esto depende del azar, que es lo que hemos pedido como requisito al procedimiento de muestreo.

Estamos entonces refiriéndonos a entidades diferentes cuando hablamos de la media poblacional y la media muestral, aunque el procedimiento de cálculo sea el mismo. La media poblacional es un valor que puede ser conocido (si hemos observado a toda la población) o desconocido, pero en todo caso es fijo. Cuando hacemos estimaciones no sabemos cuánto vale la media de la población, pero sí sabemos que es un número estable, fijo. Por el contrario, la media muestral—y porque depende de los casos que hayan sido aleatoriamente seleccionados para constituir la muestra—depende finalmente del azar, por eso es una variable aleatoria.

Las medidas que se refieren a la población se denominan **parámetros** también llamados **parámetros poblacionales**, para acentuar que se trata de la población), por ejemplo, el valor de 26,8 años que mencionamos más arriba es la media paramétrica o también media poblacional, porque fue calculada sobre todos los alumnos de Psicología. Si se trabaja con variables cualitativas, se tratará de la proporción de alguna categoría (proporción de varones, proporción de afectados de cierta patología, de egresados, de repitentes, etc.), se tratará allí de la proporción paramétrica o proporción poblacional. O bien de la varianza, la desviación estándar o también de coeficientes de correlación (Pearson, Spearman). Todas las medidas que hemos mencionado hasta aquí pueden calcularse sobre la población completa si se hace un censo, o bien sobre una muestra que debe ser aleatoria si se quiere luego hacer inferencias. En todos los casos que se trate de medidas que se refieran a la población completa, las llamaremos paramétricas. Solo podrían ser conocidas en aquellos casos en que la

[66] Las fórmulas para hacer inferencias que aparecen en este capítulo y los siguientes, son correctas si el muestreo es irrestricto aleatorio, cuando se usen otros diseños de muestra (siempre probabilísticos), será necesario introducir ajustes; el texto de Scheaffer et al (1987) es una adecuada referencia para esas correcciones.

población integra fuera observada, es decir, si se hiciera un relevamiento exhaustivo, un censo; allí no hay inferencia. Por eso, lo que interesa en estadística inferencial son las situaciones en que no conocemos los parámetros de una población, porque entonces deberemos **estimarlos** desde la muestra. Diremos que buscamos estimar diferentes parámetros. Ese es el tema que tratará el próximo capítulo: "Estimación de Parámetros". También puede suceder que haya algún valor hipotético para un parámetro, al que necesitemos poner a prueba. En ese caso usaremos los datos de la muestra para **probar una hipótesis**, de eso trata un amplio campo que trataremos más adelante llamado "Pruebas de Hipótesis".

Las medidas calculadas sobre los datos de la muestra se denominan **estadísticos** también llamadas **estadísticos muestrales**, nuevamente para acentuar de dónde provienen. Hablaremos entonces de la media muestral, la proporción, la varianza o el coeficiente de correlación muestral. Los valores que de ellos obtengamos en la muestra permitirán estimar los correspondientes valores paramétricos. Por eso decimos que la media muestral es el estimador de la media poblacional y del mismo modo con la proporción, la varianza, la desviación estándar o los coeficientes de correlación. La media muestral es el promedio de la variable (cuantitativa) que se observa en la muestra de n casos seleccionados. Para calcular la proporción, se debe contar con una variable categórica (o categorizada) y seleccionar las categorías de interés, los que hemos llamado éxitos en la distribución binomial. Si se trata de varones y mujeres, puede elegirse la proporción de mujeres, si hay alumnos que quedan libres, regularizan o promocionan (una categorización de las notas), puede ser la proporción de promocionales. La proporción es como sabemos, el cociente entre los casos que resultan en la categoría de interés y la cantidad total de casos.

Para distinguir entre las medidas calculadas sobre toda la población y las de la muestra usaremos diferentes símbolos. De manera general, las letras latinas se usarán para identificar medidas descriptivas obtenidas sobre datos muestrales, mientras que usaremos letras griegas para referirnos a los valores de la población. Pero esto no es siempre así, por razones de tradición en el uso, en el caso de la proporción se distingue la poblacional de la muestral usando P (mayúscula) para la primera y p (minúscula) para la segunda[67]. La siguiente es la notación que usamos y la correspondencia entre valores poblacionales y muestrales.

---

[67]Dado que puede haber confusión al escribir p o P, es frecuente usar $\hat{p}$ para indicar la proporción muestral, con la misma notación que se usó en regresión para indica el valor estimado de la variable dependiente.

	En la población	En la muestra
Cantidad de casos	N	n
Media	μ (mu)	$\bar{x}$
Proporción	P	$\hat{p}$
Varianza	σ^2 (sigma cuadrado)	s^2
Desviación Standard	σ (sigma)	s
Diferencia de medias	$\mu_1 - \mu_2$	$\bar{x}_1 - \bar{x}_2$
Diferencia de proporciones	$P_1 - P_2$	$\hat{p}_1 - \hat{p}_2$
Cociente de varianzas	$\frac{\sigma_1^2}{\sigma_2^2}$	$\frac{s_1^2}{s_2^2}$
Coeficiente de correlación de Pearson	ρ (rho)	r
Coeficiente de correlación de Spearman	ρ_s (rho ese)	r_s
Pendiente de la recta de regresión	β_1 (beta uno)	b_1
Ordenada al origen de la recta de regresión	β_0 (beta cero)	b_0

Las operaciones que se realizan para calcular los estadísticos que hemos tratado hasta aquí son las mismas que para los parámetros, solo difieren los nombres de cada elemento. Así, para calcular μ debemos hacer como con $\bar{x}$; sumar todos los valores y dividir por el total de casos, pero en lugar de:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i * f_i}{n}$$

Escribiremos:

$$\mu = \frac{\sum_{i=1}^{N} x_i * f_i}{N}$$

Que solo difiere en el nombre de la media y la cantidad de casos.

En el caso de la proporción, llamamos x a la cantidad de casos que se encuentran en la categoría de interés (la cantidad de éxitos):

$$\hat{p} = \frac{x}{n}$$

Mientras que en la población, si X es la cantidad de éxitos:

$$P = \frac{X}{N}$$

Una excepción a esto es el caso de la varianza, porque el modo de calcularla es levemente distinto si se trabaja con datos muestrales o poblacionales. Cuando es calculada sobre los elementos de la muestra, la varianza muestral es:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Pero cuando la varianza se calcula sobre los elementos de la población, su cálculo se realiza con la expresión:

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$$

En esta última expresión cambiaron los nombres de los elementos con los que se opera (μ en lugar de $\bar{x}$, N en lugar de n), y además se ha eliminado el -1 del denominador. Ya no es el total de casos menos uno, sino el total de casos. El origen de esto es que esta última expresión (con denominador N) es la definición original de la varianza, mientras que la que usada en la muestra (s^2 con denominador n-1) es una corrección, que se hace para que sea un buen estimador de la varianza poblacional.[68]
Con InfoStat® el cálculo de la varianza puede solicitarse para la población o para una muestra, la notación que usa ese programa es *Var(n)* para referirse a la varianza poblacional, es decir a σ^2, y *Var(n-1)* para indicar la varianza muestral, s^2, en referencia al denominador que se usa para calcular cada una.

Así, la característica poblacional que pretende conocerse se llama **parámetro** y a través del proceso de muestreo se seleccionan algunas unidades del universo que actuarán como representantes de la población completa. Esta muestra será toda la información disponible para realizar estimaciones acerca de los parámetros poblacionales. Los valores calculados sobre los datos muestrales son los que se utilizarán para realizar aproximaciones a los valores poblacionales; tales valores son denominados **estimadores puntuales**, o simplemente **estimadores.**
De una población se pueden obtener un número muy grande de muestras, dependiendo de su tamaño y del universo de donde se extraen, pero en un proceso de muestreo se toma una sola muestra de todas las posibles. Dado que las muestras se extraen al azar, cada una de ellas proveerá de una estimación diferente del parámetro. Para un parámetro elegido, habrá tantos valores estimados como muestras puedan extraerse de la población (con algunos resultados repetidos). Esta variación (casi) impredecible de los estimadores, hace que se comporten como variables aleatorias.

---

[68]Lo que se consigue con esa corrección es que, si se calculan las varianzas de todas las muestras que se saquen de una población dada, éstas promedien la varianza de la población, lo cual no sucede si se usa el denominador n. Se denomina insesgabilidad del estimador, por lo que podemos decir que el denominador de la varianza muestral se transforma en n-1 para lograr que sea un estimador insesgado de la varianza poblacional.

Es posible (aunque esperamos que sea poco probable) que el estimador se aleje notablemente del valor poblacional al que se pretende estimar. Así, si se busca estimar la edad promedio de los estudiantes de cierta carrera universitaria y no se cuenta con un registro de ellos, puede usarse una estimación a partir de una muestra extraída de todos los estudiantes. El promedio calculado sobre esos datos se tomará como estimación de la edad de todos los estudiantes; pero puede ocurrir que la muestra contenga, por azar, al grupo de mayor edad de toda la población, con lo cual el resultado así obtenido será una sobreestimación del verdadero valor poblacional. Debe destacarse que este hecho resulta completamente inadvertido para el investigador. Con respecto a la ocurrencia de estos eventos que conducen a resultados engañosos, sólo será posible —bajo ciertas condiciones—, calcular sus probabilidades.
Dos aspectos importantes para recordar cuando se usan muestras:
La variabilidad de las muestras: Las muestras difieren entre sí. Las muestras extraídas de la misma población dan resultados diferentes.

La representatividad de la muestra: No indica la similitud entre la muestra y la población, sino su obtención por un procedimiento adecuado que permita estimar valores de la población a partir de lo que se halle en la muestra.

Características de los estimadores

Insesgabilidad

Si fuera posible extraer todas las muestras de una población, se contaría con todos los estimadores de un parámetro dado. Cuando el promedio de todos los valores obtenidos en todas las muestras de un determinado tamaño para cierto parámetro es igual al valor de esa característica en la población, se dice que el estimador muestral es **insesgado**. Se denomina sesgo de un estimador a la diferencia entre el promedio que alcanzaría sobre todas las muestras posibles y el verdadero valor del parámetro poblacional. En el caso de un estimador insesgado esta diferencia es igual a cero (sin sesgo).

Consistencia

Intuitivamente puede pensarse que el aumento en el tamaño de la muestra (número de elementos que la componen) mejora la calidad de la estimación. Esta característica, que se cumple para algunos estimadores, es denominada **consistencia**. Un aumento en el tamaño de la muestra no garantiza que se obtendrán resultados más próximos a los valores poblacionales: por grande que sea la muestra no resulta imposible que a ella pertenezcan los valores más extremos de la población. Veamos esto con un ejemplo. Supongamos que se quiere estimar la calificación promedio con que egresan los alumnos de una carrera dada y que se toma una muestra de 30 egresados. Puede ocurrir que la muestra (por azar) contenga a los treinta mejores promedios de la carrera, con lo que se obtendría una sobreestimación del verdadero promedio de toda la población. El concepto de consistencia expresa que si la muestra, en lugar de 30 elementos, contiene 100, la probabilidad de obtener una sobreestimación igualmente extrema es menor. Intuitivamente podemos ver que resulta más factible encontrar a los 30 mejores que a los 100 mejores.

No debe entenderse que el estimador alcance valores más próximos a los paramétricos a medida que la muestra aumenta de tamaño, sino que disminuye la probabilidad de obtener resultados muy lejos de los paramétricos a medida que la muestra crece. Esta idea parece un poco abstracta ahora, se aclarará cuando la usemos en casos aplicados.

Eficiencia

Esta es una característica relativa, es decir que sirve para comparar estimadores. La eficiencia será mayor cuanto más pequeña sea la varianza del estimador. Por ejemplo, la media es un estimador más eficiente que la mediana porque, extraídas en todas las muestras posibles de un tamaño dado, la varianza de las medias es menor que la de las medianas.

Una vez acordados los elementos con los que trabajaremos en este capítulo, debemos volver sobre el problema del carácter aleatorio de los estimadores (los estadísticos muestrales). Como variables aleatorias que son, tienen distribuciones de probabilidad asociadas y eso es lo que permite calcular la probabilidad de ocurrencia de sus diferentes valores. Conocer las distribuciones de probabilidad de los estadísticos muestrales sirve para ponerlos en relación con los parámetros a los que estiman: se usarán las distribuciones de probabilidad ya mencionadas para relacionar los estimadores (conocidos) con los parámetros (desconocidos). A fin de presentar el tema, haremos "como si" se conocieran los valores poblacionales, y veremos qué sucede con los estimadores.

Ejemplo 9.1

El problema de las distribuciones muestrales se presenta aquí a través de un ejemplo que trata sobre una muy pequeña población ficticia. Supongamos que sea la población de tres pacientes de un hospital psiquiátrico que los tiene como únicos internados[69]. Llamaremos A, B y C a estos tres pacientes y consideraremos dos variables: el *tiempo que llevan desde su ingreso* (expresado en meses) y el *sexo*. La primera variable es cuantitativa, la segunda cualitativa. La siguiente es la matriz de datos para esta población ficticia y las variables indicadas.

caso	Paciente	Meses desde el ingreso	Sexo
1	A	3	Varón
2	B	4	Mujer
3	C	5	Varón

Para describir esta población mostramos su (elemental) distribución de frecuencia e indicaremos la media y la varianza de la variable cuantitativa (meses desde el ingreso):

[69] Suponer que en el hospital solo hay tres internados es una gran simplificación, por cierto ficticia. Se usa con fines expositivos, para poder hacer intuitiva la comparación entre la población y las muestras.

x	f
3	1
4	1
5	1
Total (N)	3

$$\mu = \frac{3+4+5}{3} = 4$$

$$\sigma^2 = \frac{(3-4)^2 + (4-4)^2 + (5-4)^2}{3} = \frac{2}{3} = 0{,}67$$

Además, calcularemos —también sobre datos de la población completa—la proporción de mujeres[70], codificando como 1 la presencia de un "éxito" y 0 su ausencia:

$$P = \frac{0+1+0}{3} = \frac{1}{3} = 0{,}33$$

Estos valores (μ, σ^2 y P) son los que llamamos parámetros y caracterizan a las dos variables para la población completa.

Ahora veremos qué sucede cuando se muestrea. Para ello vamos a sacar todas las muestras posibles de tamaño dos (podrían haber sido de otro tamaño, lo elegimos para este ejemplo), y las muestras que extraigamos serán con reposición[71]. Así resultan las siguientes nueve muestras: AA, AB, AC, BA, BC, BB, CA, CB, CC. Como todas tienen la misma oportunidad, cada una tiene probabilidad 1/9 de ser seleccionada aleatoriamente.

En cada una de las muestras calcularemos la media del tiempo de internación ($\bar{x}$) y la proporción de mujeres ($\hat{p}$).

Muestra	Meses de internación	$\bar{x}$	Cantidad de mujeres	$\hat{p}$
AA	3-3	3,0	0	0,0
AB	3-4	3,5	1	0,5
AC	3-5	4,0	0	0,0
BA	4-3	3,5	1	0,5
BB	4-4	4,0	2	1,0
BC	4-5	4,5	1	0,5
CA	5-3	4,0	0	0,0
CB	5-4	4,5	1	0,5
CC	5-5	5,0	0	0,0

[70] Esta categoría se eligió arbitrariamente, podría haber sido la otra y calcular la proporción de varones.

[71] Nuevamente se trata de una simplificación expositiva. Esta forma de extraer una muestra no es la que se aplica en la práctica, porque no se permite elegir dos veces al mismo individuo. Sin embargo, este muestreo con reposición en una buena aproximación a los muestreos verdaderos (sin reposición) cuando se trabaja con poblaciones grandes. Es así porque la extracción de unos pocos casos, aunque sean sin reposición, altera poco la probabilidad de ser extraídos de los otros casos.

Antes de analizar estos resultados, los organizaremos mejor, presentando las distribuciones de frecuencia de las $\bar{x}$ y de las $\hat{p}$:

$\bar{x}$	f	f'
3,0	1	0,11
3,5	2	0,22
4,0	3	0,33
4,5	2	0,22
5,0	1	0,11
Total	9	1,00

$\hat{p}$	f	f'
0,0	4	0,44
0,5	4	0,44
1,0	1	0,11
Total	9	1,00

Distribución de la media muestral

Vamos a concentrarnos inicialmente en la distribución de $\bar{x}$. Lo primero que se observa en la tabla de distribución de frecuencias de $\bar{x}$ es lo que significa que $\bar{x}$ sea una variable: quiere decir que las diferentes muestras ofrecen valores diferentes de $\bar{x}$; o bien, que el valor de $\bar{x}$ varía dependiendo de cuál haya sido la muestra que se seleccionó al azar. En segundo lugar, estos valores no se refieren a casos individuales sino a promedios obtenidos en muestras de tamaño dos.

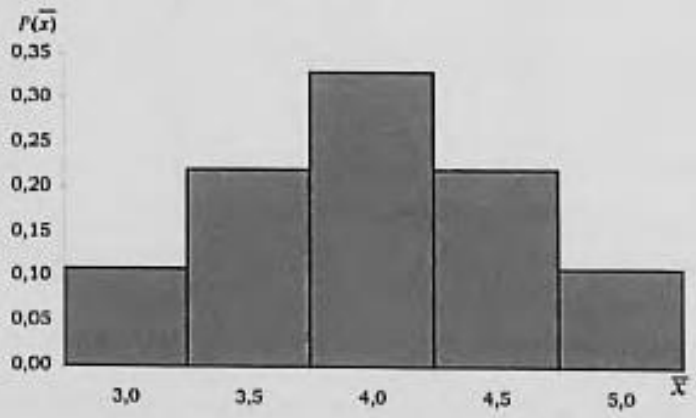
Si se usan las frecuencias relativas como aproximaciones a la probabilidad, leemos en la tabla que la probabilidad de obtener una muestra en la que el promedio sea de tres meses de internación es de 0,11. Expresamos estos simbólicamente así:

$$P(\bar{x} = 3) = 0{,}11$$

Comparando las probabilidades de los diferentes valores de $\bar{x}$, se puede ver que resulta más probable hallar una media de 4 que de 3,5 ó de 3; porque $P(\bar{x} = 4) = 0{,}33$ mientras que $P(\bar{x} = 3) = 0{,}11$. Se trata de un resultado importante, porque la media de la población es 4, por lo que vemos que es más probable encontrar una media muestral cerca de la media poblacional que lejos de ella.

La representación gráfica de la distribución también nos aporta información sobre la relación entre $\bar{x}$ y μ.

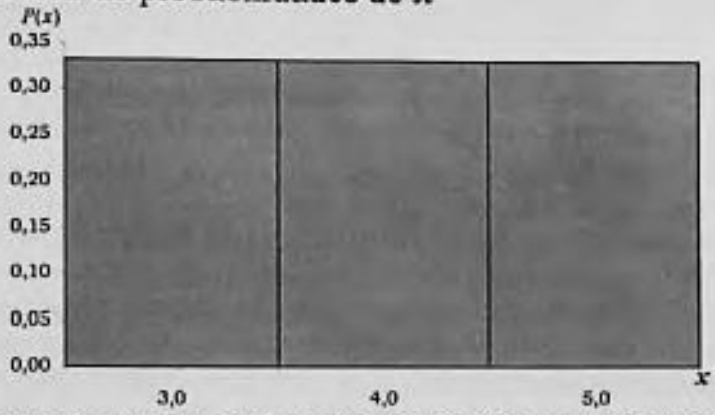
Gráfico 1: Distribución de probabilidades de $\bar{x}$



Se observa que $\bar{x}$ asume valores cuya distribución es simétrica alrededor de 4, que es la media poblacional (μ). Resulta interesante comparar esta distribución

on la que tiene la variable original, el número de meses de internación de cada aciente, x:

ráfico 2: Distribución de probabilidades de x



bservemos primero el nombre de los ejes: el Gráfico 1 muestra la distribución de as $\bar{x}$: el promedio de los tiempos de internación de muestras de dos pacientes. on nueve casos, cada uno es una muestra de tamaño 2. Sus valores están en el je horizontal y sus probabilidades se indican como $P(\bar{x})$ en el eje vertical.
l Gráfico 2, representa los valores de x: los tiempos de internación de cada aciente individualmente. Son tres casos, cada uno es un paciente. Esos son los alores que se ubican en el eje horizontal, las probabilidades del eje vertical son (x).
a del Gráfico 2 es la distribución en la población, en este caso es uniforme, pero odría tener cualquier otra forma. Por el contrario, la del Gráfico 1 es la istribución de las medias muestrales; es simétrica y va a tender a tener esta orma a medida que las muestras sean de mayor tamaño, independientemente de uál sea la distribución que la variable tenga en la población. Luego volveremos obre esta importante observación.

amos ahora a describir esta nueva variable $\bar{x}$, a través de su esperanza y su arianza.
alculemos primero la esperanza de $\bar{x}$, aunque, por la forma de la distribución, uede anticiparse:

$$E(\bar{x}) = 3 * 0{,}11 + 3{,}5 * 0{,}22 + 4 * 0{,}33 + 4{,}5 * 0{,}22 + 5 * 0{,}11 = 4$$

e verifica que el valor esperado para las medias muestrales coincide con la edia de la población. Este es el primer resultado que nos interesa retener de la elación entre $\bar{x}$ y μ; la expresamos como:

$$E(\bar{x}) = \mu$$

ue puede escribirse:

$$\mu_{\bar{x}} = \mu$$

sto implica que, si de una población se extraen todas las muestras posibles de un eterminado tamaño, y en cada una de ellas se calcula la media, el promedio de esas edias muestrales coincide con la media de la población completa. Esta cualidad egún la cual la esperanza del estimador es igual al parámetro, como ya hemos

dicho, se llama insesgabilidad. Cuando un estimador cumple con esa condición (como sucede con $\bar{x}$ como estimador de μ) se dice de él que es insesgado.

La media muestral ($\bar{x}$) es un estimador insesgado de la media poblacional (μ).

Ahora vamos a calcular la varianza de $\bar{x}$:

$$V(\bar{x}) = (3-4)^2 * 0{,}11 + (3{,}5-4)^2 * 0{,}22 + (4-4)^2 * 0{,}33 + (4{,}5-4)^2 * 0{,}22 + (5-4)^2 * 0{,}11 = 0{,}33$$

Este valor no es el mismo que el de σ^2, sino que es la mitad. Se trata nuevamente de un resultado que podemos generalizar y que depende del tamaño de la muestra. En el caso de este ejemplo, las muestras son de tamaño dos y por esa razón la varianza de la media muestral es la varianza poblacional dividida por dos. Si las muestras fuesen de tamaño 3, la varianza habría quedado reducida a la tercera parte. Para otro tamaño de muestra, la varianza de $\bar{x}$ será diferente. De modo general, la varianza de $\bar{x}$ se relaciona con la varianza de x (σ^2) a través de:

$$V(\bar{x}) = \frac{\sigma^2}{n}$$

De manera alternativa, indicamos a esta varianza como $\sigma_{\bar{x}}^2$, con lo que:

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n}$$

Esta fórmula indica que la varianza de las $\bar{x}$ varía inversamente con el tamaño de la muestra.
Este también es un resultado muy importante: nos dice que cuanto más grande sea la muestra, tanto más pequeña será la varianza de las medias muestrales. Recordemos que la varianza mide la dispersión de los valores de una variable, por lo que esta varianza mide la dispersión entre los valores de las diferentes medias muestrales. El hecho que disminuya cuando aumenta el tamaño de la muestra significa que para muestras más grandes, las medias muestrales tendrán menos dispersión, es decir que menos probables los valores muy elejados. Esta propiedad se denomina consistencia, entonces este resultado puede expresarse indicando que la media muestral es un estimador consistente de la media poblacional, porque su varianza se reduce a medida que aumenta el tamaño de la muestra.

La media muestral ($\bar{x}$) es un estimador consistente de la media poblacional (μ).

De la varianza surge inmediatamente la desviación estándar de $\bar{x}$ es:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}.$$

Es común referirse a ella como el **error estándar de la media**, y suele abreviarse, en los programas de análisis de datos como EE.
Este es el segundo resultado de importancia sobre la relación entre $\bar{x}$ y μ.

En la práctica, fuera de este ejemplo simplificado, solo extraemos una muestra y en ella calculamos la media. Lo que hemos visto hasta aquí nos dice que la media muestral que se obtenga tiene más chances de estar cerca de la media

poblacional cuanto más grande sea la muestra que tomemos. Esto es así porque a medida que aumenta el número de casos en la muestra (n) disminuye la varianza y en consecuencia las medias muestrales tienen más probabilidad de estar cerca de la media poblacional. Por eso, será más probable que la única media que se obtiene en la muestra sea próxima al parámetro que se estima. No es seguro que la media muestral sea cercana a la poblacional, lo que se sabe es que es menos probable que esté lejos cuando la muestra es más grande.

La tercera característica de la distribución de la media muestral se refiere a su forma. En el Gráfico 1 se ve que las $\bar{x}$ del ejemplo alcanzan una distribución unimodal y simétrica, sin importar que en la población la variable hubiese tenido una distribución uniforme. Este resultado también es general y es más amplio aun: a medida que aumenta el tamaño de las muestras, la distribución de las medias muestrales tiende a ser normal. La prueba de esta afirmación constituye el Teorema Central del Límite, cuyo enunciado puede resumirse como: una suma de n variables aleatorias tiende a tener distribución normal a medida que aumenta n, independientemente del modo en que esté distribuida esa variable. Para nuestro uso, la media es una suma de valores de una variable aleatoria (porque esos valores provienen de una muestra aleatoria) dividida en el total de casos. Por eso el teorema nos dice que si se trata de muestras grandes, puede tratarse a $\bar{x}$ como teniendo una distribución normal.
Anteriormente se presentó el experimento de tirar un dado dos veces, contar la suma de los puntos obtenidos y definir la variable aleatoria S que resulta de la suma de dos variables aleatorias, porque cada tirada del dado da lugar a un resultado entre 1 y 6 que depende del azar. La variable que resulta de tirar una sola vez el dado tiene distribución uniforme: todos los números tienen la misma probabilidad 1/6. La suma de puntos de los dos dados, S, ya no tiene distribución uniforme, porque es más probable obtener 7 (que puede resultar de 6+1, 5+2, 4+3, 3+4, 2+5 ó 1+6) que 12 (que solo puede obtenerse con 6+6).

Gráfico 3: Distribución de probabilidades de la variable x = *puntaje obtenido al tirar un dado*

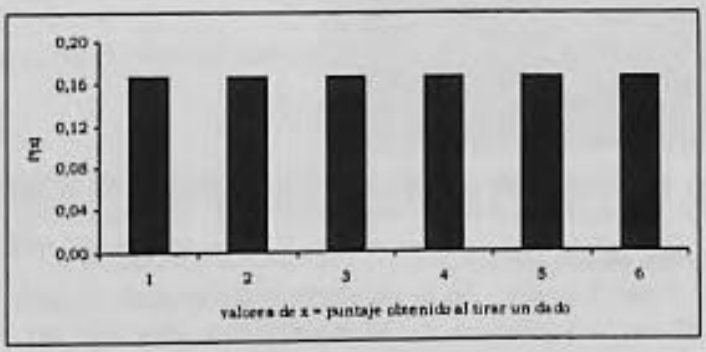


Gráfico 4: Distribución de probabilidades de *S = suma de puntajes obtenidos al tirar dos veces un dado*



Si bien la distribución de esta variable no es normal, se aprecia la tendencia, "va camino a ser normal". En este caso la muestra tiene solo dos casos (las dos tiradas del dado); cuando son más casos, la distribución va volviéndose más cercana a la normal.
Esto es lo que sucede cuando se extraen muestras de una población: la distribución de la variable en la población puede tener cualquier distribución (en el caso del dado es uniforme), pero a las medias muestrales les sucede lo mismo que a *S*, van tendiendo a tener una distribución normal a medida que se toman muestras de mayor tamaño. Éste es el tercer resultado que necesitamos para relacionar a la media muestral con la poblacional y poder hacer las primeras inferencias.

Resumimos en el recuadro siguiente los tres resultados mostrados hasta este punto.

$$E(\bar{x}) = \mu \qquad \mu_{\bar{x}} = \mu$$

$$V(\bar{x}) = \frac{\sigma^2}{n} \qquad \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

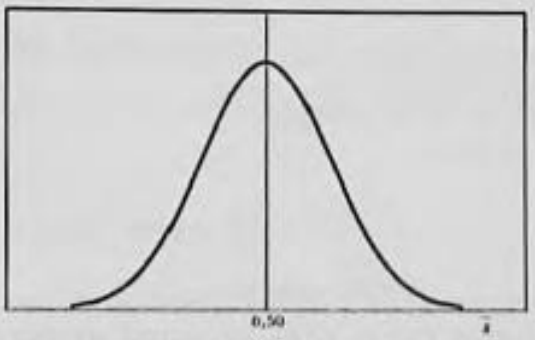
$$\bar{x} \to N\left(\mu, \frac{\sigma^2}{n}\right) \text{ cuando } n \to \infty$$

La última expresión sintetiza las anteriores y agrega que la distribución de $\bar{x}$ es normal.
Entonces, del recuadro se lee que:

- La esperanza de $\bar{x}$ es la media de la población (insesgabilidad).
- La varianza de $\bar{x}$ es la varianza de la población dividida en el tamaño de la muestra[72] (consistencia).
- La media muestral tiende a tener una distribución normal con media μ y varianza $\frac{\sigma^2}{n}$, cuando el tamaño de la muestra aumenta.

[72]De modo equivalente, la desviación estándar de la media es la desviación estándar de la población dividida en la raíz cuadrada del tamaño de la muestra. Es conocida también como error estándar de la media.

Ejemplo 8.2 (datos ficticios)
Supongamos que en la población de adultos la media de horas diarias de sueño es de 6,5 hs ($\mu = 6{,}5$) con varianza de 9 hs^2 ($\sigma^2 = 9$). Si eligiéramos al azar muestras de 200 personas (n=200) y registráramos el número promedio de horas de sueño en cada muestra, encontraríamos que la distribución de esas horas promedio sería como la siguiente:



En el eje horizontal están graficados los valores de las posibles $\bar{x}$ que resultarían si sacáramos muestras aleatorias de esa población. La distribución normal está centrada en 6,50, que es la media de la población. El gráfico muestra con claridad que "lo más probable" es encontrar a $\bar{x}$ en los alrededores de 6,50.
Con la media y la desviación estándar de esta variable $\bar{x}$ podemos calcular un puntaje z, lo que conocíamos como desvío estándar. Para llegar a la forma que tiene ahora z, recordemos que lo definimos como el número de desviaciones estándar a las que la variable se encuentra de la media, por eso era la diferencia entre el valor de la variable y el de la media, dividida en la desviación estándar:

$$z = \frac{x - \bar{x}}{s}$$

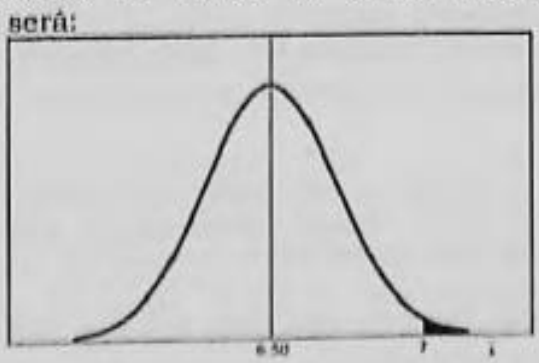
La diferencia ahora es que nuestra variable es $\bar{x}$, su media es μ y su desviación estándar es el que hemos llamado error estándar de la media: $\sigma_{\bar{x}}$. Con lo que el puntaje z asociado a cada valor de$\bar{x}$, tiene ahora la forma:

$$z = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}}$$

Si se reemplaza el error estándar de la media por su valor, se obtiene:

$$z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Si ahora nos preguntamos por la probabilidad de encontrar muestras de 200 personas cuyos promedios de horas de sueño superen las 7 horas, la representación gráfica será:



Y el valor de esa probabilidad se calcula observando a cuántas desviaciones estándar se encuentra de la media, es decir, calculando el puntaje z correspondiente a la media de 7 horas:

$$z = \frac{7 - 6{,}5}{\frac{3}{\sqrt{200}}} = \frac{0{,}5}{0{,}21} = 2{,}38$$

Pedimos a InfoStat® la probabilidad de superar este valor[73] *P(z>2,38)* y obtenemos 0,009. La lectura de este resultado es que solo el 0,9% de las muestras de tamaño 200 darán media muestral mayor a 7hs.
Para ver el efecto del tamaño de la muestra repitamos el cálculo con muestras de 30 casos[74]. El puntaje z es ahora:

$$z = \frac{7 - 6{,}5}{\frac{3}{\sqrt{30}}} = \frac{0{,}5}{0{,}55} = 0{,}91$$

Y *P(z>0,91)=0,181* es decir que el 18% de las muestras de tamaño 30 darán media que supere a 7hs. Esto indica que cuando las muestras son de mayor tamaño es menor la probabilidad de encontrar valores en los extremos de la distribución.

Supongamos que la variable *horas de sueño* tiene distribución normal en la población y calculemos la probabilidad de encontrar personas que duerman más de 7 horas. Antes destaquemos la diferencia entre esta pregunta y las dos anteriores: las probabilidades que calculamos antes son las de hallar *muestras* de 200 personas o de 30 personas con promedio superior a 7 horas de sueño, ahora preguntamos por la probabilidad de encontrar *individuos* que tengan más horas de sueño que esa cifra. El puntaje z es ahora:

$$z = \frac{7 - 6{,}5}{3} = \frac{0{,}5}{3} = 0{,}17$$

La fórmula cambia porque la pregunta no es por medias muestrales sino por valores individuales, por eso no hay n[75]. La probabilidad es ahora:

$$P(z > 0{,}17) = 0{,}432$$

Que leemos diciendo que el 43% de los individuos duerme 7 horas o más. Esto indica que es mucho más probable encontrar individuos que se alejen de la media, que grupos de 30 ó de 200 individuos cuyo promedio se aleje de la media. Cuando las muestras son de mayor tamaño, tanto más improbable resulta encontrarlas lejos de la media, eso es lo que está expresado cuando n aparece en el denominador de la desviación estándar: mayor n implica menor dispersión, y de ello se sigue que son menos probables los casos extremos.

---

[73]Alternativamente podemos ingresar al calculador de InfoStat® con la media 6,5 y la desviación estándar 0,14 y obtener el mismo resultado sin pasar por z. Hicimos este recorrido porque necesitamos estar familiarizados con el puntaje z para los contenidos que veremos más adelante.

[74]Es el mínimo tamaño que podemos usar para que sea válida la aplicación de la distribución normal

[75]Aunque puede interpretarse como si los individuos constituyeran muestras de tamaño 1.

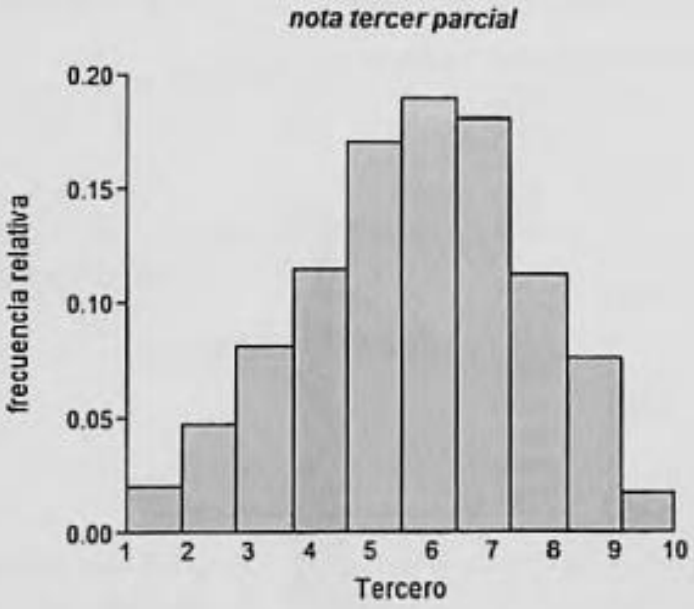
Ejemplo 8.3 (datos reales)
Ahora trabajaremos sobre una base que contiene las notas de los tres parciales de Psicoestadística en 2009. En primer lugar damos una breve descripción de la población de las notas del tercer parcial:

Variable	n	Media	Var(n)	Min	Máx
Tercero	1149	5.78	4.12	1.00	10.00

Estas medidas están calculadas sobre la población completa, que es el total que alumnos que en 2009 hizo el tercer parcial, por lo que se trata de parámetros, así:

$$\mu = 5.78$$
$$\sigma^2 = 4.12$$

El histograma de las notas del tercer parcial es:



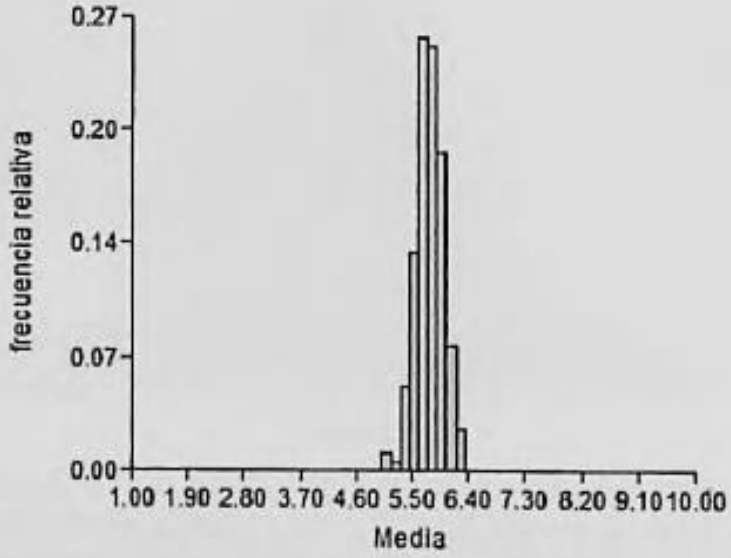
Ahora solicitamos a Infostat® que obtenga 200 muestras de 80 casos cada una y que en cada una de ellas calcule la media y la varianza muestral. No pedimos "todas las muestras posibles" ya que serían un número muy elevado, por eso, lo que tendremos será una aproximación a la relación entre estimadores y parámetros. Esa solicitud da lugar a una nueva tabla que contiene una media muestral y una varianza muestral para cada una de las 200 muestras calculadas. Cuando solicitamos un resumen de estas variables obtenemos:

Variable	n	Media	Var(n)	Mín	Máx
Media	200	5.78	0.05	5.01	6.35
Varianza	200	4.12	0.28	2.89	5.69

Observemos en detalle la salida: n=200 es la cantidad de muestras que se extrajeron (y no el tamaño de cada muestra), ahora cada muestra representa un caso y las variables que se consideran son la media y la varianza de la nota de los

80 casos seleccionados en cada muestra. Se aprecia que el campo de variación de la variable original (nota del tercer parcial) iba de 1 a 10, mientras que la nueva variable (promedio de notas del tercer parcial de muestras de 80 alumnos) varia entre 5.01 y 6.35, es decir, es notablemente más restringido, tiene menos variabilidad.
El valor 5.78 es la media de todas las medias muestrales y como vemos coincide con la media poblacional. Del mismo modo, la media de todas las varianzas muestrales (4.12) coincide con la varianza poblacional. Eso quiere decir que la media y la varianza muestrales, son estimadores insesgados de la media y la varianza poblacionales.
Además, la salida muestra la varianza de las medias muestrales, que es 0.05. La relación de esta varianza con la varianza poblacional es: $\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n}$, en la que n representa el tamaño de las muestras y no la cantidad de muestras solicitadas. Con los datos del tercer parcial es: $\sigma_{\bar{x}}^2 = \frac{4.12}{80} = 0.05$

El histograma de las medias muestrales es:



En el que hemos usado al misma escala de 1 a 10 para que se vea con claridad la reducción en la dispersión de esta nueva variable.

Distribución de la proporción muestral

El razonamiento para llegar a la relación que hay entre el estimador $\hat{p}$ y el parámetro correspondiente, P es completamente análogo al de la media, por lo que no recorreremos nuevamente los mismos pasos que llevaron a establecer la relación entre $\bar{x}$ y μ.

En primer lugar, y como sucede en el caso de la media, $\hat{p}$ es un estimador insesgado de P.

La proporción muestral $\hat{p}$ es un estimador **insesgado** de la proporción poblacional P.

Si extrajéramos todas las muestras posibles de una población y calculáramos en cada una la proporción de casos en una categoría de una variable, el promedio de todas esas proporciones muestrales, daría como resultado la proporción de casos que hay en esa categoría en la población. Por lo que podemos escribir que:

$$E(\hat{p}) = P$$

O de manera equivalente:

$$\mu_{\hat{p}} = P$$

Acerca de la dispersión que alcanzan las diferentes $\hat{p}$ en las muestras, hay más diferencia con la media. En efecto, cuando se trata con variables cualitativas (nominales u ordinales) no hay distancias y en consecuencia no se puede usar una desviación estándar. La dispersión de una variable de este nivel se aprecia a través de la idea de incertidumbre: habrá tanto menos dispersión cuanto mayor sea la concentración de casos en una categoría de la variable. Así, la distribución:

candidato que votará	f
A	0,09
B	0,74
C	0,11
D	0,06
Total	1,00

Tiene menos dispersión que:

candidato que votará	f
A	0,23
B	0,31
C	0,26
D	0,20
Total	1,00

Porque si tuviéramos que "adivinar" quién va a ganar las elecciones, en el primer caso estaríamos más seguros de inclinarnos por el candidato B, que en el segundo. Aunque en ambas distribuciones el modo es el candidato B, en la primera la concentración es mayor y menor es la incertidumbre, por lo que tenemos mayor certeza, menos dispersión.

Así es como se trata el problema de la variabilidad en variables que no admiten la medición de distancias. Pero en este caso, se está calculando $\hat{p}$ como la proporción de una categoría, sin considerar cómo se distribuyen las otras, es decir que se trabaja con variables dicotómicas. Si se considera solo al candidato A, las dos tablas anteriores se reducen a:

candidato que votará	f
A	0,09
otro candidato	0,91
Total	1,00

candidato que votará	f
A	0,23
otro candidato	0,77
Total	1,00

¿Cuál de las dos distribuciones tiene mayor dispersión? La primera tiene una mayor concentración en la categoría "otro candidato" que la segunda, por lo que tiene menor dispersión. Por eso, en variables dicotómicas, la mayor diferencia entre las dos proporciones indica la mayor concentración y por ello, la menor dispersión.
La forma operativa de evaluar esto es multiplicando las dos frecuencias relativas: 0,09*0,91 en el primer caso, y 0,23*0,77 en el segundo. Esos productos dan 0,08 y 0,18 respectivamente; estos valores son indicadores de la menor dispersión de la primera distribución.
La operación de multiplicar a la proporción de casos de una categoría por la de la otra, que se escribe como P*(1-P), es la medida de la dispersión en variables nominales, que reemplaza a la varianza de las variables cuantitativas. Como sucedió con la media, la varianza de la proporción muestral es la varianza dividida el tamaño de la muestra:

$$V(\hat{p}) = \frac{P * (1 - P)}{n}$$

Como antes, muestras de mayor tamaño dan lugar a menor variabilidad. También puede expresarse la varianza de $\hat{p}$ como $\sigma^2_{\hat{p}}$, con lo que:

$$\sigma^2_{\hat{p}} = \frac{P * (1 - P)}{n}$$

La desviación estándar de $\hat{p}$ será:

$$\sigma_{\hat{p}} = \sqrt{\frac{P * (1 - P)}{n}}$$

Esta expresión también se conoce como **error estándar de la proporción**.

Los dos últimos resultados (la esperanza y la varianza de $\hat{p}$) se derivan de la distribución que rige el experimento de extraer n observaciones y contar la cantidad de casos que allí aparecen: se trata de la distribución binomial. Como vimos, si $\hat{x}$ es la cantidad de casos en la categoría de interés en la muestra, entonces:

$$\hat{p} = \frac{\hat{x}}{n}$$

Y, en consecuencia:

$$\hat{x} = n * \hat{p}$$

En el modelo binomial, la esperanza y la varianza de x (cantidad de casos en la categoría de interés) son:

$$E(\hat{x}) = n * P \quad [1]$$

$$V(\hat{x}) = n * P * (1 - P) \quad [2]$$

Remplazando x por su relación con $\hat{p}$ y usando las propiedades de la esperanza y la varianza hallamos:

Para la esperanza de $\hat{p}$ en [1]:

$$E(n * \hat{p}) = n * P$$

$$n * E(\hat{p}) = n * P$$

$$E(\hat{p}) = P$$

Esta última igualdad muestra que, efectivamente $\hat{p}$ es un estimador insesgado de P.

Para la varianza de $\hat{p}$, reemplazamos en [2]:

$$V(n * \hat{p}) = n * P * (1 - P)$$
$$n^2 * V(\hat{p}) = n * P * (1 - P)$$
$$V(\hat{p}) = \frac{P * (1 - P)}{n}$$

Y vemos que $\hat{p}$ es un estimador consistente de P, porque a medida que aumenta el tamaño de la muestra, disminuye su varianza.

Para calcular la probabilidad de diferentes valores de $\hat{p}$, a partir de P y de un determinado tamaño de muestra, usamos la distribución binomial, en la que cambiamos la variable x (número de casos en la categoría de interés) por $\hat{p}$ (proporción de casos en esa categoría). Así, volviendo al último ejemplo que se vio en la distribución binomial, si en la población de alumnos de Psicología la proporción de mujeres es de 0,81; allí se preguntó por la probabilidad que fueran todas mujeres o bien, que $x = 15$ ahora puede plantearse en términos de proporciones: ¿Cuál es la probabilidad que, en una muestra de 15 alumnos, el 100% sean mujeres? Aquí:

$$P = 0{,}81$$
$$n = 15$$
$$\hat{p} = 1$$

Usando el valor de $\hat{p}$ y de n, calculamos x:

$$x = n * \hat{p} = 15 * 1 = 15$$

Esto quiere decir que pedir que la proporción muestral ($\hat{p}$) sea 1 (100%) equivale a pedir 15 éxitos (mujeres) en la muestra, por lo que la probabilidad es:

$$P(\hat{p} = 1) = B(15; 15; 0{,}81) = 0{,}0424$$

Es el mismo resultado obtenido antes, ahora ubicado en el contexto del muestreo.

Si la pregunta fuera ¿Cuál es la probabilidad que, si en la población la proporción es 0,81; en una muestra de 15 observaciones ésta sea 0,40? Respondemos del mismo modo, primero calculamos x:

$$x = n * \hat{p} = 15 * 0{,}40 = 6$$

Ahora la probabilidad es:

$$P(\hat{p} = 0{,}40) = B(6; 15; 0{,}81) = 0{,}000456$$

De manera general, expresada en base a n, $\hat{p}$ y P, la probabilidad es:

$$P(\hat{p}) = B(n * \hat{p}; n; P)$$

Es posible, y se hace a menudo, aproximar estas probabilidades binomiales a través de un modelo normal. El fundamento de esta aproximación es el teorema de Laplace - De Moivre que dice que si x es una variable con distribución binomial, con esperanza $n*P$ y varianza $n*P*(1-P)$, entonces, cuando n tiende a infinito, la distribución de x tiende a ser normal, con la misma media (esperanza) y varianza. Esto solo es válido[76] cuando n es grande y P no está muy cerca de 0 ó de 1. La condición se solicita de manera sencilla exigiendo que $n*P$ y $n*(1-P)$ sean ambas mayores o iguales a 5. Si la variable sobre la que trabajamos no es x sino $n * \hat{p}$, entonces la esperanza y la varianza serán:

$$E(\hat{p}) = P \qquad \text{y} \qquad V(\hat{p}) = \frac{P*(1-P)}{n}.$$

Si la condición de $n*p$ y $n*(1-P)$ mayores o iguales a 5 se cumple, puede usarse esta aproximación y obtener un resultado análogo al de la media, que se resume así:

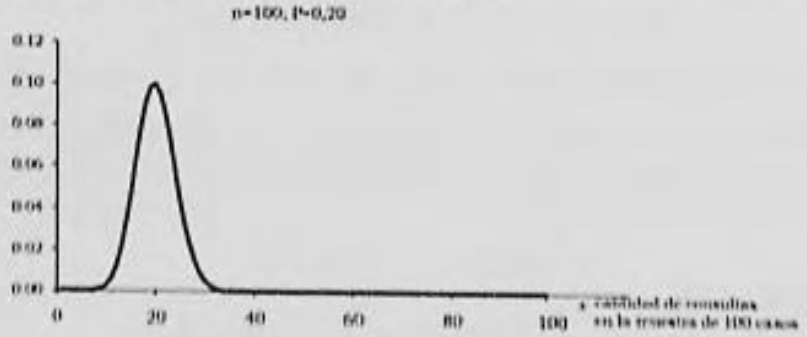
$$E(\hat{p}) = P \qquad \mu_{\hat{p}} = P$$

$$V(\hat{p}) = \frac{P(1-P)}{n} \qquad \sigma_{\hat{p}} = \sqrt{\frac{P(1-P)}{n}}$$

$$\hat{p} \to N\left(P, \frac{P(1-P)}{n}\right)$$

Cuando $n \to \infty$ y tanto $n*P$ como $n*(1-P)$ son mayores a 5

Sea el ejemplo de la proporción de personas que consultaron a un centro de salud durante el año pasado. Supongamos que, para una población determinada, esa proporción sea del 20% (P=0,20). Si extraemos muestras de tamaño 100 y en cada una de ellas observamos la proporción de personas que consultaron a ese centro de salud durante el año pasado, el gráfico de la distribución binomial de la cantidad de consultantes en cada muestra será:



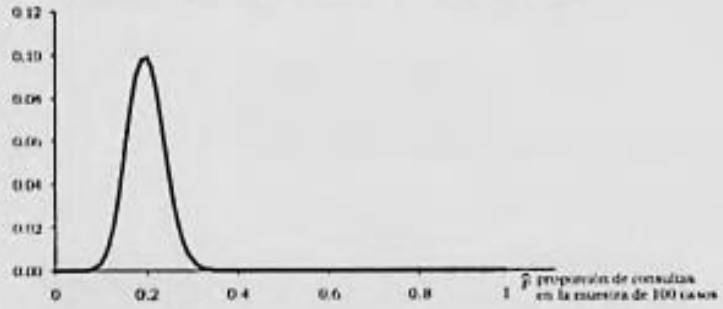
[76] Alvarado y Batanero sf., indican que "Respecto al valor de n requerido para una correcta aproximación de la distribución binomial, los textos no siempre están de acuerdo." En algunos textos se solicita que n>30, pero la calidad de la aproximación depende también de P.

Este gráfico tiene un trazado continuo aunque se trata de una variable discreta. Eso se debe a que es un gran número de observaciones y la distancia entre ellas es pequeña. Cuantas más sean las observaciones, tanto más cercana a la continuidad será la sucesión de puntos.

El gráfico muestra las probabilidades asociadas a cada cantidad $\hat{x}$ de éxitos que pueden resultar en la muestra, y cada valor de $\hat{x}$ se corresponde con un valor de $\hat{p}$ a través de:

$$\hat{p} = \frac{\hat{x}}{n}$$

Por lo que el gráfico anterior puede tratarse a escala de $\hat{p}$



Si nos interesamos por la probabilidad de obtener una proporción de 0,25 ó superior en la muestra, debemos transformarla a una cantidad de éxitos muestrales:

$$\hat{x} = n * \hat{p} = 100 * 0{,}25 = 25$$

Entonces:

$$P(\hat{p} \geq 0{,}25) = P(\hat{x} \geq 25) = B(\hat{x} \geq 25;\ 100; 0{,}20)$$

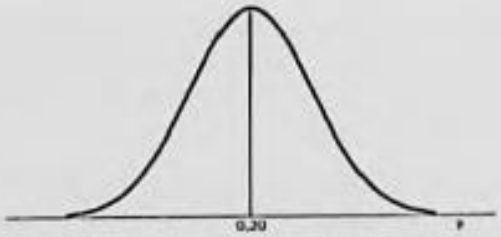
Usando InfoStat®, encontramos[77]:

$$B(\hat{x} \geq 25; 100; 0{,}20) = 0{,}1314$$

Interpretamos este resultado diciendo que, si en la población completa, la proporción de personas que consultan es del 20%, la probabilidad que en una muestra de 100 personas, hayan consultado el 25% ó más es de 0,1314. En otros términos, el 13% de las muestras de tamaño 100 que se extraigan de esa población, mostrarán una proporción de 0,25 ó mayor.

Dado que el número de casos en la muestra es elevado (100) y que $n*P$ es 20 y $n*(1-P)$ es 80, ambos mayores a 5, podemos usar la aproximación normal. Según esa aproximación, la distribución de los diferentes valores de $\hat{p}$ es:

[77]Dado que nos interesa la probabilidad de igualar o superar a 25, sumamos la probabilidad de $\hat{x} = 25$ (que es 0,0439) y la de $\hat{x} > 25$ (que es 0,0875) y obtenemos el resultado que se indica.



El eje horizontal de este gráfico representa todas las proporciones que pueden encontrarse en las diferentes muestras. La distribución está centrada en el parámetro $P = 0{,}20$.

Resolveremos la pregunta anterior transformando el valor $\hat{p} \geq 0{,}25$ en un puntaje z. Conocemos la media y la varianza de $\hat{p}$ por lo que haremos:

$$z = \frac{\hat{p} - P}{\sigma_{\hat{p}}}$$

Reemplazando por el error estándar de $\hat{p}$, tenemos:

$$z = \frac{\hat{p} - P}{\sqrt{\frac{P(1-P)}{n}}}$$

Esta es la expresión con la que transformamos los valores de $\hat{p}$ a puntajes z. Sin embargo es necesario hacer una corrección debido a que vamos a aproximar una distribución discreta (binomial) a través de una continua (normal)[78], por lo que la expresión toma la forma:

$$z = \frac{\left(\hat{p} - \frac{1}{2 \cdot n}\right) - P}{\sqrt{\frac{P \cdot (1-P)}{n}}} = \frac{\left(0{,}25 - \frac{1}{200}\right) - 0{,}20}{\sqrt{\frac{0{,}20 \cdot (1-0{,}20)}{100}}} = 1{,}125$$

$$P(\hat{p} \geq 0{,}25) = P(z \geq 1{,}125)$$

En InfoStat® hallamos que:

$$P(z > 1{,}125) = 0{,}1303$$

Cuando usamos la distribución binomial encontramos una probabilidad de 0,1314; por lo que ésta última es una buena aproximación.

---

[78] La distribución binomial tiene como variable discreta a $\hat{x}$, la cantidad de éxitos en la muestra, si nos interesa la probabilidad de los valores mayores o iguales a un $\hat{x}$ dado, debemos tener en cuenta que al pasar a la normal, como es continua, no se pueden calcular probabilidades de valores exactos. Así, el conjunto $\hat{x} \geq 3$, debe transformarse en $\hat{x} > 2{,}5$; dado que la probabilidad de $\hat{x} = 3$ es cero cuando la tratamos como variable continua. De manera análoga, si buscáramos $P(\hat{x} \leq 3)$, deberemos tratarlo como $P(\hat{x} < 3{,}5)$. La corrección consiste entonces en tomar media unidad menos cuando calculamos probabilidades de valores mayores o iguales a uno dado, y media unidad más si se trata de la probabilidad de un valor menor o igual. Veamos el efecto que tiene esta corrección sobre $\hat{p}$. Dado que $\hat{p} = \frac{\hat{x}}{n}$, cuando corregimos el número de éxitos en media unidad por debajo, nos queda $\frac{\hat{x}-0{,}5}{n} = \frac{\hat{x}}{n} - \frac{0{,}5}{n} = \hat{p} - \frac{1}{2 \cdot n}$. Cuando la corrección exija que se tome media unidad más, la corrección será $\hat{p} + \frac{1}{2 \cdot n}$.

A partir de los resultados encontrados en este capítulo podremos hacer estimaciones de la media y la proporción poblacionales a partir de los respectivos valores muestrales. Hemos visto entonces que el carácter aleatorio de las muestras hace que las estimaciones sean inciertas, pero que, debido a que conocemos la distribución de probabilidades de los estimadores podemos establecer qué valores de ellos son más probables, así podremos hacer el camino inverso, que es el que más nos interesa: el de alcanzar a los parámetros a partir de los estimadores.

Usando la distribución normal como aproximación a la binomial, entonces, para los dos estimadores que hemos mencionado en este capítulo se cumple la relación:

$$z = \frac{Es - Pa}{EEE}$$

En que resumimos:

Pa: el parámetro
Es: su estimador
EEE: el error estándar del estimador

Veremos en los próximos capítulos que esta expresión es válida para relacionar otros parámetros con sus correspondientes estimadores, mientras pueda usarse la distribución normal.

Con los contenidos vistos hasta este punto, en la expresión anterior, los componentes pueden ser:

Pa: μ ó P

Es: $\bar{x}$ ó $\hat{p}$

EEE: $\frac{\sigma}{\sqrt{n}}$ ó $\sqrt{\frac{P(1-P)}{n}}$

Muestras pequeñas

Las distribuciones de la media y la proporción muestral son asintóticamente modeladas por la distribución normal. Esto quiere decir que, a medida que el tamaño de las muestras crece, la distribución de estos estimadores va siendo más cercana a la curva del modelo normal. Sin embargo, cuando las muestras son pequeñas, se debe usar un modelo diferente. William Gosset (1908) desarrolló la distribución conocida como t de Student, que se adecua a describir la distribución de las medias muestrales cuando éstas provienen de muestras pequeñas. Expresado formalmente, si las muestras son pequeñas, entonces:

$$\frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

Tiene distribución t con $n-1$ grados de libertad. En el ejemplo anterior, si las muestras fueran de tamaño 15 en lugar de 200, se debe usar la distribución t. Así, la pregunta ¿cuál es la probabilidad que en muestras de tamaño 15, la media de horas de sueño supere las 7 horas?, se responde usando la distribución t con 14 grados de libertad.

$$P(\bar{x} > 7) = P\left(t_{14} > \frac{7-6{,}5}{\frac{3}{\sqrt{15}}}\right) = P(t_{14} > 3.87) = 0{,}00084$$

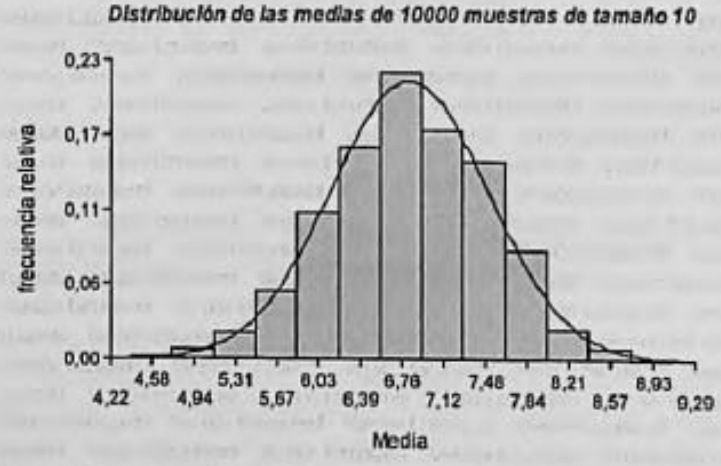
Cuando la muestra crece, la diferencia entre los modelos normal y t, se reduce. Si se repite la operación del ejemplo 8.2, resulta que:

$$P(t_{199} > 2{,}38) = 0{,}009$$

Que es, hasta el tercer decimal, igual al que ofrece la distribución normal. A esto se refiere la idea que la distribución t converge a la normal: cuando las muestras son grandes, la distribución t da resultados muy parecidos a los de la normal. El criterio usual para decidir si corresponde usar una distribución t o una normal es de 30 casos. Sin embargo, a fin de ahorrar recursos, los programas estadísticos usan siempre la distribución t.

Distribución de la varianza

La media y la proporción muestrales tienen distribuciones simétricas (normal o t); por el contrario, la varianza muestral se distribuye de manera asimétrica, lo que puede ilustrarse con el ejemplo 8.3. Si se solicitan 10000 muestras de tamaño 10, el siguiente es el histograma de las 10000 medias muestrales, con una curva normal superpuesta, para mostrar la calidad del ajuste:



Puede verse que el modelo normal "copia" muy adecuadamente la distribución real de las medias muestrales. Si se hace lo mismo con las varianzas muestrales, se obtiene:



Que muestra la asimetría de la distribución de las varianzas. Para este caso, el modelo adecuado es χ^2. La relación entre la varianza muestral y la poblacional es:

$$\frac{(n-1)*s^2}{\sigma^2} \sim \chi^2_{n-1}$$

Que quiere decir que, dada una población con una determinada varianza σ^2, si se extraen todas las muestras posibles de un tamaño dado y en cada una de ellas se calcula la varianza muestral s^2, la expresión de arriba se distribuye con un modelo ji cuadrado con *n-1* grados de libertad.

El muestreo desde dos poblaciones, se utiliza para realizar comparaciones, entre medias, entre proporciones o entre varianzas, extrayendo una muestra de cada población, los tamaños de esas muestras se denominan n_1 y n_2. Las medias y las proporciones se comparan por medio de la diferencia, mientras que con las varianzas, la comparación se hace por medio del cociente. Así, para comparar las medias de dos poblaciones, el parámetro es $\mu_1 - \mu_2$ y su estimador $\bar{x}_1 - \bar{x}_2$. Si se compara la proporción entre dos poblaciones, el parámetro es la diferencia de proporciones poblacionales: $P_1 - P_2$ y su estimador, la diferencia de proporciones muestrales: $\hat{p}_1 - \hat{p}_2$. Ambos estimadores (diferencia de medias y diferencia de proporciones) tienen distribución normal, o bien, en el caso de la media, distribución t, si se trata de muestras pequeñas.

Distribución del cociente de varianzas

Para comparar varianzas, el parámetro es el cociente de las varianzas poblacionales $\frac{\sigma_1^2}{\sigma_2^2}$ y el estimador el cociente de las varianzas muestrales $\frac{s_1^2}{s_2^2}$. La relación entre estimador y parámetro es:

$$\frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}} \sim F_{n_1-1,n_2-1}$$

Que indica que ese cociente es modelado por una distribución F con $n_1 - 1$ grados de libertad en el numerador y $n_2 - 1$ grados de libertad en el denominador.

Resumen de la relación entre estimadores y parámetros

Parámetro	Estimador	Estandarización del estimador	Distribución
Media: μ	$\bar{x}$	$\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}}$	$N(\mu,\sigma^2)$
Media: μ (muestras pequeñas)	$\bar{x}$	$\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}}$	t_{n-1}
Número de éxitos en la población X	$\hat{x}$		$B(x,n.p)$
Proporción de casos en una categoría: P (muestras grandes)	$\hat{p}$	$\frac{\hat{p}-P}{\sigma_{\hat{p}}}$	$N(P,\frac{P*(1-P)}{n})$
Varianza: σ^2	s^2	$\frac{(n-1)*s^2}{\sigma^2}$	χ^2_{n-1}
Cociente de varianzas: $\frac{\sigma_1^2}{\sigma_2^2}$	$\frac{s_1^2}{s_2^2}$	$\frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}}$	F_{n_1-1,n_2-1}