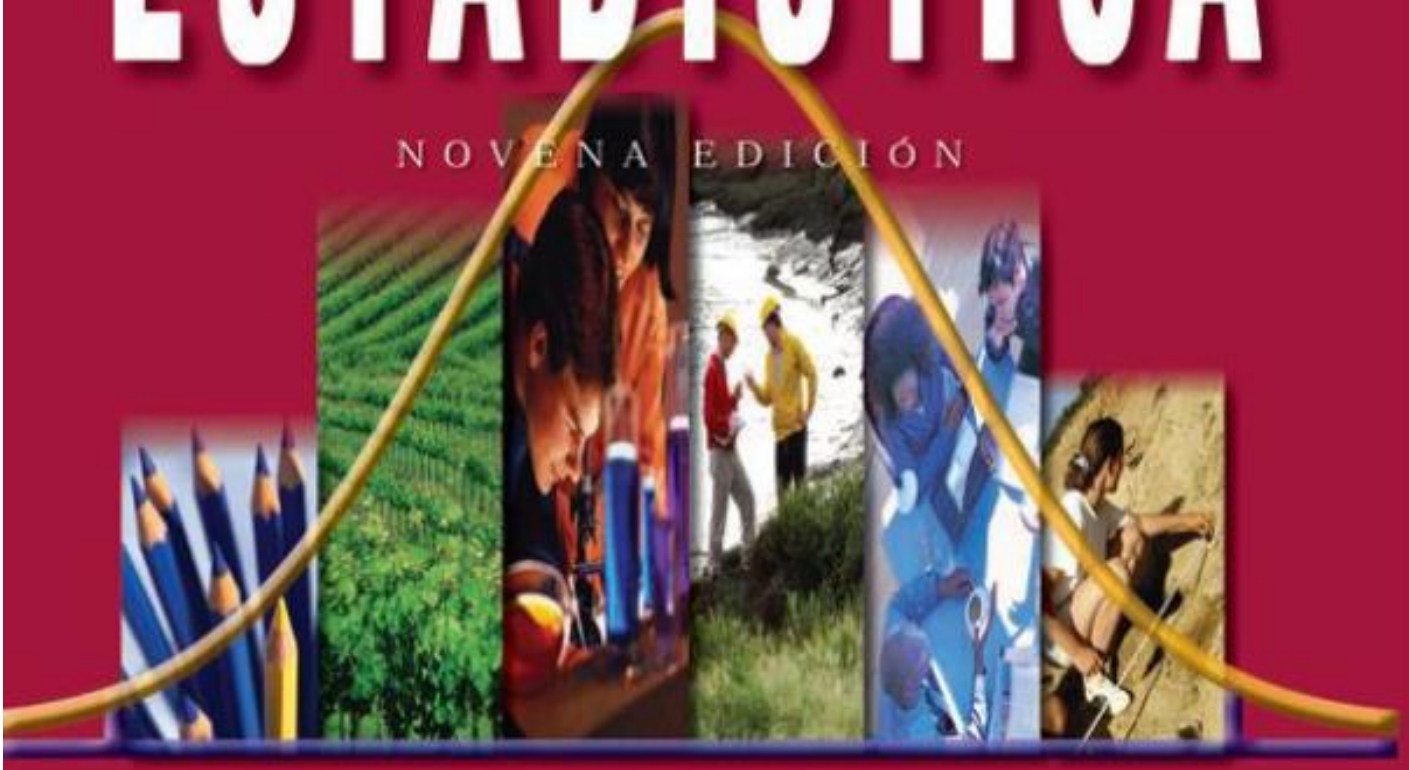
ESTADÍSTICA

NOVENA EDICIÓN



MARIO F. TRIOLA

PEARSON
Addison Wesley

INCLUYE CD-ROM

11



Análisis de varianza

11-1 Panorama general

11-2 ANOVA de un factor

11-3 ANOVA de dos factores

PROBLEMA DEL CAPÍTULO

Clancy, Rowling y Tolstoi: ¿Hay diferencias en el nivel de lectura?

El conjunto de datos 14 del Apéndice B incluye valores que se obtuvieron de 12 páginas seleccionadas aleatoriamente de cada uno de los tres libros siguientes: *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling; y *La guerra y la paz*, de León Tolstoi. Se obtuvo la puntuación de la facilidad de lectura de Flesch para cada una de estas páginas y los resultados se presentan en el conjunto de datos 14. En el sistema de puntuación de facilidad de lectura de Flesch, las puntuaciones más altas de un texto implican una mayor facilidad de lectura. Las puntuaciones más bajas corresponden a textos que son difíciles de leer.

Con la intención de explorar datos para investigar el centro, la variación, la distribución, los datos distantes y los patrones de cambio a través del tiempo (CVDDT), obtendremos los estadísticos muestrales que se incluyen en la tabla 11-1. Además, los histogramas de los tres conjuntos de datos sugieren que las muestras provienen de poblaciones con distribuciones que son aproximadamente normales. Al investigar datos distantes, los únicos candidatos son la puntuación más baja de Clancy, que está a 2.37 desviaciones estándar por debajo de la media, y la puntuación más baja de Rowling, que está a 2.10 desviaciones estándar por debajo de la media. Si se juzgan en el contexto de las demás puntuaciones, dichos valores no parecen estar muy lejos del resto, por lo que asumiremos que no hay datos distantes. Si deseamos ser muy cuidadosos, analizaremos los datos con y sin esos dos valores que se incluyen para ver si la conclusión final es afectada. (De hecho, los resultados no se ven afectados de forma importante por estos valores). Puesto que los libros nunca cambiarán, el patrón de cambio a través del tiempo no es relevante aquí.

Cuando pensamos en una comparación de la facilidad de lectura de los libros de Tom Clancy, J. K. Rowling y León Tolstoi, esperaríamos que el libro de Rowling fuese el de lectura más fácil, porque fue escrito para niños. También que el libro de Tolstoi fuese el más difícil, ya que es una traducción de un clásico ruso. Ahora observe las puntuaciones medias de facilidad de lectura y vea que parecen sustentar dichas expectativas, puesto que el libro de Rowling tiene la puntuación de facilidad de lectura más alta y el de Tolstoi la más baja. ¿Pero concluiríamos realmente que las medias son diferentes? He aquí un tema importante que abordaremos en este capítulo: ¿proporcionan los datos muestrales de las puntuaciones de facilidad de lectura de Flesch, del conjunto de datos 14, evidencia suficiente que sustente la aseveración de que los libros de Clancy, Rowling y Tolstoi tienen diferentes medias?

Tabla 11-1 Puntuaciones de facilidad de lectura de los tres libros

	Puntuación de facilidad de lectura de Flesch		
	Clancy	Rowling	Tolstoi
n	12	12	12
$\bar{x}$	70.73	80.75	66.15
s	11.33	4.68	7.86

11-1 Panorama general

En lugar de "Análisis de varianza", un mejor título para este capítulo sería "Prueba de igualdad de tres o más medias poblacionales". Aun cuando no es muy práctico, el último título describe mejor el objetivo del presente capítulo. Deseamos introducir un procedimiento para probar hipótesis que establecen que tres o más medias poblacionales son iguales, de manera que una hipótesis nula típica sería H_0: $\mu_1 = \mu_2 = \mu_3$, en tanto que la hipótesis alternativa sería la afirmación de que al menos una media es diferente de las otras. En la sección 8-3 presentamos procedimientos para probar la hipótesis de que *dos* medias poblacionales son iguales, pero los métodos de esa sección no pueden aplicarse cuando se incluyen tres o más medias. En lugar de referirnos al objetivo principal de probar medias iguales, el término *análisis de varianza* se refiere al *método* que empleamos, el cual se basa en un análisis de varianzas muestrales.

Definición

El **análisis de varianza (ANOVA)** es un método de prueba de igualdad de tres o más medias poblacionales, por medio del análisis de las varianzas muestrales.

El ANOVA se utiliza en aplicaciones tales como las siguientes:

- Si tratamos un grupo con dos tabletas de aspirina diariamente, un segundo grupo con una tableta de aspirina diariamente y un tercer grupo con un placebo diariamente, es posible hacer una prueba para determinar si hay evidencia suficiente para sustentar la aseveración de que los tres grupos cuentan con distintos niveles medios de presión sanguínea.
- Se asevera que los supermercados colocan los cereales con alto contenido de azúcar en estantes que están a la altura de los ojos de los niños, de manera que eso nos permite probar la aseveración de que los cereales en los estantes tienen el mismo contenido de azúcar.

¿Por qué no probar sencillamente dos muestras al mismo tiempo? ¿Por qué necesitamos un nuevo procedimiento, cuando la igualdad de dos medias se demuestra utilizando los métodos que se presentan en el capítulo 8? Por ejemplo, si deseamos utilizar los datos muestrales de la tabla 11-1, para probar la aseveración de que las tres poblaciones tienen la misma media, ¿por qué no simplemente tomamos dos a la vez y probamos H_0: $\mu_1 = \mu_2$, luego H_0: $\mu_2 = \mu_3$; entonces, H_0: $\mu_1 = \mu_3$? Este método (probar dos a la vez) requiere de tres pruebas de hipótesis diferentes, de forma que el grado de confianza sería tan bajo como 0.95^3 (o 0.857). En general, conforme incrementamos el número de pruebas de significancia individuales, incrementamos la posibilidad de obtener una diferencia únicamente por el azar (en lugar de una diferencia real en las medias). El riesgo de cometer un error tipo I (es decir, de encontrar una diferencia en uno de los pares cuando en realidad tal diferencia no existe) es demasiado alto. El método del análisis de varianza nos sirve para evitar este problema en particular (rechazar una hipótesis nula verdadera), si utilizamos una prueba de igualdad de varias medias.

Distribución *F*

Los métodos del ANOVA de este capítulo requieren de la distribución F, que se explicó en la sección 8-5. En esta sección señalamos que la distribución F tiene las siguientes propiedades importantes (véase la figura 11-1):

1. La distribución F es no simétrica; se sesga hacia la derecha.
2. Los valores de F pueden ser 0 o positivos, pero no negativos.
3. Hay una distribución F diferente para cada par de grados de libertad para el numerador y el denominador.

Los valores críticos de F se localizan en la tabla A-5.

El análisis de varianza (ANOVA) se basa en una comparación de dos estimados diferentes de la varianza común de las distintas poblaciones. Estos estimados (la *varianza entre muestras* y la *varianza dentro de las muestras*) se describirán en la sección 11-2. El término *un factor* se utiliza porque los datos muestrales se separan en grupos según una característica o un factor. Por ejemplo, las puntuaciones de facilidad de lectura, que se resumen en la tabla 11-1, se separaron en tres grupos diferentes, de acuerdo con la característica (o el factor) del autor (Clancy, Rowling, Tolstoi). En la sección 11-3 estudiaremos el análisis de varianza de dos factores, el cual nos permite comparar poblaciones separadas en categorías por medio de dos características (o factores). Por ejemplo, separaríamos la estatura de las personas utilizando los siguientes dos factores: 1. género (hombre o mujer) y 2. mano dominante derecha o izquierda.

Estrategia de estudio sugerida: Puesto que los procedimientos que se emplean en este capítulo requieren de cálculos complicados, pondremos énfasis en el uso y la interpretación de programas de cómputo, tales como STATDISK, Minitab y Excel, o de una calculadora TI-83 Plus. Sugerimos que inicie la sección 11-2 enfocándose en el siguiente concepto clave: estamos utilizando un procedimiento para probar la aseveración de que tres o más medias son iguales. A pesar de que los detalles de los cálculos se complican, nuestro procedimiento será fácil porque se basa en un valor P. Si el valor P es pequeño, como 0.05 o menor, se rechaza la igualdad de las medias. De otra manera, no se rechaza la igualdad de las medias.

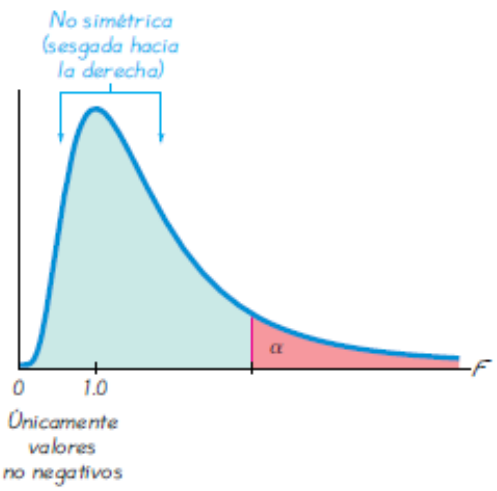


FIGURA 11-1
Distribución *F*
Existe una distribución *F* distinta para cada par de grados de libertad diferente para el numerador y el denominador.

Después de comprender este procedimiento básico y sencillo, proceda a la comprensión de los fundamentos subyacentes.

11-2 ANOVA de un factor

En esta sección consideramos las pruebas de hipótesis de que tres o más medias poblacionales son iguales, como en H_0: $\mu_1 = \mu_2 = \mu_3$. Los cálculos se complican mucho, de manera que recomendamos el siguiente método:

1. Comprenda que un valor P pequeño (como 0.05 o menos) conduce al rechazo de la hipótesis nula de igualdad de medias. Con un valor P grande (como uno mayor que 0.05), no rechace la hipótesis nula de igualdad de medias.
2. Logre comprender el fundamento subyacente estudiando los ejemplos de esta sección.
3. Familiarícese con la naturaleza de los valores de la SC (suma de cuadrados) y los CM (cuadrados medios), así como con el papel que tienen en la determinación del estadístico de prueba F, pero utilice programas estadísticos de cómputo o una calculadora para obtener dichos valores.

El método que empleamos se denomina **análisis de varianza de un factor** (o **análisis de varianza de una entrada**) porque empleamos una sola propiedad o característica para categorizar las poblaciones. En ocasiones, a esta característica se le llama *tratamiento* o *factor*.

Definición

Tratamiento (o **factor**): es una propiedad o característica que nos permite distinguir entre sí a las distintas poblaciones.

Por ejemplo, las puntuaciones de facilidad de lectura que se resumen en la tabla 11-1 se distinguen de acuerdo con el tratamiento (o factor) del autor (Clancy, Rowling, Tolstoi). Se utiliza el término *tratamiento* ya que las primeras aplicaciones del análisis de varianza implicaron experimentos de agricultura en los cuales distintas porciones de tierra se trataban con diferentes fertilizantes, tipos de semillas, insecticidas, etcétera. El siguiente recuadro incluye los supuestos requeridos y los procedimientos que utilizaremos.

Supuestos

1. Las poblaciones tienen distribuciones que son aproximadamente normales. (Este requisito no es demasiado estricto, ya que el método funciona bien, a menos que la población tenga una distribución muy diferente de la normal. Si una población tiene una distribución muy diferente a la normal, utilice la prueba de Kruskal-Wallis, descrita en la sección 12-5).
2. Las poblaciones tienen la misma varianza σ^2 (o desviación estándar σ). (Este requisito no es demasiado estricto, ya que el método funciona bien, a menos que las varianzas poblacionales difieran en grandes cantidades. El estadístico de la

Universidad de Wisconsin, George E. P. Box demostró que, siempre y cuando los tamaños muestrales sean iguales [o casi iguales], las varianzas llegan a diferir de tal forma que la más grande es nueve veces el tamaño de la más pequeña, en tanto que los resultados del ANOVA seguirán siendo esencialmente confiables).

3. Las muestras son aleatorias simples (es decir, muestras del mismo tamaño que tienen la misma probabilidad de ser elegidas).
4. Las muestras son independientes entre sí. (Las muestras no están aparejadas ni asociadas de ninguna forma).
5. Las diferentes muestras provienen de poblaciones que se categorizaron de una sola forma. (De ahí el nombre del método: análisis de varianza de *un factor*).

Procedimiento de prueba de H_0: $\mu_1 = \mu_2 = \mu_3 = \ldots$

1. **Utilice STATDISK, Minitab, Excel o una calculadora TI-83 Plus para obtener los resultados.**
2. **Identifique el valor P en los resultados.**
3. **Plantee una conclusión con base en estos criterios:**
   - **Si el valor $P \leq \alpha$, rechace la hipótesis nula de medias iguales y concluya que al menos una de las medias poblacionales es diferente de las otras.**
   - **Si el valor $P > \alpha$, no rechace la hipótesis nula de medias iguales.**

Tenga cuidado al interpretar los resultados: Cuando concluimos que hay suficiente evidencia para rechazar la aseveración de medias poblacionales iguales, no podemos concluir a partir del ANOVA que cualquier media en particular es distinta de las demás. (Existen otras pruebas que permiten identificar las medias específicas, que son diferentes. Dichas pruebas se conocen como procedimientos de comparación múltiple. La comparación de intervalos de confianza, la prueba de Scheffé, la prueba de Tukey extendida y la prueba de Bonferroni son procedimientos de comparación múltiple comunes).

EJEMPLO Facilidad de lectura de Clancy, Rowling y Tolstoi A partir de las puntuaciones de facilidad de lectura que se resumen en la tabla 11-1, y con un nivel de significancia de $\alpha = 0.05$, utilice STATDISK, Minitab, Excel o una calculadora TI-83 Plus para probar la aseveración de que las tres muestras provienen de poblaciones con medias que no son iguales.

SOLUCIÓN La hipótesis nula es H_0: $\mu_1 = \mu_2 = \mu_3$, en tanto que la hipótesis alternativa es la aseveración de que al menos una de las medias es diferente de las otras.

Paso 1: Al final de esta sección describiremos procedimientos específicos para obtener resultados por computadora o calculadora, ahora consideraremos los resultados que se despliegan en la página siguiente.

Paso 2: Todas las pantallas de resultados muestran que el valor P es 0.000562 o 0.001 redondeado.

Paso 3: Puesto que el valor P es menor que el nivel de significancia de $\alpha = 0.05$, rechazamos la hipótesis nula de igualdad de medias.

continúa



Resistencia a las encuestas

Las encuestas que se basan en muestras relativamente pequeñas pueden ser bastante precisas, siempre y cuando la muestra sea aleatoria o representativa de la población. Sin embargo, el incremento en las tasas de rechazo a las encuestas está haciendo que sea más difícil obtener muestras aleatorias. La organización Council of American Survey Research reportó que, en un año reciente, el 38% de los consumidores se rehusaron a responder encuestas. El director de una compañía de investigación de mercado dijo que "las personas tienen temor de ser seleccionadas y les preocupa que las generalizaciones se realicen con base únicamente en aquellos que cooperan". Los resultados de la industria encargada de hacer investigación de mercados, multimillonaria en dólares, afectan los productos que compramos, los programas de televisión que vemos y muchas otras facetas de nuestras vidas.

STATDISK

Equal Length Samples	
Total Num Values	36
Upper Deg Free	2
Lower Deg Free	33
SS(treatment)	1338.0
SS(error)	2331.4
SS(total)	3669.4
MS(treatment)	669.00
MS(error)	70.648
MS(total)	104.84
Test Statistic, F	9.4695
Critical F	3.2849
P-Value	0.000562

Reject the Null Hypothesis

Data provides evidence that the sample means are unequal

TI-83 Plus

```
One-way ANOVA
 F=9.469487401
 p=5.6213335E-4
 Factor
  df=2
  SS=1338.00222
↓ MS=669.001111
```

```
One-way ANOVA
↑ MS=669.001111
 Error
  df=33
  SS=2331.38667
  MS=70.6480808
 Sxp=8.40524127
```

Excel

Anova: Single Factor

SUMMARY

Groups	Count	Sum	Average	Variance
Column 1	12	848.8	70.73333333	128.2006061
Column 2	12	969	80.75	21.91545455
Column 3	12	799.8	66.65	61.74818182

ANOVA

Source of Variation	SS	df	MS	F	P-value	F crit
Between Groups	1338.002222	2	669.0011111	**9.469487401**	**0.000562133**	3.284924333
Within Groups	2331.386667	33	70.64808081			
Total	3669.388889	35				

Minitab

```
Analysis of Variance
Source     DF       SS        MS        F        P
Factor      2   1338.0     669.0     9.47    0.001
Error      33   2331.4      70.6
Total      35   3669.4
```

INTERPRETACIÓN Hay evidencia suficiente para sustentar la aseveración de que las tres medias poblacionales no son iguales. Con base en páginas que se seleccionaron al azar de las obras *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi, concluimos que estos libros tienen niveles de facilidad de lectura diferentes. Con base en la prueba ANOVA, no concluimos que alguna media en particular sea distinta de las otras.

Fundamentos

El método de análisis de varianza se basa en el siguiente concepto fundamental: bajo el supuesto de que las poblaciones tienen la misma varianza σ^2, estimamos el valor común de σ^2 por medio de dos métodos diferentes. El estadístico de prueba F es la proporción de dichos estimados, de forma que un estadístico de prueba F significativamente *grande* (que se ubica a la extrema derecha de la gráfica de distribución F) constituye evidencia en contra de que las medias poblacionales son iguales. La figura 11-2 muestra la relación entre el estadístico de prueba F y el valor P.

Los dos métodos para estimar el valor común de σ^2 son los siguientes:

1. La **varianza entre muestras** (también se le llama **variación debida al tratamiento**) es un estimado de la varianza poblacional común σ^2, que se basa en la variación entre las *medias* muestrales.
2. La **varianza dentro de las muestras** (también se le llama **variación debida al error**) es un estimado de la varianza poblacional común σ^2, que se basa en las *varianzas* muestrales.

Estadístico de prueba del ANOVA de un factor

$$F = \frac{\text{varianza entre las muestras}}{\text{varianza dentro de las muestras}}$$

El numerador del estadístico de prueba F mide la variación entre medias muestrales. El estimado de la varianza en el denominador depende únicamente de las varianzas muestrales y no se afecta por las diferencias entre las medias muestrales. Como consecuencia, las medias muestrales con valores cercanos dan como

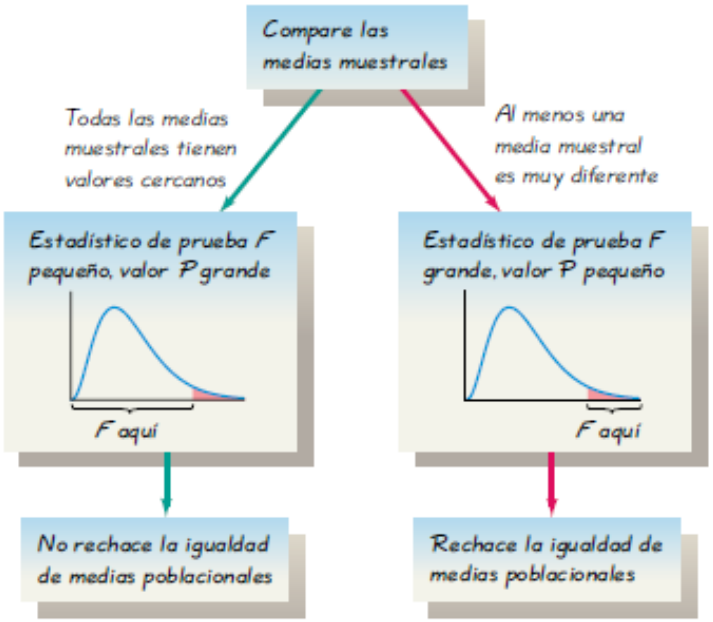


FIGURA 11-2 Relación entre el estadístico de prueba F y el valor P

resultado un estadístico de prueba F pequeño y concluimos que no existen diferencias significativas entre las medias muestrales. Pero si el valor de F es excesivamente *grande*, entonces rechazamos la aseveración de igualdad de medias. (Los términos vagos "pequeño" y "excesivamente grande" se vuelven objetivos por medio del valor P correspondiente, que indica si el estadístico de prueba F está o no en la región crítica). Puesto que valores excesivamente grandes de F reflejan medias desiguales, la prueba es de cola derecha.

Cálculos con tamaños muestrales *n* iguales

Remítase al conjunto de datos A en la tabla 11-2. Si todos los conjuntos de datos tienen el mismo tamaño de muestra (como en $n = 4$ para el conjunto de datos A de la tabla 11-2), los cálculos que se requieren no son muy difíciles. Primero, calcule la varianza entre muestras al evaluar $ns_{\bar{x}}^2$, donde $s_{\bar{x}}^2$ es la varianza de las medias muestrales y n es el tamaño de cada una de las muestras. Es decir, considere las medias muestrales como un conjunto ordinario de valores y calcule la varianza. (A partir del teorema de límite central, en $\sigma_{\bar{x}} = \sigma/\sqrt{n}$ se despeja σ para obtener $\sigma = \sqrt{n} \cdot \sigma_{\bar{x}}$, de forma que estimamos σ^2 con $ns_{\bar{x}}^2$). Por ejemplo, las medias

Tabla 11-2 Efecto de una media sobre el estadístico de prueba F

	A			añadir 10	B	
	Muestra 1	Muestra 2	Muestra 3		Muestra 1	Muestra 2	Muestra 3
	7	6	4		17	6	4
	3	5	7		13	5	7
	6	5	6		16	5	6
	6	8	7		16	8	7
	$n_1 = 4$	$n_2 = 4$	$n_3 = 4$		$n_1 = 4$	$n_2 = 4$	$n_3 = 4$
	$\bar{x}_1 = 5.5$	$\bar{x}_2 = 6.0$	$\bar{x}_3 = 6.0$		$\bar{x}_1 = 15.5$	$\bar{x}_2 = 6.0$	$\bar{x}_3 = 6.0$
	$s_1^2 = 3.0$	$s_2^2 = 2.0$	$s_3^2 = 2.0$		$s_1^2 = 3.0$	$s_2^2 = 2.0$	$s_3^2 = 2.0$
Varianza entre muestras	$ns_{\bar{x}}^2 = 4\ (0.0833) = 0.3332$				$ns_{\bar{x}}^2 = 4\ (30.0833) = 120.3332$		
Varianza dentro de muestras	$s_p^2 = \frac{3.0 + 2.0 + 2.0}{3} = 2.3333$				$s_p^2 = \frac{3.0 + 2.0 + 2.0}{3} = 2.3333$		
Estadístico de prueba F	$F = \frac{ns_{\bar{x}}^2}{s_p^2} = \frac{0.3332}{2.3333} = 0.1428$				$F = \frac{ns_{\bar{x}}^2}{s_p^2} = \frac{120.3332}{2.3333} = 51.5721$		
Valor P (obtenido con Excel)	Valor $P = 0.8688$				Valor $P = 0.0000118$		

muestrales del conjunto de datos A de la tabla 11-2 son 5.5, 6.0 y 6.0. Estos tres valores tienen una varianza de $s_{\bar{x}}^2 = 0.0833$, de forma que la

$$\text{varianza entre las muestras} = ns_{\bar{x}}^2 = 4(0.0833) = 0.3332$$

A continuación, estime la varianza dentro de las muestras, calculando s_p^2, que es la varianza que se agrupa que se obtiene al calcular la media de las varianzas muestrales. Las varianzas muestrales en la tabla 11-2 son 3.0, 2.0 y 2.0, de forma que

$$\text{varianza dentro de las muestras} = s_p^2 = \frac{3.0 + 2.0 + 2.0}{3} = 2.3333$$

Finalmente, evalúe el estadístico de prueba F de la siguiente manera:

$$F = \frac{\text{varianza entre muestras}}{\text{varianza dentro de muestras}} = \frac{ns_{\bar{x}}^2}{s_p^2} = \frac{0.3332}{2.3333} = 0.1428$$

El valor crítico de F se calcula suponiendo una prueba de cola derecha, ya que los valores grandes de F corresponden a diferencias significativas entre medias. Con k muestras, cada una con n valores, el número de grados de libertad se obtiene de la siguiente manera.

Grados de libertad:
(k = número de muestras y n = tamaño de la muestra)

$$\text{numerador de grados de libertad} = k - 1$$
$$\text{denominador de grados de libertad} = k(n - 1)$$

Para el conjunto de datos A de la tabla 11-2, $k = 3$ y $n = 4$, entonces los grados de libertad son 2 para el numerador y $3(4 - 1) = 9$ para el denominador. Con $\alpha = 0.05$, 2 grados de libertad para el numerador y nueve grados de libertad para el denominador, el valor crítico F de la tabla A-5 es 4.2565. Si utilizáramos el método tradicional de prueba de hipótesis con el conjunto de datos A de la tabla 11-2, veríamos que esta prueba de cola derecha tiene un estadístico de prueba $F = 0.1428$ y un valor crítico de $F = 4.2565$, de manera que el estadístico de prueba no se encuentra en la región crítica; por lo tanto, no rechazamos la hipótesis nula de igualdad de medias.

Para ver realmente cómo funciona el estadístico de prueba F, considere ambos conjuntos de datos muestrales de la tabla 11-2. Observe que las tres muestras de la parte A son idénticas a las tres muestras de la parte B, excepto que en la parte B añadimos 10 a cada valor de la muestra 1 de la parte A. Las tres medias muestrales de la parte A son muy cercanas, pero hay diferencias sustanciales en la parte B. Las tres varianzas muestrales de la parte A son idénticas a las de la parte B.

La suma de 10 a cada dato de la primera muestra de la tabla 11-2 produce un efecto importante en el estadístico de prueba, ya que F cambia de 0.1428 a 51.5721. La suma de 10 a cada dato de la primera muestra también surte un efecto drástico en el valor P, que cambia de 0.8688 (no significativo) a 0.0000118 (significativo).

Observe que la varianza entre muestras en la parte A es 0.3332, pero en la parte B es 120.3332 (lo que indica que las medias muestrales en la parte B se separan más). También note que las varianzas dentro de las muestras son de 2.3333 en ambas partes, puesto que la varianza dentro de una muestra no se afecta cuando sumamos una constante a cada valor muestral. *El cambio en el estadístico F y el valor P es atribuible únicamente a los cambios en* $\bar{x}_1$. Lo anterior ilustra que el estadístico de prueba F es muy sensible a las *medias* muestrales, aun cuando se obtiene a través de dos estimados distintos de la *varianza* poblacional común.

He aquí el punto clave de la tabla 11-2: los conjuntos de datos A y B son idénticos, excepto que en el conjunto de datos B se añadió 10 a cada valor de la primera muestra. La suma de 10 a cada valor de la primera muestra provoca que las tres medias muestrales se aparten más, con el resultado de que el estadístico de prueba F se incrementa y el valor P disminuye.

Cálculos con tamaños muestrales desiguales

Mientras que los cálculos que se requieren para los casos con tamaños muestrales iguales son razonables, las cosas se complican bastante cuando los tamaños muestrales son desiguales. Se aplica el mismo razonamiento básico, porque calculamos un estadístico de prueba F, que es el cociente de dos estimados diferentes de la varianza poblacional común σ^2, pero esos estimados implican medidas *ponderadas* que toman en cuenta los tamaños muestrales, tal como se muestra a continuación.

$$F = \frac{\text{varianza entre muestras}}{\text{varianza dentro de muestras}} = \frac{\left[\dfrac{\Sigma n_i(\bar{x}_i - \bar{\bar{x}})^2}{k-1}\right]}{\left[\dfrac{\Sigma(n_i-1)s_i^2}{\Sigma(n_i-1)}\right]}$$

donde $\bar{\bar{x}}$ = media de todos los valores muestrales que se combinan

k = número de medias poblacionales que se comparan

n_i = número de valores en la i-ésima muestra

$\bar{x}_i$ = media de los valores en la i-ésima muestra

s_i^2 = varianza de los valores en la i-ésima muestra

El factor de n_i se incluye, de manera que las muestras más grandes llevan más peso. El denominador del estadístico de prueba es sencillamente la media de las varianzas muestrales, pero se trata de una media ponderada cuyos pesos se basan en los tamaños muestrales.

Ya que el cálculo de este estadístico de prueba a veces conduce a grandes errores de redondeo, los diferentes programas estadísticos de cómputo suelen emplear una expresión distinta (pero equivalente) que implica la notación de la SC (suma de cuadrados) y los CM (cuadrados medios). A pesar de que la siguiente notación y los componentes son complicados y tediosos, la idea básica es la misma: el estadístico de prueba F es un cociente con un numerador que refleja la variación *entre* las medias de las muestras, en tanto que un denominador refleja la variación *dentro* de las muestras. Si las poblaciones tienen medias iguales, el cociente F tiende a ser pequeño; pero si las medias poblacionales no son iguales, el cociente F tiende a ser significativamente grande. A continuación se describen los componentes más importantes del método ANOVA.

La **SC (total)** o suma de cuadrados total, es una medida de la variación total (alrededor de $\bar{x}$) en todos los datos muestrales que se combinan.

Fórmula 11-1 $\quad SC(\text{total}) = \Sigma(x - \bar{x})^2$

La SC(total) se puede separar en los componentes de la SC (tratamiento) y la SC (error), descritas a continuación.

La **SC (del tratamiento)**, también llamada SC (del factor), SC (entre grupos) o SC (entre muestras), es una medida de la variación *entre* las medias muestrales.

Fórmula 11-2

$$\begin{aligned} SC(\text{tratamiento}) &= n_1(\bar{x}_1 - \bar{\bar{x}})^2 + n_2(\bar{x}_2 - \bar{\bar{x}})^2 + \cdots + n_k(\bar{x}_k - \bar{\bar{x}})^2 \\ &= \Sigma n_i(\bar{x}_i - \bar{\bar{x}})^2 \end{aligned}$$

Si las medias poblacionales ($\mu_1, \mu_2, \ldots, \mu_k$) son iguales, entonces todas las medias muestrales $\bar{x}_1, \bar{x}_2 \ldots, \bar{x}_k$ tenderán a acercarse entre sí y también a acercarse a $\bar{\bar{x}}$. El resultado será un valor de SC (tratamiento) relativamente pequeño. Sin embargo, si las medias poblacionales no son todas iguales, entonces al menos una de $\bar{x}_1, \bar{x}_2, \ldots, \bar{x}_k$ tenderá a estar lejos de las demás y también de $\bar{\bar{x}}$. El resultado será un valor relativamente grande de SC (tratamiento).

La **SC (error)**, también conocida como SC (dentro de grupos) o SC (dentro de muestras), es una suma de cuadrados que representa la variación que se supone común a todas las poblaciones que se consideran.

Fórmula 11-3

$$\begin{aligned} SC(\text{error}) &= (n_1 - 1)s_1^2 + (n_2 - 1)s_2^2 + \cdots + (n_k - 1)s_k^2 \\ &= \Sigma(n_i - 1)s_i^2 \end{aligned}$$

Dadas las expresiones anteriores para SC (total), SC (tratamiento) y SC (error), siempre deben mantenerse las siguientes relaciones.

Fórmula 11-4 SC (total) = SC (tratamiento) + SC (error)

SC (tratamiento) y SC (error) son ambas sumas de cuadrados, por lo que si dividimos cada una de ellas entre su número correspondiente de grados de libertad, obtendremos los cuadrados *medios*. Algunas de las siguientes expresiones, para los cuadrados medios, incluyen la notación N:

N = número total de valores en todas las muestras que se combinan

CM (tratamiento) es un cuadrado medio de tratamiento, que se obtiene como sigue:

Fórmula 11-5 $$\text{CM(tratamiento)} = \frac{\text{SC(tratamiento)}}{k - 1}$$

CM (del error) es un cuadrado medio del error, que se obtiene como sigue:

Fórmula 11-6 $$\text{CM(error)} = \frac{\text{SC(error)}}{N - k}$$

CM (total) es un cuadrado medio de la variación total, que se obtiene como sigue:

Fórmula 11-7 $$\text{CM(total)} = \frac{\text{SC(total)}}{N - 1}$$

Estadístico de prueba para ANOVA con tamaños muestrales desiguales

Al probar la hipótesis nula H_0: $\mu_1 = \mu_2 = \ldots = \mu_k$ en contra de la hipótesis alternativa, de que todas estas medias no son iguales, el estadístico de prueba

Fórmula 11-8 $$F = \frac{\text{CM(tratamiento)}}{\text{CM(error)}}$$

tiene una distribución F (cuando la hipótesis nula H_0 es verdadera) con grados de libertad dados por

$$\text{grados de libertad del numerador} = k - 1$$
$$\text{grados de libertad del denominador} = N - k$$

Este estadístico de prueba es esencialmente el mismo que se introdujo antes y su interpretación también es igual a la ya descrita. El denominador sólo depende de las varianzas muestrales que miden la variación dentro de los tratamientos y no se afecta por las diferencias entre las medias muestrales. En contraste, el numerador se afecta por las diferencias entre las medias muestrales. Si las diferencias entre las medias muestrales son extremas, causarán que el numerador sea excesivamente grande, por lo que F también será excesivamente grande. Como consecuencia, los valores muy grandes de F sugieren medias desiguales; por lo tanto, la prueba ANOVA es de cola derecha.

Las tablas implican un formato conveniente para resumir los resultados más importantes en los cálculos del ANOVA, en tanto que la tabla 11-3 tiene un formato que suele utilizarse en el despliegue de resultados de las computadoras. (Véanse los resultados anteriores de Minitab y Excel). Las cifras de la tabla 11-3 resultan de los datos de facilidad de lectura de la tabla 11-1.

Tabla 11-3 Tabla de ANOVA para los datos de facilidad de lectura

Fuente de variación	Suma de cuadrados (SC)	Grados de libertad	Cuadrado medio (CM)	Estadístico de prueba F
Tratamientos	1338.00	2	669.000	9.4695
Error	2331.39	33	70.648	
Total	3669.39	35		

Diseño del experimento: Cuando utilizamos un análisis de varianza de un factor (o de una entrada) y concluimos que las diferencias entre las medias son significativas, no estaremos completamente seguros de que el factor dado es el responsable de las diferencias. Es posible que la variación de algún otro factor desconocido sea el responsable. Una manera de reducir el efecto de factores extraños es diseñar el experimento de forma que sea un **diseño completamente aleatorizado**, en el cual se da a cada elemento la misma posibilidad de pertenecer a las diferentes categorías o tratamientos. Por ejemplo, podría asignar sujetos a un grupo de tratamiento, a un grupo placebo y a un grupo control por medio de un proceso de selección aleatoria equivalente a sacar papeles de un tazón. Otra manera de reducir el efecto de factores extraños es el uso de un **diseño rigurosamente controlado**, en el cual los elementos se eligen cuidadosamente de manera que el resto de los factores no tengan variabilidad. Por ejemplo, tratar a una niña saludable de siete años de edad de Texas, mientras que le da un placebo a otra niña saludable de siete años de edad de Texas y coloca a una tercera niña saludable de siete años de edad de Texas en un grupo control que no recibe nada. Además de la salud, la edad, el género y el estado de residencia, identificaría otros factores relevantes que convendría tomar en cuenta. En general, los buenos resultados requieren que el experimento se diseñe y ejecute de manera cuidadosa.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **One-Way Analysis of Variance** y proceda a ingresar los datos muestrales. Haga clic en **Evaluate** al finalizar.

Minitab Primero ingrese los datos muestrales en las columnas C1, C2, C3, . . . Después, elija **Stat, ANOVA ONEWAY (UNSTACKED)** e introduzca C1, C2, C3, . . . , en el recuadro que se identifica como Responses (en columnas separadas).

Excel Primero introduzca los datos en las columnas A, B, C, . . . Después seleccione **Tools** de la barra del menú principal, luego **Data Analysis**, seguido por **ANOVA: Single Factor**. En el cuadro de diálogo, introduzca el rango que contiene los datos muestrales. (Por ejemplo, ingrese A1:C12 si el primer valor está en el renglón 1 de la columna A y el último dato se ubica en el renglón 12 de la columna C).

TI-83 Plus Primero introduzca los datos en listas en L1, L2, L3, . . . , después presione **STAT**, seleccione **TESTS** y elija la opción **ANOVA**. Ingrese las etiquetas de las columnas. Por ejemplo, si los datos están en las columnas L1, L2 y L3, ingrese esas columnas para obtener **ANOVA (L1, L2, L3)** y presione la tecla **ENTER**.

11-2 Destrezas y conceptos básicos

1. Facilidad de lectura de autores El problema del capítulo utiliza las puntuaciones de facilidad de lectura de Flesch para páginas que se seleccionaron aleatoriamente de libros de Tom Clancy, J. K. Rowling y León Tolstoi. Si en su lugar se utilizan las puntuaciones del nivel de lectura de Flesch-Kincaid (véase el conjunto de datos 14 del Apéndice B), los resultados del análisis de varianza, contenidos de Minitab, son los que se incluyen en la siguiente tabla. Suponga que deseamos utilizar un nivel de significancia de 0.05 para probar la hipótesis nula de que los tres autores tienen puntuaciones del nivel de lectura de Flesch-Kincaid con la misma media.

a. ¿Cuál es la hipótesis nula?
b. ¿Cuál es la hipótesis alternativa?
c. Identifique el valor del estadístico de prueba.
d. Calcule el valor crítico para un nivel de significancia de 0.05.
e. Identifique el valor *P*.
f. Con base en los resultados anteriores, ¿qué concluye acerca de la igualdad de las medias poblacionales?

Minitab

Analysis of Variance

Source	DF	SS	MS	F	P
Factor	2	68.19	34.09	8.98	0.001
Error	33	125.31	3.80		
Total	35	193.50			

2. Prueba de inflamabilidad de tela en diferentes laboratorios Se realizaron pruebas de inflamabilidad en ropa de dormir infantil. Se utilizó la prueba Vertical Semirestrained, en la que se incendiaron pedazos de tela en condiciones controladas. Una vez que se detuvo el incendio, se midió y registró la longitud de la porción quemada. Las mismas muestras de tela se probaron en cinco laboratorios diferentes. Abajo se presentan los resultados del análisis de varianza realizado con Excel.

a. ¿Cuál es la hipótesis nula?
b. ¿Cuál es la hipótesis alternativa?
c. Identifique el valor del estadístico de prueba.
d. Calcule el valor crítico para un nivel de significancia de 0.05.
e. Identifique el valor *P*.
f. ¿Existe evidencia suficiente para sustentar la aseveración de que las medias de los distintos laboratorios no son iguales?

Excel

Source of Variation	SS	df	MS	F	P-value	F crit
Between Groups	2.007194364	4	0.021798566	2.949330096	0.030936893	2.580034036
Within Groups	7.687597403	43	0.17892087			
Total	9.694791667	47				

3. Tiempos de maratón Una muestra aleatoria de hombres que completaron la carrera de maratón de Nueva York se divide en tres categorías, con las edades 21-29, 31-39 y 40 o más. Del conjunto de datos 8 del Apéndice B se obtienen los tiempos (en segundos). Los resultados del análisis de varianza, que se obtuvieron por medio de Excel se presentan a continuación.

a. ¿Cuál es la hipótesis nula?
b. ¿Cuál es la hipótesis alternativa?
c. Identifique el valor del estadístico de prueba.
d. Calcule el valor crítico para un nivel de significancia de 0.05.
e. Identifique el valor *P*.
f. ¿Existe evidencia suficiente para sustentar la aseveración de que los hombres de las distintas categorías tienen tiempos medios diferentes?

Excel

Source of Variation	*SS*	*df*	*MS*	*F*	*P-value*	*F crit*
Between Groups	3530063.284	2	1766031.642	0.188679406	0.828324293	3.080387501
Within Groups	1010875649	108	9359959.71			
Total	1014405712	110				

4. Presión sanguínea sistólica en distintos grupos de edad A una muestra aleatoria de 40 mujeres se le dividió en tres categorías con edades por debajo de 20, de 20 a 40 y mayores de 40. Los niveles de presión sanguínea sistólica se obtienen del conjunto de datos 1 del Apéndice B. Los resultados del análisis de varianza, que se obtuvieron por medio de Excel, se presentan a continuación.
a. ¿Cuál es la hipótesis nula?
b. ¿Cuál es la hipótesis alternativa?
c. Identifique el valor del estadístico de prueba.
d. Identifique el valor *P*.
e. ¿Hay evidencia suficiente para sustentar la aseveración de que las mujeres en las distintas categorías tienen niveles medios de presión sanguínea diferentes?

Minitab

Source	DF	SS	MS	F	P
Factor	2	938	469	1.65	0.205
Error	37	10484	283		
Total	39	11422			

En los ejercicios 5 y 6, utilice los datos muestrales que se listan relativos a experimentos de choques de automóviles, que realizó la National Transportation Safety Administration. Se adquirieron coches nuevos y se chocaron contra una barrera fija a 35 millas/hora; las mediciones se registraron con respecto al maniquí colocado en el asiento del conductor. Los automóviles subcompactos son el Ford Escort, Honda Civic, Hyundai Accent, Nissan Sentra y Saturn SL4. Los automóviles compactos son Chevrolet Cavalier, Dodge Neon, Mazda 626 DX, Pontiac Sunfire y Suburban Legacy. Los automóviles medianos son Chevrolet Camaro, Dodge Intrepid, Ford Mustang, Honda Accord y Volvo S70. Los automóviles grandes son Audi A8, Cadillac Deville, Ford Crown Victoria, Oldsmobile Aurora y Pontiac Bonneville.

T **5.** Traumatismo craneal en un choque de automóvil A continuación se presentan los datos de traumatismo craneal. Utilice un nivel de significancia de 0.05 para probar la hipótesis nula de que las diferentes categorías de peso tienen la misma media. ¿Sugieren los datos que los automóviles grandes son más seguros?

Subcompacto:	681	428	917	898	420
Compacto:	643	655	442	514	525
Mediano:	469	727	525	454	259
Grande:	384	656	602	687	360

T 6. Deceleración del pecho en un choque de automóvil A continuación se presentan datos de deceleración del pecho (g). Utilice un nivel de significancia de 0.05 para probar la hipótesis nula de que las distintas categorías de peso tienen la misma media. ¿Sugieren los datos que los automóviles más grandes son más seguros?

Subcompacto:	55	47	59	49	42
Compacto:	57	57	46	54	51
Mediano:	45	53	49	51	46
Grande:	44	45	39	58	44

T 7. Arqueología: anchura de cráneos de distintas épocas Los valores en la tabla corresponden a las anchuras máximas medidas de cráneos de hombres egipcios de distintas épocas (datos que se tomaron de *Ancient Races of the Thebaid*, de Thomson y Randall-Maciver). Los cambios en la forma de la cabeza a lo largo del tiempo sugieren que hubo mestizaje con poblaciones inmigrantes. Utilice un nivel de significancia de 0.05 para probar la aseveración de que las distintas épocas no tienen la misma media.

4000 a. C.	1850 a. C.	150 d. C.
131	129	128
138	134	138
125	136	136
129	137	139
132	137	141
135	129	142
132	136	137
134	138	145
138	134	137

T 8. Energía solar en diferentes climas Un alumno del autor vive en una casa con un sistema eléctrico solar. A la misma hora, cada día, reunió las lecturas de voltaje de un medidor que conectó al sistema, cuyos resultados se listan en la tabla adjunta. Utilice un nivel de significancia de 0.05 para probar la aseveración de que la lectura media de voltaje es la misma en los tres tipos distintos de días. ¿Hay evidencia suficiente para sustentar una aseveración de medias poblacionales diferentes? Esperaríamos que un sistema solar proporcione más energía eléctrica los días soleados que los días nublados o lluviosos. ¿Concluiríamos que los días soleados dan como resultado mayores cantidades de energía eléctrica?

Días soleados	Días nublados	Días lluviosos
13.5	12.7	12.1
13.0	12.5	12.2
13.2	12.6	12.3
13.9	12.7	11.9
13.8	13.0	11.6
14.0	13.0	12.2

T 9. Pesos medios de dulces M&M Remítase al conjunto de datos 19 del Apéndice B. Con un nivel de significancia de 0.05, pruebe la aseveración de que el peso medio de los dulces M&M es el mismo para cada una de las seis poblaciones de diferente color. Si la intención de Mars, Inc., es fabricar los dulces de modo que las poblaciones de diferente color tengan el mismo peso medio, ¿sugieren los resultados que la compañía enfrenta un problema que amerita corregirse?

T 10. Distancias de jonrones Remítase al conjunto de datos 30 del Apéndice B. Utilice un nivel de significancia de 0.05 para probar la aseveración de que los jonrones que anotaron Barry Bonds, Mark McGwire y Sammy Sosa tienen distancias medias que no son iguales. ¿Explican las distancias de los jonrones el hecho de que, hasta ahora, Barry Bonds conectó el mayor número de jonrones en una temporada, mientras que Mark McGwire posee el segundo número más grande de jonrones?

T **11.** Azúcar en el cereal Remítase al conjunto de datos 16 del Apéndice B y combine las cantidades de azúcar de los estantes 3 y 4, que son los dos más altos. Utilice un nivel de significancia de 0.05 para probar la hipótesis nula de que las cantidades medias de azúcar en los diferentes estantes son iguales. ¿Qué sugieren los resultados acerca de la creencia común de que los supermercados colocan los cereales con alto contenido de azúcar en estantes que están al nivel de los ojos de los niños?

T **12.** Tabaquismo pasivo en distintos grupos Remítase al conjunto de datos 6 del Apéndice B. Utilice un nivel de significancia de 0.05 para probar la aseveración de que el nivel medio de nicotina es diferente en los siguientes tres grupos: 1. individuos que no fuman y que no están expuestos al humo del tabaco; 2. personas que no fuman y que están expuestas al humo del tabaco, y 3. personas que fuman. ¿Qué sugieren los resultados acerca del tabaquismo pasivo?

11-2 Más allá de lo básico

13. Uso de la prueba *t* Se seleccionan al azar cinco muestras independientes, de 50 valores cada una, provenientes de poblaciones que se distribuyen normalmente con varianzas iguales. Deseamos probar la aseveración de que $\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$.

- **a.** Si utilizáramos únicamente los métodos que se presentan en la sección 8-3, probaríamos las aseveraciones individuales $\mu_2 = \mu_2$, $\mu_1 = \mu_3$, etcétera. ¿De cuántas formas distintas es posible hacer pares con las cinco medias?
- **b.** Suponga que para cada prueba de igualdad entre dos medias hay una probabilidad de 0.95 de no cometer un error tipo I. Si se prueba la igualdad de todos los pares posibles de medias, ¿cuál es la probabilidad de no cometer errores tipo I? (Aun cuando las pruebas no son independientes en realidad, suponga que sí lo son).
- **c.** Si utilizamos el análisis de varianza para probar la aseveración de que $\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$, con un nivel de significancia de 0.05, ¿cuál es la probabilidad de no cometer un error tipo I?
- **d.** Compare los resultados de los incisos *b* y *c*. ¿Cuál método es mejor porque nos ofrece una mayor oportunidad de no cometer un error tipo I?

14. Pruebas equivalentes En este ejercicio comprobará que cuando tiene dos conjuntos de datos muestrales, la prueba *t* para muestras independientes y el método ANOVA de esta sección son equivalentes. Remítase a las mediciones de facilidad de lectura de la tabla 11-1, pero utilice únicamente los datos de Clancy y Rowling. Los datos originales se encuentran en el conjunto de datos 14 del Apéndice B.

- **a.** Utilice un nivel de significancia de 0.05 y el método de la sección 8-3 para probar la aseveración de que las dos muestras provienen de poblaciones con la misma media. (Suponga que ambas poblaciones tienen la misma varianza).
- **b.** Utilice un nivel de significancia de 0.05 y el método ANOVA de esta sección para probar la aseveración que se planteó en el inciso *a*.
- **c.** Verifique que los cuadrados del estadístico de prueba *t* y el valor crítico del inciso *a* son iguales al estadístico de prueba *F* y el valor crítico del inciso *b*.

11-3 ANOVA de dos factores

En la sección 11-2 empleamos el análisis de varianza para decidir si tres o más poblaciones tienen la misma media. Esa sección utiliza procedimientos que se conocen como análisis de varianza de *un* factor (o análisis de varianza de una entrada), ya que los datos se categorizan en grupos de acuerdo con un *solo* factor (o tratamiento). Recuerde que un factor o tratamiento es una propiedad que es la

12



Estadística no paramétrica

12-1 Panorama general

12-2 Prueba del signo

12-3 Prueba de rangos con signo de Wilcoxon para datos apareados

12-4 Prueba de la suma de rangos de Wilcoxon para dos muestras independientes

12-5 Prueba de Kruskal-Wallis

12-6 Correlación de rangos

12-7 Prueba de rachas para detectar aleatoriedad

¿¡Llueve más durante los fines de semana!?

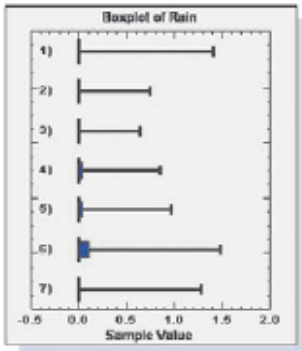
En un artículo para el Knight Ridder News Service, Usha Lee McFarling escribió que "sus peores temores por el clima son ciertos. Llueve más durante los fines de semana. Científicos que a través de muchos años reunieron gran cantidad de datos sobre la lluvia han descubierto un patrón claro y desalentador. Viernes, sábados y domingos son los días más lluviosos de la semana a todo lo largo de la costa este de Estados Unidos, desde Maine hasta Florida". La nota se refiere a un estudio que realizaron los científicos Randall S. Ceverny y Robert C. Balling de Arizona State University. Pero, ¿son correctas sus conclusiones? ¿Los datos se reportaron e interpretaron correctamente?

El conjunto de datos 11 del Apéndice B incluye cantidades de lluvia de un año reciente en Boston. Al seleccionar una ciudad para verificar el fenómeno de la lluvia durante el fin de semana, Boston debería ser una buena opción, puesto que se localiza en la costa este. Si utilizamos el STATDISK para calcular la cantidad de lluvia para cada día de la semana, obtendremos las gráficas de cuadro adjuntas. De la parte superior a la inferior, las gráficas de cuadro representan el lunes, el martes, . . . y el domingo. La gráfica de cuadro del lunes, en la parte superior, es peculiar, ya que parece estar desapareciendo del cuadro, pero las cantidades de lluvia del lunes tienen tantos ceros que el mínimo, el primer cuartil y la mediana son todos ceros, ocasionando que el cuadro se comprima hacia la izquierda. Mayores cantidades de lluvia en viernes, sábado y domingo serían visibles con las distribuciones situadas más a la derecha. ¿Es éste el caso en realidad? ¿Son realmente significativas tales diferencias?

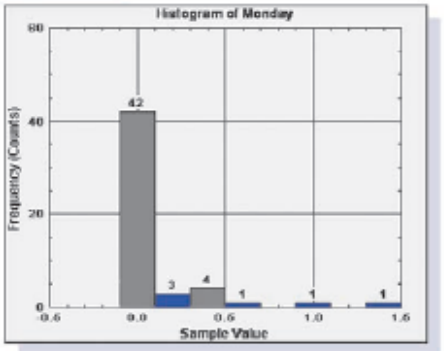
Consideremos el uso de los métodos que se presentan en capítulos anteriores para investigar este tema. El análisis de varianza (sección 11-2) sería una buena opción, pero ese método requiere que las muestras provengan de poblaciones con una distribución normal. El histograma generado por el STATDISK para las cantidades de lluvia del lunes muestra con claridad que esos valores no provienen de una población distribuida normalmente. Los otros días muestran distribuciones similares que, a todas luces, no son normales. Una ventaja importante de los métodos que se analizan en este capítulo es que no requieren de una distribución normal o de cualquiera otra distribución en particular.

¿Es posible utilizar los datos de Boston para sustentar la aseveración de más lluvias durante los fines de semana? ¿Son significativamente diferentes las cantidades de lluvia para los diferentes días? Abordaremos tales preguntas más tarde en el capítulo.

STATDISK



STATDISK



12-1 Panorama general

A los métodos de estadística diferencial que se presentan en los capítulos 6, 7, 8, 9 y 11 se les llama *métodos paramétricos*, porque se basan en el muestreo de una población con parámetros específicos, como la media μ, la desviación estándar σ o la proporción p. Estos métodos paramétricos por lo regular deben cumplir con algunas condiciones bastante estrictas, como el requisito de que los datos muestrales provengan de una población que se distribuya normalmente. Este capítulo introduce métodos no paramétricos, que están libres de tan estrictos requisitos.

Definiciones

Las **pruebas paramétricas** requieren supuestos acerca de la naturaleza o forma de las poblaciones involucradas; las **pruebas no paramétricas** no requieren supuestos acerca de las distribuciones poblacionales. En consecuencia, las pruebas de hipótesis no paramétricas suelen llamarse **pruebas de distribución libre**.

Aunque el término *no paramétrica* sugiere que la prueba no se basa en un parámetro, hay algunas pruebas no paramétricas que sí dependen de un parámetro, como la mediana. Sin embargo, las pruebas no paramétricas no requieren una distribución particular, por lo que algunas veces se les conoce como pruebas de *distribución libre*. Aunque *distribución libre* es una descripción más precisa, por lo regular se utiliza el término *no paramétrica*. Las siguientes son las ventajas y desventajas principales de los métodos no paramétricos.

Ventajas de los métodos no paramétricos

1. Los métodos no paramétricos se aplican a una amplia variedad de situaciones, puesto que no tienen los requisitos más estrictos de los métodos paramétricos correspondientes. En particular, los métodos no paramétricos no requieren poblaciones distribuidas normalmente.
2. A diferencia de los métodos paramétricos, los métodos no paramétricos con frecuencia se aplican a datos categóricos, como el género de quienes responden una encuesta.
3. Los métodos no paramétricos por lo regular implican cálculos más sencillos que los métodos paramétricos correspondientes; por lo tanto, son más fáciles de entender y aplicar.

Desventajas de los métodos no paramétricos

1. Los métodos no paramétricos tienden a desperdiciar información, pues los datos numéricos exactos suelen reducirse a una forma cualitativa. Por ejemplo, en la prueba del signo no paramétrica (descrita en la sección 12-2), las pérdidas de peso de las personas que se someten a una dieta se registran simplemente como signos negativos; las magnitudes reales de las pérdidas de peso se ignoran.
2. Las pruebas no paramétricas no son tan eficientes como las pruebas paramétricas, por lo que para una prueba no paramétrica generalmente necesitaremos

evidencia más fuerte (como una muestra más grande o diferencias mayores) para rechazar una hipótesis nula.

Cuando se satisfacen los requisitos de distribuciones poblacionales, las pruebas no paramétricas generalmente son menos eficaces que sus contrapartes paramétricas, aunque la reducción en la eficacia puede compensarse con un tamaño muestral más grande. Por ejemplo, la sección 12-6 presentará un concepto que se llama *correlación de rangos*, con una tasa de eficacia de 0.91, cuando se compara con la correlación lineal que se presenta en el capítulo 9. Esto significa que si todas las demás cosas son iguales, la correlación de rangos no paramétrica requiere 100 observaciones muestrales, para obtener los mismos resultados que 91 observaciones muestrales que se analicen con la correlación lineal paramétrica, suponiendo que se satisfacen los requisitos más estrictos para la aplicación del método paramétrico. La tabla 12-1 lista los métodos no paramétricos que se presentan en este capítulo, junto con el método paramétrico correspondiente y la tasa de **eficiencia**. La tabla 12-1 muestra que varias pruebas no paramétricas tienen tasas de eficiencia por encima de 0.90, por lo que la eficiencia más baja no sería un factor crítico para elegir entre los métodos paramétricos y no paramétricos. Sin embargo, como las pruebas paramétricas no tienen tasas de eficiencia más altas que sus contrapartes no paramétricas, generalmente es mejor utilizar las pruebas paramétricas cuando los supuestos que se requieren se satisfacen.

Rangos

Las secciones 12-3 a 12-6 utilizan métodos que se basan en rangos, que ahora describiremos.

Definición

Los datos se *ordenan* cuando se acomodan de acuerdo con algún criterio, como de más pequeño a más grande, o de mejor a peor. Un **rango** es un número que se asigna a un elemento muestral individual de acuerdo con su orden en la lista ordenada. Al primer elemento se le asigna un rango de 1, al segundo elemento se le asigna un rango de 2, etcétera.

Tabla 12-1 Eficiencia: comparación de pruebas paramétricas y no paramétricas

Aplicación	Prueba paramétrica	Prueba no paramétrica	Tasa de eficiencia de prueba no paramétrica con población normal
Datos apareados de los datos muestrales	Prueba t o prueba z	Prueba del signo	0.63
		Prueba de rangos con signo de Wilcoxon	0.95
Dos muestras independientes	Prueba t o prueba z	Prueba de la suma de rangos de Wilcoxon	0.95
Varias muestras independientes	Análisis de varianza (prueba F)	Prueba de Kruskal-Wallis	0.95
Correlación	Correlación lineal	Prueba de correlación de rangos ordenados	0.91
Aleatoriedad	Prueba no paramétrica	Prueba de rachas	Sin bases para comparación

EJEMPLO Los números 5, 3, 40, 10 y 12 pueden ordenarse (si se acomodan de menor a mayor) como 3, 5, 10, 12 y 40, con rangos de 1, 2, 3, 4 y 5, respectivamente:

5	3	40	10	12	Valores originales
3	5	10	12	40	Valores ordenados (que se acomodaron en orden)
↑	↑	↑	↑	↑	
1	2	3	4	5	Rangos

Manejo de empates en rangos: Si ocurre un empate en los rangos, el procedimiento habitual es calcular la media de los rangos que intervienen y luego asignar este rango medio a cada uno de los elementos empatados, como en el ejemplo siguiente.

EJEMPLO Los números 3, 5, 5, 10 y 12 tienen rangos dados de 1, 2.5, 2.5, 4 y 5, respectivamente. En este caso, los rangos 2 y 3 empataron; por lo tanto, calculamos la media de 2 y 3 (que es 2.5) y la asignamos a los valores que crearon el empate:

3	5	5	10	12	Valores originales
↑	↑	↑	↑	↑	
1	2.5	2.5	4	5	Rangos
	↑——	——↑			
	2 y 3 están empatados				

12-2 Prueba del signo

El objetivo principal de esta sección es entender el procedimiento de la *prueba del signo*, que es uno de los más sencillos de las pruebas no paramétricas.

Definición

Prueba del signo: una prueba no paramétrica (de distribución libre) que utiliza signos positivos y negativos para probar diferentes aseveraciones, incluyendo:

1. Aseveraciones que incluyen datos apareados de datos muestrales
2. Aseveraciones que incluyen datos nominales
3. Aseveraciones acerca de la mediana de una sola población

Concepto básico de la prueba del signo La idea básica que está detrás de la prueba del signo es el análisis de las frecuencias de los signos positivos y negativos, para determinar si son significativamente diferentes. Por ejemplo, suponga que probamos un tratamiento que se diseñó para disminuir la presión sanguínea. Si se trata a 100 sujetos y 51 de ellos experimentan una presión sanguínea más baja, mientras que los otros 49 tienen una presión sanguínea incrementada, el sentido

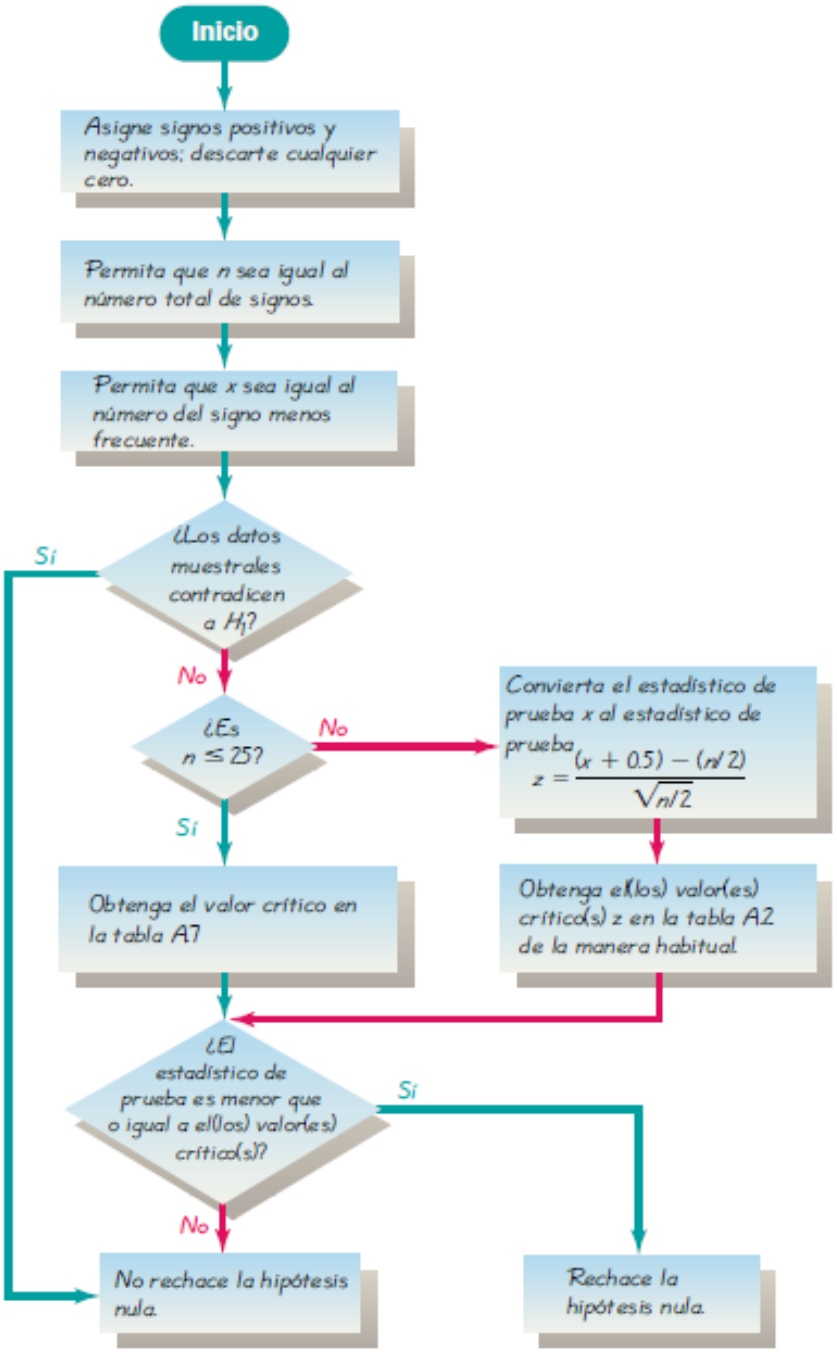


FIGURA 12-1
Procedimiento de la prueba del signo

común sugiere que no hay evidencia suficiente para decir que el fármaco es eficaz, puesto que 51 disminuciones en 100 casos no son significativas. Pero ¿qué sucede con 52 disminuciones y 48 incrementos? ¿O con 90 disminuciones y 10 incrementos? La prueba del signo nos permite determinar cuándo son significativos este tipo de resultados.

Por razones de consistencia y simplicidad, utilizaremos un estadístico de prueba con base en el número de veces que ocurre el signo menos frecuente. En el cuadro adjunto se resumen los supuestos relevantes, la notación, el estadístico de

prueba y los valores críticos. La figura 12-1 resume el procedimiento de la prueba del signo, que se ilustrará con los ejemplos que siguen.

Prueba del signo

Supuestos

1. Los datos muestrales se seleccionaron aleatoriamente.
2. *No* existe el requisito de que los datos muestrales provengan de una población con una distribución particular, como una distribución normal.

Notación

x = el número de veces que ocurre el signo *menos frecuente*

n = el número total de signos positivos y negativos combinados

Estadístico de prueba

Para $n \leq 25$: x (el número de veces que ocurre el signo menos frecuente)

Para $n > 25$: $$z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

Valores críticos

1. Para $n \leq 25$, los valores críticos x se encuentran en la tabla A-7.
2. Para $n > 25$, los valores críticos z se encuentran en la tabla A-2.

Cuidado: Cuando se aplica la prueba del signo en una prueba de una cola, necesitamos ser muy cuidadosos para no sacar la conclusión incorrecta cuando un signo ocurre significativamente con más frecuencia que el otro, aunque los datos muestrales contradicen la hipótesis alternativa. Por ejemplo, suponga que estamos probando la aseveración de que una técnica de selección de género favorece a los niños, pero tenemos una muestra de 10 niños y 90 niñas. Con una proporción muestral de niños igual a 0.10, los datos contradicen la hipótesis alternativa H_1: $p > 0.5$. No hay forma de sustentar la aseveración de que $p > 0.5$ con ninguna proporción muestral menor que 0.5, por lo que de inmediato no rechazamos la hipótesis nula y no procedemos con la prueba del signo. La figura 12-1 resume el procedimiento para la prueba del signo e incluye esta revisión: ¿Contradicen los datos muestrales a H_1? Si los datos muestrales van en el sentido opuesto de H_1, no rechace la hipótesis nula. *Siempre es importante pensar acerca de los datos y evitar la confianza a ciegas en cálculos o resultados de computadora.*

Aseveraciones que incluyen datos apareados

Cuando se utiliza la prueba del signo con datos que se ordenan en pares, convertimos los datos brutos en datos con signos positivos y negativos como sigue:

1. Restamos cada valor de la segunda variable del valor correspondiente de la primera variable.
2. Registramos sólo el *signo* de la diferencia que se encontró en el paso 1. *Excluimos los empates*, es decir, excluimos todos los datos apareados en los que ambos valores son iguales.

Éste es el concepto clave tras la aplicación de la prueba del signo:

Si dos conjuntos de datos tienen medianas iguales, el número de signos positivos debe ser aproximadamente igual al número de signos negativos.

EJEMPLO Medición de inteligencia en niños Las mediciones mentales de niños pequeños se hacen dándoles cubos y pidiéndoles que construyan una torre tan alta como sea posible. Un experimento de construcción con cubos se repitió un mes después, con los tiempos (en segundos) listados en la tabla 12-2 (datos tomados de "Tower Building", de Johnson y Courtney, *Child Development*, vol. 3). Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre los tiempos de la primera y segunda pruebas.

SOLUCIÓN La siguiente es la idea básica: si no hay diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba, los números de signos positivos y negativos deben ser aproximadamente iguales. En la tabla 12-2 tenemos 12 signos positivos y 2 signos negativos. ¿Son aproximadamente iguales los números de signos positivos y negativos, o son significativamente diferentes? Seguimos los mismos pasos básicos de prueba de hipótesis, tal como se perfilaron en la figura 12-1.

Pasos 1, 2 y 3: La hipótesis nula es la aseveración de no diferencia entre los tiempos de la primera y la segunda pruebas, en tanto que la hipótesis alternativa es la aseveración de que hay una diferencia.

H_0: No existe diferencia (la mediana de las diferencias es igual a 0).

H_1: Existe una diferencia (la mediana de las diferencias no es igual a 0).

Paso 4: El nivel de significancia es $\alpha = 0.05$.

Paso 5: Utilizamos la prueba no paramétrica del signo.

continúa

Tabla 12-2 Tiempos de construcción de torres con cubos

Niño	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
Primera prueba	30	19	19	23	29	178	42	20	12	39	14	81	17	31	52
Segunda prueba	30	6	14	8	14	52	14	22	17	8	11	30	14	17	15
Signo de la diferencia	0	+	+	+	+	+	+	−	−	+	+	+	+	+	+



Asistencia a clases y calificaciones

En un estudio entre 424 estudiantes universitarios de la Universidad de Michigan se encontró que los estudiantes con los peores registros de asistencia tendían a obtener las calificaciones más bajas (¿quién se sorprende?). Aquellos que estuvieron ausentes menos del 10% del tiempo recibieron, en general, calificaciones de B o superiores. El estudio también mostró que los estudiantes que se sientan al frente en el salón de clases significativamente obtienen mejores calificaciones.

Paso 6: El estadístico de prueba x es el número de veces que ocurre el signo menos frecuente. La tabla 12-2 incluye diferencias con 12 signos positivos y dos signos negativos; descartamos el único caso con una diferencia de cero. Permitimos que x sea igual al menor entre 12 y 2; por lo tanto, $x = 2$. Además, $n = 14$ (el número total de signos positivos y negativos combinados). Nuestra prueba es de dos colas con $\alpha = 0.05$. Nos remitimos a la tabla A-7 donde se encuentra el valor crítico de 2 para $n = 14$ y $\alpha = 0.05$ en dos colas. (Véase la figura 12-1).

Paso 7: Con un estadístico de prueba de $x = 2$ y un valor crítico de 2, rechazamos la hipótesis nula de no diferencia. [Consulte la nota 2 de la tabla A-7: "La hipótesis nula se rechaza si el número del signo menos frecuente (x) es menor que o igual al valor en la tabla". Puesto que $x = 2$ es menor que o igual al valor crítico de 2, rechazamos la hipótesis nula].

Paso 8: Hay suficiente evidencia para sustentar el rechazo de la aseveración de que la mediana de las diferencias es igual a 0; esto es, existe suficiente evidencia para sustentar el rechazo de la aseveración de que no hay una diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba. Es la misma conclusión que se alcanzaría utilizando la prueba paramétrica t con los datos apareados de la sección 8-4, aunque los resultados de la prueba del signo no siempre coinciden con los resultados de la prueba paramétrica.

Aseveraciones que incluyen datos nominales

Recuerde que los datos nominales consisten sólo en nombres, etiquetas o categorías. Aunque dichos conjuntos de datos nominales limitan los cálculos posibles, se identifica la *proporción* de datos muestrales que pertenece a una categoría en particular y se prueban aseveraciones acerca de la proporción poblacional p correspondiente. El siguiente ejemplo utiliza datos nominales que consisten en el género (hombre/mujer). La prueba del signo se utiliza representando a los hombres con signos positivos (+) y a las mujeres con signos negativos (−). (Créanme, los signos se eligieron arbitrariamente). También observe el procedimiento para manejar casos en los que $n > 25$.

EJEMPLO Discriminación por género La cadena de restaurantes Hatters recibió acusaciones de discriminación por género porque sólo contrató a 30 hombres junto a 70 mujeres solicitantes. Una representante de la compañía aceptó que los solicitantes calificados son aproximadamente la mitad hombres y la mitad mujeres, pero además asevera que "Hatters no discrimina y el hecho de que 30 de los últimos 100 empleados nuevos sean hombres es sólo una casualidad". Utilice la prueba del signo con un nivel de significancia de 0.05 y pruebe la hipótesis nula de que esta compañía contrata a hombres y a mujeres por igual.

SOLUCIÓN Permita que p denote la proporción poblacional de hombres contratados. La aseveración de no discriminación implica que las proporciones de hombres y mujeres contratados son iguales a 0.5; entonces, $p = 0.5$. Por lo tanto, las hipótesis nula y la alternativa pueden establecerse de la siguiente manera:

H_0: $p = 0.5$ (la proporción de hombres contratados es igual a 0.5)
H_1: $p \neq 0.5$

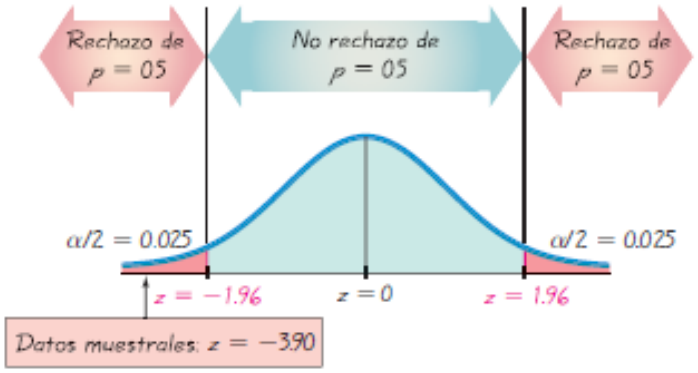


FIGURA 12-2 Prueba de la aseveración de prácticas de contratación injustas

Si denotamos a los hombres contratados con + y a las mujeres contratadas con −, tenemos 30 signos positivos y 70 signos negativos. Ahora remítase al procedimiento de prueba del signo que se resume en la figura 12-1. El estadístico de prueba x es el menor entre 30 y 70; entonces, $x = 30$. Esta prueba es de dos colas, puesto que un número desproporcionadamente bajo de cualquier género nos causará el rechazo de la aseveración de igualdad. Los datos muestrales no contradicen la hipótesis alternativa, ya que 30 y 70 no son precisamente iguales. (Esto es, los datos muestrales son consistentes con la hipótesis alternativa de una diferencia). Continuando con el procedimiento de la figura 12-1, notamos que el valor de $n = 100$ es superior a 25, por lo cual el estadístico de prueba x se convierte (utilizando una corrección por continuidad) al estadístico de prueba z como sigue:

$$z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

$$= \frac{(30 + 0.5) - \left(\frac{100}{2}\right)}{\frac{\sqrt{100}}{2}} = -3.90$$

Con $\alpha = 0.05$ en una prueba de dos colas, los valores críticos son $z = \pm 1.96$. El estadístico de prueba $z = -3.90$ es menor que -1.96 (véase la figura 12-2), por lo que rechazamos la hipótesis nula de que la proporción de hombres contratados es igual a 0.5. Hay suficiente evidencia de muestra para justificar el rechazo de la aseveración de que las prácticas de contratación son justas, con proporciones de hombres contratados y mujeres contratadas igual a 0.5. Parece que esta compañía discrimina por no contratar proporciones iguales de hombres y de mujeres.

Aseveraciones acerca de la mediana de una sola población

El siguiente ejemplo ilustra el procedimiento para utilizar la prueba del signo en la prueba de una aseveración acerca de la mediana de una sola población. Observe cómo los signos positivos y negativos se basan en el valor que se asevera para la mediana.

EJEMPLO Temperaturas corporales El conjunto de datos 4 del Apéndice B incluye temperaturas corporales medidas en adultos. Utilice las 106 temperaturas listadas para las 12:00 AM del día 2 con la prueba del signo, para probar la aseveración de que la mediana es menor que 98.6°F. El conjunto de datos tiene 106 sujetos: 68 sujetos con temperaturas por debajo de 98.6°F, 23 sujetos con temperaturas por encima de 98.6°F y 15 sujetos con temperaturas iguales a 98.6°F.

SOLUCIÓN La aseveración de que la mediana es menor que 98.6°F es la hipótesis alternativa, mientras la hipótesis nula es la aseveración de que la mediana es igual a 98.6°F.

H_0: La mediana es igual a 98.6°F. (mediana = 98.6°F)
H_1: La mediana es menor que 98.6°F. (mediana < 98.6°F)

Siguiendo el procedimiento que se perfiló en la figura 12-1, descartamos los 15 ceros, utilizamos el signo negativo (−) para denotar cada temperatura por debajo de 98.6°F y utilizamos el signo positivo (+) para denotar cada temperatura por encima de 98.6°F. Así, tenemos 68 signos negativos y 23 signos positivos; entonces, $n = 91$ y $x = 23$ (el número del signo menos frecuente). Los datos muestrales no contradicen la hipótesis alternativa, puesto que la mayoría de las 91 temperaturas están por debajo de 98.6°F. (Si los datos muestrales presentan un conflicto con la hipótesis alternativa, terminaríamos inmediatamente la prueba concluyendo que no rechazamos la hipótesis nula). El valor de n excede a 25, por lo que convertimos el estadístico de prueba x al estadístico de prueba z:

$$z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

$$= \frac{(23 + 0.5) - \left(\frac{91}{2}\right)}{\frac{\sqrt{91}}{2}} = -4.61$$

En la prueba de una cola con $\alpha = 0.05$, utilizamos la tabla A-2 para obtener el valor crítico z de -1.645. En la figura 12-3 vemos que el estadístico de prueba $z = -4.61$ cae dentro de la región crítica; por lo tanto, rechazamos la hipótesis nula. Con base en la evidencia muestral disponible, sustentamos la aseveración de que la mediana de la temperatura corporal de adultos saludables es menor que 98.6°F.

En esta prueba del signo, para la aseveración de que la mediana está por debajo de 98.6°F, obtenemos un estadístico de prueba de $z = -4.61$, con un valor P de 0.00000202, pero una prueba paramétrica de la aseveración de que $\mu < 98.6$°F da como resultado un estadístico de prueba de $t = -6.611$ con un valor P de 0.000000000813. Puesto que el valor P de la prueba del signo no es tan bajo como

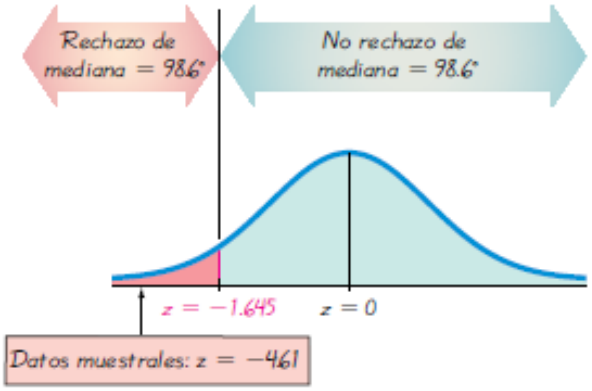


FIGURA 12-3 Prueba de la aseveración de que la mediana es menor que 98.6°F

el valor P de la prueba paramétrica, vemos que la prueba del signo no es tan sensible como la prueba paramétrica. Ambas pruebas nos llevan al rechazo de la hipótesis nula, pero la prueba del signo no considera que los datos muestrales sean tan extremos, parcialmente porque la prueba del signo utiliza sólo información acerca de la *dirección* de los datos, ignorando las *magnitudes* de los valores de los datos. La siguiente sección introduce la prueba de rangos con signo de Wilcoxon, que supera con creces tal desventaja.

Fundamentos para el estadístico de prueba que se utiliza cuando $n > 25$: Cuando se calculan valores críticos para la prueba del signo, utilizamos la tabla A-7 sólo para n hasta 25. Cuando $n > 25$, el estadístico de prueba z se basa en una aproximación normal a la distribución de probabilidad binomial con $p = q = 1/2$. Recuerde que en la sección 5-6 vimos que la aproximación normal a la distribución binomial es aceptable cuando $np \geq 5$ y $nq \geq 5$. Recuerde también que en la sección 4-4 vimos que $\mu = np$ y $\sigma = \sqrt{npq}$ para distribuciones de probabilidad binomial. Puesto que la prueba del signo supone que $p = q = 1/2$, satisfacemos los prerrequisitos de que $np \geq 5$ y $nq \geq 5$ siempre y cuando $n \geq 10$. Además, con el supuesto de que $p = q = 1/2$, obtenemos $\mu = np = n/2$ y $\sqrt{npq} = \sqrt{n/4} = \sqrt{n}/2$; por lo tanto,

$$z = \frac{x - \mu}{\sigma}$$

se convierte en

$$z = \frac{x - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

Finalmente, reemplazamos x con $x + 0.5$ como una corrección por continuidad. Esto es, los valores de x son discretos; pero, puesto que estamos utilizando la distribución de probabilidad continua, un valor discreto como 10 se representa en realidad por el intervalo de 9.5 a 10.5. Ya que x representa el signo menos frecuente, actuamos conservadoramente interesándonos sólo por $x + 0.5$. Así obtenemos el estadístico de prueba z, como aparece en la ecuación y en la figura 12-1.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Sign Test**. Elija la opción **Given Number of Signs** si conoce el número de signos positivos y negativos, o **Given Pairs of Values** si prefiere ingresar pares de datos asociados. Después de realizar las entradas que se requieren en el cuadro de diálogo, los resultados en la pantalla incluirán el estadístico de prueba, el valor crítico y la conclusión.

Minitab Primero debe crear una columna de valores que representen las diferencias entre los pares de datos asociados o el número de signos positivos y negativos. (Para detalles véase el manual *Minitab Student Laboratory Manual and Workbook*). Seleccione **Stat**, y luego **Nonparametrics** y **1-Sample Sign**. Haga clic en el botón para **Test Median**. Ingrese el valor de la mediana y elija el tipo de prueba, luego haga clic en **OK**. Minitab producirá el valor P, por lo tanto, rechace la hipótesis nula si el valor P es menor que o igual al nivel de significancia. De otra forma, no rechace la hipótesis nula.

Excel Excel no tiene una función predeterminada a la prueba del signo, pero usted puede utilizar la función BINOMDIST del programa para calcular el valor P para una prueba del signo. Haga clic en *fx* en la barra del menú principal, luego seleccione la categoría de función **Statistical** y entonces **BINOMDIST**. En el cuadro de diálogo, ingrese primero x, luego el número de ensayos n y una probabilidad de 0.5. Teclee **TRUE** en el cuadro para *cumulative*. El valor resultante es la probabilidad de obtener x o menos éxitos entre n ensayos. *Duplique este valor para pruebas de dos colas*. El resultado final es el valor P, por lo tanto, rechace la hipótesis nula, si el valor P es menor que o igual al nivel de significancia. De no ser así, no rechace la hipótesis nula.

TI-83 Plus La calculadora TI-83 Plus no tiene una función predeterminada para la prueba del signo, pero usted puede utilizar la función binomcdf para calcular el valor P para una prueba del signo. Oprima **2nd**, **VARS** (para obtener el menú **DISTR**); luego baje el cursor para seleccionar **binomcdf**. Complete la entrada de **binomcdf(n, p, x)** con n para el número total de signos positivos y negativos, 0.5 para p y el número del signo menos frecuente para x. Ahora oprima **ENTER**; el resultado será la probabilidad de obtener x o menos éxitos entre n ensayos. *Duplique este valor para pruebas de dos colas*. El resultado final es el valor P, por lo tanto, rechace la hipótesis nula si el valor P es menor que o igual al nivel de significancia. De otra forma, no rechace la hipótesis nula.

12-2 Destrezas y conceptos básicos

En los ejercicios 1 a 4, suponga que los datos apareados dan como resultado el número dado de signos cuando el valor de la segunda variable se resta del correspondiente valor de la primera variable. Utilice la prueba del signo con un nivel de significancia de 0.05 y pruebe la hipótesis nula de ninguna diferencia.

1. Signos positivos: 10; signos negativos: 5; empates: 3
2. Signos positivos: 6; signos negativos: 16; empates: 2
3. Signos positivos: 50; signos negativos: 40; empates: 5
4. Signos positivos: 10; signos negativos: 30; empates: 3

En los ejercicios 5 a 16 utilice la prueba del signo.

5. Prueba para la diferencia entre estaturas de hombres reportadas y medidas Como parte de la National Health and Nutrition Examination Survey, realizada por el Department of Health and Human Services de Estados Unidos, se obtuvieron las estaturas y medidas de hombres de 12 a 16 años de edad. Abajo se listan los resultados muestrales. ¿Existe evidencia suficiente para sustentar la aseveración de que hay una diferencia entre las estaturas reportadas y las estaturas medidas de hombres de 12 a 16 años de edad? Utilice un nivel de significancia de 0.05.

Estatura reportada	68	71	63	70	71	60	65	64	54	63	66	72
Estatura medida	67.9	69.9	64.9	68.3	70.3	60.6	64.5	67.0	55.6	74.2	65.0	70.8

6. Prueba para la diferencia entre estaturas reportadas y medidas La tabla de abajo lista datos apareados de estaturas que se midieron de 12 hombres estudiantes de estadística. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre las estaturas reportadas y las estaturas medidas.

Estatura reportada	68	74	82.25	66.5	69	68	71	70	70	67	68	70
Estatura medida	66.8	73.9	74.3	66.1	67.2	67.9	69.4	69.9	68.6	67.9	67.6	68.8

7. Prueba para temperatura corporal media de 98.6°F En una clase de estadística, se le pide a una estudiante del curso propedéutico de medicina que realice un proyecto de clase. Inspirada por las temperaturas corporales del conjunto de datos 4 en el Apéndice B, ella planea reunir sus propios datos muestrales para probar la aseveración de que la temperatura corporal media es menor que 98.6°F. Por restricciones de tiempo, encuentra que sólo alcanzará a reunir datos de 12 personas. Después de planear con cuidado un procedimiento para obtener una muestra aleatoria de 12 adultos saludables, mide sus temperaturas corporales y obtiene los resultados que se listan abajo. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que dichas temperaturas corporales provienen de una población con una mediana que es menor que 98.6°F.

97.6 97.5 98.6 98.2 98.0 99.0 98.5 98.1 98.4 97.9 97.9 97.7

8. Prueba para mediana de peso bajo La Prince County Bottling Company surte botellas de limonada que se etiquetan de 12 onzas. Cuando el Prince County Department of Weights and Measures prueba una muestra aleatoria de botellas, obtiene las cantidades que se listan abajo. Si utilizamos un nivel de significancia de 0.05, ¿existe suficiente evidencia para documentar la acusación de que la compañía embotelladora está engañando a los consumidores dando cantidades con una mediana menor que 12 onzas?

11.4 11.8 11.7 11.0 11.9 11.9 11.5 12.0 12.1 11.9 10.9 11.3 11.5 11.5 11.6

9. Datos nominales: encuesta de votantes En una encuesta que se aplicó a 1002 personas, 701 dijeron que votaron en la elección presidencial reciente (según datos del ICR Research Group). ¿Hay suficiente evidencia para sustentar la aseveración de que la mayoría de las personas votaron en la elección?

10. Datos nominales: tabaquismo y parches de nicotina En un estudio de 71 fumadores que intentaban dejar de fumar con la terapia de parches de nicotina, 41 siguieron fumando un año después del tratamiento (según datos de "High-Dose Nicotine Patch Therapy", de Dale *et al.*, *Journal of the American Medical Association*, vol. 274, núm. 17). Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que, de los fumadores que tratan de dejar el hábito con la terapia de parches de nicotina, la mayoría siguieron fumando un año después del tratamiento.

11. Prueba de la mediana del volumen de latas de Coca Cola Remítase al conjunto de datos 17 en el Apéndice B y utilice los volúmenes de Coca Cola clásica. Pruebe la aseveración de que las latas de Coca Cola clásica tienen volúmenes con una mediana mayor que 12 onzas. ¿Parece que las latas de Coca Cola se llenan correctamente?

12. Prueba de la mediana de la cantidad de azúcar Dominó en sobres Remítase al conjunto de datos 28 del Apéndice B y utilice los datos muestrales para probar la aseveración de que la mediana de la cantidad de azúcar en los sobres es igual a 3.5 onzas. ¿Parece que los sobres de azúcar se llenan correctamente?

13. Prueba de la mediana del intervalo del tiempo del géiser Old Faithful Remítase al conjunto de datos 13 en el Apéndice B. Pruebe la aseveración de que los intervalos entre las erupciones del géiser Old Faithful tienen una mediana mayor a 77 minutos, que es la mediana que se registró desde hace 30 años.

14. Prueba de la diferencia entre temperaturas pronosticadas y reales Remítase al conjunto de datos 10 en el Apéndice B y utilice las temperaturas máximas reales y el pronóstico de temperaturas máximas de tres días. ¿Parece haber una diferencia?

12-2 Más allá de lo básico

15. Procedimientos para manejar empates En el procedimiento de la prueba del signo descrito en esta sección, excluimos los empates (representados por 0 en lugar de un signo de + o de −). Un segundo método consiste en tratar a la mitad de los ceros como signos positivos y a la mitad como negativos. (Si el número de ceros es impar, excluya uno para que se dividan por igual). Con un tercer método, en pruebas de dos colas haga la mitad de los ceros positivos y la mitad negativos; en pruebas de una cola, haga todos los ceros positivos o negativos, pues cualquier signo sustenta la hipótesis nula. Suponga que en el uso de la prueba del signo para una aseveración de que el valor de la mediana es menor que 100, tenemos 60 valores por debajo de 100, 40 valores por encima de 100, y 21 valores iguales a 100. Identifique el estadístico de prueba y la conclusión con las tres formas diferentes de manejar empates (con diferencias de 0). Suponga un nivel de significancia de 0.05 en los tres casos.

16. Cálculo de valores críticos La tabla A-7 lista valores críticos para alternativas limitadas de α. Utilice la tabla A-1 para añadir una nueva columna en la tabla A-7 (bajando hasta $n = 15$) que representa un nivel de significancia de 0.03 en una cola o de 0.06 en dos colas. Para cualquier n particular, utilice $p = 0.5$, ya que la prueba del signo requiere el supuesto de que P (signo positivo) $= P$ (signo negativo) $= 0.5$. La probabilidad de x o menos signos del mismo tipo es la suma de las probabilidades de los valores hasta x, inclusive.

17. Error de aproximación normal Entre sus últimos 54 empleados nuevos, la compañía Compulife.com contrató a 18 mujeres. De los solicitantes, alrededor de la mitad son mujeres y la otra mitad hombres, y todos son calificados. Utilizando un nivel de significancia de 0.01 con la prueba del signo, ¿hay suficiente evidencia para acusar de favoritismo? ¿La conclusión cambia si se utiliza la distribución binomial en lugar de la distribución normal aproximada?

12-3 Prueba de rangos con signo de Wilcoxon para datos apareados

En la sección 12-2 utilizamos la prueba del signo para analizar tres tipos diferentes de datos, incluyendo datos muestrales consistentes en datos apareados. La prueba del signo incluyó sólo los signos de las diferencias y no sus magnitudes reales (qué tan grandes son los números). Esta sección introduce la *prueba de rangos con signo de Wilcoxon*, que también se usa con datos muestrales apareados. Mediantel uso de rangos, esta prueba toma en cuenta las magnitudes de las diferencias. (Véase la sección 12-1 para una descripción de los rangos). Puesto que la prueba de rangos con signo de Wilcoxon incorpora y utiliza más información que la prueba del signo, tiende a proporcionar conclusiones que reflejan mejor la verdadera naturaleza de los datos.

Definición

Prueba de rangos con signo de Wilcoxon: Una prueba no paramétrica que utiliza rangos ordenados de datos muestrales consistentes en datos apareados. Se usa para probar las diferencias en las distribuciones poblacionales, por lo que las hipótesis nula y alternativa son las siguientes:

H_0: Las dos muestras provienen de poblaciones con la misma distribución.

H_1: Las dos muestras provienen de poblaciones con distribuciones diferentes.

(La prueba de rangos con signo de Wilcoxon también resulta útil para probar la aseveración de que una muestra proviene de una población con una mediana específica. Véase el ejercicio 9 para dicha aplicación).

Procedimiento de la prueba de rangos con signo de Wilcoxon

Paso 1: Para cada par de datos, calcule la diferencia d restando el segundo valor del primero. Guarde los signos, pero descarte cualquier par para el que $d = 0$.

Paso 2: *Ignore los signos de las diferencias*, luego acomode las diferencias de la más baja a la más alta y reemplace las diferencias por el valor del rango correspondiente (como se describe en la sección 12-1). Cuando las diferencias tengan el mismo valor numérico, asígneles la media de los rangos implicados en el empate.

Paso 3: Adjunte a cada rango el signo de la diferencia de la que provino. Esto es, inserte aquellos signos que se ignoraron en el paso 2.

Paso 4: Calcule la suma de los valores absolutos de los rangos negativos. También, la suma de los rangos positivos.

Paso 5: Permita que T sea la *más pequeña* de las dos sumas que se calcularon en el paso 4. Es posible utilizar cualquier suma, aunque para simplificar el procedimiento seleccionamos arbitrariamente la más pequeña de las dos sumas. (Véase la notación para T en el cuadro adjunto).

Paso 6: Permita que n sea el número de pares de datos para los que la diferencia d no es 0.

Paso 7: Determine el estadístico de prueba y los valores críticos con base en el tamaño muestral, como se indica en el cuadro adjunto.

Paso 8: Cuando plantee la conclusión, rechace la hipótesis nula si los datos muestrales le llevan a un estadístico de prueba que está en la región crítica, esto es, cuando el estadístico de prueba es menor que o igual al(los) valor(es) crítico(s). De otra forma, no rechace la hipótesis nula.

Prueba de rangos con signo de Wilcoxon

Supuestos

1. Los datos consisten en datos apareados que se seleccionaron aleatoriamente.
2. La población de las diferencias (calculadas de los pares de datos) tiene una distribución que es aproximadamente *simétrica*, lo que quiere decir que la mitad izquierda de su histograma es aproximadamente una imagen de espejo de la mitad derecha. (*No* existe el requisito de que los datos tengan una distribución normal).

continúa

Notación

Véanse los pasos del procedimiento adjunto para calcular la suma de rangos T.

T = la más pequeña de las siguientes dos sumas:

1. La suma de los valores absolutos de los rangos negativos de las diferencias d que no sean cero.
2. La suma de los rangos positivos de las diferencias d que no sean cero.

Estadístico de prueba

Si $n \leq 30$, el estadístico de prueba es T.

Si $n > 30$, el estadístico de prueba es $z = \dfrac{T - \dfrac{n(n+1)}{4}}{\sqrt{\dfrac{n(n+1)(2n+1)}{24}}}$

Valores críticos

1. Si $n \leq 30$, el valor crítico T se encuentra en la tabla A-8.
2. Si $n > 30$, los valores críticos z se encuentran en la tabla A-2.

EJEMPLO Medición de la inteligencia en niños Los datos en la tabla 12-3 son datos apareados de tiempos (en segundos) que se obtuvieron a partir de una muestra aleatoria de niños a quienes se les pidió que construyeran, usando cubos, una torre tan alta como fuera posible (según datos de "Tower Building", de Johnson y Courtney, *Child Development*, vol. 3). Este procedimiento se utiliza para medir la inteligencia de los niños. Utilice la prueba de rangos con signo de Wilcoxon con un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre los tiempos de la primera y de la segunda pruebas.

SOLUCIÓN Las hipótesis nula y alternativa son como sigue:

H_0: No hay diferencia entre los tiempos de la primera y de la segunda pruebas.

H_1: Existe una diferencia entre los tiempos de la primera y de la segunda pruebas.

Tabla 12-3 Tiempos para la construcción de torres con cubos

Niño	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
Primera prueba	30	19	19	23	29	178	42	20	12	39	14	81	17	31	52
Segunda prueba	30	6	14	8	14	52	14	22	17	8	11	30	14	17	15
Diferencias d	0	13	5	15	15	126	28	−2	−5	31	3	51	3	14	37
Rangos de |diferencias|		6	4.5	8.5	8.5	14	10	1	4.5	11	2.5	13	2.5	7	12
Rangos con signo		6	4.5	8.5	8.5	14	10	−1	−4.5	11	2.5	13	2.5	7	12

El nivel de significancia es $\alpha = 0.05$. Estamos utilizando el procedimiento de la prueba de rangos con signo de Wilcoxon, por lo que el estadístico de prueba se calcula aplicando el procedimiento de ocho pasos que ya se presentó en esta sección.

Paso 1: En la tabla 12-3, el renglón de diferencias se obtiene calculando esta diferencia para cada par de datos:

d = tiempo de la primera prueba − tiempo de la segunda prueba

Paso 2: Ignorando sus signos, ordenamos los rangos de las diferencias absolutas de la más baja a la más alta. Note que los empates en los rangos se manejan asignando la media de los rangos implicados a cada uno de los valores empatados y las diferencias de 0 se descartan.

Paso 3: El renglón inferior de la tabla 12-3 se crea insertando a cada rango el signo de la diferencia correspondiente. Si en realidad no hay diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba (como en la hipótesis nula), esperamos que el número de rangos positivos sea aproximadamente igual al número de rangos negativos.

Paso 4: Ahora calculamos la suma de los valores absolutos de los rangos negativos y también calculamos la suma de los rangos positivos.

Suma de los valores absolutos de los rangos negativos: 5.5
Suma de los rangos positivos: 99.5

Paso 5: Permitiendo que T sea la menor de las dos sumas calculadas en el paso 4, encontramos que $T = 5.5$.

Paso 6: Permitiendo que n sea el número de pares de datos para los que la diferencia d no es 0, tenemos $n = 14$.

Paso 7: Puesto que $n = 14$, tenemos que $n \leq 30$, por lo cual utilizamos un estadístico de prueba de $T = 5.5$ (y no calculamos un estadístico de prueba z). Además, puesto que n $\leq$ 30, utilizamos la tabla A-8 para encontrar el valor crítico de 21.

Paso 8: El estadístico de prueba $T = 5.5$ es menor que o igual al valor crítico de 21, por lo que rechazamos la hipótesis nula. Parece que hay una diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba.

Si utilizamos la prueba del signo con el ejemplo anterior, llegaremos a la misma conclusión. Aunque la prueba de signo y la prueba de rangos con signo de Wilcoxon coinciden en este caso en particular, hay otros casos en los que no concuerdan.

Fundamentos: En este ejemplo los rangos sin signo de 1 hasta 14 tienen un total de 105, por lo que, si no hay diferencias significativas, cada uno de los dos totales de rangos con signo debe ser de alrededor de 105 ÷ 2, o 52.5. Esto es, los rangos negativos y los rangos positivos deberían repartirse como 52.5-52.5 o algo cercano, tal como 51-54. La tabla de valores críticos muestra que a un nivel de significancia de 0.05, con 14 pares de datos, un reparto de 21-84 representa una desviación significativa de la hipótesis nula y cualquier reparto que se separe más (como 20-85 o 5.5-99.5) también representará una desviación significativa de la hipótesis nula. Por el contrario, repartos como 22-83 no representan desviaciones significativas de un reparto de 52.5-52.5, por lo que no justificarían el rechazo de

la hipótesis nula. La prueba de rangos con signo de Wilcoxon se basa en el total del rango más bajo, por lo que en lugar de analizar los dos números que constituyen el reparto, consideramos sólo el número más bajo.

La suma $1 + 2 + 3 + \cdots + n$ de todos los rangos es igual a $n(n + 1)/2$, y si ésta es una suma de rangos a dividirse por igual entre dos categorías (positivo y negativo), cada uno de los dos totales debería estar cerca de $n(n + 1)/4$, que es la mitad de $n(n + 1)/2$. El reconocimiento de este principio nos ayuda a entender el estadístico de prueba que se usa cuando $n > 30$. El denominador en esa expresión representa una desviación estándar de T y se basa en el principio de que

$$1^2 + 2^2 + 3^3 + \cdots + n^2 = \frac{n(n + 1)(2n + 1)}{6}$$

La prueba de rangos con signo de Wilcoxon se utiliza sólo con datos apareados. La siguiente sección describirá una prueba de suma de rangos que puede aplicarse a dos conjuntos de datos independientes que no se asocian en pares.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Wilcoxon Tests**, ahora **Signed-Ranks Test.** Proceda a ingresar los datos muestrales apareados. Haga clic en **Evaluate**. La pantalla del STATDISK incluirá el estadístico de prueba, el valor crítico y la conclusión.

Minitab Ingrese los datos apareados en las columnas C1 y C2. Haga clic en **Editor** y luego en **Enable Command Editor**. Ingrese el comando **LET C3 = C1 − C2**. Oprima la tecla **Enter**. Elija las opciones **Stat**, **Nonparametrics** y **1-Sample Wilcoxon**. Ingrese C3 para la variable y haga clic en el botón para **Test Median**. La pantalla del Minitab incluirá el valor **P**. Rechace la hipótesis nula de distribuciones iguales si el valor P es menor que o igual al nivel de significancia. No rechace la hipótesis nula si el valor P es mayor que el nivel de significancia.

Excel Excel no está programado para la prueba de rangos con signo de Wilcoxon.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de rangos con signo de Wilcoxon.

12-3 Destrezas y conceptos básicos

Uso de la prueba de rangos con signo de Wilcoxon. *En los ejercicios 1 y 2, remítase a los datos muestrales apareados que se presentan; utilice la prueba de rangos con signo de Wilcoxon para probar la aseveración de que ambas muestras provienen de poblaciones que tienen la misma distribución. Utilice un nivel de significancia de 0.05.*

1.

x	12	14	17	19	20	27	29	30
y	12	15	15	14	12	18	19	20

2.

x	8	6	9	12	22	31	34	35	37
y	8	8	12	17	29	39	24	47	49

Uso de la prueba de rangos con signo de Wilcoxon. *En los ejercicios 3 y 4, remítase a los datos muestrales para los ejercicios de la sección 12-2. En lugar de la prueba del signo, utilice la prueba de rangos con signo de Wilcoxon para probar la aseveración de que ambas muestras provienen de poblaciones con la misma distribución.*

3. Ejercicio 5

4. Ejercicio 6

En los ejercicios 5 a 8, utilice la prueba de rangos con signo de Wilcoxon.

5. Prueba de la diferencia entre mediciones en posición de sentado y acostado En un estudio de técnicas que se utilizan para medir los volúmenes de los pulmones, se reunieron datos fisiológicos de 10 sujetos. Los valores dados en la tabla vienen en litros y representan las capacidades residuales funcionales medidas de los 10 sujetos en posición de sentado y en posición supina (acostado). Con un nivel de significancia de 0.5, pruebe la aseveración de que no hay diferencias significativas entre las mediciones que se tomaron en las dos posiciones.

Sentado	2.96	4.65	3.27	2.50	2.59	5.97	1.74	3.51	4.37	4.02
Supino	1.97	3.05	2.29	1.68	1.58	4.43	1.53	2.81	2.70	2.70

Datos tomados de "Validation of Esophageal Balloon Technique at Different Lung Volumes and Postures", de Baydur, Cha y Sassoon, *Journal of Applied Physiology*, vol. 62, núm. 1.

6. Prueba de eficacia de fármacos El captopril es un fármaco que se diseñó para disminuir la presión sanguínea sistólica. Cuando se probó este fármaco en sujetos, sus lecturas de presión sanguínea sistólica (en milímetros de mercurio) se midieron antes y después de que se tomara el fármaco, con los resultados que se presentan en la tabla adjunta. ¿Hay suficiente evidencia para sustentar la aseveración de que el fármaco no surte efecto? ¿Parece que el captopril disminuye la presión sanguínea sistólica?

Sujeto	A	B	C	D	E	F	G	H	I	J	K	L
Antes	200	174	198	170	179	182	193	209	185	155	169	210
Después	191	170	177	167	159	151	176	183	159	145	146	177

Datos tomados de "Essential Hypertension: Effect of an Oral Inhibitor of Angiotensin-Converting Enzyme", de MacGregor *et al.*, *British Medical Journal*, vol. 2.

7. Prueba de la diferencia entre temperaturas pronosticadas y reales Remítase al conjunto de datos 10 del Apéndice B. Utilice las temperaturas máximas reales y el pronóstico de temperaturas máximas de tres días. ¿Parece haber una diferencia?

8. Prueba para la diferencia entre los tiempos en que se muestra consumo de alcohol y de tabaco Remítase al conjunto de datos 7 del Apéndice B. Utilice sólo aquellas películas que muestran algún consumo de tabaco o alcohol (es decir, ignore aquellas películas con tiempos de cero para consumo de tabaco y para consumo del alcohol). ¿Parece haber una diferencia?

12-3 Más allá de lo básico

9. Uso de la prueba de rangos con signo de Wilcoxon para aseveraciones acerca de una mediana La prueba de rangos con signo de Wilcoxon se utiliza para probar la aseveración de que una muestra proviene de una población con una mediana específica. El procedimiento que se emplea es el mismo que el descrito en esta sección, excepto que las diferencias (paso 1) se obtienen restando el valor de la mediana hipotética de cada

valor. Utilice los datos muestrales consistentes en las 106 temperaturas corporales listadas para las 12 AM del día 2 en el conjunto de datos 4 del Apéndice B. Con un nivel de significancia de 0.05, pruebe la aseveración de que los adultos saludables tienen una mediana de temperatura corporal igual a 98.6°F.

12-4 Prueba de la suma de rangos de Wilcoxon para dos muestras independientes

Aquí se introduce la *prueba de la suma de rangos de Wilcoxon*, que es la prueba no paramétrica de que dos conjuntos independientes de datos muestrales provienen de poblaciones con la misma distribución. Dos muestras son independientes, si los valores muestrales seleccionados de una población no se relacionan, asocian o se aparean de ninguna forma con los valores muestrales de la otra población. (Para evitar confusiones acerca de la suma de rangos de Wilcoxon para muestras independientes y la prueba de rangos con signo de Wilcoxon para datos apareados, considere el uso de las siglas ISR correspondientes al impuesto sobre la renta como técnica mnémica para recordarnos "independiente: suma de rangos").

Definición

Prueba de la suma de rangos de Wilcoxon: Una prueba no paramétrica que utiliza rangos de datos muestrales a partir de dos poblaciones independientes. Se emplea para probar la hipótesis nula de que dos muestras independientes provienen de poblaciones con la misma distribución (es decir, las dos poblaciones son idénticas). La hipótesis alternativa es la aseveración de que las dos distribuciones poblacionales son diferentes en alguna forma.

H_0: Las dos muestras provienen de poblaciones con la misma distribución (esto es, las dos poblaciones son idénticas).

H_1: Las dos muestras provienen de poblaciones con distribuciones diferentes (esto es, las dos poblaciones son diferentes en alguna forma).

Concepto básico: La prueba de la suma de rangos de Wilcoxon es equivalente a la **prueba *U* de Mann-Whitney** (véase el ejercicio 11), que se incluye en algunos otros libros de texto y programas de cómputo (como el Minitab). Ésta es la idea clave que sustenta la prueba de la suma de rangos de Wilcoxon: si dos muestras se obtienen de poblaciones idénticas y los valores individuales se acomodan en rangos como un conjunto de valores que se combina, entonces por lo regular los rangos alto y bajo deberían caer entre las dos muestras. Si los rangos bajos se encuentran predominantemente en una muestra y los rangos altos se encuentran predominantemente en la otra muestra, sospechamos que las dos poblaciones no son idénticas. Esta idea clave se refleja en el siguiente procedimiento para calcular el valor del estadístico de prueba.

Procedimiento para calcular el valor del estadístico de prueba

1. Combine temporalmente las dos muestras en una muestra grande, entonces reemplace cada valor muestral por su rango. (El valor más bajo toma un rango

de 1, el siguiente valor más bajo toma un rango de 2, etcétera. Si los valores están empatados, asígneles la media de los rangos que implica el empate. Véase la sección 12-1 para obtener una descripción de los rangos y el procedimiento para manejar empates).

2. Calcule la suma de los rangos para cualquiera de las dos muestras.
3. Calcule el valor del estadístico de prueba z como se indica en el siguiente recuadro, donde cualquier muestra puede utilizarse como la "muestra 1". (Si se está probando la hipótesis nula de poblaciones idénticas y si ambos tamaños muestrales son mayores que 10, la distribución muestral de R es aproximadamente normal, con media μ_R y desviación estándar σ_R, en tanto que el estadístico de prueba es como se indica en el recuadro siguiente).

Prueba de la suma de rangos de Wilcoxon

Supuestos

1. Hay dos muestras independientes de datos seleccionados aleatoriamente.
2. Cada una de las dos muestras tiene más de 10 valores. (Para muestras con 10 valores o menos, en libros de referencia están disponibles tablas especiales, como las *CRC Standard Probability and Statistics Tables and Formulae*, publicadas por CRC Press).
3. No existe el requisito de que las dos poblaciones tengan una distribución normal o cualquiera otra distribución particular.

Notación

n_1 = tamaño de la muestra 1

n_2 = tamaño de la muestra 2

R_1 = suma de rangos de la muestra 1

R_2 = suma de rangos de la muestra 2

R = lo mismo que R_1 (suma de rangos de la muestra 1)

μ_R = media de los valores muestrales R que se espera cuando las dos poblaciones son idénticas

σ_R = desviación estándar de los valores muestrales R que se espera, cuando las dos poblaciones son idénticas

Estadístico de prueba

$$z = \frac{R - \mu_R}{\sigma_R}$$

donde

$$\mu_R = \frac{n_1(n_1 + n_2 + 1)}{2}$$

$$\sigma_R = \sqrt{\frac{n_1 n_2(n_1 + n_2 + 1)}{12}}$$

n_1 = tamaño de la muestra a partir de la cual se calcula la suma de rangos R

n_2 = tamaño de la otra muestra

R = suma de rangos de la muestra con tamaño n_1

Valores críticos: Los valores críticos están en la tabla-A.2 (puesto que el estadístico de prueba se basa en la distribución normal).

Note que, a diferencia de las pruebas de hipótesis correspondientes en la sección 8-3, la prueba de la suma de rangos de Wilcoxon no requiere poblaciones que se distribuyen normalmente. Además, la prueba de la suma de rangos de Wilcoxon se utiliza con datos en el nivel de medición ordinal, como los datos consistentes en rangos. En contraste, los métodos paramétricos de la sección 8-3 no se utilizan con datos en el nivel de medición ordinal. En la tabla 12-1 notamos que la prueba de la suma de rangos de Wilcoxon tuvo una tasa de eficiencia de 0.95 cuando se compara con la prueba paramétrica t o con la prueba z. Puesto que dicha prueba tiene una alta tasa de eficiencia y supone cálculos más fáciles, suele preferirse sobre las pruebas paramétricas que se presentan en la sección 8-3, aun cuando se satisfaga el requisito de normalidad.

La expresión de μ_R se basa en el resultado de inducción matemática siguiente: la suma de los primeros n enteros positivos está dada por $1 + 2 + 3 + \cdots + n = n(n + 1)/2$. La expresión de σ_R se basa en un resultado que establece que los enteros 1, 2, 3, . . . , n tienen una desviación estándar $\sqrt{(n^2 - 1)/12}$.

EJEMPLO Rowling y Tolstoi El conjunto de datos 14 del Apéndice B incluye las calificaciones de facilidad de lectura de Flesch para páginas que se seleccionaron aleatoriamente de cada uno de dos libros: *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. La tabla 12-4 incluye valores del conjunto de datos 14 junto con un valor adicional que se diseñó para ilustrar mejor el procedimiento de la suma de rangos de Wilcoxon. (El valor de 71.4 se añadió al final de la lista de Rowling para que hubiera un empate y los conjuntos de datos tuvieran números de valores diferentes). Utilice los dos conjuntos de datos muestrales independientes de la tabla 12-4, con un nivel de significancia de 0.05, y pruebe la aseveración de que las puntuaciones de facilidad de lectura para páginas de los dos libros tienen la misma distribución.

Tabla 12-4
Calificaciones de lectura

Rowling	Tolstoi
85.3 (24)	69.4 (7)
84.3 (22)	64.2 (4)
79.5 (18)	71.4 (9.5)
82.5 (20)	71.6 (11)
80.2 (19)	68.5 (6)
84.6 (23)	51.9 (1)
79.2 (17)	72.2 (12)
70.9 (8)	74.4 (15)
78.6 (16)	52.8 (2)
86.2 (25)	58.4 (3)
74.0 (14)	65.4 (5)
83.7 (21)	73.6 (13)
71.4 (9.5)	
$n_1 = 13$	$n_2 = 12$
$R_1 = 236.5$	$R_2 = 88.5$

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Los libros de Rowling y Tolstoi tienen calificaciones de facilidad de lectura de Flesch, con la misma distribución.

H_1: Las dos poblaciones tienen distribuciones de calificaciones de facilidad de lectura de Flesch, que son diferentes en alguna forma.

Acomode en rangos las 25 calificaciones de lectura que se combinaron, comenzando con un rango de 1 (que se asignó al valor más bajo de 51.9). Los empates en los rangos se manejan como se describe en la sección 12-1: calcule la media de los rangos implicados y asigne este rango medio a cada uno de los valores empatados. Los valores 9o. y 10o. son ambos de 71.4, por lo que se asigna el rango de 9.5 a cada uno de dichos valores. En la tabla 12-4, los rangos correspondientes a los valores muestrales individuales se presentan entre paréntesis. R denota la suma de los rangos para la muestra que escogimos como muestra 1. Si elegimos las calificaciones de Rowling, tenemos

$$R = 24 + 22 + 18 + \cdots + 9.5 = 236.5$$

Puesto que hay 13 valores de Rowling, tenemos $n_1 = 13$. Además, $n_2 = 12$, ya que existen 12 valores para Tolstoi. Ahora determinemos los valores de μ_R, σ_R, y el estadístico de prueba z.

$$\mu_R = \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{13(13 + 12 + 1)}{2} = 169$$

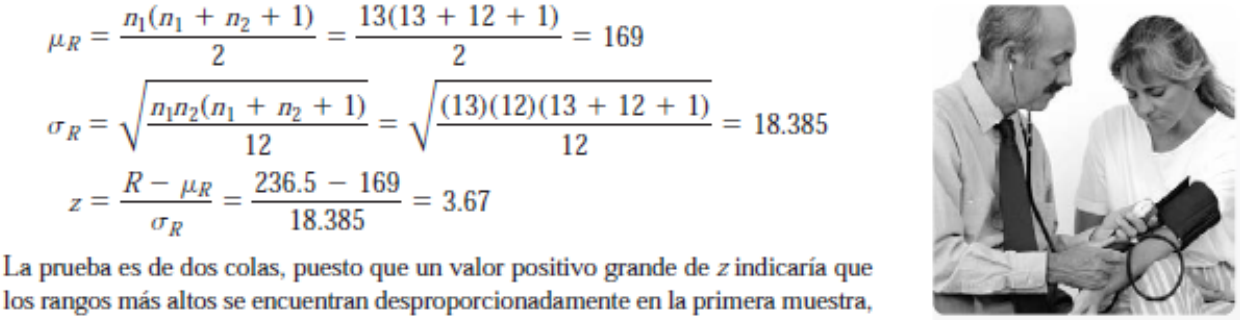
$$\sigma_R = \sqrt{\frac{n_1 n_2(n_1 + n_2 + 1)}{12}} = \sqrt{\frac{(13)(12)(13 + 12 + 1)}{12}} = 18.385$$

$$z = \frac{R - \mu_R}{\sigma_R} = \frac{236.5 - 169}{18.385} = 3.67$$

La prueba es de dos colas, puesto que un valor positivo grande de z indicaría que los rangos más altos se encuentran desproporcionadamente en la primera muestra, en tanto que un valor negativo grande de z indicaría que la primera muestra tuvo una porción desproporcionada de los rangos más bajos. En cualquier caso, tendríamos una fuerte evidencia en contra de la aseveración de que las dos muestras provienen de poblaciones con la misma distribución.

La significancia del estadístico de prueba z puede tratarse de la misma manera que en los capítulos anteriores. Ahora estamos probando (con $\alpha = 0.05$) la hipótesis de que las dos poblaciones tienen la misma distribución; entonces, tenemos una prueba de dos colas con valores críticos z de 1.96 y -1.96. El estadístico de prueba de $z = 3.67$ cae dentro de la región crítica, por lo que rechazamos la hipótesis nula de que los libros de Rowling y de Tolstoi tienen las mismas calificaciones de lectura. Parece que las páginas de Rowling y de Tolstoi provienen de poblaciones con distribuciones diferentes. Puesto que los rangos más bajos parecen ocurrir, en su mayoría, en los valores de Tolstoi, parece que Tolstoi obtuvo calificaciones significativamente más bajas de facilidad de lectura. Esto sugiere que *La guerra y la paz*, de Tolstoi, suele ser más difícil de leer que *Harry Potter y la piedra filosofal*, de Rowling.

Verifiquemos que si intercambiamos los dos conjuntos de valores muestrales y consideramos que la muestra de Tolstoi es la primera, $R = 88.5$, $\mu_R = 156$, $\sigma_R = 18.385$ y $z = -3.67$; por lo tanto, la conclusión es exactamente la misma.



Brecha de género en las pruebas de fármacos

Un estudio de la relación entre los ataques cardiacos y las dosis de aspirina incluyó a 22,000 médicos hombres. Este estudio, como muchos otros, excluyó a las mujeres. La General Accounting Office criticó hace poco a los National Institutes of Health por no incluir a ambos sexos en muchos estudios, ya que los resultados de pruebas médicas en hombres no necesariamente se aplican a las mujeres. Por ejemplo, los corazones de las mujeres son diferentes de los de los hombres en muchos aspectos importantes. Cuando se sacan conclusiones con base en resultados muestrales, debemos ser cuidadosos al generalizar las inferencias a una población más grande que aquella de la cual se obtuvo la muestra.



EJEMPLO Lluvia en miércoles y sábado El problema del capítulo se refirió a las cantidades de lluvia en Boston, listadas en el conjunto de datos 11 en el Apéndice B. El problema del capítulo incluye gráficas de cuadro de las cantidades de lluvia para los siete días de la semana, iniciando con el lunes en la parte superior. Las comparaciones de tales gráficas de cuadro indican que el miércoles y el sábado parecen ser los dos días que más difieren. Pero ¿son significativas dichas diferencias? Utilice la prueba de la suma de rangos de Wilcoxon para probar la aseveración de que las cantidades de precipitación pluvial de los miércoles y los sábados provienen de la misma distribución.

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Las cantidades de lluvia del miércoles y del sábado provienen de poblaciones con la misma distribución.

H_1: Las dos distribuciones son diferentes en alguna forma.

En lugar de calcular manualmente las sumas de los rangos, nos remitimos a la pantalla de Minitab que se muestra aquí. En esta pantalla de Minitab,

continúa

"ETA1" y "ETA2" denotan la mediana de la primera muestra y la mediana de la segunda muestra, respectivamente. La pantalla sugiere que estamos probando la hipótesis nula de medianas iguales, pero la prueba de la suma de rangos de Wilcoxon se basa en las distribuciones completas, no sólo en las medianas. He aquí los componentes clave de la pantalla del Minitab: la suma de rangos para el miércoles es M = 2639.0, el valor P es 0.2773 (o 0.1992 después de un ajuste por los empates) y la conclusión es que no podemos rechazar (la hipótesis nula) con un nivel de significancia de 0.05. Conclusión final: las diferencias entre el miércoles y el sábado no son significativas. Esto parece contradecir los reportes de los medios de comunicación de que llueve más durante los fines de semana, pero consideraremos de nuevo este tema en la siguiente sección.

Minitab

```
WED        N =  53     Median =      0.0000
SAT        N =  52     Median =      0.0000
Point estimate for ETA1-ETA2 is      0.0000
95.1 Percent CI for ETA1-ETA2 is (0.0000,0.0000)
W = 2639.0
Test of ETA1 = ETA2  vs  ETA1 not = ETA2 is significant at 0.2773
The test is significant at 0.1992 (adjusted for ties)

Cannot reject at alpha = 0.05
```



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Wilcoxon Tests**, seguida por la opción **Rank-Sum Test**. Ingrese los datos muestrales en el cuadro de diálogo y luego haga clic en **Evaluate** para obtener una pantalla, que incluye las sumas de rangos, el tamaño muestral, el estadístico de prueba, el valor crítico y la conclusión.

Minitab Primero ingrese los dos conjuntos de datos muestrales en las columnas C1 y C2. Luego seleccione las opciones **Stat**, **Nonparametrics** y **Mann-Whitney**; ahora proceda a ingresar C1 para la primera muestra y C2 para la segunda muestra. El nivel de confianza de 95.0 corresponde a un nivel de significancia de $\alpha = 0.05$, en tanto que el cuadro "alternate: not equal" se refiere a la hipótesis alternativa, donde "not equal" corresponde a una prueba de hipótesis de dos colas. Minitab produce el valor P y la conclusión. Véase la pantalla de muestra de Minitab que se incluye en el ejemplo anterior.

Excel Excel no está programado para la prueba de la suma de rangos de Wilcoxon.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de la suma de rangos de Wilcoxon.

12-4 Destrezas y conceptos básicos

Identificación de las sumas de rangos. *En los ejercicios 1 y 2, utilice un nivel de significancia de 0.05 con los métodos de esta sección para identificar las sumas de rangos R_1 y R_2, μ_R, σ_R, el estadístico de prueba z y los valores críticos z; luego establezca la conclusión.*

1. Valores de la muestra 1: 1 3 4 6 8 12 15 16 17 22 26
Valores de la muestra 2: 2 5 7 9 11 13 14 18 19 20 25 26

2.

Valores de la muestra 1:	1	3	4	6	8	12	15	16	17	22	26
Valores de la muestra 2:	22	25	28	33	34	35	37	39	41	43	45

Uso de la prueba de la suma de rangos de Wilcoxon. *En los ejercicios 3 a 10, utilice la prueba de la suma de rangos de Wilcoxon.*

3. ¿Se relacionan los trastornos psiquiátricos severos con factores biológicos? Un estudio utilizó tomografía computadorizada (TC) por rayos X para reunir datos de volúmenes cerebrales de un grupo de pacientes con trastorno obsesivo compulsivo y un grupo control de personas saludables. La lista adjunta presenta los resultados muestrales (en mililitros) para volúmenes del hemisferio derecho (datos que se tomaron de "Neuroanatomical Abnormalities in Obsesive-Compulsive Disorder Detected with Quantitative X-Ray Computed Tomography", de Luxenberg *et al.*, *American Journal of Psychiatry*, vol. 145, núm. 9). Utilice un nivel de significancia de 0.01 y pruebe la aseveración de que los pacientes obsesivo-compulsivos y las personas saludables tienen los mismos volúmenes cerebrales. Con base en este resultado, ¿concluiríamos que el trastorno obsesivo compulsivo tiene una base biológica?

Pacientes obsesivo compulsivos				**Grupo control**			
0.308	0.210	0.304	0.344	0.519	0.476	0.413	0.429
0.407	0.455	0.287	0.288	0.501	0.402	0.349	0.594
0.463	0.334	0.340	0.305	0.334	0.483	0.460	0.445

4. Prueba del efecto de anclaje Se pidió a estudiantes de estadística, seleccionados aleatoriamente, que en cinco segundos estimaran el valor de un producto de números con los resultados que vienen en la tabla adjunta. (Véanse las "Actividades de cooperación en equipo", al final del capítulo 2). ¿Hay suficiente evidencia para sustentar la aseveración de que las dos muestras provienen de poblaciones con distribuciones diferentes?

Estimados de estudiantes a los que se les pidió calcular $1 \times 2 \times 3 \times 4 \times 5 \times 6 \times 7 \times 8$

1560	169	5635	25	842	40,320	5000	500	1110	10,000
200	1252	4000	2040	175	856	42,200	49,654	560	800

Estimados de estudiantes a los que se les pidió calcular $8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1$

100,000	2000	42,000	1500	52,836	2050	428	372	300	225	64,582
23,410	500	1200	400	49,000	4000	1876	3600	354	750	640

5. ¿Afecta el orden de las preguntas de examen la calificación? Se estudió el orden de preguntas de examen para ver su efecto en la ansiedad. Los resultados muestrales se listan abajo. Utilizando un nivel de significancia de 0.05, pruebe la aseveración de que las dos muestras provienen de poblaciones con las mismas calificaciones. (Los datos se basan en "Item Arrangement, Cognitive Entry Characteristics, Sex and Test Anxiety as Predictors of Achievement Examination Performance", de Klimko, *Journal of Experimental Education*, vol. 52, núm. 4.)

Fácil a difícil				**Difícil a fácil**			
24.64	39.29	16.32	32.83	33.62	34.02	26.63	30.26
28.02	33.31	20.60	21.13	35.91	26.68	29.49	35.32
26.69	28.90	26.43	24.23	27.24	32.34	29.34	33.53
7.10	32.86	21.06	28.89	27.62	42.91	30.20	32.54
28.71	31.73	30.02	21.96				
25.49	38.81	27.85	30.29				
30.72							

6. Prueba de poblaciones idénticas de dulces M&M rojos y cafés Abajo se listan los pesos (en gramos) de dulces M&M que se tomaron del conjunto de datos 19 del Apéndice B. Utilice un nivel de significancia de 0.05, y pruebe la aseveración de que los dulces M&M clásicos rojos y cafés tienen pesos con la misma distribución. Esto es, pruebe la aseveración de que las poblaciones de dulces M&M clásicos rojos y cafés son idénticas.

Rojos:	0.870	0.933	0.952	0.908	0.911	0.908	0.913	0.983	0.920
	0.936	0.891	0.924	0.874	0.908	0.924	0.897	0.912	0.888
	0.872	0.898	0.882						
Cafés:	0.932	0.860	0.919	0.914	0.914	0.904	0.930	0.871	1.033
	0.955	0.876	0.856	0.866	0.858	0.988	0.936	0.930	0.923
	0.867	0.965	0.902	0.928	0.900	0.889	0.875	0.909	0.976
	0.921	0.898	0.897	0.902	0.920	0.909			

T **7.** Facilidad de lectura de Rowling y Tolstoi Un ejemplo de esta sección utilizó las puntuaciones de facilidad de lectura de Flesch para páginas que se seleccionaron aleatoriamente de *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. (Ese ejemplo incluyó un valor muestral adicional que no se lista en el Apéndice B). Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones del grado de Flesch-Kincaid para las páginas de Rowling y Tolstoi. Con un nivel de significancia de 0.05, pruebe la aseveración de que las dos muestras provienen de poblaciones con la misma distribución.

T **8.** Récord de jonrones Remítase a las distancias de los jonrones que anotaron Barry Bonds y Mark McGwire en el conjunto de datos 30 del Apéndice B. Considerando que estas distancias son datos muestrales, utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las muestras de Bonds y McGwire provienen de poblaciones con la misma distribución.

T **9.** Polizones del *Queen Mary* Remítase al conjunto de datos 15 del Apéndice B, utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las edades de los polizones de la costa oeste de Estados Unidos y las edades de los polizones de la costa este provienen de poblaciones con la misma distribución.

T **10.** Índice de masa corporal (IMC) Remítase al conjunto de datos 1 del Apéndice B de los valores de índice de masa corporal para hombres y mujeres. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las dos muestras de valores de IMC provienen de poblaciones con la misma distribución.

12-4 Más allá de lo básico

11. Uso de la prueba U de Mann-Whitney La prueba U de Mann-Whitney es equivalente a la prueba de la suma de rangos de Wilcoxon para muestras independientes, ya que ambas se aplican a las mismas situaciones y siempre llevan a las mismas conclusiones. En la prueba U de Mann-Whitney calculamos

$$z = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

donde

$$U = n_1 n_2 + \frac{n_1 (n_1 + 1)}{2} - R$$

Utilice las mediciones de facilidad de lectura de Rowling y Tolstoi que se listan en la tabla 12-4 de esta sección y calcule el estadístico de prueba z para la prueba U de Mann-Whitney y compárelo con el estadístico de prueba z de 3.67 que se calculó utilizando la prueba de la suma de rangos de Wilcoxon.

12. Cálculo de valores críticos Suponga que tenemos dos tratamientos (A y B), que producen resultados cuantitativos, y tenemos sólo dos observaciones del tratamiento A y dos observaciones del tratamiento B. No podemos utilizar el estadístico de prueba dado en esta sección, ya que los tamaños muestrales no exceden a 10.

Rango				Suma de rangos del tratamiento A
1	2	3	4	
A	A	B	B	3

a. Complete la tabla adjunta, listando los cinco renglones que corresponden a los otros cinco casos y registre las sumas de rangos correspondientes del tratamiento A.

b. Haga una lista de los valores posibles de R, junto con sus probabilidades correspondientes. [Suponga que los renglones de la tabla del inciso *a* son igualmente probables].

c. ¿Es posible, con un nivel de significancia de 0.10, rechazar la hipótesis nula de que no hay diferencia entre los tratamientos A y B? Explique.

12-5 Prueba de Kruskal-Wallis

Esta sección introduce la *prueba de Kruskal-Wallis*, que se utiliza para probar la hipótesis nula de que tres o más muestras independientes provienen de poblaciones idénticas. En la sección 11-2 utilizamos el análisis de varianza de un factor (ANOVA) para probar la hipótesis nula de que tres o más poblaciones tienen la misma media, pero el ANOVA requiere que todas las poblaciones implicadas tengan distribuciones normales. La prueba de Kruskal-Wallis no requiere distribuciones normales.

Definición

Prueba de Kruskal-Wallis (también se le llama **prueba *H***): Es una prueba no paramétrica que utiliza rangos de datos muestrales de tres o más poblaciones independientes. Se emplea para probar la hipótesis nula de que las muestras independientes provienen de poblaciones con la misma distribución; la hipótesis alternativa es la aseveración de que las distribuciones poblacionales son diferentes en alguna forma.

H_0: Las muestras provienen de poblaciones con la misma distribución.

H_1: Las muestras provienen de poblaciones con distribuciones diferentes.

En la aplicación de la prueba de Kruskal-Wallis, calculamos el *estadístico de prueba H, el cual tiene una distribución que puede aproximarse por la distribución chi cuadrada, siempre y cuando cada muestra tenga al menos cinco observaciones*. Cuando utilizamos la distribución chi cuadrada en este contexto, el número de grados de libertad es $k - 1$, donde k es el número de muestras. (Para una revisión rápida de las características clave de la distribución chi cuadrada, véase la sección 6-5).

Procedimiento para calcular el valor del estadístico de prueba *H*

1. Combine temporalmente todas las muestras en una muestra grande y asigne un rango a cada valor muestral. (Acomode los valores del más bajo al más alto; en caso de empates, asigne a cada observación la media de los rangos implicados).
2. En cada muestra, calcule la suma de los rangos y el tamaño muestral.
3. Calcule H utilizando los resultados del paso 2, con la notación y el estadístico de prueba que vienen en el siguiente recuadro.

Prueba de Kruskal-Wallis

Supuestos

1. Tenemos al menos tres muestras independientes, que se seleccionan aleatoriamente.
2. Cada muestra tiene al menos cinco observaciones. (Si las muestras tienen menos de cinco observaciones, remítase a tablas especiales de valores críticos, como las *CRC Standard Probability and Statistics Tables and Formulae*, publicadas por CRC Press).
3. No existe el requisito de que las poblaciones tengan una distribución normal o cualquiera otra distribución particular.

Notación

N = número total de observaciones en todas las muestras que se combinaron

k = número de muestras

R_1 = suma de los rangos de la muestra 1

n_1 = número de observaciones de la muestra 1

Para la muestra 2, la suma de los rangos es R_2 y el número de observaciones es n_2; se utiliza una notación similar para las otras muestras.

Estadístico de prueba

$$H = \frac{12}{N(N+1)}\left(\frac{R_1^2}{n_1} + \frac{R_2^2}{n_2} + \cdots + \frac{R_k^2}{n_k}\right) - 3(N+1)$$

Valores críticos

1. La prueba es de *cola derecha*.
2. gl = $k - 1$. (Puesto que el estadístico de prueba H puede aproximarse por una distribución chi cuadrada, utilice la tabla A-4 con $k - 1$ grado de libertad, donde k es el número de muestras diferentes).

El estadístico de prueba H es básicamente una medida de la varianza de las sumas de rangos $R_1, R_2, \ldots, R_k$. Si los rangos se distribuyen de manera equitativa entre los grupos muestrales, entonces H debe ser un número relativamente pequeño. Si las muestras son muy diferentes, luego los rangos serán excesivamente bajos en algunos grupos y altos en otros, con el efecto neto de que H será grande. En consecuencia, sólo los valores grandes de H nos llevan al rechazo de la hipótesis nula de que las muestras provienen de poblaciones idénticas. *La prueba de Kruskal-Wallis es, por lo tanto, una prueba de cola derecha.*

EJEMPLO Clancy, Rowling y Tolstoi El conjunto de datos 14 del Apéndice B incluye datos obtenidos de 12 páginas que se seleccionaron aleatoriamente de tres libros diferentes: *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling; y *La guerra y la paz*, de León Tolstoi. Se obtuvo la puntuación de facilidad de lectura de Flesch para cada una de estas obras; los resultados se listan en la tabla 12-5. El sistema de puntuación de facilidad de lectura de Flesch da como resultado calificaciones más altas para el texto que es más fácil de leer. Las calificaciones bajas resultan de trabajos que son más difíciles de leer. En la sección 11-2 utilizamos el análisis de varianza para probar la hipótesis nula de que tres muestras de puntuaciones de lectura provienen de poblaciones con la misma media. Ahora usaremos la prueba de Kruskal-Wallis, con la hipótesis nula de que tres muestras provienen de poblaciones con la misma distribución.

Tabla 12-5 Calificaciones de facilidad de lectura

Clancy	Rowling	Tolstoi
58.2 (4)	85.3 (34)	69.4 (10.5)
73.4 (19)	84.3 (32)	64.2 (6)
73.1 (18)	79.5 (28)	71.4 (13)
64.4 (7)	82.5 (30)	71.6 (14)
72.7 (16)	80.2 (29)	68.5 (9)
89.2 (36)	84.6 (33)	51.9 (2)
43.9 (1)	79.2 (27)	72.2 (15)
76.3 (23)	70.9 (12)	74.4 (22)
76.4 (24)	78.6 (25)	52.8 (3)
78.9 (26)	86.2 (35)	58.4 (5)
69.4 (10.5)	74.0 (21)	65.4 (8)
72.9 (17)	83.7 (31)	73.6 (20)
$n_1 = 12$	$n_2 = 12$	$n_3 = 12$
$R_1 = 201.5$	$R_2 = 337$	$R_3 = 127.5$

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Las poblaciones de calificaciones de facilidad de lectura para las páginas de los tres libros son idénticas.

H_1: Las tres poblaciones no son idénticas.

Para determinar el valor del estadístico de prueba H, primero tenemos que ordenar en rangos todos los datos. Comenzamos con el valor más bajo de 43.9, al cual se le asigna un rango de 1. En la tabla 12-5 los rangos se muestran entre paréntesis con las calificaciones de facilidad de lectura originales. Después calculamos el tamaño muestral, n, y la suma de rangos, R, para cada muestra. Estos valores se listan al final de la tabla 12-5. Puesto que el número total de

continúa

observaciones es 36, tenemos $N = 36$. Ahora evaluamos el estadístico de prueba como sigue:

$$H = \frac{12}{N(N+1)}\left(\frac{R_1^2}{n_1} + \frac{R_2^2}{n_2} + \cdots + \frac{R_k^2}{n_k}\right) - 3(N+1)$$
$$= \frac{12}{36(36+1)}\left(\frac{201.5^2}{12} + \frac{337^2}{12} + \frac{127.5^2}{12}\right) - 3(36+1)$$
$$= 16.949$$

Ya que cada muestra tuvo al menos cinco observaciones, la distribución de H es aproximadamente una distribución chi cuadrada con $k - 1$ grados de libertad. El número de muestras es $k = 3$; entonces, tenemos $3 - 1$ grados de libertad. Remítase a la tabla A-4 para encontrar el valor crítico de 5.991, que corresponde a 2 grados de libertad y a un nivel de significancia de 0.05 (con un área de 0.05 en la cola derecha).

El estadístico de prueba $H = 16.949$ está en la región crítica acotada por 5.991; por lo tanto, rechazamos la hipótesis nula de poblaciones idénticas. (En la sección 11-2, rechazamos la hipótesis nula de medias iguales).

INTERPRETACIÓN Hay suficiente evidencia para sustentar la conclusión de que las poblaciones de calificaciones de facilidad de lectura para las páginas de los tres libros no son idénticas. Los libros parecen tener calificaciones de facilidad de lectura diferentes. Examinando las sumas de rangos, vemos que Tolstoi tuvo la suma de rangos más baja, lo que sugiere que su libro es el más difícil de leer. Rowling tiene la suma de rangos más alta, lo que sugiere que su libro es el más fácil de leer de los tres.



EJEMPLO ¿Llueve más durante los fines de semana? En el problema del capítulo señalamos que los medios de comunicación reportaron que llueve más durante los fines de semana, a lo largo de la costa este de Estados Unidos, desde Maine hasta Florida. El conjunto de datos 11 del Apéndice B incluye cantidades de lluvia en un año reciente en Boston. Utilizando ese conjunto de datos, pruebe la aseveración de que los siete días de la semana tienen distribuciones que no son las mismas.

SOLUCIÓN Parecería que es conveniente someter el conjunto de datos 11 a los métodos de análisis de varianza que se introducen en la sección 11-2, pero esos métodos requieren que los valores muestrales provengan de poblaciones con distribuciones que sean aproximadamente normales. El problema del capítulo incluye un histograma para las cantidades de lluvia del lunes, por lo que es evidente que no hay una distribución normal. Los histogramas de los otros días de la semana tienen la misma forma básica que la del lunes. Puesto que los datos no indican distribuciones normales, no es posible utilizar el análisis de varianza, por lo cual la prueba de Kruskal-Wallis resulta una alternativa ideal. El conjunto de datos 11 incluye datos para cada uno de los 365 días, de forma que estamos tratando con conjuntos de datos grandes; en consecuencia, los cálculos manuales serían muy engorrosos. En lugar de ello utilizaremos un programa de cómputo. Abajo se muestran las últimas dos líneas de la pantalla de Minitab. (Véase el ejercicio 11, donde se presenta la corrección a utilizar cuando hay muchos valores muestrales empatados).

Minitab

```
H = 2.78  DF = 6  P = 0.836
H = 3.85  DF = 6  P = 0.697 (adjusted for ties)
```

No rechazamos la hipótesis nula de distribuciones idénticas, puesto que el valor P de Minitab es mayor que un nivel razonable de significancia de 0.05. El STATDISK produjo un estadístico de prueba $H = 2.7806$ y un valor crítico de 12.592; además, incluye la conclusión de "no rechazo de la hipótesis nula". No hay suficiente evidencia para sustentar la aseveración de que las cantidades de lluvia durante los siete días de la semana tienen distribuciones distintas. Las cantidades de lluvia parecen ser las mismas durante los diferentes días de la semana.

INTERPRETACIÓN Con base en las cantidades de lluvia de Boston, no parece haber evidencia que sustente la aseveración de que llueve más durante los fines de semana. Por lo tanto, ¿cómo es que los reportes del periódico, las revistas y la televisión nos hagan creer que llueve más los fines de semana? Los científicos Randall S. Cerveny y Robert C. Balling, de la Arizona State University, realizaron el estudio original. ¿Es posible culparlos de brindar información falsa? No. El autor contactó a Randall Cerveny, quien afirmó que el documento original incluyó la lluvia lejos de la costa del Atlántico, no la lluvia que se asocia con alguna ciudad en particular. Cerveny y Balling utilizaron estimados de lluvia satelitales y encontraron que ciertas áreas en el océano y cerca de la costa tuvieron mayor precipitación pluvial los fines de semana, es decir, explican este fenómeno por su relación con la contaminación que viene de las regiones costeras. Sus descubrimientos son interesantes y significativos. Los medios de comunicación malinterpretaron las conclusiones de Cerveny y Balling, pues dieron reportes que indicaban que llueve más los fines de semana para quienes vivimos en tierra, junto a la costa del Atlántico. Se trata de un caso interesante de una mala interpretación hecha por los medios de comunicación de los resultados de los estudios.

Fundamentos: El estadístico de prueba H, como se presentó, es la versión con rangos del estadístico de prueba F que se utiliza en el análisis de varianza que se estudió en el capítulo 11. Cuando tratamos con rangos R, en lugar de valores x originales, muchos componentes están predeterminados. Por ejemplo, la suma de todos los rangos se expresa como $N(N+1)/2$, donde N es el número total de valores en todas las muestras combinadas. La expresión

$$H = \frac{12}{N(N+1)} \Sigma n_i (\overline{R}_i - \overline{\overline{R}})^2$$

donde

$$\overline{R}_i = \frac{R_i}{n_i} \quad \overline{\overline{R}} = \frac{\Sigma R_i}{\Sigma n_i}$$

combina varianzas ponderadas de rangos para producir el estadístico de prueba H que se dio aquí. Tal expresión de H es equivalente algebraicamente a la expresión de H que se dio antes como estadístico de prueba. La forma anterior de H (no la que se dio aquí) es más sencilla de aplicar. Al comparar los procedimientos de la prueba paramétrica F con la prueba no paramétrica de Kruskal-Wallis, veremos que, en ausencia de programas de cómputo, la prueba de Kruskal-Wallis es mucho más simple de aplicar. No necesitamos calcular las varianzas muestrales ni las me-

dias muestrales. Tampoco requerimos distribuciones poblacionales normales. La vida se vuelve mucho más fácil. Sin embargo, la prueba de Kruskal-Wallis no es tan eficiente como la prueba F, de manera que requeriría de diferencias más marcadas para el rechazo de la hipótesis nula.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Kruskal-Wallis Test** y proceda a ingresar una copia de los datos muestrales en el cuadro de diálogo. STATDISK mostrará en la pantalla la suma de los rangos para cada muestra, el estadístico de prueba H, el valor crítico y la conclusión.

Minitab Remítase al manual *Minitab Student Laboratory Manual and Workbook* para ver el procedimiento que se requiere para utilizar las opciones **Stat**, **Nonparametrics** y **Kruskal-Wallis**. La idea básica es hacer una lista de todos los datos muestrales en una gran columna, con otra columna que identifique la muestra para los valores correspondientes. Para los datos de facilidad de lectura de la tabla 12-5, ingrese las 36 calificaciones en la columna C1 del Minitab y los 12 valores de Clancy, seguidos por los 12 valores de Rowling, y después los 12 valores de Tolstoi. En la columna C2, ingrese 12 números 1 seguidos por 12 números 2 y después por 12 números 3. Ahora seleccione **Stat**, **Nonparametrics** y **Kruskal-Wallis**. En el cuadro de diálogo, ingrese C1 como respuesta, C2 como factor y haga clic en **OK**. La pantalla de Minitab incluye el estadístico de prueba H y el valor P.

Excel Excel no está programado para la prueba de Kruskal-Wallis.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de Kruskal-Wallis.

12-5 Destrezas y conceptos básicos

Interpretación de resultados de la prueba de Kruskal-Wallis. *En los ejercicios 1 y 2, interprete los resultados de la prueba de Kruskal-Wallis y resuelva la pregunta.*

1. Tiempos de maratón Los tiempos de carrera de los hombres en la carrera de maratón de la ciudad de Nueva York se listan en el conjunto de datos 8 del Apéndice B. Cuando estos tiempos de carrera se dividen en categorías, con edades de 21 a 29, 30 a 39 y 40 o mayores, los resultados de la prueba de Kruskal-Wallis de Minitab son los que se presentan más adelante. ¿Los tiempos de carrera para los diferentes grupos de edad parecen provenir de poblaciones idénticas?

Minitab

```
H = 0.56  DF = 2  P = 0.747
```

2. ¿El Old Faithful cambia con el tiempo? Se registraron 12 diferentes intervalos de tiempo (en minutos) entre las erupciones del géiser Old Faithful en 1951, 1985 y 1996. (Los datos provienen del geólogo Rick Hutchinson y del National Park Service). Cuando se utiliza Minitab con la prueba de Kruskal-Wallis, los resultados son los que se presentan más adelante. ¿Tienen los diferentes años intervalos de tiempo con poblaciones idénticas? ¿Parece que el comportamiento de las erupciones del Old Faithful cambia con el tiempo?

Minitab

```
H = 11.93  DF = 2  P = 0.003
```

Uso de la prueba de Kruskal-Wallis. *En los ejercicios 3 a 8, utilice la prueba de Kruskal-Wallis.*

3. ¿Afecta el peso de un automóvil las heridas en la cabeza que se producen en un choque? Se obtuvieron datos de experimentos de choques realizados por la National Transportation Safety Administration. Se compraron automóviles nuevos y se hicieron estrellar contra una barrera fija a 35 millas/hora. Las mediciones se registraron en un maniquí que se colocó en el asiento del conductor. Utilice los datos muestrales que se listan más adelante para probar las diferencias en las mediciones de heridas en la cabeza en cuatro categorías de peso. ¿Hay evidencia suficiente para concluir que las mediciones de heridas en la cabeza para las cuatro categorías de peso de automóviles no son las mismas? ¿Sugieren los datos que los automóviles más pesados son más seguros en un choque?

Subcompacto:	681	428	917	898	420
Compacto:	643	655	442	514	525
Mediano:	469	727	525	454	259
Grande:	384	656	602	687	360

4. ¿La energía solar es la misma todos los días? Una alumna del autor vive en una casa con sistema eléctrico solar. A la misma hora de cada día, ella reúne lecturas de voltaje con un medidor conectado al sistema; los resultados se listan en la tabla adjunta. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las lecturas de voltaje son las mismas para los tres diferentes tipos de día. ¿Hay suficiente evidencia para sustentar una aseveración de distribuciones poblacionales diferentes? Esperaríamos que un sistema solar proporcione más energía eléctrica en días soleados que en días nublados o lluviosos. ¿Concluiríamos que los días soleados dan como resultado mayores cantidades de energía eléctrica?

5. Prueba de diferencias de amplitud craneana en distintas épocas Los valores adjuntos son amplitudes máximas medidas de cráneos de hombres egipcios de diferentes épocas (datos tomados de *Ancient Races of the Thebaid*, de Thomson y Randall-Maciver). Los cambios en la forma de la cabeza a través del tiempo sugieren que ocurrió mestizaje con poblaciones inmigrantes. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las tres muestras provienen de poblaciones idénticas. ¿Sugieren los datos un mestizaje de culturas?

6. Prueba de laboratorio de inflamabilidad de ropa de dormir para niños Se realizaron pruebas de inflamabilidad en ropa de dormir para niños. Se utilizó la prueba Vertical Semirestrained, consistente en la quema de piezas de tela en condiciones bajo control. Después de detener la combustión, se midió y registró la longitud de la porción que se quemó. Al margen se presentan los resultados para la misma tela que se probó en laboratorios diferentes. Puesto que se utilizó la misma tela, los diferentes laboratorios deberían obtener los mismos resultados. ¿Fue así?

T **7.** ¿El peso de todos los colores de los dulces M&M es el mismo? Remítase al conjunto de datos 19 del Apéndice B. Con un nivel de significancia de 0.05, pruebe la aseveración de que los pesos de los dulces M&M son los mismos para cada una de las seis poblaciones de colores diferentes. Si la intención de Mars, Inc., es hacer los dulces para que las diferentes poblaciones de color sean las mismas, ¿sugieren sus resultados que la compañía tiene un problema que requiere de una acción correctiva?

T **8.** Distancias de jonrones Remítase al conjunto de datos 30 del Apéndice B. Considere que las distancias de jonrones son muestras seleccionadas aleatoriamente a partir de poblaciones. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las poblaciones de distancias de jonrones que conectaron Barry Bonds, Mark McGwire y Sammy Sosa son idénticas.

Datos para el ejercicio 4

Soleado	Nublado	Lluvioso
13.5	12.7	12.1
13.0	12.5	12.2
13.2	12.6	12.3
13.9	12.7	11.9
13.8	13.0	11.6
14.0	13.0	12.2

Datos para el ejercicio 5

4000 AC	1850 AC	150 DC
131	129	128
138	134	138
125	136	136
129	137	139
132	137	141
135	129	142
132	136	137
134	138	145
138	134	137

Datos para el ejercicio 6

Laboratorio				
1	2	3	4	5
2.9	2.7	3.3	3.3	4.1
3.1	3.4	3.3	3.2	4.1
3.1	3.6	3.5	3.4	3.7
3.7	3.2	3.5	2.7	4.2
3.1	4.0	2.8	2.7	3.1
4.2	4.1	2.8	3.3	3.5
3.7	3.8	3.2	2.9	2.8
3.9	3.8	2.8	3.2	
3.1	4.3	3.8	2.9	
3.0	3.4	3.5		
2.9	3.3			

12-5 Más allá de lo básico

9. Prueba del efecto de transformar los datos muestrales
- **a.** En general, ¿cómo se afecta el valor del estadístico de prueba H si se suma (o se resta) una constante a cada valor muestral?
- **b.** En general, ¿cómo se afecta el valor del estadístico de prueba H si cada valor muestral se multiplica (o divide) por una constante positiva?
- **c.** En general, ¿cómo se afecta el valor del estadístico de prueba H si un solo valor muestral se cambia para convertirse en un dato distante?

10. Cálculo de valores del estadístico de prueba Para tres muestras, cada una de tamaño 5, calcule los valores máximo y mínimo posibles del estadístico de prueba H.

11. Corrección del estadístico de prueba H por empates En el uso de la prueba de Kruskal-Wallis hay un factor de corrección, que debe aplicarse siempre que existan muchos empates: divida H entre

$$1 - \frac{\Sigma T}{N^3 - N}$$

Para cada grupo de observaciones empatadas en el conjunto de datos muestrales que se combinó, calcule $T = t^3 - t$, donde t es el número de observaciones que están empatadas en el grupo individual. Calcule t para cada grupo de valores empatados, luego el valor de T para cada grupo. Entonces, sume los valores T para obtener ΣT. El número total de observaciones en todas las muestras combinadas es N. Utilice este procedimiento para calcular el valor corregido de H para el ejercicio 4. ¿Difiere el valor corregido de H sustancialmente del valor que se calculó en el ejercicio 4?

12. Pruebas equivalentes Demuestre que, para el caso de dos muestras, la prueba de Kruskal-Wallis es equivalente a la prueba de la suma de rangos de Wilcoxon. Esto se logra demostrando que, para el caso de dos muestras, el estadístico de prueba H es igual al cuadrado del estadístico de prueba z que se utiliza en la prueba de la suma de rangos de Wilcoxon. Además, note que, con 1 grado de libertad, los valores críticos de χ^2 corresponden al cuadrado de la puntuación crítica z.

12-6 Correlación de rangos

En esta sección describimos cómo el método no paramétrico de correlación de rangos se utiliza con datos apareados para probar una asociación entre dos variables. En el capítulo 9 manejamos datos muestrales apareados para calcular valores del coeficiente de correlación lineal r, pero en esta sección emplearemos *rangos* como base para medir la fuerza de la correlación entre dos variables.

Definición

Prueba de correlación de rangos (o prueba de correlación de rangos de Spearman): es una prueba no paramétrica que utiliza rangos de datos muestrales consistentes en datos apareados. Se usa para probar una asociación entre dos variables, por lo que las hipótesis nula y alternativa son las siguientes (donde ρ_s denota el coeficiente de correlación de rangos de la población completa):

H_0: $\rho_s = 0$ (*No* existe correlación entre las dos variables).

H_1: $\rho_s \neq 0$ (Existe una correlación entre las dos variables).

Ventajas: La correlación de rangos tiene varias ventajas sobre los métodos paramétricos que se analizaron en el capítulo 9:

1. El método no paramétrico de correlación de rangos puede utilizarse en una variedad más amplia de circunstancias que el método paramétrico de correlación lineal. Con la correlación de rangos, analizamos datos apareados que sean rangos o puedan convertirse a rangos. Por ejemplo, si dos jueces califican el rango de 30 gimnastas diferentes, utilizaríamos la correlación de rangos, pero no la correlación lineal. A diferencia de los métodos paramétricos del capítulo 9, el método de correlación de rangos *no* requiere una distribución normal de la población.
2. La correlación de rangos puede utilizarse para detectar algunas de las relaciones (no todas) que no son lineales. (Se dará un ejemplo más adelante en esta sección).

Desventaja: Una desventaja de la correlación de rangos es su tasa de eficacia de 0.91, como se describe en la sección 12-1. Esta tasa de eficacia muestra que, con todas las demás circunstancias iguales, el método no paramétrico de correlación de rangos requiere de 100 pares de datos muestrales para obtener los mismos resultados que sólo 91 pares de observaciones muestrales que se analizan a través del método paramétrico, suponiendo que los requisitos más estrictos del método paramétrico se satisfacen.

Los supuestos, la notación, el estadístico de prueba y los valores críticos se resumen en el siguiente recuadro. Utilizamos la notación r_s para el coeficiente de correlación de rangos, con la finalidad de no confundirlo con el coeficiente de correlación lineal r. El subíndice s no tiene nada que ver con la desviación estándar, se usa en honor de Charles Spearman (1863-1945), quien desarrolló el método de correlación de rangos. De hecho, r_s suele llamarse **coeficiente de correlación de rangos de Spearman**. El procedimiento de la correlación de rangos se resume en la figura 12-4.

Correlación de rangos

Supuestos

1. Los datos muestrales apareados se seleccionaron aleatoriamente.
2. A diferencia de los métodos paramétricos de la sección 9-2, *no* existe el requisito de que los datos muestrales apareados tengan una distribución normal bivariada (como se describe en la sección 9-2). *No* existe el requisito de una distribución normal para la población.

Notación

r_s = coeficiente de correlación de rangos para datos muestrales apareados (r_s es un estadístico muestral)

ρ_s = coeficiente de correlación de rangos para todos los datos poblacionales (ρ_s es un parámetro poblacional)

n = número de pares de datos muestrales

d = diferencia entre los rangos de los dos valores dentro de un par

continúa



Vínculo directo entre el cigarro y el cáncer

Cuando hallamos una correlación estadística entre dos variables, debemos ser extremadamente cuidadosos para evitar el error de concluir que hay una conexión de causa y efecto. La industria tabacalera ha puesto énfasis, una y otra vez, en que la correlación no implica causalidad. Sin embargo, el doctor David Sidransky, de la John Hopkins University, dice que "tenemos pruebas moleculares tan fuertes que podemos tomar un cáncer individual y potencialmente, con base en los patrones de cambio genético, determinar si fumar cigarrillos fue la causa de ese cáncer". Según sus hallazgos, él agregó que "el fumador tuvo una incidencia mucho más alta de mutación, pero el segundo hecho que lo confirmó fue el patrón tan claro de mutaciones... así que ya teníamos la pistola humeante". Aunque los métodos estadísticos no pueden probar que fumar *causa* cáncer, con evidencia física del tipo descrito por el doctor Sidransky, es posible establecer demostraciones como ésta.

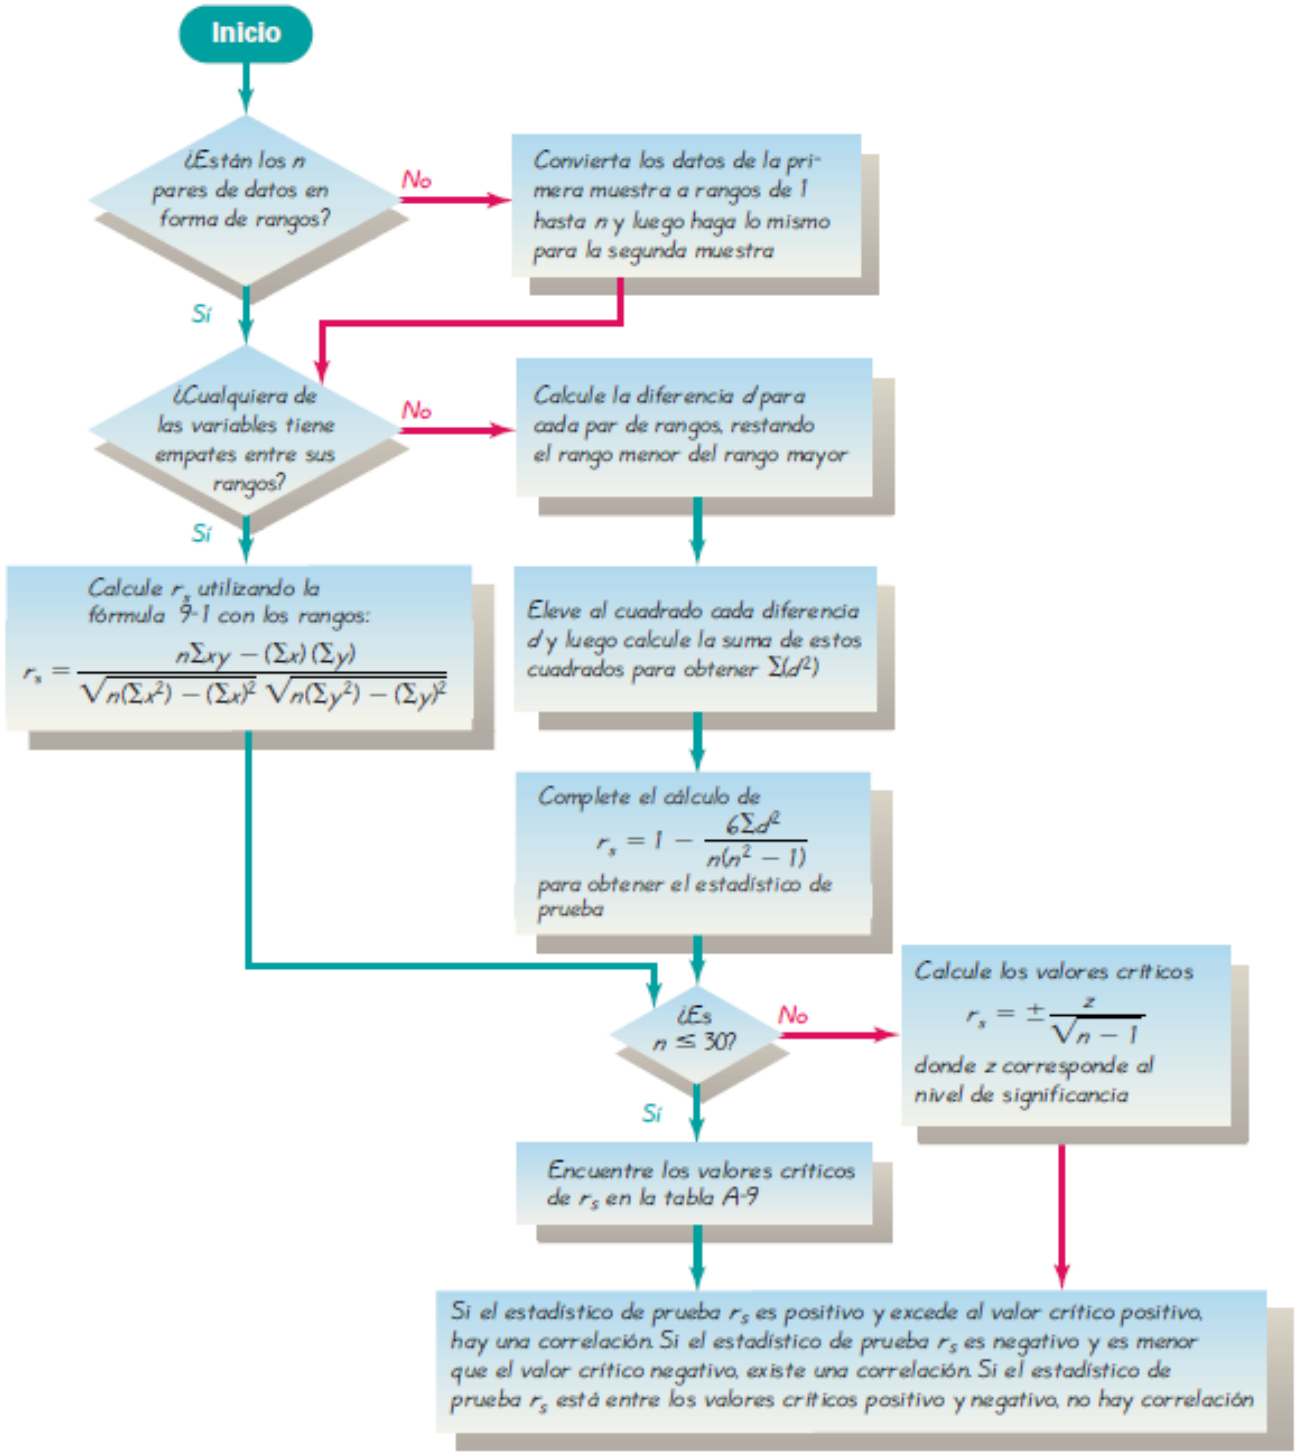


FIGURA 12-4 **Procedimiento de correlación de rangos para probar H_0: $\rho_s = 0$**

Estadístico de prueba

Sin empates: Después de convertir los datos de cada muestra a rangos, si no hay empates entre los rangos para la primera variable ni entre los rangos para la segunda variable, el valor exacto del estadístico de prueba se calcula utilizando esta fórmula:

$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)}$$

Empates: Después de convertir los datos de cada muestra a rangos, si cualquier variable tiene empates entre sus rangos, el valor exacto del estadístico de prueba r_s se calcula utilizando la fórmula 9-1 con los rangos:

$$r_s = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{\sqrt{n(\Sigma x^2) - (\Sigma x)^2}\sqrt{n(\Sigma y^2) - (\Sigma y)^2}}$$

Valores críticos

1. Si $n \leq 30$, los valores críticos se encuentran en la tabla A-9.
2. Si $n > 30$, los valores críticos de r_s se calculan utilizando la fórmula 12-1.

Fórmula 12-1 $$r_s = \frac{\pm z}{\sqrt{n - 1}}$$ (valores críticos cuando $n > 30$)

donde el valor de z corresponde al nivel de significancia.

EJEMPLO Percepción de belleza La revista *marie claire* pidió a hombres y mujeres que calificaran el grado de belleza de 10 mujeres diferentes, todas ellas bastante atractivas. ("¿Suele sorprenderse por lo que los hombres y las mujeres encuentran atractivo? Pedimos a 100 hombres y a 100 mujeres que calificaran el grado de belleza de estos rostros sumamente atractivos y explicaran exactamente lo que ellos encuentran atractivo"). La tabla 12-6 lista los rangos resultantes. ¿Hay una correlación entre las calificaciones de los hombres y las mujeres? La revista preguntó: "¿Los hombres y las mujeres están de acuerdo?". ¿Lo están? Utilice un nivel de significancia de $\alpha = 0.05$.

Tabla 12-6 Grado de belleza de 10 mujeres

Hombres	4	2	5	1	3	6	7	8	9	10	
Mujeres	2	6	7	3	1	10	4	8	5	9	
d	2	4	2	2	2	4	3	0	4	1	
d^2	4	16	4	4	4	16	9	0	16	1	→ Total = 74

SOLUCIÓN El coeficiente de correlación lineal r (sección 9-2) no debe utilizarse puesto que requiere de distribuciones normales y los datos consisten en rangos que no se distribuyen normalmente. En su lugar, utilizamos el coeficiente de correlación de rangos para probar una relación entre los rangos de hombres y de mujeres.

Las hipótesis nula y alternativa son las siguientes:

$$H_0: \quad \rho_s = 0$$
$$H_1: \quad \rho_s \neq 0$$

continúa

Siguiendo el procedimiento de la figura 12-4, los datos están en forma de rangos; ninguna de las dos variables (hombres y mujeres) tuvo empates entre los rangos; por lo tanto, el valor exacto del estadístico de prueba se calcula como se indica abajo. Utilizamos $n = 10$ (para 10 pares de datos) y $\Sigma d^2 = 74$ (como se indica en la tabla 12-4) para obtener

$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)} = 1 - \frac{6(74)}{10(10^2 - 1)}$$
$$= 1 - \frac{444}{990} = 0.552$$

Ahora nos remitimos a la tabla A-9 para determinar que los valores críticos son ± 0.648 (con base en $\alpha = 0.05$ y $n = 10$). Puesto que el estadístico de prueba $r_s = 0.552$ no excede al valor crítico de 0.648, no rechazamos la hipótesis nula. No hay suficiente evidencia para sustentar una aseveración de correlación entre las calificaciones de los hombres y de las mujeres. Parece que en asuntos de belleza los hombres y las mujeres no están de acuerdo. (Si estuvieran de acuerdo, habría una correlación significativa, pero no es así).

EJEMPLO Caso de muestra grande Suponga que el ejemplo anterior se expande, incluyendo un total de 40 mujeres, y que se encuentra que el estadístico de prueba r_s es 0.291. Si el nivel de significancia es $\alpha = 0.05$, ¿qué concluye acerca de la correlación?

SOLUCIÓN Puesto que hay 40 pares de datos, tenemos $n = 40$. Puesto que n excede de 30, calculamos los valores críticos con la fórmula 12-1, en lugar de emplear la tabla A-9. Con $\alpha = 0.05$ en dos colas, permitimos que $z = 1.96$ para obtener

$$r_s = \frac{\pm 1.96}{\sqrt{40 - 1}} = \pm 0.314$$

El estadístico de prueba $r_s = 0.291$ no excede al valor crítico de 0.314; por lo tanto, no rechazamos la hipótesis nula. No hay suficiente evidencia para sustentar la aseveración de una correlación entre hombres y mujeres.

El siguiente ejemplo tiene la intención de ilustrar el principio de que la correlación de rangos algunas veces se utiliza para detectar relaciones que no son lineales.

EJEMPLO Detección de un patrón no lineal Se utiliza una máquina de pinball *Raiders of the Lost Ark* (modelo L-7) para medir el aprendizaje que resulta de repetir funciones manuales. Los sujetos se seleccionaron para que fueran similares en características importantes de edad, género, inteligencia, educación, etcétera. La tabla 12-7 lista los números de juegos que se realizaron y las últimas puntuaciones (en millones) de sujetos seleccionados al azar del grupo con características similares. Esperamos que ahí haya una asociación entre el número de juegos que se realizaron y la puntuación del pinball. ¿Existe suficiente evidencia para sustentar la aseveración de que hay una asociación como ésta?

SOLUCIÓN Probaremos la hipótesis nula de no correlación de rangos ($\rho_s = 0$).

H_0: $\rho_s = 0$ (sin correlación)
H_1: $\rho_s \neq 0$ (correlación)

Tabla 12-7 Puntuaciones de pinball (rangos entre paréntesis)

Número de juegos	9 (2)	13 (4)	21 (5)	6 (1)	52 (7)	78 (8)	33 (6)	11 (3)	120 (9)
Puntuación	22 (2)	62 (4)	70 (6)	10 (1)	68 (5)	73 (8)	72 (7)	58 (3)	75 (9)
d	0	0	1	0	2	0	1	0	0
d^2	0	0	1	0	4	0	1	0	0

Remítase a la figura 12-4, la cual seguimos para esta solución. Las puntuaciones originales no son rangos, por lo cual las convertimos a rangos e introdujimos los resultados entre paréntesis en la tabla 12-7. (La sección 12-1 describe el procedimiento para convertir puntuaciones en rangos).

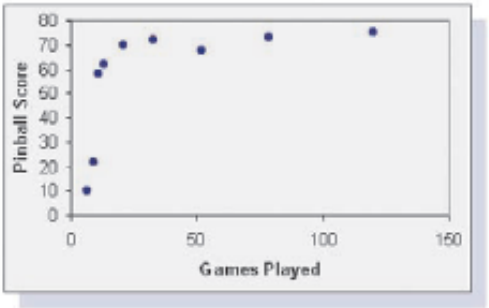
Después de expresar todos los datos como rangos, calculamos las diferencias d y luego las elevamos al cuadrado. La suma de los valores de d^2 es 6. Ahora calculamos

$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)} = 1 - \frac{6(6)}{9(9^2 - 1)}$$
$$= 1 - \frac{36}{720} = 0.950$$

Continuando con la figura 12-4, tenemos $n = 9$, por lo que respondemos sí cuando se pregunta si $n \leq 30$. Utilizamos la tabla A-9 para obtener los valores críticos de ± 0.683. Finalmente, el estadístico muestral de 0.950 excede a 0.683; por lo tanto, concluimos que hay una correlación significativa. Los números más altos de juegos parecen asociarse con puntuaciones más altas. Los sujetos parecen aprender mejor el juego al jugar más.

En el ejemplo anterior, si calculamos el coeficiente de correlación lineal r (mediante la fórmula 9-1) para los datos originales, obtendremos $r = 0.586$, lo que nos lleva a la conclusión de que no hay evidencia suficiente para sustentar la aseveración de una correlación lineal significativa al nivel 0.05 de significancia. Si examinamos el diagrama de dispersión de Excel, veremos que el patrón de puntos no es un patrón de línea recta. Este último ejemplo ilustra una ventaja del método no paramétrico sobre el método paramétrico: con la correlación de rangos, algunas veces podemos detectar relaciones que no son lineales.

Excel





Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Rank Correlation**. Ingrese los datos muestrales apareados en el cuadro de diálogo, después haga clic en **Evaluate**. Los resultados del STATDISK incluyen el valor exacto del estadístico de prueba r_s, el valor crítico y la conclusión.

Minitab Ingrese los datos apareados en las columnas C1 y C2. Si los datos todavía no son rangos, utilice las opciones **Manip** y **Rank** del Minitab para convertir los datos a rangos, luego seleccione **Stat**, seguido por **Basic Statistics** y **Correlation**. Minitab mostrará en la pantalla el valor exacto del estadístico de prueba r_s. Aunque Minitab identifica esto como el coeficiente de correlación de Pearson descrito en la sección 9-2, en realidad se trata del coeficiente de correlación de Spearman, descrito en esta sección (puesto que se basa en rangos).

Excel Excel no tiene una función que calcule el coeficiente de correlación de rangos a partir de valores muestrales originales, pero el valor exacto del estadístico de prueba r_s se calcula como sigue. Primero reemplace cada uno de los valores muestrales originales por su rango correspondiente. Ingrese estos rangos en las columnas A y B. Haga clic en el botón de función *fx* que se localiza en la barra del menú principal. Seleccione la categoría de función **Statistical** y el nombre de función **CORREL**, luego haga clic en **OK**. En el cuadro de diálogo, ingrese en la celda el rango de valores para x, como es A1:A10. También ingrese en la celda el rango de valores para y, como es B1:B10. Excel mostrará en la pantalla el valor exacto del coeficiente de correlación de rango r_s.

TI-83 Plus Si utilizamos una calculadora TI-83 Plus o cualquiera otra calculadora con estadística de dos variables, será posible calcular el valor exacto de r_s como sigue: 1. reemplace cada valor muestral por su rango correspondiente, 2. calcule el valor del coeficiente de correlación lineal r con los mismos procedimientos que se utilizaron en la sección 9-2. Ingrese los rangos apareados en las listas L1 y L2, después oprima **STAT** y elija **TESTS**. El uso de la opción **LinRegTTest** dará como resultado diversos valores que se muestran en la pantalla, incluyendo el valor exacto del coeficiente de correlación de rangos r_s.

12-6 Destrezas y conceptos básicos

1. Cálculo del estadístico de prueba y el valor crítico Para cada una de las siguientes muestras de rangos apareados, dibuje un diagrama de dispersión, estime el valor de r_s, calcule el valor de r_s y establezca si parece haber una correlación entre x y y.

a.

x	1	3	5	4	2
y	1	3	5	4	2

b.

x	1	2	3	4	5
y	5	4	3	2	1

c.

x	1	2	3	4	5
y	2	5	3	1	4

2. Cálculo de valores críticos Calcule el(los) valor(es) crítico(s) para r_s mediante la tabla A-9 o la fórmula 12-1, según resulte adecuado. Suponga casos de dos colas, donde α representa el nivel de significancia y n representa el número de pares de datos.

a. $n = 20$, $\alpha = 0.05$
b. $n = 50$, $\alpha = 0.05$
c. $n = 40$, $\alpha = 0.02$
d. $n = 15$, $\alpha = 0.01$
e. $n = 82$, $\alpha = 0.04$

Prueba para correlación de rangos. *En los ejercicios 3 a 12, utilice el coeficiente de correlación de rangos para probar una correlación entre las dos variables. Utilice un nivel de significancia de* $\alpha = 0.05$.

3. Correlación entre salario y estrés La tabla adjunta lista rangos de salario y rangos de estrés de trabajos que se seleccionaron al azar (datos tomados de *The Jobs Rated Almanac*). ¿Parece que el salario se incrementa a medida que se incrementa el estrés?

Trabajo	Rango de salario	Rango de estrés
Corredor de bolsa	2	2
Zoólogo	6	7
Ingeniero eléctrico	3	6
Director de escuela	5	4
Gerente de hotel	7	5
Funcionario bancario	10	8
Inspector de seguridad ocupacional	9	9
Economista doméstico	8	10
Psicólogo	4	3
Piloto de línea aérea	1	1

4. Correlación entre salario y demanda física El ejercicio 3 incluye rangos apareados de salario y nivel de estrés para 10 empleos que se seleccionaron al azar. Las demandas físicas de los empleos también se ordenaron en rangos; los rangos de salario y demanda física se presentan abajo (según datos de *The Jobs Rated Almanac*). ¿Parece haber una relación entre el salario de un empleo y sus demandas físicas?

Salario	2	6	3	5	7	10	9	8	4	1
Demanda física	5	2	3	8	10	9	1	7	6	4

5. Rangos de orden de escuelas de negocios La revista *Business Week* ordenó en rangos escuelas de negocios de dos formas diferentes. Los rangos de orden institucional se basaron en encuestas a reclutadores de la institución, y los rangos de orden de graduados se basaron en encuestas a graduados de la maestría en negocios. La tabla de abajo se basa en los resultados para 10 escuelas. ¿Hay una correlación entre los rangos institucionales y los rangos de los graduados? Utilice un nivel de significancia de $\alpha = 0.05$.

Escuela	PA	NW	Chi	Sfd	Hvd	MI	IN	Clb	UCLA	MIT
Rango institucional	1	2	4	5	3	6	8	7	10	9
Rango de graduados	3	5	4	1	10	7	6	8	2	9

6. Correlación entre cuentas de restaurante y propinas Los alumnos del autor reunieron datos muestrales consistentes en cantidades en cuentas de restaurante y la cantidad correspondiente de propina. Los datos se listan más adelante. Utilice la correlación de rangos para determinar si hay una correlación entre la cantidad de la cuenta y la cantidad de la propina.

Cuenta (dólares)	33.46	50.68	87.92	98.84	63.60	107.34
Propina (dólares)	5.50	5.00	8.08	17.00	12.00	16.00

7. Correlación entre estaturas y pesos de supermodelos Más adelante se listan estaturas (en pulgadas) y pesos (en libras) de las supermodelos Niki Taylor, Diana Auermann, Claudia Schiffer, Elle MacPherson, Christy Turlington, Bridget Hall, Kate Moss, Valerie Mazza y Kristy Hume.

Estatura	71	70.5	71	72	70	70	66.5	70	71
Peso	125	119	128	128	119	127	105	123	115

8. Precio de una audiencia televisiva El *New York Post* publicó los salarios anuales (en millones) y el número de televidentes (en millones), con los resultados que se incluyen abajo, para Oprah Winfrey, David Letterman, Jay Leno, Kelsey Grammer, Barbara Walters, Dan Rather, James Gandolfini y Susan Lucci, respectivamente. ¿Hay una correlación entre el salario y el número de televidentes?

Salario	100	14	14	35.2	12	7	5	1
Televidentes	7	4.4	5.9	1.6	10.4	9.6	8.9	4.2

T **9.** Cereales asesinos Remítase al conjunto de datos 16 del Apéndice B. Utilice las cantidades de grasa y los conteos calóricos medidos. ¿Hay una correlación?

T **10.** Colesterol e índice de masa corporal Remítase al conjunto de datos 1 del Apéndice B. Utilice los niveles de colesterol y los valores de índice de masa corporal de las 40 mujeres. ¿Hay una correlación entre el nivel de colesterol y el índice de masa corporal?

T **11.** Lo malo de los cigarros Remítase al conjunto de datos 5 del Apéndice B.

a. Utilice los datos apareados referentes a alquitrán y nicotina. Con base en el resultado, ¿parece haber ahí una correlación significativa entre el alquitrán y la nicotina de los cigarros? Si es así, ¿pueden los investigadores reducir sus gastos de laboratorio midiendo sólo una de estas dos variables?

b. Utilice los datos apareados consistentes en monóxido de carbono y nicotina. Con base en el resultado, ¿parece haber una correlación significativa entre el monóxido de carbono y la nicotina de los cigarros? Si es así, ¿pueden los investigadores reducir sus gastos de laboratorio midiendo sólo una de estas dos variables?

c. Suponga que los investigadores quieren desarrollar un método para predecir la cantidad de nicotina y desean medir sólo otro elemento. Al elegir entre alquitrán y monóxido de carbono, ¿cuál es la mejor opción? ¿Por qué?

T **12.** Pronósticos del clima Remítase al conjunto de datos 10 del Apéndice B.

a. Utilice las temperaturas máximas que se pronosticaron para cinco días y las temperaturas máximas reales. ¿Hay una correlación? ¿Una correlación significativa implica que las temperaturas del pronóstico de cinco días son precisas?

b. Utilice las temperaturas máximas que se pronostican para un día y las temperaturas máximas reales. ¿Hay una correlación? ¿Una correlación significativa implica que las temperaturas de pronóstico para un día son precisas?

c. ¿Cómo esperaría obtener una correlación más alta con las temperaturas máximas reales: con las temperaturas máximas del pronóstico para cinco días o con las temperaturas máximas del pronóstico para un día? ¿Los resultados de los incisos *a* y *b* concuerdan con lo que esperaría? Si hay una correlación muy alta entre las temperaturas de pronóstico y las temperaturas reales, ¿se deduce que las temperaturas de pronóstico son precisas?

12-6 Más allá de lo básico

13. Cálculo de valores críticos Una alternativa al uso de la tabla A-9 para encontrar valores críticos es calcularlos utilizando esta aproximación:

$$r_s = \pm\sqrt{\frac{t^2}{t^2 + n - 2}}$$

Aquí t es la puntuación t de la tabla A-3, correspondiente al nivel de significancia y a $n - 2$ grados de libertad. Aplique esta aproximación para calcular los valores críticos de r_s en los casos siguientes.

a. $n = 8, \alpha = 0.05$ **b.** $n = 15, \alpha = 0.05$
c. $n = 30, \alpha = 0.05$ **d.** $n = 30, \alpha = 0.01$
e. $n = 8, \alpha = 0.01$

14. Efecto de empates en r_s Remítase al conjunto de datos 7 del Apéndice B para los tiempos (en segundos) de consumo de tabaco y consumo de alcohol que se presentan en películas de dibujos animados para niños. Calcule el valor del estadístico de prueba r_s utilizando cada una de las dos fórmulas presentadas en esta sección. ¿Hay una diferencia sustancial entre los dos resultados? ¿Cuál resultado es mejor? ¿La conclusión se ve afectada por la fórmula utilizada?

12-7 Prueba de rachas para detectar aleatoriedad

El objetivo principal de esta sección es introducir la prueba de rachas para detectar aleatoriedad, que permite determinar si los datos muestrales en una secuencia están en un orden aleatorio. En la importancia de la aleatoriedad se ha puesto énfasis a lo largo de este libro; ahora nos enfocamos en un método para determinar si esta característica está presente.

Definiciones

Racha: Es una secuencia de datos que tiene la misma característica; la secuencia es precedida y seguida por datos con una característica diferente o por ningún dato en absoluto.

La **prueba de rachas** utiliza el número de rachas en una secuencia de datos muestrales para probar la aleatoriedad del orden de los datos.

Principio fundamental de la prueba de rachas

El principio fundamental de la prueba de rachas puede establecerse brevemente como sigue:

Rechace la aleatoriedad si el número de rachas es muy bajo o muy alto.

- Ejemplo: La secuencia de género MMMMMHHHHH no es aleatoria, puesto que tiene sólo dos rachas; por lo tanto, el número de rachas es muy *bajo*.
- Ejemplo: La secuencia de género MHMHMHMHMH no es aleatoria, puesto que hay 10 rachas, lo cual es muy *alto*.

El criterio exacto para determinar si un número de rachas es muy alto o muy bajo se encuentra en el recuadro adjunto, que resume los elementos clave de la prueba de rachas para detectar aleatoriedad. Además, el procedimiento de la prueba de rachas para detectar aleatoriedad se resume en la figura 12-5.