Eduardo Bologna

Métodos Estadísticos de Investigación



00026157

Editorial Brujas

Parte III: Estadística inferencial

Una vez que disponemos de una síntesis de la información que hemos recogido de un conjunto de individuos, pasa a interesar otro problema: el de preguntarnos si eso que se ha observado vale también para otros, a los que se ha observado. Si hemos visto a muchas personas, algunas exigentes consigo mismo y otras que no lo son y hallamos que las primeras manifiestan más ansiedad en los exámenes que las segundas, ¿podemos decir que la autoexigencia incide en la ansiedad?, es decir, ¿podemos generalizar nuestro resultado? La Estadística inferencial se ocupará de esto, de decirnos bajo qué condiciones se pueden extender nuestros hallazgos a casos no observados.

Si encontramos niños de madres que han tomado bebidas alcohólicas durante el embarazo y niños de madres que no bebieron y descubrimos que, en promedio, los hijos de madres bebedoras tienen niveles de desarrollo motor más bajo que los hijos de madres no bebedoras ¿podemos afirmar que beber alcohol durante el embarazo retrasa el desarrollo motor de los hijos *en general*? Según cuántos niños hayamos observado, según qué tan grande sea la diferencia entre el promedio de desarrollo motor de los hijos de bebedoras y no bebedoras, según qué tan variable sea el desarrollo entre los niños, tendremos o no argumentos para generalizar el resultado y afirmar que existe o no una relación entre consumo de alcohol durante el embarazo y desarrollo motor del niño. Se establece así una relación entre variables que pasa a tener validez general, no solo para los niños que fueron efectivamente observados.

Cuando se realicen generalizaciones, éstas estarán limitadas a un contexto específico. El análisis que se haga, de la relación entre pobreza y educación en Argentina, puede no ser válido para la población de Brasil, ni el efecto de la fijación de metas elevadas es el mismo en los países asiáticos que en los latinoamericanos. Es decir, debe estar explícita cuál es la población de referencia a la cual es válido extender los resultados que se obtienen. Por el contrario, la relación entre el consumo de alcohol de las madres y el desarrollo de sus hijos, como tiene anclaje biológico, puede hacerse extensiva a la población general.

Los dos procedimientos que se desarrollan en los capítulos siguientes son: estimación por intervalo (o estimación de parámetros o también intervalos de confianza) y pruebas de hipótesis (conocida también como docimasia de hipótesis).

Estos son los dos métodos que se utilizan para producir generalizaciones estadísticas a partir de muestras, es decir, inferencias.

Capítulo 10 Estimación por intervalo

Hemos llegado a este punto en el que haremos uso de casi todos los elementos que se presentaron hasta aquí. Se dedicó la Parte I a la descripción de datos provenientes de una muestra y luego, en la Parte II se ingresó al terreno de la incertidumbre. Solo resta integrar estos elementos en un procedimiento para realizar las estimaciones que interesen. Por esta razón se trata de un capítulo de plena aplicación práctica.

Estimación puntual

La media muestral $\bar{x}$ es un estimador de la media poblacional, por lo que ya se cuenta con una primera estimación de ese parámetro μ. De igual modo, la proporción muestral ($\hat{p}$) estima a la proporción poblacional (P). De modo que ya se conocen estimaciones de esos dos parámetros, son estimaciones puntuales. Se llaman así porque ofrecen un único valor como estimación del parámetro de interés. Por ejemplo si en una muestra de 50 psicólogos que egresaron en los últimos diez años se encuentra que han terminado la carrera con una nota promedio de $\bar{x} = 6{,}50$, disponemos de una media muestral; si ahora preguntamos por el promedio con que terminaron la carrera todos los psicólogos que egresaron en los últimos diez años, la respuesta es tentativa, diremos que "debe ser cercano a 6,50". Con esta expresión imprecisa, hacemos una estimación de la media poblacional (μ). De igual modo, si en la misma muestra de 50 psicólogos, se ve que la proporción de mujeres es $\hat{p} = 0{,}70$, podremos decir que, del total de psicólogos egresados en los últimos diez años, "alrededor del 70% son mujeres". Así hacemos una estimación de P a partir de $\hat{p}$. Pero estas estimaciones son deficientes, ya que no sabemos cuán cerca puede estar la verdadera nota promedio de 6,50 ó la verdadera proporción de mujeres del 70%. Estas son las que se denominan estimaciones puntuales.

Intervalos de confianza

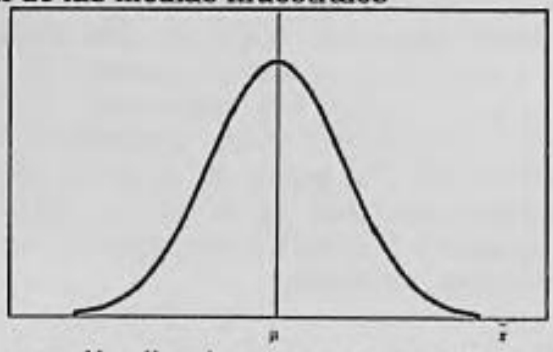
Una estimación más completa de los parámetros mencionados, se denomina **estimación por intervalo**. Ella consiste en ofrecer no ya un número como en la estimación puntual, sino un intervalo, acerca del cual se tiene cierto grado de certeza (o se deposita cierta confianza) que contenga al parámetro. Así, en lugar de decir que el promedio con que egresa el total de psicólogos de esta facultad "debe ser cercano a 6,50", se construirá un intervalo, que dirá, por ejemplo, "hay una confianza del 95% en que el intervalo [6,10; 6,90] contiene al promedio con que egresan los psicólogos de esta facultad". De manera equivalente, en lugar de "entre los que egresan hay alrededor del 70% de mujeres", se afirmará algo como "con una confianza del 95%, el intervalo [68; 72]% contiene a la proporción de mujeres sobre el total de egresados". Vemos entonces que esta forma de estimar ofrece dos números, los límites de un intervalo, del que esperamos contenga al parámetro que estimamos. Decimos "esperamos que se contenga" porque no hay certeza absoluta de que se encuentre allí, hay una confianza que en estos ejemplos hemos fijado en el 95%, y veremos que puede elegirse.
Veamos a continuación cómo construir estos intervalos de confianza para estimar los dos primeros parámetros que hemos tratado; la media y la proporción.

Estimación de la media

Vamos a hacer uso de lo que sabemos hasta el momento sobre las distribuciones en el muestreo para mejorar la calidad de las estimaciones puntuales y construir los intervalos de confianza. Para ello, empezaremos con la media. Debido a que la muestra ha sido obtenida de manera aleatoria, la media muestral es una variable aleatoria, cuya distribución tiene media μ y desviación estándar $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$. Además, a medida que aumenta el tamaño de la muestra, esa distribución tiende a ser normal, es decir que será tanto más cercana a una distribución normal cuanto más grande sea n. A los fines prácticos, una muestra de 30 casos se considera "suficientemente grande" como para usar la distribución normal en la distribución de $\bar{x}$. Si la muestra es más pequeña que ese tamaño, no podemos usar inmediatamente la distribución normal, sino que deberemos apelar a la distribución t de Student. Trabajaremos primero suponiendo que se trata de muestras lo suficientemente grandes y usaremos la distribución normal. Los paquetes informáticos de análisis de datos usan la distribución t siempre, cualquiera sea el tamaño de la muestra, haciendo uso de la convergencia de esta distribución hacia la normal cuando n crece.

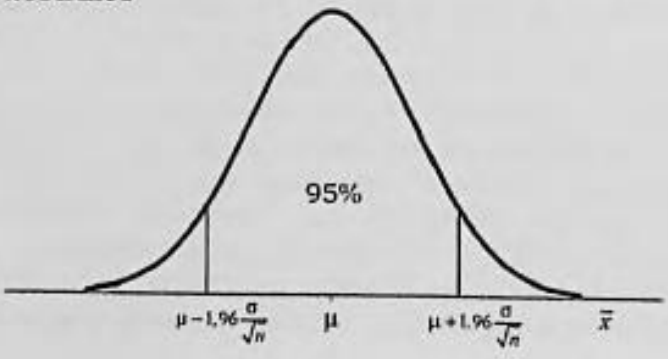
Con esa información, podemos calcular las probabilidades de los diferentes valores de $\bar{x}$. La representación gráfica de esta distribución es:

Gráfico 1: Distribución de las medias muestrales



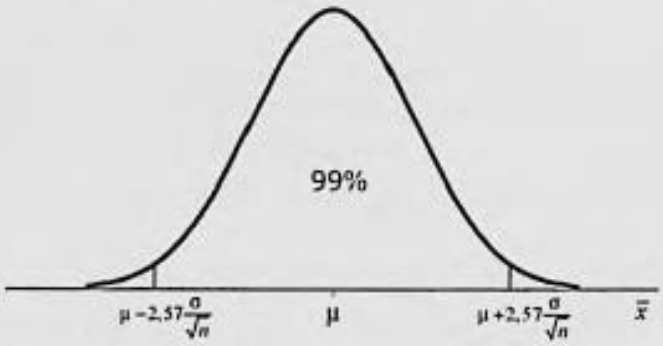
Recordando que, bajo una distribución normal, a 1,96 desviaciones estándar por encima y por debajo de la media, se encuentra el 95% de los casos, se concluye que, si extrajéramos todas las muestras de tamaño n posibles de esa población, el 95% de ellas estaría entre $\mu - 1{,}96 * \sigma_{\bar{x}}$ y $\mu + 1{,}96 * \sigma_{\bar{x}}$, o lo que es lo mismo, entre $\mu - 1{,}96 * \frac{\sigma}{\sqrt{n}}$ y $\mu + 1{,}96 * \frac{\sigma}{\sqrt{n}}$.

Gráfico 2: Intervalo en torno a la media poblacional que incluye al 95% de las posibles medias muestrales



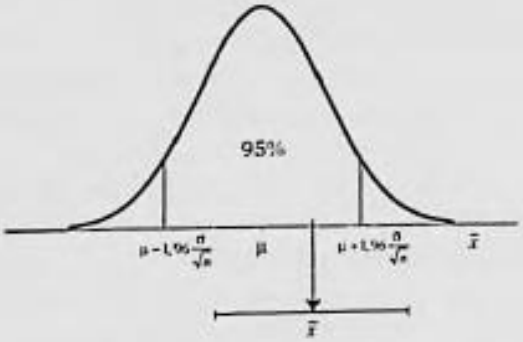
De manera equivalente, como a 2,57 desviaciones estándar alrededor de la media se encuentra el 99% de las observaciones, entonces el 99% de las medias muestrales estará entre $\mu - 2{,}57 * \frac{\sigma}{\sqrt{n}}$ y $\mu + 2{,}57 * \frac{\sigma}{\sqrt{n}}$.

Gráfico 3: Intervalo en torno a la media poblacional que incluye al 99% de las posibles medias muestrales

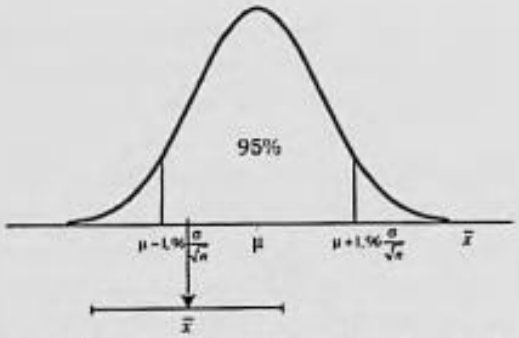


Este es el alcance más operativo de los resultados teóricos, ahora hay que ir al problema. Las curvas de arriba solo pueden dibujarse si se conoce μ y es justamente el valor que trata de estimarse. Además, en el muestreo no se extraen "todas las muestras" sino solo una, y ella se usa para hacer la estimación. Lo que sabemos de esa muestra es que tiene una probabilidad del 0,95 de estar en la zona marcada en el gráfico 2 y una probabilidad 0,99 de estar donde indica el gráfico 3. Concentremos nuestra atención en el caso del gráfico 2, correspondiente a la zona donde se halla el 95% de todas las medias muestrales posibles.

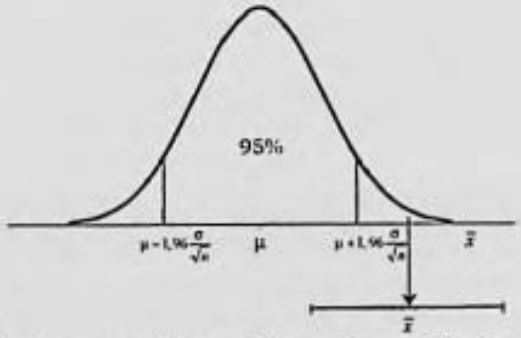
Se extrae la muestra (probabilistica, con todos los resguardos que corresponda para que admita la generalización de las conclusiones a que lleve), en esa muestra calculamos $\bar{x}$. Supongamos que la muestra da lugar a la media que está indicada en este gráfico.



Si construimos un intervalo de la misma amplitud que el anterior, pero ahora centrado en $\bar{x}$, en vez de centrado en μ, vemos que ese intervalo contiene a μ. Si la $\bar{x}$ fuera la que está en el gráfico siguiente.



También un intervalo alrededor de ella contendría a μ. Por el contrario en el caso siguiente:



El intervalo alrededor de $\bar{x}$ no contiene a la media poblacional.

— ¿Qué condición debe cumplir $\bar{x}$ para que el intervalo que se construya a su alrededor contenga a μ?
— Debe estar entre $\mu - 1{,}96 * \frac{\sigma}{\sqrt{n}}$ y $\mu + 1{,}96 * \frac{\sigma}{\sqrt{n}}$

— ¿Qué proporción de las $\bar{x}$ cumple esa condición?
— El 95% de ellas.

Así, el 95% de las $\bar{x}$ posibles dará lugar a intervalos que contengan a μ, el 5% restante de las $\bar{x}$ producirá intervalos que no contienen a μ.
Es importante señalar que no sabemos si nuestro intervalo contiene a μ o no, solo sabemos que hay una probabilidad de 0,95 que la contenga. Es decir, es muy probable que el intervalo contenga a μ, pero no es seguro.
¿Cuál es la expresión de ese intervalo?, dado que está centrado en $\bar{x}$, hay que sumar y restar a ese estimador lo mismo que sumamos y restamos a μ para construir el intervalo anterior, por lo que resulta:

$$\bar{x} - 1{,}96 * \frac{\sigma}{\sqrt{n}} \; ; \; \bar{x} + 1{,}96 * \frac{\sigma}{\sqrt{n}}$$

Estos son dos números que constituyen los límites de un intervalo que tiene una probabilidad 0,95 de contener al parámetro μ. De manera equivalente decimos que, de cada 100 intervalos que se construyan con este procedimiento, 95 contendrán a la media de la población. O bien que el 95% de las muestras aleatorias de tamaño n que se extraigan de la población, proveerán valores de $\bar{x}$ que conducirán a intervalos que contengan a la media de la población.

Cuando logramos construir un intervalo así decimos que se ha estimado a μ con un 95% de confianza. El primero valor de los indicados se llama límite inferior (L_i) y el segundo, límite superior (L_s). Así entonces:

$$Li = \bar{x} - 1{,}96 * \frac{\sigma}{\sqrt{n}}$$
$$Ls = \bar{x} + 1{,}96 * \frac{\sigma}{\sqrt{n}}$$

Ejemplo: Si en una muestra de 400 egresados de Psicología, encontramos que la nota promedio con que egresan es de 6,50 ($\bar{x} = 6{,}50$) y sabemos que la desviación estándar de la población es de 0,8 ($\sigma = 0{,}8$), estimamos la nota promedio con que egresaron todos los psicólogos reemplazando:

$$Li = 6{,}50 - 1{,}96 * \frac{0{,}8}{\sqrt{400}} = 6{,}42$$
$$Ls = 6{,}50 + 1{,}96 * \frac{0{,}8}{\sqrt{400}} = 6{,}58$$

Leemos este resultado diciendo que tenemos un confianza del 95% que el intervalo [6,42; 6,58] contiene a la media de las notas con que egresaron todos los psicólogos de esta facultad. La confianza del 95% está incluida en la construcción del intervalo en el número 1,96 que multiplica al error estándar de $\bar{x}$.

La notación puede abreviarse indicando de una sola vez ambos límites, si se escribe:

$$\bar{x} \pm 1{,}96 * \frac{\sigma}{\sqrt{n}}$$

Con lo que queremos indicar que a $\bar{x}$ se le suma y se le resta la expresión $1{,}96 * \frac{\sigma}{\sqrt{n}}$.

En el ejemplo, esto haría que escribamos el intervalo de manera alternativa como $6{,}50 \pm 0{,}08$, que indica cuál es la media muestral (el estimador puntual) y la cantidad que debe sumarse y restarse para llegar a los límites.

Si quisiéramos estar más seguros acerca de que el intervalo contiene a μ, podríamos usar los puntos que delimitan el 99% del área. Para ello, z vale 2,57 y los límites del intervalo resultan: $\bar{x} \pm 2{,}57 * \frac{\sigma}{\sqrt{n}}$

Para el ejemplo anterior, con una confianza del 99%, el intervalo es:

$$L_i = 6{,}50 - 2{,}57 * 0{,}04 = 6{,}50 - 0{,}10 = 6{,}40$$
$$L_s = 6{,}50 + 2{,}57 * 0{,}04 = 6{,}50 + 0{,}10 = 6{,}60$$

Con lo que ahora diremos que, con una confianza del 99%, el intervalo [6,40; 6,60] contiene a la media de las notas con que egresaron todos los psicólogos de esta facultad. Otra opción es la de escribir el intervalo como $6{,}50 \pm 0{,}10$, la media muestral es la misma y aumentó lo que debe alejarse de ella para llegar a los límites.

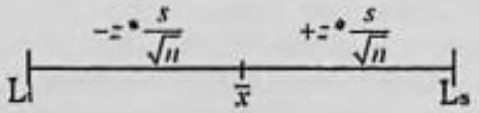
Notemos que este aumento en la confianza de la estimación, al pasar del 95 al 99%, tiene un costo, porque el intervalo es ahora más amplio: el límite inferior es menor que en el anterior y el superior, mayor. Antes el intervalo iba desde 6,42 a 6,58 y ahora va desde 6,40 hasta 6,60. Más tarde volveremos sobre este punto.

De manera general, el intervalo se escribe como $\bar{x} \pm z * \frac{\sigma}{\sqrt{n}}$, dejando z como variable, que puede reemplazarse por el valor que corresponda según la confianza que se elija para la estimación (por ahora 1,96 para 95% y 2,57 para 99%)

Sin embargo, esta manera de calcular los límites del intervalo tiene un problema para usarse en la práctica, ya las fórmulas para calcular los límites, requieren que se conozca σ, la desviación estándar de la población. Pero como nuestros datos son muestrales, no conocemos σ, a cambio de ella usaremos la desviación estándar de la muestra, a la que podemos calcular a partir de los datos disponibles[79]. Con ese ajuste, la expresión para el cálculo de los límites del intervalo de confianza será:

$$\bar{x} \pm z * \frac{s}{\sqrt{n}}$$

Que puede representarse gráficamente así:



En este gráfico solo podemos dibujar el segmento que representa al intervalo en torno a $\bar{x}$, pero no podemos dibujar la campana correspondiente a la distribución, ya que no conocemos μ que es donde la campana se centra.

Ejemplo (datos reales): Se dispone de una muestra de 277 alumnos que rindieron el primer parcial, conocemos sus notas y queremos usarlas para hacer una estimación de la nota promedio de todo el curso (que cuenta con 1600 alumnos). Haremos esa estimación con una confianza del 95%.
De la muestra hemos obtenido $\bar{x} = 6{,}63$ y $s = 2{,}15$, con lo que los límites resultan:

$$\bar{x} \pm z * \frac{s}{\sqrt{n}} = 6{,}63 \pm 1{,}96 * \frac{2{,}15}{\sqrt{277}} = 6{,}63 \pm 1{,}96 * 0{,}13 = 6{,}63 \pm 0{,}25$$

Usando primero el signo menos, obtenemos L_i= 6,38 y luego sumando L_s = 6,88. Entonces podemos afirmar el intervalo 6,38; 6,88 contiene a la nota promedio del total de alumnos del curso, con una confianza del 95%.

La solicitud de esta operación a InfoStat® se encuentra en el vídeo *intervalo de confianza* y la salida tiene la forma:

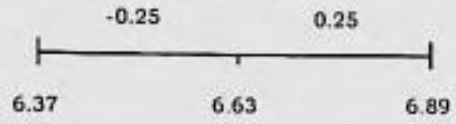
---

[79]Esto es válido en la medida que se trate de muestras grandes ($n>30$), en caso contrario, la distribución que debemos usar es la t de Student. Cuando fijemos la confianza, ya no serán z los valores que multiplicarán a $\frac{\sigma}{\sqrt{n}}$ sino puntajes t, cuyos grados de libertad se calculan como $n-1$. Pero, para poder usar la distribución t, los valores de la muestra deben provenir de una distribución normal en la población. Si esto no se cumple, la estimación puede realizarse buscando los límites a partir de una reconstrucción de la distribución empírica, por un método de remuestreo llamado "bootstrap".

Variable	Parámetro	Estimación	E.E.	n	LI(95%)	LS(95%)
Primero	Media	6.63	0.13	264	6.37	6.89

La variable se llama "primero" en referencia al primer parcial. El E.E. es el error estándar del estimador, proviene de $\frac{s}{\sqrt{n}}$, que es $\frac{2,13}{\sqrt{277}} = 0,13$. Ese error estándar del estimador es el que se multiplica por z para obtener el término que conduce a los límites del intervalo.

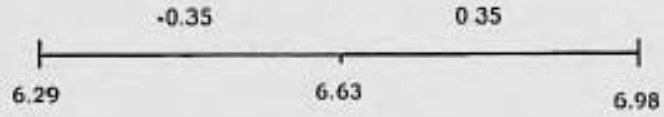
Una representación gráfica de esta estimación es:



Si la confianza se solicita en el 99%, el programa da:

Variable	Parámetro	Estimación	E.E.	n	LI(99%))	LS(99%))
Primero	Media	6.63	0.13	264	6.29	6.98

Comparada con la salida anterior, solo han cambiado los límites del intervalo, ya que son los mismos datos muestrales. El cambio en la confianza se realiza por un cambio en el valor de z y eso hace que cambien los límites. El gráfico tiene ahora la forma:



Se observa que un aumento en la confianza incide en la amplitud del intervalo, éste último es más amplio que el primero construido. Más adelante trataremos esta relación con detalle.

Estimación de la proporción

Cuando trabajamos con variables cualitativas (nominales u ordinales) no es posible calcular la media ni la desviación estándar sino solo considerar la proporción de casos que hay en una categoría que elegimos. La proporción es la frecuencia relativa de la categoría que se elige, la cantidad de casos en esa categoría dividida el tamaño de la muestra. Cuando se trata de variables con solo dos categorías (dicotómicas) puede elegirse cualquiera de ellas. Por ejemplo si es el resultado de un examen y las categorías son aprobado – no aprobado, podemos interesarnos por la proporción de cualquiera de ellas, ya que la otra es el complemento (lo que le falta para llegar a uno). Si una es 0,70 (70%), la otra no puede sino ser 0,30 (30%). Es diferente si la variable tiene más de dos categorías, por ejemplo si se trata de la intención de voto para las elecciones presidenciales. Allí es usual que haya más de dos candidatos, por lo que la proporción de uno de ellos no nos dice mucho sobre la de cada uno de los otros: si hay cinco candidatos y uno se lleva el 40%, solo sabemos que el 60% restante se reparte

entre los otros cuatro, pero no sabemos cuánto le corresponde a cada uno. A estos casos los trataremos como si fueran dicotómicos: una categoría será el candidato que nos interesa y la otra categoría estará formada por todos los demás. Así, si un candidato tiene una proporción de 0,40 a su favor, solo nos interesa que tiene una proporción de 0,60 que no está a su favor y no nos preocupamos por saber cómo se reparte ese 60% en los demás candidatos. Tratamos una categoría frente a todas las demás. De este modo es que puede definirse la proporción de personas que usa anticonceptivos orales, frente a quienes usan todos los demás métodos; o la proporción de alumnos promocionados frente a regulares y libres; o la proporción de argentinos entre todos los estudiantes extranjeros que hay en España, sin interesarnos por el modo en que se distribuye la proporción entre las demás nacionalidades. Lo que hacemos con este procedimiento es simplemente llamar la atención sobre una categoría y confrontarla con el resto indiscriminado. La categoría elegida o categoría de referencia, se llama **éxito**, su frecuencia absoluta, **cantidad de éxitos** y su frecuencia relativa **proporción de éxitos**.
Por este procedimiento trataremos siempre con dos grupos, uno formado por los casos que son de nuestro interés y el otro por los demás casos.
Existen varios procedimientos para construir intervalos de confianza para la proporción, aquí mencionaremos el de Clopper-Pearson, el de Wald y el de Wilson.

Intervalo de Clopper-Pearson
El primer modo para construir un intervalo para estimar la proporción, es usar la distribución binomial. Para ello, partimos del estimador puntual y buscamos los dos valores de $\hat{p}$ que delimiten el 95% central de la distribución.
Ejemplo (datos reales): a partir de la muestra de alumnos que rindieron el parcial se busca estimar, al 95% de confianza, la proporción de quienes lo aprobaron.
Sabemos que, de los 277 muestreados que rindieron, 255 lo aprobaron, en consecuencia la proporción de aprobados es, en la muestra[80], $\hat{p} = \frac{255}{277} = 0{,}920$. Este es nuestro estimador puntual de la proporción de aprobados para todo el curso.
En el video *límites estimación p*, usamos InfoStat® para encontrar los valores de x que acumulan el 2,5% (0,025) y el 97.5% (0,975) de la distribución binomial. El primer valor que devuelve el programa es 246, que es la cantidad de "éxitos" que acumula una probabilidad de 0,025, mientras que el segundo, 263, la cantidad de éxitos que acumula una probabilidad de 0,975. Estas cantidades de éxitos deben transformare en proporciones de éxitos, a fin de para encontrar los límites del intervalo. Para eso, se calculan sus frecuencias relativas, es decir, se los divide por el tamaño de la muestra:

$$L_i = \frac{246}{277} = 0{,}8881$$

$$L_s = \frac{263}{277} = 0{,}9495$$

[80] Estos datos conducen a la distribución:

resultado	f	f
aprobado	255	0,920
no aprobado	22	0,080
total	277	

Diremos entonces que, con una confianza del 95%, el intervalo [88,81; 94,95]% contiene a la proporción de alumnos que aprobaron en toda la población.
Esta forma de construir el intervalo de confianza para la proporción —de Clopper-Pearson—, es la más antigua, se la conoce también como "método exacto", porque no apela a aproximaciones para calcular los límites, sino que usa la distribución que corresponde al experimento: la binomial. Este es el procedimiento que utiliza InfoStat® para construir intervalos de manera automática.

Intervalo de Wald
Si se cumplen las condiciones para realizar una aproximación normal de la distribución binomial, el razonamiento que seguimos para la estimación de P será análogo al que seguimos para estimar μ. La estructura de los límites del intervalo de confianza es ahora:

$$L_i = \hat{p} - z * \sigma_{\hat{p}}$$
$$L_s = \hat{p} + z * \sigma_{\hat{p}}$$

En la que:
$\hat{p}$ es la proporción de casos en la categoría que estimamos calculada sobre los datos de la muestra.
z asume el valor de 1,96 si vamos a estimar con una confianza del 95%, ó de 2,57 si queremos una confianza del 99%.

$\sigma_{\hat{p}}$ es la desviación estándar del estimador:

$$\sigma_{\hat{p}} = \sqrt{\frac{P * (1 - P)}{n}}$$

Pero, tal como pasó con la estimación de $\bar{x}$, en la que ignorábamos σ por tratarse de un valor poblacional, ahora desconocemos P (¡es exactamente lo que estamos tratando de estimar!), por lo que deberemos necesariamente reemplazarla por su estimador: $\hat{p}$[81]. Resultará:

$$\hat{\sigma}_{\hat{p}} = \sqrt{\frac{\hat{p} * (1 - \hat{p})}{n}}$$

Y los límites del intervalo son:

$$\hat{p} \pm z \sqrt{\frac{\hat{p} * (1 - \hat{p})}{n}}$$

Ejemplo (datos reales): la muestra de alumnos que rindieron el parcial a partir de la cual se busca estimar, al 95%, la proporción de quienes lo aprobaron. Sabemos que, de los 277 que rindieron, 255 lo aprobaron, en consecuencia la proporción de aprobados es $\hat{p} = \frac{255}{277} = 0{,}920$. Este es nuestro estimador puntual de la proporción de aprobados para todo el curso. Para hacer el intervalo, usamos la expresión anterior y resulta:

[81] Como antes hicimos reemplazando σ por s.

$$\hat{p} \pm z\sqrt{\frac{\hat{p} * (1-\hat{p})}{n}} = 0{,}920 \pm 1{,}96 * \sqrt{\frac{0{,}92 * 0{,}08}{277}} = 0{,}920 \pm 0{,}032$$

Cuando restamos, obtenemos el límite inferior del intervalo:

$$L_i = 0{,}920 - 0{,}032 = 0{,}892$$

y sumando:

$$L_s = 0{,}920 + 0{,}032 = 0{,}952$$

Si se escribe de manera abreviada, la expresión toma la forma:

$$L_i = 0{,}920 \pm 0{,}032$$

Con el valor explicito de la proporción muestral que es el estimador puntual de *P*. El resultado dice que hay una confianza del 95% que el intervalo [89,2; 95,2]% contenga a la proporción de aprobados de toda la población. El intervalo difiere un poco del hallado con el método exacto, porque es una aproximación.

Esta forma de construir el intervalo de confianza para P resulta de calidad aceptable si el producto $n * \hat{p} * (1-\hat{p})$ es mayor a 5, y mejor aun si ese resultado es mayor a 10 (Canavos, 1988). Sin embargo, Cepeda-Cuervos y otros (2008) señalan evidencia sobre la inadecuación de esta estimación aun cuando la condición se cumple. Por esta razón se limita el uso de este modo de calcular el intervalo cuando el número de observaciones en mayor a cien[82].

Intervalo de Wilson
Una mejora para la calidad de la estimación es propuesta por Newcombe y Merino (2006), con un intervalo llamado de *score* o de Wilson, cuyos límites son:

$$\hat{p} \pm \frac{z}{n} * \sqrt{\frac{\left(\hat{p} * (1-\hat{p}) + \frac{z}{4*n}\right)}{n}}$$

Este intervalo no colapsa para $\hat{p} = 0$ ó $\hat{p} = 1$ y tiene mejor calidad que el de Wald, es conveniente optar por esta alternativa si se trata de pequeñas muestras o de valores de $\hat{p}$ próximos a cero o a uno. De todos modos, siempre es preferible utilizar la distribución binomial que es la adecuada para modelar el proceso.

Obtención informática del intervalo para la proporción
En el video *estimación P con infostat* se muestra la obtención del intervalo para estimar la proporción de alumnos que aprobó el segundo parcial. Como la variable (nota del segundo parcial) es cuantitativa, se debe indicar qué es lo que vamos a llamar éxito. Aquí, nos interesa la proporción de aprobados, por lo que la condición "éxito" es que la nota sea 4 o más (≥ 4). La salida tiene forma:

[82]Pero si $\hat{p}$ es muy pequeño, el límite inferior es negativo y si $\hat{p}$ es muy cercano a uno, el límite superior puede superar a 1, decimos que en estos casos el intervalo colapsa.

Variable	Parámetro	Estimación	E.E.	n	LI(95%))	LS(95%))
Segundo	Proporción(>=4)	0.79	0.03	245	0.74	0.84

La indicación entre paréntesis (>=4) se refiere a la condición que pusimos como éxito, nota 4 o superior.

Si aumentamos la confianza al 99%, el intervalo es:

Variable	Parámetro	Estimación	E.E.	n	LI(99%))	LS(99%))
Segundo	Proporción(>=4)	0.79	0.03	245	0.73	0.86

Como sucedió con la media, el aumento en la confianza se traduce en un aumento en la amplitud del intervalo.

La calidad de las estimaciones por intervalo

Intuitivamente, una estimación es de mejor calidad si es "ajustada", es decir si el intervalo es pequeño. Por ejemplo, si estimamos la edad de una persona entre 28 y 30 años, tenemos una estimación de mejor calidad que si decimos que tiene entre 20 y 40 años. Eso es porque el primer intervalo es más pequeño, los límites están más cerca. La primera estimación nos da más información que la segunda, porque delimita el valor al que estima entre números más cercanos. En las estimaciones que hemos hecho hasta aquí, de la media y de la proporción, hemos partido del estimador puntual ($\bar{x}$ y $\hat{p}$) y desde él sumamos y restamos la misma cantidad para obtener los límites del intervalo.

Esa cantidad que sumamos y restamos determina la amplitud del intervalo: cuanto más grande sea, tanto mayor será el intervalo, es decir, tanto mayor será la distancia entre los límites inferior y superior. Esa cantidad se denomina **error de estimación**. Las estimaciones están siempre acompañadas de un error, es un componente intrínseco al proceso. No es error en el sentido de equivocación o de falla, sino de imprecisión, una imprecisión que no puede evitarse, que no puede hacerse igual a cero. Se calcula como la distancia que hay desde el centro del intervalo hasta cualquiera de los límites. En el ejemplo anterior, sobre la estimación intuitiva de la edad de alguien, el centro del primer intervalo es 29, por lo que el error es 1 año, por eso se puede también escribir como 29 ± 1. El segundo intervalo de este ejemplo tiene centro en 30 y el error es de 10 años, lo escribimos 30 ± 10. Independientemente que el centro de los intervalos difiera levemente, este segundo intervalo tiene un mayor error de estimación. Esto es equivalente a decir que tiene menos **precisión**.

Se llama **error de estimación** a la distancia que hay entre el estimador puntual y cualquiera de los límites del intervalo. Cuanto mayor es el error de estimación menor es su **precisión**.

En la estimación del promedio con que egresan los psicólogos, escribimos $6{,}50 \pm 0{,}08$ al estimar al 95% de confianza y $6{,}50 \pm 0{,}10$ cuando la confianza se pasó al 99%. Allí estábamos escribiendo el intervalo como el estimador más/menos el error de estimación. En el primer caso el error de estimación es de

0,08 y en el segundo de 0,10, por eso decimos que la primera estimación es más precisa, tiene menos error.
Del mismo modo, al estimar, con una confianza del 95%, la proporción de quienes aprobaron el parcial escribimos $0{,}920 \pm 0{,}032$, el error de estimación es en este caso de 0,032 (ó 3,2%).

El error de estimación en la media

En la expresión general de la estimación por intervalo de μ, el error es el término que se suma y resta: $z * \frac{s}{\sqrt{n}}$. ¿De qué depende que ese término sea grande o chico?

Hay tres elementos en este término: z, s y n. De ellos va a depender que haya más o menos error en la estimación o, dicho de otra manera, que la estimación sea más o menos precisa. Veamos el efecto de cada uno:

z: Es elegido por el investigador cuando establece la confianza. En los ejemplos que hemos visto, asumió el valor de 1,96 para un 95% de confianza o de 2,57 para una confianza de 99%. Cuanto más confianza o certeza queramos tener en nuestra estimación, más grande será z y, en consecuencia mayor será el error de estimación. Por lo tanto no se pueden tener las dos cosas: más confianza va acompañada de menos precisión. Si todos los demás elementos del error quedan fijos, los intervalos más amplios proveen menos información, pero mayor certeza en la inclusión del parámetro que se estima. Para elegir el nivel de confianza (y en consecuencia determinar z) debe tomarse una decisión que equilibre la confianza y la precisión, ya que si una crece la otra disminuye. Si alguien intentara lograr precisión absoluta, es decir, error igual a cero, encontraria una confianza también igual a cero, es decir, ninguna certeza. A la inversa, intentar fijar la confianza en el 100%, lleva a un error infinito.

s: La desviación estándar en la muestra. Es la medida de la variabilidad de los datos que se observan, y es una estimación de la verdadera variabilidad que tiene la caracteristica que estamos estudiando en la población. Incide negativamente sobre el error, cuanto más grande es s más error tenemos. Eso refleja el hecho que si la población es muy heterogénea respecto de la cualidad que queremos estimar, tendremos estimaciones de peor calidad que si es similar para los individuos de la población. Sobre s no podemos decidir, no tenemos control sobre su valor, si es grande, tendremos peores estimaciones que si es pequeña. El muestreo estratificado es una forma de enfrentar situaciones de mucha dispersión, construyendo subconjuntos (estratos) que contengan elementos homogéneos en su interior, es decir que tengan menos dispersión que el conjunto completo.

n: El tamaño de la muestra, se encuentra en el denominador del término del error, por lo que su aumento reduce el error. Cuanto más grande sea n, menor será el error, es decir que muestras de mayor tamaño dan mayor precisión. En principio, podemos elegir n, pero depende del presupuesto que se prevea para la investigación. Si se puede obtener una muestra grande siempre es preferible, porque se lograrán estimaciones de mejor calidad.

Esto no debe confundirse con la calidad de la muestra. Todo lo mencionado sobre estimación, supone que se trata de muestras probabilísticas, es decir muestras aleatorias, para las cuales rigen las leyes de probabilidad que hemos usado. Si la muestra no es aleatoria, no se pueden hacer estimaciones con estos procedimientos y; esto es muy importante: no se mejora una muestra tomando más casos. Si la muestra no es probabilística, la estimación no mejorará porque se tomen muchos casos.

Para ejemplificar los efectos de los diferentes elementos en el error de estimación, volveremos sobre los datos de las notas del primer parcial y haremos tres diferentes estimaciones de la nota promedio:

Sobre el total de la muestra (277 casos) al 90% de confianza:

Variable	Parámetro	Estimación	E.E.	n	LI(90%)	LS(90%)
Primero	Media	6,76	0,13	277	6,55	6,97

Sobre el total de la muestra (277 casos) al 95% de confianza:

Variable	Parámetro	Estimación	E.E.	n	LI(95%)	LS(95%)
Primero	Media	6,76	0,13	277	6,51	7,01

Sobre el total de la muestra (277 casos) al 99% de confianza:

Variable	Parámetro	Estimación	E.E.	n	LI(99%)	LS(99%)
Primero	Media	6,76	0,13	277	6,43	7,09

Estas tres primeras estimaciones muestran cómo, sin cambiar el tamaño de la muestra ni la dispersión, el error aumenta (los intervalos se vuelven más amplios) cuando crece la confianza.

Sólo sobre el turno tarde (85 alumnos) al 95% de confianza:

Variable	Parámetro	Estimación	E.E.	n	LI(95%)	LS(95%)
Primero	Media	6,78	0,25	85	6,28	7,27

Si comparamos esta estimación con la segunda, que está hecha también al 95%, vemos que es menos precisa, ya que la distancia entre los límites es de $7{,}01 - 6{,}51 = 0{,}50$ en el primer caso y $7{,}27 - 6{,}28 = 0{,}99$. Esto se debe al menor tamaño de muestra: menos casos, más error de estimación.

El error de estimación en la proporción

En la construcción del intervalo de Wald, el término del error en la estimación de la proporción es:

$$z * \sqrt{\frac{\hat{p} * (1 - \hat{p})}{n}}$$

En él hay dos elementos en común con el error en la estimación de la media: los valores de z y de n. No agregaremos nada sobre ellos, porque el efecto es el mismo que en la media: un aumento de z por aumento de la confianza, da lugar a un

incremento en el error de estimación, mientras que un aumento en el tamaño de la muestra, lo reduce.
Lo nuevo en este caso es que no hay s, por el contrario, lo que hay en su lugar es el producto de la proporción por su complemento $\hat{p} * (1 - \hat{p})$, que se encuentra afectado por la raíz, pero eso no interesa para analizar su efecto sobre la precisión.
Recordemos el problema de la medición de la dispersión para variables nominales. Se vio que una variable nominal tiene poca dispersión cuando una categoría "absorbe" a las otras, cuando muchos casos están en una sola categoría, o cuando una categoría tiene una frecuencia superior a todas las demás. Por el contrario, la dispersión es elevada cuando las frecuencias son similares, cuando la distribución de casos es "pareja" en todas las categorías. En la estimación de la proporción estamos tratando solo con dos categorías, por lo que la dispersión será máxima cuando las proporciones de ellas sean similares. Siendo solo dos, son iguales cuando cada una de ellas vale 0,50 ($\hat{p} = 0{,}50\ y\ (1 - \hat{p}) = 0{,}50$), porque la mitad de los casos está en cada categoría. Por el contrario, la dispersión será menor cuanto más concentrados estén los casos en una de las categorías. Si, por ejemplo la proporción es 0,10 ($\hat{p} = 0{,}10\ y\ (1 - \hat{p}) = 0{,}90$) tendremos concentración de casos en una categoría, es decir, poca dispersión. Eso está expresado en la variabilidad medida como el producto de $\hat{p}$ por su complemento: $\hat{p} * (1 - \hat{p})$.
Cuando $\hat{p} = 0{,}50\ y\ (1 - \hat{p}) = 0{,}50$, entonces, el producto $\hat{p} * (1 - \hat{p}) = 0{,}25$. Por el contrario, cuando $\hat{p} = 0{,}10\ y\ (1 - \hat{p}) = 0{,}90$, entonces, el producto $\hat{p} * (1 - \hat{p}) = 0{,}09$.
Por eso, el producto $\hat{p} * (1 - \hat{p})$ es una medida de la dispersión de la variable nominal y ocupa, dentro del término del error, un lugar equivalente al de la varianza en la estimación de la media.
¿Cómo incide esto en el error de estimación? Como con la media, cuando la dispersión es grande, el error también lo es, entonces el error será mayor cuanto más parecidas sean $\hat{p}\ y\ (1 - \hat{p})$, dicho de otra manera, cuando $\hat{p}$ sea cercana a 0,50.
El razonamiento es el mismo que con la media, cuanto mayor sea la dispersión tanto más grande será el error y menos precisa la estimación. Pero en el caso de la media, la dispersión está medida con la desviación estándar, mientras que en la proporción, viene dada por el producto $\hat{p} * (1 - \hat{p})$, que es máximo cuando $\hat{p}$ es cercano a 0,50. Entonces, las peores condiciones para hacer una estimación de la proporción, serán aquellas en que la característica que se estima afecta a porciones cercanas a la mitad de la muestra, allí será máxima la dispersión y en consecuencia también el error de estimación.

Ejemplo: a partir de una encuesta, se estima la proporción de votos que tendrá un candidato en las próximas elecciones. La muestra es de 400 casos y 90 personas dijeron que votarán a ese candidato. Como 90 es el 22,5% de 400 (su frecuencia relativa), esa es la proporción que se halla en la muestra y la estimación por intervalo al 95% de confianza da:

$$\hat{p} \pm z * \sqrt{\frac{\hat{p} * (1 - \hat{p})}{n}} = 0{,}225 \pm 1{,}96 * \sqrt{\frac{0{,}225 * (1 - 0{,}225)}{400}} = 0{,}225 \pm 0{,}041$$

Los límites del intervalo son $L_i = 0{,}1841$ y $L_s = 0{,}2659$. Para comunicarlo, diremos que el candidato tiene una intención de voto de entre el 18,41% y el 26,59%.

Aunque la lectura correcta es que hay una confianza del 95% que el intervalo [18,41; 26,59]% contenga a la verdadera proporción de personas que dicen que votarán al candidato.

Repitamos el ejercicio, ahora suponiendo que la cantidad de personas que dice que lo votaría son 200 de los 400 encuestados, es decir si la proporción muestral hubiese sido del 50%. Siempre al 95% de confianza, la estimación es:

$$\hat{p} \pm z \cdot \sqrt{\frac{\hat{p} \cdot (1-\hat{p})}{n}} = 0{,}50 \pm 1{,}96 \cdot \sqrt{\frac{0{,}50 \cdot (1-0{,}50)}{400}} = 0{,}50 \pm 0{,}049$$

Vemos que el error de estimación ha pasado de 4,1% en el anterior a 4,9% ahora, sin que hayamos cambiado la confianza ni el tamaño de la muestra. Ese es el efecto de la proporción cuando es cercana al 50%.

Solicitamos a InfoStat® la estimación de la proporción de aprobados en diferentes condiciones:

Sobre el total de la muestra (277 casos) al 90%

Variable	Parámetro	Estimación	E.E.	n	LI(90%)	LS(90%)
Primero	Proporción(=1)	0,921	0,016	277	0,894	0,947

Sobre el total de la muestra (277 casos) al 95%

Variable	Parámetro	Estimación	E.E.	n	LI(95%)	LS(95%)
Primero	Proporción(=1)	0,921	0,016	277	0,889	0,952

Sobre el total de la muestra (277 casos) al 99%

Variable	Parámetro	Estimación	E.E.	n	LI(99%)	LS(99%)
Primero	Proporción(=1)	0,921	0,016	277	0,879	0,962

Vemos que al aumentar el nivel de confianza se reduce la precisión, ya que los límites se distancian, volviendo más amplio al intervalo.

Solo con el turno noche (110 alumnos) al 95%

Variable	Parámetro	Estimación	E.E.	n	LI(95%)	LS(95%)
Primero	Proporción(=1)	0,918	0,026	110	0,867	0,969

El intervalo se amplía respecto de la segunda de las estimaciones anteriores, aunque la confianza es la misma (95%), debido a la reducción en el número de casos.

Un elemento adicional a considerar sobre la calidad de una estimación es la **probabilidad de cobertura**, que indica la probabilidad que tienen los límites de contener efectivamente al parámetro. En el caso de la proporción, se escribe como $P(L_i \leq P \leq L_s)$ en la que L_i y L_s son variables aleatorias que corresponden a los límites del intervalo. Esta probabilidad de cobertura puede ser igual, menor o mayor que la confianza, que es una cobertura nominal, es decir, la que predice la teoría. La probabilidad de cobertura se calcula por simulación. Cepeda Cuervo et. al. (2008) muestran que el intervalo de Clopper-Pearson tiene una probabilidad de cobertura que supera a la nominal para todos los tamaños de muestra, por eso se lo considera conservador; ya que ofrece más certidumbre que la que se declara en

la confianza. Al contrario, el intervalo de Wald muestra probabilidad de cobertura inferior a la nominal aun cuando se usen muestras grandes. El intervalo de Wilson ofrece una probabilidad de cobertura más cercana a la nominal que el de Wald y que el exacto.
En el video *cobertura intervalos* se realiza una simulación que genera 100 intervalos para estimar una media poblacional de 20 ($\mu = 20$) con desviación estándar 10 ($\sigma = 10$ o $\sigma^2 = 100$) con muestras de tamaño 50, al 95% de confianza. En el gráfico se observa que el 94% de los intervalos contiene al parámetro, los intervalos rojos son los que no "atrapan" a la media poblacional. Este 94% es la probabilidad de cobertura.

En este capítulo hemos puesto en juego lo visto en los anteriores para poder generalizar las observaciones muestrales a toda la población de referencia, vemos que el modo con el que se hace es a través de los intervalos de confianza, que formalizan una práctica a la que estamos acostumbrados cuando hacemos estimaciones sobre cantidades que desconocemos: indicamos entre qué valores es más probable hallarlas.
La estructura general de los intervalos es:

$$estimador \pm error\ de\ estimación$$

Esa expresión ha tomado diferentes formas, ya sea para estimar la media de variables cuantitativas o la proporción de éxitos, para la que hay varios procedimientos de obtención de los límites.
En cualquiera de los casos, la lectura del intervalo obtenido se expresa:

Hay una confianza $1 - \alpha$ que el intervalo obtenido contenga al parámetro.

Capítulo 11 Prueba de hipótesis: la lógica

En este capítulo ingresamos a uno de los procedimientos de mayor difusión en las investigaciones en Psicología: la prueba de hipótesis. Se basa en los mismos principios de estimación de parámetros que se usaron para la construcción de intervalos de confianza. Aunque no está exento de críticas, este procedimiento es básico para hacer inferencias sobre la población, y las propuestas que existen como técnicas alternativas, requieren que se tenga dominio de las pruebas de hipótesis.

El razonamiento de la prueba de hipótesis

La prueba de hipótesis tiene como objetivo el de proveer argumentos para decidir en contextos de incertidumbre. A partir de lo que sabemos sobre las distribuciones en el muestreo, ése es el caso cuando necesitamos concluir acerca de una población, a partir de información que tenemos disponible en una muestra aleatoria. El resultado de la prueba permitirá decidir si lo que se observa en la muestra es compatible con una aseveración hipotética sobre la población. Nunca será posible decidir de manera taxativa que la hipótesis es verdadera, eso es algo que no podemos saber; por el contrario, podemos ver hasta qué punto lo que observamos en la muestra contradice —o no—lo que se afirma a escala poblacional. Es decir que podremos descartar una hipótesis por no ser compatible con lo que se observa, pero no a la inversa: no será posible "confirmar" una hipótesis, solo podremos concluir que la evidencia *no la contradice*, lo que también se expresa diciendo que *no hay evidencia para rechazarla.*

Empezaremos con ejemplos no muy cercanos a la estadística, a fin de ver que esta forma de razonar no es ajena a lo cotidiano. Una prueba de hipótesis puede compararse con un juicio: el acusado no es condenado hasta que no hay evidencia suficiente para hacerlo. La evidencia (las pruebas, en el lenguaje de la justicia) rara vez son completas, se trata de información fragmentada, sujeta a interpretaciones diferentes. En el inicio del juicio, "el acusado es inocente", en nuestra notación llamaremos a esa afirmación, **hipótesis nula**, y la indicaremos **Ho**. Esta expresión indica que se trata de un estado inicial: todos son inocentes hasta que se prueba lo contrario, por lo que la hipótesis nula señala que esta persona en particular (el acusado), no es diferente de cualquier ciudadano que no ha cometido delito. Mientras no haya pruebas suficientes, la hipótesis nula se considerará aceptada. En el juicio, el fiscal aportará pruebas en dirección contraria a esta hipótesis. Buscará información para probar que debe rechazarse la hipótesis nula y condenar al acusado. Difícilmente estarán a la vista todos los datos necesarios para reconstruir la situación y dar una respuesta absolutamente inequívoca, pero si hay suficiente evidencia, se dará la hipótesis nula por rechazada. La decisión de condenar al acusado solo se tomará cuando haya muy poco riesgo de equivocarse, cuando la probabilidad de decidir de manera errada sea muy pequeña.

En este ejemplo, la población es el conjunto completo de información necesaria para tomar la decisión de manera certera, sin error. Se trataría de un conjunto infinito de datos que permitiría la reconstrucción exacta de los hechos en los que participó el acusado. Por cierto, esa información nunca está disponible, por lo que

la decisión debe tomarse a partir de un fragmento de información, que son las pruebas que han podido reunirse (la evidencia). En la analogia que hacemos con nuestros procedimientos, esta evidencia constituye la muestra a partir de la que se juzgará la hipótesis nula: aceptarla o rechazarla. La muestra constituye el fragmento de información disponible, solo que en el caso de la estimación, ésta es obtenida con procedimientos que buscan su representatividad.

Otro ejemplo: tenemos dudas sobre lo equilibrada que pueda estar una moneda que va a usarse en un juego de azar. Repitiendo la notación del ejemplo anterior, formularemos una hipótesis nula que dice que X sale con la misma frecuencia que C, que equivale a decir que hasta que no se pruebe lo contrario, X no tiene ninguna diferencia con C, la moneda está equilibrada. Esta hipótesis nula puede escribirse de manera formal, porque "salir con la misma frecuencia que C" equivale a decir que, "en infinitas tiradas, la mitad de la veces saldrá X", por lo que escribiremos nuestra hipótesis nula así: H_0: P=1/2, a la que leeremos "la hipótesis nula afirma que la proporción de veces que saldrá cara es 1/2".
Luego debemos producir los datos para hacer la prueba, al tirar la moneda 100 veces esperaríamos —si la hipótesis nula se sostiene—, que salga aproximadamente 50 veces X. Las 100 tiradas son una muestra de las infinitas tiradas de la moneda, por lo que posiblemente no salga exactamente 50 veces X, podría salir 51 veces ó 52 y serían resultados esperables, debido a fluctuaciones propias del azar. Pero si de las 100 tiradas sale 80 veces X, concluiremos con pocas dudas que hay que rechazar la hipótesis nula. A la misma conclusión llegaríamos si, de 100 tiradas, solo sale 25 veces X. La pregunta que nos ayudará a responder el procedimiento de prueba de hipótesis es ¿cuántas más o menos veces que 50 debería salir X para que consideremos que tenemos "suficiente evidencia", para creer que la moneda no está equilibrada?

La lógica de la prueba de hipótesis consiste en plantear el escenario en el que H_0 es verdadera y observar qué tan probable es lo que hallamos en la muestra en ese caso. En el primer ejemplo el planteo es ¿qué tan probable sería haber hallado *estas pruebas* (las que lo involucran) contra el acusado, si éste fuera inocente? En el segundo preguntamos ¿qué tan probable habría sido hallar *esta cantidad de veces* que salió X, si la moneda estuviera equilibrada? De manera general la pregunta es ¿qué tan probable sería *éste resultado muestral* si la hipótesis nula fuera cierta?
Si la respuesta a esas preguntas es "muy probable", la decisión será la de no rechazar la hipótesis nula, porque los resultados muestrales hallados serían esperables (muy probables) bajo H_0. Al contrario, si la respuesta es "muy poco probable" decidiremos rechazar H_0, ya que se trata de un resultado poco esperable si H_0 fuera cierta.
En investigación, la prueba de hipótesis suele formularse de tal modo que rechazar H_0 implica aportar un nuevo hallazgo, por el contrario, aceptar H_0 equivale a que no hay cambios respecto de alguna situación inicial.
Algunos ejemplos de hipótesis nulas:
Esta droga no produce ningún efecto sobre la memoria.
La técnica terapéutica A es igualmente eficaz que la B.
Los métodos A y B para enseñar a leer a los niños producen iguales resultados.

La proporción de votos que obtendrá un candidato no ha variado respecto de las últimas elecciones.
Un programa de potabilización de agua no reduce la diarrea infantil.

En casi todos los casos, la expectativa del investigador está en rechazar la H_0, porque eso significa que ha hallado algo de interés: que la droga produce efectos, que hay técnicas terapéuticas mejores que otras y por tanto recomendables, que se pueden elegir mejores métodos para enseñar a leer, que el favor del electorado hacia un político es más o menos extendido.

La hipótesis nula es una afirmación sobre un parámetro que indica ausencia de diferencia.

El sentido de esa diferencia difiere según el tipo de prueba, veremos que hay pruebas que confrontan con valores históricos o con promedios generales o bien, que realizan comparaciones entre grupos. En todos los casos la hipótesis nula afirma algo que puede expresarse como "no hay diferencia", o "no hay cambio" o "no hay relación".
Hasta este punto se trata de la definición original de estas pruebas, desarrolladas inicialmente por Sir Ronald Fisher (1925) a las que llamó *pruebas de significación*. La idea básica es la de comparar los datos observados con la hipótesis que se pone a prueba. Fisher las ideó como manera de medir el grado de incompatibilidad de un conjunto de datos con la hipótesis nula, evaluando la probabilidad de hallar resultados como los observados o más extremos, si la hipótesis nula fuera cierta. Si esa probabilidad es muy pequeña, puede suceder que la muestra que se seleccionó haya sido excepcional, o bien que la afirmación hipotética sea falsa. Fisher argumentó que se trataba de un método objetivo para poner a prueba teorías y que puede ser usado en diferentes campos de conocimiento.

Con posterioridad a Fisher, Neyman y Pearson (1933) introducen dos cambios importantes en el procedimiento.
El primero consiste en tratar a las prueba no ya como métodos para validar teorías, sino como reglas de decisión, es decir, criterios que permiten decidir en las situaciones en que no se cuenta con toda la información necesaria.
El segundo cambio consiste en opone r a la hipótesis nula, otra hipótesis, llamada hipótesis alternativa, a la que se indica como H_1, que es hacia la que se suma evidencia cuando se rechaza H_0.
Veamos la aplicación de este modelo, que es el que usaremos a partir de ahora. La afirmación "los niños cuyos padres tienen alto nivel de educación tienen rendimiento en la escuela superior al promedio general" es una hipótesis, porque pretende tener carácter general, hace referencia a la población de niños en la escuela, los que asisten ahora y los que asistirán en el futuro; no podemos observar a la población completa, por lo tanto la hipótesis no puede probarse de manera definitiva, solo puede hacerse a partir de una muestra. Para formalizar esa hipótesis, construiremos una H_0 que niegue cualquier diferencia: "el rendimiento de niños con padres de alto nivel de educación es el mismo que el del promedio". A esta hipótesis, opondremos otra, que afirme "los niños cuyos padres tienen alto nivel de educación tienen rendimiento superior al promedio". A esta

última llamaremos hipótesis alternativa, H_1. Así formalizamos el planteo del problema.
Supongamos ahora que conocemos ese rendimiento promedio, medido por el puntaje en las pruebas y que vale 60 puntos para la población completa de alumnos. De modo que podemos formular las hipótesis ahora así:

H_0: "El rendimiento promedio de los niños con padres de alto nivel de educación es de 60 puntos"
H_1: "El rendimiento promedio de los niños con padres de alto nivel de educación es superior a 60 puntos"

Para poner a prueba la hipótesis tomaremos una muestra de niños con padres de mucha educación y veremos si su rendimiento es superior a 60 puntos. Supongamos que en la muestra hallamos una media de 62 puntos, ¿estamos autorizados para rechazar la H_0? Aunque 62 es mayor que 60, una diferencia de solo 2 puntos parece demasiado pequeña y podríamos atribuirla al azar. En el razonamiento de la prueba de hipótesis nos interesa evaluar la probabilidad de ocurrencia del resultado que se observa, si la hipótesis nula fuera cierta. En este caso será: "Si los hijos de padres con alto nivel de educación tuvieran el mismo rendimiento que el promedio (H_0), una diferencia de 2 puntos en el promedio muestral es probable, es esperable, puede deberse a la variabilidad propia de los datos muestrales, en consecuencia, esa diferencia no es suficiente para rechazar la H_0". En otros términos "Si los hijos de padres con alto nivel de educación tuvieran un rendimiento promedio de 60 puntos, no es improbable que una muestra arroje un resultado de 62 puntos". Dicho de otro modo: el resultado muestral no se aleja tanto de lo que esperaríamos si la H_0 fuera cierta, por lo tanto, no podemos rechazarla y concluimos que los hijos de padres con mucha educación no difieren del promedio.
Un elemento de mucha importancia es recordar que la hipótesis hace referencia a la población, mientras que nuestra observación es muestral, y sabemos que los resultados muestrales difieren de los valores paramétricos porque los primeros son variables aleatorias.
¿Qué habría sucedido si hubiésemos observado que el grupo de los hijos de padres con mucha educación tiene un rendimiento promedio de 95 puntos? Este resultado se aleja mucho de 60 que es el que sostiene H_0, es decir, si el hipotético fuera verdadero, sería muy poco probable hallar una muestra que promedie 95 puntos. En consecuencia seguramente rechazaríamos la H_0.
Al realizar pruebas de hipótesis, en lugar de evaluar intuitivamente si un valor muestral está cerca o lejos del valor hipotético, lo que haremos será evaluar cuál sería la probabilidad de hallarlo si fuera cierta la hipótesis nula. Cuando esta probabilidad sea grande no habrá evidencia para rechazarla, cuando sea pequeña decidiremos rechazarla. ¿Cuán grande o pequeña? Es de lo que nos ocuparemos a continuación.

Para realizar una prueba de hipótesis, necesitamos calcular la probabilidad del valor observado, si H_0 fuera cierta, es decir, si el parámetro tuviera ese valor (el que señala H_0). Es una probabilidad condicional que podemos por ahora escribir así:

$$p\left(^{observado}/_{la\ hipótesis\ nula\ es\ verdadera}\right)$$

Luego haremos más precisa esta expresión.

Comenzaremos con el ejemplo de una prueba de hipótesis sobre la media de una variable cuantitativa y luego acerca de la proporción para una categoría de una variable nominal.

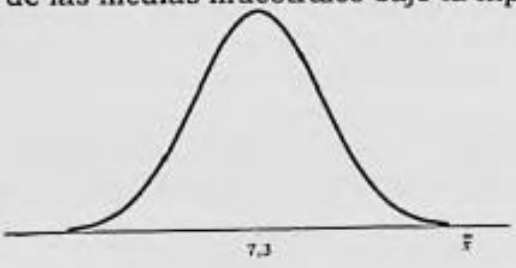
Prueba sobre la media

Ejemplo (datos ficticios): para una determinada carrera universitaria, históricamente los alumnos han tardado para recibirse un promedio de 7,30 años. Decimos históricamente para indicar que son datos acumulados por largo tiempo y que provienen de los registros de la facultad de años atrás. Se ha introducido un cambio en el plan de estudios de la carrera y puede creerse que con ese cambio los alumnos tardarán un tiempo distinto en recibirse. Tenemos entonces un promedio de la población de quienes se recibieron en las anteriores condiciones (una media poblacional histórica), y queremos hacer inferencia sobre la media poblacional de los alumnos que cursan con el nuevo plan. Estos últimos no están todos accesibles, porque hay alumnos que están cursando y otros que lo harán en el futuro, por lo que de esa población solo puede conocerse a una muestra de los que ya han egresado y ver cuánto tiempo han tardado ellos en recibirse.
Expresamos las hipótesis de este modo:

$$H_0: \mu = 7{,}30$$
$$H_1: \mu \neq 7{,}30$$

La hipótesis nula indica que la media poblacional de los alumnos que cursan con el nuevo plan es la misma que antes, que no hay diferencia, que no hay cambios. La hipótesis alternativa afirma lo contrario: que el tiempo promedio que tardan los alumnos en terminar la carrera con el nuevo plan es diferente a los 7,30 años históricos. Ambas son afirmaciones sobre la población (sobre el parámetro media poblacional), por eso son hipótesis.
Si la hipótesis nula fuera cierta, por lo que sabemos sobre las distribuciones en el muestreo, la siguiente sería la distribución de las medias muestrales:

Gráfico 1: Distribución de las medias muestrales bajo la hipótesis nula



Que quiere decir que "lo más probable" sería hallar a la media muestral alrededor de 7,30. Hay poca probabilidad de encontrar valores muy lejanos a 7,30, como lo muestran las áreas decrecientes, a medida que nos alejamos de la media hipotética. Por esta razón, para decidir si un resultado muestral se aleja mucho o

poco del valor paramétrico, deberemos determinar si es poco probable o muy probable. Será equivalente decir que un valor se aleja mucho de la media hipotética que decir que se trataría de un valor poco probable, si la media fuera la que propone la H_0.

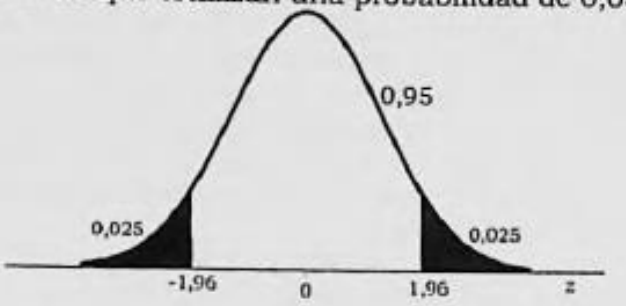
Afirmar que un valor muestral **se aleja mucho del valor poblacional** equivale a decir que **sería muy poco probable si el valor poblacional fuera el hipotético**

A fin de realizar la prueba de hipótesis debemos obtener una muestra. Supongamos que seleccionamos 100 egresados (usando un muestreo irrestricto aleatorio) y que encontramos un tiempo promedio para terminar la carrera de 7,50 años con una desviación estándar de 1,30 años ($\bar{x} = 7{,}50$ y $s = 1{,}30$). Debemos tener un criterio para decidir si este valor observado es compatible con la hipótesis nula ($\mu = 7{,}30$) o si constituye evidencia suficiente para rechazarla a favor de la hipótesis alternativa ($\mu \neq 7{,}30$). El criterio es el de ver cuán probable sería este valor observado si la hipótesis nula fuera cierta. En consecuencia, debemos calcular la probabilidad que tiene $\bar{x}$ de asumir el valor observado. Sin embargo, no es posible hallar probabilidades para valores únicos de una variable continua, por lo que buscaremos la probabilidad de hallar valores como el observado (7,50) *o más extremos que él*. Esto significa que nos preguntamos por la probabilidad que tiene la variable $\bar{x}$ de asumir el valor 7,50 *o uno más extremo*, es decir un valor que se aleje más de la media hipotética. Hemos dicho que "alejado" equivale a "poco probable si H_0 fuera cierta", por lo que los valores alejados se encuentran en los extremos de la distribución de $\bar{x}$, bajo el supuesto de H_0 verdadera (es decir, centrada en la media hipotética).
Para decidir si la evidencia hallada en la muestra es suficiente para rechazar la hipótesis nula, vamos a establecer a priori un valor máximo para la probabilidad de ocurrencia del valor muestral, o lo que es lo mismo, un valor máximo para el área extrema donde consideraremos que se encuentran los valores "alejados".

La toma de decisión

La H_0 se rechaza si hay poca probabilidad de hallar un valor como el observado o uno más extremo que él. Lo que llamamos poca probabilidad, puede establecerse a priori, por ejemplo en 0,05. Eso indica que consideraremos a los resultados con probabilidad menor a 0,05 como muy improbables de hallar si H_0 fuera cierta y nos conducirán a rechazarla. Por el contrario, si encontramos valores cuya probabilidad de ocurrencia es superior a 0,05, los trataremos como valores esperables y nos conducirán a aceptar la H_0. Como sabemos de la distribución normal, los valores de $z = \pm 1{,}96$ delimitan un área central de 95%, es decir que dejan fuera un área de 5%. Los valores de z superiores a 1,96 ó inferiores a -1,96 tienen una probabilidad de ocurrencia de 0,05, repartida en las dos "colas" de la distribución normal.

Gráfico 2: Áreas extremas que totalizan una probabilidad de 0,05



Los valores de $\bar{x}$ que correspondan a puntajes z que superen a 1,96 ó sean inferiores a -1,96 serán valores con probabilidad menor a 0,05, por lo que serán considerados como poco probables y conducirán a rechazar H_0. Por el contrario, los valores que tengan z comprendido entre -1,96 y 1,96 serán probables y nos llevarán a que aceptemos H_0. Estos dos puntos (-1,96 y 1,96) se denominan **valores críticos** de z y se indican con un subíndice: z_c.
En nuestro ejemplo, el valor observado es $\bar{x} = 7{,}50$, de aquí en adelante lo llamaremos $\bar{x}_{obs}$ (el valor de la media observado en la muestra). El puntaje z equivalente a ese $\bar{x}_{obs}$ se llama z observado (z_{obs}) y vale:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{7{,}50 - 7{,}30}{\frac{1{,}30}{\sqrt{100}}} = 1{,}54$$

Se trata de la transformación a puntaje z del valor observado de la media muestral. Se conoce con el nombre de **estadístico de prueba**.
Este puntaje no está en la zona extrema, porque no va más allá de 1,96; por el contrario, está entre -1,96 y 1,96 que pertenece a la parte de valores centrales de la distribución, los más probables. En consecuencia, la decisión es la de aceptar Ho y concluir que el tiempo que los alumnos tardan en completar la carrera no ha cambiado respecto del valor histórico. Dicho de otra manera, el valor observado de $\bar{x}_{obs} = 7{,}50$ es un resultado esperable si la media poblacional fuera de 7,30.
Por la forma en que hemos razonado y tomado la decisión, se comprende que a los valores de z comprendidos entre -1,96 y 1,96 se los denomine **zona de aceptación de Ho**. El otro conjunto de valores de z, los mayores a 1,96 junto a los menores a -1,96, constituyen la **zona de rechazo de Ho**. Luego de haber considerado a 0,05 como la probabilidad a la que llamamos "pequeña", quedaron determinados los valores de z_c que indican las zonas de aceptación y de rechazo.

La **zona de rechazo de Ho** es el conjunto de valores extremos de la distribución, donde es poco probable encontrar los valores muestrales si H_0 es verdadera.

La **zona de aceptación de Ho** es el conjunto de valores centrales de la distribución, donde es más probable encontrar los valores muestrales si H_0 es verdadera.

Luego de eso, el procedimiento que seguimos fue: calcular el puntaje z que corresponde al valor observado de $\bar{x}$, y luego ver si éste se encuentra en la zona de aceptación o de rechazo de H_0.

La probabilidad 0,05 como valor pequeño fue una elección y podría haber sido diferente; ese número tiene una larga tradición histórica, Fisher lo usaba regularmente, aunque aclarando que no era obligatorio y que no hay nada especial para elegirlo[83]. Se conoce como **nivel de significación** y se indica con la letra α (alfa). Es la probabilidad de hallar un valor como el observado o más extremo que él, si la hipótesis nula fuera cierta, por lo que es una probabilidad condicional que ahora escribimos como:

$$P(z<-1,96 \text{ ó } z>1,96/H_0 \text{ es verdadera})=0,05$$

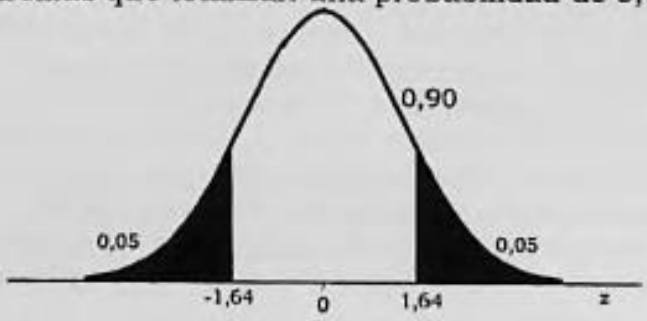
De esta expresión es importante recordar que alfa mide la probabilidad de hallar a z en la región de rechazo (más allá de los puntos críticos) si H_0 es verdadera.

El valor que elijamos para alfa indica a qué valores vamos a considerar como poco probables: en este caso se trata de valores tan poco probables como el 5%. Puede usarse un nivel de significación diferente, por ejemplo del 10% y los valores críticos de z serán diferentes. En efecto los puntos que dejan un área extrema del 10% son $z_c=\pm 1,64$.
En ese caso escribiremos:

$$P(z<-1,64 \text{ ó } z>1,64/H_0 \text{ es verdadera})=0,10$$

Se llama **nivel de significación** a la probabilidad de hallar al valor muestral en la zona de rechazo de H_0, si H_0 es verdadera. Se indica como **α**, y es elegido por el investigador

Gráfico 3: Áreas extremas que totalizan una probabilidad de 0,10



Por lo que, si el nivel de significación es 0,10 (α=0,10), la zona de aceptación de H_0 es el conjunto de valores z comprendidos entre -1,64 y 1,64 (centrales), mientras que la zona de rechazo de H_0 son los z menores a -1,64 y los mayores a 1,64 (los valores extremos cuya probabilidad es el área sombreada en el gráfico). El valor muestral del ejemplo ($z_{obs} = -1,54$) está también en la zona de aceptación

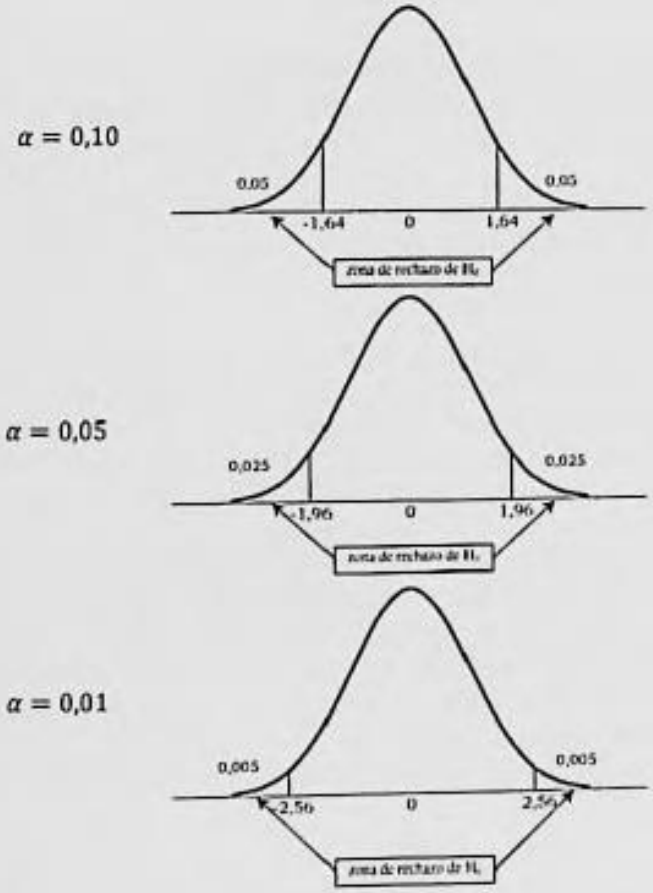
[83]En 1965, en *Statistical methods and scientific inference*, Fisher señaló: "Ningún investigador tiene un nivel de significación fijo, al cual año tras año y en toda circunstancia rechaza hipótesis; más bien entrega su mente a cada caso particular a la luz de la evidencia y de sus ideas"

para este nivel, por lo que tampoco se rechaza la H_0 a un nivel de significación de 0,10.
Otro nivel de significación que suele usarse es del 1%. Para él, los valores de z son ±2,56, por lo que la regla de decisión será: "si el valor de z correspondiente al valor observado de $\bar{x}$ está entre -2,56 y 2,56 se debe aceptar la H_0, si es menor a -2,56 o superior a 2,56 se debe rechazar la H_0".
Expresamos la probabilidad condicional como:

$$P(z<-2,56 \text{ ó } z>2,56/H_0 \text{ es verdadera})=0,01$$

Al igual que en los casos anteriores, cuando se expresan en términos de puntajes z, estos valores son fijos; no dependen de los resultados muestrales que se encuentren, constituyen una regla de decisión establecida a priori. Cuanto más pequeño se elige α, tanto más exigente es la prueba, en el sentido de que solo rechaza la hipótesis de no-diferencia si se observan valores muy alejados del hipotético.

Gráfico 4: Comparación de las zonas de aceptación y rechazo de H_0 con niveles de significación del 10, del 5 y del 1%



UNIVERSIDAD TECNICA DEL NORTE
BIBLIOTECA
Ibarra - Ecuador

Ejemplo (datos ficticios): para la misma carrera universitaria del ejemplo anterior, el promedio de calificación con que terminaban los estudios los alumnos era, según registros históricos, de 6,50. Nos preguntamos si, luego del cambio en el plan de estudios, esta nota promedio ha cambiado o sigue siendo la misma. El planteo de las hipótesis será ahora:

$$H_0: \mu = 6{,}50$$
$$H_0: \mu \neq 6{,}50$$

Por la misma razón que antes, no podemos analizar a la población completa, usaremos los datos obtenidos en una muestra. En ella encontramos, por ejemplo, que el promedio de los 100 egresados es de 6,65 con desviación estándar de 0,60, es decir: $\bar{x} = 6{,}65$ y $s = 0{,}60$. A un nivel de significación del 5%, los puntos críticos vuelven a ser $z_c = \pm 1{,}96$. Buscamos el estadístico de prueba transformando el valor observado de $\bar{x}$ a puntaje z y encontramos:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{6{,}65 - 6{,}50}{\frac{0{,}6}{\sqrt{100}}} = 2{,}50$$

El valor observado de $\bar{x}$ corresponde entonces a un z que supera al punto crítico (que es z_c=1,96), por lo que está en la zona de rechazo de H_0. La decisión es rechazar H_0 y concluir que el promedio de los alumnos es actualmente diferente del promedio histórico.

En los dos ejemplos vemos que la regla de decisión depende del nivel de significación. Cuando se fija en el 5% entonces se puede expresar como "si el valor de z correspondiente al valor observado de $\bar{x}$ está entre -1,96 y 1,96 se debe aceptar la H_0, si es menor a -1,96 o superior a 1,96 se debe rechazar la H_0". Cuando el nivel de significación es del 10%, diremos que "si el valor z correspondiente al valor observado de $\bar{x}$ está entre -1,64 y 1,64 se debe aceptar la H_0, si es menor a -1,64 o superior a 1,64 se debe rechazar la H_0".

Veamos más en detalle el significado de esta probabilidad que hemos fijado en 0,05 y que puede también elegirse en 0,10 ó en 0,01 y que llamamos α. Se trata de la probabilidad de hallar el valor observado en la muestra (o uno más extremo a él) si la H_0 fuera verdadera, por lo que cada vez que hallemos valores muestrales que se encuentran allí, tomaremos la decisión de rechazar H_0. Si la hipótesis nula fuera efectivamente verdadera, la decisión sería incorrecta, pero a eso no lo sabemos, porque nunca conocemos el verdadero valor del parámetro. Aunque sí podemos afirmar que al fijar α en el 5%, ésas serán las chances de equivocarnos rechazando una hipótesis nula que era verdadera. En el segundo ejemplo, cuyo resultado fue el de rechazar H_0, es muy importante indicar a qué nivel de significación se toma la decisión, porque ese número (5%) indica la probabilidad de haber tomado la decisión erróneamente. Mide la probabilidad de haber encontrado el promedio muestral de 6,65 por azar. Como esa probabilidad es pequeña, decidimos rechazar H_0.

Los puntos críticos en términos del estimador

Hay una manera diferente de establecer las zonas de aceptación y rechazo, que consiste en fijar los puntos críticos en términos de $\bar{x}$, en lugar de hacerlo como puntajes z. Por lo que en lugar de determinar los dos z_c, hallaremos los dos valores críticos de $\bar{x}$, a los que llamaremos $\bar{x}_c$[84]:

$$\bar{x}_c = \mu \pm z_c * \frac{s}{\sqrt{n}}$$

En el ejemplo sobre el tiempo que tardan los alumnos en terminar la carrera y a un nivel de significación de 5%, los valores de $\bar{x}_c$ son:

$$\bar{x}_c = \mu \pm z_c * \frac{s}{\sqrt{n}} = 7{,}30 \pm 1{,}96 * \frac{1{,}30}{\sqrt{100}} = 7{,}30 \pm 0{,}25$$

Al sumar obtenemos 7,55 y al restar 7,05. Estos son los puntos críticos expresados en términos de la variable original. La regla de decisión es ahora "si se encuentra un valor de $\bar{x}_{obs}$ comprendido entre 7,05 y 7,55 se debe aceptar la H_0. Si el valor observado de $\bar{x}_{obs}$ es inferior a 7,05 ó superior a 7,55 se debe rechazar H_0.

Para expresarlo como probabilidad condicionada:

$$P((\bar{x}<7{,}05 \text{ ó } \bar{x}>7{,}55)/\mu=7{,}30)=0{,}05$$

Que afirma que la probabilidad de hallar a $\bar{x}$ por debajo de 7,05 o por encima de 7,55 si la media de la población es 7,30, vale 0,05.

Al hacer la prueba, vemos que $\bar{x}_{obs} = 7{,}50$, que no va más allá de los puntos críticos, por lo que pertenece a la zona de aceptación de H_0. Concluimos que se acepta H_0 y que los alumnos no han cambiado el tiempo que tardan en terminar la carrera. La regla de decisión es la misma que antes, solo que ahora está expresada en el lenguaje de $\bar{x}$ y no de z y la conclusión también es la misma.

Volviendo ahora sobre el caso de los promedios con que egresan los estudiantes, para hallar los valores críticos de la media muestral hacemos:

$$\bar{x}_c = \mu \pm z_c * \frac{s}{\sqrt{n}} = 6{,}50 \pm 1{,}96 * \frac{0{,}60}{\sqrt{100}} = 6{,}50 \pm 0{,}12$$

Y resultan: 6,38 y 6,62. El promedio observado fue de 6,65, que supera al punto crítico superior y se encuentra en la zona de rechazo. Concluimos que se rechaza la H_0 y los alumnos egresan en la actualidad, con un promedio que difiere del histórico. Nuevamente, es la misma conclusión que si se trabaja sobre z.

[84]Aunque esta expresión es parecida a la de los intervalos de confianza, no se deben confundir. Aquí el centro está en el valor hipotético del parámetro, mientras que los intervalos de confianza se centran en el valor del estimador puntual.

Comparemos los dos procedimientos:

A. Usando valores críticos de z

1. Habiendo establecido el nivel de significación, determinar los valores z que dejan esa probabilidad en los extremos. Éstos son los z_c.
2. Para hallar el estadístico de prueba, transformar el valor observado de $\bar{x}$ en puntaje z haciendo:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}}$$

3. Observar la posición de este valor transformado en la distribución de probabilidades z

Por ejemplo, para un nivel de significación de 0,05 (ó 5%), en el ejemplo:

Gráfico 5: Ubicación de la zona de rechazo de H_0 a un nivel de significación de 0,05, sobre puntajes estándar (z), y del valor observado.



B. Usando los valores críticos de $\bar{x}$

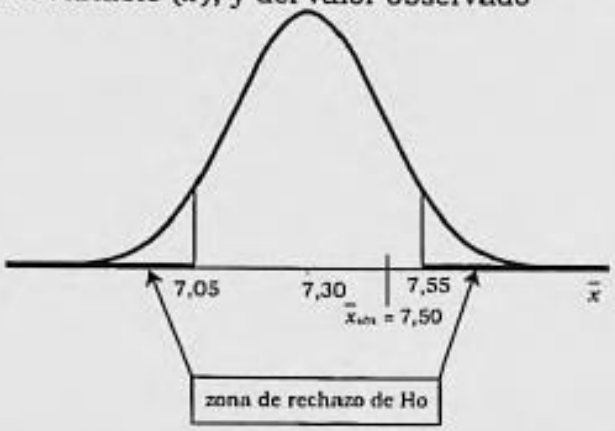
1. Habiendo establecido el nivel de significación, determinar los valores z que dejan esa probabilidad en los extremos. Éstos son los z_c.
2. Usar los z_c para determinar los correspondientes $\bar{x}_c$ haciendo:

$$\bar{x}_c = \mu \pm z_c * \frac{s}{\sqrt{n}}$$

3. Ver la posición de $\bar{x}_{obs}$ en la distribución de probabilidades de $\bar{x}$.

Por ejemplo, para el nivel de significación de 0,05 y el mismo ejemplo, resulta:

Gráfico 6: Ubicación de la zona de rechazo de H_0 a un nivel de significación de 0,05, sobre valores de la variable ($\bar{x}$), y del valor observado



La diferencia entre las dos formas de establecer los puntos criticos es que con la primera se determinan los valores de z_c a partir del nivel de significación y luego se transforma a puntaje z el valor muestral observado de $\bar{x}_{obs}$. En el segundo modo, los z_c se transforman (al revés) en puntos criticos de $\bar{x}_c$ y luego se compara el $\bar{x}_{obs}$ directamente, sin transformarlo.
Los gráficos 5 y 6 expresan lo mismo, el primero en el lenguaje estandarizado de z, el segundo en el de $\bar{x}$. Los procedimientos son equivalentes y puede vérselos aplicados de manera indiferenciada.

Pruebas unilaterales

A menudo la hipótesis alternativa no expresa solo que la media difiera del valor hipotético, sino que indica en qué *dirección* se espera que difiera. Por ejemplo, puede esperarse, en el ejemplo anterior, que los alumnos egresen con promedio superior a 6,50, con lo que ahora la H_1 dirá que $\mu > 6{,}50$. Se trata en este caso de una prueba unilateral y solo rechazaremos la H_0 si encontramos valores sustancialmente *mayores* que 6,50. Para el mismo nivel de significación del 5%, el valor z que nos interesa es el que delimita un área *superior* de 0,05.
Notemos la diferencia con las pruebas que tratamos antes: al nivel de 5% buscábamos dos z que dejaban en total 0,05 de área extrema (por encima y por debajo) o lo que es lo mismo, los dos z que dejan el 95% del área central. Ahora, como la prueba es unilateral y solo nos interesan valores que se excedan, solo buscamos un z, el que deja al 5% por encima. Ese valor de z es 1,64.[85]

[85]Este número es el mismo que usamos al nivel del 10% en pruebas bilaterales. Esto se debe a que en ese caso el 10% extremo se reparte en 5% en cada cola; ahora nos interesa una sola cola, del 5%.

Gráfico 7: Ubicación de las zonas de aceptación y rechazo de Ho para una prueba unilateral derecha.



Por oposición a las anteriores, las pruebas unilaterales se llaman **pruebas de una cola**. Como vemos en el gráfico, el conjunto de valores z que conducen a rechazar H_0 se encuentran solo a la derecha.

Ejemplo (datos ficticios): en la situación en que nuestro interés esté en analizar si el promedio con que egresan ahora los estudiantes es *superior* al valor histórico (y no solo diferente a él), las hipótesis de la prueba se expresan:

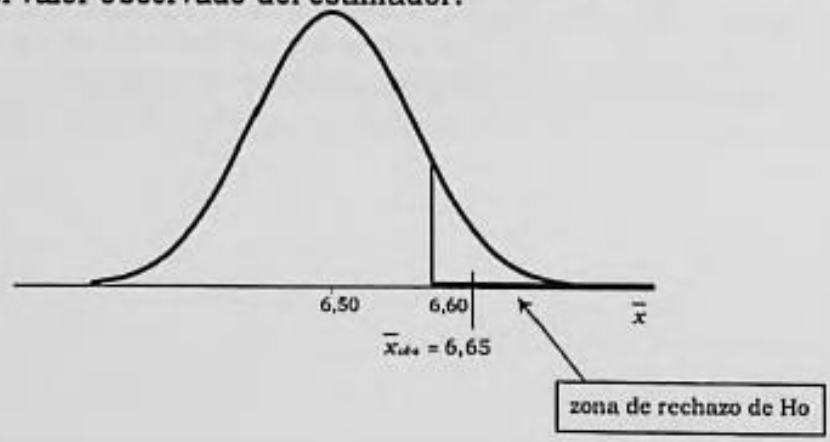
$$H_0: \mu = 6{,}50$$
$$H_1: \mu > 6{,}50$$

Haremos la prueba sobre los valores de $\bar{x}$, a un nivel de significación del 5% entonces:

$$\bar{x}_c = \mu + z_c * \frac{s}{\sqrt{n}} = 6{,}50 + 1{,}64 * \frac{0{,}60}{\sqrt{100}} = 6{,}50 + 0{,}10$$

Al sumar obtenemos 6,60 que es el único punto crítico que nos interesa por tratarse de una prueba unilateral y hemos sumado porque la prueba es derecha. Con lo que resulta la siguiente región de rechazo de H_0:

Gráfico 8: Región de rechazo unilateral derecha de $H_0: \mu = 6{,}50$ a un nivel de significación del 5%, con una muestra de 100 casos y desviación estándar 0,60, y ubicación del valor observado del estimador.



El valor observado de $\bar{x}$ había sido 6,65 que es mayor que el punto crítico, con lo que rechazamos la H_0 y concluimos que los alumnos egresan con un promedio significativamente mayor al histórico.
Si hubiésemos planteado la regla de decisión sobre los valores de z, a un nivel de significación del 5%, corresponde observar el gráfico 7 y obtener el puntaje z correspondiente al valor observado de la media muestral:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{6,65 - 6,50}{\frac{0,60}{\sqrt{100}}} = 2,5$$

Dado que este resultado supera al punto crítico del gráfico 7, concluimos nuevamente que los alumnos egresan con un promedio significativamente mayor al histórico.

En los párrafos anteriores hemos introducido una expresión nueva, que tiene un sentido preciso. Cuando decimos "significativamente mayor" no nos referimos al uso que suele darse en el lenguaje cotidiano, que es sinónimo de importante, de gran magnitud, grande, etc. Diremos que un valor es significativamente mayor o menor si se ha rechazado una prueba unilateral, o bien que es significativamente diferente o que la diferencia es significativa, si la H_0 que fue rechazada pertenece a una prueba bilateral. Además debe indicarse el nivel de significación de la prueba, por lo que diremos: según los datos observados y a un nivel del 5%, los alumnos egresan con un promedio significativamente superior al histórico.

Un resultado es **significativo** cuando conduce a rechazar una H_0 a un determinado nivel de significación.

Un resultado puede ser significativo a un nivel y no serlo a otro. Por ejemplo, si en una prueba bilateral y luego de transformar el valor observado a puntaje z, se obtiene z=2,3, este resultado conducirá a que se rechace H_0 al 5% (porque 2,3 es mayor que 1,96) pero que no se rechace al 1% (porque 2,3 no es mayor que 2,56). En ese caso diremos que se obtienen resultados significativos al 5% pero no al 1%. Luego veremos que esta clasificación puede hacerse más precisa.

Otros ejemplos de prueba de hipótesis sobre la media:
La investigación con sujetos animales en Psicología se basa en que distintas especies comparten mecanismos básicos, y los animales no humanos presentan un nivel de complejidad menor, lo que facilita la comprensión de complejos fenómenos en humanos. De hecho, los *modelos animales* han permitido avanzar en el conocimiento de mecanismos neurofisiológicos, cognitivos y comportamentales de seres humanos, siendo clave en el ámbito de la psicopatología y terapia psicológica.
En este contexto, alumnas de Psicología interesadas en la vulnerabilidad adolescente hacia el uso y abuso de drogas, recurrieron a un modelo animal para estudiar los efectos del alcohol[86]. Uno de los posibles factores que determinan las primeras aproximaciones a las drogas es la búsqueda de nuevas sensaciones, que se manifiesta en niveles elevados tanto en adolescentes humanos como no humanos, particularmente en roedores. En modelos animales, una manera de

[86]Dziula y Reyna (2005)

indagar el comportamiento de búsqueda de novedad es a través del uso de un objeto novedoso. Debido al escaso conocimiento sobre el comportamiento de los roedores ante tales objetos, las alumnas desarrollaron un estudio piloto. Concretamente, expusieron a 32 ratas Wistar[87] adolescentes (28 a 42 días de edad) a un objeto novedoso durante 3 minutos en distintos intervalos de tiempo.
A continuación, se retoman datos parciales del estudio piloto a los fines de exponer la modalidad de trabajo cuando se realiza una prueba de hipótesis sobre un valor determinado de la media. Primero ilustramos el caso de una prueba bilateral y luego unilateral.

Ejemplo (datos modificados[88]): en algunos estudios se ha observado que el tiempo que tardan los roedores (en general) en contactar un objeto novedoso (llamado tiempo de latencia, o simplemente latencia) es de 150 seg. En función de ello, se indaga si la latencia de contacto con el objeto en ratas Wistar adolescentes es la misma o no en relación a la reportada previamente en otros trabajos con roedores. Las hipótesis formuladas son:

$$H_0: \mu = 150$$
$$H_1: \mu \neq 150$$

En la muestra utilizada, la latencia media de contacto con el objeto es de 138,42 seg. y la desviación estándar 42,98. Se establece un nivel de significación del 5%, por lo que los puntos críticos en puntajes z son $z_c = \pm 1,96$.
Luego, se transforma el valor de $\bar{x}$ observado en puntaje z a través de la siguiente fórmula:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{138,42 - 150}{\frac{42,98}{\sqrt{32}}} = \frac{-11,58}{7,59} = -1,52$$

Vemos que al valor de $\bar{x}_{obs}$ le corresponde un valor z_{obs} que se encuentra entre los puntos críticos $z \pm 1,96$, es decir que se halla en la zona de no rechazo de la H_0, por lo que concluimos que no hay evidencia que indique que la latencia media de contacto con un objeto novedoso en ratas Wistar es distinta a la latencia que manifiestan los roedores en general.

Se obtiene la misma conclusión si se utilizan los valores críticos de $\bar{x}$. Revisemos el procedimiento: luego de haber establecido el nivel de significación al 5%, se obtienen los puntos críticos en puntajes originales ($\bar{x}_c$) a partir de los puntos críticos en puntajes z (z_c), a través de la siguiente fórmula[89]:

$$\bar{x}_c = \mu \pm z_c * \frac{s}{\sqrt{n}} = 150 \pm 1,96 * \frac{42,98}{\sqrt{32}} = 150 \pm 14,89$$

---

[87]Se trata de una línea albina de la rata parda. Fue desarrollada en el Wistar Institute en 1906 para fines de investigación biomédica, se trata de la primera rata empleada como organismo modelo (anteriormente se trabajaba con el ratón).
[88]Algunos de los datos son ficticios debido a la falta de disponibilidad y a la necesidad de adaptar el ejemplo a nuestros fines. Se mantiene la temática del estudio de referencia, aunque los resultados mostrados no corresponden exactamente a él.
[89]Sumamos y restamos para obtener dos puntos críticos, porque se trata de una prueba bilateral.

Entonces, los $\bar{x}_c$ que delimitan las zonas de rechazo y no rechazo son 135,02 y 164,89, y el valor observado de $\bar{x} = 138{,}42$ se encuentra comprendido entre ellos, por lo que no se rechaza la H_0.

Ejemplo (datos reales[90]): la literatura sobre comportamiento exploratorio en roedores (en general) indica que cuando los organismos son expuestos durante 180 seg a un objeto novedoso permanecen en contacto con el mismo (duración) 14 seg en promedio. Debido a las caracteristicas del periodo adolescente, en este trabajo se formula una hipótesis que indica que las ratas adolescentes estarán más tiempo en contacto con el objeto. Las hipótesis formuladas son:

$$H_0: \mu = 14$$
$$H_1: \mu > 14$$

En los animales que comprenden la muestra bajo análisis, se observa que la duración de contacto con el objeto es de 17,43 seg y la desviación estándar 4,25. El nivel de significación se establece en el 5% y, dado que la prueba es unilateral derecha, el punto critico en puntaje z es 1,64.
Luego, transformamos el valor de $\bar{x}$ observado en puntaje z:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{17{,}43 - 14}{\frac{4{,}25}{\sqrt{32}}} = \frac{3{,}43}{0{,}75} = 4{,}57$$

Al valor de $\bar{x}$ observado le corresponde un valor $z = 4{,}57$, que resulta superior al $z_c = 1{,}64$, por lo que se rechaza la H_0, es decir que las ratas adolescentes muestran una duración mayor de contacto con un objeto novedoso que lo señalado por la literatura para roedores en general.
Obtenemos la misma conclusión si usamos los valores críticos de $\bar{x}$. Una vez establecido el nivel de significación al 5%, se obtienen los puntos críticos en puntajes originales ($\bar{x}_c$) a partir de los puntos criticos en puntajes z (z_c)[91]:

$$\bar{x}_c = \mu + z_c * \frac{s}{\sqrt{n}} = 14 + 1{,}64 * \frac{4{,}25}{\sqrt{32}} = 14 + 1{,}23 = 15{,}23$$

El valor observado de $\bar{x} = 17{,}43$ resulta mayor a $\bar{x}_c = 15{,}23$, por lo que se rechaza la H_0, y concluimos que la duración promedio de contacto con un objeto novedoso en ratas adolescentes es significativamente mayor a 14.

Ejemplo (datos reales): luego de haber evaluado la latencia de contacto con un objeto novedoso de los animales en repetidas ocasiones, los investigadores observan un valor promedio de 112,48 seg. Ahora, están interesados en indagar cuál será la latencia de contacto si las ratas son nuevamente expuestas al objeto novedoso, suponiendo que será menor debido a la disminución del carácter novedoso que hacia que los animales tardaran en contactar el objeto en las exposiciones iniciales. Las hipótesis formuladas son:

---

[90] Ver nota anterior

[91] Solo se suma para obtener el punto crítico de la derecha, porque se trata de una prueba unilateral derecha.

$$H_0: \mu = 112{,}48$$
$$H_1: \mu < 112{,}48$$

En la nueva exposición, la latencia promedio de contacto con el objeto es de 71,36 y la desviación estándar es de 45,77. El nivel de significación se establece en el 5% y, dado que la prueba es unilateral izquierda, el punto crítico en puntaje z es -1,64.
Luego, transformamos el valor de $\bar{x}_c$ observado en puntaje z con el estadístico de prueba:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu}{\frac{s}{\sqrt{n}}} = \frac{71{,}36 - 112{,}48}{\frac{45{,}77}{\sqrt{32}}} = \frac{-41{,}12}{8{,}09} = -5{,}08$$

Vemos entonces que al valor de $\bar{x}_c$ observado le corresponde un valor z = *-5,08*, que resulta inferior al z_c = *-1,64*, por lo que se rechaza la H_0, es decir que la latencia de contacto con el objeto novedoso en una nueva exposición es significativamente menor a 112,48 seg.
A la misma conclusión se arriba si se realizan los cálculos con los valores críticos de $\bar{x}_c$, que se obtienen a partir de los puntos críticos en puntajes z (z_c), a través de la siguiente fórmula[92]:

$$\bar{x}_c = \mu - z_c * \frac{s}{\sqrt{n}} = 112{,}48 - 1{,}64 * \frac{45{,}77}{\sqrt{32}} = 112{,}48 - 13{,}27 = 99{,}21$$

El valor observado de $\bar{x} = 71{,}36$ resulta menor a $\bar{x}_c = 99{,}21$, por lo que se rechaza la H_0, la latencia promedio de contacto con el objeto novedoso en la nueva exposición es significativamente menor a 112,48 seg.
El video *prueba t una muestra* ilustra los comandos para pedir esta prueba a Infostat®, cuya salida es:

```
Prueba t para una media

Valor de la media bajo la hipótesis nula: 112,48
```

Variable	n	Media	DE	T	p(Unilateral I)
latencia2	32	71,36	45,77	-5,08	<0,0001

Más adelante se verá el significado del último valor que muestra la tabla.

Debemos recordar que el carácter unilateral o bilateral de la prueba no depende de la H_0 sino de la H_1. En efecto, la H_0 siempre indica un valor determinado para el parámetro (hasta aquí la media), mientras que la H_1 puede indicar un valor diferente si la prueba es bilateral, o bien señalar la dirección de la diferencia hacia los mayores o menores y en esos casos, la prueba es unilateral. La decisión de hacer una prueba unilateral o bilateral depende de cada investigación concreta, de la pregunta que el investigador formula.

[92]Solo se resta para obtener el punto crítico izquierdo, porque es una prueba unilateral izquierda.

Cuadro 1: Valores criticos usuales de la distribución normal

Significación	Puntaje z para prueba:		
	Bilateral	Unilateral derecha	Unilateral izquierda
0,10	±1,64	+1,28	-1,28
0,05	±1,96	+1,64	-1,64
0,01	±2,57	+2,33	-2,33

Prueba sobre la proporción

De modo equivalente a los intervalos de confianza, comenzaremos con la prueba de hipótesis sobre una proporción usando la distribución binomial, para luego usar la aproximación normal, si los supuestos se cumplen. El procedimiento conlleva los mismos pasos que cuando se trata de la media: se plantean, en primer lugar, las hipótesis nula y alternativa. La hipótesis nula afirma un valor para la proporción poblacional, mientras que la hipótesis alternativa puede, o bien solo indicar que el valor es diferente (prueba bilateral), o bien precisar si la diferencia se espera hacia valores mayores o menores que los indicados por la hipótesis nula (prueba unilateral). Una vez fijado el nivel de significación (α) y la lateralidad de la prueba, deben determinarse los valores de $\hat{p}$ que dejan esa probabilidad por encima (en el caso de una prueba unilateral derecha), por debajo (unilateral izquierda), o bien repartida en ambas colas (si es una prueba bilateral). La determinación de esos puntos se realiza con la distribución binomial, por lo que es necesario transformar la variable *proporción de éxitos* (p) al *número de éxitos* (x). Esta transformación vale para la proporción hipotética (P) y para la observada ($\hat{p}$):

$$P = \frac{X}{n} \quad \text{es decir} \quad X = P \cdot n$$

$$\hat{p} = \frac{\hat{x}}{n} \quad \text{es decir} \quad \hat{x} = \hat{p} \cdot n$$

Ejemplo (datos ficticios): un político tenía, haces tres meses una intención de voto equivalente al 30% del padrón. De acuerdo con algunas acciones de campaña, se cree que esta proporción pudo haber aumentado, por lo que el planteo de las hipótesis es:

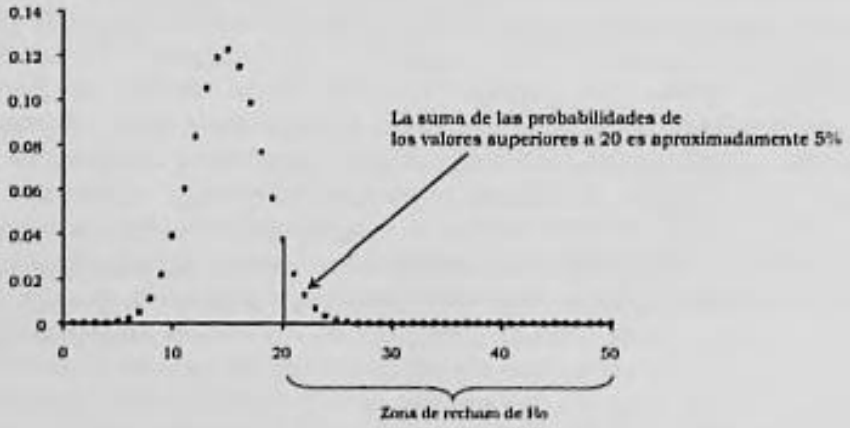
$$H_0: P = 0{,}30$$
$$H_1: P > 0{,}30$$

Hipótesis que se pondrá a prueba sobre una muestra de 50 casos. Al igual que sucedió con la media, estos son valores que planteamos de manera hipotética acerca del parámetro, en este caso la proporción poblacional (P). La H_0 indica que la proporción de votos sigue siendo la misma. Se trata de una prueba unilateral derecha, porque estamos interesados en encontrar un eventual aumento en la proporción de votantes que tiene el candidato, por eso la H_1 indica una proporción mayor.

Se fija un nivel de significación de 5% y, para determinar los puntos criticos bajo un modelo binomial, se transforma el valor hipotético de P al correspondiente a X en la muestra dada:

$$X = P * n = 0{,}30 * 50 = 15$$

Con lo que el punto crítico es el valor de $\hat{x}$ que deja por encima (porque es una prueba unilateral derecha) al 5% de los valores posibles. En InfoStat® se ingresan como datos los valores de $n = 50, P = 0.30$ y $Prob.(X > x) = 0.05$, para obtener, que el número de éxitos es 20. Por lo que el valor de $\hat{x}$ que es superado por el 5% de los valores muestrales posibles es 20. La representación gráfica es la siguiente:



Repasemos la interpretación de estas operaciones: si la proporción de votos que el candidato tiene en la población total fuera del 30% (esa es la hipótesis nula), entonces se esperaría que en una muestra de 50 casos, haya 15 que lo voten (15 es el 30% de 50). Como la muestra es aleatoria, la cantidad de votos que se obtienen en la muestra es aleatoria, puede ir desde cero hasta cincuenta, con diferentes probabilidades, que muestra el gráfico anterior. El criterio del 5%, establece al valor 20 votos como punto crítico. Eso quiere decir que, si la proporción de votos que el candidato tiene en toda la población fuera del 30%, la probabilidad de encontrar más de 20 votos en una muestra de 50 es menor al 5%. La regla de decisión será entonces: rechazar la hipótesis nula si en la muestra se encuentran más de 20 votos.

Si en la encuesta realizada sobre la muestra de 50 casos se encuentran 16 personas que dicen que lo votarán (con lo que[93] $\hat{p} = 32\%$), la decisión será la de no rechazar H_0 y considerar que no hay evidencia para creer que la proporción de votos que el candidato tiene, haya aumentado de su 30% anterior.

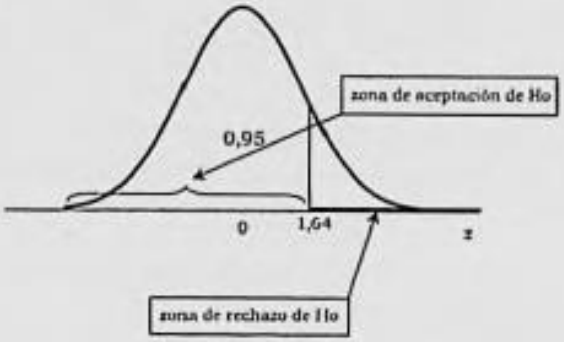
El punto crítico situado en 20 éxitos equivale a $\hat{p}_c = 0{,}40$[94]. La comparación de los 16 éxitos muestrales con los 20 del punto crítico es la misma que la del 32% muestral frente al 40% crítico.

---

[93] $\hat{p} = \frac{16}{50} = 0{,}32$

[94] Que proviene de $\frac{20}{50}$

Si se tratara de una muestra de mayor tamaño y tanto $n * P$ como $n * (1 - P)$ fueran mayores a 5, podríamos usar la aproximación normal de la distribución binomial. Para ello, establecemos un nivel de significación de 5%, y el valor crítico de z (en prueba unilateral) es 1,64. Ahora en términos de z, las zonas de aceptación y rechazo quedan así:



Una vez fijado el nivel de significación (α) y la lateralidad de la prueba, quedan determinados los puntos críticos en términos de z, según el cuadro 1.
La principal diferencia a tener en cuenta para la transformación a puntaje z de la proporción es el cálculo de su error estándar que, en la aproximación normal de la distribución en el muestreo de las $\hat{p}$ es:

$$\sigma_{\hat{p}} = \sqrt{\frac{P * (1 - P)}{n}}$$

En la construcción de intervalos de confianza es necesario aproximar $P * (1 - P)$ a través de $\hat{p} * (1 - \hat{p})$, porque se ignora el valor de la proporción poblacional. En la prueba de hipótesis, la situación es diferente, porque se cuenta con una P (poblacional) hipotética, y es esa la que se utiliza para el cálculo de $\sigma_{\hat{p}}$. Por lo tanto, la transformación del valor observado en la muestra a puntajes z se hará según:

$$z_{obs} = \frac{\hat{p}_{obs} - P}{\sqrt{\frac{P*(1-P)}{n}}}$$

Que es el estadístico de prueba para la prueba de proporciones que debe usarse cuando sea válida la aproximación normal para la distribución binomial. De acuerdo a que la posición de este z_{obs}, sea en la zona de aceptación o de rechazo de H_0, se toma la decisión.

Nuevamente sobre el ejemplo con las mismas hipótesis, nula y alternativa

$$H_0: P = 0{,}30$$
$$H_1: P > 0{,}30$$

Sea ahora que se trató de una muestra de 200 ciudadanos, en la que se halla que 64 dicen que van a votar a ese candidato (de este modo la proporción muestral sigue siendo de 32%). En la muestra entonces:

$$\hat{p} = \frac{64}{200} = 0{,}32$$

Nos preguntamos si este valor puede considerarse como un verdadero aumento respecto del 30% anterior o si solo se explica por razones de azar. Repitiendo la operación que realizamos para la media, transformamos este valor observado de la proporción muestral a puntaje z y hallamos el estadístico de prueba:

$$z_{obs} = \frac{\hat{p}_{obs} - P}{\sqrt{\frac{P*(1-P)}{n}}} = \frac{0{,}32 - 0{,}30}{\sqrt{\frac{0{,}30*(1-0{,}30)}{200}}} = 0{,}617$$

Este puntaje de z_{obs} no supera al punto crítico (z=1,64) por lo que se sitúa en la zona de aceptación de H_0. Concluimos que la proporción no ha aumentado respecto del valor anterior.

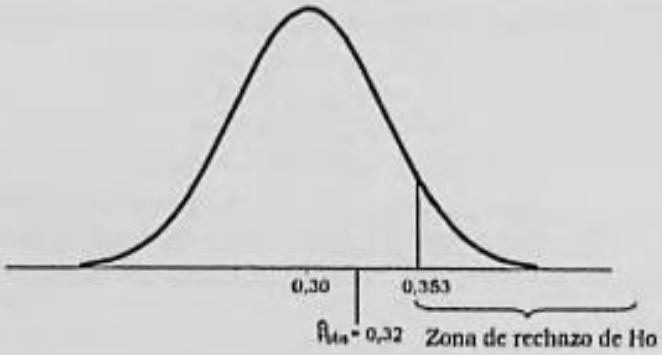
Para repetir la prueba sobre valores del estimador $\hat{p}$, vamos a transformar el punto crítico de acuerdo a la expresión general:

$$\hat{p} = P \pm z_c * \sqrt{\frac{P * (1-P)}{n}}$$

de la que usaremos ambos signos cuando se trate de una prueba bilateral o solo la suma si es unilateral derecha o solo la resta si es unilateral izquierda. Para nuestro problema, corresponde sumar, por lo que resulta:

$$\hat{p} = P + z_c * \sqrt{\frac{P * (1-P)}{n}} = 0{,}30 + 1{,}64 * \sqrt{\frac{0{,}03 * (1-0{,}30)}{200}} = 0{,}353$$

Representamos gráficamente la zona de rechazo como la cola derecha de la distribución de las $\hat{p}$:



El valor hallado en la muestra ($\hat{p}_{obs}$ = 0,32) es menor que el punto crítico, por lo que no está en la zona de rechazo, no rechazamos la H_0 y concluimos que no hay evidencia para creer que el candidato haya aumentado su proporción de votos. Como había sucedido antes, la conclusión es la misma si trabajamos sobre los puntajes estandarizados o sobre valores del estimador. Sin embargo, el punto crítico expresado en términos de $\hat{p}$ es diferente, cuando se usó la distribución binomial su valor fue 40% y ahora es 35%.

En los ejemplos siguientes trabajaremos con muestras grandes por lo que las pruebas se realizan usando la aproximación normal.

Ejemplo (datos reales): en el estudio Latinobarómetro[95] se menciona la importancia de comprender la percepción de la gente sobre el cambio generacional, cómo vivían los padres en relación a ellos y cómo vivirán los hijos con respecto a ellos (expectativa futura). En el año 2004, el 58,2% de los argentinos encuestados consideraba que los hijos vivirían mejor que ellos. En el año 2005, los investigadores indagan nuevamente la expectativa futura. Dado que habían observado fluctuaciones en años previos se preguntan si esa expectativa positiva habrá cambiado o no respecto del año anterior. Las hipótesis que se formulan son:

$$H_0: P = 0{,}582$$
$$H_1: P \neq 0{,}582$$

En el estudio del año 2005, observaron que 676 participantes de los 1200 que componían la muestra consideraban que sus hijos vivirían mejor que ellos, siendo la proporción en la muestra:

$$\hat{p} = \frac{676}{1200} = 0{,}563$$

El nivel de significación se establece al 5%, por lo que los puntos críticos en puntajes z son $z_c = \pm 1{,}96$ (prueba bilateral).
Para responder a la hipótesis planteada, se transforma el valor de proporción observado a puntaje z haciendo:

$$z_{obs} = \frac{\hat{p}_{obs} - P}{\sqrt{\frac{P \cdot (1-P)}{n}}} = \frac{0{,}563 - 0{,}582}{\sqrt{\frac{0{,}582 \cdot (1-0{,}582)}{1200}}} = -1{,}36$$

El valor $z_{obs} = -1{,}36$ se encuentra entre los puntos críticos ±1,96, es decir que se halla en la zona de no rechazo de la H_0, por lo cual se concluye que no hay evidencia que indique que la proporción de expectativas positivas haya cambiado, la proporción no es significativamente distinta de 0,582.
Se alcanza la misma conclusión si se realizan los cálculos en función de los valores del estimador. Establecido el nivel de significación al 5%, se obtienen los puntos críticos en puntajes originales ($\hat{p}$) a partir de los puntos críticos en puntajes z (z_c):

$$\hat{p} = P \pm z_c \cdot \sqrt{\frac{P \cdot (1-P)}{n}} = 0{,}582 \pm 1{,}96 \cdot \sqrt{\frac{0{,}582 \cdot (1-0{,}582)}{1200}} = 0{,}582 \pm 0{,}027$$

De esta manera se obtienen los $\hat{p}_c$ que delimitan las zonas de rechazo y no rechazo: 0,55 y 0,61. El valor $\hat{p}_{obs} = 0{,}563$ se encuentra comprendido entre ellos, por lo que no se rechaza la H_0.

---

[95]Latinobarómetro es un estudio de opinión pública que aplica anualmente alrededor de 19.000 entrevistas en 18 países de América Latina representando a más de 400 millones de habitantes. Corporación Latinobarómetro es una ONG sin fines de lucro con sede en Santiago de Chile, única responsable de la producción y publicación de los datos. http://www.latinobarometro.org/

Ejemplo (datos reales): otro de los aspectos indagados en el estudio Latinobarómetro se refiere al progreso en la reducción de la corrupción en las instituciones del Estado. En el año 2004, el 3,33% de los encuestados argentinos consideraba que se habia progresado mucho en ese aspecto. En el estudio del 2005, se espera que los resultados sean más favorables debido a la aplicación de una serie de medidas tendientes a controlar la corrupción institucional. Asi, las hipótesis que se formulan son:

$$H_0: P = 0{,}033$$
$$H_1: P > 0{,}033$$

De los 1200 argentinos encuestados en el año 2005, 51 señalan que se ha progresado mucho en reducir la corrupción institucional, es decir que la proporción en la muestra es

$$\hat{p} = \frac{51}{1200} = 0{,}043$$

El nivel de significación se establece en el 5%, dado que la prueba es unilateral derecha el único punto crítico en puntaje z es 1,64.
Luego, se transforma el valor de proporción observado en puntaje z, usando el estadístico de prueba:

$$z_{obs} = \frac{\hat{p}_{obs} - P}{\sqrt{\frac{P*(1-P)}{n}}} = \frac{0{,}043 - 0{,}033}{\sqrt{\frac{0{,}033*(1-0{,}033)}{1200}}} = 1{,}94$$

El valor $z_{obs} = 1{,}94$ resulta superior al $z_c = 1{,}64$, por lo que se rechaza la H_0. Por eso concluimos que la proporción de personas que declaran que se ha progresado en la reducción de la corrupción institucional se incrementó de manera significativa.
Se obtiene la misma conclusión a partir de los valores del estimador. Establecido el nivel de significación al 5%, se obtiene el punto crítico en puntaje original ($\hat{p}_c$) a partir del punto crítico en puntajes z (z_c):

$$\hat{p} = P + z_c * \sqrt{\frac{P*(1-P)}{n}} = 0{,}033 + 1{,}64 * \sqrt{\frac{0{,}033*(1-0{,}033)}{1200}} = 0{,}033 + 0{,}008 = 0{,}041$$

El valor observado de $\hat{p}_{obs} = 0{,}043$ resulta mayor a $\hat{p}_c = 0{,}041$, por lo que se rechaza la H_0, y se concluye que la proporción de quienes creen que se ha progresado en la reducción de la corrupción institucional se ha incrementado de manera significativa.

Ejemplo (datos reales): otro tema que aborda Latinobarómetro es el interés por la política. En el estudio del año 2004, el 11% de los encuestados argentinos manifestó estar muy interesado en la política. Si bien no ha habido notables cambios en la última década con respecto al interés de los ciudadanos en la política, una serie de indicadores llevaron a los investigadores a considerar que el interés en esta cuestión podría haber disminuido. Las hipótesis planteadas son:

$$H_0: P = 0{,}11$$

$$H_1: P < 0{,}11$$

De la muestra de 1200 argentinos encuestados en el año 2005, 111 manifiestan un elevado interés en la política, la proporción en la muestra es:

$$\hat{p} = \frac{111}{1200} = 0{,}093$$

El nivel de significación se establece en el 5%, dado que la prueba es unilateral izquierda el punto crítico en puntaje z es -1,64. Con el estadístico de prueba se transforma el valor de proporción observado en puntaje z:

$$z_{obs} = \frac{\hat{p}_{obs} - P}{\sqrt{\frac{P*(1-P)}{n}}} = \frac{0{,}093 - 0{,}11}{\sqrt{\frac{0{,}11*(1-0{,}11)}{1200}}} = -1{,}88$$

El valor $z_{obs} = -1{,}88$ resulta inferior al $z_c = -1{,}64$, por lo que se rechaza la H_0. Concluimos que la proporción de personas que manifiestan elevado interés en la política ha disminuido de manera significativa.

Como antes, puede alcanzarse la misma conclusión realizando los cálculos con el valor crítico del estimador:

$$\hat{p}_c = P - z_c * \sqrt{\frac{P*(1-P)}{n}} = 0{,}11 - 1{,}64 * \sqrt{\frac{0{,}11*(1-0{,}11)}{1200}} = 0{,}11 - 0{,}015 = 0{,}095$$

El valor observado de $\hat{p}_{obs} = 0{,}093$ resulta menor a $\hat{p}_c = 0{,}095$, por lo que se rechaza la H_0. Se concluye entonces que la proporción de ciudadanos argentinos con alto interés en la política en el año 2005 es significativamente menor a 0,11.

Tipos de error en las pruebas de hipótesis

Dado que la decisión de aceptar o rechazar la H_0 se toma de manera probabilística, siempre existe la posibilidad de tomar una decisión incorrecta. Esto sucede porque las muestras son tomadas al azar y puede suceder que la que usamos para tomar la decisión sea una muestra extrema. Aunque es un resultado poco probable, no es imposible.

Como hemos visto, el nivel de significación mide la probabilidad de hallar un determinado resultado muestral si la H_0 fuera cierta, es una probabilidad pequeña, que habitualmente fijamos en 0,05 ó 0,01. Si la H_0 es cierta y la muestra sobre la que basamos la decisión es extrema, es decir, tiene un valor ubicado en alguna de las colas de la distribución, la decisión será la de rechazar H_0 y esa decisión será errónea. La decisión de rechazar puede deberse o bien a que H_0 sea efectivamente falsa, o bien a que H_0 sea verdadera y se haya obtenido una de esas muestras muy poco probables. Por esta razón el nivel de significación mide la probabilidad de errar en la decisión de esta manera: rechazando una H_0 que es verdadera. Al igual que en los intervalos de confianza, éste no es un error de cálculo ni una equivocación, sino una imprecisión inherente a todos los procesos de estimación. Éste error se conoce como **Error de Tipo I** (ETI).

El **Error de Tipo I** es tomar una decisión errónea que consiste en rechazar la H_0 cuando esta es verdadera. Su probabilidad está fijada de antemano y es α, el nivel de significación de la prueba.

En consecuencia, establecer α es afirmar que se está dispuesto a correr ese riesgo de cometer el ETI. En un experimento que consiste en decidir si una droga produce efectos sobre un determinada patologia, la Ho dirá que no hay efecto, por lo que cometer el ETI será creer que hay efecto (rechazar H_0) cuando en realidad no lo haya (H_0 verdadera). Como no sabemos si H_0 es verdadera o falsa, cada vez que rechacemos H_0 debemos recordar que hay una probabilidad α de haber tomado una decisión incorrecta. Esta incertidumbre está siempre presente en evaluación psicológica y educativa y, en general en la toma de decisión en contextos de incertidumbre.
Ejemplo ilustrativo: las preguntas de un examen oral son una muestra de lo que el alumno sabe, si se usa un bolillero, la elección del tema que toca es aleatoria. Supongamos que un alumno ha estudiado muy poco, pero la unidad que le toca desarrollar es alguna de las (muy pocas) que sabe. En ese caso responderá correctamente y la decisión del docente será darle por aprobado el examen. Si supiéramos que el alumno ignora todos los demás temas de la materia, la decisión correcta sería que no apruebe. La formalización de este problema podría ser la siguiente: la hipótesis nula es la conservadora, esto es, que el alumno no sabe; será necesario sumar evidencia para que se tome la decisión de rechazar esa hipótesis y dar el examen por aprobado. La muestra de información que tiene el docente a su disposición (las bolillas que salieron por azar) es correctamente desarrollada por el alumno, lo que conduce a la decisión de rechazar la H_0 y dar el examen por aprobado. Para quien tiene toda la información (que el alumnos solo sabe esas unidades del programa), se ha cometido un Error de Tipo I, pero el docente nunca lo sabrá. En investigación nunca tenemos "toda la información", trabajamos con muestras, por lo que nunca sabemos si, cuando rechazamos H_0, estamos cometiendo este error o no.
Esta es la razón por la que α se elige con valores pequeños, pero no se puede reducir indefinidamente el valor de α, porque también existe el riesgo de aceptar H_0 siendo falsa.

Éste es otro tipo de error, que se llama **Error de Tipo II** (ETII) que sucede cuando se acepta H_0, siendo ésta falsa. En el experimento anterior, cometer este error consiste en creer que la droga no es efectiva (aceptar H_0) cuando en realidad sí tiene efectos (H_0 es falsa). En el ejemplo del examen, se trata de aplazar a un alumno (aceptar H_0) cuándo sí sabía, porque le tocó —a la inversa que en el caso anterior—una de las únicas bolillas que no sabía.

Se llama **Error de Tipo II** a la decisión equivocada de aceptar una hipótesis nula cuando ésta es falsa.

Según la prueba de que se trate, el costo de cometer cada tipo de error es diferente. Si se trata de evaluar el efecto de una intervención terapéutica, la H_0 dirá que no produce efectos. Entonces, cometer un ETI equivaldrá a recomendar la intervención y que no produzca efecto. Mientras que el ETII consistirá en

desestimar una intervención que si tenia efectos. Si se trata de una intervención muy riesgosa, el ETI es muy grave, porque implicará poner en peligro al paciente, por nada. Por su parte, el ETII conlleva la pérdida del beneficio que la intervención habria dado. La decisión sobre qué error es más grave debe tomarse en cada caso y no pertenece al terreno de la estadistica.

Esto se vincula a los errores a que están expuestas las pruebas diagnósticas.
Cuando la prueba da un resultado positivo al ser aplicada a alguien sano, se llama *falso positivo*. De modo más general, esa expresión indica que el error consiste en creer que "sucedió algo" cuando no fue asi y corresponde, en las pruebas de hipótesis, al ETI.
De modo equivalente, el resultado negativo de una prueba diagnóstica aplicada a alguien que si está enfermo se llama *falso negativo*. Se trata del error opuesto, porque cuando se comete se cree que "no sucedió nada" cuando en realidad si sucedió. Es el ETII.

Si insistimos sobre estos errores es para llamar la atención sobre dos aspectos fundamentales de las pruebas de hipótesis:
Las conclusiones son probabilisticas, no son verdaderas ni falsas.
Toda conclusión proveniente de estos procedimientos está sujeta a error.

ETII: μ, α y n
A diferencia del ETI, la probabilidad de cometer un ETII no es fijada de antemano, al contrario, el riesgo de creer que H_0 es verdadera cuando no lo es, depende de cuál sea la verdadera. Intuitivamente: no es igualmente probable creer que no hay diferencia entre dos valores cuando en realidad éstos son muy cercanos, que cuando difieren mucho, es más fácil confundir cosas que están cerca (creyendo que son iguales) que cuando están lejos.
Llamaremos β a la probabilidad de cometer el ETII y veremos cómo calcularla según las diferentes posibilidades del verdadero valor del parámetro sobre el cual se realiza la prueba.
El gráfico 9 corresponde a una prueba de hipótesis unilateral derecha sobre la media poblacional[96], con la forma:

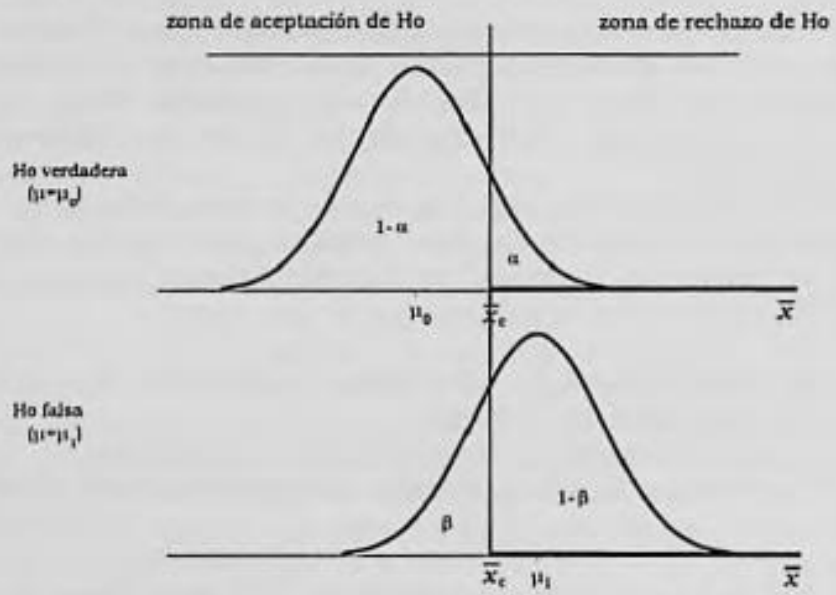
$$H_0: \mu = \mu_0$$
$$H_1: \mu > \mu_0$$

Donde μ_0 es un valor determinado e hipotético para la media de la población. En el gráfico se ha ubicado ése valor hipotético y la zona de rechazo de H_0, estableciendo el nivel de significación (α) en 0,05. Además, hemos dibujado otra curva, centrada en otra media poblacional que podria ser verdadera[97]. Asi, la curva superior representa la distribución de probabilidad de $\bar{x}$ si H_0 fuera verdadera ($\mu = \mu_0$). La curva inferior muestra la distribución de probabilidades de

[96]Aunque ejemplificaremos solo para el caso de la media y para una prueba unilateral derecha, el concepto de errores de tipo I y II es general y vale del mismo modo para la proporción y para pruebas de hipótesis sobre otros parámetros, en pruebas unilaterales o bilaterales.
[97] Lo que sigue tiene objetivos orientativos, si se necesita un tratamiento más detallado del tema —que requiere considerar que si H_0 es falsa entonces la distribución del estimador no es necesariamente simétrica—, puede consultarse Cumming (2012).

$\bar{x}$ si H_0 fuera falsa ($\mu > \mu_0$) y la verdadera media poblacional fuera μ_1 (que es una de las posibles entre las mayores que μ_0).

Gráfico 9: Comparación de la probabilidad de hallar a $\bar{x}$ en zona de aceptación o rechazo, según sea H_0 verdadera o falsa ($\alpha = 0{,}05$).



La parte superior del gráfico muestra que, si H_0 es verdadera, $\bar{x}$ tiene una probabilidad α de estar en la zona de rechazo, por lo que, si H_0 es verdadera y $\bar{x}$ está en esa zona, tomaremos la decisión errada de rechazarla. El complemento del nivel de significación ($1-\alpha$), es la probabilidad de tomar la decisión correcta de aceptar H_0 cuando ésta es verdadera. Es la probabilidad de hallar a $\bar{x}$ en la zona de aceptación de H_0.
En el gráfico inferior vemos que, si H_0 es falsa, $\bar{x}$ tiene probabilidad $1-\beta$ de estar en la zona de rechazo, lo que llevará a tomar la decisión correcta de rechazar una H_0 falsa. Bajo el mismo supuesto de H_0 falsa, β es el área correspondiente a la zona de aceptación de H_0, por lo que mide la probabilidad de errar aceptando una H_0 falsa.
Debido a que no podemos tener certeza acerca de la verdad o falsedad de H_0, es que se nos plantean dos posibles escenarios: que H_0 sea verdadera o que sea falsa. En base a los datos con que contamos en la muestra podemos tomar dos decisiones: aceptar H_0 o rechazarla, con lo que la decisión que tomemos puede ser correcta o incorrecta.

Esquema 1: Posibles combinaciones de estados de realidad y decisión que se toma. (Entre paréntesis, la probabilidad de cada evento):

	Decisión	
Estado de realidad	Aceptar H_0	Rechazar H_0
H_0 verdadera	Decisión correcta ($1-\alpha$)	Error de tipo I (α)
H_0 Falsa	Error de tipo II (β)	Decisión correcta ($1-\beta$)

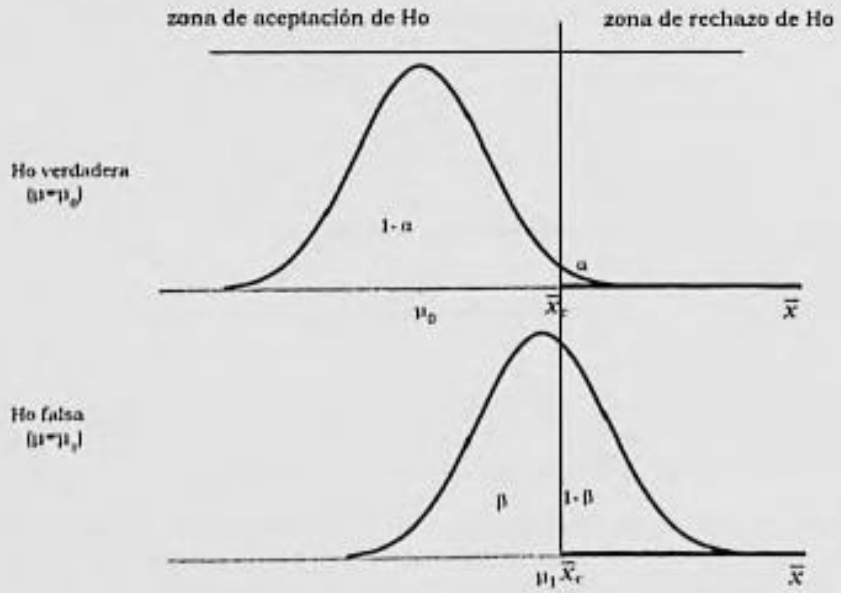
La última celda del esquema corresponde a la decisión correcta de rechazar una H_0 que es falsa, y se la denomina **potencia de la prueba**. Es un indicador de la capacidad de la prueba para detectar hipótesis nulas que son falsas y rechazarlas.

Se llama **potencia de una prueba** a la probabilidad de rechazar una H_0 cuando ésta es falsa.

Es una importante medida de la calidad de la prueba, luego volveremos sobre su cálculo, y en el apéndice ofrecemos más detalles.

Así entonces, α es elegido por el investigador y mide el riesgo que está dispuesto a correr de rechazar una H_0 que es verdadera. Por el contrario, β depende de varios elementos. En primer lugar, depende de α: si se reduce el nivel de significación, aumenta el riesgo de cometer ETII. Si cambiamos el gráfico 9, reduciendo el nivel de significación, ahora la posición relativa de las áreas de rechazo y no rechazo queda:

Gráfico 10: Comparación de la probabilidad de hallar a $\bar{x}$ en zona de aceptación o rechazo, según sea H_0 verdadera o falsa ($\alpha = 0{,}01$).

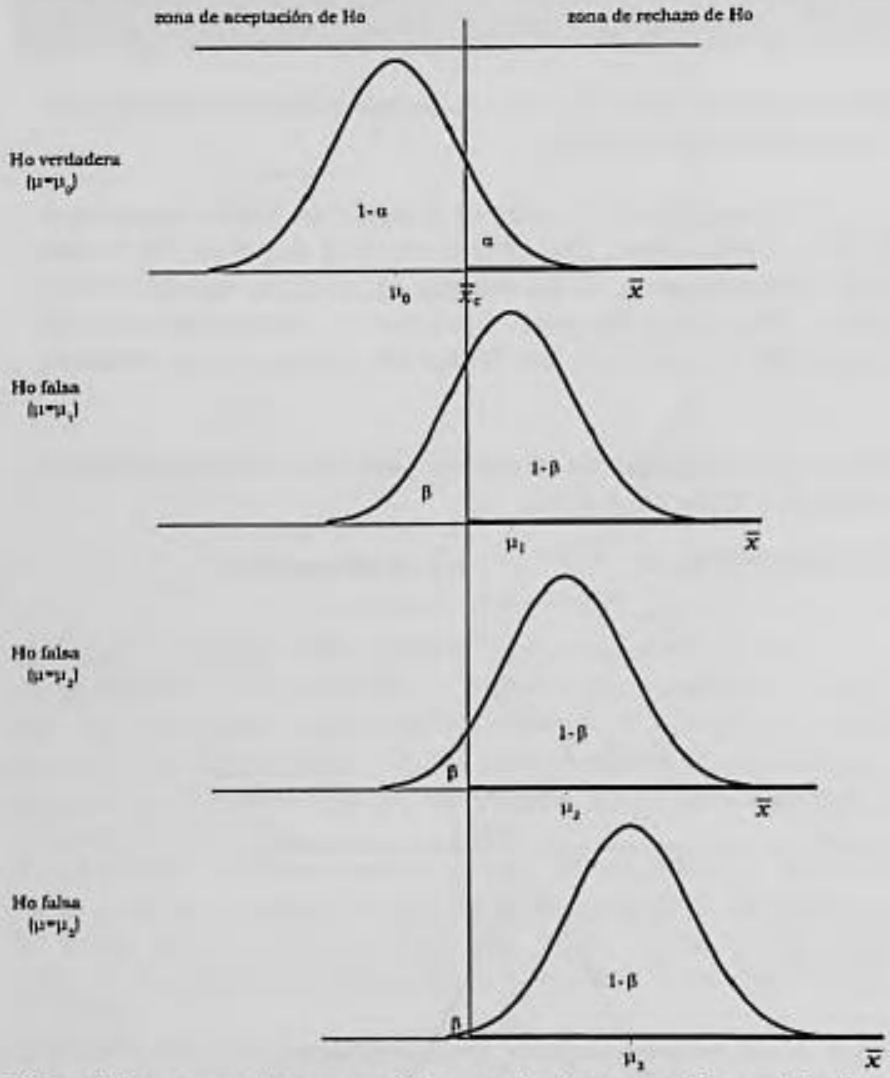


Como vemos, la reducción del nivel de significación del 5% al 1% hace que el punto crítico se desplace hacia la derecha y, en consecuencia, que aumente el área bajo la otra curva, que corresponde a H_0 falsa. Este cambio consiste en hacer a la prueba más exigente, al reducir las chances de rechazar H_0 por error del 5 al 1%. Su consecuencia es la de aumentar las chances de aceptarH_0 por error, aumentando β.

El ETII depende también de cuál sea la verdadera media poblacional. En los gráficos 9 y 10 planteamos como "otra posibilidad" que la verdadera media fuera μ_1, que es una de las formas en que puede ser H_0 falsa. Siendo H_0 falsa, μ puede tener distintos valores y ellos incidirán en la probabilidad de cometer

ETII. En el gráfico siguiente, además de μ_1 agregamos otras dos medias poblacionales posibles μ_2 y μ_3.

Gráfico 11: Comparación de la probabilidad de hallar a $\bar{x}$ en zona de aceptación o rechazo, según sea H_0 verdadera o falsa, de tres modos diferentes.



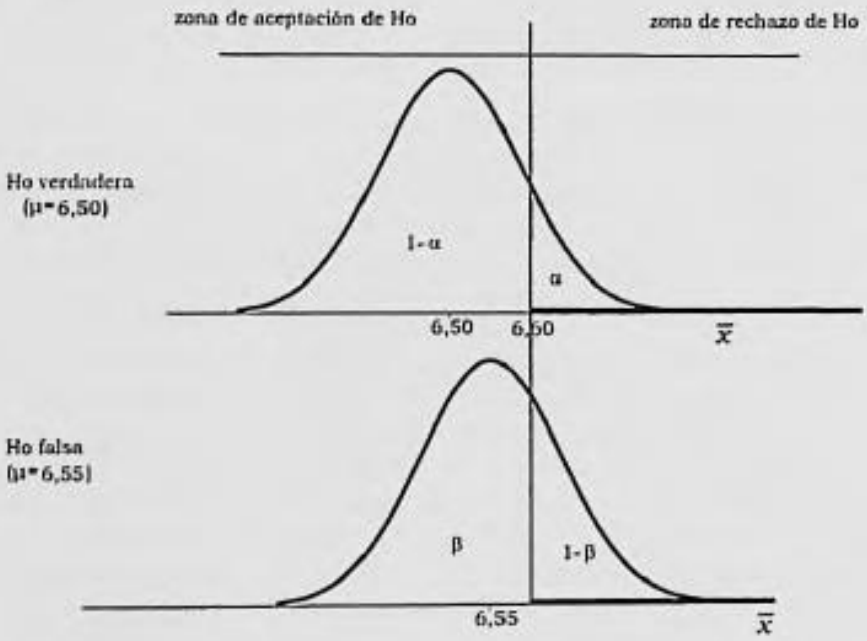
El gráfico muestra que si la verdadera media poblacional difiere mucho de la hipotética (como es el caso de μ_3), es menor la probabilidad β de cometer ETII: β va decreciendo a medida que se consideran medias más alejadas de la que sostiene la H_0. Ésta es una manera de formalizar la idea intuitiva que mencionamos más arriba: es más fácil aceptar un valor equivocado de μ si el verdadero se le parece, que si es muy diferente. Más concreto aún: es más fácil aceptar por error un billete falso si se le parece mucho al verdadero que si es muy distinto, cuanto más difiera, menor será la probabilidad de aceptarlo por error.
El gráfico 11 también muestra que, de manera complementaria, 1-β (la potencia de la prueba), va creciendo a medida que se consideran medias alternativas más alejadas de la hipotética.

Volvamos al ejemplo (ficticio) sobre el promedio con que egresan los estudiantes de Psicología en la prueba unilateral derecha, cuyas hipótesis son:

$$H_0: \mu = 6{,}50$$
$$H_1: \mu > 6{,}50$$

Preguntamos: si la verdadera media de nota con que egresan los estudiantes fuera de 6,55, ¿cuál habria sido la probabilidad de haber aceptado H_0? Dicho de otra forma ¿qué probabilidad hay de creer que la media sigue siendo 6,50 si en realidad ha aumentado a 6,55? Se trata de calcular la probabilidad de cometer ETII, porque se trata de aceptar una H_0 que es falsa. A un nivel de significación del 5%, el punto crítico que habíamos encontrado es 6,60, por lo que:

Gráfico 12: Ubicación de los tipos de error de la prueba si H_0 es verdadera o si es falsa.



La probabilidad de ETII en este caso es el área bajo la curva inferior que está por debajo del punto crítico, 6,60. Para calcular β es necesario hallar esa área bajo la curva normal centrada en 6,55, lo que requiere que se lo transforme a puntaje *z*:

$$z = \frac{6{,}60 - 6{,}55}{\frac{0{,}60}{\sqrt{100}}} = \frac{0{,}05}{0{,}06} = 0{,}83$$

Cuya área izquierda asociada (provista por InfoStat®) es: P(z<0,83)=0,7977
Éste es el valor de β para esta prueba y esta media alternativa. Leemos el resultado diciendo que "si el verdadero promedio con que egresan los estudiantes de Psicología fuera de 6,55, habría una probabilidad de 0,7977 de creer que sigue siendo igual al histórico, de 6,50".
Calculamos la potencia de esta prueba, como el complemento de β:
Potencia=1-β =1-0,7977=0,2023
Esta potencia es la probabilidad de detectar una diferencia de 0.05 entre la media real y la hipotética (es la diferencia entre 6.50 y 6.55) a un nivel de significación del 5%, con una muestra de 100 observaciones. Estos cuatro elementos:

magnitud de la diferencia, tamaño de la muestra, nivel de significación y potencia están vinculados entre sí y deben tenerse en cuenta al planificar un estudio que vaya a usar pruebas de hipótesis.

Curva de potencia

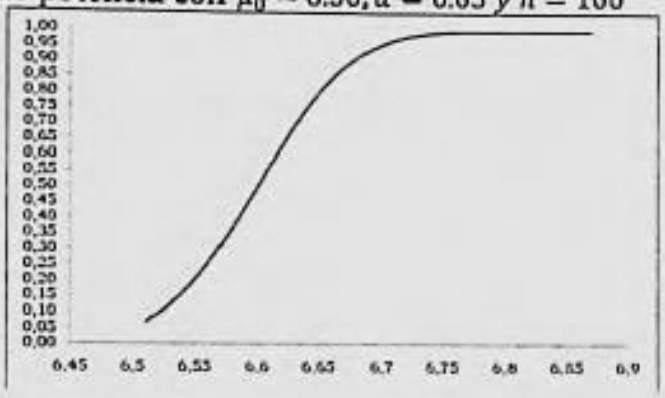
Dado que no se conoce la verdadera media de la población, solo podemos conjeturar acerca de ella y calcular el ETII, así como la potencia para diferentes valores posibles, como hemos hecho para tres valores en el gráfico 10. En general, resulta más valioso calcular la potencia (1-β) porque nos informa sobre la calidad de la prueba. El cálculo es largo porque deben seguirse los mismos pasos que en el ejemplo anterior para cada una de las medias posibles, pero podemos automatizarlo en una hoja de cálculo. La tabla para calcular la potencia de la prueba anterior se construye manteniendo el punto crítico fijo en 6,60 (y también la desviación estándar y el tamaño de la muestra), y calculando el puntaje z correspondiente a ese valor "desde" diferentes medias poblacionales alternativas, a las que hemos llamado μ_k. Así resulta:

Media alternativa μ_k	$z = \frac{6{,}60 - \mu_k}{\frac{0{,}60}{\sqrt{100}}}$	Probabilidad de ETII β	Potencia $1-\beta$
6,51	1,50	0,9332	0,0668
6,53	1,17	0,8783	0,1217
6,55	0,83	0,7977	0,2023
6,57	0,50	0,6915	0,3085
6,59	0,17	0,5662	0,4338
6,61	-0,17	0,4338	0,5662
6,63	-0,50	0,3085	0,6915
6,65	-0,83	0,2023	0,7977
6,67	-1,17	0,1217	0,8783
6,69	-1,50	0,0668	0,9332
6,71	-1,83	0,0334	0,9666
6,73	-2,17	0,0151	0,9849
6,75	-2,50	0,0062	0,9938
6,77	-2,83	0,0023	0,9977
6,79	-3,17	0,0008	0,9992
6,81	-3,50	0,0002	0,9998
6,83	-3,83	0,0001	0,9999
6,85	-4,17	0,0000	1,0000
6,87	-4,50	0,0000	1,0000

Resultan así diferentes valores para la potencia, uno para cada media posible y vemos, ahora numéricamente, como disminuye el riesgo de aceptar H_0 a medida que la verdadera media es más lejana. Al mismo tiempo, aumenta la probabilidad de rechazar H_0 (aumenta la potencia). Esos resultados se representan

gráficamente en lo que se denomina **curva de potencia**. Para el ejemplo anterior, la curva de potencia es la siguiente:

Gráfico 13: Curva de potencia con $\mu_0 = 6.50, \alpha = 0.05$ y $n = 100$



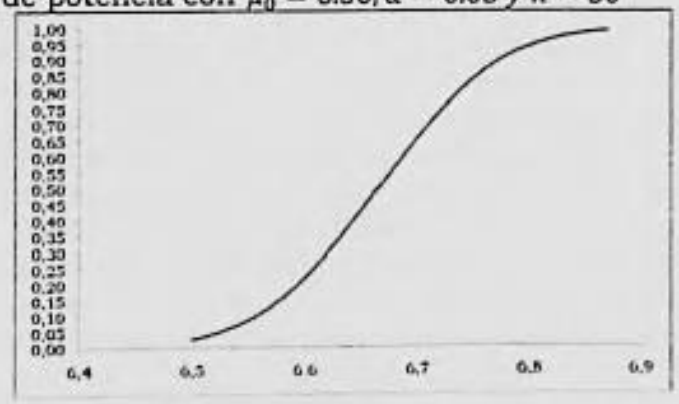
En el eje horizontal se ubican las posibles medias poblacionales (las distintas μ_k) y en el vertical, la potencia asociada a cada una de ellas. Vemos que si la verdadera media es la hipotética ($\mu = 6{,}50$), la probabilidad de rechazarla es α, y esa probabilidad aumenta a medida que se consideran medias más lejanas a μ_0. Si la verdadera media poblacional fuera tan lejana como 6,90, la probabilidad de rechazar H_0 es casi 1, lo que indica que es casi seguro que se rechazará esa hipótesis.

Dijimos antes que la potencia es una medida de la calidad de la prueba, en efecto, cuanto más rápidamente crezca esta curva, tanto más sensible será la prueba, porque será más probable detectar hipótesis nulas que son falsas y rechazarlas. Dicho de otro modo, será alta la probabilidad de rechazar una hipótesis nula si la verdadera media difiere —aunque sea poco—, de la hipotética.

La forma de la curva de potencia depende de varios factores, de los que solo nos detendremos en el tamaño de la muestra: con muestras más grandes, si todo lo demás se mantiene sin cambios, la potencia de la prueba aumenta. Inversamente, muestras pequeñas reducen la potencia.

Veamos esto gráficamente, si la muestra fuera de menor tamaño que la del ejemplo, como *n=50*, la curva de potencia toma la siguiente forma:

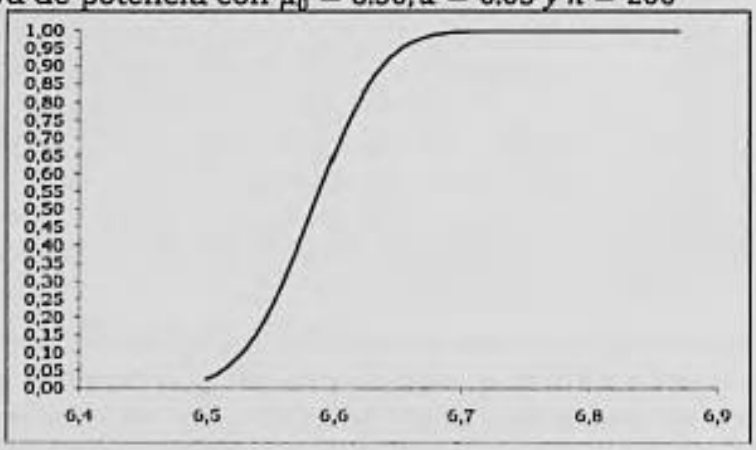
Gráfico 14: Curva de potencia con $\mu_0 = 6.50, \alpha = 0.05$ y $n = 50$



Igual que antes en 6,50, la probabilidad de rechazo es 0,05, que es α. Pero cuando consideramos valores más lejanos de la media poblacional, la curva sube

con más lentitud que la anterior, podríamos decir que "tarda más en reaccionar", son necesarios alejamientos más grandes para que crezca la probabilidad de rechazo.
Por el contrario, si se trata de una muestra de mayor tamaño, como 200 casos, la curva tiene la forma:

Gráfico 15: Curva de potencia con $\mu_0 = 6.50, \alpha = 0.05$ y $n = 200$



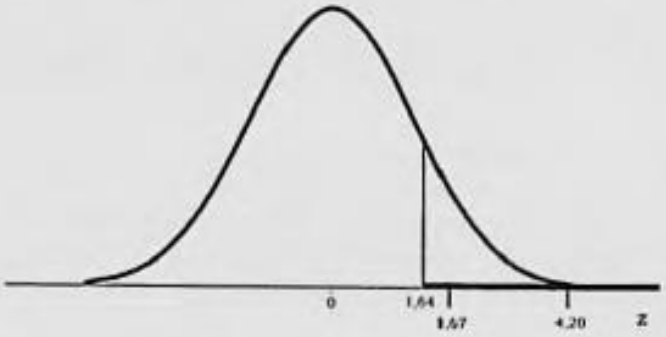
Que muestra un aumento más rápido de la probabilidad de rechazar una H_0 cuando ésta es falsa.

Es importante destacar que la potencia no depende del resultado observado en la muestra, por el contrario, es un indicador de la calidad de la prueba como tal, independientemente de lo que se encuentre en la muestra. Por esta razón, el análisis de la potencia se realiza al momento de planificar un experimento. Tiene mucha importancia para calcular el tamaño de muestra necesario para detectar una determinada diferencia entre grupos.
Existen índices para estandarizar la distancia entre el verdadero valor del parámetro y el hipotético. Esos índices permiten comparar entre pruebas de diferente naturaleza (porque están estandarizados), se denominan *medidas del tamaño del efecto*. Ellis (2010) provee un tratamiento detallado de este tema, en el apéndice regresaremos sobre ellas.

Significación estadística y valor *p*

Hasta este punto se ha indicado que el investigador establece el nivel de significación estadística al realizar una prueba de hipótesis, a partir de lo cual se determinan zonas de rechazo y no rechazo de la hipótesis nula y que esto puede hacerse sobre valores estandarizados o del estimador. Luego, una vez obtenido el resultado de la muestra, se indica en qué zona se ubica, y se decide si se acepta o rechaza la H_0. La forma en que se comunican los resultados es, por ejemplo: "se rechaza la H_0 a un nivel del 5%". De modo que, como hemos dicho, se establece una regla de decisión y en base a ella se decide por sí o por no.
En una prueba unilateral derecha al 5%, el puntaje z que determina el punto de corte entre las zonas de aceptación y rechazo (z crítico) es 1,64, por lo que, si se obtiene un z observado de 1,67, se rechaza H_0 y también se rechaza si se obtiene 4,20, porque ambos son superiores al punto crítico. Sin embargo, encontrar z=*4,20* indica que el valor observado se aleja en gran magnitud del

hipotético, mientras que si $z=1,67$, se rechaza muy cerca del límite. Entre dos situaciones, que ambas llevan a rechazar H_0, puede haber diferencias de importancia; por eso es necesaria una medida de la magnitud de la diferencia. Veamos esto gráficamente:



Aunque los dos valores de z llevan a concluir que se debe rechazar la H_0 (porque ambos están en la zona de rechazo), el valor 4,20 es sustancialmente menos probable que el 1,67, por lo que podríamos decir que en ese caso ($z_{obs}=4,20$) tenemos *más* evidencia para rechazar H_0, sin embargo, si solo informamos que "se rechaza H_0 a un nivel del 5%", quien lee no puede saber si se trató de una diferencia grande o pequeña.

El modo en que se transmite esta información es ofreciendo el **valor de probabilidad** asociado al resultado muestral, que también se llama **valor *p***. Se trata de la probabilidad de observar en la experiencia un resultado igual o más extremo que el obtenido a partir de los datos muestrales, bajo el supuesto de que la hipótesis nula es cierta. Es decir, la probabilidad de hallar un resultado como el que se encontró o más extremo que él, solo por azar. Un valor p pequeño indica que el resultado observado (o resultados más extremos que él) son poco probables bajo el supuesto de hipótesis nula cierta, por lo cual hay evidencia en contra de la hipótesis nula.

El valor p es una probabilidad condicional a la que escribimos formalmente como:

$$p\left(|u| \geq u_{obs} / H_0 V\right)$$

Donde u es el estimador del parámetro al que se refiere la H_0. La expresión $|u| \geq u_{obs}$ es la forma reducida de decir que u sea más extrema (por encima o por debajo) que el valor observado.

Cuanto más pequeño es el valor p, tanta más evidencia hay para rechazar H_0. Por el contrario, un valor p grande indica que el resultado observado es muy probable bajo el supuesto de hipótesis nula cierta, lo que no aporta evidencia en contra de la hipótesis nula y conduce a no rechazarla.

Esta manera de indicar cuán esperable sería lo que hemos observado si H_0 fuera cierta, puede vincularse con el razonamiento anterior, comparando el valor p con el nivel de significación fijado de antemano. Así resultan dos posibilidades:

Si el valor p es menor que el nivel de significación establecido ($p<\alpha$): se rechaza la hipótesis nula y se describe como "un resultado estadísticamente significativo". Esto quiere decir que la probabilidad de haber hallado este resultado por azar es

pequeña, por lo que se trata de un efecto o diferencia que muy difícilmente se puede atribuir al azar.

Si el valor p es mayor que el nivel de significación establecido ($p>\alpha$): no se rechaza la hipótesis nula y se expresa como "un resultado no estadísticamente significativo". Lo que expresa que la probabilidad de haber hallado este resultado por azar es mayor que el máximo establecido, por lo que es razonable atribuirlo al azar, es decir a la variabilidad propia de los resultados muestrales.

Pero aun cuando esta modalidad de presentar el resultado puede hacerse equivalente al procedimiento anterior, constituye un aporte de información adicional de importancia porque pasa de la conclusión dicotómica (se acepta o se rechaza) a la probabilidad de hallar este resultado si la hipótesis nula fuera cero.
A continuación calculamos estas probabilidades en los ejemplos vistos, empezando por pruebas unilaterales:

En el ejemplo sobre el promedio con que egresan los alumnos:

$$H_0: \mu = 6{,}50$$
$$H_1: \mu > 6{,}50$$

En la muestra de 100 alumnos habíamos hallado $\bar{x}_{obs} = 6{,}65$ y $s = 0{,}60$, con esos datos debemos calcular la probabilidad de hallar "un valor tan extremo como el observado o más extremo que él, si H_0 es verdadera". Se trata de una probabilidad condicional, en la que la condición es que H_0 sea verdadera, lo escribimos así:

$$P(\bar{x} \geq 6{,}65/\mu = 6{,}50)$$

Que expresa la probabilidad de coincidir con 6,65 o superarlo (se trata de una prueba unilateral derecha, por eso usamos el signo≥), si la media poblacional fuera la hipotética (6,50). Para encontrar la probabilidad, transformamos $\bar{x}$ a puntaje z:

$$z = \frac{6{,}65 - 6{,}50}{\frac{0{,}60}{\sqrt{100}}} = \frac{0{,}15}{0{,}06} = 2{,}50$$

Entonces debemos hallar $P(z \geq 2{,}50)$ y ya no hace falta indicar la condición (si $\mu = 6{,}50$), porque está incluida en el cálculo de z. Usando la opción de InfoStat®, obtenemos:

$$P(z \geq 2{,}50) = 0{,}0062$$

Ese es el valor p, e indica cuál es la probabilidad de encontrar un valor como el observado o uno más extremo que él, si la H_0 fuera verdadera. Vemos que se trata de un valor pequeño, es menor a 0,05 y también menor a 0,01, por lo que podemos decir que la H_0 se rechaza a un nivel del 5% y también del 1%. Pero además de esto, comunicamos el valor p obtenido, porque eso da al lector una idea más completa de nuestro resultado.

Para el caso de la proporción, consideremos la segunda parte del ejemplo del candidato, cuando usamos una muestra grande:

$$H_0: P = 0{,}30$$
$$H_1: P > 0{,}30$$

En la muestra de $n = 200$ casos habíamos hallado $\hat{p}_{obs} = 0{,}32$.
Por tratarse de una prueba unilateral derecha, necesitamos conocer la probabilidad condicional de hallar un valor como el observado —o más extremo que éste—, si fuera verdadera H_0

$$P(\hat{p} \geq 0{,}32 / P = 0{,}30)$$

Para calcular esta probabilidad transformamos el valor de $\hat{p}$ a puntaje z:

$$z = \frac{\hat{p} - P}{\sqrt{\frac{P*(1-P)}{n}}} = \frac{0{,}32 - 0{,}30}{\sqrt{\frac{0{,}30*(1-0{,}30)}{200}}} = 0{,}617$$

Usando InfoStat® que $P(z \geq 0{,}617) = 0{,}2686$. Se trata de una probabilidad "grande", si se compara con los niveles de significación que usamos, es superior a 0,05 y también superior a 0,10, por lo que la decisión será la de no rechazar H_0 y concluir que el candidato no mejoró su proporción de votos.

En el mismo ejemplo, cuando se trabaja con la muestra pequeña, no es válida la aproximación normal, por lo que debe usarse la binomial. El cálculo del valor p es equivalente, solo que se realiza en términos de la variable *número de éxitos*. En el ejemplo, el número observado de éxitos era de 16, la probabilidad condicional que corresponde al valor p es entonces la probabilidad de hallar en la muestra de 50 casos, 16 personas o más que vayan a votar al candidato, si en la población la proporción de quienes lo votarán es de 30%:

$$P(\hat{x} \geq 16 / n = 50, P = 0{,}30) = 0{,}4308$$

Nuevamente es un valor elevado para p, por lo que no se rechaza H_0.
Los software de análisis de datos ofrecen, como resultado de las pruebas de hipótesis este valor, a veces llamado "p", "p-value", "valor p" o "significación"; y es en él que hay que basar la decisión.

Muestras pequeñas y pruebas *t*

Se ha mencionado que la distribución *t de Student*, es un modelo de probabilidades con una forma similar a la distribución normal, pero más aplanada y dependiente de un dato al que se llama "grados de libertad". Estos grados de libertad dependen del número de casos que haya en la muestra. También se indicó que a medida que los grados de libertad aumentan, la curva *t* tiende a asemejarse más a la normal. De modo que si se trata de muestras grandes, la distribución *t* es muy similar a la normal. Esto se denomina convergencia de la distribución t hacia la normal.
Vamos a usar esa distribución en las pruebas de hipótesis cuando trabajemos con muestras pequeñas, pero con una restricción. En aquellos casos en que sea posible suponer que la variable de origen (en la población) tiene distribución normal, entonces la distribución de las medias muestrales es adecuadamente modelada por la distribución *t*. Dicho de otro modo: si la variable tiene —en la

población—, distribución normal, entonces las medias muestrales, cuando se trate de muestras pequeñas, tienen *distribución t*. Nos encontramos así con distintas situaciones, de acuerdo al tamaño de la muestra y a la normalidad o no de la variable en la población.
Muestras grandes: Por el teorema central del límite, estamos autorizados a usar distribución normal para la media muestral, sin importar cuál sea la distribución de la variable en la población.
Muestras pequeñas: Si la variable tiene distribución normal en la población, usamos distribución *t de Student*, cuyos grados de libertad son *n-1*.
De estas dos condiciones (tamaño de muestra y normalidad de la variable en la población) resultan cuatro combinaciones:

Tamaño de la muestra	Distribución de la variable en la población	
	Normal	No normal
grande ($n \geq 30$)	distribución normal	por TCL tiende a normal
pequeña ($n < 30$)	distribución *t de Student*	ninguna[98]

De modo que hay una situación que no podemos abordar con estos procedimientos: la de muestras pequeñas provenientes de poblaciones no normales, para ellas disponemos de procedimientos llamados "no paramétricos" de los que nos ocuparemos más adelante. Las demás combinaciones pueden todas ellas resolverse con la distribución *t* que es específica en el caso de muestras pequeñas y es equivalente a la normal cuando la muestra es grande (porque lo son los grados de libertad).
Por esta razón, en la mayoría de los paquetes informáticos de análisis de datos, se habla de *pruebas t* de manera genérica para las pruebas sobre la media, y el estadístico de prueba constituye un valor *t* en lugar de *z*. La lógica es exactamente la que hemos seguido en este capítulo, solo que el programa hace las cuentas usando la distribución *t* que, cuando se trabaja con una muestra grande, da el mismo resultado que la normal.

Además de operar internamente con la distribución *t de Student*, los programas de análisis de datos ofrecen los resultados de las pruebas de hipótesis siempre en términos del valor *p*. Eso permite que quien lee la salida pueda decidir si rechaza o no rechaza la H_0, de acuerdo al nivel de significación que haya fijado.

La siguiente salida InfoStat® corresponde a una prueba de hipótesis acerca del promedio del número de hijos por mujer. Se busca evidencia para decidir si, según los datos de una muestra de 116 casos, la población de la que esa muestra proviene tiene en promedio dos hijos por mujer o si ese promedio es menor a 2. Las hipótesis entonces son:

---

[98]Existe un procedimiento basado en un resultado importante de la estadística que se conoce como "desigualdad de Tchebycheff", que establece que la probabilidad de encontrar a una variable a una distancia de su media superior a k desviaciones estándar es menor a $\frac{1}{k^2}$. Se expresa como $P(|x - E(x)| > k\sigma) < \frac{1}{k^2}$. También es posible recurrir a la distribución empírica, obtenida por remuestreo, InfoStat® lo hace en la opción *estimación por bootstrap* para construir intervalos de confianza. En el capítulo 13 se verán pruebas que permiten resolver situaciones en las que no se cumplen los supuestos, como pequeñas muestras, distribución no normal y/o nivel de medición no métrico.

$$H_0: \mu = 2$$
$$H_0: \mu < 2$$

Prueba t para una media

Valor de la media bajo la hipótesis nula: 2

Variable	n	Media	DE	T	p(Unilateral)
hijos	116	1,98	1,22	-0,18	0,4326

En el primer renglón, la salida ofrece el valor de μ bajo H_0, que es 2. Luego muestra el nombre de la variable (hijos), la cantidad de casos en la muestra (n), la media muestral ($\bar{x} = 1{,}98$), la desviación estándar muestral (DE=1,22), el valor del estadístico de prueba ($t = -0{,}18$) y el valor de probabilidad asociado ($p(Unilateral\ l) = 0{,}4326$). Esta última probabilidad especifica que se trata de una prueba unilateral izquierda (rechaza para valores menores que el hipotético).
La media muestral tiene un valor que está muy levemente por debajo del hipotético (1,98 frente a 2), por lo que podríamos suponer que la diferencia no es significativa, sin embargo, con la apreciación subjetiva no es suficiente, es necesario observar el valor p de la salida. Esta última cifra es grande (43,26%) por lo que no se rechaza la H_0. Concluimos que no hay evidencia para considerar que la población de la que proviene la muestra tenga un nivel de fecundidad inferior a dos hijos por mujer.

Resumen de pruebas sobre una muestra

Parámetro	Estimador	Estadístico de prueba	Puntos críticos en términos del estimador	Supuestos
μ	$\bar{x}$	$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$	$\bar{x}_c = \mu \pm z * \frac{s}{\sqrt{n}}$	$n \geq 30$ ó distribución normal de x en la población
P	$\hat{p}$	$z = \frac{\hat{p} - P}{\sqrt{\frac{P*(1-P)}{n}}}$	$\hat{p}_c = P \pm z * \sqrt{\frac{P*(1-P)}{n}}$	$n * P \geq 5$ $n * (1-P) \geq 5$

Usando el valor p, la lectura del resultado de la prueba de hipótesis se expresa:

Si la hipótesis nula fuera verdadera, habría una probabilidad p de hallar un valor como el observado o uno más extremo.

Capítulo 12 Prueba de hipótesis: las aplicaciones

Hasta aquí, la prueba de hipótesis es un procedimiento para evaluar si un valor observado en la muestra es compatible con el valor poblacional que plantea la hipótesis nula, para la media o la proporción. Se trabajó sobre una única población y se puso a prueba un valor determinado para un parámetro (media o proporción). Ahora ampliamos el análisis, porque vamos a poner a prueba la eventual diferencia entre dos grupos y la correlación entre dos variables. Probaremos por ejemplo, si puede aceptarse que dos poblaciones tengan la misma media en una variable cuantitativa o también la misma proporción de casos en una categoría de una variable cualitativa. Como antes, la hipótesis nula será la de no diferencia, es decir que formularemos como H_0 que las dos poblaciones tienen la misma media o bien la misma proporción. Para la correlación, la H_0 indica que, a nivel poblacional, el coeficiente vale cero.

En este capítulo se abordan los procedimientos que permiten comparar las medias o proporciones de dos grupos y determinar si las diferencias que se encuentran son significativamente mayores de lo que pudiera esperarse por puro azar. Es decir, recorreremos los pasos necesarios para tomar una decisión en términos estadísticos, a favor o en contra de la hipótesis que sostiene que dos grupos son iguales respecto del parámetro bajo análisis. Un modo alternativo de expresar el problema es considerar que lo que se pone a prueba es si las dos muestras provienen de la misma población o de dos poblaciones diferentes.

En el diseño experimental —tema que se verá en detalle en Metodología de la Investigación—, a menudo interesa conocer, si un grupo sometido a cierto tratamiento muestra cambios diferentes a los que experimenta otro grupo que no fue sometido a ese tratamiento. Los procedimientos que veremos se utilizan para determinar si las ganancias obtenidas en una muestra de sujetos tras un tratamiento —por ejemplo de entrenamiento cognitivo—, son lo suficientemente amplias como para representar diferencias en la población. En este tipo de casos, se realiza una primera evaluación del grupo (pre-test), se obtiene la media de ciertas variables (aciertos en una prueba de atención, palabras recordadas, aciertos en la correspondencia entre nombres y caras, etc.). Luego se somete a los sujetos a un periodo de entrenamiento y a continuación son nuevamente evaluados (post-test). Necesitamos determinar si los cambios, medidos a través de la diferencia de los promedios, son de una magnitud tal que podamos atribuirlos al entrenamiento o bien si pueden explicarse por azar.

Los procedimientos destinados a comparar grupos tienen gran difusión en investigación. Muchos de los problemas que interesa resolver usándolos se encuentran vinculados a distintos campos de la Psicología y la Educación, ya que se comparan grupos que han recibido una droga con quienes no la han recibido, que han pasado por un periodo de entrenamiento o no, que han participado en grupos terapéuticos o han desarrollado otra actividad, alumnos que aprenden con uno u otro método, etc. En todos los casos se realiza una comparación en algún resultado, que puede ser el puntaje en un test o cualquier otra variable sobre la que se busca intervenir. Por ejemplo, en una tesis de Maestría en Psicología Clínica, el autor separa a un grupo de niños deficientes mentales en dos grupos. Uno de ellos participa de un taller con actividades ecológicas (se lo llama "grupo experimental"), mientras que el otro grupo no lo hace (es el denominado "grupo

control"). A través de pruebas estandarizadas se mide la sociabilidad, esperando que las actividades en las que participaron pudieran estimularla. Se comparan los niveles de sociabilidad de los niños que participaron del taller con los de quienes no participaron, esta evaluación se hace antes y después de la realización de estas actividades, que se prolongaron por un mes. En este ejemplo hay dos comparaciones: la socialización de los niños que participaron con la de los que no lo hicieron, y la de la sociabilidad de los que participaron antes del taller y luego de él. En ambos casos se utilizan las pruebas sobre las que trata este capítulo.

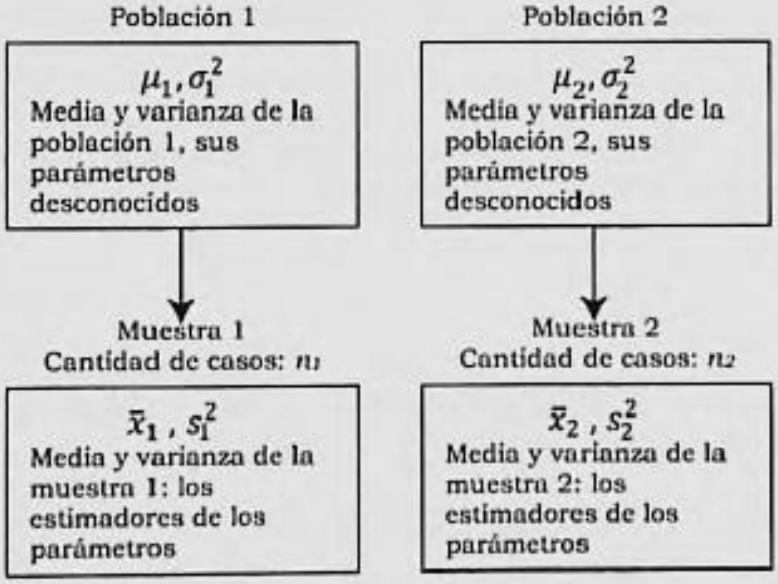
Siempre la hipótesis nula sostendrá que no hay diferencias entre las puntuaciones obtenidas antes y después del tratamiento, o por un grupo y el otro; o lo que es lo mismo, que las diferencias son cero (nulas). En la hipótesis alternativa se planteará la situación opuesta, sea bilateral (las medias difieren) o unilateral (una media es mayor que la otra).
Sin embargo estos procedimientos no sólo se utilizan en experimentos, sino también en estudios que analizan datos de encuestas o de observación. Así una variable independiente puede constituirse por grupos o muestras de sujetos que conforman categorías diferentes. Varones versus mujeres, población rural versus población urbana, niños que repiten o no repiten un grado. Pueden interesar entonces, ciertas diferencias en los promedios de alguna variable entre estos grupos. ¿Tienen los mismos ingresos promedio los varones jefes de hogar que las mujeres que son jefas de hogar? ¿La proporción de analfabetos es la misma entre provincias del NOA o del Centro del país? La edad promedio de las madres primerizas que se atienden en hospitales públicos, ¿es la misma que la de quienes van a privados? Podemos comparar varones y mujeres y evaluar si hay diferencia entre el promedio de un grupo y otro en relación a la introversión, el neuroticismo o su afabilidad. También podríamos comparar personas mayores y jóvenes en relación a los promedios que obtuvieran en pruebas de inteligencia fluida o cristalizada. En estos casos, como los investigadores esperan que ciertas puntuaciones promedios sean más altas en los adultos jóvenes (inteligencia fluida) versus los promedios que pudieran obtener los mayores, probablemente más altos en los desempeños de pruebas de inteligencia cristalizada. En estos ejemplos, jefes y jefas de hogar, NOA y Centro del país, jóvenes y viejos, mujeres y varones, etc. son grupos independientes, que se diferencian por los valores de una variable (región, edad, género) y nos interesa investigar si estos agrupamientos evidencian diferencias en otras variables de interés: como los ingresos, la proporción de analfabetos, la inteligencia, la introversión.
Cuando apreciamos que las medias de dos grupos son diferentes, no podemos saber a priori si las muestras provienen de poblaciones cuyas medias son diferentes o no, porque las diferencias observadas entre los resultados muestrales pueden provenir de azar. Por eso, encontrar que $\bar{x}_1 \neq \bar{x}_2$ (en las muestras) no conduce inmediatamente a que $\mu_1 \neq \mu_2$ (en las poblaciones).
El procedimiento para comparar los parámetros (medias o proporciones) de dos poblaciones consiste en extraer una muestra de cada población: llamaremos a los tamaños de esas muestras n_1 y n_2. En cada muestra se calculan —como antes—, los estimadores correspondientes. Si se estima una diferencia de medias calcularemos las medias ($\bar{x}_1$ y $\bar{x}_2$), así como las desviaciones estándar (s_1 y s_2) de cada una. Si lo que se estima es una diferencia de proporciones, en cada muestra

se calculará la proporción de casos en la categoría de interés: $\hat{p}_1$ y $\hat{p}_2$ que son los estimadores de los parámetros P_1 y P_2.
Aquellas situaciones en que no se puedan calcular medias y varianzas porque las variables son ordinales o bien no se sostengan los supuestos sobre normalidad de las distribuciones poblacionales, se aplican otro tipo de prueba de hipótesis, que serán tratados en el próximo capítulo.
Veamos en primer lugar el caso en que la variable bajo análisis es cuantitativa y entonces nos interesa comparar las medias poblacionales. El parámetro que se estima es la diferencia entre las medias poblacionales: $\mu_1 - \mu_2$, y la estimación se hace a través de la diferencia entre las medias muestrales: $\bar{x}_1 - \bar{x}_2$. El error estándar de ese estimador (que será necesario para estandarizar el valor observado) va a depender del tipo de prueba de que se trate. En este capítulo trataremos dos situaciones, cuando sean muestras independientes, y muestras apareadas o dependientes.

Muestras independientes

Prueba de diferencia de medias

La comparación de las medias de dos poblaciones independientes se realiza comparando los correspondientes estimadores de las medias poblacionales, veamos el siguiente esquema para recordar la notación:



Una vez que se dispone de los datos muestrales, el estadístico de prueba toma la forma;

$$\frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_{\bar{x}_1 - \bar{x}_2}}$$

Es decir, se trata de la diferencia entre la diferencia de las medias muestrales y la diferencia de las medias poblacionales, dividida por el error estándar de la

diferencia (el error estándar del estimador). La expresión mantiene la estructura que mencionamos en el capítulo anterior: estimador menos parámetro sobre el error estándar del estimador. En este caso el estimador es la diferencia de las medias muestrales y el parámetro es la diferencia de las medias poblacionales.
Este estadístico de prueba tiene distribución normal si los tamaños de las muestras son suficientemente grandes (mayores a 30 casos) y tiene distribución *t de Student* si se trata de muestras pequeñas y puede además suponerse que las variables que se analizan tienen distribución normal en la población. Debido a que la distribución *t* tiende a la normal a medida que aumenta el tamaño de la muestra, y como lo hicimos antes para una sola muestra, escribiremos de manera general:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_{\bar{x}_1 - \bar{x}_2}}$$

Como sabemos, cuando las muestras sean grandes, las probabilidades asociadas al valor de *t* coincidirán con las de la distribución normal.

El denominador del estadístico de prueba puede ser calculado de dos manera diferentes y eso va a depender de que podamos suponer que las varianzas de las dos poblaciones de las que provienen las muestras son iguales o que no sea así.

Caso 1: Varianzas poblacionales iguales $\sigma_1^2 = \sigma_2^2$
Si puede suponerse que las varianzas poblacionales son iguales, entonces las dos varianzas que se calculan desde las muestras, constituyen dos estimadores (diferentes por azar) del mismo parámetro. Cada muestra ofrece una estimación de la varianza, que es la misma en las dos poblaciones de origen. En ese caso, calcularemos primero un promedio[99] de las dos estimaciones dadas por las varianzas muestrales, a la que llamaremos varianza combinada:

$$s_{comb}^2 = \frac{(n_1 - 1) * s_1^2 + (n_2 - 1) * s_2^2}{n_1 + n_2 - 2}$$

Usando este estimador de la (supuestamente única) varianza poblacional, el estadístico de prueba asume la forma:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_{comb} * \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Cuyos grados de libertad se calculan, en función de los tamaños de las muestras como: $gl = n_1 + n_2 - 2$.

---

[99]La fórmula de este promedio tiene en cuenta que las varianzas provienen de muestras de diferente tamaño y que los denominadores de las varianzas son *n-1*. Por eso no es simplemente la suma de ambas dividida dos. Solo en el caso que las muestras son se igual tamaño (n_1=n_2), se trata del promedio simple y $s_{comb}^2 = \frac{s_1^2 + s_2^2}{2}$

Caso 2: Varianzas poblacionales diferentes $\sigma_1^2 \neq \sigma_2^2$
Si no es posible suponer que las varianzas de las poblaciones de donde provienen las muestras son iguales, entonces debemos usar las varianzas muestrales de manera separada. Cuando éste es el caso, el estadístico de prueba es:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Esta expresión es más sencilla, pero el cálculo de los grados de libertad de la distribución *t de Student* se vuelve más complejo. La fórmula para hacerlo es[100]

$$gl = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$$

No vamos a usar esta expresión para calcular los grados de libertad, pero es la que usan los programas de análisis de datos cuando detectan que las varianzas poblacionales no son iguales.

De acuerdo a esto, cuando vamos a hacer una prueba *t* para comparar las medias de dos grupos debemos antes saber si estamos ante el caso 1 ó el caso 2; lo que significa que deberemos antes decidir si las varianzas de las dos poblaciones pueden considerarse iguales o no. Dado que no conocemos estas varianzas poblacionales, la decisión se toma a partir de los datos muestrales, es decir, a partir de las varianzas halladas en las muestras (s_1^2 y s_2^2). Se realiza una prueba, cuya hipótesis nula afirma que las varianzas poblacionales son iguales y su resultado permitirá decidir, a un determinado nivel de significación, si puede tratarse a las varianzas poblacionales como iguales o si debe considerárselas diferentes, la prueba se llama prueba de homogeneidad de varianzas[101] y tiene las siguientes hipótesis.

$$H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$$

$$H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$$

El estadístico de prueba es el cociente de las varianzas muestrales:

$$\frac{s_1^2}{s_2^2}$$

Y tiene una distribución F con $n_1 - 1$ grados de libertad en el numerador y $n_2 - 1$ grados de libertad en el denominador.

---

[100] Esta expresión se conoce como la ecuación de Welch–Satterthwaite y fue desarrollada en el campo de la teoría de errores, los programas de análisis de datos la aplican de manera automática cuando las varianzas son diferentes a cierto nivel de significación.

[101] Se llama homogeneidad aquello que coloquialmente podría expresarse como "suficientemente parecidas como para tratarlas como iguales".

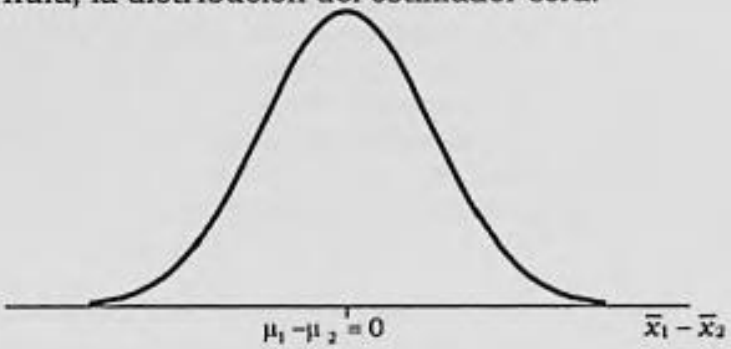
Ejemplo (datos ficticios): nos preguntamos si, para una carrera universitaria dada, el tiempo que tardan en completar sus estudios los estudiantes que trabajan y los que no trabajan es el mismo o si difiere. Para ello tomamos una muestra de 100 alumnos que trabajan y obtenemos una media de duración de la carrera de 6,7 años y una desviación estándar de 1,2 años. Extraemos otra muestra, de 150 casos de estudiantes que no trabajan, en la que obtenemos un promedio de los años de duración de 6,3 con una desviación estándar de 1,5 años. Todos estos datos provienen de la información descriptiva que proveen las muestras, son los que vamos a usar para hacer la inferencia acerca de las poblaciones, constituidas por el total de alumnos que trabajan y que no trabajan.
Como antes, la hipótesis nula es la del "no cambio", la que afirma que no hay diferencia, por lo que:

$$H_0: \mu_1 - \mu_2 = 0$$

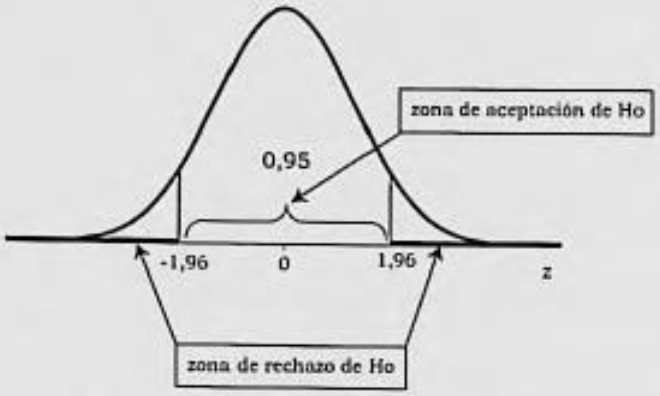
Que dice que la diferencia entre las medias poblacionales es cero (es nula). Hemos dicho que nuestro interés está en saber si las medias poblacionales son iguales o si difieren, por lo que se trata de una prueba bilateral, entonces la hipótesis alternativa indicará que:

$$H_1: \mu_1 - \mu_2 \neq 0$$

Para la presentación continuaremos usando la distribución normal, ya que resulta más familiar, pero los paquetes de análisis de datos usan directamente distribuciones *t*.
Bajo la hipótesis nula, la distribución del estimador será:



Para decirlo nuevamente, la variable aleatoria es la diferencia de medias muestrales, el centro de la distribución es el parámetro, que según la hipótesis nula es cero.
Fijamos el nivel de significación de la prueba en el 5% y los puntos criticos resultan, sobre la distribución normal estándar ±1,96, gráficamente:



Ahora transformamos a puntaje z los valores observados en las muestras. Recordemos para ello que el puntaje z se define como la diferencia entre el estimador y el parámetro, dividida por el error estándar del estimador. Para esta prueba, el parámetro es la diferencia de medias poblacionales, su estimador es la diferencia de medias muestrales, con lo que:

$$z_{obs} = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_{(\bar{x}_1 - \bar{x}_2)}}$$

Y queda por decidir cómo calcular el denominador, lo que va a depender de que puedan o no suponerse iguales las varianzas poblacionales. Para decidirlo, se realiza la prueba de homogeneidad de varianzas:

$$H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$$
$$H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$$

El estadístico de prueba es

$$\frac{s_1^2}{s_2^2} = \frac{1,2^2}{1,5^2} = 0,64$$

Con Infostat® se busca la probabilidad asociada a un valor como el observado o mayor, bajo un modelo $F_{n_1-1,\,n_2-1} = F_{99,149}$, que resulta 0,99. Este es un valor p, por lo que debe interpretarse como la probabilidad de hallar un cociente entre las varianzas muestrales como el observado o más extremo, si las varianzas poblacionales fueran iguales. Dado que es un número muy alto, no se rechaza la hipótesis nula, y se concluye que las varianzas pueden suponerse iguales. Se trata entonces de lo que se ha llamado "caso 1" y, para el denominador del estadístico de prueba, se calcula la varianza combinada[102]:

[102] Cuando se solicita a InfoStat®, automáticamente (a menos que pidamos lo contrario) se verifica si puede suponerse que las varianzas poblacionales son iguales o no y, en base al resultado de esa verificación, se calcula el error estándar de la diferencia con una fórmula o con otra.

$$s^2_{comb} = \frac{(n_1 - 1) * s_1^2 + (n_2 - 1) * s_2^2}{n_1 + n_2 - 2}$$

Con los datos del ejemplo, la varianza combinada es:

$$s^2_{comb} = \frac{(100 - 1) * 1{,}2^2 + (150 - 1) * 1{,}5^2}{100 + 150 - 2} = \frac{477{,}81}{249} = 1{,}92$$

por lo que la desviación estándar combinada resulta:

$$s_{comb} = \sqrt{1{,}92} = 1{,}38$$

Como la hipótesis nula establece que la diferencia de medias poblacionales es cero $\mu_1 - \mu_2 = 0$, entonces, el estadístico de prueba queda:

$$z = \frac{(6{,}7 - 6{,}3) - 0}{1{,}38 * \sqrt{\frac{1}{100} + \frac{1}{150}}} = \frac{0{,}4}{0{,}18} = 2{,}22$$

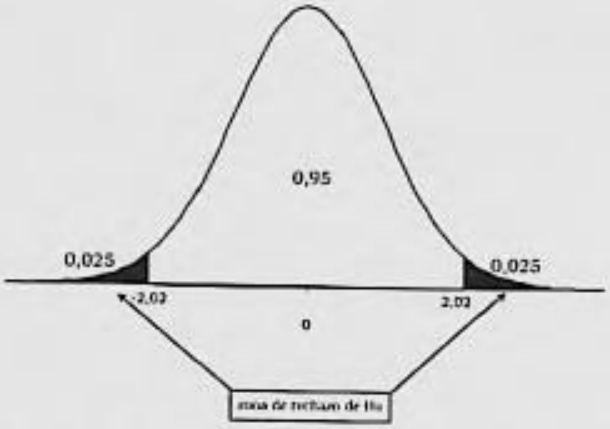
Este es el estadístico de prueba correspondiente a la diferencia de medias para muestras independientes cuando las varianzas poblacionales pueden suponerse iguales. Este valor de z (2,22) se encuentra en la zona de rechazo de H_0, por lo que la decisión será la de rechazar H_0 y concluir que el tiempo que tardan en terminar la carrera los alumnos que trabajan difiere significativamente del que tardan los que no trabajan. Dicho de otro modo: la diferencia observada en las medias de las muestras es significativa a un nivel del 5%.

Si los mismos resultados se hubiesen hallado en muestras más pequeñas, por ejemplo de 20 y 25 casos de estudiantes que trabajan y no trabajan respectivamente, y además hubiésemos podido suponer que las dos poblaciones son normales en la variable *duración de la carrera*; entonces habría correspondido usar una prueba t[103]. La prueba de homogeneidad de varianzas da, con esos nuevos tamaños de muestra, $p = 0{,}16$. Un valor que también es elevado, por lo que se puede tratar a las varianzas como iguales.
Los grados de libertad de la distribución t se calculan sumando los tamaños de muestra y restando dos:

$$gl = n_1 + n_2 - 2 = 20 + 25 - 2 = 43$$

Con 43 grados de libertad, los valores t que delimitan un 5% extremo en la distribución de probabilidades son ±2,02, que gráficamente se representan así:

[103]Recordemos que la distribución normal vale para muestras grandes, por el Teorema Central del Límite.



Para tomar la decisión calculamos el estadístico de prueba con el mismo procedimiento anterior, para lo que es necesario contar primero con la desviación estándar combinada. Calculamos primero la varianza combinada:

$$s^2_{comb} = \frac{(20-1)*1,2^2 + (25-1)*1,5^2}{20+25-2} = \frac{81,36}{43} = 1,89$$

Y la desviación estándar combinada es:

$$s_{comb} = \sqrt{1,89} = 1,37$$

por lo que el estadístico de prueba resulta:

$$t = \frac{(6,7-6,3)-0}{1,37*\sqrt{\frac{1}{20}+\frac{1}{25}}} = \frac{0,4}{0,41} = 0,97$$

Este valor no se ubica en la zona de rechazo de H_0, por lo que la conclusión será en este caso que no hay evidencia para creer que el tiempo promedio que tardan en terminar la carrera los alumnos que trabajan sea diferente que el que tardan quienes no trabajan.

La comparación de las conclusiones de estos dos ejemplos muestra algo muy importante: una misma diferencia absoluta de 0,4 años en los promedios muestrales de los grupos, es significativa cuando proviene de muestras grandes (100 y 150 casos) y deja de serlo cuando se obtiene en muestras pequeñas (20 y 25 casos). El tamaño de las muestras incide en la potencia de la prueba, que es su capacidad para detectar diferencias.

Por las razones que ya hemos mencionado, en el cálculo informatizado del estadístico de prueba no se distingue entre utilizar distribución normal (z) para muestras grandes y *t de Student* para muestras chicas, como acabamos de hacer en los ejemplos anteriores. Por el contrario, se usa siempre distribución t[104]. Así, esta prueba se conoce como *prueba t de diferencia de medias*. Es el caso del programa InfoStat® que estamos utilizando.

Ejemplo (datos reales): la salida que mostramos a continuación es una comparación de la edad promedio de los docentes varones y mujeres del nivel

[104]Recordemos que esta distribución tiende a la normal cuando las muestras son grandes.

medio. Los datos provienen de una muestra aleatoria de 246 docentes de la ciudad de Córdoba. La hipótesis nula de esa comparación es que no hay diferencia en la edad promedio de mujeres y varones docentes del nivel medio, que se confronta con una hipótesis alternativa que afirma que sí hay diferencia. Se trata de una prueba bilateral que se expresa así:

$$H_0: \mu_1 - \mu_2 = 0$$
$$H_1: \mu_1 - \mu_2 \neq 0$$

Donde los subíndices 1 y 2 se refieren a los grupos formados por docentes mujeres y varones respectivamente. En el video *prueba t dos muestras independientes*, se ve como pedir a Infostat® la realización de esta prueba, la salida es:

Prueba T para muestras Independientes

Clasific	Variable	Grupo 1	Grupo 2	n(1)	n(2)	Media(1)	Media(2)	Media(1)-Media(2)	pVar(Hom)	T	p-valor	prueba
sexo	edades	(mujeres)	(varones)	180	66	38,77	41,52	-2,75	0,2122	-1,18	0,2366	Bilateral

La primera columna (Clasific) indica cuál es la variable de clasificación, es decir la que define los grupos.
Luego se especifica la variable sobre la que se hará la comparación (la edad).
Los grupos (mujeres y varones).
La cantidad de casos en cada uno de ellos (180 mujeres y 66 varones).
Las dos columnas siguientes indican las medias muestrales: la edad promedio de las mujeres de la muestra es de 38,77 años y la de los varones 41,52.
La columna siguiente se usa para probar si las varianzas de los grupos son iguales o diferentes. P(Var.Hom) es el valor p asociado a la prueba de homogeneidad de varianzas. En este caso es 0,2122, en un valor grande (mucho mayor a 0,05 que es el nivel de significación usual) por lo que no se rechaza la igualdad de las varianzas. Por lo tanto, lo que sigue de la prueba de diferencia de medias corresponde al caso 1, varianzas iguales. Esto permite decidir cuál es la fórmula para calcular el t_{obs}. Infostat® realiza la corrección de Welch-Satterthwaite de manera automática si comprueba que las varianzas difieren al 5%.
Luego encontramos el valor del estadístico de prueba t, es el t_{obs} para los datos del problema.
Sigue el valor de probabilidad asociado a ese t_{obs}, que es de 0,2366.
La última columna indica que se trata de una prueba bilateral que fue lo que solicitamos al programa.

Debido a que el valor de probabilidad es un número alto (24%), muy superior al 5% que solemos usar como criterio para rechazar H_0, la decisión es la de no rechazarla. Por lo que concluimos que no hay evidencia para creer que en las escuelas de nivel medio de la ciudad de Córdoba, la edad promedio de los docentes varones sea diferente de la de las mujeres.

La lateralidad de la prueba que analizamos en el capítulo anterior, sigue del mismo modo cuando trabajamos con diferencias de medias. Por ejemplo, podemos tener expectativa en que una droga que se está experimentando produzca efectos sobre la depresión, en dirección a reducir el puntaje que

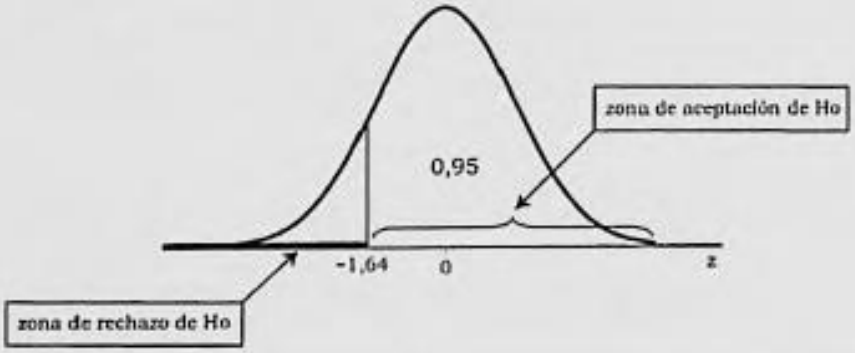
alcanzan los sujetos en un test que la evalúa. Para poner a prueba la droga será necesario diseñar un experimento, no avanzaremos en ese tema pero de manera muy simple, podemos pensar en dos grupos de pacientes depresivos a uno de los cuales se administra la droga (grupo 1) y al otro no (grupo 2)[105]. Concluiremos que la droga tiene efectos si luego de un tiempo de su administración, el grupo de pacientes que la recibieron experimenta cambios positivos en mayor magnitud que el otro. Dicho de otro modo, habrá efectos si la media de puntaje en el test que evalúa depresión es significativamente menor en el grupo que se sometió al tratamiento. Como siempre, la hipótesis nula afirmará que no hay diferencia:

$$H_0: \mu_1 - \mu_2 = 0$$

Como ahora nos interesa que el grupo 1 haya reducido su puntaje en el test de depresión, esperamos que la media del grupo 1 sea menor que la del grupo 2, lo cual se escribe:

$$H_1: \mu_1 - \mu_2 < 0$$

Por la lateralidad de la prueba, solo hay una zona extrema de rechazo, la izquierda. Fijando un 5% de nivel de significación, si se tratara de muestras grandes, en las que podemos usar distribución normal, esta zona se representa del modo habitual:



Por el contrario, si se trata de muestras pequeñas, corresponde usar distribución *t*, y el punto crítico dependerá de los grados de libertad.

Ejemplo (datos ficticios): el grupo de 15 sujetos que recibió un medicamento arroja un puntaje promedio en la prueba que evalúa la depresión de 5,7 puntos, con desviación estándar de 1,1 puntos. Los 10 pacientes que no recibieron el medicamento alcanzan un puntaje promedio de 7,2 puntos, con desviación estándar de 1,6 puntos. La prueba previa sobre la homogeneidad de las varianzas indica que no puede suponérselas iguales, por lo que estamos en el caso 2. Debe utilizarse la distribución t con grados de libertad que deben calcularse con la expresión de Welch-Satterthwaite, el resultado[106] es 15. El punto crítico $t_{15;\,0,05}$, es -1,76.

---

[105]Se trata de una versión muy simplificada, solo para ver el uso de esta prueba. El tema se desarrolla con detalles en la materia Metodología de la Investigación Psicológica.

[106]Redondeado al entero

El estadístico de prueba vale:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_1^2}{n_2}}} = \frac{(5,7 - 7,2) - 0}{\sqrt{\frac{1,1^2}{15} + \frac{1,6^2}{10}}} = -2,58$$

Es un valor que se sitúa a la izquierda del punto crítico, por lo que se rechaza la H_0 y se concluye que el grupo que recibió la droga alcanzó un puntaje significativamente menor que el otro grupo.

Ejemplo (datos reales): en un estudio realizado en el Centro de Promoción del Adulto Mayor, se seleccionaron aleatoriamente entre todos los asistentes, a 503 personas mayores de 50 años. Entre otras preguntas, se computó el número de hijos de cada uno de ellos.

Se conformaron dos grupos con los sujetos estudiados, quienes tenían hasta 65 años en el momento del estudio y quienes tenían 66 o más años. En este ejemplo, estos dos grupos, si bien no fueron asignados de manera aleatoria, se comportarían como muestras independientes.

Podríamos suponer que las personas de mayor edad tendrían más hijos, dadas ciertas razones históricas, religiosas y culturales que habitualmente inciden en el control de la natalidad. Esta hipótesis está basada también en el conocimiento demográfico; sabemos que las tasas de fecundidad en nuestro país han venido descendiendo desde hace varias décadas. Sostenemos así que los que conforman el grupo de 66 años y más tendrán más hijos que los de 65 años o menos, con lo que se trata de una prueba unilateral. Si llamamos 1 al grupo de los de hasta 65 años y 2 al de quienes tienen 66 ó más, las hipótesis se expresan de la siguiente manera:

$$H_0: \mu_1 - \mu_2 = 0$$
$$H_1: \mu_1 - \mu_2 < 0$$

Los resultados descriptivos de los dos grupos se muestran a continuación:

Estadística descriptiva

edadcod	Variable	n	Media	D.E.
1,00	hijos	243	2,49	1,44
2,00	hijos	260	2,61	1,38

El nombre de la variable edadcod, corresponde a los grupos 1, hasta 65 años y 2, de 66 ó más. Los grupos tienen 243 y 260 personas respectivamente.

Vemos que hay diferencia en el número de hijos promedio de los dos grupos. Los del segundo grupo (66 o más) tienen en promedio 0,12 hijos más que los del otro grupo. Ahora bien, dadas estas diferencias entre las medias encontradas, nos interesa determinar si se deben al azar o bien si tienen una magnitud tal que representen una diferencia que pueda atribuirse a la diferencia de edad de los sujetos de los dos grupos.

Planteamos una prueba *t* para muestras independientes, fijamos el nivel de significación en 5% y hallamos que el valor crítico de *t* con 501 grados de libertad (243+260-2) es -1,65 (como habíamos señalado, cuando los grados de libertad

son elevados, casi no hay diferencia entre una distribución t y una normal). La región de rechazo está conformada por todos los valores de t que sean inferiores a -1,65.

InfoStat® presenta la salida de esta prueba de la siguiente manera:

Prueba T para muestras Independientes

Clasific	Variable	Grupo 1	Grupo 2	n(1)	n(2)	Media(1)	Media(2)	pBrioVar	T	p-valor	prueba
edadcod	hijos	(1.00)	(2.00)	243	260	2.49	2.61	0.5191	-0.94	0.1747	Unilateral

Que muestra: la variable que clasifica (edadcod), la que se analiza (hijos), los nombres de los dos grupos (1 y 2), los tamaños de muestra en cada grupo (243 y 260), las medias (2,49 y 2,61), el valor p para la prueba de homogeneidad de varianzas (0,5191), el valor del estadístico de prueba (t=-0,94), el valor de probabilidad asociado a la prueba y el tipo de prueba, unilateral en este caso.
La prueba preliminar de homogeneidad de varianzas da un valor p de 0,5191, por lo que no se rechaza la hipótesis nula de esa prueba: las varianzas no difieren significativamente. Por lo tanto, la prueba de diferencia de medias se hace considerando varianzas iguales y los grados de libertad se calculan directamente como $n_1 + n_2 - 2$.
El t_{obs} de la prueba es -0,94, que se ubica en la zona de no rechazo (la zona de rechazo es la que queda por debajo de -1,65). Con ese resultado ya estamos en condiciones de concluir sobre la prueba: no se rechaza H_0, las medias no difieren de manera significativa, no hay diferencia en el número de hijos entre los grupos conformados.
Si no hubiésemos calculado previamente el punto crítico, podemos llegar a esta conclusión a partir del valor p, que en este caso es 0,1747 y representa la probabilidad de haber hallado esa diferencia o una mayor, por puro azar. Este es el valor que, como sabemos, se juzga en comparación con el nivel de significación, por ser mayor a 0,05 que habíamos establecido, decidimos no rechazar la H_0. Cuanto más pequeña sea esta probabilidad, tanta más evidencia habrá para rechazar H_0, en este caso la consideramos grande y no rechazamos. La lectura del valor p es, en este caso "si el número promedio de hijos de los dos grupos fuera el mismo, la probabilidad de haber encontrado entre dos muestras de tamaños 243 y 260, una diferencia de 0,12 ó superior, es de 0,1747". Brevemente:

$$P((\bar{x}_1 - \bar{x}_2 < -0{,}12)/(\mu_1 - \mu_2 = 0)) = 0{,}1747$$

Prueba de diferencia de proporciones

Compararemos ahora dos muestras en cuanto a la proporción de casos que hay en una categoría de una variable que puede ser nominal o también de un nivel superior[107]. Aunque en los programas de análisis de datos este procedimiento se

[107]Aunque la prueba se usa principalmente para comparar variables nominales, no hay inconveniente en usarla con variables métricas, definiendo con precisión qué se compara. Por ejemplo, si la variable es la edad, podemos comparar la proporción de personas mayores de 65 años en dos muestras. Todos los mayores de 65 constituyen una categoría y el resto la otra. En ese caso decimos que hemos "dicotomizado" una variable métrica, la hemos transformado en una variable con dos categorías: *mayores de 65* y *65 o menos*. De mismo modo que se definen como promocionados, los alumnos con notas 7 o mayores.

realiza también solicitando *prueba t*, esto sólo está autorizado si se trabaja con muestras grandes.
De manera muy similar a la prueba de diferencia de medias, la H_0 afirma que no hay diferencia entre las proporciones de las dos poblaciones, por lo que tiene la forma:

$$H_0: P_1 - P_2 = 0$$

Mientras que la H_1 puede indicar que las proporciones solo difieren:

$$H_1: P_1 - P_2 \neq 0$$

Cuando la prueba es bilateral o bien, si es unilateral derecha:

$$H_1: P_1 - P_2 > 0$$

O izquierda:

$$H_1: P_1 - P_2 < 0$$

Dado que solo trabajaremos con muestras grandes al analizar la diferencia de proporciones, solo usaremos la distribución normal. El estadístico de prueba tiene forma similar al que usamos en la prueba de la proporción para una sola muestra, solo que ahora hay que hacer participar los datos que provienen de dos muestras. Así resulta:

$$z = \frac{(\hat{p}_1 - \hat{p}_1) - (P_1 - P_2)}{\sqrt{\frac{\hat{p}_1 * (1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2 * (1-\hat{p}_2)}{n_2}}}$$

Donde $\hat{p}_1$ y $\hat{p}_2$ son los estimadores de P_1 y P_2 respectivamente. A diferencia de la prueba sobre una sola proporción, ahora no se cuenta con valores poblacionales de P_1 ni de P_2, ya que la H_0 solo enuncia que son iguales. Por eso ahora, el error estándar del estimador (el denominador del estadístico de prueba) se calcula en base a las proporciones muestrales.

Ejemplo (datos ficticios): se dispone de datos de la proporción de aplazos sobre el total de materias rendidas que tienen varones y mujeres estudiantes de una carrera universitaria. En una muestra de 200 mujeres hay un 15% de aplazos, mientras que entre los 150 varones que componen la otra parte de la muestra, el porcentaje es del 17%. Nos preguntamos si se trata de una diferencia significativa o si puede explicarse por la variabilidad propia de los datos. Así, las hipótesis de la prueba serán:

$$H_0: P_1 - P_2 = 0$$
$$H_1: P_1 - P_2 \neq 0$$

Es decir que la hipótesis nula afirma que la diferencia en la proporción de aplazos entre varones y mujeres es cero en la población, y la hipótesis alternativa, dice que esa diferencia es diferente de cero.

Fijamos el nivel de significación en el 5% y, por tratarse de una prueba bilateral, los puntos críticos son ±1,96.
A continuación calculamos el estadístico de prueba, que resulta:

$$z = \frac{(\hat{p}_1 - \hat{p}_1) - (P_1 - P_2)}{\sqrt{\frac{\hat{p}_1 \cdot (1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2 \cdot (1-\hat{p}_2)}{n_2}}} = \frac{(0{,}15 - 0{,}17) - 0}{\sqrt{\frac{0{,}15 \cdot (1-0{,}15)}{200} + \frac{0{,}17 \cdot (1-0{,}17)}{150}}} = -0{,}50$$

Es un valor que no se ubica en la zona de rechazo, por lo que la decisión es la de aceptar H_0 y concluir que no hay evidencia para creer que la proporción de aplazos entre mujeres y varones sea diferente.

Muestras apareadas

Esta prueba es útil cuando se buscan diferencias que puedan haber aparecido en sujetos individuales. La prueba se llama así porque las diferencias se consideran en pares o en parejas. En lugar de comparar muestras provenientes de dos poblaciones independientes, compararemos unidades de análisis consigo mismas, en dos momentos distintos. Ejemplo típico de este uso lo constituyen las pruebas en las que se compara una situación "antes y después". Así, cuando cierta característica de los sujetos experimentales se evalúa antes de un tratamiento y se vuelve a medir luego del tratamiento, interesa conocer en qué medida se han producido cambios *individuales*. Observamos a cada individuo en dos momentos y comparamos las dos observaciones (mediciones). En el contexto del diseño experimental, la medición en el momento inicial se llama *pretest* y la posterior *postest*.
Pero no es el único ámbito en que se usa, cuando se comparan los logros que los alumnos alcanzan luego de una determinada experiencia pedagógica, es valioso poder comparar el "estado inicial" (anterior a la intervención) con el "estado final" (posterior) de cada individuo, o cuánto aprendieron o si se modificó determinada conducta. Esta prueba pone el acento en los cambios sucedidos en cada sujeto y no en las diferencias entre sujetos. Cuando interesa conocer la diferencia de presión arterial a la mañana y al atardecer, corresponde medir la presión arterial de cada persona en los dos horarios y comparar uno a uno. Por cierto, luego los resultados se agregan, pero las diferencias se miden sujeto a sujeto.
No hay cambio conceptual en el planteo de las hipótesis: la H_0 afirma que no hay diferencia entre las dos mediciones (o entre las mediciones hechas en momentos distintos) y la H_1 podrá ser unilateral o bilateral. Sin embargo cambiamos levemente la notación, porque vamos a resumir la diferencia en la letra $\overline{D}$ (por media de diferencias) y equivale a $\mu_1 - \mu_2$. El objetivo de este cambio es poner el acento en que no tratamos con dos poblaciones independientes (una representada por μ_1 y la otra por μ_2) sino con las diferencias entre dos mediciones. $\overline{D}$ es un parámetro y es sobre $\overline{D}$ que formulamos ahora las hipótesis:

$$H_0: \overline{D} = 0$$

La hipótesis alternativa puede ser bilateral

$$H_1: \overline{D} \neq 0$$

Unilateral derecha

$$H_1: \overline{D} > 0$$

O bien unilateral izquierda

$$H_1: \overline{D} < 0$$

El estimador de $\overline{D}$ se llamará $\bar{d}$ y es la media de las diferencias individuales, que tiene distribución *t de Student* con *n-1* grados de libertad. Como se trata de una sola variable, el estadístico de prueba es semejante al que usábamos para una sola muestra, porque resume las diferencias para cada caso:

$$t = \frac{\bar{d} - \overline{D}}{\frac{s_d}{\sqrt{n}}} = \frac{\bar{d}}{\frac{s_d}{\sqrt{n}}}$$

La última igualdad se debe a que, bajo la H_0, $\overline{D} = 0$.
s_d es la desviación estándar de la variable d, que mide las diferencias individuales.

Ejemplo (parcial[108]): se busca detectar el eventual efecto que tendría una intervención terapéutica sobre el bienestar de pacientes diagnosticados de depresión. Disponemos de un test que nos permite evaluar el bienestar de los pacientes con nivel cuantitativo, en una escala que va de 0 (mínimo bienestar) a 10 (máximo bienestar). Para evaluar la terapia, nos interesamos por los cambios que suceden en el bienestar de los pacientes entre el momento previo y el posterior a la misma. Hacemos esto por medio de la aplicación del test a una muestra de 7 pacientes diagnosticados de depresión, en dos momentos: antes de la terapia y al cabo de ella.
Esperamos que la terapia tenga por efecto el de aumentar el bienestar de los sujetos que la reciben, dicho de otro modo, esperamos cambios positivos en el puntaje del test. Las hipótesis son entonces:

$$H_0: \overline{D} = 0$$
$$H_1: \overline{D} > 0$$

Fijado el nivel de significación en el 5% y suponiendo que la variable se distribuye de manera normal en la población, el punto crítico de la distribución t con 6 grados de libertad, de una cola derecha es t_c =+1,943.

[108] Es un ejemplo incompleto porque no hay grupo control, por lo que no es seguro que los cambios observados se deban a la intervención terapéutica o a otros factores.

Los siguientes son los datos recogidos:

sujeto	antes x_1	después x_2	diferencia d_i
1	5	7	2
2	4	7	3
3	6	6	0
4	3	5	2
5	4	5	1
6	5	6	1
7	7	7	0

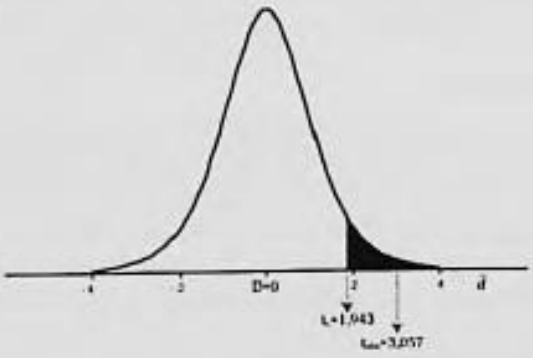
Esta tabla indica, para cada individuo, el puntaje que obtuvo en la prueba que mide bienestar tomada antes de la terapia (x_1) y en la tomada después (x_2). Además, las diferencias para cada sujeto, que es la resta de la segunda menos la primera, a esas diferencias las llamamos d_i, el subindice i se refiere a cada sujeto y va desde 1 hasta 7.

La hipótesis nula de la prueba es que no hay diferencia en las dos mediciones, es decir que no hay efectos de la terapia, que el bienestar de los sujetos luego del tratamiento es igual que antes de él. El cambio respecto de las pruebas para muestras independientes es que ahora pasamos a trabajar con d como variable, sus medidas descriptivas son; la media de las d_i, $\bar{d} = 1{,}286$, y desviación estándar, $s_d = 1{,}113$.

Con esa información se llega al estadistico de prueba:

$$t_{obs} = \frac{\bar{d}}{\frac{s_d}{\sqrt{n}}} = \frac{1{,}286}{\frac{1{,}113}{\sqrt{7}}} = 3{,}057$$

Por ser mayor que el punto crítico ($t_{obs} > t_c$), está en la zona de rechazo de H_0, y se concluye que hay evidencia para considerar que los puntajes en el test de bienestar son mayores luego de la terapia. La siguiente es la representación gráfica de este resultado.



El video *prueba t muestras apareadas* indica como pedir esta prueba a InfoStat®; el resultado se muestra así:

Prueba T (muestras apareadas)

Obs(1)	Obs(2)	N	media(dif)	DE(dif)	T	p(Unilateral D)
X1	X1	7	1.29	1.11	3.06	0.0112

En la última columna, que dice "P(Unilateral D)" que es el tipo de prueba que se pidió, agrega el valor de probabilidad de ese *t*, que vale 0,0112. Es una probabilidad pequeña (menos del 0,05) que confirma el rechazo de H_0.

Ejemplo (datos reales): un estudio que se llevó a cabo con personas mayores que asisten a centros de día, programas universitarios y centros de jubilados. Los participantes de este estudio manifestaban quejas de atención y memoria, sobre todo a corto plazo. Las quejas están centradas en cierta falta de competencia en tareas domésticas: pérdida de llaves, dejar una hornalla prendida o ciertas ejecuciones cotidianas afectadas por un declive normal del funcionamiento cognitivo. Todos los sujetos fueron entrenados en destrezas básicas asociadas a la mejora de estas habilidades cognitivas, durante 12 sesiones grupales de dos horas duración, con una frecuencia semanal. Basado en la teoría del procesamiento de la información, los alumnos mayores aprenden ciertas técnicas que les permiten controlar los automatismos motores, ser más detallistas, prestar más atención a información que se les escapa, y a través de la imaginación, del uso del lenguaje y de diversas técnicas, aprenden a mejorar su capacidad asociativa. Esta actividad se denomina "taller de memoria".
Los sujetos fueron evaluados con pruebas neuropsicológicas que valoran las habilidades entrenadas, al inicio y finalizada la intervención.
Una de las pruebas toma en cuenta los puntajes de una prueba de asociación entre caras y nombres, que consiste en presentar a las personas fotos y sus correspondientes nombres y apellidos. Luego de un tiempo, en el que deben aprenderse las caras con sus correspondientes nombres, se les presentan sólo las fotos y ellos deben completar los nombres y apellidos. Se le asigna un punto por cada nombre y por cada apellido correcto, sin descontar puntos si obtuvieron errores. La hipótesis nula dirá que no hay diferencia entre los puntajes obtenidos antes y después de la intervención, mientras que la hipótesis alternativa afirmará que si hay diferencia (sin especificar la dirección de la diferencia). Tomados los puntajes de 401 sujetos, solicitamos a InfoStat® una prueba t apareada, bilateral y la salida es:

Prueba T (muestras apareadas)

Obs(1)	Obs(2)	N	media(dif)	DE(dif)	T	Bilateral
nomcarpr	nomcarpo	401	-0.22	3.59	-1.25	0.2112

Las variables se llaman nomcarpr (nombres y caras pretest) y nomcarpo (nombres y caras postest). También se puede pedir en las opciones que muestre las medias de las pruebas antes y después, y la salida queda:

Obs(1)	Obs(2)	N	media(dif)	Media(1)	Media(2)	DE(dif)	T	Bilateral
nomcarpr	nomcarpo	401	-0.22	23.36	23.58	3.59	-1.25	0.2112

Las medias difieren poco: de 23,36, el puntaje sube a 23,58. Esa apreciación intuitiva sobre la pequeñez de la diferencia es confirmada por el valor de probabilidad (bajo el rótulo Bilateral), que es alto (21%), más grande que el 5 y

que el 10%. Como resultado, no se rechaza la H_0 y consideraremos que los puntajes no han cambiado. El entrenamiento no ha tenido efectos significativos en esta habilidad tan compleja, como la de relacionar caras y nombres.

Ejemplo (datos reales): aplicada sobre la misma muestra de adultos mayores, es una prueba de atención que consiste en marcar en medio de una sopa de letras, sólo las letras zetas, en 30 segundos. Por cada acierto se le asigna un punto, sin descontar cuando cometen errores. Formularemos la prueba de modo unilateral, con la expectativa de hallar un aumento en el puntaje de atención; esperamos que el puntaje posterior sea mayor que el previo, por lo que la diferencia de la segunda medición menos la primera dará positiva, luego $H_1: \overline{D} > 0$, es una prueba unilateral derecha. Aplicada sobre 397 casos[109], la prueba da como resultado:

Prueba T (muestras apareadas)

Obs(1)	Obs(2)	N	media(dif)	Media(1)	Media(2)	DE(dif)	T	p(Unilateral D)
atenpos	atenpre	397	5,19	23,04	17,85	7,38	14,00	<0,0001

Los nombres de las variables son atenpre (atención pretest, *Obs(2)*) y atenpos (atención postest, *Obs(1)*)[110]. La primera lectura muestra que las medias son apreciablemente diferentes, el puntaje cambió de 17,85 a 23,04, es decir un aumento de 5,19 puntos, que juzgariamos como elevado. En efecto, el valor de probabilidad de la última columna (*p(unilateral D)*) indica que, si en la población al diferencia fuese nula, la probabilidad de haber hallado esta diferencia solo por azar es menor a 1 en 10.000, lo que nos lleva a rechazar la H_0 y concluir que los puntajes efectivamente se incrementan luego del entrenamiento.

Coeficiente r de Pearson

En el análisis de relaciones entre variables a partir de datos de muestras, se han calculado coeficientes para medir el grado (o intensidad) de la asociación. Luego de haber visto los procedimientos de inferencia, corresponde generalizar las conclusiones obtenidas en estos análisis a toda la población de referencia. Ahora se dispone de las herramientas necesarias para hacer esa generalización. Para el coeficiente *r de Pearson* la lógica para la prueba de hipótesis es la que ya conocemos, solo cambia la forma de calcular el estadístico de prueba. Para niveles de medición más bajos (ordinales o nominales), se usan otras pruebas, que se desarrollan en el próximo capítulo

Si ha sido obtenido en una muestra representativa, el coeficiente de correlación de Pearson allí calculado es un estimador del coeficiente de correlación poblacional, es decir que mide la intensidad de la asociación entre las variables

---

[109] El número de casos difiere porque no siempre todas las personas completan íntegramente todas las pruebas, lo que da lugar a que haya casos perdidos, sea porque solo se cuenta con la medición previa o solo con la posterior.

[110] La que se llama *Obs(1)* es el resultado del postest y la *Obs(2)* es el puntaje del pretest, para esta elección hay que tener en cuenta la forma en que el programa hace la resta: siempre opera como *Obs(1)-Obs(2)*, debe elegirse cómo llamar a cada una para que la resta sea en el orden adecuado. La elección se realiza en la primera ventana de la prueba, al momento de ingresar las variables, la primera que se ingresa es la que se va a llamar *Obs(1)* y la segunda *Obs(2)*.

en la población; así como $\bar{x}$ es el estimador de μ y $\hat{p}$ el estimador de P. Manteniendo la notación anterior, usaremos la letra griega ρ (rho) para referirnos al coeficiente de correlación paramétrico (o poblacional).
Si se extraen todas las muestras posibles de una población dada y en cada una se calcula r, la media de todos los coeficientes de correlación encontrados, coincide con el coeficiente de correlación paramétrico. A esa media, que no calculamos, porque no es posible extraer "todas las muestras de la población", la llamamos esperanza.
Dicho de otra manera, r es un estimador insesgado de ρ. Los escribimos: $E(r) = \rho$.

Por su parte, la varianza de r es:

$$\sigma_r^2 = \frac{1 - r^2}{n - 2}$$

Por lo que el error estándar del estimador tiene la forma:

$$\sigma_r = \sqrt{\frac{1 - r^2}{n - 2}}$$

Y, tal como sucedió con la media y la proporción, el Teorema Central del Límite indica que a medida que aumenta el tamaño de las muestras, la distribución de los r tiende a ser normal. Si podemos suponer que en la población, la variable bajo análisis tiene distribución normal, es válido usar la distribución t cuando la muestra es pequeña. Cuando aumenta el tamaño de la muestra esta distribución tiende a la normal. En consecuencia, y como sucedió con la media, usaremos distribución *t de Student* siempre.
Para esta prueba de hipótesis, la distribución t tiene grados de libertad que se calculan como el tamaño de la muestra menos dos:

$$gl = n - 2$$

Conociendo la distribución de probabilidades para r podemos construir el estadístico de prueba restando el estimador menos el parámetro y dividiendo por el error estándar del estimador:

$$t = \frac{r - \rho}{\sqrt{\frac{1-r^2}{n-2}}}$$

La hipótesis de carácter conservador (aquella que señala la no-diferencia) será la que afirme que en la población no hay relación entre las variables, por lo que si en la muestra hallamos un valor de r no nulo, habrá sido por azar. Nuevamente se trata de decidir si un valor muestral observado es evidencia suficiente para rechazar la H_0; a la que escribiremos:

$$H_0: \rho = 0$$

La hipótesis alternativa puede ser bilateral:

$$H_1: \rho \neq 0$$

O unilateral derecha:

$$H_1: \rho > 0$$

O unilateral izquierda:

$$H_1: \rho < 0$$

Y en todos los casos transformaremos el coeficiente r observado a puntaje t, haciendo:

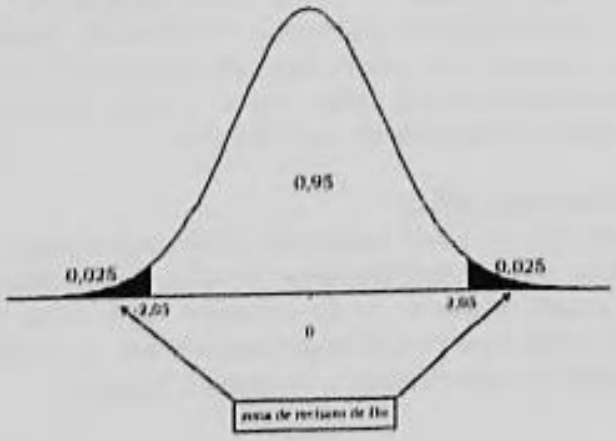
$$t = \frac{r_{obs} - \rho}{\sqrt{\frac{1-r_{obs}^2}{n-2}}} = \frac{r_{obs}}{\sqrt{\frac{1-r_{obs}^2}{n-2}}}$$

La última igualdad se debe a que la hipótesis nula afirma que $\rho = 0$.

Ejemplo (datos ficticios): se observa la relación entre el tiempo que los alumnos dedicaron a preparar el examen de una materia y la calificación obtenida en ese examen, a partir de una muestra de 27 estudiantes. Se obtiene un coeficiente de correlación lineal de Pearson de $r_{obs} = +0{,}37$. El signo positivo de este coeficiente indica que la relación es directa, por lo que, en la muestra, los alumnos que dedican más tiempo a la preparación, tienden a tener notas más altas. El valor absoluto indica que se trata de una relación moderada entre las dos variables. Ahora nos interesa probar si este resultado es suficiente evidencia para creer que en la población, las dos variables están relacionadas, es decir, que en la población el coeficiente de correlación no es cero. La pregunta es si hemos encontrado 0,37 porque en la población las variables están correlacionadas o solo por las variaciones propias del procedimiento aleatorio de muestreo, es decir, solo por azar.
Las hipótesis correspondientes a este problema son:

$$H_0: \rho = 0$$
$$H_1: \rho \neq 0$$

Es bilateral porque nuestro interés es saber si ρ difiere de cero.
Fijamos el nivel de significación en el 5% y hallamos en una distribución *t de Student* con 25 grados de libertad (n-2=27-2=25) los valores críticos correspondientes son ±2,05, gráficamente:



El área sombreada constituye la probabilidad extrema de 0,05, repartida en dos colas de 0,025 cada una. La zona de rechazo de H_0 se constituye por el conjunto de los valores *t* mayores a 2,05 así como los menores a -2,05.
Ahora transformamos el valor de *r* obtenido a puntaje *t*, calculando el estadístico de prueba:

$$t = \frac{r_{obs}}{\sqrt{\frac{1-r_{obs}^2}{n-2}}} = \frac{0,37}{\sqrt{\frac{1-0,37^2}{27-2}}} = 1,99$$

Un valor que no se encuentra en la zona de rechazo, por lo que la decisión es la de aceptar H_0 y concluir que no hay suficiente evidencia para afirmar que haya una correlación lineal no nula entre el tiempo que los alumnos dedican a preparar una materia y la nota que obtienen en el examen. Diremos que el coeficiente de correlación hallado en la muestra no difiere significativamente de cero o, más simplemente, que no es significativo.

Como siempre puede hacerse en las pruebas de hipótesis, vamos a llegar a la misma conclusión calculando el *valor p* asociado al coeficiente *r* muestral. Se trata de encontrar la probabilidad de hallar un valor de *r* como el observado o uno más extremo que él, si la hipótesis nula fuera cierta. Como la prueba es bilateral debemos tratar a la expresión "más extremo" como incluyendo dos posibilidades, que *r* sea mayor que el observado o menor que su opuesto, por lo que la probabilidad que buscamos se escribe:

$$P(r < -r_{obs} \cup r > r_{obs}/H_0 \text{ es verdadera}) = P(r < -0,37 \cup r > 0,37/\rho = 0)$$

Que se lee como "la probabilidad que *r* sea menor que el opuesto al valor observado o mayor que el valor observado, dado que la hipótesis nula es verdadera"
Usando el estadístico de prueba, transformamos los dos valores de r_{obs} en puntajes *t* y entonces esa probabilidad, expresada en términos de *t*, nos queda:

$$P(t < -1,99 \cup t > 1,99)$$

En la que no incluimos la condición que H_0 sea verdadera ($\rho = 0$) porque está implícita en la distribución *t* de *r*. Cuando la solicitamos a InfoStat®, esa probabilidad nos da 0,0568. Debido a que es mayor a nuestro nivel de significación ($\alpha = 0,05$), la decisión es la de no rechazar H_0. La lectura de este valor *p* es "si en la población no existiera correlación entre las variables, la probabilidad de haber hallado un valor como el observado o más extremo que él sería de 0,0569. Consideramos a este valor como elevado, por lo que no rechazamos la hipótesis de ausencia de correlación".

Dos consecuencias de este resultado:
Primera: un coeficiente que, a nivel muestral habríamos juzgado como moderado no puede generalizarse como significativo a toda la población. Esto se debe principalmente al reducido tamaño de la muestra. Así, para que este valor de *r* hubiese representado una asociación significativa en la población, habría sido necesario que proviniese de una muestra de mayor tamaño.

Segunda: el valor de t_{obs} es cercano al punto crítico (1,99 frente a 2,05), de modo que es poco lo que le falta para que la hipótesis sea rechazada. En el procedimiento a través del valor *p*, eso equivale a que dicho valor de probabilidad apenas supera al nivel de significación establecido: 5,6% frente a 5%. Aun así, nuestro criterio fijado a priori indica que no debemos rechazar H_0. Pero esto debe informarse en el reporte, para que el lector pueda interpretar los resultados.

Solicitada a InfoStat®, esta operación da el siguiente resultado:

Coeficientes de correlación

Correlación de Pearson: Coeficientes\probabilidades

	horas	calificacion
horas	1,00000	0,05608
promedio	0,37195	1,00000

La expresión *Coeficientes\probabilidades* indica que en la diagonal secundaria de la tabla debe leerse: primero el coeficiente, en la intersección de las dos variables (promedio y horas) y luego la significación (el valor *p*) en la otra intersección de las variables (horas y promedio).

Si la salida se pide en "forma de lista" y "formato compacto" se obtiene:

Correlación de Pearson

Variable(1)	Variable(2)	n	Pearson	p-valor
horas	promedio	27	0,37195	0,05608

Que es de lectura más accesible.

La lectura es entonces que la correlación muestral entre las dos variables es 0,37195 y que la probabilidad de que ese resultado haya sido encontrado por puro azar es 0,05608. A un nivel de significación del 5% no se rechaza la H_0 según la cual las variables no están correlacionadas. Aunque sí se rechaza si se fija un nivel de significación "más tolerante" del 10%.

Resumen de pruebas tratadas en el capítulo

Parámetro	Estimador	Estadístico de prueba	Supuestos
$\mu_1 - \mu_2$	$\bar{x}_1 - \bar{x}_2$	$t = \frac{(\bar{x}_1 - \bar{x}_2)}{s_{comb} * \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ $gl = n_1 + n_2 - 2$ $s^2_{comb} = \frac{(n_1 - 1) * s_1^2 + (n_2 - 1) * s_2^2}{n_1 + n_2 - 2}$	Grupos independientes Distribución normal en la dos poblaciones ó $n_1 > 30$ y $n_2 > 30$ Varianzas iguales
$\mu_1 - \mu_2$	$\bar{x}_1 - \bar{x}_2$	$t = \frac{(\bar{x}_1 - \bar{x}_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$ $gl = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$	Grupos independientes Distribución normal en la dos poblaciones ó $n_1 > 30$ y $n_2 > 30$ Varianzas diferentes
$P_1 - P_2$	$\hat{p}_1 - \hat{p}_2$	$z = \frac{(\hat{p}_1 - \hat{p}_1)}{\sqrt{\frac{\hat{p}_1 * (1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2 * (1 - \hat{p}_2)}{n_2}}}$	Grupos independientes y $n_1 > 100$ y $n_2 > 100$
$\overline{D}$	$\bar{d}$	$t = \frac{\bar{d}}{\frac{s_d}{\sqrt{n}}}; gl = n - 2$	Distribución normal de d, ó $n > 30$
ρ	r	$t = \frac{r}{\sqrt{\frac{1 - r^2}{n - 2}}}$	Distribución normal

Capítulo 13 Cuando los supuestos no se cumplen

Las condiciones que se han pedido hasta este punto para los procedimientos vistos, son exigentes. Por ejemplo, en las *pruebas t* debemos suponer que la variable tiene distribución normal en la población[111]. El Teorema Central del Límite nos dice que si las muestras son lo suficientemente grandes, la distribución muestral tiende a ser normal, por lo que puede eliminarse el supuesto de normalidad en la población si las muestras tienen suficiente tamaño, pero a menudo no es posible contar con muestras grandes. Todas las pruebas que hemos visto hasta este momento hacen supuestos acerca de la población, que son condiciones que debe cumplir la distribución de las variables bajo análisis en la población; estos supuestos a veces se cumplen y otras no. Los resultados que se obtengan de esas pruebas dependen del cumplimiento de esas condiciones. En algunos casos es posible poner a prueba la veracidad de esas exigencias, para ver si se cumplen, en otros casos, solo es posible "suponer" que es así. Por esa razón los resultados pueden ser aproximados o directamente incorrectos, si hay violaciones graves a sus condiciones de aplicación.

Además, los cálculos hechos en las pruebas mencionadas, requieren un nivel de medición alto, para poder calcular medias y varianzas. Hemos resuelto parcialmente el problema cuando, al tratar con variables nominales, usamos la proporción de casos en alguna categoría. Sin embargo no hemos resuelto aún el problema de analizar relaciones entre variables cualitativas, a las que no puede calcularse la media ni la varianza, pero que a menudo aparecen en nuestros análisis. Es el mismo caso con el coeficiente de Pearson, su cálculo requiere que se calculen medias y varianzas, lo que no puede hacerse si las variables no son métricas.

Para este tipo de problemas, que son muy frecuentes en investigación social (pocos casos, variables que no son métricas, sin certeza sobre la normalidad de las distribuciones paramétricas), existe un conjunto de pruebas llamadas **pruebas no paramétricas**. Por oposición a ellas, todas las pruebas presentadas hasta aquí son **pruebas paramétricas**, que quiere decir que especifican ciertas condiciones que deben cumplir (o que puede suponerse que cumplan) los parámetros de la población de la que se extrae la muestra.

Son **pruebas no paramétricas** las pruebas de hipótesis que no especifican condiciones sobre los parámetros de la población de la que proviene la muestra.

La limitación de las pruebas no paramétricas respecto de las paramétricas, es que tienen, a igual nivel de significación e igual tamaño de muestra, menor potencia. Eso significa que, para obtener la misma potencia en una prueba no paramétrica que en una paramétrica, es necesario usar más casos.

Si el problema es el del nivel de medición de las variables —que en la mayoría de los casos no es métrico—, puede resolverse apelando a una prueba no paramétrica y lograr resultados de la misma calidad, aunque a un mayor costo por la mayor cantidad de casos necesarios.

---

[111] Lo que puede verificarse inicialmente observando el histograma, comparando la media y la mediana, y calculando los coeficientes de asimetría y curtosis

Si el problema es el tamaño de la muestra, es decir, si tenemos muy pocos casos observados y no puede suponerse distribución normal en la población, entonces no hay alternativa y debe usarse una prueba no paramétrica.
En este capítulo desarrollaremos tres pruebas no paramétricas basadas en el puntaje ji cuadrado y dos alternativas a las pruebas t para muestras independientes y apareadas. Puede consultarse el manual de Siegel (1956) para una presentación muy completa, aunque no actualizada a procedimientos informáticos.

Las pruebas ji cuadrado (o chi cuadrado)

El puntaje *ji cuadrado* fue usado para derivar medidas de la asociación entre dos variables nominales (V de Cramer, C de Pearson) y luego como un modelo especial de probabilidades. Ahora relacionaremos esos dos usos del puntaje *ji cuadrado*, en primer lugar para analizar la eventual independencia entre dos variables (prueba de independencia de atributos), luego para evaluar si una distribución se ajusta a un modelo predicho (prueba de bondad de ajuste) y finalmente para comparar la tendencia central entre variables de nivel ordinal (prueba de la mediana).

Prueba de independencia de atributos

El puntaje *ji cuadrado* (χ^2) es una medida de la distancia que hay entre una distribución de frecuencias bivariada observada y la correspondiente distribución de frecuencias esperadas. Estas frecuencias esperadas son las que se esperarían observar si las variables fueran independientes. Así, cuanto más alejadas se encuentren las frecuencias observadas de las esperadas, tanto más grande será el puntaje χ^2 y más alejadas de la independencia estarán las variables que se analizan, el hecho de estar alejadas de la independencia implica que existe alguna asociación entre ellas. El valor mínimo de este puntaje es cero, que solo podría alcanzarse si todas las frecuencias observadas coincidieran con las esperadas y sería el caso de una independencia perfecta; una situación muy improbable de hallar en la realidad. El puntaje χ^2 carece de un valor máximo, puede ser indefinidamente grande, dependiendo no solo de lo alejadas que están las frecuencias observadas de las esperadas, sino también de la dimensión de la tabla y de la cantidad de casos.

Como las frecuencias observadas que están en la tabla bivariada provienen de una muestra, necesitamos poder generalizar el resultado que hallemos a la población de referencia. Es decir que ahora, en el contexto de la inferencia, nos preguntamos ¿Cómo debería ser de grande el puntaje χ^2 encontrado para que consideremos que las variables se alejan lo suficiente de la independencia? Por la redacción de la pregunta puede verse que tratamos con una prueba de hipótesis, nos estamos preguntando ¿A partir de qué valor podemos considerar que χ^2 es significativo? La respuesta dependerá del valor que asuma χ^2 (que está influido por el tamaño de la muestra) y de la dimensión de la tabla. Para formular las hipótesis de esta prueba, recordemos que la H_0 es aquella que indica no-diferencia, el no-cambio, es la hipótesis "conservadora". Por el contrario, la hipótesis alternativa presenta una diferencia en algún sentido. En este problema,

como vamos a tratar acerca de relaciones entre variables, la H_0 indicará que no hay relación o, lo que es lo mismo, que las variables son independientes.

Ejemplo (datos ficticios) se trata analizar la posible relación entre el resultado del primer parcial de Psicoestadística (aprobado – no aprobado) y el turno en que los alumnos lo hicieron. Se construye una muestra con 180 alumnos seleccionados entre quienes hicieron el primer parcial en los últimos cinco años. La siguiente es la tabla de distribución de frecuencias observadas.

Tabla 1: Frecuencias conjuntas observadas del resultado del parcial y el turno en que se realizó:

Resultado del parcial	Turno			
	Mañana	Tarde	Noche	Total
Aprobado	60	30	40	130
No aprobado	30	10	10	50
Total	90	40	50	180

Para el análisis de la independencia se calculan las frecuencias esperadas[112]:

Tabla 2: Frecuencias conjuntas esperadas del resultado del parcial y el turno en que se realizó.

Resultado del parcial	Turno			
	Mañana	Tarde	Noche	Total
Aprobado	65	29	36	130
No aprobado	25	11	14	50
Total	90	40	50	180

Las frecuencias esperadas conducen al puntaje[113] χ^2, que en este caso es $\chi^2 = 3{,}05$. En el interés por generalizar a toda la población, se trata de alcanzar una conclusión acerca de la independencia o no de las dos variables, que no esté limitada a estos 180 casos, sino que sea general. No debemos olvidar que los datos disponibles son muestrales y, por el modo en que se seleccionan los casos de la muestra, dependen del azar.
Nos preguntamos: ¿el valor hallado para el puntaje $\chi^2 = 3{,}05$, puede explicarse por azar, o representa un distanciamiento suficientemente grande como para atribuirlo a una relación entre las variables en la población?
Queremos entonces decidir si lo que hemos observado para estos alumnos (la muestra de quienes cursaron en los últimos cinco años, por ejemplo) es general, es decir, si vale para alumnos a los que no hemos observado. Por eso, la hipótesis nula de la prueba será:

---

[112] Como $f_{ij} = \frac{f_i \cdot f_j}{n}$

[113] Haciendo: $\chi^2 = \sum \frac{(f_o - f_e)^2}{f_e}$

H_0: El resultado del parcial es independiente del turno en que se realiza[114]

Que equivale a afirmar que no hay relación entre el turno y el resultado.
Su contrapartida, la H_1 dirá que:

> H_1: Existe relación entre el turno en el que se realiza el parcial y el resultado que se obtiene.

La pregunta será entonces si la evidencia hallada a partir de nuestros datos es suficiente para rechazar H_0 y concluir que las variables están relacionadas o si, por el contrario, deberemos seguir sosteniendo que las variables no están relacionadas.
La variable aleatoria χ^2 tiene una distribución de probabilidad asimétrica y su forma depende de los grados de libertad. Estos últimos, para tablas de doble entrada dependen del número de filas y de columnas que tenga la tabla, según:

$$gl = (f - 1) * (c - 1)$$

Donde gl son los grados de libertad, f es el número de filas de la tabla y c el número de columnas. Entonces conocemos el puntaje χ^2 y su distribución de probabilidad, con lo que puede decidirse si se trata de un valor extremo (muy poco probable si H_0 fuera cierta) o bien de un valor esperable. En el primer caso rechazaremos H_0 y concluiremos que hay relación entre el turno en que se hace el parcial y el resultado que se obtiene. En el segundo caso, aceptaremos H_0 y diremos que no hay evidencia para descartar la independencia, o que no hay pruebas para sostener que las variables estén relacionadas. Rechazaremos H_0 si el valor χ^2 encontrado es grande, porque eso es sinónimo de un gran alejamiento de nuestros datos respecto de la independencia. En razón de ello, ésta será siempre una prueba unilateral derecha: se rechaza para valores que excedan cierto límite.

El procedimiento para hacer la prueba puede ser el tradicional, que consiste en fijar de antemano el nivel de significación (α), luego determinar el (único) punto crítico y comparar si el valor observado de χ^2 excede ese punto crítico; si es así se rechaza H_0. O también puede usarse el *valor p* asociado al puntaje χ^2 observado, y si esa probabilidad es menor al nivel de significación, se rechaza H_0.
En este ejemplo, los grados de libertad son:

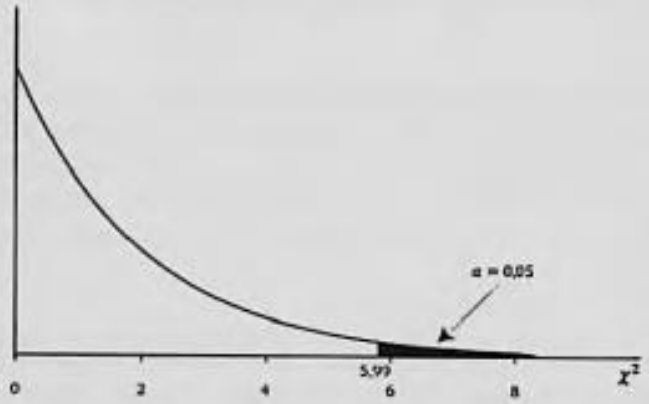
$$gl = (f - 1) * (c - 1) = (2 - 1) * (3 - 1) = 1 * 2 = 2$$

Se fija un nivel de significación $\alpha = 0{,}05$ y, usando una hoja de cálculo (o el calculador de probabilidades y cuantiles de Infostat[30]), se encuentra que el punto crítico que corresponde para esa área (superior) y esos grados de libertad bajo la curva de la distribución χ^2 es 5,99, se lo llama χ^2_c (chi cuadrado crítico). La representación gráfica de la zona de rechazo de H_0 es entonces:

---

[114]De mismo modo que sucede con las pruebas paramétricas, las hipótesis se refieren a toda la población, aunque aquí no aparezca el nombre de un parámetro reconocible, como μ o P.

Gráfico 1: Ubicación del punto crítico que deja un 5% de área superior en una distribución χ^2 con 2 grados de libertad.



De acuerdo a este gráfico, la región de rechazo de H_0 es la que se encuentra a la derecha de 5,99, formada por todos los valores de χ^2 que superen a 5,99. Los datos dieron un puntaje $\chi^2_{obs} = 3{,}05$, que no pertenece a la zona de rechazo de H_0, por lo que no se rechaza H_0 y se concluye que no hay relación entre las variables; o bien que no hay evidencia suficiente para descartar la independencia entre el resultado del parcial y el turno en que éste se realiza.

Si se prefiere usar el valor de probabilidad (*valor p*) para tomar la decisión y dar mayor claridad a los resultados, entonces, como en las pruebas paramétricas, se informa la probabilidad de hallar un valor de χ^2 como el observado o más extremo que él. En esta prueba (de independencia de atributos), "más extremo" siempre quiere decir "mayor que", porque es una prueba unilateral derecha. Buscamos entonces la probabilidad que tiene la variable χ^2 con dos grados de libertad, de asumir un valor igual o mayor al que hemos observado, es decir:

$$P(\chi^2 \geq \chi^2_{obs}) = P(\chi^2 \geq 3{,}05)$$

Y en la calculadora de Infostat® se encuentra 0,2176. Lo leemos diciendo que, si las dos variables fueran independientes, la probabilidad de hallar un puntaje χ^2 como el observado o más extremo que él es de 0,2176. Dado que es una probabilidad alta (sea a un nivel de significación del 5 o del 10%), consideramos a éste como un resultado altamente probable, de ser cierto que las variables son independientes.

En el video *ji cuadrado* se muestra cómo pedirlo a InfoStat®. La salida es:

Frecuencias absolutas
En columnas: turno

resultado	mañana	tarde	noche	Total
aprobado	60	40	30	130
no aprobado	30	10	10	50
Total	90	50	40	180

Frecuencias esperadas bajo independencia
En columnas: turno

resultado	mañana	tarde	noche	Total
aprobado	65,00	36,11	28,89	130,00
no aprobado	25,00	13,89	11,11	50,00
Total	90,00	50,00	40,00	180,00

Estadístico	Valor	gl	p
Chi Cuadrado Pearson	3,05	2	0,2180
Chi Cuadrado MV-G2	3,10	2	0,2119
Coef.Conting.Cramer	0,09		
Coef.Conting.Pearson	0,13		

Que muestra las frecuencias observadas (los datos originales) y la tabla de frecuencias esperadas si fueran independientes. Luego aparece el puntaje χ^2 (3,05) y su valor de probabilidad asociado (*p=0,2180*). Esa es la parte que interesa de esta salida.

Pruebas de bondad de ajuste

El cálculo del puntaje χ^2 ofrece la posibilidad de hacer comparaciones entre frecuencias observadas (reales, provenientes de la recolección de datos) y frecuencias esperadas bajo diferentes hipótesis. En la prueba anterior, las esperadas lo han sido bajo la hipótesis de independencia, pero la condición bajo la cual se esperan determinadas frecuencias puede ser otra y el puntaje χ^2 también permite medir esas distancias.

Ejemplo (datos ficticios): la distribución de la condición que alcanzan los alumnos que cursan Psicoestadistica ha sido, históricamente, 35% de promocionados, 35% de regulares y 30% de libres. Consideremos el subconjunto de alumnos que estudian otra carrera además de Psicología. Una muestra de 142 de estos alumnos se distribuye, según condición, del siguiente modo:

Tabla 3: Distribución de frecuencias de los alumnos de Psicología que también estudian otra carrera, según condición:

condición	alumnos
Promocionados	53
Regulares	51
Libres	38
Total	142

La tabla anterior muestra las frecuencias observadas. Nos preguntamos si esta distribución se aleja significativamente de la tendencia general, o bien si está dentro de lo esperado. Esta pregunta puede reformularse en dirección a saber si los datos observados se "ajustan" a la distribución general o se apartan de ella. Expresado en términos de hipótesis, la H_0 afirmará que no hay diferencia:

> H_0: La distribución de promocionados, regulares y libres de los alumnos que estudian otra carrera se ajusta a la distribución del total de alumnos.

UNIVERSIDAD TÉCNICA DEL NORTE
BIBLIOTECA
Ibarra - Ecuador

Mientras que la H_1, afirmará lo contrario:

> H_1: La distribución de promocionados, regulares y libres de los alumnos que estudian otra carrera se aparta de la distribución del total de alumnos.

Si la distribución se mantuviera igual (si H_0 fuera verdadera), esperaríamos que los 142 alumnos que estudian otra carrera se distribuyeran en las tres categorías según estas proporciones: 0,35 - 0,35 - 0,30. La frecuencia que esperaríamos encontrar en la categoría promocionados es *0,35*142= 49,7* y del mismo modo con las demás categorías. Por lo que esperaríamos la siguiente distribución de frecuencias:

Tabla 4: Frecuencias esperadas bajo la hipótesis de ajuste a la distribución general:

condición	Alumnos
Promocionados	49,7
Regulares	49,7
Libres	42,6

Disponemos ahora de las dos tablas, una de frecuencias observadas y otra de esperadas y queremos evaluar si son similares o muy diferentes; que es el mismo problema que en la prueba de independencia, solo que ahora las tablas son univariadas. Para medir la distancia entre las dos tablas nuevamente se usa el puntaje χ^2, que compara una a una las frecuencias de las celdas. Aplicada a las tablas de arriba, da:

$$\chi^2 = \sum \frac{(f_o - f_o)^2}{f_e} = \frac{(53-49{,}7)^2}{49{,}7} + \frac{(51-49{,}7)^2}{49{,}7} + \frac{(38-42{,}6)^2}{42{,}6} = 0{,}75$$

Del mismo modo que en la prueba de independencia de atributos, buscaremos un valor crítico de χ^2, para tomar la decisión. En este caso, los grados de libertad de la distribución χ^2 dependen del número de categorías de la tabla univariada, simplemente es el número de categorías menos uno:

$$gl = k - 1$$

En este ejemplo, las categorías son tres, por lo que *gl=2*. Con 2 grados de libertad y 5% de nivel de significación, el punto crítico es $\chi^2 = 5{,}99$, por lo que la región de rechazo es el conjunto de valores que superan 5,99. El valor observado se encuentra fuera de la región de rechazo, por lo que corresponde no rechazar H_0 y concluir que los alumnos que estudian otra carrera además de Psicología no muestran, en Psicoestadística, una distribución entre promocionados, regulares y libres que difiera significativamente de la tendencia general de quienes cursan esa materia.

Prueba de la mediana

Cuando es necesario comparar la tendencia central de dos distribuciones, se dispone de la *prueba t de diferencia de medias*. Sin embargo esa prueba no es válida cuando se trabaja con variables que tienen nivel ordinal, ya que allí no tiene interpretación la media ni tampoco la varianza. Si se deben comprar dos muestras en una variable medida a nivel ordinal se puede plantear la hipótesis que afirma que las medianas son iguales, como una equivalencia a la que, en variables métricas plantea que las medias de dos distribuciones son iguales:

$$H_0: M_{dn_1} - M_{dn_2} = 0$$

Frente a una hipótesis alternativa que usualmente es bilateral:

$$H_1: M_{dn_1} - M_{dn_2} \neq 0$$

El procedimiento consiste en calcular, en primer lugar, la mediana del grupo compuesto por los casos de las dos muestras, todos reunidos en una sola distribución, se la denomina "mediana combinada" y se indica M_{dn_c}. Luego se cuentan los casos de cada grupo que quedan por encima y por debajo de esa mediana combinada. Si la mediana de los dos grupos fuera la misma, se esperaría que aproximadamente la mitad de los casos de cada grupo queden por encima de la mediana combinada y la otra mitad por debajo. En la medida que los casos de los grupos se aparten de esa forma de distribuirse habrá evidencia para creer que las medianas difieren. Por lo tanto, se trata de ver si una distribución real de datos respeta una distribución teórica (esperada) o no.
La disposición de los datos se realiza en una tabla de dos por dos como la siguiente:

Ubicación respecto de la mediana combinada	Grupo 1	Grupo 2	Total
Por encima			
Por debajo			
Total			

Bajo la hipótesis nula, esperaríamos que la cantidad de casos por encima y por debajo de la M_{dn_c} fuera la misma para los dos grupos. Dicho de otro modo, para aceptar la H_0 deberíamos hallar independencia entre la pertenencia a los grupos y la ubicación de los casos por encima y por debajo de M_{dn_c}. De este modo vemos que el problema puede tratarse como una prueba de independencia: si el puntaje χ^2_{obs} es tal que debe rechazarse la hipótesis de independencia, será —en esta prueba—, equivalente a rechazar la igualdad de las medianas.
Un problema que suele aparecer cuando se hace el recuento de casos por encima y por debajo de la M_{dn_c} es que algunos coincidan con ella, que no estén ni encima ni debajo. Si la cantidad total de casos con que se cuenta es grande, se pueden dejar de lado esos casos y solo contar los que efectivamente difieran (en más o en menos) de la M_{dn_c}. De lo contrario, puede hacerse el recuento de los casos que están por encima de la M_{dn_c} y los que no lo están, es decir que uno de los grupos

cuenta la cantidad de casos que hay por encima de la M_{dn_c} y el otro los que la igualan o están por debajo de ella.

Ejemplo (datos ficticios): se comparan las calificaciones "de concepto" asignadas por docentes de escuelas primarias de dos grupos de alumnos. Dichas calificaciones, presentan categorías: 1. Excelente, 2. Muy bueno, 3. Bueno, 4. Satisfactorio, 5. No satisfactorio, por lo que son de nivel ordinal y no es posible realizar una prueba de diferencia de medias, en su reemplazo recurrimos a la prueba de la mediana. Se seleccionan 40 alumnos de cada docente y se relevan las notas de concepto de cada uno. Calculamos la mediana de los 80 alumnos juntos y obtenemos 3. A continuación contamos cuántos alumnos de la primera docente están por encima y por debajo de 3 y lo mismo para la segunda docente. La distribución queda del siguiente modo:

Ubicación respecto de la mediana combinada	Grupo		Total
	1	2	
Por encima	28	8	36
Por debajo	8	24	32
Total	36	32	68

Aunque originalmente se relevaron 40 alumnos de cada docente, quedaron 36 de la primera y 32 de la segunda, porque cuatro casos de un grupo y ocho del otro coincidieron con la M_{dn_c} y fueron descartados, con lo que el total se redujo a 68 observaciones.

La sola inspección de la tabla sugiere que debe descartarse la igualdad de las medianas de los grupos, ya que hay concentración de casos en las celdas de la diagonal, que es una indicación de la relación que hay entre filas y columnas. El grupo 1 está mayoritariamente por encima de la M_{dn_c} y el grupo 2 por debajo. En efecto, el puntaje $\chi^2_{obs} = 18{,}94$, con 1 grado de libertad, tiene una probabilidad asociada (*valor p*) de 0,0000135, que quiere decir que se rechaza la hipótesis de igualdad de medianas.

Cuando esta operación se solicita a InfoStat®, la salida no presenta la tabla de clasificación de casos según su ubicación respecto de la M_{dn_c}, solo nos ofrece lo siguiente:

Prueba de la mediana para dos muestras

Clasific	Variable	n(1)	n(2)	Med	P(X1>Med)	P(X2>Med)	p(2 colas)
docente	concepto	40	40	3,00	0,70	0,20	<0,0001

Que indica:

Clasific: el nombre de la variable que separa los grupos, en este caso, docente.

Variable: la característica que se compara.

n(1) y n(2): la cantidad de casos en cada uno de los grupos.

Med: la mediana combinada

P(X1>Med) y *P(X2>Med)*: son las proporciones de casos de cada grupo que superan a la M_{dn_c}, en este caso el 70% del primer grupo y el 20% del segundo.

P(2 colas): el valor p para prueba bilateral, obtenido a través de la prueba χ^2. Esta probabilidad no se presenta de manera exacta sino, en este caso, solo señalando

que es menor que una diezmilésima, suficiente evidencia para rechazar H_0 y concluir que la diferencia de las medianas es significativa.

Coeficiente r_s de Spearman

El coeficiente *r de Pearson* solo puede interpretarse si proviene de variables medidas a nivel intervalar o proporcional, es decir, métricas. Cuando trabajamos con variables ordinales, disponemos de otra medida de la asociación, el coeficiente de correlación por rangos *r_s de Spearman*, cuyos valores se interpretan como los de *r de Pearson*. Por trabajar con un nivel de medición no métrico, la prueba sobre este coeficiente es no paramétrica.

La prueba de hipótesis que permite generalizar su valor a una población de referencia, casi no difiere de la de *r*. Llamaremos ρ_s al coeficiente de Spearman paramétrico y r_s al muestral. El error estándar de este estimador tiene la misma forma que el de Pearson:

$$\sigma_{r_s} = \sqrt{\frac{1 - r_s^2}{n - 2}}$$

Y cuando la muestra tiene al menos 10 observaciones, se distribuye con una distribución t con n-2 grados de libertad[115]. En consecuencia, el estadístico de prueba será:

$$t = \frac{r_s - \rho_s}{\sqrt{\frac{1-r_s^2}{n-2}}}$$

Ejemplo (datos ficticios): se interroga a 20 alumnos de primer año de una carrera universitaria sobre las razones de su elección de carrera y a partir de las respuestas se construye un índice que clasifica el interés en 1. Muy fuerte, 2. Fuerte, 3. Débil, 4. Muy débil. Los resultados de este índice se ponen en correspondencia con el orden de mérito alcanzado en el ingreso a la carrera universitaria (1. Primero, 2. Segundo, etc.). En el análisis de la relación entre estas dos variables ordinales obtenemos un coeficiente de correlación de Spearman de 0,82, que indica, en la muestra, una relación positiva e intensa entre el interés y el orden de mérito en el ingreso. Preguntamos si este resultado, obtenido sobre 20 casos, nos autoriza a afirmar que existe una asociación entre las dos variables más allá de la muestra observada. Formularemos las hipótesis correspondientes a una prueba bilateral, porque queremos probar si el coeficiente es significativamente diferente de cero.

$$H_0: \rho_s = 0$$
$$H_1: \rho_s \neq 0$$

Fijamos el nivel de significación en el 5% y hallamos en una distribución t con 18 grados de libertad ($n - 2 = 20 - 2 = 18$) los valores críticos correspondientes son ±2,10. El estadístico de prueba es:

---

[115]Kendall (1948) citado por Siegel (1956)

$$t = \frac{r_s - \rho_s}{\sqrt{\frac{1-r_s^2}{n-2}}} = \frac{0,82}{\sqrt{\frac{1-0,82^2}{20-2}}} = \frac{0,82}{0,135} = 6,08$$

Este valor se ubica en la región de rechazo de H_0, con lo que la decisión es la de rechazar H_0 y concluir que "hay evidencia para creer que la correlación a nivel poblacional no es nula".

Cuando se pide a InfoStat® (en forma de lista, formato compacto), la salida es:

Coeficientes de correlación
Correlación de Spearman

Variable(1)	Variable(2)	n	Spearman	p-valor
Interés	orden de mérito	20	0,81842	0,00036

El pequeño valor p es señal de lo escasamente probable que resulta que este resultado provenga del azar, es decir, es evidencia para creer que en la población, la asociación efectivamente existe.

Alternativas no paramétricas a las pruebas t

Muestras independientes

La prueba U de Mann-Whitney es la versión no paramétrica de la prueba t de Student, es decir, sirve para comparar la tendencia central entre dos muestras independientes. Se usa cuando no se cumplen los supuestos de la prueba t y, sobre todo cuando las variables son de nivel ordinal. La hipótesis nula es que las muestras provienen de poblaciones iguales.
Si se dispone de dos muestras de tamaños n_1 y n_2, para realizar la prueba se ordenan las observaciones de las dos muestras juntas, de menor a mayor, y se les asignan rangos desde *1* hasta $n_1 + n_2$. Si la tendencia central de ambas poblaciones es la misma los rangos deberían distribuirse aleatoriamente entre las dos muestras y el rango medio de las observaciones de una muestra debería ser casi el mismo que el de la otra. El estadístico de prueba U de Mann-Whitney se construye a partir de la suma de rangos de una de las muestras, R_i, elegida arbitrariamente.
Si se trata de dos grupos, llamados experimental y control cuyos sujetos son evaluados antes y después de una intervención, la primera parte del video *Mann-Whitney Wilcoxon* muestra la comparación entre los puntajes de los dos grupos antes del experimento y después de él. La salida tiene la forma:

Prueba de Wilcoxon para muestras independientes

Clasific	Variable	Grupo1	Grupo2	n(1)	n(2)	Media(1)	Media(2)	DE(1)	DE(2)	W	p(2colas)
grupos	antes	control	experimental	32	36	1,63	3,64	1,68	1,69	769,50	<0,0001
grupos	después	control	experimental	32	36	1,63	3,25	1,62	1,63	813,00	0,0003

El resultado muestra que los grupos difieren significativamente, tanto antes del experimento ($p < 0.0001$) como después de él ($p = 0.0003$).
Los nombres de los comandos de Infostat® son ambiguos, para solicitar la prueba hay que elegir "Wilcoxon (Mann-Whitney U)", pero en la salida, la llama "Prueba Wilcoxon para muestras independientes", no hay acuerdo universal sobre el nombre de esta prueba.

Muestras relacionadas

La prueba de los rangos con signo de Wilcoxon es una prueba no paramétrica para comparar el rango medio de dos muestras relacionadas. Es una alternativa a la prueba t de Student para muestras relacionadas, que se usa en los casos en que no se sostiene la normalidad de la distribución y, especialmente cuando las variables son de nivel ordinal.

La hipótesis nula dice que las muestras provienen de poblaciones con la misma distribución de probabilidad. La prueba tiene en cuenta las diferencias entre las puntuaciones de los elementos de cada par asociado, y considera tanto el signo, como la magnitud de la diferencia.
Con los mismos datos del ejemplo anterior, ahora interesa comparar los puntajes antes y después del experimento, para cada uno de los grupos. El "antes" y "después" son dos medidas hechas sobe el mismo sujeto, por lo que se trata como mediciones apareadas y, dado el bajo nivel de medición de los puntajes, debe usase esta prueba no paramétrica. La segunda parte del video *Mann-Whitney Wilcoxon*, muestra los comandos. El resultado de la prueba, particionada para cada uno de los dos grupos es:
Prueba de Wilcoxon (muestras apareadas)

P-valor estimado por muestreo de todas las permutaciones posibles (n = 5000)

grupos	Obs(1)	Obs(2)	N	Suma(R+)	E(R+)	Var(R+)	media(dif)	Z	p(2 colas)
control	antes	después	32	227,50	264,00	2781,75	0,00	-0,69	0,6912
experimental	antes	después	36	432,00	333,00	3863,25	0,39	1,59	0,0542

Se observa que los cambios del grupo control no son significativos ($p = 0.6912$) mientras que los del grupo experimental lo son a un nivel de significación del 10%, no del 5% ($p = 0.0543$). Como este segundo resultado está en el limite de la significación al 5%, debe informarse la magnitud del cambio (0.39) a fin de decidir si se trata de una variación apreciable desde el punto de vista práctico, más allá de su significación estadistica.
Nuevamente, debe tenerse cuidado en el modo en que Infostat® denomina la prueba. En el comando se llama "Wilcoxon", en la salida dice "Prueba de Wilcoxon (muestras apareadas)".