FADENA

LICENCIATURA EN CIBERDEFENSA

PROBABILIDAD Y ESTADÍSTICA

CÁTEDRA I (COD.13)

AÑO: 2026

CARGA HORARIA: 64 HS

Prueba de hipótesis de chi cuadrado de independencia.

Prueba de hipótesis de chi cuadrado de independencia

Consigna del ejercicio

Un equipo de ciberdefensa implementó un módulo de capacitación orientado al reconocimiento y reporte de correos sospechosos. Para evaluar si la finalización del módulo se asocia con la conducta de los usuarios, se realizó una simulación controlada de phishing. En la base de datos se registró, para cada usuario, si había completado o no la capacitación y cuál fue su respuesta ante el correo simulado.

A partir de la base de datos Base 4, realice una prueba de hipótesis de chi cuadrado de independencia para decidir si existe asociación entre la finalización de la capacitación y la respuesta ante la simulación de phishing. Utilice un nivel de significación de $\alpha = .05$. Si se encuentra asociación, informe una medida adecuada de la magnitud de la asociación e interprete el resultado en términos del problema planteado.

Descripción de la base de datos

La base de datos contiene 180 unidades de análisis. Cada una corresponde a un usuario evaluado en la simulación.

Variable	Tipo de medida	Descripción	Valores
ID_Usuario	Nominal identificatoria	Identificador anónimo del usuario.	1 a 180
Capacitacion_Phishing	Nominal dicotómica	Indica si el usuario completó el módulo de capacitación en phishing.	Completo; No completo
Respuesta_Simulacion	Nominal politómica	Conducta registrada ante el correo simulado de phishing.	Reporte correcto; Ignoro el correo; Interacción de riesgo

Resolución del ejercicio

Delimitación de variables y supuestos para la prueba

Variables

Sea X la variable Capacitación en Phishing, que registra si los usuarios completaron o no completaron una capacitación institucional sobre identificación y reporte de correos de phishing.

Sea Y la variable Respuesta de Simulación, que registra la conducta observada ante un correo simulado de phishing. Esta variable presenta tres categorías: reporte correcto, ignoró el correo e interacción de riesgo.

La prueba de chi cuadrado de independencia se utiliza para evaluar si dos variables categóricas se comportan de manera independiente o si existe asociación entre ellas. En este ejercicio, el interés es analizar si la distribución de respuestas ante la simulación de phishing es la misma entre quienes completaron la capacitación y quienes no la completaron.

Supuestos principales

Las observaciones deben ser independientes, cada usuario debe aportar una única observación, las categorías deben ser mutuamente excluyentes y las frecuencias esperadas deben ser suficientemente grandes. En este caso, la frecuencia esperada mínima es 14.5, por lo que se cumple el criterio habitual de contar con frecuencias esperadas mayores a 5.

1. Plantear las hipótesis estadísticas por contrastar

El objetivo es evaluar si existe asociación entre la finalización de la capacitación y la respuesta ante la simulación. Por lo tanto, se plantea un contraste de independencia.

H_o: la variable Capacitación en Phishing y la variable Respuesta en Simulación son independientes en la población de usuarios de referencia.

H_1: la variable Capacitación en Phishing y la variable Respuesta en Simulación no son independientes en la población de usuarios de referencia.

2. Indicar el estadístico de prueba adecuado y su distribución bajo H_o

Como se desea analizar la asociación entre dos variables nominales, corresponde utilizar la prueba de chi cuadrado de independencia. El estadístico de prueba se expresa como:

$$\chi^2 = \Sigma \left[(O_{ij} - E_{ij})^2 / E_{ij}\right]$$

Donde O_{ij} representa la frecuencia observada en la celda i,j y E_{ij} representa la frecuencia esperada bajo la hipótesis nula de independencia.

La frecuencia esperada de cada celda se calcula como:

$$E_{ij} = (\text{Total fila i} \times \text{Total columna j}) / n$$

Bajo H_o, el estadístico χ^2 se distribuye aproximadamente como una distribución chi cuadrado con grados de libertad:

$$gl = (F - 1) \times (C - 1)$$

En este ejercicio hay 2 filas y 3 columnas. Por lo tanto:

$$gl = (2 - 1) \times (3 - 1) = 2$$

3. Elegir α y establecer una regla de decisión basada en el valor p

Se trabaja con un nivel de significación de $\alpha = .05$.

Condición	Decisión
$p < .05$	Se rechaza H_o
$p \geq .05$	No se rechaza H_o

En la prueba de chi cuadrado, valores grandes del estadístico indican mayor discrepancia entre las frecuencias observadas y las frecuencias esperadas bajo independencia. Por este motivo, el valor p se interpreta como una probabilidad acumulada en la cola derecha de la distribución chi cuadrado.

4. Presentar la tabla de contingencia observada

Capacitación en Phishing	Reporte correcto	Ignoro el correo	Interacción de riesgo	Total
Completo	62	20	8	90
No completo	38	31	21	90
Total	100	51	29	180

La tabla muestra que, entre quienes completaron la capacitación, el 68.9% reportó correctamente el correo simulado. En cambio, entre quienes no completaron la capacitación, el 42.2% reportó correctamente el correo. Además, la interacción de riesgo fue menor en el grupo con capacitación completa, con 8.9%, que en el grupo sin capacitación completa, con 23.3%.

5. Calcular las frecuencias esperadas bajo H_o

Si las variables fueran independientes, las frecuencias esperadas se obtendrían a partir de los totales marginales.

Capacitación en Phishing	Reporte correcto	Ignoro el correo	Interacción de riesgo
Completo	50.0	25.5	14.5
No completo	50.0	25.5	14.5

Por ejemplo, para la celda Completo y Reporte correcto, la frecuencia esperada se calcula como: $E = (90 \times 100) / 180 = 50.0$.

6. Calcular el valor observado del estadístico de prueba

En esta demostración se muestra el cálculo del estadístico. Luego, el mismo resultado puede obtenerse directamente en jamovi.

Celda	O	E	$(O - E)^2 / E$
Completo, Reporte correcto	62	50.0	2.880
Completo, Ignoro	20	25.5	1.186
Completo, Riesgo	8	14.5	2.914
No completo, Reporte correcto	38	50.0	2.880
No completo, Ignoro	31	25.5	1.186
No completo, Riesgo	21	14.5	2.914
Total			13.960

Por lo tanto, el valor observado del estadístico de prueba es $\chi^2 = 13.960$, con gl = 2.

7. Calcular el valor p asociado al estadístico de prueba

El valor p asociado a $\chi^2 = 14$ con 2 grados de libertad es $p < .001$. Este valor representa la probabilidad de obtener una discrepancia entre frecuencias observadas y esperadas igual o mayor que la observada, suponiendo que las variables fueran independientes en la población.

8. Tomar la decisión sobre H_o

Como p es menor que $\alpha = .05$, la decisión estadística es rechazar H_o.

9. Brindar una conclusión en términos del problema planteado

A partir de los resultados obtenidos, se cuenta con evidencia estadísticamente significativa para sostener que existe asociación entre la finalización del módulo de capacitación en phishing y la respuesta ante la simulación. En términos del problema, los datos sugieren que quienes completaron la capacitación presentaron una mayor proporción de reportes correctos y una menor proporción de interacciones de riesgo. No obstante, el resultado permite hablar de asociación estadística, no de efecto causal, ya que el diseño del ejercicio no permite aislar otras posibles explicaciones.

Informar una medida adecuada de asociación

Como la tabla tiene dimensión 2 × 3 y las variables son nominales, una medida adecuada de asociación es V de Cramer. Esta medida permite cuantificar la magnitud de la asociación en tablas de contingencia con más de dos columnas o más de dos filas.

$$V = \sqrt{[\chi^2 / (n \times (k - 1))]}$$

Donde n es el tamaño muestral y k es el menor número entre la cantidad de filas y columnas.

En este caso, n = 180 y k = 2. Por lo tanto:

$$V = \sqrt{[13.960 / (180 \times 1)]} = .278$$

El valor obtenido fue V de Cramer = .278. Esto indica una asociación de magnitud baja a moderada entre la finalización de la capacitación y la respuesta ante la simulación.

Ejemplo de reporte de resultados:

Se observó una asociación estadísticamente significativa entre la finalización de la capacitación en phishing y la respuesta ante la simulación, $\chi^2(2, N = 180) = 13.960$, $p < .001$, V de Cramer = .278. Los usuarios que completaron la capacitación presentaron mayor proporción de reportes correctos y menor proporción de interacciones de riesgo.