Eduardo Bologna

Métodos Estadísticos de Investigación



00026157

Editorial Brujas

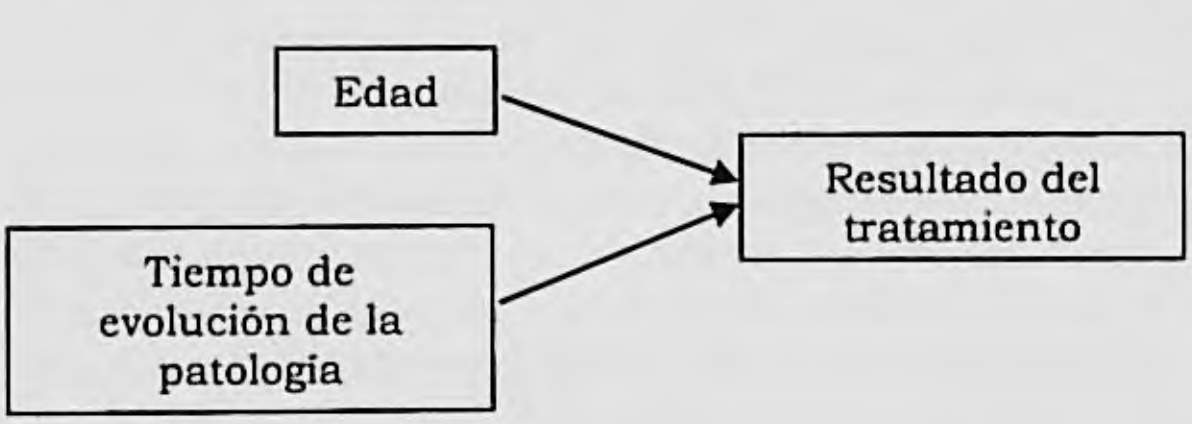
Capítulo 4 Relación entre variables: los fundamentos

Hasta este punto se han descripto variables observadas o medidas a través de instrumentos de a una por vez. Ahora, el objetivo se acerca más al modo de hacer investigación en Ciencias Sociales. Es así porque en este capítulo y el siguiente se trata con *relaciones* entre variables: no ya describir cada variable por separado sino reunirlas en relaciones de dos como mínimo, pero que puede incluir a una gran cantidad. Buscar relaciones entre variables es comenzar a transitar el camino de la explicación de los fenómenos que observamos.

Si nos preguntamos, por ejemplo: ¿por qué un tratamiento es exitoso con algunos pacientes diagnosticados de depresión y con otros no? Formularemos hipótesis sobre la respuesta: quizás la edad influya, puede suceder que con pacientes más jóvenes se obtenga mejor resultado que con los de más edad. Razonando así, introducimos otra variable, la *edad*, que aportaría a explicar la razón de los diferentes resultados del tratamiento. La hipótesis está formulada como una relación entre dos variables: se trata de indagar por el efecto que la *edad* (primera variable) tendría sobre el *resultado del tratamiento* (segunda variable). La edad podría ser un **factor explicativo** del resultado del tratamiento.

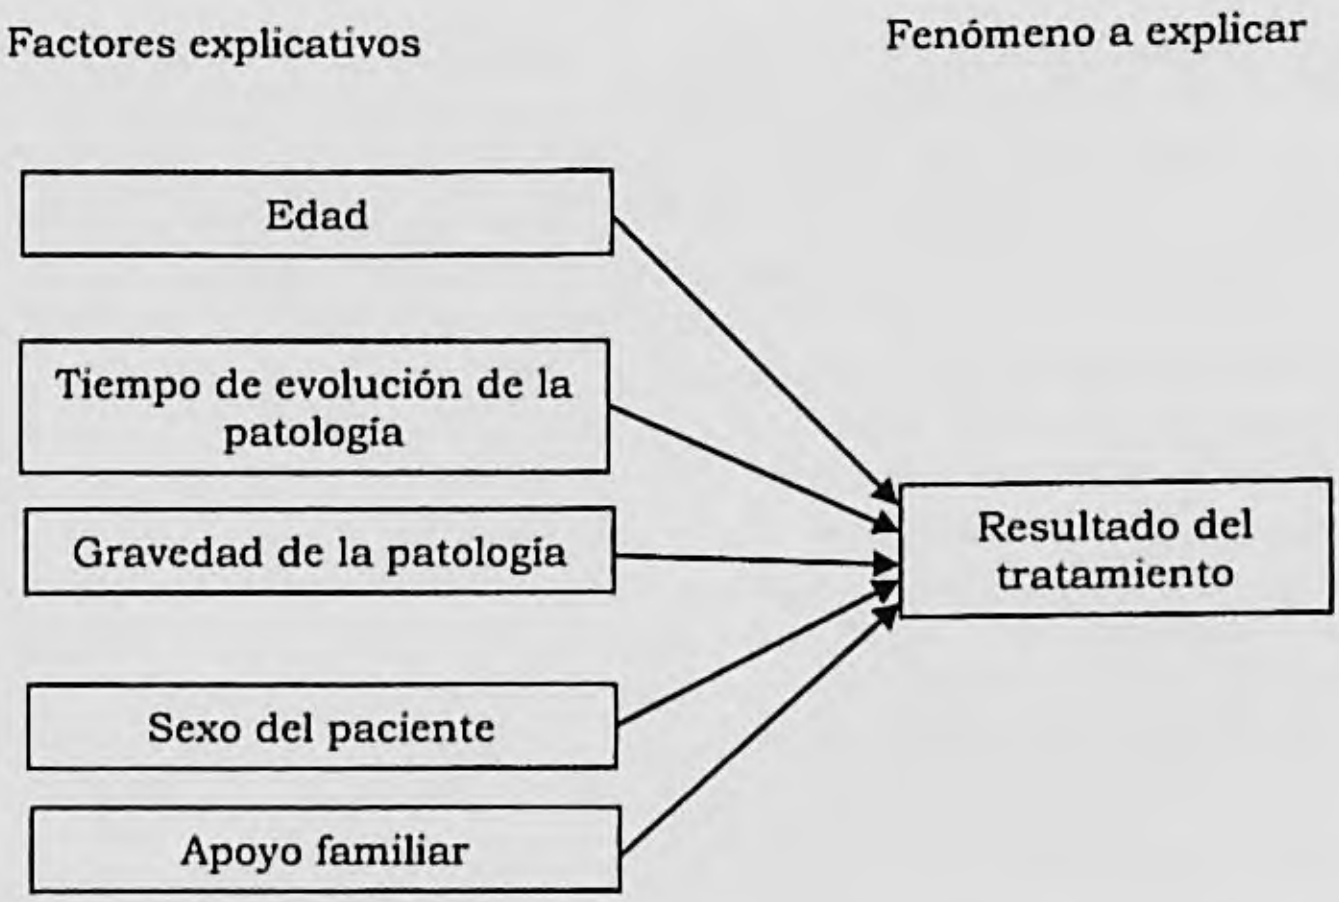
Dentro del mismo ejemplo, también podemos sospechar que quienes han sido diagnosticados más precozmente pueden aprovechar el tratamiento mejor que quienes traen una dolencia de larga data. Aquí la variable que viene a explicar el resultado es el *tiempo de evolución de la enfermedad*. Ahora el *tiempo de evolución de la enfermedad* podría ser otro factor explicativo del *resultado del tratamiento*. Notemos el acento en "podría ser": estas relaciones son hipotéticas, nuestro objetivo será analizar la evidencia que haya a su favor o en su contra. Esquemáticamente la relación se plantea de la siguiente manera:

Relación hipotética entre dos factores explicativos y el resultado de un tratamiento para la depresión



Estas dos variables son parte de la hipótesis para explicar las diferencias en los resultados que ofrece un determinado tratamiento sobre pacientes diagnosticados de depresión. Puede haber más variables: la gravedad de la depresión, el sexo del paciente (quizás el resultado no sea igual en mujeres que en hombres), el apoyo familiar que el paciente reciba, etc. Tendríamos entonces un esquema explicativo más completo:

Esquema simplificado[27] de la relación hipotética entre cinco factores explicativos y el resultado de un tratamiento para la depresión



Jamás agotaremos el conjunto de todos los factores explicativos de un fenómeno, porque en última instancia cada caso es único. Los fenómenos que observamos son multicausados, por lo que no puede decirse que una variable *X* sea la causa de otra variable *Y*[28]. Pero lo que sí puede hacerse es analizar la importancia relativa de los diferentes factores explicativos; saber en qué grado aporta cada uno a las diferencias que se observan.

Ilustremos esto con otro ejemplo: el resultado escolar que alcanzan los alumnos. No hay dudas que cada niño tiene una trayectoria única, que depende de su historia, de su contexto familiar, etc. Supongamos que analizamos el resultado escolar obtenido en primer grado y observamos que algunos cursos tienen docentes tradicionales, que usan los mismos métodos estandarizados de enseñanza desde hace muchos años. Otros cursos tienen docentes que invitan a los alumnos participar, que innovan en los métodos de enseñanza. Luego comparamos el rendimiento de los alumnos en los dos cursos y vemos que los alumnos del primer grupo aprenden más lentamente que los del segundo y que además, los primeros dicen que se aburren yendo a la escuela y los otros no. Esto no sucede con todos los niños: habrá en el primer grupo algunos que aprenden más rápido y que se divierten, así como algunos del segundo grupo tardarán más en aprender. Pero, en general, en promedio, podríamos hallar mejores resultados entre los alumnos que tienen docentes innovadores. Esto nos lleva a indicar que

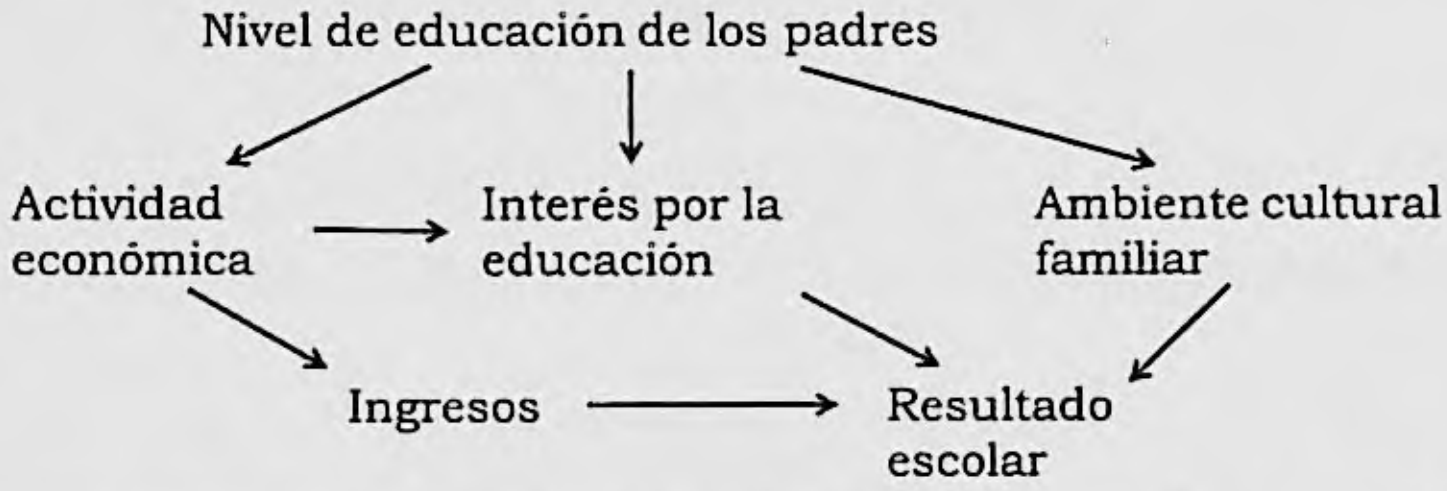
---

[27] El esquema está simplificado porque, solo a los fines de la presentación, suponemos que cada una de las variables de la izquierda influye individualmente sobre el resultado. Sin embargo, es de esperar que la edad esté relacionada con el tiempo de evolución de la patología y éste con la gravedad de los síntomas, por lo que el esquema real tendría más flechas vinculando las variables.

[28] Salvo en el caso de diseños experimentales que permitan tener control sobre el conjunto de variables que participan en el resultado que se observa.

hay evidencia para creer que los docentes innovadores obtienen con sus alumnos mejores resultados que los docentes tradicionales. Pero esto no es para todos los alumnos, sino para la mayoria de ellos. De eso se trata la búsqueda de factores explicativos: en este ejemplo diremos que, de los múltiples factores que explican por qué a algunos chicos les va bien en la escuela y a otros les va mal, el tipo de docente es parte de la explicación.

Las hipótesis son respuestas tentativas a la pregunta formulada como problema de la investigación. Como tales, consisten en el planteamiento de una relación entre, al menos, dos variables. Recordemos que las hipótesis constituyen afirmaciones que se derivan del modelo de análisis que el investigador ha propuesto para explicar una situación dada. Las hipótesis son consecuencias deductivas de la teoria, cuya verificación no es suficiente para validar la teoria, aunque si para "aportar evidencia en su favor". Además, las hipótesis como tales, rara vez pueden ponerse a prueba de manera directa, son sus consecuencias observables las que permiten la verificación empirica. En cualquier modelo explicativo hipotético participa un número de variables mayor a dos, sin embargo de las hipótesis pueden deducirse relaciones más simples, inicialmente solo de dos variables. Un último ejemplo de un esquema que muestra la relación entre varias variables que aportan a explicar las diferencias en el rendimiento escolar, desde la perspectiva de las condiciones familiares.



El esquema muestra una hipótesis según la cual, los padres con más educación tienden a tener ocupaciones de mayor jerarquia, lo que implica de mejores ingresos y esto puede ayudar a crear condiciones adecuadas para el estudio, como disponer de un lugar para estudiar o tener acceso a otras fuentes de aprendizaje (visitas a museos, viajes, etc.). También los padres con mayor educación probablemente valoren más el estudio y asi ofrezca mayor apoyo a sus hijos en la escuela. Por último, seria de esperar que los padres con más educación generen un ambiente con hábitos de lectura y discusiones que transmitan a sus hijos el valor de la educación.

Esto es más cercano a la realidad, en la que las variables se relacionan de manera más compleja que la simple $x \rightarrow y$. Sin embargo la base para analizar estas relaciones complejas, son las relaciones bivariadas, es decir, entre solo dos variables.

Establecer de manera hipotética una relación entre dos variables equivale a afirmar que, por alguna razón, los cambios de una de ellas van acompañados de cambios en la otra. Pero esto puede suceder de maneras muy diferentes, por ejemplo, el trueno sucede al relámpago, los síntomas de tuberculosis coinciden con la detección del bacilo de Koch, los movimientos sociales se incrementan en

tiempos de deterioro económico, las personas abusadas en la infancia son más propensas a la depresión. En algunos de estos ejemplos puede identificarse una secuencia cronológica, señalando cuál de los dos eventos sucede primero, en otros esta distinción no es segura, a veces una variable es la que incide sobre la otra, otras veces es solo una contribución, por último, hay casos en que su ocurrencia conjunta o sucesiva se debe a otras razones. Evitaremos, por ahora hablar de relaciones de causalidad, llegaremos a este concepto hacia el final del capítulo y veremos que debe tratarse con suma cautela.

Con el objetivo de ordenar la gran variedad de formas que pueden asumir las relaciones entre variables, estableceremos algunos criterios de clasificación que, sin ser exhaustivos, nos ayudarán a verlas desde diferentes ópticas.

El modo más usado para observar relaciones entre dos variables consiste en presentar el comportamiento conjunto de ellas a través de tablas o gráficos. Las primeras son más adecuadas para variables con pocas categorías (usualmente nominales), mientras que los gráficos son más pertinentes para mostrar relaciones entre variables métricas. Veamos un ejemplo para ilustrar el primer modo de representación: creemos que los niños que han crecido en diferentes tipos de hogar (solo con su madre, solo con su padre, con ambos o con otros parientes) tienen diferentes formas de relacionarse con sus compañeros (con relaciones de liderazgo, sumisión o rebeldía). En el lenguaje de las relaciones entre variables, estaríamos proponiendo que existe **asociación** entre el tipo de hogar en que el niño crece (con las cuatro categorías mencionadas) y el tipo de relación que mantiene con sus pares. La presentación conjunta de esas dos variables es:

Tipo de hogar ⟶ Relación con los pares

Disposición de las variables y sus categorías para analizar la relación entre dos variables

	Relación con los pares		
Tipo de hogar	Sumisión	Rebeldía	Liderazgo
Monoparental materno			
Monoparental paterno			
Nuclear			
Extendido			

Tablas de contingencia

Cuando se distribuyen los datos en las celdas, se obtiene una **tabla bivariada** (porque contiene dos variables), que también se llama **tabla de contingencia** o **tabla de distribución conjunta** o también **tabla de doble entrada**. Las celdas del interior de la tabla llevarán, cuando los datos sean recolectados, la cantidad de niños que se encuentren en cada coincidencia de categorías. Si nuestra hipótesis afirmara que los niños provenientes de hogares nucleares son más propensos a ser líderes, esperaríamos una concentración relativa de casos en la celda correspondiente a "hogar nuclear" – "liderazgo", hipótesis que luego deberemos confrontar con la información recogida.

Una **tabla bivariada** o **tabla de contingencia** o **tabla de distribución conjunta** es un arreglo con tantas filas (horizontales) como categorías tenga una de las variables y tantas columnas (verticales) como categorías tenga la otra variable.

Por oposición, las tablas que se mostraron en los capítulos anteriores, así como las medidas descriptivas que se calcularon, se denominan **univariadas**.
A este arreglo se agrega una fila y una columna adicionales que corresponden a los totales de cada categoría. A los fines de usar un lenguaje común, en la tabla llamaremos filas a la líneas horizontales y columnas a las verticales e identificaremos la **dimensión** de la tabla indicando cuántas filas tiene y cuántas columnas, en este orden. En el ejemplo anterior, la dimensión de la tabla es cuatro por tres, porque tiene cuatro filas y tres columnas correspondientes a la cantidad de categorías de cada una de las dos variables.

La **dimensión** de la tabla se indica como *f X c*, donde *f* es el número de categorías de la variable que está en las filas y *c* es el número de categorías de la variable que está en las columnas.

La celda en la que, bajo la hipótesis indicada, esperaríamos una mayor concentración *relativa* de casos corresponde entonces a la tercera fila y tercera columna. Con *f* indicaremos la frecuencia y con el subíndice la celda a que corresponde, así, f_{ij} será la cantidad de casos en la celda que corresponde a la fila *i* y a la columna *j* simultáneamente. La frecuencia de la celda de "nuclear-liderazgo" será indicada entonces como f_{33}. Para aclarar la presentación de la tabla, se agregan una fila y una columna en la que se indica el total de casos de cada una de ellas, que se llaman **marginales** de fila y de columna. La notación será:
$f_{i.}$ ("efe i-punto") para los marginales de fila
f_{j} ("efe punto-jota") para los de columnas
$f_{..}$ ("efe punto-punto") para el total general.

Con esa notación, $f_{3.}$ indica el total de niños que crecieron en hogares nucleares y $f_{.2}$ el total de quienes se vinculan con rebeldía con sus compañeros, la tabla anterior resulta:

Disposición de las frecuencias para el análisis de la relación entre dos variables.

	Relación con los pares			
Tipo de hogar	Sumisión	Rebeldía	Liderazgo	Total
Monoparental materno	f_{11}	f_{12}	f_{13}	$f_{1.}$
Monoparental paterno	f_{21}	f_{22}	f_{23}	$f_{2.}$
Nuclear	f_{31}	f_{32}	f_{33}	$f_{3.}$
Extendido	f_{41}	f_{42}	f_{43}	$f_{4.}$
Total	$f_{.1}$	$f_{.2}$	$f_{.3}$	$f_{..}$

Si hemos recogido datos sobre estas características de los niños, la tabla podría quedar así:

Tabla 1: Alumnos de escuelas primarias por relación con sus pares según tipo de hogar.

Tipo de hogar	Relación con los pares			
	Sumisión	Rebeldía	Liderazgo	Total
Monoparental materno	20	30	50	100
Monoparental paterno	10	40	15	65
Nuclear	5	10	25	40
Extendido	30	20	10	60
Total	65	100	100	265

Esta tabla dice que se han observado un total de 265 niños y se ha registrado el tipo de hogar en que crecieron y la forma en que se relacionan con sus compañeros. De los 265:
100 provienen de hogares monoparentales maternos: $f_{1.}$,
65 de monoparentales paternos: $f_{2.}$,
40 de nucleares: $f_{3.}$ y
60 de hogares extendidos: $f_{4.}$.
Los mismos niños se relacionan con sus compañeros:
65 de ellos con sumisión: $f_{.1}$,
100 con rebeldia: $f_{.2}$ y
100 con liderazgo: $f_{.3}$.
Todas estas son lecturas de las frecuencias marginales. Marginales de fila las del tipo de hogar y marginales de columna las de la forma de la relación.

Se llama **frecuencias marginales de fila** a las frecuencias absolutas de las categorías de la variable que se ubica en las filas.

Las **frecuencias marginales de columna** son las frecuencias absolutas de las categorías de la variable ubicada en las columnas.

Las frecuencias de las celdas, que se llaman **frecuencias conjuntas** se leen: 20 de los niños observados crecieron en hogares monoparentales maternos y se relacionan con sus compañeros con sumisión (f_{11}), 30 niños se relacionan con liderazgo y provienen de hogares monoparentales maternos (f_{12}), 10 se relacionan con rebeldia y provienen de hogares nucleares (f_{32}) y del mismo modo el resto de las frecuencias conjuntas. Ellas indican la cantidad de casos que reúnen al mismo tiempo las dos condiciones que se indican en la fila y en la columna.

Las **frecuencias conjuntas** indican la cantidad de casos que corresponden simultáneamente a una determinada categoría de la variable de las filas y una categoría de la variable de columnas.

Frecuencias relativas

Del mismo modo en que trabajamos con las tablas de distribución de frecuencia de una sola variable, podemos transformar todas estas frecuencias absolutas en relativas, por el simple procedimiento de dividirlas en el total general. Resulta asi:

Alumnos de escuelas primarias por relación con sus pares según tipo de hogar, frecuencias relativas

Tipo de hogar	Relación con los pares			
	Sumisión	Rebeldía	Liderazgo	Total
Monoparental materno	0,08	0,11	0,19	**0,38**
Monoparental paterno	0,04	**0,15**	0,06	0,25
Nuclear	0,02	0,04	0,09	0,15
Extendido	0,11	0,08	0,04	0,23
Total	**0,25**	0,38	0,38	1,00

Leemos así las frecuencias que están destacadas en la tabla:
-El 15% del total de alumnos observados proviene de hogares monoparentales paternos y se relacionan con sus pares con rebeldía: Por ser una frecuencia relativa usamos la "prima" en la notación, entonces es f'_{22}
-Un 25% del total se relaciona con sumisión, sin considerar el tipo de hogar del que provengan. Es f'_1
-Un 38% proviene de hogares monoparentales maternos, sin tener en cuenta de qué manera se relacionan con sus pares. Es f'_1
La primera de estas frecuencias relativas es conjunta, las otras dos marginales. Verifique que queda bien clara la notación usada en cada caso y que pueden leerse las demás frecuencias relativas de la tabla.

Una clasificación en referencia al tiempo

Como señalamos al principio hay relaciones en las que resulta posible identificar a una de las variables como previa a la presencia de la otra, o a un evento como anterior a la ocurrencia del otro. Así, el trueno siempre sucede luego del relámpago, si tenemos la oportunidad de oírlo. Aun cuando no podamos establecer la causa de la relación entre los dos eventos, no tenemos dudas en señalar a uno como anterior al otro. Los malos tratos sufridos durante la niñez son anteriores (en la historia del sujeto) a la eventual manifestación adulta de conductas antisociales. De modo que si nos interrogáramos sobre la existencia de una relación entre estos dos eventos, ubicaríamos a los malos tratos como variable anterior, aunque solo fuera porque su manifestación es temporalmente previa. Así sucede también al buscar una relación entre los resultados de un examen de ingreso a la universidad y el rendimiento posterior de los alumnos.
Es importante indicar a esta altura que no estamos suponiendo que la relación exista, nos encontramos en el momento del planteo de las hipótesis; bien puede suceder que, luego del análisis de los datos, encontremos que la relación no es válida, que no se sostiene, en fin, que las observaciones no avalan una asociación entre malos tratos infantiles y conducta antisocial, o que el resultado de examen de ingreso no se relaciona con el desempeño posterior, pero esto no invalida que, en la relación que proponíamos, una variable sea tratada como anterior a la otra.
Así como en ciertos casos es posible anticipar el orden (sea lógico o cronológico) en que se presentan las variables que constituyen una relación, hay algunas situaciones en que esto es muy difícil, o imposible y otras en las que no tiene

ningún interés. Una relación que ilustra el primer caso es la relación entre el comportamiento infantil y el trato que recibe de sus padres. Puede interpretarse a los niños revoltosos como respondiendo a la escasa atención que le brindan sus padres, o leer la forma en que los padres tratan a sus hijos como consecuencia de la mala conducta de estos últimos. En este ejemplo se ve que el orden en que se establezcan las variables que se busca relacionar está influido por la posición teórica que el investigador asuma.
Otros casos en los que no tiene interés mencionar qué variable es anterior y cual posterior son típicos de los estudios descriptivos, en los que interesa mostrar cómo se distribuyen ciertas variables, y no qué relación puede haber entre ellas. Así, una distribución de la población por sexo y edad como la de la tabla siguiente:

Tabla 3: Departamento Capital, Provincia de Córdoba. Población por sexo según grupos de edad. Año 2001

Grupos de edad	Sexo		Total
	Varones	Mujeres	
0-4	56.913	55.053	111.966
5-9	57.471	56.073	113.544
10-14	55.564	54.394	109.958
15-19	55.581	55.834	111.415
20-24	67.519	69.727	137.246
25-29	53.736	54.667	108.403
30-34	42.209	43.852	86.061
35-39	36.910	39.894	76.804
40-44	34.681	38.243	72.924
45-49	31.879	36.634	68.513
50-54	30.780	36.187	66.967
55-59	24.485	29.448	53.933
60-64	19.914	25.038	44.952
65-69	16.485	22.387	38.872
70-74	13.858	20.831	34.689
75-79	8.816	15.318	24.134
80-84	4.423	9.471	13.894
85-89	1.827	5.355	7.182
90-94	600	1.906	2.506
95-99	120	448	568
100 y más	8	43	51
Total	**613.779**	**670.803**	**1.284.582**

Fuente: INDEC (2009)

Solo pretende describir a la población y no tiene sentido preguntar qué variable es prioritaria a la otra o cuál depende de cuál.

Las relaciones en que no es posible o no interesa señalar qué variable es anterior, se llaman **simétricas**[29] o de variación conjunta o de covariación, con ellas simplemente puede preguntarse si las variables están correlacionadas. Es decir si varían simultáneamente, sin preguntar cuál es la que podría preceder a la otra.
Otro ejemplo de este tipo de relaciones es la que puede plantearse entre las calificaciones que los alumnos obtienen en dos materias que cursan simultáneamente; si encontramos que a aquellos alumnos que les va bien en Epistemología también obtienen buenas notas en Biología, no creeremos que un resultado incida en el otro, solamente *describiremos* que varían conjuntamente. Si luego nos interesamos por avanzar en un estudio explicativo iremos a buscar otras variables que den cuenta de esta covariación.

Una relación entre dos variables es **simétrica** cuando es de variación conjunta y no puede identificarse a una variable como previa a la otra

Por el contrario, aquellas relaciones en las que puede identificarse a una variable como anterior a otra se denominan **asimétricas**, es decir, no es lo mismo planearlas en un sentido que en otro. Una de las variables (la anterior) se llama antecedente y la otra (posterior) consecuente. En el contexto del diseño experimental, estas variables se denominan, respectivamente independiente y dependiente.
Puede observarse que una variable cambia a continuación de la otra (en sentido temporal) pero esto no nos autoriza a decir que cambia a causa de la otra, como resulta claro en el ejemplo del relámpago y el trueno. Que la relación sea asimétrica no implica que una variable sea ni la causa, ni un factor explicativo, de la otra.
A la inversa, en los estudios explicativos la relación debe ser asimétrica, porque se busca identificar factores que anticipen determinados eventos. Por eso decimos que la asimetría es una condición necesaria de la causalidad, pero no suficiente.

Una relación entre dos variables es **asimétrica** cuando una de las variables precede (lógica o cronológicamente) a la otra y puede identificarse a una como antecedente y a la otra como consecuente.

La dirección de la relación

Cuando las variables que se ponen en juego en una relación tienen un nivel de medición superior al nominal, resulta posible hacer juicios de orden entre sus categorías, con lo que es posible indicar si los valores van creciendo o decreciendo. Ya sea que se trate de una relación simétrica o asimétrica, si las variables tienen nivel ordinal o superior, resulta de interés plantear la **dirección** de la relación. Se trata de otro criterio para clasificar relaciones entre variables: si a cambios ascendentes (crecientes) de una variable se siguen cambios ascendentes de la otra, llamamos a la relación **directa**. Si, por el contrario, un

---

[29] Atención, éste es un uso diferente de los términos simetría y asimetría. La simetría de una distribución (univariada) indica su forma, acá se refiere al tipo de relación entre dos variables. El primer uso caracteriza a una variable, el segundo a una relación.

crecimiento de una de las variables va acompañado de una disminución en los valores de la otra, la denominaremos **inversa**[30]. Cuando se espera que la relación entre dos variables sea directa o inversa para toda la serie de categorías, decimos que la relación es monótona.
Por ejemplo, puede plantearse, de manera hipotética, la relación entre los años de educación y el salario. Las personas que han asistido más años a instituciones educativas tienden, en promedio, a tener ingresos más altos que quienes asistieron menos tiempo. La hipótesis anticipa una relación directa entre la escolarización y los ingresos.

Una relación entre dos variables medidas a nivel ordinal o superior es **directa** si cuando los valores de una de ella aumentan, también aumentan los de la otra.

Análogamente:

Se llama **inversa** a la relación entre dos variables de nivel ordinal o superior en la que los incrementos en los valores de una de ellas van acompañados de disminuciones en los valores de la otra

La clasificación solo tiene sentido si puede hablarse de aumento o disminución, es decir, si es factible realizar juicios de orden entre las categorías de las variables. Por eso es que este criterio requiere, para su aplicación, que ambas variables tengan por lo menos nivel ordinal.
Por ejemplo, la *calificación* que se obtiene en un examen (variable consecuente, de nivel ordinal) puede tener relación directa con las *horas dedicadas* a estudiarla (variable antecedente, de nivel proporcional). Lo que equivale a decir que quienes estudian más horas tenderían a obtener calificaciones más altas.
Si en otro ejemplo, se formula como hipótesis que el *tipo de escuela* secundaria (variable antecedente, de nivel nominal) a la que los alumnos asistieron tiene relación con el *rendimiento* que alcanzan en su carrera universitaria (variable consecuente, de nivel ordinal), no es posible establecer la dirección de esta relación, porque no se cumple que ambas variables sean al menos ordinales.

Ejemplo (datos ficticios): la expresión "si los padres los ayudan con las tareas, a los chicos les va mucho mejor en la escuela" equivale a decir que la ayuda que los padres les dan a sus hijos está relacionada con mucha intensidad con el rendimiento en la escuela. La primera variable, la ayuda es la antecedente, que puede ser de nivel nominal, con categorías: *ayuda, no ayuda*; o bien ordinal, con categorías: *ayuda siempre, casi siempre, pocas veces, nunca.* La segunda variable, el rendimiento, es la consecuente, y sus categorías podrían ser: *rendimiento alto, medio, bajo.* El esquema de la relación será:



3030 No es directamente o inversamente proporcional. La proporcionalidad es otra cosa. Aquí solo se trata de que cambien en la misma dirección (ambas aumentan o ambas disminuyen) o en dirección inversa (una aumenta y la otra disminuye).

Y la tabla que reúna los datos para verificar esta relación podrá tener dimensión 2X3, con forma:

Disposición de las variables para analizar la relación entre la ayuda que los padres dan a sus hijos y el rendimiento que alcanzan en la escuela

	Rendimiento			Total
Ayuda	Alto	Medio	Bajo	
Si				
No				
Total				

O bien, considerando a la ayuda como ordinal, en una tabla de 4X3

Disposición de las variables para analizar la relación entre la ayuda que los padres dan a sus hijos y el rendimiento que alcanzan en la escuela

	Rendimiento			Total
Ayuda	Alto	Medio	Bajo	
Siempre				
Casi siempre				
Pocas veces				
Nunca				
Total				

Planteada de este modo, se trata de una relación asimétrica, ya que suponemos que es la ayuda (antecedente) la que incide sobre el resultado (consecuente). Si vemos el último esquema, puede considerarse la dirección (en el anterior no ¿por qué?) y la formularíamos como directa, es decir que, cuanto mayor sea ayuda que los padres aportan, tanto mejores serán los resultados. Esto está dentro de la hipótesis, aún no hemos recogido datos para avalarla o refutarla. Llegar a conocer si la ayuda de los padres contribuye en gran medida o escasamente a los resultados en la escuela, es un problema de la intensidad de la relación, que solo podrá responderse a posteriori, una vez que los datos están recolectados.

Concepto de riesgo relativo

En las tablas de contingencia de dimensión 2X2, que plantean relaciones asimétricas se suele calcular una medida que resulta de muy accesible interpretación, denominada *riesgo relativo.* Se trata de un cociente entre la proporción de casos que se encuentran en una categoría de la variable consecuente bajo determinado escenario (una categoría de la variable antecedente) y la proporción de casos que se hallan en la misma, bajo el escenario complementario (la otra categoría de la variable antecedente). Es un término que tiene uso regular en epidemiología y tiene la ventaja de la claridad en la comunicación. Por ejemplo, un informe afirma que "El riesgo relativo de cardiopatía isquémica (CI) es 2,5 veces mayor en pacientes hipertensos." Se interpreta que las personas que son hipertensas tienen dos veces y media mayores chances de sufrir CI que quienes no lo son. El riesgo relativo se usa principalmente (pero no solo) en la relación entre dos variables dicotómicas; en este ejemplo las variables son: ser hipertenso y haber sufrido cardiopatía isquémica, ambas con categorías si – no, la primera es el antecedente y la

segunda el consecuente, porque interesa plantear el posible efecto de la hipertensión sobre la CI. El esquema de la relación hipotética es:

Ser hipertenso ⟶ Sufrir cardiopatía isquémica

Y la disposición de las variables para observar la eventual relación es:

		Sufrir cardiopatía isquémica	
		Si	No
Ser hipertenso	Si		
	No		

Ejemplo (datos ficticios): interesados en el efecto que podría tener el hábito de lectura de los alumnos sobre su rendimiento en Lengua, usamos una pregunta de un cuestionario aplicado a estudiantes del último año del secundario, que dice: "Durante los últimos dos meses ¿Leiste o estás leyendo algún libro, además de los que te pidieron en la escuela?" Con categorías de respuesta si – no. Nos interesa analizar la relación de esta variable con el resultado que los alumnos obtienen en la prueba de lengua, para lo cual cortamos los puntajes de esta prueba en dos categorías: altos (50 puntos o más) y bajos (menos de 50 puntos). Para la provincia de Córdoba, en el año 2000 resulta la siguiente tabla:

Durante los últimos dos meses ¿Leiste o estás leyendo algún libro, además de los que te pidieron en la escuela?	Puntaje de la prueba de Lengua		
	Bajos	Altos	Total
Si	2382	10299	12681
No	3530	9821	13351
Total	5912	20120	26032

Fuente ONE 2000

A fin de comparar los puntajes que obtienen quienes leen con los que obtienen los que no leen (para ver si hay alguna diferencia), hacen falta frecuencias relativas. En este caso se calculan según las filas de la tabla:

Durante los últimos dos meses ¿Leiste o estás leyendo algún libro, además de los que te pidieron en la escuela?	Puntaje de la prueba de Lengua		
	Bajos	Altos	Total
Si	18,8%	81,2%	100,0%
No	26,4%	73,6%	100,0%
Total	22,7%	77,3%	100,0%

Fuente ONE 2000

En esta tabla se observa que menos de un cuarto (el 22,7%) obtuvo resultados bajos, pero que este porcentaje es diferente entre quienes lee y quienes no lo hacen: entre quienes dicen que leen, menos del 19% (el 18,8%) tiene bajo puntaje, mientras que entre quienes dicen que no leen, ese porcentaje sube a más del 26 (26,4%). Dado que el resultado bajo se considera como el evento desfavorable, puede hablarse del riesgo de obtenerlo. Así, el riesgo de obtener puntaje bajo en Lengua es 18,8% para quienes dicen que leen y de 26,4% para quienes dicen que

no leen. Estos valores son los que se usan para calcular el riesgo relativo, el cociente entre 26,4 y 18,8 es 1,4, por lo que diremos que hay 1,4 veces más chances de obtener bajos resultados en Lengua entre alumnos que no leen que entre los que si lo hacen.

La intensidad

Sea que se trate de relaciones simétricas o asimétricas y que pueda o no decidirse sobre la dirección, siempre es posible (y tiene mucho interés hacerlo) evaluar la **intensidad** en que se manifiesta la relación entre las variables a partir de los datos de nuestras observaciones. Esta medida de la relación se corresponde con la idea intuitiva de "X tiene mucha influencia en Y", la idea de mucha o poca influencia, es la de intensidad de la relación. Cuando hay muchos factores explicativos para un fenómeno, interesa saber qué factores inciden en mayor o menor medida en el fenómeno y a eso se responde indicando la intensidad de cada relación.

La intensidad o grado de la relación puede también aplicarse a relaciones simétricas. En ese caso, la intensidad mide cuán a menudo los cambios de una de las variables se ven acompañados de cambios en la otra, y es un resultado descriptivo, no explicativo.

La **intensidad de una relación**[31] es una medida de la fuerza con que los cambios en una variable afectan los cambios en la otra (si es una relación asimétrica) o bien, de la frecuencia con que los cambios de una variable acompañan a los de la otra (si se trata de una relación simétrica).

La evaluación de esta intensidad puede lograrse, en una primera aproximación, observando la distribución conjunta de las dos variables. En la medida que cierta combinación de categorías de una y otra variable concentren la mayor parte de los casos, estaremos en presencia de relaciones más fuertes o de mayor intensidad. Los siguientes son resultados de un estudio que relaciona el tipo de docente con el rendimiento de sus alumnos:

Tabla 4: Alumnos primarios por rendimiento según tipo de docente, frecuencias absolutas

tipo de docente	rendimiento			Total
	alto	medio	bajo	
Autoritario	5	35	50	90
Democrático	260	40	10	310
Total	265	75	60	400

InfoStat® ofrece la tabla de contingencia así:

[31]No es posible ofrecer una definición más precisa porque según el modo en que se mida la intensidad, es decir, según el coeficiente que se use, es diferente el aspecto de la relación que se tiene en cuenta.

Tablas de contingencia

Frecuencias absolutas
En columnas: rendimiento

tipo docente	1,00	2,00	3,00	Total
1,00	5	35	50	90
2,00	260	40	10	310
Total	265	75	60	400

En la están codificados los tipos de docente como 1 y 2 y del mismo modo los rendimientos de los alumnos.

Al pedir las frecuencias relativas al total obtenemos:

Tabla 5: Alumnos primarios por rendimiento según tipo de docente, frecuencias relativas al total

tipo de docente	rendimiento			Total
	alto	medio	bajo	
Autoritario	0,01	0,09	0,13	0,22
Democrático	0,65	0,10	0,03	0,78
Total	0,66	0,19	0,15	1,00

Leemos las frecuencias conjuntas y las marginales como en la tabla 2. Por ejemplo:
El 10% de los alumnos tuvo docente democrático y rendimiento medio.
El 15% de los alumnos tuvo rendimiento bajo (sin importar qué tipo de docente tuvo).
El 22% tuvo docente autoritario (sin importar cuál fue su rendimiento).

Observando la distribución de los casos de la tabla 4 (frecuencia absolutas) parece haber una tendencia a que los docentes autoritarios tengan alumnos con menor rendimiento. Supondremos que los alumnos han sido distribuidos al azar entre los docentes de los dos tipos, es decir que no sucedió que a los docentes autoritarios "les tocaron" malos alumnos. Por lo tanto la pregunta es acerca del efecto que tendria el tipo de docente (antecedente) sobre el rendimiento de los alumnos (consecuente).
De los 90 alumnos que tuvieron docente autoritario, la mayor parte (50) muestra bajo rendimiento; por el contrario, de los 310 alumnos que tuvieron docente "democrático", la mayoria (260) tiene rendimiento alto, por lo que podria afirmarse que no es igual el rendimiento que se observa en alumnos con docentes de un tipo o de otro.
A fin de eliminar los efectos de las cantidades diferentes de alumnos con docentes autoritarios y democráticos, la relación puede verse mejor si se calculan porcentajes en cada celda. Tomando como totales las cantidades de alumnos que tienen docentes autoritarios y que los tienen democráticos; es decir, calculando las frecuencias relativas según los totales de la variable antecedente, se obtiene:

Tabla 6: Alumnos primarios por rendimiento según tipo de docente, frecuencias relativas por filas

Tipo de docente	Rendimiento			Total
	Alto	Medio	Bajo	
Autoritario	0,06	0,39	0,55	1,00
Democrático	0,84	0,13	0,03	1,00
Total	0,66	0,19	0,15	1,00

Sobre esta tabla puede afirmarse que, del total de alumnos que tuvieron docentes autoritarios, un 55% ha tenido bajo rendimiento. Por el contrario solo un 3% de los alumnos con docente democrático acusa rendimiento bajo. En el otro extremo, los autoritarios tienen un 6% de alumnos de rendimiento alto frente a un 84% de los democráticos.

Otra manera de leer los porcentajes es comparando con los marginales: sin considerar el tipo de docente, el 66% de los alumnos tuvo rendimiento alto. Cuando se considera al grupo de alumnos que tuvo docentes democráticos, este porcentaje sube al 84%, mientras que, en el grupo de quienes tuvieron docente autoritario, solo el 6% tuvo alto rendimiento.

La ventaja de usar porcentajes (o frecuencias relativas) es que las comparaciones se hacen sobre los mismos totales, es "como si" hubiese 100 alumnos con docente autoritario y 100 con democrático.
Que haya cierto efecto del tipo de docente (antecedente) sobre el rendimiento de los alumnos (consecuente) no es equivalente a que el tipo de docente sea "la causa" del rendimiento alto o bajo. Asi, vemos que hay algunos alumnos con docente autoritario que obtuvieron altos rendimientos (aunque solo sea el 6% del total) y otros que aun con docente democrático, tuvieron rendimiento bajo. Solo podemos afirmar que si el docente es democrático, hay más posibilidades de que los alumnos tengan mejor rendimiento, o que el tipo de docente es uno de los muchos factores que pueden incidir en el rendimiento de los alumnos.
Al comparar la tabla 6 con la 5 vemos que aunque ambas ofrecen frecuencias relativas, la 5 las calcula respecto del total general (los 400 casos) mientras que en la 6 los totales son las frecuencias marginales de cada fila. Son dos resultados muy diferentes, en efecto, la frecuencia de la celda 1,1 en la tabla 5 es 0,01 e indica que el 1% **del total de alumnos** tuvo docente autoritario y tuvo rendimiento alto, La misma celda en la tabla 6 tiene frecuencia de 0,06 y se lee: **de los alumnos con docente autoritario**, el 6% tuvo rendimiento alto. Veamos que la primera de las frecuencias (relativa al total) contiene información simultanea sobre las dos variables, mientras que la segunda (relativa a los totales de fila), fija una categoria para una de las variables: al hablar de los alumnos con docente autoritario, estamos restringiendo el conjunto completo, ya no es un juicio sobre los 400 alumnos del total, sino solo sobre los 90 que cumplen con ese requisito (haber tenido docente autoritario). La frecuencia está condicionada por ese requisito. Esto equivale a decir que las frecuencias relativas cambian cuando se establece una condición como la mencionada. En general, la proporción de alumnos con alto rendimiento es del 66%, pero si agregamos el dato que indica que estamos tratando solo con los que tuvieron docente autoritario, entonces la

proporción decae al 6%. El tipo de docente es una condición que imponemos cuando calculamos estas frecuencias relativas a los totales de fila.

El modo en que se calcularon las frecuencias relativas (o los porcentajes) en la tabla 6 fue tomando como total al número de alumnos con cada tipo de docente. No es ésta la única opción posible, ¿por qué no lo hicimos dividiendo por los totales de cada nivel de rendimiento? Es decir ¿qué hizo que eligiéramos en esta tabla las filas y no las columnas como totales para el cálculo de los porcentajes? En los casos en que tratemos con relaciones asimétricas, como lo es el del ejemplo, siempre elegiremos como denominador a los totales de la variable antecedente, porque queremos ver qué diferencia hay entre los grupos que definen sus categorías. En nuestro caso, el interés se centra en saber si el cambio de docente autoritario a democrático implica diferencia en el rendimiento de los alumnos. No es importante si la variable antecedente se ubica en las filas o en las columnas, son sus totales los que usaremos para el cálculo de los porcentajes.

Con el paso de las frecuencias simples a las relativas, hemos avanzado en la detección de la relación entre las dos variables, pero aun no podemos cuantificar su intensidad. Para ello existe una gran cantidad de coeficientes que se usan para reconocer si se trata de relaciones fuertes, débiles o simplemente inexistentes. Estos coeficientes varían según el nivel de medición de las variables, según el número de categorías, la simetría de la relación y, en especial, en el aspecto que analizan de la relación y el modo en que se interpretan. En este capítulo solo nos detendremos en uno de ellos que es de utilidad para tratar relaciones entre variables que tienen dos categorías cada una, es decir entre dos variables dicotómicas. En los próximos capítulos trataremos con otros coeficientes.
El coeficiente que usaremos para evaluar la intensidad de una relación entre dos variables dicotómicas se denomina *Q de Kendall - Yule* y en su cálculo tiene en cuenta el modo en que las frecuencias se distribuyen entre las cuatro celdas de la tabla.
Para ejemplificar el uso de este coeficiente, transformaremos la relación del caso anterior, dejando de lado a los alumnos de rendimiento medio, con lo que la tabla queda:

Tabla 7: Alumnos primarios por rendimiento según tipo de docente

Tipo de docente	Rendimiento		
	Alto	Bajo	Total
Democrático	260	10	270
Autoritario	5	50	55
Total	265	60	325

La concentración de la mayoría de los casos en las celdas de una de las diagonales de la tabla es una señal de la asociación existente entre las dos variables. El coeficiente Q se calcula operando con esas frecuencias del siguiente modo:

$$Q = \frac{260 * 50 - 5 * 10}{260 * 50 + 5 * 10} = \frac{12950}{13050} = 0{,}992$$

En el numerador, hemos multiplicado las frecuencias de una de las diagonales (260*50) y le hemos restado el producto de las frecuencias de la otra diagonal (5*10). En el denominador, hemos sumado los mismos dos productos. De manera simbólica, si representamos a las frecuencias de las celdas como A, B, C y D, tenemos

A B
C D

$$Q = \frac{A * D - C * B}{A * D + C * B}$$

El cálculo de este coeficiente da un número que puede ser positivo o negativo pero que siempre se encuentra entre –1 y 1.

$$-1 \leq Q \leq 1$$

En este coeficiente, el signo no tiene interpretación, se consideran iguales, por ejemplo, los valores 0,80 y -0,80. Esto se debe a que el signo que resulta depende del orden (arbitrariamente elegido) con que se hayan dispuesto las filas y las columnas. Si en la tabla 7 cambiamos las filas:

Tabla 7bis: Alumnos primarios por rendimiento según tipo de docente

Tipo de docente	Rendimiento		
	Alto	Bajo	Total
Autoritario	5	50	55
Democrático	260	10	270
Total	265	60	325

La tabla es la misma, pero el coeficiente cambia de signo:

$$Q = \frac{5 * 10 - 260 * 50}{5 * 10 + 260 * 50} = \frac{-12950}{13050} = -0{,}992$$

Este resultado se interpreta igual que si fuera positivo.

Cuanto más próximo a uno (1) o a menos uno (-1) sea el coeficiente, tanto más intensa es la relación entre las dos variables. Los valores del coeficiente cercanos a cero indican una relación entre las variables que es débil o inexistente.
Por lo tanto, el valor obtenido en el ejemplo anterior señala una relación intensa entre las dos variables, pudiendo llevarnos a afirmar que el tipo de docente tiene, según estos datos, mucho que ver con los resultados que los alumnos obtienen. Dicho de otra manera, entre los muchos factores que pueden incidir en el rendimiento de los alumnos, el tipo de docente juega un papel importante.
En el caso extremo que el coeficiente sea igual a uno (o a menos uno) diremos que la relación es perfecta. Se trata de un caso ideal, no factible de ser observado en la realidad, pero que sirve para establecer el valor límite del coeficiente. Un ejemplo en que esto sucedería es si las frecuencias de la tabla anterior fueran como las siguientes:

Tabla 8: Alumnos primarios por rendimiento según tipo de docente

Tipo de docente	Rendimiento		
	Alto	Bajo	Total
Democrático	270	0	270
Autoritario	0	55	55
Total	270	55	325

Aquí resulta que todos los alumnos que tuvieron docentes autoritarios tienen bajo rendimiento y todos los que tuvieron docentes democráticos, alto rendimiento. En esta tabla

$$Q = \frac{270 * 55 - 0 * 0}{270 * 55 + 0 * 0} = \frac{14850}{14850} = 1$$

El valor 1 se interpreta entonces indicando que la relación entre el tipo de docente y el rendimiento de los alumnos es perfecta.

El caso contrario es aquél en el que no haya relación alguna entre las variables, allí es cuando el coeficiente alcanza (en valor absoluto) su mínimo valor posible, cero. Otra vez se trata de un caso ideal, porque muy improbablemente se encontrarán en la realidad observaciones que lleven a un coeficiente que sea exactamente cero.
Modifiquemos nuevamente las frecuencias de nuestra tabla para ejemplificar esa situación ficticia:

Tabla 9: Alumnos primarios por rendimiento según tipo de docente

Tipo de docente	Rendimiento		
	Alto	Bajo	Total
Democrático	54	216	270
Autoritario	11	44	55
Total	65	260	325

En este caso los alumnos están distribuidos en las celdas del mismo modo si se trata de docentes autoritarios o democráticos, lo cual puede verse mejor si se calculan las frecuencias relativas por filas, como hicimos antes:

Tabla 10: Alumnos primarios por rendimiento según tipo de docente

tipo de docente	rendimiento		
	alto	bajo	total
democrático	0,20	0,80	1,00
autoritario	0,20	0,80	1,00
total	0,20	0,80	1,00

Aquí encontramos que un 20% de los alumnos tiene rendimiento alto y un 80% bajo, ya sea que hayan tenido docentes autoritarios o democráticos.
El cálculo del coeficiente da ahora:

$$Q = \frac{54 * 44 - 11 * 216}{54 * 44 + 11 * 216} = \frac{0}{4752} = 0$$

Este valor indica que no hay relación entre las variables, es decir que, según estos datos, el tipo de docente no hace diferencia alguna en el rendimiento de los alumnos.

El **coeficiente Q de Kendall - Yule** mide la intensidad de la relación entre dos variables dicotómicas comparando la concentración de frecuencias en las diagonales. Alcanza su valor máximo cuando todos los casos se ubican sobre una diagonal y la relación es perfecta. Alcanza su mínimo valor cuando las frecuencias están distribuidas de manera proporcional entre las celdas y las variables son independientes.

Una limitación importante de este coeficiente aparece cuando la distribución de las frecuencias es "rinconal". Esto quiere decir que una de las frecuencias es cero, como sucedería si en la tabla 7, no se hubiesen encontrado docentes democráticos con alumnos de bajo rendimiento:

Tabla 11: Ejemplo de distribución rinconal, alumnos primarios por rendimiento según tipo de docente

Tipo de docente	Rendimiento		
	Alto	Bajo	Total
Democrático	54	0	54
Autoritario	11	44	55
Total	65	44	109

En este ejemplo —y siempre que una celda tenga frecuencia cero—, el coeficiente Q dará valor 1 (ó -1) y esto no debe interpretarse como una asociación perfecta.

Terminaremos esta introducción a la relación entre variables con una referencia al problema de la causalidad. El hecho de haber encontrado que, en una relación asimétrica, existe una asociación intensa entre las variables, no nos lleva inmediatamente a suponer que la antecedente sea causa del consecuente. En toda explicación de un fenómeno, en especial de los fenómenos sociales, la causalidad es múltiple, es casi siempre imposible atribuir una causa única a la explicación de un hecho. Desde el sentido común es frecuente enunciar que "todo tiene una causa", pero en el dominio de la investigación en ciencias sociales los hechos que nos interesa analizar tienen múltiples causas, las cuales compiten entre sí en la explicación. Por lo tanto, descubriendo relaciones entre variables podemos aportar a la inclusión o exclusión de variables como factores explicativos de un fenómeno dado, pero no a "determinar su causa". Podremos afirmar qué factores hacen más probable la aparición de un fenómeno dado, bajo qué condiciones su ocurrencia es más frecuente, o inclusive indicar cuáles son las variables más importantes para que el fenómeno suceda, pero muy difícilmente lleguemos a afirmaciones del tipo *X es la causa de Y*.
Pensemos por ejemplo en fenómenos psicosociales complejos, como la delincuencia juvenil. El tipo de hogar del que las personas provienen puede tener efecto, la relación con los padres, el abandono temprano de la escuela, la estructura familiar actual, y pueden seguir enumerándose factores que contribuirían a explicar que algunas personas desarrollen conductas delictivas y

otras no. Pero no será posible alcanzar una explicación completa del fenómeno, en una expresión ingenua como *la causa de la delincuencia es...*

El concepto de independencia estadística

Formulemos ahora el problema de manera inversa, interrogándonos por las condiciones en que puede decirse que dos variables son independientes. Intuitivamente la independencia entre dos eventos equivale a que la ocurrencia de uno de ellos no tiene efecto en el del otro. Así, las oportunidades que un evento ocurra serán iguales tanto si el otro evento sucedió como si no lo hizo. Cuando decimos que X no tiene efectos sobre Y, indicamos que Y sucede tanto si X está presente como si no lo está. La independencia de dos variables es equivalente a que no haya asociación entre ellas.

Repitamos el cruce de las variables tipo de docente y rendimiento, ahora con frecuencias diferentes.

Tabla 12: Alumnos primarios por rendimiento según tipo de docente, frecuencias absolutas

tipo de docente	rendimiento		
	alto	bajo	total
democrático	170	10	180
autoritario	30	90	120
total	200	100	300

Tabla 13: Alumnos primarios por rendimiento según tipo de docente, frecuencias relativas por filas

tipo de docente	rendimiento		
	alto	bajo	total
democrático	0,94	0,06	1,00
autoritario	0,25	0,75	1,00
total	0,67	0,33	1,00

En la última fila, las frecuencias marginales indican que en la muestra observada hubo un 67% de alumnos de rendimiento alto y 33% de rendimiento bajo, sin tener en cuenta el tipo de docente. Este dato nada dice sobre la relación entre las variables sino que proviene del modo en que resultó la composición de la muestra.

Si el tipo de docente no tuviera efecto en el rendimiento, esperariamos que haya igual proporción de alumnos con rendimiento alto y bajo entre docentes de diferente tipo. Si del total de alumnos, el 67% tiene rendimiento alto, los docentes democráticos deberian tener un 67% de alumnos con rendimiento alto y también deberia ser asi para los docentes autoritarios. De modo que, de los 180 alumnos que tuvieron docente democrático, 120 (que constituyen aproximadamente el 67% de 180) deberian haber tenido rendimiento alto. Análogamente, el 67% de 120, (aproximadamente 80 alumnos) son los que deberia haber con alto rendimiento y docente autoritario. Las frecuencias de las celdas de los alumnos con bajo rendimiento se obtienen usando ahora el porcentaje del 33% sobre los mismos

totales (180 y 120). Puede entonces construirse una nueva tabla con las frecuencias que se esperaría encontrar si las dos variables fueran independientes, es decir si el tipo de docente no tuviera efecto alguno en el rendimiento de los alumnos.

Tabla 14: Frecuencias esperadas bajo la hipótesis de independencia correspondiente a la tabla 12

tipo de docente	rendimiento		
	alto	bajo	total
democrático	120	60	180
autoritario	80	40	120
total	200	100	300

Observemos algunos detalles de esta tabla. En primer lugar, las frecuencias marginales no han cambiado, los totales son los mismos y solo se trata de un reordenamiento de las frecuencias conjuntas bajo la hipótesis de independencia de las dos variables[32].
Tratemos ahora de formalizar las operaciones que condujeron a esta segunda tabla. Los valores 67% y 33% provienen de las proporciones de casos en cada una de las categorías de la variable "rendimiento de los alumnos", y se calcularon como $\frac{200}{300}$ y $\frac{100}{300}$ respectivamente. Luego esas proporciones se multiplicaron por los totales de casos de cada categoría de la variable "tipo de docente". De esa operación obtuvimos 120 como 180*0,66, que daría lo mismo como $180 * \frac{200}{300}$.
El valor 80 proviene de 120*0,66 o bien de $120 * \frac{200}{300}$.
60 es $180 * \frac{100}{300}$.
Finalmente, 40 resulta de hacer $120 * \frac{100}{300}$.

De manera general entonces, obtenemos cada una de las frecuencias de la segunda tabla multiplicando la frecuencia marginal de su fila por la de su columna y dividiendo por el total general. En símbolos, las frecuencias esperadas son:

$$f_{ij}^{e} = \frac{f_i * f_j}{n}$$

Si las dos variables fueran independientes (con más precisión se dice estadísticamente independientes), las frecuencias conjuntas que se esperaría encontrar serían como las que calculamos con este procedimiento. ¿Y qué sería en ese caso de las frecuencias relativas? Dividiendo todo por el total obtenemos:

---

[32] Como consecuencia de ello, de las cuatro celdas solo es necesario calcular una frecuencia, ya que las demás pueden obtenerse restando de los totales de filas y de columnas. Una vez que sabemos que la frecuencia de la celda 1,1 es 120, podemos obtener 60 como lo que resta para llegar a 180 (de la primera fila), 80 como la diferencia con 200 (de la primera columna) y 40 como lo que le falta a 60 para llegar a 100 (segunda columna) o lo que le falta a 80 para alcanzar 120 (segunda fila).

Tabla 15: Frecuencias relativas esperadas bajo la hipótesis de independencia correspondiente a la tabla 12

tipo de docente	rendimiento		
	alto	bajo	total
democrático	0,40	0,20	0,60
autoritario	0,27	0,13	0,40
total	0,67	0,33	1,00

Puede llegarse directamente a las frecuencias relativas, porque la frecuencia absoluta de cada celda es:

$$f_{ij} = \frac{f_i * f_j}{n}$$

Y relativa de esa celda:

$$f'_{ij} = \frac{f_{ij}}{n}$$

Si reemplazamos, nos queda:

$$f'_{ij} = \frac{f_{ij}}{n} = \frac{\left(\frac{f_i * f_j}{n}\right)}{n} = \frac{f_i}{n} * \frac{f_j}{n} = f'_i * f'_j$$

Más brevemente:

$$f'_{ij} = f'_i * f'_j$$

Es decir que, si las variables fueran independientes, cada frecuencia relativa será producto de las correspondientes frecuencias relativas marginales. Ahora podemos dar una definición de independencia estadistica.

Dos variables son **estadísticamente independientes** si la frecuencia relativa de cada celda es igual al producto de las frecuencias relativas marginales de la fila y la columna a las que la celda pertenece.

En efecto, cada frecuencia conjunta de la tabla 14 es el producto de las marginales correspondientes.

Como verificación, el coeficiente de Kendall-Yule de la tabla 14 es:

$$Q = \frac{120 * 40 + 80 * 60}{120 * 40 - 80 * 60} = 0$$

Como debe ser por haber construido la tabla con el criterio de independencia.

En este capítulo solo se trató con variables nominales, y en un caso también ordinales, pero aún no se ha dicho nada sobre las variables intervalares y proporcionales. En las distribuciones univariadas se vio que una tabla de distribución de frecuencias no puede listar todas las categorías de una variable de estos niveles, sino que deben construirse intervalos de valores. Eso mismo puede hacerse para construir una tabla bivariada, cuando se analiza la relación entre variables intervalares y/o proporcionales. De ese modo resultaría una tabla como:

Disposición de las variables para analizar la relación entre los años de escolarización y el ingreso mensual individual

Años de escolarización	Ingresos mensuales				
	<1000	1000 a 2000	2000 a 3000	3000 a 4000	>4000
< 5					
5-10					
10-15					
> 15					

Pero en el próximo capítulo veremos que para variables de estos niveles de medición se cuenta con procedimientos más simples y más eficaces que permiten analizar con más detalle sus relaciones.

Capítulo 5 Relación entre variables: el análisis

En el capítulo anterior hemos tratado la relación entre dos variables en escalas nominales, y señalamos que si se trata de variables de nivel superior es posible crear categorías y tratarlas del mismo modo. En cuanto a la medida de la intensidad de la relación, nos hemos limitado al caso de dos variables dicotómicas, es decir, con dos categorías en cada una, con lo que la tabla resultante es de dos por dos y calculamos el coeficiente Q de Kendall - Yule. Ahora se amplía el dominio de nuestro análisis, incorporando herramientas que permiten poner a prueba la hipotética relación entre dos variables de nivel nominal con más de dos categorías cada una y variables de nivel superior (ordinales y métricas).

Variables nominales con más de dos categorías cada una

La distancia entre frecuencias esperadas y observadas

Sobre el final del capítulo anterior presentamos el concepto de independencia estadística y vimos la manera de calcular las frecuencias de las celdas que se esperarían encontrar si las variables fueran independientes. Para hacer esto es suficiente multiplicar las frecuencias marginales correspondientes a cada celda y dividir el resultado por el total de casos. Sea el caso que interese analizar la relación del tipo de violencia[33] con el lugar donde sucede. Aunque estadísticamente equivalente, no es adecuado preguntar si el lugar incide sobre el tipo de violencia, sino más bien si el tipo de violencia difiere según el lugar. Aquí es más pertinente el planteo del problema como una comparación de grupos (los definidos por los diferentes lugares) antes que como una relación entre variables. Lo mismo pasa cuando se comparan los resultados de un examen entre quienes cursan por la tarde o la mañana. Cuando hay control de variables, como en el diseño experimental o en la evaluación de impacto, el paralelismo entre las dos lecturas es más cercano. Así, preguntar si un grupo de niños que recibió un suplemento en su dieta, tiene mejor desarrollo que uno que no lo recibió (planteo en términos de comparación de grupos), equivale a preguntar si el suplemento dietario incide sobre el desarrollo (planteo en términos de relación entre variables). Las operaciones estadísticas que responden a las dos preguntas son las mismas, pero según el caso, una manera de formular el problema puede ser más adecuada que otra.

Para el ejemplo de las diferencias en el tipo de violencia según área geográfica, una muestra de 500 casos provee la siguiente distribución conjunta:

---

33 Según la clasificación sugerida por el Informe Mundial sobre la Violencia y la Salud, Organización Panamericana de la Salud, 2003

Tabla 1: Clasificación de diferentes tipos de violencia según área donde se manifiesta

Tipo de violencia	Área			Total
	Ciudades grandes	Ciudades pequeñas	Áreas rurales	
Autoinfligida	100	35	15	150
Interpersonal	110	100	90	300
Colectiva	35	10	5	50
Total	245	145	110	500

Una primera aproximación consiste en calcular frecuencias relativas. Dado que nuestro interés está en comparar el tipo de violencia según las áreas, calcularemos los porcentajes según las columnas de la tabla 1 y resulta:

Tabla 2: Frecuencia relativas por columnas de la clasificación de diferentes tipos de violencia según área donde se manifiesta

Tipo de violencia	Área			Total
	Ciudades grandes	Ciudades pequeñas	Áreas rurales	
Autoinfligida	41%	24%	14%	30%
Interpersonal	45%	69%	82%	60%
Colectiva	14%	7%	5%	10%
Total	100%	100%	100%	100%

Si no consideramos el área, se ve (en la columna de los totales) que la violencia interpersonal es la más frecuente (60%), seguida de la autoinfligida con el 30%. Este patrón de distribución en las distintas formas de violencia se mantiene en las diferentes áreas, pero en más acentuado en las rurales, donde la categoria modal (que sigue siendo interpersonal) alcanza el 82% del total del área. Por el contrario, la violencia autoinfligida, que es el 30% del total, sube al 41% en grandes ciudades y solo representa el 14% de las formas de violencia que se observan en áreas rurales. Asi, pareceria que hay diferencia en la distribución de los tipos de violencia según las áreas que están considerándose.

Codificando como 1, 2 y 3 las áreas y del mismo modo el tipo de violencia, el programa InfoStat® muestra las frecuencias absolutas y las relativas por columnas asi:

Tablas de contingencia

Frecuencias absolutas
En columnas: área

tipo violencia	1	2	3	Total
1	100	35	15	150
2	110	100	90	300
3	35	10	5	50
Total	245	145	110	500

Frecuencias relativas por columnas
En columnas: área

tipo violencia	1	2	3	Total
1	0,41	0,24	0,14	0,30
2	0,45	0,69	0,82	0,60
3	0,14	0,07	0,05	0,10
Total	1,00	1,00	1,00	1,00

Buscaremos ahora de cuantificar la intensidad de esa relación, para lo que nos preguntaremos cuáles serían las frecuencias de las celdas si el tipo de violencia fuera independiente del área donde sucede, es decir, si se observara la misma proporción de los distintos tipos de violencia en todas las áreas. Usemos el concepto de independencia estadística para calcular las frecuencias esperadas correspondientes a la tabla 1

Tabla 3: Frecuencias esperadas bajo la hipótesis de independencia entre el tipo de violencia y el área donde se observa

Tipo de violencia	Área			Total
	Ciudades grandes	Ciudades pequeñas	Áreas rurales	
Autoinfligida	74	43	33	150
Interpersonal	147	87	66	300
Colectiva	24	15	11	50
Total	245	145	110	500

Estas frecuencias están calculadas como indicamos en el capítulo anterior, haciendo:

$$f_{ij}^{e} = \frac{f_i * f_j}{n}$$

Por ejemplo, la frecuencia de la celda 1,1 resultó de $f_{ij}^{e} = \frac{150 \cdot 245}{500} = 73{,}5$ que redondeamos a 74.

Solicitada a InfoStat®, esta salida tiene la forma:

Tablas de contingencia[34]
Frecuencias absolutas
En columnas: área

tipo violencia	1	2	3	Total
1	100	35	15	150
2	110	100	90	300
3	35	10	5	50
Total	245	145	110	500

[34]En la salida no están redondeados los decimales de las frecuencias esperadas

Frecuencias esperadas
En columnas: área

tipo violencia	1	2	3	Total
1	73,5	43,5	33,0	150,0
2	147,0	87,0	66,0	300,0
3	24,5	14,5	11,0	50,0
Total	245,0	145,0	110,0	500,0

Estas últimas son las frecuencias que esperaríamos encontrar si no hubiera relación entre las variables, si éstas fueran independientes. A ellas debemos compararlas con las que realmente hemos encontrado, las que se denominan frecuencias observadas.

Si halláramos que nuestras frecuencias observadas son muy similares a las esperadas bajo la hipótesis de independencia, diríamos que las variables "están cerca" de ser independientes, o lo que es equivalente, que habría escasa relación entre ellas. Por el contrario, si las frecuencias observadas fueran muy diferentes de las esperadas, creeríamos que las variables "están lejos" de ser independientes, es decir, que habría alguna relación entre ellas. Para decidir, debemos comparar la tabla 1 con la 3.
Para simplificar quitamos los nombres de las categorías y las frecuencias marginales, así, las que debemos comparar son las siguientes frecuencias:

Tabla 4: Frecuencias observadas y esperadas para la tabla 1

Observadas		
100	35	15
110	100	90
35	10	5

Esperadas		
74	43	33
147	87	66
24	15	11

Una opción para medir la distancia entre los dos conjuntos de frecuencias es la de restar las correspondientes de cada celda; pero si hacemos eso nos encontraremos con un problema parecido al que tuvimos cuando intentamos observar la dispersión restando los valores de la media: la suma da cero. Por única vez realizaremos esta operación de manera manual:

$$(100-74)+(35-43)+(15-33)+(110-147)+(100-87)+(90-66)+(35-24)+(10-15)+(5-11)=0$$

Obtenemos este resultado porque las frecuencias marginales son fijas y lo que una celda tiene de más, lo tiene otra de menos. Siempre sucederá así y por esa razón, no podemos saber si las observadas están cerca o lejos de las esperadas con el procedimiento directo de restarlas. Por el contrario, para medir la distancia entre los dos conjuntos de frecuencias (observadas y esperadas) se usa la siguiente expresión:

$$\sum_{\substack{i=1\\ j=1}}^{\substack{i=f\\ j=c}} \frac{(f_{ij}^{o}-f_{ij}^{e})^2}{f_{ij}^{e}}$$

La expresión nos dice que deben restarse cada una de las frecuencias esperadas de cada observada correspondiente, elevar esa diferencia al cuadrado[35] y dividir el resultado por cada una de las frecuencias esperadas. Los subíndices mantienen la notación del capítulo anterior: i es el índice de filas, que va desde la primera (i=1) hasta la última (f es el número total de filas); j es el índice de las columnas, que también empieza en 1 (j=1) y termina en c, que es el número total de columnas[36]. Vamos a aplicarla una vez, solo para ver su funcionamiento, luego la pediremos al programa:

$$\frac{(100-74)^2}{74}+\frac{(35-43)^2}{43}+\frac{(15-33)^2}{33}+\frac{(110-147)^2}{147}+\frac{(100-87)^2}{87}+\frac{(90-66)^2}{66}+\frac{(35-24)^2}{24}$$
$$+\frac{(10-15)^2}{15}+\frac{(5-11)^2}{11}=50{,}40$$

El número que resulta de esta operación se llama puntaje chi cuadrado (o también ji cuadrado), se indica con el símbolo χ^2 y es una medida de la distancia a la que se encuentran las frecuencias observadas de las que se esperaría encontrar si las variables fueran independientes.

Cuando se pide a InfoStat®, se obtiene:

Estadístico	Valor	gl	p
Chi Cuadrado Pearson	**50,19**	4	<0,0001
Chi Cuadrado MV-G2	52,25	4	<0,0001
Coef.Conting.Cramer	0,18		
Coef.Conting.Pearson	0,30		

De esta salida por ahora solo nos interesa lo que está destacado (Chi Cuadrado Pearson); más adelante se usarán otros de los resultados de la salida. El valor no es idéntico al que hallamos manualmente (50,19 contra 50,40), eso se debe a que habíamos redondeado las frecuencias esperadas y el programa trabaja con los decimales, pero la diferencia no es importante.
Este número, el puntaje χ^2 no puede ser negativo, ya que proviene de la suma de números elevados al cuadrado. Solo puede ser cero si todos los términos de la suma son cero, es decir, si cada frecuencia observada es exactamente igual a la esperada correspondiente. En ese caso no habría duda en decir que las variables son independientes, cumplirían exactamente con la definición de independencia estadística. El puntaje χ^2 indica si las frecuencias observadas están cerca o lejos de las esperadas, pero ¿qué tan grande debe ser para que consideremos lejanas a las frecuencias?
Dos problemas que tiene este puntaje son: que puede ser indefinidamente grande y que su valor depende del número de casos que se evalúan y de la dimensión de la tabla. Así, por ejemplo, si multiplicamos por 10 todas las frecuencias de la tabla 3, obtenemos:

---

[35]El mismo recurso que se usó cuando se definió la varianza y no era posible usar la suma de los desvíos porque daba cero. Nuevamente aquí, usamos el exponente 2 para volver positivos a los números negativos.
[36]Recordemos que, de manera general la dimensión de la tabla es f X c, filas por columnas.

Tabla 5: Ejemplo de expansión artificial del total de casos de la tabla 1

Tipo de violencia	Área			Total
	Ciudades grandes	Ciudades pequeñas	Áreas rurales	
Autoinfligida	1000	350	150	1500
Interpersonal	1100	1000	900	3000
Colectiva	350	100	50	500
Total	2450	1450	1100	5000

Aunque los valores absolutos son diez veces más grandes, no hubo cambios en las frecuencias relativas, por ejemplo, en la celda 1,1: $\frac{1000}{2450} = 0{,}41$ (41%) lo mismo que habia dado esa celda en la tabla 2. Cualquiera sea la intensidad de la relación entre estas dos variables, ésta no ha cambiado porque hayamos multiplicado todo por 10, sin embargo, si calculamos el puntaje χ^2 en la tabla 5 obtenemos 501,9, es decir un número 10 veces más grande. Entonces el puntaje χ^2 puede cambiar muy ampliamente sin que cambien las frecuencias relativas; esto nos dice que este puntaje no mide de manera directa la asociación entre dos variables, por ello:

Para comparar la intensidad de la asociación, el puntaje χ^2 solo en válido si las tablas tienen la misma dimensión y el mismo número de casos.

Para medir la asociación, debe eliminarse el efecto de la cantidad de casos y también de la dimensión de la tabla. Calcularemos tres coeficientes que nos permitan evaluar el grado o intensidad de la relación y que tengan un limite superior de modo que podamos juzgarlos como elevados o bajos.
El primero de ellos es el **coeficiente φ**[37], válido para medir la asociación entre dos variables dicotómicas (o binarias), se calcula como:

$$\varphi = \sqrt{\frac{\chi^2}{n}}$$

Vale cero si las variables son independientes e indica mayor asociación cuando está más cerca de uno.

Ejemplo (datos ficticios): en el análisis de la calidad de items de un examen, se observa las veces que una pregunta es correctamente respondida por los alumnos que aprobaron el examen y por quienes no lo aprobaron. Para el caso de una pregunta a la que se llama #7745, que fue respondida por 100 alumnos (a quienes les tocó por azar), la información se presenta en una tabla de 2X2:

[37] Ver Ekström, J. (2011) para las discusiones en torno a este coeficiente en el llamado "debate Pearson-Yule".

Resultado del examen	Respuesta a la pregunta #7745 correcta	incorrecta	total
aprobó	50	15	65
no aprobó	10	25	35
total	60	40	100

Para la que el puntaje χ^2 vale 22,16, y el coeficiente resulta en:

$$\varphi = \sqrt{\frac{22.16}{100}} = 0.47$$

Como el cálculo del puntaje χ^2 es engorroso para hacer manualmente, existe una expresión alternativa, que solo usa las frecuencias observadas en la tabla. Si estas son:

a	b
c	d

La fórmula de cálculo del coeficiente φ es:

$$\varphi = \frac{(c * b) - (a * d)}{\sqrt{(a+b) * (c+d) * (a+c) * (b+d)}}$$

Aplicado a los datos del ejemplo da:

$$\varphi = \frac{(10 * 15) - (50 * 25)}{\sqrt{(50+15) * (10+25) * (50+10) * (15+25)}} = \frac{1100}{2337} = 0.47$$

Otra forma de medir la asociación entre dos variables, cuando alguna de ellas o las dos, tienen más de dos categorías, es el **coeficiente de contingencia**, C de Pearson, se calcula del siguiente modo a partir del puntaje χ^2:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

Como φ, este coeficiente no puede ser menor que cero (0) y solo toma ese valor si las variables son independientes (es decir cuando $\chi^2 = 0$). Tampoco puede ser mayor que uno (1), pero su valor máximo depende de la dimensión de la tabla. Solo en el caso particular en que la tabla sea cuadrada (misma cantidad de filas que de columnas), el valor máximo del coeficiente es:

$C_{max} = \sqrt{\frac{f-1}{f}}$, o lo que es lo mismo: $C_{max} = \sqrt{\frac{c-1}{c}}$

Ya que nos referimos a tablas cuadradas, en las que $f = c$.

Si la tabla no es cuadrada, sino de fXc, el valor máximo es:

$$C_{max} = \sqrt{\frac{\min(f,c) - 1}{\min(f,c)}}$$

En la que *min(f,c)* es el más chico de los dos números.
De este modo se obtiene un coeficiente que indica el grado de la asociación entre dos variables, que mejora lo que mide el coeficiente Q de Kendall - Yule, ya que este último es apto para tablas de cualquier dimensión, no solo para las de 2 X 2.
Reemplacemos los valores para el ejemplo anterior:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}} = \sqrt{\frac{50{,}19}{50{,}19 + 500}} = 0{,}30$$

Para decidir si este resultado es alto o bajo, es decir, si la relación es fuerte o débil, calculemos el máximo que podría haber alcanzado para una tabla de 3X3:

$$C_{max} = \sqrt{\frac{f-1}{f}} = \sqrt{\frac{3-1}{3}} = \sqrt{\frac{2}{3}} = 0{,}82$$

Entonces el valor que hemos encontrado es moderado, y nos indica que la relación entre el tipo de violencia y el tamaño de las ciudades no es intensa.

El tercer (y último) coeficiente que calcularemos para variables nominales está también basado en el puntaje χ^2 y tiene un valor máximo de 1 (uno). Se llama **coeficiente V de Cramer** y se calcula así:

$$V = \sqrt{\frac{\chi^2}{n * \min(f-1; c-1)}}$$

La expresión *min(f-1, c-1)*, tiene el mismo significado que en C_{max}, es mínimo entre el número de filas menos uno y el número de columnas menos uno. Para obtenerlo se resta 1 al número de filas, luego se resta 1 al número de columnas y se elige el menor de los dos. Si la tabla es de 3X2 se hace $3-1=2$ y $2-1=1$, entre 2 y 1 el mínimo es 1 y ése es el número que ubicamos en el denominador, multiplicando a n. En este ejemplo, las filas y las columnas son tres, por lo que se toma el mínimo entre 3-1 y 3-1, el resultado es 2, y el coeficiente V de Cramer resulta:

$$V = \sqrt{\frac{\chi^2}{n * \min(f-1, c-1)}} = \sqrt{\frac{50{,}19}{500 * \min(3-1, 3-1)}} = \sqrt{\frac{50{,}19}{500 * 2}} = 0{,}45$$

Como el valor máximo que puede alcanzar este coeficiente es 1 (uno), en este caso se trata de una relación moderada entre las dos variables.

Variables de nivel ordinal

Si nuestro problema es el de describir la relación entre variables cuyas categorías están ordenadas, es decir variables ordinales, los coeficientes anteriores son válidos: pero como sucedió con las medidas descriptivas, el mayor nivel de

medición permite calcular coeficientes más elaborados y que, por esa razón, informen más acerca de la relación entre las variables que se analizan. Un punto a tener en cuenta es que cuando se trata con dos variables, la del menor nivel de medición es la que manda. Asi, para relacionar una ordinal y una nominal, debe usarse un coeficiente V o C, como si fueran las dos nominales.
Si las dos variables son ordinales o si una es ordinal y la otra intervalar o proporcional, es posible calcular un coeficiente que tiene en cuenta los "rangos" es decir la posición de cada categoria respecto de las demás, su carácter de primera, segunda, etc., es decir, el orden. Sea el problema de indagar por la relación que podria haber entre el resultado que obtienen los alumnos al rendir un examen de ingreso a una carrera y el nivel de educación de sus madres, consideraremos como variables *el nivel máximo de educación de la madre* de cada uno y *el orden de mérito alcanzado en el ingreso* a esa carrera; ambas variables son ordinales. Tratemos solo la situación de pocos casos por ahora. Si para el orden de mérito codificamos como 1, 2, 3... el primer lugar en el ingreso, el segundo, etc. y para la educación de la madre usamos 1 = universitario completo, 2 = universitario incompleto, etc., entonces el fragmento de la matriz de datos para 8 observaciones tendria una forma como esta:

Sujeto	Orden de mérito en el ingreso	Educación de la madre
1	1	2
2	2	2
3	3	3
4	4	2
5	5	3
6	6	4
7	7	5
8	8	3

Que está ordenada según los valores de la primera variable (orden de mérito). A estos datos no conviene presentarlos en una tabla de doble entrada, porque cada orden de mérito corresponde a un único individuo, por lo que resultaria una tabla tan poco resumida como la siguiente:

Tabla 6: Distribución conjunta de las frecuencias del orden de mérito en el ingreso a una carrera universitaria y el nivel de educación de la madre.

	Educación de la madre							total
Orden de mérito en el ingreso	1	2	3	4	5	6	7	
1	0	1	0	0	0	0	0	1
2	0	1	0	0	0	0	0	1
3	0	0	1	0	0	0	0	1
4	0	1	0	0	0	0	0	1
5	0	0	1	0	0	0	0	1
6	0	0	0	1	0	0	0	1
7	0	0	0	0	1	0	0	1
8	0	0	1	0	0	0	0	1
Total	0	3	3	1	1	0	0	8

Esta tabla no es útil, ya que tiene tantas filas como la matriz de datos (porque cada orden de mérito corresponde a una sola persona), hay solo un caso en cada celda no vacia y hay muchas celdas vacias (con frecuencia cero). Por eso, cuando

se trata de variables de este nivel de medición, no se usan tablas de doble entrada para representar los datos, solo se calcula un coeficiente que indique la intensidad de la relación. Este coeficiente se llama coeficiente de **correlación por rangos, de Spearman** y para calcularlo hay que transformar los valores de las variables en rangos, de mayor a menor, de manera que al máximo valor de cada variable corresponda el 1, al siguiente el 2 y así sucesivamente. En nuestro ejemplo, el orden de mérito ya está en rangos, uno para el primero, dos para el segundo y un rango para cada persona. No es así para el nivel de educación, ya que varias personas pueden tener el mismo, a esta variable la transformaremos en rangos. El mayor nivel de educación observado es 2 (universitario incompleto) a ese valor le correspondería el rango 1 (uno), pero hay tres madres con ese nivel de educación, ellas deberían llevar los rangos 1, 2 y 3, como están empatadas, les asignamos a todas el promedio de los tres rangos: 2. Luego sigue el nivel de educación 3 (secundario completo) a quien deberíamos asignar el rango 4, pero acá también hay empate entre tres casos, corresponderían los rangos 4, 5 y 6, nuevamente usamos el promedio de los tres rangos para asignar a los tres el mismo: 5. Sigue el nivel 4 (secundario incompleto), al que asignamos el rango siguiente: 7, ya que hay solo un caso aquí; y lo mismo pasa con el nivel 5 (primario completo) al que le toca rango 8.
Resumiendo entonces, la transformación de los valores de las variables en rangos resulta así:

Tabla 7: Transformación de las categorías de la variable a rangos

Orden de mérito en el ingreso	Rango del orden de mérito	Educación de la madre	Rango de la educación de la madre
1	1	2	2
2	2	2	2
3	3	3	5
4	4	2	2
5	5	3	5
6	6	4	7
7	7	5	8
8	8	3	5

No ha sido necesario transformar los valores del orden de mérito, porque ya correspondían uno a cada sujeto.
Una vez construidos los rangos, se observa, para cada caso la diferencia entre el rango de una variable y de la otra, esas diferencias se llamarán *d*.

Tabla 8: Cálculo de las diferencias entre los rangos de dos variables ordinales

Rango del orden de mérito	Rango de la educación de la madre	*d*
1	2	-1
2	2	0
3	5	-2
4	2	2
5	5	0
6	7	-1
7	8	-1
8	5	3

Estas diferencias indican la distancia que hay entre los dos ordenamientos, si fueran ambos iguales (si el máximo de uno coincidiera con el máximo del otro y así en todas las categorías), tendríamos una asociación perfecta entre las dos variables. Por el contrario si el orden estuviese exactamente invertido (si el rango máximo de una variable coincidiera con el rango mínimo de la otra y así en las demás) la relación también sería perfecta, pero inversa.
La intensidad de la relación se mide entonces con el que hemos llamado coeficiente se Spearman, la expresión de su cálculo es la siguiente:

$$r_s = 1 - \frac{6 * \sum_{i=1}^{n} d_i^2}{n^3 - n}$$

En la que:
d_i son las diferencias de rangos (calculadas en la última columna de la tabla de arriba) que en la fórmula van elevadas al cuadrado.
La sumatoria indica que ésta va desde la primera de las diferencias (i=1) hasta la última (n).
n es el número total de observaciones.

Este coeficiente puede ser positivo o negativo y tiene un campo de variación igual al del Q de Kendall - Yule, es decir, entre -1 y 1, es decir:

$$-1 \leq r_s \leq 1$$

Al igual que el coeficiente de Kendall - Yule, los valores próximos a 1 ó a -1 se interpretan como propios de una asociación fuerte (intensa) y los cercanos a 0 (cero), sean positivos o negativos, corresponden a asociaciones débiles. Si un coeficiente vale 1 ó -1 diremos que la asociación es perfecta, pero eso no es algo que suceda en la realidad, del mismo modo que si el coeficiente es exactamente 0 (cero), la asociación será nula y otra vez es muy poco común que eso suceda con datos reales.
A diferencia de los coeficientes usados para variables nominales, ahora el signo importa: cuando es positivo da cuenta de una relación directa entre las dos variables, una relación en la que cuando una aumenta, la otra también lo hace. Si el coeficiente es negativo indica relación inversa, el crecimiento de una variable se acompaña del decrecimiento de la otra. En este nivel de medición (ordinal) podemos hacer estos juicios, podemos decir "aumenta" o "disminuye", porque las categorías están ordenadas, por esa razón podemos analizar no solo la intensidad de la relación, sino también si se trata de una relación directa o inversa.
Se trata de dos características independientes de cada relación: puede ser fuerte y directa; o fuerte e inversa; o bien débil y directa; o débil e inversa. Un error muy frecuente es creer que si el coeficiente es negativo, la relación es débil, no es así. Es débil si el coeficiente es cercano a 0 (cero), es igualmente débil si r_s=0,03 como si r_s=-0,03, el signo del coeficiente no aporta para saber si es fuerte o débil. Del mismo modo es igual de fuerte una relación en la que r_s=0,96 como una en la que r_s=-0,96.
Para obtener el valor del coeficiente en nuestro ejemplo, vamos primero a calcular las d_i^2:

Rango del orden de mérito	Rango de la educación de la madre	d_i	d_i^2
1	2	-1	1
2	2	0	0
3	5	-2	4
4	2	2	4
5	5	0	0
6	7	-1	1
7	8	-1	1
8	5	3	9

Por lo que la suma de la última columna es 20. Al reemplazar los valores en la expresión de r_s, obtenemos:

$$r_s = 1 - \frac{6 * \sum_{i=1}^{n} d_i^2}{n^3 - n} = 1 - \frac{6 * 20}{8^3 - 8} = 1 - \frac{120}{512 - 8} = 1 - \frac{120}{504} = 0{,}76$$

Este valor de $r_s = 0{,}76$, indica una asociación intensa y positiva entre la educación de la madre y los resultados del ingreso a la universidad. Que sea positiva quiere decir que los alumnos con madres de mayor educación obtienen mejores resultados en el ingreso a esa carrera. Como ya hemos señalado, esto no quiere decir causalidad, no significa que la causa del resultado en el ingreso sea la educación de la madre. El problema de la causalidad es teórico y depende del análisis que se hace de las relaciones entre los conceptos, en este ejemplo, la educación de la madre es uno de muchos de los factores interrelacionados, que inciden sobre el resultado que obtiene el alumno. Este coeficiente (como sucede con todos los coeficientes de asociación) no revelan la causalidad sino lo frecuente que resulta que los cambios de una variable se vean acompañados de cambios en la otra.

Al solicitar este coeficiente a InfoStat®, se obtiene la siguiente salida, de la que solo nos interesa por ahora el valor del coeficiente, que está destacado:

Coeficientes de correlación

Correlacion de Spearman: coeficientes\probabilidades

	orden de mérito	educación de la madr
orden de mérito	1,00	0,04
educación de la madr	**0,76**	1,00

En esta salida la diagonal principal siempre estará constituida por unos (1s), porque es la asociación de cada variable consigo misma. El coeficiente aparece en la posición 2,1, como el que está aquí destacado. El valor que aparece opuesto a él, el 0,04 no será interpretado hasta más adelante.
Para ilustrar con otros ejemplos de relaciones entre variables ordinales, sea que si ponemos en correspondencia el ranking de temas musicales de una semana con la frecuencia con que cada tema es reproducido en la radio, esperamos hallar que la relación sea muy fuerte y directa: los temas de mayor posición en el ranking son también los que más frecuentemente se pasan en la radio. Al revés, en la relación entre el rating de los programas de televisión y el contenido cultural que

ofrecen esperamos una relación también fuerte, pero ahora inversa: los de mayor rating son habitualmente lo que menos contenido cultural tienen.
Este coeficiente es adecuado, no solo cuando las variables son ordinales, sino cuando son cuantitativas (intervalares o proporcionales) y existen casos atípicos, que afectarían el cálculo de otro coeficiente que se verá a continuación. Para que la interpretación del coeficiente de Spearman sea correcta, es necesario de las variables guarden entre si una relación directa o inversa, en todo su conjunto de valores, es decir, que sean monótonas crecientes o decrecientes.

Nivel intervalar o proporcional

Si tratamos con variables intervalares o proporcionales, podríamos usar los procedimientos que referimos antes para el cálculo de la intensidad de las relaciones entre variables nominales. Para ello, deberíamos construir intervalos y tratarlos como las categorías de las dos variables. De ese modo, perderíamos la información que provee una variable cuantitativa. Por ejemplo, si disponemos de un conjunto de personas adultas de las que sabemos la edad a la que cada una se casó (o unió) por primera vez y los años de escolarización, y nos interesamos por la relación entre estas dos variables, el fragmento de la matriz de datos para estas dos variables en 30 casos es:

sujeto	años escuela	edad primera unión	sujeto	años escuela	edad primera unión
1	5	18	16	11	26
2	6	20	17	11	27
3	7	17	18	11	29
4	7	18	19	12	25
5	8	21	20	12	26
6	8	22	21	12	27
7	8	24	22	12	29
8	8	32	23	12	30
9	9	16	24	12	30
10	9	18	25	13	29
11	9	19	26	15	28
12	9	25	27	16	30
13	9	27	28	16	31
14	11	18	29	16	33
15	11	25	30	17	30

Si se intenta construir una tabla de doble entrada para estas dos variables, el problema es aún mayor que con las ordinales, dado que habría un gran número de filas y de columnas, y resultaría casi imposible de leer. Además, muchas

celdas estarían vacías y habría muy pocos casos en cada una de las restantes. Los treinta datos de la matriz anterior quedarán, en una tabla de doble entrada, así:

Tabla 9: Distribución conjunta de los años de escolarización y la edad a la que se realizó la primera unión conyugal

		Edad a la primera unión																	
		16	17	18	19	20	21	22	24	25	26	27	28	29	30	31	32	33	Total
Años de escolarización	5	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
	6	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	1
	7	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2
	8	0	0	0	0	0	1	1	1	0	0	0	0	0	0	0	1	0	4
	9	1	0	1	1	0	0	0	0	1	0	1	0	0	0	0	0	0	5
	11	0	0	1	0	0	0	0	0	1	1	1	0	1	0	0	0	0	5
	12	0	0	0	0	0	0	0	0	1	1	1	0	1	2	0	0	0	6
	13	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	1
	15	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	1
	16	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0	1	3
	17	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1
	Total	1	1	4	1	1	1	1	1	3	2	3	1	3	4	1	1	1	30

Nuevamente, esta no es una tabla adecuada para representar estos datos y sería más legible con las categorías agrupadas:

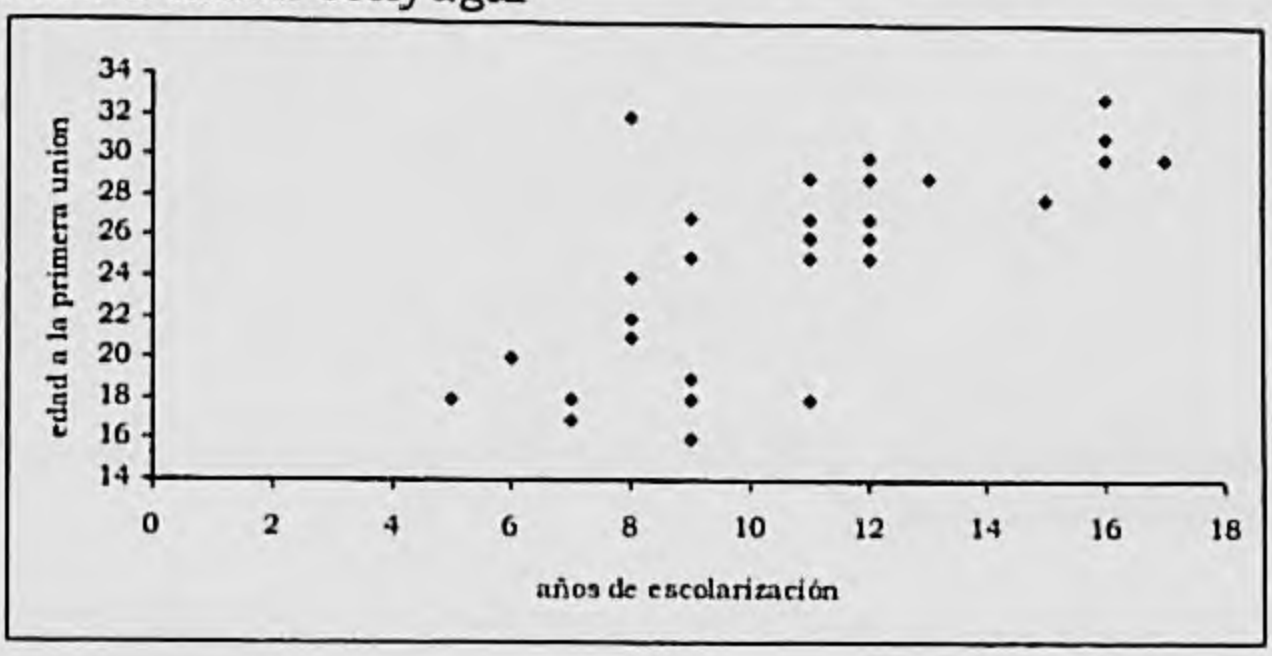
Tabla 10: Distribución conjunta de los años de escolarización y la edad a la que se realizó la primera unión conyugal (categorías agrupadas)

	Edad a la primera unión				
Años de escolarización	16-20	21-25	26-30	31-35	Total
5-8	4	3	0	1	8
9-12	4	3	9	0	16
13-16	0	0	3	2	5
17-20	0	0	1	0	1
Total	8	6	13	3	30

Ahora la tabla se lee con más facilidad y podemos tratarla como hicimos antes, como si fueran nominales y calcular un puntaje chi cuadrado y coeficientes *C de Pearson* y *V de Cramer*, o bien, como los intervalos están ordenados, poner una ranking y calcular el coeficiente de Spearman. Sin embargo, haciendo esto se trata como si tuvieran igual edad quienes tienen entre 16 y 20 años, así como a todos los que tienen entre 21 y 25 y lo mismo con los otros grupos de edades, además, se pierden las posibilidades de análisis que ofrecen las variables cuantitativas.

Para poder mantener las variables con sus verdaderos valores (sin agrupar) y tener al mismo tiempo una representación abreviada de los datos, existe un recurso muy valioso: una representación gráfica de los valores que se denomina **diagrama de dispersión.**

Gráfico 1: Diagrama de dispersión de los años de escolarización y la edad a la que se realizó la primera unión conyugal



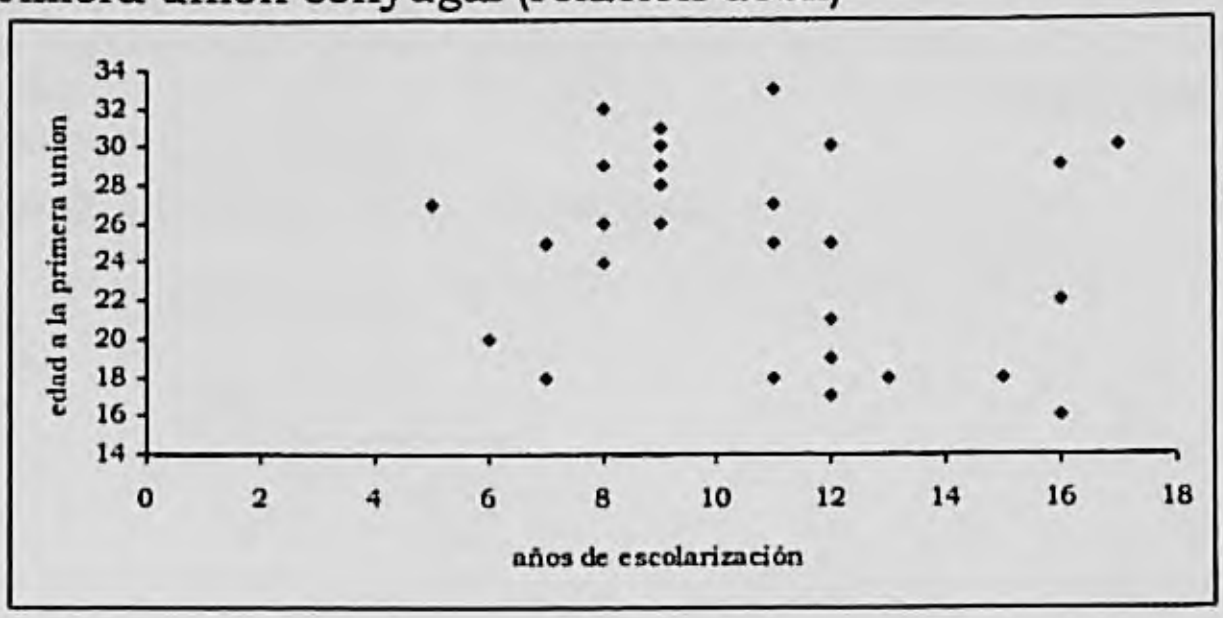
Este gráfico usa los ejes cartesianos para indicar los valores de las dos variables que estamos analizando y representa con un punto cada concordancia de dos categorías que puede corresponder a un caso o a varios. Cada punto es un par ordenado: el primer número son los años de escolarización y el segundo la edad a la que se unió por primera vez. Los ceros de la tabla 9 ya no aparecen en este diagrama. El primer punto de la izquierda del diagrama corresponde a una única persona que alcanzó 5 años de escolarización y que tuvo su primera unión a los 18 años. Observemos que los cuatro puntos alineados sobre los 8 años de escolarización, son los cuatro sujetos que aparecen como total de la fila correspondiente al 8 en la tabla 9.

Lo que eran filas y columnas en todas las tablas mostradas hasta aquí son ahora ejes coordenados, porque ya no se trata con categorías separadas de cada variable sino con valores cuantitativos de las variables que ahora son intervalares o proporcionales. Estos ejes se llaman **ordenadas** el vertical y **abscisas** el horizontal. En el ejemplo están representados los valores de los años de escolarización en el eje de las abscisas (primer elemento de cada par ordenado) y la edad a la primera unión en el eje de las ordenadas (segundo elemento de cada par).

La manera en que los puntos se distribuyen en el diagrama de dispersión nos da una primera aproximación a la relación entre las dos variables. Así, en el caso del ejemplo, hay una cierta tendencia creciente, en la que se vería que *globalmente*, las personas con más años de escolarización tenderían a unirse más tardiamente. Esta observación es equivalente a ver la concentración de casos en las celdas de la diagonal de una tabla bivariada.

Por el contrario, si los datos se dispersan de este otro modo:

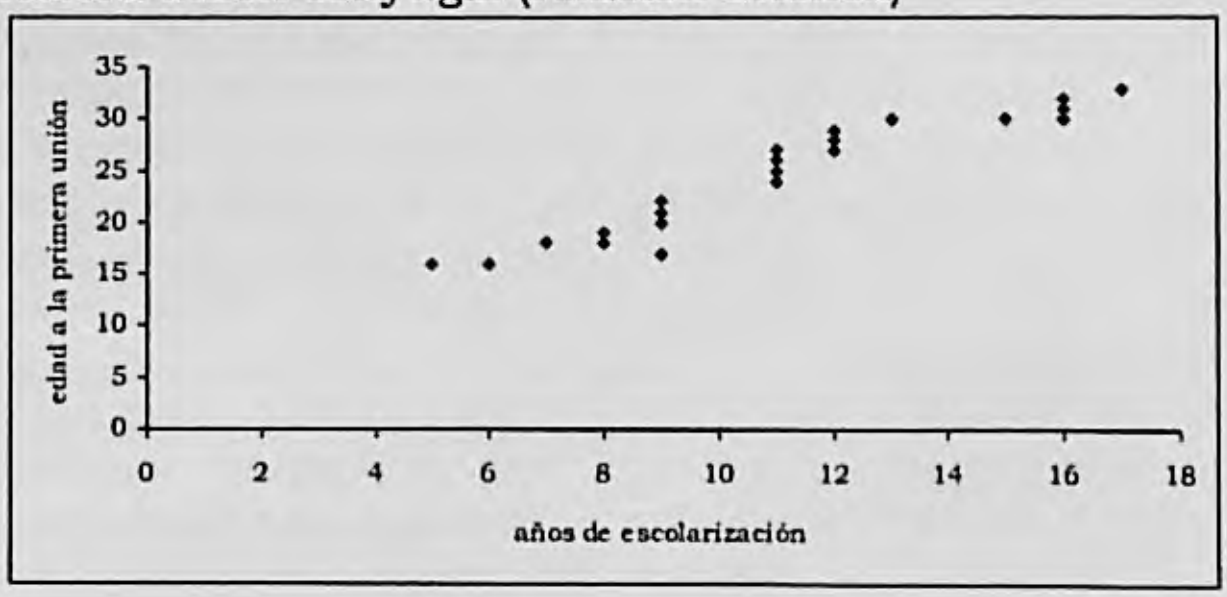
Gráfico 2: Diagrama de dispersión de los años de escolarización y la edad a la que se realizó la primera unión conyugal (relación débil)



No hay ninguna razón para creer que las variables estén relacionadas: los puntos no muestran una tendencia clara.

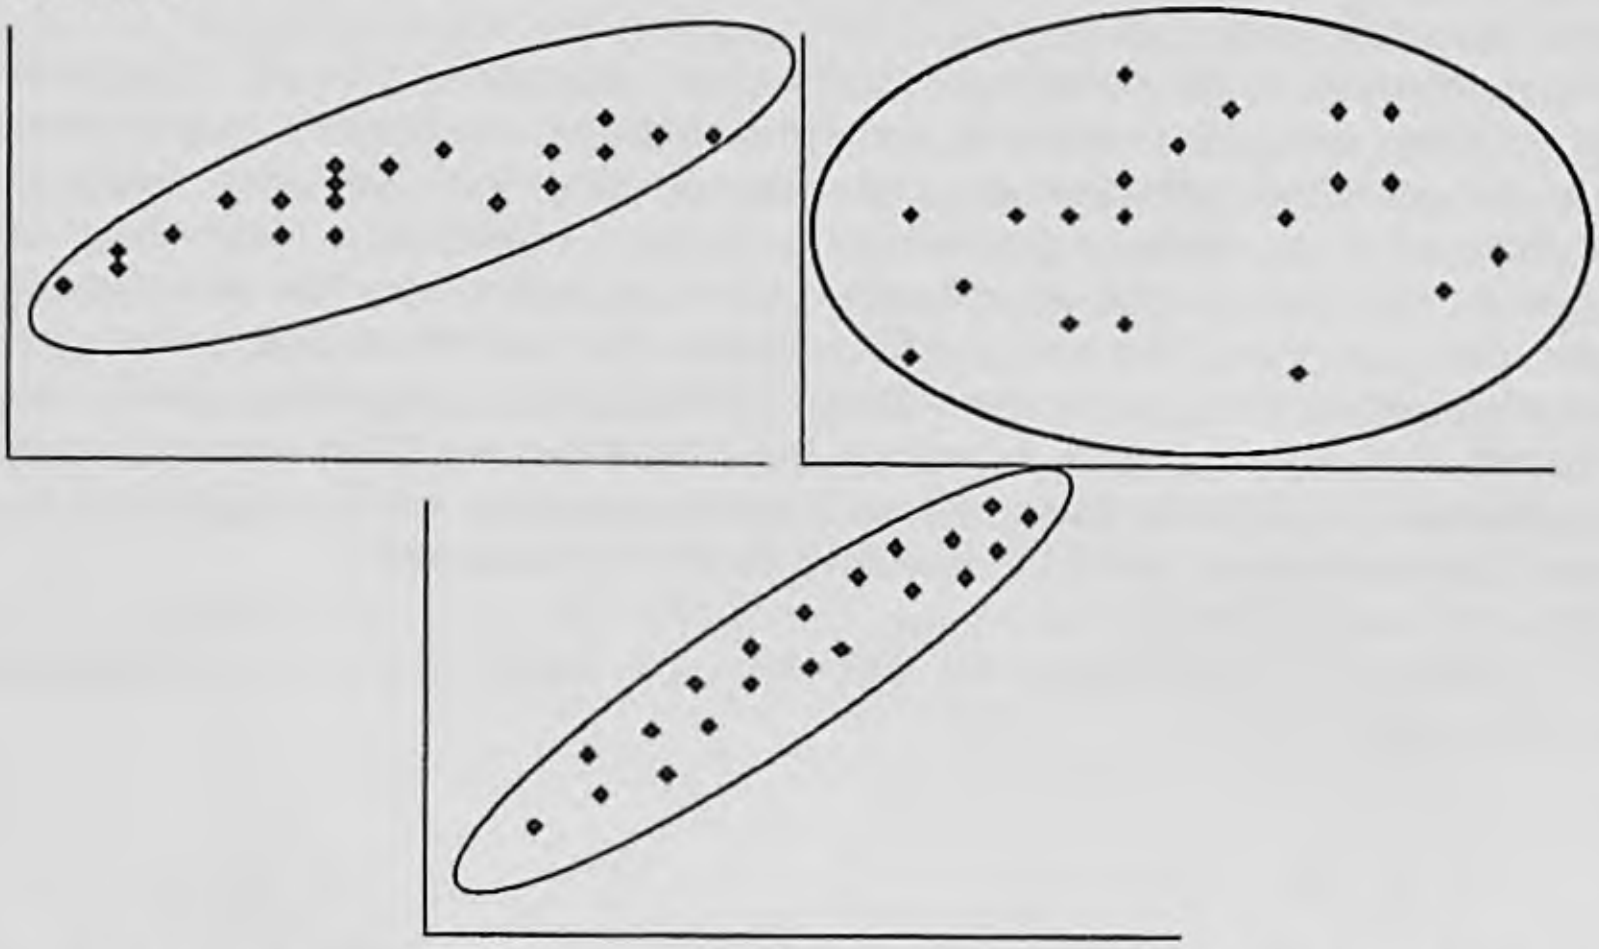
Una asociación más acentuada entre las mismas dos variables se observa en el siguiente diagrama de dispersión:

Gráfico 3: Diagrama de dispersión de los años de escolarización y la edad a la que se realizó la primera unión conyugal (relación intensa)



En el que la tendencia *lineal* es más clara, por lo que resulta más definido el efecto de la escolarización sobre la edad a la que se produce la primera unión. Aquí, la nube de puntos está más aplanada que en el ejemplo anterior; en efecto, en el gráfico 2 la nube de puntos tiene forma más circular que en el 3, donde es más elíptica.

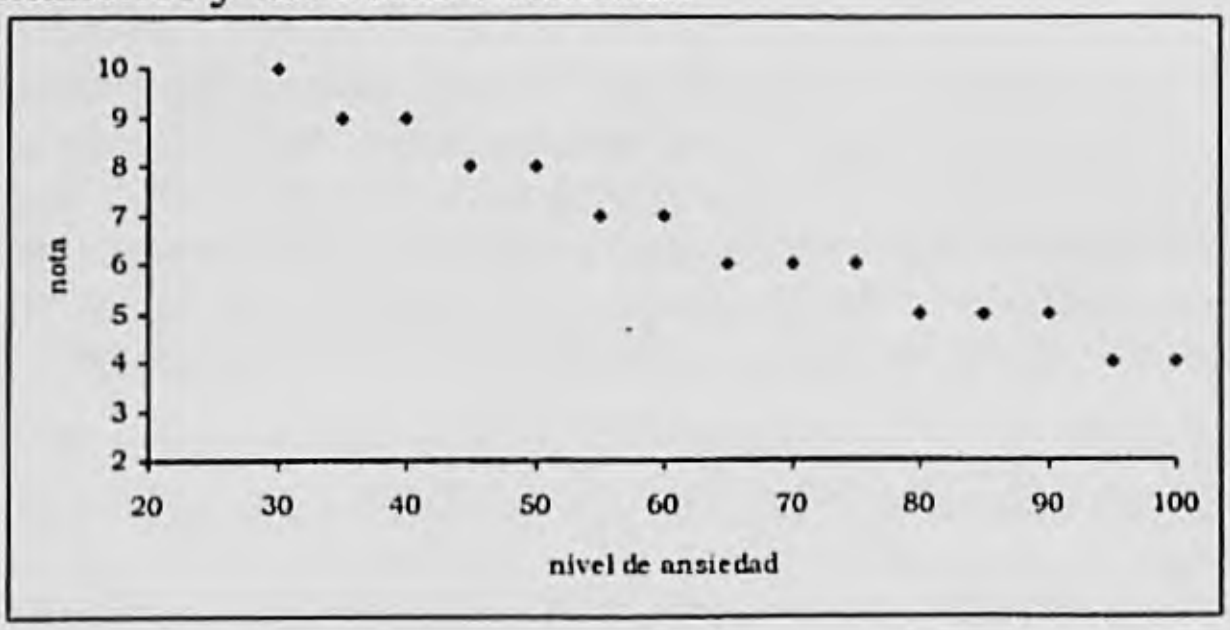
Gráfico 4: Comparación de la forma de las nubes de puntos según la intensidad de la relación



La intensidad de la relación está vinculada al achatamiento de la elipse que rodea la nube de puntos y éste al grado de alineación que los puntos tengan. Luego volveremos sobre esta idea.

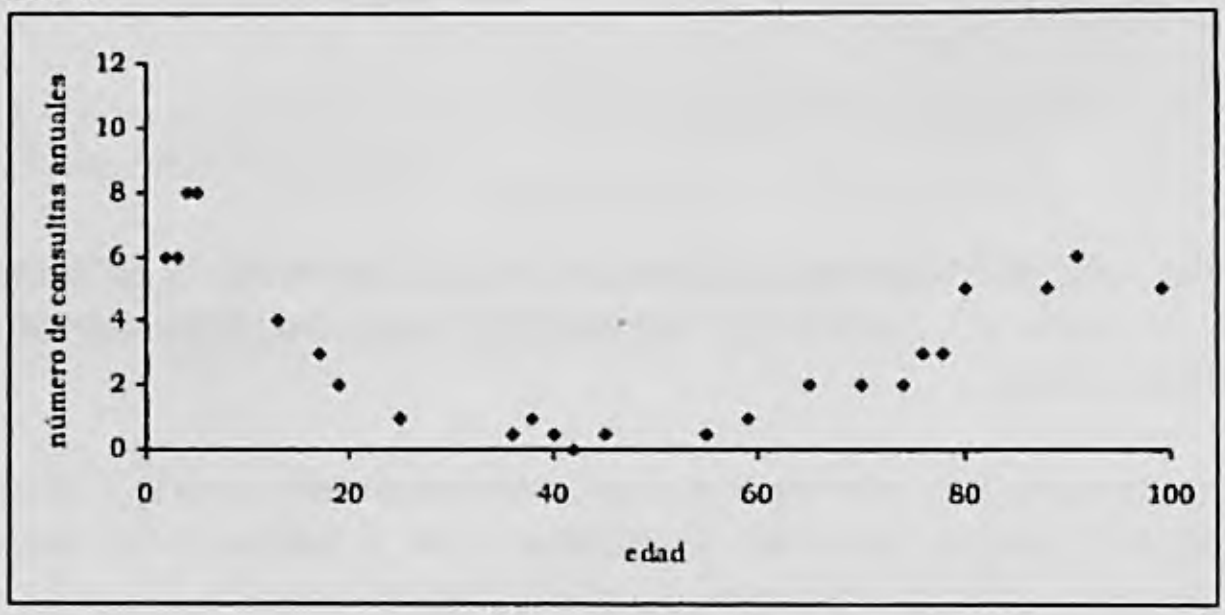
El ejemplo que hemos mostrado hasta aquí corresponde a una relación directa: más años de escolarización parecen asociarse con edades más tardías para la primera unión. De manera equivalente pueden representarse relaciones inversas. Consideremos el caso de la ansiedad frente a los exámenes y la calificación que se obtiene. En un estudio realizado por el Laboratorio de Evaluación Psicológica y Educativa (LEPE, Facultad de Psicología UNC) se observó que a mayor puntaje en una prueba de ansiedad ante los exámenes, menor rendimiento académico (Furlán, Cassady & Pérez, 2009). Tomando las notas obtenidas en un examen y el puntaje de la escala de ansiedad medido en una escala de 0 a 100, este resultado puede representarse gráficamente así:

Gráfico 5: Diagrama de dispersión del puntaje obtenido en una prueba de ansiedad en exámenes y las notas obtenidas



Que muestra que quienes llegan más ansiosos a los exámenes obtienen peores calificaciones[38]. La relación inversa queda entonces graficada como un conjunto de puntos descendentes.
Solo nos ocuparemos de relaciones como las que acabamos de ejemplificar: aquellas en las que la tendencia es creciente o decreciente, pero siempre siguiendo un camino parecido a una linea recta. Son las que llamaremos *relaciones lineales*. No son la únicas que existen; solo a modo de ilustración, veamos cómo se representa la relación entre la edad de las personas y la frecuencia con que consultan al médico. Estas dos variables son tales que, en términos muy generales y sin considerar situaciones específicas, para valores pequeños de la primera (en la infancia) las consultas son frecuentes, luego se reducen durante la adultez para volver a incrementarse en la vejez. Por eso el gráfico que las representa tiene la siguiente forma aproximada:

Gráfico 6: Diagrama de dispersión del número medio de consultas médicas anuales y la edad.



Este conjunto de puntos muestra una tendencia *no lineal*, eso no implica que las variables no estén relacionadas; por el contrario, la relación existe, pero no es lineal. Estos puntos, en lugar de ser aproximados por una linea recta, lo serian con una curva con forma de parábola. No nos ocuparemos aquí de relaciones no lineales. Limitaremos nuestro análisis a relaciones lineales, debido a que es muy frecuente usarlas como primera aproximación a la forma que tiene la relación entre dos variables y porque a menudo, cuando se trabaja con relaciones no lineales, es posible realizar transformaciones de las variables para lograr relaciones lineales.

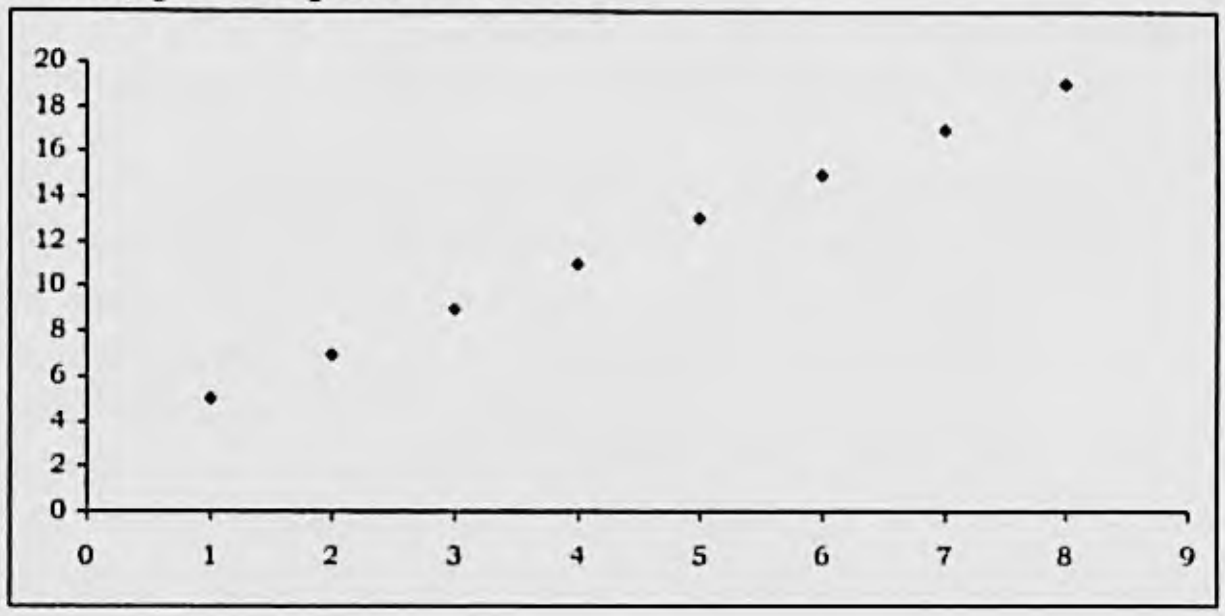
Para analizar la intensidad de la relación lineal entre dos variables (ambas medidas a nivel intervalar o proporcional) calcularemos un coeficiente comparable a los que hemos visto hasta aquí, que tendrá una interpretación similar a la del coeficiente de correlación por rangos de Spearman. Este coeficiente se llama **coeficiente de correlación r de Pearson** y es uno de los de mayor utilización cuando las variables que se analizan alcanzan el nivel de medición que autoriza

---

[38]Nuevamente aquí recordemos que esto no quiere decir causalidad, de ningún modo podemos afirmar que la ansiedad "causa" bajos resultados. Bien podria ser que los alumnos lleguen más ansiosos cuanto menos han estudiado para el examen y eso sea lo que afecta la calificación.

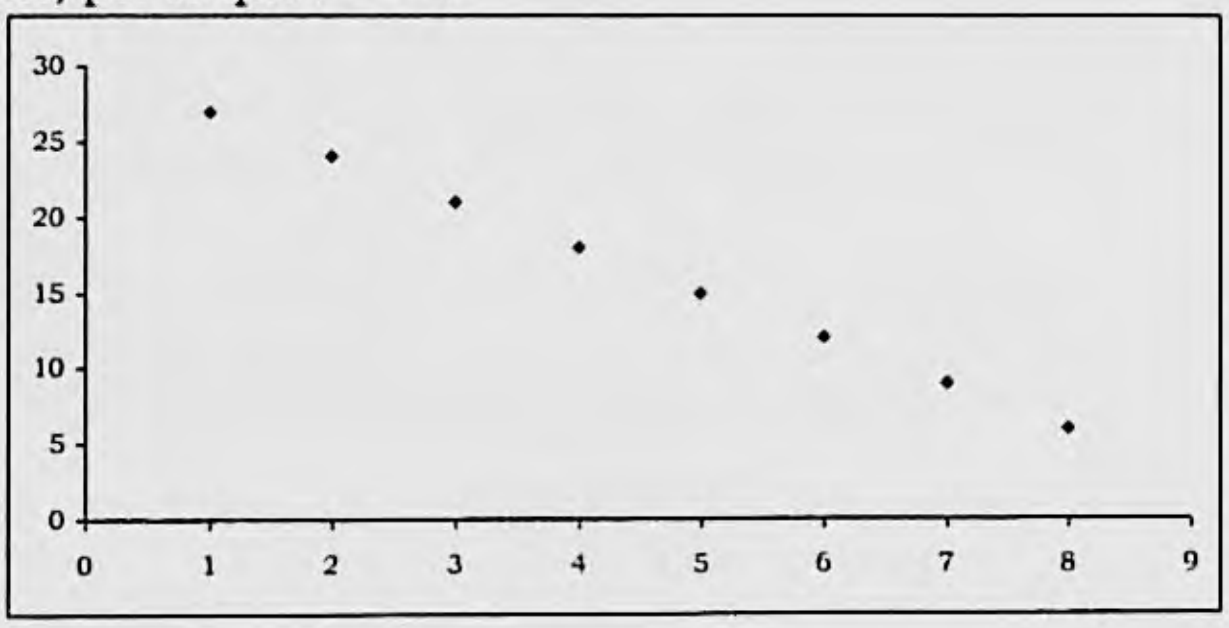
su cálculo. Este coeficiente va a medir qué tan bien se puede aproximar el conjunto de puntos con una función lineal y va a depender de lo que antes llamamos el "achatamiento" de la elipse. Será grande (próximo a 1 ó a -1) si las variables están muy relacionadas linealmente, es decir, si la nube de puntos se elonga hacia una línea; y será pequeño (próximo a cero) si las variables guardan poca relación lineal, es decir si la nube de puntos tiene forma redondeada. Será positivo y elevado (próximo a 1) si valores pequeños de una variable están acompañados de valores pequeños de la otra y valores grandes de una siguen a valores grandes de la otra, como sucedió en el ejemplo del gráfico 3. Será negativo y elevado (próximo a -1) si los valores grandes de una de las variables acompañan a los pequeños de la otra y viceversa, como en el gráfico 5. La correlación será perfecta positiva ($r = 1$) si todos los puntos se ubican sobre una recta creciente:

Gráfico 7: Ejemplo de situación ideal con todas las observaciones alineadas en una recta creciente, por lo que $r = 1$



Y será perfecta negativa ($r = -1$) si todos los puntos se ubican sobre una recta decreciente:

Gráfico 8: Ejemplo de situación ideal con todas las observaciones alineadas en una recta decreciente, por lo que $r = -1$



Ambas son situaciones ideales que no se encuentran en la realidad, constituyen el límite de la intensidad que pueden alcanzar las relaciones directas o inversas.

Las unidades en que se miden las variables que se relacionan pueden ser muy diferentes, en el ejemplo de ansiedad y resultado de los exámenes, la primera se

media en una escala de 0 a 100 y la segunda de 0 a 10, por lo que un valor elevado de la primera sería 95 y uno elevado de la segunda, 9. Esto impide que se comparen directamente los valores grandes con los grandes y los pequeños con los pequeños. Vamos a usar un recurso que ya fue presentado: las puntuaciones *z*, aquellas que indican a cuantas desviaciones estándar se encuentra cada observación de la media. Son los puntajes que permiten decidir si se trata de un valor grande (muy superior a la media) o pequeño (muy inferior a la media) o intermedio (semejante a la media), sin tener unidades, por lo que permite la comparación de elementos que pueden tener cualquier unidad de medida. Recordemos que para los valores bajos de la variable (menores a la media), el puntaje *z* es negativo y es positivo para los valores altos (superiores a la media). Si dos variables están correlacionadas positivamente (altos con altos y bajos con bajos), entonces sus puntajes *z* se corresponderán positivos con positivos y negativos con negativos. Si para cada sujeto multiplicamos los puntajes z de las dos variables que se relacionan, obtendremos siempre un resultado positivo, ya sea porque multiplicamos dos números positivos ($+\times+=+$) o dos negativos ($-\times-=+$). Si luego sumamos esos productos para todos los sujetos obtendremos un número alto positivo.

A la inversa, si dos variables se correlacionan negativamente los productos de sus puntajes z serán negativos, porque los valores altos de una irán con los bajos de la otra (que equivale a *z* positivos con *z* negativos, y $+\times-=-$) y bajos con altos (que es lo mismo que *z* negativos con *z* positivos y $-\times+=-$). Cuando sumemos estos productos para todos los casos tendremos un número alto y negativo.

Si las variables no estuvieran correlacionadas, habría casos en el que un valor alto de una variable se acompaña de uno alto de la otra y casos en que un valor alto va seguido de uno bajo, algunos productos de z serían positivos y otros negativos y entonces, al sumarlos, obtendríamos un número bajo, que puede ser positivo o negativo, pero será cercano a cero.

Entonces el producto de las puntuaciones *z* ofrece un resultado que será alto y positivo si las variables tienen una correlación alta y directa, dará alto y negativo si la correlación es inversa y dará un resultado cercano a cero si no están correlacionadas.

Haciendo uso de este razonamiento, el coeficiente de correlación de Pearson se calcula como[39]:

$$r = \frac{\sum_{i=1}^{n} z_{x_i} * z_{y_i}}{n-1}$$

Donde *z* representan los desvíos estándar de las variables *x* e *y*, *n* es el total de observaciones y los subíndices *i* corresponden a cada una de ellas. El signo de suma señala que ésta debe extenderse desde el primer caso (*i=1*) hasta el último (*n*).

Como en el caso del coeficiente de Spearman, el campo de variación del coeficiente de Pearson es el intervalo -1, 1.

---

[39]Esta expresión puede encontrarse un poco diferente en algunos manuales. Si las desviaciones estándar, que se usan para calcular los puntajes z, se calcularan con denominador *n* (como si correspondieran a observaciones provenientes de toda la población), entonces la fórmula de *r* llevaría denominador *n* también. Aquí mantenemos el modo de cálculo de la desviación estándar muestral con denominador *n-1* y por eso esta fórmula lo lleva así también.

Para el cálculo del coeficiente de Pearson, no es necesario que las dos variables tengan las mismas unidades, porque se usan los puntajes z, que carecen de unidades. No hay inconveniente en correlacionar el peso (en kilogramos) con la talla (medida en centimetros).

A continuación, se presenta un ejemplo de cómo calcular el coeficiente de correlación de Pearson para evaluar la relación entre dos variables. Las variables seleccionadas para el ejemplo son: 1) puntaje obtenido en una escala de inteligencia lógico-matemática y 2) cantidad de ejercicios correctamente realizados en una prueba de matemática. El fragmento de la matriz de datos correspondiente es el siguiente:

Sujetos	Puntaje escala inteligencia lógico-matemática X	Ejercicios correctamente realizados Y
1	46	7
2	44	2
3	56	7
4	57	8
5	30	2
6	60	9
7	45	5
8	43	1
9	64	9
10	32	3

Una vez que se ha obtenido la media y desviación estándar de las medidas del puntaje en la escala de inteligencia lógico-matemática ($\bar{x} = 47{,}7\ s_x = 11{,}44$) y de cantidad de ejercicios matemáticos correctamente realizados ($\bar{y} = 5{,}3\ s_y = 3{,}09$), se deben convertir las observaciones brutas en puntuaciones z. Para ello se calcula la diferencia entre la puntuación bruta original y la media del grupo, y el resultado de esta operación se divide por la desviación estándar del grupo. La transformación a puntaje z se obtiene como vimos antes:
Para el puntaje en inteligencia lógico – matemática (x),

$$z_x = \frac{x - \bar{x}}{s_x}$$

Para la cantidad de ejercicios correctamente realizados (y),

$$z_y = \frac{y - \bar{y}}{s_y}$$

Entonces, el puntaje z del sujeto 1 para cada escala se obtiene de la siguiente manera:

$$z_{x_1} = \frac{46 - 47{,}7}{11{,}44} = -0{,}15$$

$$z_{y_1} = \frac{7 - 5{,}3}{3{,}09} = 0{,}55$$

Y del mismo modo para cada uno de los sujetos observados, para obtener la siguiente tabla:

Sujetos	Puntaje escala inteligencia lógico-matemática z_x	Ejercicios correctamente realizados z_y	$z_x * z_y$
1	-0,15	0,55	-0,08
2	-0,32	-1,07	0,35
3	0,73	0,55	0,40
4	0,81	0,87	0,71
5	-1,55	-1,07	1,65
6	1,08	1,20	1,29
7	-0,24	-0,10	0,02
8	-0,41	-1,39	0,57
9	1,42	1,20	1,70
10	-1,37	-0,74	1,02

El numerador del coeficiente r de Pearson se obtiene sumando la última columna:

$$\sum z_x * z_y = 7{,}63$$

y solo queda dividir este número por *n-1=10-1=9* para obtener $r = 0{,}85$.
El coeficiente dio positivo, lo que indica que la relación es directa. Como se habria esperado: las personas con mayor puntaje en la escala de inteligencia lógico–matemática, son quienes tienen una mayor cantidad de ejercicios correctamente realizados.
Además, el valor 0,85 es elevado, lo que indica que la relación entre las dos variables es intensa.

Cuando esta operación se solicita a InfoStat®, se obtiene:
Coeficientes de correlación

Correlacion de Pearson: coeficientes\probabilidades

	int. Logicomatem	ejercicios bien
int. logicomatem	1,000	0,002
ejercicios bien	**0,847**	1,000

De esta salida interesa el valor del coeficiente (destacado en negrita), que aparece en la primera intersección de las dos variables que correlacionamos. Como la salida ofrece tres decimales, el resultado difiere levemente del obtenido manualmente, si se redondea a dos decimales es 0,85. El formato de la salida es el mismo que cuando se obtiene el coeficiente de Spearman, por ahora solo leemos el valor que señalamos en negrita.

La decisión acerca de considerar como grande o pequeño al valor de un coeficiente de asociación o de correlación depende del tipo de variable con que se esté trabajando y en especial de la forma en que son medidas esas variables. En buena medida, el uso de estos coeficientes es comparativo y puede ser muy valioso saber si una variable se asocia (o se correlaciona) más con una que con otra. Cuando tratamos de explicar un fenómeno y formulamos hipótesis sobre varios factores, es útil saber cuáles de ellos se asocian más intensamente con ese fenómeno.
Se han establecido algunos valores de referencia, según los cuales la correlación se considera nula si $r < 0{,}10$, pequeña si $0{,}10 \leq r < 0{,}30$, media si $0{,}30 \leq r \leq 0{,}50$ y grande si $r > 0{,}50$. Coincidimos con Cohen (1988), en que estos criterios son un tanto arbitrarios y siempre debe considerarse al coeficiente de correlación en contexto.
Para poder interpretar el coeficiente de Pearson, se requiere que las variables guarden entre sí una relación lineal, de lo contrario, la interpretación como intensidad de la relación es incorrecta. Además, este coeficiente se ve afectado por valores extremos, es decir aquellos que se apartan de la tendencia mayoritaria, por lo que si éstos existen convienen calcular el coeficiente de Spearman. Ambas situaciones, tendencia lineal o no, y existencia o no de casos atípicos pueden verse en el diagrama de dispersión.

Cuando la relación entre dos variables es lineal, el coeficiente de Pearson da una interpretación más detallada de la incidencia de una variable sobre la otra. Cuando este coeficiente se eleva al cuadrado, se obtiene un número que se llama **coeficiente general de determinación**, que se indica como R^2 y que mide la parte de la varianza que es compartida por las dos variables. Esta interpretación puede no ser clara en este momento, y volveremos sobre ella hacia el final del capítulo.
Cuando la relación es asimétrica y una variable opera como antecedente y la otra como consecuente, el coeficiente general de determinación mide la parte de la varianza de la variable consecuente que se explica por la antecedente. O bien la parte de la variabilidad de la variable dependiente que puede atribuirse a la variable independiente. Así, en nuestro ejemplo: $R^2 = 0{,}85^2 = 0{,}72$, lo podemos indicar como 72% y quiere decir que el 72% de la variabilidad total que aparece en el número de ejercicios correctamente realizados, se explica por el puntaje alcanzado en la escala de inteligencia lógico matemática. Así, con este coeficiente identificamos la magnitud del aporte que una variable hace a explicar los cambios de la otra. Los hechos que se observan obedecen a una multiplicidad factores explicativos, por esa razón es muy valioso disponer de un coeficiente como R^2, que mide qué parte de los cambios en lo observado pueden atribuirse a un determinado factor explicativo.
En el apartado siguiente volveremos sobre el coeficiente general de determinación en una aplicación más general.

Dicotomías reales y artificiales

Cuando se trabaja con variables dicotómicas, estas pueden tener dos orígenes diferentes; hay dicotomías reales y las hay artificiales. Las primeras son variables que por su construcción, solo admiten dos categorías, como turno (mañana – tarde), sexo (varón – mujer), grupo (experimental – control). Las segundas, provienen de haber recategorizado una variable continua en dos grupos, como puntaje (alto – bajo), ingresos medidos según línea de pobreza (pobre – no pobre), resultado de un examen (aprobado – no aprobado), posición política (izquierda – derecha). Esta situación es especialmente interesante en la medición de rasgos latentes a los que se considera continuos, pero que se miden de manera dicotómica. Por ejemplo, la actitud hacia la política, puede ir desde el desinterés completo hasta la participación activa, pudiendo identificarse graduaciones entre esos extremos. Si se usa la afiliación a un partido como indicador de participación, se toma una medida dicotómica (está afiliado – no está afiliado); esta dicotomización se considera artificial, porque se supone que es un punto de corte que define dos categorías en un continuo.

Cuando trata de dicotomías reales, el coeficiente φ que ya se mencionó, es adecuado. Por el contrario, en los análisis de la intensidad de la asociación entre dos variables que han sido dicotomizadas de manera artificial a partir de una variable que se considera continua, se usa una estimación del coeficiente de Pearson que habría resultado si las variables no hubieran sido dicotomizadas y hubiese entre ellas una relación lineal. El coeficiente para este caso se denomina **coeficiente de correlación tetracórica**, su cálculo requiere procedimientos matemáticos complejos, pero hay fórmulas aproximadas. Una de ellas es la siguiente

$$r_{tet} = \cos\left(\frac{\pi}{1+\sqrt{\frac{a \cdot d}{b \cdot c}}}\right)$$

En la que a, b, c y d son las frecuencias absolutas de una tabla de 2x2 dispuestas así:

a	b
c	d

El resultado de r_{tet} puede variar entre -1 y 1, los valores más cercanos a 1 o a -1 indican mayor intensidad en la asociación. Respecto del signo, es más claro no considerarlo en el coeficiente y observar en qué sentido se da la relación a partir de las frecuencias relativas calculadas en la tabla.

Ejemplo (datos reales): para analizar la relación entre los puntajes en las subescalas mental y motora de la prueba de Bayley, se dicotomizan las dos variables en la media, asignando el valor 0 a quienes tienen puntajes inferiores a la media en cada subescala y uno a quienes superan a la media. Resulta así la tabla:

subescala motora	subescala mental		
	0	1	total
0	139	102	241
1	102	200	302
total	241	302	543

El cálculo del coeficiente de correlación tetracórico para esa tabla es:

$$r_{tet} = \cos\left(\frac{\pi}{1+\sqrt{\frac{139*200}{102*102}}}\right) = \cos\left(\frac{\pi}{2.63}\right) = 0{,}37$$

Que indica una correlación moderada entre las variables. Como en este caso si se dispone de los valores originales y la dicotomización se hizo a fines de ilustración, es posible calcularlo, su valor es 0,35. Pero si solo se hubiese contado con la dicotomia, el tetracórico es el único que puede calcularse.
El coeficiente de Kendall – Yule es otra aproximación al coeficiente tetracórico. En este caso da 0,45, que es de peor calidad que la que se obtiene con la expresión anterior.
Esta fórmula es aproximada, el cálculo exacto no puede hacerse manualmente, por lo que hay que usar programas informáticos. Infostat® no lo tiene entre las opciones. Si se usa R (2017), allí se cuenta con la función *tetrachoric* en el paquete *psych* (Revelle, 2017). El resultado que se obtiene con él es también 0,37, lo que indica que la fórmula provee una buena aproximación. También puede solicitarse a ViSta, por medio del plugin ViSta-Tetrachor (Ledesma, Macbeth, & Valero-Mora, 2011).

Niveles de medición combinados

Debido a que las operaciones que pueden hacerse a un nivel de medición son también válidas para los niveles superiores, pero no a la inversa; cada vez que haya variables con niveles de medición diferente, habrá que tener en cuenta el nivel más bajo para decidir qué coeficiente corresponde usar. Por ejemplo, la correlación entre una variable ordinal y una continua debe hacerse con el coeficiente de Spearman, porque las operaciones que este requiere se puede realizar tanto con variables ordinales como con continuas. Por el contrario, el coeficiente de Pearson requiere operaciones que no son válidas cunado la variable es ordinal.
Sin embargo, hay algunos casos particulares que merecen mención.

Una variable dicotómica real y una proporcional

La comparación de los valores de una variable continua entre dos grupos se trata como la correlación entre una variable dicotómica real (que define los grupos) y una continua. Allí, los grupos se codifican como cero y uno, y se calcula el coeficiente de Pearson entre las dos variables.
Sin embargo, para esta situación existe un coeficiente especifico, que se denomina **punto biserial** (r_{pb}). Su fórmula de cálculo conduce al mismo resultado que el coeficiente de Pearson, pero tiene en cuenta las medias de la variable continua y la proporción de casos en cada grupo, junto con la desviación estándar de la variable continua:

$$r_{pb} = \frac{\bar{x}_1 - \bar{x}_0}{s} * \sqrt{p * (1-p) * \frac{n}{n-1}}$$

Donde:
$\bar{x}_1$ Es la media de la variable en el grupo codificado como uno

$\bar{x}_0$ Es la media de la variable en el grupo codificado como cero
p Es la proporción de casos que hay en grupo codificado como uno
n Es el número total de observaciones y
s Es la desviación estándar de la variable continua
El signo de este coeficiente indica el sentido de la diferencia; es positivo cuando el grupo codificado como uno tiene valores más altos y negativo en el caso contrario. Su valor absoluto mide la magnitud de la relación entre las dos variables. Infostat® carece de un comando para solicitar este coeficiente, por lo que deben codificarse las categorías de la variable dicotómica como cero y uno y solicitar el coeficiente de Pearson.
Ejemplo (datos ficticios): se comparan los puntajes alcanzados en una prueba por los individuos pertenecientes a los grupos experimental y control, y se obtienen estos valores:

grupo	puntaje
control	8
control	5
control	6
control	5
control	6
control	8
control	6
experimental	4
experimental	5,6
experimental	5,6
experimental	8
experimental	7,2
experimental	6,4
experimental	7,2
experimental	8
experimental	8
experimental	7,2

Se toma como grupo de referencia (grupo 1) al experimental y resulta:
$\bar{x}_1 = 6.7$
$\bar{x}_0 = 6.3$
$p = 0.59$
$n = 17$
$s = 1.27$
La fórmula da:

$$r_{pb} = \frac{6.7 - 6.3}{1.27} * \sqrt{0.59 * (1 - 0.59) * \frac{17}{17 - 1}} = 0.1734$$

Que sea positivo indica que el grupo al que se codificó uno (el experimental) tiene puntajes medios más altos. Su valor absoluto señala una correlación pequeña entre la pertenencia a los grupos y los puntajes de la prueba.

De manera equivalente, puede pedirse a Infostat®, codificando la variable *grupo*.

grupo	codigo.grupo	puntaje
control	0	8,00
control	0	5,00
control	0	6,00
control	0	5,00
control	0	6,00
control	0	8,00
control	0	6,00
experimental	1	4,00
experimental	1	5,60
experimental	1	5,60
experimental	1	8,00
experimental	1	7,20
experimental	1	6,40
experimental	1	7,20
experimental	1	8,00
experimental	1	8,00
experimental	1	7,20

Y se solicita el coeficiente r se Pearson, el resultado es:

Correlación de Pearson

Variable(1)	Variable(2)	n	Pearson	p-valor
codigo.grupo	puntaje	17	0,17343	0,5056

Que coincide con el que se obtuvo con la fórmula especifica del coeficiente punto biserial.

Una variable continua dicotomizada y una proporcional

Si la variable dicotómica proviene de la recategorización de una continua que se dividió en dos categorías, es decir, si la dicotomia es artificial y se supone que hay una variable latente continua, entonces el coeficiente que corresponde calcular es el llamado **biserial** r_b. Como sucedió con el coeficiente de correlación tetracórico, se trata de una estimación del valor que tendría el coeficiente de Pearson si la variable no hubiese sido dicotomizada.

$$r_b = \frac{\bar{x}_1 - \bar{x}_0}{s} * \frac{p * (1-p)}{y}$$

Con la misma notación que se usó para el coeficiente r_{pb}. Lo diferente es la y en el denominador, cuyo cálculo depende de la distribución normal, que se verá más adelante[40].

Resumen de coeficientes de asociación

Nivel de medición de las variables		Coeficiente	Rango de variación	Lectura
Ambas dicotómicas	reales	φ (phi) de Yule	[-1; 1]	No importa el signo, la relación es fuerte si es cercano a 1 ó a -1 y débil si está cerca de 0
	provenientes de dos continuas recategorizadas	tetracórico r_{tet} o bien Q de Kendall – Yule		
Ambas nominales		de contingencia, C	[0, C_{max}] depende de la dimensión de la tabla	Más intensa si es próximo a C_{max}
		V de Cramer	[0; 1]	Más intensa si es próximo a 1
Ambas ordinales o una ordinal y una proporcional		r_s de Spearman	[-1; 1]	El signo indica la dirección, positivo es directa, negativo es inversa. Fuerte si es cercano a 1 ó a -1 y débil si está cerca de 0
Ambas proporcionales		r de Pearson		
Una dicotómica real y una proporcional		r_{pb} Punto biserial	[-1; 1]	Más intensa si es próximo a 1 o a -1
Una dicotómica proveniente de una continua recategorizada y otra proporcional		r_b biserial		

[40] Es la ordenada correspondiente a un valor de z que deja a derecha e izquierda, en una distribución normal, proporciones del área bajo la curva iguales a p y 1-p respectivamente.

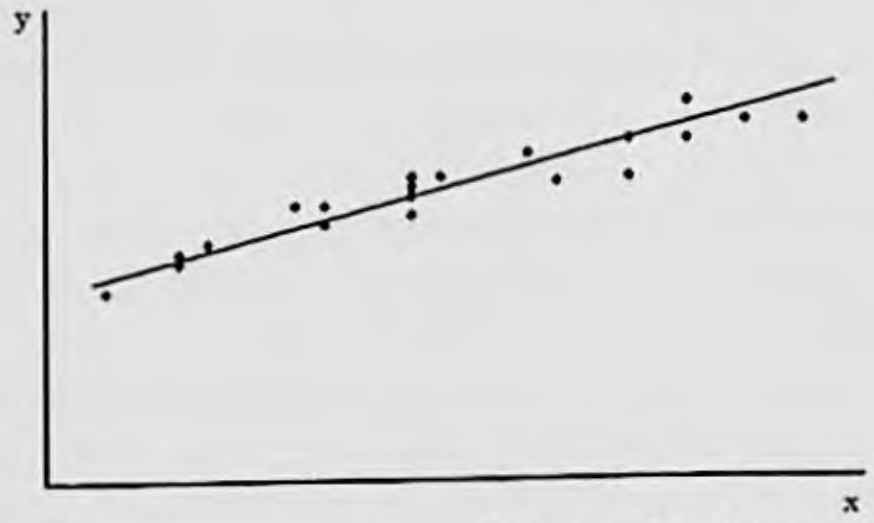
La forma de la relación

En este capítulo hemos trabajado con los coeficientes que miden la intensidad de la relación entre dos variables pero no hemos hecho referencia a la simetría o asimetría de la relación. No nos preocupamos por distinguir si una variable explica a otra o si se trata de variación conjunta, salvo la breve referencia a R^2 al final del apartado anterior. Ahora nos concentraremos en relaciones asimétricas: aquellas en las que es posible identificar a una de las variables como antecedente y a la otra como consecuente (o como independiente y dependiente, en el contexto del diseño experimental). Se trata de relaciones que se dirigen a explicar una variable (la consecuente) a partir de los valores de la otra (la antecedente). Por ejemplo, cuando preguntamos si una droga es efectiva para tratar la depresión, buscamos la relación entre las diferentes dosis de la droga y la reducción de síntomas de la depresión, por ejemplo a través del puntaje alcanzado en una prueba que la evalúa. O también, si preguntamos por el efecto del nivel de ansiedad (variable antecedente) sobre los resultados que se obtienen en un examen (variable consecuente, a explicar), o el impacto de la cobertura de una campaña de vacunación (variable antecedente) sobre la frecuencia de casos de gripe.

Cuando las variables tienen nivel de medición proporcional, es posible representar la relación con un diagrama de dispersión y, como hemos visto, cuanto más intensa es la relación (coeficiente de correlación de Pearson cercano a 1), tanto más se aplana la nube de puntos, yendo hacia una tendencia lineal, aproximándose a una alineación a lo largo de una recta.

En este apartado avanzamos un paso más en el análisis de la relación entre variables: cuando los puntos del diagrama de dispersión tengan una disposición semejante a una recta (creciente, como en el gráfico 3 o decreciente, como en el 5), podremos buscar la función lineal que mejor aproxima esos puntos. Usaremos a partir de aquí una notación general: llamaremos x a la variable antecedente (o independiente) e y a la consecuente (o dependiente). Porque la relación se supone asimétrica, esperamos que x tenga efectos sobre y (la dosis de droga sobre la depresión, o la ansiedad sobre los resultados del examen, la cobertura de la campaña de vacunación sobre la prevalencia de gripe, en los ejemplos mencionados). Se trata de modelar la nube de puntos a través de una recta, como en el gráfico siguiente:

Gráfico 9: Ejemplo de función lineal que aproxima los puntos con una tendencia creciente



Aquí, la recta que aproxima los puntos está trazada de modo que equilibre lo que los puntos se apartan de ella por encima y por debajo. La búsqueda de esa función lineal implica proponer un **modelo** para la forma de la relación entre las

dos variables, veremos cuán realista resulta suponer que las dos variables se relacionan de manera lineal. Antes de eso será necesaria una breve referencia a esta función.
La **función lineal** tiene una expresión matemática como la siguiente $y = b_0 + b_1 * x$ en la que x e y son las variables cuya relación analizamos y los números b_0 y b_1 son valores fijos que determinan cuál es la recta de la que hablamos. Hallar la recta implica encontrar esos dos números b_0 y b_1. Una vez que están determinados, se conoce la recta y se la puede trazar.

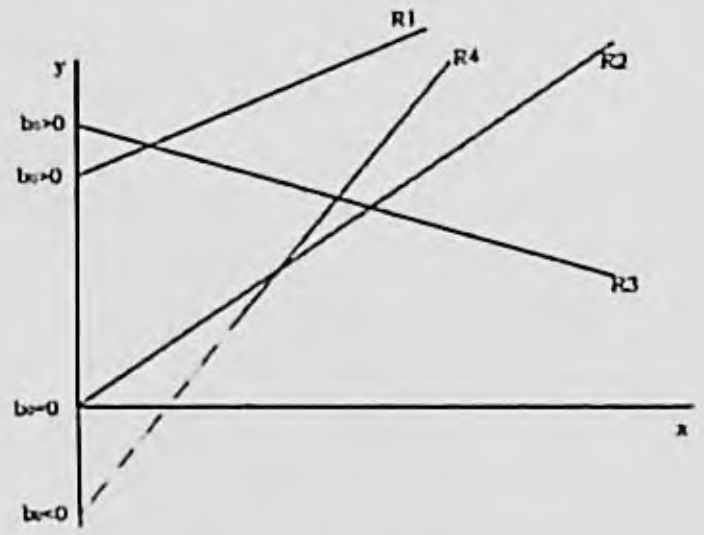
Ordenada al origen

El número b_o se llama ordenada al origen y representa el valor de y cuando x vale cero. Eso puede verse fácilmente en la expresión de la recta cuando se reemplaza a x por cero, así se obtiene:

$$y = b_0 + b_1 * x = b_0 + b_1 * 0 = b_0$$

Entonces, si $x = 0$, tendremos $y = b_0$. Como los ejes tienen el cero en el punto en que se cortan, gráficamente esta ordenada al origen se ubica sobre el eje y (por ser una ordenada), como indican las diferentes rectas en el gráfico siguiente.

Gráfico 10: Ejemplos de funciones lineales con diferentes valores de la ordenada al origen



Las rectas R1 y R3 tienen ordenada al origen positiva ($b_0 > 0$). La ordenada al origen de R3 es mayor que la de R1, porque su b_0 está más arriba en el eje de ordenadas. A los efectos de la ordenada al origen, no hay ninguna diferencia en que R1 vaya subiendo y R3 baje.
La recta R2 pasa exactamente por el origen de coordenadas, por lo que su ordenada al origen es cero, $b_0 = 0$.
La recta R4 ha sido prolongada para llegar a cortar al eje de ordenadas y lo hace en un valor negativo ($b_0 < 0$).

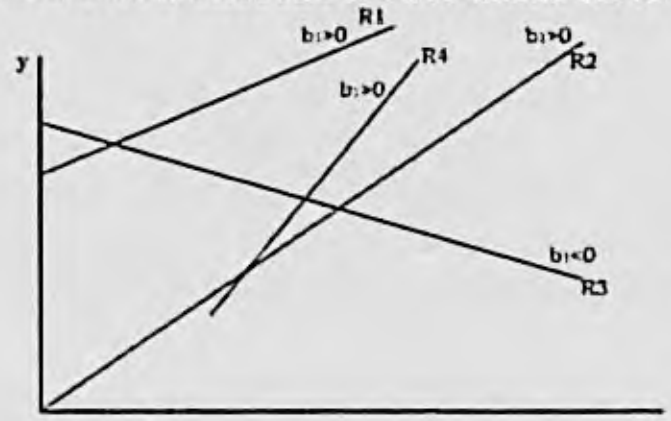
Según las variables con que se trabaje, a veces b_0 no tiene interés, porque no se consideran los valores negativos o bien porque no tiene sentido que la variable antecedente sea cero ($x=0$).
En los ejemplos que hemos mencionado hay diferentes situaciones con respecto al valor de b_0. En la relación *dosis droga–depresión*, el valor cero para la dosis es la no-administración de la misma. Aquellos sujetos que tienen $x = 0$ son quienes no recibieron la droga y la ordenada al origen será el valor que hallemos en la escala de depresión (variable y) para quienes no tomaron la droga (a dosis cero).

Por el contrario, no es posible considerar un valor cero de la ansiedad en el segundo ejemplo, por lo que allí no nos interesamos por la ordenada al origen.

Pendiente

El otro número que determina de qué función lineal se trata, es b_1 que se llama pendiente y gráficamente indica la inclinación de la recta: su valor es responsable de que la recta "suba" o "baje", siempre mirándola de izquierda a derecha.

Gráfico 11: Ejemplos de funciones lineales con diferentes valores de la pendiente



Las rectas R1, R2 y R4 son crecientes, van aumentando hacia la derecha (a medida que x crece), por eso la pendiente es positiva ($b_1 > 0$).
La recta R3 desciende, es una función decreciente, porque a medida que x aumenta y disminuye y la pendiente es negativa ($b_1 < 0$).
Vemos entonces que la pendiente depende de que sea una relación directa o inversa. Cuando es directa, x crece e y crece y la pendiente es positiva; cuando es inversa, x crece e y disminuye y la pendiente es negativa. Esto es lo mismo que sucede con el coeficiente de Pearson: positivo indica relación directa y negativo, inversa. Por esta razón, b_1 (la pendiente de la recta) siempre tiene el mismo signo de r, porque en ambos casos el signo indica si se trata de una relación directa o inversa.

Además del gráfico, el significado analítico de la pendiente es muy importante, porque indica en cuánto varía y por cada unidad que aumenta x. El número b_1 mide cuánto cambia la variable consecuente (dependiente), cuando la variable antecedente (independiente) cambia en una unidad. Como b_1 puede ser positivo o negativo, el cambio en y puede ser en dirección de aumentar cuando x aumenta o de reducirse. En el ejemplo de la relación *dosis droga-depresión*, se esperaría que el valor de b_1 fuera negativo, porque mide en cuánto se reduce la depresión (medida con el puntaje correspondiente a la escala que se use) por cada unidad que se aumente la dosis. Del mismo modo con la *ansiedad* y el *resultado del examen*, se espera que los sujetos con mayor ansiedad alcancen resultados menores en el examen, por lo que la relación se espera que sea inversa, con pendiente negativa y que la recta sea decreciente.
Por el contrario, si observamos la relación entre las *horas dedicadas al estudio*—como variable antecedente— y el *resultado del examen*—como consecuente—, esperaríamos una relación directa, una pendiente positiva ($b_1 > 0$), una recta creciente que indica cómo aumenta el resultado del examen a medida que se dedican más horas al estudio.

Obtención de la recta de regresión

Para encontrar b_0 y b_1 y determinar así la función lineal que corresponde a nuestra recta de regresión, deben usarse los puntos del diagrama, es decir los pares ordenados correspondientes a cada caso. Para hacerlo usaremos las fórmulas que mostramos a continuación pero, como antes solo será para ver el modo de usarlas, luego lo pediremos a InfoStat®. Llamando x_i e y_i a cada valor de cada par ordenado y n al número total de observaciones, la expresión para calcular la pendiente de la recta es:

$$b_1 = \frac{n * \sum_{i=1}^{n} x_i * y_i - (\sum_{i=1}^{n} x_i) * (\sum_{i=1}^{n} y_i)}{n * \sum_{i=1}^{n} x_i^2 - (\sum_{i=1}^{n} x_i)^2}$$

Una vez que conocemos la pendiente, se puede hallar la ordenada al origen haciendo:

$$b_0 = \bar{y} - b_1 * \bar{x}$$

Donde $\bar{x}$ e $\bar{y}$ son las medias de x y de y respectivamente.

Vamos a aplicar estas expresiones para encontrar la función lineal que mejor ajusta los puntos del ejemplo en el que relacionamos el *puntaje en la escala de inteligencia lógico-matemática* con el *número de ejercicios correctamente realizados.* Tratamos de manera asimétrica a esta relación y tomamos al puntaje de la escala de inteligencia lógico-matemática como antecedente (x) y al número de aciertos como consecuente (y). Es decir que en nuestro modelo estamos tratando de explicar el *número de aciertos* a partir del *puntaje en la escala de inteligencia lógico-matemática.*

Para facilitar el uso de la expresión del cálculo de la pendiente, agregamos dos columnas adicionales a los valores de las dos variables: la de los productos de cada x por cada y, y la de las x al cuadrado, del siguiente modo:

	x_i	y_i	$x_i * y_i$	x_i^2
	46	7	322	2116
	44	2	88	1936
	56	7	392	3136
	57	8	456	3249
	30	2	60	900
	60	9	540	3600
	45	5	225	2025
	43	1	43	1849
	64	9	576	4096
	32	3	96	1024
Sumas de las columnas	477	53	2798	23931

Tenemos entonces

$$\sum_{i=1}^{10} x_i = 477,\ \sum_{i=1}^{10} y_i = 53,\ \sum_{i=1}^{10} x_i * y_i = 2798,\ \sum_{i=1}^{10} x_i^2 = 23931$$

Reemplazando, obtenemos la pendiente de la recta:

Ahora $b_1 = \dfrac{n*\sum_{i=1}^{n} x_i * y_i - (\sum_{i=1}^{n} x_i)*(\sum_{i=1}^{n} y_i)}{n*\sum_{i=1}^{n} x_i^2 - (\sum_{i=1}^{n} x_i)^2} = \dfrac{10*2798-477*53}{10*23931-477^2} = \dfrac{2699}{11781} = 0,23$

Esta pendiente es positiva, como lo había sido r, y eso indica que la relación es directa. La pendiente además nos informa que por cada punto adicional en la variable antecedente (puntaje escala inteligencia lógico-matemática) se espera que se incremente en 0,23 el número de ejercicios bien resueltos.

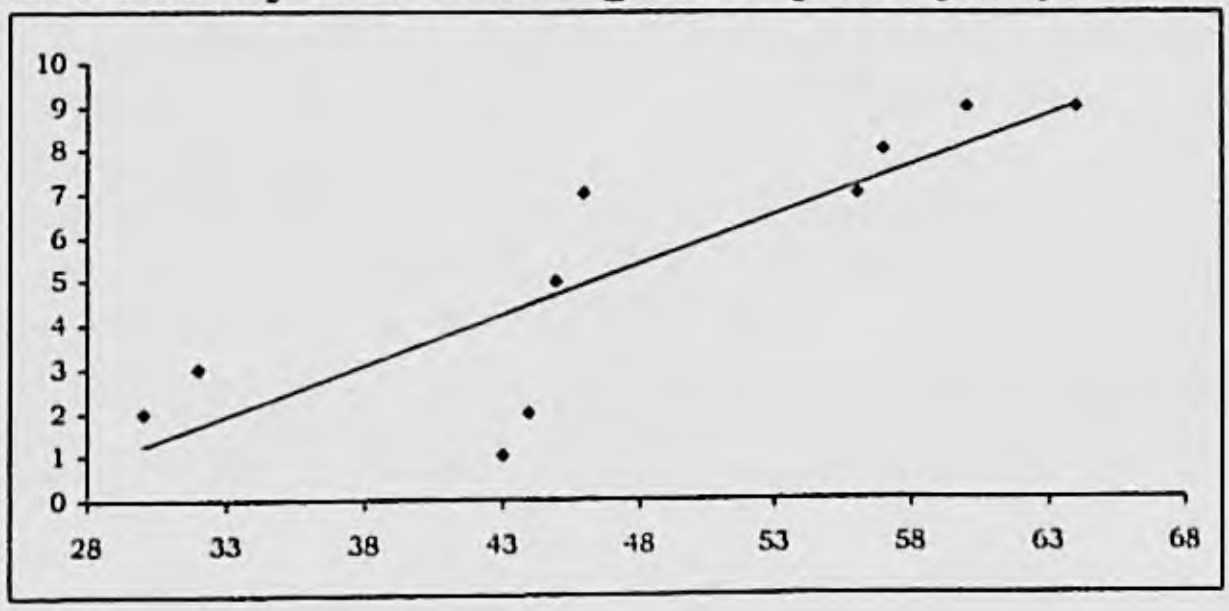
Las medias de x y de y habian sido calculadas cuando las necesitamos para r: $\bar{x} = 47,7$ e $\bar{y} = 5,3$ por lo que la ordenada al origen de la recta es:

$$b_0 = \bar{y} - b_1 * \bar{x} = 5,3 - 0,23 * 47,7 = -5,63$$

El valor de la ordenada al origen no tiene interés en este ejemplo —salvo para el trazado de la recta—, porque seria el número de aciertos esperado (que resultan negativos, es decir sin interpretación posible) para alguien con inteligencia cero, lo cual no está definido.

Conociendo la pendiente y la ordenada al origen, podemos escribir la ecuación de la recta: $\hat{y} = -5,63 + 0,23 * x$. Esta es la función lineal que describe los cambios de y a partir de los de x. Hemos escrito a y con una indicación especial, un circunflejo:$\hat{y}$, vamos a llamarla "y estimada" y es la que vamos a usar para trazar la recta:

Gráfico 12: Diagrama de dispersión de la relación entre el puntaje en la escala de inteligencia lógico-matemática y el número de ejercicios de matemática correctamente realizados y la recta de regresión que mejor ajusta los puntos



La recta que hemos encontrado usando las fórmulas de arriba es la que hace mínimos los cuadrados de las distancias de cada punto a la recta[41], por eso, a esta también se la llama **recta de mínimos cuadrados**.

Para hacer esta operación con InfoStat® (ver el video *regresión*) hay que tener en cuenta que a las variables las llama "dependiente" a la consecuente (y) y "regresora" a la antecedente (x).

El formato de la salida es el siguiente:

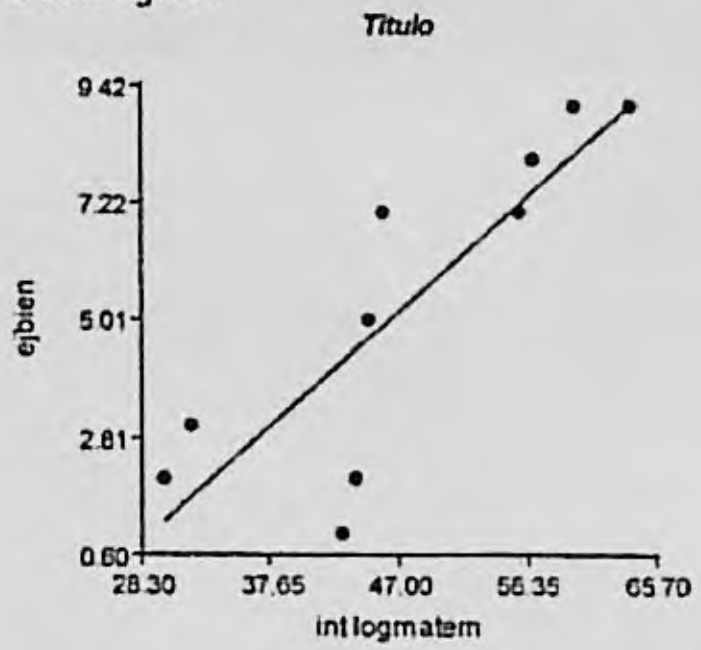
Análisis de regresión lineal

Variable	N	R^2	R^2 Aj	ECMP	AIC	BIC
ejbien	**10**	**0.72**	0.68	4.17	43.24	44.15

Coeficientes de regresión y estadísticos asociados

Coef	Est.	E.E.	LI(95%	LS(95%)	T	p-valor	CpMallows
Const	**-5.63**	2.48	-11.35	0.10	-2.27	0.0531	
Intlogmatem	**0.23**	0.05	0.11	0.35	4.51	0.0020	19.23

En esta salida tenemos dos partes. De la primera consideraremos por ahora: el número de observaciones *N=10*, y el coeficiente general de determinación $R^2=0,72$, al que ya habíamos calculado antes como cuadrado del coeficiente de Pearson.
De la segunda parte nos interesan los números -5,63 y 0,23. El primero está identificado como "constante", y es la ordenada al origen: b_0. El segundo, indicado como *intlogmatem* (el nombre de la variable antecedente), es la pendiente de la recta: b_1.
El gráfico que produce InfoStat® es el siguiente, que permite editarse para colocar título y rótulos diferentes a los ejes.



Además de mostrarnos la forma del modelo, la recta de regresión sirve para hacer estimaciones de valores no observados, porque nos ofrece valores de $\hat{y}$[42] para cada

[41]No es posible poner como condición que la recta haga mínimas las distancias porque hay puntos por encima y por debajo, por lo que la suma de las distancias se hace cero (igual a lo que sucedió con la suma de los desvíos alrededor de la media y que llevó a usar sus cuadrados para definir la varianza). Por esa razón se usan los cuadrados de las distancias.