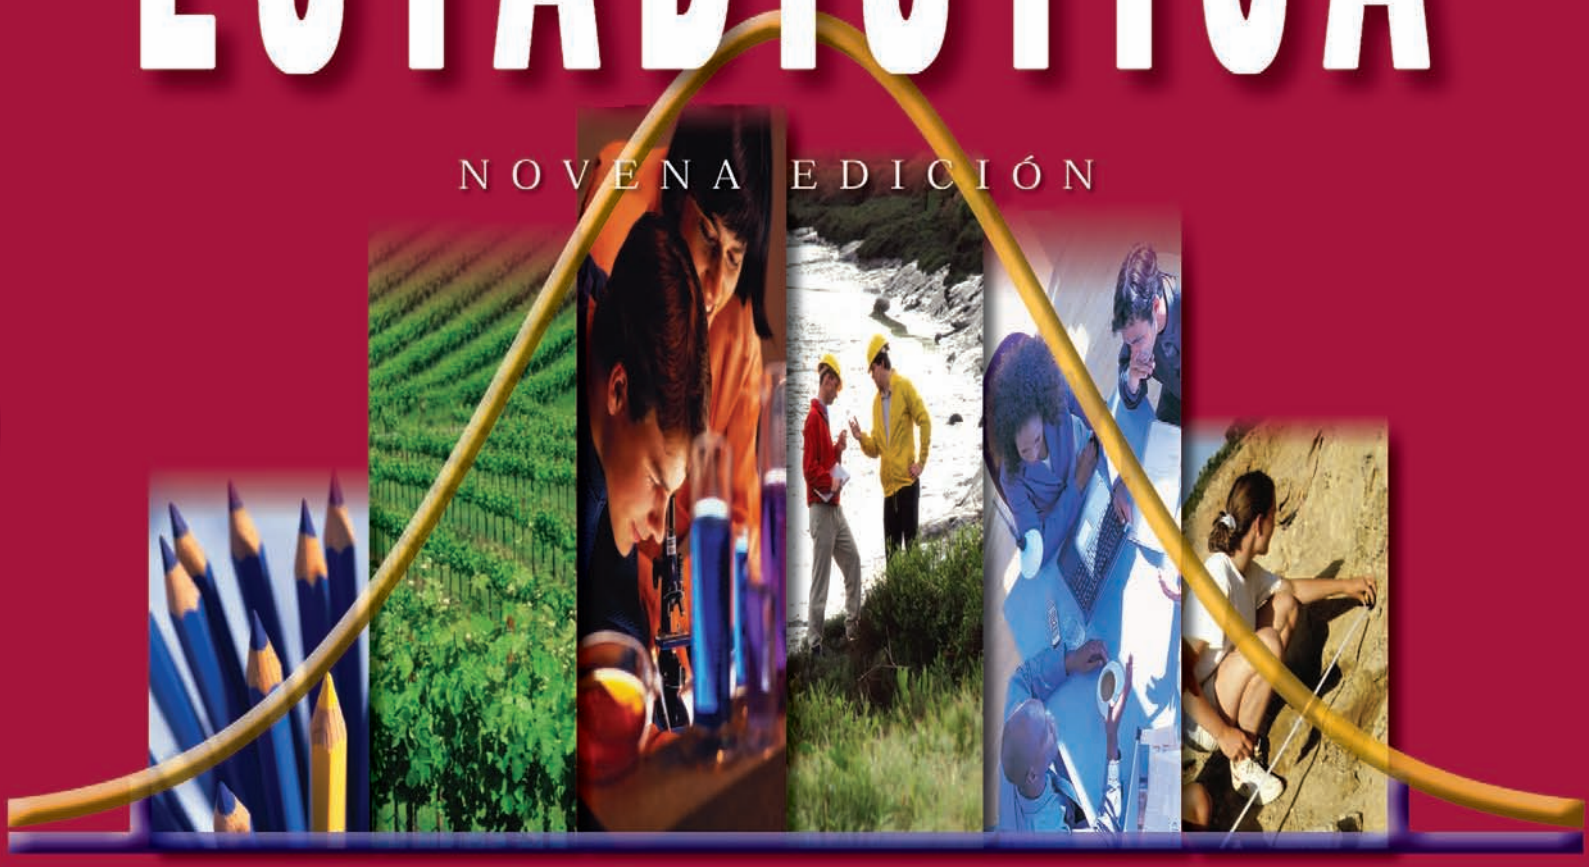
ESTADÍSTICA

NOVENA EDICIÓN



MARIO F. TRIOLA

PEARSON
Addison Wesley®

INCLUYE CD-ROM

9



Correlación y regresión

9-1 Panorama general

9-2 Correlación

9-3 Regresión

9-4 Variación e intervalos de predicción

9-5 Regresión múltiple

9-6 Elaboración de modelos

PROBLEMA DEL CAPÍTULO

¿Deberían imponerse restricciones a la navegación de barcos para reducir las muertes de manatíes?

Los manatíes, también llamados "vacas marinas", son grandes mamíferos que viven bajo el agua, con frecuencia cerca de rutas marinas con un gran tráfico de embarcaciones. En Florida, las muertes de manatíes por encuentros con barcos han sido motivo de gran controversia entre ambientalistas y operadores de embarcaciones. Recientemente, Andrew Revkin escribió un artículo para el *The New York Times* titulado "How Endangered a Species?" El periodista afirmó que "las muertes [de manatíes] por barcos han continuado a pesar de la creación de una red de refugios y zonas de baja velocidad para las embarcaciones; el resultado es uno de los debates más intensos del país sobre especies en peligro de extinción". El artículo incluyó dos gráficas juntas, similares a las que se presentan en la figura 9-1. (Las gráficas del *New York Times* incluían datos desde 1976 hasta el 2000). Las gráficas de la figura 9-1 reflejan los datos de la tabla 9-1 (de acuerdo con datos del Florida Department of Highway Safety and Motor Vehicles y del Florida Marine Research Institute).

He aquí algunos temas cubiertos en este capítulo:

- En comparación con la figura 9-1, ¿hay otra gráfica que ilustre mejor la relación entre el número de barcos registrados y el número de muertes de manatíes por los barcos?
- ¿De qué manera es posible utilizar métodos de estadística para determinar objetivamente si hay una relación entre dos variables, tales como el número de barcos registrados y la cantidad de manatíes muertos por los barcos?
- Si hay una relación entre el número de embarcaciones que se registran y el número de manatíes que asesinan los barcos, ¿cómo se describiría? ¿Existe alguna ecuación que sea posible utilizar para predecir las muertes de manatíes que provocan las barcos, a partir de un número particular de barcos registrados?
- Además del número de barcos registrados, ¿hay otras variables importantes que afecten el número de manatíes que asesinan los barcos?

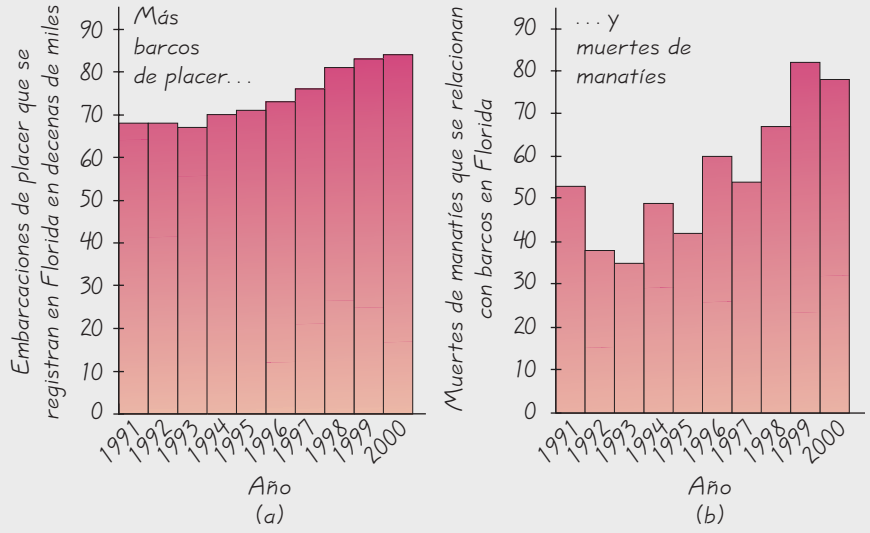


FIGURA 9-1 **Embarcaciones de placer que se registran en Florida (en decenas de miles) y muertes de manatíes que se relacionan con barcos**

Tabla 9-1 Embarcaciones de placer que se registraron en Florida (en decenas de miles) y muertes de manatíes que se relacionan con barcos

Año	1991	1992	1993	1994	1995	1996	1997	1998	1999	2000
x: Barcos	68	68	67	70	71	73	76	81	83	84
y: Muertes de manatíes	53	38	35	49	42	60	54	67	82	78

9-1 Panorama general

Este capítulo introduce métodos importantes para hacer inferencias que se basan en datos muestrales que se ordenan en *pares*. La sección 8-4 utilizó muestras apareadas, pero las inferencias en la sección 8-4 se referían a diferencias entre dos medias poblacionales. Este capítulo tiene el objetivo de determinar si hay una relación entre las dos variables; en caso de existir tal relación, queremos describirla con una ecuación que permita hacer predicciones.

Iniciamos en la sección 9-2 considerando el concepto de correlación, que se emplea para determinar si existe una relación estadísticamente significativa entre dos variables. Investigaremos la correlación por medio del diagrama de dispersión (una gráfica) y el coeficiente de correlación lineal (una medida de la dirección y el poder de la asociación lineal entre dos variables). En la sección 9-3 investigaremos el análisis de regresión; describiremos la relación entre dos variables con una ecuación que las relaciona y mostraremos cómo utilizar esa ecuación para predecir valores de una variable cuando conocemos los valores de la otra variable.

En la sección 9-4 analizaremos las diferencias entre los valores predichos y los valores reales que se observan de una variable. Las secciones 9-2 a 9-4 implican relaciones entre *dos* variables, pero en la sección 9-5 emplearemos conceptos de regresión múltiple para describir la relación entre tres o más variables. Finalmente, en la sección 9-6 describiremos algunos métodos básicos para crear un modelo matemático que permita describir la relación entre dos variables. Aun cuando la sección 9-3 se limita a relaciones lineales, la sección 9-6 incluye algunas relaciones no lineales comunes.

9-2 Correlación

El principal objetivo de esta sección es analizar un conjunto de datos muestrales apareados (que llamamos en ocasiones **datos bivariados**) y determinar si parece haber una relación entre las dos variables. En estadística, nos referimos a una relación como ésta como una *correlación.* (Consideraremos únicamente relaciones *lineales*, lo que significa que, cuando se grafica, los puntos se aproximan a un patrón de línea recta. Además, consideramos solamente datos cuantitativos).

Definición

Correlación: Existe entre dos variables cuando una de ellas se relaciona con la otra de alguna manera.

La tabla 9-1, por ejemplo, se compone de datos barco/manatí apareados para cada año de la década pasada. Determinaremos si hay una correlación entre la va-

riable *x* (número de barcos que se registran) y la variable *y* (número de manatíes que asesinan los barcos).

Exploración de los datos

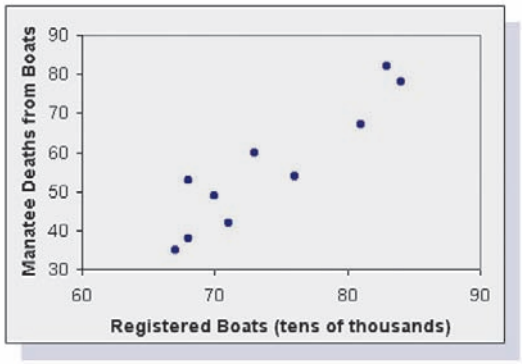
Antes de trabajar con los métodos más formales de cálculo de esta sección, primero debemos explorar el conjunto de datos para ver qué es posible aprender. Con frecuencia encontraremos una relación entre dos variables al construir una gráfica que se denomina *diagrama de dispersión*.

Definición

Diagrama de dispersión: Una gráfica en la que datos muestrales apareados (*x*, *y*) se grafican en un eje *x* horizontal y un eje *y* vertical. Cada par individual (*x*, *y*) se grafica como un solo punto.

Como ejemplo, véase el resultado de Excel de los 10 pares de datos que se listan en la tabla 9-1. Cuando examinamos un diagrama de dispersión como ése, es necesario estudiar el patrón general de los puntos graficados. Si existe un patrón, debemos señalar su dirección. Es decir, mientras una variable se incrementa, ¿la otra parece aumentar o disminuir? Tenemos que observar si hay datos distantes, que son puntos que se ubican muy lejos de todos los demás. El diagrama de dispersión que se genera en Excel no parece revelar un patrón que indique que un mayor número de barcos que se registran se asocie con una mayor cantidad de muertes de manatíes debidas a los barcos. El diagrama de dispersión sirve mucho más para visualizar la asociación entre los barcos que se registran y las muertes de manatíes que las gráficas de barras que se muestran en la figura 9-1. Como se ordenan de acuerdo con una secuencia temporal, las gráficas de barras de la figura 9-1 son muy útiles para mostrar la tendencia a largo plazo del número de barcos que se registran y el número de muertes de manatíes que ocasionan los barcos, aunque el diagrama de dispersión es útil para ilustrar la relación existente entre esas dos variables.

Excel

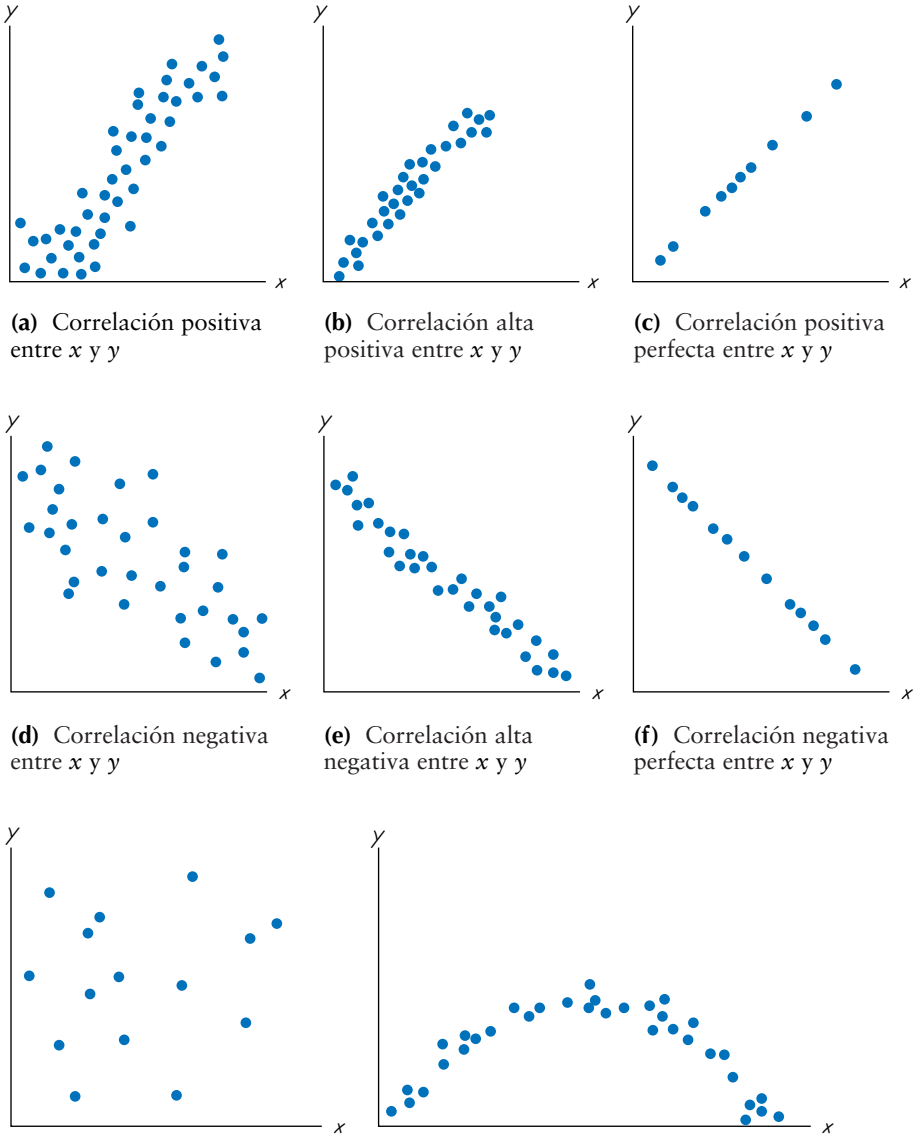




Los profesores son evaluados por estudiantes

Muchas universidades consideran que las buenas evaluaciones de los profesores, hechas por estudiantes, son equivalentes a una buena enseñanza, ecuación que se fomenta por el hecho de que las evaluaciones de los estudiantes son fáciles de administrar y medir. Sin embargo, un estudio que comparó evaluaciones de profesores hechas por alumnos con la cantidad de material que se aprende reveló una fuerte correlación *negativa* entre los dos factores. Los maestros que mejor evalúan los alumnos parecieron producir menor aprendizaje. En un estudio que se relaciona, una audiencia otorgó una evaluación alta a un conferencista que ofreció muy poca información, pero que era interesante y entretenido. (Véase "Rating the Teachers", de Miriam Rodin, *Center Magazine,* vol. VIII, núm. 5).

En la figura 9-2 se presentan otros ejemplos de diagramas de dispersión. Las gráficas en la figura 9-2a, b y c describen un patrón de valores crecientes de y, que corresponde a valores crecientes de x. Conforme vamos de a a c, el patrón de puntos se aproxima a una línea recta, lo que sugiere que la relación entre x y y se hace más fuerte. Los diagramas de dispersión en d, e y f describen patrones en los que los valores de y disminuyen mientras los de x aumentan. Nuevamente, conforme vamos de d a f, la relación se hace más fuerte. En contraste con las primeras seis gráficas, el diagrama de dispersión de g no presenta ningún patrón y



(a) Correlación positiva entre x y y

(b) Correlación alta positiva entre x y y

(c) Correlación positiva perfecta entre x y y

(d) Correlación negativa entre x y y

(e) Correlación alta negativa entre x y y

(f) Correlación negativa perfecta entre x y y

(g) Sin correlación entre x y y

(h) Relación no lineal entre x y y

FIGURA 9-2 Diagramas de dispersión

sugiere que no hay correlación alguna (o relación) entre x y y. Finalmente, el diagrama de dispersión de h indica un patrón, pero no de tipo lineal.

Coeficiente de correlación lineal

Puesto que el examen visual de los diagramas de dispersión es muy subjetivo, necesitamos medidas más precisas y objetivas. El coeficiente de correlación lineal r sirve para detectar patrones lineales.

Definición

Coeficiente de correlación lineal *r*: mide la fuerza de la relación lineal entre los valores cuantitativos apareados x y y en una *muestra*. Su valor se calcula con la fórmula 9-1, que se incluye en el siguiente recuadro. [El coeficiente de correlación lineal también se conoce como **coeficiente de correlación producto momento de Pearson**, en honor de Karl Pearson (1857-1936), quien lo desarrolló originalmente].

Puesto que el coeficiente de correlación lineal r se calcula con datos muestrales, se trata de un estadístico muestral que se emplea para medir la fuerza de la correlación lineal entre x y y. Si tuviésemos cada par de los valores poblacionales de x y y, el resultado de la fórmula 9-1 sería un parámetro poblacional, que se representaría por ρ (rho griega). El siguiente recuadro incluye los supuestos que se requieren, la notación y la fórmula 9-1.

Supuestos

1. La muestra de datos apareados (x, y) es una muestra *aleatoria* de datos cuantitativos.
2. Los pares de datos (x, y) tienen una **distribución normal bivariada**. (Las distribuciones normales se estudiaron en el capítulo 5, pero este supuesto requiere básicamente que, para cualquier valor fijo de x, los valores correspondientes de y contengan una distribución con forma de campana y que para cualquier valor fijo de y los valores de x tengan también una distribución con forma de campana). Suele ser difícil verificar este supuesto, pero es posible realizar una verificación parcial determinando si las distribuciones básicamente de los valores de x y y tienen forma de campana.

Notación para el coeficiente de correlación lineal

n	representa el número de pares de datos presentes.
Σ	denota la suma de los elementos que se indican.
Σx	denota la suma de todos los valores de x.
Σx^2	indica que cada valor de x debe elevarse al cuadrado y que después dichos cuadrados se suman.
$(\Sigma x)^2$	indica que los valores de x deben sumarse y el total elevarse al cuadrado. Es sumamente importante evitar confundirse entre Σx^2 y $(\Sigma x)^2$.

continúa



"El mercado de valores varía de acuerdo con la superstición del triunfo patriota"

Este encabezado del *New York Post* es una afirmación acerca del *pronóstico del Súper Bowl*, que establece que la victoria de un equipo de la NFL es seguida por un año cuando el índice de intercambio de la bolsa de Nueva York se incrementa; de otra manera, disminuye. (En 1970, la NFL y la AFL se unieron para formar la actual NFL). Tal indicador ha sido correcto en 29 de los últimos 35 años, principalmente por el hecho de que los equipos de la NFL ganan con mayor frecuencia y que el mercado de valores tiende a subir con el paso del tiempo. El pronóstico y las predicciones son metas importantes de los estadísticos y de los consejeros de inversiones, aunque el sentido común sugiere que nadie debe basar sus inversiones en el resultado de un juego de futbol. Otros indicadores que se utilizan para pronosticar el desempeño del mercado de valores incluye la aparición de faldas más cortas, la venta de aspirinas, las limusinas en Wall Street, las órdenes de cajas de cartón, las ventas de cerveza en relación con las de vino y el tráfico de elevadores en el mercado de valores de Nueva York.

Σxy	indica que cada valor de x debe multiplicarse primero por su valor y correspondiente. Después de obtener todos estos productos, se calcula su suma.
r	representa el coeficiente de correlación lineal de una *muestra*.
ρ	representa el coeficiente de correlación lineal de una *población*.

Fórmula 9-1
$$r = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{\sqrt{n(\Sigma x^2) - (\Sigma x)^2}\sqrt{n(\Sigma y^2) - (\Sigma y)^2}}$$

Interpretación de *r* por medio de la tabla A-6: Si el valor absoluto del valor que se calculó de r excede el valor de la tabla A-6, concluya que hay una correlación lineal significativa. De lo contrario, no existe evidencia suficiente para sustentar la conclusión de una correlación lineal significativa.

Redondeo del coeficiente de correlación lineal

Redondee el coeficiente de correlación lineal r a tres decimales (de manera que su valor se compare directamente con los valores críticos de la tabla A-6). Al calcular r y otros estadísticos en este capítulo, hacer un redondeo a la mitad de un cálculo suele crear errores importantes; por lo tanto, trate de utilizar la memoria de su calculadora para almacenar los resultados inmediatos y redondee sólo al final. Muchas calculadoras baratas incluyen la fórmula 9-1, por lo que evalúan automáticamente r después de introducir los datos muestrales.

EJEMPLO Cálculo de *r* Con los datos que se presentan a continuación, calcule el valor del coeficiente de correlación lineal r.

x	1	1	3	5
y	2	8	6	4

SOLUCIÓN Para la muestra dada de datos apareados, $n = 4$, ya que existen cuatro pares de datos. Los otros componentes que se requieren para la fórmula 9-1 se obtienen de los cálculos en la tabla 9-2. Note cómo este formato vertical facilita los cálculos.

Con los valores que se calcularon y la fórmula 9-1 es posible evaluar r de la siguiente forma:

$$r = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{\sqrt{n(\Sigma x^2) - (\Sigma x)^2}\sqrt{n(\Sigma y^2) - (\Sigma y)^2}}$$
$$= \frac{4(48) - (10)(20)}{\sqrt{4(36) - (10)^2}\sqrt{4(120) - (20)^2}}$$
$$= \frac{-8}{\sqrt{44}\sqrt{80}} = -0.135$$

Tabla 9-2 Obtención de estadísticos que se emplean para calcular r

	x	y	$x \cdot y$	x^2	y^2
	1	2	2	1	4
	1	8	8	1	64
	3	6	18	9	36
	5	4	20	25	16
Total	**10** ↑ Σx	**20** ↑ Σy	**48** ↑ Σxy	**36** ↑ Σx^2	**120** ↑ Σy^2

Con grandes conjuntos de datos, estos cálculos dan resultado muy desordenados; por fortuna, el coeficiente de correlación lineal se determina automáticamente usando calculadoras y programas de cómputo. Consulte la sección "Utilizando la tecnología" al final de esta sección para referencias de STATDISK, Minitab, Excel, y la calculadora TI-83 Plus.

Interpretación del coeficiente de correlación lineal

Necesitamos interpretar un valor calculado de r, tal como el valor de -0.135 que se obtuvo en el ejemplo anterior. Como la manera en donde la fórmula 9-1 se construyó, el valor de r siempre debe estar entre -1 y $+1$, inclusive. Si r se acerca a 0, concluimos que no hay una correlación lineal significativa entre x y y, pero si r se acerca a -1 o $+1$, concluimos que hay una correlación lineal significativa entre x y y. Interpretaciones tales como "cercano a" 0 o 1 o -1 son vagas, por lo que utilizamos el siguiente criterio de decisión muy específico:

> **Si el valor absoluto del valor que se calculó de *r* excede el valor de la tabla A-6, se concluye que hay una correlación lineal significativa. De lo contrario, no existe evidencia suficiente para sustentar la conclusión de una correlación lineal significativa.**

Cuando en realidad no hay una correlación lineal entre x y y, la tabla A-6 lista valores que son "críticos" en este sentido: separan valores *comunes* de r de aquellos que son *poco comunes*. Por ejemplo, la tabla A-6 nos indica que con $n = 10$ pares de datos muestrales, los valores críticos son 0.632 (para $\alpha = 0.05$) y 0.765 (para $\alpha = 0.01$). Los valores críticos y el papel de α se describen en detalle en los capítulos 6 y 7. He aquí cómo interpretamos dichos números: con 10 pares de datos y ninguna correlación lineal entre x y y, existe una probabilidad del 5% de que el valor absoluto del coeficiente de correlación lineal que se calcula exceda 0.632. Con $n = 10$ y sin correlación lineal, hay una probabilidad del 1% de que $|r|$ exceda 0.765.



Lectura de las manos

Algunas personas piensan que la longitud de la línea de la vida de la palma de sus manos es útil para predecir la longevidad. En una carta publicada en el *Journal of the American Medical Association*, M. E. Wilson y L. E. Mather refutaron esta creencia con un estudio de cadáveres. Se registraron las edades a la muerte, junto con las longitudes de la línea de la vida de sus palmas. Los autores concluyeron que no hay una correlación significativa entre la edad al morir y la longitud de la línea de la vida. La quiromancia pierde, bajen las manos.



EJEMPLO Barcos y manatíes Con los datos muestrales de la tabla 9-1, calcule el valor del coeficiente de correlación lineal *r*, después remítase a la tabla A-6 para determinar si existe una correlación lineal significativa entre el número de barcos que se registran y la cantidad de manatíes que asesinan los barcos. En la tabla A-6, utilice el valor crítico para $\alpha = 0.05$. (Con $\alpha = 0.05$, concluimos que hay una correlación lineal significativa sólo si la muestra es improbable en este sentido: si no existe una correlación lineal entre dos variables, un valor de *r* como éste ocurre el 5% de las veces o menos).

SOLUCIÓN Al utilizar el mismo procedimiento que se ilustra en el ejemplo anterior o empleando las herramientas tecnológicas, obtenemos que los 10 pares de datos barco/manatí de la tabla 9-1 dan como resultado $r = 0.922$. A continuación se presentan los resultados de Minitab:

Minitab

```
Pearson correlation of Boats and Manatees = 0.922
P-Value = 0.000
```

Si nos remitimos a la tabla A-6, localizaremos el renglón en que $n = 10$ (porque hay 10 pares de datos). Este renglón contiene los valores críticos de 0.632 (para $\alpha = 0.05$) y 0.765 (para $\alpha = 0.01$). Con el valor crítico para $\alpha = 0.05$, observamos que hay una probabilidad menor al 5% de que, sin correlación lineal, el valor absoluto de *r* que se calculó exceda 0.632. Puesto que $r = 0.922$, su valor absoluto excede 0.632, por lo que concluimos que existe una correlación lineal significativa entre el número de barcos que se registran y la cantidad de muertes de manatíes a consecuencia de los barcos.

Ya señalamos que la fórmula 9-1 requiere que el valor que se calculó de *r* caiga siempre entre -1 y $+1$, inclusive. Listamos esa propiedad, junto con otras que también son importantes.

Propiedades del coeficiente de correlación lineal *r*

1. El valor de *r* está siempre entre -1 y $+1$, inclusive. Es decir,
$$-1 \le r \le +1$$
2. *El valor de r no cambia si todos los valores de cualquier variable se convierten a una escala diferente.*
3. *El valor de r no se afecta por la elección de* x *o* y. Intercambie todos los valores de *x* y *y*, y el valor de *r* no sufrirá cambios.
4. *r mide la fuerza de una relación lineal*. No se diseñó para medir la fuerza de una relación que no sea lineal.

Interpretación de *r*: variación explicada

Si concluimos que hay una correlación lineal significativa entre *x* y *y*, obtendremos una ecuación lineal que exprese *y* en términos de *x*; la ecuación se utiliza pa-

ra predecir valores de y a partir de valores dados de x. En la sección 9-3 describiremos un procedimiento para el cálculo de dichas ecuaciones y mostraremos cómo predecir valores de y cuando se tienen valores dados de x. Pero un valor predicho de y no será necesariamente el resultado exacto porque, además de x, hay otros factores que afectan a y, como la variación aleatoria y otras características que no se incluyen en el estudio. En la sección 9-4 presentaremos los fundamentos y más detalles acerca de este principio importante:

El valor de r^2 es la proporción de la variación de y que se explica por la relación lineal entre x y y.



EJEMPLO Barcos y manatíes Con los datos barco/manatí de la tabla 9-1, encontramos que el coeficiente de correlación lineal es $r = 0.922$. ¿Qué proporción de la variación de las muertes de manatíes se explicaría por la variación en el número de registros de barcos?

SOLUCIÓN Con $r = 0.922$, obtenemos $r^2 = 0.850$. (Redondeando el valor de r resulta $r^2 = 0.849$).

INTERPRETACIÓN Concluimos que 0.850 (o aproximadamente el 85%) de la variación en las muertes de manatíes debidas a los barcos se explicaría por la relación lineal entre el número de registros de barcos y el número de muertes de manatíes por los barcos. Lo anterior implica que cerca del 15% de la variación de estas muertes no se explica por el número de registros de barcos. Otro factor verdaderamente importante es el tamaño de la población de manatíes; de hecho, hay evidencia que indica que su población continúa en crecimiento. Algunas personas argumentan que el incremento de las muertes de manatíes por los barcos se explica por el hecho de que la población creciente de manatíes ocasiona una mayor cantidad de estos animales en el agua, y que la tasa creciente de muertes por los barcos es un síntoma de una población saludable y en aumento de manatíes, por lo que las restricciones adicionales a los barcos son innecesarias. Puesto que los estimados de la población de manatíes se basan en observaciones aéreas, otros argumentan que los estimados del tamaño de esta población son poco confiables. El investigador Thomas Fraser sugirió en un reporte que "el Estado debe poner en marcha un programa vigoroso de captura y etiquetación, y de recaptura para obtener mejor información sobre el tamaño de la población y sus cambios". (Véase la tercera actividad de cooperación en equipo del capítulo 3).

Errores comunes en las correlaciones

Ahora identificamos tres de las fuentes más comunes de errores que se cometen al interpretar los resultados de correlaciones:

1. *Un error común es concluir que la correlación implica causalidad*. Con los datos muestrales de la tabla 9-1, concluiríamos que hay una correlación entre el número de barcos que se registran y la cantidad de manatíes que son asesinados por barcos, pero no es posible concluir que un mayor número de barcos que se registró *causa* más muertes de manatíes. Las muertes de manatíes por los barcos pueden afectarse por alguna otra variable interventora en los ante-

cedentes. (Una **variable interventora** es aquella que afecta a las variables que se estudian, pero que no está incluida en la investigación). Por ejemplo, temperaturas más cálidas llegan a afectar el número de barcos y el número de manatíes asesinados por los barcos. Por lo tanto, la temperatura sería una variable interventora.

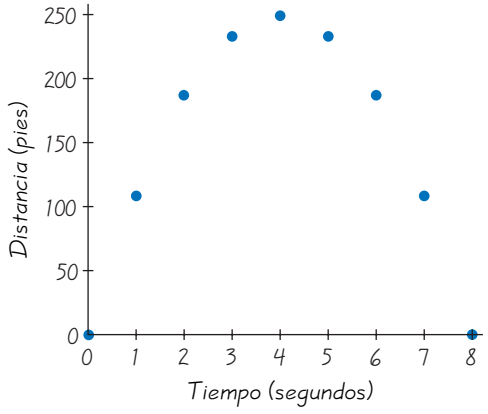
2. *Otro error proviene de los datos basados en promedios*. Los promedios eliminan la variación individual y pueden inflar el coeficiente de correlación. Un estudio produjo un coeficiente de correlación lineal de 0.4 para datos apareados que relacionaban el ingreso y la educación de individuos, pero el coeficiente de correlación lineal se convirtió en 0.7 cuando se utilizaron promedios regionales.
3. *Un tercer error implica la propiedad de linealidad.* Puede existir una relación entre x y y, aun cuando no haya una correlación lineal significativa. Los datos presentados en la figura 9-3 tienen un valor de $r = 0$, lo que indica que no existe una correlación *lineal* entre las dos variables. Sin embargo, al observar la figura, con facilidad podemos percibir que existe un patrón que refleja una relación *no lineal* muy fuerte. (La figura 9-3 es un diagrama de dispersión que representa la relación entre la distancia, del suelo hacia arriba, y el tiempo transcurrido para un objeto lanzado hacia arriba).

Prueba formal de hipótesis (requiere el estudio del capítulo 7)

Presentamos dos métodos (resumidos en el recuadro siguiente y en la figura 9-4) para utilizar una prueba formal de hipótesis a fin de determinar si existe una correlación lineal significativa entre dos variables. Algunos profesores prefieren el método 1 debido a que refuerza conceptos introducidos en capítulos anteriores. Otros prefieren el método 2 porque implica cálculos más fáciles. El método 1 emplea la distribución t de Student, con un estadístico de prueba con la forma $t = (r - \mu_r)/s_r$, donde μ_r y s_r denotan el valor aseverado de la media y de la desviación estándar muestral de valores de r. El estadístico de prueba incluido en el recuadro (para el método 1) refleja el hecho de que la desviación estándar de los valores de r se expresa como $\sqrt{(1 - r^2)/(n - 2)}$.

La figura 9-4 indica que el criterio de decisión es el rechazo de la hipótesis nula de $\rho = 0$, si el valor absoluto del estadístico de prueba excede los valores crí-

FIGURA 9-3 Diagrama de dispersión que muestra un patrón no lineal



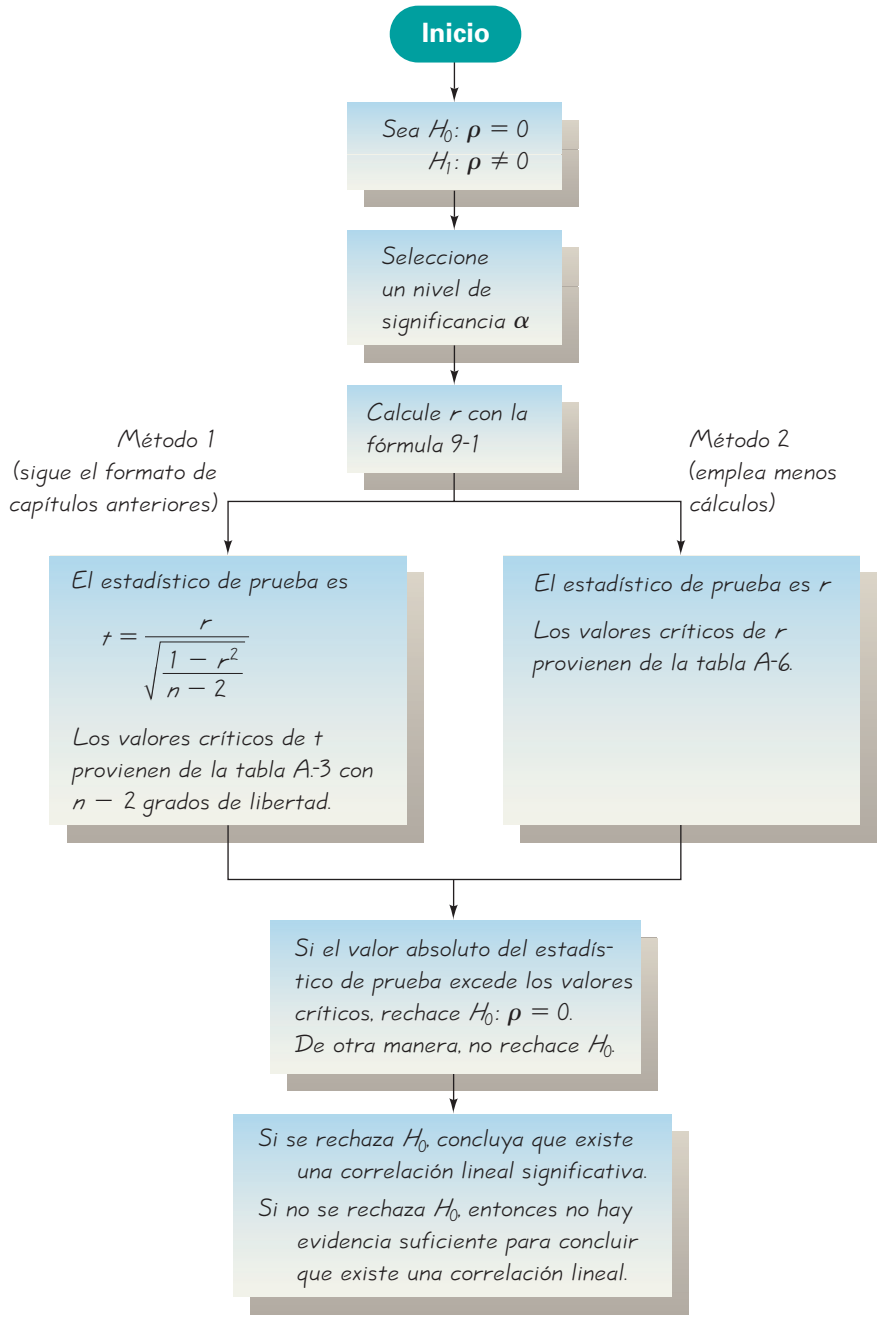


FIGURA 9-4 **Prueba de hipótesis para una correlación lineal**

ticos; el rechazo de $\rho = 0$ significa que existe evidencia suficiente para sustentar una aseveración de una correlación lineal entre las dos variables. Si el valor absoluto del estadístico de prueba no excede los valores críticos, entonces no rechazamos $\rho = 0$; es decir, no existe suficiente evidencia para concluir que existe una correlación lineal entre las dos variables.

Prueba de hipótesis de correlación (Véase la figura 9-4).

H_0: $\rho = 0$ **(No existe una correlación lineal).**
H_1: $\rho \neq 0$ **(Existe una correlación lineal).**

Método 1: El estadístico de prueba es *t*

Estadístico de prueba: $t = \dfrac{r - \mu_r}{\sqrt{\dfrac{1 - r^2}{n - 2}}}$

donde μ_r denota el valor aseverado de la media de los valores de r. Sea $\mu_r = 0$ al probar la hipótesis nula de $\rho = 0$.
Valores críticos: Utilice la tabla A-3 con $n - 2$ grados de libertad.
Valor *P*: Utilice la tabla A-3 con $n - 2$ grados de libertad.
Conclusión: Si $|t| >$ el valor crítico de la tabla A-3, rechace H_0 y concluya que existe una correlación lineal. Si $|t| \leq$ valor crítico, no rechace H_0; no hay evidencia suficiente para concluir que existe una correlación lineal.

Método 2: El estadístico de prueba es *r*

Estadístico de prueba: r
Valores críticos: Remítase a la tabla A-6.
Conclusión: Si $|r| >$ el valor crítico de la tabla A-6, rechace H_0 y concluya que existe una correlación lineal. Si $|r| \leq$ valor crítico, no rechace H_0; no hay evidencia suficiente para concluir que existe una correlación lineal.



EJEMPLO Barcos y manatíes Con los datos muestrales de la tabla 9-1, pruebe la aseveración de que existe una correlación lineal entre el número de barcos registrados y la cantidad de manatíes asesinados por barcos. Para obtener el estadístico de prueba utilice a) el método 1 y b) el método 2.

SOLUCIÓN Remítase a la figura 9-4. Aseverar que existe una correlación lineal significativa equivale a aseverar que el coeficiente de correlación lineal poblacional ρ es distinto de 0. Por lo tanto, tenemos las siguientes hipótesis:

H_0: $\rho = 0$ (No existe una correlación lineal).
H_1: $\rho \neq 0$ (Existe una correlación lineal).

Puesto que no se especificó un nivel de significancia, utilice $\alpha = 0.05$.

En un ejemplo previo ya calculamos que $r = 0.922$. Con ese valor ahora calculamos el estadístico de prueba y el valor crítico por medio de los dos métodos descritos.

a. *Método 1:* El estadístico de prueba es

$$t = \frac{r}{\sqrt{\dfrac{1 - r^2}{n - 2}}} = \frac{0.922}{\sqrt{\dfrac{1 - 0.922^2}{10 - 2}}} = 6.735$$

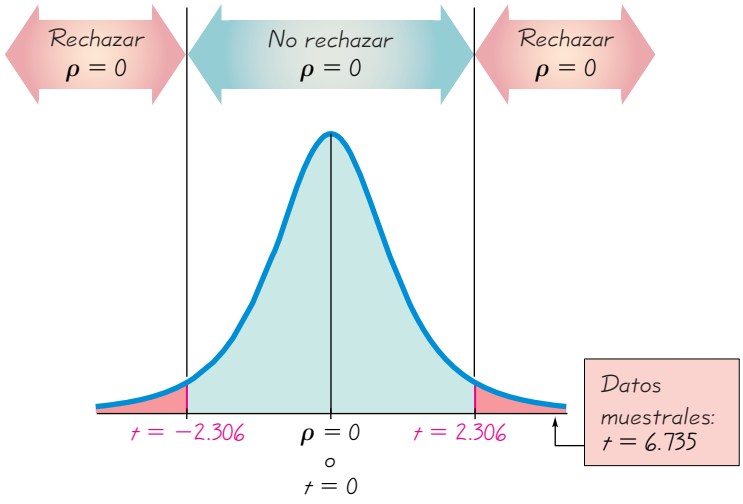


FIGURA 9-5 **Prueba de H_0: $\rho = 0$ con el método 1**

Los valores críticos de $t = \pm 2.306$ se encuentran en la tabla A-3, donde 2.306 corresponde a un área de 0.05, dividida entre dos colas, y el número de grados de libertad es $n - 2 = 8$. Observe la figura 9-5 con la gráfica que incluye el estadístico de prueba y los valores críticos.

b. *Método 2:* El estadístico de prueba es $r = 0.922$. Los valores críticos de $r = \pm 0.632$ se encuentran en la tabla A-6, con $n = 10$ y $\alpha = 0.05$. Observe la figura 9-6 con una gráfica que incluye el estadístico de prueba y los valores críticos.

Con el uso de cualquiera de los dos métodos encontramos que el valor absoluto del estadístico de prueba excede el valor crítico (Método 1: $6.735 > 2.306$. Método 2: $0.922 > 0.632$); es decir, el estadístico de prueba cae en la región crítica. Por lo tanto, rechazamos H_0: $\rho = 0$. Existe evidencia suficiente para sustentar la aseveración de una correlación lineal entre el número de barcos registrados y la cantidad de manatíes muertos por los barcos.

Pruebas de una cola: El ejemplo anterior y las figuras 9-5 y 9-6 ilustran una prueba de hipótesis de dos colas. Los ejemplos y los ejercicios de esta sección generalmente implicarán únicamente pruebas de dos colas, aunque podría presentar-

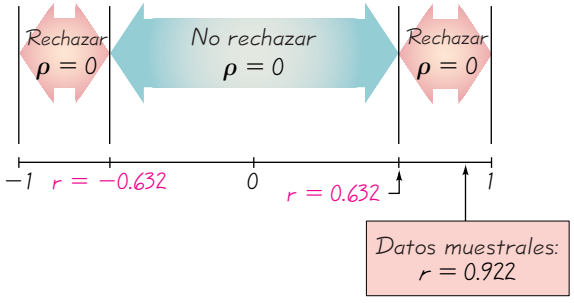


FIGURA 9-6 **Prueba de H_0: $\rho = 0$ con el método 2**

se una prueba de dos colas en una aseveración de una correlación lineal positiva o una aseveración de una correlación lineal negativa. En estos casos, las hipótesis serán como las que se muestran a continuación.

Aseveración de correlación *negativa* **(prueba de cola izquierda)**	**Aseveración de correlación *positiva*** **(prueba de cola derecha)**
$H_0: \rho = 0$ $H_1: \rho < 0$	$H_0: \rho = 0$ $H_1: \rho > 0$

Con estas pruebas de una cola, el método 1 puede seguirse como se hizo en capítulos previos. En el caso del método 2, hay que calcular el valor crítico como se describió en el ejercicio 31, o bien, modificar la tabla A-6 reemplazando los encabezados de columna de $\alpha = 0.05$ y $\alpha = 0.01$ por los valores de un solo lado de $\alpha = 0.025$ y $\alpha = 0.005$, respectivamente.

Fundamentos: Ya presentamos la fórmula 9-1 para el cálculo de r e ilustramos su uso; ahora lo justificaremos. La fórmula 9-1 simplifica los cálculos utilizados en esta fórmula equivalente:

$$r = \frac{\Sigma(x - \bar{x})(y - \bar{y})}{(n - 1)s_x s_y}$$

De manera temporal utilizaremos esta última versión de la fórmula 9-1, ya que su forma se relaciona de manera más directa con la teoría subyacente. Ahora considere los siguientes datos apareados, que están representados en el diagrama de dispersión de la figura 9-7.

x	1	1	2	4	7
y	4	5	8	15	23

La figura 9-7 incluye el punto $(\bar{x}, \bar{y}) = (3, 11)$, denominado el *centroide* de los puntos muestrales.

Definición

Dado un conjunto de datos apareados (x,y), el punto $(\bar{x}, \bar{y})$ se denomina **centroide**.

El estadístico r, que en ocasiones se llama *producto momento de Pearson*, fue creado por Karl Pearson. Se basa en la suma de los productos de los momentos $(x - \bar{x})$ y $(y - \bar{y})$; es decir, en el estadístico $\Sigma(x - \bar{x})(y - \bar{y})$. En cualquier diagrama de dispersión, las líneas vertical y horizontal que pasan a través del centroide $(\bar{x}, \bar{y})$ dividen el diagrama en cuatro cuadrantes, como se muestra en la figura 9-7. Si los puntos del diagrama de dispersión tienden a aproximarse a una línea ascendente (como la figura), los valores individuales del producto $(x - \bar{x})(y - \bar{y})$ tienden a ser positivos debido a que la mayoría de los puntos se encuentran en el

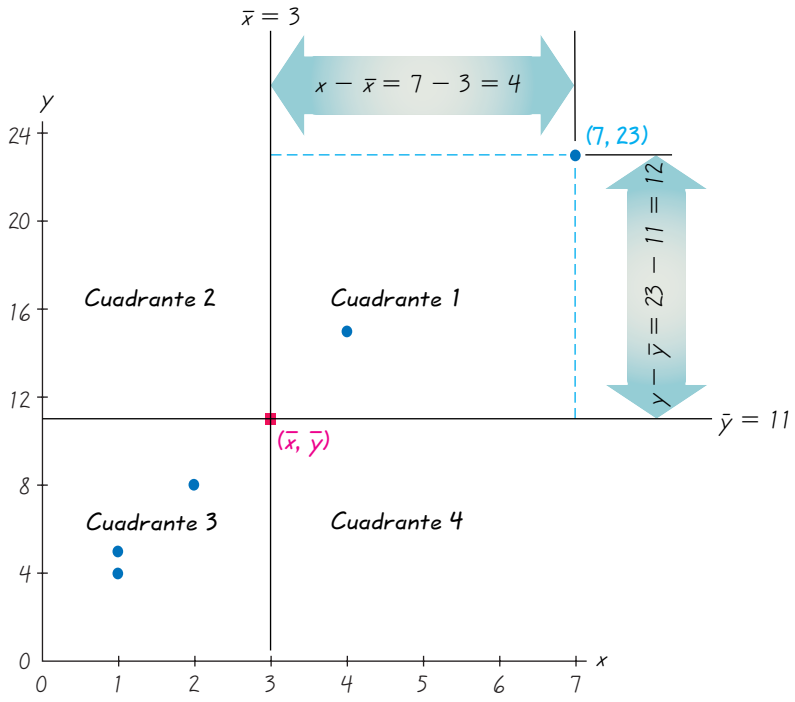


FIGURA 9-7 **Diagrama de dispersión dividido cuadrantes**

primero y tercer cuadrantes, donde los productos de $(x - \bar{x})$ y $(y - \bar{y})$ son positivos. Si los puntos del diagrama de dispersión se aproximan a una línea descendente, la mayoría de los puntos se encuentran en el segundo y cuarto cuadrantes, donde $(x - \bar{x})$ y $(y - \bar{y})$ tienen signos opuestos, de modo que $\Sigma(x - \bar{x})(y - \bar{y})$ es negativo. Los puntos que no siguen un patrón lineal tienden a dispersarse en los cuatro cuadrantes, de modo que el valor de $\Sigma(x - \bar{x})(y - \bar{y})$ tiende a ser cercano 0.

La suma $\Sigma(x - \bar{x})(y - \bar{y})$ depende de la magnitud de los números utilizados. Por ejemplo, si se cambia x de pulgadas a pies, dicha suma cambiará. Para lograr que r sea independiente de la escala utilizada, incluimos la desviación estándar muestral de la siguiente manera:

$$r = \frac{\Sigma(x - \bar{x})(y - \bar{y})}{(n - 1)s_x s_y}$$

Esta expresión se manipula de manera algebraica en la forma equivalente de la fórmula 9-1.

En capítulos anteriores estudiamos métodos de estadística inferencial y enfatizamos los métodos de prueba de hipótesis, así como también los métodos para construir estimados de intervalos de confianza. Es factible emplear un procedimiento similar para calcular intervalos de confianza para ρ. Sin embargo, debido a que la construcción de dichos intervalos de confianza implica transformaciones que son hasta cierto punto complicadas, ese proceso se presenta en el ejercicio 33 (Más allá de lo básico).

Podemos utilizar el coeficiente de correlación lineal para determinar si existe una relación lineal entre dos variables. Con los datos de la tabla 9-1 hemos concluido que existe una correlación lineal entre el número de barcos registrados y la cantidad de manatíes asesinados por los barcos. Una vez habiendo concluido que existe una relación, nos gustaría determinar de qué relación se trata, de modo que podamos predecir el número de muertes de manatíes para un número dado de barcos registrados. La siguiente etapa de este análisis se estudia en la siguiente sección.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, después utilice la opción **Correlation and Regression**. Introduzca los datos apareados o utilice copiar/pegar para copiar los datos. Ingrese los valores de *x* en la columna 1 y los valores *y* correspondientes en la columna 2. Ingrese un valor para el nivel de significancia. Haga clic en el botón **Evaluate**. Los resultados de STATDISK incluirán el valor del coeficiente de correlación lineal, junto con el valor crítico de *r*, la conclusión y otros resultados que se estudiarán en secciones posteriores. También se obtienen gráficas, incluyendo un diagrama de dispersión, al hacer clic en los botones Plot 1 y Plot2.

Minitab Introduzca los datos apareados en las columnas C1 y C2, después seleccione **Stat** de la barra del menú principal, elija **Basic Statistics** y después **Correlation**; proceda a introducir C1 y C2 , las columnas que serán utilizadas. Minitab proporcionara el valor del coeficiente de correlación lineal *r*, así como también un valor *P*. Para obtener un diagrama de dispersión seleccione **Graph**, luego **Plot** y después introduzca C1 y C2 para *X* y *Y*; finalmente haga clic en **OK**.

Excel Excel tiene una función que calcula el valor del coeficiente de correlación lineal. Primero introduzca los datos muestrales apareados en las columnas A y B. Haga clic en la tecla de función ***fx*** localizada en la barra del menú principal. Seleccione la categoría **Statistical** y el nombre de la función **CORREL**, después haga clic en **OK**. En el cuadro de diálogo ingrese el rango de celda de los valores para *x*, como A1:A10. También ingrese el rango de celda de los valores para *y*, como B1:B10. Para obtener un diagrama de dispersión, haga clic en el Chart Wizard del menú principal, después seleccione el tipo de gráfica identificada como **XY(Scatter)**. En el cuadro de diálogo introduzca el rango de entrada de los datos, como A1:B10. Haga clic en **Next** y proceda a utilizar los cuadros de diálogo para modificar la gráfica como lo desee.

También puede emplearse el complemento Data Desk XL. Haga clic en **DDXL** y seleccione **Regression**, después haga clic en el cuadro del tipo de función y seleccione **Correlation**. En el cuadro de diálogo, haga clic en el icono del lápiz para la variable del eje X e introduzca el rango de valores para la variable *x*, como A1:A10. Haga clic en el icono del lápiz para la variable del eje Y e introduzca el rango de valores para *y*. Haga clic en **OK**. Aparecerán el diagrama de dispersión y el coeficiente de correlación.

TI-83 Plus Introduzca los datos apareados en las listas L1 y L2, después presione **STAT** y seleccione **TESTS**. Si utiliza la opción de **LinRegTTest** resultarán diversos valores, incluyendo el valor del coeficiente de correlación lineal *r*.

Para obtener un diagrama de dispersión, presione **2nd**, después **Y=** (para STAT PLOT). Presione **Enter** dos veces para activar Plot 1, después seleccione el primer tipo de gráfica, que representa un diagrama de dispersión. Establezca las etiquetas de la lista *X* y *Y* para L1 y L2 y presione la tecla de **ZOOM**, finalmente elija **ZoomStat** y presione la tecla **Enter.**

9-2 Destrezas y conceptos básicos

En los ejercicios 1 a 4, utilice un nivel de significancia de $\alpha = 0.05$.

1. Tamaño del pecho y peso de osos Mientras ocho osos se encontraban anestesiados, algunos investigadores midieron las distancias (en pulgadas) alrededor del pecho de los osos y los pesaron (en libras). Se utilizó Minitab para calcular el valor del coeficiente de correlación lineal, que resultó ser $r = 0.993$.

a. ¿Existe una correlación lineal significativa entre tamaño del pecho y el peso? Explique.

b. ¿Qué proporción de la variación del peso se explica por la relación lineal entre el peso y el tamaño del pecho?

2. Armas de fuego y tasa de asesinatos Con datos reunidos del FBI y del Bureau of Alcohol, Tobacco and Firearms, se obtuvo el número de armas automáticas registradas y la tasa de asesinatos (en asesinatos por 10,000 individuos) de cada uno de ocho estados de la Unión Americana seleccionados al azar. Por medio de STATDISK se calculó el valor del coeficiente de correlación lineal $r = 0.885$.

a. ¿Existe una correlación lineal significativa entre el número de armas automáticas registradas y la tasa de asesinatos? Explique.

b. ¿Qué proporción de la variación de la tasa de asesinatos puede explicarse por la relación lineal entre la tasa de asesinatos y el número de armas automáticas registradas?

3. Acciones y el Súper Bowl El conjunto de datos 25 del Apéndice B incluye pares de datos del valor elevado del Promedio Industrial Dow Jones (DJIA, por sus siglas en inglés) y el número total de puntos anotados en el Súper Bowl en 21 años diferentes. Se utilizó Excel para calcular el valor del coeficiente de correlación lineal $r = -0.133$.

a. ¿Existe una correlación lineal significativa entre el valor elevado del DJIA y los puntos en el Súper Bowl? Explique.

b. ¿Qué proporción de la variación de los puntos del Súper Bowl se explica por la variación del valor elevado del DJIA?

4. Ventas de automóviles y manchas solares El conjunto de datos 25 del Apéndice B incluye pares de datos del número de manchas solares y del número de ventas de automóviles en Estados Unidos, durante 21 años distintos. Se utilizó la calculadora TI-83 Plus para calcular que el valor del coeficiente de correlación lineal es $r = -0.284$.

a. ¿Existe una correlación lineal significativa entre el número de manchas solares y el número de ventas de automóviles en Estados Unidos? Explique.

b. ¿Qué proporción de la variación del número de ventas de automóviles en Estados Unidos se explica por la variación del número de manchas solares?

Prueba de una correlación lineal. *En los ejercicios 5 y 6, utilice un diagrama de dispersión y el coeficiente de correlación lineal r para determinar si existe una correlación entre las dos variables.*

5.

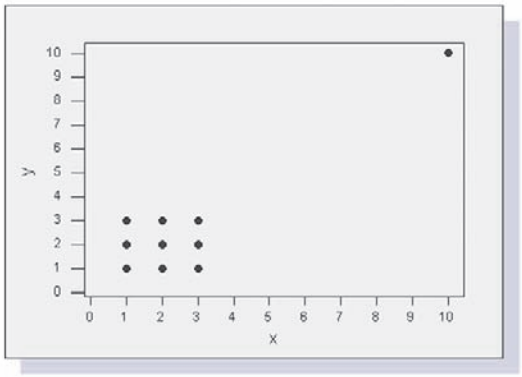
x	0	1	2	3	4
y	4	1	0	1	4

6.

x	1	2	2	5	6
y	2	5	4	15	15

7. Efectos de un dato distante Remítase al siguiente diagrama de dispersión generado por Minitab.

Excel



continúa

a. Examine el patrón de los 10 puntos y determine de forma subjetiva si parece existir una correlación entre x y y.
b. Después de identificar los 10 pares de coordenadas, correspondientes a los 10 puntos, calcule el valor del coeficiente de correlación r y determine si existe una correlación lineal significativa.
c. Ahora elimine el punto con las coordenadas (10, 10) y repita los incisos *a* y *b*.
d. ¿Qué concluye cerca del posible efecto de un solo par de valores?

Prueba de una correlación lineal. *En los ejercicios 8 a 14, construya un diagrama de dispersión, calcule el valor del coeficiente de correlación lineal r y utilice a nivel de significancia de $\alpha = 0.05$ para determinar si existe una correlación lineal significativa entre las dos variables. Guarde su trabajo, ya que utilizaremos los mismos conjuntos de datos en la siguiente sección.*

8. Incendios y acres quemados A continuación se lista el número de incendios (en miles) y los acres que resultaron quemados (en millones) en 11 estados del oeste de Estados Unidos, durante cada año de la última década (según datos de *USA Today*). ¿Existe una correlación? Los datos se listaron bajo un encabezado de "Loggers seize on fires to argue for more cutting". ¿Sustentan los datos el argumento de que si los madereros quitan más árboles, el riesgo de incendios disminuye porque los bosques tienen menor densidad?

Incendios	73	69	58	48	84	62	57	45	70	63	48
Acres quemados	6.2	4.2	1.9	2.7	5.0	1.6	3.0	1.6	1.5	2.0	3.7

9. Compra de una audiencia televisiva El *New York Post* publicó los salarios anuales (en millones) y el número de televidentes (en millones), los cuales se presentan abajo, correspondientes a Oprah Winfrey, David Letterman, Jay Leno, Kelsey Grammer, Barbara Walters, Dan Rather, James Gandolfini y Susan Lucci, respectivamente. ¿Existe una correlación entre el salario y el número de televidentes? ¿Cuál de las estrellas listadas tiene el menor costo por televidente? ¿Y el mayor costo por televidente?

Salario	100	14	14	35.2	12	7	5	1
Televidentes	7	4.4	5.9	1.6	10.4	9.6	8.9	4.2

10. Estaturas y pesos de supermodelos A continuación se incluyen las estaturas (en pulgadas) y los pesos (en libras) de las supermodelos Niki Taylor, Nadia Averman, Claudia Schiffer, Elle MacPherson, Christy Turlington, Bridget Hall, Kate Moss, Valerie Mazza y Kristy Hume. ¿Existe una correlación entre estatura y peso? Si es así, ¿significa esto que existe una correlación entre la estatura y el peso de todas las mujeres adultas?

Estatura (pulgadas)	71	70.5	71	72	70	70	66.5	70	71
Peso (libras)	125	119	128	128	119	127	105	123	115

11. Mediciones de la presión sanguínea Catorce estudiantes distintos del segundo año de medicina tomaron mediciones de la presión sanguínea del mismo paciente, y los resultados se presentan abajo (datos proporcionados por el doctor Marc Triola). ¿Existe una correlación entre los valores sistólicos y diastólicos? Además de la correlación, ¿habrá algún otro método que pueda utilizarse para enfatizar un aspecto importante sugerido por los datos?

Sistólica	138	130	135	140	120	125	120	130	130	144	143	140	130	150
Diastólica	82	91	100	100	80	90	80	80	80	98	105	85	70	100

12. Temperaturas y maratones En "The Effects of Temperature on Marathon Runner's Performance", de David Martin y John Buoncristiani (*Chance*, vol. 12, núm. 4), se in-

cluyen las altas temperaturas y los tiempos (en minutos) de mujeres que ganaron la maratón de la ciudad de Nueva York en años recientes. Los resultados se listan abajo. ¿Existe una correlación entre la temperatura y el tiempo de los triunfos? ¿Parece que los tiempos ganadores se ven afectados por la temperatura?

x (temperatura)	55	61	49	62	70	73	51	57
y (tiempo)	145.283	148.717	148.300	148.100	147.617	146.400	144.667	147.533

13. Tabaquismo y nicotina Cuando la nicotina es absorbida por el cuerpo se produce cotinina. Por consiguiente, la medición de cotinina es un buen indicador de qué tanto fuma una persona. A continuación se incluye el reporte del número de cigarrillos fumados por día y las cantidades medidas de nicotina (en ng/mL). (Los valores provienen de sujetos seleccionados al azar de la National Health Examination Survey). ¿Existe una correlación lineal significativa? Explique el resultado.

x (cigarrillos por día)	60	10	4	15	10	1	20	8	7	10	10	20
y (cotinina)	179	283	75.6	174	209	9.51	350	1.85	43.4	25.1	408	344

14. Circunferencia y altura de árboles A continuación se presentan las circunferencias (en pies) y las alturas (en pies) de árboles en Marshall, Minnesota (datos tomados de "Tree Measurements", de Stanley Rice, *American Biology Teacher*, vol. 61, núm.9). ¿Existe una correlación? ¿Por qué debería haber una correlación?

x (circunferencia)	1.8	1.9	1.8	2.4	5.1	3.1	5.5	5.1	8.3	13.7	5.3	4.9	3.7	3.8
y (altura)	21.0	33.5	24.6	40.7	73.2	24.9	40.4	45.3	53.5	93.8	64.0	62.7	47.2	44.3

Prueba de una correlación lineal. *En los ejercicios 15 a 24, utilice los datos del Apéndice B para construir un diagrama de dispersión, calcule el valor del coeficiente de correlación lineal r, y utilice un nivel de significancia de $\alpha = 0.05$ para determinar si existe una correlación lineal significativa entre las dos variables. Guarde su trabajo porque utilizaremos los mismos conjuntos de datos en la siguiente sección.*

T **15.** Cereales asesinos Remítase al conjunto de datos 16 del Apéndice B y utilice las cantidades de grasa y los conteos calóricos medidos. ¿Existe una correlación?

T **16.** Tabaco y alcohol en películas infantiles Remítase al conjunto de datos 7 del Apéndice B y utilice los tiempos que las películas infantiles de dibujos animados presentan consumo de tabaco y alcohol. ¿Existe una correlación entre los tiempos para el tabaco y los tiempos para el alcohol?

T **17.** Colesterol e índice de masa corporal Remítase al conjunto de datos 1 del Apéndice B y utilice los niveles de colesterol y los valores del índice de masa corporal de las 40 mujeres. ¿Existe una correlación entre el nivel de colesterol y el índice de masa corporal?

T **18.** Niveles de lectura Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones de la facilidad de lectura de Flesch y los valores del grado Flesch-Kincaid para *El oso y el dragón*, de Tom Clancy. Puesto que ambas puntuaciones están diseñadas para medir la facilidad de lectura, esperaríamos una correlación entre ellas. ¿Existe correlación? ¿De qué manera se explica el valor negativo del coeficiente de correlación?

T **19.** Precios de venta de casas, precios de lista e impuestos Remítase al conjunto de datos 24 del Apéndice B.

a. Utilice los datos apareados consistentes en los precios de lista y los precios de venta de casas. Esperaríamos que estas variables estuviesen relacionadas, ¿pero existe suficiente evidencia para sustentar esta expectativa?

b. Utilice los datos apareados que consisten en el precio de venta de casas y la suma de impuestos. Se supone que el cargo de impuestos debe estar basado en el valor de la casa. ¿Es así? Explique.

T **20.** Alquitrán y nicotina Remítase al conjunto de datos 5 del Apéndice B.

a. Utilice los datos apareados de alquitrán y nicotina. Con base en el resultado, ¿parece existir una correlación lineal significativa entre el alquitrán y la nicotina del cigarrillo? Si es así, ¿podrán los investigadores reducir sus gastos de laboratorio midiendo únicamente una de estas dos variables?

b. Utilice los datos apareados de monóxido de carbono y nicotina. Con base en el resultado, ¿parece existir una correlación lineal significativa entre el monóxido de carbono y la nicotina de los cigarrillos? Si es así, ¿podrán los investigadores reducir sus gastos de laboratorio midiendo únicamente una de estas dos variables?

c. Suponga que algunos investigadores desean diseñar un método para predecir la cantidad de nicotina y sólo desean medir algún otro elemento. ¿Cuál será una mejor elección, el alquitrán o el monóxido de carbono? ¿Por qué?

T **21.** Pronóstico del tiempo Remítase al conjunto de datos 10 del Apéndice B.

a. Utilice el pronóstico de altas temperaturas para cinco días y las temperaturas altas reales. ¿Existe correlación? ¿Implica una correlación lineal significativa que las temperaturas pronosticadas a cinco días son precisas?

b. Utilice el pronóstico de altas temperaturas para un día y las temperaturas altas reales. ¿Existe una correlación? ¿Implica una correlación lineal significativa que las temperaturas pronosticadas para un día son precisas?

c. ¿Cuál esperaría que tuviera una mayor correlación con las temperaturas altas reales: el pronóstico de altas temperaturas para cinco días o el pronóstico de altas temperaturas para un día? ¿Coinciden los resultados de los incisos *a* y *b* con lo que esperaría? Si existe una correlación muy alta entre las temperaturas pronosticadas y las temperaturas reales, ¿se infiere que las temperaturas pronosticadas son precisas?

T **22.** Everglades de Florida Remítase al conjunto de datos 12 del Apéndice B.

a. Utilice las temperaturas inferiores y las mediciones de conductividad. ¿Existe una correlación?

b. Utilice las cantidades de lluvia y las mediciones de conductividad. ¿Existe una correlación?

c. Cuando se aparean los valores de conductividad con las mediciones de salinidad (contenido de sal), el coeficiente de correlación es cercano a 1. ¿Qué concluye acerca de la correlación entre la temperatura inferior y la salinidad? ¿Qué concluye acerca de la correlación entre la cantidad de lluvia y la salinidad?

T **23.** Old Faithful Remítase al conjunto de datos 13 del Apéndice B.

a. Utilice los datos apareados de las duraciones y los intervalos después de las erupciones del géiser. ¿Existe una correlación lineal significativa que sugiera que el intervalo posterior a una erupción está relacionado con la duración de la erupción?

b. Utilice los datos apareados de las alturas de las erupciones y de los intervalos después de las erupciones del géiser Old Faithful. ¿Existe una correlación lineal significativa que sugiera que el intervalo posterior a una erupción está relacionado con la altura de la erupción?

c. Suponga que usted desea crear un método para predecir el intervalo hasta la siguiente erupción. Con base en los resultados de los incisos *a* y *b*, ¿qué factores serían más relevantes: la duración de la erupción o la altura de la erupción? ¿Por qué?

T **24.** Precios, quilates y colores de diamantes Remítase al conjunto de datos 18 del Apéndice B.

a. Utilice los datos apareados de los quilates (peso) y el precio. ¿Existe una correlación lineal significativa entre el peso de un diamante, en quilates, y su precio?

b. Utilice los datos apareados color/precio. ¿Existe una correlación lineal significativa entre el color de un diamante y su precio?

c. Suponga que planea comprar un anillo de compromiso de diamantes. Al considerar el valor de un diamante, ¿qué características debería considerar más importantes: el peso en quilates o el color? ¿Por qué?

Identificación de errores de correlación. *En los ejercicios 25 a 28, describa el error en la conclusión. (Véase la lista de errores comunes incluida en esta sección).*

25. *Considere que:* los datos muestrales apareados de las edades de sujetos y sus puntuaciones en una prueba de razonamiento dan como resultado un coeficiente de correlación lineal muy cercano a 0.
Conclusión: Las personas más jóvenes tienden a obtener puntuaciones más altas.

26. *Considere que:* Existe una correlación lineal significativa entre los ingresos personales y los años de educación.
Conclusión: Una mayor educación causa que se incrementen los ingresos de una persona.

27. *Considere que:* Ciertos sujetos resuelven una prueba de habilidades verbales y una prueba de destreza manual, y dichos pares de puntuaciones dan como resultado un coeficiente de correlación lineal muy cercano a 0.
Conclusión: Las puntuaciones en ambas pruebas no tienen ninguna relación.

28. *Considere que:* Existe una correlación lineal significativa entre las cargas del impuesto estatal promedio y los ingresos estatales promedio.
Conclusión: Existe una correlación lineal significativa entre las cargas de impuestos individuales y los ingresos individuales.

9-2 Más allá de lo básico

29. Uso de datos de diagramas de dispersión En ocasiones, en lugar de tener datos numéricos, tenemos únicamente datos graficados. El diagrama de dispersión adjunto de Excel es similar al que se incluyó en "The Prevalence of Nosocomial Infection in Intensive Care Units in Europe", de Vincent *et al.*, *Journal of American Medical Association*, vol. 274, núm. 8. Cada punto representa un país europeo diferente. Estime el valor del coeficiente de correlación lineal y determine si existe una correlación lineal significativa entre la tasa de mortalidad y la proporción de infecciones adquiridas en las unidades de cuidados intensivos.



30. Correlaciones con datos transformados Además de probar una correlación lineal entre x y y, con frecuencia podemos utilizar *transformaciones* de datos para explorar

otras relaciones. Por ejemplo, podríamos reemplazar cada valor de x por x^2 y emplear los métodos de esta sección para determinar si existe una correlación lineal entre y y x^2. A partir de los datos apareados en la tabla adjunta, construya el diagrama de dispersión y luego realice una prueba de correlación lineal entre y y cada uno de los siguientes elementos. ¿Cuál de estos casos resulta en el valor más grande de r?

a. x **b.** x^2 **c.** $\log x$ **d.** $\sqrt{x}$ **e.** $1/x$

x	1.3	2.4	2.6	2.8	2.4	3.0	4.1
y	0.11	0.38	0.41	0.45	0.39	0.48	0.61

31. Cálculo de valores críticos de r Los valores críticos de r en la tabla A-6 se calculan resolviendo

$$t = \frac{r}{\sqrt{\frac{1 - r^2}{n - 2}}}$$

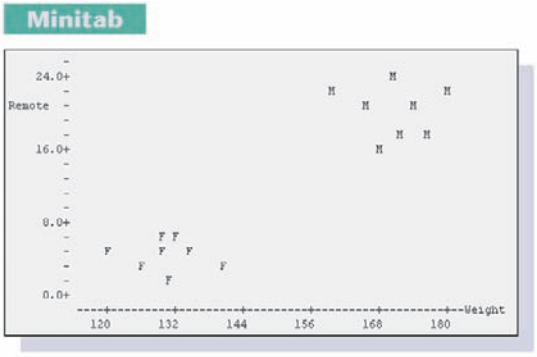
para obtener r

$$r = \frac{t}{\sqrt{t^2 + n - 2}}$$

dónde el valor t se obtiene de la tabla A-3, suponiendo un caso de dos colas con $n - 2$ grados de libertad. La tabla A-6 lista los resultados para valores seleccionados de n y α. Aplique la fórmula para r dada aquí, y la tabla A-3 (con $n - 2$ grados de libertad) para calcular los valores críticos de r en los siguientes casos.

a. H_1: $\rho \neq 0$, $n = 50$, $\alpha = 0.05$
b. H_1: $\rho \neq 0$, $n = 75$, $\alpha = 0.10$
c. H_1: $\rho < 0$, $n = 20$, $\alpha = 0.05$
d. H_1: $\rho > 0$, $n = 10$, $\alpha = 0.05$
e. H_1: $\rho > 0$, $n = 12$, $\alpha = 0.01$

32. Inclusión de datos categóricos en un diagrama de dispersión En ocasiones se vuelve importante incluir datos categóricos en un diagrama de dispersión. Considere los datos muestrales presentados abajo, donde el peso está representado en libras y los valores "remotos" consisten en el número de veces que el sujeto utilizó el control remoto del televisor durante un periodo de una hora. Se utiliza Minitab para generar el diagrama de dispersión, con las letras F (para las mujeres) y M (para los hombres) para identificar el género.



Género	F	F	F	F	F	F	F	F	M	M	M	M	M	M	M	M
Peso	120	126	129	130	131	132	134	140	160	166	168	170	172	174	176	180
Remoto	5	3	6	4	2	7	4	3	23	20	16	24	18	21	17	22

a. Antes de hacer cualquier cálculo, examine el diagrama de dispersión generado por Minitab. ¿Qué concluye cerca de la correlación entre el peso y el uso del control remoto?
b. Utilice los 16 pares de datos. ¿Existe una correlación entre el peso y el uso del control remoto?
c. Utilice sólo a las ocho mujeres. ¿Existe una correlación entre el peso y el uso del control remoto?
d. Utilice sólo a los ocho hombres. ¿Existe una correlación entre el peso y el uso del control remoto?
e. Con base en los resultados anteriores, ¿qué concluye?

33. Construcción de intervalos de confianza para ρ Dados n pares de datos con los que se puede calcular el coeficiente de correlación lineal r, utilice el siguiente procedimiento para construir un intervalo de confianza acerca del parámetro poblacional ρ.

Paso a. Utilice la tabla A-2 para calcular $z_{\alpha/2}$ que corresponde al nivel de confianza deseado.

Paso b. Evalúe los límites w_I y w_D del intervalo:

$$w_I = \frac{1}{2}\ln\left(\frac{1+r}{1-r}\right) - z_{\alpha/2}\cdot\frac{1}{\sqrt{n-3}}$$

$$w_D = \frac{1}{2}\ln\left(\frac{1+r}{1-r}\right) + z_{\alpha/2}\cdot\frac{1}{\sqrt{n-3}}$$

Paso c. Ahora evalúe los límites del intervalo de confianza en la siguiente expresión.

$$\frac{e^{2w_I}-1}{e^{2w_I}+1} < \rho < \frac{e^{2w_D}-1}{e^{2w_D}+1}$$

Utilice este procedimiento para construir un intervalo de confianza del 95% para ρ, dados 50 pares de datos para los cuales $r = 0.600$.

9-3 Regresión

En la sección 9-2 analizamos pares de datos con el objetivo de determinar si existía una correlación entre dos variables. El principal objetivo de esta sección es describir la relación entre dos variables por medio del cálculo de la gráfica y la ecuación de la recta que representa la relación. Esta recta se conoce como *recta de regresión* y su ecuación como *ecuación de regresión*. Sir Francis Galton (1822-1911) estudió el fenómeno de la herencia y demostró que cuando parejas altas o bajas tienen hijos, las estaturas de éstos tienden a *regresar* o a revertirse a la estatura media más común de las personas del mismo género. Continuaremos utilizando la terminología de "regresión" de Galton, aun cuando nuestros datos no incluyen el mismo fenómeno de estatura estudiado por Galton.

El recuadro que se presenta a continuación incluye la definición de la ecuación de regresión y de la recta de regresión, así como la notación y las fórmulas que estamos utilizando. La ecuación de regresión expresa una relación entre x (llamada la **variable independiente**, **variable predictora** o **variable explicativa**) y $\hat{y}$ (llamada la **variable dependiente** o **variable de respuesta**). La ecuación típica de una línea recta $y = mx + b$ está expresada en la forma $\hat{y} = b_0 + b_1x$, donde b_0 es el intercepto y y b_1 es la pendiente. La notación dada muestra que b_0 y b_1 son estadísticos muestrales utilizados para estimar los parámetros poblacio-

nales β_0 y β_1. Emplearemos datos muestrales apareados para estimar la ecuación de regresión. Si se utilizan únicamente datos muestrales no podemos calcular los valores exactos de los parámetros poblacionales β_0 y β_1, pero podemos emplear los datos muestrales para estimarlos con b_0 y b_1, que se calculan con las fórmulas 9-2 y 9-3.

Supuestos

1. Estamos investigando únicamente relaciones *lineales*.
2. Para cada valor de x, y es una variable aleatoria con una distribución normal (en forma de campana). Todas estas distribuciones de y tienen la misma varianza. Además, para un valor dado de x, la distribución de los valores de y tiene una media que está en la recta de regresión. (Los resultados no se ven gravemente afectados si las desviaciones de las distribuciones normales y las varianzas iguales no son demasiado extremas).

Definiciones

Dado un conjunto de datos muestrales apareados, la **ecuación de regresión**

$$\hat{y} = b_0 + b_1 x$$

describe algebraicamente la relación entre dos variables. La gráfica de la ecuación de regresión se denomina **recta de regresión** (*recta del mejor ajuste o recta de mínimos cuadrados*).

Notación para la ecuación de regresión

	Parámetro poblacional	Estadístico muestral
Intercepto y de la ecuación de regresión	β_0	b_0
Pendiente de la ecuación de regresión	β_1	b_1
Ecuación de la recta de regresión	$y = \beta_0 + \beta_1 x$	$\hat{y} = b_0 + b_1 x$

Cálculo de la pendiente b_1 y del intercepto b_0 en la ecuación de regresión $\hat{y} = b_0 + b_1 x$

Fórmula 9-2 **Pendiente:**
$$b_1 = \frac{n(\Sigma xy) - (\Sigma x)(\Sigma y)}{n(\Sigma x^2) - (\Sigma x)^2}$$

Fórmula 9-3 **Intercepto y:**
$$b_0 = \bar{y} - b_1 \bar{x}$$

El intercepto y, b_0, también se calcula usando la fórmula siguiente, pero es mucho más fácil utilizar la fórmula 9-3.

$$b_0 = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n(\Sigma x^2) - (\Sigma x)^2}$$

Tal vez las fórmulas 9-2 y 9-3 intimiden al estudiante, pero están consideradas en muchas calculadoras y programas de cómputo, de modo que los valores de b_0 y b_1 se calculan con facilidad. (Véase "Utilizando la tecnología" al final de esta sección). En aquellos casos en los que debemos aplicar las fórmulas en lugar de em-

plear una calculadora o un programa de cómputo, los cálculos requeridos serán mucho más fáciles si tenemos en mente los siguientes hechos:

1. Si se calculó el coeficiente de correlación r por medio de la fórmula 9-1, ya se tienen los valores de Σx, Σy, Σx^2 y Σxy, y pueden emplearse nuevamente en la fórmula 9-2. (Además, el numerador para r en la fórmula 9-1 es el mismo numerador que para b_1 en la fórmula 9-2; el denominador para r incluye el denominador para b_1. Si el cálculo de r se realiza con cuidado, el cálculo de b_1 requiere sólo de dividir un número conocido entre otro).
2. Si utiliza la fórmula 9-2 para calcular primero la pendiente de b_1, es fácil emplear la fórmula 9-3 para calcular b_0, el intercepto de y. [La recta de regresión siempre pasa por el centroide $(\bar{x}, \bar{y})$, de modo que $\bar{y} = b_0 + b_1\bar{x}$ siempre debe ser verdadera, y esta ecuación se expresa como la fórmula 9-3].

Una vez que hemos evaluado b_1 y b_0 podemos identificar la ecuación estimada de regresión, que tiene la siguiente propiedad especial: *la recta de regresión es la que se ajusta mejor a los puntos muestrales.* (El criterio específico utilizado para determinar cuál recta se ajusta "mejor" es la propiedad de los mínimos cuadrados, que se describirá posteriormente). Ahora estudiaremos brevemente el redondeo y después ejemplificaremos el procedimiento del cálculo y la aplicación de la ecuación de regresión.

Redondeo de la pendiente b_1 y de b_0, el intercepto de y

Es difícil proporcionar una regla simple universal para el redondeo de los valores de b_1 y b_0, pero generalmente tratamos de redondear cada uno de estos valores hasta *tres dígitos significativos* o utilizamos los valores proporcionados por STATDISK, Minitab, Excel o la calculadora TI-83 Plus. Puesto que estos valores son muy sensibles al redondeo durante los pasos intermedios del cálculo, trate de conservar al menos seis dígitos significativos (o utilice valores exactos) en los pasos intermedios. Dependiendo de la forma en que usted realice el redondeo, las respuestas a los ejemplos y ejercicios de este libro pueden variar ligeramente de sus respuestas.

EJEMPLO Cálculo de la ecuación de regresión En la sección 9-2 empleamos los valores listados abajo para calcular el coeficiente de correlación lineal de $r = -0.135$. (Con el uso de los métodos de la sección 9-2 no existe una correlación lineal significativa entre x y y). Use los datos muestrales dados para calcular la ecuación de regresión.

x	1	1	3	5
y	2	8	6	4

SOLUCIÓN Calculamos la ecuación de regresión por medio de las fórmulas 9-2 y 9-3. Los siguientes valores ya se obtuvieron en la tabla 9-2, en la sección 9-2.

$$n = 4 \qquad \Sigma x = 10 \qquad \Sigma y = 20$$
$$\Sigma x^2 = 36 \qquad \Sigma y^2 = 120 \qquad \Sigma xy = 48$$

continúa



Error de pronóstico de 1° = mil millones de dólares

A pesar de que el pronóstico de las temperaturas a veces parece una ciencia inexacta, muchas compañías están trabajando con fervor para obtener estimados más precisos. El reportero de *USA Today*, Del Jones, escribió que "el costo anual de la electricidad podría disminuir por lo menos mil millones de dólares si se mejorara la precisión de las predicciones del tiempo en 1 grado Fahrenheit". Al referirse a las autoridades de Tennessee Valley, afirma que "los pronósticos sobre sus 80,000 millas cuadradas han fallado un promedio de 2.35 grados durante los últimos dos años, que es bastante representativo de los pronósticos que se hacen a nivel nacional. Si se mejorara en 1.35 grados, esto ahorraría al Tennessee Valley tanto como $100,000 diarios y tal vez más". El pronóstico de temperaturas se utiliza para determinar la ubicación de la energía proveniente de generadores, plantas nucleares, plantas hidroeléctricas, carbón, gas natural y del viento. Las técnicas de pronóstico estadístico están siendo refinadas, de modo que se pueda ahorrar dinero y recursos naturales.



Teléfonos celulares y choques

Debido a que algunos países han prohibido el uso de teléfonos celulares en los automóviles y a que otros países están considerando dicha prohibición, algunos investigadores estudiaron si el empleo de teléfonos celulares al conducir incrementa la posibilidad de un choque. Se obtuvo una muestra de 699 conductores. Los miembros del grupo muestral utilizaron teléfonos celulares y sufrieron choques. Los sujetos completaron cuestionarios y se verificaron sus registros telefónicos. Se comparó el intervalo de tiempo entre el uso del teléfono celular y el choque, con un periodo comparable del día anterior. Conclusión: El riesgo de chocar es cuatro veces mayor cuando se utiliza un teléfono celular que cuando no se utiliza. (Véase "Association between Cellular-Telephone Calls and Motor Vehicle Collisions", de Redelmeier y Tibshirani, *New England Journal of Medicine,* vol. 336, núm. 7).

Primero calcule la pendiente b_1 con la fórmula 9-2:

$$b_1 = \frac{n(\Sigma xy) - (\Sigma x)(\Sigma y)}{n(\Sigma x^2) - (\Sigma x)^2}$$
$$= \frac{4(48) - (10)(20)}{4(36) - (10)^2} = \frac{-8}{44} = -0.181818 = -0.182$$

Después, calcule b_0, el intercepto de y, con la fórmula 9-3 (con $\bar{y} = 20/4 = 5$ y $\bar{x} = 10/4 = 2.5$):

$$b_0 = \bar{y} - b_1\bar{x}$$
$$= 5 - (-0.181818)(2.5) = 5.45$$

Conociendo la pendiente b_1 y b_0, el intercepto de y, ahora podemos expresar la ecuación estimada de la recta de regresión como

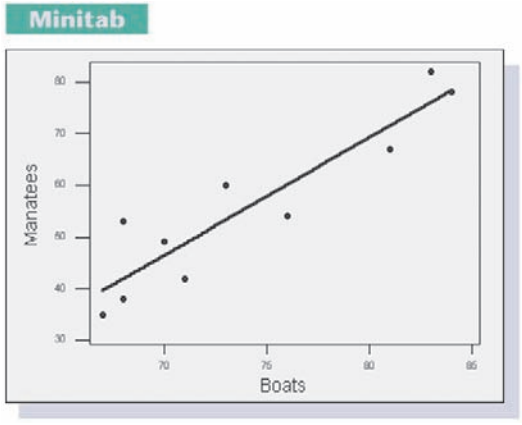
$$\hat{y} = 5.45 - 0.182x$$

Debemos estar conscientes de que esta ecuación es un *estimado* de la verdadera ecuación de regresión $y = \beta_0 + \beta_1 x$. Este estimado se basa en un conjunto particular de datos muestrales, pero otra muestra obtenida de la misma población probablemente produciría una ecuación ligeramente diferente.



EJEMPLO Barcos y manatíes Con los datos barco/manatí de la tabla 9-1 obtuvimos que el coeficiente de correlación lineal es $r = 0.922$. Utilice los mismos datos muestrales para calcular la ecuación de la recta de regresión.

SOLUCIÓN Si utilizamos el mismo procedimiento ilustrado en el ejemplo anterior, o empleamos herramientas tecnológicas, podemos obtener que los 10 pares de datos barco/manatí de la tabla 9-1 dan como resultado $b_0 = -113$ y $b_1 = 2.27$. Los resultados de Minitab se presentan en la página siguiente. Sustituyendo los valores calculados para b_0 y b_1, expresamos la ecuación de regresión como $\hat{y} = -113 + 2.27x$. A continuación se muestra el diagrama de dispersión generado por Minitab, con la recta de regresión incluida. Podemos ver que la recta de regresión se ajusta bien a los datos.



Minitab

```
The regression equation is

Manatees = −113 + 2.27 Boats

Predictor          Coef     SE Coef         T         P
Constant       −112.71       25.19     −4.47     0.002
Boats           2.2741      0.3388      6.71     0.000

S = 6.612       R-Sq = 84.9%   R-Sq(adj) = 83.0%
```

Uso de la ecuación de regresión para hacer predicciones

Las ecuaciones de regresión resultan útiles cuando se emplean para *predecir* el valor de una variable, a partir de algún valor particular de la otra variable. Si la recta de regresión se ajusta bastante bien a los datos, entonces es sensato utilizar esta ecuación para hacer predicciones, ya que no vamos más allá de los valores disponibles. Sin embargo, *debemos utilizar la ecuación de la recta de regresión sólo si r indica que existe una correlación lineal. En ausencia de una correlación lineal no debemos emplear la ecuación de regresión para proyectar o predecir; en su lugar, el mejor estimado de la segunda variable es sencillamente su media muestral.*

Al predecir un valor de *y* con base en algún valor dado de *x*. . .

1. **Si *no* existe una correlación lineal, el mejor valor predicho de *y* es $\bar{y}$.**
2. **Si existe una correlación lineal, el mejor valor predicho de *y* se calcula sustituyendo el valor de *x* en la ecuación de regresión.**

La figura 9-8 en la siguiente página resume este proceso, el cual se comprende con mayor facilidad si pensamos en *r* como una medida de qué tan bien se ajusta la recta de regresión a los datos muestrales. Si *r* se acerca a −1 o +1, entonces la recta de regresión se ajusta bien a los datos, pero si *r* es cercana a 0, entonces la recta de regresión se ajusta muy poco (y no debe emplearse para hacer predicciones).



EJEMPLO Predicción de muertes de manatíes Con los datos muestrales de la tabla 9-1, encontramos que existe una correlación lineal significativa entre el número de barcos registrados y la cantidad de manatíes asesinados por los barcos; también encontramos que la ecuación de regresión es $\hat{y} = -113 + 2.27x$. Suponga que en el año 2001 había 850,000 barcos registrados. Puesto que la tabla 9-1 lista el número de barcos registrados en decenas de miles, esto significa que para 2001 tenemos $x = 85$. Ya que $x = 85$, calcule el mejor valor predicho de *y*, el número de manatíes asesinados por barcos.

SOLUCIÓN Existe una fuerte tentación de brincar y sustituir *x* por 85 en la ecuación de regresión, pero primero debemos considerar si existe una correlación lineal que justifique el uso de dicha ecuación. En este ejemplo, tenemos

continúa



La pizza se correlaciona con la crisis

Cuando el Congreso de Estados Unidos amenazó al ex presidente Clinton con enjuiciarlo, los empleados del gobierno trabajaron hasta tarde y ordenaron un número récord de pizzas. Frank Meeks, dueño de 59 tiendas de Domino's Pizza en Washington, D.C. reportó que el sábado en el punto culminante de la crisis de la amenaza de juicio, las entregas de pizza a Capitol Hill excedieron los $10,000, mientras que las entregas de pizza a la Casa Blanca totalizaron $3,000. Meeks señaló que las ventas de pizzas también se incrementaron durante la Guerra del Golfo Pérsico y suelen aumentar anualmente durante los debates en torno al presupuesto.

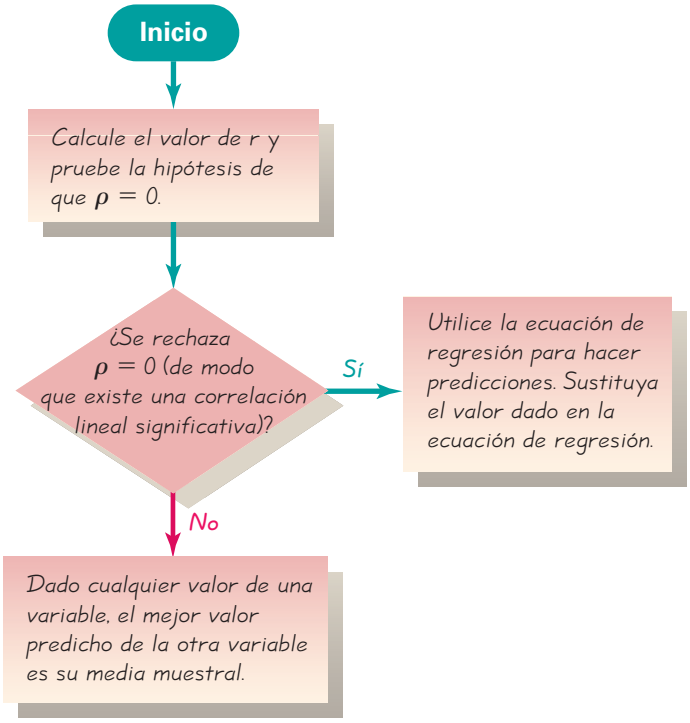


FIGURA 9-8 **Procedimiento para hacer predicciones**

una correlación lineal significativa (con $r = 0.922$), por lo que el valor predicho se calcula de la siguiente manera:

$$\hat{y} = -113 + 2.27x$$
$$= -113 + 2.27(85) = 80.0$$

El número predicho de muertes de manatíes, a partir de 850,000 barcos registrados, es de 80.0. (Si no hubiese una correlación lineal significativa, el mejor valor predicho sería $\bar{y} = 558/10 = 55.8$). El número real de muertes de manatíes por barcos en 2001 fue de 82, de modo que el valor predicho de 80.0 es bastante cercano.

EJEMPLO **Medida de sombrero y CI** Evidentemente no existe una correlación lineal entre la medida de sombrero y las puntuaciones de CI de adultos. Como un individuo utiliza un sombrero de tamaño 7, calcule el mejor valor predicho de la puntuación de CI de esta persona.

SOLUCIÓN Puesto que no existe una correlación lineal, no empleamos una ecuación de regresión. No hay necesidad de reunir datos muestrales apareados consistentes de la medida de sombrero y de la puntuación de CI de una muestra de adultos seleccionados aleatoriamente. En su lugar, la mejor puntuación de CI predicho es sencillamente el CI medio de todos los adultos, que es de 100.

Compare con cuidado las soluciones de los dos ejemplos anteriores y note que utilizamos la ecuación de regresión cuando existía una correlación lineal, pero en ausencia de dicha correlación, el mejor valor predicho de y es sencillamente el va-

lor de la media muestral $\bar{y}$. Un error común es el uso de la ecuación de regresión para hacer una predicción cuando no existe una correlación lineal. Este error viola el primero de los siguientes lineamientos.

Lineamientos para el uso de la ecuación de regresión

1. *Si no existe una correlación lineal, no utilice la ecuación de regresión para hacer predicciones.*
2. *Cuando utilice la ecuación de regresión para hacer predicciones, permanezca en el ámbito de los datos muestrales disponibles*. Si usted calcula una ecuación de regresión que relaciona la estatura y el número de calzado de mujeres, es absurdo predecir el número de calzado de una mujer que mide 10 pies de estatura.
3. *Una ecuación de regresión que está basada en datos antiguos no necesariamente es válida ahora.* La ecuación de regresión que relaciona precios de automóviles usados con la antigüedad de los automóviles ya no es útil si está basada en datos de los años 1970.
4. *No haga predicciones acerca de una población distinta de la población de donde se obtuvieron los datos muestrales*. Si reunimos datos muestrales de hombres y desarrollamos una ecuación de regresión que relaciona edad y uso del control remoto del televisor, los resultados no necesariamente se aplican a las mujeres. Si empleamos *promedios* estatales para desarrollar una ecuación de regresión que relaciona las calificaciones de matemáticas del SAT con las calificaciones verbales del SAT, los resultados no necesariamente se aplican a los *individuos*.

Interpretación de la ecuación de regresión: cambio marginal

Podemos utilizar la ecuación de regresión para observar el efecto en una variable, cuando la otra variable cambia una cantidad específica.

Definición

Cuando se trabaja con dos variables relacionadas por una ecuación de regresión, el **cambio marginal** en una variable es la cantidad que cambia cuando la otra variable cambia exactamente una unidad. La pendiente b_1 en la ecuación de regresión representa el cambio marginal que ocurre en y cuando x cambia una unidad.

Para los datos barco/manatí de la tabla 9-1, la recta de regresión tiene una pendiente de 2.27, lo que demuestra que si incrementamos x (el número de barcos registrados en decenas de miles) en una unidad, el número predicho de muertes se incrementará en 2.27 manatíes. Es decir, por cada 10,000 barcos adicionales registrados, esperamos aproximadamente 2.27 muertes adicionales de manatíes debidas a los barcos.

Datos distantes y puntos de influencia

Un análisis de correlación/regresión de datos bivariados (apareados) debe incluir la investigación de *datos distantes* y *puntos de influencia*, que se definen de la siguiente manera.

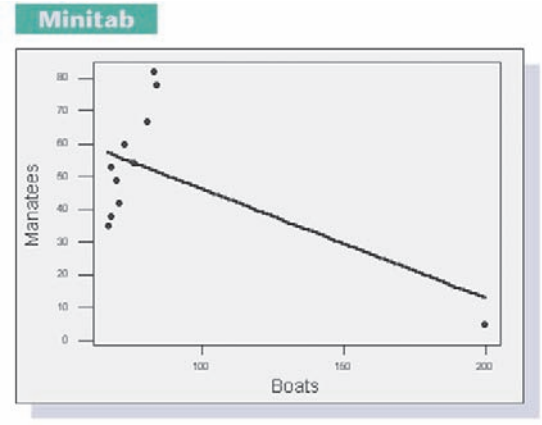
Definiciones

En un diagrama de dispersión, un **dato distante** es un punto que aparece muy lejos de los otros puntos de datos.

Los datos muestrales apareados incluyen uno o más **puntos de influencia**, que son puntos que afectan fuertemente la gráfica de la recta de regresión.

Es fácil identificar un dato distante: examine el diagrama de dispersión e identifique un punto que se aleja de los otros puntos. He aquí cómo determinar un punto de influencia: grafique la recta de regresión que resulta de los datos con el punto incluido, después grafique la recta de regresión resultante de los datos sin incluir el punto. Si la gráfica cambia de forma considerable, se trata de un punto de influencia. Los puntos de influencia con frecuencia se encuentran al identificar los datos distantes que están *horizontalmente* alejados de los demás puntos.

Por ejemplo, remítase a los resultados previos de Minitab. Suponga que incluimos el siguiente par adicional de datos: $x = 200$, $y = 5$ (en un año con 2,000,000 de barcos registrados, únicamente cinco manatíes fueron asesinados por barcos). Este punto adicional sería un punto de influencia debido a que la gráfica de la recta de regresión cambiaría considerablemente, tal como se muestra en la siguiente pantalla de Minitab. Compare esta recta de regresión con la que se presentó en la imagen previa de Minitab y observará con claridad que la añadidura de ese par de valores tiene un efecto importante en la recta de regresión.



Residuales y la propiedad de los mínimos cuadrados

Hemos establecido que la ecuación de regresión representa la recta que se ajusta "mejor" a los datos, y ahora describiremos el criterio utilizado para determinar la recta que es mejor que todas las demás. Este criterio se basa en las distancias verticales entre los puntos de datos originales y la recta de regresión. Dichas distancias se denominan *residuales*.

Definición

Para una muestra de datos apareados (x,y), un **residual** es la diferencia $(y - \hat{y})$ entre un valor y muestral observado y el valor de $\hat{y}$, que es el valor de y predicho por medio de la ecuación de regresión. Es decir,

$$\text{residual} = y \text{ observada} - y \text{ predicha} = y - \hat{y}$$

Esta definición tal vez parezca tan clara como las instrucciones de una forma de impuestos, pero usted comprenderá fácilmente los residuales si se remite a la figura 9-9, que corresponde a los datos muestrales apareados que se listan a continuación. En la figura 9-9, los residuales están representados por las líneas punteadas. Para tener un ejemplo específico, observe el residual indicado como 7, que se encuentra directamente por arriba de $x = 5$. Si sustituimos $x = 5$ en la ecuación de regresión $\hat{y} = 5 + 4x$, obtenemos un valor predicho de $\hat{y} = 25$. Cuando $x = 5$, el valor *predicho* de y es $\hat{y} = 25$, pero el valor muestral real *observado* es $y = 32$. La diferencia $y - \hat{y} = 32 - 25 = 7$ es un residual.

x	1	2	4	5
y	4	24	8	32

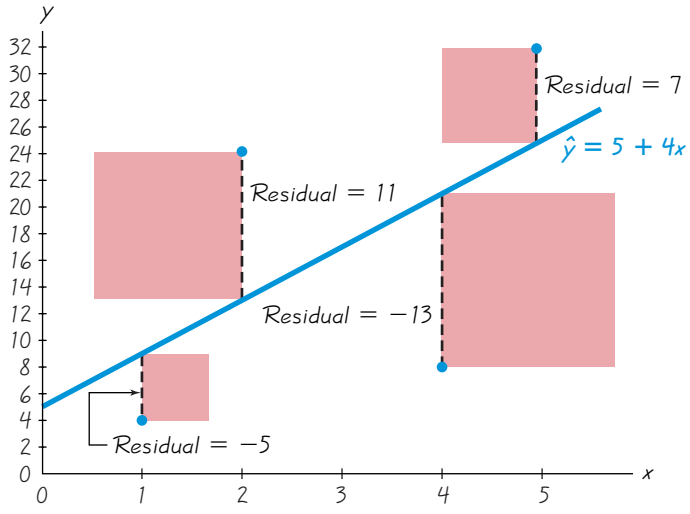


FIGURA 9-9 **Residuales y cuadrados de residuales**

La ecuación de regresión representa la recta que se ajusta "mejor" a los puntos, según la siguiente *propiedad de mínimos cuadrados*.

Definición

Una recta satisface la **propiedad de mínimos cuadrados** si la suma de los cuadrados de los residuales es la menor suma posible.

En la figura 9-9 podemos observar que los residuales son −5, 11, −13 y 7, de modo que la suma de sus cuadrados es

$$(-5)^2 + 11^2 + (-13)^2 + 7^2 = 364$$

Podemos visualizar la propiedad de mínimos cuadrados si nos remitimos a la figura 9-9, donde los cuadrados de los residuales están representados por las áreas de los cuadrados sombreados. La suma de las áreas cuadradas es 364, que es la menor suma posible. Utilice cualquier otra recta y los cuadrados se combinarán para producir una área mayor que el área combinada de 364.

Por fortuna, no necesitamos enfrentar directamente la propiedad de mínimos cuadrados cuando deseamos obtener la ecuación de la recta de regresión. Ya se realizaron los cálculos para satisfacer la propiedad de mínimos cuadrados en las fórmulas 9-2 y 9-3. Puesto que en las derivaciones de estas fórmulas se requiere del cálculo, no las incluimos en este libro.



Utilizando la tecnología

Debido a los cálculos complejos implicados, el coeficiente de correlación lineal *r*, la pendiente y el intercepto *y* de la recta de regresión suelen calcularse por medio de una calculadora o un programa de cómputo.

STATDISK Seleccione **Analysis** de la barra del menú principal, después utilice la opción **Correlation and Regression**. Introduzca los datos apareados o use copiar/pegar para copiar los datos. Introduzca los valores de *x* en la columna 1 y los valores de *y* correspondientes en la columna 2. Introduzca un valor para el nivel de significancia. Haga clic en el botón de **Evaluate**. Los resultados de STATDISK incluyen el valor del coeficiente de correlación lineal, junto con el valor crítico de *r*, la conclusión acerca de la correlación, y el intercepto y la pendiente de la ecuación de regresión, así como otros resultados. Haga clic en **Plot 1** para obtener una gráfica del diagrama de dispersión con la recta de regresión incluida.

Minitab Primero introduzca los valores de *x* en la columna C1 y los valores de *y* en la columna C2. En la sección 9-2 vimos que podemos obtener el valor del coeficiente de correlación lineal *r* seleccionando **Stat/Basic Statistics/Correlation**. Para obtener la ecuación de la recta de regresión, seleccione **Stat/Regression/Regression** e introduzca C2 en "respuesta" y C1 en "predictor". Para obtener la gráfica del diagrama de dispersión con la recta de regresión, seleccione **Stat/Regression/Fitted Line Plot**, después introduzca C2 en la variable de respuesta y C1 en la variable predictora. Seleccione el modelo "lineal".

Excel Introduzca los datos apareados en las columnas A y B. Utilice el complemento de análisis de datos de Excel seleccionando **Tools** del menú principal, después seleccione **Data Analysis** y **Regression**, luego haga clic en **OK**. Introduzca el rango para los valores de *y*, tal como B1:B10. Introduzca el rango para los valores de *x*, tal como A1:A10. Haga clic en el recuadro adyacente a Line Fit Plots, después haga clic en **OK**. De toda la información proporcionada por Excel, la pendiente y el intercepto de la ecuación de regresión aparecen en la tabla con el encabezado "coeficiente". La gráfica presentada incluirá un diagrama de dispersión de los puntos muestrales originales, junto con los puntos que serían predichos por la ecuación de regresión. Fácilmente puede obtener la recta de regresión conectando los puntos "predichos de *y*".

Para emplear el complemento Data Desk XL, haga clic en **DDXL** y seleccione **Regression**, luego haga clic en el recuadro Function Type y seleccione **Simple Regression**. Haga clic en el icono del lápiz para la variable de respuesta e introduzca el rango de valores para la variable *y* (o dependiente). Haga clic en el icono del lápiz para la variable explicatoria e introduzca el rango de valores para la variable *x* (o independiente). Haga clic en **OK**. La pendiente y el intercepto de la ecuación de regresión se encuentran en la tabla con el encabezado "coeficiente".

TI-83 Plus Introduzca los datos apareados en las listas L1 y L2, luego presione **STAT** y seleccione **TESTS**; después elija la opción **LinRegTTest.** El despliegue de resultados incluirá el intercepto de *y* y la pendiente de la ecuación de regresión. La calculadora TI-83 Plus representa los valores b_0 y b_1 como *a* y *b*.

9-3 Destrezas y conceptos básicos

Haciendo predicciones. *En los ejercicios 1 a 4, utilice los datos dados para calcular el mejor valor predicho de la variable dependiente. Asegúrese de seguir el procedimiento para predicciones descrito en esta sección.*

1. En cada uno de los casos siguientes, calcule el mejor valor predicho de y, puesto que $x = 3.00$. Los estadísticos dados se resumen a partir de datos muestrales apareados.
- **a.** $r = 0.987$, $\bar{y} = 5.00$, $n = 20$, y la recta de la ecuación de regresión es $\hat{y} = 6.00 + 4.00x$.
- **b.** $r = 0.052$, $\bar{y} = 5.00$, $n = 20$, y la recta de la ecuación de regresión es $\hat{y} = 6.00 + 4.00x$.

2. En cada uno de los casos siguientes, calcule el mejor valor predicho de y, puesto que $x = 2.00$. Los estadísticos dados se resumen a partir de datos muestrales apareados.
- **a.** $r = -0.123$, $\bar{y} = 8.00$, $n = 30$, y la recta de la ecuación de regresión es $\hat{y} = 7.00 - 2.00x$.
- **b.** $r = -0.567$, $\bar{y} = 8.00$, $n = 30$, y la recta de la ecuación de regresión es $\hat{y} = 7.00 - 2.00x$.

3. Tamaño del pecho y peso de osos Cuando se anestesió a ocho osos, algunos investigadores midieron las distancias (en pulgadas) alrededor de su pecho y pesaron a los osos (en libras). Se utilizó Minitab para calcular que el valor del coeficiente de correlación lineal es $r = 0.993$ y la recta de la ecuación de regresión es $\hat{y} = -187 + 11.3x$, donde x representa el tamaño del pecho. Además, el peso medio de los ocho osos es de 234.5 libras. ¿Cuál es el mejor peso predicho de un oso con un pecho de 52 pulgadas?

4. Acciones y Súper Bowl El conjunto de datos 25 del Apéndice B incluye pares de datos del valor más alto del Promedio Industrial de Dow-Jones (DJIA) y el número total de puntos anotados en el Súper Bowl, durante 21 años distintos. Se utilizó Excel para calcular que el valor del coeficiente de correlación lineal es $r = -0.133$ y que la ecuación de regresión es $\hat{y} = 53.3 - 0.000442x$, donde x es el valor más alto del DJIA. Además, la media de los puntos anotados en el Súper Bowl es de 51.4. ¿Cuál es el mejor valor predicho para el número total de puntos anotados en el Súper Bowl en un año, con un valor alto del DJIA de 1200?

Cálculo de la ecuación de la recta de regresión. *En los ejercicios 5 y 6, utilice los datos dados para calcular la ecuación de la recta de regresión.*

5.

x	0	1	2	3	4
y	4	1	0	1	4

6.

x	1	2	2	5	6
y	2	5	4	15	15

7. Efectos de un dato distante Remítase al diagrama de dispersión generado por Minitab que se presenta en el ejercicio 7 de la sección 9-2.
- **a.** Utilice los pares de valores de los 10 puntos y calcule la ecuación de la recta de regresión.
- **b.** Después de eliminar el punto con las coordenadas (10, 10), utilice los pares de valores de los nueve puntos restantes y calcule la ecuación de la recta de regresión.
- **c.** Compare los resultados de los incisos *a* y *b*.

Cálculo de la ecuación de la recta de regresión y predicciones. *En los ejercicios 8 a 24, utilice los mismos conjuntos de datos que en los ejercicios de la sección 9-2. En cada caso, calcule la ecuación de regresión, permitiendo que la primera variable sea la variable independiente (x). Calcule los valores predichos indicados.* Cuidado: *Al calcular los valores predichos, asegúrese de seguir los procedimientos para predicciones descritos en esta sección.*

8. Incendios y acres quemados Calcule el mejor valor predicho para el número de acres quemados, considerando que hubo 80 incendios.

Incendios	73	69	58	48	84	62	57	45	70	63	48
Acres quemados	6.2	4.2	1.9	2.7	5.0	1.6	3.0	1.6	1.5	2.0	3.7

9. Compra de una audiencia televisiva Calcule el mejor valor predicho para el número de televidentes (en millones), considerando que el salario (en millones de dólares) de la estrella de televisión Jennifer Anniston es de $16 millones. ¿De qué forma se compara el valor predicho con el número real de televidentes, que fue de 24 millones?

Salario	100	14	14	35.2	12	7	5	1
Televidentes	7	4.4	5.9	1.6	10.4	9.6	8.9	4.2

10. Estaturas y pesos de supermodelos Calcule el mejor peso predicho de una supermodelo que mide 69 pulgadas.

Estatura (pulgadas)	71	70.5	71	72	70	70	66.5	70	71
Peso (libras)	125	119	128	128	119	127	105	123	115

11. Mediciones de la presión sanguínea Calcule la mejor presión sanguínea diastólica predicha para una persona con una lectura sistólica de 122.

Sistólica	138	130	135	140	120	125	120	130	130	144	143	140	130	150
Diastólica	82	91	100	100	80	90	80	80	80	98	105	85	70	100

12. Temperaturas y maratones Calcule el mejor tiempo ganador predicho para la maratón de 1990, ya que la temperatura era de 73 grados. ¿De qué forma se compara el valor predicho con el tiempo ganador real de 150.750 minutos?

x (temperatura)	55	61	49	62	70	73	51	57
y (tiempo)	145.283	148.717	148.300	148.100	147.617	146.400	144.667	147.533

13. Tabaquismo y nicotina Calcule el mejor nivel de cotinina predicho para una persona que fuma 40 cigarrillos diarios.

x (cigarrillos por día)	60	10	4	15	10	1	20	8	7	10	10	20
y (cotinina)	179	283	75.6	174	209	9.51	350	1.85	43.4	25.1	408	344

14. Circunferencia y altura de árboles Calcule la mejor altura predicha de un árbol que tiene una circunferencia de 4.0 pies. ¿Cuál es una de las ventajas de poder determinar la altura de un árbol a partir de su circunferencia?

x (circunferencia)	1.8	1.9	1.8	2.4	5.1	3.1	5.5	5.1	8.3	13.7	5.3	4.9	3.7	3.8
y (altura)	21.0	33.5	24.6	40.7	73.2	24.9	40.4	45.3	53.5	93.8	64.0	62.7	47.2	44.3

T **15.** Cereales asesinos Remítase al conjunto de datos 16 del Apéndice B y utilice las cantidades de grasa (x) y los conteos calóricos medidos (y). Calcule el mejor conteo calórico predicho para un cereal con 0.05 gramos de grasa por gramo de cereal.

T **16.** Tabaco y alcohol en películas infantiles Remítase al conjunto de datos 7 del Apéndice B y utilice los tiempos que las películas infantiles de dibujos animados presentan consumo de tabaco (x) y alcohol (y). Calcule el mejor tiempo predicho para el consumo de alcohol, dado que una película no muestre consumo de tabaco.

T **17.** Colesterol e índice de masa corporal Remítase al conjunto de datos 1 del Apéndice B y utilice los niveles de colesterol (x) y los valores del índice de masa corporal (y) de las 40 mujeres. ¿Cuál es el mejor valor predicho del índice de masa corporal de una mujer que tiene un nivel de colesterol de 500?

T **18.** Niveles de lectura Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones de la facilidad de lectura de Flesch (x) y los valores del grado Flesch-Kincaid (y) para *El oso y el dragón*, de Tom Clancy. Calcule el mejor valor predicho del grado de Flesch-Kincaid para una página con una puntuación de facilidad de lectura de Flesch de 50.0.

T **19.** Precios de venta de casas, precios de lista e impuestos Remítase al conjunto de datos 24 del Apéndice B. *Cuidado*: Los valores muestrales de los precios de lista y los precios de venta están en miles de dólares, pero las cantidades de los impuestos están en dólares.

a. Utilice los datos apareados de los precios de lista (x) y de los precios de venta (y) de casas. ¿Cuál es el mejor precio de venta predicho para una casa con un precio de lista de $200,000?

b. Utilice los datos apareados que consisten en el precio de venta de casas (x) y la suma de impuestos (y). ¿Cuál es el mejor cargo de impuestos predicho para una casa que se vendió en $400,000?

T **20.** Alquitrán y nicotina Remítase al conjunto de datos 5 del Apéndice B.

a. Utilice los datos apareados de alquitrán (x) y nicotina (y). ¿Cuál es el mejor nivel de nicotina predicho para un cigarrillo que contiene 15 mg de alquitrán?

b. Utilice los datos apareados de monóxido de carbono (x) y nicotina (y). ¿Cuál es el mejor nivel de nicotina predicho para un cigarrillo que contiene 15 mg de monóxido de carbono?

T **21.** Pronóstico del tiempo Remítase al conjunto 10 de datos del Apéndice B.

a. Utilice el pronóstico de altas temperaturas para cinco días (x) y las temperaturas altas reales (y). ¿Cuál es la mejor temperatura alta real predicha, si la temperatura alta pronosticada a cinco días es de 28 grados?

b. Utilice el pronóstico de altas temperaturas para un día (x) y las temperaturas altas reales (y). ¿Cuál es la mejor temperatura alta real predicha, si la temperatura alta pronosticada para un día es de 28 grados?

c. ¿Cuál de los valores predichos es mejor: el resultado del inciso *a* o el resultado del inciso *b*? ¿Por qué?

T **22.** Everglades de Florida Remítase al conjunto de datos 12 del Apéndice B.

a. tilice las temperaturas inferiores (x) y las mediciones de conductividad (y). ¿Cuál es la mejor medición de conductividad predicha para un tiempo en el que la temperatura más baja es de 30.0°C?

b. Utilice las cantidades de lluvia (x) y las mediciones de conductividad (y). ¿Cuál es la mejor medición de conductividad predicha para un tiempo en que la cantidad de lluvia es de 0.00 pulgadas?

c. Después de identificar la mejor medición de conductividad predicha en los incisos *a* y *b*, ¿será preciso alguno de los valores predichos? ¿Por qué?

T **23.** Old Faithful Remítase al conjunto de datos 13 del Apéndice B.

a. Utilice los datos apareados de las duraciones (x) y los intervalos posteriores a las erupciones del géiser (y). ¿Cuál es el mejor tiempo predicho antes de la siguiente erupción, si la última erupción duró 210 segundos?

b. Utilice los datos apareados de las alturas de las erupciones (x) y de los intervalos después de las erupciones (y) del géiser Old Faithful. ¿Cuál es el mejor tiempo predicho antes de la siguiente erupción, si la última erupción alcanzó una altura de 275 pies?

c. ¿Cuál tiempo predicho es mejor: el resultado del inciso *a* o el resultado del inciso *b*? ¿Por qué?

T **24.** Precios, quilates y colores de diamantes Remítase al conjunto de datos 18 del Apéndice B.

a. Utilice los datos apareados del peso en quilates (x) y el precio (y). ¿Cuál es el mejor precio predicho de un diamante con un peso de 1.5 quilates?

b. Utilice los datos apareados de color (x) y precio (y). ¿Cuál es el mejor precio predicho para un diamante con un rango de color de 3?

c. ¿Cuál precio predicho es mejor: el resultado del inciso *a* o el resultado del inciso *b*? ¿Por qué?

25. Identificación de datos distantes y puntos de influencia Remítase a los datos muestrales listados en la tabla 9-1. Si incluimos otro par de valores consistente en $x = 120$ (para 1,200,000 barcos) y $y = 160$ (muertes de manatíes por barcos), ¿será el nuevo punto un dato distante? ¿Será un punto de influencia?

26. Identificación de puntos de influencia Remítase a los datos muestrales listados en la tabla 9-1. Si incluimos otro par de valores consistentes en $x = 120$ (para 1,200,000 barcos) y $y = 10$ (muertes de manatíes por barcos), ¿será el nuevo punto un dato distante? ¿Será un punto de influencia?

9-3 Más allá de lo básico

27. ¿De qué manera se ve afectada una ecuación de regresión por un cambio en la escala? Los números grandes, tales como los que se incluyen la tabla adjunta, suelen causar problemas de cálculo. Primero utilice los datos proporcionados para calcular la ecuación de la recta de regresión, después calcule la ecuación de la recta de regresión una vez que cada valor de x se ha dividido entre 1000. ¿Cómo se ven afectados los resultados por el cambio en x? ¿De qué forma se afectarían los resultados si cada valor de y se dividiera entre 1000?

x	924,736	832,985	825,664	793,427	857,366
y	142	111	109	95	119

x	1	2	4	5
y	4	24	8	32

28. Prueba de la propiedad de mínimos cuadrados Según la propiedad de mínimos cuadrados, la recta de regresión minimiza la suma de los cuadrados de los residuales. Señalamos que, con los datos apareados al margen, la ecuación de regresión que $\hat{y} = 5 + 4x$ y la suma de cuadrados de los residuales es 364. Demuestre que la ecuación $\hat{y} = 8 + 3x$ da como resultado una suma de cuadrados de residuales mayor que 364.

29. Uso de logaritmos para transformar datos Si un diagrama de dispersión revela un patrón no lineal (sin una recta), que usted reconoce como otro tipo de curva, podría aplicar los métodos de esta sección. Para los datos presentados al margen, calcule la ecuación lineal ($y = b_0 + b_1x$) que se ajusta mejor a los datos muestrales, y calcule la

ecuación logarítmica ($y = a + b \ln x$) que se ajusta mejor a los datos muestrales. (*Sugerencia:* Inicie reemplazando cada valor de x por $\ln x$). ¿Cuál de estas dos ecuaciones se ajusta mejor a los datos? ¿Por qué?

x	2.0	2.5	4.2	10.0
y	12.0	18.7	53.0	225.0

30. Pruebas de hipótesis equivalentes Explique por qué una prueba de la hipótesis nula H_0: $\rho = 0$ es equivalente a una prueba de la hipótesis nula H_0: $\beta_1 = 0$, donde ρ es el coeficiente de correlación lineal de una población de datos apareados, y β_1 es la pendiente de la recta de regresión de esa misma población.

31. Gráfica residual Un diagrama de dispersión es una gráfica de los datos muestrales apareados (x,y). Una **gráfica residual** es la gráfica de los puntos con las mismas coordenadas de x, pero donde las coordenadas correspondientes de y son valores residuales. Para construir una gráfica residual, utilice el mismo eje x que en el diagrama de dispersión, pero elabore un eje vertical para los valores residuales. Dibuje una línea horizontal de referencia a lo largo del valor residual de 0, después grafique los valores apareados de (*x*, residual). Las gráficas residuales son útiles para identificar patrones que sugieren que la relación entre las variables es no lineal, o que el supuesto de las varianzas constantes no se satisface. Construya una gráfica residual para los datos de la tabla 9-1. ¿Existe algún patrón sobresaliente?

9-4 Variación e intervalos de predicción

Hasta ahora, hemos utilizado datos muestrales apareados para probar una correlación lineal entre x y y, y para identificar la ecuación de regresión. En esta sección continuamos analizando datos apareados (x,y), conforme procedemos a considerar distintos tipos de variación que se emplean para dos aplicaciones principales:

1. Para determinar la proporción de variación en y que se explica por la relación lineal entre x y y.
2. Para construir estimados de intervalos de valores predichos de y. Dichos intervalos se denominan *intervalos de predicción*, que se definirán de manera formal más adelante en esta sección.

Variación explicada y sin explicar

En la sección 9-2 introdujimos el concepto de correlación y empleamos el coeficiente de correlación lineal r para determinar si existe una correlación lineal significativa entre dos variables, denotadas por x y y. Además de servir como una medida de la correlación lineal entre dos variables, el valor de r también nos proporciona información adicional acerca de la variación de puntos muestrales respecto a la recta de regresión. Iniciamos con un caso muestral, que nos conduce a una definición importante (coeficiente de determinación).

Suponga que tenemos un gran conjunto de datos apareados con estos resultados:

- Existe una correlación lineal significativa.
- La ecuación de la recta de regresión es $\hat{y} = 3 + 2x$.
- La media de los valores de y está dada por $\bar{y} = 9$.
- Uno de los pares de datos muestrales es $x = 5$ y $y = 19$.



Diferencia en el salario por género

Aunque un reporte reciente de la revista *Working Woman* afirma que la diferencia del salario con base en el género está disminuyendo, en su mayoría, los hombres aún poseen los empleos con sueldos más altos. Los datos más recientes indican que, en promedio, las mujeres que trabajan tiempo completo ganan aproximadamente 73 centavos por cada dólar ganado por hombres que trabajan tiempo completo. Investigadores del Institute for Social Research, en la Universidad de Michigan, analizaron los efectos de diversos factores clave y encontraron que cerca de una tercera parte de la discrepancia entre los salarios de hombres y mujeres puede explicarse por diferencias en educación, antigüedad, interrupciones en el trabajo y opciones de empleo. Las restantes dos terceras partes continúan sin poder explicarse mediante este tipo de factores laborales.

- El punto (5, 13) es uno de los puntos sobre la recta de regresión, ya que al sustituir $x = 5$ en la ecuación de regresión, resulta $\hat{y} = 13$.

$$\hat{y} = 3 + 2x = 3 + 2(5) = 13$$

La figura 9-10 indica que el punto (5, 13) está sobre la recta de regresión, pero el punto (5, 19) proviene del conjunto de datos original y no está sobre la recta de regresión, debido a que no satisface la ecuación de regresión. Tome su tiempo para examinar cuidadosamente la figura 9-10 y observe las diferencias, definidas de la siguiente manera.

Desviación sin explicar, explicada y total

Definiciones

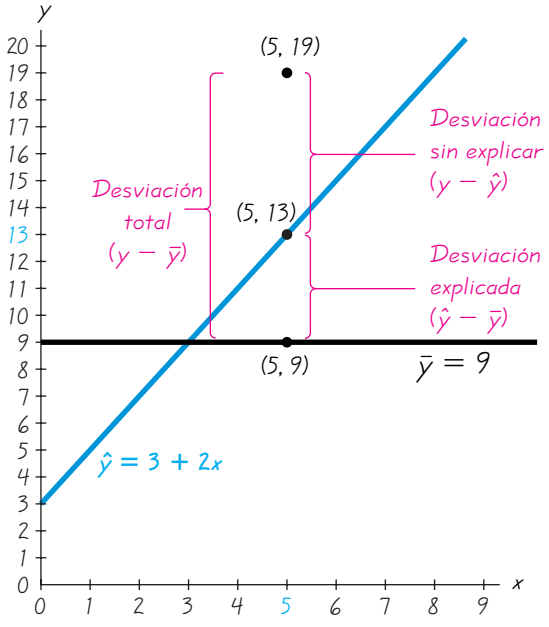
Suponga que tenemos un conjunto de datos apareados que contienen el punto muestral (x,y), que $\hat{y}$ es el valor predicho de y (obtenido por medio de la ecuación de regresión), y que la media de los valores y muestrales es $\bar{y}$.

La **desviación total** (a partir de la media) del punto particular (x,y) es la distancia vertical $y - \bar{y}$, que es la distancia entre el punto (x,y) y la recta horizontal que pasa por la media muestral $\bar{y}$.

La **desviación explicada** es la distancia vertical $\hat{y} - \bar{y}$, que es la distancia entre el valor predicho y y la recta horizontal que pasa por la media muestral $\bar{y}$.

La **desviación sin explicar** es la distancia vertical $y - \hat{y}$, que es la distancia vertical entre el punto (x,y) y la recta de regresión. (La distancia $y - \hat{y}$ también se conoce como un *residual*, tal como se definió en la sección 9-3.)

FIGURA 9-10 **Desviación sin explicar, explicada y total**



Para los datos específicos bajo consideración, obtenemos los siguientes resultados:

Desviación total de (5, 19) $= y - \bar{y} = 19 - 9 = 10$

Desviación explicada de (5, 19) $= \hat{y} - \bar{y} = 13 - 9 = 4$

Desviación sin explicar de (5, 19) $= y - \hat{y} = 19 - 13 = 6$

Si fuésemos totalmente ignorantes de los conceptos de correlación y regresión, y deseáramos predecir un valor de y, dado un valor de x y un conjunto de datos apareados (x,y), nuestra mejor conjetura sería $\bar{y}$. Pero no ignoramos totalmente los conceptos de correlación y regresión: sabemos que en este caso (con una correlación lineal significativa), la forma de predecir el valor de y cuando $x = 5$ es utilizar la ecuación de regresión, que produce $\hat{y} = 13$, como se calculó antes. Podemos explicar la discrepancia entre $\bar{y} = 9$ y $\hat{y} = 13$ señalando sencillamente que existe una correlación lineal significativa que está mejor descrita por la recta de regresión. Como consecuencia, cuando $x = 5$, *y debe ser* 13, y no el valor medio de 9. Pero, aun cuando y debería ser 13, *es* 19. La discrepancia entre 13 y 19 no puede explicarse por la recta de regresión, y se denomina *desviación sin explicar* o *residual*. El caso específico ilustrado en la figura 9-10 se generaliza de la siguiente forma:

	(desviación total	=	(desviación explicada)	+	(desviación sin explicar)
o	$(y - \bar{y})$	=	$(\hat{y} - \bar{y})$	+	$(y - \hat{y})$

Esta última expresión se aplica a un punto (x,y) particular, y la misma relación se aplica a las sumas de cuadrados mostradas en la fórmula 9-4, aunque esta última expresión no es algebraicamente equivalente a la fórmula 9-4. En ésta, la **variación total** se expresa como las sumas de los cuadrados de los valores de desviación totales, la **variación explicada** es la suma de los cuadrados de los valores de desviación explicados, y la **variación sin explicar** es la suma de los cuadrados de los valores de desviación sin explicar.

Fórmula 9-4

	(variación total)	=	(variación explicada)	+	(variación sin explicar)
o	$\Sigma(y - \bar{y})^2$	=	$\Sigma(\hat{y} - \bar{y})^2$	+	$\Sigma(y - \hat{y})^2$

Coeficiente de determinación

Los componentes de la fórmula 9-4 se utilizan en la siguiente definición importante.

Definición

El **coeficiente de determinación** es la cantidad de variación en y que está explicada por la recta de regresión. Se calcula como

$$r^2 = \frac{\text{variación explicada}}{\text{variación total}}$$

Podemos calcular r^2 por medio de la definición dada con la fórmula 9-4 o simplemente elevar al cuadrado el coeficiente de correlación lineal r, que se obtiene utilizando los métodos descritos en la sección 9-2. Por ejemplo, en la sección 9-2 señalamos que si $r = 0.922$, entonces $r^2 = 0.850$, que significa que *el 85% de la variación total de* y *puede explicarse por medio de la relación lineal entre* x *y* y *(como se describió por medio de la ecuación de regresión). Se infiere que el 15% de la variación total de* y *permanece sin explicación.*

EJEMPLO Diamantes En el ejercicio 24a, en la sección 9-2, encontramos que para los datos apareados consistentes en los pesos (en quilates) y los precios de los diamantes, el coeficiente de correlación lineal está dado por $r = 0.767$. Calcule el porcentaje de la variación en y (precio) que se explica por la relación lineal entre el peso y el precio.

SOLUCIÓN El coeficiente de determinación es $r^2 = 0.767^2 = 0.588$, lo que indica que la proporción de variación explicada en y, respecto a la variación total en y, es 0.588. Ahora podemos afirmar que el 58.8% de la variación total en y puede explicarse por la ecuación de regresión. Interpretamos que el 58.8% de la variación total de los precios de diamantes se explica por la variación en sus pesos; el restante 41.2% es atribuible a otros factores tales como el color, la claridad y el azar. Sin embargo, recuerde que estos resultados son estimados basados en datos muestrales dados. Probablemente otros datos muestrales darían como resultado estimados distintos.

Intervalos de predicción

En la sección 9-3 empleamos los datos muestrales de la tabla 9-1 para calcular la ecuación de regresión $\hat{y} = -113 + 2.27x$, donde $\hat{y}$ representa el número predicho de muertes de manatíes y x representa el número de barcos (en decenas de miles). Después utilizamos esa ecuación para predecir el valor de y, puesto que $x = 85$ (para 850,000 barcos). Encontramos que el mejor número predicho de muertes de manatíes es 80.0. Si usamos los valores sin redondear de la pendiente y del intercepto, obtenemos el resultado más preciso de 80.6 muertes de manatíes. Puesto que 80.6 es un valor único, se le conoce como *estimado del punto*. En el capítulo 6 aprendimos que los estimados del punto tienen la grave desventaja de no proporcionarnos ninguna información acerca de su precisión. Aquí, sabemos que 80.6 es el mejor valor predicho, pero no sabemos qué tan preciso es este valor. En el capítulo 6 elaboramos estimados del intervalo de confianza para superar esa desventaja, y en esta sección seguimos este precedente. Utilizaremos un **intervalo de predicción**, que es un estimado del intervalo de un valor predicho de y.

La creación de un intervalo de predicción requiere una medida de la dispersión de los puntos muestrales alrededor de la recta de regresión. Recuerde que la desviación sin explicar (o residual) es la distancia vertical entre un punto muestral y la recta de regresión, tal como se ilustra en la figura 9-10. El *error estándar del estimado* es una medida colectiva de la dispersión de los puntos muestrales alrededor de la recta de regresión y se define de manera formal como sigue.

Definición

El **error estándar del estimado**, denotado por s_e, es una medida de las diferencias (o distancias) entre los valores muestrales de y observados y los valores predichos $\hat{y}$ que se obtienen por medio de la ecuación de regresión. Está dado por

$$s_e = \sqrt{\frac{\Sigma(y - \hat{y})^2}{n - 2}} \qquad \text{(donde } \hat{y} \text{ es el valor predicho de } y\text{)}$$

o por la siguiente fórmula equivalente:

Fórmula 9-5

$$s_e = \sqrt{\frac{\Sigma y^2 - b_0 \Sigma y - b_1 \Sigma xy}{n - 2}}$$

STATDISK, Minitab, Excel y la calculadora TI-83 Plus están diseñados para calcular de manera automática el valor de s_e. Véase el apartado "Utilizando la tecnología" al final de esta sección.

La elaboración del error estándar del estimado s_e se asemeja mucho a la de la desviación estándar ordinaria introducida en el capítulo 2. Así como la desviación estándar es una medida de qué tanto los valores se desvían de su media, el error estándar del estimado s_e es una medida de qué tanto los puntos de los datos muestrales se desvían de su recta de regresión. La lógica que subyace a la división entre $n - 2$ es similar a la lógica que condujo a la división entre $n - 1$ para la desviación estándar ordinaria. Es importante señalar que valores relativamente pequeños de s_e reflejan puntos que están cercanos a la recta de regresión, y valores relativamente grandes ocurren con puntos que se alejan de la recta de regresión.

La fórmula 9-5 es algebraicamente equivalente a la otra expresión en la definición, pero la fórmula 9-5 suele ser más fácil debido a que no requiere que calculemos cada uno de los valores predichos $\hat{y}$ por medio de su sustitución en la ecuación de regresión. Sin embargo, la fórmula 9-5 sí requiere que calculemos b_0, el intercepto y y la pendiente b_1 de la recta de regresión estimada.



EJEMPLO Utilice la fórmula 9-5 para calcular el error estándar del estimado s_e para los datos muestrales barco/manatí listados en la tabla 9-1.

SOLUCIÓN Con los datos muestrales de la tabla 9-1, calculamos estos valores:

$$n = 10 \qquad \Sigma y^2 = 33{,}456 \qquad \Sigma y = 558 \qquad \Sigma xy = 42{,}214$$

En la sección 9-3 empleamos los datos muestrales de la tabla 9-1 para obtener el intercepto y y la pendiente de la recta de regresión. Dichos valores se presentan aquí con más decimales para una mayor precisión.

$$b_0 = -112.7098976 \qquad b_1 = 2.274087687$$

continúa

Ahora podemos usar estos valores en la fórmula 9-5 para calcular el error estándar del estimado s_e.

$$s_e = \sqrt{\frac{\Sigma y^2 - b_0\Sigma y - b_1\Sigma xy}{n - 2}}$$

$$= \sqrt{\frac{33{,}456 - (-112.7098976)(558) - (2.274087687)(42{,}214)}{10 - 2}}$$

$$= 6.6123487 = 6.61 \quad \text{(redondeado)}$$

Medimos la dispersión de los puntos muestrales alrededor de la recta de regresión, con el error estándar del estimado $s_e = 6.61$.

Podemos emplear el error estándar del estimado s_e para construir estimados de intervalo que nos ayuden a ver qué tan confiables son realmente nuestros estimados del punto y. Suponga que para cada valor fijo de x, los valores muestrales correspondientes de y se distribuyen normalmente alrededor de la recta de regresión, y que estas distribuciones normales tienen la misma varianza. El siguiente estimado del intervalo se aplica a un valor y *individual*. (Consulte el ejercicio 24 para ver un intervalo de confianza utilizado para predecir la *media* de todos los valores de y, para algún valor dado de x).

Intervalo de predicción para una *y* individual

Dado el valor fijo x_0, el intervalo de predicción para una y individual es

$$\hat{y} - E < y < \hat{y} + E$$

donde el margen de error E es

$$E = t_{\alpha/2} s_e \sqrt{1 + \frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{n(\Sigma x^2) - (\Sigma x)^2}}$$

y x_0 que representa el valor dado de x, $t_{\alpha/2}$ tiene $n - 2$ grados de libertad, y s_e se calcula partir de la fórmula 9-5.

EJEMPLO Barcos y manatíes Para los datos apareados barco/manatí de la tabla 9-1, encontramos que cuando $x = 85$ (para 850,000 barcos), el mejor número predicho de muertes de manatíes es 80.0, pero obtenemos un valor predicho de 80.6 cuando empleamos valores más precisos de b_0, el intercepto y y la pendiente b_1. Construya un intervalo de predicción del 95% para el número de manatíes asesinados por barcos, considerando que el número de barcos es de 850,000 (de modo que $x = 85$). Esto nos proporcionará una idea de cuán preciso es el valor predicho de 80.6.

SOLUCIÓN En secciones anteriores hemos demostrado que existe una correlación lineal significativa (a nivel 0.05 de significancia), y la ecuación de regresión

es $\hat{y} = -113 + 2.27x$. En el ejemplo anterior encontramos que $s_e = 6.6123487$, y los siguientes estadísticos se obtienen a partir de los datos muestrales de la tabla 9-1:

$$n = 10 \qquad \bar{x} = 74.1 \qquad \Sigma x = 741 \qquad \Sigma x^2 = 55{,}289$$

En la tabla A-3 encontramos que $t_{\alpha/2} = 2.306$. (Utilizamos $10 - 2 = 8$ grados de libertad con $\alpha = 0.05$ en dos colas). Primero calculamos el margen de error E permitiendo que $x_0 = 85$, ya que buscamos el intervalo de predicción del número de muertes de manatíes, puesto que $x = 85$ (para 850,000 barcos).

$$E = t_{\alpha/2} s_e \sqrt{1 + \frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{n(\Sigma x^2) - (\Sigma x)^2}}$$

$$= (2.306)(6.6123487)\sqrt{1 + \frac{1}{10} + \frac{10(85 - 74.1)^2}{10(55{,}289) - (741)^2}}$$

$$= (2.306)(6.6123487)(1.1882420) = 18.1$$

Con $\hat{y} = 80.6$ y $E = 18.1$, obtenemos el intervalo de predicción de la siguiente forma:

$$\hat{y} - E < y < \hat{y} + E$$
$$80.6 - 18.1 < y < 80.6 + 18.1$$
$$62.5 < y < 98.7$$

Es decir, para $x = 85$ (para 850,000 barcos) tenemos una certeza del 95% de que el número de muertes de manatíes está entre 62.5 y 98.7. Se trata de un rango relativamente grande. (Un factor que contribuye a lo grande del rango es que el tamaño de la muestra es muy pequeño, debido a que estamos utilizando únicamente 10 pares de datos muestrales).

Minitab es útil para calcular los límites del intervalo de predicción. Si utilizamos Minitab, nos dará el resultado de (62.5, 98.7) bajo el encabezado "95.0% P.I.". Éste corresponde al mismo intervalo de predicción calculado antes.

Además de saber que para $x = 85$, el número predicho de muertes de manatíes es 80.6, ahora tenemos una idea de qué tan confiable es en realidad el estimado. El intervalo de predicción del 95% calculado en este ejemplo indica que el valor real de y llega a variar sustancialmente del valor predicho de 80.6.



Utilizando la tecnología

STATDISK STATDISK es útil para calcular el coeficiente de correlación lineal r, la ecuación de la recta de regresión, el error estándar del estimado s_e, la variación total, la variación explicada, la variación sin explicar y el coeficiente de determinación. Seleccione **Analysis** de la barra del menú principal, después utilice la opción **Correlation and Regression.** Introduzca los datos apareados o utilice las funciones copiar/pegar para copiar los datos. Ingrese los valores de x en la columna 1 y los valores correspondientes de y en la columna 2. Introduzca un valor para el nivel de significancia. Haga clic en el botón **Evaluate**. Los resultados de STATDISK incluirán el coeficiente de correlación lineal, el coeficiente de determinación, la ecuación de regresión y el valor del error estándar del estimado s_e.

Minitab Minitab se utiliza para calcular la ecuación de regresión, el error estándar del estimado s_e (denotado por s), el

continúa

valor del coeficiente de determinación (denotado por R-sq) y los límites del intervalo de predicción. Ingrese los datos de *x* en la columna C1 y los datos de *y* en la columna C2, luego seleccione las opciones **Stat, Regression** y **Regression**. Introduzca C2 en el recuadro denominado "Response" e introduzca C1 en el recuadro denominado "Predictors". Si busca un intervalo de predicción para algún valor dado de *x*, haga clic en **Opciones** e introduzca el valor deseado de x_0 en el recuadro denominado "Prediction intervals for new observations".

Excel Excel sirve para calcular la ecuación de regresión, el error estándar del estimado s_e y el coeficiente de determinación (denotado por R square). Introduzca los datos apareados en las columnas A y B.

Para emplear el complemento Data Analysis, seleccione **Tools** del menú principal, después elija **Data Analysis**, seguido por **Regression** y después haga clic en **OK.** Ingrese el rango para los valores de *y*, tal como B1:B10. Ingrese el rango para los valores de *x*, tal como A1:A10. Haga clic en **OK**.

Para emplear el complemento Data Desk XL, haga clic en **DDXL** y seleccione **Regression**, luego haga clic en el recuadro Function Type y seleccione **Sample Regression**. Haga clic en el icono del lápiz para la variable de respuesta e introduzca el rango de valores para la variable *y* (o dependiente). Haga clic en el icono del lápiz para la variable explicativa e introduzca el rango de valores para la variable *x* (o independiente). Haga clic en **OK**.

TI-83 Plus La calculadora TI-83 Plus permite calcular el coeficiente de correlación lineal *r*, la ecuación de la recta de regresión, el error estándar del estimado s_e y el coeficiente de determinación (denominado r^2). Ingrese los datos apareados en las listas L1 y L2, después presione **STAT** y seleccione **TESTS**, luego elija la opción **LinRegTTest.**

9-4 Destrezas y conceptos básicos

Interpretación del coeficiente de determinación*. En los ejercicios 1 a 4, utilice el valor del coeficiente de correlación lineal r para calcular el coeficiente de determinación y el porcentaje de variación total que explica la relación lineal entre las dos variables.*

1. $r = 0.8$

2. $r = -0.6$

3. $r = -0.503$

4. $r = 0.636$

Interpretaciones de resultados de un programa de cómputo. *En los ejercicios 5 a 8, remítase a los resultados de Minitab que se obtuvieron utilizando datos apareados de alquitrán y nicotina, de una muestra de 29 cigarrillos, como se listan en el conjunto de datos 5 del Apéndice B. Junto con los datos muestrales apareados, se le indicó a Minitab una cantidad de alquitrán de 17 mg a utilizar para predecir la cantidad de nicotina.*

Minitab

```
The regression equation is
Nicotine = 0.154 + 0.0651 Tar

Predictor          Coef      SE Coef          T          P
Constant        0.15403      0.04635       3.32      0.003
Tar            0.065052     0.003585      18.15      0.000

S = 0.08785    R-Sq = 92.4%    R-Sq(adj) = 92.1%

Predicted Values for New Observations

New Obs    Fit SE Fit      95.0% CI          95.0% PI
1       1.2599 0.0240 ( 1.2107, 1.3091)( 1.0731, 1.4468)
```

5. Prueba de correlación Con la información proporcionada en los resultados, determine el valor del coeficiente de correlación lineal. Como hay 29 pares de datos, ¿existe una correlación lineal significativa entre la cantidad de alquitrán y la cantidad de nicotina en un cigarrillo?

6. Identificación de la variación total ¿Qué porcentaje de la variación total de nicotina se explica por la relación lineal entre alquitrán y nicotina?

7. Predicción de la cantidad de nicotina Si un cigarrillo contiene 17 mg de alquitrán, ¿cuál es el valor que predice mejor la cantidad de nicotina? (Suponga que existe una correlación lineal significativa entre alquitrán y nicotina).

8. Cálculo del intervalo de predicción Para una cantidad de alquitrán dada de 17 mg, identifique el estimado del intervalo de predicción del 95% de la cantidad de nicotina y redacte una afirmación que interprete ese intervalo.

Cálculo de medidas de variación. *En los ejercicios 9 a 12, calcule a) la variación explicada, b) la variación no explicada, c) la variación total, d) el coeficiente de determinación y e) el error estándar del estimado s_e. En cada caso existe una correlación lineal significativa, de modo que es razonable utilizar la ecuación de regresión para hacer predicciones.*

9. Estatura y peso de supermodelos A continuación se listan las estaturas (en pulgadas) y los pesos (en libras) de las supermodelos Niki Taylor, Nadia Auerman, Claudia Schiffer, Elle MacPherson, Christy Turlington, Bridget Hall, Kate Moss, Valerie Mazza y Kristy Hume.

Estatura (pulg.)	71	70.5	71	72	70	70	66.5	70	71
Peso (libras)	125	119	128	128	119	127	105	123	115

10. Mediciones de presión sanguínea Catorce estudiantes diferentes del segundo año de medicina tomaron mediciones de la presión sanguínea del mismo paciente, y los resultados se presentan abajo (datos proporcionados por el doctor Marc Triola).

Sistólica	138	130	135	140	120	125	120	130	130	144	143	140	130	150
Diastólica	82	91	100	100	80	90	80	80	80	98	105	85	70	100

11 Circunferencia y altura de árboles A continuación se listan las circunferencias (en pies) y las alturas (en pies) de árboles en Marshall, Minnesota (datos tomados de "Tree Measurements", de Stanley Rice, *American Biology Teacher*, vol. 61, núm. 9).

x (circ.)	1.8	1.9	1.8	2.4	5.1	3.1	5.5	5.1	8.3	13.7	5.3	4.9	3.7	3.8
y (ht)	21.0	33.5	24.6	40.7	73.2	24.9	40.4	45.3	53.5	93.8	64.0	62.7	47.2	44.3

12. Niveles de facilidad de lectura Remítase al conjunto de datos 14 del Apéndice B y utilice los caracteres por palabra (x) y la puntuaciones de facilidad de lectura de Flesch (y) para *Harry Potter y la piedra filosofal*, de J. K. Rowling.

13. Efecto de la variación en el intervalo de predicción Remítase a los datos dados en el ejercicio 9 y suponga que se cumplen las condiciones necesarias de normalidad y varianza.

a. Calcule el peso predicho de una supermodelo que mide 69 pulgadas.

b. Calcule un estimado del intervalo de predicción del 95% del peso de una supermodelo que mide 69 pulgadas.

14. Cálculo del valor predicho e intervalo de predicción Remítase al ejercicio 10 y suponga que se cumplen las condiciones necesarias de normalidad y varianza.
- **a.** Calcule la lectura diastólica predicha, dado que la lectura sistólica es de 120.
- **b.** Calcule un estimado del intervalo de predicción del 95% de la lectura diastólica, dado que la lectura sistólica es de 120.

15. Cálculo del valor predicho e intervalo de predicción Remítase a los datos del ejercicio 11 y suponga que se cumplen las condiciones necesarias de normalidad y varianza.
- **a.** Calcule la altura predicha de un árbol que tiene una circunferencia de 4.0 pies.
- **b.** Calcule un estimado del intervalo de predicción del 99% de la altura de un árbol que tiene una circunferencia de 4.0 pies.

16. Cálculo del valor predicho e intervalo de predicción Remítase a los datos descritos en el ejercicio 12 y suponga que se cumplen las condiciones necesarias de normalidad y varianza.
- **a.** Calcule la puntuación de facilidad de lectura de Flesch predicha para una página que tiene un promedio de 4.0 caracteres por palabra.
- **b.** Calcule un estimado del intervalo de predicción del 99% de la puntuación de facilidad de lectura de Flesch, predicha para una página que tiene un promedio de 4.0 caracteres por palabra.
- **c.** ¿De qué manera se comparan los resultados de los incisos *a* y *b* con el par de datos observados, consistentes en 4.0 caracteres por palabra y una calificación de facilidad de lectura de Flesch de 86.2?

Cálculo de un intervalo de predicción. *En los ejercicios 17 a 20, remítase a los datos muestrales de la tabla 9-1. Permita que x represente el número de barcos registrados (en decenas de miles) y permita que y represente el número de manatíes muertos por barcos. Utilice el número de barcos registrados (en decenas de miles) y el nivel de confianza indicado para construir un estimado del intervalo de predicción del número de manatíes muertos por barcos. (Véase el ejemplo en esta sección).*

17. $x = 85$ (para 850,000 barcos); 99% de confianza

18. $x = 85$ (para 850,000 barcos); 90% de confianza

19. $x = 90$ (para 900,000 barcos); 95% de confianza

20. $x = 90$ (para 900,000 barcos); 99% de confianza

9-4 Más allá de lo básico

21. Intervalos de confianza para β_0 y β_1 Los intervalos de confianza para β_0, el intercepto *y*, y la pendiente β_1 de una recta de regresión ($y = \beta_0 + \beta_1 x$) se obtienen evaluando los límites en los intervalos que siguen.

$$b_0 - E < \beta_0 < b_0 + E$$

donde

$$E = t_{\alpha/2} s_e \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\Sigma x^2 - \frac{(\Sigma x)^2}{n}}}$$

$$b_1 - E < \beta_1 < b_1 + E$$

donde

$$E = t_{\alpha/2} \cdot \frac{s_e}{\sqrt{\Sigma x^2 - \frac{(\Sigma x)^2}{n}}}$$

En estas expresiones b_0, el intercepto y y la pendiente b_1, se calculan a partir de los datos muestrales, y $t_{\alpha/2}$ se obtiene de la tabla A-3 utilizando $n - 2$ grados de libertad. Con los datos barco/manatí en la tabla 9-1, calcule los estimados del intervalo de confianza del 95% de β_0 y β_1.

22. Comprensión de la variación

a. Si un conjunto de datos apareados incluye al menos tres pares de valores, ¿qué sabe usted acerca del coeficiente de correlación lineal si $s_e = 0$?

b. Si un conjunto de datos apareados es tal que la variación explicada total es 0, ¿qué sabe acerca de la pendiente de la recta de regresión?

23. Comprensión de la variación

a. Encuentre una expresión para la variación no explicada en términos del tamaño de muestra n y el error estándar del estimado s_e.

b. Encuentre una expresión para la variación explicada en términos del coeficiente de determinación r^2 y la variación sin explicar.

c. Suponga que tenemos un conjunto de datos apareados para los que $r^2 = 0.900$ y la ecuación de regresión es $\hat{y} = 3 - 2x$. Calcule el coeficiente de correlación lineal.

24. Cálculo del intervalo de confianza para un valor predicho de la media A partir de la expresión que se dio en esta sección para el margen de error correspondiente a un intervalo de predicción para y, podemos obtener la expresión

$$s_{\hat{y}} = s_e \sqrt{1 + \frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{n(\Sigma x^2) - (\Sigma x)^2}}$$

que es el *error estándar de la predicción* cuando se predice para una *sola* y, ya que $x = x_0$. Cuando se predice la *media* de todos los valores de y para los que $x = x_0$, el estimado del punto $\hat{y}$ es el mismo, pero $s_{\hat{y}}$ es de la siguiente manera:

$$s_{\hat{y}} = s_e \sqrt{\frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{n(\Sigma x^2) - (\Sigma x)^2}}$$

Utilice los datos de la tabla 9-1 y extienda el último ejemplo de esta sección para calcular un estimado del punto y un estimado del intervalo de confianza del 95% del número medio de muertes de manatíes por barcos, ya que el número de barcos registrados es de 850,000 (de manera que $x = 85$).

9-5 Regresión múltiple

Hasta ahora hemos utilizado métodos de correlación y regresión para investigar relaciones entre exactamente *dos* variables, pero algunas circunstancias requieren más de dos variables. Al predecir el precio de un diamante, por ejemplo, podríamos considerar variables tales como el peso (en quilates), el color y la claridad, de manera que interviene un total de cuatro variables. Esta sección presenta un método para analizar relaciones que incluyen *más de dos* variables. Nos enfocaremos en tres elementos clave: 1. la ecuación de regresión múltiple, 2. el valor de R^2 ajustada y 3. el valor P. Igual que en las secciones anteriores de este capítulo, trabajaremos únicamente con relaciones *lineales*. Iniciamos con la *ecuación de regresión múltiple*.



Salarios de la NBA y desempeño

El investigador Matthew Weeks estudió la correlación entre los salarios de la NBA y las estadísticas del juego de básquetbol. Además del salario (S), consideró los minutos jugados (M), las intervenciones (I), los rebotes (R) y los puntos anotados (P); utilizó datos de 30 jugadores. La ecuación de regresión múltiple es $S = -0.716 - 0.0756M - 0.425I + 0.0536R + 0.742P$ con $R^2 = 0.458$. Debido a una alta correlación entre los minutos jugados (M) y los puntos anotados (P), y puesto que los puntos anotados tuvieron una alta correlación con el salario, la variable de minutos jugados se eliminó de la ecuación de regresión múltiple. Además, no se encontró que las variables de intervenciones (I) y rebotes (R) fuesen significativas, por lo que también se eliminaron. La variable de los puntos anotados pareció ser la mejor elección para predecir los salarios de la NBA, pero se encontró que las predicciones no eran muy precisas debido a otras variables que no se consideraron, tales como la popularidad del jugador.

Ecuación de regresión múltiple

Definición

Una **ecuación de regresión múltiple** expresa una relación lineal entre una variable dependiente y y dos o más variables independientes ($x_1, x_2, \ldots, x_k$). La forma general de una ecuación de regresión múltiple es $\hat{y} = b_0 + b_1x_1 + b_2x_2 + \ldots + b_kx_k$.

Emplearemos la siguiente notación, que surge de manera natural de la notación utilizada en la sección 9-3.

Notación

$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \ldots + b_kx_k$ (forma general de la ecuación de regresión múltiple estimada)

n = tamaño de la muestra

k = número de variables *independientes*. (Las variables independientes también se conocen como **variables predictoras** o variables x).

$\hat{y}$ = valor predicho de la variable dependiente y (que se calcula por medio de la ecuación de regresión múltiple).

$x_1, x_2, \ldots, x_k$ son las variables independientes.

β_0 = intercepto y, o el valor de y cuando todas las variables predictoras son 0. (Este valor es un parámetro poblacional).

b_0 = estimado de β_0 basado en los datos muestrales (b_0 es un estadístico muestral).

$\beta_1, \beta_2, \ldots, \beta_k$ son los coeficientes de las variables independientes $x_1, x_2, \ldots, x_k$

$b_1, b_2, \ldots, b_k$ son estimados muestrales de los coeficientes $\beta_1, \beta_2, \ldots, \beta_k$

Los cálculos que se requieren para la regresión múltiple son tan complicados que *debe* utilizarse un programa de cómputo de estadística, por lo que nos concentraremos en *interpretar* las pantallas de resultados de los programas de cómputo. Al final de esta sección se incluyen instrucciones para el uso del STATDISK, Minitab, Excel y la calculadora TI-83 Plus.

EJEMPLO Osos Por cuestiones de seguridad, un estudio de osos implicó la recolección de diversas mediciones una vez que los osos estaban anestesiados. Cuando se obtienen mediciones de un oso salvaje anestesiado, es relativamente fácil utilizar una cinta métrica para obtener valores como el tamaño del pecho, el tamaño del cuello y la altura total, pero es difícil calcular el peso debido a que se debe alzar al oso. En lugar de pesar realmente a un oso, ¿podemos predecir su peso con base en otras mediciones que son más fáciles de obtener? El conjunto de datos 9 del Apéndice B incluye mediciones tomadas de 54 osos, pero nosotros consideraremos los datos de únicamente ocho osos, que se listan en la tabla 9-3. Utilice los datos de la tabla 9-3 y calcule la ecuación

Tabla 9-3 Datos de osos machos anestesiados

Variable	Columna de Minitab	Nombre	Datos muestrales							
y	C1	WEIGHT(PESO)	80	344	416	348	262	360	332	34
x_2	C2	AGE(EDAD)	19	55	81	115	56	51	68	8
x_3	C3	HEADLEN(LONGITUD DE CABEZA)	11.0	16.5	15.5	17.0	15.0	13.5	16.0	9.0
x_4	C4	HEADWDTH(ANCHO DE CABEZA)	5.5	9.0	8.0	10.0	7.5	8.0	9.0	4.5
x_5	C5	NECK(CUELLO)	16.0	28.0	31.0	31.5	26.5	27.0	29.0	13.0
x_6	C6	LENGTH(ALTURA)	53.0	67.5	72.0	72.0	73.5	68.5	73.0	37.0
x_7	C7	CHEST(PECHO)	26	45	54	49	41	49	44	19

de regresión múltiple en la que la variable dependiente (y) es el peso y las variables independientes son la longitud de la cabeza (HEADLEN) y la altura total (LENGTH).

SOLUCIÓN Con el uso de Minitab, obtenemos los resultados mostrados en la imagen de abajo. La ecuación de regresión múltiple se presenta como

$$\text{WEIGHT} = -374 + 18.8\,\text{HEADLEN} + 5.87\,\text{LENGTH}$$

Si empleamos la notación presentada anteriormente en esta sección, podríamos escribir esta ecuación como

$$\hat{y} = -374 + 18.8x_3 + 5.87x_6$$

Minitab

```
The regression equation is
WEIGHT = -374 + 18.8 HEADLEN + 5.87 LENGTH   ← ① Ecuación de regresión múltiple

Predictor          Coef       Stdev     t-ratio         p
Constant        -374.3       134.1       -2.79     0.038
HEADLEN          18.82       23.15        0.81     0.453
LENGTH           5.875       5.065        1.16     0.299

s = 68.56  R-sq = 82.8% R-sq(adj) = 75.9%
                  ↖ R² = 0.828        ↖ ② Ajustada R² = 0.759

Analysis of Variance

SOURCE          DF         SS         MS          F         p
Regresión        2     113142      56571      12.03     0.012
Error            5      23506       4701                  ↑
Total            7     136648                ③ Significancia general de la
                                             ecuación de regresión múltiple
```



Fabricación de música con regresión múltiple

Sony fabrica millones de discos compactos en Terre Haute, Indiana. En un punto del proceso de fabricación se expone una placa fotográfica a un láser, de modo que una señal musical es transferida a una señal digital codificada con ceros y unos. Este proceso se analizó estadísticamente para identificar los efectos de diferentes variables, tales como el tiempo de exposición y el grosor de la emulsión fotográfica. Métodos de regresión múltiple demostraron que, entre todas las variables consideradas, cuatro eran las más significativas. El proceso fotográfico se ajustó con base en estas cuatro variables para obtener resultados óptimos. Esto dio como resultado la disminución de discos defectuosos en favor de una mayor calidad. El uso de métodos de regresión múltiple condujo a costos más bajos de producción y a un mejor control del proceso de fabricación.

Si una ecuación de regresión múltiple se ajusta bien a los datos muestrales, resulta útil para hacer predicciones. Por ejemplo, si determinamos que la ecuación es adecuada para predecir, y tenemos un oso con una longitud de cabeza de 14.0 pulgadas y una altura total de 71.0 pulgadas, podemos predecir su peso sustituyendo esos valores en la ecuación de regresión para obtener un peso predicho de 306 libras. Además, los coeficientes $b_3 = 18.8$ y $b_6 = 5.87$ se emplean para determinar el cambio marginal, como se describió en la sección 9-3. Por ejemplo, el coeficiente $b_3 = 18.8$ indica que cuando la altura total de un oso permanece constante, el peso predicho se incrementa en 18.8 libras por cada pulgada de aumento en la longitud de la cabeza.

R^2 ajustada

R^2 denota el **coeficiente múltiple de determinación**, que es una medida de qué tan bien se ajusta la ecuación de regresión múltiple a los datos muestrales. Un ajuste perfecto daría como resultado $R^2 = 1$, y un ajuste muy bueno da como resultado un valor cercano a 1. Un ajuste muy pobre se relaciona con un valor de R^2 cercano a 0. El valor de $R^2 = 0.828$ en los resultados de Minitab indica que el 82.8% de la variación del peso de los osos puede explicarse por la longitud de la cabeza x_3 y la altura total x_6. Sin embargo, el coeficiente múltiple de determinación R^2 tiene una grave desventaja: a mayor número de variables incluidas, R^2 se incrementa. (R^2 podría permanecer igual, pero suele incrementarse). La R^2 más grande se obtiene por el sencillo hecho de incluir todas las variables disponibles, pero la mejor ecuación de regresión múltiple no necesariamente utiliza todas las variables de que se dispone. Debido a esta desventaja, la comparación de diferentes ecuaciones de regresión múltiple se logra mejor con el coeficiente ajustado de determinación, que es R^2 ajustada para el número de variables y el tamaño de la muestra.

Definición

El **coeficiente ajustado de determinación** es el coeficiente múltiple de determinación R^2 modificado para justificar el número de variables y el tamaño de la muestra. Se calcula por medio de la fórmula 9-6.

Fórmula 9-6

$$R^2 \text{ ajustada} = 1 - \frac{(n-1)}{[n-(k+1)]}(1-R^2)$$

donde n = tamaño de la muestra

k = número de variables independientes (x)

Los resultados de Minitab para los datos de la tabla 9-3 indican que el coeficiente ajustado de determinación es `R-sq(adj) = 75.9%`. Si utilizamos la fórmula 9-6 con el valor de $R^2 = 0.828$, $n = 8$ y $k = 2$, encontramos que el valor ajustado de R^2 es 0.759, lo que confirma el valor de 75.9% de los resultados de Minitab. Para los datos de la tabla 9-3 relativos al peso, la longitud de la cabeza y la altura, el valor de R^2 de 82.8% indica que el 82.8% de la variación del peso puede explicarse por la longitud en la cabeza x_3 y la altura total x_6, pero cuando comparamos esta ecuación de regresión múltiple con otras, es mejor utilizar la R^2 ajustada de 75.9% (o 0.759).

Valor *P*

El valor *P* es una medida de la significancia general de la ecuación de regresión múltiple. El valor *P* de 0.012 de los resultados de Minitab es pequeño, lo que indica que la ecuación de regresión múltiple tiene una buena significancia general y es útil para hacer predicciones. Es decir, es lógico predecir pesos de osos con base en la longitud de su cabeza y de su altura total. Al igual que la R^2 ajustada, este valor *P* es una buena medida de qué tan bien se ajusta la ecuación a los datos muestrales. El valor de 0.012 resulta de una prueba de la hipótesis nula de que $\beta_3 = \beta_6 = 0$. El rechazo de $\beta_3 = \beta_6 = 0$ implica que al menos uno de β_3 y β_6 no es 0, lo que indica que esta ecuación de regresión es eficaz para determinar los pesos de osos. Un análisis completo de los resultados de Minitab podría llevarnos a concluir otros elementos importantes, tales como la significancia de los coeficientes individuales, pero limitaremos nuestra explicación a los tres componentes principales: la ecuación de regresión múltiple, la R^2 ajustada y el valor *P*.

Cálculo de la mejor ecuación de regresión múltiple

La tabla 9-3 incluye siete variables distintas de medición de ocho osos diferentes. El resultado de Minitab se basa en la selección del peso como variable dependiente y en la selección de la longitud de la cabeza y de la altura total como variables independientes. Pero si deseamos predecir el peso de un oso, ¿existe alguna otra combinación de variables que podría ser mejor que la longitud de la cabeza y la altura total? La tabla 9-4 lista algunas de las combinaciones de variables, y ahora nos confrontamos con el objetivo importante de calcular la *mejor* ecuación de regresión múltiple. Puesto que la determinación de la mejor regresión múltiple requiere de una buena dosis de juicio, no existe un procedimiento exacto y automático para esto. *La determinación de la mejor ecuación de regresión múltiple suele ser bastante difícil y va más allá de los objetivos de este libro,* pero los siguientes lineamientos proporcionan cierta ayuda.

Lineamientos para el cálculo de la mejor ecuación de regresión múltiple

1. *Utilice el sentido común y consideraciones prácticas para incluir o excluir variables.* Por ejemplo, podríamos excluir la variable de edad debido a que investigadores inexpertos tal vez no sepan cómo determinar la edad de un oso y, al preguntarles, los osos se rehúsan a revelar su edad. A diferencia de otras variables independientes, la edad de un oso no se obtiene fácilmente con una cinta de medición. Por lo tanto, parece lógico excluir la edad como variable independiente.

Tabla 9-4 Búsqueda de la mejor ecuación de regresión múltiple

	ALTURA	PECHO	LONGITUD DE CABEZA/ ALTURA	EDAD/ CUELLO/ ALTURA/PECHO	EDAD/LONGITUD DE CABEZA/ ANCHO DE CABEZA/CUELLO/ ALTURA/PECHO
R^2	0.805	0.983	0.828	0.999	0.999
R^2 ajustada	0.773	0.980	0.759	0.997	0.996
Significancia general	0.002	0.000	0.012	0.000	0.046



Predictores de éxito

Cuando una universidad acepta a un nuevo estudiante, es conveniente tener algunos indicadores positivos de que el estudiante tendrá éxito en sus estudios. Los decanos universitarios de admisiones toman en cuenta las calificaciones del SAT, las pruebas estándar de aprovechamiento, el lugar que ocupa el estudiante en la clase, la dificultad de los cursos de preparatoria, las calificaciones de preparatoria y actividades extracurriculares. En un estudio de las características que suelen ser buenos predictores de éxito en la universidad, se encontró que el lugar que se tiene en la clase y las puntuaciones en pruebas estándar de aprovechamiento son mejores predictores que las calificaciones del SAT. Una ecuación de regresión múltiple con el promedio general en la universidad predicho por el lugar que ocupa el estudiante en la clase y la puntuación en pruebas de aprovechamiento no mejoró al incluir la calificación del SAT como otra variable. Este estudio en particular sugiere que las calificaciones del SAT no deben incluirse entre los criterios de admisión, aunque otros argumentan que las calificaciones de esta prueba son útiles para comparar estudiantes de diferentes lugares y de distintas preparatorias de procedencia.

2. *Considere el valor P.* Seleccione una ecuación que tiene significancia general, tal como determina el valor *P* indicado en los resultados del programa de cómputo. Por ejemplo, observe los valores de la significancia general en la tabla 9-4. El uso de las seis variables independientes da como resultado una significancia general de 0.046, que es apenas significativa a nivel $\alpha = 0.05$; la variable sola PECHO es mejor, ya que tiene una significancia general de 0.000.
3. *Considere ecuaciones con valores altos de R^2 y trate de incluir sólo unas cuantas variables.* En lugar de incluir casi todas las variables disponibles, trate de incluir relativamente pocas variables independientes (x). Utilice los siguientes lineamientos:
   - Seleccione una ecuación que tenga un valor de R^2 ajustada con esta propiedad: si se incluye una variable independiente adicional, el valor de R^2 ajustada no se incrementa de manera sustancial. Por ejemplo, la tabla 9-4 muestra que si empleamos únicamente la variable independiente PECHO, la R^2 ajustada es 0.980, pero cuando incluimos las seis variables, la R^2 ajustada se incrementa a 0.996. Incluir las seis variables, en lugar de sólo una, es un precio demasiado alto para un incremento tan pequeño en la R^2 ajustada. Es mejor que utilicemos únicamente la variable independiente PECHO, que las seis variables independientes.
   - Para un número dado de variables independientes (x), seleccione la ecuación con el valor más grande de la R^2 ajustada.
   - Para suprimir las variables independientes que no tienen mucho efecto sobre la variable dependiente, sería útil calcular el coeficiente de correlación lineal r para cada par de variables en consideración. Por ejemplo, con los datos de la tabla 9-3, encontraremos que existe una correlación lineal de 0.955 para los datos apareados CUELLO/LONGITUD DE CABEZA. Debido a que existe una correlación tan alta entre el tamaño del cuello y la longitud de la cabeza, no hay necesidad de incluir ambas variables. Para elegir entre CUELLO y LONGITUD DE CABEZA, debemos inclinarnos por el CUELLO por la siguiente razón: el CUELLO es un mejor predictor del PESO, ya que los datos apareados CUELLO/PESO tienen un coeficiente de correlación lineal de $r = 0.971$, que es más alto que $r = 0.884$ de los datos apareados LONGITUD DE CABEZA/PESO.

Si seguimos estos lineamientos al intentar calcular la mejor ecuación para predecir los pesos de osos, encontramos que, para los datos de la tabla 9-3, la mejor ecuación de regresión utiliza la variable independiente del tamaño del pecho (PECHO). Parece que la mejor ecuación de regresión es

$$\text{PESO} = -195 + 11.4\ \text{PECHO}$$

o

$$\hat{y} = -195 + 11.4x_7$$

Algunos programas estadísticos de cómputo incluyen un programa para realizar la **regresión por pasos**, de modo que los cálculos se realizan con distintas combinaciones de variables independientes, pero este procedimiento implica graves problemas, incluyendo los siguientes: la regresión por pasos no necesariamente produce el mejor modelo si algunas variables predictoras tienen una alta correlación; produce valores inflados de R^2; utiliza demasiado papel y no nos permite *pensar* en el problema. Como siempre, debemos ser cuidadosos al emplear los resultados de las computadoras como una herramienta que nos ayude a tomar

decisiones inteligentes; no debemos permitir que la computadora sea quien tome las decisiones. En lugar de confiar únicamente en los resultados de una regresión por pasos realizada por un programa de cómputo, considere los factores anteriores cuando trate de identificar la mejor ecuación de regresión múltiple.

Si eliminamos la variable EDAD (como en el lineamiento 1) y después corremos el programa de regresión por pasos de Minitab, obtendremos una pantalla de resultados que sugieren que la mejor ecuación de regresión es aquella en la que PECHO es la única variable independiente. (Si incluimos las seis variables independientes, Minitab selecciona una ecuación de regresión con las variables independientes EDAD, CUELLO, ALTURA y PECHO, con un valor ajustado de R^2 de 0.997 y una significancia general de 0.000). Parece que podemos estimar el peso de un oso con base en el tamaño de su pecho, y la ecuación de regresión nos conduce a esta regla: se estima que el peso de un oso (en libras) es 11.4 veces el tamaño de su pecho (en pulgadas) menos 195.

Cuando estudiamos la regresión en la sección 9-3, indicamos cuatro errores comunes que deben evitarse al utilizar ecuaciones de regresión para hacer predicciones. Estos mismos errores deben evitarse cuando se emplean ecuaciones de regresión múltiple. Sea especialmente cuidadoso al concluir que existe una relación causa-efecto.



Utilizando la tecnología

STATDISK Seleccione **Analysis**, luego **Multiple Regression**. Ingrese los datos en las diferentes columnas o utilice las funciones copiar/pegar para obtener las columnas de datos deseadas. Introduzca los datos de la variable dependiente en la columna 1. Haga clic en **Evaluate** y aparecerá un cuadro de diálogo. Identifique las columnas que desea incluir. STATDISK proporcionará la ecuación de regresión múltiple y otros elementos, incluyendo el coeficiente múltiple de determinación R^2, la R^2 ajustada y el valor *P*.

Minitab Primero introduzca los valores en las distintas columnas. Para evitar confusiones entre las diferentes variables, escriba un nombre para cada variable en el cuadro que se encuentra en la parte superior de la columna de datos. Seleccione **Statistics** del menú principal, después **Regression** y luego **Regression** una vez más. En el cuadro de diálogo, ingrese la variable que se empleará como variable de respuesta (*y*) y las variables que desea incluir como variables *x*. Haga clic en **OK**. Los resultados incluirán el coeficiente múltiple de determinación R^2 y la R^2 ajustada.

Excel Primero ingrese los datos muestrales en las columnas. Seleccione **Tools** del menú principal, después **Data Analysis** y **Regression.** En el cuadro de diálogo introduzca el rango de valores para la variable dependiente *Y*, después el rango de valores para las variables independientes *X*, que deben estar en columnas adyacentes. (Utilice las funciones copiar/pegar para mover las columnas como desee). Los resultados incluirán el coeficiente múltiple de determinación R^2, la R^2 ajustada y una lista de los valores del intercepto y coeficiente utilizados para la ecuación de regresión múltiple.

TI-83 Plus El programa A2MULREG de la calculadora TI-83 Plus puede bajarse del CD-ROM incluido en este libro. Seleccione el archivo de *software*, después *TI83PlusPRGMS*. Debe bajar el programa a su calculadora y después introducir los datos muestrales como una matriz D, en donde la primera columna contenga los valores de la variable dependiente (*y*). Presione **2nd** y la tecla x^{-1}, gire hacia la derecha hasta **EDIT**, gire hacia abajo hasta **[D]**, después presione **ENTER** y proceda a introducir el número de valores listados por cada variable, seguido por el número total de variables (incluyendo la variable dependiente). Ahora presione **PRGM,** seleccione **A2MULREG** y luego **ENTER**. Cuando se le solicite, ingrese el número de variables independientes, después introduzca los números de las columnas de las variables independientes que desea incluir. La pantalla proporcionará un resultado que incluye al valor *P* y el valor de R^2 ajustada. Presione **ENTER** para ver los valores que se utilizarán en la ecuación de regresión múltiple. Presione **ENTER** nuevamente para obtener el menú que incluye opciones para generar intervalos de confianza, intervalos de predicción, residuales o para salir. Si usted desea generar intervalos de confianza y de predicción, utilice el número de grados de libertad que aparece, vaya a la tabla A-3 y busque el valor *t* crítico correspondiente, introdúzcalo y proceda a ingresar los valores que se emplearán para las variables independientes. Presione **ENTER** para seleccionar la opción **QUIT**.

9-5 Destrezas y conceptos básicos

Interpretación de resultados de programas de cómputo. *En los ejercicios 1 a 4, remítase a los resultados de Minitab que se presentan aquí y responda las preguntas o identifique los elementos indicados. Los resultados de Minitab están basados en la muestra de 54 osos incluida en el conjunto de datos 9 del Apéndice B.*

1. Mediciones de osos Identifique la ecuación de regresión múltiple que expresa el peso en términos de la longitud de la cabeza, la altura y el tamaño del pecho.

2. Mediciones de osos Identifique lo siguiente:
- **a.** El valor *P* correspondiente a la significancia general de la ecuación de regresión múltiple
- **b.** El valor del coeficiente múltiple de determinación R^2
- **c.** El valor ajustado de R^2

3. Mediciones de osos ¿Es útil la ecuación de regresión múltiple para predecir el peso de un oso con base en la longitud de su cabeza, la altura y el tamaño del pecho? ¿Por qué?

4. Mediciones de osos Se encuentra que un oso tiene una longitud de cabeza de 14.0 pulgadas, una altura de 70.0 pulgadas y un tamaño del pecho de 50.0 pulgadas.
- **a.** Calcule el peso predicho del oso.
- **b.** El oso en cuestión en realidad pesaba 320 libras. ¿Qué tan preciso es el peso predicho en el inciso *a*?

Minitab

```
The regression equation is
WEIGHT = −272 − 0.87 HEADLEN + 0.55 LENGTH + 12.2 CHEST
Predictor          Coef     SE Coef          T          P
Constant       −271.71       31.62     −8.59      0.000
HEADLEN         −0.870       5.676     −0.15      0.879
LENGTH           0.554       1.259      0.44      0.662
CHEST           12.153       1.116     10.89      0.000

S = 33.66          R-Sq = 92.8%      R-Sq(adj) = 92.4%

Analysis of Variance

Source            DF        SS        MS         F        P
Regresión          3    729645    243215    214.71    0.000
Residual Error    50     56638      1133
Total             53    786283
```

Datos de automóviles: cálculo de la mejor ecuación de regresión múltiple. *En los ejercicios 5 a 8, remítase a la tabla adjunta, que se obtuvo utilizando el conjunto de datos 22 del Apéndice B. La variable dependiente es el consumo de combustible en ciudad (en millas/galón), y las variables independientes están listadas en la tabla. CRT denota el consumo de combustible en carretera, PS denota el peso del automóvil y DSPZ el desplazamiento del motor del automóvil.*

Variables independientes	Valor P	R^2	R^2 ajustada	Ecuación de regresión
CRT, PS, DSPZ	0.000	0.882	0.860	$\hat{y} = 5.9 + 0.742x_1 - 0.00162x_2 - 0.441x_3$
CRT, PS	0.000	0.876	0.861	$\hat{y} = 4.6 + 0.794x_1 - 0.00209x_2$
CRT, DSPZ	0.000	0.873	0.859	$\hat{y} = -3.23 + 0.892x_1 - 0.626x_2$
PS, DSPZ	0.000	0.788	0.763	$\hat{y} = 41.5 - 0.00535x_1 - 0.950x_2$
CRT	0.000	0.860	0.853	$\hat{y} = -9.73 + 1.05x$
PS	0.000	0.759	0.746	$\hat{y} = 44.2 - 0.00708x$
DSPZ	0.000	0.620	0.599	$\hat{y} = 29.5 - 2.74x$

5. Si se utiliza únicamente una variable independiente para predecir la cantidad de consumo de combustible en la ciudad (en mi/gal), ¿cuál variable es mejor? ¿Por qué?

6. Si se van a utilizar exactamente dos variables independientes para predecir la cantidad del consumo de combustible en la ciudad, ¿cuáles dos variables deben elegirse? ¿Por qué?

7. ¿Cuál ecuación de regresión es mejor para predecir la cantidad de consumo de combustible en la ciudad? ¿Por qué?

8. Si un automóvil tiene una tasa de consumo de combustible en carretera de 35 mi/gal, un peso de 2675 libras y un desplazamiento de motor de 3.8 L, ¿cuál es el mejor valor predicho de la tasa de consumo de combustible en la ciudad? ¿Es posible que ese valor predicho constituya un buen estimado? ¿Es posible que el valor predicho sea muy preciso?

T **9.** Estaturas de padres e hijos Remítase al conjunto de datos de 2 del Apéndice B.

a. Calcule la ecuación de regresión que expresa la variable dependiente de la estatura de un hijo en términos de la variable independiente de la estatura de la madre.

b. Calcule la ecuación de regresión que expresa la variable dependiente de la estatura de un hijo en términos de la variable independiente de la estatura del padre.

c. Calcule la ecuación de regresión que expresa la variable dependiente de la estatura de un hijo en términos de las variables independientes de la estatura de la madre y la estatura del padre.

d. Respecto a las ecuaciones de regresión obtenidas en los incisos *a*, *b* y *c*, ¿cuál es la mejor ecuación para predecir la estatura de un hijo? ¿Por qué?

e. ¿Será la mejor ecuación de regresión, identificada en el inciso *d*, una *buena* ecuación para predecir la estatura de un hijo? ¿Por qué?

T **10.** Facilidad de lectura de Harry Potter Remítase al conjunto de datos 14 del Apéndice B y utilice los valores de *Harry Potter y la piedra filosofal*, de J. K. Rowling.

a. Calcule la ecuación de regresión que expresa la variable dependiente de la puntuación de facilidad de lectura de Flesch en términos de la variable independiente de las palabras por oración.

b. Calcule la ecuación de regresión que expresa la variable dependiente de la puntuación de facilidad de lectura de Flesch en términos de la variable independiente de los caracteres por palabra.

c. Calcule la ecuación de regresión que expresa la variable dependiente de la puntuación de facilidad de lectura de Flesch en términos de las variables independientes de las palabras por oración y los caracteres por palabra.

d. Respecto a las ecuaciones de regresión obtenidas en los incisos *a*, *b* y *c*, ¿cuál es la mejor ecuación para predecir una puntuación de la facilidad de lectura de Flesch? ¿Por qué?

e. ¿Será la mejor ecuación de regresión, identificada en el inciso *d*, una *buena* ecuación para predecir una puntuación de facilidad de lectura de Flesch? ¿Por qué?

T **11.** Cereales y calorías Remítase al conjunto de datos 16 del Apéndice B.

a. Calcule la ecuación de regresión que expresa la variable dependiente de calorías en términos de la variable independiente de la cantidad de grasa.

b. Calcule la ecuación de regresión que expresa la variable dependiente de calorías en términos de la variable independiente de la cantidad de azúcar.
c. Calcule la ecuación de regresión que expresa la variable dependiente de calorías en términos de las variables independientes de la cantidad de grasa y de la cantidad de azúcar.
d. Respecto a las ecuaciones de regresión obtenidas en los incisos *a*, *b* y *c*, ¿cuál es la mejor ecuación para predecir el número de calorías? ¿Por qué?
e. ¿Será la mejor ecuación de regresión, identificada en el inciso *d*, una *buena* ecuación para predecir el número de calorías? ¿Por qué?

T 12. Uso de la basura para predecir el tamaño poblacional Remítase al conjunto de datos 23 del Apéndice B.
a. Calcule la ecuación de regresión que expresa la variable dependiente del tamaño de los hogares en términos de la variable independiente del peso de los desechos de comida.
b. Calcule la ecuación de regresión que expresa la variable dependiente del tamaño de los hogares en términos de la variable independiente del peso de los desechos plásticos.
c. Calcule la ecuación de regresión que expresa la variable dependiente del tamaño de los hogares en términos de las variables independientes del peso de los desechos de comida y el peso de los deshechos plásticos.
d. Respecto a las ecuaciones de regresión obtenidas en los incisos *a*, *b* y *c*, ¿cuál es la mejor ecuación para predecir el tamaño de los hogares? ¿Por qué?
e. ¿Será la mejor ecuación de regresión, identificada en el inciso *d*, una *buena* ecuación para predecir el tamaño de los hogares? ¿Por qué?

9-5 Más allá de lo básico

T 13. Nicotina de cigarrillos: cálculo de la mejor ecuación de regresión múltiple Remítase al conjunto de datos 5 del Apéndice B y calcule la mejor ecuación de regresión múltiple, con la nicotina como variable dependiente. ¿Será esta "mejor" ecuación buena para predecir la cantidad de nicotina en un cigarrillo con base en la cantidad de alquitrán y monóxido de carbono?

T 14. Precio de un diamante: cálculo de la mejor ecuación de regresión múltiple Remítase al conjunto de datos 18 del Apéndice B.
a. Utilice únicamente los tres factores tradicionales del quilate, color y claridad para calcular la mejor ecuación de regresión múltiple que podría emplearse para predecir el precio de un diamante.
b. Las variables profundidad y meseta describen el corte de un diamante que, se supone, afecta su color. ¿Existe una relación lineal significativa entre la variable dependiente del color y las variables dependientes de profundidad y meseta? Si no existe una relación lineal significativa, ¿quiere esto decir que el color no se ve afectado por la profundidad y la meseta?

T 15. Precio de venta de casas: cálculo de la mejor ecuación de regresión múltiple Remítase al conjunto de datos 24 del Apéndice B y calcule la mejor ecuación de regresión múltiple con el precio de venta como variable dependiente. ¿Será esta "mejor" ecuación buena para predecir el precio de venta de una casa?

x	1	3	4	7	5
y	5	14	19	42	26

T 16. Uso de la regresión múltiple para la ecuación de la parábola En algunos casos, la ecuación de regresión múltiple que se ajusta mejor tiene la forma $\hat{y} = b_0 + b_1x + b_2x^2$. La gráfica de un ecuación como ésta es una parábola. Utilice el conjunto de datos listado al margen, permita que $x_1 = x$, permita que $x_2 = x^2$, y calcule la ecuación de regresión múltiple para la parábola, que se ajusta mejor a los datos. Con base en el valor del coeficiente múltiple de determinación, ¿qué tan bien se ajusta esta ecuación a los datos?

9-6 Elaboración de modelos

No, no ese tipo de modelos. Esta sección introduce algunos conceptos básicos del desarrollo de un **modelo matemático**, que es una función matemática que se "ajusta" o describe datos del mundo real. Por ejemplo, podríamos buscar un modelo matemático consistente en una ecuación que relaciona una variable del tamaño poblacional con otra variable que representa el tiempo. Esto es muy parecido a los métodos de regresión de la sección 9-3, excepto que ya no estamos restringidos a un modelo que deba ser lineal. Además, en lugar de utilizar datos muestrales seleccionados al azar, consideraremos datos reunidos periódicamente a través del tiempo o alguna otra unidad básica de medición. Existen algunos métodos estadísticos poderosos que podemos estudiar (tales como las *series de tiempo*), pero el principal objetivo de esta sección es describir brevemente la manera en que se emplea la tecnología para obtener un buen modelo matemático.

A continuación se presentan algunos modelos genéricos como aparecen en un menú de la calculadora TI-83 Plus (presione **STAT** y luego seleccione **CALC**):

Lineal: $y = a + bx$ Cuadrático: $y = ax^2 + bx + c$

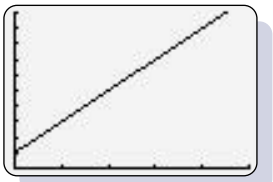
Logarítmico: $y = a + b \ln x$ Exponencial: $y = ab^x$

Potencia: $y = ax^b$ Logístico: $y = \dfrac{c}{1 + ae^{-bx}}$

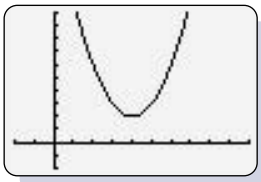
El modelo particular que usted seleccione depende de la naturaleza de los datos muestrales, y un diagrama de dispersión resulta muy útil para tomar esta determinación. Las ilustraciones a continuación son gráficas de algunos modelos comunes elaborados en una calculadora TI-83 Plus.

TI-83 Plus

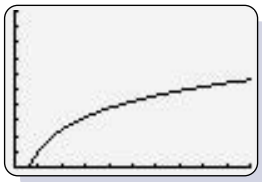
Linear: $y = 1 + 2x$



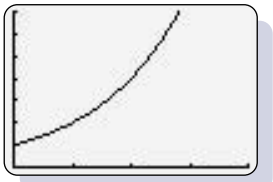
Quadratic: $y = x^2 - 8x + 18$



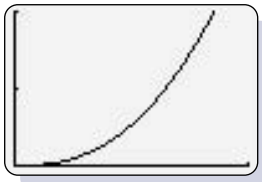
Logarithmic: $y = 1 + 2 \ln x$



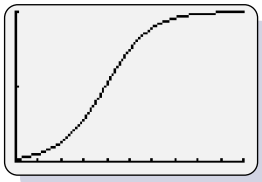
Exponential: $y = 2^x$



Power: $y = 3x^{2.5}$



Logistic: $y = \dfrac{2}{1 + 50e^{-x}}$



12



Estadística no paramétrica

12-1 Panorama general

12-2 Prueba del signo

12-3 Prueba de rangos con signo de Wilcoxon para datos apareados

12-4 Prueba de la suma de rangos de Wilcoxon para dos muestras independientes

12-5 Prueba de Kruskal-Wallis

12-6 Correlación de rangos

12-7 Prueba de rachas para detectar aleatoriedad

PROBLEMA DEL CAPÍTULO 12

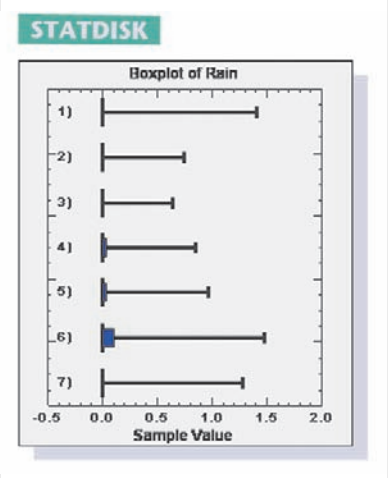
¿¡Llueve más durante los fines de semana!?

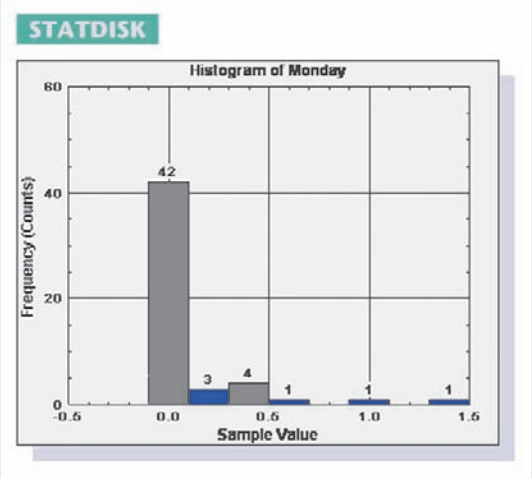
En un artículo para el Knight Ridder News Service, Usha Lee McFarling escribió que “sus peores temores por el clima son ciertos. Llueve más durante los fines de semana. Científicos que a través de muchos años reunieron gran cantidad de datos sobre la lluvia han descubierto un patrón claro y desalentador. Viernes, sábados y domingos son los días más lluviosos de la semana a todo lo largo de la costa este de Estados Unidos, desde Maine hasta Florida”. La nota se refiere a un estudio que realizaron los científicos Randall S. Ceverny y Robert C. Balling de Arizona State University. Pero, ¿son correctas sus conclusiones? ¿Los datos se reportaron e interpretaron correctamente?

El conjunto de datos 11 del Apéndice B incluye cantidades de lluvia de un año reciente en Boston. Al seleccionar una ciudad para verificar el fenómeno de la lluvia durante el fin de semana, Boston debería ser una buena opción, puesto que se localiza en la costa este. Si utilizamos el STATDISK para calcular la cantidad de lluvia para cada día de la semana, obtendremos las gráficas de cuadro adjuntas. De la parte superior a la inferior, las gráficas de cuadro representan el lunes, el martes, . . . y el domingo. La gráfica de cuadro del lunes, en la parte superior, es peculiar, ya que parece estar desapareciendo del cuadro, pero las cantidades de lluvia del lunes tienen tantos ceros que el mínimo, el primer cuartil y la mediana son todos ceros, ocasionando que el cuadro se comprima hacia la izquierda. Mayores cantidades de lluvia en viernes, sábado y domingo serían visibles con las distribuciones situadas más a la derecha. ¿Es éste el caso en realidad? ¿Son realmente significativas tales diferencias?

Consideremos el uso de los métodos que se presentan en capítulos anteriores para investigar este tema. El análisis de varianza (sección 11-2) sería una buena opción, pero ese método requiere que las muestras provengan de poblaciones con una distribución normal. El histograma generado por el STATDISK para las cantidades de lluvia del lunes muestra con claridad que esos valores no provienen de una población distribuida normalmente. Los otros días muestran distribuciones similares que, a todas luces, no son normales. Una ventaja importante de los métodos que se analizan en este capítulo es que no requieren de una distribución normal o de cualquiera otra distribución en particular.

¿Es posible utilizar los datos de Boston para sustentar la aseveración de más lluvias durante los fines de semana? ¿Son significativamente diferentes las cantidades de lluvia para los diferentes días? Abordaremos tales preguntas más tarde en el capítulo.





12-1 Panorama general

A los métodos de estadística diferencial que se presentan en los capítulos 6, 7, 8, 9 y 11 se les llama *métodos paramétricos*, porque se basan en el muestreo de una población con parámetros específicos, como la media μ, la desviación estándar σ o la proporción p. Estos métodos paramétricos por lo regular deben cumplir con algunas condiciones bastante estrictas, como el requisito de que los datos muestrales provengan de una población que se distribuya normalmente. Este capítulo introduce métodos no paramétricos, que están libres de tan estrictos requisitos.

Definiciones

Las **pruebas paramétricas** requieren supuestos acerca de la naturaleza o forma de las poblaciones involucradas; las **pruebas no paramétricas** no requieren supuestos acerca de las distribuciones poblacionales. En consecuencia, las pruebas de hipótesis no paramétricas suelen llamarse **pruebas de distribución libre**.

Aunque el término *no paramétrica* sugiere que la prueba no se basa en un parámetro, hay algunas pruebas no paramétricas que sí dependen de un parámetro, como la mediana. Sin embargo, las pruebas no paramétricas no requieren una distribución particular, por lo que algunas veces se les conoce como pruebas de *distribución libre*. Aunque *distribución libre* es una descripción más precisa, por lo regular se utiliza el término *no paramétrica*. Las siguientes son las ventajas y desventajas principales de los métodos no paramétricos.

Ventajas de los métodos no paramétricos

1. Los métodos no paramétricos se aplican a una amplia variedad de situaciones, puesto que no tienen los requisitos más estrictos de los métodos paramétricos correspondientes. En particular, los métodos no paramétricos no requieren poblaciones distribuidas normalmente.
2. A diferencia de los métodos paramétricos, los métodos no paramétricos con frecuencia se aplican a datos categóricos, como el género de quienes responden una encuesta.
3. Los métodos no paramétricos por lo regular implican cálculos más sencillos que los métodos paramétricos correspondientes; por lo tanto, son más fáciles de entender y aplicar.

Desventajas de los métodos no paramétricos

1. Los métodos no paramétricos tienden a desperdiciar información, pues los datos numéricos exactos suelen reducirse a una forma cualitativa. Por ejemplo, en la prueba del signo no paramétrica (descrita en la sección 12-2), las pérdidas de peso de las personas que se someten a una dieta se registran simplemente como signos negativos; las magnitudes reales de las pérdidas de peso se ignoran.
2. Las pruebas no paramétricas no son tan eficientes como las pruebas paramétricas, por lo que para una prueba no paramétrica generalmente necesitaremos

evidencia más fuerte (como una muestra más grande o diferencias mayores) para rechazar una hipótesis nula.

Cuando se satisfacen los requisitos de distribuciones poblacionales, las pruebas no paramétricas generalmente son menos eficaces que sus contrapartes paramétricas, aunque la reducción en la eficacia puede compensarse con un tamaño muestral más grande. Por ejemplo, la sección 12-6 presentará un concepto que se llama *correlación de rangos*, con una tasa de eficacia de 0.91, cuando se compara con la correlación lineal que se presenta en el capítulo 9. Esto significa que si todas las demás cosas son iguales, la correlación de rangos no paramétrica requiere 100 observaciones muestrales, para obtener los mismos resultados que 91 observaciones muestrales que se analicen con la correlación lineal paramétrica, suponiendo que se satisfacen los requisitos más estrictos para la aplicación del método paramétrico. La tabla 12-1 lista los métodos no paramétricos que se presentan en este capítulo, junto con el método paramétrico correspondiente y la tasa de **eficiencia**. La tabla 12-1 muestra que varias pruebas no paramétricas tienen tasas de eficiencia por encima de 0.90, por lo que la eficiencia más baja no sería un factor crítico para elegir entre los métodos paramétricos y no paramétricos. Sin embargo, como las pruebas paramétricas no tienen tasas de eficiencia más altas que sus contrapartes no paramétricas, generalmente es mejor utilizar las pruebas paramétricas cuando los supuestos que se requieren se satisfacen.

Rangos

Las secciones 12-3 a 12-6 utilizan métodos que se basan en rangos, que ahora describiremos.

Definición

Los datos se *ordenan* cuando se acomodan de acuerdo con algún criterio, como de más pequeño a más grande, o de mejor a peor. Un **rango** es un número que se asigna a un elemento muestral individual de acuerdo con su orden en la lista ordenada. Al primer elemento se le asigna un rango de 1, al segundo elemento se le asigna un rango de 2, etcétera.

Tabla 12-1 Eficiencia: comparación de pruebas paramétricas y no paramétricas

Aplicación	Prueba paramétrica	Prueba no paramétrica	Tasa de eficiencia de prueba no paramétrica con población normal
Datos apareados de los datos muestrales	Prueba *t* o prueba *z*	Prueba del signo	0.63
		Prueba de rangos con signo de Wilcoxon	0.95
Dos muestras independientes	Prueba *t* o prueba *z*	Prueba de la suma de rangos de Wilcoxon	0.95
Varias muestras independientes	Análisis de varianza (prueba *F*)	Prueba de Kruskal-Wallis	0.95
Correlación	Correlación lineal	Prueba de correlación de rangos ordenados	0.91
Aleatoriedad	Prueba no paramétrica	Prueba de rachas	Sin bases para comparación

EJEMPLO Los números 5, 3, 40, 10 y 12 pueden ordenarse (si se acomodan de menor a mayor) como 3, 5, 10, 12 y 40, con rangos de 1, 2, 3, 4 y 5, respectivamente:

5	3	40	10	12	Valores originales
3	5	10	12	40	Valores ordenados (que se acomodaron en orden)
↑	↑	↑	↑	↑	
1	2	3	4	5	Rangos

Manejo de empates en rangos: Si ocurre un empate en los rangos, el procedimiento habitual es calcular la media de los rangos que intervienen y luego asignar este rango medio a cada uno de los elementos empatados, como en el ejemplo siguiente.

EJEMPLO Los números 3, 5, 5, 10 y 12 tienen rangos dados de 1, 2.5, 2.5, 4 y 5, respectivamente. En este caso, los rangos 2 y 3 empataron; por lo tanto, calculamos la media de 2 y 3 (que es 2.5) y la asignamos a los valores que crearon el empate:

3	5	5	10	12	Valores originales
↑	↑	↑	↑	↑	
1	2.5	2.5	4	5	Rangos
	↑	↑			

2 y 3 están empatados

12-2 Prueba del signo

El objetivo principal de esta sección es entender el procedimiento de la *prueba del signo*, que es uno de los más sencillos de las pruebas no paramétricas.

Definición

Prueba del signo: una prueba no paramétrica (de distribución libre) que utiliza signos positivos y negativos para probar diferentes aseveraciones, incluyendo:

1. Aseveraciones que incluyen datos apareados de datos muestrales
2. Aseveraciones que incluyen datos nominales
3. Aseveraciones acerca de la mediana de una sola población

Concepto básico de la prueba del signo La idea básica que está detrás de la prueba del signo es el análisis de las frecuencias de los signos positivos y negativos, para determinar si son significativamente diferentes. Por ejemplo, suponga que probamos un tratamiento que se diseñó para disminuir la presión sanguínea. Si se trata a 100 sujetos y 51 de ellos experimentan una presión sanguínea más baja, mientras que los otros 49 tienen una presión sanguínea incrementada, el sentido

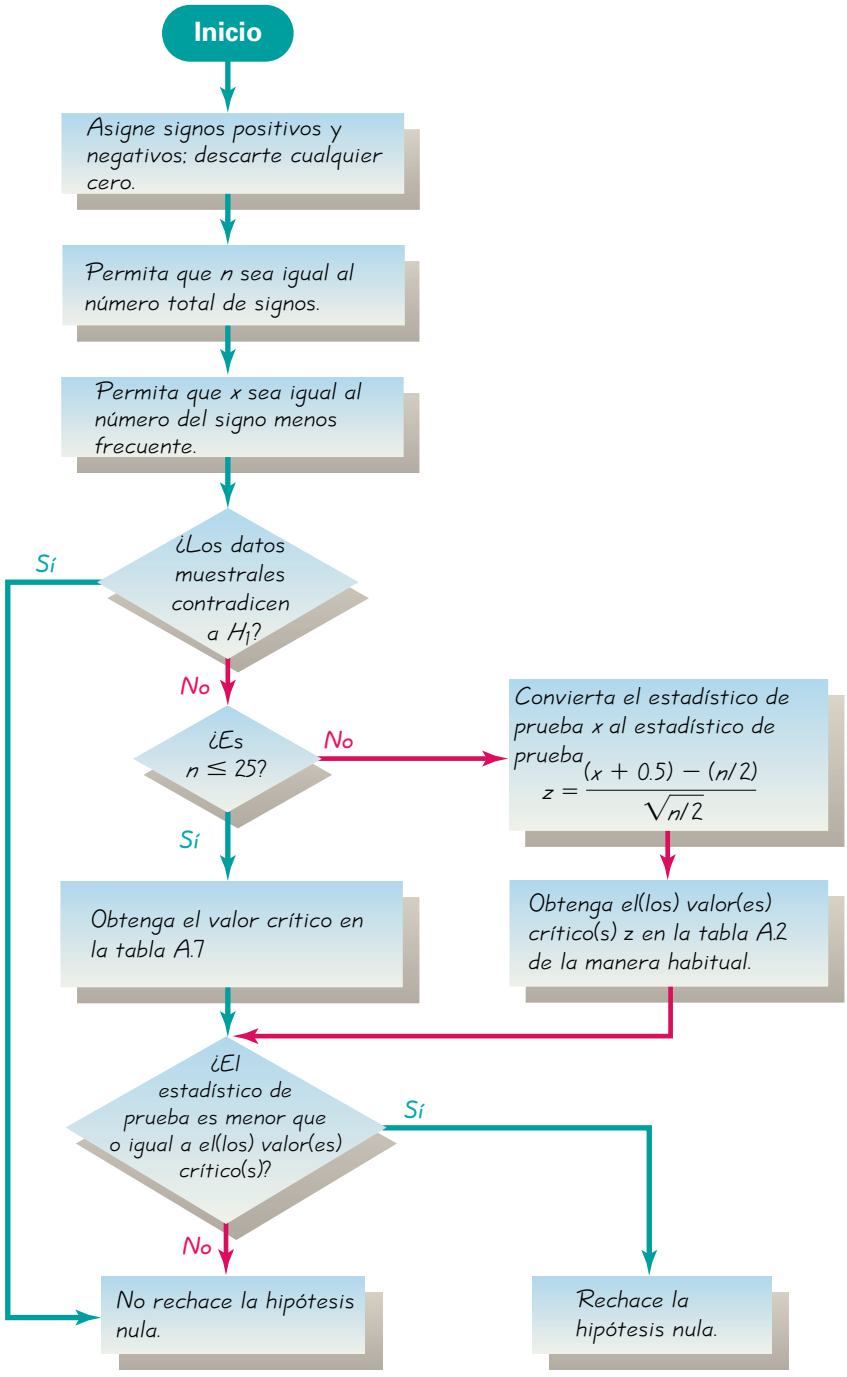


FIGURA 12-1
Procedimiento de la prueba del signo

común sugiere que no hay evidencia suficiente para decir que el fármaco es eficaz, puesto que 51 disminuciones en 100 casos no son significativas. Pero ¿qué sucede con 52 disminuciones y 48 incrementos? ¿O con 90 disminuciones y 10 incrementos? La prueba del signo nos permite determinar cuándo son significativos este tipo de resultados.

Por razones de consistencia y simplicidad, utilizaremos un estadístico de prueba con base en el número de veces que ocurre el signo menos frecuente. En el cuadro adjunto se resumen los supuestos relevantes, la notación, el estadístico de

prueba y los valores críticos. La figura 12-1 resume el procedimiento de la prueba del signo, que se ilustrará con los ejemplos que siguen.

Prueba del signo

Supuestos

1. Los datos muestrales se seleccionaron aleatoriamente.
2. *No* existe el requisito de que los datos muestrales provengan de una población con una distribución particular, como una distribución normal.

Notación

x = el número de veces que ocurre el signo *menos frecuente*

n = el número total de signos positivos y negativos combinados

Estadístico de prueba

Para $n \leq 25$: x (el número de veces que ocurre el signo menos frecuente)

$$\text{Para } n > 25\text{: } z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

Valores críticos

1. Para $n \leq 25$, los valores críticos x se encuentran en la tabla A-7.
2. Para $n > 25$, los valores críticos z se encuentran en la tabla A-2.

Cuidado: Cuando se aplica la prueba del signo en una prueba de una cola, necesitamos ser muy cuidadosos para no sacar la conclusión incorrecta cuando un signo ocurre significativamente con más frecuencia que el otro, aunque los datos muestrales contradicen la hipótesis alternativa. Por ejemplo, suponga que estamos probando la aseveración de que una técnica de selección de género favorece a los niños, pero tenemos una muestra de 10 niños y 90 niñas. Con una proporción muestral de niños igual a 0.10, los datos contradicen la hipótesis alternativa H_1: $p > 0.5$. No hay forma de sustentar la aseveración de que $p > 0.5$ con ninguna proporción muestral menor que 0.5, por lo que de inmediato no rechazamos la hipótesis nula y no procedemos con la prueba del signo. La figura 12-1 resume el procedimiento para la prueba del signo e incluye esta revisión: ¿Contradicen los datos muestrales a H_1? Si los datos muestrales van en el sentido opuesto de H_1, no rechace la hipótesis nula. *Siempre es importante pensar acerca de los datos y evitar la confianza a ciegas en cálculos o resultados de computadora.*

Aseveraciones que incluyen datos apareados

Cuando se utiliza la prueba del signo con datos que se ordenan en pares, convertimos los datos brutos en datos con signos positivos y negativos como sigue:

1. Restamos cada valor de la segunda variable del valor correspondiente de la primera variable.
2. Registramos sólo el *signo* de la diferencia que se encontró en el paso 1. *Excluimos los empates*, es decir, excluimos todos los datos apareados en los que ambos valores son iguales.

Éste es el concepto clave tras la aplicación de la prueba del signo:

Si dos conjuntos de datos tienen medianas iguales, el número de signos positivos debe ser aproximadamente igual al número de signos negativos.

EJEMPLO Medición de inteligencia en niños Las mediciones mentales de niños pequeños se hacen dándoles cubos y pidiéndoles que construyan una torre tan alta como sea posible. Un experimento de construcción con cubos se repitió un mes después, con los tiempos (en segundos) listados en la tabla 12-2 (datos tomados de "Tower Building", de Johnson y Courtney, *Child Development*, vol. 3). Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre los tiempos de la primera y segunda pruebas.

SOLUCIÓN La siguiente es la idea básica: si no hay diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba, los números de signos positivos y negativos deben ser aproximadamente iguales. En la tabla 12-2 tenemos 12 signos positivos y 2 signos negativos. ¿Son aproximadamente iguales los números de signos positivos y negativos, o son significativamente diferentes? Seguimos los mismos pasos básicos de prueba de hipótesis, tal como se perfilaron en la figura 12-1.

Pasos 1, 2 y 3: La hipótesis nula es la aseveración de no diferencia entre los tiempos de la primera y la segunda pruebas, en tanto que la hipótesis alternativa es la aseveración de que hay una diferencia.

H_0: No existe diferencia (la mediana de las diferencias es igual a 0).

H_1: Existe una diferencia (la mediana de las diferencias no es igual a 0).

Paso 4: El nivel de significancia es $\alpha = 0.05$.

Paso 5: Utilizamos la prueba no paramétrica del signo.

continúa

Tabla 12-2 Tiempos de construcción de torres con cubos

Niño	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
Primera prueba	30	19	19	23	29	178	42	20	12	39	14	81	17	31	52
Segunda prueba	30	6	14	8	14	52	14	22	17	8	11	30	14	17	15
Signo de la diferencia	0	+	+	+	+	+	+	−	−	+	+	+	+	+	+



Asistencia a clases y calificaciones

En un estudio entre 424 estudiantes universitarios de la Universidad de Michigan se encontró que los estudiantes con los peores registros de asistencia tendían a obtener las calificaciones más bajas (¿quién se sorprende?). Aquellos que estuvieron ausentes menos del 10% del tiempo recibieron, en general, calificaciones de B o superiores. El estudio también mostró que los estudiantes que se sientan al frente en el salón de clases significativamente obtienen mejores calificaciones.

Paso 6: El estadístico de prueba x es el número de veces que ocurre el signo menos frecuente. La tabla 12-2 incluye diferencias con 12 signos positivos y dos signos negativos; descartamos el único caso con una diferencia de cero. Permitimos que x sea igual al menor entre 12 y 2; por lo tanto, $x = 2$. Además, $n = 14$ (el número total de signos positivos y negativos combinados). Nuestra prueba es de dos colas con $\alpha = 0.05$. Nos remitimos a la tabla A-7 donde se encuentra el valor crítico de 2 para $n = 14$ y $\alpha = 0.05$ en dos colas. (Véase la figura 12-1).

Paso 7: Con un estadístico de prueba de $x = 2$ y un valor crítico de 2, rechazamos la hipótesis nula de no diferencia. [Consulte la nota 2 de la tabla A-7: "La hipótesis nula se rechaza si el número del signo menos frecuente (x) es menor que o igual al valor en la tabla". Puesto que $x = 2$ es menor que o igual al valor crítico de 2, rechazamos la hipótesis nula].

Paso 8: Hay suficiente evidencia para sustentar el rechazo de la aseveración de que la mediana de las diferencias es igual a 0; esto es, existe suficiente evidencia para sustentar el rechazo de la aseveración de que no hay una diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba. Es la misma conclusión que se alcanzaría utilizando la prueba paramétrica t con los datos apareados de la sección 8-4, aunque los resultados de la prueba del signo no siempre coinciden con los resultados de la prueba paramétrica.

Aseveraciones que incluyen datos nominales

Recuerde que los datos nominales consisten sólo en nombres, etiquetas o categorías. Aunque dichos conjuntos de datos nominales limitan los cálculos posibles, se identifica la *proporción* de datos muestrales que pertenece a una categoría en particular y se prueban aseveraciones acerca de la proporción poblacional p correspondiente. El siguiente ejemplo utiliza datos nominales que consisten en el género (hombre/mujer). La prueba del signo se utiliza representando a los hombres con signos positivos (+) y a las mujeres con signos negativos (−). (Créanme, los signos se eligieron arbitrariamente). También observe el procedimiento para manejar casos en los que $n > 25$.

EJEMPLO Discriminación por género La cadena de restaurantes Hatters recibió acusaciones de discriminación por género porque sólo contrató a 30 hombres junto a 70 mujeres solicitantes. Una representante de la compañía aceptó que los solicitantes calificados son aproximadamente la mitad hombres y la mitad mujeres, pero además asevera que "Hatters no discrimina y el hecho de que 30 de los últimos 100 empleados nuevos sean hombres es sólo una casualidad". Utilice la prueba del signo con un nivel de significancia de 0.05 y pruebe la hipótesis nula de que esta compañía contrata a hombres y a mujeres por igual.

SOLUCIÓN Permita que p denote la proporción poblacional de hombres contratados. La aseveración de no discriminación implica que las proporciones de hombres y mujeres contratados son iguales a 0.5; entonces, $p = 0.5$. Por lo tanto, las hipótesis nula y la alternativa pueden establecerse de la siguiente manera:

H_0: $p = 0.5$ (la proporción de hombres contratados es igual a 0.5)
H_1: $p \neq 0.5$

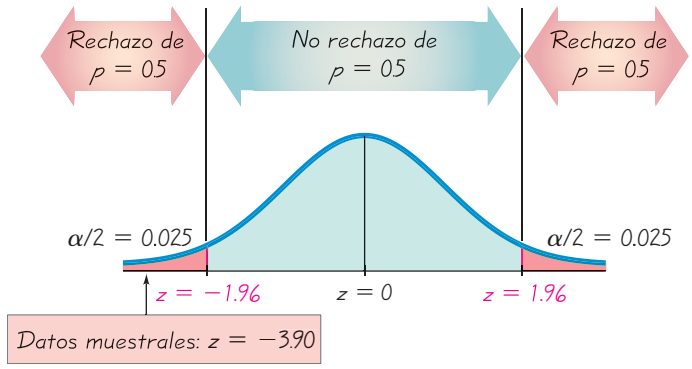


FIGURA 12-2 **Prueba de la aseveración de prácticas de contratación injustas**

Si denotamos a los hombres contratados con + y a las mujeres contratadas con −, tenemos 30 signos positivos y 70 signos negativos. Ahora remítase al procedimiento de prueba del signo que se resume en la figura 12-1. El estadístico de prueba x es el menor entre 30 y 70; entonces, $x = 30$. Esta prueba es de dos colas, puesto que un número desproporcionadamente bajo de cualquier género nos causará el rechazo de la aseveración de igualdad. Los datos muestrales no contradicen la hipótesis alternativa, ya que 30 y 70 no son precisamente iguales. (Esto es, los datos muestrales son consistentes con la hipótesis alternativa de una diferencia). Continuando con el procedimiento de la figura 12-1, notamos que el valor de $n = 100$ es superior a 25, por lo cual el estadístico de prueba x se convierte (utilizando una corrección por continuidad) al estadístico de prueba z como sigue:

$$z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

$$= \frac{(30 + 0.5) - \left(\frac{100}{2}\right)}{\frac{\sqrt{100}}{2}} = -3.90$$

Con $\alpha = 0.05$ en una prueba de dos colas, los valores críticos son $z = \pm 1.96$. El estadístico de prueba $z = -3.90$ es menor que -1.96 (véase la figura 12-2), por lo que rechazamos la hipótesis nula de que la proporción de hombres contratados es igual a 0.5. Hay suficiente evidencia de muestra para justificar el rechazo de la aseveración de que las prácticas de contratación son justas, con proporciones de hombres contratados y mujeres contratadas igual a 0.5. Parece que esta compañía discrimina por no contratar proporciones iguales de hombres y de mujeres.

Aseveraciones acerca de la mediana de una sola población

El siguiente ejemplo ilustra el procedimiento para utilizar la prueba del signo en la prueba de una aseveración acerca de la mediana de una sola población. Observe cómo los signos positivos y negativos se basan en el valor que se asevera para la mediana.

EJEMPLO Temperaturas corporales El conjunto de datos 4 del Apéndice B incluye temperaturas corporales medidas en adultos. Utilice las 106 temperaturas listadas para las 12:00 AM del día 2 con la prueba del signo, para probar la aseveración de que la mediana es menor que 98.6°F. El conjunto de datos tiene 106 sujetos: 68 sujetos con temperaturas por debajo de 98.6°F, 23 sujetos con temperaturas por encima de 98.6°F y 15 sujetos con temperaturas iguales a 98.6°F.

SOLUCIÓN La aseveración de que la mediana es menor que 98.6°F es la hipótesis alternativa, mientras la hipótesis nula es la aseveración de que la mediana es igual a 98.6°F.

H_0: La mediana es igual a 98.6°F. (mediana = 98.6°F)
H_1: La mediana es menor que 98.6°F. (mediana < 98.6°F)

Siguiendo el procedimiento que se perfiló en la figura 12-1, descartamos los 15 ceros, utilizamos el signo negativo (−) para denotar cada temperatura por debajo de 98.6°F y utilizamos el signo positivo (+) para denotar cada temperatura por encima de 98.6°F. Así, tenemos 68 signos negativos y 23 signos positivos; entonces, $n = 91$ y $x = 23$ (el número del signo menos frecuente). Los datos muestrales no contradicen la hipótesis alternativa, puesto que la mayoría de las 91 temperaturas están por debajo de 98.6°F. (Si los datos muestrales presentan un conflicto con la hipótesis alternativa, terminaríamos inmediatamente la prueba concluyendo que no rechazamos la hipótesis nula). El valor de n excede a 25, por lo que convertimos el estadístico de prueba x al estadístico de prueba z:

$$z = \frac{(x + 0.5) - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

$$= \frac{(23 + 0.5) - \left(\frac{91}{2}\right)}{\frac{\sqrt{91}}{2}} = -4.61$$

En la prueba de una cola con $\alpha = 0.05$, utilizamos la tabla A-2 para obtener el valor crítico z de -1.645. En la figura 12-3 vemos que el estadístico de prueba $z = -4.61$ cae dentro de la región crítica; por lo tanto, rechazamos la hipótesis nula. Con base en la evidencia muestral disponible, sustentamos la aseveración de que la mediana de la temperatura corporal de adultos saludables es menor que 98.6°F.

En esta prueba del signo, para la aseveración de que la mediana está por debajo de 98.6°F, obtenemos un estadístico de prueba de $z = -4.61$, con un valor P de 0.00000202, pero una prueba paramétrica de la aseveración de que $\mu < 98.6$°F da como resultado un estadístico de prueba de $t = -6.611$ con un valor P de 0.000000000813. Puesto que el valor P de la prueba del signo no es tan bajo como

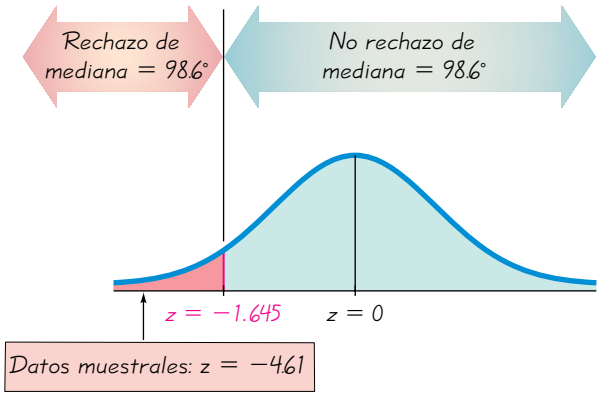


FIGURA 12-3 **Prueba de la aseveración de que la mediana es menor que 98.6°F**

el valor *P* de la prueba paramétrica, vemos que la prueba del signo no es tan sensible como la prueba paramétrica. Ambas pruebas nos llevan al rechazo de la hipótesis nula, pero la prueba del signo no considera que los datos muestrales sean tan extremos, parcialmente porque la prueba del signo utiliza sólo información acerca de la *dirección* de los datos, ignorando las *magnitudes* de los valores de los datos. La siguiente sección introduce la prueba de rangos con signo de Wilcoxon, que supera con creces tal desventaja.

Fundamentos para el estadístico de prueba que se utiliza cuando $n > 25$: Cuando se calculan valores críticos para la prueba del signo, utilizamos la tabla A-7 sólo para *n* hasta 25. Cuando $n > 25$, el estadístico de prueba *z* se basa en una aproximación normal a la distribución de probabilidad binomial con $p = q = 1/2$. Recuerde que en la sección 5-6 vimos que la aproximación normal a la distribución binomial es aceptable cuando $np \geq 5$ y $nq \geq 5$. Recuerde también que en la sección 4-4 vimos que $\mu = np$ y $\sigma = \sqrt{npq}$ para distribuciones de probabilidad binomial. Puesto que la prueba del signo supone que $p = q = 1/2$, satisfacemos los prerrequisitos de que $np \geq 5$ y $nq \geq 5$ siempre y cuando $n \geq 10$. Además, con el supuesto de que $p = q = 1/2$, obtenemos $\mu = np = n/2$ y $\sqrt{npq} = \sqrt{n/4} = \sqrt{n}/2$; por lo tanto,

$$z = \frac{x - \mu}{\sigma}$$

se convierte en

$$z = \frac{x - \left(\frac{n}{2}\right)}{\frac{\sqrt{n}}{2}}$$

Finalmente, reemplazamos *x* con $x + 0.5$ como una corrección por continuidad. Esto es, los valores de *x* son discretos; pero, puesto que estamos utilizando la distribución de probabilidad continua, un valor discreto como 10 se representa en realidad por el intervalo de 9.5 a 10.5. Ya que *x* representa el signo menos frecuente, actuamos conservadoramente interesándonos sólo por $x + 0.5$. Así obtenemos el estadístico de prueba *z*, como aparece en la ecuación y en la figura 12-1.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Sign Test**. Elija la opción **Given Number of Signs** si conoce el número de signos positivos y negativos, o **Given Pairs of Values** si prefiere ingresar pares de datos asociados. Después de realizar las entradas que se requieren en el cuadro de diálogo, los resultados en la pantalla incluirán el estadístico de prueba, el valor crítico y la conclusión.

Minitab Primero debe crear una columna de valores que representen las diferencias entre los pares de datos asociados o el número de signos positivos y negativos. (Para detalles véase el manual *Minitab Student Laboratory Manual and Workbook*). Seleccione **Stat**, y luego **Nonparametrics** y **1-Sample Sign**. Haga clic en el botón para **Test Median**. Ingrese el valor de la mediana y elija el tipo de prueba, luego haga clic en **OK**. Minitab producirá el valor *P*; por lo tanto, rechace la hipótesis nula si el valor *P* es menor que o igual al nivel de significancia. De otra forma, no rechace la hipótesis nula.

Excel Excel no tiene una función predeterminada a la prueba del signo, pero usted puede utilizar la función BINOMDIST del programa para calcular el valor *P* para una prueba del signo. Haga clic en *fx* en la barra del menú principal, luego seleccione la categoría de función **Statistical** y entonces **BINOMDIST**. En el cuadro de diálogo, ingrese primero *x*, luego el número de ensayos *n* y una probabilidad de 0.5. Teclee **TRUE** en el cuadro para *cumulative*. El valor resultante es la probabilidad de obtener *x* o menos éxitos entre *n* ensayos. *Duplique este valor para pruebas de dos colas*. El resultado final es el valor *P*; por lo tanto, rechace la hipótesis nula, si el valor *P* es menor que o igual al nivel de significancia. De no ser así, no rechace la hipótesis nula.

TI-83 Plus La calculadora TI-83 Plus no tiene una función predeterminada para la prueba del signo, pero usted puede utilizar la función binomcdf para calcular el valor *P* para una prueba del signo. Oprima **2nd, VARS** (para obtener el menú **DISTR**); luego baje el cursor para seleccionar **binomcdf**. Complete la entrada de **binomcdf(n, p, x)** con *n* para el número total de signos positivos y negativos, 0.5 para *p* y el número del signo menos frecuente para *x*. Ahora oprima **ENTER**; el resultado será la probabilidad de obtener *x* o menos éxitos entre *n* ensayos. *Duplique este valor para pruebas de dos colas*. El resultado final es el valor *P*; por lo tanto, rechace la hipótesis nula si el valor *P* es menor que o igual al nivel de significancia. De otra forma, no rechace la hipótesis nula.

12-2 Destrezas y conceptos básicos

En los ejercicios 1 a 4, suponga que los datos apareados dan como resultado el número dado de signos cuando el valor de la segunda variable se resta del correspondiente valor de la primera variable. Utilice la prueba del signo con un nivel de significancia de 0.05 y pruebe la hipótesis nula de ninguna diferencia.

1. Signos positivos: 10; signos negativos: 5; empates: 3
2. Signos positivos: 6; signos negativos: 16; empates: 2
3. Signos positivos: 50; signos negativos: 40; empates: 5
4. Signos positivos: 10; signos negativos: 30; empates: 3

En los ejercicios 5 a 16 utilice la prueba del signo.

5. Prueba para la diferencia entre estaturas de hombres reportadas y medidas Como parte de la National Health and Nutrition Examination Survey, realizada por el Department of Health and Human Services de Estados Unidos, se obtuvieron las estaturas y medidas de hombres de 12 a 16 años de edad. Abajo se listan los resultados muestrales. ¿Existe evidencia suficiente para sustentar la aseveración de que hay una diferencia entre las estaturas reportadas y las estaturas medidas de hombres de 12 a 16 años de edad? Utilice un nivel de significancia de 0.05.

Estatura reportada	68	71	63	70	71	60	65	64	54	63	66	72
Estatura medida	67.9	69.9	64.9	68.3	70.3	60.6	64.5	67.0	55.6	74.2	65.0	70.8

6. Prueba para la diferencia entre estaturas reportadas y medidas La tabla de abajo lista datos apareados de estaturas que se midieron de 12 hombres estudiantes de estadística. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre las estaturas reportadas y las estaturas medidas.

Estatura reportada	68	74	82.25	66.5	69	68	71	70	70	67	68	70
Estatura medida	66.8	73.9	74.3	66.1	67.2	67.9	69.4	69.9	68.6	67.9	67.6	68.8

7. Prueba para temperatura corporal media de 98.6°F En una clase de estadística, se le pide a una estudiante del curso propedéutico de medicina que realice un proyecto de clase. Inspirada por las temperaturas corporales del conjunto de datos 4 en el Apéndice B, ella planea reunir sus propios datos muestrales para probar la aseveración de que la temperatura corporal media es menor que 98.6°F. Por restricciones de tiempo, encuentra que sólo alcanzará a reunir datos de 12 personas. Después de planear con cuidado un procedimiento para obtener una muestra aleatoria de 12 adultos saludables, mide sus temperaturas corporales y obtiene los resultados que se listan abajo. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que dichas temperaturas corporales provienen de una población con una mediana que es menor que 98.6°F.

97.6 97.5 98.6 98.2 98.0 99.0 98.5 98.1 98.4 97.9 97.9 97.7

8. Prueba para mediana de peso bajo La Prince County Bottling Company surte botellas de limonada que se etiquetan de 12 onzas. Cuando el Prince County Department of Weights and Measures prueba una muestra aleatoria de botellas, obtiene las cantidades que se listan abajo. Si utilizamos un nivel de significancia de 0.05, ¿existe suficiente evidencia para documentar la acusación de que la compañía embotelladora está engañando a los consumidores dando cantidades con una mediana menor que 12 onzas?

11.4 11.8 11.7 11.0 11.9 11.9 11.5 12.0 12.1 11.9 10.9 11.3 11.5 11.5 11.6

9. Datos nominales: encuesta de votantes En una encuesta que se aplicó a 1002 personas, 701 dijeron que votaron en la elección presidencial reciente (según datos del ICR Research Group). ¿Hay suficiente evidencia para sustentar la aseveración de que la mayoría de las personas votaron en la elección?

10. Datos nominales: tabaquismo y parches de nicotina En un estudio de 71 fumadores que intentaban dejar de fumar con la terapia de parches de nicotina, 41 siguieron fumando un año después del tratamiento (según datos de "High-Dose Nicotine Patch Therapy", de Dale *et al*., *Journal of the American Medical Association*, vol. 274, núm. 17). Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que, de los fumadores que tratan de dejar el hábito con la terapia de parches de nicotina, la mayoría siguieron fumando un año después del tratamiento.

11. Prueba de la mediana del volumen de latas de Coca Cola Remítase al conjunto de datos 17 en el Apéndice B y utilice los volúmenes de Coca Cola clásica. Pruebe la aseveración de que las latas de Coca Cola clásica tienen volúmenes con una mediana mayor que 12 onzas. ¿Parece que las latas de Coca Cola se llenan correctamente?

12. Prueba de la mediana de la cantidad de azúcar Dominó en sobres Remítase al conjunto de datos 28 del Apéndice B y utilice los datos muestrales para probar la aseveración de que la mediana de la cantidad de azúcar en los sobres es igual a 3.5 onzas. ¿Parece que los sobres de azúcar se llenan correctamente?

13. Prueba de la mediana del intervalo del tiempo del géiser Old Faithful Remítase al conjunto de datos 13 en el Apéndice B. Pruebe la aseveración de que los intervalos entre las erupciones del géiser Old Faithful tienen una mediana mayor a 77 minutos, que es la mediana que se registró desde hace 30 años.

14. Prueba de la diferencia entre temperaturas pronosticadas y reales Remítase al conjunto de datos 10 en el Apéndice B y utilice las temperaturas máximas reales y el pronóstico de temperaturas máximas de tres días. ¿Parece haber una diferencia?

12-2 Más allá de lo básico

15. Procedimientos para manejar empates En el procedimiento de la prueba del signo descrito en esta sección, excluimos los empates (representados por 0 en lugar de un signo de + o de −). Un segundo método consiste en tratar a la mitad de los ceros como signos positivos y a la mitad como negativos. (Si el número de ceros es impar, excluya uno para que se dividan por igual). Con un tercer método, en pruebas de dos colas haga la mitad de los ceros positivos y la mitad negativos; en pruebas de una cola, haga todos los ceros positivos o negativos, pues cualquier signo sustenta la hipótesis nula. Suponga que en el uso de la prueba del signo para una aseveración de que el valor de la mediana es menor que 100, tenemos 60 valores por debajo de 100, 40 valores por encima de 100, y 21 valores iguales a 100. Identifique el estadístico de prueba y la conclusión con las tres formas diferentes de manejar empates (con diferencias de 0). Suponga un nivel de significancia de 0.05 en los tres casos.

16. Cálculo de valores críticos La tabla A-7 lista valores críticos para alternativas limitadas de α. Utilice la tabla A-1 para añadir una nueva columna en la tabla A-7 (bajando hasta $n = 15$) que representa un nivel de significancia de 0.03 en una cola o de 0.06 en dos colas. Para cualquier n particular, utilice $p = 0.5$, ya que la prueba del signo requiere el supuesto de que P (signo positivo) $= P$ (signo negativo) $= 0.5$. La probabilidad de x o menos signos del mismo tipo es la suma de las probabilidades de los valores hasta x, inclusive.

17. Error de aproximación normal Entre sus últimos 54 empleados nuevos, la compañía Compulife.com contrató a 18 mujeres. De los solicitantes, alrededor de la mitad son mujeres y la otra mitad hombres, y todos son calificados. Utilizando un nivel de significancia de 0.01 con la prueba del signo, ¿hay suficiente evidencia para acusar de favoritismo? ¿La conclusión cambia si se utiliza la distribución binomial en lugar de la distribución normal aproximada?

12-3 Prueba de rangos con signo de Wilcoxon para datos apareados

En la sección 12-2 utilizamos la prueba del signo para analizar tres tipos diferentes de datos, incluyendo datos muestrales consistentes en datos apareados. La prueba del signo incluyó sólo los signos de las diferencias y no sus magnitudes reales (qué tan grandes son los números). Esta sección introduce la *prueba de rangos con signo de Wilcoxon*, que también se usa con datos muestrales apareados. Mediantel uso de rangos, esta prueba toma en cuenta las magnitudes de las diferencias. (Véase la sección 12-1 para una descripción de los rangos). Puesto que la prueba de rangos con signo de Wilcoxon incorpora y utiliza más información que la prueba del signo, tiende a proporcionar conclusiones que reflejan mejor la verdadera naturaleza de los datos.

Definición

Prueba de rangos con signo de Wilcoxon: Una prueba no paramétrica que utiliza rangos ordenados de datos muestrales consistentes en datos apareados. Se usa para probar las diferencias en las distribuciones poblacionales, por lo que las hipótesis nula y alternativa son las siguientes:

H_0: Las dos muestras provienen de poblaciones con la misma distribución.

H_1: Las dos muestras provienen de poblaciones con distribuciones diferentes.

(La prueba de rangos con signo de Wilcoxon también resulta útil para probar la aseveración de que una muestra proviene de una población con una mediana específica. Véase el ejercicio 9 para dicha aplicación).

Procedimiento de la prueba de rangos con signo de Wilcoxon

Paso 1: Para cada par de datos, calcule la diferencia d restando el segundo valor del primero. Guarde los signos, pero descarte cualquier par para el que $d = 0$.

Paso 2: *Ignore los signos de las diferencias*, luego acomode las diferencias de la más baja a la más alta y reemplace las diferencias por el valor del rango correspondiente (como se describe en la sección 12-1). Cuando las diferencias tengan el mismo valor numérico, asígneles la media de los rangos implicados en el empate.

Paso 3: Adjunte a cada rango el signo de la diferencia de la que provino. Esto es, inserte aquellos signos que se ignoraron en el paso 2.

Paso 4: Calcule la suma de los valores absolutos de los rangos negativos. También, la suma de los rangos positivos.

Paso 5: Permita que T sea la *más pequeña* de las dos sumas que se calcularon en el paso 4. Es posible utilizar cualquier suma, aunque para simplificar el procedimiento seleccionamos arbitrariamente la más pequeña de las dos sumas. (Véase la notación para T en el cuadro adjunto).

Paso 6: Permita que n sea el número de pares de datos para los que la diferencia d no es 0.

Paso 7: Determine el estadístico de prueba y los valores críticos con base en el tamaño muestral, como se indica en el cuadro adjunto.

Paso 8: Cuando plantee la conclusión, rechace la hipótesis nula si los datos muestrales le llevan a un estadístico de prueba que está en la región crítica, esto es, cuando el estadístico de prueba es menor que o igual al(los) valor(es) crítico(s). De otra forma, no rechace la hipótesis nula.

Prueba de rangos con signo de Wilcoxon

Supuestos

1. Los datos consisten en datos apareados que se seleccionaron aleatoriamente.
2. La población de las diferencias (calculadas de los pares de datos) tiene una distribución que es aproximadamente *simétrica*, lo que quiere decir que la mitad izquierda de su histograma es aproximadamente una imagen de espejo de la mitad derecha. (*No* existe el requisito de que los datos tengan una distribución normal).

continúa

Notación

Véanse los pasos del procedimiento adjunto para calcular la suma de rangos T.

T = la más pequeña de las siguientes dos sumas:

1. La suma de los valores absolutos de los rangos negativos de las diferencias d que no sean cero.
2. La suma de los rangos positivos de las diferencias d que no sean cero.

Estadístico de prueba

Si $n \leq 30$, el estadístico de prueba es T.

Si $n > 30$, el estadístico de prueba es $z = \dfrac{T - \dfrac{n(n+1)}{4}}{\sqrt{\dfrac{n(n+1)(2n+1)}{24}}}$

Valores críticos

1. Si $n \leq 30$, el valor crítico T se encuentra en la tabla A-8.
2. Si $n > 30$, los valores críticos z se encuentran en la tabla A-2.

EJEMPLO Medición de la inteligencia en niños Los datos en la tabla 12-3 son datos apareados de tiempos (en segundos) que se obtuvieron a partir de una muestra aleatoria de niños a quienes se les pidió que construyeran, usando cubos, una torre tan alta como fuera posible (según datos de "Tower Building", de Johnson y Courtney, *Child Development*, vol. 3). Este procedimiento se utiliza para medir la inteligencia de los niños. Utilice la prueba de rangos con signo de Wilcoxon con un nivel de significancia de 0.05 y pruebe la aseveración de que no hay diferencia entre los tiempos de la primera y de la segunda pruebas.

SOLUCIÓN Las hipótesis nula y alternativa son como sigue:

H_0: No hay diferencia entre los tiempos de la primera y de la segunda pruebas.

H_1: Existe una diferencia entre los tiempos de la primera y de la segunda pruebas.

Tabla 12-3 Tiempos para la construcción de torres con cubos

Niño	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
Primera prueba	30	19	19	23	29	178	42	20	12	39	14	81	17	31	52
Segunda prueba	30	6	14	8	14	52	14	22	17	8	11	30	14	17	15
Diferencias d	0	13	5	15	15	126	28	−2	−5	31	3	51	3	14	37
Rangos de |diferencias|		6	4.5	8.5	8.5	14	10	1	4.5	11	2.5	13	2.5	7	12
Rangos con signo		6	4.5	8.5	8.5	14	10	−1	−4.5	11	2.5	13	2.5	7	12

El nivel de significancia es $\alpha = 0.05$. Estamos utilizando el procedimiento de la prueba de rangos con signo de Wilcoxon, por lo que el estadístico de prueba se calcula aplicando el procedimiento de ocho pasos que ya se presentó en esta sección.

Paso 1: En la tabla 12-3, el renglón de diferencias se obtiene calculando esta diferencia para cada par de datos:

d = tiempo de la primera prueba − tiempo de la segunda prueba

Paso 2: Ignorando sus signos, ordenamos los rangos de las diferencias absolutas de la más baja a la más alta. Note que los empates en los rangos se manejan asignando la media de los rangos implicados a cada uno de los valores empatados y las diferencias de 0 se descartan.

Paso 3: El renglón inferior de la tabla 12-3 se crea insertando a cada rango el signo de la diferencia correspondiente. Si en realidad no hay diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba (como en la hipótesis nula), esperamos que el número de rangos positivos sea aproximadamente igual al número de rangos negativos.

Paso 4: Ahora calculamos la suma de los valores absolutos de los rangos negativos y también calculamos la suma de los rangos positivos.

Suma de los valores absolutos de los rangos negativos: 5.5

Suma de los rangos positivos: 99.5

Paso 5: Permitiendo que T sea la menor de las dos sumas calculadas en el paso 4, encontramos que $T = 5.5$.

Paso 6: Permitiendo que n sea el número de pares de datos para los que la diferencia d no es 0, tenemos $n = 14$.

Paso 7: Puesto que $n = 14$, tenemos que $n \leq 30$, por lo cual utilizamos un estadístico de prueba de $T = 5.5$ (y no calculamos un estadístico de prueba z). Además, puesto que n $\leq$ 30, utilizamos la tabla A-8 para encontrar el valor crítico de 21.

Paso 8: El estadístico de prueba $T = 5.5$ es menor que o igual al valor crítico de 21, por lo que rechazamos la hipótesis nula. Parece que hay una diferencia entre los tiempos de la primera prueba y los tiempos de la segunda prueba.

Si utilizamos la prueba del signo con el ejemplo anterior, llegaremos a la misma conclusión. Aunque la prueba de signo y la prueba de rangos con signo de Wilcoxon coinciden en este caso en particular, hay otros casos en los que no concuerdan.

Fundamentos: En este ejemplo los rangos sin signo de 1 hasta 14 tienen un total de 105, por lo que, si no hay diferencias significativas, cada uno de los dos totales de rangos con signo debe ser de alrededor de 105 ÷ 2, o 52.5. Esto es, los rangos negativos y los rangos positivos deberían repartirse como 52.5-52.5 o algo cercano, tal como 51-54. La tabla de valores críticos muestra que a un nivel de significancia de 0.05, con 14 pares de datos, un reparto de 21-84 representa una desviación significativa de la hipótesis nula y cualquier reparto que se separe más (como 20-85 o 5.5-99.5) también representará una desviación significativa de la hipótesis nula. Por el contrario, repartos como 22-83 no representan desviaciones significativas de un reparto de 52.5-52.5, por lo que no justificarían el rechazo de

la hipótesis nula. La prueba de rangos con signo de Wilcoxon se basa en el total del rango más bajo, por lo que en lugar de analizar los dos números que constituyen el reparto, consideramos sólo el número más bajo.

La suma $1 + 2 + 3 + \cdots + n$ de todos los rangos es igual a $n(n + 1)/2$, y si ésta es una suma de rangos a dividirse por igual entre dos categorías (positivo y negativo), cada uno de los dos totales debería estar cerca de $n(n + 1)/4$, que es la mitad de $n(n + 1)/2$. El reconocimiento de este principio nos ayuda a entender el estadístico de prueba que se usa cuando $n > 30$. El denominador en esa expresión representa una desviación estándar de T y se basa en el principio de que

$$1^2 + 2^2 + 3^3 + \cdots + n^2 = \frac{n(n + 1)(2n + 1)}{6}$$

La prueba de rangos con signo de Wilcoxon se utiliza sólo con datos apareados. La siguiente sección describirá una prueba de suma de rangos que puede aplicarse a dos conjuntos de datos independientes que no se asocian en pares.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Wilcoxon Tests**, ahora **Signed-Ranks Test.** Proceda a ingresar los datos muestrales apareados. Haga clic en **Evaluate**. La pantalla del STATDISK incluirá el estadístico de prueba, el valor crítico y la conclusión.

Minitab Ingrese los datos apareados en las columnas C1 y C2. Haga clic en **Editor** y luego en **Enable Command Editor**. Ingrese el comando **LET C3 = C1 − C2**. Oprima la tecla **Enter**. Elija las opciones **Stat**, **Nonparametrics** y **1-Sample Wilcoxon**. Ingrese C3 para la variable y haga clic en el botón para **Test Median**. La pantalla del Minitab incluirá el valor **P**. Rechace la hipótesis nula de distribuciones iguales si el valor P es menor que o igual al nivel de significancia. No rechace la hipótesis nula si el valor P es mayor que el nivel de significancia.

Excel Excel no está programado para la prueba de rangos con signo de Wilcoxon.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de rangos con signo de Wilcoxon.

12-3 Destrezas y conceptos básicos

Uso de la prueba de rangos con signo de Wilcoxon. *En los ejercicios 1 y 2, remítase a los datos muestrales apareados que se presentan; utilice la prueba de rangos con signo de Wilcoxon para probar la aseveración de que ambas muestras provienen de poblaciones que tienen la misma distribución. Utilice un nivel de significancia de 0.05.*

1.

x	12	14	17	19	20	27	29	30
y	12	15	15	14	12	18	19	20

2.

x	8	6	9	12	22	31	34	35	37
y	8	8	12	17	29	39	24	47	49

Uso de la prueba de rangos con signo de Wilcoxon. *En los ejercicios 3 y 4, remítase a los datos muestrales para los ejercicios de la sección 12-2. En lugar de la prueba del signo, utilice la prueba de rangos con signo de Wilcoxon para probar la aseveración de que ambas muestras provienen de poblaciones con la misma distribución.*

3. Ejercicio 5

4. Ejercicio 6

En los ejercicios 5 a 8, utilice la prueba de rangos con signo de Wilcoxon.

5. Prueba de la diferencia entre mediciones en posición de sentado y acostado En un estudio de técnicas que se utilizan para medir los volúmenes de los pulmones, se reunieron datos fisiológicos de 10 sujetos. Los valores dados en la tabla vienen en litros y representan las capacidades residuales funcionales medidas de los 10 sujetos en posición de sentado y en posición supina (acostado). Con un nivel de significancia de 0.5, pruebe la aseveración de que no hay diferencias significativas entre las mediciones que se tomaron en las dos posiciones.

Sentado	2.96	4.65	3.27	2.50	2.59	5.97	1.74	3.51	4.37	4.02
Supino	1.97	3.05	2.29	1.68	1.58	4.43	1.53	2.81	2.70	2.70

Datos tomados de "Validation of Esophageal Balloon Technique at Different Lung Volumes and Postures", de Baydur, Cha y Sassoon, *Journal of Applied Physiology*, vol. 62, núm. 1.

6. Prueba de eficacia de fármacos El captopril es un fármaco que se diseñó para disminuir la presión sanguínea sistólica. Cuando se probó este fármaco en sujetos, sus lecturas de presión sanguínea sistólica (en milímetros de mercurio) se midieron antes y después de que se tomara el fármaco, con los resultados que se presentan en la tabla adjunta. ¿Hay suficiente evidencia para sustentar la aseveración de que el fármaco no surte efecto? ¿Parece que el captopril disminuye la presión sanguínea sistólica?

Sujeto	A	B	C	D	E	F	G	H	I	J	K	L
Antes	200	174	198	170	179	182	193	209	185	155	169	210
Después	191	170	177	167	159	151	176	183	159	145	146	177

Datos tomados de "Essential Hypertension: Effect of an Oral Inhibitor of Angiotensin-Converting Enzyme", de MacGregor *et al.*, *British Medical Journal*, vol. 2.

7. Prueba de la diferencia entre temperaturas pronosticadas y reales Remítase al conjunto de datos 10 del Apéndice B. Utilice las temperaturas máximas reales y el pronóstico de temperaturas máximas de tres días. ¿Parece haber una diferencia?

8. Prueba para la diferencia entre los tiempos en que se muestra consumo de alcohol y de tabaco Remítase al conjunto de datos 7 del Apéndice B. Utilice sólo aquellas películas que muestran algún consumo de tabaco o alcohol (es decir, ignore aquellas películas con tiempos de cero para consumo de tabaco y para consumo del alcohol). ¿Parece haber una diferencia?

12-3 Más allá de lo básico

9. Uso de la prueba de rangos con signo de Wilcoxon para aseveraciones acerca de una mediana La prueba de rangos con signo de Wilcoxon se utiliza para probar la aseveración de que una muestra proviene de una población con una mediana específica. El procedimiento que se emplea es el mismo que el descrito en esta sección, excepto que las diferencias (paso 1) se obtienen restando el valor de la mediana hipotética de cada

valor. Utilice los datos muestrales consistentes en las 106 temperaturas corporales listadas para las 12 AM del día 2 en el conjunto de datos 4 del Apéndice B. Con un nivel de significancia de 0.05, pruebe la aseveración de que los adultos saludables tienen una mediana de temperatura corporal igual a 98.6°F.

12-4 Prueba de la suma de rangos de Wilcoxon para dos muestras independientes

Aquí se introduce la *prueba de la suma de rangos de Wilcoxon*, que es la prueba no paramétrica de que dos conjuntos independientes de datos muestrales provienen de poblaciones con la misma distribución. Dos muestras son independientes, si los valores muestrales seleccionados de una población no se relacionan, asocian o se aparean de ninguna forma con los valores muestrales de la otra población. (Para evitar confusiones acerca de la suma de rangos de Wilcoxon para muestras independientes y la prueba de rangos con signo de Wilcoxon para datos apareados, considere el uso de las siglas ISR correspondientes al impuesto sobre la renta como técnica mnémica para recordarnos "**i**ndependiente: **s**uma de **r**angos").

Definición

Prueba de la suma de rangos de Wilcoxon: Una prueba no paramétrica que utiliza rangos de datos muestrales a partir de dos poblaciones independientes. Se emplea para probar la hipótesis nula de que dos muestras independientes provienen de poblaciones con la misma distribución (es decir, las dos poblaciones son idénticas). La hipótesis alternativa es la aseveración de que las dos distribuciones poblacionales son diferentes en alguna forma.

H_0: Las dos muestras provienen de poblaciones con la misma distribución (esto es, las dos poblaciones son idénticas).

H_1: Las dos muestras provienen de poblaciones con distribuciones diferentes (esto es, las dos poblaciones son diferentes en alguna forma).

Concepto básico: La prueba de la suma de rangos de Wilcoxon es equivalente a la **prueba *U* de Mann-Whitney** (véase el ejercicio 11), que se incluye en algunos otros libros de texto y programas de cómputo (como el Minitab). Ésta es la idea clave que sustenta la prueba de la suma de rangos de Wilcoxon: si dos muestras se obtienen de poblaciones idénticas y los valores individuales se acomodan en rangos como un conjunto de valores que se combina, entonces por lo regular los rangos alto y bajo deberían caer entre las dos muestras. Si los rangos bajos se encuentran predominantemente en una muestra y los rangos altos se encuentran predominantemente en la otra muestra, sospechamos que las dos poblaciones no son idénticas. Esta idea clave se refleja en el siguiente procedimiento para calcular el valor del estadístico de prueba.

Procedimiento para calcular el valor del estadístico de prueba

1. Combine temporalmente las dos muestras en una muestra grande, entonces reemplace cada valor muestral por su rango. (El valor más bajo toma un rango

de 1, el siguiente valor más bajo toma un rango de 2, etcétera. Si los valores están empatados, asígneles la media de los rangos que implica el empate. Véase la sección 12-1 para obtener una descripción de los rangos y el procedimiento para manejar empates).

2. Calcule la suma de los rangos para cualquiera de las dos muestras.
3. Calcule el valor del estadístico de prueba z como se indica en el siguiente recuadro, donde cualquier muestra puede utilizarse como la "muestra 1". (Si se está probando la hipótesis nula de poblaciones idénticas y si ambos tamaños muestrales son mayores que 10, la distribución muestral de R es aproximadamente normal, con media μ_R y desviación estándar σ_R, en tanto que el estadístico de prueba es como se indica en el recuadro siguiente).

Prueba de la suma de rangos de Wilcoxon

Supuestos

1. Hay dos muestras independientes de datos seleccionados aleatoriamente.
2. Cada una de las dos muestras tiene más de 10 valores. (Para muestras con 10 valores o menos, en libros de referencia están disponibles tablas especiales, como las *CRC Standard Probability and Statistics Tables and Formulae*, publicadas por CRC Press).
3. No existe el requisito de que las dos poblaciones tengan una distribución normal o cualquiera otra distribución particular.

Notación

n_1 = tamaño de la muestra 1

n_2 = tamaño de la muestra 2

R_1 = suma de rangos de la muestra 1

R_2 = suma de rangos de la muestra 2

R = lo mismo que R_1 (suma de rangos de la muestra 1)

μ_R = media de los valores muestrales R que se espera cuando las dos poblaciones son idénticas

σ_R = desviación estándar de los valores muestrales R que se espera, cuando las dos poblaciones son idénticas

Estadístico de prueba

$$z = \frac{R - \mu_R}{\sigma_R}$$

donde

$$\mu_R = \frac{n_1(n_1 + n_2 + 1)}{2}$$

$$\sigma_R = \sqrt{\frac{n_1 n_2(n_1 + n_2 + 1)}{12}}$$

n_1 = tamaño de la muestra a partir de la cual se calcula la suma de rangos R

n_2 = tamaño de la otra muestra

R = suma de rangos de la muestra con tamaño n_1

Valores críticos: Los valores críticos están en la tabla-A.2 (puesto que el estadístico de prueba se basa en la distribución normal).

Note que, a diferencia de las pruebas de hipótesis correspondientes en la sección 8-3, la prueba de la suma de rangos de Wilcoxon no requiere poblaciones que se distribuyen normalmente. Además, la prueba de la suma de rangos de Wilcoxon se utiliza con datos en el nivel de medición ordinal, como los datos consistentes en rangos. En contraste, los métodos paramétricos de la sección 8-3 no se utilizan con datos en el nivel de medición ordinal. En la tabla 12-1 notamos que la prueba de la suma de rangos de Wilcoxon tuvo una tasa de eficiencia de 0.95 cuando se compara con la prueba paramétrica t o con la prueba z. Puesto que dicha prueba tiene una alta tasa de eficiencia y supone cálculos más fáciles, suele preferirse sobre las pruebas paramétricas que se presentan en la sección 8-3, aun cuando se satisfaga el requisito de normalidad.

La expresión de μ_R se basa en el resultado de inducción matemática siguiente: la suma de los primeros n enteros positivos está dada por $1 + 2 + 3 + \cdots + n = n(n + 1)/2$. La expresión de σ_R se basa en un resultado que establece que los enteros 1, 2, 3, . . . , n tienen una desviación estándar $\sqrt{(n^2 - 1)/12}$.

EJEMPLO Rowling y Tolstoi El conjunto de datos 14 del Apéndice B incluye las calificaciones de facilidad de lectura de Flesch para páginas que se seleccionaron aleatoriamente de cada uno de dos libros: *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. La tabla 12-4 incluye valores del conjunto de datos 14 junto con un valor adicional que se diseñó para ilustrar mejor el procedimiento de la suma de rangos de Wilcoxon. (El valor de 71.4 se añadió al final de la lista de Rowling para que hubiera un empate y los conjuntos de datos tuvieran números de valores diferentes). Utilice los dos conjuntos de datos muestrales independientes de la tabla 12-4, con un nivel de significancia de 0.05, y pruebe la aseveración de que las puntuaciones de facilidad de lectura para páginas de los dos libros tienen la misma distribución.

Tabla 12-4
Calificaciones de lectura

Rowling	Tolstoi
85.3 (24)	69.4 (7)
84.3 (22)	64.2 (4)
79.5 (18)	71.4 (9.5)
82.5 (20)	71.6 (11)
80.2 (19)	68.5 (6)
84.6 (23)	51.9 (1)
79.2 (17)	72.2 (12)
70.9 (8)	74.4 (15)
78.6 (16)	52.8 (2)
86.2 (25)	58.4 (3)
74.0 (14)	65.4 (5)
83.7 (21)	73.6 (13)
71.4 (9.5)	
$n_1 = 13$	$n_2 = 12$
$R_1 = 236.5$	$R_2 = 88.5$

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Los libros de Rowling y Tolstoi tienen calificaciones de facilidad de lectura de Flesch, con la misma distribución.

H_1: Las dos poblaciones tienen distribuciones de calificaciones de facilidad de lectura de Flesch, que son diferentes en alguna forma.

Acomode en rangos las 25 calificaciones de lectura que se combinaron, comenzando con un rango de 1 (que se asignó al valor más bajo de 51.9). Los empates en los rangos se manejan como se describe en la sección 12-1: calcule la media de los rangos implicados y asigne este rango medio a cada uno de los valores empatados. Los valores 9o. y 10o. son ambos de 71.4, por lo que se asigna el rango de 9.5 a cada uno de dichos valores. En la tabla 12-4, los rangos correspondientes a los valores muestrales individuales se presentan entre paréntesis. R denota la suma de los rangos para la muestra que escogimos como muestra 1. Si elegimos las calificaciones de Rowling, tenemos

$$R = 24 + 22 + 18 + \cdots + 9.5 = 236.5$$

Puesto que hay 13 valores de Rowling, tenemos $n_1 = 13$. Además, $n_2 = 12$, ya que existen 12 valores para Tolstoi. Ahora determinemos los valores de μ_R, σ_R, y el estadístico de prueba z.

$$\mu_R = \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{13(13 + 12 + 1)}{2} = 169$$

$$\sigma_R = \sqrt{\frac{n_1 n_2(n_1 + n_2 + 1)}{12}} = \sqrt{\frac{(13)(12)(13 + 12 + 1)}{12}} = 18.385$$

$$z = \frac{R - \mu_R}{\sigma_R} = \frac{236.5 - 169}{18.385} = 3.67$$

La prueba es de dos colas, puesto que un valor positivo grande de z indicaría que los rangos más altos se encuentran desproporcionadamente en la primera muestra, en tanto que un valor negativo grande de z indicaría que la primera muestra tuvo una porción desproporcionada de los rangos más bajos. En cualquier caso, tendríamos una fuerte evidencia en contra de la aseveración de que las dos muestras provienen de poblaciones con la misma distribución.

La significancia del estadístico de prueba z puede tratarse de la misma manera que en los capítulos anteriores. Ahora estamos probando (con $\alpha = 0.05$) la hipótesis de que las dos poblaciones tienen la misma distribución; entonces, tenemos una prueba de dos colas con valores críticos z de 1.96 y -1.96. El estadístico de prueba de $z = 3.67$ cae dentro de la región crítica, por lo que rechazamos la hipótesis nula de que los libros de Rowling y de Tolstoi tienen las mismas calificaciones de lectura. Parece que las páginas de Rowling y de Tolstoi provienen de poblaciones con distribuciones diferentes. Puesto que los rangos más bajos parecen ocurrir, en su mayoría, en los valores de Tolstoi, parece que Tolstoi obtuvo calificaciones significativamente más bajas de facilidad de lectura. Esto sugiere que *La guerra y la paz*, de Tolstoi, suele ser más difícil de leer que *Harry Potter y la piedra filosofal*, de Rowling.

Verifiquemos que si intercambiamos los dos conjuntos de valores muestrales y consideramos que la muestra de Tolstoi es la primera, $R = 88.5$, $\mu_R = 156$, $\sigma_R = 18.385$ y $z = -3.67$; por lo tanto, la conclusión es exactamente la misma.



EJEMPLO Lluvia en miércoles y sábado El problema del capítulo se refirió a las cantidades de lluvia en Boston, listadas en el conjunto de datos 11 en el Apéndice B. El problema del capítulo incluye gráficas de cuadro de las cantidades de lluvia para los siete días de la semana, iniciando con el lunes en la parte superior. Las comparaciones de tales gráficas de cuadro indican que el miércoles y el sábado parecen ser los dos días que más difieren. Pero ¿son significativas dichas diferencias? Utilice la prueba de la suma de rangos de Wilcoxon para probar la aseveración de que las cantidades de precipitación pluvial de los miércoles y los sábados provienen de la misma distribución.

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Las cantidades de lluvia del miércoles y del sábado provienen de poblaciones con la misma distribución.

H_1: Las dos distribuciones son diferentes en alguna forma.

En lugar de calcular manualmente las sumas de los rangos, nos remitimos a la pantalla de Minitab que se muestra aquí. En esta pantalla de Minitab,

continúa



Brecha de género en las pruebas de fármacos

Un estudio de la relación entre los ataques cardiacos y las dosis de aspirina incluyó a 22,000 médicos hombres. Este estudio, como muchos otros, excluyó a las mujeres. La General Accounting Office criticó hace poco a los National Institutes of Health por no incluir a ambos sexos en muchos estudios, ya que los resultados de pruebas médicas en hombres no necesariamente se aplican a las mujeres. Por ejemplo, los corazones de las mujeres son diferentes de los de los hombres en muchos aspectos importantes. Cuando se sacan conclusiones con base en resultados muestrales, debemos ser cuidadosos al generalizar las inferencias a una población más grande que aquella de la cual se obtuvo la muestra.

"ETA1" y "ETA2" denotan la mediana de la primera muestra y la mediana de la segunda muestra, respectivamente. La pantalla sugiere que estamos probando la hipótesis nula de medianas iguales, pero la prueba de la suma de rangos de Wilcoxon se basa en las distribuciones completas, no sólo en las medianas. He aquí los componentes clave de la pantalla del Minitab: la suma de rangos para el miércoles es M = 2639.0, el valor *P* es 0.2773 (o 0.1992 después de un ajuste por los empates) y la conclusión es que no podemos rechazar (la hipótesis nula) con un nivel de significancia de 0.05. Conclusión final: las diferencias entre el miércoles y el sábado no son significativas. Esto parece contradecir los reportes de los medios de comunicación de que llueve más durante los fines de semana, pero consideraremos de nuevo este tema en la siguiente sección.

Minitab

```
WED        N =  53     Median =      0.0000
SAT        N =  52     Median =      0.0000
Point estimate for ETA1-ETA2 is      0.0000
95.1 Percent CI for ETA1-ETA2 is (0.0000,0.0000)
W = 2639.0
Test of ETA1 = ETA2  vs  ETA1 not = ETA2 is significant at 0.2773
The test is significant at 0.1992 (adjusted for ties)

Cannot reject at alpha = 0.05
```



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Wilcoxon Tests**, seguida por la opción **Rank-Sum Test**. Ingrese los datos muestrales en el cuadro de diálogo y luego haga clic en **Evaluate** para obtener una pantalla, que incluye las sumas de rangos, el tamaño muestral, el estadístico de prueba, el valor crítico y la conclusión.

Minitab Primero ingrese los dos conjuntos de datos muestrales en las columnas C1 y C2. Luego seleccione las opciones **Stat**, **Nonparametrics** y **Mann-Whitney**; ahora proceda a ingresar C1 para la primera muestra y C2 para la segunda muestra. El nivel de confianza de 95.0 corresponde a un nivel de significancia de $\alpha = 0.05$, en tanto que el cuadro "alternate: not equal" se refiere a la hipótesis alternativa, donde "not equal" corresponde a una prueba de hipótesis de dos colas. Minitab produce el valor *P* y la conclusión. Véase la pantalla de muestra de Minitab que se incluye en el ejemplo anterior.

Excel Excel no está programado para la prueba de la suma de rangos de Wilcoxon.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de la suma de rangos de Wilcoxon.

12-4 Destrezas y conceptos básicos

Identificación de las sumas de rangos. *En los ejercicios 1 y 2, utilice un nivel de significancia de 0.05 con los métodos de esta sección para identificar las sumas de rangos R_1 y R_2, μ_R, σ_R, el estadístico de prueba z y los valores críticos z; luego establezca la conclusión.*

1. Valores de la muestra 1: 1 3 4 6 8 12 15 16 17 22 26

Valores de la muestra 2: 2 5 7 9 11 13 14 18 19 20 25 26

2.

Valores de la muestra 1:	1	3	4	6	8	12	15	16	17	22	26
Valores de la muestra 2:	22	25	28	33	34	35	37	39	41	43	45

Uso de la prueba de la suma de rangos de Wilcoxon. *En los ejercicios 3 a 10, utilice la prueba de la suma de rangos de Wilcoxon.*

3. ¿Se relacionan los trastornos psiquiátricos severos con factores biológicos? Un estudio utilizó tomografía computadorizada (TC) por rayos X para reunir datos de volúmenes cerebrales de un grupo de pacientes con trastorno obsesivo compulsivo y un grupo control de personas saludables. La lista adjunta presenta los resultados muestrales (en mililitros) para volúmenes del hemisferio derecho (datos que se tomaron de "Neuroanatomical Abnormalities in Obsesive-Compulsive Disorder Detected with Quantitative X-Ray Computed Tomography", de Luxenberg *et al.*, *American Journal of Psychiatry*, vol. 145, núm. 9). Utilice un nivel de significancia de 0.01 y pruebe la aseveración de que los pacientes obsesivo-compulsivos y las personas saludables tienen los mismos volúmenes cerebrales. Con base en este resultado, ¿concluiríamos que el trastorno obsesivo compulsivo tiene una base biológica?

Pacientes obsesivo compulsivos				**Grupo control**			
0.308	0.210	0.304	0.344	0.519	0.476	0.413	0.429
0.407	0.455	0.287	0.288	0.501	0.402	0.349	0.594
0.463	0.334	0.340	0.305	0.334	0.483	0.460	0.445

4. Prueba del efecto de anclaje Se pidió a estudiantes de estadística, seleccionados aleatoriamente, que en cinco segundos estimaran el valor de un producto de números con los resultados que vienen en la tabla adjunta. (Véanse las "Actividades de cooperación en equipo", al final del capítulo 2). ¿Hay suficiente evidencia para sustentar la aseveración de que las dos muestras provienen de poblaciones con distribuciones diferentes?

Estimados de estudiantes a los que se les pidió calcular $1 \times 2 \times 3 \times 4 \times 5 \times 6 \times 7 \times 8$

1560	169	5635	25	842	40,320	5000	500	1110	10,000
200	1252	4000	2040	175	856	42,200	49,654	560	800

Estimados de estudiantes a los que se les pidió calcular $8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1$

100,000	2000	42,000	1500	52,836	2050	428	372	300	225	64,582
23,410	500	1200	400	49,000	4000	1876	3600	354	750	640

5. ¿Afecta el orden de las preguntas de examen la calificación? Se estudió el orden de preguntas de examen para ver su efecto en la ansiedad. Los resultados muestrales se listan abajo. Utilizando un nivel de significancia de 0.05, pruebe la aseveración de que las dos muestras provienen de poblaciones con las mismas calificaciones. (Los datos se basan en "Item Arrangement, Cognitive Entry Characteristics, Sex and Test Anxiety as Predictors of Achievement Examination Performance", de Klimko, *Journal of Experimental Education*, vol. 52, núm. 4.)

Fácil a difícil				**Difícil a fácil**			
24.64	39.29	16.32	32.83	33.62	34.02	26.63	30.26
28.02	33.31	20.60	21.13	35.91	26.68	29.49	35.32
26.69	28.90	26.43	24.23	27.24	32.34	29.34	33.53
7.10	32.86	21.06	28.89	27.62	42.91	30.20	32.54
28.71	31.73	30.02	21.96				
25.49	38.81	27.85	30.29				
30.72							

6. Prueba de poblaciones idénticas de dulces M&M rojos y cafés Abajo se listan los pesos (en gramos) de dulces M&M que se tomaron del conjunto de datos 19 del Apéndice B. Utilice un nivel de significancia de 0.05, y pruebe la aseveración de que los dulces M&M clásicos rojos y cafés tienen pesos con la misma distribución. Esto es, pruebe la aseveración de que las poblaciones de dulces M&M clásicos rojos y cafés son idénticas.

Rojos:	0.870	0.933	0.952	0.908	0.911	0.908	0.913	0.983	0.920
	0.936	0.891	0.924	0.874	0.908	0.924	0.897	0.912	0.888
	0.872	0.898	0.882						
Cafés:	0.932	0.860	0.919	0.914	0.914	0.904	0.930	0.871	1.033
	0.955	0.876	0.856	0.866	0.858	0.988	0.936	0.930	0.923
	0.867	0.965	0.902	0.928	0.900	0.889	0.875	0.909	0.976
	0.921	0.898	0.897	0.902	0.920	0.909			

T **7.** Facilidad de lectura de Rowling y Tolstoi Un ejemplo de esta sección utilizó las puntuaciones de facilidad de lectura de Flesch para páginas que se seleccionaron aleatoriamente de *Harry Potter y la piedra filosofal*, de J. K. Rowling, y *La guerra y la paz*, de León Tolstoi. (Ese ejemplo incluyó un valor muestral adicional que no se lista en el Apéndice B). Remítase al conjunto de datos 14 del Apéndice B y utilice las puntuaciones del grado de Flesch-Kincaid para las páginas de Rowling y Tolstoi. Con un nivel de significancia de 0.05, pruebe la aseveración de que las dos muestras provienen de poblaciones con la misma distribución.

T **8.** Récord de jonrones Remítase a las distancias de los jonrones que anotaron Barry Bonds y Mark McGwire en el conjunto de datos 30 del Apéndice B. Considerando que estas distancias son datos muestrales, utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las muestras de Bonds y McGwire provienen de poblaciones con la misma distribución.

T **9.** Polizones del *Queen Mary* Remítase al conjunto de datos 15 del Apéndice B, utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las edades de los polizones de la costa oeste de Estados Unidos y las edades de los polizones de la costa este provienen de poblaciones con la misma distribución.

T **10.** Índice de masa corporal (IMC) Remítase al conjunto de datos 1 del Apéndice B de los valores de índice de masa corporal para hombres y mujeres. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las dos muestras de valores de IMC provienen de poblaciones con la misma distribución.

12-4 Más allá de lo básico

11. Uso de la prueba *U* de Mann-Whitney La prueba *U* de Mann-Whitney es equivalente a la prueba de la suma de rangos de Wilcoxon para muestras independientes, ya que ambas se aplican a las mismas situaciones y siempre llevan a las mismas conclusiones. En la prueba *U* de Mann-Whitney calculamos

$$z = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

donde

$$U = n_1 n_2 + \frac{n_1 (n_1 + 1)}{2} - R$$

Utilice las mediciones de facilidad de lectura de Rowling y Tolstoi que se listan en la tabla 12-4 de esta sección y calcule el estadístico de prueba z para la prueba U de Mann-Whitney y compárelo con el estadístico de prueba z de 3.67 que se calculó utilizando la prueba de la suma de rangos de Wilcoxon.

12. Cálculo de valores críticos Suponga que tenemos dos tratamientos (A y B), que producen resultados cuantitativos, y tenemos sólo dos observaciones del tratamiento A y dos observaciones del tratamiento B. No podemos utilizar el estadístico de prueba dado en esta sección, ya que los tamaños muestrales no exceden a 10.

Rango				Suma de rangos del tratamiento A
1	2	3	4	
A	A	B	B	3

a. Complete la tabla adjunta, listando los cinco renglones que corresponden a los otros cinco casos y registre las sumas de rangos correspondientes del tratamiento A.

b. Haga una lista de los valores posibles de R, junto con sus probabilidades correspondientes. [Suponga que los renglones de la tabla del inciso *a* son igualmente probables].

c. ¿Es posible, con un nivel de significancia de 0.10, rechazar la hipótesis nula de que no hay diferencia entre los tratamientos A y B? Explique.

12-5 Prueba de Kruskal-Wallis

Esta sección introduce la *prueba de Kruskal-Wallis*, que se utiliza para probar la hipótesis nula de que tres o más muestras independientes provienen de poblaciones idénticas. En la sección 11-2 utilizamos el análisis de varianza de un factor (ANOVA) para probar la hipótesis nula de que tres o más poblaciones tienen la misma media, pero el ANOVA requiere que todas las poblaciones implicadas tengan distribuciones normales. La prueba de Kruskal-Wallis no requiere distribuciones normales.

Definición

Prueba de Kruskal-Wallis (también se le llama **prueba *H***): Es una prueba no paramétrica que utiliza rangos de datos muestrales de tres o más poblaciones independientes. Se emplea para probar la hipótesis nula de que las muestras independientes provienen de poblaciones con la misma distribución; la hipótesis alternativa es la aseveración de que las distribuciones poblacionales son diferentes en alguna forma.

H_0: Las muestras provienen de poblaciones con la misma distribución.

H_1: Las muestras provienen de poblaciones con distribuciones diferentes.

En la aplicación de la prueba de Kruskal-Wallis, calculamos el *estadístico de prueba H, el cual tiene una distribución que puede aproximarse por la distribución chi cuadrada, siempre y cuando cada muestra tenga al menos cinco observaciones*. Cuando utilizamos la distribución chi cuadrada en este contexto, el número de grados de libertad es $k - 1$, donde k es el número de muestras. (Para una revisión rápida de las características clave de la distribución chi cuadrada, véase la sección 6-5).

Procedimiento para calcular el valor del estadístico de prueba *H*

1. Combine temporalmente todas las muestras en una muestra grande y asigne un rango a cada valor muestral. (Acomode los valores del más bajo al más alto; en caso de empates, asigne a cada observación la media de los rangos implicados).
2. En cada muestra, calcule la suma de los rangos y el tamaño muestral.
3. Calcule *H* utilizando los resultados del paso 2, con la notación y el estadístico de prueba que vienen en el siguiente recuadro.

Prueba de Kruskal-Wallis

Supuestos

1. Tenemos al menos tres muestras independientes, que se seleccionan aleatoriamente.
2. Cada muestra tiene al menos cinco observaciones. (Si las muestras tienen menos de cinco observaciones, remítase a tablas especiales de valores críticos, como las *CRC Standard Probability and Statistics Tables and Formulae*, publicadas por CRC Press).
3. No existe el requisito de que las poblaciones tengan una distribución normal o cualquiera otra distribución particular.

Notación

N = número total de observaciones en todas las muestras que se combinaron

k = número de muestras

R_1 = suma de los rangos de la muestra 1

n_1 = número de observaciones de la muestra 1

Para la muestra 2, la suma de los rangos es R_2 y el número de observaciones es n_2; se utiliza una notación similar para las otras muestras.

Estadístico de prueba

$$H = \frac{12}{N(N+1)}\left(\frac{R_1^2}{n_1} + \frac{R_2^2}{n_2} + \cdots + \frac{R_k^2}{n_k}\right) - 3(N+1)$$

Valores críticos

1. La prueba es de *cola derecha*.
2. gl = $k - 1$. (Puesto que el estadístico de prueba *H* puede aproximarse por una distribución chi cuadrada, utilice la tabla A-4 con $k - 1$ grado de libertad, donde k es el número de muestras diferentes).

El estadístico de prueba *H* es básicamente una medida de la varianza de las sumas de rangos $R_1, R_2, \ldots, R_k$. Si los rangos se distribuyen de manera equitativa entre los grupos muestrales, entonces *H* debe ser un número relativamente pequeño. Si las muestras son muy diferentes, luego los rangos serán excesivamente bajos en algunos grupos y altos en otros, con el efecto neto de que *H* será grande. En consecuencia, sólo los valores grandes de *H* nos llevan al rechazo de la hipótesis nula de que las muestras provienen de poblaciones idénticas. *La prueba de Kruskal-Wallis es, por lo tanto, una prueba de cola derecha.*

EJEMPLO Clancy, Rowling y Tolstoi El conjunto de datos 14 del Apéndice B incluye datos obtenidos de 12 páginas que se seleccionaron aleatoriamente de tres libros diferentes: *El oso y el dragón*, de Tom Clancy; *Harry Potter y la piedra filosofal*, de J. K. Rowling; y *La guerra y la paz*, de León Tolstoi. Se obtuvo la puntuación de facilidad de lectura de Flesch para cada una de estas obras; los resultados se listan en la tabla 12-5. El sistema de puntuación de facilidad de lectura de Flesch da como resultado calificaciones más altas para el texto que es más fácil de leer. Las calificaciones bajas resultan de trabajos que son más difíciles de leer. En la sección 11-2 utilizamos el análisis de varianza para probar la hipótesis nula de que tres muestras de puntuaciones de lectura provienen de poblaciones con la misma media. Ahora usaremos la prueba de Kruskal-Wallis, con la hipótesis nula de que tres muestras provienen de poblaciones con la misma distribución.

Tabla 12-5 Calificaciones de facilidad de lectura

Clancy	Rowling	Tolstoi
58.2 (4)	85.3 (34)	69.4 (10.5)
73.4 (19)	84.3 (32)	64.2 (6)
73.1 (18)	79.5 (28)	71.4 (13)
64.4 (7)	82.5 (30)	71.6 (14)
72.7 (16)	80.2 (29)	68.5 (9)
89.2 (36)	84.6 (33)	51.9 (2)
43.9 (1)	79.2 (27)	72.2 (15)
76.3 (23)	70.9 (12)	74.4 (22)
76.4 (24)	78.6 (25)	52.8 (3)
78.9 (26)	86.2 (35)	58.4 (5)
69.4 (10.5)	74.0 (21)	65.4 (8)
72.9 (17)	83.7 (31)	73.6 (20)
$n_1 = 12$	$n_2 = 12$	$n_3 = 12$
$R_1 = 201.5$	$R_2 = 337$	$R_3 = 127.5$

SOLUCIÓN Las hipótesis nula y alternativa son las siguientes:

H_0: Las poblaciones de calificaciones de facilidad de lectura para las páginas de los tres libros son idénticas.

H_1: Las tres poblaciones no son idénticas.

Para determinar el valor del estadístico de prueba H, primero tenemos que ordenar en rangos todos los datos. Comenzamos con el valor más bajo de 43.9, al cual se le asigna un rango de 1. En la tabla 12-5 los rangos se muestran entre paréntesis con las calificaciones de facilidad de lectura originales. Después calculamos el tamaño muestral, n, y la suma de rangos, R, para cada muestra. Estos valores se listan al final de la tabla 12-5. Puesto que el número total de

continúa

observaciones es 36, tenemos $N = 36$. Ahora evaluamos el estadístico de prueba como sigue:

$$H = \frac{12}{N(N+1)}\left(\frac{R_1^2}{n_1} + \frac{R_2^2}{n_2} + \cdots + \frac{R_k^2}{n_k}\right) - 3(N+1)$$
$$= \frac{12}{36(36+1)}\left(\frac{201.5^2}{12} + \frac{337^2}{12} + \frac{127.5^2}{12}\right) - 3(36+1)$$
$$= 16.949$$

Ya que cada muestra tuvo al menos cinco observaciones, la distribución de H es aproximadamente una distribución chi cuadrada con $k - 1$ grados de libertad. El número de muestras es $k = 3$; entonces, tenemos $3 - 1$ grados de libertad. Remítase a la tabla A-4 para encontrar el valor crítico de 5.991, que corresponde a 2 grados de libertad y a un nivel de significancia de 0.05 (con un área de 0.05 en la cola derecha).

El estadístico de prueba $H = 16.949$ está en la región crítica acotada por 5.991; por lo tanto, rechazamos la hipótesis nula de poblaciones idénticas. (En la sección 11-2, rechazamos la hipótesis nula de medias iguales).

INTERPRETACIÓN Hay suficiente evidencia para sustentar la conclusión de que las poblaciones de calificaciones de facilidad de lectura para las páginas de los tres libros no son idénticas. Los libros parecen tener calificaciones de facilidad de lectura diferentes. Examinando las sumas de rangos, vemos que Tolstoi tuvo la suma de rangos más baja, lo que sugiere que su libro es el más difícil de leer. Rowling tiene la suma de rangos más alta, lo que sugiere que su libro es el más fácil de leer de los tres.



EJEMPLO ¿Llueve más durante los fines de semana? En el problema del capítulo señalamos que los medios de comunicación reportaron que llueve más durante los fines de semana, a lo largo de la costa este de Estados Unidos, desde Maine hasta Florida. El conjunto de datos 11 del Apéndice B incluye cantidades de lluvia en un año reciente en Boston. Utilizando ese conjunto de datos, pruebe la aseveración de que los siete días de la semana tienen distribuciones que no son las mismas.

SOLUCIÓN Parecería que es conveniente someter el conjunto de datos 11 a los métodos de análisis de varianza que se introducen en la sección 11-2, pero esos métodos requieren que los valores muestrales provengan de poblaciones con distribuciones que sean aproximadamente normales. El problema del capítulo incluye un histograma para las cantidades de lluvia del lunes, por lo que es evidente que no hay una distribución normal. Los histogramas de los otros días de la semana tienen la misma forma básica que la del lunes. Puesto que los datos no indican distribuciones normales, no es posible utilizar el análisis de varianza, por lo cual la prueba de Kruskal-Wallis resulta una alternativa ideal. El conjunto de datos 11 incluye datos para cada uno de los 365 días, de forma que estamos tratando con conjuntos de datos grandes; en consecuencia, los cálculos manuales serían muy engorrosos. En lugar de ello utilizaremos un programa de cómputo. Abajo se muestran las últimas dos líneas de la pantalla de Minitab. (Véase el ejercicio 11, donde se presenta la corrección a utilizar cuando hay muchos valores muestrales empatados).

Minitab

```
H = 2.78  DF = 6  P = 0.836
H = 3.85  DF = 6  P = 0.697 (adjusted for ties)
```

No rechazamos la hipótesis nula de distribuciones idénticas, puesto que el valor *P* de Minitab es mayor que un nivel razonable de significancia de 0.05. El STATDISK produjo un estadístico de prueba $H = 2.7806$ y un valor crítico de 12.592; además, incluye la conclusión de "no rechazo de la hipótesis nula". No hay suficiente evidencia para sustentar la aseveración de que las cantidades de lluvia durante los siete días de la semana tienen distribuciones distintas. Las cantidades de lluvia parecen ser las mismas durante los diferentes días de la semana.

INTERPRETACIÓN Con base en las cantidades de lluvia de Boston, no parece haber evidencia que sustente la aseveración de que llueve más durante los fines de semana. Por lo tanto, ¿cómo es que los reportes del periódico, las revistas y la televisión nos hagan creer que llueve más los fines de semana? Los científicos Randall S. Cerveny y Robert C. Balling, de la Arizona State University, realizaron el estudio original. ¿Es posible culparlos de brindar información falsa? No. El autor contactó a Randall Cerveny, quien afirmó que el documento original incluyó la lluvia lejos de la costa del Atlántico, no la lluvia que se asocia con alguna ciudad en particular. Cerveny y Balling utilizaron estimados de lluvia satelitales y encontraron que ciertas áreas en el océano y cerca de la costa tuvieron mayor precipitación pluvial los fines de semana, es decir, explican este fenómeno por su relación con la contaminación que viene de las regiones costeras. Sus descubrimientos son interesantes y significativos. Los medios de comunicación malinterpretaron las conclusiones de Cerveny y Balling, pues dieron reportes que indicaban que llueve más los fines de semana para quienes vivimos en tierra, junto a la costa del Atlántico. Se trata de un caso interesante de una mala interpretación hecha por los medios de comunicación de los resultados de los estudios.

Fundamentos: El estadístico de prueba *H*, como se presentó, es la versión con rangos del estadístico de prueba *F* que se utiliza en el análisis de varianza que se estudió en el capítulo 11. Cuando tratamos con rangos *R*, en lugar de valores *x* originales, muchos componentes están predeterminados. Por ejemplo, la suma de todos los rangos se expresa como $N(N + 1)/2$, donde *N* es el número total de valores en todas las muestras combinadas. La expresión

$$H = \frac{12}{N(N + 1)} \Sigma n_i(\overline{R}_i - \overline{\overline{R}})^2$$

donde

$$\overline{R}_i = \frac{R_i}{n_i} \quad \overline{\overline{R}} = \frac{\Sigma R_i}{\Sigma n_i}$$

combina varianzas ponderadas de rangos para producir el estadístico de prueba *H* que se dio aquí. Tal expresión de *H* es equivalente algebraicamente a la expresión de *H* que se dio antes como estadístico de prueba. La forma anterior de *H* (no la que se dio aquí) es más sencilla de aplicar. Al comparar los procedimientos de la prueba paramétrica *F* con la prueba no paramétrica de Kruskal-Wallis, veremos que, en ausencia de programas de cómputo, la prueba de Kruskal-Wallis es mucho más simple de aplicar. No necesitamos calcular las varianzas muestrales ni las me-

dias muestrales. Tampoco requerimos distribuciones poblacionales normales. La vida se vuelve mucho más fácil. Sin embargo, la prueba de Kruskal-Wallis no es tan eficiente como la prueba *F*, de manera que requeriría de diferencias más marcadas para el rechazo de la hipótesis nula.



Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Kruskal-Wallis Test** y proceda a ingresar una copia de los datos muestrales en el cuadro de diálogo. STATDISK mostrará en la pantalla la suma de los rangos para cada muestra, el estadístico de prueba *H*, el valor crítico y la conclusión.

Minitab Remítase al manual *Minitab Student Laboratory Manual and Workbook* para ver el procedimiento que se requiere para utilizar las opciones **Stat**, **Nonparametrics** y **Kruskal-Wallis**. La idea básica es hacer una lista de todos los datos muestrales en una gran columna, con otra columna que identifique la muestra para los valores correspondientes. Para los datos de facilidad de lectura de la tabla 12-5, ingrese las 36 calificaciones en la columna C1 del Minitab y los 12 valores de Clancy, seguidos por los 12 valores de Rowling, y después los 12 valores de Tolstoi. En la columna C2, ingrese 12 números 1 seguidos por 12 números 2 y después por 12 números 3. Ahora seleccione **Stat**, **Nonparametrics** y **Kruskal-Wallis**. En el cuadro de diálogo, ingrese C1 como respuesta, C2 como factor y haga clic en **OK**. La pantalla de Minitab incluye el estadístico de prueba *H* y el valor *P*.

Excel Excel no está programado para la prueba de Kruskal-Wallis.

TI-83 Plus La calculadora TI-83 Plus no está programada para la prueba de Kruskal-Wallis.

12-5 Destrezas y conceptos básicos

Interpretación de resultados de la prueba de Kruskal-Wallis. *En los ejercicios 1 y 2, interprete los resultados de la prueba de Kruskal-Wallis y resuelva la pregunta.*

1. Tiempos de maratón Los tiempos de carrera de los hombres en la carrera de maratón de la ciudad de Nueva York se listan en el conjunto de datos 8 del Apéndice B. Cuando estos tiempos de carrera se dividen en categorías, con edades de 21 a 29, 30 a 39 y 40 o mayores, los resultados de la prueba de Kruskal-Wallis de Minitab son los que se presentan más adelante. ¿Los tiempos de carrera para los diferentes grupos de edad parecen provenir de poblaciones idénticas?

Minitab

```
H = 0.58  DF = 2  P = 0.747
```

2. ¿El Old Faithful cambia con el tiempo? Se registraron 12 diferentes intervalos de tiempo (en minutos) entre las erupciones del géiser Old Faithful en 1951, 1985 y 1996. (Los datos provienen del geólogo Rick Hutchinson y del National Park Service). Cuando se utiliza Minitab con la prueba de Kruskal-Wallis, los resultados son los que se presentan más adelante. ¿Tienen los diferentes años intervalos de tiempo con poblaciones idénticas? ¿Parece que el comportamiento de las erupciones del Old Faithful cambia con el tiempo?

Minitab

```
H = 11.93  DF = 2  P = 0.003
```

Uso de la prueba de Kruskal-Wallis. *En los ejercicios 3 a 8, utilice la prueba de Kruskal-Wallis.*

3. ¿Afecta el peso de un automóvil las heridas en la cabeza que se producen en un choque? Se obtuvieron datos de experimentos de choques realizados por la National Transportation Safety Administration. Se compraron automóviles nuevos y se hicieron estrellar contra una barrera fija a 35 millas/hora. Las mediciones se registraron en un maniquí que se colocó en el asiento del conductor. Utilice los datos muestrales que se listan más adelante para probar las diferencias en las mediciones de heridas en la cabeza en cuatro categorías de peso. ¿Hay evidencia suficiente para concluir que las mediciones de heridas en la cabeza para las cuatro categorías de peso de automóviles no son las mismas? ¿Sugieren los datos que los automóviles más pesados son más seguros en un choque?

Subcompacto:	681	428	917	898	420
Compacto:	643	655	442	514	525
Mediano:	469	727	525	454	259
Grande:	384	656	602	687	360

4. ¿La energía solar es la misma todos los días? Una alumna del autor vive en una casa con sistema eléctrico solar. A la misma hora de cada día, ella reúne lecturas de voltaje con un medidor conectado al sistema; los resultados se listan en la tabla adjunta. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las lecturas de voltaje son las mismas para los tres diferentes tipos de día. ¿Hay suficiente evidencia para sustentar una aseveración de distribuciones poblacionales diferentes? Esperaríamos que un sistema solar proporcione más energía eléctrica en días soleados que en días nublados o lluviosos. ¿Concluiríamos que los días soleados dan como resultado mayores cantidades de energía eléctrica?

Datos para el ejercicio 4

Soleado	Nublado	Lluvioso
13.5	12.7	12.1
13.0	12.5	12.2
13.2	12.6	12.3
13.9	12.7	11.9
13.8	13.0	11.6
14.0	13.0	12.2

5. Prueba de diferencias de amplitud craneana en distintas épocas Los valores adjuntos son amplitudes máximas medidas de cráneos de hombres egipcios de diferentes épocas (datos tomados de *Ancient Races of the Thebaid*, de Thomson y Randall-Maciver). Los cambios en la forma de la cabeza a través del tiempo sugieren que ocurrió mestizaje con poblaciones inmigrantes. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las tres muestras provienen de poblaciones idénticas. ¿Sugieren los datos un mestizaje de culturas?

Datos para el ejercicio 5

4000 AC	1850 AC	150 DC
131	129	128
138	134	138
125	136	136
129	137	139
132	137	141
135	129	142
132	136	137
134	138	145
138	134	137

6. Prueba de laboratorio de inflamabilidad de ropa de dormir para niños Se realizaron pruebas de inflamabilidad en ropa de dormir para niños. Se utilizó la prueba Vertical Semirestrained, consistente en la quema de piezas de tela en condiciones bajo control. Después de detener la combustión, se midió y registró la longitud de la porción que se quemó. Al margen se presentan los resultados para la misma tela que se probó en laboratorios diferentes. Puesto que se utilizó la misma tela, los diferentes laboratorios deberían obtener los mismos resultados. ¿Fue así?

Datos para el ejercicio 6

Laboratorio				
1	2	3	4	5
2.9	2.7	3.3	3.3	4.1
3.1	3.4	3.3	3.2	4.1
3.1	3.6	3.5	3.4	3.7
3.7	3.2	3.5	2.7	4.2
3.1	4.0	2.8	2.7	3.1
4.2	4.1	2.8	3.3	3.5
3.7	3.8	3.2	2.9	2.8
3.9	3.8	2.8	3.2	
3.1	4.3	3.8	2.9	
3.0	3.4	3.5		
2.9	3.3			

T **7.** ¿El peso de todos los colores de los dulces M&M es el mismo? Remítase al conjunto de datos 19 del Apéndice B. Con un nivel de significancia de 0.05, pruebe la aseveración de que los pesos de los dulces M&M son los mismos para cada una de las seis poblaciones de colores diferentes. Si la intención de Mars, Inc., es hacer los dulces para que las diferentes poblaciones de color sean las mismas, ¿sugieren sus resultados que la compañía tiene un problema que requiere de una acción correctiva?

T **8.** Distancias de jonrones Remítase al conjunto de datos 30 del Apéndice B. Considere que las distancias de jonrones son muestras seleccionadas aleatoriamente a partir de poblaciones. Utilice un nivel de significancia de 0.05 y pruebe la aseveración de que las poblaciones de distancias de jonrones que conectaron Barry Bonds, Mark McGwire y Sammy Sosa son idénticas.

12-5 Más allá de lo básico

9. Prueba del efecto de transformar los datos muestrales
- **a.** En general, ¿cómo se afecta el valor del estadístico de prueba H si se suma (o se resta) una constante a cada valor muestral?
- **b.** En general, ¿cómo se afecta el valor del estadístico de prueba H si cada valor muestral se multiplica (o divide) por una constante positiva?
- **c.** En general, ¿cómo se afecta el valor del estadístico de prueba H si un solo valor muestral se cambia para convertirse en un dato distante?

10. Cálculo de valores del estadístico de prueba Para tres muestras, cada una de tamaño 5, calcule los valores máximo y mínimo posibles del estadístico de prueba H.

11. Corrección del estadístico de prueba H por empates En el uso de la prueba de Kruskal-Wallis hay un factor de corrección, que debe aplicarse siempre que existan muchos empates: divida H entre

$$1 - \frac{\Sigma T}{N^3 - N}$$

Para cada grupo de observaciones empatadas en el conjunto de datos muestrales que se combinó, calcule $T = t^3 - t$, donde t es el número de observaciones que están empatadas en el grupo individual. Calcule t para cada grupo de valores empatados, luego el valor de T para cada grupo. Entonces, sume los valores T para obtener ΣT. El número total de observaciones en todas las muestras combinadas es N. Utilice este procedimiento para calcular el valor corregido de H para el ejercicio 4. ¿Difiere el valor corregido de H sustancialmente del valor que se calculó en el ejercicio 4?

12. Pruebas equivalentes Demuestre que, para el caso de dos muestras, la prueba de Kruskal-Wallis es equivalente a la prueba de la suma de rangos de Wilcoxon. Esto se logra demostrando que, para el caso de dos muestras, el estadístico de prueba H es igual al cuadrado del estadístico de prueba z que se utiliza en la prueba de la suma de rangos de Wilcoxon. Además, note que, con 1 grado de libertad, los valores críticos de χ^2 corresponden al cuadrado de la puntuación crítica z.

12-6 Correlación de rangos

En esta sección describimos cómo el método no paramétrico de correlación de rangos se utiliza con datos apareados para probar una asociación entre dos variables. En el capítulo 9 manejamos datos muestrales apareados para calcular valores del coeficiente de correlación lineal r, pero en esta sección emplearemos *rangos* como base para medir la fuerza de la correlación entre dos variables.

Definición

Prueba de correlación de rangos (o prueba de correlación de rangos de Spearman): es una prueba no paramétrica que utiliza rangos de datos muestrales consistentes en datos apareados. Se usa para probar una asociación entre dos variables, por lo que las hipótesis nula y alternativa son las siguientes (donde ρ_s denota el coeficiente de correlación de rangos de la población completa):

H_0: $\rho_s = 0$ (*No* existe correlación entre las dos variables).

H_1: $\rho_s \neq 0$ (Existe una correlación entre las dos variables).

Ventajas: La correlación de rangos tiene varias ventajas sobre los métodos paramétricos que se analizaron en el capítulo 9:

1. El método no paramétrico de correlación de rangos puede utilizarse en una variedad más amplia de circunstancias que el método paramétrico de correlación lineal. Con la correlación de rangos, analizamos datos apareados que sean rangos o puedan convertirse a rangos. Por ejemplo, si dos jueces califican el rango de 30 gimnastas diferentes, utilizaríamos la correlación de rangos, pero no la correlación lineal. A diferencia de los métodos paramétricos del capítulo 9, el método de correlación de rangos *no* requiere una distribución normal de la población.
2. La correlación de rangos puede utilizarse para detectar algunas de las relaciones (no todas) que no son lineales. (Se dará un ejemplo más adelante en esta sección).

Desventaja: Una desventaja de la correlación de rangos es su tasa de eficacia de 0.91, como se describe en la sección 12-1. Esta tasa de eficacia muestra que, con todas las demás circunstancias iguales, el método no paramétrico de correlación de rangos requiere de 100 pares de datos muestrales para obtener los mismos resultados que sólo 91 pares de observaciones muestrales que se analizan a través del método paramétrico, suponiendo que los requisitos más estrictos del método paramétrico se satisfacen.

Los supuestos, la notación, el estadístico de prueba y los valores críticos se resumen en el siguiente recuadro. Utilizamos la notación r_s para el coeficiente de correlación de rangos, con la finalidad de no confundirlo con el coeficiente de correlación lineal r. El subíndice s no tiene nada que ver con la desviación estándar, se usa en honor de Charles Spearman (1863-1945), quien desarrolló el método de correlación de rangos. De hecho, r_s suele llamarse **coeficiente de correlación de rangos de Spearman**. El procedimiento de la correlación de rangos se resume en la figura 12-4.

Correlación de rangos

Supuestos

1. Los datos muestrales apareados se seleccionaron aleatoriamente.
2. A diferencia de los métodos paramétricos de la sección 9-2, *no* existe el requisito de que los datos muestrales apareados tengan una distribución normal bivariada (como se describe en la sección 9-2). *No* existe el requisito de una distribución normal para la población.

Notación

r_s = coeficiente de correlación de rangos para datos muestrales apareados (r_s es un estadístico muestral)

ρ_s = coeficiente de correlación de rangos para todos los datos poblacionales (ρ_s es un parámetro poblacional)

n = número de pares de datos muestrales

d = diferencia entre los rangos de los dos valores dentro de un par

continúa



Vínculo directo entre el cigarro y el cáncer

Cuando hallamos una correlación estadística entre dos variables, debemos ser extremadamente cuidadosos para evitar el error de concluir que hay una conexión de causa y efecto. La industria tabacalera ha puesto énfasis, una y otra vez, en que la correlación no implica causalidad. Sin embargo, el doctor David Sidransky, de la John Hopkins University, dice que "tenemos pruebas moleculares tan fuertes que podemos tomar un cáncer individual y potencialmente, con base en los patrones de cambio genético, determinar si fumar cigarrillos fue la causa de ese cáncer". Según sus hallazgos, él agregó que "el fumador tuvo una incidencia mucho más alta de mutación, pero el segundo hecho que lo confirmó fue el patrón tan claro de mutaciones... así que ya teníamos la pistola humeante". Aunque los métodos estadísticos no pueden probar que fumar *causa* cáncer, con evidencia física del tipo descrito por el doctor Sidransky, es posible establecer demostraciones como ésta.

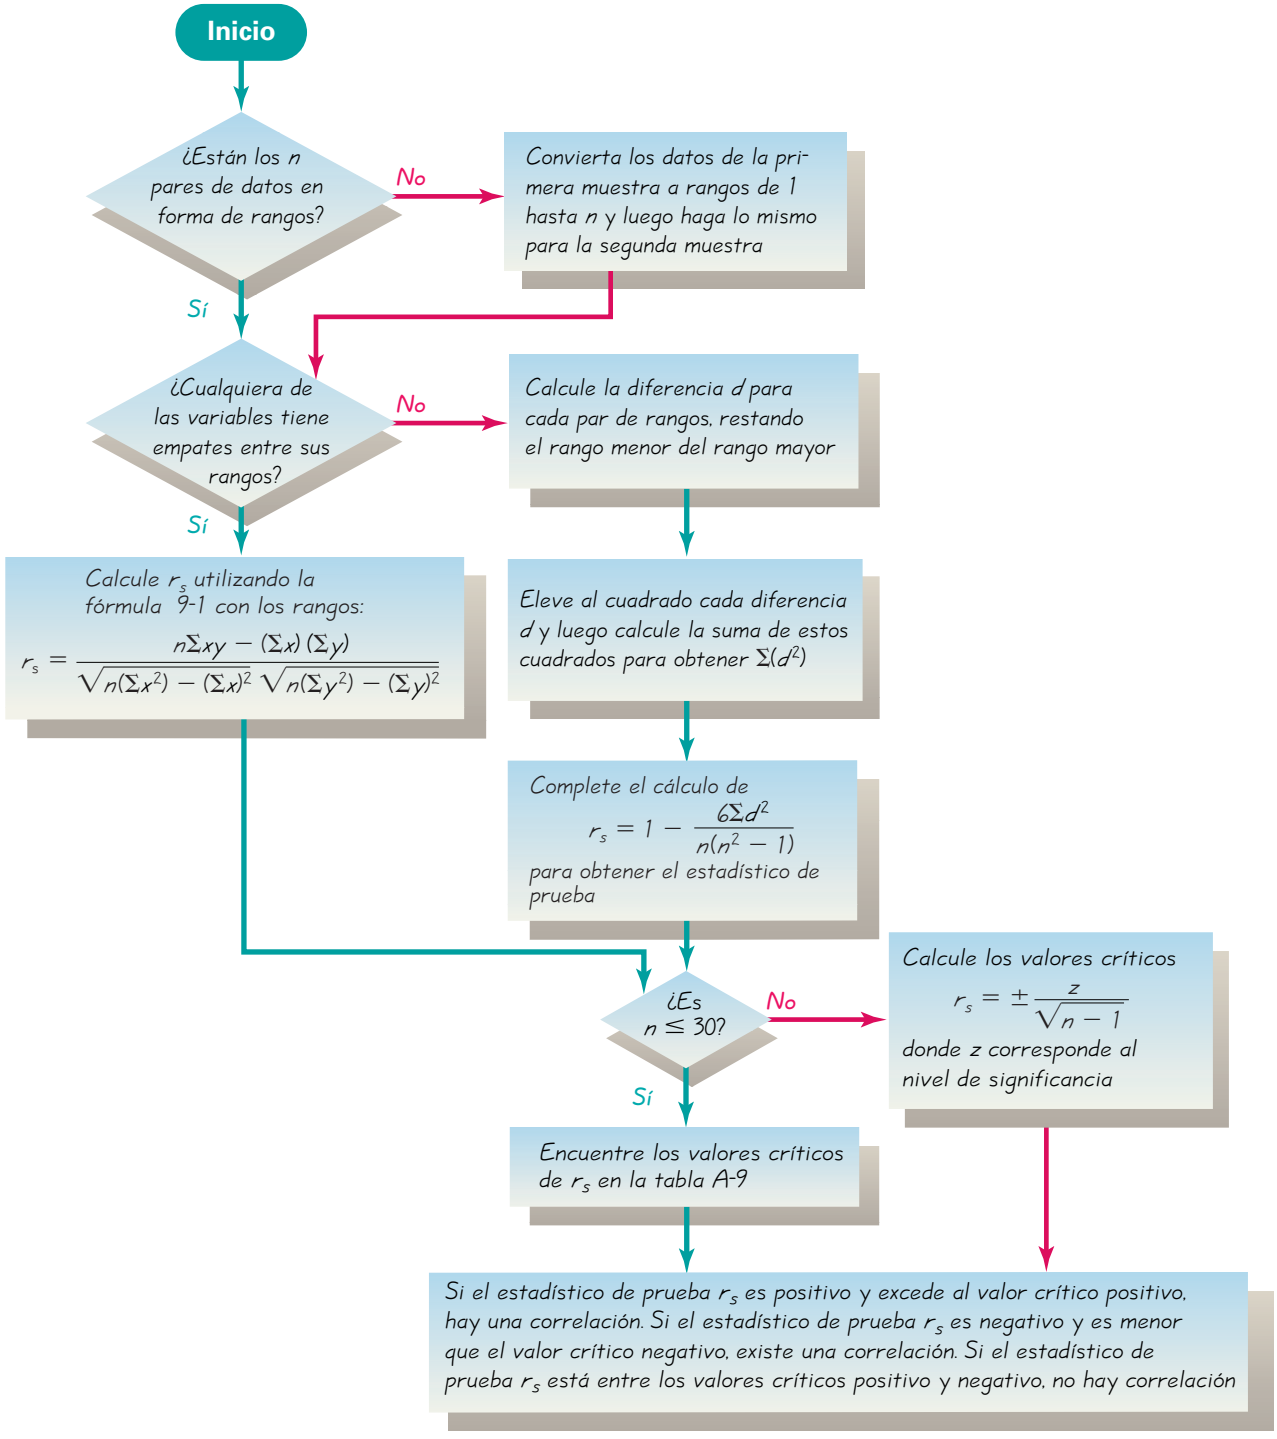


FIGURA 12-4 **Procedimiento de correlación de rangos para probar H_0: $\rho_s = 0$**

Estadístico de prueba

Sin empates: Después de convertir los datos de cada muestra a rangos, si no hay empates entre los rangos para la primera variable ni entre los rangos para la segunda variable, el valor exacto del estadístico de prueba se calcula utilizando esta fórmula:

$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)}$$

Empates: Después de convertir los datos de cada muestra a rangos, si cualquier variable tiene empates entre sus rangos, el valor exacto del estadístico de prueba r_s se calcula utilizando la fórmula 9-1 con los rangos:

$$r_s = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{\sqrt{n(\Sigma x^2) - (\Sigma x)^2}\sqrt{n(\Sigma y^2) - (\Sigma y)^2}}$$

Valores críticos

1. Si $n \leq 30$, los valores críticos se encuentran en la tabla A-9.
2. Si $n > 30$, los valores críticos de r_s se calculan utilizando la fórmula 12-1.

Fórmula 12-1 $$r_s = \frac{\pm z}{\sqrt{n - 1}}$$ (valores críticos cuando $n > 30$)

donde el valor de z corresponde al nivel de significancia.

EJEMPLO Percepción de belleza La revista *marie claire* pidió a hombres y mujeres que calificaran el grado de belleza de 10 mujeres diferentes, todas ellas bastante atractivas. ("¿Suele sorprenderse por lo que los hombres y las mujeres encuentran atractivo? Pedimos a 100 hombres y a 100 mujeres que calificaran el grado de belleza de estos rostros sumamente atractivos y explicaran exactamente lo que ellos encuentran atractivo"). La tabla 12-6 lista los rangos resultantes. ¿Hay una correlación entre las calificaciones de los hombres y las mujeres? La revista preguntó: "¿Los hombres y las mujeres están de acuerdo?". ¿Lo están? Utilice un nivel de significancia de $\alpha = 0.05$.

Tabla 12-6 Grado de belleza de 10 mujeres

Hombres	4	2	5	1	3	6	7	8	9	10	
Mujeres	2	6	7	3	1	10	4	8	5	9	
d	2	4	2	2	2	4	3	0	4	1	
d^2	4	16	4	4	4	16	9	0	16	1	$\rightarrow$ Total = 74

SOLUCIÓN El coeficiente de correlación lineal r (sección 9-2) no debe utilizarse puesto que requiere de distribuciones normales y los datos consisten en rangos que no se distribuyen normalmente. En su lugar, utilizamos el coeficiente de correlación de rangos para probar una relación entre los rangos de hombres y de mujeres.

Las hipótesis nula y alternativa son las siguientes:

$$H_0: \quad \rho_s = 0$$
$$H_1: \quad \rho_s \neq 0$$

continúa

Siguiendo el procedimiento de la figura 12-4, los datos están en forma de rangos; ninguna de las dos variables (hombres y mujeres) tuvo empates entre los rangos; por lo tanto, el valor exacto del estadístico de prueba se calcula como se indica abajo. Utilizamos $n = 10$ (para 10 pares de datos) y $\Sigma d^2 = 74$ (como se indica en la tabla 12-4) para obtener

$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)} = 1 - \frac{6(74)}{10(10^2 - 1)}$$
$$= 1 - \frac{444}{990} = 0.552$$

Ahora nos remitimos a la tabla A-9 para determinar que los valores críticos son ± 0.648 (con base en $\alpha = 0.05$ y $n = 10$). Puesto que el estadístico de prueba $r_s = 0.552$ no excede al valor crítico de 0.648, no rechazamos la hipótesis nula. No hay suficiente evidencia para sustentar una aseveración de correlación entre las calificaciones de los hombres y de las mujeres. Parece que en asuntos de belleza los hombres y las mujeres no están de acuerdo. (Si estuvieran de acuerdo, habría una correlación significativa, pero no es así).

EJEMPLO Caso de muestra grande Suponga que el ejemplo anterior se expande, incluyendo un total de 40 mujeres, y que se encuentra que el estadístico de prueba r_s es 0.291. Si el nivel de significancia es $\alpha = 0.05$, ¿qué concluye acerca de la correlación?

SOLUCIÓN Puesto que hay 40 pares de datos, tenemos $n = 40$. Puesto que n excede de 30, calculamos los valores críticos con la fórmula 12-1, en lugar de emplear la tabla A-9. Con $\alpha = 0.05$ en dos colas, permitimos que $z = 1.96$ para obtener

$$r_s = \frac{\pm 1.96}{\sqrt{40 - 1}} = \pm 0.314$$

El estadístico de prueba $r_s = 0.291$ no excede al valor crítico de 0.314; por lo tanto, no rechazamos la hipótesis nula. No hay suficiente evidencia para sustentar la aseveración de una correlación entre hombres y mujeres.

El siguiente ejemplo tiene la intención de ilustrar el principio de que la correlación de rangos algunas veces se utiliza para detectar relaciones que no son lineales.

EJEMPLO Detección de un patrón no lineal Se utiliza una máquina de pinball *Raiders of the Lost Ark* (modelo L-7) para medir el aprendizaje que resulta de repetir funciones manuales. Los sujetos se seleccionaron para que fueran similares en características importantes de edad, género, inteligencia, educación, etcétera. La tabla 12-7 lista los números de juegos que se realizaron y las últimas puntuaciones (en millones) de sujetos seleccionados al azar del grupo con características similares. Esperamos que ahí haya una asociación entre el número de juegos que se realizaron y la puntuación del pinball. ¿Existe suficiente evidencia para sustentar la aseveración de que hay una asociación como ésta?

SOLUCIÓN Probaremos la hipótesis nula de no correlación de rangos ($\rho_s = 0$).

H_0: $\rho_s = 0$ (sin correlación)
H_1: $\rho_s \neq 0$ (correlación)

Tabla 12-7 Puntuaciones de pinball (rangos entre paréntesis)

Número de juegos	9 (2)	13 (4)	21 (5)	6 (1)	52 (7)	78 (8)	33 (6)	11 (3)	120 (9)
Puntuación	22 (2)	62 (4)	70 (6)	10 (1)	68 (5)	73 (8)	72 (7)	58 (3)	75 (9)
d	0	0	1	0	2	0	1	0	0
d^2	0	0	1	0	4	0	1	0	0

Remítase a la figura 12-4, la cual seguimos para esta solución. Las puntuaciones originales no son rangos, por lo cual las convertimos a rangos e introdujimos los resultados entre paréntesis en la tabla 12-7. (La sección 12-1 describe el procedimiento para convertir puntuaciones en rangos).

Después de expresar todos los datos como rangos, calculamos las diferencias d y luego las elevamos al cuadrado. La suma de los valores de d^2 es 6. Ahora calculamos

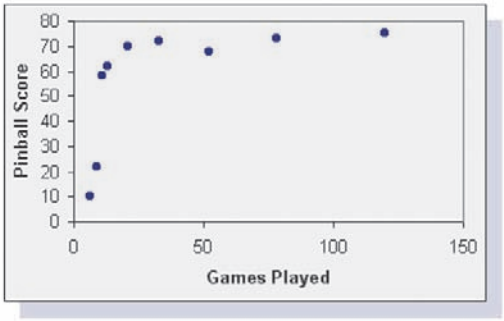
$$r_s = 1 - \frac{6\Sigma d^2}{n(n^2 - 1)} = 1 - \frac{6(6)}{9(9^2 - 1)}$$

$$= 1 - \frac{36}{720} = 0.950$$

Continuando con la figura 12-4, tenemos $n = 9$, por lo que respondemos sí cuando se pregunta si $n \leq 30$. Utilizamos la tabla A-9 para obtener los valores críticos de ± 0.683. Finalmente, el estadístico muestral de 0.950 excede a 0.683; por lo tanto, concluimos que hay una correlación significativa. Los números más altos de juegos parecen asociarse con puntuaciones más altas. Los sujetos parecen aprender mejor el juego al jugar más.

En el ejemplo anterior, si calculamos el coeficiente de correlación lineal r (mediante la fórmula 9-1) para los datos originales, obtendremos $r = 0.586$, lo que nos lleva a la conclusión de que no hay evidencia suficiente para sustentar la aseveración de una correlación lineal significativa al nivel 0.05 de significancia. Si examinamos el diagrama de dispersión de Excel, veremos que el patrón de puntos no es un patrón de línea recta. Este último ejemplo ilustra una ventaja del método no paramétrico sobre el método paramétrico: con la correlación de rangos, algunas veces podemos detectar relaciones que no son lineales.

Excel





Utilizando la tecnología

STATDISK Seleccione **Analysis** de la barra del menú principal, luego **Rank Correlation**. Ingrese los datos muestrales apareados en el cuadro de diálogo, después haga clic en **Evaluate**. Los resultados del STATDISK incluyen el valor exacto del estadístico de prueba r_s, el valor crítico y la conclusión.

Minitab Ingrese los datos apareados en las columnas C1 y C2. Si los datos todavía no son rangos, utilice las opciones **Manip** y **Rank** del Minitab para convertir los datos a rangos, luego seleccione **Stat**, seguido por **Basic Statistics** y **Correlation**. Minitab mostrará en la pantalla el valor exacto del estadístico de prueba r_s. Aunque Minitab identifica esto como el coeficiente de correlación de Pearson descrito en la sección 9-2, en realidad se trata del coeficiente de correlación de Spearman, descrito en esta sección (puesto que se basa en rangos).

Excel Excel no tiene una función que calcule el coeficiente de correlación de rangos a partir de valores muestrales originales, pero el valor exacto del estadístico de prueba r_s se calcula como sigue. Primero reemplace cada uno de los valores muestrales originales por su rango correspondiente. Ingrese estos rangos en las columnas A y B. Haga clic en el botón de función *fx* que se localiza en la barra del menú principal. Seleccione la categoría de función **Statistical** y el nombre de función **CORREL**, luego haga clic en **OK**. En el cuadro de diálogo, ingrese en la celda el rango de valores para *x*, como es A1:A10. También ingrese en la celda el rango de valores para *y*, como es B1:B10. Excel mostrará en la pantalla el valor exacto del coeficiente de correlación de rango r_s.

TI-83 Plus Si utilizamos una calculadora TI-83 Plus o cualquiera otra calculadora con estadística de dos variables, será posible calcular el valor exacto de r_s como sigue: 1. reemplace cada valor muestral por su rango correspondiente, 2. calcule el valor del coeficiente de correlación lineal r con los mismos procedimientos que se utilizaron en la sección 9-2. Ingrese los rangos apareados en las listas L1 y L2, después oprima **STAT** y elija **TESTS**. El uso de la opción **LinRegTTest** dará como resultado diversos valores que se muestran en la pantalla, incluyendo el valor exacto del coeficiente de correlación de rangos r_s.

12-6 Destrezas y conceptos básicos

1. Cálculo del estadístico de prueba y el valor crítico Para cada una de las siguientes muestras de rangos apareados, dibuje un diagrama de dispersión, estime el valor de r_s, calcule el valor de r_s y establezca si parece haber una correlación entre x y y.

a.

x	1	3	5	4	2
y	1	3	5	4	2

b.

x	1	2	3	4	5
y	5	4	3	2	1

c.

x	1	2	3	4	5
y	2	5	3	1	4

2. Cálculo de valores críticos Calcule el(los) valor(es) crítico(s) para r_s mediante la tabla A-9 o la fórmula 12-1, según resulte adecuado. Suponga casos de dos colas, donde α representa el nivel de significancia y n representa el número de pares de datos.

a. $n = 20$, $\alpha = 0.05$
b. $n = 50$, $\alpha = 0.05$
c. $n = 40$, $\alpha = 0.02$
d. $n = 15$, $\alpha = 0.01$
e. $n = 82$, $\alpha = 0.04$

Prueba para correlación de rangos. *En los ejercicios 3 a 12, utilice el coeficiente de correlación de rangos para probar una correlación entre las dos variables. Utilice un nivel de significancia de $\alpha = 0.05$.*

3. Correlación entre salario y estrés La tabla adjunta lista rangos de salario y rangos de estrés de trabajos que se seleccionaron al azar (datos tomados de *The Jobs Rated Almanac*). ¿Parece que el salario se incrementa a medida que se incrementa el estrés?

Trabajo	Rango de salario	Rango de estrés
Corredor de bolsa	2	2
Zoólogo	6	7
Ingeniero eléctrico	3	6
Director de escuela	5	4
Gerente de hotel	7	5
Funcionario bancario	10	8
Inspector de seguridad ocupacional	9	9
Economista doméstico	8	10
Psicólogo	4	3
Piloto de línea aérea	1	1

4. Correlación entre salario y demanda física El ejercicio 3 incluye rangos apareados de salario y nivel de estrés para 10 empleos que se seleccionaron al azar. Las demandas físicas de los empleos también se ordenaron en rangos; los rangos de salario y demanda física se presentan abajo (según datos de *The Jobs Rated Almanac*). ¿Parece haber una relación entre el salario de un empleo y sus demandas físicas?

Salario	2	6	3	5	7	10	9	8	4	1
Demanda física	5	2	3	8	10	9	1	7	6	4

5. Rangos de orden de escuelas de negocios La revista *Business Week* ordenó en rangos escuelas de negocios de dos formas diferentes. Los rangos de orden institucional se basaron en encuestas a reclutadores de la institución, y los rangos de orden de graduados se basaron en encuestas a graduados de la maestría en negocios. La tabla de abajo se basa en los resultados para 10 escuelas. ¿Hay una correlación entre los rangos institucionales y los rangos de los graduados? Utilice un nivel de significancia de $\alpha = 0.05$.

Escuela	PA	NW	Chi	Sfd	Hvd	MI	IN	Clb	UCLA	MIT
Rango institucional	1	2	4	5	3	6	8	7	10	9
Rango de graduados	3	5	4	1	10	7	6	8	2	9

6. Correlación entre cuentas de restaurante y propinas Los alumnos del autor reunieron datos muestrales consistentes en cantidades en cuentas de restaurante y la cantidad correspondiente de propina. Los datos se listan más adelante. Utilice la correlación de rangos para determinar si hay una correlación entre la cantidad de la cuenta y la cantidad de la propina.

Cuenta (dólares)	33.46	50.68	87.92	98.84	63.60	107.34
Propina (dólares)	5.50	5.00	8.08	17.00	12.00	16.00

7. Correlación entre estaturas y pesos de supermodelos Más adelante se listan estaturas (en pulgadas) y pesos (en libras) de las supermodelos Niki Taylor, Diana Auermann, Claudia Schiffer, Elle MacPherson, Christy Turlington, Bridget Hall, Kate Moss, Valerie Mazza y Kristy Hume.

Estatura	71	70.5	71	72	70	70	66.5	70	71
Peso	125	119	128	128	119	127	105	123	115

8. Precio de una audiencia televisiva El *New York Post* publicó los salarios anuales (en millones) y el número de televidentes (en millones), con los resultados que se incluyen abajo, para Oprah Winfrey, David Letterman, Jay Leno, Kelsey Grammer, Barbara Walters, Dan Rather, James Gandolfini y Susan Lucci, respectivamente. ¿Hay una correlación entre el salario y el número de televidentes?

Salario	100	14	14	35.2	12	7	5	1
Televidentes	7	4.4	5.9	1.6	10.4	9.6	8.9	4.2

T **9.** Cereales asesinos Remítase al conjunto de datos 16 del Apéndice B. Utilice las cantidades de grasa y los conteos calóricos medidos. ¿Hay una correlación?

T **10.** Colesterol e índice de masa corporal Remítase al conjunto de datos 1 del Apéndice B. Utilice los niveles de colesterol y los valores de índice de masa corporal de las 40 mujeres. ¿Hay una correlación entre el nivel de colesterol y el índice de masa corporal?

T **11.** Lo malo de los cigarros Remítase al conjunto de datos 5 del Apéndice B.

a. Utilice los datos apareados referentes a alquitrán y nicotina. Con base en el resultado, ¿parece haber ahí una correlación significativa entre el alquitrán y la nicotina de los cigarros? Si es así, ¿pueden los investigadores reducir sus gastos de laboratorio midiendo sólo una de estas dos variables?

b. Utilice los datos apareados consistentes en monóxido de carbono y nicotina. Con base en el resultado, ¿parece haber una correlación significativa entre el monóxido de carbono y la nicotina de los cigarros? Si es así, ¿pueden los investigadores reducir sus gastos de laboratorio midiendo sólo una de estas dos variables?

c. Suponga que los investigadores quieren desarrollar un método para predecir la cantidad de nicotina y desean medir sólo otro elemento. Al elegir entre alquitrán y monóxido de carbono, ¿cuál es la mejor opción? ¿Por qué?

T **12.** Pronósticos del clima Remítase al conjunto de datos 10 del Apéndice B.

a. Utilice las temperaturas máximas que se pronosticaron para cinco días y las temperaturas máximas reales. ¿Hay una correlación? ¿Una correlación significativa implica que las temperaturas del pronóstico de cinco días son precisas?

b. Utilice las temperaturas máximas que se pronostican para un día y las temperaturas máximas reales. ¿Hay una correlación? ¿Una correlación significativa implica que las temperaturas de pronóstico para un día son precisas?

c. ¿Cómo esperaría obtener una correlación más alta con las temperaturas máximas reales: con las temperaturas máximas del pronóstico para cinco días o con las temperaturas máximas del pronóstico para un día? ¿Los resultados de los incisos *a* y *b* concuerdan con lo que esperaría? Si hay una correlación muy alta entre las temperaturas de pronóstico y las temperaturas reales, ¿se deduce que las temperaturas de pronóstico son precisas?

12-6 Más allá de lo básico

13. Cálculo de valores críticos Una alternativa al uso de la tabla A-9 para encontrar valores críticos es calcularlos utilizando esta aproximación:

$$r_s = \pm\sqrt{\frac{t^2}{t^2 + n - 2}}$$

Aquí t es la puntuación t de la tabla A-3, correspondiente al nivel de significancia y a $n - 2$ grados de libertad. Aplique esta aproximación para calcular los valores críticos de r_s en los casos siguientes.

a. $n = 8, \alpha = 0.05$ **b.** $n = 15, \alpha = 0.05$
c. $n = 30, \alpha = 0.05$ **d.** $n = 30, \alpha = 0.01$
e. $n = 8, \alpha = 0.01$

14. Efecto de empates en r_s Remítase al conjunto de datos 7 del Apéndice B para los tiempos (en segundos) de consumo de tabaco y consumo de alcohol que se presentan en películas de dibujos animados para niños. Calcule el valor del estadístico de prueba r_s utilizando cada una de las dos fórmulas presentadas en esta sección. ¿Hay una diferencia sustancial entre los dos resultados? ¿Cuál resultado es mejor? ¿La conclusión se ve afectada por la fórmula utilizada?

12-7 Prueba de rachas para detectar aleatoriedad

El objetivo principal de esta sección es introducir la prueba de rachas para detectar aleatoriedad, que permite determinar si los datos muestrales en una secuencia están en un orden aleatorio. En la importancia de la aleatoriedad se ha puesto énfasis a lo largo de este libro; ahora nos enfocamos en un método para determinar si esta característica está presente.

Definiciones

Racha: Es una secuencia de datos que tiene la misma característica; la secuencia es precedida y seguida por datos con una característica diferente o por ningún dato en absoluto.

La **prueba de rachas** utiliza el número de rachas en una secuencia de datos muestrales para probar la aleatoriedad del orden de los datos.

Principio fundamental de la prueba de rachas

El principio fundamental de la prueba de rachas puede establecerse brevemente como sigue:

Rechace la aleatoriedad si el número de rachas es muy bajo o muy alto.

- Ejemplo: La secuencia de género MMMMMHHHHH no es aleatoria, puesto que tiene sólo dos rachas; por lo tanto, el número de rachas es muy *bajo*.
- Ejemplo: La secuencia de género MHMHMHMHMH no es aleatoria, puesto que hay 10 rachas, lo cual es muy *alto*.

El criterio exacto para determinar si un número de rachas es muy alto o muy bajo se encuentra en el recuadro adjunto, que resume los elementos clave de la prueba de rachas para detectar aleatoriedad. Además, el procedimiento de la prueba de rachas para detectar aleatoriedad se resume en la figura 12-5.