Schaum

ESTADÍSTICA

SEGUNDA EDICIÓN

Murray R. Spiegel

- 975 problemas resueltos con soluciones completamente detalladas
- Más de 700 problemas suplementarios con solución
- Especial énfasis en la comprensión de los métodos de resolución de problemas prácticos
- Abarca los aspectos teóricos esenciales de la estadística

Utilizado por millones de estudiantes y recomendado por profesores de todo el mundo

Mc Graw Hill

Entonces, como $r = \dfrac{\sum xy}{\sqrt{(\sum x^2)(\sum y^2)}}$ (véase Prob. 14.10)

tenemos $$\frac{\sum xy}{\sum x^2} = \frac{r\sqrt{(\sum x^2)(\sum y^2)}}{\sum x^2} = \frac{r\sqrt{\sum y^2}}{\sqrt{\sum x^2}} = \frac{rs_Y}{s_X}$$

y el resultado es el deseado.

(*b*) Esto se deduce intercambiando X e Y en la parte (*a*).

14.22. Si las rectas de regresión de Y sobre X y de X sobre Y son, respectivamente, $Y = a_0 + a_1 X$ y $X = b_0 + b_1 Y$, probar que $a_1 b_1 = r^2$.

Solución

Del Problema 14.21, partes (*a*) y (*b*),

$$a_1 = \frac{rs_Y}{s_X} \quad \text{y} \quad b_1 = \frac{rs_X}{s_Y}$$

Luego $$a_1 b_1 = \left(\frac{rs_Y}{s_X}\right)\left(\frac{rs_X}{s_Y}\right) = r^2$$

Cabe tomar este resultando como punto de partida para la definición del coeficiente de correlación lineal.

14.23. Usar el resultado del Problema 14.22 para hallar el coeficiente de correlación lineal para los datos del Problema 14.1.

Solución

Del Problema 14.1 [partes (*b*) y (*c*), respectivamente] $a_1 = 484/1016 = 0.476$ y $b_1 = 484/467 = 1.036$. Así que $r^2 = a_1 b_1 = (484/1016)(484/467)$ y $r = 0.7027$, de acuerdo con los Problemas 14.9, 14.14 y 14.16.

14.24. Para los datos del Problema 14.19, escribir las ecuaciones de las rectas de regresión de (*a*) Y sobre X y (*b*) X sobre Y.

Solución

De la tabla de correlación (Tabla 14.12) del Problema 14.19, tenemos

$$\bar{X} = A + c_X \frac{\sum f_X u_X}{N} = 64.5 + \frac{(10)(64)}{100} = 70.9$$

$$\bar{Y} = B + c_Y \frac{\sum f_Y u_Y}{N} = 74.5 + \frac{(10)(-55)}{100} = 69.0$$

Por el Problema 14.20, $s_X = 13.966$, $s_Y = 14.925$ y $r = 0.7686$. Ahora usamos el Problema 14.21, partes (*a*) y (*b*), para obtener las ecuaciones de las rectas de regresión.

(*a*) $Y - \bar{Y} = \dfrac{rs_Y}{s_X}(X - \bar{X})$ $\quad Y - 69.0 = \dfrac{(0.7686)(14.925)}{13.966}(X - 70.9) = 0.821(X - 70.9)$

(*b*) $X - \bar{X} = \dfrac{rs_X}{s_Y}(Y - \bar{Y})$ $\quad X - 70.9 = \dfrac{(0.7686)(13.966)}{14.925}(Y - 69.0) = 0.719(Y - 69.0)$

14.25. Calcular, para los datos del Problema 14.19, los errores típicos de estimación (*a*) $s_{Y.X}$ y (*b*) $s_{X.Y}$. Usar los resultados del Problema 14.20.

Solución

(*a*) $s_{Y.X} = s_Y\sqrt{1 - r^2} = 14.925\sqrt{1 - (0.7686)^2} = 9.548$

(*b*) $s_{X.Y} = s_X\sqrt{1 - r^2} = 13.966\sqrt{1 - (0.7686)^2} = 8.934$

14.26. La Tabla 14.13 muestra los índices de precios al consumo de alimentación y de asistencia sanitaria durante los años 1975-1983 comparados con los precios en un año base, 1967 (tomados como 100). Calcular el coeficiente de correlación entre esos dos índices.

Tabla 14.13

Año	1975	1976	1977	1978	1979	1980	1981	1982	1983
Alimentación	175	181	192	211	235	255	275	286	292
Asistencia sanitaria	169	185	202	219	240	266	295	329	357

Fuente: Survey of Current Business.

Solución

(*a*) Denotando por X e Y los índices de alimentación y de asistencia sanitaria, respectivamente, el cálculo del coeficiente de correlación procede como sugiere la Tabla 14.14. (Nótese que el año se emplea sólo para especificar los valores correspondientes de X e Y). Entonces, por la fórmula momento-producto,

$$r = \frac{\sum xy}{\sqrt{(\sum x^2)(\sum y^2)}} = \frac{23.442}{\sqrt{(16,774)(34,107)}} = 0.98$$

Luego existe una correlación lineal muy buena entre ambos índices de costo. Hay que hacer constar, no obstante, que eso no quiere decir que los costes hayan aumentado *lo mismo* a lo largo de los años: así, por ejemplo, de 1975 a 1983 los alimentos han subido un 67% mientras que la asistencia sanitaria lo ha hecho en un 111%.

Tabla 14.14

X	Y	$x = X - \bar{X}$	$y = Y - \bar{Y}$	x^2	xy	y^2
175	169	−59	−82	3,481	4,838	6,724
181	185	−53	−66	2,809	3,498	4,356
192	202	−42	−49	1,764	2,058	2,401
211	219	−23	−32	529	736	1,024
235	240	1	−11	1	−11	121
255	266	21	15	441	315	225
275	295	41	44	1,681	1,804	1,936
286	329	52	78	2,704	4,056	6,084
292	357	58	106	3,364	6,148	11,236
$\sum X = 2,102$ $\bar{X} = 234$	$\sum Y = 2,262$ $\bar{Y} = 251$			$\sum x^2 = 16,774$	$\sum xy = 23,442$	$\sum y^2 = 34,107$

CORRELACION NO LINEAL

14.27. Ajustar una parábola de mínimos cuadrados de la forma $Y = a_0 + a_1X + a_2X^2$ al conjunto de datos de la Tabla 14.15.

Tabla 14.15

X	1.2	1.8	3.1	4.9	5.7	7.1	8.6	9.8
Y	4.5	5.9	7.0	7.8	7.2	6.8	4.5	2.7

Solución

Las ecuaciones normales (23) del Capítulo 13 son

$$\begin{aligned} \sum Y &= a_0 N + a_1 \sum X + a_2 \sum X^2 \\ \sum XY &= a_0 \sum X + a_1 \sum X^2 + a_2 \sum X^3 \\ \sum X^2 Y &= a_0 \sum X^2 + a_1 \sum X^3 + a_2 \sum X^4 \end{aligned} \tag{36}$$

El proceso de cálculo de las sumas se presenta en la Tabla 14.16. Como $N = 8$, las ecuaciones normales (36) pasan a ser

$$\begin{aligned} 8a_0 + 42.2a_1 + 291.20a_2 &= 46.4 \\ 42.2a_0 + 291.20a_1 + 2275.35a_2 &= 230.42 \\ 291.20a_0 + 2275.35a_1 + 18971.92a_2 &= 1449.00 \end{aligned} \tag{37}$$

Resolviendo, $a_0 = 2.588$, $a_1 = 2.065$, y $a_2 = -0.2110$; por tanto, la parábola de mínimos cuadrados buscada es

$$Y = 2.588 + 2.065X - 0.2110X^2$$

14.28. Estimar, mediante la parábola de mínimos cuadrados del Problema 14.27, los valores de Y a partir de los valores de X dados.

Solución

Para $X = 1.2$, $Y_{est} = 2.588 + 2.065(1.2) - 0.2110(1.2)^2 = 4.762$. Otros valores estimados se obtienen análogamente. Los resultados, junto con los valores reales de Y, se muestran en la Tabla 14.17.

Tabla 14.16

X	Y	X^2	X^3	X^4	XY	X^2Y
1.2	4.5	1.44	1.73	2.08	5.40	6.48
1.8	5.9	3.24	5.83	10.49	10.62	19.12
3.1	7.0	9.61	29.79	92.35	21.70	67.27
4.9	7.8	24.01	117.65	576.48	38.22	187.28
5.7	7.2	32.49	185.19	1055.58	41.04	233.93
7.1	6.8	50.41	357.91	2541.16	48.28	342.79
8.6	4.5	73.96	636.06	5470.12	38.70	332.82
9.8	2.7	96.04	941.19	9223.66	26.46	259.31
$\sum X$ = 42.2	$\sum Y$ = 46.4	$\sum X^2$ = 291.20	$\sum X^3$ = 2275.35	$\sum X^4$ = 18,971.92	$\sum XY$ = 230.42	$\sum X^2Y$ = 1449.00

Tabla 14.17

Y_{est}	4.762	5.621	6.962	7.640	7.503	6.613	4.741	2.561
Y	4.5	5.9	7.0	7.8	7.2	6.8	4.5	2.7

14.29. (*a*) Hallar el coeficiente de correlación lineal entre las variables X e Y del Problema 14.27.
(*b*) Hallar el coeficiente de correlación no lineal entre estas variables, suponiendo la relación parabólica obtenida en el Problema 14.27.
(*c*) Explicar la diferencia entre los coeficientes de correlación obtenidos en las partes (*a*) y (*b*).
(*d*) ¿Qué porcentaje de la variación total queda inexplicada al suponer una relación parabólica entre X e Y?

Solución

(*a*) Haciendo uso de los cálculos ya realizados en la Tabla 14.16 y el hecho añadido de que $\sum Y^2 = 290.52$, vemos que

$$r = \frac{N\sum XY - (\sum X)(\sum Y)}{\sqrt{[N\sum X^2 - (\sum X)^2][N\sum Y^2 - (\sum Y)^2]}} = \frac{(8)(230.42) - (42.2)(46.4)}{\sqrt{[(8)(291.20) - (42.2)^2][(8)(290.52) - (46.4)^2]}} = -0.3743$$

(*b*) De la Tabla 14.16, $\bar{Y} = (\sum Y)/N = 46.4/8 = 5.80$; luego la variación total es $\sum (Y - \bar{Y})^2 = 21.40$. De la Tabla 14.17 vemos que la variación explicada es $\sum (Y_{est} - \bar{Y})^2 = 21.02$. Luego

$$r^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{21.02}{21.40} = 0.9822 \quad \text{y} \quad r = 0.9911 \quad \text{o sea} \quad 0.99$$

(*c*) El que (*a*) haya dado un coeficiente de correlación lineal de sólo -0.3743 indica que *no hay* prácticamente *relación lineal* entre X e Y. Sin embargo, hay una *relación no lineal* muy fuerte dada por la parábola del Problema 14.27, como ratifica el hecho de que el coeficiente de correlación en (*b*) es 0.9.

(*d*) $$\frac{\text{Variación inexplicada}}{\text{Variación total}} = 1 - r^2 = 1 - 0.9822 = 0.0178$$

Luego el 1.78% de la variación total queda inexplicada. Ello podría ser debido a fluctuaciones aleatorias o a una variable adicional que no se ha tenido en cuenta.

14.30. Hallar (*a*) s_Y y (*b*) $s_{Y.X}$ para los datos del Problema 14.27.

Solución

(*a*) Del Problema 14.29(*a*), $\sum (Y - \bar{Y})^2 = 21.40$. Así pues, la desviación típica de Y es

$$s_Y = \sqrt{\frac{\sum (Y - \bar{Y})^2}{N}} = \sqrt{\frac{21.40}{8}} = 1.636 \quad \text{o sea} \quad 1.64$$

(*b*) *Primer método*

Usando la parte (*a*) y el Problema 14.29(*b*), el error típico de estimación de Y sobre X es

$$s_{Y.X} = s_Y\sqrt{1 - r^2} = 1.636\sqrt{1 - (0.9911)^2} = 0.218 \quad \text{o sea} \quad 0.22$$

Segundo método

Usando el Problema 14.29,

$$s_{Y.X} = \sqrt{\frac{\sum (Y - Y_{est})^2}{N}} = \sqrt{\frac{\text{variación inexplicada}}{N}} = \sqrt{\frac{21.40 - 21.02}{8}} = 0.218 \quad \text{o sea} \quad 0.22$$

Tercer método

Por el Problema 14.27 y el cálculo adicional $\sum Y^2 = 290.52$, tenemos

$$s_{Y.X} = \sqrt{\frac{\sum Y^2 - a_0 \sum Y - a_1 \sum XY - a_2 \sum X^2 Y}{N}} = 0.218 \quad \text{o sea} \quad 0.22$$

TEORIA MUESTRAL DE LA CORRELACION

14.31. Al calcular el coeficiente de correlación de una muestra de tamaño 18, ha dado el valor 0.32. ¿Podemos concluir al nivel de significación (*a*) 0.05 y (*b*) 0.01 que el coeficiente de correlación de la población correspondiente difiere de cero?

Solución

Queremos decidir entre las hipótesis H_0: $\rho = 0$ y H_1: $\rho > 0$.

$$t = \frac{r\sqrt{N-2}}{\sqrt{1-r^2}} = \frac{0.32\sqrt{18-2}}{\sqrt{1-(0.32)^2}} = 1.35$$

(*a*) Usando un contraste unilateral con la distribución de Student en el nivel 0.05, rechazaríamos la hipótesis H_0 si $t > t_{.95} = 1.75$ para $(18 - 2) = 16$ grados de libertad. Luego no podemos rechazar H al nivel 0.05.

(*b*) Puesto que no podemos rechazar H al nivel 0.05, ciertamente, tampoco al 0.01.

14.32. ¿Cuál es el mínimo tamaño de muestra necesario para poder concluir que un coeficiente de correlación de 0.32 difiere significativamente de cero al nivel 0.05?

Solución

Con un contraste de una cola de la distribución de Student en el nivel 0.05, el mínimo valor de N debe ser tal que

$$\frac{0.32\sqrt{N-2}}{\sqrt{1-(0.32)^2}} = t_{.95}$$

para $N - 2$ grados de libertad. Para un número infinito de grados de libertad, $t_{95} = 1.64$ y por tanto, $N = 25.6$.

Para $N = 26$: $\nu = 24$ $t_{.95} = 1.71$ $t = 0.32\sqrt{24}/\sqrt{1-(0.32)^2} = 1.65$

Para $N = 27$: $\nu = 25$ $t_{.95} = 1.71$ $t = 0.32\sqrt{25}/\sqrt{1-(0.32)^2} = 1.69$

Para $N = 28$: $\nu = 26$ $t_{.96} = 1.71$ $t = 0.32\sqrt{26}/\sqrt{1-(0.32)^2} = 1.72$

Así que el tamaño mínimo de la muestra es $N = 28$.

14.33. Un coeficiente de correlación de una muestra de tamaño 24 resulta ser $r = 0.75$. Al nivel de significación 0.05, ¿podemos rechazar la hipótesis de que el coeficiente de correlación de la población es tan pequeño como (*a*) $\rho = 0.60$ y (*b*) $\rho = 0.50$?

Solución

(*a*) $$Z = 1.1513 \log\left(\frac{1 + 0.75}{1 - 0.75}\right) = 0.9730 \qquad \mu_Z = 1.1513 \log\left(\frac{1 + 0.60}{1 - 0.60}\right) = 0.6932$$

y $$\sigma_Z = \frac{1}{\sqrt{N - 3}} = \frac{1}{\sqrt{21}} = 0.2182$$

Por tanto $$z = \frac{Z - \mu_Z}{\sigma_Z} = \frac{0.9730 - 0.6932}{0.2182} = 1.28$$

Usando un contraste de una cola con la distribución normal al nivel 0.05, rechazaríamos la hipótesis sólo si z fuera mayor que 1.64. Luego no podemos rechazar la hipótesis de que el coeficiente de correlación de la población es tan pequeño como 0.60.

(*b*) Si $\rho = 0.50$, entonces $\mu_Z = 1.1513 \log 3 = 0.5493$ y $z = (0.9730 - 0.5493)/0.2182 = 1.94$. Luego podemos rechazar la hipótesis de que el coeficiente de correlación de la población sea tan pequeño como $\rho = 0.50$, al nivel 0.05.

14.34. El coeficiente de correlación entre las notas en Física y Matemáticas para un grupo de 21 estudiantes resulta ser 0.80. Hallar los límites de confianza 95% para este coeficiente.

Solución

Como $r = 0.80$ y $N = 21$, los límites de confianza 95% para μ_Z vienen dados por

$$Z \pm 1.96\sigma_Z = 1.1513 \log\left(\frac{1 + r}{1 - r}\right) \pm 1.96\left(\frac{1}{\sqrt{N - 3}}\right) = 1.0986 \pm 0.4620$$

Así pues, μ_Z tiene el intervalo de confianza 95% desde 0.5366 a 1.5606. Ahora bien, si

$$\mu_Z = 1.1513 \log\left(\frac{1 + \rho}{1 - \rho}\right) = 0.5366 \qquad \text{entonces} \qquad \rho = 0.4904$$

y si $$\mu_Z = 1.1513 \log\left(\frac{1 + \rho}{1 - \rho}\right) = 1.5606 \qquad \text{entonces} \qquad \rho = 0.9155$$

Luego los límites de confianza 95% para ρ son 0.49 y 0.92.

14.35. Dos coeficientes de correlación obtenidos de muestras de tamaños $N_1 = 28$ y $N_3 = 35$ han resultado ser $r_1 = 0.50$ y $r_2 = 0.30$, respectivamente. ¿Hay diferencia significativa entre los dos coeficientes al nivel 0.05?

Solución

$$Z_1 = 1.1513 \log\left(\frac{1 + r_1}{1 - r_1}\right) = 0.5493 \qquad Z_2 = 1.1513 \log\left(\frac{1 + r_2}{1 - r_2}\right) = 0.3095$$

y $$\sigma_{Z1\ Z2} = \sqrt{\frac{1}{N_1 - 3} + \frac{1}{N_2 - 3}} = 0.2669$$

Queremos decidir entre dos hipótesis H_0: $\mu_{Z1} = \mu_{Z2}$ y H_1: $\mu_{Z1} \neq \mu_{Z2}$. Bajo la hipótesis H_0,

$$z = \frac{Z_1 - Z_2 - (\mu_{Z1} - \mu_{Z2})}{\sigma_{Z1-Z2}} = \frac{0.5493 - 0.3095 - 0}{0.2669} = 0.8985$$

Con un contraste bilateral mediante la distribución normal, rechazaríamos H sólo si $z > 1.96$ o si $z < -1.96$. Por tanto, no podemos rechazar H, y concluimos que los resultados no son significativamente diferentes al nivel 0.05.

TEORIA MUESTRAL DE LA REGRESION

14.36. En el Problema 14.1 hallamos como ecuación de regresión de Y sobre X la que sigue: $Y = 35.82 + 0.476X$. Contrastar la hipótesis, al nivel de significación 0.05, de que el coeficiente de correlación de la ecuación de regresión de la población es 0.180.

Solución

$$t = \frac{a_1 - A_1}{s_{Y.X}/s_X}\sqrt{N-2} = \frac{0.476 - 0.180}{1.28/2.66}\sqrt{12-2} = 1.95$$

como $s_{Y.X} = 1.28$ (calculado en el Problema 14.5) y $s_X = \sqrt{(\sum x^2)/N} = \sqrt{84.68/12} = 2.66$ (del Problema 14.2). Usando un contraste de una cola con la distribución de Student al nivel 0.05, rechazaríamos la hipótesis de que el coeficiente de regresión es tan bajo como 0.180 si $t > t_{.95} = 1.81$ para $(12 - 2) = 10$ grados de libertad. Luego no podemos rechazar la hipótesis.

14.37. Hallar los límites de confianza 95% para el coeficiente de regresión del Problema 14.36.

Solución

$$A_1 = a_1 - \frac{t}{\sqrt{N-2}}\left(\frac{s_{Y.X}}{s_X}\right)$$

Luego los límites de confianza para A (obtenidos haciendo $t = \pm t_{.975} = \pm 2.23$ para $12 - 2 = 10$ grados de libertad) vienen dados por

$$a_1 \pm \frac{2.23}{\sqrt{12-2}}\left(\frac{s_{Y.X}}{s_X}\right) = 0.476 \pm \frac{2.23}{\sqrt{10}}\left(\frac{1.28}{2.66}\right) = 0.476 \pm 0.340$$

Es decir, tenemos 95% de confianza de que A está entre 0.136 y 0.816.

14.38. En el Problema 14.1, hallar los límites de confianza 9% para las alturas de los hijos cuyos padres miden (*a*) 65.0 y (*b*) 70.0 in.

Solución

Como $t_{.975} = 2.23$ para $(12 - 2) = 10$ grados de libertad, los límites de confianza 95% para Y_p (véase pág. 330) vienen dados por

$$Y_0 \pm \frac{2.23}{\sqrt{N-2}} s_{Y.X}\sqrt{N + 1 + \frac{(X_0 - \bar{X})^2}{s_X^2}}$$

donde $Y_0 = 35.82 + 0.476X_0$ (Problema 14.1), $s_{Y.X} = 1.28$, $s_X = 2.66$ (Problema 14.36) y $N = 12$.

(*a*) Si $X_0 = 65.0$, entonces $Y_0 = 66.76$ in. Además $(X_0 - \bar{X})^2 = (65.0 - 800/12)^2 = 2.78$. Así pues los límites de confianza al 95% son

$$66.76 \pm \frac{2.23}{\sqrt{10}}(1.28)\sqrt{12 + 1 + \frac{2.78}{(2.66)^2}} = 66.76 \pm 3.31 \text{ in}$$

Esto es, podemos tener un 95% de confianza de que las alturas de los hijos están entre 63.4 y 70.1.

(*b*) Si $X_0 = 70.0$, entonces $Y_0 = 69.14$ in. Además, $(X_0 - \bar{X})^2 = (70.0 - 800/12)^2 = 11.11$. Luego los límites de confianza 95% resultan ser 69.14 ± 3.45 in; es decir, con un 95% de confianza las alturas de los hijos están entre 65.7 y 72.6 in.

Nótese que para los valores grandes de N, los límites de confianza 95% vienen dados aproximadamente por $Y_0 \pm 1.96s_{Y.X}$ o sea $Y_0 \pm 2s_{Y.X}$, supuesto que $(X_0 - \bar{X})$ no sea demasiado grande. Eso coincide con los resultados aproximados mencionados en la página 210. Los métodos de este problema son válidos con independencia del valor de N o de $(X_0 - \bar{X})$; esto es, los métodos de muestreo son exactos.

14.39. En el Problema 14.1 hallar los límites de confianza 95% para las alturas medias de los hijos cuyos padres miden (*a*) 65.0 in y (*b*) 70.0 in.

Solución

Ya que $t_{.975} = 2.23$ para 10 grados de libertad, los límites de confianza 95% para $\bar{Y}_p$ (véase página 330) vienen dados por

$$Y_0 \pm \frac{2.23}{\sqrt{10}} s_{Y.X}\sqrt{1 + \frac{(X_0 - \bar{X})^2}{s_X^2}}$$

donde $Y_0 = 35.82 + 0.476X_0$ (Problema 14.1), $s_{Y.X} = 1.28$ y $s_X = 2.66$ (Problema 14.36).

(*a*) Si $X_0 = 65.0$, vemos que los límites de confianza 95% son 66.76 ± 1.07 in [comparar con el Problema 14.38(*a*)]. Es decir, podemos tener 95% de confianza de que la altura media de todos los hijos cuyos padres miden 65.0 in está entre 65.7 y 67.8 in.

(*b*) Si $X_0 = 70.0$, vemos que los límites de confianza 95% son 69.14 ± 1.45 in [comparar con el Problema 14.38(*b*)]. Es decir, podemos tener 95% de confianza de que la *altura media* de todos los hijos cuyos padres miden 70.0 in estará entre 67.7 y 70.6 in.

PROBLEMAS SUPLEMENTARIOS

REGRESION LINEAL Y CORRELACION LINEAL

14.40. La Tabla 14.18 presenta las notas de dos exámenes de Biología, X e Y, de 10 estudiantes.

(*a*) Construir un diagrama de dispersión.

(*b*) Hallar la recta de regresión de mínimos cuadrados de Y sobre X.

(*c*) Hallar la recta de regresión de mínimos cuadrados de X sobre Y.

(*d*) Representar las dos rectas de las partes (*b*) y (*c*) en el diagrama de dispersión de la parte (*a*).